

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH
KHOA ĐIỆN ĐIỆN TỬ
BỘ MÔN KỸ THUẬT MÁY TÍNH



HCM-UTE

ĐỒ ÁN TỐT NGHIỆP

**NGHIÊN CỨU TỐI ƯU HÓA MÔ HÌNH PHÂN LOẠI TÍN
HIỆU ECG BẰNG KỸ THUẬT LƯỢNG TỬ HÓA VÀ TÍCH
CHẬP PHÂN TÁCH CHIỀU SÂU**

NGÀNH CÔNG NGHỆ KỸ THUẬT MÁY TÍNH

Sinh viên: **NGUYỄN HỮU KHOA**
MSSV: **22119191**

TP. HỒ CHÍ MINH – 06/2026

TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT THÀNH PHỐ HỒ CHÍ MINH
KHOA ĐIỆN ĐIỆN TỬ
BỘ MÔN KỸ THUẬT MÁY TÍNH



HCM-UTE

ĐỒ ÁN TỐT NGHIỆP

**NGHIÊN CỨU TỐI ƯU HÓA MÔ HÌNH PHÂN LOẠI TÍN
HIỆU ECG BẰNG KỸ THUẬT LƯỢNG TỬ HÓA VÀ TÍCH
CHẬP PHÂN TÁCH CHIỀU SÂU**

NGÀNH CÔNG NGHỆ KỸ THUẬT MÁY TÍNH

Sinh viên: **NGUYỄN HỮU KHOA**
MSSV: 22119191

Hướng dẫn: **ThS. Huỳnh Hoàng Hà**

TP. HỒ CHÍ MINH – 06/2026

TRANG THÔNG TIN LUẬN VĂN

1.Thông tin sinh viên

Họ và tên sinh viên: NGUYỄN HỮU KHOA

MSSV: 22119191

Email: 22119191@student.hcmute.edu.vn

2.Thông tin đề tài

- Tên đề tài: NGHIÊN CỨU TỐI ƯU HÓA MÔ HÌNH PHÂN LOẠI TÍN HIỆU ECG BẰNG KỸ THUẬT LƯỢNG TỬ HÓA VÀ TÍCH CHẬP PHÂN TÁCH CHIỀU SÂU

- Đơn vị quản lý: Bộ môn kỹ thuật Máy tính, Khoa Điện -Điện tử, Trường Đại học Công Nghệ Kỹ thuật TP. Hồ Chí Minh

- Thời gian thực hiện: Từ ngày....../...../2025 đến ngày/...../2026

- Thời gian bảo vệ: Ngày/...../ 2026.

3.Lời cam đoan

Đề tài “Nghiên cứu tối ưu hóa mô hình phân loại tín hiệu ECG bằng kỹ thuật lượng tử hóa và tích chập phân tách chiều sâu” được sinh viên tự nghiên cứu và thực hiện, quá trình này được thực hiện dựa trên hướng dẫn của ThS. Huỳnh Hoàng Hà và tham khảo một số bài báo khoa học và tài liệu có liên quan, cam kết không sao chép từ các nguồn thông tin trước đó.

TP.HCM, ngày ...tháng ... năm 2026

Người thực hiện

Nguyễn Hữu Khoa

Giảng viên hướng dẫn xác nhận quyền báo cáo đã được chỉnh sửa theo đề nghị ghi trong biên bản của Hội đồng đánh giá Khóa luận tốt nghiệp.

.....

Xác nhận của Bộ môn

Tp. HCM, ngày ... tháng ... năm 2026

Giáo viên hướng dẫn

(Ký, ghi rõ họ tên và học hàm – học vị)

ThS. Huỳnh Hoàng Hà

BẢN NHẬN XÉT KHÓA LUẬN TỐT NGHIỆP

(Dành cho giảng viên hướng dẫn)

Đề tài: Nghiên cứu tối ưu hóa mô hình phân loại tín hiệu ECG bằng kỹ thuật lượng tử hóa và tích chập phân tách chiều sâu.

Sinh viên: Nguyễn Hữu Khoa

MSSV: 22119191

Hướng dẫn: ThS. Huỳnh Hoàng Hà

Nhận xét bao gồm các nội dung sau đây:

1. Tính hợp lý trong cách đặt vấn đề và giải quyết vấn đề; ý nghĩa khoa học và thực tiễn:
 - Đề tài có mục tiêu rõ ràng, nội dung phù hợp chuyên ngành và có tính ứng dụng thực tiễn cao.
2. Phương pháp thực hiện/ phân tích/ thiết kế:
 - Phương pháp nghiên cứu phù hợp, được triển khai có hệ thống và bám sát mục tiêu đề ra.
3. Kết quả thực hiện/ phân tích và đánh giá kết quả/ kiểm định thiết kế:
 - Kết quả đạt được đáp ứng yêu cầu đề tài, có phân tích và đánh giá đầy đủ.
4. Kết luận và đề xuất:
 - Kết luận phù hợp với kết quả nghiên cứu, các hướng phát triển có tính khả thi.
5. Hình thức trình bày và bố cục báo cáo:
 - Báo cáo trình bày rõ ràng, bố cục hợp lý, đúng quy định.
6. Kỹ năng chuyên nghiệp và tính sáng tạo:
 - Sinh viên thể hiện khả năng tự nghiên cứu tốt và có tinh thần chủ động trong thực hiện đề tài.
7. Tài liệu trích dẫn
 - Tài liệu tham khảo phù hợp, được trích dẫn đầy đủ và có độ tin cậy.
8. Đánh giá về sự trùng lặp của đề tài
 - Đề tài không có dấu hiệu trùng lặp với các công trình nghiên cứu đã công bố.
9. Những nhược điểm và thiếu sót, những điểm cần được bổ sung và chỉnh sửa*
 - Cần bổ sung thêm kết quả đánh giá trên nền tảng phần cứng thực tế để tăng tính thuyết phục.
10. Nhận xét tinh thần, thái độ học tập, nghiên cứu của sinh viên
 - Sinh viên có tinh thần học tập nghiêm túc, chủ động và hoàn thành tốt nhiệm vụ được giao.

Đề nghị của giảng viên hướng dẫn

Báo cáo đạt yêu cầu của khóa luận tốt nghiệp kỹ sư và được phép bảo vệ khóa luận tốt nghiệp.

Tp. HCM, ngày 23 tháng 06 năm 2026

Người nhận xét
(Ký và ghi rõ họ tên)


Huỳnh Hoàng Hà

* Giảng viên hướng dẫn có thể ghi tiếp vào mặt sau

LỜI CẢM ƠN

Trong suốt quá trình học tập và thực hiện khóa luận tốt nghiệp tại Trường Đại học Công nghệ Kỹ thuật Thành phố Hồ Chí Minh, tôi đã nhận được nhiều sự hỗ trợ và động viên từ quý Thầy, Cô, gia đình và bạn bè. Đây là nguồn động lực quan trọng giúp tôi hoàn thành khóa luận này.

Trước hết, tôi xin chân thành cảm ơn quý Thầy, Cô thuộc Khoa Điện – Điện tử đã truyền đạt những kiến thức chuyên môn và kinh nghiệm quý báu trong suốt thời gian học tập tại trường. Những kiến thức đó là nền tảng giúp tôi tiếp cận và thực hiện đề tài nghiên cứu này.

Đặc biệt, tôi xin gửi lời cảm ơn sâu sắc đến ThS. Huỳnh Hoàng Hà, giảng viên hướng dẫn đã luôn theo sát, định hướng và hỗ trợ tôi trong suốt quá trình thực hiện khóa luận. Những góp ý chuyên môn, sự tận tình hướng dẫn cũng như những nhận xét kịp thời của thầy đã giúp tôi từng bước hoàn thiện nội dung nghiên cứu và khắc phục các khó khăn phát sinh trong quá trình thực hiện đề tài.

Tôi cũng xin cảm ơn gia đình và bạn bè đã luôn động viên, hỗ trợ và tạo điều kiện thuận lợi để tôi có thể tập trung học tập và hoàn thành khóa luận đúng tiến độ.

Mặc dù đã cố gắng trong quá trình nghiên cứu và thực hiện, khóa luận khó tránh khỏi những hạn chế nhất định. Tôi rất mong nhận được những ý kiến đóng góp từ quý Thầy, Cô để tiếp tục hoàn thiện kiến thức và kinh nghiệm của bản thân trong thời gian tới.

Xin chân thành cảm ơn!

Người thực hiện đề tài

TÓM TẮT

Phân loại tín hiệu điện tâm đồ (ECG) bằng học sâu đang được nghiên cứu rộng rãi nhằm hỗ trợ phát hiện sớm các rối loạn nhịp tim. Tuy nhiên, việc triển khai các mô hình học sâu trên thiết bị nhúng và hệ thống Edge AI vẫn gặp nhiều thách thức do hạn chế về bộ nhớ và năng lực tính toán.

Luận văn này nghiên cứu tối ưu hóa mô hình Mini InceptionNet cho bài toán phân loại năm loại nhịp tim trên cơ sở dữ liệu MIT-BIH Arrhythmia Database. Hai hướng tối ưu hóa được khảo sát gồm: (1) thay thế các lớp Conv1D bằng kiến trúc Depthwise Separable Convolution nhằm giảm độ phức tạp của mô hình; (2) áp dụng các kỹ thuật lượng tử hóa Post-Training Quantization (PTQ) và Quantization-Aware Training (QAT) để giảm kích thước mô hình và tăng tốc độ suy luận.

Kết quả thực nghiệm cho thấy mô hình Mini InceptionNet đạt độ chính xác 98,75%. Sau khi thay thế bằng kiến trúc Depthwise Separable Convolution, số lượng tham số giảm khoảng 34,5% trong khi độ chính xác đạt 97,64%. Đối với lượng tử hóa, mô hình PTQ đạt độ chính xác 97,67%, còn mô hình QAT đạt 98,55%, chỉ thấp hơn 0,20% so với mô hình gốc nhưng vẫn cho phép triển khai dưới định dạng INT8 với kích thước nhỏ và tốc độ suy luận cao.

Kết quả nghiên cứu cho thấy Quantization-Aware Training là giải pháp tối ưu nhất, bảo toàn hiệu năng phân loại đồng thời nâng cao khả năng triển khai trên các hệ thống Edge AI và thiết bị nhúng có tài nguyên hạn chế.

MỤC LỤC

LỜI CẢM ƠN.....	vi
TÓM TẮT.....	vii
DANH MỤC TỪ VIẾT TẮT	xi
DANH MỤC BẢNG BIỂU	xii
DANH MỤC HÌNH ẢNH.....	xiii
CHƯƠNG 1 TỔNG QUAN.....	14
1.1 LÝ DO CHỌN ĐỀ TÀI.....	14
1.2 MỤC TIÊU	15
1.3 NỘI DUNG NGHIÊN CỨU.....	15
1.4 PHẠM VI NGHIÊN CỨU.....	16
1.5 BỐ CỤC.....	16
CHƯƠNG 2 CƠ SỞ LÝ THUYẾT.....	18
2.1 TỔNG QUAN VỀ MẠNG TÍCH CHẬP MỘT CHIỀU (1D CNN)	18
2.1.1 Giới thiệu mạng tích chập 1 chiều	18
2.1.2 Nguyên lý hoạt động của 1D CNN	18
2.1.3 So sánh giữa 2D CNN và 1D CNN	19
2.2 KIẾN TRÚC INCEPTION NET ^[1]	20
2.2.1 Inception Block.....	20
2.2.2 Kiến trúc 1-D Mini InceptionNet.....	23
2.3 TÍCH CHẬP PHÂN TÁCH CHIỀU SÂU ^[4]	25
2.3.1 Nguyên lý hoạt động của Tích chập phân tách chiều sâu	25
2.3.2 So sánh hiệu quả toán học giữa Conv1D và Conv1D-DW	26
2.4 KỸ THUẬT LƯỢNG TỬ HÓA (QUANTIZATION) ^[5]	27
2.4.1 Giải thích cơ chế lượng tử hóa.....	28
2.4.2 Kỹ thuật lượng tử hóa sau huấn luyện (Post-Training Quantization - PTQ).....	29
2.4.3 Kỹ thuật lượng tử hóa trong quá trình huấn luyện (Quantization-Aware Training - QAT).....	30
2.5 TÍN HIỆU ECG VÀ BỘ DỮ LIỆU MIT-BIH	31
2.5.1 Tín hiệu điện tâm đồ (ECG)	31
2.5.2 Thách thức trong phân loại tín hiệu ECG	32

2.5.3 Cơ sở dữ liệu MIT-BIH Arrhythmia Database.....	32
2.5.4 Phân bố dữ liệu	33
2.6 CÁC CHỈ SỐ ĐÁNH GIÁ MÔ HÌNH.....	33
2.6.1 Ma trận nhầm lẫn (Confusion Matrix - CM).....	33
2.6.2 Accuracy	34
2.6.3 Precision	35
2.6.4 Recall.....	35
2.6.5 F1-score	35
2.6.6 Số lượng tham số	36
2.6.7 Kích thước mô hình.....	36
2.6.8 Thời gian suy luận.....	36
CHƯƠNG 3 PHƯƠNG PHÁP ĐỀ XUẤT VÀ TRIỂN KHAI	37
3.1 TỔNG QUAN PHƯƠNG PHÁP NGHIÊN CỨU.....	37
3.2 MÔ HÌNH CƠ SỞ MINI INCEPTIONNET	38
3.2.1 Kiến trúc mô hình gốc	38
3.2.2 Kết quả thực nghiệm và so sánh với bài báo gốc	39
3.2.3 Phân tích hạn chế của mô hình cơ sở.....	41
3.3 ĐỀ XUẤT TỐI ƯU KIẾN TRÚC BẰNG TÍCH CHẬP PHÂN TÁCH THEO CHIỀU SÂU.....	42
3.3.1 Thiết kế khối Conv1D-DW	42
3.3.2 Tích hợp Conv1D-DW vào kiến trúc Mini InceptionNet	43
3.3.3 Xử lý mất cân bằng dữ liệu	44
3.3.4 Phân tích lợi ích lý thuyết của Conv1D-DW.....	47
3.4 ĐỀ XUẤT TỐI ƯU ĐỊNH DẠNG DỮ LIỆU BẰNG KỸ THUẬT LƯỢNG TỬ HÓA	48
3.4.1 Tối ưu hóa bằng post-training quantization (PTQ).....	48
3.4.2 Tối ưu hóa bằng quantization-aware training (QAT)	51
3.5 CÁC MÔ HÌNH THỰC NGHIỆM	55
3.6 MÔI TRƯỜNG THỰC NGHIỆM	57
3.6.1 Cấu hình phần cứng	57
3.6.2 Môi trường phần mềm.....	57
3.6.3 Bộ dữ liệu thực nghiệm	57
3.6.4 Quy trình đánh giá.....	58
CHƯƠNG 4 KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ.....	59
4.1 KẾT QUẢ TỐI ƯU HÓA BẰNG DEPTHWISE SEPARABLE CONVOLUTION.....	59
4.1.1 Kết quả huấn luyện.....	59
4.1.2 Ma trận nhầm lẫn của mô hình Mini InceptionNet-DW	61

4.1.3 So sánh ma trận nhầm lẫn trước và sau khi áp dụng Focal Loss + Class Weight	62
4.1.4 Nhận xét.....	64
4.2 KẾT QUẢ LƯỢNG TỬ HÓA PTQ	64
4.2.1 Kết quả phân loại	64
4.2.2 Ma trận nhầm lẫn của mô hình PTQ.....	65
4.2.3 Nhận xét.....	66
4.3 KẾT QUẢ LƯỢNG TỬ HÓA QAT.....	66
4.3.1 So sánh các chiến lược QAT	66
4.3.2 Kết quả mô hình QAT tốt nhất	67
4.3.3 Ma trận nhầm lẫn của mô hình QAT	68
4.3.4 Nhận xét.....	68
4.4 SO SÁNH TỔNG HỢP CÁC MÔ HÌNH	69
4.4.1 So sánh tổng hợp.....	69
4.4.2 So sánh độ chính xác phân loại.....	70
4.4.3 So sánh số lượng tham số	70
4.4.4 So sánh kích thước mô hình và cấu trúc TensorFlow Lite	71
4.4.5 So sánh thời gian suy luận.....	71
4.4.6 Nhận xét tổng hợp.....	73
4.5 THẢO LUẬN	74
4.5.1 Ảnh hưởng của kiến trúc Depthwise Separable Convolution	74
4.5.2 So sánh hiệu quả giữa PTQ và QAT.....	75
4.5.3 Khả năng kết hợp Conv1D-DW và lượng tử hóa	76
4.5.4 Mô hình tối ưu được lựa chọn	76
CHƯƠNG 5 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	78
5.1 KẾT LUẬN.....	78
5.2 HƯỚNG PHÁT TRIỂN	79
TÀI LIỆU THAM KHẢO	80

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Ý nghĩa
AI	Artificial Intelligence
ANN	Artificial Neural Network
APB	Atrial Premature Beat
CM	Confusion Matrix – Ma trận nhầm lẫn
CNN	Convolutional Neural Network
Conv	Convolution
Conv1D-DW	1D Depthwise Separable Convolution
CPU	Central Processing Unit
DL	Deep Learning
Dense	Dense Layer
DW	Depthwise Convolution
ECG	Electrocardiogram
FLOPs	Floating Point Operations
FPGA	Field Programmable Gate Array
GAP	Global Average Pooling
INT8	8-bit Integer
LBBB	Left Bundle Branch Block
MACs	Multiply-Accumulate Operations
MIT-BIH	MIT-BIH Arrhythmia Database
PTQ	Post-Training Quantization
PVC	Premature Ventricular Contraction
PW	Pointwise Convolution
QAT	Quantization-Aware Training
QRS	QRS Complex
RAM	Random Access Memory
ReLU	Rectified Linear Unit
RBBB	Right Bundle Branch Block
SEN	Sensitivity (Recall)
SPEC	Specificity
PPV	Positive Predictive Value (Precision)
TFLite	TensorFlow Lite
TFMOT	TensorFlow Model Optimization Toolkit

DANH MỤC BẢNG BIỂU

Bảng 2.1 So sánh 2D CNN và 1D CNN	19
Bảng 2.2 So sánh PTQ và QAT	31
Bảng 2.3 Số lượng mẫu của từng lớp được sử dụng trong nghiên cứu.	33
Bảng 2.4 Mối quan hệ giữa kết quả thực tế và kết quả dự đoán của mô hình	34
Bảng 3.1 So sánh kết quả thực nghiệm thu được với bài báo gốc	39
Bảng 3.2 Các Conv1D được thay thế bằng Conv1D-DW	43
Bảng 3.3 Trọng số class weight cho từng lớp	45
Bảng 3.4 Tham số cấu hình lượng tử PTQ.....	49
Bảng 3.5 Toàn bộ mô hình được sử dụng trong quá trình thực nghiệm.....	55
Bảng 3.6 Cấu hình phần cứng.....	57
Bảng 3.7 Môi trường phần mềm	57
Bảng 4.1 Kết quả đánh giá mô hình Mini InceptionNet-DW trên tập kiểm tra và so sánh với mô hình Mini InceptionNet gốc.	60
Bảng 4.2 Kết quả đánh giá	62
Bảng 4.3 so sánh số lượng lớp APB khi không áp dụng và có áp dụng Focal Loss và Class Weight	63
Bảng 4.4 Kết quả lượng tử hóa PQT trên model gốc	64
Bảng 4.5 Kết quả đánh giá các chiến lược QAT được thực hiện.....	66
Bảng 4.6 Kết quả so sánh giữa mô hình Float32 và mô hình QAT được lựa chọn.	67
Bảng 4.7 Bảng so sánh tổng hợp các mô hình chính trong nghiên cứu	69
Bảng 4.8 So sánh kích thước sau lượng tử.....	71
Bảng 4.9 Thời gian suy luận của mô hình.....	71

DANH MỤC HÌNH ẢNH

Hình 2.1 Inception Block	21
Hình 2.2 Kiến trúc Mini InceptionNet	24
Hình 3.1 Luồng nghiên cứu chính	38
Hình 3.2 CM của mô hình MiniInceptionNet thực nghiệm trên tập kiểm tra	40
Hình 3.3 Cấu trúc khối Conv1D-DW	42
Hình 3.4 Kiến trúc mô hình Mini InceptionNet – DW	44
Hình 3.5 Quy trình thực hiện lượng tử hóa PTQ trên model gốc	48
Hình 3.6 Quy trình thực hiện lượng tử hóa QAT	54
Hình 4.1 Biểu đồ Loss thu được sau huấn luyện	59
Hình 4.2 Biểu đồ Accuracy thu được sau huấn luyện	60
Hình 4.3 CM của mô hình Mini InceptionNet-DW trên tập kiểm tra	61
Hình 4.4 CM của mô hình Mini InceptionNet-DW không sử dụng Focal Loss và Class Weight	63
Hình 4.5 CM của mô hình Mini InceptionNet + PTQ (Full INT8)	65
Hình 4.6 CM của mô hình Mini InceptionNet + QAT	68
Hình 4.7 So sánh metric của các mô hình	70
Hình 4.8 So sánh thời gian suy luận trung bình	72

CHƯƠNG 1

TỔNG QUAN

1.1 LÝ DO CHỌN ĐỀ TÀI

Sự phát triển của các thiết bị theo dõi sức khỏe cá nhân và các hệ thống chăm sóc y tế thông minh đã làm gia tăng nhu cầu xử lý tín hiệu sinh học trực tiếp trên thiết bị biên (Edge Device). Trong số đó, tín hiệu điện tâm đồ (ECG) được xem là nguồn thông tin quan trọng giúp phát hiện các bất thường về nhịp tim và hỗ trợ chẩn đoán sớm nhiều bệnh lý tim mạch. Việc tự động phân tích tín hiệu ECG bằng trí tuệ nhân tạo đang trở thành một hướng nghiên cứu nhận được nhiều sự quan tâm nhờ khả năng hỗ trợ bác sĩ trong quá trình sàng lọc và đánh giá bệnh nhân.

Các mô hình học sâu hiện nay có khả năng đạt độ chính xác rất cao trong bài toán phân loại tín hiệu ECG. Tuy nhiên, phần lớn các mô hình này được phát triển với mục tiêu tối đa hóa hiệu năng phân loại mà chưa chú trọng đến khả năng triển khai trên các nền tảng phần cứng có tài nguyên hạn chế. Khi được ứng dụng vào các thiết bị nhúng, thiết bị đeo hoặc các hệ thống Edge AI, kích thước mô hình, dung lượng bộ nhớ và thời gian suy luận trở thành những yếu tố quan trọng không kém độ chính xác.

Mini InceptionNet là một kiến trúc mạng nơ-ron tích chập được thiết kế hướng đến các ứng dụng phân loại ECG với số lượng tham số tương đối nhỏ nhưng vẫn duy trì hiệu năng cao. Mặc dù vậy, mô hình vẫn còn tiềm năng tối ưu thêm nhằm giảm chi phí tính toán và nâng cao khả năng triển khai thực tế. Điều này đặt ra câu hỏi nghiên cứu: liệu có thể tiếp tục giảm độ phức tạp của mô hình mà vẫn duy trì được độ chính xác phân loại ở mức chấp nhận được hay không?

Từ những yêu cầu thực tiễn và bài toán kỹ thuật nêu trên, đề tài “Nghiên cứu tối ưu hóa mô hình phân loại tín hiệu ECG bằng kỹ thuật lượng tử hóa và tích chập phân tách chiều sâu” được thực hiện nhằm đánh giá hiệu quả của các phương pháp tối ưu hóa đối với mô hình Mini InceptionNet, đồng thời tìm ra giải pháp cân bằng

giữa độ chính xác, kích thước mô hình và hiệu năng xử lý phục vụ cho các ứng dụng Edge AI trong lĩnh vực chăm sóc sức khỏe.

1.2 MỤC TIÊU

Mục tiêu của đề tài là nghiên cứu và tối ưu hóa mô hình Mini InceptionNet cho bài toán phân loại tín hiệu điện tâm đồ (ECG), hướng tới việc giảm độ phức tạp tính toán, giảm kích thước mô hình nhưng vẫn duy trì độ chính xác phân loại ở mức cao, từ đó nâng cao khả năng triển khai trên các hệ thống nhúng và thiết bị Edge AI.

- Tối ưu hóa kiến trúc mạng bằng cách thay thế các lớp Conv1D truyền thống bằng tích chập phân tách chiều sâu (Depthwise Separable Convolution) nhằm giảm số lượng tham số và chi phí tính toán.
- Tối ưu hóa mô hình bằng các kỹ thuật lượng tử hóa gồm Post-Training Quantization (PTQ) và Quantization-Aware Training (QAT) nhằm giảm kích thước lưu trữ và tăng tốc độ suy luận.
- Đánh giá ảnh hưởng của từng phương pháp tối ưu hóa đến độ chính xác phân loại, số lượng tham số, kích thước mô hình và thời gian suy luận.
- Đề xuất phương án tối ưu phù hợp cho bài toán phân loại tín hiệu ECG trên các nền tảng có tài nguyên phần cứng hạn chế.

1.3 NỘI DUNG NGHIÊN CỨU

Để thực hiện các mục tiêu đã đề ra, đề tài tiến hành các nội dung nghiên cứu sau:

1. Nghiên cứu cơ sở lý thuyết liên quan đến tín hiệu điện tâm đồ (ECG), mạng nơ-ron tích chập một chiều (1D-CNN), tích chập phân tách chiều sâu (Depthwise Separable Convolution) và các kỹ thuật lượng tử hóa mô hình học sâu.
2. Khảo sát bộ dữ liệu MIT-BIH Arrhythmia Database, thực hiện tiền xử lý dữ liệu và phân tích mô hình Mini InceptionNet [1] làm mô hình cơ sở cho bài toán phân loại ECG.

3. Thiết kế và xây dựng mô hình Mini InceptionNet-DW bằng cách thay thế các lớp tích chập Conv1D trong kiến trúc gốc bằng các khối Depthwise Separable Convolution.
4. Triển khai kỹ thuật lượng tử hóa sau huấn luyện (Post-Training Quantization - PTQ) và lượng tử hóa nhận thức trong quá trình huấn luyện (Quantization-Aware Training - QAT) trên các mô hình nghiên cứu.
5. Thực hiện huấn luyện, kiểm thử và đánh giá các mô hình thông qua các chỉ số Accuracy, Precision, Recall, F1-score, số lượng tham số, kích thước mô hình và thời gian suy luận.
6. So sánh kết quả giữa mô hình cơ sở và các mô hình tối ưu hóa nhằm xác định giải pháp đạt hiệu quả tốt nhất về độ chính xác và khả năng triển khai thực tế.

1.4 PHẠM VI NGHIÊN CỨU

Đề tài tập trung nghiên cứu tối ưu hóa mô hình Mini InceptionNet cho bài toán phân loại tín hiệu ECG trên cơ sở dữ liệu MIT-BIH Arrhythmia Database thông qua hai hướng tiếp cận chính:

- Áp dụng các kỹ thuật lượng tử hóa gồm Post-Training Quantization (PTQ) và Quantization-Aware Training (QAT).
- Thay thế các lớp Conv1D bằng kiến trúc Depthwise Separable Convolution nhằm giảm số lượng tham số và chi phí tính toán.

Hiệu quả của các phương pháp được đánh giá dựa trên các chỉ số Accuracy, Precision, Recall, F1-score, số lượng tham số, kích thước mô hình và thời gian suy luận.

Đề tài không đi sâu vào thiết kế phần cứng chuyên dụng (FPGA, ASIC), thu thập dữ liệu ECG thực tế hoặc xây dựng hệ thống chẩn đoán lâm sàng hoàn chỉnh.

1.5 BỐ CỤC

Nội dung khóa luận được trình bày trong 5 chương:

- **Chương 1: Tổng quan**

Trình bày lý do chọn đề tài, mục tiêu, nội dung, phạm vi nghiên cứu và bố cục khóa luận.

- **Chương 2: Cơ sở lý thuyết**

Trình bày các kiến thức nền tảng về 1D-CNN, InceptionNet, Depthwise Separable Convolution, Quantization, tập dữ liệu MIT-BIH và các thông số đánh giá được sử dụng.

- **Chương 3: Phương pháp đề xuất và triển khai**

Trình bày mô hình cơ sở Mini InceptionNet, đề xuất phương pháp tối ưu bằng ConvDW, lượng tử PTQ và QAT.

- **Chương 4: Kết quả thực nghiệm và đánh giá**

Phân tích, so sánh và đánh giá hiệu năng của các mô hình thông qua các chỉ số thực nghiệm.

- **Chương 5: Kết luận và hướng phát triển**

Tổng kết các kết quả đạt được và đề xuất các hướng nghiên cứu tiếp theo.

CHƯƠNG 2

CƠ SỞ LÝ THUYẾT

2.1 TỔNG QUAN VỀ MẠNG TÍCH CHẬP MỘT CHIỀU (1D CNN)

2.1.1 Giới thiệu mạng tích chập 1 chiều

Đối với các dữ liệu dạng chuỗi thời gian (Time-series data) hoặc tín hiệu một chiều như âm thanh, sóng điện tâm đồ (ECG), tín hiệu rung động của cảm biến gia tốc, việc áp dụng mạng 2D CNN truyền thống là không cần thiết và gây lãng phí tài nguyên tính toán. Mạng Tích chập Một chiều (1D CNN) ra đời trở thành một giải pháp tối ưu và hiệu quả cho các loại dữ liệu này.

2.1.2 Nguyên lý hoạt động của 1D CNN

Trong mạng 1D CNN, các bộ lọc (kernels) chỉ có một chiều vật lý và chỉ trượt dọc theo trục thời gian (hoặc trục chuỗi dữ liệu) của tín hiệu đầu vào. Ngoài kích thước kernel, stride là tham số xác định bước dịch chuyển của bộ lọc trên tín hiệu đầu vào. Giá trị stride lớn hơn 1 giúp giảm kích thước dữ liệu đầu ra và giảm chi phí tính toán.

Giả sử tín hiệu đầu vào một chiều có chiều dài là L và số kênh là K . Một bộ lọc toán học có kích thước kernel là J sẽ thực hiện phép toán tích chập một chiều để tạo ra một bản đồ đặc trưng đầu ra. Giá trị tại vị trí y của bản đồ đặc trưng thứ n được tính toán theo công thức:

$$Z[n, y] = \sum_{k=0}^{K-1} \sum_{j=0}^{J-1} W[n, k, j] \times X[k, y \times s + j] + b[n] \quad (2.1)$$

Trong đó:

Biến số	Phạm vi	Mô tả
$Z[n, y]$	$0 \leq n < N,$ $0 \leq y < Y$	Đầu ra tích chập (Output Feature Map) tại kênh đầu ra thứ n và vị trí đầu ra thứ y .

N		Số kênh đầu ra (Output Channel index).
Y		Kích thước đầu ra (Output Position index).
K		Số kênh đầu vào (Input Channel index).
J		Kích thước kernel (Kernel size) (ví dụ: 1, 3, 5, 7).
$W[n,k,j]$		Trọng số (Weight) của kernel, ứng với kênh đầu ra n , kênh đầu vào k , và kernel j .
$X[k,y \times s + j]$		Giá trị đầu vào (Pixel Input) tại kênh đầu vào k và vị trí dữ liệu đầu vào cụ thể ($y \times s + j$).
s		Bước nhảy (Stride), khoảng cách di chuyển của kernel.
$b[n]$		Độ lệch (Bias), chỉ áp dụng cho kênh đầu ra n .

Và chiều dài đầu ra được tính theo công thức:

$$Y = \left(\frac{L - J + 2P}{s} \right) + 1 \quad (2.2)$$

Trong đó:

- L : chiều dài tín hiệu đầu vào.
- J : kích thước kernel.
- P : số phần tử padding.
- s : stride.
- Y : chiều dài đầu ra.

2.1.3 So sánh giữa 2D CNN và 1D CNN

Bảng 2.1 So sánh 2D CNN và 1D CNN

Tiêu chí	2D CNN	1D CNN
Dữ liệu đầu vào	Ảnh	Chuỗi thời gian
Kernel	$K \times K$	$K \times 1$
Số tham số	Lớn	Nhỏ hơn
Chi phí tính toán	Cao	Thấp

Ứng dụng	Vision	ECG, EEG, Audio
-----------------	--------	-----------------

Kích thước bộ lọc: Bộ lọc của 2D CNN có kích thước $K_h * K_w$ (trượt theo cả hai chiều không gian x và y), trong khi bộ lọc của 1D CNN chỉ có kích thước $K * 1$ (chỉ trượt theo một chiều thời gian).

Khối lượng tính toán: Khối lượng tính toán và số lượng tham số của 1D CNN thấp hơn nhiều so với 2D CNN. Điều này làm cho 1D CNN cực kỳ phù hợp để triển khai trên các hệ thống nhúng, thiết bị vi điều khiển có tài nguyên phần cứng hạn chế về cả bộ nhớ RAM, Flash lẫn xung nhịp xử lý (CPU).


Khả năng trích xuất đặc trưng thời gian: 1D CNN có khả năng học được các mẫu đặc trưng cục bộ theo trình tự thời gian (như các đoạn sóng P-Q-R-S-T đặc trưng trong tín hiệu điện tâm đồ ECG) một cách hiệu quả mà không bị ảnh hưởng bởi nhiễu tần số cao hoặc sự thay đổi biên độ cục bộ mang tính toàn cục.

Nhờ khả năng khai thác các đặc trưng cục bộ theo thời gian cùng với chi phí tính toán thấp, mạng 1D-CNN đã trở thành một trong những kiến trúc được sử dụng phổ biến trong các hệ thống phân loại tín hiệu ECG. Nhiều nghiên cứu gần đây đã đề xuất các biến thể của 1D-CNN nhằm nâng cao độ chính xác và giảm độ phức tạp của mô hình, trong đó có kiến trúc Mini InceptionNet được sử dụng làm mô hình nền trong nghiên cứu này.

2.2 KIẾN TRÚC INCEPTION NET ^[1]

2.2.1 Inception Block

Khối Inception là thành phần cốt lõi trong kiến trúc InceptionNet, được thiết kế nhằm trích xuất đặc trưng ở nhiều tỷ lệ khác nhau thông qua các nhánh xử lý song song. Cấu trúc của một khối Inception được thể hiện trong Hình 2.1



Hình 2.1 Inception Block

Từ dữ liệu đầu vào, tín hiệu được chia thành hai nhánh chính:

- Nhánh Max-Pooling: Dữ liệu đầu vào được đưa qua lớp MaxPooling1D với kích thước kernel ($J=3$) và ($\text{stride}=1$), giúp giữ lại các đặc trưng nổi bật đồng thời giảm ảnh hưởng của nhiễu. Sau đó, đầu ra tiếp tục được xử lý bởi lớp Conv1D có kích thước kernel ($J=1$).
- Nhánh Bottleneck: Dữ liệu đầu vào được đưa qua lớp Conv1D có kích thước kernel ($J=1$). Lớp tích chập này đóng vai trò như một lớp bottleneck nhằm giảm số lượng kênh đặc trưng trước khi đưa vào các lớp tích chập có kích thước lớn hơn. Nhờ đó, số lượng tham số và chi phí tính toán của mô hình được giảm đáng kể.

Sau lớp bottleneck, dữ liệu được xử lý song song bởi ba lớp tích chập Conv1D có kích thước kernel lần lượt là ($J=3$), ($J=5$) và ($J=7$). Các kernel có kích thước khác nhau cho phép mạng học được các đặc trưng ở nhiều mức độ chi tiết khác nhau, từ các mẫu cục bộ đến các mẫu có phạm vi rộng hơn trên tín hiệu. Kích thước kernel ở các Conv truyền thống thường là 1 số cố định (ví dụ: $J = 5$) để cân bằng giữa kích thước và hiệu quả tính toán. Việc giữ cố định J giúp đơn giản phần cứng nhưng lại làm kém linh hoạt, không tận dụng được phần cứng làm giảm tốc độ và độ chính xác của mô hình.

Trong khối Inception, số kênh đầu ra của mỗi nhánh tích chập được thiết kế bằng $(N/4)$, với (N) là số kênh đầu ra của toàn bộ khối. Sau khi xử lý, các bản đồ đặc trưng từ bốn nhánh Conv được ghép nối theo chiều kênh để tạo thành một bản đồ đặc trưng mới có tổng số kênh bằng (N) . Quá trình này được gọi là Filter Concatenation.

Cuối cùng, đầu ra sau khi ghép nối được đưa qua hàm kích hoạt ReLU nhằm tăng khả năng biểu diễn phi tuyến của mô hình.

Đối với một lớp tích chập một chiều thông thường, số lượng tham số được xác định bởi:

$$P = K \times N \times J + N \quad (2.3)$$

Trong đó:

- (K) : số kênh đầu vào;
- (N) : số kênh đầu ra;
- (J) : kích thước kernel.

Nhờ sử dụng lớp bottleneck Conv1D ($(J=1)$), số kênh đầu vào của các lớp ConvJ3, ConvJ5 và ConvJ7 được giảm từ (K) xuống còn $(N/4)$. Điều này giúp giảm đáng kể số lượng tham số và chi phí tính toán so với việc áp dụng trực tiếp các lớp tích chập có kích thước kernel lớn trên toàn bộ dữ liệu đầu vào.

Tổng số paramater của khối Inception được tính như sau [1]:

$$P_{Incept} = P_{ConvJ1.1} + P_{ConvJ1.2} + P_{ConvJ3} + P_{ConvJ5} + P_{ConvJ7} \quad (2.4)$$

Trong đó, 2 lớp Conv với kích thước kernel $J=1$ sẽ có công thức [1]:

$$P_{ConvJ1.1} = K \times \frac{N}{4} \times 1 + \frac{N}{4} \quad (2.5)$$

$$P_{ConvJ1.2} = K \times \frac{N}{4} \times 1 + \frac{N}{4} \quad (2.6)$$

Khi đó đầu vào của các lớp Conv còn lại trong khối (J= 3, 5, 7) không còn là K nữa mà được thay bằng $\frac{N}{4}$ [1]:

$$P_{ConvJ3} = \frac{N}{4} \times \frac{N}{4} \times 3 + \frac{N}{4} \quad (2.7)$$

$$P_{ConvJ5} = \frac{N}{4} \times \frac{N}{4} \times 5 + \frac{N}{4} \quad (2.8)$$

$$P_{ConvJ7} = \frac{N}{4} \times \frac{N}{4} \times 7 + \frac{N}{4} \quad (2.9)$$

Đem (2.5), (2.6), (2.7), (2.8), (2.9) thay vào (2.4) được kết quả:

$$P_{Incept} = K \times \frac{N}{2} + \frac{15}{16} \times (N)^2 + \frac{5 \times N}{4} \quad (2.10)$$

Giả sử K=8, N=8, tổng tham số paramater của khối Inception là:

$$P_{Incept} = 8 \times \frac{8}{2} + \frac{15}{16} \times (8)^2 + \frac{5 \times 8}{4} = 32 + 60 + 10 = \mathbf{102} \text{ (tham số)}$$

So với khối tích chập thông thường (J=3):

$$P = 8 \times 8 \times 3 + 8 = \mathbf{200} \text{ (tham số)}$$

Khối Inception (1D) thể hiện ưu thế vượt trội về thiết kế kiến trúc khi tối ưu lượng tham số giảm gần **2 lần** so với một lớp tích chập thông thường (102 so với 200 tham số). Sự tối ưu này đạt được nhờ cơ chế nén kênh đầu vào (bottleneck) từ K=8 xuống còn 2, giúp triệt tiêu sự bùng nổ tham số. Đặc biệt, dù dung lượng nhẹ hơn đáng kể, khối Inception vẫn mang lại sức mạnh biểu diễn tri thức mạnh mẽ hơn nhờ khả năng trích xuất đặc trưng đa quy mô đồng thời trên nhiều kích thước kernel J=1, 3, 5, 7, giúp mô hình vừa tiết kiệm bộ nhớ, vừa học được ngữ cảnh rộng mà không bị quá khớp.

2.2.2 Kiến trúc 1-D Mini InceptionNet

Kiến trúc 1-D Mini InceptionNet được xây dựng dựa trên các khối Inception nhằm tối ưu sự cân bằng giữa độ chính xác phân loại và số lượng tham số của mô hình. Cấu trúc tổng thể của mạng được trình bày trong Hình 2.2.

Đầu vào của mạng là tín hiệu ECG có kích thước (320, 1). Dữ liệu trước tiên được đưa qua lớp Conv1D với kích thước kernel ($J=7$) và ($\text{stride}=2$), tạo ra bản đồ đặc trưng kích thước (160, 8). Tín hiệu ECG có tần số thấp (0.1–50 Hz) và các đặc trưng quan trọng (như phức bộ QRS, sóng P, sóng T) trải rộng trên một đoạn tín hiệu đáng kể. Việc sử dụng kernel lớn (như $J=7$) ngay từ đầu giúp mở rộng trường tiếp nhận (receptive field), cho phép mô hình thu thập các mẫu tín hiệu có ý nghĩa tốt hơn so với các kernel nhỏ ($J=1,3$).

Sau lớp tích chập đầu tiên, dữ liệu lần lượt đi qua ba giai đoạn xử lý. Mỗi giai đoạn bao gồm hai khối Inception liên tiếp và một lớp Conv1D với bước nhảy = 2 giúp thay đổi kích thước bản đồ đặc trưng. Kích thước dữ liệu được giảm dần từ:

$$(320, 1) \rightarrow (160, 8) \rightarrow (80, 16) \rightarrow (40, 32)$$


Nhờ việc sử dụng các khối Inception, mô hình có khả năng trích xuất đồng thời các đặc trưng ở nhiều tỷ lệ khác nhau trong từng giai đoạn xử lý. Điều này giúp nâng cao khả năng nhận diện các mẫu đặc trưng của tín hiệu ECG mà không làm tăng số lượng tham số đáng kể.

Để cải thiện quá trình huấn luyện, Mini InceptionNet sử dụng cơ chế Residual Connection giữa đầu vào và đầu ra của mỗi nhóm Inception Block. Đầu ra của khối được xác định bởi:

$$Z = F(X) + X \quad (2.11)$$

Trong đó:

- (X) là đầu vào của khối;
- ($F(X)$) là đầu ra của các phép biến đổi bên trong khối;
- (Z) là đầu ra cuối cùng sau phép cộng tắt.



Hình 2.2 Kiến trúc Mini InceptionNet

Residual Connection tạo ra một đường truyền gradient trực tiếp từ đầu ra về đầu vào của khối mạng, qua đó giảm hiện tượng tiêu biến gradient (vanishing gradient) và giúp quá trình huấn luyện ổn định hơn đối với các mô hình sâu.

Sau giai đoạn trích xuất đặc trưng, dữ liệu được đưa qua lớp Global Average Pooling để giảm số chiều của đặc trưng trước khi đi vào lớp Fully Connected cuối cùng thực hiện nhiệm vụ phân loại tín hiệu ECG.

2.3 TÍCH CHẬP PHÂN TÁCH CHIỀU SÂU ^[4]

Để một mô hình học sâu triển khai được trên thiết bị nhúng, thiết bị di động hoặc các hệ thống Edge AI có tài nguyên phần cứng hạn chế, việc giảm số lượng tham số và chi phí tính toán là yêu cầu quan trọng nhằm giảm bộ nhớ lưu trữ, tăng tốc độ suy luận và tiết kiệm năng lượng. Một trong những giải pháp hiệu quả được đề xuất trong kiến trúc MobileNet là Tích chập phân tách chiều sâu (Depthwise Separable Convolution) [4].

2.3.1 Nguyên lý hoạt động của Tích chập phân tách chiều sâu

Một lớp tích chập một chiều (1D Conv) thông thường xử lý đồng thời việc trích xuất đặc trưng không gian và kết hợp thông tin giữa các kênh. Ngược lại, Tích chập tách biệt theo chiều sâu phân tách quá trình này thành hai bước độc lập hoàn toàn: Tích chập chiều sâu (Depthwise Convolution - DW) và Tích chập điểm (Pointwise Convolution - PW). Nhờ đó, số lượng tham số và khối lượng tính toán của mô hình được giảm đáng kể trong khi vẫn duy trì khả năng biểu diễn đặc trưng.

Bước 1: Tích chập chiều sâu (Depthwise Convolution)

Ở bước này, thay vì sử dụng các bộ lọc đa kênh để quét qua tất cả các kênh dữ liệu cùng lúc, hệ thống áp dụng một bộ lọc một chiều (1D kernel) riêng biệt cho từng kênh đầu vào độc lập.

Giả sử tín hiệu đầu vào có số kênh là C_{in} , ta sẽ sử dụng chính xác C_{in} bộ lọc có kích thước toán học là K . Mỗi bộ lọc chỉ thực hiện tính toán trên một kênh duy nhất được chỉ định, tạo ra C_{in} bản đồ đặc trưng đầu ra tương ứng. Quá trình này hoàn toàn chỉ tập trung vào việc trích xuất đặc trưng không gian theo trục thời gian

cục bộ của từng kênh mà không có sự giao thoa hay tổng hợp thông tin giữa các kênh với nhau.

Bước 2: Tích chập điểm (Pointwise Convolution)

Để tổng hợp và hòa trộn thông tin từ các kênh độc lập được tạo ra từ bước Depthwise, bước Tích chập điểm được áp dụng ngay sau đó. Tích chập điểm bản chất là một phép toán tích chập thông thường nhưng có kích thước bộ lọc cố định tối giản là 1 (Kernel size = 1).

Mỗi bộ lọc 1x1 này sẽ quét qua toàn bộ độ sâu (kênh) tại từng điểm thời gian của dữ liệu, thực hiện một phép tổ hợp tuyến tính qua các kênh để biến đổi số lượng kênh từ C_{in} sang số lượng kênh đầu ra mong muốn là C_{out} .

Nhờ việc tách riêng hai quá trình trích xuất đặc trưng và kết hợp thông tin kênh, Depthwise Separable Convolution giúp giảm đáng kể độ phức tạp tính toán so với lớp tích chập truyền thống [4].

2.3.2 So sánh hiệu quả toán học giữa Conv1D và Conv1D-DW

Giả sử tín hiệu đầu vào có chiều dài (L), số kênh đầu vào là (C_{in}), số kênh đầu ra là (C_{out}) và kích thước kernel là (K).

1. Đối với lớp Tích chập 1D thông thường (Standard Conv1D):

- Số lượng tham số (không tính bias):

$$P_{standard} = K \cdot C_{in} \cdot C_{out} \quad (2.12)$$

- Số lượng phép toán tính toán (MACs):

$$M_{standard} = L \cdot K \cdot C_{in} \cdot C_{out} \quad (2.13)$$

2. Đối với lớp Tích chập tách biệt chiều sâu (Depthwise Separable Conv1D):

- Số lượng tham số (cho cả 2 bước DW và PW):

$$P_{separable} = \underbrace{K \cdot C_{in}}_{\text{Depthwise}} + \underbrace{1 \cdot C_{in} \cdot C_{out}}_{\text{Pointwise}} \quad (2.14)$$

- Số lượng phép toán tính toán (MACs):

$$M_{separable} = \underbrace{L \cdot K \cdot C_{in}}_{\text{Depthwise}} + \underbrace{L \cdot 1 \cdot C_{in} \cdot C_{out}}_{\text{Pointwise}} \quad (2.15)$$

3. Tỷ lệ cải tiến và tối ưu tài nguyên:

Ta lập tỷ lệ so sánh về mặt khối lượng tính toán toán học:

$$\frac{M_{\text{separable}}}{M_{\text{standard}}} = \frac{L \cdot K \cdot C_{in} + L \cdot C_{in} \cdot C_{out}}{L \cdot K \cdot C_{in} \cdot C_{out}} = \frac{K + C_{out}}{K \cdot C_{out}} = \frac{1}{C_{out}} + \frac{1}{K} \quad (2.16)$$

Trong các kiến trúc mạng Deep Learning hiện đại, số lượng kênh đầu ra C_{out} thường rất lớn (ví dụ: 32, 64, 128, 256 nơ-ron). Do đó, giá trị $\frac{1}{C_{out}}$ tiến dần về 0.

Lúc này, tỷ lệ tiết kiệm tài nguyên tính toán phụ thuộc chủ yếu vào kích thước bộ lọc K :

$$\frac{M_{\text{separable}}}{M_{\text{standard}}} \approx \frac{1}{K}$$

Điều này cho thấy chi phí tính toán của Depthwise Separable Convolution chỉ còn xấp xỉ ($1/K$) so với lớp Conv1D thông thường. Ví dụ thực tế: Nếu cấu hình mạng sử dụng bộ lọc kích thước $K = 5$, việc chuyển đổi sang dạng Separable giúp giảm tới gần 80% (hay giảm ~ 5 lần) số lượng tham số và khối lượng tính toán của lớp đó, giúp mô hình trở nên cực kỳ gọn nhẹ, góp phần đáng kể vào việc tối ưu hóa mô hình cho các nền tảng phần cứng có tài nguyên hạn chế.

2.4 KỸ THUẬT LƯỢNG TỬ HÓA (QUANTIZATION) [5]

Lượng tử hóa mô hình (Model Quantization) là quá trình chuyển đổi các trọng số (weights) và các giá trị kích hoạt (activations) của mạng nơ-ron từ kiểu dữ liệu số thực dấu phẩy động độ chính xác cao (thường là Float32 - 32 bits) sang các kiểu dữ liệu số nguyên có độ chính xác thấp hơn (thường là INT8 - 8 bits hoặc thậm chí 1 bit trong mạng nhị phân).

Mục tiêu chính của lượng tử hóa là giảm đáng kể dung lượng lưu trữ của mô hình trên bộ nhớ Flash, tối ưu hóa không gian chiếm dụng trên RAM, đồng thời tăng tốc độ tính toán (inference speed) thông qua việc thay thế các phép toán số thực phức tạp bằng các phép toán số nguyên trên các nền tảng phần cứng có tài nguyên hạn chế.

2.4.1 Giải thích cơ chế lượng tử hóa

Trong các mô hình học sâu hiện đại, phương pháp được sử dụng phổ biến nhất là lượng tử hóa tuyến tính đồng nhất (Uniform Linear Quantization). Phương pháp này thực hiện ánh xạ một giá trị số thực (r) thuộc khoảng $r \in [r_{\min}, r_{\max}]$ sang một giá trị số nguyên lượng tử hóa (q) thuộc khoảng $q \in [q_{\min}, q_{\max}]$ thông qua hai tham số là Scale và Zero-point.

Quá trình lượng tử hóa được thực hiện theo công thức (Quantization):

$$q = \text{clip}(\text{round}(\frac{r}{S}) + Z, q_{\min}, q_{\max}) \quad (2.17)$$

Trong đó:

- (q): giá trị số nguyên sau lượng tử hóa;
- (r): giá trị số thực ban đầu;
- (S): hệ số tỷ lệ (Scale);
- (Z): điểm không (Zero-point);
- ($q_{\min}, q_{\max}$): giới hạn của miền giá trị lượng tử hóa;
- ($\text{clip}()$): hàm giới hạn giá trị trong khoảng cho phép.

Ngược lại, quá trình khôi phục giá trị gần đúng từ miền số nguyên về miền số thực được gọi là giải lượng tử hóa (Dequantization), được xác định bởi:

$$\tilde{r} = S \cdot (q - Z) \quad (2.18)$$

Trong đó: $\tilde{r}$ là giá trị số thực được khôi phục từ giá trị lượng tử hóa.

Tham số Scale được tính theo công thức:

$$S = \frac{r_{\max} - r_{\min}}{q_{\max} - q_{\min}} \quad (2.19)$$

Scale xác định kích thước của mỗi mức lượng tử và quyết định độ phân giải của quá trình biểu diễn dữ liệu.

Tham số Zero-point được xác định bởi:

$$Z = \text{round}\left(\frac{-r_{min}}{S}\right) + q_{min} \quad (2.20)$$

Zero-point cho phép giá trị 0 trong miền số thực được biểu diễn chính xác trong miền số nguyên, từ đó giảm sai số lượng tử hóa. Đối với kiểu dữ liệu INT8, miền giá trị lượng tử hóa thường được sử dụng là:

$$q \in [-128; 127]$$

Sau khi lượng tử hóa, các phép toán suy luận của mạng nơ-ron được thực hiện chủ yếu trên dữ liệu số nguyên thay vì số thực dấu phẩy động. Trọng số và activation được biểu diễn dưới dạng INT8, trong khi bias và bộ tích lũy (accumulator) sử dụng INT32 nhằm tránh hiện tượng tràn số trong quá trình cộng dồn các phép nhân INT8. Điều này giúp giảm đáng kể dung lượng lưu trữ mô hình, giảm yêu cầu bộ nhớ và tăng hiệu quả tính toán trên các hệ thống nhúng cũng như các thiết bị Edge AI.

Tuy nhiên, việc giảm độ chính xác biểu diễn dữ liệu sẽ làm phát sinh sai số lượng tử hóa (Quantization Error), có thể ảnh hưởng đến độ chính xác của mô hình. Để giảm thiểu ảnh hưởng này, nhiều kỹ thuật lượng tử hóa khác nhau đã được đề xuất, trong đó phổ biến nhất là lượng tử hóa sau huấn luyện (PTQ) và lượng tử hóa nhận biết trong quá trình huấn luyện (QAT).

2.4.2 Kỹ thuật lượng tử hóa sau huấn luyện (Post-Training Quantization - PTQ)

Lượng tử hóa sau huấn luyện (PTQ) là kỹ thuật lượng tử hóa trực tiếp một mô hình số thực đã được huấn luyện hội tụ hoàn toàn (Pre-trained model Float32) mà không cần phải thực hiện lại quá trình lan truyền thuận hay lan truyền ngược (huấn luyện lại mạng).

Quy trình thực hiện PTQ bao gồm các bước chính:

1. Lượng tử hóa trọng số (Weights Quantization): Trọng số của các lớp tích chập hoặc kết nối đầy đủ cố định sau khi train, do đó dải giá trị $[r_{min}, r_{max}]$ được xác định chính xác để dùng để tính toán S và Z.

2. Thu thập dữ liệu đại diện và căn chỉnh (Calibration): Đối với các giá trị kích hoạt (activations), dải giá trị thay đổi phụ thuộc vào dữ liệu đầu vào. Do đó, PTQ cần một tập dữ liệu nhỏ đại diện (Representative Dataset) không gán nhãn (thường từ 100 đến 500 mẫu) chạy qua mô hình (quá trình Calibration) để mô phỏng dải phân phối động của các tầng ẩn, từ đó xác định các tham số S và Z tối ưu cho activations.

Với ưu điểm là tốc độ chuyển đổi cực nhanh, không đòi hỏi tài nguyên tính toán lớn hay thời gian huấn luyện lại dữ liệu từ đầu. Nhưng do dải giá trị bị ép một cách thụ động, hiện tượng nhiễu lượng tử (quantization noise) xuất hiện lớn, dẫn đến sự sụt giảm độ chính xác (Accuracy drop) đáng kể, đặc biệt là với các mô hình nhỏ, có cấu trúc nhạy cảm như CNN-1D xử lý tín hiệu.

Trong nghiên cứu này, PTQ được thực hiện bằng TensorFlow Lite với tập dữ liệu đại diện nhằm xác định dải giá trị kích hoạt của các lớp trong mô hình.

2.4.3 Kỹ thuật lượng tử hóa trong quá trình huấn luyện (Quantization-Aware Training - QAT)

Để khắc phục nhược điểm mất mát độ chính xác của PTQ, kỹ thuật Huấn luyện nhận thức lượng tử hóa (QAT) được áp dụng. QAT tích hợp hành vi lượng tử hóa trực tiếp vào trong chính quá trình huấn luyện hoặc fine-tune lại mô hình.

- Cơ chế Lượng tử hóa giả lập (Fake Quantization): Trong pha lan truyền thuận (forward pass) của QAT, các nút lượng tử hóa giả lập (Fake Quantization Nodes) được chèn vào trước các phép toán tích chập. Các nút này tính toán dải giới hạn, nén giá trị Float32 về INT8 rồi lại giải lượng tử ngay lập tức về Float32. Điều này giúp mô hình làm quen với sai số sinh ra do mất mát thông tin lượng tử hóa, từ đó các trọng số khác của mạng tự động điều chỉnh để bù đắp sai số đó.
- Thuật toán lan truyền ngược với bộ ước lượng truyền thẳng (Straight-Through Estimator - STE): Do hàm lượng tử hóa có dạng bậc thang (hàm rời rạc có đạo hàm bằng 0 ở mọi nơi và vô cùng tại điểm nhảy), thuật toán

lan truyền ngược truyền thông không thể tính toán gradient. QAT giải quyết vấn đề này bằng cách sử dụng bộ ước lượng STE, bỏ qua hàm lượng tử hóa trong pha lan truyền ngược và coi đạo hàm của nó tương đương với một hàm đồng nhất (Identity function):

$$\frac{\partial q}{\partial r} \approx 1$$

Nhờ quá trình huấn luyện với sai số lượng tử hóa được mô phỏng trước, mô hình sau khi kết thúc quá trình huấn luyện lại (fine-tune) đạt được sự hội tụ tối ưu với sai số lượng tử thấp nhất, giúp khôi phục hoàn toàn hoặc giữ vững độ chính xác tương đương mô hình Float32. QAT thường giúp duy trì độ chính xác tốt hơn so với PTQ sau khi mô hình được chuyển đổi sang định dạng INT8.

Bảng 2.2 So sánh PTQ và QAT

Tiêu chí	PTQ	QAT
Huấn luyện lại	Không	Có
Thời gian triển khai	Nhanh	Chậm hơn
Độ phức tạp	Thấp	Cao
Độ chính xác	Giảm nhiều hơn	Tốt hơn
Tài nguyên huấn luyện	Thấp	Cao

Trong phạm vi đề tài, cả hai phương pháp PTQ và QAT đều được áp dụng nhằm đánh giá khả năng giảm kích thước mô hình, tối ưu tốc độ suy luận và duy trì độ chính xác phân loại ECG. Kết quả thực nghiệm và so sánh chi tiết sẽ được trình bày trong Chương 4.

2.5 TÍN HIỆU ECG VÀ BỘ DỮ LIỆU MIT-BIH

2.5.1 Tín hiệu điện tâm đồ (ECG)

Điện tâm đồ (Electrocardiogram – ECG) là tín hiệu ghi lại hoạt động điện của tim thông qua các điện cực gắn trên cơ thể. ECG là một công cụ quan trọng trong chẩn đoán các bệnh lý tim mạch, đặc biệt là các rối loạn nhịp tim.

Một chu kỳ ECG bình thường gồm các thành phần chính:

- **Sóng P:** biểu thị quá trình khử cực tâm nhĩ.
- **Phức bộ QRS:** biểu thị quá trình khử cực tâm thất và là thành phần có biên độ lớn nhất trên tín hiệu ECG.
- **Sóng T:** biểu thị quá trình tái cực tâm thất.

Trong các bài toán học sâu, tín hiệu ECG thường được xử lý dưới dạng các đoạn nhịp tim riêng lẻ (beat-by-beat ECG) để phục vụ cho việc phân loại nhịp tim.

2.5.2 Thách thức trong phân loại tín hiệu ECG

Việc xây dựng mô hình phân loại ECG tự động gặp một số thách thức chính:

- Tín hiệu ECG thường chứa nhiều loại nhiễu như baseline wander, nhiễu điện lưới và nhiễu cơ.
- Hình dạng sóng ECG có sự khác biệt giữa các bệnh nhân, làm giảm khả năng khái quát hóa của mô hình.
- Dữ liệu thường mất cân bằng do số lượng nhịp tim bình thường lớn hơn đáng kể so với các nhịp bất thường.

2.5.3 Cơ sở dữ liệu MIT-BIH Arrhythmia Database

Nghiên cứu sử dụng cơ sở dữ liệu MIT-BIH Arrhythmia Database do PhysioNet cung cấp [3]. Đây là một trong những bộ dữ liệu ECG tiêu chuẩn được sử dụng rộng rãi trong các nghiên cứu về phân loại nhịp tim.

Bộ dữ liệu gồm 48 bản ghi ECG thu thập từ 47 bệnh nhân, mỗi bản ghi có thời lượng khoảng 30 phút với tần số lấy mẫu 360 Hz. Các nhịp tim trong bộ dữ liệu được các chuyên gia tim mạch gán nhãn thủ công [2].

Trong nghiên cứu này, bài toán được xây dựng dưới dạng phân loại 5 lớp nhịp tim:

- N: Normal Beat.

- L: Left Bundle Branch Block.
- R: Right Bundle Branch Block.
- V: Premature Ventricular Contraction (PVC).
- A: Atrial Premature Beat (APB).

Mỗi nhịp tim được trích xuất thành một đoạn tín hiệu có độ dài 320 mẫu, lấy đỉnh R làm tâm của cửa sổ tín hiệu. Sau đó dữ liệu được chuẩn hóa và đưa vào mô hình dưới dạng tensor có kích thước (320,1), tương ứng với 320 điểm tín hiệu và 1 kênh dữ liệu.

2.5.4 Phân bố dữ liệu

Bảng 2.3 Số lượng mẫu của từng lớp được sử dụng trong nghiên cứu.

Nhóm	Loại nhịp tim	Số mẫu
N	Normal	75.050
L	LB BB	8.076
R	RB BB	7.259
V	PVC	7.130
A	APB	2.546

Có thể nhận thấy tập dữ liệu tồn tại hiện tượng mất cân bằng lớp, trong đó số lượng mẫu Normal lớn hơn đáng kể so với các lớp còn lại. Điều này ảnh hưởng trực tiếp đến quá trình huấn luyện và là một trong những nguyên nhân dẫn đến việc sử dụng Focal Loss kết hợp Class Weight trong nghiên cứu.

2.6 CÁC CHỈ SỐ ĐÁNH GIÁ MÔ HÌNH

Để đánh giá hiệu quả của mô hình, nghiên cứu sử dụng các chỉ số đánh giá phổ biến trong bài toán phân loại đa lớp gồm Accuracy, Precision, Recall, F1-score và Confusion Matrix. Ngoài ra, nhằm đánh giá khả năng triển khai trên các nền tảng có tài nguyên hạn chế, các chỉ số liên quan đến độ phức tạp mô hình như số lượng tham số, kích thước lưu trữ và thời gian suy luận cũng được xem xét.

2.6.1 Ma trận nhầm lẫn (Confusion Matrix - CM)

Ma trận nhầm lẫn là công cụ trực quan dùng để phân tích kết quả dự đoán của mô hình. Thông qua ma trận này có thể xác định số lượng mẫu được phân loại đúng và các trường hợp bị nhầm lẫn giữa các lớp.

Bảng 2.4 *Mối quan hệ giữa kết quả thực tế và kết quả dự đoán của mô hình*

	Model dự đoán		
		Positive	Negative
		TP (Thực tế là Positive và dự đoán đúng là Positive)	FN (Thực tế Positive mà dự đoán sai thành Negative)
Thực tế	Positive		
	Negative	FP (Thực tế Negative mà dự đoán sai thành Positive)	TN (Thực tế là Negative và dự đoán đúng là Negative)

Đối với bài toán phân loại, bốn khái niệm cơ bản được sử dụng bao gồm:

- **True Positive (TP):** số mẫu thuộc lớp dương được dự đoán đúng.
- **True Negative (TN):** số mẫu thuộc lớp âm được dự đoán đúng.
- **False Positive (FP):** số mẫu thuộc lớp âm nhưng bị dự đoán nhầm là dương.
- **False Negative (FN):** số mẫu thuộc lớp dương nhưng bị dự đoán nhầm là âm.

Các chỉ số đánh giá tiếp theo được tính toán dựa trên bốn giá trị này.

2.6.2 Accuracy

Accuracy thể hiện tỷ lệ mẫu được phân loại đúng trên toàn bộ tập dữ liệu kiểm thử.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.21)$$

Trong đó:

- TP: số mẫu dương được dự đoán đúng.
- TN: số mẫu âm được dự đoán đúng.
- FP: số mẫu âm bị dự đoán sai.
- FN: số mẫu dương bị dự đoán sai.

Đây là chỉ số tổng quát phản ánh hiệu năng chung của mô hình. Tuy nhiên, đối với bộ dữ liệu mất cân bằng như MIT-BIH, Accuracy không phải lúc nào cũng phản ánh đầy đủ chất lượng phân loại của từng lớp nhịp tim.

2.6.3 Precision

Precision cho biết mức độ tin cậy của các dự đoán do mô hình đưa ra.

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.22)$$

Precision cao đồng nghĩa với việc mô hình ít đưa ra các dự đoán sai đối với lớp đang xét. Trong bài toán hỗ trợ chẩn đoán y khoa, chỉ số này giúp hạn chế các cảnh báo không chính xác.

2.6.4 Recall

Recall (Sensitivity) phản ánh khả năng phát hiện đúng các mẫu thuộc lớp cần nhận dạng.

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.23)$$

Recall đặc biệt quan trọng trong các bài toán phát hiện bất thường vì giá trị Recall thấp đồng nghĩa với việc mô hình bỏ sót nhiều trường hợp bệnh lý.

2.6.5 F1-score

F1-score là chỉ số tổng hợp giữa Precision và Recall, được sử dụng để đánh giá sự cân bằng giữa hai tiêu chí này.

$$\text{F1 - Score} = 2 \frac{\text{Precision} * \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2.24)$$

Đối với các bộ dữ liệu có sự chênh lệch số lượng mẫu giữa các lớp, F1-score thường phản ánh hiệu năng thực tế của mô hình tốt hơn Accuracy.

2.6.6 Số lượng tham số

Số lượng tham số là tổng số trọng số và hệ số dịch cần lưu trữ trong mô hình. Chỉ số này phản ánh độ phức tạp của kiến trúc mạng và ảnh hưởng trực tiếp đến yêu cầu bộ nhớ cũng như chi phí tính toán.

Trong nghiên cứu này, số lượng tham số được sử dụng để đánh giá hiệu quả của việc thay thế các lớp Conv1D bằng Depthwise Separable Convolution.

2.6.7 Kích thước mô hình

Kích thước mô hình là dung lượng lưu trữ thực tế để lưu trữ toàn bộ tham số của mạng sau khi huấn luyện hoặc chuyển đổi sang định dạng TensorFlow Lite.

Chỉ số này phản ánh khả năng triển khai trên các thiết bị có dung lượng bộ nhớ hạn chế. Việc áp dụng lượng tử hóa INT8 giúp giảm đáng kể kích thước mô hình so với phiên bản Float32.

2.6.8 Thời gian suy luận

Trong nguyên cứu này, thời gian suy luận là khoảng thời gian cần thiết từ khi dữ liệu được đưa vào input mô hình đến khi đưa ra kết quả dự đoán.

Chỉ số này được sử dụng để đánh giá khả năng đáp ứng thời gian thực của hệ thống. Trong nghiên cứu, thời gian suy luận trung bình trên mỗi mẫu được đo và sử dụng để so sánh hiệu quả giữa mô hình gốc và các mô hình tối ưu hóa.

CHƯƠNG 3

PHƯƠNG PHÁP ĐỀ XUẤT VÀ TRIỂN KHAI

3.1 TỔNG QUAN PHƯƠNG PHÁP NGHIÊN CỨU

Trong nghiên cứu này, mô hình Mini InceptionNet được sử dụng làm mô hình nền cho bài toán phân loại nhịp tim trên cơ sở dữ liệu MIT-BIH Arrhythmia Database. Kết quả thực nghiệm cho thấy mô hình đạt độ chính xác cao, tuy nhiên vẫn tồn tại một số hạn chế khi hướng tới triển khai trên các nền tảng phần cứng có tài nguyên hạn chế. Cụ thể, mô hình vẫn yêu cầu một lượng bộ nhớ nhất định để lưu trữ tham số và sử dụng các phép tích chập truyền thống với chi phí tính toán tương đối lớn.

Xuất phát từ thực tế đó, nghiên cứu tập trung khảo sát hai hướng tối ưu hóa nhằm giảm độ phức tạp của mô hình nhưng vẫn duy trì khả năng phân loại tín hiệu ECG.


Hướng thứ nhất là tối ưu hóa ở mức kiến trúc mạng. Các lớp Conv1D trong mô hình Mini InceptionNet được thay thế bằng cấu trúc Depthwise Separable Convolution để giảm số lượng tham số và số phép tính cần thực hiện trong quá trình suy luận. Mô hình sau khi thay đổi kiến trúc được ký hiệu là Mini InceptionNet-DW.

Hướng thứ hai là tối ưu hóa ở mức biểu diễn dữ liệu thông qua kỹ thuật lượng tử hóa. Các mô hình sau khi huấn luyện được chuyển đổi từ định dạng Float32 sang INT8 bằng phương pháp Post-Training Quantization (PTQ). Đồng thời, kỹ thuật Quantization-Aware Training (QAT) cũng được áp dụng nhằm khảo sát khả năng duy trì độ chính xác sau lượng tử hóa.

Quy trình nghiên cứu được thực hiện theo các bước chính như sau:

1. Phân tích và đánh giá mô hình Mini InceptionNet làm mô hình cơ sở.
2. Thiết kế và triển khai phiên bản Mini InceptionNet-DW bằng cách thay thế các lớp Conv1D bằng Depthwise Separable Convolution.
3. Áp dụng kỹ thuật lượng tử hóa PTQ trên các mô hình đã huấn luyện.

4. Áp dụng kỹ thuật lượng tử hóa QAT nhằm cải thiện độ chính xác của mô hình lượng tử hóa.
5. Đánh giá và so sánh hiệu năng của các mô hình thông qua các chỉ số Accuracy, Precision, Recall, F1-score, số lượng tham số, kích thước mô hình và thời gian suy luận.



Hình 3.1 Luồng nghiên cứu chính

Hình 3.1 trình bày luồng thực hiện của nghiên cứu. Từ các kết quả thu được, đề tài đánh giá mức độ ảnh hưởng của từng phương pháp tối ưu hóa cũng như khả năng kết hợp giữa lượng tử hóa và Depthwise Separable Convolution nhằm tìm ra phương án phù hợp cho bài toán phân loại tín hiệu ECG trên các hệ thống Edge AI.

3.2 MÔ HÌNH CƠ SỞ MINI INCEPTIONNET

3.2.1 Kiến trúc mô hình gốc

Mô hình cơ sở được sử dụng trong nghiên cứu là kiến trúc Mini InceptionNet được đề xuất trong bài báo *MINA: A Hardware-Efficient and Flexible Mini-InceptionNet Accelerator for ECG Classification in Wearable Devices* [1]. Đây là một mạng tích chập một chiều (1D CNN) được thiết kế chuyên biệt cho bài toán phân loại tín

hiệu điện tâm đồ với mục tiêu đạt độ chính xác cao trong khi vẫn đảm bảo khả năng triển khai trên các hệ thống phần cứng có tài nguyên hạn chế.

Kiến trúc của mô hình bao gồm các thành phần chính:

- Lớp đầu vào có kích thước (320, 1), tương ứng với một đoạn tín hiệu ECG gồm 320 mẫu.
- Một lớp Conv1D đầu vào với kernel size bằng 7 và stride bằng 2 nhằm giảm kích thước tín hiệu và mở rộng receptive field.
- Sáu khối Inception Block được tổ chức thành ba giai đoạn xử lý đặc trưng.
- Ba kết nối tắt (Residual Connection) giúp cải thiện quá trình lan truyền gradient và tăng độ ổn định trong huấn luyện.
- Lớp Global Average Pooling nhằm giảm số lượng tham số trước khi phân loại.
- Lớp Dense đầu ra thực hiện phân loại năm lớp nhịp tim gồm Normal, LBBB, RBBB, PVC và APB.

Tổng số tham số của mô hình là 6.457 tham số, tương đương khoảng 25,22 KB bộ nhớ tham số khi sử dụng định dạng Float32.

3.2.2 Kết quả thực nghiệm và so sánh với bài báo gốc

Để làm cơ sở đánh giá cho các phương pháp tối ưu hóa được đề xuất trong nghiên cứu, mô hình Mini InceptionNet được chạy lại trên tập kiểm tra của bộ dữ liệu MIT-BIH Arrhythmia Database. Các thí nghiệm được thực hiện trên máy tính sử dụng bộ xử lý Intel Core i5-1135G7 với xung nhịp 2.40 GHz.


Bảng 3.1 trình bày kết quả so sánh giữa kết quả được công bố trong bài báo gốc và kết quả thực nghiệm thu được trong quá trình triển khai lại mô hình.

Bảng 3.1 So sánh kết quả thực nghiệm thu được với bài báo gốc

Chỉ số	Bài báo gốc (%)	Thực nghiệm (%)
--------	-----------------	-----------------

Acc	99,37	98,75
Sen (Recall)	99,37	98,75
Spec	98,83	99,37
Precision	99,38	98,73

Kết quả thực nghiệm khi chạy lại cho thấy mô hình đạt độ chính xác 98,75%, thấp hơn khoảng 0,62% so với kết quả được báo cáo trong bài báo gốc. Tuy nhiên, khoảng chênh lệch này tương đối nhỏ vẫn đảm bảo độ tin cậy của mô hình để làm cơ sở so sánh cho các nghiên cứu phía sau.



Hình 3.2 CM của mô hình MiniInceptionNet thực nghiệm trên tập kiểm tra

Từ Hình 3.2 có thể thấy phần lớn các mẫu được phân loại chính xác và tập trung trên đường chéo chính của ma trận nhầm lẫn. Lớp Normal đạt số lượng dự đoán đúng cao nhất với 11.084 mẫu được phân loại chính xác. Các lớp LBBB, RBBB và PVC cũng đạt tỷ lệ nhận dạng chính xác rất cao với số lượng mẫu bị nhầm lẫn không đáng kể.

Lớp APB là lớp có tỷ lệ nhầm lẫn lớn nhất, trong đó 57 mẫu APB bị phân loại nhầm sang lớp Normal. Nguyên nhân có thể xuất phát từ sự tương đồng về hình dạng tín hiệu ECG giữa một số nhịp APB và nhịp tim bình thường, đồng thời số

lượng mẫu APB trong tập dữ liệu cũng thấp hơn đáng kể so với lớp Normal. Mặc dù vậy, số lượng mẫu dự đoán đúng của lớp APB vẫn đạt 305 mẫu, cho thấy mô hình vẫn duy trì khả năng nhận dạng tốt đối với lớp này.

Sự khác biệt giữa kết quả thực nghiệm và kết quả công bố có thể xuất phát từ nhiều nguyên nhân như sự khác nhau trong quá trình tiền xử lý dữ liệu, phiên bản thư viện TensorFlow sử dụng, Ngoài ra, một số chi tiết triển khai trong bài báo không được mô tả đầy đủ nên khó có thể tái tạo hoàn toàn 100% điều kiện thí nghiệm ban đầu.

Mặc dù có sự sai khác nhỏ về độ chính xác, mô hình thực nghiệm vẫn đạt hiệu năng phân loại cao và được lựa chọn làm mô hình cơ sở (baseline) để đánh giá hiệu quả của các phương pháp tối ưu hóa được đề xuất trong các phần tiếp theo.

3.2.3 Phân tích hạn chế của mô hình cơ sở

Kết quả thực nghiệm ở mục 3.2.2 cho thấy mô hình Mini InceptionNet đạt độ chính xác cao trên bộ dữ liệu MIT-BIH Arrhythmia Database. Tuy nhiên, khi xem xét dưới góc độ triển khai trên các nền tảng Edge AI hoặc hệ thống nhúng, mô hình vẫn còn một số điểm có thể cải thiện được.

Trước hết, kiến trúc Mini InceptionNet sử dụng hoàn toàn các lớp tích chập Conv1D truyền thống. Mặc dù mang lại khả năng trích xuất đặc trưng hiệu quả, các lớp Conv1D vẫn yêu cầu số lượng tham số và phép tính tương đối lớn do quá trình trích xuất đặc trưng theo thời gian và kết hợp thông tin giữa các kênh được thực hiện đồng thời trong cùng một phép tích chập.

Bên cạnh đó, mô hình có tổng cộng 6.457 tham số và được lưu trữ dưới định dạng Float32. Với mỗi tham số chiếm 4 byte bộ nhớ, dung lượng lưu trữ và băng thông truy cập bộ nhớ vẫn còn tương đối lớn đối với các nền tảng có tài nguyên hạn chế.

Ngoài ra, mô hình chưa khai thác các kỹ thuật tối ưu hóa hiện đại như lượng tử hóa tham số. Điều này khiến quá trình suy luận vẫn sử dụng các phép toán dấu phẩy động, làm tăng chi phí tính toán và chưa tận dụng được khả năng xử lý số nguyên của nhiều bộ xử lý nhúng hiện nay.

Từ những hạn chế trên có thể thấy rằng vẫn còn tiềm năng để tiếp tục giảm độ phức tạp của mô hình mà vẫn duy trì hiệu năng phân loại ở mức chấp nhận được. Do đó, nghiên cứu tập trung khảo sát hai hướng tối ưu hóa chính. Hướng thứ nhất là thay thế các lớp Conv1D bằng kiến trúc Depthwise Separable Convolution nhằm giảm số lượng tham số và chi phí tính toán. Hướng thứ hai là áp dụng các kỹ thuật lượng tử hóa PTQ và QAT nhằm giảm kích thước mô hình và tăng tốc độ suy luận. Các phương pháp này sẽ được trình bày chi tiết trong các mục tiếp theo.

3.3 ĐỀ XUẤT TỐI ƯU KIẾN TRÚC BẰNG TÍCH CHẬP PHÂN TÁCH THEO CHIỀU SÂU

3.3.1 Thiết kế khối Conv1D-DW


Như đã phân tích trong Chương 2, lớp tích chập một chiều truyền thống (Conv1D) thực hiện đồng thời hai nhiệm vụ gồm trích xuất đặc trưng theo chiều thời gian và kết hợp thông tin giữa các kênh đầu vào. Mặc dù mang lại khả năng biểu diễn mạnh mẽ, cách tiếp cận này làm gia tăng số lượng tham số và chi phí tính toán của mô hình.

Để giảm độ phức tạp của kiến trúc Mini InceptionNet, nghiên cứu đề xuất sử dụng khối tích chập phân tách chiều sâu (1D Depthwise Separable Convolution Block – Conv1D-DW) thay thế cho các lớp Conv1D truyền thống.

Cấu trúc của một khối Conv1D-DW được thiết kế như sau (hình 3.3):

Trong đó:

- **Depthwise Conv1D** thực hiện tích chập độc lập trên từng kênh đầu vào nhằm trích xuất đặc trưng theo chiều thời gian.
- **Batch Normalization** được sử dụng để chuẩn hóa dữ liệu đầu ra của mỗi tầng tích chập, giúp quá trình huấn luyện ổn định hơn và tăng tốc độ hội tụ.



Hình 3.3 Cấu trúc khối Conv1D-DW

- **ReLU** đóng vai trò tạo tính phi tuyến cho mô hình.
- **Pointwise Conv1D** với kích thước kernel bằng 1 thực hiện quá trình kết hợp thông tin giữa các kênh đặc trưng và tạo ra số lượng kênh đầu ra mong muốn.

So với lớp Conv1D truyền thống, cấu trúc Conv1D-DW giúp giảm đáng kể số lượng tham số và khối lượng tính toán trong khi vẫn duy trì khả năng học đặc trưng của mạng.

3.3.2 Tích hợp Conv1D-DW vào kiến trúc Mini InceptionNet

Sau khi thiết kế khối Conv1D-DW, nghiên cứu tiến hành tích hợp cấu trúc này vào mô hình Mini InceptionNet nhằm xây dựng phiên bản tối ưu hóa có tên gọi Mini InceptionNet-DW.

Trong kiến trúc Mini InceptionNet gốc, các phép tích chập Conv1D xuất hiện ở hai vị trí chính:

- Các lớp Conv1D nằm giữa các giai đoạn xử lý đặc trưng.
- Các nhánh tích chập song song bên trong các Inception Block.

Để tối đa hóa hiệu quả giảm tham số, nghiên cứu thực hiện thay thế toàn bộ các lớp Conv1D có kích thước kernel lớn bằng các khối Conv1D-DW tương ứng. Cụ thể:


Bảng 3.2 Các Conv1D được thay thế bằng Conv1D-DW

Kiến trúc gốc	Kiến trúc đề xuất
Conv1D (Kernel = 7)	Conv1D-DW (Kernel = 7)
Conv1D (Kernel = 5)	Conv1D-DW (Kernel = 5)
Conv1D (Kernel = 3)	Conv1D-DW (Kernel = 3)
Conv1D (Kernel = 3)	Conv1D-DW (Kernel = 3)
Conv1D (Kernel = 5)	Conv1D-DW (Kernel = 5)

Conv1D (Kernel = 7)	Conv1D-DW (Kernel = 7)
---------------------	------------------------

Riêng các lớp Conv1D có kích thước kernel bằng 1 trong các tầng Bottleneck và các nhánh MaxPooling được giữ nguyên. Nguyên nhân là do Conv1D với kernel bằng 1 bản chất đã là phép tích chập Pointwise, việc tiếp tục thay thế bằng Conv1D-DW không mang lại lợi ích đáng kể về mặt giảm tham số hay chi phí tính toán.

Ngoài ra, toàn bộ cấu trúc Residual Connection của mô hình gốc vẫn được giữ nguyên nhằm đảm bảo khả năng lan truyền gradient và duy trì tính ổn định trong quá trình huấn luyện.



Hình 3.4 Kiến trúc mô hình Mini InceptionNet – DW

3.3.3 Xử lý mất cân bằng dữ liệu

3.3.3.1 Vấn đề mất cân bằng dữ liệu

Trong bài toán phân loại tín hiệu ECG, số lượng mẫu giữa các lớp nhịp tim thường không đồng đều. Các nhịp tim bình thường thường chiếm tỷ lệ lớn, trong khi một

số lớp bất thường như APB có số lượng mẫu ít hơn. Điều này làm cho mô hình có xu hướng học tốt lớp chiếm đa số nhưng lại dễ bỏ sót hoặc phân loại sai các lớp thiểu số.

Đối với bài toán phân loại nhịp tim, việc nhận dạng chính xác các lớp bất thường có ý nghĩa quan trọng. Nếu mô hình quá thiên lệch về lớp Normal, độ chính xác tổng thể vẫn có thể cao nhưng khả năng phát hiện các loại nhịp bất thường sẽ bị suy giảm. Vì vậy, nghiên cứu sử dụng kết hợp hai kỹ thuật là **Class Weight** và **Focal Loss** trong quá trình huấn luyện nhằm giảm ảnh hưởng của mất cân bằng dữ liệu.

3.3.3.2 Sử dụng Class Weight

Class Weight là kỹ thuật gán trọng số khác nhau cho từng lớp trong hàm mất mát. Các lớp có số lượng mẫu ít hơn hoặc khó phân loại hơn sẽ được gán trọng số lớn hơn, từ đó làm tăng mức phạt khi mô hình dự đoán sai các lớp này.

Trong nghiên cứu này, trọng số lớp được thiết lập như sau:

Bảng 3.3 Trọng số class weight cho từng lớp

Lớp	Ý nghĩa	Trọng số
Normal	Nhịp tim bình thường	1.0
LBBB	Block nhánh trái	1.5
RBBB	Block nhánh phải	1.8
PVC	Ngoại tâm thu thất	1.8
APB	Ngoại tâm thu nhĩ	2.5

Lớp Normal được gán trọng số thấp nhất do đây là lớp có số lượng mẫu lớn và dễ chiếm ưu thế trong quá trình huấn luyện. Ngược lại, lớp APB được gán trọng số cao nhất nhằm tăng khả năng học đặc trưng của lớp này, vì đây là lớp có số lượng mẫu ít hơn và dễ bị nhầm lẫn với nhịp tim bình thường.

3.3.3.3 Sử dụng Focal Loss

Bên cạnh Class Weight, nghiên cứu sử dụng Focal Loss để giúp mô hình tập trung hơn vào các mẫu khó phân loại. Trong hàm Cross Entropy thông thường, mọi mẫu

huấn luyện đều đóng góp vào hàm mất mát theo cùng một cơ chế. Điều này khiến các mẫu dễ phân loại, thường thuộc lớp chiếm đa số, có thể chi phối quá trình tối ưu.

Focal Loss bổ sung thêm hệ số điều chỉnh $(1 - p_t)^\gamma$, trong đó (p_t) là xác suất dự đoán đúng của lớp mục tiêu. Khi mô hình dự đoán đúng một mẫu với xác suất cao, (p_t) lớn và hệ số $(1 - p_t)^\gamma$ nhỏ, làm giảm đóng góp của mẫu đó vào hàm mất mát. Ngược lại, đối với các mẫu khó hoặc bị dự đoán sai, (p_t) nhỏ nên hệ số này lớn hơn, giúp mô hình tập trung học các mẫu này nhiều hơn.

Hàm Focal Loss có dạng:

$$FL(p_t) = -(1 - p_t)^\gamma \log(p_t) \quad (3.1)$$

Trong đó:

- (p_t) : xác suất dự đoán đúng của lớp mục tiêu;
- (γ) : hệ số điều chỉnh mức độ tập trung vào các mẫu khó.

Trong nghiên cứu này, giá trị $(\gamma = 0.5)$ được sử dụng. Giá trị này giúp tăng mức độ chú ý đến các mẫu khó mà không làm quá trình huấn luyện mất ổn định.

3.3.3.4 Kết hợp Focal Loss và Class Weight

Để đồng thời xử lý mất cân bằng lớp và tăng khả năng học các mẫu khó, nghiên cứu kết hợp Focal Loss với Class Weight. Hàm mất mát cuối cùng được xác định như sau:

$$Loss = \omega_c (1 - p_t)^\gamma CE \quad , \text{ với } CE = -\log(p_t) \quad (3.2)$$

Trong đó:

- (ω_c) : trọng số của lớp (c);
- (p_t) : xác suất dự đoán đúng của lớp mục tiêu;
- (γ) : hệ số Focal Loss;
- (CE) : giá trị Cross Entropy của mẫu đang xét.

Với cách kết hợp này, các mẫu thuộc lớp thiểu số sẽ có ảnh hưởng lớn hơn đến quá trình cập nhật trọng số thông qua hệ số (ω_c) . Đồng thời, các mẫu khó phân loại cũng được nhấn mạnh thông qua hệ số Focal Loss. Nhờ đó, mô hình không chỉ học

tốt lớp chiếm đa số mà còn cải thiện khả năng nhận dạng các lớp có số lượng mẫu thấp hơn.

Trong quá trình hiện thực, hàm mất mát được xây dựng dựa trên Sparse Categorical Cross Entropy. Đầu ra của mô hình là logits, sau đó được đưa qua hàm Softmax để tính xác suất dự đoán của từng lớp. Giá trị (p_t) được lấy tại lớp nhãn đúng của mỗi mẫu, sau đó kết hợp với hệ số Focal Loss và trọng số lớp tương ứng để tạo thành giá trị mất mát cuối cùng.

Chiến lược này được áp dụng trong quá trình huấn luyện các mô hình Float32 trước khi thực hiện các bước tối ưu hóa bằng Depthwise Separable Convolution, PTQ và QAT. Việc xử lý mất cân bằng dữ liệu ngay từ giai đoạn huấn luyện giúp tạo ra mô hình cơ sở ổn định hơn, đồng thời cải thiện khả năng phân loại đối với các lớp nhíp tìm bất thường.

3.3.4 Phân tích lợi ích lý thuyết của Conv1D-DW

Giả sử một lớp Conv1D truyền thống có số kênh đầu vào là (C_{in}) số kênh đầu ra là (C_{out}) và kích thước kernel là (K).

Số lượng tham số (không tính bias) của lớp Conv1D được xác định bởi:

$$P_{standard} = K \times C_{in} \times C_{out} \quad (3.3)$$

Trong khi đó, số lượng tham số của lớp Depthwise Separable Convolution được tính theo:

$$P_{DW} = K \times C_{in} + C_{in} \times C_{out} \quad (3.4)$$

Do (C_{out}) thường có giá trị lớn hơn nhiều so với (K), số lượng tham số của Conv1D-DW nhỏ hơn đáng kể so với Conv1D truyền thống.

Bên cạnh việc giảm số lượng tham số, Conv1D-DW còn giúp giảm khối lượng tính toán của mô hình thông qua việc tách riêng quá trình trích xuất đặc trưng theo thời gian và quá trình kết hợp thông tin giữa các kênh. Điều này đặc biệt phù hợp với các hệ thống Edge AI và thiết bị nhúng, nơi tài nguyên tính toán và bộ nhớ lưu trữ thường bị giới hạn.

Trên cơ sở đó, nghiên cứu kỳ vọng việc thay thế Conv1D bằng Conv1D-DW sẽ giúp giảm độ phức tạp của mô hình Mini InceptionNet trong khi vẫn duy trì được hiệu năng phân loại tín hiệu ECG ở mức chấp nhận được. Hiệu quả thực nghiệm của phương pháp đề xuất sẽ được trình bày và đánh giá chi tiết trong Chương 4.


3.4 ĐỀ XUẤT TỐI ƯU ĐỊNH DẠNG DỮ LIỆU BẰNG KỸ THUẬT LƯỢNG TỬ HÓA

3.4.1 Tối ưu hóa bằng post-training quantization (PTQ)

3.4.1.1 Triển khai PTQ trên Mini InceptionNet (mô hình gốc)

Sau khi có được mô hình ở định dạng Float32, nghiên cứu tiến hành áp dụng kỹ thuật lượng tử hóa sau huấn luyện (PTQ) nhằm giảm kích thước mô hình và tối ưu khả năng triển khai trên các nền tảng phần cứng có tài nguyên hạn chế.

PTQ được thực hiện bằng TensorFlow Lite Converter. Khác với Quantization-Aware Training (QAT), phương pháp này không yêu cầu huấn luyện lại mô hình mà chỉ thực hiện chuyển đổi trực tiếp từ mô hình Float32 sang mô hình lượng tử hóa. Quy trình thực hiện PTQ trong nguyên cứu này được thực hiện như sau:



Hình 3.5 Quy trình thực hiện lượng tử hóa PTQ trên model gốc

Đối với mô hình Mini InceptionNet gốc, nghiên cứu khảo sát hai cấu hình lượng tử hóa khác nhau nhằm đánh giá ảnh hưởng của kiểu dữ liệu đầu vào và đầu ra đến độ chính xác của mô hình.

a) Full Integer Quantization (INT8 – INT8 – INT8)

Ở cấu hình Full Integer Quantization, toàn bộ quá trình suy luận của mô hình được thực hiện bằng kiểu dữ liệu số nguyên 8-bit. Dữ liệu đầu vào được lượng tử hóa sang INT8, các trọng số và tensor trung gian trong mô hình cũng được biểu diễn dưới dạng INT8, đồng thời kết quả đầu ra của mô hình cũng có kiểu dữ liệu INT8.

Trong TensorFlow Lite, cấu hình này được thiết lập bằng các tham số:

Bảng 3.4 Tham số cấu hình lượng tử PTQ

Tham số cấu hình	Ý nghĩa
Optimize.DEFAULT	Bật cơ chế tối ưu hóa/lượng tử hóa mặc định
representative_dataset	Dữ liệu đại diện dùng để hiệu chuẩn scale và zero_point
TFLITE_BUILTINS_INT8	Ép các toán tử trong mô hình sử dụng INT8
inference_input_type	Đầu vào của mô hình TFLite là INT8
inference_output_type	Đầu ra của mô hình TFLite là INT8

Ví dụ cấu hình trong code:

```
converter = tf.lite.TFLiteConverter.from_keras_model(model)
converter.optimizations = [tf.lite.Optimize.DEFAULT]
converter.representative_dataset = representative_data_gen

converter.target_spec.supported_ops = [
    tf.lite.OpsSet.TFLITE_BUILTINS_INT8
]
converter.inference_input_type = tf.int8
converter.inference_output_type = tf.int8

tflite_model = converter.convert()
```

Representative Dataset đóng vai trò quan trọng trong việc xác định khoảng giá trị thực tế của tín hiệu trong mô hình. Tập dữ liệu này được lấy từ 100 mẫu đại diện

trong tập dữ liệu ECG, giúp quá trình lượng tử hóa phản ánh đúng phân phối dữ liệu đầu vào thực tế.

Cấu hình Full INT8 có ưu điểm là giảm đáng kể kích thước mô hình, giảm dung lượng bộ nhớ cần thiết và tận dụng tốt các phép toán số nguyên trên phần cứng nhúng. Tuy nhiên, do cả đầu vào và đầu ra đều ở dạng INT8, phía ứng dụng cần thực hiện thêm bước lượng tử hóa dữ liệu đầu vào và giải lượng tử hóa kết quả đầu ra khi cần diễn giải xác suất hoặc giá trị dự đoán.

b) Hybrid Quantization (Float32 – INT8 – Float32)

Ở cấu hình Hybrid Quantization, mô hình vẫn nhận dữ liệu đầu vào ở định dạng Float32 và trả về kết quả đầu ra ở định dạng Float32. Tuy nhiên, các trọng số và một số phép toán bên trong mô hình được lượng tử hóa sang INT8 nhằm giảm kích thước mô hình và cải thiện hiệu quả tính toán.

Do đó, trong TensorFlow Lite Converter chỉ cần bật tối ưu hóa:

```
converter = tf.lite.TFLiteConverter.from_keras_model(model)
converter.optimizations = [tf.lite.Optimize.DEFAULT]

converter.representative_dataset = representative_data_gen      #

tflite_model = converter.convert()
```

Và không cần khai báo:

```
converter.inference_input_type = tf.int8
converter.inference_output_type = tf.int8
```

Ưu điểm của Hybrid Quantization là dễ tích hợp với pipeline suy luận hiện có, do dữ liệu ECG đầu vào không cần được lượng tử hóa thủ công ở phía ứng dụng. Kết quả đầu ra cũng ở dạng Float32 nên có thể được xử lý trực tiếp bằng các hàm như `argmax`, `softmax` hoặc các bước tính metric. Tuy nhiên, so với Full INT8, cấu hình này thường chưa tối ưu tuyệt đối về tốc độ và bộ nhớ vì vẫn tồn tại các bước chuyển đổi qua lại giữa Float32 và INT8 trong quá trình suy luận.

3.4.1.2 Triển khai PTQ trên Mini InceptionNet-DW

Sau khi xây dựng thành công mô hình Mini InceptionNet-DW dựa trên kiến trúc Depthwise Separable Convolution, nghiên cứu tiếp tục áp dụng quy trình PTQ (full Int8) tương tự nhằm đánh giá khả năng kết hợp giữa tối ưu hóa kiến trúc và lượng tử hóa.

Quy trình thực hiện hoàn toàn tương tự như đối với mô hình Mini InceptionNet gốc, bao gồm:

- Chuyển đổi mô hình Float32 sang TensorFlow Lite.
- Sử dụng Representative Dataset để thực hiện Calibration.
- Sinh mô hình lượng tử hóa INT8 phục vụ triển khai.

Việc áp dụng PTQ trên Mini InceptionNet-DW cho phép đánh giá đồng thời hai yếu tố tối ưu hóa:

- Giảm số lượng tham số thông qua Depthwise Separable Convolution.
- Giảm độ chính xác biểu diễn dữ liệu thông qua lượng tử hóa INT8.

Nhờ đó có thể xác định mức độ ảnh hưởng của từng phương pháp cũng như khả năng kết hợp giữa chúng đối với bài toán phân loại tín hiệu ECG.

Hiệu quả thực nghiệm của các mô hình PTQ sẽ được trình bày và phân tích chi tiết trong Chương 4.

3.4.2 Tối ưu hóa bằng quantization-aware training (QAT)

Mặc dù Post-Training Quantization (PTQ) có ưu điểm triển khai nhanh và không yêu cầu huấn luyện lại mô hình, quá trình lượng tử hóa trực tiếp từ Float32 sang INT8 thường làm phát sinh sai số lượng tử hóa (Quantization Error), dẫn đến suy giảm độ chính xác của mô hình.

Để khắc phục hạn chế này, nghiên cứu sử dụng kỹ thuật Quantization-Aware Training (QAT). Khác với PTQ, QAT mô phỏng quá trình lượng tử hóa ngay trong giai đoạn huấn luyện nhằm giúp mạng nơ-ron thích nghi với sai số lượng tử hóa trước khi được chuyển đổi sang định dạng INT8.

Trong nghiên cứu này, QAT được triển khai thông qua thư viện TensorFlow Model Optimization Toolkit (TFMOT) [6].

3.4.2.1 Các chiến lược QAT được khảo sát

Nhằm đánh giá ảnh hưởng của thời điểm áp dụng lượng tử hóa đến hiệu quả cuối cùng của mô hình, nghiên cứu khảo sát nhiều chiến lược QAT khác nhau.

a) QAT ngay từ đầu quá trình huấn luyện

Ở phương pháp này, các lớp Fake Quantization được chèn vào mô hình trước khi bắt đầu huấn luyện. Toàn bộ quá trình học diễn ra dưới tác động của sai số lượng tử hóa.

Mục tiêu của phương pháp là giúp mô hình thích nghi hoàn toàn với môi trường lượng tử hóa ngay từ đầu. Tuy nhiên, việc xuất hiện sai số lượng tử hóa quá sớm có thể làm quá trình hội tụ trở nên khó khăn hơn.

b) Huấn luyện mô hình ở dạng Float32 trước, sau đó kích hoạt QAT

Ở chiến lược này, mô hình được huấn luyện một phần bằng Float32 trước khi chuyển sang chế độ QAT.

Cách tiếp cận này giúp mô hình học được các đặc trưng cơ bản của dữ liệu trước khi phải thích nghi với sai số lượng tử hóa.

c) Fine-tune QAT từ mô hình Float32 đã hội tụ

Đây là phương pháp phổ biến nhất trong thực tế.

Trước tiên, mô hình được huấn luyện hoàn chỉnh ở định dạng Float32 cho đến khi hội tụ. Sau đó, các lớp Fake Quantization được chèn vào mạng và quá trình huấn luyện tiếp tục được thực hiện với tốc độ học nhỏ nhằm điều chỉnh các trọng số để bù lại sai số lượng tử hóa.

Phương pháp này tận dụng được khả năng biểu diễn mạnh của mô hình Float32 đồng thời cho phép thích nghi với môi trường INT8 trong giai đoạn cuối.

d) QAT với lượng tử hóa đối xứng (Symmetric Quantization)

Ngoài lượng tử hóa bất đối xứng (Asymmetric Quantization) mặc định của TensorFlow Lite, nghiên cứu cũng khảo sát phương pháp lượng tử hóa đối xứng, trong đó Zero-point được cố định bằng 0.

Mục tiêu của phương pháp này là đơn giản hóa phép tính lượng tử hóa và giảm độ phức tạp khi triển khai trên phần cứng nhúng.

e) QAT trên kiến trúc Mini InceptionNet-DW

Sau khi xây dựng thành công mô hình Mini InceptionNet-DW, nghiên cứu tiếp tục áp dụng QAT trên kiến trúc này nhằm đánh giá khả năng kết hợp giữa tối ưu hóa kiến trúc và lượng tử hóa.

Việc khảo sát đồng thời nhiều chiến lược QAT giúp xác định phương pháp phù hợp nhất cho bài toán phân loại tín hiệu ECG.

3.4.2.2 Fine-tune QAT được lựa chọn


Sau quá trình khảo sát, nghiên cứu lựa chọn phương pháp Fine-tune QAT từ mô hình Float32 đã hội tụ để làm đại diện cho hướng QAT trên model gốc.

Quy trình thực hiện QAT được mô tả như sau (Hình 3.5):

1. Nạp mô hình Mini InceptionNet đã huấn luyện.
2. Đánh dấu các lớp cần lượng tử hóa, trong nguyên cứu này các lớp được chọn là Conv1D và Dense (đây là 2 lớp chứa phần lớn trọng số của mô hình).
3. TensorFlow Model Optimization Toolkit sẽ bọc các layer đã đánh dấu bằng QuantizeWrapper. Wrapper này sẽ chèn các nút **fake quantization** vào mô hình.
 - Conv1D $\rightarrow$ QuantizeWrapper(Conv1D)
 - Dense $\rightarrow$ QuantizeWrapper(Dense)
4. Mô hình QAT được compile lại để fine-tune với Learning rate nhỏ ($1e - 5$) giúp mô hình thích nghi với sai số lượng tử hóa mà không làm phá vỡ trọng số đã học.
5. Nạp lại train và validation dataset để chuẩn bị fine-tune.
6. Fine-tune với giả lập lượng tử hóa: đây là bước quan trọng nhất của QAT, trong quá trình train, mô hình giả lập sai số INT8 theo luồng:

Float32 $\rightarrow$ Quantize giả lập INT8 $\rightarrow$ Dequantize về Float32

- Công thức lượng tử hóa: $q = \text{round}(\frac{x}{scale} + \text{zero_point})$ (3.5)



Hình 3.6 Quy trình thực hiện lượng tử hóa QAT

- Giải lượng tử hóa: $x_{fake} \approx scale \times (q - zero_point)$ (3.6)

Nhờ vậy, mô hình học cách thích nghi với sai số lượng tử hóa trước khi xuất sang TFLite INT8.

7. Lưu qat_finetuned.h5: sau fine-tune, mô hình QAT được lưu lại dưới dạng .h5, file này vẫn là Keras model, nhưng bên trong đã có các wrapper phục vụ QAT.
8. Convert sang TFLite: Bước này chuyển mô hình QAT từ Keras sang TensorFlow Lite
9. Representative Dataset Calibration: hiệu chuẩn dải giá trị của input và các activation chưa được QAT. Tương tự trong PTQ, các mẫu đại diện này cũng sẽ được chạy qua toàn bộ kiến trúc để lấy được giá trị min và max của output ở từng lớp nhưng trong QAT các lớp Conv1D và Dense đã được tính toán tỷ lệ scale và zero-point thông qua fake quantization khi fine tune, vì vậy hệ thống chỉ cần tính toán cho những lớp chưa được áp dụng fake quantization (như ReLU, Concatenate, GlobalAveragePooling, Add,...)
10. Ép full INT8: Input, Weight, Ops, Output.
11. Cuối cùng là xuất file .tflite đã lượng tử.

Việc sử dụng phương pháp Fine-tune QAT giúp tận dụng các trọng số đã được huấn luyện trước đó, đồng thời giảm đáng kể thời gian huấn luyện so với việc huấn luyện lại toàn bộ mô hình từ đầu. Hiệu quả của các chiến lược QAT được khảo sát sẽ được trình bày và phân tích chi tiết trong Chương 4.

3.5 CÁC MÔ HÌNH THỰC NGHIỆM

Nhằm đánh giá hiệu quả của các phương pháp tối ưu hóa được đề xuất, nghiên cứu tiến hành xây dựng và thực nghiệm trên nhiều phiên bản mô hình khác nhau.

Bảng 3.5 Toàn bộ mô hình được sử dụng trong quá trình thực nghiệm.

STT	Mô hình	Mục đích
-----	---------	----------

1	Mini InceptionNet [1]		Mô hình cơ sở (Baseline)
2	Mini InceptionNet + PTQ	<i>Full Integer Quantization</i>	Đánh giá hiệu quả PTQ trên mô hình gốc
		<i>Hybrid Quantization</i>	
3	Mini InceptionNet + QAT (INT8)	<i>QAT ngay từ đầu quá trình huấn luyện</i>	Đánh giá hiệu quả QAT trên mô hình gốc
		<i>Huấn luyện mô hình ở dạng Float32 trước, sau đó kích hoạt QAT</i>	
		<i>Fine-tune QAT từ mô hình Float32 đã hội tụ</i>	
		<i>QAT với lượng tử hóa đối xứng</i>	
4	Mini InceptionNet-DW		Đánh giá hiệu quả thay thế Conv1D bằng Conv1D-DW
5	Mini InceptionNet-DW + PTQ (INT8)		Đánh giá khả năng kết hợp Conv1D-DW và PTQ
6	Mini InceptionNet-DW + QAT (INT8)		Đánh giá khả năng kết hợp Conv1D-DW và QAT

Trong đó, mô hình Mini InceptionNet [1] được sử dụng để làm mô hình tham chiếu. Các mô hình còn lại được xây dựng dựa trên những phương pháp tối ưu hóa đã trình bày trong các mục trước.

Hiệu quả của từng mô hình được đánh giá thông qua các chỉ số Metrics, số lượng tham số, bộ nhớ tham số, kích thước mô hình và thời gian suy luận.

Việc khảo sát đồng thời nhiều phương hướng khác nhau giúp đánh giá riêng biệt tác động của từng phương pháp tối ưu hóa cũng như hiệu quả khi kết hợp giữa tối ưu hóa kiến trúc và lượng tử hóa.

3.6 MÔI TRƯỜNG THỰC NGHIỆM

Các thí nghiệm trong nghiên cứu được thực hiện trên máy tính cá nhân với cấu hình phần cứng và phần mềm như sau:

3.6.1 Cấu hình phần cứng

Bảng 3.6 Cấu hình phần cứng

Thành phần	Thông số
CPU	Intel Core i5-1135G7 @ 2.40 GHz
RAM	12 GB
Hệ điều hành	Windows 11

3.6.2 Môi trường phần mềm

Bảng 3.7 Môi trường phần mềm

Thành phần	Phiên bản
Python	3.11.9
TensorFlow	2.13.1
TensorFlow Lite	2.13.1
TensorFlow Model Optimization Toolkit	0.7.5
NumPy	1.24.3
Pandas	2.0.3

3.6.3 Bộ dữ liệu thực nghiệm

Nghiên cứu sử dụng cơ sở dữ liệu MIT-BIH Arrhythmia Database được cung cấp bởi PhysioNet.

Sau quá trình tiền xử lý, mỗi nhịp tim được biểu diễn dưới dạng chuỗi tín hiệu ECG một chiều gồm 320 mẫu với kích thước đầu vào của mô hình là (320, 1). Các mẫu dữ liệu được gán nhãn thành năm lớp gồm: N, L, R, V, A.

Tập dữ liệu được chia thành train set, val set và test set theo cấu hình được định dạng thống nhất trong suốt trong toàn bộ quá trình thực nghiệm nhằm đảm bảo tính nhất quán khi so sánh giữa các mô hình.

3.6.4 Quy trình đánh giá

Đối với mỗi mô hình, quá trình đánh giá được thực hiện trên cùng một tập kiểm tra (test set) nhằm đảm bảo tính khách quan của kết quả.

Các chỉ số được sử dụng để đánh giá bao gồm:

- Accuracy
- Precision
- Recall
- F1-score
- Specificity
- Ma trận nhầm lẫn
- Số lượng tham số
- Bộ nhớ tham số
- Kích thước mô hình TensorFlow Lite
- Thời gian suy luận trung bình trên mỗi mẫu ECG

Các kết quả thực nghiệm thu được sẽ được trình bày và phân tích chi tiết trong Chương 4.


CHƯƠNG 4

KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ

4.1 KẾT QUẢ TỐI ƯU HÓA BẰNG DEPTHWISE SEPARABLE CONVOLUTION

4.1.1 Kết quả huấn luyện


Dựa trên biểu đồ huấn luyện hệ thống, quá trình hội tụ của mô hình diễn ra rất lý tưởng và đạt hiệu năng cao. Đối với đường Loss, cả Train Loss và Val Loss đều có xu hướng giảm mạnh và mượt mà ngay từ những epoch đầu tiên. Cụ thể, Train Loss giảm nhanh từ 0.7949 xuống 0.2397 chỉ sau 10 epoch, thể hiện tốc độ học tín hiệu cực kỳ tối ưu của thuật toán. Ở các giai đoạn sau, khi learning rate được điều chỉnh giảm dần theo chiến lược phù hợp, đường loss tiệm cận trạng thái hội tụ ổn định, duy trì giá trị rất thấp ở mức khoảng 0.0766 đối với tập huấn luyện và đi ngang quanh ngưỡng 0.1380 đối với tập kiểm thử.



Hình 4.1 Biểu đồ Loss thu được sau huấn luyện

Song song với đó, đường Accuracy chứng kiến sự tăng trưởng đồng đều, bứt phá mạnh mẽ vượt mốc 91.22% ngay từ epoch thứ 5. Trong suốt quá trình còn lại, độ chính xác trên hai tập dữ liệu tăng dần và tiến tới trạng thái bão hòa ổn định từ

epoch 60 trở đi. Kết quả cuối cùng đạt hiệu năng phân loại vô cùng ấn tượng với Val Accuracy (ACC) đạt xấp xỉ 97.63% – 97.65%.



Hình 4.2 Biểu đồ Accuracy thu được sau huấn luyện

Khoảng cách giữa các đường Train và Validation (cả đối với Loss lẫn Accuracy) luôn giữ một khoảng cách rất nhỏ, song song và không hề xảy ra hiện tượng đường Val Loss bị bật tăng ngược trở lại ở giai đoạn cuối. Điều này là minh chứng rõ ràng cho thấy mô hình đạt trạng thái khớp tốt, hoàn toàn tránh được hiện tượng quá khớp (Overfitting) và sở hữu khả năng tổng quát hóa dữ liệu cực kỳ mạnh mẽ. Bên cạnh đó, các chỉ số đánh giá đi kèm như F1-score đạt 0.9757, độ nhạy (SEN) đạt 0.9763 và độ đặc hiệu (SPEC) đạt 0.9865 phản ánh một mô hình phân loại toàn diện, có độ tin cậy rất cao.

Bảng 4.1 Kết quả đánh giá mô hình Mini InceptionNet-DW trên tập kiểm tra và so sánh với mô hình Mini InceptionNet gốc.

Chỉ số	Mini InceptionNet	Mini InceptionNet-DW
Accuracy	98,75%	97,64%
Sensitivity (Recall)	98,75%	97,64%
Specificity	99,37%	98,85%


Positive Predictive Value (Precision)	98,73%	97,60%
F1 – score	98,73%	97,61%
Parameters	6.457	4.228
Parameter Memory	25,22 KB	16,52 KB

Kết quả cho thấy việc thay thế các lớp Conv1D truyền thống bằng các khối Depthwise Separable Convolution giúp giảm số lượng tham số từ 6.457 xuống còn 4.228 tham số, tương đương mức giảm khoảng 34,5%. Đồng thời, bộ nhớ tham số giảm từ 25,22 KB xuống còn 16,52 KB.

Mặc dù độ chính xác phân loại giảm từ 98,75% xuống 97,64%, mức suy giảm chỉ khoảng 1,11%, cho thấy mô hình vẫn duy trì được khả năng nhận dạng tín hiệu ECG ở mức cao trong khi đạt được hiệu quả tối ưu hóa đáng kể về mặt kiến trúc.

4.1.2 Ma trận nhầm lẫn của mô hình Mini InceptionNet-DW

Từ Hình 4.3 có thể nhận thấy phần lớn các mẫu vẫn được phân loại chính xác và tập trung trên đường chéo chính của ma trận nhầm lẫn.



Hình 4.3 CM của mô hình Mini InceptionNet-DW trên tập kiểm tra

Lớp **Normal** đạt số lượng dự đoán đúng cao nhất với 11.132 mẫu được phân loại chính xác. Các lớp **LBBB**, **RBBB** và **PVC** cũng duy trì tỷ lệ nhận dạng cao với lần lượt 1.177, 1.059 và 1007 mẫu được dự đoán đúng.

Tuy nhiên, so với mô hình Mini InceptionNet gốc, số lượng mẫu bị nhầm lẫn đã tăng lên ở hầu hết các lớp. Đặc biệt, lớp **APB** có tỷ lệ nhầm lẫn cao nhất khi có 76 mẫu bị phân loại nhầm sang lớp Normal và 23 mẫu bị phân loại nhầm sang lớp RBBB. Điều này cho thấy việc giảm số lượng tham số của mô hình đã làm suy giảm khả năng học các đặc trưng tinh vi của một số loại nhịp tim có hình dạng tương đối giống nhau.

Ngoài ra, lớp **PVC** cũng xuất hiện nhiều trường hợp bị nhận dạng nhầm thành lớp Normal hơn so với mô hình gốc. Kết quả này phản ánh sự đánh đổi giữa khả năng biểu diễn của mô hình và mức độ tối ưu hóa tài nguyên tính toán.

4.1.3 So sánh ma trận nhầm lẫn trước và sau khi áp dụng Focal Loss + Class Weight

Để đánh giá hiệu quả của chiến lược xử lý mất cân bằng dữ liệu, mô hình Mini InceptionNet-DW được huấn luyện trong hai trường hợp: sử dụng hàm mất mát thông thường và sử dụng Focal Loss kết hợp Class Weight.


Bảng 4.2 Kết quả đánh giá

Chỉ số	Không áp dụng	Có áp dụng
ACC	97,64%	97,64%
SEN	97,64%	97,64%
SPEC	98,73%	98,85%
PPV	97,60%	97,60%
F1-score	97,50%	97,61%

Có thể thấy Accuracy tổng thể của hai mô hình là tương đương nhau. Tuy nhiên, mô hình sử dụng Focal Loss và Class Weight đạt giá trị Specificity và F1-score

cao hơn. Điều này cho thấy mặc dù mức cải thiện về Accuracy không đáng kể, khả năng nhận dạng các lớp thiểu số đã được cải thiện.

Hình 4.3 trình bày ma trận nhầm lẫn của mô hình Mini InceptionNet-DW khi sử dụng Focal Loss và Class Weight, trong khi Hình 4.4 phía dưới thể hiện kết quả khi không áp dụng hai kỹ thuật này.



Hình 4.4 CM của mô hình Mini InceptionNet-DW không sử dụng Focal Loss và Class Weight

Quan sát hai ma trận nhầm lẫn cho thấy sự cải thiện rõ rệt nhất xuất hiện ở lớp **APB** (Atrial Premature Beat) – lớp có số lượng mẫu thấp và thường bị nhầm lẫn với lớp Normal.

Bảng 4.3 so sánh số lượng lớp APB khi không áp dụng và có áp dụng Focal Loss và Class Weight

Lớp APB	Không áp dụng	Có áp dụng
Dự đoán đúng APB	263	280
Nhầm thành Normal	93	76

Kết quả cho thấy số lượng mẫu APB được nhận dạng đúng tăng từ 263 lên 280 mẫu, trong khi số mẫu APB bị nhầm sang lớp Normal giảm từ 93 xuống còn 76

mẫu. Điều này chứng tỏ mô hình đã học tốt hơn các đặc trưng của lớp thiểu số sau khi áp dụng chiến lược xử lý mất cân bằng dữ liệu.

Ngoài lớp APB, các lớp bất thường khác như PVC và RBBB cũng ghi nhận sự cải thiện nhẹ về số lượng dự đoán đúng. Mặc dù mức tăng không lớn, kết quả này cho thấy Focal Loss và Class Weight giúp mô hình giảm xu hướng thiên lệch về lớp Normal và nâng cao khả năng nhận dạng các nhịp tim bất thường.

Từ các kết quả trên có thể kết luận rằng việc sử dụng Focal Loss kết hợp Class Weight không làm thay đổi đáng kể Accuracy tổng thể nhưng cải thiện chất lượng phân loại đối với các lớp thiểu số. Vì vậy, chiến lược này được sử dụng cho toàn bộ các thí nghiệm được trình bày trong các phần tiếp theo của nghiên cứu.

4.1.4 Nhận xét

Mô hình Mini InceptionNet-DW đạt Accuracy 97,64% với 4.228 tham số, giảm 34,5% so với mô hình gốc. Kết quả cho thấy kiến trúc Depthwise Separable Convolution giúp giảm đáng kể độ phức tạp của mô hình trong khi vẫn duy trì hiệu năng phân loại ở mức cao.

4.2 KẾT QUẢ LƯỢNG TỬ HÓA PTQ

4.2.1 Kết quả phân loại

Bảng 4.4 Kết quả lượng tử hóa PQT trên model gốc

Chỉ số	Full INT8	Float32 – INT8 – Float32
Accuracy	97,67%	98,38%
Sensitivity (Recall)	97,67%	98,38%
Specificity	98,93%	99,24%
Positive Predictive Value (Precision)	97,65%	98,36%
F1-score	97,66%	98,36%


Kết quả cho thấy cả hai phương pháp PTQ đều duy trì được độ chính xác ở mức cao sau khi lượng tử hóa mô hình.

Trong đó, cấu hình **Float32 – INT8 – Float32** đạt Accuracy 98,38%, chỉ thấp hơn khoảng 0,37% so với mô hình Float32 gốc (98,75%). Trong khi đó, cấu hình **Full INT8** đạt Accuracy 97,67%, thấp hơn khoảng 1,08%.

Điều này cho thấy việc giữ nguyên dữ liệu đầu vào và đầu ra ở định dạng Float32 giúp hạn chế sai số lượng tử hóa phát sinh trong quá trình chuyển đổi dữ liệu, từ đó duy trì hiệu năng phân loại tốt hơn.

4.2.2 Ma trận nhầm lẫn của mô hình PTQ

Từ Hình 4.5 có thể nhận thấy phần lớn các mẫu vẫn được phân loại chính xác và tập trung trên đường chéo chính của ma trận nhầm lẫn.



Hình 4.5 CM của mô hình Mini InceptionNet + PTQ (Full INT8)

Lớp **Normal** đạt 11.165 mẫu dự đoán đúng, trong khi các lớp **LBBB**, **RBBB** và **PVC** cũng duy trì tỷ lệ nhận dạng cao với lần lượt 1.186, 1.027 và 984 mẫu được phân loại chính xác.

So với mô hình Float32 ban đầu, số lượng mẫu bị nhầm lẫn tăng nhẹ ở hầu hết các lớp. Đặc biệt, lớp **APB** tiếp tục là lớp khó phân loại nhất khi có 66 mẫu bị nhận

dạng nhầm thành lớp Normal. Ngoài ra, một số mẫu RBBB cũng bị phân loại nhầm thành APB hoặc Normal nhiều hơn so với mô hình gốc.

Tuy nhiên, mức độ nhầm lẫn tăng không đáng kể, cho thấy quá trình lượng tử hóa sau huấn luyện vẫn bảo toàn được phần lớn khả năng biểu diễn đặc trưng của mô hình.

4.2.3 Nhận xét

Cả hai cấu hình PTQ đều duy trì Accuracy trên 97%, cho thấy mô hình Mini InceptionNet có khả năng thích nghi tốt với quá trình lượng tử hóa. Trong đó, cấu hình Float32–INT8–Float32 cho kết quả tốt hơn Full INT8.

4.3 KẾT QUẢ LƯỢNG TỬ HÓA QAT

4.3.1 So sánh các chiến lược QAT

Để đánh giá ảnh hưởng của các phương pháp huấn luyện nhận thức lượng tử hóa, nghiên cứu tiến hành khảo sát nhiều chiến lược QAT khác nhau trên mô hình Mini InceptionNet.

Bảng 4.5 Kết quả đánh giá các chiến lược QAT được thực hiện.

	MiniInception + QAT				
	QAT từ đầu (10 epoch)	Float → QAT (30 epoch)	Fine-tune QAT		Symmetric QAT (Zero-point = 0)
			Chỉ quantize Conv, 100 mẫu đại diện	Quantize Conv và Dense, 500 samples, earlystopping, kiểm soát learning rate	
ACC	0.9133	0.9525	0.9756	0.9855	0.9780
SEN	0.9133	0.9525	0.9756	0.9855	0.9780

SPEC	0.9481	0.9722	0.9892	0.9919	0.9901
PPV	0.9083	0.9520	0.9765	0.9852	0.9782

Kết quả cho thấy chiến lược huấn luyện có ảnh hưởng rất lớn đến hiệu quả của QAT.

Khi áp dụng QAT ngay từ đầu quá trình huấn luyện, mô hình chỉ đạt độ chính xác 91,33%, thấp hơn đáng kể so với mô hình Float32. Nguyên nhân là do sai số lượng tử hóa xuất hiện ngay từ giai đoạn đầu khiến quá trình tối ưu trọng số trở nên khó khăn, làm giảm khả năng hội tụ của mạng.

Khi mô hình được huấn luyện trước bằng Float32 rồi mới chuyển sang QAT, độ chính xác tăng lên 95,25%, cho thấy việc học đặc trưng trước khi áp dụng lượng tử hóa giúp mô hình ổn định hơn.

Phương pháp Fine-tune QAT từ mô hình Float32 đã hội tụ cho kết quả tốt nhất. Đặc biệt, cấu hình sử dụng 500 mẫu đại diện, lượng tử hóa cả các lớp Conv và Dense, kết hợp cơ chế Early Stopping và điều chỉnh Learning Rate đạt Accuracy 98,55%, gần tương đương với mô hình Float32 ban đầu.

4.3.2 Kết quả mô hình QAT tốt nhất

Từ các thí nghiệm trên, mô hình Fine-tune QAT với 500 mẫu đại diện được lựa chọn làm mô hình QAT tối ưu để so sánh với các phương pháp khác.


Bảng 4.6 Kết quả so sánh giữa mô hình Float32 và mô hình QAT được lựa chọn.

Chỉ số	Mini InceptionNet	Mini InceptionNet + QAT
Accuracy	98,75%	98,55%
Sensitivity	98,75%	98,55%
Specificity	99,37%	99,19%
PPV	98,73%	98,52%

Kết quả cho thấy mô hình QAT chỉ giảm khoảng 0,20% Accuracy so với mô hình Float32 ban đầu. Mức suy giảm này là rất nhỏ và thấp hơn đáng kể so với phương pháp PTQ Full INT8.

4.3.3 Ma trận nhầm lẫn của mô hình QAT

Từ Hình 4.6 có thể thấy phần lớn các mẫu vẫn được phân loại chính xác và tập trung trên đường chéo chính của ma trận nhầm lẫn.



Hình 4.6 CM của mô hình Mini InceptionNet + QAT

Lớp **Normal** đạt 11.216 mẫu dự đoán đúng. Các lớp **LBBB**, **RBBB** và **PVC** cũng duy trì tỷ lệ nhận dạng cao với lần lượt 1.190, 1.051 và 1.027 mẫu được phân loại chính xác.

Lớp **APB** tiếp tục là lớp khó phân loại nhất khi có 65 mẫu bị nhận dạng nhầm thành lớp Normal và 7 mẫu bị nhận dạng nhầm thành lớp PVC. Tuy nhiên, số lượng mẫu được dự đoán đúng vẫn đạt 307 mẫu, cho thấy khả năng nhận dạng của mô hình vẫn được duy trì tốt sau quá trình lượng tử hóa.

So với mô hình Float32 ban đầu, cấu trúc phân bố của ma trận nhầm lẫn gần như không thay đổi đáng kể. Điều này chứng tỏ mô hình đã thích nghi hiệu quả với sai số lượng tử hóa trong quá trình huấn luyện và vẫn bảo toàn được khả năng trích xuất đặc trưng của tín hiệu ECG.

4.3.4 Nhận xét

Fine-tune QAT đạt Accuracy 98,55%, cao nhất trong các phương pháp lượng tử hóa được khảo sát. Kết quả này cho thấy QAT giúp giảm đáng kể ảnh hưởng của sai số lượng tử hóa so với PTQ

4.4 SO SÁNH TỔNG HỢP CÁC MÔ HÌNH

4.4.1 So sánh tổng hợp


Bảng 4.7 trình bày kết quả tổng hợp của các mô hình chính được khảo sát trong nghiên cứu.

Bảng 4.7 Bảng so sánh tổng hợp các mô hình chính trong nghiên cứu

Chỉ số	Baseline	Baseline + PTQ	Baseline + QAT	Incep- DW	Incep-DW + PTQ	Incep-DW + QAT
ACC (%)	98.75	97.67	98.55	97,64	95.78	95.25
SEN (%)	98.75	97.67	98.55	97,64	95.78	95.25
SPEC (%)	99.37	98.93	99.19	98,85	97.75	97.22
PPV (%)	98.73	97.65	98.52	97,60	95.64	95.20
F1-Score	98.73	97.66	98.53	97,61	95.66	94.94
Định dạng	Float32	INT8	INT8	Float32	INT8	INT8
Parameters	6457	6457	6457	4228	4228	4228
Parameter Memory	25.22 KB	-	-	16.52 KB	-	-
Buffer Weights	-	7.25 KB	7.25 KB	-	4.64 KB	4.61 KB
Số Operator	-	122	122	-	185	227
Inference (ms/sample)	0.5040	0.2461	0.2106	0.5539	0.2645	0.2442

Kết quả cho thấy mỗi phương pháp tối ưu hóa mang lại những ưu điểm và hạn chế riêng.

4.4.2 So sánh độ chính xác phân loại



Hình 4.7 So sánh metric của các mô hình

Từ Hình 4.7 có thể nhận thấy mô hình Mini InceptionNet gốc đạt Accuracy cao nhất với 98,75%.

Trong các mô hình lượng tử hóa, QAT đạt Accuracy 98,55%, chỉ thấp hơn 0,20% so với mô hình gốc. Trong khi đó, PTQ đạt Accuracy 97,67%, thấp hơn khoảng 1,08%.

Đối với nhóm mô hình Conv1D-DW, Accuracy giảm xuống còn 97,64%. Khi kết hợp với PTQ, Accuracy tiếp tục giảm xuống 95,78%. Mức suy giảm lớn nhất xuất hiện ở mô hình Conv1D-DW + QAT với Accuracy chỉ đạt 95,25%.

Kết quả này cho thấy việc lượng tử hóa trên kiến trúc Mini InceptionNet gốc mang lại hiệu quả tốt hơn đáng kể so với việc kết hợp lượng tử hóa với Conv1D-DW.

4.4.3 So sánh số lượng tham số

Các mô hình sử dụng Conv1D-DW đều có số lượng tham số là 4.228, thấp hơn đáng kể so với 6.457 tham số của kiến trúc gốc.

Mức giảm tham số đạt:

$$\frac{6457 - 4228}{6457} \times 100 = 34.52\%$$

Bộ nhớ tham số cũng giảm từ 25,22 KB xuống còn 16,52 KB.

Kết quả này chứng minh Conv1D-DW là giải pháp hiệu quả trong việc giảm độ phức tạp của mô hình.

4.4.4 So sánh kích thước mô hình và cấu trúc TensorFlow Lite

Mô hình QAT đạt kích thước TensorFlow Lite nhỏ nhất với khoảng 50 KB, gần tương đương mô hình PTQ.

Trong khi đó, các mô hình Conv1D-DW sau lượng tử hóa có kích thước lớn hơn đáng kể mặc dù số lượng tham số nhỏ hơn. Cụ thể:

Bảng 4.8 So sánh kích thước sau lượng tử

Model	Input/Output	Số operator	Buffer weights
PTQ Baseline	INT8 / INT8	122	~7.25 KB
QAT Baseline	INT8 / INT8	122	~7.25 KB
PTQ DW	INT8 / INT8	185	~4.64 KB
QAT DW	INT8 / INT8	227	~4.61 KB

Nguyên nhân là do Conv1D-DW làm tăng số lượng toán tử trong đồ thị TensorFlow Lite. Mô hình PTQ và QAT trên Mini InceptionNet gốc chỉ sử dụng 122 operator, trong khi Conv1D-DW + PTQ sử dụng 185 operator và Conv1D-DW + QAT sử dụng tới 227 operator.


Do đó, mặc dù số lượng tham số giảm, kích thước file TensorFlow Lite không giảm tương ứng.

4.4.5 So sánh thời gian suy luận

Để đảm bảo tính khách quan, thời gian suy luận của mỗi mô hình được đo lặp lại 5 lần trên cùng tập dữ liệu kiểm thử. Giá trị thời gian suy luận trung bình được tính bằng trung bình cộng của 5 lần đo. Các thí nghiệm được thực hiện trên bộ xử lý Intel Core i5-1135G7 với cùng điều kiện phần cứng.

Bảng 4.9 Thời gian suy luận của mô hình

Model	Baseline	Baseline + PTQ (Full int8)	Baseline + QAT	Incep-DW	Incep-DW + PTQ	Incep-DW + QAT
1	0.5078	0.2342	0.2085	0.5410	0.2544	0.2640
2	0.5161	0.2454	0.2057	0.5444	0.2633	0.2453
3	0.4756	0.2346	0.2052	0.5397	0.2741	0.2380
4	0.5261	0.2641	0.2217	0.6069	0.2532	0.2311
5	0.4948	0.2524	0.2119	0.5371	0.2775	0.2429
TB (ms)	0.5040	0.2461	0.2106	0.5539	0.2645	0.2442



Hình 4.8 So sánh thời gian suy luận trung bình

Kết quả đo thời gian suy luận trên bộ xử lý Intel Core i5-1135G7 cho thấy các mô hình lượng tử hóa đều có tốc độ xử lý nhanh hơn đáng kể so với mô hình Float32. Mô hình QAT đạt thời gian suy luận thấp nhất với 0,2106 ms/mẫu, nhanh hơn khoảng:

$$\frac{0.5040}{0.2106} \approx \mathbf{2.39}$$

lần so với mô hình Float32 ban đầu.

Tương tự, mô hình Mini InceptionNet + PTQ đạt thời gian suy luận 0,2461 ms/mẫu, nhanh hơn khoảng 2,04 lần so với mô hình gốc. Điều này cho thấy việc chuyển đổi các phép toán từ Float32 sang INT8 đã giúp giảm đáng kể chi phí tính toán trên CPU.

Một kết quả đáng chú ý là mô hình Mini InceptionNet-DW mặc dù giảm khoảng 34,5% số lượng tham số nhưng lại có thời gian suy luận cao nhất, đạt 0,5539 ms/mẫu. Kết quả này cho thấy việc giảm số lượng tham số không đồng nghĩa với việc giảm thời gian thực thi.

Nguyên nhân là do kiến trúc Conv1D-DW sử dụng nhiều phép toán Depthwise Convolution, Pointwise Convolution và Batch Normalization hơn so với kiến trúc gốc, làm tăng số lượng toán tử cần thực hiện trong đồ thị tính toán. Trên nền tảng CPU được sử dụng trong nghiên cứu, chi phí điều phối các toán tử này lớn hơn lợi ích thu được từ việc giảm tham số, dẫn đến thời gian suy luận tăng lên.

Khi kết hợp với lượng tử hóa, thời gian suy luận của các mô hình Conv1D-DW được cải thiện đáng kể. Cụ thể, mô hình Mini InceptionNet-DW + PTQ đạt 0,2645 ms/mẫu và mô hình Mini InceptionNet-DW + QAT đạt 0,2442 ms/mẫu. Tuy nhiên, các mô hình này vẫn không đạt được sự cân bằng tốt giữa tốc độ và độ chính xác như mô hình Mini InceptionNet + QAT.

Từ các kết quả thực nghiệm có thể thấy rằng mô hình **Mini InceptionNet + QAT** là phương án tối ưu nhất xét trên cả hai tiêu chí độ chính xác và tốc độ suy luận, đồng thời vẫn duy trì kích thước mô hình nhỏ để phục vụ triển khai trên các thiết bị có tài nguyên hạn chế.

4.4.6 Nhận xét tổng hợp

Kết quả thực nghiệm cho thấy hai hướng tối ưu hóa được khảo sát trong nghiên cứu có tác động khác nhau đến hiệu năng của mô hình phân loại ECG.

Đối với hướng tối ưu kiến trúc, việc thay thế các lớp Conv1D bằng Depthwise Separable Convolution giúp giảm đáng kể số lượng tham số và bộ nhớ lưu trữ. Tuy nhiên, sự đơn giản hóa kiến trúc cũng làm giảm một phần khả năng biểu diễn đặc

trung của mô hình, dẫn đến sự suy giảm độ chính xác so với mô hình Mini InceptionNet ban đầu.

Đối với hướng tối ưu bằng lượng tử hóa, cả PTQ và QAT đều giúp chuyển đổi mô hình sang định dạng INT8, từ đó giảm kích thước lưu trữ và cải thiện tốc độ suy luận. Trong đó, PTQ có ưu điểm là quy trình triển khai đơn giản, không yêu cầu huấn luyện lại mô hình nhưng vẫn duy trì được độ chính xác ở mức cao. Ngược lại, QAT yêu cầu chi phí huấn luyện lớn hơn nhưng mang lại khả năng thích nghi tốt với sai số lượng tử hóa, giúp duy trì hiệu năng phân loại gần tương đương mô hình Float32.

Kết quả cũng cho thấy việc kết hợp đồng thời kiến trúc Depthwise Separable Convolution và lượng tử hóa không phải lúc nào cũng mang lại hiệu quả cộng hưởng. Khi khả năng biểu diễn của mô hình đã bị suy giảm do tối giản kiến trúc, việc tiếp tục áp dụng lượng tử hóa có thể làm gia tăng sai số và ảnh hưởng đến độ chính xác phân loại.

Xét trên các tiêu chí Accuracy, kích thước mô hình và thời gian suy luận, mô hình Mini InceptionNet kết hợp Quantization-Aware Training là phương án đạt hiệu quả tổng thể tốt nhất trong phạm vi nghiên cứu. Mô hình này duy trì được độ chính xác gần tương đương phiên bản Float32 trong khi vẫn tận dụng được các lợi ích của mô hình INT8, phù hợp cho các ứng dụng phân loại ECG trên nền tảng Edge AI và hệ thống nhúng.

4.5 THẢO LUẬN

4.5.1 Ảnh hưởng của kiến trúc Depthwise Separable Convolution

Kết quả thực nghiệm cho thấy việc thay thế các lớp Conv1D bằng Conv1D-DW đã giúp giảm đáng kể độ phức tạp của mô hình. Số lượng tham số giảm từ 6.457 xuống còn 4.228 tham số, tương ứng mức giảm khoảng 34,5%. Bộ nhớ tham số cũng giảm từ 25,22 KB xuống 16,52 KB.

Tuy nhiên, sự đơn giản hóa kiến trúc đi kèm với sự suy giảm nhất định về hiệu năng phân loại. Accuracy của mô hình giảm từ 98,75% xuống còn 97,64%. Điều

này cho thấy việc giảm số lượng tham số đã làm hạn chế khả năng học và biểu diễn đặc trưng của mạng đối với tín hiệu ECG.

Một kết quả đáng chú ý là mặc dù số lượng tham số giảm đáng kể, thời gian suy luận trung bình lại tăng từ 0,5040 ms lên 0,5539 ms cho mỗi mẫu. Kết quả này cho thấy số lượng tham số không phải là yếu tố duy nhất quyết định tốc độ thực thi của mô hình. Trên nền tảng CPU Intel Core i5-1135G7, việc phân tách phép tích chập thành các bước Depthwise và Pointwise làm tăng số lượng phép toán trung gian cũng như chi phí điều phối dữ liệu, dẫn đến thời gian xử lý cao hơn so với mô hình gốc.

Như vậy, Conv1D-DW mang lại lợi ích rõ rệt về mặt giảm kích thước kiến trúc, nhưng chưa chứng minh được ưu thế về tốc độ suy luận trên nền tảng CPU được sử dụng trong nghiên cứu.

4.5.2 So sánh hiệu quả giữa PTQ và QAT

Cả PTQ và QAT đều giúp chuyển đổi mô hình từ định dạng Float32 sang INT8, qua đó giảm kích thước lưu trữ và cải thiện tốc độ suy luận. Tuy nhiên, mức độ duy trì độ chính xác của hai phương pháp có sự khác biệt đáng kể.

Với PTQ, mô hình đạt Accuracy 97,67%, thấp hơn khoảng 1,08% so với mô hình Float32. Mặc dù xuất hiện sai số lượng tử hóa, phần lớn đặc trưng đã học vẫn được bảo toàn. Ưu điểm lớn nhất của PTQ là quy trình triển khai đơn giản và không yêu cầu huấn luyện lại mô hình.

Trong khi đó, mô hình QAT đạt Accuracy 98,55%, chỉ thấp hơn 0,20% so với mô hình gốc. Kết quả này cho thấy việc mô phỏng quá trình lượng tử hóa ngay trong giai đoạn huấn luyện đã giúp mạng thích nghi tốt hơn với môi trường INT8. Các trọng số được điều chỉnh để giảm ảnh hưởng của sai số lượng tử hóa trước khi mô hình được chuyển đổi sang TensorFlow Lite.

Ngoài ra, các thí nghiệm QAT cũng cho thấy thời điểm áp dụng lượng tử hóa có ảnh hưởng lớn đến kết quả cuối cùng. Các mô hình được huấn luyện hoàn chỉnh

trên miền Float32 trước khi thực hiện fine-tune QAT đều cho kết quả tốt hơn so với việc áp dụng QAT ngay từ đầu quá trình huấn luyện.

4.5.3 Khả năng kết hợp Conv1D-DW và lượng tử hóa

Một mục tiêu của nghiên cứu là khảo sát khả năng kết hợp đồng thời hai hướng tối ưu hóa gồm giảm độ phức tạp kiến trúc và lượng tử hóa tham số. Tuy nhiên, kết quả thực nghiệm cho thấy hiệu quả thu được chưa đạt như kỳ vọng.

Mô hình Mini InceptionNet-DW + PTQ đạt Accuracy 95,78%, trong khi Mini InceptionNet-DW + QAT đạt Accuracy 95,25%. Mặc dù các mô hình này có số lượng tham số thấp hơn đáng kể so với mô hình gốc, hiệu năng phân loại giảm tương đối nhiều.

Nguyên nhân có thể xuất phát từ việc hai kỹ thuật tối ưu hóa cùng tác động lên khả năng biểu diễn của mạng. Depthwise Separable Convolution làm giảm số lượng tham số học được, trong khi lượng tử hóa tiếp tục làm giảm độ chính xác biểu diễn của các trọng số và giá trị kích hoạt. Khi hai hiệu ứng này xuất hiện đồng thời, sai số tích lũy trở nên đáng kể hơn so với khi áp dụng riêng lẻ từng kỹ thuật.

Bên cạnh đó, số lượng operator của các mô hình Conv1D-DW sau lượng tử hóa cũng tăng đáng kể so với mô hình Mini InceptionNet gốc. Điều này cho thấy việc giảm tham số không đồng nghĩa với việc giảm độ phức tạp thực thi trên mọi nền tảng phần cứng.

4.5.4 Mô hình tối ưu được lựa chọn

Dựa trên toàn bộ kết quả thực nghiệm, mô hình Mini InceptionNet kết hợp Quantization-Aware Training được lựa chọn là phương án tối ưu trong phạm vi nghiên cứu.

Mô hình này đạt Accuracy 98,55%, chỉ thấp hơn 0,20% so với mô hình Float32 ban đầu nhưng vẫn tận dụng được các ưu điểm của định dạng INT8 như giảm kích thước lưu trữ và cải thiện tốc độ suy luận. Đồng thời, chỉ chiếm Buffer Weights khoảng 7.25 KB, phù hợp với các nền tảng có tài nguyên hạn chế.

Kết quả đạt được cho thấy QAT là giải pháp hiệu quả nhất để cân bằng giữa độ chính xác phân loại và khả năng triển khai thực tế. Đây cũng là phương án được đề xuất cho các ứng dụng phân loại tín hiệu ECG trên hệ thống Edge AI và thiết bị nhúng trong tương lai.

CHƯƠNG 5

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 KẾT LUẬN

Trong nghiên cứu này, mô hình Mini InceptionNet đã được tối ưu hóa cho bài toán phân loại tín hiệu điện tâm đồ (ECG) trên cơ sở dữ liệu MIT-BIH Arrhythmia Database thông qua hai hướng tiếp cận chính: tối ưu kiến trúc bằng Depthwise Separable Convolution và tối ưu biểu diễn tham số bằng các kỹ thuật lượng tử hóa.

Kết quả thực nghiệm cho thấy mô hình Mini InceptionNet gốc đạt Accuracy 98,75%, chỉ sai khác 0,62% so với kết quả được công bố trong bài báo tham khảo. Điều này khẳng định độ tin cậy của mô hình cơ sở được sử dụng trong nghiên cứu.

Đối với hướng tối ưu kiến trúc, việc thay thế các lớp Conv1D bằng Depthwise Separable Convolution giúp giảm số lượng tham số từ 6.457 xuống còn 4.228 tham số, tương ứng mức giảm khoảng 34,5%. Tuy nhiên, Accuracy giảm xuống còn 97,64%, cho thấy việc giảm độ phức tạp kiến trúc có ảnh hưởng nhất định đến khả năng biểu diễn đặc trưng của mô hình.

Đối với hướng tối ưu bằng lượng tử hóa, cả PTQ và QAT đều giúp chuyển đổi mô hình sang định dạng INT8, qua đó giảm kích thước lưu trữ và cải thiện tốc độ suy luận. Trong đó, PTQ đạt Accuracy 97,67% với ưu điểm là quy trình triển khai đơn giản và không yêu cầu huấn luyện lại mô hình.

Kết quả tốt nhất đạt được với phương pháp Quantization-Aware Training. Mô hình Mini InceptionNet + QAT đạt Accuracy 98,55%, chỉ thấp hơn 0,20% so với mô hình Float32 ban đầu, đồng thời Buffer Weights chỉ chiếm khoảng 7.25 KB và đạt thời gian suy luận trung bình 0,2106 ms trên mỗi mẫu ECG.

Từ các kết quả đạt được có thể kết luận rằng Quantization-Aware Training là giải pháp tối ưu nhất trong phạm vi nghiên cứu. Phương pháp này duy trì được độ chính xác gần tương đương mô hình Float32 trong khi vẫn tận dụng được các lợi ích của

lượng tử hóa INT8, phù hợp cho các ứng dụng phân loại ECG trên các hệ thống Edge AI và thiết bị nhúng có tài nguyên hạn chế.

5.2 HƯỚNG PHÁT TRIỂN

Mặc dù đã đạt được những kết quả khả quan, nghiên cứu vẫn còn một số hướng phát triển có thể tiếp tục thực hiện trong tương lai.

Thứ nhất, mô hình có thể được đánh giá trên các cơ sở dữ liệu ECG khác nhằm khảo sát khả năng tổng quát hóa đối với nhiều nguồn dữ liệu và đối tượng bệnh nhân khác nhau.

Thứ hai, các nghiên cứu tiếp theo có thể khảo sát những kiến trúc mạng nhẹ hiện đại như MobileNet, ShuffleNet hoặc GhostNet, đồng thời kết hợp với các kỹ thuật lượng tử hóa mức thấp hơn như INT4 để tiếp tục giảm kích thước mô hình và chi phí tính toán.

Thứ ba, mô hình tối ưu có thể được triển khai trực tiếp trên các nền tảng phần cứng nhúng hoặc FPGA nhằm đánh giá khả năng hoạt động trong môi trường thực tế, bao gồm các chỉ tiêu về tốc độ xử lý, mức tiêu thụ bộ nhớ và năng lượng.

Các hướng nghiên cứu trên sẽ góp phần nâng cao khả năng ứng dụng của hệ thống phân loại ECG trong các thiết bị chăm sóc sức khỏe thông minh và các nền tảng Edge AI trong tương lai.

TÀI LIỆU THAM KHẢO

- [1] H. L. Pham et al., "MINA: A Hardware-Efficient and Flexible Mini-InceptionNet Accelerator for ECG Classification in Wearable Devices," *IEEE Trans. Circuits Syst. I*, vol. 72, no. 6, pp. 2740–2753, 2025.
- [2] G. B. Moody and R. G. Mark, "The impact of the MIT-BIH Arrhythmia Database," *IEEE Eng. Med. Biol. Mag.*, vol. 20, no. 3, pp. 45–50, May-Jun. 2001.
- [3] A. Goldberger, L. Amaral, L. Glass, J. Hausdorff, P. C. Ivanov, R. Mark, et al., "PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals," *Circulation*, vol. 101, no. 23, pp. e215–e220, 2000, RRID: SCR_007345.
- [4] A. G. Howard, M. Zhu, B. Chen, D. Kalenichenko, W. Wang, T. Weyand, et al., "MobileNets: Efficient convolutional neural networks for mobile vision applications," arXiv preprint arXiv:1704.04861, 2017.
- [5] B. Jacob, S. Kligys, B. Chen, M. Zhu, M. Tang, A. G. Howard, et al., "Quantization and training of neural networks for efficient integer-arithmetic-only inference," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2018, pp. 2704–2713.
- [6] Google, "TensorFlow Model Optimization Toolkit documentation," TensorFlow. Accessed on: Mar. 20, 2026. [Online]. Available: https://www.tensorflow.org/model_optimization

Optimizing_NguyenHuuKhoa

by Ha Huynh

Submission date: 23-Jun-2026 08:47AM (UTC+0700)

Submission ID: 2986706273

File name: Optimizing_NguyenHuuKhoa_v2.pdf (2.2M)

Word count: 20757

Character count: 86284

Optimizing_NguyenHuuKhoa

ORIGINALITY REPORT

26%	22%	15%	%
SIMILARITY INDEX	INTERNET SOURCES	PUBLICATIONS	STUDENT PAPERS

PRIMARY SOURCES

1	ictu.edu.vn Internet Source	2%
2	tailieu.vn Internet Source	2%
3	www.ctu.edu.vn Internet Source	2%
4	cokhivietnam.vn Internet Source	1%
5	Ton Duc Thang University Publication	1%
6	text.123docz.net Internet Source	1%
7	www.slideshare.net Internet Source	1%
8	Hanoi National University of Education Publication	1%
9	123docz.net Internet Source	1%
10	fit.huflit.edu.vn Internet Source	1%
11	luanvan.co Internet Source	1%
12	journal.hcmue.edu.vn Internet Source	1%

13	portal.ptit.edu.vn Internet Source	<1 %
14	Phenikaa University Publication	<1 %
15	www.tailieudaihoc.com Internet Source	<1 %
16	github.com Internet Source	<1 %
17	Vũ Lê Quỳnh Phương, Trần Nguyễn Minh Thư, Phạm Nguyên Khang. "ỨNG DỤNG MÔ HÌNH REPVGG VÀO BÀI TOÁN PHÂN LOẠI TÌNH TRẠNG GIAO THÔNG", FAIR KỶ YẾU HỘI NGHỊ KHOA HỌC CÔNG NGHỆ QUỐC GIA LẦN THỨ XV - Nghiên cứu cơ bản và Ứng dụng công nghệ thông tin - Proceedings of the 15th National Conference on Fundamental and Applied Information Technology Research (FAIR'2022), 2022 Publication	<1 %
18	hcmute.edu.vn Internet Source	<1 %
19	www.thuvientailieu.vn Internet Source	<1 %
20	text.xemtailieu.net Internet Source	<1 %
21	Đào Vũ Hiệp, Mạc Đình Hiếu, Tống Việt Hùng, Vũ Văn Phán, Hà Quốc Trung. "IVA-EC: GIẢI PHÁP PHÂN TÍCH VIDEO THÔNG MINH DỰA TRÊN ĐIỆN TOÁN BIÊN", KỶ YẾU HỘI NGHỊ KHOA HỌC CÔNG NGHỆ QUỐC GIA LẦN THỨ XIII NGHIÊN CỨU CƠ BẢN VÀ ỨNG DỤNG CÔNG NGHỆ THÔNG TIN - Proceedings of the 13th National Conference on Fundamental &	<1 %

Applied Information Technology Research, 2020

Publication

22	doc.edu.vn Internet Source	<1 %
23	saigonbiz.com.vn Internet Source	<1 %
24	Trần Văn Quang, Trần Đình Toàn, Lê Mậu Long, Lê Minh Hưng. "PHÂN LOẠI HẠCH UNG THƯ PHỐI BẰNG MÔ HÌNH 3D-CNN", KỶ YẾU HỘI NGHỊ KHOA HỌC CÔNG NGHỆ QUỐC GIA LẦN THỨ XIII NGHIÊN CỨU CƠ BẢN VÀ ỨNG DỤNG CÔNG NGHỆ THÔNG TIN - Proceedings of the 13th National Conference on Fundamental & Applied Information Technology Research, 2020 Publication	<1 %
25	hvtc.edu.vn Internet Source	<1 %
26	thuvienso.hcmute.edu.vn Internet Source	<1 %
27	jst.tnu.edu.vn Internet Source	<1 %
28	Do Hoang Tu, Tran Van Lang, Pham Cong Xuyen, Le Mau Long. "PREDICTING THE ACTIVITY OF CHEMICAL COMPOUNDS BASED ON MACHINE LEARNING APPROACHES", FAIR KỶ YẾU HỘI NGHỊ KHOA HỌC CÔNG NGHỆ QUỐC GIA LẦN THỨ XVI Nghiên cứu cơ bản và Ứng dụng công nghệ thông tin Proceedings of the 16th National Conference on Fundamental and Applied Information Technology Research (FAIR'2023), 2023 Publication	<1 %

29	www.studocu.com Internet Source	<1 %
30	Giang Lê Khánh, Hương Hồ Thị Lan, Linh Nguyễn Thuỳ. "Khung học máy lai ghép IF – LOF để phát hiện số liệu GNSS-RTK ngoại lai trong quan trắc chuyển dịch cầu dây văng", <i>Transport and Communications Science Journal</i> , 2026 Publication	<1 %
31	Vu Van Hieu, Nguyen Thi Tinh, Ngo Van Binh. "COMBINED DEEP LEARNING NETWORK TO IMPROVE THE POSITIONING EFFICIENCY OF THE INDOOR POSITIONING SYSTEM", FAIR KỶ YẾU HỘI NGHỊ KHOA HỌC CÔNG NGHỆ QUỐC GIA LẦN THỨ XVI Nghiên cứu cơ bản và Ứng dụng công nghệ thông tin Proceedings of the 16th National Conference on Fundamental and Applied Information Technology Research (FAIR'2023), 2023 Publication	<1 %
32	ichi.pro Internet Source	<1 %
33	jst-ud.vn Internet Source	<1 %
34	thesis.lib.ncku.edu.tw Internet Source	<1 %
35	Vũ Trọng Hiếu, Nguyễn Đức Đảm, Vũ Quang Dũng, Bế Ngọc Sơn, Ngô Quốc Trinh, Phùng Tăng Nghị. "Nghiên cứu áp dụng mô hình LGBM trong dự báo khối lượng thể tích khô lớn nhất của đất sử dụng trong đầm nén nền đường", <i>Tạp chí điện tử Khoa học và Công nghệ Giao thông</i> , 2025 Publication	<1 %

36	jmst.mod.gov.vn Internet Source	<1 %
37	jmst.vimaru.edu.vn Internet Source	<1 %
38	luanvan.net.vn Internet Source	<1 %
39	vanhoadoisong.vn Internet Source	<1 %
40	www.zbook.vn Internet Source	<1 %
41	Long Vũ Thắng, Khôi Trần Đăng, Thuần Nguyễn Văn. "Ứng dụng trí tuệ nhân tạo vào hệ thống điều khiển xe điện tự lái tại trường đại học Nha Trang", <i>Transport and Communications Science Journal</i> , 2026 Publication	<1 %
42	arxiv.org Internet Source	<1 %
43	Hùng Hồ Việt. "Áp dụng các mô hình mạng nơ-ron nhân tạo (ANN) tính toán chiều dài khu xoáy của nước nhảy trong kênh chữ nhật nằm ngang", <i>Transport and Communications Science Journal</i> , 2026 Publication	<1 %
44	Thị Phương Loan Võ, Thị Bảo Trâm Lê, Đăng Khoa Nguyễn, Bình Minh Phan, Đình Tứ Nguyễn. "Nghiên cứu và thiết kế hệ thống giám sát an ninh tích hợp IoT", <i>CTU Journal of Science</i> , 2026 Publication	<1 %
45	www.mdpi.com Internet Source	<1 %

46	E. Delgado, J.L. Rodriguez, F. Jimenez, D. Cuesta, G. Castellanos. "Recognition of cardiac arrhythmias by means of beat clustering on ECG-holter records", 2007 Computers in Cardiology, 2007 Publication	<1 %
47	Phan Anh Cang, Nguyễn Thị Mỹ Nga, Phan Thượng Cang. "CHẨN ĐOÁN XUẤT HUYẾT NÃO DỰA TRÊN CHỈ SỐ HOUNSFIELD VÀ KỸ THUẬT MẠNG NƠ-RON TÍCH CHẬP", KỶ YẾU HỘI NGHỊ KHOA HỌC CÔNG NGHỆ QUỐC GIA LẦN THỨ XI NGHIÊN CỨU CƠ BẢN VÀ ỨNG DỤNG CÔNG NGHỆ THÔNG TIN, 2018 Publication	<1 %
48	Vietnam National University of Forestry Publication	<1 %
49	www.aimspress.com Internet Source	<1 %
50	tailieuso.udn.vn Internet Source	<1 %
51	www.researchgate.net Internet Source	<1 %
52	Duong Tran Duc, Pham Bao Son, Tan Hanh. "Xác định đặc điểm tác giả bài viết diễn đàn tiếng Việt dựa trên âm tiết và vần", Research and Development on Information and Communication Technology, 2017 Publication	<1 %
53	Hanoi Pedagogical University 2 Publication	<1 %
54	Đỗ Phúc Thịnh, Quách Thị Bích Nường, Trần Văn Ninh. "ƯỚC LƯỢNG SỐ NGƯỜI TRONG ĐÁM ĐÔNG SỬ DỤNG MẠNG NƠ-RON TÍCH	<1 %

CHẬP", KỸ YẾU HỘI NGHỊ KHOA HỌC CÔNG
NGHỆ QUỐC GIA LẦN THỨ XIII NGHIÊN CỨU
CƠ BẢN VÀ ỨNG DỤNG CÔNG NGHỆ THÔNG
TIN - Proceedings of the 13th National
Conference on Fundamental & Applied
Information Technology Research, 2020
Publication

55	m.vietnamnet.vn Internet Source	<1 %
56	vjs.ac.vn Internet Source	<1 %
57	Linh Lê Hà, Chinh Ngô Đức, Hiền Lê Đặc, Hải Hoàng Việt. "Đánh giá khả năng tăng cường dữ liệu trong dự báo khả năng chịu cắt của dầm bê tông cốt thép được tăng cường bởi bê tông UHPC", Transport and Communications Science Journal, 2026 Publication	<1 %
58	Phạm Văn Ngọc. "Mô hình dự đoán cường độ đất gia cố xi măng trong môi trường sunfat cao bằng học máy", Tạp chí Khoa học Công nghệ Xây dựng (TCKHCN XD) - ĐHXDHN, 2026 Publication	<1 %
59	doantotnghiep.vn Internet Source	<1 %
60	gonhub.com Internet Source	<1 %
61	issuu.com Internet Source	<1 %
62	www.coursehero.com Internet Source	<1 %
63	Võ Minh Thiện, Lê Minh Hưng, Trần Kim Tâm, Trần Văn Lăng. "XỬ LÝ MẤT CÂN BẰNG DỮ	<1 %

LIỆU TRONG PHÂN LOẠI TỔN THƯƠNG DA
TRÊN ẢNH SOI DA", KỶ YẾU HỘI NGHỊ KHOA
HỌC CÔNG NGHỆ QUỐC GIA LẦN THỨ XIII
NGHIÊN CỨU CƠ BẢN VÀ ỨNG DỤNG CÔNG
NGHỆ THÔNG TIN - Proceedings of the 13th
National Conference on Fundamental &
Applied Information Technology Research,
2020

Publication

64	Duc Hanh Nguyen, Van Hung Nguyen, Van Thai Phung, Van Quang Truong, Ly Tong, Trong Chuong Trinh. "Study on wind energy forecasting of Quang Tri region using artificial neural networks NARX", Journal of Measurement, Control, and Automation, 2025	<1 %
65	fr.slideshare.net Internet Source	<1 %
66	Yifei Ding, Minping Jia. "A Convolutional Transformer Architecture for Remaining Useful Life Estimation", 2021 Global Reliability and Prognostics and Health Management (PHM-Nanjing), 2021	<1 %
67	baoninhbinh.org.vn Internet Source	<1 %
68	www.actapress.com Internet Source	<1 %
69	123doc.org Internet Source	<1 %
70	Han-Gyeol Mun, Jeong-Min Woo, Seunghyun Moon, Byungjun Kim, Jongmin Lee, Jae-Yoon Sim, Hyunwoo Son. "Bayesian Deep-Learning Processor for Real-Time Bio-Applications With	<1 %

Structured Monte Carlo Dropout for High-Volume Sample Generation", IEEE Transactions on Circuits and Systems I: Regular Papers, 2026

Publication

71	Nguyễn Thị Duyên, Trương Xuân Nam, Nguyễn Thanh Tùng. "MỘT MÔ HÌNH HỌC SÂU CHO PHÁT HIỆN CẢM XÚC KHUÔN MẶT", KỶ YẾU HỘI NGHỊ KHOA HỌC CÔNG NGHỆ QUỐC GIA LẦN THỨ XII NGHIÊN CỨU CƠ BẢN VÀ ỨNG DỤNG CÔNG NGHỆ THÔNG TIN, 2019	<1 %
72	alphabimvn.com Internet Source	<1 %
73	siliconwit.com Internet Source	<1 %
74	studio.funix.edu.vn Internet Source	<1 %
75	thientanthoibao.com.vn Internet Source	<1 %
76	blog.ntechdevelopers.com Internet Source	<1 %
77	congdongtinhoc.vn Internet Source	<1 %
78	dosm.gov.vn Internet Source	<1 %
79	lib.uet.vnu.edu.vn Internet Source	<1 %
80	mftp.mmcheng.net Internet Source	<1 %
81	sangkienkinhnghiem.net	

	Internet Source	<1 %
82	skcd.vn Internet Source	<1 %
83	tailieu.tv Internet Source	<1 %
84	tailieu123.net Internet Source	<1 %
85	www.2cf.info Internet Source	<1 %
86	www.hanbonnuoc.com Internet Source	<1 %
87	Banking Academy Publication	<1 %
88	Lê Minh Lợi, Trần Nguyễn Minh Thư, Hồ Trọng Nguyễn, Phạm Nguyên Khang. "ỨNG DỤNG MÔ HÌNH U-NET PHÁT HIỆN VÙNG BẤT THƯỜNG TRÊN ẢNH MRI NÃO", KỶ YẾU HỘI NGHỊ KHOA HỌC CÔNG NGHỆ QUỐC GIA LẦN THỨ XIII NGHIÊN CỨU CƠ BẢN VÀ ỨNG DỤNG CÔNG NGHỆ THÔNG TIN - Proceedings of the 13th National Conference on Fundamental & Applied Information Technology Research, 2020 Publication	<1 %
89	Nguyễn Thái Minh Tuấn, Nguyễn Văn Khang. "Tìm nghiệm tuần hoàn của hệ tuyến tính từng khúc bằng hàm mũ ma trận và phương pháp bắn", TUYỂN TẬP HỘI NGHỊ KHOA HỌC TOÀN QUỐC LẦN THỨ NHẤT ĐỘNG LỰC HỌC VÀ ĐIỀU KHIỂN, 2019 Publication	<1 %

90	Nguyễn Đức Dư, Phạm Đình Phong, Phạm Đình Vũ, Nguyễn Đức Thảo. "Một phương pháp thiết kế ngữ nghĩa tính toán của các từ ngôn ngữ giải bài toán phân lớp dựa trên luật mờ", Journal of Research and Development on Information and Communication Technology, 2020 Publication	<1 %
91	canhgiacduoc.org.vn Internet Source	<1 %
92	dieutri.vn Internet Source	<1 %
93	doithoai.haiphongcity.vn Internet Source	<1 %
94	i.vietnamdoc.net Internet Source	<1 %
95	images1.cafef.vn Internet Source	<1 %
96	ir.vnulib.edu.vn Internet Source	<1 %
97	phankhang.vn Internet Source	<1 %
98	thongke.cesti.gov.vn Internet Source	<1 %
99	www.lapphap.vn Internet Source	<1 %
100	www.ptscquangngai.com.vn Internet Source	<1 %
101	www.smartvisiontech.vn Internet Source	<1 %

- | | | |
|-------|--|------|
| 102 | Ha Thi Minh Phuong, Nguyen Thanh Long, Nguyen Thanh Binh. "A COMBINATION OF FEATURE SELECTION AND DATA SAMPLING TECHNIQUES FOR SOFTWARE FAULT PREDICTION", FAIR KỸ YẾU HỘI NGHỊ KHOA HỌC CÔNG NGHỆ QUỐC GIA LẦN THỨ XVI Nghiên cứu cơ bản và Ứng dụng công nghệ thông tin Proceedings of the 16th National Conference on Fundamental and Applied Information Technology Research (FAIR'2023), 2023
<small>Publication</small> | <1 % |
| <hr/> | | |
| 103 | Jiaxiang Guo, Hao Qi. "Using Artificial Neural Networks to Model Errors in Biochemical Manipulation of DNA Molecules", IEEE/ACM Transactions on Computational Biology and Bioinformatics, 2021
<small>Publication</small> | <1 % |
| <hr/> | | |
| 104 | Lê Văn Vũ, Hoàng Lê Uyên Thực. "ỨNG DỤNG KỸ THUẬT NHẬN DẠNG TIẾNG NÓI TỰ ĐỘNG VÀO HỖ TRỢ HOẠT ĐỘNG KIỂM SOÁT KHÔNG LƯU", KỸ YẾU HỘI NGHỊ KHOA HỌC CÔNG NGHỆ QUỐC GIA LẦN THỨ XIII NGHIÊN CỨU CƠ BẢN VÀ ỨNG DỤNG CÔNG NGHỆ THÔNG TIN - Proceedings of the 13th National Conference on Fundamental & Applied Information Technology Research, 2020
<small>Publication</small> | <1 % |
| <hr/> | | |
| 105 | Trần Thị Hương, Phạm Văn Hạnh. "MỘT CÁCH TIẾP CẬN KẾT HỢP MẠNG NƠ-RON HỒI QUY VÀ TẬP LUẬT CHO PHÁT HIỆN XÂM NHẬP MẠNG", Tạp chí Khoa học Đại học Đà Lạt, 2019
<small>Publication</small> | <1 % |

aquanetviet.org

106	Internet Source	<1 %
107	bacsigioi.vn Internet Source	<1 %
108	cameragiarebinhduong.com Internet Source	<1 %
109	ctelg.ueh.edu.vn Internet Source	<1 %
110	dke.com.vn Internet Source	<1 %
111	dn721906.ca.archive.org Internet Source	<1 %
112	gridbon.blogspot.com Internet Source	<1 %
113	gs.ctu.edu.vn Internet Source	<1 %
114	gust.edu.vn Internet Source	<1 %
115	ictmag.vn Internet Source	<1 %
116	id.scribd.com Internet Source	<1 %
117	maker.iotlabs.vn Internet Source	<1 %
118	trangtrinhmoi.com Internet Source	<1 %
119	vi.wikipedia.org Internet Source	<1 %
120	vietnamnet.vn Internet Source	<1 %

121	vinachem.com.vn Internet Source	<1 %
122	vnpc.com.vn Internet Source	<1 %
123	www.grad.hcmut.edu.vn Internet Source	<1 %
124	www.hebergementwebs.com Internet Source	<1 %
125	www.hoiketoanhcm.org.vn Internet Source	<1 %
126	www.hopetech.vn Internet Source	<1 %
127	www.hyundaisaigon.vn Internet Source	<1 %
128	www.moha.gov.vn Internet Source	<1 %
129	www.unicef.org Internet Source	<1 %
130	www.voer.edu.vn Internet Source	<1 %
131	Anastácio, Ricardo Ribeiro. "Classificação de Cenas Acústicas em Dispositivos com Constrangimentos Computacionais Utilizando Inteligência Artificial", Instituto Politecnico de Leiria (Portugal), 2024 Publication	<1 %
132	Bushur, Jacob. "Hardware/Software Co-Design for Keyword Spotting on Edge Devices.", Purdue University, 2023 Publication	<1 %

- | | | |
|-------|---|------|
| 133 | Công Pháp Huỳnh, Hải Thọ Quách, Anh Phương Phạm. "Giải pháp cảnh báo tránh va chạm dựa trên dữ liệu môi trường và đặc điểm điều khiển phương tiện.", Journal of Research and Development on Information and Communication Technology, 2021
<small>Publication</small> | <1 % |
| <hr/> | | |
| 134 | Hoàng Ngọc Thanh, Trần Văn Lăng. "TẠO LUẬT CHO CÁC BỨC TƯỜNG LỬA SỬ DỤNG CÁC KỸ THUẬT KẾT HỢP DỰA TRÊN CÂY QUYẾT ĐỊNH", KỶ YẾU HỘI NGHỊ KHOA HỌC CÔNG NGHỆ QUỐC GIA LẦN THỨ XI NGHIÊN CỨU CƠ BẢN VÀ ỨNG DỤNG CÔNG NGHỆ THÔNG TIN, 2018
<small>Publication</small> | <1 % |
| <hr/> | | |
| 135 | Lê Hữu Bình, Nguyễn Đăng Khoa, Nguyễn Đình Hoàng Phương. "Thiết kế tậpô mạng không dây hình lưới: Một phương pháp mới sử dụng bài toán quy hoạch tuyến tính nguyên", Research and Development on Information and Communication Technology, 2017
<small>Publication</small> | <1 % |
| <hr/> | | |
| 136 | Mã Văn Thu, Đỗ Năng Toàn, Lê Sơn Thái, Đỗ Hồng Quân. "MỘT KỸ THUẬT RÚT GỌN BỀ MẶT LƯỚI MÔ HÌNH 3D TRONG CÁC ỨNG DỤNG CỦA THỰC TẠI ẢO", FAIR - NGHIÊN CỨU CƠ BẢN VÀ ỨNG DỤNG CÔNG NGHỆ THÔNG TIN - 2017, 2017
<small>Publication</small> | <1 % |
| <hr/> | | |
| 137 | Nguyễn Chí Thanh, Võ Thị Huyền Trang, Lê Minh Hưng, Hoàng Lê Uyên Thực. "KẾT HỢP ĐẶC TRƯNG SÂU TRONG HỖ TRỢ CHẨN ĐOÁN UNG THƯ VÚ TRÊN NHỮ ẮNH X-QUANG", KỶ YẾU HỘI NGHỊ KHOA HỌC CÔNG | <1 % |

NGHỆ QUỐC GIA LẦN THỨ XIII NGHIÊN CỨU
CƠ BẢN VÀ ỨNG DỤNG CÔNG NGHỆ THÔNG
TIN - Proceedings of the 13th National
Conference on Fundamental & Applied
Information Technology Research, 2020

Publication

- 138 Nguyễn Hiếu Cường. "Một lược đồ mới phát hiện ảnh giả mạo dựa trên luật Benford", Research and Development on Information and Communication Technology, 2017

<1 %

Publication

- 139 Nguyễn Hùng Cường, Trần Hoài Linh, Phạm Tiến Tới, Phạm Nguyễn Vân Phương. "Ứng dụng mạng nơ ron nhân tạo dự báo ảnh hưởng của các yếu tố công nghệ thi công đến tính công tác hỗn hợp bê tông tự lèn", Tạp chí Khoa học Công nghệ Xây dựng (KHCVXD) - ĐHXD, 2020

<1 %

Publication

- 140 Nguyễn Hồng Quang, Trịnh Văn Loan, Phạm Ngọc Hưng. "NHẬN DẠNG PHƯƠNG NGỮ TIẾNG VIỆT SỬ DỤNG MẠNG NƠN TÍCH CHẬP CNN", FAIR - NGHIÊN CỨU CƠ BẢN VÀ ỨNG DỤNG CÔNG NGHỆ THÔNG TIN - 2017, 2017

<1 %

Publication

- 141 Nguyễn Quang Phúc. "Gom cụm kết quả tìm kiếm video với hướng tiếp cận kết hợp đa đặc trưng", Journal of Research and Development on Information and Communication Technology, 2016

<1 %

Publication

- 142 Nguyễn Tiến Hà, Nguyễn Thị Minh Huyền, Nguyễn Minh Hải. "Xây dựng kho ngữ liệu du lịch song ngữ Việt-Anh giống hàng mức câu

<1 %

cho dịch máy", Research and Development on
Information and Communication Technology,
2018

Publication

- 143 Nguyễn Văn Minh, Nguyễn Long Giang, Nguyễn Như Sơn, Cù Nguyên Giáp et al. "MỘT SỐ HƯỚNG PHÁT TRIỂN MỚI VỀ HỆ TƯ VẤN MỜ", KỶ YẾU HỘI NGHỊ KHOA HỌC CÔNG NGHỆ QUỐC GIA LẦN THỨ XIII NGHIÊN CỨU CƠ BẢN VÀ ỨNG DỤNG CÔNG NGHỆ THÔNG TIN - Proceedings of the 13th National Conference on Fundamental & Applied Information Technology Research, 2020 <1 %
Publication

- 144 Phan Phương Lan, Huỳnh Hữu Hưng, Huỳnh Xuân Hiệp. "HỆ TƯ VẤN DỰA TRÊN ĐỘ ĐO CƯỜNG ĐỘ HÀM Ý VÀ TRÁCH NHIỆM", FAIR - NGHIÊN CỨU CƠ BẢN VÀ ỨNG DỤNG CÔNG NGHỆ THÔNG TIN - 2017, 2017 <1 %
Publication

- 145 Phan Thanh Toàn, Đặng Quốc Hữu, Nguyễn Thế Lộc. "Toán tử lân cận mới cho thuật toán Tabu Search và PSO giải bài toán lập lịch luồng công việc trong môi trường điện toán đám mây", Research and Development on Information and Communication Technology, 2019 <1 %
Publication

- 146 Tran Van Ut Chinh, Tran Cao De. "DEEP LEARNING FOR VIETNAMESE UPPERCASE HANDWRITTEN CHARACTERS RECOGNITION", KỶ YẾU HỘI NGHỊ KHOA HỌC CÔNG NGHỆ QUỐC GIA LẦN THỨ XIII NGHIÊN CỨU CƠ BẢN VÀ ỨNG DỤNG CÔNG NGHỆ THÔNG TIN - Proceedings of the 13th National Conference <1 %

on Fundamental & Applied Information
Technology Research, 2020

Publication

147	baochinhphu.vn Internet Source	<1 %
148	benhtimmach.info.vn Internet Source	<1 %
149	chm.vnua.edu.vn Internet Source	<1 %
150	data.uet.vnu.edu.vn:8080 Internet Source	<1 %
151	dienthoaidoc.com Internet Source	<1 %
152	documents.worldbank.org Internet Source	<1 %
153	dulieu.tailieuhocTap.vn Internet Source	<1 %
154	fceam.hcmute.edu.vn Internet Source	<1 %
155	iosviet.net Internet Source	<1 %
156	lop4.com Internet Source	<1 %
157	luutruvn.com Internet Source	<1 %
158	mmosite.vn Internet Source	<1 %
159	nhchau.com Internet Source	<1 %
160	proceeding.vap.ac.vn Internet Source	<1 %

161	quanlydoanhnghiep.edu.vn Internet Source	<1 %
162	raovathue.vn Internet Source	<1 %
163	sdh.hcmute.edu.vn Internet Source	<1 %
164	sdh.hmu.edu.vn Internet Source	<1 %
165	sj.ctu.edu.vn Internet Source	<1 %
166	tailieumienphi.vn Internet Source	<1 %
167	thubongpham.blogspot.com Internet Source	<1 %
168	timtailieu.vn Internet Source	<1 %
169	www.docs.vn Internet Source	<1 %
170	www.doccity.com Internet Source	<1 %
171	www.ifc.org Internet Source	<1 %
172	www.immigration.vn Internet Source	<1 %
173	www.tailieudoc.net Internet Source	<1 %
174	www.timtailieu.vn Internet Source	<1 %
175	Pham T.T., Bennett K., Vu T.P., Brunner J., Le N.D., Nguyen D.T.. "Chi tra dich vu môi trường"	<1 %

rung tại Viet Nam: Tu chính sách den thuc
tien", Center for International Forestry
Research (CIFOR) and World Agroforestry
Centre (ICRAF), 2013

Publication

- 176 Phạm Ngọc Hưng, Trịnh Văn Loan, Nguyễn
Hồng Quang, Trần Vũ Duy. "CẢI THIỆN HIỆU
NĂNG HỆ THỐNG NHẬN DẠNG TIẾNG VIỆT
VỚI THÔNG TIN VỀ PHƯƠNG NGỮ", FAIR -
NGHIÊN CỨU CƠ BẢN VÀ ỨNG DỤNG CÔNG
NGHỆ THÔNG TIN - 2016, 2017

<1 %

Publication

- 177 Ti Hon Nguyen, Ngoc Han Nguyen Thi, The Phi
Pham, Thanh Nghi Do. "TRAINING
VIETNAMESE TEXT SUMMARIZATION MODELS
FROM A BIG DATA COLLECTION", KỶ YẾU HỘI
NGHỊ KHOA HỌC CÔNG NGHỆ QUỐC GIA LẦN
THỨ XIII NGHIÊN CỨU CƠ BẢN VÀ ỨNG DỤNG
CÔNG NGHỆ THÔNG TIN - Proceedings of the
13th National Conference on Fundamental &
Applied Information Technology Research,
2020

<1 %

Publication

- 178 VNUA

Publication

<1 %

- 179 Bui Van Hau, Hoang Trong Minh, Dinh Thi Thu
Ngoc, Vu Nhu Lan, Nguyen Thi Thuyet. "AN
EFFICIENCY EDGE DETECTION METHOD BASED
ON FUZZY LOGIC FOR MEDICAL IMAGES", KỶ
YẾU HỘI NGHỊ KHOA HỌC CÔNG NGHỆ QUỐC
GIA LẦN THỨ XIII NGHIÊN CỨU CƠ BẢN VÀ
ỨNG DỤNG CÔNG NGHỆ THÔNG TIN -
Proceedings of the 13th National Conference
on Fundamental & Applied Information
Technology Research, 2020

<1 %

-
- 180 Dinh Dien, Trang Minh Chien, Nguyen Thi Kim Phuong, Nguyen Hong Buu Long. "AUTOMATIC NÔM-SCRIPTS TRANSLITERATION USING NEURAL MACHINE TRANSLATION APPROACH", KỶ YẾU HỘI NGHỊ KHOA HỌC CÔNG NGHỆ QUỐC GIA LẦN THỨ XIII NGHIÊN CỨU CƠ BẢN VÀ ỨNG DỤNG CÔNG NGHỆ THÔNG TIN - Proceedings of the 13th National Conference on Fundamental & Applied Information Technology Research, 2020
Publication <1 %
-
- 181 Duy Thai Ha, Tien Dung Dinh, Trung Anh Le, Van Hoang Le, Đặng Quang Bùi, Hoang Phuong Vu. "An apporoach of digital control for single-phase VSI with compensation of time delay", Journal of Measurement, Control, and Automation, 2025
Publication <1 %
-
- 182 Hanoi Pedagogycal University 2
Publication <1 %
-
- 183 Ma Phạm Nhật Tân, Tạ Viết Tài, Nguyễn Việt Hà, Trần Thị Thảo Nguyên. "Trích xuất tín hiệu điện tim từ tín hiệu điện não cho thiết bị cảnh báo sức khỏe tất cả trong một", Tuyển tập Khoa học và Công nghệ Nhật Bản - Science - Technology in Japan, 2024
Publication <1 %
-
- 184 Nguyen Thanh Binh, Nguyen Huu Nhat Minh, Le Thi My Hanh, Nguyen Thanh Binh. "CODE-SMELL PREDICTION BASED ON MULTI-LABEL CLASSIFICATION", FAIR KỶ YẾU HỘI NGHỊ KHOA HỌC CÔNG NGHỆ QUỐC GIA LẦN THỨ XVI Nghiên cứu cơ bản và Ứng dụng công <1 %

nghe thông tin Proceedings of the 16th
National Conference on Fundamental and
Applied Information Technology Research
(FAIR'2023), 2023

Publication

- 185 Nguyễn Trung Kiên. "Mô hình hóa đa tỷ lệ bài toán địa cơ học sử dụng phương pháp kết hợp phần tử hữu hạn và phần tử rời rạc", Tạp chí Khoa học Công nghệ Xây dựng (KHCN XD) - ĐHXD, 2020 <1 %

Publication

- 186 Triệu V.H., Phạm T.T., Đào Thị L.C.. "Kết quả thực hiện Chiến lược phát triển Lâm nghiệp Việt Nam giai đoạn 2006–2020 và đề xuất nội dung Chiến lược phát triển Lâm nghiệp Việt Nam giai đoạn 2021–2030, tầm nhìn đến năm 2050", Center for International Forestry Research (CIFOR) and World Agroforestry Centre (ICRAF), 2020 <1 %

Publication

- 187 Trần Hoàng Phát, Phạm Mạnh Cường, Trần Đình Toàn, Hoàng Tùng, Lê Minh Hưng. "TĂNG CƯỜNG DỮ LIỆU ẢNH CHO BỘ DỮ LIỆU X-QUANG PHỔ SỬ DỤNG MẠNG SINH ĐỐI NGHỊCH", KỶ YẾU HỘI NGHỊ KHOA HỌC CÔNG NGHỆ QUỐC GIA LẦN THỨ XIII NGHIÊN CỨU CƠ BẢN VÀ ỨNG DỤNG CÔNG NGHỆ THÔNG TIN - Proceedings of the 13th National Conference on Fundamental & Applied Information Technology Research, 2020 <1 %

Publication

- 188 Trần Thanh Trâm, Trần Thanh Phước, Nguyễn Thị Anh Thư, Nguyễn Thế Hữu, Văn Thế Thành. "HỆ THỐNG TRẢ LỜI TỰ ĐỘNG TƯ <1 %

VẤN TUYỂN SINH SAU ĐẠI HỌC", KỶ YẾU HỘI
NGHỊ KHOA HỌC CÔNG NGHỆ QUỐC GIA LẦN
THỨ XIII NGHIÊN CỨU CƠ BẢN VÀ ỨNG DỤNG
CÔNG NGHỆ THÔNG TIN - Proceedings of the
13th National Conference on Fundamental &
Applied Information Technology Research,
2020

Publication

189

Văn Đình Vũ Phương, Trần Văn Lăng, Trần Văn
Hoài, Lê Văn Vinh. "ÁP DỤNG MÔ HÌNH ẮN
KẾT HỢP THUẬT TOÁN BIMETA TRONG VIỆC
GOM NHÓM TRÌNH TỰ METAGENOMIC", FAIR
- NGHIÊN CỨU CƠ BẢN VÀ ỨNG DỤNG CÔNG
NGHỆ THÔNG TIN - 2016, 2017

Publication

<1 %

190

docs.kreston.vn

Internet Source

<1 %

Exclude quotes On

Exclude matches Off

Exclude bibliography On