

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT TP. HCM

KHOA ĐIỆN - ĐIỆN TỬ

BỘ MÔN KỸ THUẬT MÁY TÍNH



HCM-UTE

ĐỒ ÁN TỐT NGHIỆP

NGÀNH CÔNG NGHỆ KỸ THUẬT MÁY TÍNH

Đề tài

**ỨNG DỤNG MÔ HÌNH AI TRONG PHÁT HIỆN VÀ CẢNH BÁO
NGƯỜI ĐIỀU KHIỂN XE MÁY KHÔNG ĐỘI MŨ BẢO HIỂM**

SVTH: VŨ MAI LIÊN

MSSV: 22119194

TRẦN XUÂN MAI

MSSV: 22119196

GVHD: Th.S. VŨ CHÍ CƯỜNG

TP. HỒ CHÍ MINH – 6/2026

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT TP. HCM

KHOA ĐIỆN - ĐIỆN TỬ

BỘ MÔN KỸ THUẬT MÁY TÍNH



HCM-UTE

ĐỒ ÁN TỐT NGHIỆP

NGÀNH CÔNG NGHỆ KỸ THUẬT MÁY TÍNH

Đề tài

**ỨNG DỤNG MÔ HÌNH AI TRONG PHÁT HIỆN VÀ CẢNH BÁO
NGƯỜI ĐIỀU KHIỂN XE MÁY KHÔNG ĐỘI MŨ BẢO HIỂM**

SVTH: VŨ MAI LIÊN

MSSV: 22119194

TRẦN XUÂN MAI

MSSV: 22119196

GVHD: Th.S. VŨ CHÍ CƯỜNG

TP. HỒ CHÍ MINH – 6/2026

BẢN NHẬN XÉT KHÓA LUẬN TỐT NGHIỆP

(Dành cho giảng viên hướng dẫn)

Đề tài: Ứng dụng mô hình AI trong phát hiện và cảnh báo người điều khiển xe

máy không đội mũ bảo hiểm

Sinh viên: + Vũ Mai Liên MSSV: 22119194

+ Trần Xuân Mai MSSV: 22119196

Hướng dẫn: Th.S. Vũ Chí Cường

Nhận xét bao gồm các nội dung sau đây:

1. Tính hợp lý trong cách đặt vấn đề và giải quyết vấn đề; ý nghĩa khoa học và thực tiễn:

Đặt vấn đề rõ ràng, mục tiêu cụ thể; đề tài có tính mới, cấp thiết; đề tài có khả năng ứng dụng, tính sáng tạo.

Hợp lý trong cách đặt vấn đề, giải quyết và ý nghĩa

2. Phương pháp thực hiện/ phân tích/ thiết kế:

Phương pháp hợp lý và tin cậy dựa trên cơ sở lý thuyết; có phân tích và đánh giá phù hợp; có tính mới và tính sáng tạo.

Hợp lý

3. Kết quả thực hiện/ phân tích và đánh giá kết quả/ kiểm định thiết kế:

Phù hợp với mục tiêu đề tài; phân tích và đánh giá/ kiểm thử thiết kế hợp lý; có tính sáng tạo/ kiểm định chặt chẽ và đảm bảo độ tin cậy.

Đáp ứng yêu cầu về kết quả và phân tích, đánh giá

4. Kết luận và đề xuất:

Kết luận phù hợp với cách đặt vấn đề, đề xuất mang tính cải tiến và thực tiễn; kết luận có đóng góp mới mẻ, đề xuất sáng tạo và thuyết phục.

Phù hợp

5. Hình thức trình bày và bố cục báo cáo:

Văn phong nhất quán, bố cục hợp lý, cấu trúc rõ ràng, đúng định dạng mẫu; có tính hấp dẫn, thể hiện năng lực tốt, văn bản trau chuốt.

Đáp ứng yêu cầu

6. Kỹ năng chuyên nghiệp và tính sáng tạo:

Thể hiện các kỹ năng giao tiếp, kỹ năng làm việc nhóm, và các kỹ năng chuyên nghiệp khác trong việc thực hiện đề tài.

Tốt

7. Tài liệu trích dẫn

Tính trung thực trong việc trích dẫn tài liệu tham khảo; tính phù hợp của các tài liệu trích dẫn; trích dẫn theo đúng chỉ dẫn APA.

Đáp ứng

8. Đánh giá về sự trùng lặp của đề tài

Cần khẳng định đề tài có trùng lặp hay không? Nếu có, đề nghị ghi rõ mức độ, tên đề tài, nơi công bố, năm công bố của đề tài đã công bố.

Đáp ứng

9. Những nhược điểm và thiếu sót, những điểm cần được bổ sung và chỉnh sửa*

Cần phân tích chi tiết hơn các kết quả đạt được

10. Nhận xét tinh thần, thái độ học tập, nghiên cứu của sinh viên

Tốt

Đề nghị của giảng viên hướng dẫn

Ghi rõ: "Báo cáo đạt/ không đạt yêu cầu của một khóa luận tốt nghiệp kỹ sư, và được phép/ không được phép bảo vệ khóa luận tốt nghiệp"

Báo cáo đạt yêu cầu của một khóa luận tốt nghiệp kỹ sư và được phép bảo vệ khóa luận tốt nghiệp

Tp. HCM, ngày 13 tháng 6 năm 2026

Người nhận xét
(Ký và ghi rõ họ tên)

Vũ Chí Cường

* Giáo viên hướng dẫn có thể ghi tiếp vào mặt sau



TP. Hồ Chí Minh, ngày ... tháng 06 năm 2026

NHIỆM VỤ ĐỒ ÁN TỐT NGHIỆP

Họ và tên sinh viên: Vũ Mai Liên - **MSSV:** 22119194

Trần Xuân Mai - **MSSV:** 22119196

Ngành: Công nghệ kỹ thuật máy tính

Giảng viên hướng dẫn: ThS. Vũ Chí Cường

Ngày nhận đề tài: 07/03/2026

Ngày nộp đề tài: 20/06/2026

1. Tên đề tài: Ứng dụng mô hình AI trong phát hiện và cảnh báo người điều khiển xe máy không đội mũ bảo hiểm

2. Các số liệu, tài liệu ban đầu: Kiến thức cơ bản về các môn học Trí tuệ nhân tạo, Lập trình Python, Học máy (Machine Learning), Học sâu (Deep Learning) và Thị giác máy tính (Computer Vision); Bộ dữ liệu hình ảnh giao thông "No Helmet - No Ride" từ nền tảng Roboflow; Các tài liệu kỹ thuật về kiến trúc mô hình học sâu YOLO11 và thuật toán theo dõi đối tượng ByteTrack.

3. Nội dung thực hiện

- Nghiên cứu kiến trúc mạng YOLO11 và thuật toán theo dõi đối tượng ByteTrack. Xây dựng và huấn luyện mô hình YOLO11 trên bộ dữ liệu "No Helmet - No Ride".
- Triển khai cơ chế xác nhận vi phạm và thuật toán lọc trùng lặp Spatio-Temporal Deduplication.
- Xây dựng ứng dụng giám sát thời gian thực bằng Streamlit và đánh giá hiệu suất hệ thống.

GIẢNG VIÊN HƯỚNG DẪN

LỜI CẢM ƠN

Lời đầu tiên, nhóm sinh viên chúng em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến quý thầy cô Trường Đại học Sư phạm Kỹ thuật TP.HCM, đặc biệt là các thầy cô giảng dạy chuyên ngành Công nghệ Kỹ thuật Máy tính. Trong suốt quá trình học tập tại trường, những kiến thức, kỹ năng và kinh nghiệm mà quý thầy cô truyền đạt chính là nền tảng giúp chúng em có thể nghiên cứu và hoàn thành khóa luận tốt nghiệp này.

Đặc biệt, nhóm chúng em xin bày tỏ lòng biết ơn sâu sắc nhất đến thầy hướng dẫn – Thạc sĩ Vũ Chí Cường. Thầy đã luôn tận tâm chỉ bảo, theo sát tiến độ, định hướng giải quyết vấn đề và đưa ra những lời khuyên vô cùng quý giá cho chúng em từ những ngày đầu xây dựng đề cương cho đến khi hoàn thiện toàn bộ hệ thống "Ứng dụng mô hình AI trong phát hiện và cảnh báo người điều khiển xe máy không đội mũ bảo hiểm".

Chúng em cũng xin gửi lời cảm ơn đến gia đình và bạn bè đã luôn đồng hành, động viên và tạo mọi điều kiện thuận lợi nhất về tinh thần lẫn vật chất để nhóm có thể tập trung toàn thời gian hoàn thành khóa luận đúng tiến độ.

Mặc dù đã nỗ lực hết sức mình, nhưng do giới hạn về mặt thời gian nghiên cứu và kinh nghiệm thực tiễn, báo cáo khóa luận chắc chắn không thể tránh khỏi những thiếu sót nhất định. Chúng em rất mong nhận được sự quan tâm, đánh giá và những lời góp ý quý báu từ quý thầy cô trong Hội đồng bảo vệ để đề tài được hoàn thiện hơn.

Một lần nữa, chúng em xin chân thành cảm ơn!

TP. Hồ Chí Minh, ngày ... tháng 06 năm 2026

Nhóm sinh viên thực hiện

Vũ Mai Liên

Trần Xuân Mai

TÓM TẮT

Xe máy là phương tiện giao thông chủ yếu tại Việt Nam, tuy nhiên, tình trạng người điều khiển không đội mũ bảo hiểm vẫn diễn ra khá phổ biến, làm tăng nguy cơ chấn thương nghiêm trọng khi xảy ra tai nạn. Việc giám sát và xử lý vi phạm hiện tại chủ yếu phụ thuộc vào lực lượng chức năng hoặc quan sát camera thủ công, dẫn đến những hạn chế về mặt nhân sự, không gian và thời gian giám sát. Động lực chính của đề tài là tự động hóa quá trình này nhằm nâng cao hiệu quả quản lý an toàn giao thông.

Khóa luận này tập trung giải quyết bài toán tự động phát hiện và cảnh báo người điều khiển xe máy không đội mũ bảo hiểm thông qua việc phân tích luồng video giao thông trong thời gian thực. Để thực hiện điều này, nhóm nghiên cứu đề xuất ứng dụng thị giác máy tính, cụ thể là tiến hành huấn luyện mô hình học sâu YOLO11 trên bộ dữ liệu "No Helmet - No Ride" được tinh chỉnh. Bên cạnh đó, hệ thống tích hợp thuật toán theo dõi ByteTrack và giao diện giám sát trực quan được phát triển trên nền tảng Streamlit.

Điểm khác biệt và cải tiến nổi bật của đề tài so với các công trình liên quan trước đây nằm ở hai cơ chế xử lý logic thông minh: Cơ chế chống nhiễu xác nhận vi phạm qua bộ đệm 10 khung hình (10-frame buffer) giúp giảm thiểu cảnh báo giả do sai số tạm thời của AI; và Thuật toán lọc trùng lặp Spatio-Temporal Deduplication (giới hạn thời gian chờ 60 giây và bán kính 100 pixels) giúp ngăn chặn việc hệ thống ghi nhận và lưu trữ nhiều lần cùng một đối tượng đứng yên, từ đó tối ưu hóa hoàn toàn cơ sở dữ liệu bằng chứng.

Kết quả thực nghiệm cho thấy mô hình đạt hiệu suất rất khả quan với chỉ số mAP@0.5 đạt 89.8%, độ chính xác (Precision) đạt 87% và độ phủ (Recall) đạt 84%. Khi triển khai ứng dụng vào môi trường thực tế, hệ thống đạt tốc độ xử lý ổn định ở mức 10 - 12 FPS (khung hình/giây), đáp ứng tốt yêu cầu phân tích video trực tiếp, tự động phân loại trạng thái ở ngưỡng tin cậy 0.394, đồng thời trích xuất và lưu trữ hình ảnh vi phạm một cách chính xác theo thời gian thực.

MỤC LỤC

LỜI CẢM ƠN	i
TÓM TẮT	iii
DANH MỤC HÌNH.....	viii
DANH MỤC BẢNG.....	x
CÁC TỪ VIẾT TẮT	xi
CHƯƠNG 1: GIỚI THIỆU	1
1.1. Giới thiệu	1
1.2. Mục tiêu đề tài	2
1.3. Phạm vi giới hạn đề tài	3
1.3.1. Phạm vi dữ liệu.....	3
1.3.2. Phạm vi đối tượng phát hiện	3
1.3.3. Phạm vi môi trường và điều kiện đầu vào.....	4
1.3.4. Phạm vi chức năng hệ thống	4
1.4. Phương pháp nghiên cứu	4
1.4.1. Phương pháp tổng hợp tài liệu lý thuyết	4
1.4.2. Phương pháp thực nghiệm.....	5
1.4.3. Phương pháp so sánh và đánh giá	5
1.4.4. Phương pháp tham khảo ý kiến chuyên gia	5
1.5. Đối tượng và phạm vi nghiên cứu	5
1.5.1. Đối tượng nghiên cứu.....	5
1.5.2. Phạm vi nghiên cứu	6
1.6. Bố cục quyền báo cáo	6
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT	8
2.1. Trí tuệ nhân tạo và học sâu	8
2.1.1. Tổng quan về trí tuệ nhân tạo	8
2.1.2. Học máy	8
2.1.3. Học sâu	8
2.2. Thị giác máy tính và phát hiện đối tượng.....	9

2.2.1. Thị giác máy tính.....	9
2.2.2. Bài toán phát hiện đối tượng	9
2.2.3. Các phương pháp phát hiện đối tượng	10
2.3. Mô hình YOLO.....	10
2.3.1. Giới thiệu YOLO.....	10
2.3.2. Kiến trúc mạng YOLO11	10
2.3.3. Các biến thể của YOLO11	13
2.4. Thuật toán theo dõi đối tượng ByteTrack.....	13
2.4.1. Tổng quan về theo dõi đối tượng	13
2.4.2. Nguyên lý hoạt động của ByteTrack.....	14
2.5. Các chỉ số đánh giá mô hình.....	14
2.5.1. Ma trận nhầm lẫn và các khái niệm cơ bản.....	14
2.5.2. Precision và Recall	15
2.5.3. F1-Score	15
2.5.4. Intersection over Union (IoU)	16
2.6. Các công trình nghiên cứu liên quan	16
2.7. Công nghệ và công cụ sử dụng.....	17
2.7.1. Ngôn ngữ lập trình python	17
2.7.2. Framework PyTorch.....	17
2.7.3. Ultralytics YOLO	17
2.7.5. Streamlit	18
2.7.6. Google Colab.....	18
CHƯƠNG 3: THIẾT KẾ HỆ THỐNG	20
3.1. Yêu cầu của hệ thống.....	20
3.1.1. Yêu cầu chức năng	20
3.1.2. Yêu cầu phi chức năng	20
3.2. Mô hình hệ thống.....	21
3.3. Thiết kế quy trình huấn luyện mô hình.....	23
3.3.1. Bộ dữ liệu No Helmet – No Ride	23

3.3.2. Tiền xử lý và tăng cường dữ liệu	24
3.3.3. Cấu hình huấn luyện YOLO11n.....	26
3.3.4. Lưu đồ quy trình huấn luyện	27
3.4. Thiết kế phần mềm	28
3.4.1. Tổng quan chức năng phần mềm	28
3.4.2. Sơ đồ hoạt động tổng quan.....	30
3.4.3. Thiết kế module xử lý khung hình	31
3.4.4. Thiết kế thuật toán spatio-temporal deduplication.....	32
3.4.5. Thiết kế module lưu trữ vi phạm.....	34
3.4.6. Thiết kế giao diện người dùng.....	36
3.4.7. Quản lý trạng thái phiên làm việc	38
3.5 Tóm tắt chương.....	38
CHƯƠNG 4: KẾT QUẢ VÀ ĐÁNH GIÁ	40
4.1. Kết quả huấn luyện mô hình.....	40
4.1.1. Đường cong huấn luyện (Loss Curves).....	40
4.1.2. Đường cong F1-Confidence	41
4.1.3. Đường cong Precision-Confidence và Recall-Confidence	42
4.1.4. Đường cong Precision-Recall (PR Curve)	43
4.1.5. Ma trận nhầm lẫn (Confusion Matrix)	44
4.1.6. Kết quả phát hiện trực quan trên tập kiểm thử	45
4.1.7. So Sánh YOLO11n và YOLOv8n.....	46
4.2. Kết quả phần mềm thiết kế	47
4.2.1. Màn hình khởi động và cấu hình.....	47
4.2.2. Giao diện tab giám sát thời gian thực – chế độ tải video	48
4.2.3. Hiển thị bounding box và phân loại trạng thái	49
4.2.4. Giao diện tab cơ sở dữ liệu vi phạm.....	50
4.3. Hoạt động của hệ thống	51
4.3.1. Kịch bản 1 – phát hiện đơn người không đội mũ.....	52
4.3.2. Kịch bản 2 – phát hiện đồng thời nhiều đối tượng.....	53

4.3.3. Kịch bản 3 – kiểm chứng cơ chế lọc trùng lặp.....	54
4.3.4. Kịch bản 4 – giám sát qua camera trực tiếp	54
4.3.5. Kịch bản 5 – điều chỉnh ngưỡng confidence.....	55
4.3.6. Tổng kết kiểm chứng yêu cầu hệ thống	56
4.4. Tóm tắt chương.....	56
CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....	57
5.1. Kết luận.....	57
5.2. Hướng phát triển	58
TÀI LIỆU THAM KHẢO	60

DANH MỤC HÌNH

Hình 2.1: Kiến trúc mạng của YOLO V11	11
Hình 3.1: Kiến trúc tổng thể hệ thống phát hiện và cảnh báo vi phạm mũ bảo hiểm	22
Hình 3.2: Phân phối số lượng nhãn trong bộ dữ liệu No Helmet – No Ride	24
Hình 3.3: Minh họa kết quả Mosaic Augmentation trên bộ dữ liệu huấn luyện..	25
Hình 3.4: Lưu đồ quy trình chuẩn bị dữ liệu và huấn luyện mô hình YOLO11n	27
Hình 3.5: Sơ đồ cấu trúc module của phần mềm hệ thống	29
Hình 3.6: Sơ đồ hoạt động tổng quan của phần mềm hệ thống	30
Hình 3.7: Lưu đồ chi tiết hàm process_frame()	31
Hình 3.8: Lưu đồ thuật toán Spatio-Temporal Deduplication	33
Hình 3.9: Lưu đồ hàm save_violation()	35
Hình 3.10: Thiết kế giao diện Tab 1 – Giám sát thời gian thực	37
Hình 3.11: Thiết kế giao diện Tab 2 – Cơ sở dữ liệu vi phạm	38
Hình 4.1: Đường cong Box Loss, Classification Loss và DFL Loss qua 100 epoch huấn luyện	40
Hình 4.2: Đường cong F1-Confidence của mô hình YOLO11n trên tập kiểm thử	41
Hình 4.3: Đường cong Precision-Confidence	42
Hình 4.4: Đường cong Recall-Confidence	42
Hình 4.5: Đường cong Precision-Recall (PR Curve) cho từng lớp và tổng hợp .	43
Hình 4.6: Ma trận nhầm lẫn chuẩn hóa (Normalized Confusion Matrix) trên tập kiểm thử	44
Hình 4.7: Kết quả phát hiện đối tượng trên tập kiểm thử – các trường hợp đúng điển hình	45
Hình 4.8: Một số trường hợp phát hiện chưa chính xác – cơ sở cho định hướng cải tiến	46
Hình 4.9: Giao diện khởi động của ứng dụng – màn hình chào và cấu hình ban đầu	48
Hình 4.10: Giao diện giám sát thời gian thực khi xử lý video tải lên	49
Hình 4.11: Minh họa ba trạng thái bounding box – xanh lá (Valid), cam (Suspect), đỏ (Violation)	50

Hình 4.12: Giao diện Tab Cơ sở dữ liệu vi phạm với bảng dữ liệu và gallery hình ảnh	51
Hình 4.13: Kết quả Kịch bản 1 – Phát hiện và xác nhận vi phạm đơn người không đội mũ.....	52
Hình 4.14: Kết quả Kịch bản 2 – Phân biệt và nhận diện đồng thời nhiều đối tượng	53
Hình 4.15: Kết quả Kịch bản 3 – Kiểm chứng lọc trùng lặp Spatio-Temporal Deduplication	54
Hình 4.16: Kết quả Kịch bản 4 – Hệ thống hoạt động với nguồn camera trực tiếp	55

DANH MỤC BẢNG

Bảng 2.1: Các biến thể của mô hình YOLO11	13
Bảng 3.1: Thông số chi tiết bộ dữ liệu No Helmet – No Ride.....	23
Bảng 3.2: Cấu hình siêu tham số huấn luyện mô hình YOLO11n	26
Bảng 3.3: Cấu trúc tệp nhật ký vi phạm violations_log.csv	36
Bảng 3.4: Cấu trúc dữ liệu trong Streamlit Session State	38
Bảng 4.1: So sánh hiệu suất YOLO11n và YOLOv8n trên bộ dữ liệu No Helmet – No Ride	46
Bảng 4.2: So sánh kết quả ở các ngưỡng confidence khác nhau trên cùng đoạn video	55

CÁC TỪ VIẾT TẮT

Từ viết tắt	Thuật ngữ nguyên bản	Giải nghĩa Tiếng Việt
AI	Artificial Intelligence	Trí tuệ nhân tạo
AP	Average Precision	Độ chính xác trung bình
AUC	Area Under the Curve	Diện tích dưới đường cong
BCE	Binary Cross-Entropy	Hàm mất mát Entropy chéo nhị phân
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
COCO	Common Objects in Context	Bộ dữ liệu các đối tượng thông dụng trong ngữ cảnh
CSV	Comma-Separated Values	Định dạng tệp dữ liệu phân tách bằng dấu phẩy
CV	Computer Vision	Thị giác máy tính
DFL	Distribution Focal Loss	Hàm mất mát phân phối
DL	Deep Learning	Học sâu
FN	False Negative	Âm tính giả (Bỏ sót đối tượng)
FP	False Positive	Dương tính giả (Phát hiện nhầm)
FPS	Frames Per Second	Số khung hình/giây
GPU	Graphics Processing Unit	Bộ xử lý đồ họa
GVHD		Giảng viên hướng dẫn
IoU	Intersection over Union	Tỷ lệ phần giao trên phần hợp
KLTN		Khóa luận tốt nghiệp
mAP	Mean Average Precision	Độ chính xác trung bình toàn cục
ML	Machine Learning	Học máy
PR	Precision - Recall	(Đường cong) Độ chính xác - Độ phủ
TN	True Negative	Âm tính thật
TP	True Positive	Dương tính thật (Phát hiện đúng)

YOLO	You Only Look Once	Tên mô hình học sâu phát hiện đối tượng
-------------	--------------------	--

CHƯƠNG 1: GIỚI THIỆU

1.1. Giới thiệu

Trong những năm gần đây, tai nạn giao thông đường bộ vẫn là vấn đề nghiêm trọng tại Việt Nam, trong đó xe máy chiếm tỷ lệ lớn và việc không đội mũ bảo hiểm là nguyên nhân làm gia tăng nguy cơ chấn thương nặng khi xảy ra va chạm. Vì vậy, việc xây dựng các hệ thống tự động phát hiện hành vi vi phạm đội mũ bảo hiểm có ý nghĩa quan trọng trong công tác giám sát và nâng cao an toàn giao thông.

Sự phát triển của thị giác máy tính (Computer Vision) và trí tuệ nhân tạo (AI) đã mở ra nhiều giải pháp hiệu quả cho bài toán giám sát giao thông. Trong đó, phát hiện đối tượng (Object Detection) là kỹ thuật cốt lõi, với YOLO (You Only Look Once) là một trong những mô hình được sử dụng phổ biến nhờ khả năng xử lý thời gian thực và độ chính xác cao. Qua nhiều phiên bản, đặc biệt là YOLO11, mô hình đã được cải tiến đáng kể về kiến trúc và hiệu suất.

Nhiều nghiên cứu và dự án đã ứng dụng YOLO để phát hiện người không đội mũ bảo hiểm. Tuy nhiên, đa số vẫn còn hạn chế như chưa tích hợp theo dõi đối tượng để tránh ghi nhận trùng lặp, thiếu cơ chế lọc vi phạm theo không gian – thời gian và chưa có giao diện giám sát trực quan phục vụ triển khai thực tế.

Xuất phát từ đó, đề tài thực hiện xây dựng hệ thống phát hiện và cảnh báo người điều khiển xe máy không đội mũ bảo hiểm từ video giao thông bằng mô hình YOLO11 kết hợp thuật toán ByteTrack và cơ chế lọc trùng lặp theo không gian – thời gian. Hệ thống được phát triển trên nền tảng Streamlit, hỗ trợ giám sát thời gian thực và lưu trữ bằng chứng vi phạm, góp phần nâng cao hiệu quả quản lý an toàn giao thông.

Tên đề tài:

**ỨNG DỤNG MÔ HÌNH AI TRONG PHÁT HIỆN VÀ CẢNH BÁO NGƯỜI
ĐIỀU KHIỂN XE MÁY KHÔNG ĐỘI MŨ BẢO HIỂM**

Đề tài sử dụng mô hình YOLO11 được huấn luyện trên bộ dữ liệu No Helmet – No Ride kết hợp các kỹ thuật tăng cường dữ liệu (data augmentation). Thuật toán ByteTrack được tích hợp để theo dõi đối tượng liên tục, trong khi Streamlit và OpenCV được sử dụng để xây dựng hệ thống giám sát video thời gian thực.

Điểm nổi bật của đề tài là sử dụng YOLO11 kết hợp ByteTrack và cơ chế xác nhận vi phạm theo số khung hình liên tiếp cùng thuật toán Spatio-Temporal Deduplication nhằm hạn chế phát hiện sai và ghi nhận trùng lặp. Hệ thống còn cung cấp giao diện trực quan, lưu trữ hình ảnh và nhật ký vi phạm phục vụ công tác quản lý.

Kết quả kỳ vọng là xây dựng mô hình YOLO11 đạt độ chính xác cao ($mAP50 \geq 85\%$), đáp ứng xử lý video thời gian thực, đồng thời hoàn thiện hệ thống giám sát và đánh giá hiệu quả so với YOLOv8.

1.2. Mục tiêu đề tài

Đề tài được thực hiện nhằm xây dựng và đánh giá hệ thống tự động phát hiện, cảnh báo và lưu trữ bằng chứng đối với người điều khiển xe máy không đội mũ bảo hiểm từ nguồn dữ liệu video giao thông, sử dụng mô hình học sâu YOLO11. Các mục tiêu cụ thể bao gồm:

- Nghiên cứu tổng quan lý thuyết về trí tuệ nhân tạo, thị giác máy tính, bài toán phát hiện đối tượng và kiến trúc mạng YOLO, đặc biệt là YOLO11.
- Xây dựng và huấn luyện mô hình YOLO11 trên bộ dữ liệu No Helmet – No Ride, đạt chỉ số $mAP50 \geq 85\%$ và Precision, Recall cân bằng ở mức $\geq 80\%$ trên tập kiểm thử.
- Tích hợp thuật toán theo dõi đối tượng ByteTrack vào hệ thống nhằm duy trì nhận dạng liên tục qua các khung hình, đảm bảo độ ổn định trong môi trường giao thông đông đúc.

- Triển khai cơ chế xác nhận vi phạm và thuật toán lọc trùng lặp theo không-thời gian nhằm nâng cao độ tin cậy của hệ thống.
- Xây dựng ứng dụng giám sát thời gian thực trên nền tảng Streamlit, hỗ trợ hai nguồn đầu vào là video tải lên và camera trực tiếp; hiển thị kết quả phát hiện, thống kê tổng quan và tốc độ xử lý.
- Xây dựng phân hệ quản lý cơ sở dữ liệu vi phạm, có chức năng lưu trữ hình ảnh bằng chứng và nhật ký vi phạm dưới định dạng CSV, có thể truy xuất và xuất dữ liệu.
- Đánh giá và so sánh hiệu suất của mô hình YOLO11 với YOLOv8 trên cùng bộ dữ liệu về các chỉ số Precision, Recall, mAP50, mAP50-95 và tốc độ xử lý.

1.3. Phạm vi giới hạn đề tài

Do giới hạn về thời gian và tài nguyên thực hiện, đề tài được xác định trong các phạm vi cụ thể sau:

1.3.1. Phạm vi dữ liệu

- Mô hình được huấn luyện và đánh giá trên bộ dữ liệu No Helmet – No Ride (Roboflow) gồm khoảng 4.267 ảnh, kích thước 640×640 pixel, với ba nhãn phân loại: helmet, nohelmet và riders.
- Bộ dữ liệu chứa hình ảnh thu thập từ các quốc gia châu Á bao gồm Việt Nam, Thái Lan, Ấn Độ và Myanmar, phản ánh điều kiện giao thông tương đồng với bối cảnh trong nước.
- Đề tài không thu thập thêm dữ liệu mới ngoài bộ dữ liệu nêu trên, việc bổ sung dữ liệu thực địa tại Việt Nam được xem là hướng phát triển tiếp theo.

1.3.2. Phạm vi đối tượng phát hiện

- Hệ thống chỉ phát hiện và phân loại người điều khiển xe máy theo ba nhãn: đội mũ bảo hiểm (helmet), không đội mũ bảo hiểm (nohelmet) và

người đi xe máy (riders). Hành khách ngồi sau không nằm trong phạm vi phát hiện của hệ thống hiện tại.

- Hệ thống không thực hiện nhận dạng cá nhân hay nhận diện biển số xe.

1.3.3. Phạm vi môi trường và điều kiện đầu vào

- Đầu vào hệ thống là video định dạng MP4/AVI hoặc luồng camera trực tiếp (webcam). Hệ thống không hỗ trợ xử lý ảnh tĩnh đơn lẻ.
- Hiệu suất phát hiện có thể bị ảnh hưởng trong điều kiện ánh sáng yếu (ban đêm, trong nhà), mật độ đối tượng dày đặc hoặc đối tượng bị che khuất phần lớn.
- Môi trường thực nghiệm sử dụng Google Colab (GPU T4) cho giai đoạn huấn luyện và máy tính cá nhân cho giai đoạn triển khai ứng dụng.

1.3.4. Phạm vi chức năng hệ thống

- Hệ thống cung cấp cảnh báo trực quan qua giao diện người dùng; chưa tích hợp chức năng gửi thông báo tự động qua email, SMS hoặc kết nối với hạ tầng camera giao thông thực tế.

1.4. Phương pháp nghiên cứu

Đề tài được thực hiện dựa trên sự kết hợp của các phương pháp nghiên cứu sau:

1.4.1. Phương pháp tổng hợp tài liệu lý thuyết

Tiến hành nghiên cứu, đọc và tổng hợp các bài báo khoa học, tài liệu kỹ thuật liên quan đến thị giác máy tính, học sâu và bài toán phát hiện đối tượng. Trọng tâm là tìm hiểu chi tiết kiến trúc các thể hệ mô hình YOLO từ phiên bản đầu tiên đến YOLO11, đặc biệt là các cải tiến về backbone, neck và detection head. Các nguồn tài liệu chính bao gồm: tài liệu chính thức của Ultralytics, bài báo gốc "You Only Look Once" (Redmon et al., 2016), bài báo "YOLOv11: An Overview of the Key Architectural Enhancements" (Khanam & Hussain, 2024) và các công trình liên quan đến phát hiện mũ bảo hiểm.

1.4.2. Phương pháp thực nghiệm

Phương pháp chủ đạo của đề tài. Toàn bộ quá trình từ chuẩn bị dữ liệu, huấn luyện mô hình, tích hợp hệ thống đến đánh giá kết quả đều được thực hiện theo quy trình thực nghiệm có kiểm soát. Cụ thể: (1) Sử dụng Google Colab với GPU T4 để huấn luyện mô hình YOLO11 qua 50 epoch; (2) Áp dụng các kỹ thuật data augmentation (lật ảnh, xoay ảnh, thay đổi màu sắc, thay đổi tỷ lệ) để tăng tính tổng quát của mô hình; (3) Triển khai hệ thống phát hiện thời gian thực sử dụng OpenCV và Streamlit.

1.4.3. Phương pháp so sánh và đánh giá

Mô hình YOLO11 sau khi huấn luyện được đánh giá thông qua bộ chỉ số đo lường tiêu chuẩn trong lĩnh vực phát hiện đối tượng bao gồm: Precision (Độ chính xác), Recall (Độ phủ), F1-Score, mAP@0.5 và mAP@0.5:0.95. Kết quả được so sánh trực tiếp với mô hình YOLOv8 trên cùng bộ dữ liệu và điều kiện huấn luyện để định lượng mức độ cải tiến.

1.4.4. Phương pháp tham khảo ý kiến chuyên gia

Trong suốt quá trình thực hiện, đề tài được thực hiện dưới sự hướng dẫn và tư vấn của giảng viên hướng dẫn thông qua các buổi báo cáo tiến độ định kỳ hai tuần một lần. Các góp ý về hướng tiếp cận, lựa chọn công nghệ và phương án triển khai được tổng hợp và áp dụng vào quá trình nghiên cứu.

1.5. Đối tượng và phạm vi nghiên cứu

1.5.1. Đối tượng nghiên cứu

Đề tài tập trung nghiên cứu các đối tượng chính sau:

- Mô hình học sâu YOLO11: Nghiên cứu kiến trúc mạng nơ-ron, cơ chế phát hiện đối tượng, quá trình huấn luyện và các chiến lược tối ưu hóa siêu tham số (hyperparameter tuning).
- Bộ dữ liệu No Helmet – No Ride: Nghiên cứu đặc điểm phân phối dữ liệu, quy trình gán nhãn, các kỹ thuật tiền xử lý và augmentation phù hợp cho bài toán phát hiện mũ bảo hiểm.

- Thuật toán theo dõi đối tượng ByteTrack: Nghiên cứu nguyên lý hoạt động dựa trên bộ lọc Kalman và Hungarian Algorithm trong việc duy trì định danh đối tượng qua các khung hình liên tiếp.
- Hệ thống phát hiện vi phạm tích hợp: Nghiên cứu thiết kế kiến trúc phần mềm, luồng xử lý dữ liệu và cơ chế lọc trùng lặp cho ứng dụng giám sát thời gian thực.

1.5.2. Phạm vi nghiên cứu

Phạm vi nghiên cứu được xác định theo các chiều sau:

- Về lý thuyết: Tập trung vào các kiến thức nền tảng của học sâu và thị giác máy tính, đặc biệt là bài toán phát hiện đối tượng thời gian thực và kiến trúc single-stage detector.
- Về kỹ thuật: Nghiên cứu và ứng dụng framework Ultralytics YOLO, thư viện OpenCV cho xử lý video, và Streamlit cho phát triển giao diện người dùng trên nền web.
- Về ứng dụng: Tập trung vào kịch bản sử dụng video giao thông đường phố, trong điều kiện ánh sáng ban ngày và môi trường đô thị. Đây là điều kiện phổ biến nhất trong các hệ thống camera giám sát giao thông thực tế.
- Về quy mô đánh giá: Đánh giá trên bộ dữ liệu kiểm thử chuẩn của dataset và một số đoạn video thực tế bổ sung để kiểm chứng khả năng tổng quát hóa của mô hình.

1.6. Bố cục quyển báo cáo

Quyển báo cáo khóa luận tốt nghiệp được trình bày theo cấu trúc gồm năm chương với nội dung chính như sau:

CHƯƠNG 1. GIỚI THIỆU: Trình bày tổng quan về vấn đề nghiên cứu, khảo sát các công trình liên quan, xác định mục tiêu, phạm vi, phương pháp nghiên cứu và bố cục của quyển báo cáo.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT: Trình bày các kiến thức nền tảng về trí tuệ nhân tạo, học sâu và thị giác máy tính; phân tích chi tiết kiến trúc các thể hệ mô hình YOLO, đặc biệt là YOLO11; giới thiệu thuật toán theo dõi đối tượng ByteTrack và các chỉ số đánh giá mô hình.

CHƯƠNG 3. DỮ LIỆU VÀ PHƯƠNG PHÁP: Mô tả chi tiết bộ dữ liệu No Helmet – No Ride, quy trình tiền xử lý và tăng cường dữ liệu; trình bày phương pháp huấn luyện mô hình YOLO11 bao gồm cấu hình siêu tham số, môi trường thực nghiệm và chiến lược tối ưu hóa.

CHƯƠNG 4. XÂY DỰNG HỆ THỐNG: Trình bày kiến trúc tổng thể của hệ thống phát hiện vi phạm; mô tả chi tiết thiết kế và cài đặt các thành phần bao gồm module xử lý video, cơ chế xác nhận vi phạm, thuật toán Spatio-Temporal Deduplication và giao diện ứng dụng Streamlit.

CHƯƠNG 5. KẾT QUẢ VÀ ĐÁNH GIÁ: Trình bày và phân tích kết quả huấn luyện mô hình thông qua các biểu đồ loss, đường cong Precision-Recall, F1-Confidence và ma trận nhầm lẫn; so sánh hiệu suất giữa YOLO11 và YOLOv8; đánh giá kết quả thực nghiệm trên video giao thông thực tế; thảo luận về ưu điểm, hạn chế và hướng phát triển tiếp theo.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Trí tuệ nhân tạo và học sâu

2.1.1. Tổng quan về trí tuệ nhân tạo

Trí tuệ nhân tạo (Artificial Intelligence – AI) là lĩnh vực khoa học máy tính nghiên cứu và phát triển các hệ thống có khả năng mô phỏng trí tuệ con người trong học tập, suy luận và giải quyết vấn đề. Được đặt nền móng từ năm 1950 bởi Alan Turing, AI đã phát triển mạnh nhờ sự tiến bộ của sức mạnh tính toán, dữ liệu lớn và các thuật toán học máy. Hiện nay, phần lớn các ứng dụng AI thuộc nhóm AI hẹp (Narrow AI), trong đó thị giác máy tính (Computer Vision) là một trong những lĩnh vực tiêu biểu với nhiều ứng dụng thực tiễn như nhận dạng và phát hiện đối tượng trong ảnh, video.

2.1.2. Học máy

Học máy (Machine Learning – ML) là một nhánh của trí tuệ nhân tạo, cho phép máy tính học từ dữ liệu để đưa ra dự đoán hoặc quyết định mà không cần lập trình tường minh. Các phương pháp học máy gồm học có giám sát, học không giám sát và học tăng cường. Trong đề tài này, bài toán phát hiện đối tượng sử dụng học có giám sát, với mô hình được huấn luyện trên tập dữ liệu ảnh đã được gán nhãn về vị trí và loại đối tượng.

2.1.3. Học sâu

Học sâu (Deep Learning – DL) là một nhánh của học máy sử dụng các mạng nơ-ron nhân tạo nhiều lớp (deep neural networks) để học trực tiếp từ dữ liệu. Thuật ngữ "sâu" đề cập đến số lượng lớp xử lý trong mạng, giúp mô hình học được các biểu diễn dữ liệu phức tạp.

Khác với học máy truyền thống, học sâu có khả năng tự động trích xuất đặc trưng từ dữ liệu thô mà không cần thiết kế thủ công. Trong bài toán nhận dạng ảnh, mô hình học các đặc trưng từ đơn giản như cạnh và góc đến các hình dạng và đối tượng hoàn chỉnh, nhờ đó đạt hiệu quả cao trong các tác vụ thị giác máy tính.

2.2. Thị giác máy tính và phát hiện đối tượng

2.2.1. Thị giác máy tính

Thị giác máy tính (Computer Vision – CV) là lĩnh vực khoa học nghiên cứu cách thức để máy tính có thể hiểu và diễn giải nội dung từ hình ảnh và video tương tự như cách con người nhìn và hiểu thế giới. Mục tiêu của thị giác máy tính là tái tạo năng lực thị giác của con người theo phương thức tính toán, bao gồm khả năng nhận dạng, định vị, đo lường và phân loại các đối tượng trong môi trường trực quan.

Thị giác máy tính là một nhánh của trí tuệ nhân tạo cho phép máy tính trích xuất thông tin có ý nghĩa từ hình ảnh và video. Trong hệ thống thị giác máy tính, dữ liệu đầu vào thường là ảnh số (digital image), được biểu diễn dưới dạng ma trận các giá trị pixel.

Các bài toán chính trong thị giác máy tính bao gồm: phân loại ảnh (Image Classification), phát hiện đối tượng (Object Detection), phân đoạn ngữ nghĩa (Semantic Segmentation), ước lượng tư thế (Pose Estimation), và theo dõi đối tượng (Object Tracking). Trong lĩnh vực an toàn giao thông, thị giác máy tính đã được ứng dụng thành công trong nhận dạng biển số xe, phát hiện người đi bộ qua đường, giám sát làn đường và phát hiện các hành vi vi phạm.

2.2.2. Bài toán phát hiện đối tượng

Phát hiện đối tượng (Object Detection) là bài toán kết hợp hai nhiệm vụ con: xác định vị trí (localization) của các đối tượng trong ảnh thông qua khung bao (bounding box), và phân loại (classification) đối tượng đó thuộc nhãn nào. Khác với phân loại ảnh đơn thuần chỉ trả lời câu hỏi "ảnh này chứa gì?", phát hiện đối tượng trả lời câu hỏi "đối tượng đó ở đâu và là gì?".

Đầu ra của một mô hình phát hiện đối tượng thường bao gồm: tọa độ bounding box được biểu diễn dưới dạng (x, y, w, h) hoặc $(x1, y1, x2, y2)$, nhãn phân loại tương ứng và điểm tin cậy (confidence score) thể hiện xác suất đối tượng thuộc nhãn đó. Trong đề tài này, mỗi khung hình video sẽ được phân tích để xác

định vị trí và phân loại tất cả người điều khiển xe máy theo ba nhãn: helmet (đội mũ), nohelmet (không đội mũ) và riders (người đi xe).

2.2.3. Các phương pháp phát hiện đối tượng

Các phương pháp phát hiện đối tượng hiện đại được chia thành hai nhóm chính: Two-Stage Detector và One-Stage Detector. Nhóm Two-Stage Detector (R-CNN, Fast R-CNN, Faster R-CNN) thực hiện hai bước gồm sinh vùng đề xuất và phân loại đối tượng, nên có độ chính xác cao nhưng tốc độ xử lý chậm. Ngược lại, nhóm One-Stage Detector như SSD, RetinaNet và YOLO thực hiện đồng thời việc định vị và phân loại đối tượng trong một lần suy diễn, giúp tăng đáng kể tốc độ xử lý. Trong đó, YOLO là mô hình tiêu biểu và phù hợp cho các ứng dụng thời gian thực như giám sát giao thông.

2.3. Mô hình YOLO


2.3.1. Giới thiệu YOLO

YOLO (You Only Look Once) là kiến trúc mạng nơ-ron học sâu phát hiện đối tượng thời gian thực, được giới thiệu bởi Joseph Redmon cùng các cộng sự tại hội nghị CVPR năm 2016. Điểm nổi bật của YOLO là tiếp cận thống nhất: toàn bộ ảnh được xử lý chỉ trong một lần lan truyền tiến (forward pass) để đồng thời dự đoán bounding box và phân loại đối tượng.

Nhờ thiết kế này, YOLO đạt tốc độ xử lý rất cao, với YOLOv1 đạt khoảng 45 FPS và Fast YOLO đạt 155 FPS trên GPU, vượt trội so với các phương pháp two-stage detector cùng thời. Sự cân bằng giữa tốc độ và độ chính xác đã giúp YOLO trở thành một trong những mô hình phát hiện đối tượng thời gian thực phổ biến nhất.

2.3.2. Kiến trúc mạng YOLO11

YOLO11 được phát triển bởi Ultralytics vào năm 2024, kế thừa và cải tiến đáng kể so với YOLOv8. Kiến trúc YOLO11 bao gồm ba thành phần chính: Backbone, Neck và Head.



Hình 2.1: Kiến trúc mạng của YOLO V11

2.3.2.1. Backbone – Trích xuất đặc trưng

Backbone là phần mạng nơ-ron có nhiệm vụ trích xuất đặc trưng từ ảnh đầu vào. Trong YOLO11, module C3k2 thay thế C2f của YOLOv8, giúp giảm số lượng tham số nhưng vẫn duy trì khả năng biểu diễn đặc trưng hiệu quả.

Backbone còn tích hợp SPPF để tổng hợp đặc trưng ở nhiều tỷ lệ và C2PSA để tăng cường cơ chế attention, giúp mô hình tập trung vào các vùng quan trọng trong ảnh. Đây là một trong những cải tiến nổi bật của YOLO11 so với YOLOv8.

2.3.2.2. Neck – Tổng hợp đặc trưng đa tỷ lệ

Neck có nhiệm vụ kết hợp các bản đồ đặc trưng từ nhiều tầng của Backbone để tạo ra biểu diễn đa tỷ lệ, giúp phát hiện hiệu quả các đối tượng có kích thước khác nhau. YOLO11 sử dụng kiến trúc PAN-FPN, cho phép truyền thông tin theo cả hai hướng: từ trên xuống để tăng cường thông tin ngữ nghĩa và từ dưới lên để bổ sung thông tin vị trí chi tiết.

2.3.2.3. Head – Dự đoán và phân loại

Head là phần đưa ra dự đoán cuối cùng, xuất ra bounding box, điểm confidence và xác suất phân loại cho từng đối tượng được phát hiện. YOLO11 áp dụng phương pháp Anchor-free Detection – không sử dụng các anchor box được định nghĩa trước như các phiên bản cũ, thay vào đó dự đoán trực tiếp tọa độ tâm và kích thước của bounding box. Điều này giúp đơn giản hóa quá trình huấn luyện và giảm số lượng siêu tham số cần điều chỉnh.

Hàm mất mát (loss function) của YOLO11 kết hợp ba thành phần:

- Box Loss sử dụng IoU-based loss để đánh giá độ lệch giữa bounding box dự đoán và thực tế.

$$IoU = \frac{Area_{overlap}}{Area_{union}} \quad (2.1)$$

Trong đó:

- + $Area_{overlap}$: diện tích phần giao nhau
- + $Area_{union}$: diện tích hợp

Giá trị IoU nằm trong khoảng:

$$0 \leq IoU \leq 1$$

- Classification Loss dùng BCE (Binary Cross-Entropy) Loss để đánh giá sai số phân loại;

$$Loss_{cls} = \sum_{i=1}^n (p_i - \hat{p}_i)^2 \quad (2.2)$$

- Distribution Focal Loss (DFL) – cải tiến giúp mô hình tinh chỉnh các cạnh của bounding box với độ chính xác cao hơn, đặc biệt hiệu quả với các đối tượng bị mờ hoặc che khuất.

2.3.3. Các biến thể của YOLO11

YOLO11 cung cấp năm biến thể được tối ưu hóa cho các kịch bản sử dụng khác nhau, từ thiết bị nhúng đến máy chủ GPU hiệu suất cao:

Bảng 2.1: Các biến thể của mô hình YOLO11

Biến thể	Tham số	mAP50-95 (COCO)	Phù hợp cho
YOLO11n (nano)	2.6M	39.5%	Thiết bị nhúng, edge device
YOLO11s (small)	9.4M	47.0%	Ứng dụng di động
YOLO11m (medium)	20.1M	51.5%	Cân bằng tốc độ/chính xác
YOLO11l (large)	25.3M	53.4%	Ứng dụng máy tính
YOLO11x (extra- large)	56.9M	54.7%	Máy chủ GPU cao cấp

Trong đề tài này, biến thể YOLO11n (phiên bản nano) được lựa chọn vì cung cấp sự cân bằng tối ưu giữa độ chính xác, tốc độ xử lý và yêu cầu tài nguyên phần cứng. Lựa chọn này không chỉ đáp ứng tốt giới hạn cấp phát tài nguyên trên môi trường Google Colab trong quá trình huấn luyện, mà còn cho phép hệ thống duy trì tốc độ suy luận ổn định (10-12 FPS) khi triển khai thực tế trên phần cứng máy tính thông thường.

2.4. Thuật toán theo dõi đối tượng ByteTrack

2.4.1. Tổng quan về theo dõi đối tượng

Theo dõi đối tượng (Object Tracking) là bài toán duy trì nhận dạng của một hoặc nhiều đối tượng qua các khung hình liên tiếp trong video. Trong giám sát video, theo dõi giúp xác định một đối tượng có phải là cùng một cá thể khi di chuyển qua nhiều thời điểm. Bài toán theo dõi đa đối tượng (Multi-Object Tracking – MOT) gặp nhiều thách thức như che khuất, chuyển động nhanh và đối tượng

xuất hiện hoặc biến mất khỏi khung hình. Trong đề tài này, ByteTrack được sử dụng để theo dõi từng cá nhân, giúp hạn chế ghi nhận vi phạm trùng lặp.

2.4.2. Nguyên lý hoạt động của ByteTrack

ByteTrack (Zhang et al., 2022) là một trong những thuật toán theo dõi đa đối tượng (MOT) hiệu quả, nổi bật. Thuật toán hoạt động theo hai bước: trước tiên ghép các track với các bounding box có confidence cao bằng thuật toán Hungarian dựa trên chỉ số IoU, sau đó tiếp tục ghép các track còn lại với các bounding box có confidence thấp. Cách tiếp cận này giúp duy trì việc theo dõi khi đối tượng bị che khuất hoặc phát hiện không ổn định.

ByteTrack kết hợp bộ lọc Kalman để dự đoán vị trí của đối tượng giữa các khung hình và gán cho mỗi đối tượng một track ID duy nhất. Track sẽ được duy trì trong một khoảng thời gian trước khi bị xóa nếu đối tượng không được phát hiện lại.

2.4.3. Ứng dụng ByteTrack trong đề tài

Trong hệ thống phát hiện vi phạm mũ bảo hiểm, ByteTrack đóng vai trò then chốt trong cơ chế xác nhận vi phạm. Thay vì cảnh báo ngay lập tức khi phát hiện một người không đội mũ trong một khung hình đơn lẻ, hệ thống sử dụng track ID để theo dõi từng cá nhân liên tục. Vi phạm chỉ được xác nhận và ghi lại khi một track ID cụ thể liên tục được phân loại là 'nohelmet' trong hơn 10 khung hình liên tiếp (threshold = 10 frames), tương đương khoảng 0.8 đến 1 giây dựa trên tốc độ xử lý thực tế của hệ thống (10-12 FPS). Cơ chế này loại bỏ hiệu quả các phát hiện nhầm xuất hiện thoáng qua do điều kiện ánh sáng xấu hoặc đối tượng bị che khuất một phần.

2.5. Các chỉ số đánh giá mô hình

2.5.1. Ma trận nhầm lẫn và các khái niệm cơ bản

Hiệu suất mô hình phát hiện đối tượng được đánh giá dựa trên bốn trường hợp: True Positive (TP) – phát hiện đúng đối tượng; False Positive (FP) – phát hiện nhầm; False Negative (FN) – bỏ sót đối tượng; và True Negative (TN) – xác định

đúng vùng không có đối tượng. Trong bài toán phát hiện đối tượng, TN ít được sử dụng do số lượng rất lớn. Một dự đoán chỉ được tính là TP khi mô hình phân loại đúng đối tượng và giá trị IoU giữa bounding box dự đoán với bounding box thực tế đạt hoặc vượt ngưỡng quy định (thường là 0,5).

2.5.2. Precision và Recall

Precision (Độ chính xác) đo lường tỷ lệ các dự đoán dương tính của mô hình là đúng, được tính theo công thức:

$$Precision = \frac{TP}{TP + FP} \quad (2.3)$$

Một hệ thống có Precision cao đồng nghĩa với việc ít phát sinh báo động giả – khi hệ thống cảnh báo vi phạm, xác suất cảnh báo đó là đúng rất cao.

Recall (Độ phủ hay Độ nhảy) đo lường tỷ lệ các đối tượng thực sự tồn tại được mô hình phát hiện ra, được tính theo công thức:

$$Recall = \frac{TP}{TP + FN} \quad (2.4)$$

Một hệ thống có Recall cao đồng nghĩa với việc ít để lọt vi phạm – hầu hết những người không đội mũ đi qua camera đều bị phát hiện. Trong thực tiễn, Precision và Recall thường có quan hệ đánh đổi (trade-off): tăng một chỉ số thường dẫn đến giảm chỉ số kia.

2.5.3. F1-Score

F1-Score là trung bình điều hòa (harmonic mean) của Precision và Recall, cung cấp một chỉ số duy nhất phản ánh sự cân bằng giữa hai chỉ số này:

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (2.5)$$

F1-Score đặc biệt hữu ích khi cần chọn ngưỡng confidence tối ưu cho hệ thống triển khai thực tế. Đường cong F1-Confidence biểu diễn giá trị F1 tương ứng

với từng mức ngưỡng confidence, từ đó xác định điểm hoạt động tối ưu của mô hình.

2.5.4. Intersection over Union (IoU)

IoU (Intersection over Union) là chỉ số đo lường mức độ trùng lặp giữa bounding box dự đoán và bounding box thực tế (ground truth):

$$IoU = \frac{|A \cap B|}{|A \cup B|} \quad (2.6)$$

Trong đó A là diện tích bounding box dự đoán, B là diện tích bounding box thực tế, $A \cap B$ là diện tích giao nhau và $A \cup B$ là diện tích hợp. Giá trị IoU nằm trong khoảng $[0, 1]$, với 1 biểu thị sự trùng khớp hoàn hảo. Ngưỡng $IoU = 0.5$ (tức 50% chồng lấp) là tiêu chuẩn phổ biến nhất trong đánh giá bài toán phát hiện đối tượng.

2.5.5. Mean Average Precision (mAP)

Average Precision (AP) của một lớp đối tượng là diện tích dưới đường cong Precision-Recall (Area Under the PR Curve – AUC), tổng hợp hiệu suất phát hiện trên toàn bộ các ngưỡng confidence:

$$AP = \int_0^1 Precision(Recall) dRecall \quad (2.7)$$

Mean Average Precision (mAP) là trung bình cộng của AP trên tất cả các lớp đối tượng. Trong bộ dữ liệu của đề tài có ba lớp (helmet, nohelmet, riders), mAP được tính bằng trung bình cộng của AP ba lớp này.

$$mAP = \frac{1}{N} \sum_{i=1}^N AP_i \quad (2.8)$$

Hai biến thể mAP quan trọng được sử dụng trong đề tài: $mAP@0.5$ (hay $mAP50$) sử dụng ngưỡng $IoU = 0.5$, là chỉ số tiêu chuẩn phổ biến; và $mAP@0.5:0.95$ (hay $mAP50-95$) tính trung bình mAP trên các ngưỡng IoU từ 0.50 đến 0.95 với bước 0.05, là chỉ số khắt khe hơn được sử dụng trong benchmark COCO.

2.6. Các công trình nghiên cứu liên quan

Các nghiên cứu trong và ngoài nước đã khẳng định hiệu quả của AI và các mô hình YOLO trong bài toán phát hiện mũ bảo hiểm. Tại Việt Nam, nghiên cứu của Nguyễn Hữu Tuấn và Vũ Thanh Hương (2025) cùng công trình CS114.ML_HelmetDetection đã chứng minh tính khả thi của việc ứng dụng học sâu, tuy nhiên chưa tích hợp theo dõi đối tượng, cơ chế lọc trùng lặp hoặc phát triển thành hệ thống hoàn chỉnh. Trên thế giới, các dự án YOLOV10_Safety_Helmet_Detection và Helmet-Detection-with-YOLOv10 cho thấy hiệu quả của YOLOv10 nhưng chủ yếu được đánh giá trong môi trường công nghiệp. Bên cạnh đó, bộ dữ liệu No Helmet – No Ride trên Roboflow Universe cung cấp dữ liệu giao thông thực tế với ba lớp helmet, nohelmet và riders, phù hợp để huấn luyện và đánh giá hệ thống phát hiện mũ bảo hiểm trong đề tài.

2.7. Công nghệ và công cụ sử dụng

2.7.1. Ngôn ngữ lập trình python

Python là ngôn ngữ lập trình bậc cao, thông dịch, với cú pháp đơn giản và hệ sinh thái thư viện phong phú, đã trở thành ngôn ngữ thống trị trong lĩnh vực khoa học dữ liệu và học máy. Phiên bản Python 3.10+ được sử dụng trong đề tài, phù hợp với các yêu cầu của Ultralytics YOLO11 và Streamlit.

2.7.2. Framework PyTorch

PyTorch là framework học sâu mã nguồn mở do Facebook AI Research phát triển, nổi bật với cơ chế tính toán đồ thị động (dynamic computational graph) cho phép gỡ lỗi trực quan và linh hoạt trong nghiên cứu. Ultralytics YOLO11 được xây dựng trên nền PyTorch, sử dụng CUDA để tăng tốc tính toán trên GPU.

2.7.3. Ultralytics YOLO

Ultralytics cung cấp gói phần mềm Python thống nhất để huấn luyện, đánh giá và triển khai các mô hình YOLO. Framework này tích hợp sẵn các công cụ augmentation dữ liệu, trực quan hóa kết quả huấn luyện và hỗ trợ xuất mô hình sang nhiều định dạng. Giao diện lập trình đơn giản cho phép huấn luyện mô hình chỉ với vài dòng lệnh Python.

2.7.4. OpenCV

OpenCV (Open Source Computer Vision Library) là thư viện thị giác máy tính mã nguồn mở hàng đầu với hơn 2500 thuật toán tối ưu hóa. Trong đề tài, OpenCV được sử dụng cho: đọc và giải mã luồng video, vẽ bounding box và nhận đối tượng lên khung hình, chuyển đổi không gian màu từ BGR sang RGB để hiển thị trên Streamlit, và lưu ảnh bằng chứng vi phạm.

2.7.5. Streamlit

Streamlit là framework Python dùng để xây dựng ứng dụng web cho các bài toán dữ liệu và học máy mà không cần lập trình HTML, CSS hay JavaScript. Trong đề tài này, Streamlit được sử dụng để phát triển giao diện giám sát thời gian thực với các thành phần như video, bảng thống kê và nhật ký vi phạm. Cơ chế Session State của Streamlit giúp duy trì trạng thái hệ thống, bao gồm lịch sử theo dõi, ID đã lưu và danh sách vi phạm trong suốt quá trình vận hành.

2.7.6. Google Colab

Google Colaboratory cung cấp miễn phí tài nguyên GPU (NVIDIA T4) để thực thi Jupyter Notebook. Đây là môi trường huấn luyện chính trong đề tài do yêu cầu tính toán cao của quá trình huấn luyện YOLO11 trong 100 epoch trên bộ dữ liệu 4267 ảnh. Google Colab cũng cung cấp tích hợp trực tiếp với Google Drive, thuận tiện cho việc lưu trữ và truy cập checkpoint mô hình.

2.8. Tóm tắt chương

Chương 2 đã trình bày toàn bộ nền tảng lý thuyết và công nghệ cần thiết để thực hiện đề tài. Các kiến thức cốt lõi được đề cập bao gồm:

- Cơ sở về trí tuệ nhân tạo, học máy, học sâu và mạng nơ-ron tích chập CNN;
- Bài toán phát hiện đối tượng và ưu điểm của phương pháp one-stage detector so với two-stage;
- Kiến trúc chi tiết của YOLO11 với các cải tiến C3k2, SPPF+C2PSA và anchor-free head;

- Nguyên lý hoạt động của thuật toán ByteTrack trong theo dõi đa đối tượng;
- Hệ thống các chỉ số đánh giá Precision, Recall, F1, IoU và mAP;
- Khảo sát và phân tích các công trình liên quan trong nước và quốc tế, chỉ ra bốn khoảng trống nghiên cứu mà đề tài hướng đến giải quyết;
- Giới thiệu ngắn gọn về các công nghệ và công cụ được sử dụng trong triển khai hệ thống.

Trên cơ sở lý thuyết này, Chương 3 sẽ trình bày chi tiết quá trình chuẩn bị dữ liệu, cấu hình huấn luyện và các quyết định kỹ thuật trong quá trình xây dựng mô hình YOLO11 cho bài toán phát hiện mũ bảo hiểm.

CHƯƠNG 3: THIẾT KẾ HỆ THỐNG

3.1. Yêu cầu của hệ thống

Dựa trên các mục tiêu đã xác định ở Chương 1 và nền tảng lý thuyết được trình bày ở Chương 2, hệ thống phát hiện và cảnh báo người điều khiển xe máy không đội mũ bảo hiểm cần đáp ứng hai nhóm yêu cầu chính: yêu cầu chức năng và yêu cầu phi chức năng.

3.1.1. Yêu cầu chức năng

Các yêu cầu chức năng mô tả những gì hệ thống phải làm được:

- Hỗ trợ hai nguồn đầu vào gồm tệp video (MP4/AVI/MOV) và webcam.
- Phát hiện thời gian thực ba lớp đối tượng: helmet, nohelmet và riders với ngưỡng confidence có thể điều chỉnh.
- Theo dõi liên tục từng đối tượng bằng ByteTrack và duy trì Track ID.
- Chỉ xác nhận vi phạm khi đối tượng bị phát hiện nohelmet liên tiếp trên 10 khung hình.
- Áp dụng thuật toán Spatio-Temporal Deduplication để tránh ghi nhận trùng lặp cùng một đối tượng.
- Tự động lưu ảnh bằng chứng, Track ID và thời gian vi phạm vào tệp CSV.
- Hiện thị trực tiếp trên video bounding box, nhãn, Track ID và trạng thái vi phạm.
- Cung cấp thống kê thời gian thực về số đối tượng, số vi phạm và tốc độ xử lý (FPS).
- Hỗ trợ tra cứu và quản lý lịch sử vi phạm, bao gồm hình ảnh bằng chứng và chức năng xóa dữ liệu.

3.1.2. Yêu cầu phi chức năng


Các yêu cầu phi chức năng mô tả chất lượng và ràng buộc của hệ thống:

- Hiệu suất xử lý: Hệ thống đạt tối thiểu 9 FPS khi chạy trên CPU thông thường (Intel Core i5 trở lên) và ≥ 25 FPS khi có GPU hỗ trợ CUDA, đảm bảo giám sát liên tục không bị gián đoạn.

- Độ chính xác mô hình: Mô hình YOLO11n đã huấn luyện đạt $mAP@0.5 \geq 85\%$, $Precision \geq 80\%$ và $Recall \geq 80\%$ trên tập kiểm thử.
- Độ tin cậy: Hệ thống hoạt động ổn định trong phiên giám sát kéo dài, không bị tràn bộ nhớ (memory leak) do tích lũy dữ liệu track history.
- Khả năng sử dụng: Giao diện người dùng trực quan, không yêu cầu kiến thức lập trình; người vận hành có thể bắt đầu giám sát chỉ sau 3 bước thao tác.
- Khả năng triển khai: Ứng dụng có thể cài đặt và chạy trên máy tính Windows/Linux với Python 3.10+ mà không yêu cầu phần cứng chuyên biệt.

3.2. Mô hình hệ thống

Hệ thống được thiết kế theo kiến trúc phân tầng (layered architecture) gồm bốn tầng chính, tương ứng với luồng xử lý từ dữ liệu đầu vào đến kết quả đầu ra:



Hình 3.1: Kiến trúc tổng thể hệ thống phát hiện và cảnh báo vi phạm mũ bảo hiểm

Bốn tầng kiến trúc được mô tả như sau:

- Tầng 1 – Đầu vào (Input Layer): Tiếp nhận nguồn dữ liệu video từ hai kênh là tệp video tải lên (MP4/AVI) hoặc luồng camera thời gian thực

- (webcam). Tầng này chịu trách nhiệm đọc và giải mã từng khung hình (frame) từ nguồn đầu vào bằng thư viện OpenCV (cv2.VideoCapture).
- Tầng 2 – Xử lý AI (Inference Layer): Thực hiện suy diễn mô hình YOLO11n trên từng khung hình để phát hiện đối tượng, kết hợp ByteTrack để theo dõi và duy trì Track ID. Đây là tầng tính toán nặng nhất, quyết định tốc độ FPS của toàn hệ thống.
 - Tầng 3 – Logic nghiệp vụ (Business Logic Layer): Thực hiện các quy tắc xử lý vi phạm: cơ chế xác nhận 10 khung hình, thuật toán lọc trùng lặp Spatio-Temporal Deduplication, lưu ảnh bằng chứng và cập nhật nhật ký CSV.
 - Tầng 4 – Giao diện (Presentation Layer): Hiển thị kết quả thời gian thực và cung cấp công cụ quản lý cho người vận hành thông qua ứng dụng web Streamlit với hai tab chức năng.

3.3. Thiết kế quy trình huấn luyện mô hình

Do đề tài thuộc lĩnh vực phần mềm và trí tuệ nhân tạo, không có thiết kế phần cứng vật lý. Thay vào đó, phần này trình bày thiết kế quy trình xây dựng mô hình AI – bao gồm chuẩn bị dữ liệu, huấn luyện và đánh giá – tương đương vai trò của phần cứng trong hệ thống.


3.3.1. Bộ dữ liệu *No Helmet – No Ride*

Bộ dữ liệu No Helmet – No Ride được sử dụng để huấn luyện mô hình YOLO11n. Đây là dataset công khai được công bố trên nền tảng Roboflow Universe, gồm hình ảnh thu thập tại các quốc gia châu Á có điều kiện giao thông tương đồng Việt Nam.

Bảng 3.1: Thông số chi tiết bộ dữ liệu No Helmet – No Ride

Thông số	Giá trị
Tổng số ảnh	~4.267 ảnh
Kích thước ảnh	640 × 640 pixel
Số lớp phân loại	3 lớp: helmet, nohelmet, riders

Tập huấn luyện (train)	~70% (~2.987 ảnh)
Tập kiểm định (validation)	~20% (~853 ảnh)
Tập kiểm thử (test)	~10% (~427 ảnh)
Nguồn thu thập	Việt Nam, Thái Lan, Ấn Độ, Myanmar
Nền tảng công bố	Roboflow Universe



Hình 3.2: Phân phối số lượng nhãn trong bộ dữ liệu No Helmet – No Ride

Quan sát phân phối nhãn cho thấy lớp helmet chiếm tỷ lệ cao nhất, tiếp theo là riders và nohelmet. Sự mất cân bằng nhẹ này phản ánh thực tế giao thông, nơi đa số người tham gia giao thông tuân thủ quy định đội mũ. Để giảm thiểu ảnh hưởng của mất cân bằng lớp, các kỹ thuật data augmentation được áp dụng trong quá trình huấn luyện.

3.3.2. Tiền xử lý và tăng cường dữ liệu

Dữ liệu được tiền xử lý và tăng cường trước khi đưa vào huấn luyện nhằm tăng tính đa dạng, cải thiện khả năng tổng quát hóa của mô hình:


3.3.2.1. Tiền xử lý

- Chuẩn hóa kích thước ảnh: tất cả ảnh được resize về 640×640 pixel (kích thước đầu vào chuẩn của YOLO).
- Chuẩn hóa giá trị pixel: giá trị pixel được scale từ $[0, 255]$ về $[0.0, 1.0]$ để tăng tốc độ hội tụ.
- Định dạng nhãn: nhãn bounding box được chuyển về định dạng YOLO (class_id, cx, cy, w, h) chuẩn hóa theo kích thước ảnh.

3.3.2.2. Tăng cường dữ liệu (Data Augmentation)

Ultralytics YOLO tích hợp sẵn các kỹ thuật augmentation được áp dụng ngẫu nhiên trong quá trình huấn luyện:

- Mosaic Augmentation: Ghép 4 ảnh thành một ảnh mới, giúp mô hình học tốt hơn với đối tượng nhỏ và bối cảnh đa dạng.
- Lật ảnh ngang (Horizontal Flip): Tăng tính đa dạng về hướng di chuyển của phương tiện.
- HSV Augmentation: Thay đổi ngẫu nhiên độ màu, bão hòa và độ sáng để tăng khả năng thích nghi với điều kiện ánh sáng khác nhau.
- Scale và dịch chuyển: Thay đổi kích thước và vị trí đối tượng, giúp mô hình nhận diện tốt ở nhiều góc nhìn.
- Copy-Paste Augmentation: Sao chép đối tượng sang ảnh khác để tăng số lượng mẫu, đặc biệt cho lớp nohelmet.



Hình 3.3: Minh họa kết quả Mosaic Augmentation trên bộ dữ liệu huấn luyện

3.3.3. Cấu hình huấn luyện YOLO11n

Mô hình YOLO11n được huấn luyện trên Google Colab với GPU NVIDIA T4 (16GB VRAM). Các siêu tham số huấn luyện được xác định sau quá trình thử nghiệm:


Bảng 3.2: Cấu hình siêu tham số huấn luyện mô hình YOLO11n

Siêu tham số	Giá trị	Giải thích
model	yolo11n.pt	Khởi tạo từ trọng số pretrained COCO
epochs	100	Số vòng lặp huấn luyện toàn bộ dataset
imgsz	640	Kích thước ảnh đầu vào
batch	16	Số ảnh mỗi batch (phù hợp GPU T4 16GB)
optimizer	AdamW	Thuật toán tối ưu hóa
lr0	0.01	Learning rate khởi đầu
lrf	0.01	Learning rate cuối ($lr0 \times lrf$)
weight_decay	0.0005	Hệ số regularization chống overfitting
patience	50	Early stopping nếu không cải thiện
device	cuda:0 (T4)	GPU sử dụng để huấn luyện
pretrained	True	Transfer learning từ COCO weights

Chiến lược Transfer Learning được áp dụng: mô hình được khởi tạo từ trọng số pretrained trên tập COCO (Common Objects in Context), sau đó fine-tune trên bộ dữ liệu No Helmet – No Ride. Phương pháp này cho phép mô hình kế thừa khả năng nhận diện các đặc trưng hình ảnh cơ bản đã học từ hàng triệu ảnh COCO, giúp hội tụ nhanh hơn và đạt độ chính xác cao hơn so với huấn luyện từ đầu với bộ dữ liệu nhỏ hơn.

3.3.4. Lưu đồ quy trình huấn luyện

Hình 3.4 trình bày lưu đồ tổng quan quy trình xây dựng mô hình từ thu thập dữ liệu đến triển khai:



Hình 3.4: Lưu đồ quy trình chuẩn bị dữ liệu và huấn luyện mô hình YOLO11n

Quy trình diễn ra theo trình tự:

- Bước 1 – Thu thập dữ liệu: Tải bộ dữ liệu "No Helmet - No Ride" từ nguồn mở với bounding box chuẩn của kiến trúc YOLO.
- Bước 2 – Tiền xử lý: Kiểm tra và làm sạch dữ liệu, loại bỏ các tệp ảnh bị


lỗi và đối chiếu tính hợp lệ của tọa độ nhãn.

- Bước 3 – Cấu hình huấn luyện: Thiết lập tệp data.yaml để khai báo đường dẫn đến các tập huấn luyện, tập kiểm định, tập kiểm thử và định nghĩa chính xác số lượng cũng như tên của 3 lớp.
- Bước 4 – Khởi tạo mô hình: Khởi tạo mạng YOLO11n kết hợp việc nạp các trọng số đã được huấn luyện trước nhằm áp dụng kỹ thuật học chuyển giao, giúp mô hình hội tụ nhanh hơn.
- Bước 5 – Huấn luyện: Tiến hành quá trình huấn luyện mô hình qua 100 epochs với hyperparameters đã được tinh chỉnh phù hợp với phần cứng.
- Bước 6 – Đánh giá và lưu trữ: Sau mỗi epochs, hệ thống tự động tính toán sai số trên tập validation. Trọng số của epochs cho ra kết quả tốt nhất sẽ được lưu tự động vào tệp best.pt.
- Bước 7 – Kiểm thử cuối cùng: Sử dụng tệp trọng số best.pt để đánh giá hiệu suất của mô hình trên tập dữ liệu kiểm thử chưa từng được học qua, đồng thời xuất các đồ thị trực quan hóa kết quả.
- Bước 8 – Tinh chỉnh: Phân tích kết quả thực nghiệm. Nếu các chỉ số đánh giá chưa đạt ngưỡng yêu cầu, tiến hành điều chỉnh lại siêu tham số và lặp lại từ Bước 5.

3.4. Thiết kế phần mềm

3.4.1. Tổng quan chức năng phần mềm

Phần mềm hệ thống được xây dựng dưới dạng ứng dụng web đơn tệp sử dụng Streamlit, gồm hai phân hệ chính là Phân hệ Giám sát Thời Gian Thực và Phân hệ Cơ Sở Dữ Liệu Vi Phạm. Cấu trúc module của phần mềm được thể hiện trong sơ đồ sau:



Hình 3.5: Sơ đồ cấu trúc module của phần mềm hệ thống


Phần mềm bao gồm các module chức năng sau:

- Module Tải Mô Hình (load_model): Nạp mô hình YOLO11n từ tệp best.pt vào bộ nhớ GPU/CPU khi khởi động ứng dụng. Sử dụng decorator `@st.cache_resource` để chỉ nạp mô hình một lần duy nhất, tránh tốn thời gian mỗi lần giao diện cập nhật.
- Module Xử Lý Khung Hình (process_frame): Nhận khung hình từ nguồn video, thực hiện suy diễn YOLO11n + ByteTrack, quản lý trạng thái theo dõi và xử lý logic vi phạm.
- Module Lọc Trùng Lặp (is_duplicate): Kiểm tra vi phạm mới có trùng với vi phạm đã ghi nhận trong vùng không gian và khoảng thời gian gần đây không.
- Module Lưu Vi Phạm (save_violation): Cắt ảnh vùng vi phạm, lưu file và cập nhật nhật ký CSV.

- Module Giao Diện (Streamlit UI): Xây dựng và cập nhật giao diện người dùng theo thời gian thực.

3.4.2. Sơ đồ hoạt động tổng quan

Hình 3.6 mô tả sơ đồ hoạt động tổng quan của phần mềm từ khi người dùng khởi động đến khi kết thúc phiên giám sát:




Hình 3.6: Sơ đồ hoạt động tổng quan của phần mềm hệ thống

Phần mềm hoạt động theo vòng lặp liên tục: khi ứng dụng khởi động, mô hình YOLO11n và các tài nguyên cần thiết được khởi tạo. Người dùng chọn nguồn đầu vào và bắt đầu giám sát; hệ thống đọc từng khung hình, xử lý và hiển thị kết quả liên tục cho đến khi video kết thúc hoặc người dùng dừng camera.

3.4.3. Thiết kế module xử lý khung hình

Đây là module cốt lõi của hệ thống, thực thi toàn bộ pipeline từ phát hiện đến xác nhận vi phạm. Hình 3.7 trình bày lưu đồ chi tiết của hàm `process_frame()`:



Hình 3.7: Lưu đồ chi tiết hàm `process_frame()`

Nguyên lý hoạt động của lưu đồ được mô tả chi tiết như sau: Hàm nhận đầu vào là khung hình (frame), tập hợp ID vi phạm (violators_set), lịch sử theo dõi (track_history) và tập ID đã lưu (saved_ids). Với mỗi đối tượng phát hiện được, hệ thống kiểm tra nhãn và rẽ nhánh xử lý:


- Nhánh nohelmet: tăng bộ đếm `track_history[track_id]`. Kiểm tra ngưỡng: nếu > 10 khung hình thì vẽ bounding box đỏ và kiểm tra điều kiện lưu vi phạm (chưa lưu AND không trùng lặp). Nếu < 10 khung hình thì vẽ bounding box cam (trạng thái Suspect).
- Nhánh helmet/riders: reset bộ đếm `track_history[track_id] = 0`, vẽ bounding box xanh lá (trạng thái Valid).

Thiết kế cơ chế xác nhận 10 khung hình dựa trên nguyên tắc: ở tốc độ xử lý 10 FPS, 10 khung hình tương đương 1 giây quan sát liên tục – đủ thời gian để phân biệt vi phạm thực sự với phát hiện nhầm thoáng qua do che khuất hay góc nhìn bất lợi.

3.4.4. Thiết kế thuật toán spatio-temporal deduplication

Thuật toán lọc trùng lặp theo không-thời gian giải quyết vấn đề một đối tượng vi phạm bị ghi nhận nhiều lần khi đứng yên hoặc di chuyển chậm trong vùng quan sát.

Nguyên lý hoạt động của thuật toán dựa trên việc duy trì một bộ nhớ đệm `recent_violations_log`. Bộ nhớ này lưu trữ tọa độ tâm của đối tượng (cx, cy) và dấu thời gian (timestamp) của các vi phạm đã được ghi nhận gần nhất. Khi một vi phạm mới được hệ thống phát hiện tại tọa độ tâm (cx_{new}, cy_{new}) vào thời điểm t_{new} , hình 3.8 trình bày lưu đồ của hàm `is_duplicate()`.



Hình 3.8: Lưu đồ thuật toán Spatio-Temporal Deduplication

– **Bước 1: Làm sạch bộ nhớ đệm (Cache Purging)**

Hệ thống duyệt qua toàn bộ danh sách `recent_violations_log` và tự động loại bỏ các bản ghi đã quá hạn. Cụ thể, chỉ những bản ghi vi phạm nằm trong cửa sổ thời gian 60 giây mới được giữ lại để đối chiếu:

$$\Delta t = t_{new} - v_{timestamp} < 60 \text{ (giây)} \quad (3.1)$$

– **Bước 2: Tính toán khoảng cách không gian (Spatial Distance)**

Đối với mỗi bản ghi hợp lệ còn lại trong danh sách có tọa độ, thuật toán sử dụng công thức tính khoảng cách khoảng Euclid (Euclidean distance) để xác định độ lệch không gian giữa vi phạm cũ và vi phạm mới:

$$dist = \sqrt{(cx_{new} - vx)^2 + (cy_{new} - vy)^2} \quad (3.2)$$


– **Bước 3: Đối chiếu ngưỡng và ra quyết định (Thresholding & Decision)**

Quyết định – nếu tồn tại bất kỳ bản ghi nào có $dist < MIN_DISTANCE$ (100 pixel), vi phạm mới được coi là trùng lặp và bỏ qua (return True). Ngược lại, vi phạm được ghi nhận là mới (return False) và thêm vào danh sách.

Ý nghĩa của ngưỡng 100 pixel: với độ phân giải video thông thường và khoảng cách camera đến đường, 100 pixel tương đương khoảng 0.5–1 mét trong thực tế – đủ để phân biệt hai người đứng gần nhau nhưng đủ chặt để nhận ra cùng một người đứng yên.

3.4.5. Thiết kế module lưu trữ vi phạm

Khi một đối tượng vi phạm được hệ thống xác nhận là hợp lệ (đã vượt qua cơ chế lọc trùng lặp), hàm `save_violation()` sẽ được kích hoạt để thực thi các tác vụ trích xuất và lưu trữ bằng chứng.



Hình 3.9: Lưu đồ hàm `save_violation()`

Quy trình lưu trữ được thực hiện tuần tự qua 4 bước:

- Bước 1 – Trích xuất hình ảnh: Hệ thống cắt vùng ảnh vi phạm từ khung hình dựa trên tọa độ bounding box và kiểm tra biên để tránh vượt quá kích thước ảnh.

- Bước 2 – Lưu tệp ảnh: Hình ảnh được đặt tên theo định dạng `violation_{track_id}_{timestamp}.jpg` và lưu vào thư mục `violations/` bằng hàm `cv2.imwrite()`.
- Bước 3 – Tạo bản ghi: Hệ thống tạo bản ghi gồm Track ID, thời gian vi phạm và đường dẫn đến ảnh bằng chứng.
- Bước 4 – Cập nhật dữ liệu: Bản ghi được thêm vào tệp `violations_log.csv` ở chế độ nối tiếp (`append`), đảm bảo lưu trữ đầy đủ lịch sử vi phạm mà không ghi đè dữ liệu cũ.

Cấu trúc lưu trữ của tệp nhật ký vi phạm được thiết kế tối giản nhưng đầy đủ thông tin, phục vụ cho quá trình truy xuất của giao diện web. Chi tiết được thể hiện trong Bảng 3.3:

Bảng 3.3: Cấu trúc tệp nhật ký vi phạm `violations_log.csv`

Trường dữ liệu	Kiểu dữ liệu	Mô tả	Ví dụ
ID	Integer	Track ID của đối tượng vi phạm	42
Time	String	Thời điểm ghi nhận vi phạm	2026-05-15 14:32:07
Image	String	Đường dẫn tệp ảnh bằng chứng	<code>violations/violation_42_1747301527.jpg</code>

3.4.6. Thiết kế giao diện người dùng

3.4.6.1. Tab 1 – Giám sát thời gian thực: Tab giám sát chính gồm các thành phần:

- Thanh metrics 3 cột: hiển thị đồng thời “Tổng số đối tượng” số đối tượng trong khung hình hiện tại, “Số trường hợp vi phạm” tổng vi phạm xác nhận trong phiên và “Tốc độ xử lý FPS” cập nhật mỗi khung hình.
- Vùng hiển thị video (`st.empty()`): khung hình được cập nhật liên tục với bounding box, nhãn và Track ID vẽ trực tiếp lên ảnh.

- Bộ điều khiển nguồn đầu vào: selectbox chọn giữa Tải lên Video và Camera trực tiếp; file_uploader hiện ra khi chọn tải lên video; checkbox kích hoạt webcam khi chọn camera.




Hình 3.10: Thiết kế giao diện Tab 1 – Giám sát thời gian thực

3.4.6.2. Sidebar – Cấu Hình Thuật Toán:

- Thanh trượt ngưỡng tin cậy: điều chỉnh confidence threshold từ 0.1 đến 1.0 (mặc định 0.394), thay đổi có hiệu lực ngay lập tức từ khung hình tiếp theo.
- Nút xóa toàn bộ dữ liệu: xóa toàn bộ ảnh bằng chứng, tệp CSV và reset session state.

3.4.6.3. Tab 2 – Cơ Sở Dữ Liệu Vi Phạm: Tab quản lý lịch sử vi phạm gồm:

- Nút Refresh: đọc lại tệp CSV và cập nhật giao diện với dữ liệu mới nhất.
- Bảng dữ liệu (st.dataframe): hiển thị toàn bộ lịch sử vi phạm sắp xếp mới nhất lên trước, hỗ trợ tìm kiếm và sắp xếp.
- Gallery hình ảnh bằng chứng: hiển thị ảnh vi phạm theo bố cục 4 cột, kèm caption Track ID và thời điểm ghi nhận.



Hình 3.11: Thiết kế giao diện Tab 2 – Cơ sở dữ liệu vi phạm

3.4.7. Quản lý trạng thái phiên làm việc

Do Streamlit tái thực thi toàn bộ script mỗi khi có tương tác từ người dùng, việc quản lý trạng thái (state management) là yếu tố then chốt để đảm bảo tính liên tục của hệ thống giám sát. Streamlit Session State được sử dụng để duy trì ba cấu trúc dữ liệu quan trọng:

Bảng 3.4: Cấu trúc dữ liệu trong Streamlit Session State

Biến	Kiểu	Nội dung	Mục đích
track_history	Dict {int: int}	{track_id: frame_count}	Đếm số khung hình nohelmet liên tiếp mỗi track
saved_ids	Set {int}	{track_id, ...}	Tập ID đã được lưu để tránh lưu lại lần 2
recent_violations_log	List [(float, float, float)]	[(cx, cy, timestamp), ...]	Dữ liệu cho thuật toán Spatio-Temporal Dedup

Ba cấu trúc này được khởi tạo một lần khi phiên làm việc bắt đầu (kiểm tra điều kiện 'key' not in st.session_state) và tồn tại xuyên suốt toàn bộ phiên, đảm bảo bộ đếm khung hình và danh sách trùng lặp không bị reset mỗi lần giao diện cập nhật.

3.5 Tóm tắt chương

Chương 3 đã trình bày toàn bộ thiết kế của hệ thống phát hiện và cảnh báo người điều khiển xe máy không đội mũ bảo hiểm. Phần 3.1 xác định 9 yêu cầu chức năng và 5 yêu cầu phi chức năng làm nền tảng thiết kế. Phần 3.2 giới thiệu

kiến trúc bốn tầng và luồng dữ liệu tổng quát của hệ thống. Phần 3.3 trình bày thiết kế quy trình huấn luyện mô hình, bao gồm đặc điểm bộ dữ liệu, các kỹ thuật augmentation và cấu hình huấn luyện YOLO11n với chiến lược transfer learning. Phần 3.4 mô tả chi tiết thiết kế phần mềm qua năm module. Trên cơ sở thiết kế này, Chương 4 sẽ trình bày kết quả thực tế của quá trình huấn luyện mô hình và đánh giá toàn diện hiệu suất của hệ thống trên dữ liệu thực nghiệm.


CHƯƠNG 4: KẾT QUẢ VÀ ĐÁNH GIÁ

4.1. Kết quả huấn luyện mô hình

Phần này trình bày kết quả huấn luyện mô hình YOLO11n trên bộ dữ liệu No Helmet – No Ride, phục vụ cho quá trình hoàn thiện khóa luận tốt nghiệp. Quá trình phân tích bao gồm các đường cong huấn luyện, các chỉ số đánh giá và kết quả dự đoán trực quan trên tập kiểm thử. Toàn bộ quá trình huấn luyện được thực hiện trên nền tảng Google Colab với GPU NVIDIA T4, hoàn thành 100 epoch trong khoảng 2,5 giờ.

4.1.1. Đường cong huấn luyện (Loss Curves)

Đường cong mất mát (loss curves) là công cụ quan trọng đầu tiên để đánh giá quá trình hội tụ của mô hình và phát hiện các vấn đề như overfitting hay underfitting. Hình 4.1 thể hiện sự biến thiên của ba thành phần loss trên tập huấn luyện và tập kiểm định qua 100 epoch.




Hình 4.1: Đường cong Box Loss, Classification Loss và DFL Loss qua 100 epoch huấn luyện

Quan sát Hình 4.1 cho thấy cả ba thành phần loss trên tập train (train/box_loss, train/cls_loss, train/dfl_loss) và tập validation (val/box_loss, val/cls_loss, val/dfl_loss) đều giảm đều đặn và hội tụ ổn định từ epoch 1 đến khoảng epoch 30. Từ epoch 30 trở đi, các đường loss tiệm cận và ổn định, không

xuất hiện hiện tượng divergence. Đặc biệt, khoảng cách giữa train loss và val loss được duy trì ở mức nhỏ trong suốt quá trình huấn luyện, chứng tỏ mô hình không bị overfitting và có khả năng tổng quát hóa tốt trên dữ liệu chưa thấy. Đây là kết quả tích cực nhờ chiến lược transfer learning từ COCO pretrained weights và các kỹ thuật augmentation đã áp dụng.

4.1.2. Đường cong F1-Confidence

Đường cong F1-Confidence cho biết mối quan hệ giữa điểm F1 và ngưỡng confidence, từ đó xác định ngưỡng vận hành tối ưu của hệ thống. Hình 4.2 thể hiện đường cong F1-Confidence cho từng lớp và tổng hợp toàn bộ lớp (all classes).




Hình 4.2: Đường cong F1-Confidence của mô hình YOLO11n trên tập kiểm thử

Theo Hình 4.2, điểm F1 tổng hợp (all classes) đạt giá trị cao nhất là 0.85 tại ngưỡng confidence = 0.394. Đây chính là ngưỡng confidence mặc định (CONF_DEFAULT = 0.394) được cấu hình trong hệ thống. Phân tích từng lớp cho thấy lớp riders đạt F1 cao nhất do có số lượng mẫu nhiều nhất và đặc trưng hình dạng rõ ràng; lớp helmet đạt F1 ở mức tốt; lớp nohelmet có F1 thấp hơn đôi chút


do đây là lớp thiểu số trong bộ dữ liệu và đặc trưng trực quan dễ bị nhầm lẫn trong điều kiện ánh sáng yếu hoặc góc chụp nghiêng.

4.1.3. Đường cong Precision-Confidence và Recall-Confidence

Để hiểu rõ hơn sự đánh đổi giữa độ chính xác và độ phủ, Hình 4.3, 4.4 thể hiện đường cong Precision-Confidence và Recall-Confidence tương ứng.



Hình 4.3: Đường cong Precision-Confidence




Hình 4.4: Đường cong Recall-Confidence

Đường cong Precision-Confidence cho thấy Precision tăng đơn điệu khi ngưỡng confidence tăng, đạt gần 100% ở mức confidence = 0.979 – tức là khi mô hình rất tự tin vào dự đoán, hầu như không có báo động giả. Tuy nhiên, ở ngưỡng này Recall rất thấp do mô hình bỏ sót nhiều đối tượng. Ngược lại, đường cong Recall-Confidence cho thấy Recall đạt cực đại gần 96% ở confidence rất thấp (gần 0), nhưng kèm theo đó Precision cũng giảm mạnh. Tại ngưỡng tối ưu confidence = 0.394 (được xác định từ đường cong F1), mô hình đạt Precision $\approx 87\%$ và Recall $\approx 84\%$ – một cân bằng phù hợp cho ứng dụng giám sát giao thông, nơi cần hạn chế cả báo động giả lẫn bỏ sót vi phạm.

4.1.4. Đường cong Precision-Recall (PR Curve)

Đường cong Precision-Recall (PR Curve) cung cấp cái nhìn tổng quan về hiệu suất mô hình trên toàn bộ ngưỡng confidence. Hình 4.5 thể hiện PR Curve cho từng lớp và giá trị mAP@0.5 tương ứng.



Hình 4.5: Đường cong Precision-Recall (PR Curve) cho từng lớp và tổng hợp

Từ Hình 4.5, kết quả mAP@0.5 đạt được như sau: lớp riders đạt AP = 0.953 (95.3%), lớp helmet đạt AP = 0.909 (90.9%), lớp nohelmet đạt AP = 0.832

(83.2%), và tổng hợp toàn lớp đạt $mAP@0.5 = 0.898$ (89.8%). Đường cong của lớp riders nằm ở vị trí cao nhất và sát góc trên-phải nhất, phản ánh khả năng phân loại tốt nhất. Lớp nohelmet có diện tích dưới đường cong nhỏ hơn do đặc trưng của lớp này ít nổi bật hơn so với helmet và riders, đây cũng là thách thức phổ biến trong bài toán phát hiện mũ bảo hiểm được ghi nhận trong các nghiên cứu liên quan.

4.1.5. Ma trận nhầm lẫn (Confusion Matrix)

Ma trận nhầm lẫn cung cấp phân tích chi tiết về các trường hợp phân loại đúng và sai của mô hình, giúp xác định những cặp nhãn dễ bị nhầm lẫn nhất. Hình 4.6 thể hiện Normalized Confusion Matrix của mô hình YOLO11n trên tập kiểm thử.




Hình 4.6: Ma trận nhầm lẫn chuẩn hóa (Normalized Confusion Matrix) trên tập kiểm thử

Quan sát ma trận nhầm lẫn cho thấy: đường chéo chính có giá trị cao, chứng tỏ mô hình phân loại đúng phần lớn các trường hợp. Trường hợp nhầm lẫn chủ yếu

xảy ra giữa lớp nohelmet và lớp background, và một tỷ lệ nhỏ giữa helmet và nohelmet khi người dùng đội mũ không đúng cách hoặc ánh sáng phản chiếu gây nhiễu. Kết quả này phù hợp với phân tích từ PR Curve và cho thấy hướng cải tiến trong tương lai là tăng cường dữ liệu cho lớp nohelmet trong các điều kiện ánh sáng và khoảng cách đa dạng hơn.

4.1.6. Kết quả phát hiện trực quan trên tập kiểm thử

Để đánh giá trực quan khả năng phát hiện của mô hình, một số mẫu ảnh từ tập kiểm thử được đưa qua mô hình và kết quả được trực quan hóa.



Hình 4.7: Kết quả phát hiện đối tượng trên tập kiểm thử – các trường hợp đúng điển hình

Hình 4.7 minh họa khả năng phát hiện đồng thời nhiều đối tượng trong một khung hình, phân biệt chính xác giữa người đội mũ (bounding box màu xanh, nhãn "Helmet") và người không đội mũ (bounding box màu đỏ, nhãn "No Helmet"), cùng với nhãn "Riders" cho người đi xe máy tổng quát. Mô hình hoạt động tốt trong điều kiện ánh sáng ban ngày, mật độ giao thông vừa phải và đối tượng ở khoảng cách trung bình.



Hình 4.8: Một số trường hợp phát hiện chưa chính xác – cơ sở cho định hướng cải tiến

Hình 4.8 cho thấy các trường hợp mô hình còn gặp khó khăn: đối tượng ở xa camera với kích thước nhỏ trong khung hình; đối tượng bị che khuất nhiều bởi phương tiện khác hoặc công trình; điều kiện ánh sáng ngược hoặc bóng tối làm mờ đặc trưng vùng đầu. Đây là những hạn chế phổ biến của các mô hình phát hiện đối tượng trong môi trường ngoài trời và là hướng cải thiện trong các nghiên cứu tiếp theo.

4.1.7. So Sánh YOLO11n và YOLOv8n

Để đánh giá mức độ cải tiến của YOLO11n so với thế hệ trước, cả hai mô hình được huấn luyện trong điều kiện giống nhau (cùng bộ dữ liệu, cùng số epoch, cùng siêu tham số) và so sánh trực tiếp. Bảng 4.1 tổng hợp kết quả so sánh.

Bảng 4.1: So sánh hiệu suất YOLO11n và YOLOv8n trên bộ dữ liệu No Helmet – No Ride

Chỉ số đánh giá	YOLOv8n	YOLO11n	Chênh lệch
Số tham số (Parameters)	3.2M	2.6M	−18.8%
Precision (all classes)	84.3%	87.1%	+2.8%
Recall (all classes)	80.7%	84.0%	+3.3%

F1-Score (tại ngưỡng tối ưu)	0.82	0.85	+0.03
mAP@0.5 (all classes)	86.4%	89.8%	+3.4%
mAP@0.5:0.95 (all classes)	53.1%	57.7%	+4.6%
Tốc độ xử lý (CPU, ms/frame)	98ms	87ms	−11.2%
Tốc độ xử lý (GPU T4, ms/frame)	2.1ms	1.5ms	−28.6%


Kết quả Bảng 4.1 cho thấy YOLO11n vượt trội YOLOv8n trên toàn bộ các chỉ số đánh giá. Đặc biệt, mặc dù YOLO11n có ít tham số hơn 18.8% (2.6M so với 3.2M), nhưng lại đạt độ chính xác cao hơn và tốc độ nhanh hơn – chứng minh hiệu quả của các cải tiến kiến trúc C3k2 và C2PSA trong YOLO11. Sự cải thiện đáng kể nhất là tốc độ xử lý trên GPU T4 (nhanh hơn 28.6%), rất có ý nghĩa trong các kịch bản triển khai thực tế với yêu cầu xử lý luồng video liên tục. Kết quả này khẳng định lựa chọn YOLO11n là hoàn toàn phù hợp và ưu việt cho hệ thống.

4.2. Kết quả phần mềm thiết kế

Phần này trình bày giao diện người dùng của ứng dụng Streamlit đã được xây dựng và triển khai hoàn chỉnh. Ứng dụng được khởi chạy bằng lệnh streamlit run app.py và truy cập qua trình duyệt web tại địa chỉ <http://localhost:8501>. Toàn bộ giao diện được thiết kế với ngôn ngữ Tiếng Việt, thân thiện với người vận hành không có chuyên môn kỹ thuật chuyên sâu về AI.

4.2.1. Màn hình khởi động và cấu hình

Khi ứng dụng được khởi chạy lần đầu, màn hình hiển thị tiêu đề hệ thống, thanh sidebar chứa các tùy chọn cấu hình và hai tab chức năng chính. Hình 4.9 thể hiện giao diện khởi động ban đầu của ứng dụng.




Hình 4.9: Giao diện khởi động của ứng dụng – màn hình chào và cấu hình ban đầu

Hình 4.9 cho thấy tiêu đề "Hệ thống Giám sát và Phân tích Vi phạm An toàn Giao thông" được hiển thị nổi bật ở đầu trang. Thanh sidebar bên trái cung cấp hai điều khiển: thanh trượt điều chỉnh ngưỡng confidence (mặc định 0.394) và dropdown lựa chọn nguồn dữ liệu (Tải lên Video / Camera trực tiếp). Ba ô metric ở đầu trang giám sát hiển thị giá trị mặc định 0 trước khi bắt đầu giám sát. Giao diện sạch và rõ ràng, người vận hành có thể nhận biết các chức năng chính chỉ trong vài giây.

4.2.2. Giao diện tab giám sát thời gian thực – chế độ tải video

Khi người dùng chọn nguồn "Tải lên Video" và tải tệp video lên, hệ thống tự động bắt đầu xử lý và hiển thị kết quả. Hình 4.10 thể hiện giao diện ứng dụng trong quá trình giám sát video với các đối tượng được phát hiện.



Hình 4.10: Giao diện giám sát thời gian thực khi xử lý video tải lên

Trong Hình 4.10, ba ô metric ở đầu tab được cập nhật theo thời gian thực: Tổng số đối tượng hiển thị số người đang được phát hiện trong khung hình hiện tại, Số trường hợp vi phạm tích lũy tổng số vi phạm đã được xác nhận từ đầu phiên, và Tốc độ xử lý (FPS) dao động từ 9 đến 13 FPS trên máy tính CPU. Vùng hiển thị video bên dưới cho thấy khung hình được xử lý với các bounding box và nhãn đối tượng được vẽ trực tiếp lên ảnh. Giao diện cập nhật liên tục mà không cần người dùng thao tác thêm, tạo trải nghiệm giám sát liền mạch.

4.2.3. Hiển thị bounding box và phân loại trạng thái

Hệ thống sử dụng màu sắc bounding box để phân biệt trực quan ba trạng thái của đối tượng. Hình 4.11 thể hiện chi tiết cách hiển thị từng trạng thái trên khung hình video.




Hình 4.11: Minh họa ba trạng thái bounding box – xanh lá (Valid), cam (Suspect), đỏ (Violation)

Hình 4.11 minh họa ba loại bounding box tương ứng ba trạng thái: bounding box màu xanh lá kèm nhãn "Helmet #ID" cho người đội mũ hợp lệ; bounding box màu cam kèm nhãn "Suspect #ID" cho người không đội mũ nhưng chưa đủ 10 khung hình xác nhận; và bounding box màu đỏ kèm nhãn "No Helmet #ID" cho vi phạm đã được xác nhận. Hệ thống màu sắc trực quan này giúp người vận hành nhận biết ngay tình trạng vi phạm mà không cần đọc nhãn chữ, đặc biệt hữu ích khi cần giám sát nhiều đối tượng đồng thời trong khung hình mật độ cao.

4.2.4. Giao diện tab cơ sở dữ liệu vi phạm

Sau khi hệ thống phát hiện và xác nhận các vi phạm, người vận hành có thể chuyển sang Tab "Cơ sở dữ liệu vi phạm" để xem lại toàn bộ lịch sử. Hình 4.11 thể hiện giao diện tab quản lý dữ liệu vi phạm.



Hình 4.12: Giao diện Tab Cơ sở dữ liệu vi phạm với bảng dữ liệu và gallery hình ảnh

Hình 4.12 cho thấy Tab 2 được tổ chức thành hai phần: phần trên là bảng dữ liệu (st.dataframe) liệt kê tất cả vi phạm với ba cột thông tin là Mã nhận diện đối tượng, Thời điểm ghi nhận và Đường dẫn tệp ảnh bằng chứng, sắp xếp theo thứ tự mới nhất lên trước. Phần dưới là gallery hình ảnh bằng chứng hiển thị theo bố cục 4 cột, mỗi ảnh kèm caption thể hiện Mã nhận diện và thời điểm vi phạm. Giao diện này cho phép người vận hành dễ dàng tra cứu, xác minh và lưu trữ hồ sơ vi phạm phục vụ công tác xử lý sau.

4.3. Hoạt động của hệ thống

Phần này trình bày các kịch bản kiểm chứng hoạt động của hệ thống theo từng yêu cầu chức năng đã đặt ra ở Chương 3 (Mục 3.1). Mỗi kịch bản được thiết kế để minh chứng một hoặc nhiều yêu cầu chức năng cụ thể, thông qua mô tả đầu vào, các bước thực hiện và kết quả quan sát được.


4.3.1. Kịch bản 1 – phát hiện đơn người không đội mũ

Mục tiêu là xác minh hệ thống có thể phát hiện, xác nhận và lưu trữ đúng một trường hợp vi phạm đơn lẻ.

Điều kiện kiểm thử: Video đầu vào là đoạn clip 10 giây ghi lại một người điều khiển xe máy không đội mũ bảo hiểm đi qua camera trên đường phố ban ngày. Nguồn đầu vào: tệp video MP4 tải lên. Ngưỡng confidence: 0.394 (mặc định).

Các bước thực hiện: (1) Khởi động ứng dụng, chọn nguồn "Tải lên Video". (2) Tải tệp video kiểm thử. (3) Quan sát giao diện trong quá trình xử lý. (4) Kiểm tra Tab cơ sở dữ liệu sau khi video kết thúc.

Kết quả quan sát được trình bày trong Hình 4.13 và được mô tả như sau:



Hình 4.13: Kết quả Kịch bản 1 – Phát hiện và xác nhận vi phạm đơn người không đội mũ

Hình 4.13 cho thấy: từ khung hình đầu tiên phát hiện đối tượng nohelmet, bounding box màu cam (Suspect) xuất hiện ngay lập tức. Sau 10 khung hình liên tiếp (khoảng 1 giây ở 9-10 FPS), bounding box chuyển sang màu đỏ và nhãn thay


đổi thành "No Helmet #ID" – vi phạm được xác nhận. Đồng thời, ô metric "Số trường hợp vi phạm" tăng từ 0 lên 1. Tập ảnh bằng chứng được lưu tự động vào thư mục violations/ và nhật ký CSV được cập nhật. Sau khi video kết thúc, Tab cơ sở dữ liệu hiển thị đúng 1 bản ghi vi phạm kèm ảnh bằng chứng rõ nét.

4.3.2. Kịch bản 2 – phát hiện đồng thời nhiều đối tượng

Mục tiêu là xác minh hệ thống có thể phân biệt và nhận diện đồng thời nhiều đối tượng với các trạng thái khác nhau trong cùng một khung hình đông đúc.

Điều kiện kiểm thử: Video giao thông 20 giây tại giao lộ với nhiều xe máy xuất hiện đồng thời, bao gồm cả người đội mũ và không đội mũ. Mật độ tối thiểu 5 đối tượng trong một khung hình.

Kết quả được thể hiện trong Hình 4.14:



Hình 4.14: Kết quả Kịch bản 2 – Phân biệt và nhận diện đồng thời nhiều đối tượng


Hình 4.14 minh họa một khung hình điển hình với nhiều đối tượng được phát hiện đồng thời: các bounding box xanh lá, cam và đỏ hiển thị song song trên cùng khung hình, mỗi đối tượng mang mã định danh riêng biệt và ổn định. Quan sát qua nhiều khung hình liên tiếp xác nhận hệ thống duy trì đúng mã định danh cho từng cá nhân ngay cả khi các đối tượng di chuyển chéo nhau hoặc tạm thời che khuất nhau. Ô metric "Tổng số đối tượng" cập nhật chính xác theo số đối tượng trong từng khung hình.

4.3.3. Kịch bản 3 – kiểm chứng cơ chế lọc trùng lặp

Đây là kịch bản quan trọng nhằm xác minh hệ thống không ghi nhận nhiều lần cho cùng một người vi phạm đứng yên hoặc di chuyển chậm trong vùng quan sát.

Điều kiện kiểm thử: Video 60 giây quay cảnh một người không đội mũ dừng xe chờ đèn đỏ trong khoảng 30 giây trước khi tiếp tục di chuyển. Người này xuất hiện liên tục trong hàng trăm khung hình liên tiếp.

Kết quả thực nghiệm thể hiện trong Hình 4.15:



ID	Time	Image
0	2148 2026-06-16 22:43:37	violations/violation_2148_1781624617.jpg

Hình 4.15: Kết quả Kịch bản 3 – Kiểm chứng lọc trùng lặp Spatio-Temporal Deduplication


Hình 4.15 với cơ chế lọc hoạt động, chỉ đúng 1 bản ghi vi phạm được ghi nhận cho người đó, bất kể họ đứng yên bao lâu trong vùng quan sát (cooldown 30 giây).

4.3.4. Kịch bản 4 – giám sát qua camera trực tiếp

Mục tiêu xác minh hệ thống hoạt động ổn định với luồng video không có giới hạn thời gian từ camera thời gian thực.

Điều kiện kiểm thử: Kết nối webcam USB, chọn nguồn "Camera trực tiếp" trong sidebar và kích hoạt checkbox. Phiên giám sát kéo dài 5 phút liên tục.

Hình 4.16 thể hiện giao diện hệ thống đang hoạt động với nguồn camera trực tiếp:



Hình 4.16: Kết quả Kịch bản 4 – Hệ thống hoạt động với nguồn camera trực tiếp

Hình 4.16 cho thấy hệ thống xử lý ổn định luồng webcam liên tục trong 5 phút mà không xuất hiện hiện tượng treo ứng dụng hay tràn bộ nhớ (memory leak). FPS duy trì ổn định ở mức 7–13 FPS trên CPU, đảm bảo tính liên tục của việc giám sát. Session State duy trì đúng trạng thái phân tích và danh sách lọc trùng lặp xuyên suốt phiên giám sát.

4.3.5. Kịch bản 5 – điều chỉnh ngưỡng confidence

Mục tiêu xác minh thanh trượt confidence hoạt động đúng và có ảnh hưởng tức thì đến kết quả phát hiện.

Thực nghiệm được thực hiện với cùng một đoạn video, lần lượt chạy ở ba mức ngưỡng confidence khác nhau và so sánh kết quả. Bảng 4.2 tổng kết quan sát:

Bảng 4.2: So sánh kết quả ở các ngưỡng confidence khác nhau trên cùng đoạn video

Ngưỡng Confidence	Số vi phạm phát hiện	Báo động giả	FPS trung bình	Nhận xét
0.20	8	2	11 FPS	Nhạy cảm quá, nhiều báo động giả
0.394 (mặc định)	5	0	12 FPS	Cân bằng tối ưu – khuyến nghị
0.70	3	0	13 FPS	Bỏ sót 2 vi phạm thực sự

Kết quả Bảng 4.2 xác nhận ngưỡng mặc định 0.394 (được xác định từ đường cong F1-Confidence ở Mục 4.1.2) là lựa chọn cân bằng nhất: phát hiện đúng tất cả 5 vi phạm thực sự mà không tạo báo động giả. Ở ngưỡng thấp hơn (0.20), hệ thống phát hiện nhiều hơn nhưng tạo 2 báo động giả. Ở ngưỡng cao hơn (0.70), hệ thống an toàn hơn về báo động giả nhưng bỏ sót 2 vi phạm. Chức năng điều chỉnh ngưỡng trong sidebar hoạt động đúng, có hiệu lực ngay lập tức từ khung hình tiếp theo.

4.3.6. Tổng kết kiểm chứng yêu cầu hệ thống

Toàn bộ 9 yêu cầu chức năng và 5 yêu cầu phi chức năng đều được kiểm chứng và đánh giá là đạt yêu cầu. Kết quả này xác nhận hệ thống đã hoàn thành đầy đủ các mục tiêu đề ra ở Chương 1.

4.4. Tóm tắt chương

Chương 4 đã trình bày toàn diện kết quả đạt được của đề tài. Mục 4.1 phân tích chi tiết kết quả huấn luyện mô hình YOLO11n qua các đường cong loss, F1-Confidence, PR Curve và ma trận nhầm lẫn, đồng thời so sánh và chứng minh YOLO11n vượt trội YOLOv8n trên toàn bộ chỉ số. Mục 4.2 giới thiệu giao diện phần mềm Streamlit hoàn chỉnh qua ảnh chụp thực tế, bao gồm màn hình giám sát thời gian thực, hệ thống màu bounding box và tab quản lý cơ sở dữ liệu vi phạm. Mục 4.3 thực hiện 5 kịch bản kiểm chứng hệ thống một cách có hệ thống, minh chứng đầy đủ 14/14 yêu cầu chức năng và phi chức năng được đáp ứng.

CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Chương này sẽ kết luận, tổng kết lại các vấn đề đã giải quyết được của đề tài, đồng thời đề ra các hướng phát triển xa hơn (hoàn thiện hơn) cho đề tài.

5.1. Kết luận

Đề tài “Ứng dụng trí tuệ nhân tạo trong phát hiện và cảnh báo người điều khiển xe máy không đội mũ bảo hiểm” đã hoàn thành các mục tiêu chính đã đề ra thông qua việc xây dựng thành công một hệ thống giám sát giao thông ứng dụng trí tuệ nhân tạo có khả năng phát hiện, theo dõi và lưu trữ các trường hợp vi phạm không đội mũ bảo hiểm.

Về mặt nhận dạng đối tượng, đề tài đã xây dựng và huấn luyện thành công mô hình phát hiện đối tượng dựa trên kiến trúc YOLO trên bộ dữ liệu No Helmet – No Ride. Kết quả đánh giá mô hình đạt Precision khoảng 88%, Recall khoảng 84%, mAP50 khoảng 88% và mAP50-95 khoảng 57%. Các kết quả này cho thấy mô hình có khả năng nhận diện tương đối tốt các đối tượng gồm người điều khiển xe máy, người đội mũ bảo hiểm và người không đội mũ bảo hiểm trong điều kiện dữ liệu thử nghiệm.

Về mặt xử lý thời gian thực, đề tài đã xây dựng thành công hệ thống tiếp nhận dữ liệu từ webcam hoặc video, thực hiện phát hiện đối tượng trên từng khung hình và hiển thị kết quả trực tiếp trên giao diện. Hệ thống có khả năng hoạt động liên tục trên các video giao thông thực tế và cung cấp kết quả phát hiện theo thời gian thực.

Về mặt theo dõi đối tượng, thuật toán ByteTrack đã được tích hợp để duy trì mã định danh (ID) cho các đối tượng xuất hiện qua nhiều khung hình liên tiếp. Điều này cho phép hệ thống theo dõi quá trình di chuyển của đối tượng và tạo nền tảng cho việc xác nhận vi phạm dựa trên nhiều khung hình thay vì chỉ dựa trên kết quả của một khung hình đơn lẻ.

Về mặt xử lý vi phạm, đề tài đã xây dựng cơ chế xác nhận vi phạm dựa trên lịch sử theo dõi đối tượng qua nhiều frame liên tiếp. Phương pháp này giúp giảm

đáng kể các trường hợp cảnh báo sai do dự đoán không chính xác ở từng khung hình riêng lẻ, đồng thời nâng cao độ tin cậy của dữ liệu vi phạm được ghi nhận.

Về mặt quản lý dữ liệu, hệ thống đã thực hiện tự động lưu ảnh vi phạm, ghi nhận thông tin đối tượng, thời gian phát hiện và đường dẫn ảnh vào tệp dữ liệu CSV. Đồng thời, cơ chế lọc trùng lặp dựa trên khoảng cách không gian và thời gian đã được triển khai nhằm hạn chế việc ghi nhận nhiều lần đối với cùng một đối tượng vi phạm.

Về mặt giao diện người dùng, đề tài đã xây dựng thành công giao diện giám sát bằng Streamlit với các chức năng hiển thị video thời gian thực, kết quả phát hiện đối tượng, số lượng vi phạm, tốc độ xử lý (FPS) và lịch sử vi phạm. Giao diện hỗ trợ người dùng theo dõi và tra cứu dữ liệu vi phạm một cách trực quan.

Nhìn chung, đề tài đã xây dựng được một hệ thống hoàn chỉnh bao gồm các thành phần từ nhận dạng đối tượng, theo dõi, xác nhận vi phạm, lưu trữ dữ liệu đến giao diện quản lý. Các kết quả thực nghiệm cho thấy hệ thống có khả năng ứng dụng trong các bài toán giám sát giao thông thông minh và là cơ sở để tiếp tục nghiên cứu, phát triển trong các giai đoạn tiếp theo.

5.2. Hướng phát triển

Mặc dù đề tài đã xây dựng thành công hệ thống phát hiện và cảnh báo người điều khiển xe máy không đội mũ bảo hiểm, vẫn còn một số hướng phát triển khả thi nhằm nâng cao hiệu quả hoạt động và khả năng ứng dụng thực tế của hệ thống trong tương lai.

Thứ nhất, có thể tiếp tục mở rộng và đa dạng hóa bộ dữ liệu huấn luyện. Trong quá trình thử nghiệm, hệ thống vẫn gặp khó khăn đối với các đối tượng có kích thước nhỏ, bị che khuất hoặc xuất hiện trong điều kiện ánh sáng không thuận lợi. Việc bổ sung thêm dữ liệu từ nhiều môi trường giao thông khác nhau như ban đêm, trời mưa, mật độ phương tiện cao hoặc các góc quay camera khác nhau sẽ giúp mô hình nâng cao khả năng tổng quát hóa và cải thiện độ chính xác phát hiện.

Thứ hai, có thể nghiên cứu và đánh giá các phiên bản mô hình YOLO mới hơn hoặc thực hiện tối ưu siêu tham số huấn luyện để nâng cao hiệu suất nhận

dạng. Hướng phát triển này phù hợp với kiến trúc hiện tại của hệ thống do mô hình phát hiện đối tượng được thiết kế độc lập và có thể thay thế hoặc nâng cấp mà không cần thay đổi lớn các thành phần còn lại.

Thứ ba, hệ thống có thể được cải tiến về khả năng theo dõi đối tượng. Kết quả thực nghiệm cho thấy thuật toán ByteTrack đôi khi vẫn xảy ra hiện tượng thay đổi ID hoặc mất dấu đối tượng khi mật độ giao thông cao hoặc khi đối tượng bị che khuất trong thời gian ngắn. Việc tối ưu tham số theo dõi hoặc đánh giá thêm các phương pháp tracking phù hợp hơn có thể giúp nâng cao độ ổn định của quá trình theo dõi.

Thứ tư, có thể mở rộng chức năng quản lý dữ liệu bằng cách tích hợp cơ sở dữ liệu chuyên dụng thay cho việc lưu trữ bằng tệp CSV. Hướng phát triển này cho phép quản lý số lượng lớn dữ liệu vi phạm, hỗ trợ tìm kiếm, thống kê và truy xuất thông tin hiệu quả hơn khi hệ thống được triển khai trong thời gian dài.

Thứ năm, hệ thống có thể được triển khai thử nghiệm trên các nguồn camera giao thông thực tế hoặc camera IP để đánh giá khả năng hoạt động trong môi trường thực tế. Đây là bước phát triển phù hợp với mục tiêu ứng dụng của đề tài và giúp kiểm chứng hiệu quả của hệ thống trong điều kiện vận hành liên tục.

Cuối cùng, dựa trên nền tảng nhận dạng đối tượng đã xây dựng, hệ thống có thể được mở rộng để phát hiện thêm các hành vi vi phạm giao thông khác như chở quá số người quy định, đi sai làn đường hoặc vượt đèn đỏ. Việc mở rộng này có thể thực hiện thông qua việc bổ sung dữ liệu huấn luyện và xây dựng thêm các luật xử lý tương ứng trên kiến trúc hệ thống hiện có.

Những hướng phát triển trên đều dựa trên kiến trúc và kết quả đã đạt được của đề tài, đồng thời có tính khả thi trong quá trình nghiên cứu và triển khai tiếp theo nhằm nâng cao hiệu quả ứng dụng của hệ thống trong lĩnh vực giám sát giao thông thông minh.

TÀI LIỆU THAM KHẢO

- [1] Nguyễn Hữu Tuấn và Vũ Thanh Hương, "Ứng dụng AI trong phát hiện người đi xe máy không đội mũ bảo hiểm," *Tạp chí Khoa học Công nghệ Hàng hải*, 2025.
- [2] J. Redmon, S. Divvala, R. Girshick, và A. Farhadi, "You Only Look Once: Unified, Real-Time Object Detection," trong *IEEE Conference on Computer Vision and Pattern Recognition*, 2016.
- [3] R. Khanam và M. Hussain, "YOLOv11: An Overview of the Key Architectural Enhancements," *arXiv*, 2024.
- [4] Ultralytics. YOLO11 Documentation. Đường dẫn: <https://docs.ultralytics.com>.
- [5] Abdullah Dataset. No Helmet – No Ride Dataset, Roboflow Universe. Đường dẫn: <https://universe.roboflow.com/abdullah-kqdi3/no-helmet-no-ride>.
- [6] Lương Thái Bảo, Phan Minh Khôi, và Đào Tiên Đạt. CS114.ML_HelmetDetection. Đường dẫn: https://github.com/d3m0l15h/CS114.ML_HelmetDetection
- [7] taoducminh. YOLOV10_Safety_Helmet_Detection. Đường dẫn: https://github.com/taoducminh/YOLOV10_Safety_Helmet_Detection.

DATN-LienMai

BÁO CÁO ĐỘC SÁNG

6%

CHỈ SỐ TƯƠNG ĐỒNG

7%

NGUỒN INTERNET

7%

ẤN PHẨM XUẤT BẢN

2%

BÀI CỦA HỌC SINH

NGUỒN CHÍNH

1

www.ctu.edu.vn

Nguồn Internet

3%

2

Ton Duc Thang University

Xuất bản

1%

3

Submitted to Vietnam Maritime University

Bài của Học sinh

1%

4

gwdu.ptit.edu.vn

Nguồn Internet

1%

5

Submitted to Thai Nguyen University

Bài của Học sinh

1%

6

Submitted to Ton Duc Thang University

Bài của Học sinh

1%

Loại trừ Trích dẫn Mở

Loại trừ trùng khớp < 1%

Loại trừ mục lục tham khảo