

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH
KHOA ĐIỆN - ĐIỆN TỬ
BỘ MÔN KỸ THUẬT MÁY TÍNH



ĐỒ ÁN TỐT NGHIỆP
NGÀNH CÔNG NGHỆ KỸ THUẬT MÁY TÍNH
Đề tài
TINH CHỈNH VÀ TRIỂN KHAI MÔ HÌNH TEXT-TO-SPEECH
DỰA TRÊN KIẾN TRÚC ZIPVOICE

GVHD : TS. VŨ CHÍ CƯỜNG

Sinh viên : NGUYỄN NGỌC GIA MÃN
MSSV: 22119197
TRẦN THỦY TIÊN
MSSV: 22119238

TP. HỒ CHÍ MINH – 06/2026

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH
KHOA ĐIỆN - ĐIỆN TỬ
BỘ MÔN KỸ THUẬT MÁY TÍNH



HCM-UTE

ĐỒ ÁN TỐT NGHIỆP

NGÀNH CÔNG NGHỆ KỸ THUẬT MÁY TÍNH

Đề tài

**TINH CHỈNH VÀ TRIỂN KHAI MÔ HÌNH TEXT-TO-SPEECH
DỰA TRÊN KIẾN TRÚC ZIPVOICE**

GVHD : TS. VŨ CHÍ CƯỜNG

Sinh viên : NGUYỄN NGỌC GIA MÃN
MSSV: 22119197
TRẦN THỦY TIÊN
MSSV: 22119238

TP. HỒ CHÍ MINH – 06/2026



TP. HCM, ngày 12 tháng 06 năm 2026

NHIỆM VỤ ĐỒ ÁN TỐT NGHIỆP

Họ và tên sinh viên: Nguyễn Ngọc Gia Mẫn

MSSV: 22119197

Trần Thủy Tiên

MSSV: 22119238

Ngành: Công nghệ kỹ thuật máy tính

Lớp: 221191A

Giảng viên hướng dẫn: TS. Vũ Chí Cường

Ngày nhận đề tài: 05/03/2026

Ngày nộp đề tài: 25/06/2026

1. Tên đề tài: Tinh chỉnh và triển khai mô hình Text-to-speech dựa trên kiến trúc ZipVoice.

2. Các số liệu, tài liệu ban đầu

- Kiến thức về Học sâu, Xử lý tín hiệu số và Text-to-Speech.
- Tài liệu nghiên cứu, mã nguồn ZipVoice và các tập dữ liệu tiếng nói tiếng Việt.

3. Nội dung thực hiện đề tài

- Tìm hiểu kiến trúc ZipVoice và các kỹ thuật liên quan. Tiền xử lý dữ liệu tiếng nói tiếng Việt.
- Fine-tune và distillation mô hình ZipVoice trên dữ liệu tiếng Việt. Đánh giá chất lượng và hiệu năng mô hình.
- Triển khai hệ thống dưới dạng REST API trong môi trường Docker.
- Hoàn thiện báo cáo đồ án tốt nghiệp.

4. Lời cam đoan

Nhóm thực hiện xin cam đoan KLTN là công trình nghiên cứu của nhóm, dưới sự hướng dẫn của Tiến sĩ Vũ Chí Cường. Kết quả công bố trong KLTN là trung thực và không sao chép từ bất kỳ công trình nào khác.

Tp. HCM, ngày 25 tháng 06 năm 2026

Xác nhận của Bộ Môn

Giảng viên hướng dẫn

(Ký, ghi rõ họ tên và học hàm – học vị)

BẢN NHẬN XÉT KHÓA LUẬN TỐT NGHIỆP

(Dành cho giảng viên hướng dẫn)

Đề tài: TÍNH CỤNH YÃ TRIỂN KHAI MÔ HÌNH TEX-TO-SPEECH DƯA
TRÊN KIẾN TRÚC ZIP VOICE

Sinh viên: + Nguyễn Ngọc Gia Mân
+ Trần Thùy Liên

MSSV: 22119197

MSSV: 22119238

Hướng dẫn: Tiêu Sĩ Vũ Chí Cường

Nhận xét bao gồm các nội dung sau đây:

1. Tính hợp lý trong cách đặt vấn đề và giải quyết vấn đề; ý nghĩa khoa học và thực tiễn:
Đặt vấn đề rõ ràng, mục tiêu cụ thể; đề tài có tính mới, cấp thiết; đề tài có khả năng ứng dụng, tính sáng tạo.

Đặt vấn đề

2. Phương pháp thực hiện/ phân tích/ thiết kế:

Phương pháp hợp lý và tin cậy dựa trên cơ sở lý thuyết; có phân tích và đánh giá phù hợp; có tính mới và tính sáng tạo.

Phương pháp hợp lý

3. Kết quả thực hiện/ phân tích và đánh giá kết quả/ kiểm định thiết kế:

Phù hợp với mục tiêu đề tài; phân tích và đánh giá/ kiểm thử thiết kế hợp lý; có tính sáng tạo/ kiểm định chặt chẽ và đảm bảo độ tin cậy.

Kết quả đạt

4. Kết luận và đề xuất:

Kết luận phù hợp với cách đặt vấn đề, đề xuất mang tính cải tiến và thực tiễn; kết luận có đóng góp mới mẻ, đề xuất sáng tạo và thuyết phục.

Kết luận đạt yêu cầu

5. Hình thức trình bày và bố cục báo cáo:

Văn phong nhất quán, bố cục hợp lý, cấu trúc rõ ràng, đúng định dạng mẫu; có tính hấp dẫn, thể hiện năng lực tốt, văn bản trau chuốt.

Đạt yêu cầu

6. Kỹ năng chuyên nghiệp và tính sáng tạo:

Thể hiện các kỹ năng giao tiếp, kỹ năng làm việc nhóm, và các kỹ năng chuyên nghiệp khác trong việc thực hiện đề tài.

Kỹ năng tốt

7. Tài liệu trích dẫn

Tính trung thực trong việc trích dẫn tài liệu tham khảo; tính phù hợp của các tài liệu trích dẫn; trích dẫn theo đúng chỉ dẫn APA.

Đạt

8. Đánh giá về sự trùng lặp của đề tài

Cần khẳng định đề tài có trùng lặp hay không? Nếu có, đề nghị ghi rõ mức độ, tên đề tài, nơi công bố, năm công bố của đề tài đã công bố.

Đạt

9. Những nhược điểm và thiếu sót, những điểm cần được bổ sung và chỉnh sửa*

Nhận xét của giảng viên về đề tài

10. Nhận xét tinh thần, thái độ học tập, nghiên cứu của sinh viên

Tốt

Đề nghị của giảng viên hướng dẫn

Ghi rõ: "Báo cáo đạt/ không đạt yêu cầu của một khóa luận tốt nghiệp kỹ sư, và được phép/ không được phép bảo vệ khóa luận tốt nghiệp"

Báo cáo đạt yêu cầu và được phép bảo vệ khóa luận tốt nghiệp

Tp. HCM, ngày 24 tháng 6, năm 2026

Người nhận xét
(Ký và ghi rõ họ tên)

Vũ Chí Cường

* Giảng viên hướng dẫn có thể ghi tiếp vào mặt sau

LỜI CẢM ƠN

Lời đầu tiên, nhóm sinh viên thực hiện đề tài xin trân trọng cảm ơn Ban Giám hiệu Trường Đại học Công nghệ Kỹ thuật TP.HCM, Khoa Điện - Điện tử cùng Bộ môn Công nghệ Kỹ thuật Máy tính đã tận tâm giảng dạy, trang bị nền tảng kiến thức vững chắc và tạo mọi điều kiện thuận lợi cho nhóm trong suốt quá trình học tập.

Đặc biệt, nhóm xin gửi lời tri ân sâu sắc nhất đến Thầy Vũ Chí Cường, người đã trực tiếp hướng dẫn đồ án. Nhờ sự chỉ bảo tận tình, định hướng chuyên môn sắc bén và những giải pháp kỹ thuật hiệu quả từ Thầy, nhóm đã tháo gỡ được nhiều khó khăn trong lĩnh vực Xử lý tiếng nói để triển khai thành công mô hình ZipVoice.

Bên cạnh đó, nhóm cũng xin gửi lời cảm ơn chân thành đến gia đình và bạn bè đã luôn động viên, hỗ trợ tinh thần trong suốt thời gian thực hiện dự án.

Do giới hạn về thời gian và kinh nghiệm thực tiễn, đồ án chắc chắn khó tránh khỏi những thiếu sót. Nhóm rất mong nhận được sự đánh giá, góp ý và phản biện từ Hội đồng quý Thầy Cô để đề tài được hoàn thiện hơn, đồng thời giúp các thành viên đúc kết thêm kinh nghiệm quý giá cho chặng đường tương lai.

Một lần nữa, nhóm sinh viên thực hiện đề tài xin kính chúc quý Thầy Cô luôn dồi dào sức khỏe, tràn đầy nhiệt huyết và tiếp tục gặt hái thêm nhiều thành tựu rực rỡ trong sự nghiệp cao quý của mình.

TÓM TẮT

Hiện nay, công nghệ Xử lý tiếng nói đã có những cải tiến đáng chú ý. Tuy nhiên, các hệ thống tổng hợp tiếng nói (Text-to-Speech - TTS) truyền thống thường vấp phải rào cản lớn về tính linh hoạt, đòi hỏi lượng dữ liệu khổng lồ và tốn kém tài nguyên để tái huấn luyện khi muốn mô phỏng một giọng nói mới. Từ thực tiễn đó, đề tài "Tinh chỉnh và triển khai mô hình Text-to-speech dựa trên kiến trúc ZipVoice" được thực hiện với mục tiêu xây dựng một hệ thống có khả năng tự động tạo ra giọng nói ổn định và sao chép đặc trưng âm học mà không cần tốn chi phí huấn luyện lại.

Mục tiêu của đề tài là tinh chỉnh mô hình mã nguồn mở ZipVoice trên các bộ dữ liệu tiếng Việt như VLSP, VIVOS và Mozilla Common Voice nhằm nâng cao chất lượng tổng hợp tiếng nói tiếng Việt. Đề tài tập trung cải thiện quá trình xử lý ngôn ngữ tiếng Việt thông qua chuẩn hóa văn bản và chuyển đổi G2P, đồng thời hỗ trợ nhân bản giọng nói (Zero-shot Voice Cloning) và tăng khả năng thích ứng với các phương ngữ Bắc, Trung, Nam thông qua dữ liệu huấn luyện đa dạng.

MỤC LỤC

DANH MỤC HÌNH	X
DANH MỤC BẢNG	XI
CÁC TỪ VIẾT TẮT	XII
CHƯƠNG 1 GIỚI THIỆU	1
1.1 GIỚI THIỆU	1
1.2 MỤC TIÊU ĐỀ TÀI	1
1.3 LÝ DO LỰA CHỌN MÔ HÌNH ZIPVOICE	2
1.4 PHƯƠNG PHÁP NGHIÊN CỨU ĐỀ TÀI	2
1.5 ĐIỂM MỚI CỦA ĐỀ TÀI	3
1.6 PHẠM VI NGHIÊN CỨU	3
1.7 BỐ CỤC QUYỀN BÁO CÁO	3
CHƯƠNG 2 CƠ SỞ LÝ THUYẾT	5
2.1 TỔNG QUAN VỀ MÔ HÌNH TEXT-TO-SPEECH (TTS)	5
2.1.1 Kiến trúc chung của hệ thống TTS	5
2.1.2 Bài toán Zero-shot TTS và Voice Cloning	6
2.2 XỬ LÝ TÍN HIỆU SỐ VÀ ĐẶC TRƯNG ÂM THANH	6
2.2.1 Biến đổi Fourier ngắn hạn (STFT)	7
2.2.2 Đặc trưng Mel-spectrogram	8
2.2.3 So sánh Linear spectrogram và Mel-spectrogram	8
2.3 CÁC MÔ HÌNH HỌC SÂU NỀN TẢNG (DEEP LEARNING FOUNDATIONS)	
9	
2.3.1 Mạng Zipformer	9
2.3.2 Nguyên lý Conditional Flow Matching (CFM)	10
2.3.3 Knowledge Distillation trong TTS	11
2.4 KIẾN TRÚC CHI TIẾT HỆ THỐNG ZIPVOICE	13
2.4.1 Cấu trúc tổng thể của hệ thống ZipVoice	13
2.4.2 Trích xuất đặc trưng người nói (Speaker Embedding)	14
2.4.3 Cơ chế kết hợp đặc trưng (Fusion Mechanism)	14

2.4.4	Cơ chế Average Upsampling.....	15
2.4.5	Vocoder tích hợp (Vocos)	16
2.5	CÁC PHƯƠNG PHÁP ĐÁNH GIÁ HỆ THỐNG.....	17
2.5.1	Đánh giá định lượng (Quantitative Metrics)	17
2.5.2	Đánh giá định tính (Qualitative Metrics)	17
CHƯƠNG 3 THIẾT KẾ VÀ THỰC HIỆN HỆ THỐNG		18
3.1	QUY TRÌNH THỰC NGHIỆM TỔNG THỂ VÀ KIẾN TRÚC MÃ NGUỒN	18
3.1.1	Quy trình thực nghiệm tổng thể.....	18
3.1.2	Kiến trúc mã nguồn hệ thống	19
3.1.3	Môi trường thực nghiệm.....	20
3.2	CHUẨN BỊ VÀ TIỀN XỬ LÝ DỮ LIỆU	21
3.2.1	Thu thập và phân tích tập dữ liệu	24
3.2.2	Dữ liệu thực nghiệm	24
3.2.3	Chuẩn hóa văn bản và G2P	25
3.2.4	Xử lý âm thanh	26
3.2.5	Đồng bộ chiều dài và Average Upsampling.....	26
3.2.6	Đóng gói Manifest và Trích xuất đặc trưng với Lhotse	27
3.3	FINE-TUNE TEACHER MODEL	28
3.3.1	Khởi tạo từ pretrained checkpoint	28
3.3.2	Thiết lập siêu tham số huấn luyện	28
3.3.3	Huấn luyện CFM trên dữ liệu tiếng Việt.....	29
3.3.4	Lưu checkpoint và chọn mô hình	30
3.4	TINH CHỈNH MÔ HÌNH STUDENT	31
3.4.1	Huấn luyện bằng Knowledge Distillation	31
3.4.2	Giảm số bước ODE và tối ưu suy luận.....	32
CHƯƠNG 4 TRIỂN KHAI VÀ THỬ NGHIỆM HỆ THỐNG		33
4.1	QUY TRÌNH THỰC NGHIỆM HỆ THỐNG	33
4.2	KIỂM THỬ MÔ HÌNH TEACHER	35
4.3	KIỂM THỬ MÔ HÌNH STUDENT	36

4.4	KIỂM THỬ KHẢ NĂNG VOICE CLONING TIẾNG VIỆT	36
4.5	TRIỂN KHAI HỆ THỐNG Suy luận.....	39
CHƯƠNG 5 KẾT QUẢ VÀ ĐÁNH GIÁ HỆ THỐNG		42
5.1	KẾT QUẢ THỰC NGHIỆM	42
5.1.1	Kết quả suy luận của Fine-tuned Teacher Model.....	42
5.1.2	Kết quả suy luận của Fine-tuned Student Model	43
5.2	ĐÁNH GIÁ MÔ HÌNH.....	43
5.2.1	Đánh giá định lượng	43
5.2.2	Đánh giá định tính	45
5.2.3	Đánh giá hiệu năng suy luận	46
5.3	ĐÁNH GIÁ MÔ HÌNH.....	46
5.4	SO SÁNH VỚI CÁC NGHIÊN CỨU LIÊN QUAN VÀ ĐÓNG GÓP CỦA	
ĐỀ TÀI		47
CHƯƠNG 6 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN		50
6.1	KẾT LUẬN	50
6.2	HƯỚNG PHÁT TRIỂN.....	51
TÀI LIỆU THAM KHẢO.....		52

DANH MỤC HÌNH

Hình 2.1: Kiến trúc tổng quát của hệ thống Text-to-Speech (TTS)	5
Hình 2.2: So sánh trực quan giữa phổ tuyến tính (Linear Spectrogram) và phổ Mel (Mel-Spectrogram) của cùng một tín hiệu âm thanh.....	8
Hình 2.3: Kiến trúc Zipformer [1]	9
Hình 2.4: Minh họa sự tối ưu quỹ đạo của OT-CFM so với các phương pháp Flow Matching tiêu chuẩn [2].....	10
Hình 2.5: Minh họa cơ chế Knowledge Distillation trong hệ thống TTS	12
Hình 2.6: Sơ đồ cấu trúc xử lý tổng thể của hệ thống ZipVoice	13
Hình 2.7: Sơ đồ kiến trúc tổng thể của hệ thống ZipVoice [4].....	15
Hình 2.8: Kiến trúc mạng Vocos với sự kết hợp của.....	16
Hình 3.1: Lưu đồ quy trình tinh chỉnh mô hình ZipVoice.....	18
Hình 3.2: Lưu đồ giải thuật quy trình tiền xử lý, dọn dẹp dữ liệu thô và đóng gói Manifest	24
Hình 3.3: Sơ đồ cơ chế căn chỉnh độ dài chuỗi bằng thuật toán Average Upsampling của ZipVoice so với phương pháp padding của E2-TTS	27
Hình 3.4: Lưu đồ giải thuật vòng lặp thực thi huấn luyện CFM hệ thống	30
Hình 4.1: Quy trình suy luận của hệ thống ZipVoice	33
Hình 4.2: Kết quả kiểm thử Speaker Similarity của Teacher Model.....	35
Hình 4.3: Kết quả kiểm thử Speaker Similarity của Student Model	36
Hình 4.4: Kiểm thử Voice Cloning tiếng Việt với giọng nam qua API	37
Hình 4.5: Kiểm thử Voice Cloning tiếng Việt với giọng nữ qua API	38
Hình 4.6: Docker Container triển khai hệ thống ZipVoice.....	39
Hình 4.7: Giao diện thử nghiệm hệ thống ZipVoice bằng Gradio	40
Hình 5.1: Kết quả suy luận của Fine-tuned Teacher Model	42
Hình 5.2: Kết quả suy luận của Fine-tuned Student Model.....	43

DANH MỤC BẢNG

Bảng 3.1: Các thành phần mã nguồn hệ thống	19
Bảng 3.2: Cấu hình môi trường thực nghiệm của hệ thống ZipVoice.....	20
Bảng 3.3: Các bộ dữ liệu tiếng Việt được khảo sát trong quá trình nghiên cứu.....	22
Bảng 3.4: Thông tin dữ liệu và quá trình fine-tuning mô hình.....	25
Bảng 3.5: Các siêu tham số huấn luyện Teacher Model.....	29
Bảng 3.6: So sánh số bước ODE giữa Teacher Model và Student Model.....	32
 Bảng 4.1: Cấu hình thực nghiệm hệ thống	 34
 Bảng 5.1: Kết quả đánh giá WER và CER trên tập kiểm thử.....	 44
Bảng 5.2: Kết quả đánh giá UTMOS.....	45
Bảng 5.3: So sánh hiệu năng suy luận giữa các mô hình ZipVoice	46
Bảng 5.4: So sánh đề tài và một số hệ thống Text-to-speech gần đây.....	47
Bảng 5.5: So sánh giữa mô hình ZipVoice pretrained và hệ thống đề xuất [8].....	49

CÁC TỪ VIẾT TẮT

Từ viết tắt	Tiếng Anh	Ý nghĩa
CER	Character Error Rate	Tỷ lệ lỗi ký tự
CUDA	Compute Unified Device Architecture	Nền tảng tính toán song song của NVIDIA
GPU	Graphics Processing Unit	Bộ xử lý đồ họa
MOS	Mean Opinion Score	Điểm đánh giá chủ quan chất lượng âm thanh
REST API	Representational State Transfer Application Programming Interface	Giao diện lập trình ứng dụng theo kiến trúc REST
SIM	Speaker Similarity	Độ tương đồng giọng nói
STFT	Short-Time Fourier Transform	Biến đổi Fourier thời gian ngắn
TTS	Text-to-Speech	Chuyển đổi văn bản thành tiếng nói
UTMOS	Universal Mean Opinion Score	Chỉ số đánh giá chất lượng âm thanh tự động
WER	Word Error Rate	Tỷ lệ lỗi từ

CHƯƠNG 1

GIỚI THIỆU

1.1 GIỚI THIỆU

Trong những năm gần đây, sự phát triển của Trí tuệ nhân tạo (AI) và Học sâu (Deep Learning) đã thúc đẩy nhiều bước tiến trong lĩnh vực Xử lý tiếng nói (Speech Processing), đặc biệt là các hệ thống Tổng hợp tiếng nói từ văn bản (Text-to-Speech - TTS). Các mô hình TTS hiện đại có khả năng tạo ra giọng nói tự nhiên và được ứng dụng rộng rãi trong trợ lý ảo, sách nói và các hệ thống tương tác.

Tuy nhiên, nhiều hệ thống TTS vẫn gặp hạn chế khi cần mô phỏng một giọng nói mới do phải sử dụng lượng lớn dữ liệu và thực hiện huấn luyện lại mô hình. Để khắc phục vấn đề này, mô hình ZipVoice ứng dụng kiến trúc Flow Matching cho phép thực hiện Zero-shot Voice Cloning từ một đoạn âm thanh tham chiếu ngắn mà không cần huấn luyện lại toàn bộ hệ thống.

Đề tài tập trung nghiên cứu, tinh chỉnh và triển khai mô hình ZipVoice cho tiếng Việt nhằm cải thiện chất lượng tổng hợp tiếng nói và khả năng ứng dụng thực tế của hệ thống TTS tiếng Việt.

1.2 MỤC TIÊU ĐỀ TÀI

Hiện nay, công nghệ xử lý tiếng nói đã có những bước phát triển mạnh mẽ, đặc biệt trong lĩnh vực tổng hợp tiếng nói từ văn bản (Text-to-Speech - TTS). Tuy nhiên, nhiều hệ thống TTS truyền thống vẫn gặp hạn chế về tính linh hoạt khi cần xây dựng hoặc mở rộng sang các giọng nói mới do yêu cầu lượng dữ liệu lớn và chi phí huấn luyện cao. Xuất phát từ thực tiễn đó, đề tài “Tinh chỉnh và triển khai mô hình Text-to-Speech dựa trên kiến trúc ZipVoice” được thực hiện nhằm nghiên cứu và triển khai một hệ thống có khả năng tổng hợp tiếng nói tự nhiên, đồng thời

hỗ trợ nhân bản giọng nói từ một đoạn âm thanh tham chiếu ngắn thông qua cơ chế Zero-shot Voice Cloning.

Mục tiêu chính của đề tài là nghiên cứu và triển khai hệ thống tổng hợp tiếng nói tiếng Việt dựa trên mô hình ZipVoice, đồng thời đánh giá khả năng thích ứng của mô hình đối với dữ liệu tiếng Việt và bài toán Zero-shot Voice Cloning. Đề tài tập trung tìm hiểu kiến trúc mô hình, quy trình xử lý văn bản và âm thanh, đồng thời cải thiện khả năng xử lý tiếng Việt thông qua các bước chuẩn hóa văn bản và chuyển đổi đầu vào phù hợp với hệ thống. Bên cạnh đó, đề tài đánh giá khả năng tổng hợp tiếng nói, nhân bản giọng nói và khả năng ứng dụng của mô hình trong các bài toán thực tế.

1.3 LÝ DO LỰA CHỌN MÔ HÌNH ZIPVOICE

ZipVoice sử dụng cơ chế Flow Matching giúp giảm số bước suy luận so với nhiều mô hình khuếch tán (Diffusion-based TTS) truyền thống, từ đó cải thiện tốc độ sinh tiếng nói trong khi vẫn duy trì chất lượng âm thanh tự nhiên. Ngoài ra, mô hình hỗ trợ Zero-shot Voice Cloning và Knowledge Distillation, phù hợp với yêu cầu triển khai thực tế.

1.4 PHƯƠNG PHÁP NGHIÊN CỨU ĐỀ TÀI

Đề tài khóa luận áp dụng kết hợp các phương pháp nghiên cứu lý thuyết và thực nghiệm. Nhóm tiến hành thu thập, tham khảo và phân tích các tài liệu, bài báo khoa học liên quan đến lĩnh vực xử lý tiếng nói (Speech Processing), hệ thống tổng hợp tiếng nói từ văn bản (Text-to-Speech - TTS) và mô hình ZipVoice nhằm xây dựng cơ sở lý thuyết cho đề tài.

Nhóm thực hiện thu thập và tiền xử lý dữ liệu tiếng Việt, bao gồm chuẩn hóa văn bản, xử lý âm thanh và chuyển đổi văn bản sang chuỗi âm vị phục vụ quá trình huấn luyện mô hình. Sau đó, mô hình ZipVoice được fine-tune trên các bộ dữ liệu tiếng Việt để nâng cao khả năng tổng hợp, nhân bản giọng nói.

Hệ thống được đánh giá thông qua các tiêu chí định lượng và định tính như tỷ lệ lỗi từ (WER), tốc độ suy luận và điểm đánh giá chất lượng âm thanh (MOS) để kiểm tra độ rõ lời, tính ổn định và mức độ tương đồng giọng nói của hệ thống.

1.5 ĐIỂM MỚI CỦA ĐỀ TÀI

Đề tài nghiên cứu khả năng thích nghi của mô hình ZipVoice đối với dữ liệu tiếng Việt thông qua quá trình fine-tuning và đánh giá thực nghiệm trên các bộ dữ liệu tiếng Việt.

1.6 PHẠM VI NGHIÊN CỨU

Đề tài tập trung nghiên cứu và triển khai hệ thống tổng hợp tiếng nói tiếng Việt dựa trên mô hình ZipVoice cho bài toán Zero-shot Voice Cloning. Dữ liệu sử dụng trong quá trình nghiên cứu là các tập dữ liệu tiếng Việt phục vụ bài toán Text-to-Speech, bao gồm các cặp văn bản và âm thanh đã được gán nhãn tương ứng. Quá trình tiền xử lý bao gồm chuẩn hóa văn bản, kiểm tra chất lượng âm thanh, chuyển đổi tần số lấy mẫu và xây dựng tập token phục vụ huấn luyện mô hình.

Hệ thống được xây dựng để xử lý các câu hoặc đoạn văn bản ngắn và thực hiện nhân bản giọng nói dựa trên đoạn âm thanh tham chiếu ngắn. Đề tài tập trung vào việc tinh chỉnh (Fine-tuning) mô hình có sẵn, không nghiên cứu thiết kế kiến trúc mạng mới hay huấn luyện mô hình từ đầu.

Quá trình huấn luyện và đánh giá mô hình được thực hiện trên nền tảng Cloud GPU. Chất lượng hệ thống được đánh giá thông qua các chỉ số định lượng như WER, CER và đánh giá cảm nhận người nghe thông qua MOS.

1.7 BỐ CỤC QUYỀN BÁO CÁO

Nội dung báo cáo bao gồm các chương sau:

- Chương 1: Tổng quan. Trình bày bối cảnh, lý do chọn đề tài, mục tiêu, phạm vi và phương pháp nghiên cứu.
- Chương 2: Cơ sở lý thuyết. Giới thiệu các kiến thức nền tảng về hệ thống TTS, Zero-shot Voice Cloning và mô hình ZipVoice.
- Chương 3: Thiết kế và thực hiện hệ thống. Trình bày kiến trúc hệ thống, quy trình xử lý dữ liệu và các thành phần chính của mô hình.
- Chương 4: Triển khai và thử nghiệm hệ thống. Trình bày quá trình fine-tune mô hình, cấu hình môi trường và các kịch bản thử nghiệm.

- Chương 5: Kết quả và đánh giá hệ thống. Trình bày kết quả thực nghiệm và đánh giá chất lượng hệ thống qua các chỉ số định lượng và định tính.
- Chương 6: Kết luận và hướng phát triển. Tổng kết kết quả đạt được, nêu hạn chế và đề xuất hướng cải tiến trong tương lai.

CHƯƠNG 2


CƠ SỞ LÝ THUYẾT

2.1 TỔNG QUAN VỀ MÔ HÌNH TEXT-TO-SPEECH (TTS)

2.1.1 Kiến trúc chung của hệ thống TTS

Hệ thống Text-to-Speech (TTS) hiện đại có nhiệm vụ chuyển đổi văn bản đầu vào thành tín hiệu tiếng nói tự nhiên. Phần lớn các hệ thống TTS hiện nay được xây dựng dựa trên ba thành phần chính gồm Text Frontend, Acoustic Model và Neural Vocoder.

Hình 2.1 minh họa kiến trúc tổng quát của hệ thống Text-to-Speech.



Hình 2.1: Kiến trúc tổng quát của hệ thống Text-to-Speech (TTS)

Text Frontend thực hiện các bước xử lý văn bản như chuẩn hóa văn bản (Text Normalization), chuyển đổi văn bản thành chuỗi phoneme hoặc token và tạo các đặc trưng ngôn ngữ phục vụ cho quá trình tổng hợp tiếng nói.

Acoustic Model có nhiệm vụ học mối quan hệ giữa đặc trưng ngôn ngữ và đặc trưng âm học, để sinh ra Mel-Spectrogram hoặc các biểu diễn âm học trung gian.

Neural Vocoder tiếp nhận Mel-Spectrogram và chuyển đổi thành tín hiệu âm thanh dạng sóng (Waveform) để tạo ra tiếng nói đầu ra.

2.1.2 Bài toán Zero-shot TTS và Voice Cloning

Voice Cloning là kỹ thuật tái tạo giọng nói của một người dựa trên một hoặc nhiều đoạn âm thanh tham chiếu. Mục tiêu của Voice Cloning là duy trì đặc trưng người nói trong khi vẫn tạo ra nội dung tiếng nói mới.

Trong các hệ thống TTS truyền thống, việc tạo giọng nói mới thường yêu cầu thu thập lượng lớn dữ liệu và huấn luyện lại mô hình cho từng người nói. Điều này làm tăng chi phí dữ liệu và thời gian triển khai.

Để khắc phục hạn chế trên, các hệ thống Zero-shot TTS được phát triển nhằm cho phép mô hình tổng hợp giọng nói mới mà không cần huấn luyện lại. Thay vào đó, mô hình chỉ cần một đoạn âm thanh tham chiếu ngắn để trích xuất đặc trưng người nói dưới dạng Speaker Embedding hoặc Speaker Condition.

Nhờ đó, hệ thống có thể tạo ra tiếng nói mang nội dung văn bản đầu vào nhưng vẫn giữ được đặc trưng của người nói tham chiếu. Đây cũng là bài toán mà mô hình ZipVoice hướng tới giải quyết.

Để xây dựng hệ thống TTS có khả năng tổng hợp và nhân bản giọng nói hiệu quả, tín hiệu âm thanh cần được chuyển đổi sang các dạng đặc trưng phù hợp cho quá trình học máy. Vì vậy, phần tiếp theo trình bày các kỹ thuật xử lý tín hiệu số và đặc trưng âm thanh được sử dụng trong hệ thống TTS hiện đại.

2.2 XỬ LÝ TÍN HIỆU SỐ VÀ ĐẶC TRƯNG ÂM THANH

Trong các hệ thống tổng hợp tiếng nói hiện đại, tín hiệu âm thanh cần được chuyển đổi từ dạng sóng thời gian sang dạng đặc trưng số để mô hình học sâu có

thể xử lý hiệu quả. Quá trình này giúp trích xuất các thông tin quan trọng của giọng nói như tần số, năng lượng và ngữ điệu.

2.2.1 Biến đổi Fourier ngắn hạn (STFT)

Tín hiệu âm thanh trong thực tế tồn tại dưới dạng sóng liên tục theo thời gian. Để máy tính và các mô hình học sâu có thể xử lý, tín hiệu này cần được chuyển đổi sang dạng số thông qua quá trình lấy mẫu (sampling).

Do tín hiệu tiếng nói thay đổi theo thời gian, hệ thống sử dụng phép biến đổi Fourier ngắn hạn (STFT) để phân tích đặc trưng tần số trong từng khoảng thời gian ngắn. STFT chuyển tín hiệu từ miền thời gian sang miền tần số, tạo ra phổ tần số biểu diễn sự phân bố năng lượng của tín hiệu theo thời gian. Công thức tổng quát của STFT được biểu diễn như sau:

$$X(m, \omega) = \sum_{n=-\infty}^{\infty} x[n] \times \omega[n - mR] \times e^{-j\omega n} \quad (2.1)$$

Trong đó:

- $x[n]$ là tín hiệu âm thanh đầu vào trong miền thời gian.
- $\omega[n - mR]$ là hàm cửa sổ (thường là cửa sổ Hann để giảm rò rỉ phổ) được dịch chuyển một khoảng R (hop size).
- $e^{-j\omega n}$ là thành phần biến đổi Fourier, chuyển đổi tín hiệu sang miền tần số.
- $X(m, \omega)$ là giá trị phức biểu diễn biên độ và pha của tần số ω tại thời điểm m .
- R là bước dịch giữa hai khung liên tiếp.

STFT hoạt động bằng cách chia tín hiệu âm thanh thành nhiều khung nhỏ có chồng lấn, sau đó thực hiện biến đổi Fourier trên từng khung để tạo ra phổ tần số theo thời gian. Kết quả thu được là phổ tuyến tính (Linear Spectrogram), biểu diễn sự phân bố năng lượng của tín hiệu ở các dải tần khác nhau.

Trong hệ thống ZipVoice, Mel-Spectrogram được sử dụng làm biểu diễn âm học trung gian. Đối với âm thanh tham chiếu, Mel-Spectrogram được dùng để trích xuất đặc trưng người nói. Đối với quá trình tổng hợp tiếng nói, Mel-Spectrogram là đầu ra của mô hình CFM trước khi được chuyển đổi thành tín hiệu âm thanh thông qua vocoder Vocos.

2.2.2 Đặc trưng Mel-spectrogram


Sau khi thu được Linear Spectrogram từ STFT, hệ thống tiếp tục chuyển đổi sang Mel-Spectrogram bằng cách ánh xạ tần số sang thang Mel. Đây là thang đo mô phỏng cách con người cảm nhận âm thanh, giúp nhấn mạnh các dải tần quan trọng đối với tiếng nói.

Mel-Spectrogram giúp giảm số chiều dữ liệu nhưng vẫn giữ được các đặc trưng âm học cần thiết cho quá trình tổng hợp tiếng nói. Vì vậy, đây là dạng đặc trưng được sử dụng phổ biến trong các hệ thống TTS hiện đại, bao gồm ZipVoice.

Trong đề tài này, Mel-Spectrogram được sử dụng làm đầu vào cho mô hình và cũng là đặc trưng trung gian để tái tạo lại tín hiệu âm thanh thông qua Vocoder.

2.2.3 So sánh Linear spectrogram và Mel-spectrogram

Hình 2.2 minh họa sự khác biệt giữa Linear Spectrogram và Mel-Spectrogram của cùng một tín hiệu âm thanh.



Hình 2.2: So sánh trực quan giữa phổ tuyến tính (Linear Spectrogram) và phổ Mel (Mel-Spectrogram) của cùng một tín hiệu âm thanh

Hình 2.2 cho thấy Mel-Spectrogram có khả năng làm nổi bật các đặc trưng chính của tiếng nói và loại bỏ bớt thông tin dư thừa so với phổ tuyến tính. Nhờ đó, mô hình có thể học đặc trưng âm học hiệu quả hơn và giảm chi phí tính toán trong quá trình huấn luyện.

Vì vậy, Mel-Spectrogram được lựa chọn làm đặc trưng âm học phổ biến trong nhiều hệ thống TTS hiện đại, bao gồm ZipVoice.

Sau khi chuyển đổi tín hiệu âm thanh sang dạng đặc trưng Mel-Spectrogram, hệ thống cần các mô hình học sâu để học mối quan hệ giữa văn bản, đặc trưng người nói và đặc trưng âm học. Vì vậy, phần tiếp theo trình bày các kiến trúc học sâu nền tảng được sử dụng trong ZipVoice.


2.3 CÁC MÔ HÌNH HỌC SÂU NỀN TẢNG (DEEP LEARNING FOUNDATIONS)

Việc trích xuất biểu diễn đặc trưng phức tạp từ văn bản và xử lý chuỗi tín hiệu âm thanh có cấu trúc thời gian dài đòi hỏi kiến trúc mạng nơ-ron có khả năng biểu diễn cao. Để xây dựng hệ thống Text-to-Speech có khả năng tổng hợp tiếng nói tự nhiên và hỗ trợ Zero-shot Voice Cloning, ZipVoice sử dụng nhiều kỹ thuật học sâu khác nhau. Trong đó, Zipformer được sử dụng để mã hóa thông tin ngôn ngữ từ văn bản đầu vào, Conditional Flow Matching được sử dụng để sinh đặc trưng âm học và Knowledge Distillation được áp dụng nhằm tối ưu tốc độ suy luận.

2.3.1 Mạng Zipformer

Zipformer là kiến trúc mạng nơ-ron được đề xuất bởi Yao et al. (2023) [1], nhằm giảm chi phí tính toán và bộ nhớ so với các kiến trúc Transformer và Conformer truyền thống. Kiến trúc này sử dụng cơ chế xử lý đa tỷ lệ, cho phép mô hình khai thác thông tin ngữ cảnh hiệu quả trong khi vẫn duy trì tốc độ xử lý cao.

Cấu trúc tổng thể của Zipformer được minh họa trong Hình 2.3.




Hình 2.3: Kiến trúc Zipformer [1]

Hình 2.3, dữ liệu đầu vào được xử lý qua nhiều tầng với các mức độ phân giải khác nhau. Các tầng Downsample giúp giảm chiều dài chuỗi để giảm chi phí tính toán, trong khi các tầng Upsample hỗ trợ khôi phục thông tin cần thiết cho các bước xử lý tiếp theo. Cách tổ chức này giúp mô hình cân bằng giữa hiệu quả tính toán và khả năng biểu diễn đặc trưng.

Trong hệ thống ZipVoice, Zipformer được sử dụng làm bộ mã hóa để trích xuất đặc trưng ngôn ngữ từ chuỗi phoneme đầu vào. Chuỗi phoneme hoặc token sau khi được ánh xạ thành embedding sẽ được đưa qua các khối Zipformer để học ngữ cảnh dài hạn giữa các thành phần trong câu. Đầu ra của Zipformer là các biểu diễn ngôn ngữ có ngữ nghĩa cao (linguistic representation), được sử dụng làm điều kiện đầu vào cho mô hình Conditional Flow Matching ở các bước tiếp theo.

2.3.2 Nguyên lý Conditional Flow Matching (CFM)

Conditional Flow Matching (CFM) là phương pháp sinh dữ liệu bằng cách học một trường vector mô tả quá trình biến đổi liên tục từ dữ liệu nhiễu sang dữ liệu mục tiêu. Trong ZipVoice, mô hình không sinh trực tiếp tín hiệu âm thanh dạng sóng mà sinh Mel-Spectrogram. Quá trình sinh Mel-Spectrogram được điều kiện hóa bởi đặc trưng văn bản từ Zipformer và đặc trưng người nói được trích xuất từ âm thanh tham chiếu. Mô hình học một trường vector (vector field) dự đoán hướng biến đổi của dữ liệu tại từng thời điểm t trong khoảng $[0,1]$ [2].



Hình 2.4: Minh họa sự tối ưu quỹ đạo của OT-CFM so với các phương pháp Flow Matching tiêu chuẩn [2]

Hình 2.4 minh họa quá trình biến đổi từ dữ liệu nhiễu ban đầu thành Mel-Spectrogram mục tiêu thông qua các quỹ đạo được điều kiện hóa bởi nội dung văn bản và đặc trưng giọng nói. Trong quá trình huấn luyện, mô hình học cách dự đoán hướng biến đổi của dữ liệu tại từng thời điểm, từ đó xây dựng một trường vector mô tả toàn bộ quá trình chuyển đổi từ nhiễu sang dữ liệu đích.


Khác với các mô hình Diffusion truyền thống phải thực hiện quá trình khử nhiễu qua nhiều bước lặp liên tiếp, CFM học trực tiếp quỹ đạo biến đổi giữa dữ liệu nguồn và dữ liệu mục tiêu. Nhờ đó, mô hình có thể sử dụng ít bước suy luận hơn trong quá trình sinh dữ liệu mà vẫn duy trì chất lượng đầu ra.

Trong giai đoạn suy luận, mô hình giải phương trình vi phân thường (Ordinary Differential Equation - ODE) theo các bước thời gian liên tiếp để chuyển đổi nhiều ban đầu thành Mel-Spectrogram. Việc giảm số bước giải ODE giúp rút ngắn thời gian tổng hợp tiếng nói so với các phương pháp Diffusion truyền thống, đồng thời vẫn đảm bảo chất lượng và độ tự nhiên của âm thanh được sinh ra.

2.3.3 Knowledge Distillation trong TTS

Trong phương pháp này, Teacher Model đóng vai trò là mô hình tham chiếu có chất lượng tổng hợp cao, trong khi Student Model được huấn luyện để học cách xấp xỉ hành vi sinh dữ liệu của Teacher Model với chi phí tính toán thấp hơn. Thay vì học trực tiếp từ dữ liệu gốc, Student Model học từ các biểu diễn hoặc kết quả sinh ra bởi Teacher Model, giúp quá trình học hiệu quả hơn [3].

Hình 2.5 minh họa nguyên lý chung của Knowledge Distillation, trong đó mô hình Student học cách mô phỏng đầu ra hoặc biểu diễn trung gian của mô hình Teacher. Mục tiêu là giúp Student kế thừa tri thức từ Teacher để giảm kích thước mô hình hoặc giảm chi phí suy luận trong khi vẫn duy trì chất lượng đầu ra ở mức chấp nhận được.



Hình 2.5: Minh họa cơ chế Knowledge Distillation trong hệ thống TTS [3]

Trong hệ thống ZipVoice, Knowledge Distillation được sử dụng để huấn luyện Student Model từ Teacher Model đã được fine-tune. Mục tiêu là giúp Student Model học được quá trình sinh Mel-Spectrogram tương tự Teacher Model nhưng với số bước giải ODE ít hơn. Nhờ đó, Student Model được thiết kế với số bước suy luận ít hơn Teacher Model trong khi vẫn duy trì chất lượng tiếng nói ở mức chấp nhận được.


Việc giảm số bước ODE giúp rút ngắn thời gian tổng hợp tiếng nói, giảm chi phí tính toán và nâng cao khả năng triển khai hệ thống trong các ứng dụng thực tế yêu cầu phản hồi nhanh.

2.4 KIẾN TRÚC CHI TIẾT HỆ THỐNG ZIPVOICE

Hệ thống ZipVoice là sự kết hợp giữa kiến trúc mạng học chuỗi tiên tiến và mô hình sinh dữ liệu hiện đại. Toàn bộ mô hình được thiết kế theo dạng phi tự hồi quy (non-autoregressive), cho phép tổng hợp âm thanh song song với tốc độ cao.

2.4.1 Cấu trúc tổng thể của hệ thống ZipVoice

Kiến trúc lõi của ZipVoice đảm nhận nhiệm vụ chuyển đổi trực tiếp văn bản thành biểu diễn âm học dựa trên đặc trưng của một giọng nói tham chiếu. Cấu trúc và quy trình suy luận của hệ thống được minh họa chi tiết trong Hình 2.6:



Hình 2.6: Sơ đồ cấu trúc xử lý tổng thể của hệ thống ZipVoice [4]

Hình 2.6 minh họa hệ thống ZipVoice hoạt động theo bốn bước chính là mã hóa văn bản bằng Zipformer, trích xuất đặc trưng giọng nói từ âm thanh tham chiếu, sinh Mel-Spectrogram bằng Conditional Flow Matching và chuyển đổi Mel-Spectrogram thành âm thanh bằng vocoder Vocos.

Đối với nhánh văn bản (Text Branch), chuỗi văn bản đầu vào được chuyển đổi thành chuỗi phoneme và đưa qua bộ mã hóa Zipformer để tạo ra các đặc trưng ngôn ngữ (Text Condition). Các đặc trưng này biểu diễn nội dung cần được tổng hợp thành tiếng nói.

Đối với nhánh âm thanh tham chiếu (Audio Branch), một đoạn âm thanh ngắn của người nói được đưa vào bộ trích xuất đặc trưng người nói để tạo ra Speaker Embedding. Đây là vector đặc trưng biểu diễn các đặc điểm giọng nói của người nói tham chiếu.

Sau khi thu được Text Condition và Speaker Embedding, hệ thống kết hợp hai nguồn thông tin này để tạo thành biểu diễn điều kiện (Condition Representation). Biểu diễn này đồng thời chứa nội dung văn bản cần đọc và đặc trưng giọng nói tham chiếu, đóng vai trò điều kiện đầu vào cho mô hình Conditional Flow Matching trong quá trình sinh Mel-Spectrogram [4].

2.4.2 Trích xuất đặc trưng người nói (Speaker Embedding)

Hệ thống ZipVoice sử dụng một đoạn âm thanh tham chiếu để trích xuất đặc trưng giọng nói của người nói để thực hiện bài toán Zero-shot Voice Cloning. Đặc trưng này được biểu diễn dưới dạng một vector có kích thước cố định gọi là Speaker Embedding.

Speaker Embedding chứa các thông tin đặc trưng về âm sắc, cao độ, phong cách phát âm và các đặc điểm cá nhân của người nói, nhưng không chứa nội dung ngôn ngữ của câu nói tham chiếu. Nhờ đó, mô hình có thể sử dụng cùng một văn bản đầu vào để tạo ra tiếng nói mang đặc trưng của nhiều người nói khác nhau.

Trong hệ thống ZipVoice, Speaker Embedding được trích xuất từ âm thanh tham chiếu và được sử dụng như tín hiệu điều kiện trong quá trình sinh Mel-Spectrogram. Điều này cho phép mô hình tạo ra tiếng nói mới mang đặc trưng của người nói tham chiếu mà không cần huấn luyện lại cho từng người nói riêng biệt.

2.4.3 Cơ chế kết hợp đặc trưng (Fusion Mechanism)

Sau khi thu được đặc trưng ngôn ngữ từ bộ mã hóa Zipformer và đặc trưng người nói dưới dạng Speaker Embedding, hệ thống cần kết hợp hai nguồn thông tin này trước khi đưa vào bộ sinh Mel-Spectrogram.

Đặc trưng ngôn ngữ chứa nội dung cần phát âm, trong khi Speaker Embedding chứa thông tin về giọng nói mục tiêu. Việc kết hợp hai loại đặc trưng giúp mô hình


đồng thời xác định được nội dung cần đọc và cách phát âm theo giọng nói tham chiếu.

Trong ZipVoice, Speaker Embedding được sử dụng như tín hiệu điều kiện (conditioning signal) cho mô hình Conditional Flow Matching. Nhờ đó, quá trình sinh Mel-Spectrogram không chỉ phụ thuộc vào văn bản đầu vào mà còn chịu ảnh hưởng bởi đặc trưng giọng nói của người nói tham chiếu.

Cơ chế kết hợp này đóng vai trò quan trọng trong việc duy trì độ tương đồng giọng nói giữa âm thanh tham chiếu và âm thanh tổng hợp, góp phần nâng cao chất lượng của hệ thống Zero-shot Voice Cloning.

2.4.4 Cơ chế Average Upsampling

Trong hệ thống TTS, chiều dài chuỗi văn bản và chiều dài đặc trưng âm thanh thường không đồng nhất. Để giải quyết vấn đề này, ZipVoice sử dụng cơ chế Average Upsampling như minh họa trong Hình 2.7 [4].




Hình 2.7: Sơ đồ kiến trúc tổng thể của hệ thống ZipVoice [4]

Cơ chế Average Upsampling trong Hình 2.7 được sử dụng để căn chỉnh chiều dài giữa chuỗi đặc trưng ngôn ngữ và chuỗi đặc trưng âm thanh. Zipformer tạo ra đặc trưng ở mức phoneme, còn Mel-Spectrogram được biểu diễn theo frame thời gian. Vậy cần một cơ chế mở rộng đặc trưng văn bản để số lượng vector ngôn ngữ tương ứng với số frame âm thanh. Average Upsampling sử dụng thông tin duration để sao chép hoặc phân bổ đặc trưng ngôn ngữ sang nhiều frame thời gian liên tiếp, tạo điều kiện cho mô hình sinh Mel-Spectrogram có chiều dài phù hợp [4].

2.4.5 Vocoder tích hợp (Vocos)

ZipVoice sử dụng Vocos làm bộ vocoder để chuyển đổi Mel-Spectrogram thành tín hiệu âm thanh đầu ra. Khác với vocoder truyền thống hoạt động trên miền thời gian, Vocos xử lý trực tiếp trên miền tần số nhằm tăng tốc độ tổng hợp, cải thiện chất lượng âm thanh. Kiến trúc Vocos được minh họa trong Hình 2.8 [5].



Hình 2.8: Kiến trúc mạng Vocos với sự kết hợp của ConvNeXt và iSTFT [5]

Qua Hình 2.8 có thể thấy Vocos hoạt động qua ba bước chính. Đầu tiên, Mel-Spectrogram được đưa vào mạng ConvNeXt để trích xuất các đặc trưng âm thanh. Tiếp theo, mô hình dự đoán các thành phần phổ cần thiết cho quá trình tái tạo tín hiệu âm thanh. Cuối cùng, phép biến đổi iSTFT được sử dụng để chuyển các đặc trưng này thành tín hiệu âm thanh dạng sóng (waveform). Nhờ dự đoán trực tiếp các đặc trưng phổ thay vì sinh từng mẫu âm thanh trong miền thời gian, Vocos có khả năng tái tạo tốt các thành phần tần số của tiếng nói, giúp âm thanh đầu ra tự nhiên hơn, ít nhiễu hơn và vẫn duy trì tốc độ suy luận nhanh.

2.5 CÁC PHƯƠNG PHÁP ĐÁNH GIÁ HỆ THỐNG

Nghiên cứu sử dụng cả phương pháp đánh giá định lượng và định tính để đánh giá chất lượng hệ thống ZipVoice nhằm đo lường độ rõ chữ, tính ổn định và mức độ tương đồng giọng nói của âm thanh tổng hợp.

2.5.1 Đánh giá định lượng (Quantitative Metrics)

Đánh giá định lượng được sử dụng để đo lường chất lượng hệ thống một cách khách quan thông qua các chỉ số tự động. Trong đề tài này, Word Error Rate (WER) được sử dụng để đánh giá độ chính xác của nội dung tiếng nói tổng hợp bằng cách so sánh văn bản gốc với kết quả nhận dạng từ hệ thống ASR. Character Error Rate (CER) được sử dụng để đo mức độ sai lệch ở cấp độ ký tự, đặc biệt phù hợp với tiếng Việt có dấu. Ngoài ra, Speaker Similarity (SIM) được tính bằng độ tương đồng cosine giữa speaker embedding của âm thanh tham chiếu và speaker embedding của âm thanh tổng hợp. Các chỉ số này giúp đánh giá khả năng phát âm, độ chính xác nội dung và mức độ bảo toàn giọng nói của hệ thống.

2.5.2 Đánh giá định tính (Qualitative Metrics)

Đối với đánh giá định tính, Mean Opinion Score (MOS) là phương pháp phổ biến dựa trên cảm nhận của người nghe về độ tự nhiên và chất lượng của tiếng nói tổng hợp. UTMOS là một mô hình học máy được xây dựng nhằm ước lượng điểm MOS một cách tự động, giúp giảm chi phí và thời gian đánh giá. Tuy nhiên, kết quả UTMOS chỉ mang tính tham khảo và có thể chưa phản ánh đầy đủ cảm nhận thực tế của người nghe đối với các mô hình đã được tinh chỉnh trên những bộ dữ liệu hoặc ngôn ngữ cụ thể. UTMOS được huấn luyện chủ yếu trên dữ liệu tiếng Anh. Do đó, khi áp dụng cho tiếng Việt vốn có hệ thống thanh điệu và âm tiết khác biệt đáng kể, mô hình có xu hướng đánh giá thấp hơn thực tế, đặc biệt với các mẫu âm thanh đã được fine-tune để phát âm đúng thanh điệu tiếng Việt. Kết quả UTMOS trong đề tài cần được diễn giải kết hợp với đánh giá nghe thử trực tiếp thay vì xem xét độc lập.

CHƯƠNG 3


THIẾT KẾ VÀ THỰC HIỆN HỆ THỐNG

3.1 QUY TRÌNH THỰC NGHIỆM TỔNG THỂ VÀ KIẾN TRÚC MÃ NGUỒN

Trong quá trình thực hiện đề tài, nhóm thực hiện đã xây dựng quy trình thực nghiệm tổng thể nhằm phục vụ việc tinh chỉnh và triển khai mô hình ZipVoice cho bài toán Text-to-Speech tiếng Việt. Phần này trình bày lưu đồ thực nghiệm tổng thể, kiến trúc mã nguồn hệ thống và môi trường thực nghiệm được sử dụng trong quá trình nghiên cứu và triển khai mô hình.

3.1.1 Quy trình thực nghiệm tổng thể

Nhóm thực hiện quy trình gồm các bước chính: chuẩn bị dữ liệu, tinh chỉnh Teacher Model, huấn luyện Student Model bằng Knowledge Distillation và tối ưu quá trình suy luận. Quy trình tổng thể được minh họa trong Hình 3.1.



Hình 3.1: Lưu đồ quy trình tinh chỉnh mô hình ZipVoice

Hình 3.1 minh họa quy trình thực nghiệm của hệ thống được triển khai theo năm giai đoạn chính. Đầu tiên, dữ liệu tiếng Việt được thu thập, tiền xử lý và trích xuất đặc trưng phục vụ quá trình huấn luyện mô hình. Tiếp theo, mô hình Teacher được fine-tune từ checkpoint pre-trained trên dữ liệu tiếng Việt nhằm cải thiện chất lượng tổng hợp tiếng nói. Sau khi hoàn thành giai đoạn này, Student Model được huấn luyện bằng phương pháp Knowledge Distillation để kế thừa tri thức từ Teacher Model, đồng thời giảm số bước suy luận và tăng tốc độ tổng hợp âm thanh. Các checkpoint có kết quả tốt được thực hiện trung bình (Average Checkpoint) nhằm nâng cao độ ổn định của mô hình. Cuối cùng, hệ thống được đánh giá bằng các phương pháp định lượng và định tính để đo lường chất lượng phát âm, chất lượng âm thanh tổng hợp và hiệu năng suy luận.

3.1.2 Kiến trúc mã nguồn hệ thống

Cấu trúc mã nguồn dự án được tổ chức chặt chẽ theo phương pháp thiết kế hướng module để hiện thực hóa luồng thực nghiệm thành một hệ thống phần mềm có khả năng vận hành ổn định trong môi trường thực tế. Các thành phần thư mục được phân định ranh giới chức năng độc lập, kế thừa trực tiếp từ cấu trúc mẫu của tổ chức k2-fsa. Vai trò kỹ thuật và các tập tin tiêu biểu của từng khối cấu trúc được tổng hợp chi tiết tại Bảng 3.1.

Bảng 3.1: Các thành phần mã nguồn hệ thống

Thư mục / Tập tin cốt lõi	Vai trò kỹ thuật trong hệ thống	Tập tin chức năng tiêu biểu
tokenizer/	Tiếp nhận văn bản thô, xử lý chuẩn hóa ký tự đặc biệt, số, viết tắt và băm chuỗi thành ID âm vị.	normalizer.py, tokenizer.py
local/ & dataset/	Tiền xử lý âm thanh, trích xuất bộ lọc Fbank và đóng gói dữ liệu đồng bộ dưới dạng Lhotse Manifest.	preprocess_emilia.py, datamodule.py

models/& models/modules/	Định nghĩa kiến trúc các lớp mạng nơ-ron lõi của hệ thống bao gồm khối xử lý phân tầng đa tỷ lệ và bộ giải vi phân.	zipformer.py (Mạng backbone), solver.py (Bộ giải Euler ODE)
utils/	Chứa các thuật toán phụ trợ điều phối gradient, lập lịch biến thiên tốc độ học và cải thiện bộ nhớ.	optim.py, lr_scheduler.py
bin/	Tập hợp các kịch bản thực thi của hệ thống cho quá trình huấn luyện chung cất và suy diễn.	train_zipvoice_distill.py, infer_zipvoice.py
eval/	Bộ công cụ đo đặc kiểm thử tự động chất lượng đầu ra sau huấn luyện.	Module tính toán các chỉ số wer, mos, speaker_similarity

Việc phân chia mã nguồn thành các module độc lập rõ ràng giúp hệ thống loại bỏ sự phụ thuộc. Cũng như giúp việc bảo trì, mở rộng và tái sử dụng mã nguồn thuận lợi hơn.

3.1.3 Môi trường thực nghiệm

Quá trình huấn luyện và triển khai được thực hiện trên môi trường Linux với container Docker, sử dụng GPU NVIDIA Quadro RTX 6000 (24 GB VRAM) để tăng tốc tính toán. Các thông số cấu hình chi tiết được trình bày trong Bảng 3.2.

Bảng 3.2: Cấu hình môi trường thực nghiệm của hệ thống ZipVoice

Thành phần	Cấu hình
GPU	NVIDIA Quadro RTX 6000 (24 GB VRAM)
CUDA Runtime	12.1
Driver NVIDIA	570.133.20

Hệ điều hành	Ubuntu 22.04
Python	3.10
Framework chính	PyTorch 2.3.1 (cu121), Torchaudio 2.3.1
Thư viện hỗ trợ	k2-fsa, Lhotse, piper_phonemize
Container Runtime	Docker + NVIDIA Runtime
API Server	Gunicorn + UvicornWorker

Môi trường thực nghiệm được đóng gói bằng Docker dựa trên image `nvidia/cuda:12.1.1-cudnn8-runtime-ubuntu22.04` nhằm đảm bảo tính nhất quán giữa các lần huấn luyện và triển khai. Mô hình được thực thi với PyTorch 2.3.1 (CUDA 12.1) bên trong container. Máy chủ sử dụng NVIDIA Driver 570.133.20, phiên bản này hỗ trợ tối đa CUDA 12.8, tuy nhiên nhờ cơ chế tương thích ngược của NVIDIA Container Runtime, container chạy CUDA Runtime 12.1 vẫn truy cập và khai thác đầy đủ tài nguyên GPU Quadro RTX 6000 mà không cần thay đổi môi trường bên trong. Hệ thống API được triển khai bằng Gunicorn kết hợp UvicornWorker, phục vụ suy luận trên GPU và cung cấp dịch vụ Text-to-Speech qua giao thức HTTP.

3.2 CHUẨN BỊ VÀ TIỀN XỬ LÝ DỮ LIỆU

Trong quá trình nghiên cứu, nhóm thực hiện khảo sát và thử nghiệm trên một số bộ dữ liệu tiếng Việt công khai như VLSP TTS, VIVOS và Mozilla Common Voice nhằm đánh giá đặc điểm dữ liệu, chất lượng ghi âm và khả năng áp dụng cho bài toán Text-to-Speech tiếng Việt.

Tuy nhiên, quá trình fine-tune thực tế được thực hiện trên tập dữ liệu tiếng Việt quy mô lớn do doanh nghiệp cung cấp với tổng thời lượng khoảng 4000 giờ. Tập dữ liệu này bao gồm nhiều người nói, nhiều phong cách đọc và nhiều điều kiện thu âm khác nhau, giúp mô hình học được các đặc trưng ngữ âm và ngữ điệu đa dạng của tiếng Việt.

Quy trình tiền xử lý dữ liệu được thực hiện nhằm chuẩn hóa văn bản, xử lý tín hiệu âm thanh và đóng gói dữ liệu phục vụ quá trình huấn luyện mô hình ZipVoice.

Bảng 3.3 trình bày các bộ dữ liệu tiếng Việt được khảo sát trong quá trình nghiên cứu.


Bảng 3.3: Các bộ dữ liệu tiếng Việt được khảo sát trong quá trình nghiên cứu

Tập dữ liệu	Số lượng người nói (Speakers)	Tổng thời lượng (Giờ)	Tần số lấy mẫu gốc (Sampling Rate)	Môi trường thu âm	Vai trò thực nghiệm trong hệ thống
VLSP TTS	01(Đơn giọng chuyên nghiệp)	~10 giờ	44.1 kHz hoặc 48 kHz	Phòng thu (Studio cách âm)	Giúp khối lỗi Acoustic Model học nhanh cấu trúc ngữ âm, thanh điệu tiếng Việt chuẩn mực ở chặng huấn luyện Teacher.
VIVOS	65 (Đa giọng Nam/Nữ)	~15 giờ	16 kHz	Yên tĩnh (Studio học thuật)	Cung cấp dữ liệu đa người nói giúp mô hình học và biểu diễn đặc trưng người nói

					phục vụ bài toán Zero-shot Voice Cloning.
Mozilla Common Voice	Hàng trăm (Đa phương ngữ)	~20 giờ (đã lọc)	48 kHz	Đời thực (Có nhiều môi trường)	Giúp mô hình nâng cao khả năng khái quát hóa, làm quen với biến âm vùng miền trong kịch bản ứng dụng đời sống.

Các bộ dữ liệu trên được sử dụng trong quá trình khảo sát và đánh giá đặc điểm dữ liệu tiếng Việt cho bài toán Text-to-Speech. Việc phân tích các bộ dữ liệu này giúp nhóm hiểu rõ sự khác biệt về chất lượng ghi âm, số lượng người nói và đặc điểm phương ngữ, từ đó xây dựng quy trình tiền xử lý phù hợp cho dữ liệu thực nghiệm. Điều này giúp xây dựng quy trình tiền xử lý phù hợp và chuẩn bị dữ liệu phục vụ quá trình fine-tuning mô hình.

Quy trình tiền xử lý dữ liệu được thực hiện nhằm chuẩn hóa văn bản, xử lý tín hiệu âm thanh và đóng gói dữ liệu phục vụ cho quá trình huấn luyện mô hình ZipVoice. Toàn bộ quy trình được minh họa trong Hình 3.2.



Hình 3.2: Lưu đồ giải thuật quy trình tiền xử lý, dọn dẹp dữ liệu thô và đóng gói Manifest

Quy trình tiền xử lý dữ liệu trong Hình 3.2 được chia thành các giai đoạn chính bao gồm thu thập dữ liệu, chuẩn hóa văn bản, xử lý tín hiệu âm thanh, đồng bộ chiều dài dữ liệu và đóng gói Manifest phục vụ huấn luyện mô hình.

3.2.1 Thu thập và phân tích tập dữ liệu

Nhóm thực hiện khảo sát ba bộ dữ liệu tiếng Việt phổ biến gồm VLSP TTS, VIVOS và Mozilla Common Voice nhằm phân tích đặc điểm dữ liệu phục vụ bài toán Text-to-Speech. Mỗi bộ dữ liệu có ưu điểm riêng về chất lượng ghi âm, số lượng người nói và mức độ đa dạng ngôn ngữ.

Thông qua quá trình khảo sát, nhóm đánh giá được các đặc trưng cần thiết cho việc xây dựng quy trình tiền xử lý và huấn luyện mô hình. Kết quả phân tích này được sử dụng làm cơ sở cho việc chuẩn bị tập dữ liệu thực nghiệm quy mô lớn phục vụ quá trình fine-tune ZipVoice.

3.2.2 Dữ liệu thực nghiệm

Trong các bài toán tổng hợp tiếng nói (TTS), quy mô dữ liệu thường được biểu diễn theo thời lượng âm thanh thay vì số lượng mẫu do mỗi câu nói có độ dài khác nhau.

Quá trình fine-tuning được thực hiện trên tập dữ liệu tiếng Việt có tổng thời lượng khoảng 4000 giờ do doanh nghiệp cung cấp. Tổng thời gian fine-tuning kéo

dài hơn 22 ngày trên hệ thống GPU. Sau khi hoàn tất quá trình huấn luyện, mô hình được đánh giá trên tập kiểm thử gồm 210 câu tiếng Việt bằng các chỉ số WER, CER và UTMOS. Các bộ dữ liệu trên được sử dụng để khảo sát và phân tích đặc điểm dữ liệu tiếng Việt.

Bảng 3.4 trình bày các thông tin chính về dữ liệu và quá trình fine-tuning được sử dụng trong thực nghiệm.

Bảng 3.4: Thông tin dữ liệu và quá trình fine-tuning mô hình

Thông số	Giá trị
Dữ liệu fine-tuning	4000 giờ
Số giai đoạn huấn luyện	2 Stage
Tổng thời gian fine-tuning	Hơn 22 ngày
Tập kiểm thử	210 câu

Bảng 3.4 cho thấy quá trình fine-tuning được thực hiện trên tập dữ liệu có quy mô lớn với thời lượng khoảng 4000 giờ, giúp mô hình học được các đặc trưng ngữ âm và ngữ điệu của tiếng Việt. Việc huấn luyện qua hai giai đoạn cùng thời gian xử lý kéo dài hơn 22 ngày cho thấy khối lượng tính toán đáng kể của mô hình. Tập kiểm thử gồm 210 câu được sử dụng để đánh giá khách quan chất lượng tổng hợp tiếng nói sau khi fine-tuning.

3.2.3 Chuẩn hóa văn bản và G2P

Dữ liệu văn bản được xử lý thông qua các script trong thư mục tokenizer/ nhằm chuẩn hóa nội dung, chuyển đổi sang định dạng phù hợp cho mô hình ZipVoice [8] Trước tiên, script normalizer.py thực hiện chuẩn hóa văn bản bằng cách chuyển đổi chữ số, ngày tháng, ký hiệu và các từ viết tắt sang dạng văn bản đầy đủ nhằm đảm bảo tính nhất quán trong dữ liệu huấn luyện. Sau đó, script prepare_token_file_char.py thực hiện quá trình chuyển đổi văn bản sang chuỗi âm vị (phoneme). Chuỗi phoneme sau khi sinh được ánh xạ thành Token ID để làm đầu vào cho bộ mã hóa Zipformer.

3.2.4 Xử lý âm thanh


Dữ liệu âm thanh được chuẩn hóa và xử lý thông qua các công cụ tiền xử lý nhằm đảm bảo tính nhất quán trước khi đưa vào huấn luyện mô hình. Toàn bộ các tệp âm thanh từ các bộ dữ liệu khác nhau được chuyển đổi về cùng tần số lấy mẫu 24 kHz để thống nhất định dạng đầu vào. Loại bỏ các đoạn im lặng không cần thiết ở đầu và cuối câu nói. Quá trình chuẩn hóa này góp phần cải thiện độ ổn định của mô hình và hỗ trợ việc học các đặc trưng âm thanh hiệu quả hơn.

3.2.5 Đồng bộ chiều dài và Average Upsampling

Hệ thống sử dụng cơ chế Average Upsampling để thực hiện đồng bộ dữ liệu trong quá trình huấn luyện vì chiều dài giữa chuỗi văn bản và đặc trưng âm thanh thường không đồng nhất.

Cơ chế này giúp căn chỉnh chiều dài giữa token văn bản và đặc trưng âm thanh ổn định hơn so với phương pháp padding truyền thống. Việc căn chỉnh tốt hơn giữa chuỗi văn bản và chuỗi đặc trưng âm thanh giúp cải thiện độ ổn định phát âm khi tổng hợp các câu có độ dài lớn.

Cơ chế này được minh họa trong Hình 3.3.



Hình 3.3: Sơ đồ cơ chế căn chỉnh độ dài chuỗi bằng thuật toán Average Upsampling của ZipVoice so với phương pháp padding của E2-TTS [4]

Giải pháp lặp đều trong Hình 3.3 giúp duy trì alignment ổn định giữa văn bản và âm thanh, từ đó cải thiện chất lượng phát âm khi tổng hợp câu dài.

3.2.6 Đóng gói Manifest và Trích xuất đặc trưng với Lhotse

Sau khi hoàn tất quá trình tiền xử lý, dữ liệu được đóng gói dưới định dạng Manifest của Lhotse nhằm hỗ trợ việc quản lý và truy xuất dữ liệu trong quá trình huấn luyện. Hệ thống tạo các tệp recordings.jsonl và supervisions.jsonl để lưu trữ thông tin về tệp âm thanh, nội dung văn bản và định danh người nói, giúp đồng bộ dữ liệu giữa các thành phần của hệ thống.

Các tệp Manifest này được sử dụng để tổ chức và quản lý tập dữ liệu một cách hiệu quả, đồng thời hỗ trợ quá trình tải dữ liệu theo từng lô (batch) trong khi huấn luyện mô hình. Việc sử dụng Lhotse giúp đơn giản hóa quá trình xử lý dữ liệu, tăng tốc độ truy xuất và nâng cao hiệu quả huấn luyện trên các tập dữ liệu có quy mô lớn.

Các Manifest được sử dụng trực tiếp bởi DataModule để tạo dữ liệu đầu vào cho mô hình trong quá trình huấn luyện và đánh giá.

3.3 FINE-TUNE TEACHER MODEL

Sau khi hoàn thành quá trình chuẩn bị và tiền xử lý dữ liệu, nhóm tiến hành fine-tune Teacher Model của ZipVoice trên tập dữ liệu tiếng Việt nhằm giúp mô hình học được đặc trưng ngữ âm và thanh điệu của tiếng Việt. Quá trình huấn luyện được thực hiện dựa trên pretrained checkpoint kết hợp với cơ chế CFM để cải thiện khả năng tổng hợp tiếng nói.

3.3.1 Khởi tạo từ pretrained checkpoint

Nhóm sử dụng pretrained checkpoint của mô hình ZipVoice làm điểm khởi tạo cho quá trình fine-tune để rút ngắn thời gian huấn luyện và tận dụng tri thức đã học từ các tập dữ liệu lớn. Việc khởi tạo từ mô hình đã được huấn luyện trước giúp hệ thống hội tụ nhanh hơn và cải thiện khả năng học đặc trưng tiếng Việt so với huấn luyện từ đầu.

Checkpoint pretrained được nạp vào Teacher Model thông qua các script huấn luyện của hệ thống, đồng thời kế thừa các tham số của kiến trúc Zipformer và Flow Matching Decoder trong quá trình huấn luyện tiếp theo.

3.3.2 Thiết lập siêu tham số huấn luyện

Cấu hình huấn luyện của Teacher Model được thiết lập thông qua các tệp cấu hình trong thư mục conf/ và được điều phối bởi các script huấn luyện của hệ thống. Các cấu hình này cho phép tách biệt phần logic mô hình và tham số thực nghiệm, giúp việc thử nghiệm và tái lập kết quả trở nên thuận tiện hơn.

Trong quá trình fine-tuning, mô hình sử dụng bộ tối ưu ScaledAdam với tốc độ học khởi điểm 10^{-4} . Learning rate scheduler được áp dụng để giảm dần tốc độ học và hỗ trợ quá trình hội tụ.

Kích thước batch được lựa chọn dựa trên giới hạn bộ nhớ của GPU NVIDIA Quadro RTX 6000 (24GB VRAM). Để mô phỏng batch size lớn hơn mà không vượt quá giới hạn bộ nhớ, kỹ thuật Gradient Accumulation được sử dụng, giúp tích lũy gradient qua nhiều bước cập nhật trước khi thực hiện backpropagation.

Ngoài ra, quá trình huấn luyện sử dụng mixed precision (FP16) nhằm tối ưu tốc độ tính toán và giảm dung lượng bộ nhớ GPU, đồng thời vẫn đảm bảo độ ổn định của mô hình trong quá trình học.

Các siêu tham số chính được sử dụng trong quá trình fine-tune Teacher Model được tổng hợp trong Bảng 3.5.


Bảng 3.5: Các siêu tham số huấn luyện Teacher Model

Siêu tham số	Giá trị
Optimizer	ScaledAdam
Learning rate	10^{-4}
Batch size	8
Sampling rate	24 kHz
Warmup steps	4000
Mixed Precision	FP16
n_mels	100
n_fft (window size)	1,024
hop_length	256

3.3.3 Huấn luyện CFM trên dữ liệu tiếng Việt

Sau khi hoàn tất quá trình chuẩn bị dữ liệu và thiết lập các siêu tham số huấn luyện, nhóm tiến hành fine-tune Teacher Model từ pretrained checkpoint của ZipVoice trên tập dữ liệu tiếng Việt. Mục tiêu của giai đoạn này là giúp mô hình thích nghi với đặc trưng ngữ âm và thanh điệu của tiếng Việt, từ đó nâng cao chất lượng tổng hợp tiếng nói.

Quy trình huấn luyện của hệ thống được minh họa trong Hình 3.4.



Hình 3.4: Lưu đồ giải thuật vòng lặp thực thi huấn luyện CFM hệ thống

Sau khi hoàn tất quá trình chuẩn bị dữ liệu và thiết lập các siêu tham số huấn luyện, nhóm tiến hành fine-tune Teacher Model từ pretrained checkpoint của ZipVoice trên tập dữ liệu tiếng Việt. Mục tiêu của giai đoạn này là giúp mô hình thích nghi với đặc trưng ngữ âm và thanh điệu tiếng Việt trong khi vẫn kế thừa tri thức đã học từ dữ liệu tiền huấn luyện.

Trong quá trình huấn luyện, chuỗi văn bản sau khi chuẩn hóa được chuyển thành token và đưa vào bộ mã hóa Zipformer để trích xuất đặc trưng ngôn ngữ. Đồng thời, đặc trưng người nói được trích xuất từ âm thanh tham chiếu và kết hợp với thông tin ngôn ngữ để điều kiện hóa quá trình sinh Mel-Spectrogram. Bộ sinh dựa trên Conditional Flow Matching được huấn luyện để dự đoán quỹ đạo biến đổi từ nhiễu ban đầu đến Mel-Spectrogram mục tiêu.

Quá trình huấn luyện được thực hiện lặp lại trên toàn bộ tập dữ liệu cho đến khi mô hình hội tụ. Các checkpoint được lưu định kỳ và đánh giá trên tập validation nhằm lựa chọn mô hình phù hợp cho giai đoạn distillation.

3.3.4 Lưu checkpoint và chọn mô hình

Trong quá trình huấn luyện, hệ thống tự động lưu checkpoint định kỳ nhằm phục vụ việc khôi phục và đánh giá mô hình. Kỹ thuật Average Checkpoint được

áp dụng bằng cách lấy trung bình trọng số của nhiều checkpoint gần nhau nhằm giảm ảnh hưởng của dao động trong quá trình huấn luyện và cải thiện độ ổn định khi suy luận.

Sau khi hoàn thành fine-tune, nhóm lựa chọn checkpoint có kết quả tốt nhất trên tập validation để sử dụng làm Teacher Model cho giai đoạn huấn luyện Student Model bằng Knowledge Distillation.

3.4 TINH CHỈNH MÔ HÌNH STUDENT

Sau khi hoàn thành quá trình fine-tune Teacher Model, nhóm tiếp tục huấn luyện Student Model nhằm giảm độ trễ suy luận của hệ thống Text-to-Speech. Quá trình này được thực hiện bằng phương pháp Knowledge Distillation, trong đó Student Model học cách tái tạo đầu ra của Teacher Model với chi phí tính toán thấp hơn. Mục tiêu là duy trì chất lượng tổng hợp tiếng nói trong khi rút ngắn thời gian suy luận.

3.4.1 Huấn luyện bằng Knowledge Distillation

Student Model sử dụng cùng kiến trúc ZipVoice với Teacher Model bao gồm bộ mã hóa Zipformer và bộ sinh Mel-Spectrogram dựa trên CFM, nhưng không được huấn luyện trực tiếp trên dữ liệu thô. Thay vào đó, Student Model được huấn luyện thông qua cơ chế Knowledge Distillation [3] nhằm giảm số bước suy luận và chi phí tính toán trong khi vẫn duy trì chất lượng tổng hợp tiếng nói ở mức phù hợp. Quá trình này được thực hiện bằng script `train_zipvoice_distill.py` trên GPU NVIDIA Quadro RTX 6000.

Trong quá trình distillation, Teacher Model được sử dụng để sinh ra các biểu diễn trung gian và Mel-Spectrogram mục tiêu làm tín hiệu hướng dẫn cho Student Model. Student Model sử dụng cùng kiến trúc ZipVoice nhưng được cấu hình với số bước ODE nhỏ hơn. Mục tiêu huấn luyện là Student Model học được quỹ đạo sinh Mel-Spectrogram tương tự Teacher Model trong khi giảm số bước suy luận.

Nhờ sử dụng Teacher Model đã được fine-tune trên dữ liệu tiếng Việt, Student Model có thể kế thừa các đặc trưng ngữ âm, thanh điệu và đặc trưng giọng nói đã học được mà không cần huấn luyện lại từ đầu. Các checkpoint được lưu định kỳ

và đánh giá trên tập validation nhằm lựa chọn mô hình phù hợp cho giai đoạn triển khai.

3.4.2 Giảm số bước ODE và tối ưu suy luận

Một trong những mục tiêu quan trọng của quá trình Knowledge Distillation là giảm độ trễ suy luận của hệ thống Text-to-Speech trong khi vẫn duy trì chất lượng âm thanh ở mức phù hợp. Trong kiến trúc ZipVoice, quá trình sinh Mel-Spectrogram được thực hiện thông qua bộ giải ODE, do đó số bước ODE ảnh hưởng trực tiếp đến thời gian tổng hợp tiếng nói.

Bảng 3.6 trình bày số bước ODE được sử dụng bởi Teacher Model và Student Model trong quá trình suy luận.

Bảng 3.6: So sánh số bước ODE giữa Teacher Model và Student Model

Mô hình	Số bước ODE
Teacher (ZipVoice)	16
Student (ZipVoice-Distill)	8

Kết quả cho thấy Student Model chỉ sử dụng 8 bước ODE, giảm 50% so với Teacher Model (16 bước). Việc giảm số bước suy luận giúp rút ngắn thời gian sinh Mel-Spectrogram, từ đó giảm độ trễ inference và nâng cao khả năng triển khai trong các ứng dụng Text-to-Speech thời gian thực.

Bên cạnh đó, hệ thống sử dụng mixed precision inference trên GPU NVIDIA Quadro RTX 6000 nhằm tận dụng hiệu quả tài nguyên phần cứng và tăng tốc quá trình tổng hợp âm thanh. Mục tiêu của quá trình distillation là giảm số bước ODE từ 16 xuống còn 8 nhằm rút ngắn thời gian suy luận trong khi hạn chế suy giảm chất lượng tổng hợp tiếng nói. Hiệu quả của phương pháp này sẽ được đánh giá trong Chương 4 thông qua các chỉ số thực nghiệm.


CHƯƠNG 4

TRIỂN KHAI VÀ THỬ NGHIỆM HỆ THỐNG

4.1 QUY TRÌNH THỰC NGHIỆM HỆ THỐNG

Sau khi hoàn thành quá trình huấn luyện, nhóm tiến hành kiểm thử và triển khai hệ thống.

Hình 4.1 trình bày quy trình suy luận được sử dụng trong giai đoạn này.



Hình 4.1: Quy trình suy luận của hệ thống ZipVoice

Trong quá trình suy luận, người dùng nhập văn bản tiếng Việt và cung cấp một đoạn âm thanh tham chiếu của người nói. Văn bản đầu vào được chuẩn hóa và chuyển đổi thành chuỗi token hoặc phoneme thông qua bộ tokenizer eSpeak (công cụ chuyển đổi văn bản sang chuỗi âm vị hỗ trợ tiếng Việt). Đồng thời, hệ thống thực hiện trích xuất Speaker Embedding từ đoạn âm thanh tham chiếu nhằm biểu diễn đặc trưng giọng nói của người nói.

Tiếp theo, mô hình ZipVoice sử dụng thông tin ngôn ngữ và đặc trưng người nói để sinh Mel-spectrogram. Vocoder Vocos chuyển đổi Mel-spectrogram thành

tín hiệu âm thanh dạng song, xuất ra tệp âm thanh định dạng WAV.

Bảng 4.1 trình bày cấu hình thực nghiệm được sử dụng trong quá trình suy luận mô hình.

Bảng 4.1: Cấu hình thực nghiệm hệ thống

Thông số	Giá trị
GPU	NVIDIA Quadro RTX 6000
VRAM	24 GB
CUDA Runtime	12.1
Python	3.10
Framework	PyTorch 2.3.1
Sampling Rate	24 kHz
Tokenizer	eSpeak
Số câu kiểm thử	210
Định dạng đầu ra	.wav

Bảng 4.1 trình bày cấu hình phần cứng và phần mềm được sử dụng trong quá trình thực nghiệm và kiểm thử hệ thống ZipVoice. Toàn bộ quá trình suy luận được thực hiện trên GPU NVIDIA Quadro RTX 6000 với 24 GB VRAM, sử dụng môi trường PyTorch 2.3.1 và CUDA Runtime 12.1 nhằm tăng tốc độ xử lý và giảm thời gian suy luận.

Hệ thống sử dụng tần số lấy mẫu 24 kHz, phù hợp với cấu hình của mô hình ZipVoice và vocoder trong quá trình tổng hợp tiếng nói. Ngoài ra, bộ chuyển đổi âm vị eSpeak được sử dụng để chuyển đổi văn bản tiếng Việt thành chuỗi phoneme trước khi đưa vào mô hình.


Tập kiểm thử gồm 210 câu tiếng Việt được xây dựng với nhiều dạng khác nhau bao gồm câu ngắn, câu dài, câu hội thoại và các câu chứa nhiều thanh điệu phức tạp để đảm bảo tính khách quan trong quá trình đánh giá. Tập dữ liệu này được sử dụng để đánh giá khả năng tổng hợp tiếng nói trên nhiều dạng câu khác nhau.

4.2 KIỂM THỬ MÔ HÌNH TEACHER

Trong quá trình kiểm thử, hệ thống nhận văn bản đầu vào cùng đoạn âm thanh tham chiếu, sau đó thực hiện trích xuất Speaker Embedding, sinh ra tín hiệu tiếng nói tương ứng. Các thử nghiệm được thực hiện với nhiều câu tiếng Việt có độ dài khác nhau nhằm đánh giá khả năng duy trì nội dung, đặc trưng của người nói.

Teacher Model được sử dụng để sinh tiếng nói trên tập kiểm thử gồm 210 câu tiếng Việt với nhiều độ dài và ngữ cảnh khác nhau. Trong quá trình kiểm thử, mô hình sử dụng đoạn âm thanh tham chiếu để trích xuất Speaker Embedding và sinh tiếng nói dựa trên nội dung văn bản đầu vào. Kết quả quan sát cho thấy mô hình có khả năng tổng hợp tiếng nói ổn định và duy trì được đặc trưng cơ bản của người nói tham chiếu.

Nhóm sử dụng công cụ Speaker Similarity trên tập kiểm thử tiếng Việt để đánh giá khả năng bảo toàn đặc trưng người nói. Công cụ này đo mức độ tương đồng giữa giọng nói tham chiếu và giọng nói được tổng hợp bởi mô hình.



Hình 4.2: Kết quả kiểm thử Speaker Similarity của Teacher Model

Hình 4.2 trình bày kết quả đánh giá Speaker Similarity của Teacher Model sau quá trình fine-tuning trên dữ liệu tiếng Việt. Kết quả thực nghiệm cho thấy mô hình đạt giá trị Speaker Similarity (SIM-O) khoảng 0.678. Chỉ số này phản ánh mức độ tương đồng tương đối cao giữa giọng nói tổng hợp và giọng nói tham chiếu, cho thấy mô hình có khả năng bảo toàn tốt đặc trưng âm học của người nói sau quá trình fine-tuning.

4.3 KIỂM THỬ MÔ HÌNH STUDENT

Sau khi hoàn thành quá trình Knowledge Distillation, Student Model được sử dụng trong giai đoạn suy luận nhằm giảm số bước suy luận và chi phí tính toán, đồng thời vẫn duy trì chất lượng tổng hợp tiếng nói ở mức phù hợp. Quá trình kiểm thử được thực hiện trên cùng tập dữ liệu và các speaker tham chiếu như Teacher Model để đảm bảo tính nhất quán trong đánh giá.

Nhóm sử dụng chỉ số Speaker Similarity (SIM-O), đo mức độ tương đồng giữa giọng nói tổng hợp và giọng nói tham chiếu để đánh giá khả năng duy trì đặc trưng người nói sau quá trình distillation.

Kết quả đánh giá được trình bày trong Hình 4.3.



Hình 4.3: Kết quả kiểm thử Speaker Similarity của Student Model


Hình 4.3 cho thấy Student Model đạt giá trị SIM-O khoảng 0.650. Mặc dù thấp hơn Teacher Model, mô hình vẫn duy trì được khả năng bảo toàn đặc trưng người nói ở mức tốt. Kết quả này cho thấy Student Model có thể được sử dụng thay thế Teacher Model trong giai đoạn suy luận, tạo tiền đề cho việc cải thiện tốc độ xử lý và hiệu năng triển khai thực tế được phân tích trong Mục 5.2.3.

4.4 KIỂM THỬ KHẢ NĂNG VOICE CLONING TIẾNG VIỆT

Sau khi hoàn thành triển khai mô hình ZipVoice dưới dạng dịch vụ REST API, nhóm tiến hành kiểm thử khả năng sao chép giọng nói tiếng Việt trong môi trường thực tế. Mục tiêu của quá trình kiểm thử là đánh giá khả năng tổng hợp nội dung mới dựa trên một đoạn âm thanh tham chiếu ngắn, đồng thời kiểm tra tính ổn định của hệ thống khi được triển khai dưới dạng dịch vụ trực tuyến.

Trong quá trình kiểm thử, hệ thống nhận ba thành phần đầu vào gồm văn bản cần tổng hợp (text), nội dung tương ứng với đoạn âm thanh tham chiếu (prompt_text) và tệp âm thanh tham chiếu (prompt_wav). Sau khi tiếp nhận yêu cầu, hệ thống thực hiện trích xuất đặc trưng người nói từ đoạn âm thanh tham chiếu, kết hợp với nội dung văn bản đầu vào để sinh Mel-Spectrogram bằng mô hình ZipVoice-Distill. Mel-Spectrogram sau đó được chuyển đổi thành tín hiệu âm thanh dạng sóng thông qua vocoder Vocos và trả về cho người dùng dưới dạng tệp âm thanh WAV.

Nhóm thực hiện kiểm thử với các đoạn âm thanh tham chiếu thuộc hai nhóm giọng nói phổ biến là giọng nam và giọng nữ để đánh giá khả năng hoạt động của hệ thống. Hệ thống được kiểm thử với một đoạn âm thanh tham chiếu của người nói nam. Quá trình gửi yêu cầu tổng hợp tiếng nói thông qua API được minh họa trong Hình 4.4.




Hình 4.4: Kiểm thử Voice Cloning tiếng Việt với giọng nam qua API

Hình 4.4 cho thấy yêu cầu được gửi thành công tới máy chủ thông qua phương thức POST. Hệ thống tiếp nhận văn bản cần tổng hợp cùng đoạn âm thanh tham chiếu của người nói nam và thực hiện quá trình suy luận trên mô hình ZipVoice-Distill. Kết quả trả về có mã trạng thái HTTP 200 OK cùng tệp âm thanh WAV

đầu ra. Âm thanh tổng hợp giữ được các đặc trưng cơ bản của giọng tham chiếu như đặc trưng giọng nói của nam và phong cách phát âm, đồng thời nội dung được phát âm đúng theo văn bản đầu vào.

Tiếp theo, nhóm kiểm thử với một đoạn âm thanh tham chiếu của người nói nữ nhằm đánh giá khả năng thích ứng của mô hình với các đặc trưng giọng nói khác nhau. Quá trình gửi yêu cầu và nhận kết quả được trình bày trong Hình 4.5.



Hình 4.5: Kiểm thử Voice Cloning tiếng Việt với giọng nữ qua API

Hệ thống tiếp tục xử lý thành công yêu cầu tổng hợp tiếng nói với giọng tham chiếu nữ. Kết quả trả về là tệp âm thanh WAV có thể phát trực tiếp trên giao diện Postman. Âm thanh đầu ra duy trì được các đặc trưng của giọng nữ tham chiếu, bao gồm đặc trưng giọng nói và ngữ điệu cơ bản, đồng thời không xuất hiện lỗi trong quá trình suy luận hay trả kết quả từ máy chủ.

Kết quả kiểm thử cho thấy sau khi được tinh chỉnh trên dữ liệu tiếng Việt, ZipVoice có khả năng thực hiện Voice Cloning với các giọng nói khác nhau thông qua một đoạn âm thanh tham chiếu ngắn.


Việc triển khai dưới dạng REST API cho phép người dùng gửi yêu cầu và nhận kết quả tổng hợp một cách thuận tiện, đồng thời chứng minh tính khả thi của hệ thống trong các ứng dụng Text-to-Speech tiếng Việt thực tế.

4.5 TRIỂN KHAI HỆ THỐNG SUY LUẬN

Trong hệ thống triển khai thực tế, mô hình ZipVoice-Distill (Student Model) được lựa chọn làm mô hình suy luận chính nhằm cân bằng giữa chất lượng tiếng nói và tốc độ xử lý.

Sau khi hoàn thành quá trình fine-tuning, distillation và kiểm thử mô hình, nhóm tiến hành triển khai hệ thống ZipVoice dưới dạng dịch vụ Text-to-Speech nhằm phục vụ quá trình suy luận trong môi trường thực tế. Việc triển khai được thực hiện theo mô hình client-server, trong đó mô hình ZipVoice-Distill được đóng gói và cung cấp dưới dạng REST API để người dùng có thể gửi yêu cầu tổng hợp tiếng nói từ xa.

Toàn bộ hệ thống được đóng gói bằng Docker để đảm bảo tính nhất quán của môi trường thực thi và thuận tiện cho việc triển khai. Các thư viện phụ thuộc, mô hình đã huấn luyện và mã nguồn ứng dụng được tích hợp trong cùng một Docker Image, giúp giảm thiểu các vấn đề liên quan đến cấu hình môi trường và nâng cao khả năng mở rộng của hệ thống.




Hình 4.6: Docker Container triển khai hệ thống ZipVoice

Hệ thống ZipVoice trong Hình 4.6 được triển khai thành công trong môi

trường Docker. Container được cấu hình để sử dụng GPU thông qua NVIDIA Container Toolkit nhằm tận dụng khả năng tăng tốc phần cứng trong quá trình suy luận. Sau khi khởi động, mô hình được nạp vào bộ nhớ và sẵn sàng tiếp nhận các yêu cầu tổng hợp tiếng nói từ người dùng.

Ứng dụng được xây dựng trên nền tảng FastAPI và cung cấp điểm cuối (endpoint) /tts để thực hiện chức năng tổng hợp tiếng nói. Người dùng gửi yêu cầu dưới dạng HTTP POST bao gồm văn bản cần tổng hợp, nội dung của đoạn âm thanh tham chiếu và tệp âm thanh tham chiếu. Sau khi hoàn thành quá trình suy luận, hệ thống trả về kết quả dưới dạng tệp âm thanh WAV.



Hình 4.7: Giao diện thử nghiệm hệ thống ZipVoice bằng Gradio

Nhóm xây dựng giao diện người dùng bằng Gradio để thuận tiện cho việc kiểm thử và trình diễn hệ thống. Giao diện cho phép người dùng nhập văn bản cần tổng hợp, tải lên đoạn âm thanh tham chiếu và nhận kết quả âm thanh được sinh ra trực tiếp trên trình duyệt.

Thông qua giao diện này, người dùng có thể thực hiện các chức năng Text-to-Speech và Zero-shot Voice Cloning mà không cần gửi yêu cầu trực tiếp đến API. Kết quả thực nghiệm cho thấy giao diện hoạt động ổn định và có thể kết nối thành công với mô hình ZipVoice-Distill được triển khai trong môi trường Docker.

Quá trình triển khai thực tế cho thấy hệ thống hoạt động ổn định trên môi trường GPU NVIDIA Quadro RTX 6000. Các yêu cầu tổng hợp tiếng nói được xử lý thành công, trả về kết quả đúng định dạng. Chứng minh mô hình ZipVoice sau

quá trình tinh chỉnh và tối ưu hóa đã có thể được triển khai như một dịch vụ Text-to-Speech hoàn chỉnh, đáp ứng nhu cầu tích hợp vào các ứng dụng.

Qua quá trình kiểm thử và triển khai, Teacher Model và Student Model đều cho thấy khả năng tổng hợp tiếng nói tiếng Việt hiệu quả, duy trì được đặc trưng của người nói tham chiếu. Hệ thống Voice Cloning hoạt động ổn định với cả giọng nam và giọng nữ, đồng thời đã được triển khai thành công dưới dạng dịch vụ REST API trong môi trường Docker. Các kết quả đánh giá chi tiết về chất lượng tiếng nói, độ chính xác nội dung, tốc độ suy luận sẽ được trình bày trong Chương 5.

CHƯƠNG 5

KẾT QUẢ VÀ ĐÁNH GIÁ HỆ THỐNG


5.1 KẾT QUẢ THỰC NGHIỆM

Sau khi hoàn thành quá trình huấn luyện, nhóm tiến hành thực nghiệm trên tập kiểm thử gồm 210 câu tiếng Việt. Hai mô hình được đánh giá bao gồm Fine-tuned Teacher Model và Fine-tuned Student Model nhằm kiểm tra chất lượng tổng hợp tiếng nói, khả năng voice cloning và hiệu năng suy luận của hệ thống.

5.1.1 Kết quả suy luận của Fine-tuned Teacher Model

Sau quá trình fine-tuning trên tập dữ liệu tiếng Việt, Teacher Model được sử dụng để đánh giá khả năng thích nghi của ZipVoice đối với ngôn ngữ đích.

Hình 5.1 trình bày kết quả suy luận của Teacher Model trên tập kiểm thử.



```
2026-05-22 21:11:05,279 INFO [infer_zipvoice.py:748] =====
2026-05-22 21:11:05,279 INFO [infer_zipvoice.py:749] Total inference time: 285.78s
2026-05-22 21:11:05,279 INFO [infer_zipvoice.py:750] Number of sentences: 210
2026-05-22 21:11:05,279 INFO [infer_zipvoice.py:751] Average wall time per sentence: 1.360s
2026-05-22 21:11:05,279 INFO [infer_zipvoice.py:755] Average model inference time: 1.314s
2026-05-22 21:11:05,279 INFO [infer_zipvoice.py:759] Throughput: 8.74 sentences/sec
2026-05-22 21:11:05,280 INFO [infer_zipvoice.py:760] =====
2026-05-22 21:11:05,280 INFO [infer_zipvoice.py:762] Average RTF vocoder: 0.0036
2026-05-22 21:11:05,280 INFO [infer_zipvoice.py:940] Done
(venv) root@linux17406:/home/pitel/ZipVoice#
```

Hình 5.1: Kết quả suy luận của Fine-tuned Teacher Model


Từ Hình 5.1 có thể thấy mô hình hoàn thành quá trình suy luận trên toàn bộ tập kiểm thử gồm 210 câu tiếng Việt. Thời gian suy luận trung bình đạt khoảng 1,314 giây cho mỗi câu với giá trị Average RTF bằng 0,5676.

Qua quá trình nghe thử, mô hình cho khả năng phát âm tiếng Việt tự nhiên hơn so với phiên bản ZipVoice gốc. Các lỗi đọc sai từ và sai thanh điệu được giảm đáng kể, đồng thời vẫn duy trì được đặc trưng giọng nói của người tham chiếu trong quá trình voice cloning

5.1.2 Kết quả suy luận của Fine-tuned Student Model

Nhóm tiếp tục áp dụng phương pháp Knowledge Distillation để xây dựng Student Model với số bước ODE giảm từ 16 xuống còn 8 bước nhằm giảm chi phí tính toán và tăng tốc độ suy luận.

Kết quả suy luận của Student Model được trình bày trong Hình 5.2.



```
2026-05-22 21:18:37,215 INFO [infer_zipvoice.py:748] =====
2026-05-22 21:18:37,215 INFO [infer_zipvoice.py:749] Total inference time: 135.22s
2026-05-22 21:18:37,215 INFO [infer_zipvoice.py:750] Number of sentences: 210
2026-05-22 21:18:37,215 INFO [infer_zipvoice.py:751] Average wall time per sentence: 0.644s
2026-05-22 21:18:37,215 INFO [infer_zipvoice.py:755] Average model inference time: 0.600s
2026-05-22 21:18:37,215 INFO [infer_zipvoice.py:759] Throughput: 1.55 sentences/sec
2026-05-22 21:18:37,215 INFO [infer_zipvoice.py:760] =====
2026-05-22 21:18:37,215 INFO [infer_zipvoice.py:762] Average RTF vocoder: 0.0032
2026-05-22 21:18:37,216 INFO [infer_zipvoice.py:940] Done
(venv) root@linux17406:/home/pitel/ZipVoice#
```

Hình 5.2: Kết quả suy luận của Fine-tuned Student Model

Quan sát Hình 5.2 cho thấy mô hình hoàn thành thành công toàn bộ tập kiểm thử. Thời gian suy luận trung bình đạt khoảng 0,600 giây cho mỗi câu với Average RTF bằng 0,2564.

Mặc dù số bước ODE chỉ bằng một nửa so với Teacher Model, chất lượng tiếng nói đầu ra vẫn được duy trì ở mức tương đương. Điều này cho thấy quá trình Distillation đã truyền tải hiệu quả tri thức từ Teacher Model sang Student Model, đồng thời giúp tăng tốc độ suy luận đáng kể.

5.2 ĐÁNH GIÁ MÔ HÌNH

5.2.1 Đánh giá định lượng

Nhóm tiến hành đánh giá định lượng chất lượng tổng hợp tiếng nói của hệ thống thông qua các chỉ số WER và CER trên tập kiểm thử gồm 210 câu tiếng Việt. Các chỉ số được tính bằng cách sử dụng mô hình nhận dạng tiếng nói tự động (ASR) để chuyển đổi âm thanh tổng hợp thành văn bản, sau đó so sánh với nội dung gốc của tập kiểm thử.

Trong thực nghiệm, nhóm tiến hành đánh giá ba mô hình gồm: Pretrained Model (mô hình ZipVoice gốc chưa được tinh chỉnh trên dữ liệu tiếng Việt), Fine-tuned Model (Teacher) (mô hình được fine-tune trên tập dữ liệu tiếng Việt của đề tài) và Fine-tuned Distill Model (Student) (mô hình Student được huấn luyện bằng

phương pháp Knowledge Distillation từ Teacher Model nhằm giảm độ phức tạp tính toán nhưng vẫn duy trì chất lượng tổng hợp tiếng nói).

Kết quả đánh giá được trình bày trong Bảng 5.1.

Bảng 5.1: Kết quả đánh giá WER và CER trên tập kiểm thử

Chỉ số	Pretrained Model	Fine-tuned Model (Teacher)	Fine-tuned Distill Model (Student)
Số câu kiểm thử	210	210	210
WER (%)	118.91	8.37	7.65
CER có dấu (%)	82.05	5.04	4.72
CER không dấu (%)	73.45	4.36	4.07
Insertions	731	2	1
Deletions	93	38	36
Substitutions	1848	148	135

Kết quả cho thấy mô hình Pretrained hoạt động chưa hiệu quả trên dữ liệu tiếng Việt khi đạt WER 118.91% và CER không dấu 73.45%. Điều này cho thấy mô hình thường xuyên phát sinh lỗi nhận dạng, thay thế hoặc bỏ sót từ khi tổng hợp tiếng nói tiếng Việt.

Sau quá trình fine-tuning trên tập dữ liệu tiếng Việt, Teacher Model đạt WER 8.37%, giảm hơn 110 điểm phần trăm so với mô hình gốc. WER có thể vượt 100% khi số lượng từ bị chèn thêm (Insertions) rất lớn so với tổng số từ trong văn bản gốc, như trường hợp của Pretrained Model với 731 lỗi Insertions. Đồng thời, CER có dấu và CER không dấu lần lượt giảm xuống còn 5.04% và 4.36%. Số lượng lỗi chèn từ (Insertions) giảm mạnh từ 731 xuống chỉ còn 2 lỗi, cho thấy mô hình đã học được đặc trưng ngữ âm và thanh điệu tiếng Việt hiệu quả hơn.

Đáng chú ý, Student Model sau quá trình Knowledge Distillation tiếp tục cải thiện kết quả với WER đạt 7.65%, CER có dấu đạt 4.72% và CER không dấu đạt

4.07%. Số lỗi thay thế từ (Substitutions) giảm từ 148 xuống 135 và lỗi chèn từ chỉ còn 1 trường hợp trên toàn bộ tập kiểm thử.

Các kết quả trên cho thấy quá trình fine-tuning giúp mô hình ZipVoice thích nghi hiệu quả với tiếng Việt, trong khi Knowledge Distillation không những giúp giảm số bước suy luận mà còn duy trì, thậm chí cải thiện nhẹ độ chính xác của nội dung tổng hợp. Điều này chứng minh Student Model có khả năng kế thừa tri thức từ Teacher Model và phù hợp cho các hệ thống Text-to-Speech triển khai thực tế nhờ cân bằng tốt giữa chất lượng âm thanh và hiệu năng suy luận.

5.2.2 Đánh giá định tính

Nhóm tiến hành đánh giá chất lượng ổn định của tiếng nói tổng hợp thông qua chỉ số UTMOS (Universal Mean Opinion Score). Đây là phương pháp đánh giá tự động sử dụng mô hình học sâu nhằm ước lượng chất lượng âm thanh theo thang điểm MOS.

Quá trình đánh giá được thực hiện thông qua module `zipvoice.eval.mos.utmos` trên các tệp âm thanh được sinh ra từ pretrained model và mô hình sau fine-tuning.

Bảng 5.2: Kết quả đánh giá UTMOS

Mô hình	Điểm UTMOS
Pretrained Model	3.28
Fine-tuned Teacher	2.89
Distill Student	2.95

Kết quả cho thấy mô hình pretrained đạt điểm UTMOS cao hơn mô hình sau khi fine-tuning. Tuy nhiên, qua quá trình nghe thử thực tế, nhóm nhận thấy kết quả này chưa phản ánh chính xác chất lượng phát âm tiếng Việt của hệ thống.

Mặc dù có điểm UTMOS thấp hơn, Teacher Model và Student Model cho khả năng phát âm tiếng Việt tự nhiên hơn, giảm đáng kể các lỗi đọc sai từ và sai thanh điệu. Điều này cho thấy UTMOS chủ yếu phản ánh chất lượng tín hiệu tiếng nói tổng quát và chưa thực sự phù hợp để đánh giá hiệu quả của quá trình fine-tuning tiếng Việt trong phạm vi đề tài.

Do đó, bên cạnh UTMOS, nhóm tiến hành đánh giá chủ quan bằng phương pháp MOS thông qua việc nghe trực tiếp các mẫu âm thanh được sinh ra từ các mô hình. Kết quả nghe thử cho thấy Teacher Model và Student Model có chất lượng tiếng nói tốt hơn rõ rệt so với mô hình pretrained, đặc biệt về độ chính xác phát âm và ngữ điệu tiếng Việt.

5.2.3 Đánh giá hiệu năng suy luận

Nhóm tiến hành đo thời gian suy luận trên cùng tập kiểm thử gồm 210 câu tiếng Việt để đánh giá khả năng triển khai thực tế.

Bảng 5.3: So sánh hiệu năng suy luận giữa các mô hình ZipVoice

Mô hình	Avg Inference Time (s)	Average RTF	Throughput (câu/s)
Pretrained Model	1.371	0.5689	0.71
Fine-tuned Teacher Model	1.314	0.5676	0.74
Fine-tuned Student Model	0.600	0.2564	1.55

Kết quả cho thấy quá trình fine-tuning gần như không làm thay đổi tốc độ suy luận. Trong khi đó, Student Model đạt tốc độ suy luận nhanh hơn khoảng 2,2 lần so với Teacher Model nhờ giảm số bước ODE từ 16 xuống còn 8 bước.

Điều này chứng minh Knowledge Distillation là giải pháp hiệu quả giúp giảm chi phí tính toán nhưng vẫn duy trì được chất lượng tổng hợp tiếng nói.

5.3 ĐÁNH GIÁ MÔ HÌNH

Kết quả thực nghiệm cho thấy quá trình fine-tuning đã giúp mô hình ZipVoice thích nghi hiệu quả với tiếng Việt. Các chỉ số WER và CER giảm đáng kể so với mô hình pretrained, đồng thời số lượng lỗi chèn, xóa và thay thế từ cũng được cải thiện rõ rệt. Điều này cho thấy mô hình đã học được tốt hơn đặc trưng ngữ âm và thanh điệu của tiếng Việt.

Bên cạnh đó, Student Model sau quá trình Knowledge Distillation vẫn duy trì được chất lượng tổng hợp tiếng nói tương đương Teacher Model, đồng thời đạt kết

quả tốt hơn ở một số chỉ số định lượng. Kết quả này cho thấy Student Model đã kế thừa hiệu quả tri thức từ Teacher Model trong khi giảm độ phức tạp của quá trình suy luận.

Đối với đánh giá định tính, mặc dù điểm UTMOS của các mô hình sau fine-tuning thấp hơn mô hình pretrained, kết quả nghe thử thực tế cho thấy khả năng phát âm tiếng Việt đã được cải thiện đáng kể. Điều này cho thấy việc đánh giá hệ thống Text-to-Speech cần kết hợp giữa các chỉ số khách quan và đánh giá chủ quan để phản ánh chính xác chất lượng tổng hợp tiếng nói.

Về hiệu năng suy luận, Student Model đạt tốc độ xử lý nhanh hơn khoảng 2,2 lần so với Teacher Model và tăng đáng kể thông lượng xử lý. Điều này chứng minh Knowledge Distillation là giải pháp hiệu quả giúp nâng cao khả năng triển khai thực tế của hệ thống mà vẫn duy trì chất lượng tổng hợp tiếng nói. Nhìn chung, đề tài đã hoàn thành mục tiêu tinh chỉnh và triển khai thành công mô hình ZipVoice cho tiếng Việt, đồng thời xây dựng được hệ thống Text-to-Speech có khả năng ứng dụng trong thực tế.

5.4 SO SÁNH VỚI CÁC NGHIÊN CỨU LIÊN QUAN VÀ ĐÓNG GÓP CỦA ĐỀ TÀI

Nhóm so sánh hệ thống đề xuất với vài công trình tiêu biểu gần đây gồm [6], [7] và [8] để đánh giá vị trí của đề tài trong bối cảnh các nghiên cứu Text-to-Speech hiện nay. Các mô hình này đều thuộc nhóm Text-to-Speech dựa trên Flow Matching và có khả năng thực hiện Zero-shot Voice Cloning.

Bảng 5.4: So sánh đề tài và một số hệ thống Text-to-speech gần đây

[6] [7] [8]

Tiêu chí	E2-TTS (2024)	F5-TTS (2024)	ZipVoice (2025)	Đề tài
Flow Matching	Có	Có	Có	Có

Zero-shot Voice Cloning	Có	Có	Có	Có
Average Upsampling	Không	Không	Có	Có
Fine-tune tiếng Việt	Không	Không	Không	Có
Knowledge Distillation	Không	Không	Có	Có
Teacher ODE Steps	32	32	16	16
Student ODE Steps	Không	Không	8	8
Docker Deployment	Không đề cập	Không đề cập	Không đề cập	Có
REST API	Không đề cập	Không đề cập	Không đề cập	Có

Bảng 5.4 cho thấy đề tài kế thừa các đặc điểm chính của kiến trúc ZipVoice như Flow Matching, Zero-shot Voice Cloning và Knowledge Distillation. Bên cạnh đó, đề tài mở rộng khả năng ứng dụng của mô hình thông qua quá trình tinh chỉnh trên dữ liệu tiếng Việt và triển khai hệ thống dưới dạng dịch vụ REST API trong môi trường Docker. Cần lưu ý rằng bảng trên chỉ mang tính chất so sánh đặc điểm hệ thống, không phản ánh sự so sánh trực tiếp về hiệu năng do các nghiên cứu được thực hiện trên những tập dữ liệu và điều kiện thực nghiệm khác nhau.

Để đánh giá trực tiếp hiệu quả của quá trình fine-tuning, nhóm tiếp tục so sánh kết quả giữa mô hình ZipVoice pretrained và hệ thống đề xuất [8].

Bảng 5.5: So sánh giữa mô hình ZipVoice pretrained và hệ thống đề xuất [8]

Tiêu chí	ZipVoice Pretrained	Đề tài
Dữ liệu huấn luyện	Emilia (EN, ZH)	VLSP TTS, VIVOS, Common Voice
Ngôn ngữ mục tiêu	Tiếng Anh, Tiếng Trung	Tiếng Việt
Fine-tuning	Không	Có
WER	118.91%	8.37%
CER (accented)	82.05%	5.04%
Distillation	Có	Có
Docker Deployment	Không đề cập	Có
REST API	Không đề cập	Có

Kết quả thực nghiệm tại Bảng 5.5 cho thấy quá trình fine-tuning đã giúp mô hình ZipVoice thích nghi tốt với đặc trưng ngữ âm tiếng Việt, minh chứng qua việc chỉ số WER giảm từ 118,91% xuống 8,37% và CER giảm từ 82,05% xuống 5,04%. Đồng thời, phương pháp Knowledge Distillation đã tối ưu hóa hiệu năng khi giảm thời gian suy luận từ 1,314 giây xuống còn 0,600 giây trên mỗi câu, giúp giảm RTF và tăng thông lượng xử lý của Student Model mà vẫn duy trì chất lượng âm thanh ổn định.

Thông qua các kết quả đạt được, đề tài đóng góp ba nội dung cốt lõi bao gồm việc cấu hình fine-tuning thành công mô hình ZipVoice cho tiếng Việt, áp dụng kỹ thuật chưng cất tri thức để tối ưu tốc độ suy luận, và triển khai hoàn chỉnh hệ thống dưới dạng REST API trong môi trường Docker hỗ trợ tăng tốc phần cứng qua GPU. Mặc dù không đề xuất kiến trúc mạng mới, nghiên cứu đã chứng minh tính hiệu quả của mô hình đối với ngôn ngữ đích và hoàn thiện trọn vẹn quy trình từ xử lý dữ liệu đến thực nghiệm triển khai ứng dụng.

CHƯƠNG 6

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1 KẾT LUẬN

Trong đề án này, nhóm đã nghiên cứu, tinh chỉnh và triển khai thành công mô hình ZipVoice cho bài toán tổng hợp tiếng nói tiếng Việt và sao chép giọng nói (Zero-shot Voice Cloning). Hệ thống được xây dựng dựa trên mô hình pretrained kết hợp với dữ liệu tiếng Việt nhằm cải thiện khả năng phát âm, thanh điệu và thích nghi với đặc trưng ngữ âm của tiếng Việt.

Trong quá trình thực hiện, nhóm đã xây dựng quy trình tiền xử lý dữ liệu bao gồm chuẩn hóa văn bản, chuyển đổi văn bản sang token, xử lý âm thanh, đóng gói dữ liệu bằng Lhotse Manifest và tổ chức dữ liệu phục vụ huấn luyện. Teacher Model được fine-tune từ pretrained checkpoint của ZipVoice trên dữ liệu tiếng Việt nhằm nâng cao chất lượng tổng hợp tiếng nói.

Kết quả thực nghiệm cho thấy mô hình sau khi fine-tuning đạt chất lượng tổng hợp tiếng nói tốt hơn so với mô hình pretrained ban đầu, thể hiện thông qua các chỉ số đánh giá như WER, CER và UTMOS. Bên cạnh đó, hệ thống có khả năng tổng hợp tiếng nói từ văn bản đồng thời duy trì đặc trưng của người nói từ âm thanh tham chiếu, phù hợp với bài toán Zero-shot Voice Cloning.

Nhóm cũng đã áp dụng phương pháp Knowledge Distillation để huấn luyện Student Model từ Teacher Model. Quá trình này cho phép giảm số bước ODE từ 16 xuống còn 8 bước, góp phần rút ngắn thời gian suy luận và nâng cao khả năng triển khai thực tế của hệ thống.

Ngoài ra, mô hình đã được triển khai thành công dưới dạng dịch vụ HTTP API trên môi trường Docker và GPU NVIDIA, tạo nền tảng cho việc tích hợp vào các ứng dụng thực tế như trợ lý ảo, chatbot hoặc hệ thống đọc văn bản tự động.

6.2 HƯỚNG PHÁT TRIỂN

Trong tương lai, hệ thống có thể được cải thiện bằng cách mở rộng và làm sạch tập dữ liệu tiếng Việt với số lượng người nói lớn hơn, đa dạng hơn về giới tính, độ tuổi và vùng miền. Điều này giúp mô hình học được nhiều đặc trưng giọng nói hơn, từ đó nâng cao chất lượng tổng hợp tiếng nói và khả năng sao chép giọng nói trong các tình huống thực tế.

Bên cạnh đó, có thể tiếp tục nghiên cứu các phương pháp tối ưu hóa mô hình nhằm giảm số bước suy luận, giảm chi phí tính toán và cải thiện tốc độ tổng hợp tiếng nói trên các thiết bị có tài nguyên hạn chế. Các kỹ thuật distillation hoặc tối ưu hóa mô hình khác cũng có thể được áp dụng để nâng cao hiệu năng triển khai.

Ngoài ra, việc nghiên cứu khả năng tổng hợp tiếng nói theo vùng miền hoặc kiểm soát các thuộc tính của giọng nói như tốc độ đọc, ngữ điệu và cảm xúc cũng là những hướng phát triển tiềm năng nhằm nâng cao tính tự nhiên của tiếng nói tổng hợp.

Cuối cùng, hệ thống có thể được tích hợp với các ứng dụng thực tế như trợ lý ảo, chatbot hội thoại, hệ thống đọc văn bản tự động hoặc các nền tảng AI đa phương thức nhằm mở rộng phạm vi ứng dụng của công nghệ Text-to-Speech tiếng Việt.

TÀI LIỆU THAM KHẢO

- [1] Z. Yao và cộng sự, “Zipformer: A Faster and Better Encoder for Automatic Speech Recognition,” arXiv preprint arXiv:2310.11230, 2024. [Online]. Available: <https://arxiv.org/abs/2310.11230>. [Accessed 18 May 2026].
- [2] Y. Lipman và cộng sự, “Flow Matching for Generative Modeling,” arXiv preprint arXiv:2210.02747, 2023. [Online]. Available: <https://arxiv.org/abs/2210.02747>. [Accessed 18 May 2026].
- [3] R. Chevi và cộng sự, “NIX-TTS: Lightweight and End-to-End Text-to-Speech via Module-Wise Distillation,” arXiv preprint arXiv:2203.15643, 2022. [Online]. Available: <https://arxiv.org/abs/2203.15643>. [Accessed 18 May 2026].
- [4] H. Zhu và cộng sự, “ZipVoice: Fast and High-Quality Zero-Shot Text-to-Speech with Flow Matching,” arXiv preprint arXiv:2506.13053, 2025. [Online]. Available: <https://arxiv.org/abs/2506.13053>. [Accessed 18 May 2026].
- [5] H. Siuzdak, “Vocos: Closing the Gap Between Time-Domain and Fourier-Based Neural Vocoders for High-Quality Audio Synthesis,” arXiv preprint arXiv:2306.00814, 2023. [Online]. Available: <https://arxiv.org/abs/2306.00814>. [Accessed 18 May 2026].
- [6] S. E. Eskimez và cộng sự, “E2 TTS: Embarrassingly Easy Fully Non-Autoregressive Zero-Shot TTS,” arXiv preprint arXiv:2406.18009, 2024. [Online]. Available: <https://arxiv.org/abs/2406.18009>. [Accessed 31 May 2026].
- [7] Y. Chen và cộng sự, “F5-TTS: A Fairytaler that Fakes Fluent and Faithful Speech with Flow Matching,” arXiv preprint arXiv:2410.06885, 2024. [Online]. Available: <https://arxiv.org/abs/2410.06885>. [Accessed 31 May 2026].

- [8] Z. Han và cộng sự, “ZipVoice,” 2025. [Online]. Available: <https://github.com/k2-fsa/ZipVoice>. [Accessed 31 May 2026].
- [9] M. Le và cộng sự, “Voicebox: Text-Guided Multilingual Universal Speech Generation at Scale,” arXiv preprint arXiv:2306.15687, 2023. [Online]. Available: <https://arxiv.org/abs/2306.15687>. [Accessed 18 May 2026].
- [10] Y. Saeki và cộng sự, “UTMOS: UTokyo-SaruLab System for VoiceMOS Challenge 2022,” arXiv preprint arXiv:2204.02152, 2022. [Online]. Available: <https://arxiv.org/abs/2204.02152>. [Accessed 31 May 2026].
- [11] B. Desplanques, J. Thienpondt và K. Demuynck, “ECAPA-TDNN: Emphasized Channel Attention, Propagation and Aggregation in TDNN Based Speaker Verification,” in Proc. Interspeech 2020, Shanghai, China, 2020, pp. 3830–3834. [Online]. Available: <https://arxiv.org/abs/2005.07143>. [Accessed 31 May 2026].
- [12] C. Wang và cộng sự, “Neural Codec Language Models are Zero-Shot Text to Speech Synthesizers,” arXiv preprint arXiv:2301.02111, 2023. [Online]. Available: <https://arxiv.org/abs/2301.02111>. [Accessed 31 May 2026].
- [13] R. Ardila và cộng sự, “Common Voice: A Massively-Multilingual Speech Corpus,” in Proc. LREC 2020, Marseille, France, 2020, pp. 4218–4222. [Online]. Available: <https://arxiv.org/abs/1912.06670>. [Accessed 31 May 2026].

DATN ManTien

BÁO CÁO ĐỘC SẮNG

11% CHỈ SỐ TƯƠNG ĐỒNG	9% NGUỒN INTERNET	10% ẤN PHẨM XUẤT BẢN	2% BÀI CỦA HỌC SINH
---------------------------------	-----------------------------	--------------------------------	-------------------------------

NGUỒN CHÍNH

1	www.ctu.edu.vn Nguồn Internet
2	Phenikaa University Xuất bản
3	Ton Duc Thang University Xuất bản
4	text.123docz.net Nguồn Internet
5	uet-test.uet.edu.vn Nguồn Internet
6	Hanoi University Xuất bản
7	Hanoi Pedagogical University 2 Xuất bản
8	Submitted to Ho Chi Minh University of Technology and Education Bài của Học sinh
9	arxiv.org Nguồn Internet

Loại trừ Trích dẫn	Mở	Loại trừ trùng khớp	< 1%
Loại trừ mục lục tham khảo	Mở		