

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT TP.HCM
KHOA ĐIỆN - ĐIỆN TỬ
BỘ MÔN KỸ THUẬT MÁY TÍNH



KHÓA LUẬN TỐT NGHIỆP

**PHÁT HIỆN ĐỐI TƯỢNG TỪ DỮ LIỆU RADAR
THÔNG QUA PHÁT TRIỂN MÔ HÌNH HỌC SÂU**

NGÀNH: CÔNG NGHỆ KỸ THUẬT MÁY TÍNH

Sinh viên: **NGUYỄN HOÀI NAM**

MSSV: 22119200

Hướng dẫn: TS. **HUỲNH THẾ THIÊN**

TP. HỒ CHÍ MINH, 06/2026

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT TP.HCM
KHOA ĐIỆN - ĐIỆN TỬ
BỘ MÔN KỸ THUẬT MÁY TÍNH



KHÓA LUẬN TỐT NGHIỆP

PHÁT HIỆN ĐỐI TƯỢNG TỪ DỮ LIỆU RADAR
THÔNG QUA PHÁT TRIỂN MÔ HÌNH HỌC SÂU

NGÀNH: CÔNG NGHỆ KỸ THUẬT MÁY TÍNH

Sinh viên: **NGUYỄN HOÀI NAM**

MSSV: 22119200

Hướng dẫn: TS. **HUỲNH THẾ THIÊN**

TP. HỒ CHÍ MINH, 06/2026

BẢN NHẬN XÉT KHÓA LUẬN TỐT NGHIỆP

(Dành cho giảng viên hướng dẫn)

Đề tài: PHÁT HIỆN ĐỐI TƯỢNG TỪ DỮ LIỆU RADAR THÔNG QUA PHÁT TRIỂN MÔ HÌNH HỌC SÂU
Sinh viên: Nguyễn Hoài Nam **MSSV:** 22119200
Hướng dẫn: TS. Huỳnh Thế Thiện

Nhận xét bao gồm các nội dung sau đây:

- Tính hợp lý trong cách đặt vấn đề và giải quyết vấn đề; ý nghĩa khoa học và thực tiễn:** Đề tài đi đúng vào bài toán cốt lõi của hệ thống hỗ trợ lái xe tiên tiến (ADAS). Việc chọn dữ liệu Radar FMCW sóng milimet thay vì camera hay LiDAR để xử lý bài toán thời tiết khắc nghiệt thể hiện tính ứng dụng thực tiễn rất cao.
- Phương pháp thực hiện/ phân tích/ thiết kế:** Sinh viên có tư duy thiết kế mạng học sâu. Mô hình RaDecNet không tập trung vào việc mở rộng quy mô mạng mà chú trọng thiết kế các mô-đun chuyên biệt (ARSC, DTSA, SRA) bám sát đặc trưng thưa và bất đẳng hướng của tín hiệu vô tuyến.
- Kết quả thực hiện/ phân tích và đánh giá kết quả/ kiểm định thiết kế:** Kết quả thực nghiệm trên tập dữ liệu CRUW rất ấn tượng. Mô hình đạt Overall AP 88.41% và AR 91.74%. Điểm sáng lớn nhất là sự tối ưu hóa phần cứng tuyệt vời: chỉ tiêu tốn 1.26M tham số, 5.78G FLOPs với độ trễ 18 ms, hoàn toàn có thể đáp ứng được yêu cầu thời gian thực trên các thiết bị nhúng.
- Kết luận và đề xuất:** Phần kết luận bám sát số liệu định lượng thu được. Các đề xuất tiếp tục mở rộng kịch bản thời tiết phức tạp và tối ưu hóa lượng tử hóa cho thiết bị biên (TensorRT/FPGA) mang tính định hướng rất tốt.
- Hình thức trình bày và bố cục báo cáo:** Bố cục khóa luận logic, tuy nhiên trong quá trình soạn thảo, sinh viên còn mắc lỗi đánh máy liên quan đến tham chiếu chéo hình ảnh (gọi tên hình trong văn bản không khớp với chú thích hình thực tế). Lỗi này đã được nhắc nhở và hiệu đính ở bản nộp cuối.
- Kỹ năng chuyên nghiệp và tính sáng tạo:** Sinh viên am hiểu sâu sắc về kiến trúc mạng học sâu (CNN, Attention) và nguyên lý xử lý tín hiệu Radar. Kỹ năng lập trình tối ưu hóa chi phí tính toán mạng nơ-ron là điểm cộng sáng tạo lớn nhất.
- Tài liệu trích dẫn:** Tài liệu tham khảo được lựa chọn nghiêm túc, tập trung vào các công bố uy tín nhất về Computer Vision và Radar Object Detection. Trích dẫn chuẩn xác theo định dạng IEEE.
- Đánh giá về sự trùng lặp của đề tài:** Đề tài mang tính độc lập cao. Kiến trúc RaDecNet cùng ba mô-đun cải tiến là kết quả nghiên cứu và chất xám của sinh viên, không trùng lặp với các hệ thống đã có.
- Những nhược điểm và thiếu sót, những điểm cần được bổ sung và chỉnh sửa:** Khuyết điểm chính nằm ở khâu chế bản (trùng lặp hình ảnh, sai lệch đánh số). Sau khi được chỉ ra, sinh viên đã cập nhật lại định dạng tự động và nộp bản báo cáo hoàn thiện.
- Nhận xét tinh thần, thái độ học tập, nghiên cứu của sinh viên:** Thái độ học tập nghiêm túc, cầu thị, có tinh thần trách nhiệm cao đối với công trình nghiên cứu. Luôn chủ động báo cáo tiến độ và tiếp thu góp ý chuyên môn.

Đề nghị của giảng viên hướng dẫn:

Báo cáo hoàn toàn đạt yêu cầu của một khóa luận tốt nghiệp kỹ sư, và được phép bảo vệ khóa luận tốt nghiệp trước Hội đồng.

Tp. HCM, ngày 23 tháng 06 năm 2026

Người nhận xét
(Ký và ghi rõ họ tên)



TS. Huỳnh Thế Thiện

LỜI CẢM ƠN

Để hoàn thành khóa luận tốt nghiệp này, bên cạnh sự cố gắng và nỗ lực nghiêm túc của bản thân, tôi đã nhận được rất nhiều sự quan tâm, hỗ trợ và giúp đỡ quý báu từ các cá nhân và tập thể. Nhân dịp này, tôi xin được bày tỏ lòng biết ơn chân thành và sâu sắc nhất đến TS. Huỳnh Thế Thiện, người Thầy đã trực tiếp hướng dẫn, đồng hành và định hướng cho tôi trong suốt quá trình thực hiện đề tài. Những chỉ dẫn tận tình, các góp ý mang tính chuyên môn cao cùng sự định hướng rõ ràng của Thầy ngay từ giai đoạn đầu đã giúp tôi từng bước hoàn thiện nội dung nghiên cứu. Không chỉ dừng lại ở vai trò hướng dẫn học thuật, Thầy còn truyền cho tôi niềm đam mê nghiên cứu khoa học, tinh thần làm việc nghiêm túc và tư duy sáng tạo. Sự tận tâm và trách nhiệm của Thầy là nguồn động lực to lớn, góp phần quan trọng vào sự trưởng thành của tôi trong quá trình học tập. Tôi cũng xin gửi lời cảm ơn chân thành đến toàn thể quý thầy cô Khoa Điện - Điện tử, những người đã tận tình giảng dạy, truyền đạt kiến thức nền tảng và chuyên sâu, đồng thời chia sẻ nhiều kinh nghiệm thực tiễn quý báu, tạo điều kiện thuận lợi để tôi có thể hoàn thành đồ án này một cách tốt nhất. Bên cạnh đó, tôi xin bày tỏ lòng biết ơn đến gia đình, bạn bè và những người thân yêu, những người luôn ở bên cạnh động viên, khích lệ và tiếp thêm động lực tinh thần cho tôi trong suốt quá trình học tập và thực hiện đề tài. Mặc dù đã nỗ lực hết khả năng của mình, song do giới hạn về thời gian và kinh nghiệm nghiên cứu, đồ án không tránh khỏi những thiếu sót nhất định. Tôi rất mong nhận được những ý kiến đóng góp quý báu từ quý thầy cô để có thể tiếp tục hoàn thiện nội dung, nâng cao giá trị học thuật và làm cơ sở cho các nghiên cứu tiếp theo trong tương lai.

Sinh viên thực hiện
(Ký và ghi rõ họ tên)



Nguyễn Hoài Nam

LỜI CAM ĐOAN

Tôi, Nguyễn Hoài Nam, sinh viên ngành Công nghệ Kỹ thuật Máy tính, mã số sinh viên 22119200, khoa Điện - Điện tử, Trường Đại học Công nghệ Kỹ thuật Thành phố Hồ Chí Minh, xin cam đoan rằng khóa luận tốt nghiệp với đề tài này là sản phẩm nghiên cứu độc lập và sáng tạo của bản thân. Khóa luận được hoàn thành dựa trên nền tảng kiến thức chuyên môn, kỹ năng nghiên cứu và nỗ lực cá nhân của tôi, không sao chép nội dung hay kết quả của bất kỳ đồ án, bài báo khoa học, hay tài liệu nào khác đã được công bố trước đây. Tất cả nội dung tham khảo từ các nguồn tài liệu khác, bao gồm sách, báo, bài báo khoa học, trang web, v.v., đều được trích dẫn đầy đủ và chính xác theo đúng quy định của trường và các tiêu chuẩn học thuật quốc tế. Tôi cam đoan rằng thông tin trong khóa luận là trung thực và khách quan, không có hành vi gian lận hay đạo văn dưới bất kỳ hình thức nào. Tôi nhận thức được hậu quả của việc vi phạm cam đoan này và sẵn sàng chịu trách nhiệm trước hội đồng và nhà trường nếu có bất kỳ sai phạm nào được phát hiện.

Sinh viên thực hiện
(Ký và ghi rõ họ tên)



Nguyễn Hoài Nam

TÓM TẮT

Trong bối cảnh các hệ thống hỗ trợ lái xe thông minh và phương tiện tự hành ngày càng phát triển, phát hiện đối tượng bằng radar sóng milimet trở thành một hướng nghiên cứu quan trọng nhờ khả năng hoạt động ổn định trong các điều kiện bất lợi như thiếu sáng, mưa, sương mù hoặc nhiễu thị giác mạnh. Tuy nhiên, dữ liệu radar thường có đặc tính thưa, nhiễu lớn, phản xạ không ổn định và khó diễn giải về mặt ngữ nghĩa, khiến việc trích xuất đặc trưng và phát hiện đối tượng trở thành một thách thức đáng kể. Các mô hình học sâu trước đây, đặc biệt là các kiến trúc dựa trên 3D CNN hoặc Transformer, tuy đã đạt được một số kết quả khả quan, nhưng vẫn còn hạn chế về khả năng khai thác đặc trưng bất đẳng hướng, mô hình hóa quan hệ Doppler-thời gian và tối ưu chi phí tính toán cho triển khai thời gian thực.

Để giải quyết những hạn chế đó, đề tài này đề xuất RaDecNet, một kiến trúc học sâu gọn nhẹ dành cho bài toán phát hiện đối tượng bằng radar sóng milimet. Mô hình được xây dựng dựa trên ba mô-đun cải tiến chính: ARSC, DTSA và SRA. Trong đó, ARSC khai thác đặc trưng cục bộ theo các chiều vật lý quan trọng của radar như khoảng cách, góc phương vị và thời gian; DTSA mô hình hóa phụ thuộc Doppler-thời gian nhằm nắm bắt sự biến đổi động học của mục tiêu qua chuỗi khung radar; còn SRA tập trung năng lực trích xuất đặc trưng vào các vùng tín hiệu thưa nhưng giàu thông tin. Sự kết hợp này giúp RaDecNet học được biểu diễn không gian-thời gian phù hợp hơn với bản chất tín hiệu radar, đồng thời hạn chế xử lý dư thừa trên các vùng nền hoặc nhiễu ít liên quan. Về mặt thực nghiệm, mô hình được đánh giá trên tập dữ liệu CRUW và đạt Overall AP 88.41%, Overall AR 91.74%. Khi xét theo từng lớp đối tượng, RaDecNet đạt 87.09% AP và 91.52% AR đối với người đi bộ, 93.06% AP và 95.33% AR đối với người đi xe đạp, đồng thời đạt 87.25% AP và 88.98% AR đối với xe ô tô. Bên cạnh hiệu quả phát hiện, mô hình chỉ sử dụng khoảng 1.26M tham số, 5.78G FLOPs và đạt độ trễ suy luận 18 ms, cho thấy khả năng cân bằng tốt giữa độ chính xác, chi phí tính toán và tốc độ xử lý.

Những kết quả trên khẳng định rằng RaDecNet không chỉ đạt hiệu năng cạnh tranh so với các mô hình radar object detection trước đây, mà còn thể hiện ưu thế về tính gọn nhẹ và khả năng triển khai thực tế. Với thiết kế phù hợp với bản chất vật lý của tín hiệu radar, mô hình đề xuất có tiềm năng ứng dụng trong các hệ thống phát hiện đối tượng thời gian thực, thiết bị biên và các nền tảng hỗ trợ lái xe thông minh trong tương lai.

Mục lục

LỜI CẢM ƠN	i
LỜI CAM ĐOAN	ii
TÓM TẮT	iii
DANH SÁCH CÁC HÌNH ẢNH	vii
DANH SÁCH CÁC BẢNG	ix
DANH MỤC CÁC TỪ NGỮ VIẾT TẮT	x
CHƯƠNG 1 TỔNG QUAN	1
1.1 GIỚI THIỆU	1
1.2 MỤC TIÊU NGHIÊN CỨU	2
1.3 PHƯƠNG PHÁP NGHIÊN CỨU	2
1.4 GIỚI HẠN NGHIÊN CỨU	3
1.5 BỐ CỤC	4
CHƯƠNG 2 CƠ SỞ LÝ THUYẾT	6
2.1 TỔNG QUAN VỀ CÁC CẢM BIẾN TRONG PHÁT HIỆN ĐỐI TƯỢNG CHO ADAS	6
2.1.1 Vai trò của phát hiện đối tượng trong hệ thống ADAS	7
2.1.2 Phân tích đặc tính của cảm biến Camera và LiDAR	9
2.1.3 Phân tích ưu thế của Radar trong các điều kiện vận hành thực tế	10
2.2 CƠ SỞ XỬ LÝ TÍN HIỆU RADAR FMCW	11
2.2.1 Nguyên lý cơ bản của radar sóng milimet	12
2.2.2 Phép biến đổi FFT trong ước lượng khoảng cách và vận tốc . . .	14
2.2.3 Quy trình tạo hình ảnh vô tuyến	16
2.3 TỔNG QUAN VỀ LÝ THUYẾT HỌC SÂU	18
2.3.1 Mạng nơ-ron sâu	19

2.3.2	Mạng nơ-ron tích chập	21
2.3.3	Cơ chế tự chú ý	23
2.4	TỔNG QUAN VỀ CÁC MÔ HÌNH HỌC SÂU TRONG VIỆC PHÁT HIỆN ĐỐI TƯỢNG CHO DỮ LIỆU RADAR FMCW	24
2.4.1	Các mô hình dựa trên 3D CNN	25
2.4.2	Các mô hình dựa trên Transformer	26
2.4.3	Các mô hình tăng cường ngữ cảnh không gian-thời gian	27
2.4.4	Các mô hình gọn nhẹ và định hướng triển khai thực tế	28
2.5	TỔNG QUAN VỀ TẬP DỮ LIỆU CRUW VÀ CƠ CHẾ GIÁM SÁT ĐA PHƯƠNG THỨC	29
2.5.1	Khái niệm về dung hợp Camera-Radar (CRF)	30
2.5.2	Phương pháp sinh nhân tự động cho dữ liệu Radar	31
CHƯƠNG 3 THIẾT KẾ HỆ THỐNG		33
3.1	YÊU CẦU HỆ THỐNG	33
3.2	TỔNG QUAN KIẾN TRÚC HỆ THỐNG	34
3.3	PHƯƠNG PHÁP ĐỀ XUẤT	36
3.3.1	Khối tích chập tách biệt dị hướng	37
3.3.2	Khối chú ý dịch chuyển Doppler - thời gian	41
3.3.3	Khối tổng hợp vùng thừa	44
3.3.4	Các khối chuyển đổi và hợp nhất đặc trưng	48
3.3.5	Kiến trúc mô hình đề xuất	53
3.4	CÀI ĐẶT MÔ PHỎNG	57
3.4.1	Thiết lập môi trường mô phỏng	57
3.4.2	Thiết lập dữ liệu mô phỏng	58
3.4.3	Cấu hình và tham số huấn luyện mô hình	58
3.4.4	Phương pháp đánh giá mô hình	59
CHƯƠNG 4 KẾT QUẢ VÀ THẢO LUẬN		61
4.1	KẾT QUẢ PHÁT HIỆN CỦA MÔ HÌNH ĐỀ XUẤT	61
4.2	SO SÁNH HIỆU QUẢ PHÁT HIỆN QUA TỪNG MÔ-ĐUN CẢI TIẾN	63

4.3	SO SÁNH HIỆU QUẢ PHÁT HIỆN SO VỚI CÁC MÔ HÌNH HỌC SÂU ĐÃ ĐƯỢC ĐỀ XUẤT TRƯỚC ĐÂY	66
CHƯƠNG 5 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN		69
5.1	KẾT LUẬN	69
5.2	HƯỚNG PHÁT TRIỂN	70
PHỤ LỤC		72
TÀI LIỆU THAM KHẢO		73

Danh sách các hình ảnh

Hình 2.1	Hệ thống cảm biến trên phương tiện tự hành trong bộ dữ liệu nuScenes [1].	6
Hình 2.2	Sơ đồ tổng quan về quy trình nhận diện đối tượng đa phương thức, minh họa sự phối hợp giữa các tầng cảm biến để đưa ra dự đoán về môi trường [2].	8
Hình 2.3	Phân loại tổng quan các hệ thống radar theo dạng tín hiệu phát [3].	12
Hình 2.4	Hiệu ứng Doppler trong radar sóng liên tục, trong đó tần số tín hiệu thu thay đổi theo vận tốc tương đối của mục tiêu [4].	13
Hình 2.5	Sơ đồ hệ thống radar FMCW SISO, trong đó tín hiệu thu được trộn với tín hiệu phát để tạo thành tín hiệu IF [5].	13
Hình 2.6	Tín hiệu chirp trong radar FMCW và quá trình tạo tín hiệu IF từ tín hiệu phát và tín hiệu thu [5].	14
Hình 2.7	Quá trình biến đổi Fourier hai chiều trong radar FMCW để ước lượng khoảng cách và vận tốc mục tiêu [5].	15
Hình 2.8	Ước lượng góc tới của mục tiêu trong hệ radar FMCW nhiều anten dựa trên độ lệch pha giữa các tín hiệu thu [5].	16
Hình 2.9	Các dạng biểu diễn dữ liệu radar từ tín hiệu ADC thông qua Range-FFT, Doppler-FFT và Azimuth-FFT [5].	17
Hình 2.10	Kiến trúc cơ bản của một DNN. Các chấm tròn đại diện cho các trọng số học tập	20
Hình 2.11	Kiến trúc CNN cơ bản trong bài toán phân loại đối tượng. Các lớp tích chập và tổng hợp giúp biểu diễn các đặc trưng có trong ảnh .	22
Hình 2.12	Kiến trúc AM cơ bản cấu tạo nên nhiều mô hình học sâu tiên tiến ngày nay.	23
Hình 2.13	Tổng quan kiến trúc mô hình RODNet dựa trên mạng tích chập 3D [2].	25
Hình 2.14	Kiến trúc T-RODNet kết hợp giữa CNN và Swin Transformer [6].	26
Hình 2.15	Mô hình Mask-RadarNet với cơ chế tăng cường ngữ cảnh không gian-thời gian [7].	27

Hình 2.16	Kiến trúc tổng quan của mRadNet dựa trên MetaFormer cho bài toán phát hiện đối tượng bằng radar [8].	28
Hình 3.1	Tổng quan kiến trúc hệ thống mạng phục vụ bài toán nhận dạng đối tượng từ dữ liệu chuỗi thời gian Radar.	35
Hình 3.2	Kiến trúc tổng thể của mô hình RaDecNet đề xuất.	36
Hình 3.3	Kiến trúc khối tích chập tách biệt dị hướng ARSC.	37
Hình 3.4	Kiến trúc khối chú ý dịch chuyển Doppler - thời gian DTSA. . . .	41
Hình 3.5	Kiến trúc khối tổng hợp vùng thưa SRA.	45
Hình 3.6	Kiến trúc khối nhúng token trong mô hình RaDecNet.	49
Hình 3.7	Kiến trúc khối gộp token trong mô hình RaDecNet.	50
Hình 4.1	Kết quả minh họa khả năng phát hiện đối tượng của RaDecNet trên tập dữ liệu CRUW.	62

Danh sách các bảng

Bảng 3.1	Cấu hình môi trường phần mềm và các phiên bản thư viện sử dụng trong thực nghiệm	57
Bảng 3.2	Các tham số huấn luyện mô hình RaDecNet	59
Bảng 4.1	Kết quả thực nghiệm của mô hình RaDecNet trên tập dữ liệu CRUW.	62
Bảng 4.2	Ablation Study của mô hình với các thành phần khác nhau (ARSC, DTSA, SRA).	64
Bảng 4.3	So sánh hiệu quả các mô hình trên tập CRUW.	67

Danh mục các từ viết tắt

Dưới đây là danh mục các từ viết tắt được sử dụng trong khóa luận.

Các từ viết tắt	Định nghĩa
ACC	Adaptive cruise control
ADAS	Advanced driver assistance systems
ADC	Analog-to-Digital Converter
AEB	Autonomous emergency braking
AI	Artificial Intelligence
AM	Self-Attention Mechanism
AP	Average precision
AR	Average recall
ARSC	Anisotropic range-azimuth separable convolution
BCE	Binary Cross-Entropy
CFAR	Constant false alarm rate
CMAM	Class Masking Attention Module
CNN	Convolutional Neural Network
CRF	Camera-radar fusion
CRUW	Chinese Radar Object Detection Dataset
DAM	Dilated Attention Module
DL	Deep Learning
DNN	Deep Neural Network
DTSA	Doppler-temporal shift attention
FC	Fully Connected
FFT	Fast Fourier Transform
FLOPs	Floating point operations
FMCW	Frequency-modulated continuous wave
FN	False Negative
FP	False Positive
FPS	Frames Per Second
GELU	Gaussian Error Linear Unit
GN	Group Normalization
GPU	Graphics Processing Unit
IF	Intermediate frequency
IoU	Intersection over union
LiDAR	Light detection and ranging

LN	Layer Normalization
ML	Machine Learning
MLP	Multi-Layer Perceptron
NLP	Natural Language Processing
OLS	Object Location Similarity
RaDecNet	Radar Detection Network
RAM	Random Access Memory
RAMaps	Range-Azimuth Heatmaps
ReLU	Rectified Linear Unit
RF	Radio frequency
RGB	Red Green Blue
RNN	Recurrent Neural Network
RX	Receiver
SNR	Signal-to-Noise Ratio
SRA	Sparse region aggregator
ToF	Time of flight
TP	True Positive
TPU	Tensor Processing Unit
TX	Transmitter
ULA	Uniform linear array
ViT	Vision Transformer
VRAM	Video Random Access Memory
WFF	Weighted feature fusion

Chương 1

TỔNG QUAN

1.1 GIỚI THIỆU

Trong kỷ nguyên phát triển của giao thông thông minh và phương tiện tự hành, hệ thống hỗ trợ lái xe tiên tiến (advanced driver assistance systems - ADAS) đóng vai trò quan trọng trong việc nâng cao an toàn và khả năng nhận thức môi trường. Trong các hệ thống này, phát hiện chính xác đối tượng xung quanh phương tiện là một nhiệm vụ cốt lõi. Mặc dù các cảm biến như camera và LiDAR (light detection and ranging - LiDAR) cung cấp lượng thông tin giàu ngữ nghĩa với độ phân giải cao, nhưng hiệu năng của chúng lại dễ bị suy giảm trong các điều kiện môi trường bất lợi như thiếu sáng, mưa, sương mù hoặc nhiễu thị giác mạnh. Ngược lại, radar (radio detection and ranging - radar) sóng milimet điều tần liên tục (frequency-modulated continuous wave - FMCW) thể hiện khả năng hoạt động ổn định xuyên suốt trong các điều kiện thời tiết phức tạp, đồng thời cung cấp thông tin trực tiếp về khoảng cách, góc phương vị và động học của mục tiêu, khiến nó trở thành một cảm biến không thể thiếu trong các hệ thống ADAS hiện đại [2].

Tuy nhiên, việc xử lý dữ liệu radar FMCW cũng đặt ra nhiều thách thức đặc thù. Khác với ảnh RGB (Red Green Blue - RGB) trực quan, dữ liệu radar thường tồn tại dưới dạng ảnh tần số vô tuyến (radio frequency image - RF image) hoặc radar tensors, mang đặc tính thưa thớt, mức độ nhiễu nền cao, phản xạ không ổn định và rất khó diễn giải về mặt ngữ nghĩa. Các phương pháp phát hiện truyền thống dựa trên thuật toán CFAR (constant false alarm rate - CFAR) hoặc trích xuất đặc trưng thủ công khó có thể thích ứng với sự biến đổi phức tạp này. Trong khi đó, các mô hình học sâu dựa trên 3D CNN (convolutional neural network - CNN) như RODNet đã chứng minh được khả năng trích xuất đặc trưng không gian-thời gian từ chuỗi ảnh RF, nhưng thường đòi hỏi chi phí tính toán lớn và bị giới hạn trong việc mô hình hóa phụ thuộc dài hạn [2]. Mặt khác, các kiến trúc dựa trên Transformer như T-RODNet hay Mask-RadarNet tuy cải thiện được khả năng học ngữ cảnh toàn cục, song lại kéo theo sự gia tăng mạnh về độ phức tạp tính toán khi áp dụng trên dữ liệu radar dạng chuỗi [6, 7]. Vì vậy, bài toán đặt ra không chỉ dừng lại ở việc nâng cao độ chính xác phát hiện, mà còn phải đảm bảo kiến trúc mô hình đủ gọn nhẹ để có thể triển khai thực tiễn trong các hệ thống yêu cầu xử lý thời gian thực.

Xuất phát từ yêu cầu đó, đề tài đề xuất mô hình **RaDecNet (Radar Detection Network**

- RaDecNet) như một giải pháp học sâu gọn nhẹ, được thiết kế phù hợp tối đa với bản chất vật lý của tín hiệu radar FMCW. Thay vì cải thiện hiệu năng bằng cách mở rộng quy mô mạng một cách thuần túy, RaDecNet tập trung tối ưu hóa thông qua ba cơ chế cốt lõi: Khối tích chập tách biệt dị hướng (anisotropic range-azimuth separable convolution - ARSC) khai thác đặc trưng bất đẳng hướng theo các trục khoảng cách, góc phương vị và thời gian; Cơ chế chú ý dịch chuyển Doppler-thời gian (doppler-temporal shift attention - DTSA) mô hình hóa phụ thuộc Doppler-thời gian nhằm nắm bắt sự biến đổi động học của mục tiêu qua chuỗi khung radar liên tiếp; và cơ chế tổng hợp vùng thưa (sparse region aggregator - SRA) tập trung tài nguyên tính toán vào các vùng tín hiệu thưa nhưng giàu thông tin để hạn chế tối đa ảnh hưởng của nhiễu nền. Nhờ chiến lược thiết kế này, RaDecNet đạt được sự cân bằng chặt chẽ giữa hiệu quả phát hiện, chi phí tính toán và khả năng triển khai thực tế, góp phần xây dựng một hướng tiếp cận tối ưu cho bài toán nhận thức bằng radar trong hệ sinh thái giao thông thông minh.

1.2 MỤC TIÊU NGHIÊN CỨU

Mục tiêu của đề tài này là thiết kế và phát triển một mô hình học sâu gọn nhẹ, hiệu quả và phù hợp với bản chất vật lý của tín hiệu radar FMCW sóng milimet nhằm phục vụ bài toán phát hiện đối tượng trong các hệ thống hỗ trợ lái xe thông minh. Trên cơ sở kế thừa những tiến bộ của các mô hình học sâu trong phát hiện đối tượng bằng radar như 3D CNN, Transformer và MetaFormer, đề tài đề xuất kiến trúc RaDecNet với định hướng đạt được sự cân bằng tối ưu giữa hiệu quả phát hiện và độ phức tạp tính toán. Cụ thể, RaDecNet tích hợp ba mô-đun cải tiến cốt lõi: ARSC để học đặc trưng cục bộ theo ba chiều khoảng cách, góc phương vị và thời gian; DTSA để mô hình hóa phụ thuộc Doppler-thời gian, giúp nắm bắt sự biến đổi động học của đối tượng qua chuỗi khung radar liên tiếp; và SRA để tập trung năng lực trích xuất đặc trưng vào các vùng tín hiệu thưa nhưng giàu thông tin, qua đó giảm thiểu ảnh hưởng của nhiễu nền và các vùng không gian ít liên quan. Tóm lại, mục tiêu cốt lõi của đề tài là xây dựng một mô hình phát hiện đối tượng bằng radar FMCW có khả năng học hiệu quả các biểu diễn không gian-thời gian từ chuỗi ảnh RF, đồng thời duy trì quy mô tham số nhỏ gọn, chi phí tính toán hợp lý và độ trễ suy luận đáp ứng yêu cầu thời gian thực, từ đó đóng góp một giải pháp khả thi cho bài toán nhận thức bằng radar trên các hệ thống nhúng và thiết bị biên.

1.3 PHƯƠNG PHÁP NGHIÊN CỨU

Để đạt được các mục tiêu đã đề ra, đề tài được triển khai dựa trên ba nhóm phương pháp chính: phương pháp nghiên cứu lý thuyết, phương pháp thực nghiệm, và phương

pháp phân tích - tổng hợp.

Phương pháp nghiên cứu lý thuyết: Đề tài nghiên cứu các cơ sở lý thuyết liên quan đến radar FMCW, quá trình biểu diễn tín hiệu dưới dạng ảnh RF, cũng như các đặc trưng cốt lõi của dữ liệu radar như khoảng cách, góc phương vị, thông tin Doppler và sự biến đổi theo chuỗi thời gian. Bên cạnh đó, đề tài tiến hành khảo sát các mô hình học sâu tiêu biểu trong bài toán phát hiện đối tượng bằng radar, bao gồm các kiến trúc dựa trên 3D CNN, Transformer, ConvFormer và MetaFormer, nhằm làm rõ ưu điểm, hạn chế và định vị khoảng trống nghiên cứu. Từ đó, nghiên cứu thiết lập định hướng xây dựng kiến trúc RaDecNet tích hợp ba mô-đun cải tiến trọng tâm gồm ARSC, DTSA và SRA.

Phương pháp thực nghiệm: Phát triển, huấn luyện và đánh giá mô hình RaDecNet trên tập dữ liệu chuẩn CRUW. Quá trình thực nghiệm bao trùm các khâu: tiền xử lý dữ liệu, cấu trúc hóa chuỗi ảnh RF, xây dựng kiến trúc mạng, huấn luyện và kiểm thử mô hình trên các phân lớp đối tượng như người đi bộ (pedestrian), người đi xe đạp (cyclist) và xe ô tô (car). Hiệu năng của hệ thống được đo lường thông qua các chỉ số định lượng tiêu chuẩn như độ chính xác trung bình (average precision - AP), độ nhạy trung bình (average recall - AR), số lượng tham số, số phép tính dấu phẩy động (floating point operations - FLOPs) và độ trễ suy luận. Đồng thời, đề tài tiến hành so sánh đối chiếu RaDecNet với các mô hình tiên tiến đã được công bố nhằm đánh giá khách quan mức độ hiệu quả và tính cạnh tranh của kiến trúc đề xuất.

Phương pháp phân tích – tổng hợp: Dựa trên kết quả thực nghiệm, đề tài phân tích toàn diện hiệu quả phát hiện của RaDecNet trên từng phân lớp mục tiêu cũng như trên tổng thể tập dữ liệu. Song song đó, nghiên cứu tiến hành đánh giá thành phần để làm rõ vai trò độc lập và mức độ bổ trợ lẫn nhau của các mô-đun ARSC, DTSA và SRA trong kiến trúc mạng. Từ các dữ liệu thu thập được, đề tài tổng hợp những ưu điểm, hạn chế và đánh giá tính khả thi của mô hình khi triển khai trong thực tiễn với các hệ thống radar thời gian thực, làm tiền đề đề xuất các hướng phát triển tiếp theo cho nghiên cứu.

1.4 GIỚI HẠN NGHIÊN CỨU

Đề tài tập trung vào việc thiết kế và đánh giá mô hình RaDecNet cho bài toán phát hiện đối tượng từ dữ liệu radar FMCW sóng milimet. Mặc dù mô hình đạt được kết quả khả quan, nghiên cứu vẫn tồn tại một số giới hạn nhất định trong phạm vi triển khai.

Dữ liệu đầu vào: Nghiên cứu được thực hiện trên tập dữ liệu CRUW với chuỗi ảnh RF radar trong các kịch bản giao thông. Do đó, khả năng tổng quát hóa của mô hình trên các bộ dữ liệu radar khác, các loại cảm biến khác hoặc các môi trường giao thông phức

tập hơn vẫn cần được kiểm chứng thêm.

Biểu diễn và tiền xử lý dữ liệu: Đề tài tập trung khai thác dữ liệu radar dưới dạng ảnh RF, trong đó các thông tin về khoảng cách, góc phương vị và thời gian được sử dụng làm đầu vào cho mô hình. Các hướng biểu diễn radar khác như radar đám mây điểm, range-Doppler hoặc dữ liệu đa góc nhìn chưa được khảo sát sâu trong phạm vi nghiên cứu này.

Kiến trúc mô hình: Nghiên cứu tập trung vào kiến trúc RaDecNet với ba mô-đun chính gồm ARSC, DTSA và SRA. Các mô-đun này được thiết kế phù hợp với đặc trưng của dữ liệu radar FMCW, do đó khi áp dụng cho các dạng dữ liệu radar hoặc bài toán nhận thức khác có thể cần điều chỉnh lại kiến trúc và tham số mô hình.

Phương pháp đánh giá: Hiệu quả của mô hình được đánh giá chủ yếu thông qua các chỉ số AP, AR, số lượng tham số, FLOPs và độ trễ suy luận. Trong phạm vi đề tài, các thử nghiệm tập trung vào so sánh với các mô hình học sâu đã công bố và đánh giá thành phần, chưa mở rộng sang kiểm thử thực tế trên phần cứng nhúng hoặc hệ thống radar triển khai ngoài môi trường thật.

1.5 BỐ CỤC

Đề tài được tổ chức thành năm chương, mỗi chương tập trung giải quyết một nội dung cụ thể trong tiến trình nghiên cứu và phát triển mô hình RaDecNet:

- Chương 1: TỔNG QUAN - Giới thiệu bối cảnh nghiên cứu, vai trò của radar FMCW sóng milimet trong các hệ thống ADAS và sự cấp thiết của việc phát triển các mô hình học sâu gọn nhẹ cho bài toán phát hiện đối tượng. Chương này cũng trình bày mục tiêu, phương pháp, giới hạn nghiên cứu và bố cục tổng thể của đề tài.
- Chương 2: CƠ SỞ LÝ THUYẾT - Cung cấp các nền tảng kiến thức liên quan đến radar FMCW, quá trình biểu diễn tín hiệu dưới dạng ảnh RF, các đặc trưng không gian-thời gian của dữ liệu radar, cũng như tổng quan các kiến trúc học sâu tiêu biểu trong lĩnh vực này như 3D CNN, Transformer, ConvFormer, MetaFormer.
- Chương 3: THIẾT KẾ HỆ THỐNG - Trình bày chi tiết kiến trúc đề xuất RaDecNet, bao gồm quy trình tiền xử lý dữ liệu đầu vào, cấu trúc mạng dạng encoder-decoder và ba mô-đun cải tiến cốt lõi bao gồm ARSC, DTSA, SRA. Chương này làm rõ cơ chế mô hình khai thác đặc trưng bất đẳng hướng, mô hình hóa phụ thuộc Doppler-thời gian và tối ưu hóa các vùng tín hiệu thưa.
- Chương 4: KẾT QUẢ VÀ THẢO LUẬN, phân tích kết quả thực nghiệm của RaDec-

Net trên tập dữ liệu chuẩn CRUW thông qua các chỉ số định lượng như Average Precision (AP), Average Recall (AR), độ phức tạp (số tham số, FLOPs) và độ trễ suy luận. Đồng thời, chương này tiến hành đánh giá thành phần (ablation study) và so sánh đối chiếu hiệu năng với các mô hình tiên tiến đã được công bố.


- Chương 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN, tổng hợp các đóng góp và kết quả đạt được, khẳng định tính hiệu quả cùng khả năng triển khai thực tiễn của RaDec-Net. Cuối cùng, chương này đề xuất các hướng nghiên cứu mở rộng như làm giàu tập dữ liệu, nâng cao hiệu năng trong các kịch bản phức tạp, tối ưu hóa cho thiết bị biên và kết hợp hệ thống nhận thức đa cảm biến.

Chương 2

CƠ SỞ LÝ THUYẾT

2.1 TỔNG QUAN VỀ CÁC CẢM BIẾN TRONG PHÁT HIỆN ĐỐI TƯỢNG CHO ADAS

Để hiện thực hóa khả năng vận hành tự chủ trong các môi trường giao thông phức tạp, phương tiện thông minh cần được trang bị một hệ thống nhận thức môi trường có khả năng quan sát, phân tích và diễn giải không gian xung quanh một cách tin cậy. Tương tự như con người không chỉ phụ thuộc vào một giác quan duy nhất khi nhận biết môi trường, các hệ thống hỗ trợ lái xe tiên tiến hiện đại cũng thường kết hợp nhiều loại cảm biến khác nhau nhằm bổ sung ưu điểm và khắc phục hạn chế của từng nguồn dữ liệu riêng lẻ. Trong đó, camera, LiDAR và radar thường được xem là ba thành phần cảm biến quan trọng, đóng vai trò nền tảng trong việc xây dựng biểu diễn không gian đa chiều cho phương tiện tự hành [1].



Hình 2.1: Hệ thống cảm biến trên phương tiện tự hành trong bộ dữ liệu nuScenes [1].

Kiến trúc bố trí cảm biến trên một phương tiện tự hành tiêu biểu được minh họa trong Hình 2.1. Có thể thấy, hệ thống nhận thức không gian thường được thiết kế theo hướng


đa cảm biến, trong đó nhiều camera, radar và LiDAR được lắp đặt tại các vị trí khác nhau trên xe nhằm mở rộng vùng quan sát và tăng độ tin cậy của thông tin môi trường.

Tuy nhiên, mỗi loại cảm biến đều mang những đặc tính vật lý, ưu điểm và giới hạn vận hành riêng. Camera cung cấp thông tin hình ảnh giàu ngữ nghĩa nhưng dễ bị ảnh hưởng bởi điều kiện ánh sáng; LiDAR cho phép thu nhận cấu trúc hình học không gian với độ chính xác cao nhưng có thể suy giảm trong mưa, sương mù hoặc môi trường nhiều hạt phản xạ; trong khi đó, radar có khả năng hoạt động ổn định hơn trong các điều kiện thời tiết bất lợi và cung cấp thông tin liên quan đến khoảng cách, vận tốc và chuyển động của mục tiêu. Vì vậy, việc phân tích đặc điểm của từng loại cảm biến không chỉ giúp làm rõ vai trò của chúng trong hệ thống ADAS, mà còn tạo cơ sở lý luận cho việc phát triển các mô hình học sâu chuyên biệt cho dữ liệu radar FMCW trong các phần tiếp theo của đề tài.

2.1.1 Vai trò của phát hiện đối tượng trong hệ thống ADAS

Trong kỷ nguyên phát triển mạnh mẽ của công nghệ xe tự hành, các hệ thống ADAS đã trở thành tiêu chuẩn cốt lõi nhằm đảm bảo an toàn và tối ưu hóa trải nghiệm vận hành. Để các hệ thống này có thể hoạt động một cách tự chủ và đáng tin cậy, khả năng nhận diện, phân loại và theo dõi chính xác các thực thể trong môi trường xung quanh là một yêu cầu kỹ thuật mang tính tiên quyết. Lấy cảm hứng từ cơ chế quan sát và phản xạ của con người, phân hệ nhận thức chịu trách nhiệm số hóa toàn bộ thế giới thực vào không gian tính toán của phương tiện thông qua sự kết hợp của nhiều phương thức cảm biến bao gồm camera, LiDAR và radar. Theo đánh giá từ các nghiên cứu nền tảng, việc phát hiện đối tượng một cách bền vững đóng vai trò cốt lõi trong việc triển khai các công nghệ tự hành, nơi mà sự thiếu chính xác hoặc độ trễ trong khâu nhận thức có thể dẫn đến những sai lệch nghiêm trọng, gây nguy hiểm trực tiếp đến tính mạng con người [1].

Hơn thế nữa, bài toán phát hiện đối tượng không chỉ dừng lại ở việc xác định sự tồn tại của vật cản, mà còn bao hàm một quy trình phân tích phức tạp bao gồm định vị không gian 3D, ước lượng vận tốc và phân loại thực thể. Theo đó, năng lực này được xem là thành phần then chốt của hệ thống nhận thức môi trường mới, cho phép thực hiện đồng thời các nhiệm vụ phát hiện, định vị và nhận dạng đối tượng với hiệu suất cao [9]. Cụ thể hơn, các thông tin đầu ra từ mô-đun phát hiện đối tượng, chẳng hạn như tọa độ 3D chính xác từ LiDAR, thông tin ngữ nghĩa từ camera và khả năng bám bắt chuyển động từ radar, sẽ đóng vai trò là luồng dữ liệu đầu vào sống còn cho các thuật toán hoạch định quỹ đạo và các hệ thống can thiệp an toàn như phanh khẩn cấp tự động (autonomous emergency braking - AEB) hay kiểm soát hành trình thích ứng (adaptive cruise control - ACC).



Hình 2.2: Sơ đồ tổng quan về quy trình nhận diện đối tượng đa phương thức, minh họa sự phối hợp giữa các tầng cảm biến để đưa ra dự đoán về môi trường [2].

Mặc dù đóng vai trò trọng yếu, việc duy trì độ tin cậy của hệ thống phát hiện đối tượng dưới các điều kiện môi trường biến động vẫn là một thách thức công nghệ lớn. Các hệ thống nhận thức hiện đại thường dựa vào LiDAR để cung cấp đám mây điểm 3D có độ chính xác cao phục vụ cho việc định vị và nhận dạng mục tiêu. Tuy nhiên, cả LiDAR và camera đều bị suy giảm hiệu năng trong các điều kiện thời tiết bất lợi như mưa lớn, sương mù hoặc sương khói [2]. Cụ thể, trong khi camera chịu ảnh hưởng nghiêm trọng do phụ thuộc vào điều kiện chiếu sáng và hiện tượng tán xạ ánh sáng, LiDAR có thể bị nhiễu và suy giảm tầm hoạt động do tương tác của tia laser với các hạt trong môi trường. Trong bối cảnh đó, các hệ thống ADAS đòi hỏi sự hỗ trợ từ các cảm biến vô tuyến có độ bền vững cao hơn, chẳng hạn như radar. Tuy nhiên, trái ngược với hình ảnh RGB giàu thông tin từ camera hay cấu trúc hình học rõ ràng từ LiDAR, việc trích xuất thông tin ngữ nghĩa từ tín hiệu radar được xem là một bài toán thách thức do bản chất nhiễu cao và độ phân giải không gian hạn chế [2]. Các tín hiệu radar thường thiếu chi tiết về kết cấu bề mặt, từ đó gây khó khăn đáng kể cho các phương pháp thị giác máy tính truyền thống vốn được thiết kế cho dữ liệu quang học.

Từ những phân tích trên, có thể khẳng định rằng phát hiện đối tượng là nền tảng sống còn, định hình giới hạn an toàn của mọi hệ thống ADAS. Việc thiết kế một mô hình có khả năng trích xuất thông tin ngữ nghĩa trực tiếp từ radar, cảm biến có độ bền vững cao nhất nhưng khó xử lý nhất, không chỉ giúp khắc phục giới hạn vật lý của LiDAR và

camera mà còn là hướng đi đột phá để hoàn thiện hệ thống nhận thức toàn diện, đảm bảo an toàn tuyệt đối cho xe tự hành trong mọi điều kiện vận hành thực tế.

2.1.2 Phân tích đặc tính của cảm biến Camera và LiDAR

Trong kiến trúc nhận thức ngoại vi của các hệ thống xe tự hành cấp độ cao, camera và LiDAR được coi là những nguồn dữ liệu sơ cấp, đóng vai trò nền tảng trong việc tái cấu trúc môi trường xung quanh. Tuy nhiên, để xây dựng một cơ sở lý thuyết chặt chẽ cho việc đề xuất các mô hình dung hợp cảm biến, cần phải phân tích sâu sắc các đặc tính kỹ thuật và những giới hạn vật lý nội tại của hai công nghệ này.

Lấy cảm hứng từ cơ chế quan sát và phân tích ngữ nghĩa của thị giác con người, cảm biến Camera hoạt động dựa trên việc thu nhận ánh sáng phản xạ để tạo ra các ma trận điểm ảnh RGB với độ phân giải cực cao. Ưu thế lớn nhất của phương thức này nằm ở khả năng cung cấp các đặc trưng ngữ nghĩa phong phú như màu sắc, biển báo giao thông và kết cấu bề mặt của thực thể. Theo khẳng định trong nghiên cứu về mạng RODNet, sự tường minh của hình ảnh RGB cho phép các thuật toán học sâu trích xuất thông tin đối tượng một cách hiệu quả hơn đáng kể so với bản chất nhiễu và rời rạc của tín hiệu vô tuyến [2]. Mặt khác, camera là loại cảm biến thụ động, có chi phí sản xuất thấp và khả năng tích hợp linh hoạt, khiến nó trở thành thành phần không thể thiếu trong mọi gói cảm biến tiêu chuẩn [9].

Tuy nhiên, tính chính xác của Camera lại tỉ lệ thuận với chất lượng nguồn sáng môi trường. Cụ thể hơn, các nghiên cứu thực nghiệm đã chỉ ra rằng trong các kịch bản vận hành bất lợi như ban đêm, sương mù dày đặc hoặc dưới tác động của ánh sáng ngược, hiệu năng của các hệ thống dựa trên cảm biến quang học thuần túy thường bị suy giảm nghiêm trọng, thậm chí dẫn đến mất hoàn toàn khả năng nhận diện đối tượng [9]. Ngoài ra, một hạn chế vật lý kinh điển của Camera là việc thiếu hụt thông tin về chiều sâu thực tế, buộc hệ thống phải sử dụng các thuật toán ước lượng không gian dựa trên hình học đa khung hình, vốn dĩ có độ trễ lớn và sai số tích lũy cao.

Đối với bài toán xác định tọa độ không gian chính xác, cảm biến LiDAR được đưa vào hệ thống như một giải pháp cung cấp thông tin hình học 3D vượt trội. Hoạt động trên nguyên lý đo thời gian lan truyền của xung laser (time of flight - ToF) của các xung laser, LiDAR cho phép tạo ra các đám mây điểm mô tả chi tiết cấu trúc bề mặt vật thể với độ chính xác ở mức centimet. Như đã được phân tích trong tài liệu về bộ dữ liệu nuScenes, việc tích hợp LiDAR giúp bù đắp hoàn hảo cho các khiếm khuyết về định vị không gian mà camera gặp phải, tạo cơ sở cho các tác vụ như phân đoạn thực thể và dự báo quỹ đạo [1].

Mặc dù sở hữu năng lực định vị mạnh mẽ, LiDAR vẫn đối mặt với những rào cản mang tính chiến lược về mặt kỹ thuật và kinh tế. Về mặt vật lý, các xung laser với bước sóng ngắn cực kỳ nhạy cảm với các hạt vật chất trong không khí như giọt mưa, bông tuyết hoặc sương mù. Hiện tượng tán xạ ánh sáng trong các điều kiện này tạo ra một lượng lớn nhiễu điểm, làm suy yếu cường độ tín hiệu phản hồi và gây ra các sai số nghiêm trọng trong việc tái tạo mô hình vật thể [9]. Về mặt kinh tế, chi phí sản xuất một hệ thống LiDAR có độ phân giải cao vẫn ở mức rất đắt đỏ so với Radar và Camera, đồng thời yêu cầu công suất tiêu thụ và tài nguyên tính toán để xử lý hàng triệu điểm dữ liệu mỗi giây là rất lớn.

Tóm lại, sự kết hợp giữa camera và LiDAR mặc dù cung cấp một bức tranh chi tiết về môi trường, nhưng vẫn tồn tại những điểm yếu chí mạng khi đối mặt với các kịch bản thời tiết và ánh sáng cực đoan. Điều này tạo nên một cơ sở lý luận vững chắc cho việc nghiên cứu và tích hợp cảm biến Radar sóng milimet, một phương thức nhận thức có khả năng xuyên thấu vật lý cao, giá thành thấp và tính ổn định tuyệt đối trong mọi điều kiện vận hành, nhằm xây dựng một hệ thống ADAS thực sự an toàn và bền vững.

2.1.3 Phân tích ưu thế của Radar trong các điều kiện vận hành thực tế

Kế thừa những phân tích về rào cản vật lý của camera và LiDAR, việc tìm kiếm một phương thức nhận thức có khả năng duy trì độ tin cậy tuyệt đối trong mọi tình huống giao thông đã thúc đẩy sự phát triển mạnh mẽ của công nghệ Radar sóng milimet. Hoạt động dựa trên việc phát và thu các dải sóng vô tuyến có bước sóng từ 1 đến 10 milimet, phổ biến nhất là băng tần 77 GHz trong các ứng dụng ô tô, radar thể hiện những đặc tính quang học hoàn toàn khác biệt, cho phép giải quyết triệt để các điểm mù của những cảm biến truyền thống.

Ưu thế vượt trội và dễ nhận thấy nhất của Radar nằm ở khả năng xuyên thấu môi trường xuất sắc. Lấy cảm hứng từ nguyên lý truyền sóng điện từ, các bước sóng milimet có kích thước lớn hơn đáng kể so với các hạt sương mù, khói, bụi hay giọt mưa nhỏ. Do đó, hiện tượng tán xạ Rayleigh, nguyên nhân chính gây nhiễu trên LiDAR và camera, bị suy giảm mạnh mẽ khi áp dụng cho tín hiệu radar. Theo khẳng định trong nghiên cứu nền tảng của mạng RODNet, radar thường thể hiện sự bền vững vượt trội so với camera trong các kịch bản lái xe khắc nghiệt, chẳng hạn như điều kiện ánh sáng quá yếu, chói sáng hoặc thời tiết cực đoan [2]. Tính độc lập hoàn toàn với nguồn sáng môi trường này đã biến Radar chi phí thấp trở thành một giải pháp thay thế đầy tiềm năng cho các hệ thống cảm biến quang học thuần túy khi phương tiện vận hành trong các điều kiện khắc nghiệt [9].

Mặt khác, xét về đặc trưng động lực học, Radar sở hữu một năng lực nội tại độc nhất mà không cảm biến quang học nào có được: khả năng đo lường trực tiếp vận tốc xuyên tâm của đối tượng theo thời gian thực. Thay vì phải so sánh sự dịch chuyển của vật thể qua nhiều khung hình liên tiếp, một quá trình tiêu tốn lượng lớn tài nguyên tính toán và dễ phát sinh sai số trễ như trên camera hay LiDAR, radar tận dụng trực tiếp hiệu ứng Doppler từ tín hiệu phản xạ. Cụ thể hơn, sự thay đổi tần số giữa sóng phát đi và sóng dội về cung cấp thông tin vận tốc tức thời với độ chính xác cao. Khả năng phân giải vận tốc này không chỉ giúp hệ thống ADAS dễ dàng tách biệt các đối tượng di chuyển ra khỏi cảnh nền tĩnh mà còn đóng vai trò sống còn trong các hệ thống phanh khẩn cấp tự động.

Hơn thế nữa, radar sóng milimet thế hệ mới có tầm hoạt động rất xa lên tới hơn 200 mét và góc nhìn cực rộng, cho phép hệ thống tự hành nhận thức được các mối nguy hiểm từ khoảng cách an toàn. Tuy nhiên, bất chấp những ưu thế vật lý tuyệt đối này, tín hiệu Radar thô lại tồn tại dưới dạng các phổ tần số vô tuyến vô cùng trù tượng, có độ phân giải không gian thấp và thiếu vắng hoàn toàn các đặc trưng bề mặt.


Tóm lại, radar là một mảnh ghép bắt buộc phải có để đảm bảo tính toàn vẹn của hệ thống nhận thức trên xe tự hành. Sự tương phản giữa ưu thế vật lý vượt trội và sự nghèo nàn về thông tin ngữ nghĩa của Radar chính là cơ sở lý luận nền tảng, đặt ra yêu cầu cấp thiết cho việc nghiên cứu các thuật toán xử lý tín hiệu và mạng học sâu chuyên biệt nhằm dịch các phổ sóng vô tuyến này thành những thông tin đối tượng có ý nghĩa.

2.2 CƠ SỞ XỬ LÝ TÍN HIỆU RADAR FMCW

Radar là một hệ thống cảm biến chủ động có khả năng phát sóng điện từ ra môi trường và thu nhận tín hiệu phản xạ từ các vật thể xung quanh để ước lượng các thông tin như khoảng cách, vận tốc và hướng xuất hiện của mục tiêu [3]. Trong các hệ thống hỗ trợ lái xe tiên tiến, radar sóng milimet ngày càng được sử dụng rộng rãi nhờ khả năng hoạt động ổn định trong nhiều điều kiện bất lợi như thiếu sáng, mưa, sương mù hoặc môi trường có nhiều thị giác mạnh. Khác với camera, radar không phụ thuộc trực tiếp vào ánh sáng môi trường; đồng thời, so với LiDAR, sóng radar có bước sóng dài hơn nên ít bị suy giảm hơn trong một số điều kiện thời tiết bất lợi. Đặc biệt, radar sóng liên tục điều chế tần số (frequency-modulated continuous-wave radar - FMCW radar) không chỉ cung cấp thông tin khoảng cách mà còn có khả năng khai thác vận tốc và góc xuất hiện của mục tiêu, phù hợp với các bài toán phát hiện đối tượng trong môi trường giao thông.

Các hệ thống radar có thể được phân loại dựa trên dạng tín hiệu phát ra, trong đó hai nhóm cơ bản là radar xung và radar sóng liên tục. Radar xung phát ra các xung sóng ngắn và ước lượng khoảng cách dựa trên thời gian bay của tín hiệu. Trong khi đó, radar

sóng liên tục phát tín hiệu liên tục theo thời gian và có thể khai thác sự dịch tần Doppler để ước lượng vận tốc tương đối của mục tiêu [4]. Radar FMCW là một dạng radar sóng liên tục có điều chế tần số, trong đó tần số tín hiệu phát thay đổi theo thời gian để cho phép ước lượng đồng thời khoảng cách và vận tốc của mục tiêu [5]. Phân loại tổng quan các hệ thống radar được minh họa trong Hình 2.3.



Hình 2.3: Phân loại tổng quan các hệ thống radar theo dạng tín hiệu phát [3].

2.2.1 Nguyên lý cơ bản của radar sóng milimet

Đối với radar xung, khoảng cách từ radar đến mục tiêu được xác định dựa trên thời gian bay của tín hiệu. Nếu gọi Δt là thời gian tín hiệu truyền từ radar đến mục tiêu rồi phản xạ trở lại, khoảng cách R được tính bởi:


$$R = \frac{c\Delta t}{2}, \quad (2.1)$$

trong đó c là tốc độ ánh sáng. Hệ số $\frac{1}{2}$ xuất hiện do tín hiệu phải di chuyển hai chiều, từ radar đến mục tiêu và từ mục tiêu phản xạ trở lại radar. Tuy nhiên, cơ chế đo trực tiếp thời gian bay thường không phù hợp với các ứng dụng cự ly gần yêu cầu theo dõi nhiều mục tiêu liên tục trong thời gian thực như trên phương tiện giao thông.

In radar sóng liên tục, vận tốc tương đối của mục tiêu có thể được ước lượng thông qua hiệu ứng Doppler. Khi mục tiêu tiến lại gần hoặc rời xa radar, tần số của tín hiệu phản xạ sẽ bị dịch đi so với tín hiệu phát. Hiệu ứng này được minh họa trong Hình 2.4. Độ dịch tần Doppler được xác định bởi:


$$f_D = \frac{2vf_c}{c}, \quad (2.2)$$

trong đó f_D là tần số Doppler, v là vận tốc tương đối của mục tiêu, f_c là tần số sóng mang và c là tốc độ ánh sáng. Radar sóng liên tục không điều chế có thể đo vận tốc của mục tiêu chuyển động, nhưng không cung cấp trực tiếp thông tin khoảng cách do không có mốc thời gian bay rõ ràng [4].



Hình 2.4: Hiệu ứng Doppler trong radar sóng liên tục, trong đó tần số tín hiệu thu thay đổi theo vận tốc tương đối của mục tiêu [4].

Để khắc phục hạn chế của radar sóng liên tục không điều chế, radar FMCW sử dụng tín hiệu có tần số thay đổi theo thời gian. Một đoạn tín hiệu có tần số biến thiên trong một khoảng thời gian ngắn được gọi là một chirp, và một tập hợp nhiều chirp liên tiếp tạo thành một frame radar. Trong hệ thống FMCW điển hình, tín hiệu phản xạ thu được được trộn với tín hiệu phát để tạo ra tín hiệu trung tần (intermediate frequency - IF). Sơ đồ cơ bản của một hệ thống radar FMCW một Anten phát và một Anten thu được minh họa trong Hình 2.5.




Hình 2.5: Sơ đồ hệ thống radar FMCW SISO, trong đó tín hiệu thu được trộn với tín hiệu phát để tạo thành tín hiệu IF [5].

Giả sử tín hiệu phát có tần số tức thời f_T và pha ϕ_T , còn tín hiệu thu có tần số f_R và pha ϕ_R . Tín hiệu IF sau bộ trộn được xác định bởi:

$$f_{IF} = f_T - f_R, \quad \phi_{IF} = \phi_T - \phi_R. \quad (2.3)$$

Do tín hiệu thu có thể xem như phiên bản bị trễ của tín hiệu phát, độ lệch tần số IF phản ánh trực tiếp thời gian trễ của tín hiệu. Quá trình tạo tín hiệu IF từ chirp phát và chirp thu được minh họa trong Hình 2.6.



Hình 2.6: Tín hiệu chirp trong radar FMCW và quá trình tạo tín hiệu IF từ tín hiệu phát và tín hiệu thu [5].

Nếu S là độ dốc của chirp, thời gian bay của tín hiệu được xác định bởi:

$$\Delta t = \frac{f_{IF}}{S}. \quad (2.4)$$

Thay vào công thức ước lượng khoảng cách, ta thu được:

$$R = \frac{cf_{IF}}{2S}. \quad (2.5)$$

Như vậy, trong một hệ thống FMCW với độ dốc chirp đã biết, khoảng cách của mục tiêu có thể được suy ra từ tần số của tín hiệu IF. Khi trong môi trường có nhiều mục tiêu ở các khoảng cách khác nhau, tín hiệu IF là tổng hợp của nhiều thành phần hình sin có tần số khác nhau; do đó, mỗi mục tiêu sẽ tạo ra một đỉnh trong phổ tần số của tín hiệu IF.

2.2.2 Phép biến đổi FFT trong ước lượng khoảng cách và vận tốc

Để trích xuất thông tin khoảng cách, phép biến đổi Fourier nhanh (fast Fourier transform - FFT) được áp dụng trên trục mẫu của từng chirp. Quá trình này thường được gọi là Range-FFT. Nếu tín hiệu IF rời rạc sau khi lấy mẫu được ký hiệu là $x[n]$, phổ theo chiều khoảng cách được biểu diễn bởi:

$$X[k] = \sum_{n=0}^{N-1} x[n] \exp\left(-j\frac{2\pi kn}{N}\right), \quad (2.6)$$

trong đó N là số mẫu trong một chirp và k là chỉ số tần số. Các đỉnh trong phổ $X[k]$ tương ứng với các phản xạ mạnh tại những khoảng cách nhất định [5].


Bên cạnh khoảng cách, radar FMCW còn có thể khai thác vận tốc mục tiêu thông qua sự thay đổi pha giữa các chirp liên tiếp. Trong thực tế, dịch tần Doppler có thể nhỏ so với tần số sóng mang, nhưng pha của tín hiệu IF lại rất nhạy với các dịch chuyển nhỏ của mục tiêu qua từng chirp. Nếu mục tiêu di chuyển với vận tốc tương đối v trong thời gian chirp T_c , độ thay đổi pha của tín hiệu phản xạ được mô tả bởi:

$$\Delta\phi_R = \frac{4\pi v T_c}{\lambda}, \quad (2.7)$$

trong đó λ là bước sóng của tín hiệu radar. Từ đó, vận tốc tương đối của mục tiêu có thể được suy ra:

$$v = \frac{\lambda \Delta\phi_R}{4\pi T_c}. \quad (2.8)$$

Để thu được thông tin vận tốc trên toàn bộ frame, FFT tiếp tục được áp dụng theo trục chirp. Phép biến đổi này được gọi là Doppler-FFT. Kết quả sau Range-FFT và Doppler-FFT là bản đồ khoảng cách - Doppler (range-Doppler map - RD map), trong đó một chiều biểu diễn khoảng cách và chiều còn lại biểu diễn vận tốc tương đối của mục tiêu. Quá trình biến đổi Fourier hai chiều để tạo bản đồ RD được minh họa trong Hình 2.7 [5].



Hình 2.7: Quá trình biến đổi Fourier hai chiều trong radar FMCW để ước lượng khoảng cách và vận tốc mục tiêu [5].

Ngoài khoảng cách và vận tốc, hướng xuất hiện của mục tiêu cũng là một thông tin quan trọng trong bài toán phát hiện đối tượng. Với radar có nhiều anten thu, góc tới của tín hiệu phản xạ có thể được ước lượng dựa trên độ lệch pha giữa các anten. Giả sử khoảng cách giữa hai anten là d , góc tới của mục tiêu là θ , và bước sóng là λ , độ lệch


pha giữa hai tín hiệu thu được xác định bởi:

$$\Delta\phi_R = \frac{2\pi d \sin \theta}{\lambda}. \quad (2.9)$$

Từ đó, góc tới của mục tiêu được tính bằng:

$$\theta = \arcsin \left(\frac{\Delta\phi_R \lambda}{2\pi d} \right). \quad (2.10)$$


Để tránh nhập nhằng pha, khoảng cách giữa các anten thường cần nhỏ hơn một nửa bước sóng, tức $d < \frac{\lambda}{2}$. Khi có nhiều anten thu được bố trí thành mảng, Azimuth-FFT có thể được áp dụng theo trục anten để trích xuất thông tin góc phương vị của mục tiêu. Nguyên lý ước lượng góc tới trong hệ radar FMCW nhiều anten được minh họa trong Hình 2.8 [5].



Hình 2.8: Ước lượng góc tới của mục tiêu trong hệ radar FMCW nhiều anten dựa trên độ lệch pha giữa các tín hiệu thu [5].

2.2.3 Quy trình tạo hình ảnh vô tuyến

Từ góc nhìn xử lý tín hiệu, dữ liệu radar ban đầu sau khi được lấy mẫu bởi bộ chuyển đổi tương tự - số (analog-to-digital converter - ADC) có thể được tổ chức thành một ma trận ba chiều. Ba chiều này lần lượt tương ứng với số mẫu trong mỗi chirp, số chirp trong một frame và số anten thu. Các phép biến đổi FFT được áp dụng trên từng trục để trích xuất các đại lượng vật lý khác nhau: Range-FFT trên trục mẫu để ước lượng khoảng cách, Doppler-FFT trên trục chirp để ước lượng vận tốc và Azimuth-FFT trên trục anten để ước lượng góc phương vị [5]. Quá trình chuyển đổi từ dữ liệu ADC sang các biểu diễn RD, RA và RAD được minh họa trong Hình 2.9.



Hình 2.9: Các dạng biểu diễn dữ liệu radar từ tín hiệu ADC thông qua Range-FFT, Doppler-FFT và Azimuth-FFT [5].

Tùy thuộc vào số phép FFT được sử dụng và yêu cầu của bài toán, dữ liệu radar có thể được biểu diễn dưới nhiều dạng khác nhau. Nếu áp dụng Range-FFT và Doppler-FFT, ta thu được bản đồ khoảng cách - Doppler (range-Doppler map - RD map). Nếu áp dụng Range-FFT và Azimuth-FFT, ta thu được bản đồ khoảng cách - góc phương vị (range-azimuth map - RA map). Nếu áp dụng cả ba phép biến đổi Range-FFT, Doppler-FFT và Azimuth-FFT, ta thu được khối dữ liệu khoảng cách - góc phương vị - Doppler (range-azimuth-Doppler cube - RAD cube). Mỗi biểu diễn nhấn mạnh một khía cạnh vật lý khác nhau của tín hiệu radar, nhưng đều có điểm chung là biểu diễn các phản xạ của mục tiêu trong miền tần số [5].

Trong các bài toán phát hiện đối tượng bằng học sâu, biểu diễn RA hoặc ảnh tần số vô tuyến thường được sử dụng vì có thể xem như một dạng ảnh nhìn từ trên xuống trong hệ tọa độ radar. Trục khoảng cách biểu diễn độ xa của mục tiêu so với cảm biến, trong khi trục góc phương vị biểu diễn hướng xuất hiện của mục tiêu trong vùng quan sát. So với biểu diễn điểm mây radar, ảnh RF hoặc RA map giữ lại nhiều thông tin phản xạ hơn vì không loại bỏ các vùng có cường độ thấp thông qua bước phát hiện đỉnh. Điều này đặc biệt quan trọng đối với các mục tiêu nhỏ hoặc có phản xạ yếu như người đi bộ và người đi xe đạp [2].

Tuy nhiên, dữ liệu radar vẫn tồn tại nhiều thách thức khi được sử dụng làm đầu vào cho mô hình học sâu. Thứ nhất, bản đồ radar thường có tính thưa cao, trong đó chỉ một phần nhỏ không gian chứa phản xạ có ý nghĩa từ mục tiêu. Thứ hai, độ phân giải giữa các chiều vật lý không đồng nhất; radar thường có độ phân giải tốt hơn theo chiều khoảng cách nhưng hạn chế hơn theo chiều góc phương vị do số lượng anten và cấu hình phần cứng. Thứ ba, tín hiệu radar thường là tín hiệu phức, bao gồm thành phần thực và thành phần ảo, mang thông tin về biên độ và pha. Các đặc điểm này khiến việc thiết kế mô hình học sâu cho radar không thể sao chép trực tiếp từ các mô hình xử lý ảnh RGB thông thường.

Trong phạm vi đề tài này, dữ liệu radar được sử dụng dưới dạng chuỗi ảnh RF/RA liên tiếp. Mỗi mẫu đầu vào gồm nhiều frame radar theo thời gian, trong đó mỗi frame có hai kênh tương ứng với thành phần thực và thành phần ảo của tín hiệu radar. Cách tổ chức này cho phép mô hình khai thác đồng thời thông tin không gian trên mặt phẳng khoảng cách - góc phương vị và thông tin động học qua chuỗi thời gian. Đây cũng là cơ sở để kiến trúc RaDecNet được thiết kế với các mô-đun chuyên biệt như ARSC để khai thác tính dị hướng, DTSA để mô hình hóa phụ thuộc Doppler - thời gian và SRA để tập trung vào các vùng tín hiệu thưa giàu thông tin.

2.3 TỔNG QUAN VỀ LÝ THUYẾT HỌC SÂU

Lý thuyết học sâu (deep learning - DL) là một nhánh trọng yếu trong lĩnh vực trí tuệ nhân tạo (artificial intelligence - AI) và học máy (machine learning - ML), đóng vai trò nền tảng trong việc xây dựng các hệ thống có khả năng tự học và trích xuất tri thức từ dữ liệu quy mô lớn. Trọng tâm của DL là mạng nơ-ron sâu (deep neural network - DNN), một cấu trúc mô phỏng hoạt động của não người với nhiều tầng xử lý thông tin nhằm học các biểu diễn ngày càng trừu tượng và phức tạp.

Khác với các phương pháp học máy truyền thống vốn phụ thuộc nhiều vào đặc trưng được thiết kế thủ công, DNN có khả năng tự động học biểu diễn đặc trưng trực tiếp từ dữ liệu. Cấu trúc của DNN gồm nhiều lớp ẩn (hidden layers), trong đó mỗi lớp thực hiện một phép biến đổi phi tuyến để trích xuất thông tin có ý nghĩa cao hơn so với lớp trước. Quá trình học của DNN được thực hiện thông qua cơ chế lan truyền ngược (backpropagation) và tối ưu hóa hàm mất mát (loss function). Mục tiêu của quá trình này là điều chỉnh trọng số (weights) của các nơ-ron sao cho đầu ra dự đoán tiệm cận giá trị thực tế, giúp mạng dần cải thiện hiệu suất qua từng vòng huấn luyện.

Sức mạnh của DNN nằm ở khả năng biểu diễn dữ liệu ở nhiều mức độ trừu tượng

khác nhau. Các lớp đầu tiên thường học các đặc trưng cơ bản (như cạnh, đường viền, mẫu hình), trong khi các lớp sâu hơn có thể học các cấu trúc phức tạp hơn (như hình dạng, đối tượng, hoặc mối quan hệ ngữ cảnh). Nhờ đó, DNN trở thành công cụ đặc biệt hiệu quả trong các bài toán như nhận dạng hình ảnh, xử lý ngôn ngữ tự nhiên, phát hiện tấn công mạng, và dự đoán hành vi người dùng.

Sự phát triển mạnh mẽ của DL trong thập kỷ qua còn đến từ sự tiên bộ của phần cứng (GPU, TPU), sự sẵn có của dữ liệu lớn (Big Data), và các thuật toán tối ưu hóa tiên tiến. Ngày nay, học sâu không chỉ giới hạn ở DNN mà còn mở rộng ra nhiều kiến trúc khác như mạng nơ-ron tích chập (convolutional neural network - CNN) chuyên cho xử lý dữ liệu không gian, mạng hồi quy (recurrent neural network - RNN) cho dữ liệu chuỗi thời gian, hay các mô hình tự chú ý (attention-based models) và Transformer, vốn đã định hình thể hệ mới của các ứng dụng thông minh.

Như vậy, học sâu không chỉ là một phương pháp, mà là một khuôn khổ lý thuyết cho khả năng học biểu diễn tự động, giúp máy tính tiến gần hơn tới khả năng hiểu, phân tích và ra quyết định một cách thông minh tương tự con người. Các mục tiếp theo sẽ trình bày khái quát những mô hình học sâu tiêu biểu được khảo sát và có liên hệ mật thiết đến đề tài nghiên cứu.

2.3.1 Mạng nơ-ron sâu


Mạng nơ-ron sâu (deep neural network - DNN) là một hệ thống tính toán nhiều tầng được thiết kế nhằm mô phỏng cơ chế xử lý thông tin của não người. Về bản chất, DNN là một chuỗi các thuật toán có khả năng học và trích xuất mối quan hệ phức tạp trong dữ liệu, giúp máy tính có thể tự động nhận dạng, phân loại hoặc dự đoán mà không cần lập trình cụ thể cho từng nhiệm vụ.

Tương tự như cấu trúc của nơ-ron sinh học, mỗi nơ-ron nhân tạo trong DNN thể hiện ở hình 2.10 đóng vai trò như một đơn vị xử lý cơ bản. Nó tiếp nhận các tín hiệu đầu vào (inputs), nhân chúng với trọng số (weights), đại diện cho mức độ quan trọng của từng tín hiệu, rồi cộng dồn và truyền qua hàm kích hoạt (activation function) để tạo ra đầu ra (output). Quá trình này cho phép mạng học cách kết hợp các đặc trưng đơn giản thành các đặc trưng phức tạp hơn qua từng tầng xử lý.

Về mặt cấu trúc, một mạng DNN điển hình bao gồm ba thành phần chính:

- **Lớp đầu vào (Input Layer):** Tiếp nhận dữ liệu ban đầu, với số lượng nơ-ron tương ứng với số đặc trưng (features) của tập dữ liệu.

- **Lớp ẩn (Hidden Layers):** Thực hiện việc học biểu diễn thông qua các phép biến đổi phi tuyến. Số lượng lớp ẩn và nơ-ron trong mỗi lớp là yếu tố quyết định độ sâu và khả năng biểu diễn của mô hình. Nếu mạng quá nông, nó có thể không học được các đặc trưng phức tạp; ngược lại, nếu quá sâu, có thể gây hiện tượng quá khớp (overfitting) hoặc tiêu tốn tài nguyên tính toán. Các lớp này thường được gọi là các lớp kết nối đầy đủ (Fully Connected - FC layers).
- **Lớp đầu ra (Output Layer):** Tạo ra kết quả cuối cùng, có thể là xác suất trong bài toán phân loại hoặc giá trị dự đoán trong bài toán hồi quy.



Hình 2.10: Kiến trúc cơ bản của một DNN. Các chấm tròn đại diện cho các trọng số học tập, giúp rút trích và học các đặc trưng từ dữ liệu đầu vào. Các đường liên nét màu đen đại diện cho các phép nhân giữa các ma trận trọng số, từ đó tính toán đầu ra phân loại mong muốn [10].

Trong quá trình huấn luyện, DNN học cách điều chỉnh các trọng số thông qua thuật toán lan truyền ngược (backpropagation), một cơ chế cập nhật trọng số dựa trên sai lệch giữa đầu ra dự đoán và đầu ra thực tế. Thuật toán này giúp giảm thiểu hàm mất mát (loss function), cho phép mạng dần cải thiện độ chính xác sau mỗi vòng huấn luyện.

DNN hiện được ứng dụng rộng rãi trong nhiều lĩnh vực của đời sống và công nghiệp. Trong xử lý ảnh và thị giác máy tính, DNN được dùng để nhận dạng đối tượng, phân

đoạn ảnh, phát hiện khuôn mặt hay điều khiển xe tự hành. Trong xử lý ngôn ngữ tự nhiên (natural language processing - NLP), DNN giúp cải thiện đáng kể hiệu suất của các hệ thống dịch máy, phân tích cảm xúc, tóm tắt văn bản và nhận dạng giọng nói.

Như vậy, mạng nơ-ron sâu đại diện cho nền tảng cốt lõi của học sâu, mang lại khả năng mô hình hóa những mối quan hệ phi tuyến tính phức tạp trong dữ liệu thực tế. Với tính linh hoạt, khả năng khái quát hóa mạnh mẽ và hiệu suất vượt trội, DNN đã trở thành một công cụ không thể thiếu trong việc giải quyết các bài toán của trí tuệ nhân tạo.

2.3.2 Mạng nơ-ron tích chập


Mạng nơ-ron tích chập (convolutional neural network - CNN) là một trong những mô hình học sâu mang tính đột phá, được thiết kế đặc biệt để xử lý và phân tích dữ liệu có cấu trúc không gian, điển hình là hình ảnh và video. CNN đã trở thành nền tảng cho hầu hết các ứng dụng thị giác máy tính hiện đại, từ nhận dạng khuôn mặt, phát hiện vật thể, đến phân tích ảnh y tế và điều khiển xe tự hành.

Trong quá trình phát triển của học sâu, các nhà nghiên cứu nhận ra rằng việc làm phẳng dữ liệu hình ảnh hai chiều (2D) thành dạng một chiều (1D) để đưa vào mạng nơ-ron sâu truyền thống (DNN) khiến mô hình mất đi thông tin không gian giữa các điểm ảnh. CNN ra đời để khắc phục hạn chế này nhờ khả năng duy trì và khai thác mối tương quan không gian giữa các vùng lân cận của ảnh thông qua các phép tích chập (convolution). Nhờ đó, CNN đã nhanh chóng vượt qua DNN trong hàng loạt bài toán thị giác máy tính phức tạp.

Về mặt cấu trúc, một mạng CNN điển hình bao gồm các thành phần chính sau:

- **Lớp tích chập (Convolutional Layer):** Đây là trái tim của CNN, nơi thực hiện các phép tích chập giữa ảnh đầu vào và các bộ lọc (kernels/filters). Mỗi bộ lọc hoạt động như một cửa sổ trượt, quét qua ảnh để trích xuất các đặc trưng cục bộ như cạnh, góc, họa tiết hoặc cấu trúc phức tạp. Mỗi lớp tích chập có thể học nhiều bộ lọc khác nhau, giúp mạng hiểu sâu hơn về dữ liệu đầu vào.
- **Lớp chuẩn hóa (Batch Normalization):** Giúp ổn định và tăng tốc quá trình huấn luyện bằng cách chuẩn hóa đầu ra của mỗi lớp tích chập, điều chỉnh trung bình và phương sai của dữ liệu trong từng batch. Điều này không chỉ tăng tốc độ hội tụ mà còn giảm hiện tượng quá khớp (overfitting).
- **Hàm kích hoạt (Activation Layer):** Sau mỗi lớp tích chập, một hàm kích hoạt phi tuyến như ReLU (Rectified Linear Unit) được áp dụng để tăng khả năng biểu diễn của mạng và giúp mô hình học được các mối quan hệ phi tuyến trong dữ liệu.

- **Lớp gộp (Pooling Layer):** Có nhiệm vụ giảm kích thước không gian của các bản đồ đặc trưng (feature maps) nhằm giảm số lượng tham số và chi phí tính toán, đồng thời duy trì các đặc trưng quan trọng. Hai dạng gộp phổ biến là max pooling (chọn giá trị lớn nhất) và average pooling (tính trung bình).
- **Lớp kết nối đầy đủ (Fully Connected - FC Layer):** Sau khi các đặc trưng được trích xuất và giảm chiều, các lớp FC thực hiện vai trò phân loại hoặc dự đoán. Đây là nơi các biểu diễn đặc trưng học được được kết hợp để tạo ra quyết định cuối cùng của mạng.



Hình 2.11: Kiến trúc CNN cơ bản trong bài toán phân loại đối tượng. [11].

Hình 2.11 minh họa một cấu trúc cơ bản của CNN với các lớp tích chập, gộp và kết nối đầy đủ. Có thể thấy rằng CNN duy trì được tính tương quan không gian của dữ liệu trong khi giảm đáng kể số lượng trọng số cần huấn luyện, một ưu điểm nổi bật so với DNN truyền thống.


Về mặt hiệu quả, CNN sở hữu ba đặc điểm cốt lõi giúp nó trở thành công cụ mạnh mẽ trong học sâu:

- **Trích xuất đặc trưng cục bộ:** Các bộ lọc cho phép CNN học được các đặc trưng từ mức thấp (như cạnh, điểm góc) đến mức cao (như khuôn mặt, vật thể), giúp mô hình hiểu sâu sắc nội dung của dữ liệu.
- **Chia sẻ trọng số (Weight Sharing):** Các bộ lọc được dùng lặp lại trên toàn bộ ảnh, giúp giảm mạnh số lượng tham số và tránh tình trạng dư thừa thông tin, nhờ đó tăng tính khái quát.
- **Hiệu suất vượt trội:** Nhờ cơ chế học đặc trưng tự động và khả năng tổng quát cao, CNN đã đạt hiệu năng vượt trội trong nhiều bài toán thị giác máy tính, thậm chí trong một số trường hợp còn vượt qua khả năng nhận dạng của con người.

2.3.3 Cơ chế tự chú ý

Cơ chế tự chú ý (Self-Attention Mechanism - AM) là một kỹ thuật tiên tiến trong học sâu, lần đầu được giới thiệu trong công trình nổi tiếng “Attention Is All You Need” của Vaswani và cộng sự (2017) [12]. Cơ chế này đánh dấu một bước ngoặt trong lĩnh vực xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP), và nhanh chóng được mở rộng sang nhiều bài toán khác như dịch máy, tóm tắt văn bản, nhận diện giọng nói, và gần đây là thị giác máy tính.

Tư tưởng cốt lõi của cơ chế tự chú ý dựa trên nguyên tắc: tập trung vào những phần quan trọng nhất của đầu vào. Giống như khi con người đọc văn bản, chỉ chú ý vào những từ hoặc cụm từ mang ý nghĩa chính, thì mô hình học sâu sử dụng AM để tự động xác định các thành phần đầu vào có liên quan nhất đến nhiệm vụ hiện tại.



Hình 2.12: Sơ đồ biểu diễn thuật toán multi-head attention nổi tiếng [12].

Cấu trúc của AM: Một mô hình AM cơ bản bao gồm ba thành phần chính như hình 2.12, được biểu diễn dưới dạng ba vector có cùng kích thước:

- **Query (Q):** Đại diện cho mục tiêu mà mô hình muốn tập trung vào, phản ánh câu hỏi mà mạng đang cố gắng trả lời.
- **Key (K):** Đại diện cho ngữ cảnh hoặc thông tin tham chiếu mà mô hình dùng để xác định xem phần nào của đầu vào có liên quan đến truy vấn.
- **Value (V):** Chứa thông tin thực tế cần được trích xuất dựa trên mối quan hệ giữa Query và Key.

Quá trình tính toán của cơ chế tự chú ý được thực hiện như sau: đầu tiên, mỗi cặp Query-Key được so sánh để tính toán điểm tương đồng (similarity score), phản ánh mức độ liên quan giữa hai phần tử. Sau đó, các điểm này được chuẩn hóa bằng hàm Softmax để đảm bảo tổng trọng số bằng 1. Cuối cùng, mỗi Value được nhân với trọng số tương ứng và cộng gộp lại để tạo ra đầu ra, là biểu diễn mới của dữ liệu, trong đó các phần

quan trọng được làm nổi bật. Quá trình này được mô tả thông qua biểu thức sau:

$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2.11)$$

Trong đó d_k là kích thước của vector Key, được sử dụng để cân bằng tỷ lệ khi tính toán điểm tương đồng.

Lợi ích của AM: Cơ chế tự chú ý mang lại nhiều ưu điểm nổi bật, khiến nó trở thành nền tảng của các mô hình hiện đại như Transformer và ViT (Vision Transformer):

- **Khả năng học phụ thuộc dài hạn:** Không giống như RNN chỉ nắm bắt được mối quan hệ ngắn hạn, AM có thể học được các phụ thuộc xa giữa các phần tử trong chuỗi hoặc các vùng trong ảnh.
- **Tính diễn giải cao:** Trọng số chú ý thể hiện mức độ quan trọng của từng phần đầu vào, giúp con người có thể trực quan hóa và hiểu cách mô hình đưa ra quyết định.
- **Hiệu suất vượt trội:** cho phép mô hình song song hóa quá trình tính toán, giúp tăng tốc độ huấn luyện và cải thiện độ chính xác, đặc biệt trong các mô hình quy mô lớn.


Tuy nhiên, song song với những ưu điểm đó, cơ chế tự chú ý cũng kéo theo chi phí tính toán lớn, đặc biệt khi kích thước đầu vào tăng, do số lượng phép tính tỉ lệ với $O(n^2)$ theo độ dài chuỗi. Điều này khiến các mô hình dựa trên AM trở nên khó triển khai trong các ứng dụng thời gian thực hoặc trên thiết bị có tài nguyên hạn chế.

2.4 TỔNG QUAN VỀ CÁC MÔ HÌNH HỌC SÂU TRONG VIỆC PHÁT HIỆN ĐỐI TƯỢNG CHO DỮ LIỆU RADAR FMCW

Trong những năm gần đây, radar FMCW sóng milimet ngày càng được quan tâm trong các hệ thống ADAS và phương tiện tự hành nhờ khả năng hoạt động ổn định trong nhiều điều kiện môi trường bất lợi như mưa, sương mù, thiếu sáng hoặc nhiễu thị giác mạnh. Khác với camera, vốn cung cấp hình ảnh giàu ngữ nghĩa nhưng dễ bị ảnh hưởng bởi ánh sáng, radar có khả năng đo khoảng cách, góc phương vị và chuyển động của mục tiêu một cách ổn định hơn. Tuy nhiên, dữ liệu radar FMCW thường có dạng RF image hoặc RAD tensor với đặc trưng thưa, nhiễu cao và khó diễn giải trực quan, khiến bài toán phát hiện đối tượng trở nên phức tạp hơn so với ảnh thông thường. Do đó, các mô hình học sâu đã được phát triển nhằm tự động học đặc trưng không gian, thời gian và động học từ dữ liệu radar, thay thế dần các phương pháp xử lý tín hiệu truyền thống dựa trên đặc trưng thủ công. Phần này trình bày tổng quan một số hướng mô hình học sâu tiêu biểu trong bài toán phát hiện đối tượng bằng radar FMCW, bao gồm các mô hình 3D CNN, Transformer, kiến trúc lai ghép và các mô hình gọn nhẹ định hướng triển khai thực tế.

2.4.1 Các mô hình dựa trên 3D CNN

Một trong những hướng tiếp cận nền tảng trong phát hiện đối tượng bằng radar là sử dụng mạng tích chập 3D để học đặc trưng không gian-thời gian từ chuỗi ảnh RF. Tiêu biểu cho hướng này là RODNet, một mô hình phát hiện đối tượng radar theo thời gian thực, sử dụng chuỗi RF images trong hệ tọa độ range-azimuth làm đầu vào và dự đoán bản đồ độ tin cậy của các đối tượng trong trường quan sát radar [2]. Thay vì yêu cầu gán nhãn thủ công trực tiếp trên dữ liệu radar, RODNet sử dụng cơ chế giám sát chéo từ kết quả hợp nhất camera-radar, qua đó tạo ra nhãn huấn luyện dưới dạng confidence map. Kiến trúc tổng quan của RODNet được minh họa trong Hình 2.13, cho thấy cách mô hình tiếp nhận chuỗi ảnh RF và trích xuất đặc trưng không gian-thời gian thông qua các khối tích chập 3D.




Hình 2.13: Tổng quan kiến trúc mô hình RODNet dựa trên mạng tích chập 3D [2].

Các biến thể như RODNet-CDC, RODNet-HG và RODNet-HGwI cho thấy 3D CNN có khả năng khai thác đồng thời đặc trưng không gian và thông tin chuyển động qua nhiều khung radar liên tiếp. Đây là một ưu điểm quan trọng vì dữ liệu radar không chỉ phản ánh vị trí tức thời của mục tiêu mà còn chứa thông tin biến đổi theo thời gian. Tuy nhiên, hạn chế lớn của các mô hình dựa trên 3D CNN là chi phí tính toán cao, số lượng tham số lớn và khả năng mô hình hóa phụ thuộc toàn cục còn hạn chế. Do đó, để đạt hiệu quả cao, các kiến trúc này thường phải mở rộng độ sâu hoặc số kênh, dẫn đến khó triển khai trên các hệ thống nhúng hoặc thiết bị biên có tài nguyên hạn chế.

2.4.2 Các mô hình dựa trên Transformer

Để khắc phục hạn chế của 3D CNN trong việc mô hình hóa quan hệ dài hạn, một số nghiên cứu đã đưa cơ chế attention và Transformer vào bài toán radar object detection. T-RODNet là một đại diện tiêu biểu cho hướng tiếp cận này, kết hợp CNN và Transformer nhằm khai thác đồng thời đặc trưng cục bộ và phụ thuộc toàn cục trong chuỗi RF images [6]. Trong kiến trúc này, CNN giúp trích xuất các đặc trưng không gian cục bộ, trong khi các khối Swin Transformer hỗ trợ mô hình hóa quan hệ giữa nhiều vùng đặc trưng và nhiều khung thời gian. Cấu trúc của T-RODNet được thể hiện trong Hình 2.14, qua đó làm rõ cách mô hình kết hợp giữa khối tích chập và cơ chế attention để tăng cường khả năng biểu diễn đặc trưng radar.




Hình 2.14: Kiến trúc T-RODNet kết hợp giữa CNN và Swin Transformer [6].

Việc đưa Transformer vào phát hiện đối tượng bằng radar giúp cải thiện khả năng nắm bắt ngữ cảnh không gian-thời gian, đặc biệt trong các kịch bản có nhiễu mạnh, nhiều đối tượng hoặc phản xạ không ổn định. Tuy nhiên, cơ chế self-attention thường đi kèm với

chi phí tính toán lớn, đặc biệt khi được áp dụng trên dữ liệu radar dạng chuỗi có kích thước không gian-thời gian cao. Vì vậy, các nghiên cứu sau này thường tập trung vào việc giới hạn phạm vi attention, sử dụng cửa sổ trượt hoặc kết hợp attention với các phép tích chập nhằm cân bằng giữa hiệu năng và độ phức tạp.

2.4.3 Các mô hình tăng cường ngữ cảnh không gian-thời gian

Bên cạnh việc sử dụng Transformer để học phụ thuộc toàn cục, một hướng nghiên cứu khác tập trung vào việc tăng cường ngữ cảnh không gian-thời gian cho biểu diễn radar. Mask-RadarNet là một ví dụ tiêu biểu, được thiết kế nhằm khai thác tốt hơn các đặc trưng ngữ nghĩa phân cấp từ chuỗi RF images [7]. Mô hình này kết hợp xen kẽ giữa tích chập và attention để tận dụng ưu điểm của cả hai cơ chế: tích chập hỗ trợ học đặc trưng cục bộ, còn attention giúp nắm bắt quan hệ ngữ cảnh rộng hơn. Hình 2.15 minh họa kiến trúc tổng thể của Mask-RadarNet, trong đó các thành phần attention và decoder phụ trợ được sử dụng nhằm tăng cường thông tin ngữ cảnh không gian-thời gian cho quá trình phát hiện.




Hình 2.15: Mô hình Mask-RadarNet với cơ chế tăng cường ngữ cảnh không gian-thời gian [7].

Ngoài ra, Mask-RadarNet sử dụng cơ chế patch shift nhằm tăng cường học đặc trưng thời gian với chi phí tính toán thấp hơn, đồng thời đề xuất mô-đun class masking attention để khai thác ngữ cảnh không gian-thời gian có liên quan đến từng lớp đối tượng. Cách tiếp cận này cho thấy trong dữ liệu radar, việc chỉ trích xuất đặc trưng cục bộ là chưa đủ; mô hình cần hiểu được quan hệ giữa vùng phản xạ, thời điểm xuất hiện và lớp đối tượng để nâng cao độ chính xác phát hiện. Tuy nhiên, các kiến trúc dạng này vẫn có độ phức tạp nhất định do sử dụng nhiều thành phần attention và decoder phụ trợ trong quá trình huấn luyện.

2.4.4 Các mô hình gọn nhẹ và định hướng triển khai thực tế

Do các hệ thống radar trên phương tiện thường yêu cầu khả năng suy luận theo thời gian thực, nhiều nghiên cứu gần đây không chỉ tập trung vào việc nâng cao độ chính xác phát hiện, mà còn hướng đến việc giảm thiểu số lượng tham số, độ phức tạp tính toán (floating point operations - FLOPs) và độ trễ suy luận. Điển hình cho hướng tiếp cận này là E-RODNet, một mô hình sử dụng khối ConvFormer làm đơn vị trích xuất đặc trưng chủ đạo, đồng thời tinh chỉnh toán tử SepConv để tương thích tốt hơn với dữ liệu radar 3D không gian-thời gian [13]. Bên cạnh đó, mô hình còn tích hợp cơ chế hợp nhất đặc trưng toàn cục và cải tiến mô-đun hợp nhất chuỗi ngắn, qua đó tăng cường năng lực biểu diễn mà vẫn kiểm soát chặt chẽ độ phức tạp tính toán. Điều này minh chứng cho việc xu hướng thiết kế mô hình radar hiện đại không còn phụ thuộc vào việc mở rộng quy mô mạng một cách thuần túy, mà đang chuyển dịch sang tối ưu hóa kiến trúc để đạt được sự cân bằng giữa hiệu năng, tốc độ và khả năng triển khai thực tế.



Hình 2.16: Kiến trúc tổng quan của mRadNet dựa trên MetaFormer cho bài toán phát hiện đối tượng bằng radar [8].

Gần đây, mRadNet tiếp tục kế thừa định hướng này thông qua việc ứng dụng kiến trúc MetaFormer vào bài toán phát hiện đối tượng bằng radar [8]. Thay vì phụ thuộc hoàn toàn vào cơ chế self-attention với chi phí tính toán đắt đỏ, mRadNet sử dụng các token mixer kết hợp giữa separable convolution và attention nhằm hòa quyện khả năng học đặc trưng cục bộ lẫn toàn cục. Đồng thời, các chiến lược như token embedding, token merging cùng cấu trúc encoder-decoder giúp mô hình tiết giảm tài nguyên xử lý mà vẫn bảo toàn năng lực biểu diễn đặc trưng không gian-thời gian của dữ liệu radar. Kiến trúc tổng quan của mRadNet được minh họa trong hình 2.16, thể hiện rõ triết lý thiết kế mô hình gọn nhẹ (compact) cho radar object detection.

Nhìn chung, các mô hình gọn nhẹ như CompactRADNet, E-RODNet và mRadNet cho thấy một xu thế thiết yếu trong phát hiện đối tượng bằng radar FMCW: mô hình không chỉ cần đạt độ chính xác cao, mà còn phải đáp ứng các ràng buộc khắt khe về số lượng tham số, FLOPs, độ trễ suy luận và khả năng triển khai trên thiết bị biên. Tuy nhiên, bài toán cân bằng giữa hiệu quả phát hiện, chi phí tính toán và khả năng mô hình hóa đặc trưng radar vẫn là một thách thức mở. Đây chính là tiền đề để nghiên cứu phát triển RaDecNet, một kiến trúc được thiết kế chuyên biệt nhằm khai thác triệt để đặc trưng bất đẳng hướng, phụ thuộc Doppler-thời gian và các vùng tín hiệu thừa trong dữ liệu radar FMCW.

2.5 TỔNG QUAN VỀ TẬP DỮ LIỆU CRUW VÀ CƠ CHẾ GIÁM SÁT ĐA PHƯƠNG THỨC

Như đã phân tích trong các phần trước, mặc dù radar sóng milimet sở hữu năng lực vận hành bền vững tuyệt đối dưới các điều kiện vật lý khắc nghiệt, phổ tín hiệu thô của cảm biến này lại tồn tại dưới dạng các ma trận vô tuyến vô cùng trừu tượng. Sự thiếu hụt trầm trọng về các đặc trưng kết cấu bề mặt và độ phân giải không gian khiến cho việc gán nhãn thủ công trên dữ liệu radar trở thành một nhiệm vụ gần như bất khả thi đối với con người. Lấy cảm hứng từ khả năng liên kết và chuyển giao kiến thức đa giác quan của hệ thống thần kinh, cơ chế học giám sát chéo (cross-modal supervision) đã nổi lên như một giải pháp mang tính đột phá nhằm giải quyết triệt để rào cản dữ liệu này trong hệ thống xe tự hành [14].

Mặt khác, nguyên lý cốt lõi của phương pháp giám sát chéo được xây dựng dựa trên mô hình thầy - trò (teacher-student paradigm). Trong đó, cảm biến quang học như camera, vốn sở hữu lượng thông tin ngữ nghĩa phong phú và dễ dàng được phân tích bởi các thuật toán thị giác máy tính trưởng thành, sẽ đảm nhận vai trò như người hướng dẫn (teacher) [2]. Ở chiều ngược lại, mạng nơ-ron xử lý dữ liệu radar sẽ đóng vai trò học sinh

(student), học cách trích xuất và dự đoán các thông tin vị trí không gian tương tự như camera, nhưng chỉ từ đầu vào là hình ảnh vô tuyến.

Cụ thể hơn, quá trình chuyển giao tri thức này chỉ được thực hiện trong giai đoạn huấn luyện dưới điều kiện môi trường lý tưởng như ban ngày, ánh sáng tốt,... để đảm bảo camera có thể tạo ra các nhãn dán tự động với độ tin cậy cao nhất. Sự ưu việt của tư duy này đã được chứng minh qua các nghiên cứu tiên phong, tiêu biểu như việc sử dụng camera để dạy mạng vô tuyến nhìn xuyên tường [15], hay mạng RODNet trong việc chuyển đổi tọa độ 3D thành bản đồ độ tin cậy [2]. Tóm lại, việc ứng dụng cơ chế giám sát chéo không chỉ loại bỏ hoàn toàn chi phí gán nhãn dữ liệu khổng lồ mà còn ép buộc mạng Radar phải học được các biểu diễn đặc trưng mang tính ngữ nghĩa, tạo nền tảng lý thuyết vững chắc cho các thuật toán dung hợp không gian sẽ được trình bày chi tiết trong các tiểu mục tiếp theo.

2.5.1 Khái niệm về dung hợp Camera-Radar (CRF)

Trong kiến trúc nhận thức của phương tiện tự hành, dung hợp camera-radar (camera-radar fusion - CRF) là quy trình tích hợp các đặc trưng dữ liệu từ cảm biến quang học và cảm biến vô tuyến nhằm tạo ra một mô hình biểu diễn môi trường toàn diện và chính xác hơn so với việc sử dụng các cảm biến đơn lẻ. Lấy cảm hứng từ tính bổ trợ tự nhiên về mặt vật lý, CRF tận dụng tối đa ưu thế về thông tin ngữ nghĩa của camera và năng lực đo lường động lực học bền vững của radar [14]. Cụ thể hơn, trong khi camera cung cấp độ phân giải góc cực cao và chi tiết về hình dáng đối tượng, radar lại đóng vai trò là nguồn dữ liệu tin cậy về khoảng cách và vận tốc tức thời, ngay cả trong các điều kiện môi trường mà thị giác máy tính truyền thống bị suy giảm hiệu năng [16].

Mặt khác, việc thiết lập khái niệm CRF trong bài toán phát hiện đối tượng thường được phân loại dựa trên các cấp độ dung hợp dữ liệu khác nhau. Theo các nghiên cứu tổng quan về nhận diện đa phương thức, quy trình này có thể diễn ra ở cấp độ dữ liệu thô, cấp độ đặc trưng hoặc cấp độ ra quyết định [14]. Tuy nhiên, trong khung lý thuyết của đề tài, khái niệm CRF được mở rộng sang một vai trò đặc thù: dung hợp để định vị 3D và gán nhãn [2]. Trong kịch bản này, các hộp bao 2D từ camera được kết hợp với các đỉnh năng lượng trên bản đồ nhiệt radar để xác định tọa độ thực thể trong không gian ba chiều. Sự giao thoa này cho phép hệ thống chiếu các đặc trưng ngữ nghĩa từ miền hình ảnh sang miền vô tuyến, từ đó giải quyết bài toán thiếu hụt thông tin không gian của Radar [2].

Hơn thế nữa, tính chặt chẽ của khái niệm CRF còn nằm ở khả năng khử nhiễu và loại bỏ các mục tiêu giả. Radar vốn dĩ rất nhạy cảm với các nhiễu phản xạ từ mặt đường hoặc

các vật thể tĩnh, trong khi camera có thể bị đánh lừa bởi bóng đổ hoặc các hình ảnh trên biển quảng cáo. Thông qua cơ chế kiểm chứng chéo trong CRF, một đối tượng chỉ được xác nhận tồn tại khi và chỉ khi có sự đồng nhất về mặt hình học từ radar và sự xác nhận về mặt thực thể từ camera [17]. Tóm lại, dung hợp Camera-Radar không chỉ đơn thuần là việc cộng dồn dữ liệu, mà là một quy trình tối ưu hóa toán học nhằm trích xuất các nhãn dán mềm có độ tin cậy cao. Đây chính là trái tim của cơ chế giám sát chéo, cho phép mạng nơ-ron học được cách nhận diện đối tượng trong miền Radar mà không cần đến sự can thiệp thủ công của con người [2].

2.5.2 Phương pháp sinh nhãn tự động cho dữ liệu Radar

Để giải quyết bài toán thiếu hụt dữ liệu gán nhãn trong miền vô tuyến, quy trình gán nhãn tự động đóng vai trò là nhịp cầu chuyển giao tri thức từ cảm biến quang học sang cảm biến radar. Lấy cảm hứng từ khả năng phân tích ngữ nghĩa vượt trội của thị giác máy tính, tác giả thiết lập một quy trình xử lý đa tầng nhằm trích xuất các nhãn dán giả có độ tin cậy cao từ Camera để phục vụ huấn luyện mạng Radar Student. Quá trình này không chỉ đơn thuần là việc sao chép tọa độ, mà là một chuỗi các phép biến đổi hình học và tối ưu hóa xác suất nhằm đồng nhất hóa hai không gian dữ liệu hoàn toàn khác biệt [2].

Giai đoạn khởi đầu của quy trình là việc thực hiện phát hiện đối tượng 2D và ước lượng tọa độ không gian 3D từ hình ảnh Camera. Sử dụng các mạng nơ-ron mạnh mẽ như Faster R-CNN [18] kết hợp với các giải pháp định vị 3D đơn mục, hệ thống xác định được hộp bao 3D của thực thể trong hệ tọa độ Camera. Theo các nghiên cứu về định vị vật thể trong cảnh quan đường phố của Wang [19], tọa độ thực của đối tượng (x, y, z) trong không gian 3D được tác giả trích xuất từ tọa độ điểm ảnh (u, v) thông qua ma trận nội chiếu của Camera:

$$x = \frac{z(u - c_u)}{f_u}, \quad y = \frac{z(v - c_v)}{f_v} \quad (2.12)$$

Trong đó f_u, f_v là tiêu cự và c_u, c_v là điểm chính của ống kính. Mặt khác, để có thể gán nhãn chính xác lên các bản đồ nhiệt radar (RAMaps), các tọa độ này cần được chuyển đổi sang hệ tọa độ cực tương ứng với góc nhìn của cảm biến radar sóng milimet. Tác giả tiến hành thực hiện phép biến đổi tọa độ theo các biểu thức sau [2]:

$$\rho = \sqrt{x^2 + z^2}, \quad \phi = \arctan\left(\frac{x}{z}\right) \quad (2.13)$$

Với ρ là khoảng cách và ϕ là góc hướng của đối tượng đối với tâm cảm biến.

Tuy nhiên, do sự sai lệch tiềm tàng về mặt thời gian và độ phân giải giữa hai cảm

biến, việc sử dụng các nhãn dán dạng hộp bao cứng thường gây ra hiện tượng mất hội tụ cho mạng nơ-ron radar. Để khắc phục hạn chế này, khung lý thuyết của RODNet đề xuất việc sử dụng các bản đồ nhiệt độ tin cậy thay thế cho nhãn dán truyền thống [2]. Cụ thể hơn, nhãn dán giả tại vị trí (r_0, a_0) được biểu diễn bởi một phân phối Gaussian hai chiều, phản ánh sự không chắc chắn về vị trí không gian của đối tượng. Giá trị độ tin cậy L tại một điểm (r, a) trên RAMap được xác lập bởi công thức [2]:

$$L(r, a) = \exp \left(-\frac{(r - r_0)^2}{2\sigma_r^2} - \frac{(a - a_0)^2}{2\sigma_a^2} \right) \quad (2.14)$$

Trong đó σ_r và σ_a là các tham số điều khiển độ lan tỏa của nhãn dán theo chiều khoảng cách và góc hướng, giúp mô hình hóa kích thước vật lý của thực thể trong miền vô tuyến.

Cuối cùng, tính chặt chẽ của quy trình gán nhãn tự động còn được củng cố bằng cơ chế kiểm chứng tính nhất quán theo thời gian. Thông qua việc sử dụng các thuật toán theo dõi đối tượng trên Camera, hệ thống loại bỏ các nhãn dán giả phát sinh từ nhiễu nhất thời hoặc các sai số định vị cục bộ [20]. Tóm lại, quy trình gán nhãn tự động là một hệ thống tinh vi kết hợp giữa hình học chiếu và xác suất học sâu, cho phép tạo ra nguồn dữ liệu huấn luyện dồi dào và chính xác cho mạng Radar mà không cần sự can thiệp của con người. Đây chính là nền tảng sống còn để hiện thực hóa khả năng nhận diện đối tượng bền vững trong mọi điều kiện ánh sáng thông qua cơ chế giám sát chéo [2].

Chương 3

THIẾT KẾ HỆ THỐNG

3.1 YÊU CẦU HỆ THỐNG

Hệ thống được xây dựng với mục tiêu phát triển một kiến trúc học sâu có độ tin cậy cao cho bài toán nhận dạng và định vị đối tượng từ dữ liệu radar mmWave. Đây là một nhiệm vụ đầy thách thức do đặc tính vốn có của tín hiệu radar, bao gồm tính thừa thớt trong không gian biểu diễn, sự mất cân bằng về độ phân giải giữa các chiều dữ liệu và sự biến thiên phức tạp trong chuyển động của các đối tượng giao thông. Trên cơ sở đó, một số yêu cầu cốt lõi được đặt ra nhằm định hướng quá trình thiết kế và đánh giá hệ thống như sau:


- **Khả năng định vị và phân loại đối tượng chính xác:** Hệ thống phải có khả năng học và khai thác hiệu quả các đặc trưng không gian - thời gian từ chuỗi bản đồ nhiệt radar nhằm nhận dạng chính xác các đối tượng tham gia giao thông. Khi được đánh giá trên tập dữ liệu chuẩn CRUW, mô hình cần duy trì khả năng phát hiện ổn định đối với ba lớp mục tiêu chính gồm người đi bộ, người đi xe đạp và xe ô tô. Bên cạnh độ chính xác phân loại, hệ thống còn phải đảm bảo khả năng định vị đáng tin cậy trong các tình huống thực tế có mật độ nhiễu nền cao, sự giao thoa tín hiệu hoặc hiện tượng che khuất giữa các đối tượng.
- **Hiệu năng vượt trội so với các kiến trúc học sâu hiện có:** Một trong những mục tiêu trọng tâm của nghiên cứu là chứng minh hiệu quả của kiến trúc RaDecNet thông qua việc tích hợp các mô-đun ARSC, DTSA và SRA vào cùng một khuôn khổ xử lý thống nhất. Các thành phần này được kỳ vọng sẽ nâng cao khả năng biểu diễn đặc trưng, tăng cường năng lực mô hình hóa quan hệ không gian - thời gian và cải thiện tính tổng quát hóa của mạng. Hiệu quả của phương pháp đề xuất cần được đánh giá một cách khách quan thông qua việc so sánh với các mô hình tiêu biểu trong lĩnh vực, từ các kiến trúc CNN truyền thống như RODNet đến các phương pháp hiện đại ứng dụng cơ chế chú ý hoặc Transformer gọn nhẹ như mRadNet, CompactRADNet và E-RODNet. Sự cải thiện về hiệu năng được định lượng bằng các thước đo chuẩn mực, bao gồm độ chính xác trung bình (average precision - AP) và độ nhạy trung bình (average recall - AR).
- **Kiểm soát độ phức tạp tính toán và tối ưu hóa tài nguyên phần cứng:** Bên cạnh yêu cầu về độ chính xác, hệ thống cần được thiết kế theo định hướng tối ưu hóa hiệu

quả tính toán nhằm bảo đảm khả năng triển khai thực tiễn. Kiến trúc đề xuất phải đạt được sự cân bằng giữa năng lực biểu diễn đặc trưng và chi phí xử lý, tránh việc gia tăng quá mức số lượng tham số hoặc khối lượng tính toán. Điều này đặc biệt quan trọng đối với các môi trường triển khai có nguồn tài nguyên hạn chế như máy tính cấu hình phổ thông hoặc các thiết bị biên phục vụ xử lý thời gian thực. Để đánh giá toàn diện mức độ tối ưu hóa của mô hình, các chỉ số về độ phức tạp tính toán cần được phân tích và định lượng chặt chẽ, bao gồm tổng số lượng tham số, dung lượng lưu trữ mô hình và số lượng phép toán dấu phẩy động.

3.2 TỔNG QUAN KIẾN TRÚC HỆ THỐNG

Nhằm đáp ứng đồng thời yêu cầu về độ chính xác nhận dạng và hiệu quả tính toán trong các bài toán cảm nhận môi trường bằng radar, nghiên cứu này đề xuất một kiến trúc học sâu chuyên biệt mang tên RaDecNet. Mô hình được thiết kế để khai thác trực tiếp các tín hiệu vô tuyến thu nhận từ những kịch bản giao thông thực tế, qua đó giải quyết các thách thức đặc trưng của dữ liệu radar mmWave như sự thưa thớt trong không gian biểu diễn, tỷ lệ tín hiệu trên nhiễu thấp và mức độ biến thiên cao của môi trường quan sát. Thông qua sự phối hợp chặt chẽ giữa các mô-đun xử lý được tổ chức theo cấu trúc phân cấp, RaDecNet cho phép trích xuất, tổng hợp và biểu diễn hiệu quả các đặc trưng không gian - thời gian giàu ngữ nghĩa từ dữ liệu radar thô. Trên nền tảng đó, hệ thống thực hiện quá trình nhận dạng và định vị đối tượng với độ chính xác cao, đồng thời duy trì mức độ phức tạp tính toán hợp lý. Sự cân bằng giữa năng lực biểu diễn và hiệu suất vận hành giúp kiến trúc đề xuất không chỉ nâng cao chất lượng dự đoán mà còn đảm bảo khả năng huấn luyện và suy luận trên các nền tảng phần cứng phổ thông, đáp ứng yêu cầu triển khai trong thực tế. Tổng quan về kiến trúc hệ thống cùng luồng xử lý dữ liệu được minh họa trong Hình 3.1.

Ở giai đoạn đầu tiên, hệ thống tiến hành tiền xử lý dữ liệu và nhúng đặc trưng nhằm xây dựng biểu diễn đầu vào giàu thông tin cho các bước xử lý tiếp theo. Tín hiệu thô thu nhận từ cảm biến radar mmWave trước hết được biến đổi sang miền tần số, tạo thành chuỗi bản đồ nhiệt khoảng cách - góc phương vị, qua đó phản ánh trực quan phân bố cường độ phản xạ của các đối tượng trong môi trường quan sát. Tiếp theo, chuỗi dữ liệu đầu vào từ bộ dữ liệu chuẩn CRUW được đưa qua mạng trích xuất đặc trưng cơ sở kết hợp với khối nhúng mã thông báo. Quá trình này không chỉ giúp giảm thiểu sự dư thừa trong không gian vật lý của dữ liệu radar mà còn ánh xạ các phân bố năng lượng thô sang không gian đặc trưng có chiều cao hơn, từ đó làm nổi bật các thông tin ngữ nghĩa quan trọng và tạo nền tảng cho việc học biểu diễn không gian - thời gian hiệu quả ở các tầng mạng phía sau.




Hình 3.1: Tổng quan kiến trúc hệ thống mạng phục vụ bài toán nhận dạng đối tượng từ dữ liệu chuỗi thời gian Radar.

Tiếp theo, hệ thống bước vào giai đoạn mã hóa không gian - thời gian và tích hợp vùng thưa, đây là thành phần cốt lõi chịu trách nhiệm xây dựng các biểu diễn đặc trưng giàu ngữ nghĩa từ dữ liệu radar đã được nhúng. Nhằm giải quyết sự mất cân bằng về độ phân giải và mật độ thông tin giữa các chiều khoảng cách, góc phương vị và thời gian, kiến trúc đề xuất sử dụng các khối tích chập tách biệt dị hướng để học và khai thác đặc trưng theo từng chiều một cách độc lập. Cách tiếp cận này cho phép mô hình thích nghi hiệu quả với đặc tính vật lý không đồng nhất của dữ liệu radar, đồng thời nâng cao khả năng bảo toàn các thông tin cấu trúc quan trọng.

Trên nền tảng đó, các mối quan hệ động học và sự biến thiên theo thời gian của các đối tượng chuyển động được mô hình hóa thông qua cơ chế chú ý Doppler - thời gian dịch chuyển. Bằng việc tích hợp tri thức tiên nghiệm Gauss về độ lệch Doppler vào quá trình tính toán trọng số chú ý, mô-đun này giúp tăng cường khả năng nhận biết quỹ đạo chuyển động và duy trì tính nhất quán của biểu diễn đặc trưng qua các khung thời gian liên tiếp. Đồng thời, để giảm thiểu ảnh hưởng của nhiễu nền và tối ưu hóa chi phí tính toán, bộ tổng hợp vùng thưa được triển khai như một cơ chế chọn lọc thích nghi, tập trung xử lý các vùng có xác suất chứa mục tiêu cao trong khi loại bỏ các khu vực ít thông tin. Nhờ đó, hệ thống vừa nâng cao hiệu quả khai thác đặc trưng vừa duy trì khả năng vận hành với độ phức tạp tính toán hợp lý.

3.3 PHƯƠNG PHÁP ĐỀ XUẤT

Mục tiêu của đề tài là phát triển một mô hình học sâu gọn nhẹ nhằm phát hiện các đối tượng giao thông từ dữ liệu radar FMCW sóng milimet, bao gồm các lớp mục tiêu chính như xe ô tô, người đi bộ và người đi xe đạp. Đây là một bài toán nhiều thách thức do tín hiệu radar trong môi trường thực tế thường chịu ảnh hưởng bởi nhiễu nền, phản xạ đa đường, sự giao thoa giữa các nguồn phản xạ và tính thưa vón có của không gian radar. Bên cạnh đó, yêu cầu triển khai trong các hệ thống hỗ trợ lái xe thông minh cũng đặt ra các ràng buộc nghiêm ngặt về số lượng tham số, chi phí tính toán và độ trễ suy luận. Để giải quyết đồng thời các vấn đề trên, đề tài đề xuất kiến trúc RaDecNet theo dạng mã hóa - giải mã đa tầng, có khả năng xử lý trực tiếp chuỗi ảnh radar và sinh ra bản đồ độ tin cậy phục vụ cho nhiệm vụ phát hiện đối tượng. Kiến trúc tổng quan của mô hình đề xuất được minh họa trong Hình 3.2, thể hiện luồng xử lý từ dữ liệu radar đầu vào, quá trình trích xuất đặc trưng trong bộ mã hóa, hợp nhất đặc trưng trong bộ giải mã và tạo ra bản đồ dự đoán cuối cùng.




Hình 3.2: Kiến trúc tổng thể của mô hình RaDecNet đề xuất.

Nhằm khai thác hiệu quả các đặc tính đặc thù của dữ liệu radar, RaDecNet tích hợp ba mô-đun cốt lõi hoạt động bổ trợ lẫn nhau trong một luồng xử lý thống nhất. Cụ thể, khối tích chập tách biệt dị hướng được sử dụng để học các đặc trưng cục bộ theo từng chiều vật lý của radar, bao gồm khoảng cách, góc phương vị và thời gian. Trên nền tảng đặc trưng này, khối chú ý dịch chuyển Doppler - thời gian tiếp tục mô hình hóa quan hệ động học giữa các khung radar liên tiếp, giúp mô hình khai thác tốt hơn thông tin chuyển động và duy trì tính nhất quán của mục tiêu theo thời gian. Song song với đó, khối tổng hợp vùng thưa đóng vai trò chọn lọc và tinh chỉnh các vùng tín hiệu có khả năng chứa mục tiêu, qua đó hạn chế ảnh hưởng của nhiễu nền và các khu vực ít mang thông tin.

Các đặc trưng đa tỷ lệ sau đó được truyền qua bộ giải mã và hợp nhất bằng cơ chế hợp nhất đặc trưng có trọng số, giúp kết hợp hài hòa giữa chi tiết không gian ở tầng nông và thông tin ngữ nghĩa ở tầng sâu. Nhờ cách tổ chức này, RaDecNet hướng đến sự cân bằng giữa khả năng biểu diễn không gian - thời gian, độ chính xác phát hiện và hiệu quả tính toán trong các kịch bản giao thông thực tế.

3.3.1 Khối tích chập tách biệt dị hướng



Hình 3.3: Kiến trúc khối tích chập tách biệt dị hướng ARSC.

Trong dữ liệu radar FMCW, các chiều khoảng cách, góc phương vị và thời gian không mang cùng một ý nghĩa vật lý như các chiều không gian trong ảnh RGB thông thường. Chiều khoảng cách phản ánh vị trí mục tiêu theo phương truyền sóng, chiều góc phương vị mô tả hướng xuất hiện của mục tiêu trong mặt phẳng quan sát, trong khi chiều thời gian biểu diễn sự thay đổi của tín hiệu phản xạ qua nhiều khung radar liên tiếp. Do đó,

việc sử dụng trực tiếp các hạt nhân tích chập 3D đồng nhất, chẳng hạn conv $3 \times 3 \times 3$, có thể chưa khai thác đầy đủ tính dị hướng của dữ liệu radar, đồng thời làm gia tăng chi phí tính toán khi số tầng mạng tăng lên.

Để giải quyết vấn đề này, RaDecNet sử dụng khối tích chập tách biệt dị hướng (anisotropic range-azimuth separable convolution - ARSC) như một mô-đun trích xuất đặc trưng cục bộ quan trọng. Thay vì xử lý đồng thời ba chiều dữ liệu bằng một hạt nhân tích chập duy nhất, ARSC phân rã quá trình trích xuất đặc trưng thành ba nhánh tích chập một chiều hoạt động song song. Mỗi nhánh tập trung vào một chiều vật lý riêng của dữ liệu radar, bao gồm khoảng cách, góc phương vị và thời gian. Cách thiết kế này giúp mô hình học được các đặc trưng cục bộ phù hợp hơn với bản chất của tín hiệu radar, đồng thời giảm số lượng tham số và số phép tính so với tích chập 3D đầy đủ.

Cấu trúc tổng quát của khối ARSC được minh họa trong Hình 3.3. Có thể thấy, mô-đun này gồm ba thành phần chính: lớp tích chập điểm dùng để mở rộng kênh đặc trưng, ba nhánh tích chập theo chiều sâu hoạt động song song theo các trục khoảng cách, góc phương vị và thời gian, cùng với cơ chế hợp nhất trọng số thích nghi để tổng hợp thông tin từ các nhánh. Thiết kế này cho phép ARSC khai thác đặc trưng radar theo từng chiều vật lý riêng biệt nhưng vẫn duy trì luồng kết nối dư nhằm bảo toàn thông tin đầu vào và ổn định quá trình huấn luyện.

Giả sử đầu vào của khối ARSC là tensor đặc trưng $\mathbf{F}_{\text{in}}^{\text{ARSC}} \in \mathbb{R}^{B \times T \times H \times W \times C}$, trong đó B là kích thước lô dữ liệu, T là số khung thời gian, H là số ô theo chiều góc phương vị, W là số ô theo chiều khoảng cách và C là số kênh đặc trưng. Trước khi thực hiện tích chập theo từng chiều, đầu vào được đưa qua một lớp tích chập điểm nhằm mở rộng số kênh và tăng khả năng tương tác giữa các kênh đặc trưng:

$$\mathbf{U} = \phi \left(\text{pwconv}_1(\mathbf{F}_{\text{in}}^{\text{ARSC}}) \right), \quad (3.1)$$

trong đó pwconv_1 là phép tích chập điểm $1 \times 1 \times 1$, $\phi(\cdot)$ là hàm kích hoạt StarReLU, và $\mathbf{U} \in \mathbb{R}^{B \times T \times H \times W \times C_m}$ là đặc trưng trung gian sau khi mở rộng kênh. Số kênh trung gian được xác định bởi

$$C_m = \eta C, \quad (3.2)$$

với η là hệ số mở rộng kênh. Trong thiết kế của RaDecNet, η thường được chọn bằng 2 nhằm tăng năng lực biểu diễn nhưng vẫn kiểm soát độ phức tạp tính toán. Hàm kích hoạt StarReLU được sử dụng sau lớp tích chập điểm để bổ sung tính phi tuyến cho đặc

trung. Hàm này có dạng:

$$\begin{aligned}\text{StarReLU}(x) &= s \cdot (\text{ReLU}(x))^2 + b \\ &= s \cdot (\max(0, x))^2 + b\end{aligned}\tag{3.3}$$

trong đó s và b lần lượt là hệ số tỷ lệ và độ lệch có thể học được trong quá trình huấn luyện. So với ReLU thông thường, StarReLU tạo ra dạng phi tuyến mạnh hơn thông qua thành phần bình phương, nhưng vẫn giữ chi phí tính toán thấp do chỉ sử dụng các phép toán cơ bản. Điều này phù hợp với định hướng xây dựng mô hình gọn nhẹ cho dữ liệu radar.

Sau bước mở rộng kênh, tensor $\mathbf{U}$ được đưa vào ba nhánh tích chập theo chiều sâu. Ba nhánh này lần lượt được định nghĩa như sau:

$$\mathbf{U}_r = \text{dwconv}_{1 \times 1 \times K_r}(\mathbf{U}),\tag{3.4}$$

$$\mathbf{U}_a = \text{dwconv}_{1 \times K_a \times 1}(\mathbf{U}),\tag{3.5}$$

$$\mathbf{U}_t = \text{dwconv}_{K_t \times 1 \times 1}(\mathbf{U}),\tag{3.6}$$

trong đó dwconv là tích chập theo chiều sâu, K_r , K_a và K_t lần lượt là kích thước hạt nhân theo chiều khoảng cách, góc phương vị và thời gian. Trong cài đặt của RaDecNet, các giá trị này được chọn là $K_r = 9$, $K_a = 5$ và $K_t = 3$. Nhánh thứ nhất với kernel $1 \times 1 \times K_r$ tập trung khai thác sự biến đổi tín hiệu theo chiều khoảng cách; nhánh thứ hai với kernel $1 \times K_a \times 1$ học đặc trưng theo chiều góc phương vị; trong khi nhánh thứ ba với kernel $K_t \times 1 \times 1$ khai thác sự thay đổi của mục tiêu theo chuỗi thời gian.

Do ba chiều dữ liệu radar có mức độ đóng góp khác nhau tùy theo từng cảnh quan sát, ARSC không cộng trực tiếp ba nhánh với trọng số cố định. Thay vào đó, mô-đun sử dụng một vector tham số học được

$$\alpha = [\alpha_r, \alpha_a, \alpha_t],\tag{3.7}$$

để xác định mức độ quan trọng tương đối của từng nhánh. Các trọng số hợp nhất được chuẩn hóa bằng hàm Softmax:

$$[w_r, w_a, w_t] = \text{Softmax}([\alpha_r, \alpha_a, \alpha_t]),\tag{3.8}$$

với:

$$w_r + w_a + w_t = 1.\tag{3.9}$$

Khi đó, đặc trưng hợp nhất từ ba nhánh được tính bởi:

$$\mathbf{U}_{\text{fused}} = w_r \mathbf{U}_r + w_a \mathbf{U}_a + w_t \mathbf{U}_t. \quad (3.10)$$

Cơ chế này cho phép mô hình tự điều chỉnh mức độ ưu tiên giữa các chiều khoảng cách, góc phương vị và thời gian trong quá trình học, thay vì giả định rằng mọi chiều dữ liệu đều có vai trò như nhau.

Sau khi hợp nhất đặc trưng, tensor $\mathbf{U}_{\text{fused}}$ được chuẩn hóa và chiếu ngược về số kênh ban đầu thông qua lớp tích chập điểm thứ hai:

$$\mathbf{V} = \text{pwconv}_2(\mathcal{LN}(\mathbf{U}_{\text{fused}})), \quad (3.11)$$

trong đó $\mathcal{LN}(\cdot)$ là Layer Normalization và pwconv_2 là phép tích chập điểm dùng để đưa số kênh từ C_m về C . Cuối cùng, khối ARSC sử dụng kết nối dư để bảo toàn thông tin gốc và ổn định quá trình lan truyền gradient:

$$\mathbf{F}_{\text{out}}^{\text{ARSC}} = \mathbf{F}_{\text{in}}^{\text{ARSC}} + \mathbf{V}. \quad (3.12)$$

Như vậy, toàn bộ khối ARSC có thể được tóm tắt theo chuỗi biến đổi:


$$\begin{aligned} \mathbf{F}_{\text{out}}^{\text{ARSC}} = \mathbf{F}_{\text{in}}^{\text{ARSC}} + \text{pwconv}_2 \Big(& \mathcal{LN} \Big(w_r \text{dwconv}_{1 \times 1 \times K_r}(\mathbf{U}) \\ & + w_a \text{dwconv}_{1 \times K_a \times 1}(\mathbf{U}) + w_t \text{dwconv}_{K_t \times 1 \times 1}(\mathbf{U}) \Big) \Big), \end{aligned} \quad (3.13)$$

với:

$$\mathbf{U} = \phi(\text{pwconv}_1(\mathbf{F}_{\text{in}}^{\text{ARSC}})). \quad (3.14)$$

Về mặt ý nghĩa, ARSC đóng vai trò giúp RaDecNet học các đặc trưng cục bộ phù hợp với cấu trúc vật lý của dữ liệu radar. Nhánh khoảng cách hỗ trợ mô hình nhận biết sự phân bố phản xạ theo độ sâu, nhánh góc phương vị khai thác hình thái mục tiêu theo hướng ngang trong mặt phẳng radar, còn nhánh thời gian bổ sung thông tin biến đổi qua các khung liên tiếp. Sự kết hợp giữa tích chập tách biệt dị hướng, hợp nhất trọng số thích nghi và kết nối dư giúp ARSC vừa duy trì khả năng biểu diễn mạnh, vừa giảm độ phức tạp so với tích chập 3D truyền thống. Đây là nền tảng quan trọng để các khối tiếp theo trong RaDecNet tiếp tục mô hình hóa quan hệ Doppler-thời gian và tập trung vào các vùng tín hiệu thưa có giá trị cao.

3.3.2 Khối chú ý dịch chuyển Doppler - thời gian



Hình 3.4: Kiến trúc khối chú ý dịch chuyển Doppler - thời gian DTSA.

Sau khi các đặc trưng cục bộ theo chiều khoảng cách, góc phương vị và thời gian được khai thác bởi khối ARSC, mô hình cần tiếp tục học các quan hệ động học dài hơn trong chuỗi radar. Đây là một yêu cầu quan trọng đối với dữ liệu radar FMCW, bởi mỗi mục tiêu không chỉ được mô tả bởi vị trí tức thời trên mặt phẳng radar, mà còn mang thông tin liên quan đến vận tốc tương đối, sự thay đổi phản xạ và tính liên tục chuyển động qua

nhiều khung thời gian. Những đặc trưng này có ý nghĩa trực tiếp đối với việc phân biệt các lớp đối tượng như người đi bộ, người đi xe đạp và xe ô tô.

Trong các kiến trúc dựa trên Transformer, cơ chế tự chú ý (self-attention) có khả năng mô hình hóa phụ thuộc dài hạn hiệu quả [12]. Tuy nhiên, nếu áp dụng trực tiếp self-attention trên toàn bộ tensor không gian - thời gian $\mathbf{F}_{\text{in}}^{\text{DTSA}} \in \mathbb{R}^{B \times T \times H \times W \times C}$, số lượng token cần xử lý là $T \times H \times W$. Khi đó, độ phức tạp của attention tăng theo bậc hai của số token, xấp xỉ $\mathcal{O}((THW)^2C)$. Điều này tạo ra chi phí tính toán và bộ nhớ rất lớn, đặc biệt đối với dữ liệu radar có nhiều khung thời gian và độ phân giải không gian cao. Hơn nữa, self-attention tiêu chuẩn không trực tiếp đưa vào các ràng buộc vật lý của tín hiệu radar, trong khi các khung radar gần nhau theo thời gian thường có mối liên hệ động học mạnh hơn các khung ở xa.

Để giải quyết vấn đề trên, RaDecNet sử dụng khối chú ý dịch chuyển Doppler - thời gian (doppler-temporal shift attention - DTSA). Ý tưởng chính của DTSA là không thực hiện attention trên toàn bộ không gian ba chiều, mà trước hết nén thông tin không gian để thu được một chuỗi đặc trưng theo thời gian. Sau đó, cơ chế attention chỉ được áp dụng trên trục thời gian, đồng thời được bổ sung một ma trận thiên lệch Doppler nhằm ưu tiên các quan hệ động học có tính liên tục giữa các khung radar lân cận.

Cấu trúc tổng quát của khối DTSA được minh họa trong Hình 3.4. Có thể thấy, mô-đun này trước hết thực hiện gộp trung bình không gian để chuyển tensor đặc trưng từ dạng không gian - thời gian sang chuỗi đặc trưng theo thời gian. Sau đó, chuỗi đặc trưng này được đưa vào cơ chế chú ý đa đầu nhằm học quan hệ giữa các khung radar liên tiếp. Điểm khác biệt chính của DTSA nằm ở việc bổ sung ma trận thiên lệch Doppler - thời gian vào quá trình tính toán attention, giúp mô hình ưu tiên các quan hệ động học có tính liên tục giữa những khung thời gian lân cận. Cuối cùng, đặc trưng thời gian sau khi được tổng hợp sẽ được broadcast trở lại không gian ban đầu và cộng với đầu vào thông qua kết nối dư.

Giả sử đầu vào của khối DTSA là $\mathbf{F}_{\text{in}}^{\text{DTSA}} \in \mathbb{R}^{B \times T \times H \times W \times C}$, trong đó B là kích thước lô dữ liệu, T là số khung thời gian, H là số ô theo chiều góc phương vị, W là số ô theo chiều khoảng cách và C là số kênh đặc trưng. Đầu tiên, DTSA thực hiện gộp trung bình trên hai chiều không gian H và W :

$$\mathbf{Z}_{b,t,:} = \frac{1}{HW} \sum_{i=1}^H \sum_{j=1}^W (\mathbf{F}_{\text{in}}^{\text{DTSA}})_{b,t,i,j,:}. \quad (3.15)$$

Sau phép biến đổi này, ta thu được chuỗi đặc trưng thời gian là $\mathbf{Z} \in \mathbb{R}^{B \times T \times C}$. Bước gộp trung bình không gian giúp giảm mạnh số lượng token cần đưa vào attention, từ

$T \times H \times W$ xuống còn T . Nhờ đó, độ phức tạp attention giảm còn $\mathcal{O}(T^2C)$, phù hợp hơn với định hướng xây dựng mô hình gọn nhẹ cho xử lý radar thời gian thực.

Trước khi tính attention, chuỗi đặc trưng thời gian được chuẩn hóa bằng Layer Normalization:

$$\tilde{\mathbf{Z}} = \mathcal{LN}(\mathbf{Z}). \quad (3.16)$$

Từ biểu diễn đã chuẩn hóa, mô hình sinh ra ba ma trận truy vấn, khóa và giá trị:

$$[\mathbf{Q}, \mathbf{K}, \mathbf{V}] = \tilde{\mathbf{Z}} \mathbf{W}_{qkv}, \quad (3.17)$$

trong đó $\mathbf{W}_{qkv} \in \mathbb{R}^{C \times 3C}$ là ma trận tham số học được. Ba tensor $\mathbf{Q}$, $\mathbf{K}$ và $\mathbf{V}$ sau đó được tách thành h đầu chú ý. Các ma trận đầu vào có kích thước $\mathbf{Q}, \mathbf{K}, \mathbf{V} \in \mathbb{R}^{B \times h \times T \times d_h}$, với h là số head attention và $d_h = C/h$ là số chiều đặc trưng của mỗi head.

Điểm khác biệt quan trọng của DTSA so với attention tiêu chuẩn nằm ở ma trận thiên lệch Doppler - thời gian. Thay vì để mô hình học quan hệ giữa các thời điểm hoàn toàn tự do, DTSA bổ sung một ma trận thiên lệch có kích thước $\mathbf{B}^D \in \mathbb{R}^{h \times T \times T}$. Với mỗi head attention, phần tử tại vị trí (i, j) của ma trận này được khởi tạo theo dạng Gaussian:

$$\mathbf{B}_{m,i,j}^D = \exp\left(-\frac{1}{2} \left(\frac{i-j}{\sigma_D}\right)^2\right), \quad (3.18)$$

trong đó m là chỉ số head, i và j là hai chỉ số thời gian, còn σ_D là hệ số điều khiển mức độ suy giảm theo khoảng cách thời gian. Trong thiết kế của RaDecNet, σ_D được chọn bằng 2. Cách khởi tạo này phản ánh một giả định phù hợp với dữ liệu radar: trạng thái chuyển động của mục tiêu tại một thời điểm thường có quan hệ mạnh hơn với các khung thời gian lân cận và suy giảm dần khi khoảng cách thời gian tăng lên. Trong quá trình huấn luyện, ma trận $\mathbf{B}^D$ tiếp tục được tối ưu cùng với các tham số khác của mô hình, nhờ đó vừa giữ được định hướng vật lý ban đầu, vừa có khả năng thích nghi với dữ liệu thực tế.

Với ma trận thiên lệch Doppler - thời gian, trọng số attention tại head thứ m được tính như sau:

$$\mathbf{A}_m = \text{Softmax}\left(\frac{\mathbf{Q}_m \mathbf{K}_m^\top}{\sqrt{d_h}} + \mathbf{B}_m^D\right), \quad (3.19)$$

trong đó $\mathbf{A}_m \in \mathbb{R}^{B \times T \times T}$ là ma trận attention theo thời gian. Thành phần $\frac{\mathbf{Q}_m \mathbf{K}_m^\top}{\sqrt{d_h}}$ biểu diễn mức độ tương đồng học được giữa các thời điểm, còn $\mathbf{B}_m^D$ đóng vai trò như một thiên lệch tiên nghiệm giúp ưu tiên các quan hệ Doppler – thời gian có tính liên tục.

Đặc trưng thời gian tại head thứ m được tổng hợp bằng:

$$\mathbf{O}_m = \mathbf{A}_m \mathbf{V}_m. \quad (3.20)$$

Sau đó, các head attention được nối lại và đưa qua phép chiếu tuyến tính:

$$\mathbf{O} = \text{Dropout}(\text{Proj}(\text{concat}(\mathbf{O}_1, \mathbf{O}_2, \dots, \mathbf{O}_h))), \quad (3.21)$$

trong đó $\mathbf{O} \in \mathbb{R}^{B \times T \times C}$. Tensor $\mathbf{O}$ lúc này chứa thông tin động học đã được tổng hợp từ nhiều khung radar theo cơ chế chú ý thời gian. Cuối cùng, để đưa thông tin động học trở lại không gian đặc trưng ban đầu, $\mathbf{O}$ được mở rộng theo hai chiều không gian H và W bằng phép broadcast:

$$\mathbf{O}_{b,t,i,j,:}^{\uparrow} = \mathbf{O}_{b,t,:}, \quad \forall i \in [1, H], \forall j \in [1, W]. \quad (3.22)$$

Đầu ra của khối DTSA được tính bằng kết nối dư:

$$\mathbf{F}_{\text{out}}^{\text{DTSA}} = \mathbf{F}_{\text{in}}^{\text{DTSA}} + \mathbf{O}^{\uparrow}. \quad (3.23)$$

Nhờ kết nối này, cấu trúc không gian ban đầu của tensor vẫn được bảo toàn, trong khi mỗi vị trí trên bản đồ radar được bổ sung thêm thông tin động học toàn cục theo thời gian.


Về mặt ý nghĩa, DTSA đóng vai trò bổ sung khả năng mô hình hóa động học cho RaDecNet. Nếu ARSC tập trung khai thác đặc trưng cục bộ theo từng chiều vật lý của dữ liệu radar, thì DTSA mở rộng khả năng biểu diễn bằng cách học quan hệ giữa các khung radar liên tiếp. Ma trận thiên lệch Doppler - thời gian giúp mô hình ưu tiên các quan hệ chuyển động có tính liên tục, từ đó cải thiện khả năng theo dõi và nhận dạng mục tiêu trong các tình huống phản xạ yếu, nhiễu nền cao hoặc hình dạng mục tiêu thay đổi không ổn định. Đồng thời, nhờ cơ chế nén không gian trước khi attention, DTSA đạt được hiệu quả tính toán tốt hơn so với self-attention trên toàn bộ tensor không gian - thời gian, phù hợp với mục tiêu xây dựng một mô hình radar gọn nhẹ và có khả năng triển khai thực tế.

3.3.3 Khối tổng hợp vùng thưa

Sau khi đặc trưng cục bộ và quan hệ động học được khai thác thông qua ARSC và DTSA, mô hình vẫn cần xử lý một đặc tính quan trọng khác của dữ liệu radar FMCW,

đó là tính thưa. Trong bản đồ đặc trưng radar, các đối tượng như người đi bộ, người đi xe đạp và xe ô tô thường chỉ chiếm một phần rất nhỏ trong toàn bộ không gian quan sát, trong khi phần lớn các vị trí còn lại là nền, nhiễu hoặc các phản xạ không mang nhiều ý nghĩa nhận dạng. Nếu mô hình xử lý đồng đều toàn bộ bản đồ đặc trưng, tài nguyên tính toán sẽ bị phân tán vào nhiều vùng ít giá trị, đồng thời các tín hiệu mục tiêu yếu có thể bị pha loãng bởi nhiễu nền.

Để giải quyết vấn đề này, RaDecNet sử dụng khối tổng hợp vùng thưa (sparse region aggregator - SRA) nhằm tập trung quá trình tinh chỉnh đặc trưng vào các vùng có khả năng chứa mục tiêu cao. Khác với các cơ chế chú ý mềm, trong đó toàn bộ không gian vẫn được xử lý với các mức trọng số khác nhau, SRA sử dụng cơ chế chọn lọc Top-K để trực tiếp xác định một tập con các vị trí quan trọng nhất trên bản đồ đặc trưng. Nhờ đó, mô hình có thể ưu tiên tài nguyên biểu diễn cho các vùng tín hiệu giàu thông tin, đồng thời hạn chế ảnh hưởng của các vùng nền hoặc nhiễu ít liên quan.



Hình 3.5: Kiến trúc khối tổng hợp vùng thưa SRA.

Cấu trúc tổng quát của khối SRA được minh họa trong Hình 3.5. Có thể thấy, mô-đun này trước hết sinh ra bản đồ điểm quan trọng nhằm đánh giá mức độ đóng góp của từng vị trí trên bản đồ đặc trưng. Sau đó, cơ chế Top-K được sử dụng để lựa chọn các vùng

có phản hồi cao nhất, tương ứng với những vị trí có khả năng chứa mục tiêu hoặc mang thông tin phân biệt quan trọng. Các đặc trưng tại những vị trí này được thu thập bằng phép Gather, tinh chỉnh thông qua mạng MLP nhỏ, rồi được đưa trở lại không gian ban đầu bằng phép Scatter. Cuối cùng, kết nối dư được sử dụng để cộng phần đặc trưng hiệu chỉnh vào đầu vào, giúp mô hình tăng cường các vùng tín hiệu quan trọng nhưng vẫn bảo toàn cấu trúc tổng thể của bản đồ radar.

Giả sử đầu vào của khối SRA là tensor đặc trưng $\mathbf{F}_{\text{in}}^{\text{SRA}} \in \mathbb{R}^{B \times T \times H \times W \times C}$ trong đó B là kích thước lô dữ liệu, T là số khung thời gian, H và W lần lượt là kích thước không gian theo chiều góc phương vị và khoảng cách, còn C là số kênh đặc trưng. Trước hết, SRA sử dụng một lớp $\text{pwconv}_{1 \times 1 \times 1}$ để sinh bản đồ điểm quan trọng cho từng vị trí không gian tại mỗi thời điểm:

$$\mathbf{S} = \text{conv}_{1 \times 1 \times 1}(\mathbf{F}_{\text{in}}^{\text{SRA}}), \quad (3.24)$$

với $\mathbf{S} \in \mathbb{R}^{B \times T \times H \times W}$. Mỗi phần tử $\mathbf{S}_{b,t,i,j}$ biểu diễn mức độ quan trọng của vị trí (i, j) tại thời điểm t trong mẫu thứ b . Có thể hiểu $\mathbf{S}$ như một bản đồ định tuyến, giúp mô hình xác định những vùng nào cần được xử lý chuyên sâu hơn.

Để thực hiện lựa chọn vùng thưa, bản đồ điểm số tại từng cặp (b, t) được làm phẳng theo hai chiều không gian:

$$\mathbf{s}_{b,t} = \text{Flatten}(\mathbf{S}_{b,t,:,:}) \in \mathbb{R}^{HW}. \quad (3.25)$$

Số lượng vị trí được chọn được xác định bởi:

$$K = \max(1, \lfloor \rho HW \rfloor), \quad (3.26)$$

trong đó ρ là tỉ lệ chọn vùng thưa. Khi ρ nhỏ, mô hình chỉ tập trung vào một số ít vùng có điểm số cao nhất; khi ρ lớn hơn, phạm vi vùng được chọn sẽ rộng hơn. Tập chỉ số của các vị trí quan trọng nhất được xác định bằng phép chọn Top-K:

$$\mathcal{I}_{b,t} = \text{TopK}(\mathbf{s}_{b,t}, K). \quad (3.27)$$

Trong đó, $\mathcal{I}_{b,t}$ chứa K chỉ số không gian có điểm phản hồi cao nhất tại thời điểm t của mẫu thứ b .

Dựa trên tập chỉ số $\mathcal{I}_{b,t}$, SRA sử dụng phép Gather để trích xuất các vector đặc trưng tương ứng từ tensor đầu vào:

$$\mathbf{P}_{b,t} = \left\{ (\mathbf{F}_{\text{in}}^{\text{SRA}})_{b,t,u,:} \mid u \in \mathcal{I}_{b,t} \right\}, \quad (3.28)$$

với $\mathbf{P}_{b,t} \in \mathbb{R}^{K \times C}$. Ở đây, u là chỉ số không gian sau khi làm phẳng từ cặp tọa độ (i, j) . Tensor $\mathbf{P}_{b,t}$ chỉ chứa các đặc trưng tại những vị trí được xem là quan trọng nhất, thay vì toàn bộ $H \times W$ vị trí trên bản đồ đặc trưng. Do $K \ll HW$, lượng đặc trưng cần tính chỉnh được giảm đáng kể.

Sau khi thu thập các vùng đặc trưng quan trọng, SRA sử dụng một mạng MLP nhỏ để tính chỉnh các vector này. Trước hết, đặc trưng được chuẩn hóa bằng Layer Normalization:

$$\tilde{\mathbf{P}}_{b,t} = \mathcal{LN}(\mathbf{P}_{b,t}). \quad (3.29)$$

Sau đó, đặc trưng được đưa qua MLP:

$$\Delta \mathbf{P}_{b,t} = \text{MLP}(\tilde{\mathbf{P}}_{b,t}). \quad (3.30)$$

Trong đó, MLP được định nghĩa bởi:

$$\text{MLP}(\mathbf{p}) = \mathbf{W}_2^s \text{GELU}(\mathbf{W}_1^s \mathbf{p}), \quad (3.31)$$

với $\mathbf{W}_1^s$ và $\mathbf{W}_2^s$ là các ma trận tham số học được, còn $\text{GELU}(\cdot)$ là hàm kích hoạt phi tuyến được sử dụng trong mạng MLP. Thành phần $\Delta \mathbf{P}_{b,t}$ biểu diễn lượng hiệu chỉnh đặc trưng tại các vùng được chọn.

Sau bước tính chỉnh, các đặc trưng hiệu chỉnh được đưa trở lại đúng vị trí ban đầu trên bản đồ đặc trưng thông qua phép Scatter. Gọi $\mathbf{O}$ là tensor hiệu chỉnh có cùng kích thước với đầu vào $\mathbf{O} \in \mathbb{R}^{B \times T \times H \times W \times C}$. Ban đầu, $\mathbf{O}$ được gán bằng tensor không. Với các vị trí thuộc tập $\mathcal{I}_{b,t}$, giá trị hiệu chỉnh được gán lại như sau:

$$\mathbf{O}_{b,t,u,:} = \Delta \mathbf{P}_{b,t,u,:}, \quad u \in \mathcal{I}_{b,t}. \quad (3.32)$$

Các vị trí không thuộc tập được chọn giữ giá trị hiệu chỉnh bằng 0:

$$\mathbf{O}_{b,t,u,:} = \mathbf{0}, \quad u \notin \mathcal{I}_{b,t}. \quad (3.33)$$

Cuối cùng, khối SRA sử dụng kết nối dư để cộng phần đặc trưng hiệu chỉnh vào đầu vào ban đầu:

$$\mathbf{F}_{\text{out}}^{\text{SRA}} = \mathbf{F}_{\text{in}}^{\text{SRA}} + \mathbf{O}. \quad (3.34)$$

Tương đương, có thể viết theo từng vị trí không gian:

$$(\mathbf{F}_{\text{out}}^{\text{SRA}})_{b,t,u,:} = \begin{cases} (\mathbf{F}_{\text{in}}^{\text{SRA}})_{b,t,u,:} + \Delta \mathbf{P}_{b,t,u,:}, & u \in \mathcal{I}_{b,t}, \\ (\mathbf{F}_{\text{in}}^{\text{SRA}})_{b,t,u,:}, & u \notin \mathcal{I}_{b,t}. \end{cases} \quad (3.35)$$

Như vậy, chỉ những vùng được lựa chọn bởi cơ chế Top-K mới được tinh chỉnh mạnh hơn, trong khi các vùng còn lại vẫn giữ nguyên đặc trưng ban đầu. Điều này giúp mô hình vừa bảo toàn cấu trúc tổng thể của bản đồ radar, vừa tăng cường biểu diễn tại các vùng có khả năng chứa mục tiêu.

Về mặt ý nghĩa, SRA đóng vai trò như một cơ chế chọn lọc vùng quan trọng trong RaDecNet. Nếu ARSC giúp học đặc trưng cục bộ theo từng chiều vật lý của radar và DTSA giúp mô hình hóa quan hệ động học theo thời gian, thì SRA giúp tập trung năng lực biểu diễn vào các vùng tín hiệu thưa nhưng giàu thông tin. Cơ chế Top-K cho phép mô hình ưu tiên các vị trí có khả năng chứa mục tiêu, trong khi các phép Gather và Scatter giúp quá trình tinh chỉnh đặc trưng được thực hiện có chọn lọc. Nhờ đó, SRA góp phần giảm ảnh hưởng của nhiễu nền, hạn chế xử lý dư thừa và tăng khả năng phân biệt của các vùng mục tiêu trong bản đồ radar. Đây là một thành phần quan trọng giúp RaDecNet đạt được sự cân bằng giữa độ chính xác phát hiện và hiệu quả tính toán trong các kịch bản giao thông thực tế.


3.3.4 Các khối chuyển đổi và hợp nhất đặc trưng

Bên cạnh ba khối xử lý chính gồm ARSC, DTSA và SRA, RaDecNet còn sử dụng các khối chuyển đổi và hợp nhất đặc trưng nhằm tổ chức luồng dữ liệu trong toàn bộ kiến trúc mã hóa - giải mã. Các khối này không trực tiếp đóng vai trò học đặc trưng chuyên biệt như ARSC hay DTSA, nhưng giữ vai trò quan trọng trong việc xây dựng biểu diễn đa tỷ lệ, giảm độ phân giải không gian có kiểm soát và kết hợp thông tin giữa các tầng encoder và decoder. Cụ thể, mô hình sử dụng ba thành phần chính: khối nhúng token, khối gộp token và khối hợp nhất đặc trưng có trọng số.

- **Khối nhúng token:** Khối nhúng token được sử dụng ở giai đoạn đầu của encoder nhằm chuyển đổi dữ liệu radar từ không gian đặc trưng ban đầu sang không gian biểu diễn có số chiều cao hơn. Giả sử tensor đầu vào sau bước xử lý ban đầu là $\mathbf{F}_{\text{in}}^{\text{TokenEmbed}} \in \mathbb{R}^{B \times T \times H \times W \times C_{\text{in}}}$, trong đó B là kích thước lô dữ liệu, T là số khung thời gian, H và W lần lượt là kích thước không gian theo chiều góc phương vị và khoảng cách, còn C_{in} là số kênh đầu vào. Trong thiết lập của RaDecNet, dữ liệu radar đầu vào ban đầu có dạng $B \times 2 \times 16 \times 128 \times 128$, sau đó được tổ chức lại thành dạng phù hợp với các khối xử lý

đặc trưng.

Khác với các phép giảm mẫu thông thường, Token Embedding trong RaDecNet chỉ giảm độ phân giải theo hai chiều không gian và giữ nguyên chiều thời gian. Điều này xuất phát từ yêu cầu bảo toàn chuỗi động học của dữ liệu radar, vì các thông tin liên quan đến chuyển động và sự thay đổi phản xạ theo thời gian có vai trò quan trọng trong phát hiện đối tượng.



Hình 3.6: Kiến trúc khối nhúng token trong mô hình RaDecNet.

Cấu trúc tổng quát của khối Token Embedding được minh họa trong Hình 3.6. Có thể thấy, khối này sử dụng một phép tích chập 3D với kernel size và stride bằng $(1, 2, 2)$ để thực hiện nhúng đặc trưng đầu vào. Cách thiết kế này giúp mô hình giảm độ phân giải theo hai chiều không gian, đồng thời giữ nguyên chiều thời gian nhằm bảo toàn chuỗi động học của dữ liệu radar. Sau phép tích chập, Layer Normalization được sử dụng để ổn định phân phối đặc trưng trước khi đưa vào các tầng mã hóa tiếp theo. Với kích thước patch:

$$\mathbf{p} = (p_t, p_h, p_w) = (1, 2, 2), \quad (3.36)$$

phép nhúng token được thực hiện bằng một lớp tích chập 3D có kernel size và stride cùng bằng $\mathbf{p}$:

$$\mathbf{F}_{\text{out}}^{\text{TokenEmbed}} = \mathcal{LN} \left(\text{conv}_{\mathbf{p}, \mathbf{p}} \left(\mathbf{F}_{\text{in}}^{\text{TokenEmbed}} \right) \right), \quad (3.37)$$

trong đó $\text{conv}_{\mathbf{p}, \mathbf{p}}$ là phép tích chập 3D với kernel size và stride bằng $(1, 2, 2)$, còn $\mathcal{LN}(\cdot)$ là Layer Normalization.


Sau bước này, tensor đặc trưng có dạng $\mathbf{F}_{\text{out}}^{\text{TokenEmbed}} \in \mathbb{R}^{B \times T \times \frac{H}{2} \times \frac{W}{2} \times C_0}$, trong đó C_0 là số kênh đặc trưng cơ sở của mô hình. Có thể thấy, chiều thời gian T được giữ nguyên, trong khi chiều góc phương vị và khoảng cách được giảm một nửa. Thiết kế này giúp mô hình giảm số lượng phần tử cần xử lý ở các tầng sau nhưng vẫn giữ lại đầy đủ thông tin thời gian phục vụ cho các khối mô hình hóa động học như DTSA.

Về mặt ý nghĩa, Token Embedding đóng vai trò đưa dữ liệu radar từ không gian tín hiệu ban đầu sang không gian đặc trưng học sâu. Phép tích chập với bước trượt $(1, 2, 2)$ cho phép mô hình tổng hợp thông tin cục bộ trong từng vùng không gian nhỏ, trong khi Layer Normalization giúp ổn định phân phối đặc trưng trước khi đưa vào encoder. Đây

là bước nền tảng để các khối ARSC, DTSA và SRA có thể học biểu diễn không gian - thời gian hiệu quả hơn ở các tầng tiếp theo.

- **Khối gộp token:** Sau khi đặc trưng được nhúng vào không gian biểu diễn, encoder cần tiếp tục xây dựng các đặc trưng đa tỷ lệ bằng cách giảm dần độ phân giải không gian và tăng dần số kênh. Trong RaDecNet, quá trình này được thực hiện bởi khối gộp token được lấy ý tưởng từ kiến trúc MetaFormer [21]. Khác với max pooling, vốn chỉ giữ lại phản hồi lớn nhất trong một vùng cục bộ, Token Merging sử dụng cách gộp có học để bảo toàn và tái tổ hợp thông tin từ các vị trí lân cận.

Cấu trúc tổng quát của khối Token Merging được minh họa trong Hình 3.7. Có thể thấy, mô-đun này thực hiện quá trình gộp các token lân cận trong vùng không gian 2×2 bằng cách tách đặc trưng theo chỉ số chẵn - lẻ trên hai chiều không gian, sau đó nối các nhóm token này theo chiều kênh. Khác với các phép giảm mẫu cố định như max pooling, Token Merging không loại bỏ trực tiếp các phản hồi yếu mà đưa toàn bộ thông tin trong vùng cục bộ vào một phép chiếu tuyến tính có khả năng học. Nhờ đó, mô hình vừa giảm được độ phân giải không gian, vừa tăng số kênh đặc trưng để xây dựng biểu diễn ngữ nghĩa sâu hơn cho các tầng encoder tiếp theo.



Hình 3.7: Kiến trúc khối gộp token trong mô hình RaDecNet.

Giả sử đầu vào của khối Token Merging là $\mathbf{F}_{in}^{TokenMerging} \in \mathbb{R}^{B \times T \times H \times W \times C}$. Trước hết, bốn nhóm token lân cận theo không gian được tách ra dựa trên chỉ số chẵn - lẻ của hai

chiều H và W :

$$\mathbf{Z}_{00} = \mathbf{F}_{\text{in}}^{\text{TokenMerging}}[:, :, 0 :: 2, 0 :: 2, :], \quad (3.38)$$

$$\mathbf{Z}_{10} = \mathbf{F}_{\text{in}}^{\text{TokenMerging}}[:, :, 1 :: 2, 0 :: 2, :], \quad (3.39)$$

$$\mathbf{Z}_{01} = \mathbf{F}_{\text{in}}^{\text{TokenMerging}}[:, :, 0 :: 2, 1 :: 2, :], \quad (3.40)$$

$$\mathbf{Z}_{11} = \mathbf{F}_{\text{in}}^{\text{TokenMerging}}[:, :, 1 :: 2, 1 :: 2, :]. \quad (3.41)$$

Mỗi nhóm chứa một phần thông tin trong vùng không gian 2×2 . Bốn nhóm này sau đó được nối theo chiều kênh:

$$\mathbf{Z}_{\text{cat}} = \text{concat}(\mathbf{Z}_{00}, \mathbf{Z}_{10}, \mathbf{Z}_{01}, \mathbf{Z}_{11}), \quad (3.42)$$

với $\mathbf{Z}_{\text{cat}} \in \mathbb{R}^{B \times T \times \frac{H}{2} \times \frac{W}{2} \times 4C}$. Sau khi nối đặc trưng, tensor được chuẩn hóa và đưa qua một phép chiếu tuyến tính để giảm số kênh từ $4C$ về $2C$:

$$\mathbf{F}_{\text{out}}^{\text{TokenMerging}} = \text{Linear}(\mathcal{LN}(\mathbf{Z}_{\text{cat}})), \quad (3.43)$$

trong đó $\mathbf{F}_{\text{out}}^{\text{TokenMerging}} \in \mathbb{R}^{B \times T \times \frac{H}{2} \times \frac{W}{2} \times 2C}$. Như vậy, Token Merging làm giảm một nửa kích thước theo hai chiều không gian nhưng tăng gấp đôi số kênh đặc trưng. Chiều thời gian vẫn được giữ nguyên trong toàn bộ quá trình.

Về mặt tính toán, cơ chế này có thể được hiểu như một dạng gộp không gian có học. Thay vì loại bỏ thông tin bằng một quy tắc cố định, mô hình gom các đặc trưng trong vùng 2×2 vào chiều kênh, sau đó học phép chiếu tuyến tính để chọn lọc và tái tổ hợp thông tin. Nhờ đó, Token Merging giúp encoder xây dựng biểu diễn phân cấp: các tầng nông giữ nhiều chi tiết không gian, trong khi các tầng sâu có trường tiếp nhận rộng hơn và mang nhiều thông tin ngữ nghĩa hơn.

• **Khối hợp nhất đặc trưng có trọng số:** Trong kiến trúc encoder - decoder, đặc trưng ở tầng sâu thường chứa nhiều thông tin ngữ nghĩa nhưng bị giảm độ phân giải không gian, trong khi đặc trưng ở tầng nông giữ được nhiều chi tiết vị trí hơn nhưng có thể chứa nhiều nhiễu nền. Vì vậy, khi decoder khôi phục độ phân giải, việc kết hợp đặc trưng giải mã với đặc trưng skip từ encoder là một bước quan trọng để tái tạo bản đồ dự đoán chính xác.

Các phương pháp truyền thống thường sử dụng phép cộng hoặc phép nối trực tiếp giữa hai nguồn đặc trưng. Tuy nhiên, cách này chưa xét đến mức độ đóng góp khác nhau của từng nhánh trong từng giai đoạn giải mã. Đối với dữ liệu radar, điều này càng quan trọng vì đặc trưng tầng nông có thể chứa nhiều phản xạ nhiễu, trong khi đặc trưng tầng

sâu tuy giàu ngữ nghĩa nhưng có thể mất một phần chi tiết không gian. Do đó, RaDecNet sử dụng khối hợp nhất đặc trưng có trọng số (weighted feature fusion - WFF) để mô hình tự học mức độ đóng góp của từng nguồn đặc trưng.

Giả sử $\mathbf{F}_{in,d}^{WFF}$ là đặc trưng từ decoder sau khi được upsample về cùng độ phân giải với tầng encoder tương ứng, và $\mathbf{F}_{in,e}^{WFF}$ là đặc trưng skip từ encoder. Khi đó, WFF được định nghĩa như sau:

$$WFF(\mathbf{F}_{in,d}^{WFF}, \mathbf{F}_{in,e}^{WFF}) = \frac{\beta_d \mathbf{F}_{in,d}^{WFF} + \beta_e \mathbf{F}_{in,e}^{WFF}}{\beta_d + \beta_e + \varepsilon}, \quad (3.44)$$

trong đó ε là một hằng số nhỏ nhằm tránh mất ổn định số học khi mẫu số tiến về 0. Hai hệ số β_d và β_e được tính từ các trọng số học được:

$$\beta_d = \text{ReLU}(w_d), \quad (3.45)$$

$$\beta_e = \text{ReLU}(w_e). \quad (3.46)$$

Ở đây, w_d và w_e là hai tham số được tối ưu trong quá trình huấn luyện. Việc sử dụng hàm ReLU bảo đảm các hệ số hợp nhất không âm, giúp phép hợp nhất giữ ý nghĩa như một trung bình có trọng số giữa hai nguồn đặc trưng. Sau khi hợp nhất bằng WFF, đặc trưng thu được có dạng:

$$\mathbf{F}_{out}^{WFF} = WFF(\mathbf{F}_{in,d}^{WFF}, \mathbf{F}_{in,e}^{WFF}). \quad (3.47)$$

Trong decoder của RaDecNet, đặc trưng hợp nhất này tiếp tục được nối với đặc trưng skip đã được chiếu kênh:

$$\mathbf{X}_c = \text{concat}(\mathbf{F}_{out}^{WFF}, \mathbf{F}_{in,e}^{WFF}). \quad (3.48)$$

Sau đó, $\mathbf{X}_c$ được đưa qua các khối xử lý tiếp theo để tinh chỉnh đặc trưng trước khi tiếp tục giải mã ở mức không gian cao hơn. Cách kết hợp này cho phép mô hình vừa tận dụng được khả năng điều phối thích nghi của WFF, vừa giữ lại đầy đủ đặc trưng chi tiết từ nhánh encoder.

Về mặt ý nghĩa, WFF giúp decoder tự điều chỉnh mức độ phụ thuộc vào thông tin ngữ nghĩa từ nhánh giải mã và thông tin chi tiết từ nhánh mã hóa. Khi đặc trưng encoder hữu ích cho việc khôi phục vị trí mục tiêu, mô hình có thể tăng trọng số của nhánh encoder. Ngược lại, khi đặc trưng encoder chứa nhiều nhiễu nền, mô hình có thể ưu tiên đặc trưng decoder đã được xử lý ở tầng sâu hơn. Nhờ đó, quá trình hợp nhất đặc trưng trở nên linh hoạt hơn so với phép cộng hoặc phép nối trực tiếp.

Qua phân tích trên, ba khối Token Embedding, Token Merging và WFF đóng vai trò xây dựng khung truyền tải đặc trưng cho toàn bộ RaDecNet. Token Embedding chuyển

đổi dữ liệu radar sang không gian đặc trưng ban đầu và giảm nhẹ độ phân giải không gian; Token Merging xây dựng biểu diễn đa tỷ lệ bằng cách gộp không gian có học; còn WFF hỗ trợ decoder hợp nhất hiệu quả giữa đặc trưng ngữ nghĩa và đặc trưng chi tiết. Sự kết hợp của các khối này giúp RaDecNet duy trì luồng thông tin ổn định từ đầu vào đến đầu ra, đồng thời bảo đảm sự cân bằng giữa khả năng biểu diễn, độ chính xác phát hiện và hiệu quả tính toán.

3.3.5 Kiến trúc mô hình đề xuất

Dựa trên các phân tích về đặc trưng của dữ liệu radar FMCW, đề tài đề xuất kiến trúc RaDecNet nhằm giải quyết bài toán phát hiện đối tượng trong không gian radar theo hướng gọn nhẹ và phù hợp với xử lý thời gian thực. Mô hình được xây dựng theo cấu trúc mã hóa - giải mã đa tầng, trong đó các khối ARSC, DTSA, SRA, Token Merging và Weighted Feature Fusion được kết hợp thành một luồng xử lý thống nhất. Mục tiêu của thiết kế này là khai thác đồng thời ba đặc tính quan trọng của dữ liệu radar, bao gồm tính dị hướng theo các chiều vật lý, sự phụ thuộc động học theo thời gian và tính thừa của tín hiệu phản xạ.

Như minh họa trong Hình 3.2, kiến trúc RaDecNet được tổ chức theo dạng mã hóa - giải mã đa tầng. Nhánh mã hóa có nhiệm vụ trích xuất và cô đọng đặc trưng từ chuỗi ảnh radar đầu vào thông qua các tầng xử lý phân cấp, trong khi nhánh giải mã từng bước khôi phục độ phân giải không gian để tạo ra bản đồ độ tin cậy cuối cùng. Các kết nối tắt giữa encoder và decoder giúp duy trì thông tin chi tiết ở các tầng nông, đồng thời kết hợp với đặc trưng ngữ nghĩa ở các tầng sâu nhằm nâng cao khả năng định vị mục tiêu trên mặt phẳng radar.

Từ kiến trúc tổng thể trên, luồng xử lý của RaDecNet có thể được mô tả lần lượt qua các giai đoạn: biến đổi đặc trưng đầu vào, nhúng token, mã hóa đa tầng, hợp nhất đặc trưng trong bộ giải mã và sinh bản đồ độ tin cậy ở độ phân giải ban đầu.

Đầu vào của mô hình là chuỗi ảnh radar được biểu diễn dưới dạng tensor: $\mathbf{X}_0 \in \mathbb{R}^{B \times C_{in} \times T \times H \times W}$, trong đó B là kích thước lô dữ liệu, C_{in} là số kênh đầu vào, T là số khung thời gian, còn H và W lần lượt biểu diễn kích thước không gian theo chiều góc phương vị và khoảng cách. Trong thiết lập thực nghiệm của đề tài, đầu vào có dạng $B \times 2 \times 16 \times 128 \times 128$. Trước khi đi vào bộ mã hóa, dữ liệu được đưa qua lớp biến đổi ban đầu nhằm mở rộng số kênh đặc trưng:

$$\mathbf{F}_{in}^{\text{TokenEmbed}} = \text{GELU}(\mathcal{N}(\text{conv}_{1 \times 1 \times 1}(\mathbf{X}_0))), \quad (3.49)$$

trong đó $\text{conv}_{1 \times 1 \times 1}$ là tích chập điểm ba chiều, $\mathcal{GN}(\cdot)$ là Group Normalization và $\phi(\cdot)$ là hàm kích hoạt phi tuyến. Sau đó, tensor được tổ chức về dạng thuận tiện cho các khối xử lý đặc trưng $\mathbf{F}_{\text{in}}^{\text{TokenEmbed}} \in \mathbb{R}^{B \times T \times H \times W \times C_0}$, với C_0 là số kênh đặc trưng cơ sở.

Tiếp theo, khối Token Embedding được sử dụng để giảm nhẹ độ phân giải không gian nhưng vẫn giữ nguyên chiều thời gian. Với kích thước patch $(1, 2, 2)$, quá trình nhúng token được viết:

$$\mathbf{F}_{\text{out}}^{\text{TokenEmbed}} = \text{LN} \left(\text{conv}_{(1,2,2)} \left(\mathbf{F}_{\text{in}}^{\text{TokenEmbed}} \right) \right), \quad (3.50)$$

trong đó phép tích chập có kernel size và stride đều bằng $(1, 2, 2)$. Do đó, đầu ra sau Token Embedding có dạng $\mathbf{F}_{\text{out}}^{\text{TokenEmbed}} \in \mathbb{R}^{B \times T \times \frac{H}{2} \times \frac{W}{2} \times C_0}$. Việc giữ nguyên chiều T giúp mô hình bảo toàn chuỗi động học của dữ liệu radar, trong khi việc giảm hai chiều không gian giúp giảm chi phí xử lý ở các tầng tiếp theo.

Bộ mã hóa của RaDecNet được tổ chức thành bốn mức đặc trưng. Ở các tầng đầu, mô hình ưu tiên học đặc trưng cục bộ bằng khối ARSC nhằm khai thác sự khác biệt giữa các chiều khoảng cách, góc phương vị và thời gian. Sau đó, ở các tầng sâu hơn, khối DTSA được sử dụng để mô hình hóa quan hệ động học theo thời gian. Cuối cùng, SRA được áp dụng tại mức đặc trưng sâu nhằm tăng cường các vùng tín hiệu thưa nhưng có khả năng chứa mục tiêu. Luồng mã hóa được mô tả như sau:

$$\mathbf{F}_{\text{out},0}^{\text{ARSC}} = \mathcal{A}_0 \left(\mathbf{F}_{\text{out}}^{\text{TokenEmbed}} \right), \quad (3.51)$$

$$\mathbf{F}_{\text{out},1}^{\text{TokenMerging}} = \text{TM}_0 \left(\mathbf{F}_{\text{out},0}^{\text{ARSC}} \right), \quad (3.52)$$

$$\mathbf{F}_{\text{out},1}^{\text{ARSC}} = \mathcal{A}_1 \left(\mathbf{F}_{\text{out},1}^{\text{TokenMerging}} \right), \quad (3.53)$$

$$\mathbf{F}_{\text{out},2}^{\text{TokenMerging}} = \text{TM}_1 \left(\mathbf{F}_{\text{out},1}^{\text{ARSC}} \right), \quad (3.54)$$

$$\mathbf{F}_{\text{out},2}^{\text{DTSA}} = \mathcal{D}_2 \left(\mathbf{F}_{\text{out},2}^{\text{TokenMerging}} \right), \quad (3.55)$$

$$\mathbf{F}_{\text{out},3}^{\text{TokenMerging}} = \text{TM}_2 \left(\mathbf{F}_{\text{out},2}^{\text{DTSA}} \right), \quad (3.56)$$

$$\mathbf{F}_{\text{out}}^{\text{SRA}} = \text{SRA} \left(\mathcal{D}_3 \left(\mathbf{F}_{\text{out},3}^{\text{TokenMerging}} \right) \right). \quad (3.57)$$

Trong đó, $\mathcal{A}_0$ và $\mathcal{A}_1$ là các stage sử dụng khối ARSC, $\mathcal{D}_2$ và $\mathcal{D}_3$ là các stage sử dụng khối DTSA, còn TM_i là các khối Token Merging. Cách tổ chức này phản ánh đúng vai trò của từng nhóm mô-đun: ARSC học cấu trúc cục bộ ở độ phân giải cao, DTSA học phụ thuộc thời gian ở tầng sâu hơn, và SRA tập trung vào các vùng tín hiệu quan trọng sau khi đặc trưng đã được cô đọng.

Sau quá trình mã hóa, mô hình thu được tập đặc trưng đa tỷ lệ:

$$\mathcal{F} = \{\mathbf{F}_{\text{out},0}^{\text{ARSC}}, \mathbf{F}_{\text{out},1}^{\text{ARSC}}, \mathbf{F}_{\text{out},2}^{\text{DTSA}}, \mathbf{F}_{\text{out}}^{\text{SRA}}\}. \quad (3.58)$$

Các đặc trưng này có kích thước lần lượt:

$$\begin{aligned} \mathbf{F}_{\text{out},0}^{\text{ARSC}} &\in \mathbb{R}^{B \times T \times \frac{H}{2} \times \frac{W}{2} \times C_0} \\ \mathbf{F}_{\text{out},1}^{\text{ARSC}} &\in \mathbb{R}^{B \times T \times \frac{H}{4} \times \frac{W}{4} \times 2C_0} \\ \mathbf{F}_{\text{out},2}^{\text{DTSA}} &\in \mathbb{R}^{B \times T \times \frac{H}{8} \times \frac{W}{8} \times 4C_0} \\ \mathbf{F}_{\text{out}}^{\text{SRA}} &\in \mathbb{R}^{B \times T \times \frac{H}{16} \times \frac{W}{16} \times 8C_0} \end{aligned}$$

Có thể thấy, chiều thời gian được giữ nguyên trong toàn bộ encoder, trong khi độ phân giải không gian giảm dần và số kênh đặc trưng tăng dần. Điều này giúp mô hình mở rộng trường tiếp nhận, học được biểu diễn ngữ nghĩa sâu hơn nhưng vẫn không làm mất thông tin động học theo thời gian.

Bộ giải mã của RaDecNet có nhiệm vụ khôi phục dần độ phân giải không gian để tạo ra bản đồ độ tin cậy cuối cùng. Quá trình giải mã bắt đầu từ đặc trưng sâu nhất $\mathbf{F}_{\text{out}}^{\text{SRA}}$. Trước hết, đặc trưng này được chiếu về không gian đặc trưng của decoder:

$$\mathbf{Y}_3 = \mathbf{F}_{\text{out}}^{\text{SRA}} \mathbf{W}_3^d, \quad (3.59)$$

trong đó $\mathbf{W}_3^d$ là ma trận chiếu tuyến tính dùng để điều chỉnh số kênh đặc trưng.

Tại mỗi mức giải mã, đặc trưng từ tầng sâu được lấy mẫu lên theo hai chiều không gian bằng phép upsampling hoặc convTranspose3D với stride (1, 2, 2). Sau đó, đặc trưng này được hợp nhất với đặc trưng skip connection từ encoder thông qua khối WFF. Gọi $\mathbf{F}_{\text{skip},l}$ là đặc trưng tương ứng từ nhánh mã hóa tại mức l , với $l \in \{2, 1, 0\}$, quá trình giải mã có thể được viết tổng quát:

$$\mathbf{F}_{\text{in},d,l}^{\text{WFF}} = \text{up}_l(\mathbf{Y}_{l+1}), \quad (3.60)$$

$$\mathbf{F}_{\text{in},e,l}^{\text{WFF}} = \mathbf{F}_{\text{skip},l} \mathbf{W}_l^d, \quad (3.61)$$

$$\mathbf{F}_{\text{out},l}^{\text{WFF}} = \text{WFF}(\mathbf{F}_{\text{in},d,l}^{\text{WFF}}, \mathbf{F}_{\text{in},e,l}^{\text{WFF}}), \quad (3.62)$$

$$\mathbf{C}_l = \text{concat}(\mathbf{F}_{\text{out},l}^{\text{WFF}}, \mathbf{F}_{\text{in},e,l}^{\text{WFF}}), \quad (3.63)$$

$$\mathbf{Y}_l = \Psi_l(\mathbf{C}_l). \quad (3.64)$$

Trong đó, $\text{Up}_l(\cdot)$ là phép tăng độ phân giải không gian, $\mathbf{W}_l^d$ là phép chiếu đặc trưng skip

về cùng số kênh với decoder, WFF($\cdot$) là khối hợp nhất đặc trưng có trọng số, còn $\Psi_l(\cdot)$ là khối tinh chỉnh đặc trưng tại mức giải mã thứ l .

Cơ chế WFF giúp decoder tự điều chỉnh mức độ đóng góp giữa hai nguồn thông tin: đặc trưng ngữ nghĩa từ nhánh giải mã và đặc trưng chi tiết từ nhánh mã hóa. Điều này đặc biệt quan trọng trong dữ liệu radar, vì đặc trưng tầng nông thường giữ được thông tin vị trí nhưng có thể chứa nhiều nền, trong khi đặc trưng tầng sâu giàu ngữ nghĩa hơn nhưng đã suy giảm độ phân giải không gian. Nhờ hợp nhất có trọng số, mô hình có thể kết hợp hai loại thông tin này một cách linh hoạt hơn so với phép cộng hoặc phép nối trực tiếp. Sau ba bước giải mã, đặc trưng $\mathbf{Y}_0$ có độ phân giải không gian bằng $\frac{H}{2} \times \frac{W}{2}$. Để khôi phục về kích thước ban đầu, mô hình tiếp tục thực hiện phép upsample với hệ số (1, 2, 2):

$$\mathbf{Y}_{\text{up}} = \text{Upsample}_{(1,2,2)}(\mathbf{Y}_0). \quad (3.65)$$

Sau đó, đặc trưng được đưa qua các lớp tích chập cuối để sinh bản đồ dự đoán:

$$\mathbf{P} = \text{conv}_{3 \times 3 \times 3}(\text{GELU}(\mathcal{GN}(\text{conv}_{1 \times 1 \times 1}(\mathbf{Y}_{\text{up}}))))). \quad (3.66)$$

Trong đó, $\mathbf{P}$ là tensor logit đầu ra trước khi ánh xạ về xác suất $\mathbf{P} \in \mathbb{R}^{B \times C_{\text{cls}} \times T \times H \times W}$, với C_{cls} là số lớp đối tượng cần phát hiện. Khi diễn giải dưới dạng bản đồ độ tin cậy, có thể áp dụng hàm sigmoid:

$$\hat{\mathbf{Y}} = \sigma(\mathbf{P}), \quad (3.67)$$

trong đó $\hat{\mathbf{Y}} \in [0, 1]^{B \times C_{\text{cls}} \times T \times H \times W}$. Mỗi phần tử $\hat{\mathbf{Y}}_{b,c,t,i,j}$ biểu diễn mức độ tin cậy rằng tại thời điểm t , vị trí (i, j) trên mặt phẳng radar có sự xuất hiện của đối tượng thuộc lớp c .

Nhìn tổng thể, RaDecNet được thiết kế theo hướng học biểu diễn phù hợp với bản chất vật lý của tín hiệu radar FMCW. ARSC giúp khai thác đặc trưng cục bộ theo các chiều di hướng của dữ liệu; DTSA bổ sung khả năng mô hình hóa quan hệ Doppler - thời gian giữa các khung radar; SRA tập trung tinh chỉnh các vùng tín hiệu thừa nhưng giàu thông tin; trong khi Token Merging và WFF hỗ trợ xây dựng, truyền tải và hợp nhất đặc trưng đa tỷ lệ. Sự kết hợp của các thành phần này giúp RaDecNet đạt được sự cân bằng giữa khả năng biểu diễn không gian - thời gian, độ chính xác phát hiện và hiệu quả tính toán, phù hợp với định hướng triển khai trong các hệ thống radar thời gian thực.

3.4 CÀI ĐẶT MÔ PHỎNG

3.4.1 Thiết lập môi trường mô phỏng

Để đảm bảo tính khách quan và khả năng tái lập kết quả nghiên cứu, toàn bộ quá trình thực nghiệm mô hình được triển khai cục bộ trên một hệ thống máy trạm. Về mặt phần cứng, hệ thống sử dụng bộ vi xử lý trung tâm Intel Core i9-13900K kết hợp cùng 32GB bộ nhớ RAM. Đặc biệt, để tối ưu hóa và tăng tốc tối đa quá trình huấn luyện các đồ thị tính toán phức tạp, hệ thống được trang bị bộ xử lý đồ họa NVIDIA GeForce RTX 4090 với dung lượng 24GB VRAM. Việc triển khai trên một cấu hình phần cứng có băng thông tính toán vượt trội không chỉ giúp rút ngắn triệt để chu kỳ thực nghiệm, mà còn tạo không gian lưu trữ lý tưởng để kiểm thử mô hình với các batch size lớn mà không gặp hiện tượng tràn bộ nhớ.

Về môi trường phần mềm, toàn bộ quy trình tiền xử lý dữ liệu, xây dựng kiến trúc mạng và đánh giá hiệu năng được thực hiện bằng ngôn ngữ Python 3.8.20 thông qua hệ quản lý môi trường Conda. Cấu hình chi tiết của môi trường phần mềm, bao gồm các thư viện sử dụng và phiên bản tương ứng, được trình bày trong Bảng 3.1. Các phiên bản thư viện được cố định xuyên suốt quá trình nghiên cứu nhằm hạn chế những sai khác phát sinh từ môi trường thực thi, đồng thời bảo đảm tính nhất quán giữa các kịch bản thử nghiệm. Nhờ đó, các kết quả thu được phản ánh chính xác ảnh hưởng của các thành phần kiến trúc được đề xuất và tạo cơ sở đáng tin cậy cho việc so sánh, phân tích cũng như đánh giá hiệu năng của mô hình.

Bảng 3.1: Cấu hình môi trường phần mềm và các phiên bản thư viện sử dụng trong thực nghiệm

Nhóm chức năng	Tên thư viện	Phiên bản
Deep learning core	PyTorch	2.4.1+cu121
	Torchvision	0.19.1+cu121
	Timm	1.0.27
Xử lý dữ liệu	Pandas	2.0.3
Tính toán ma trận	Numpy	1.24.3
	SciPy	1.10.1
Huấn luyện mô hình	TensorBoard	2.14.0
	Thop (OpCounter)	0.1.1
Đánh giá & Trực quan	CRUW-devkit	1.1.0
	Matplotlib	3.7.5

3.4.2 Thiết lập dữ liệu mô phỏng

Để đánh giá hiệu quả của mô hình phát hiện đối tượng từ dữ liệu radar mmWave, đề tài sử dụng bộ dữ liệu CRUW (Chinese Radar Object Detection Dataset), một trong những bộ dữ liệu công khai tiêu biểu dành cho bài toán phát hiện đối tượng bằng radar FMCW. Bộ dữ liệu bao gồm khoảng 400.000 khung hình radar và ảnh camera được đồng bộ ở tần số 30 Hz, thu thập trong nhiều môi trường giao thông thực tế như đường nội khu, khu dân cư, bãi đỗ xe và đường cao tốc. Dữ liệu radar được biểu diễn dưới dạng bản đồ khoảng cách - góc phương vị (Range-Azimuth map), với 128 ô khoảng cách và 128 ô góc phương vị, bao phủ trường quan sát $\pm 90^\circ$ và phạm vi phát hiện từ 1 đến 25 m. Các đối tượng trong CRUW được gán nhãn theo ba lớp chính gồm người đi bộ, xe đạp và phương tiện giao thông, phù hợp với các kịch bản ứng dụng trong hệ thống hỗ trợ lái xe và xe tự hành.

Trong nghiên cứu này, dữ liệu được tổ chức theo thiết lập thực nghiệm của CRUW ROD2021, gồm 40 chuỗi dữ liệu, trong đó 36 chuỗi được sử dụng cho huấn luyện và 4 chuỗi dành cho kiểm thử. Việc phân chia theo chuỗi thay vì theo từng khung hình giúp bảo đảm dữ liệu kiểm thử được thu thập ở các thời điểm và vị trí khác với dữ liệu huấn luyện, từ đó phản ánh chính xác hơn khả năng tổng quát hóa của mô hình. Mỗi mẫu đầu vào bao gồm 16 khung radar liên tiếp với kích thước $16 \times 2 \times 128 \times 128$, trong đó hai kênh tương ứng với thành phần thực và thành phần ảo của tín hiệu radar. Ngoài ra, để đánh giá độ bền vững của mô hình trong điều kiện tín hiệu suy giảm, nhiễu Gaussian được bổ sung vào tập kiểm thử với dải SNR từ -10 dB đến 20 dB.

3.4.3 Cấu hình và tham số huấn luyện mô hình

Nhằm đánh giá hiệu quả của kiến trúc RaDecNet trên bài toán phát hiện và định vị đối tượng từ dữ liệu radar mmWave, quá trình huấn luyện được triển khai trên nền tảng PyTorch với tập hợp siêu tham số được lựa chọn phù hợp với đặc tính của tín hiệu vô tuyến và cấu trúc mạng đề xuất. Bộ tối ưu hóa Adam được sử dụng với tốc độ học khởi tạo 5×10^{-5} nhờ khả năng thích nghi hiệu quả với các phân phối dữ liệu có mức biến thiên lớn về cường độ phản xạ. Hàm mất mát Binary Cross-Entropy (BCE Loss) được áp dụng để tối ưu trực tiếp bản đồ độ tin cậy đầu ra, trong đó mỗi phần tử biểu diễn xác suất xuất hiện của mục tiêu tại một vị trí không gian cụ thể. Bên cạnh đó, tốc độ học được điều chỉnh động thông qua bộ lập lịch StepLR với chu kỳ suy giảm 15 epoch và hệ số $\gamma = 0.1$, cho phép mô hình duy trì khả năng học hiệu quả ở giai đoạn đầu và tinh chỉnh tham số ổn định khi tiến gần trạng thái hội tụ. Toàn bộ trạng thái huấn luyện được lưu trữ định kỳ thông qua cơ chế checkpoint nhằm đảm bảo khả năng khôi phục và tiếp

tục các thí nghiệm trong những quá trình huấn luyện kéo dài.

Chi tiết các siêu tham số và cấu hình được sử dụng trong quá trình huấn luyện được trình bày trong Bảng 3.2.

Bảng 3.2: Các tham số huấn luyện mô hình RaDecNet

Tham số	Giá trị	Mô tả
Optimizer	Adam	Tốc độ học khởi tạo $\eta = 5 \times 10^{-5}$.
Loss Function	BCE Loss	Tối ưu bản đồ độ tin cậy $[0, 1]$.
Batch Size	4	Số mẫu cho mỗi lần cập nhật.
Epoch	50	Tổng chu kỳ huấn luyện.
Window Size	16	Số khung hình radar liên tiếp.
Train Stride	4	Bước dịch cửa sổ thời gian.
Input Channels	2	Kênh tín hiệu I/Q.

3.4.4 Phương pháp đánh giá mô hình

Nhằm đánh giá khách quan hiệu quả của kiến trúc RaDecNet trên dữ liệu radar mmWave, nghiên cứu sử dụng hệ thống chỉ số đánh giá chuẩn được áp dụng rộng rãi trong các bài toán phát hiện đối tượng [22]. Khác với bài toán phân loại thông thường, việc đánh giá chủ yếu tập trung vào khả năng phát hiện đúng mục tiêu, hạn chế cảnh báo giả và giảm thiểu đối tượng bị bỏ sót thông qua ba đại lượng cơ bản: TP (True Positive) là số lượng đối tượng được RaDecNet phát hiện chính xác, thỏa mãn ngưỡng dung sai không gian định trước. FP (False Positive) là số lượng cảnh báo giả, xảy ra khi RaDecNet dự đoán một đối tượng không tồn tại hoặc định vị sai lệch vượt mức cho phép. FN (False Negative) là số lượng đối tượng thực tế bị RaDecNet bỏ sót.

Dựa trên các đại lượng TP, FP và FN, hiệu suất phát hiện của mô hình được đánh giá thông qua hai chỉ số cơ bản là Precision và Recall. Hai chỉ số này được xác định như sau:

- **Độ chính xác dự đoán (Precision):** Thể hiện mức độ tin cậy của các kết quả phát hiện, phản ánh khả năng hạn chế các cảnh báo giả của mô hình.

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (3.68)$$

- **Độ bao phủ (Recall):** Phản ánh khả năng phát hiện đầy đủ các mục tiêu thực tế, qua đó đánh giá mức độ bỏ sót đối tượng của hệ thống.

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (3.69)$$

Tuy nhiên, khác với các bài toán phát hiện đối tượng trên ảnh quang học, nơi tiêu chuẩn đánh giá thường dựa trên độ giao nhau giữa các hộp giới hạn (intersection over union - IoU), việc đánh giá trên dữ liệu radar mmWave đòi hỏi một thước đo phù hợp hơn với đặc tính vật lý của tín hiệu vô tuyến. Trong bộ dữ liệu CRUW, mức độ khớp giữa dự đoán và nhãn chuẩn được xác định thông qua chỉ số Object Location Similarity (OLS). Thước đo này mô tả mức độ tương đồng về vị trí giữa mục tiêu dự đoán và mục tiêu thực tế, đồng thời xét đến ảnh hưởng của khoảng cách từ đối tượng đến cảm biến radar. Giá trị OLS được định nghĩa như sau:

$$\text{OLS} = \exp\left(-\frac{d^2}{2(s\kappa_{cls})^2}\right) \quad (3.70)$$

trong đó d là khoảng cách Euclid giữa vị trí dự đoán và nhãn chuẩn, s biểu diễn khoảng cách từ mục tiêu tới cảm biến radar, còn κ_{cls} là hệ số dung sai đặc trưng cho từng lớp đối tượng. Cơ chế này cho phép hệ thống đánh giá linh hoạt hơn đối với các mục tiêu ở xa, nơi sai số định vị tuyệt đối thường lớn hơn do giới hạn vật lý của cảm biến.

Dựa trên các ngưỡng OLS khác nhau, hiệu suất của mô hình được đánh giá thông qua hai chỉ số tổng hợp là Average Precision (AP) và Average Recall (AR). AP phản ánh độ chính xác trung bình của quá trình phát hiện mục tiêu, trong khi AR thể hiện khả năng bao phủ mục tiêu trung bình trên nhiều mức dung sai vị trí khác nhau. Hai chỉ số này bổ sung lẫn nhau, cho phép đánh giá toàn diện năng lực nhận dạng và định vị đối tượng của kiến trúc RaDecNet trong các điều kiện quan sát khác nhau.

Theo giao thức đánh giá chuẩn của bộ dữ liệu CRUW, các chỉ số AP và AR được tính trung bình trên tập các ngưỡng OLS từ 0.50 đến 0.90 với bước tăng 0.05. Cách tiếp cận này giúp loại bỏ sự phụ thuộc vào một ngưỡng đánh giá cố định, đồng thời phản ánh chính xác hơn năng lực định vị và nhận dạng của mô hình trong các tình huống thực tế. Nhờ đó, các kết quả thực nghiệm thu được không chỉ thể hiện khả năng phát hiện mục tiêu ở một điều kiện riêng lẻ, mà còn cung cấp cái nhìn toàn diện về mức độ chính xác, tính ổn định và khả năng tổng quát hóa của kiến trúc RaDecNet trên dữ liệu radar mmWave.

Chương 4

KẾT QUẢ VÀ THẢO LUẬN

Chương này trình bày các kết quả thực nghiệm nhằm đánh giá toàn diện hiệu quả của mô hình RaDecNet được đề xuất trong bài toán phát hiện đối tượng bằng radar sóng milimet trên tập dữ liệu CRUW. Xuất phát từ đặc thù của dữ liệu radar, vốn có tính thưa, nhiễu mạnh, phản xạ không ổn định và tồn tại sự phụ thuộc phức tạp theo các miền khoảng cách, góc-phương vị cũng như chuỗi thời gian, việc đánh giá mô hình không chỉ tập trung vào độ chính xác phát hiện mà còn cần xem xét khả năng tổng quát hóa, mức độ ổn định, độ phức tạp tính toán và tiềm năng triển khai trong các hệ thống thời gian thực. Trên cơ sở đó, nội dung chương được triển khai theo ba hướng chính. Trước hết, hiệu suất phát hiện đối tượng của mô hình đề xuất được phân tích thông qua các chỉ số định lượng như Average Precision, Average Recall, số lượng tham số, FLOPs và độ trễ suy luận, qua đó làm rõ khả năng cân bằng giữa hiệu năng phát hiện và tính gọn nhẹ của RaDecNet. Tiếp theo, nghiên cứu loại bỏ thành phần được thực hiện nhằm đánh giá vai trò riêng biệt của từng mô-đun cải tiến, bao gồm ARSC, DTSA và SRA, từ đó chỉ ra mức độ đóng góp của các cơ chế học đặc trưng bất đẳng hướng, mô hình hóa phụ thuộc Doppler-thời gian và tập trung khai thác các vùng tín hiệu thưa nhưng giàu thông tin. Cuối cùng, mô hình đề xuất được so sánh với các kiến trúc học sâu đã được công bố trước đây nhằm khẳng định tính hiệu quả của RaDecNet không chỉ ở khía cạnh độ chính xác phát hiện mà còn ở khả năng tối ưu tài nguyên tính toán. Thông qua các phân tích định lượng và thảo luận chi tiết, chương này hướng đến việc chứng minh rằng RaDecNet là một kiến trúc phù hợp với bản chất vật lý của tín hiệu radar, trong đó sự kết hợp giữa học đặc trưng cục bộ theo từng trục không gian, mô hình hóa quan hệ thời gian và chọn lọc vùng thông tin quan trọng giúp mô hình đạt được sự cân bằng giữa hiệu suất, độ ổn định và khả năng ứng dụng thực tế trong các hệ thống hỗ trợ lái xe thông minh.


4.1 KẾT QUẢ PHÁT HIỆN CỦA MÔ HÌNH ĐỀ XUẤT

Mục này trình bày kết quả thực nghiệm của mô hình RaDecNet trên tập dữ liệu CRUW nhằm đánh giá khả năng phát hiện đối tượng từ dữ liệu radar FMCW. Hiệu quả của mô hình được đánh giá thông qua các chỉ số độ chính xác trung bình, độ nhạy trung bình, số lượng tham số, số phép tính dấu phẩy động và độ trễ suy luận. Các chỉ số này cho phép đánh giá đồng thời cả hiệu quả phát hiện và mức độ phù hợp của mô hình đối với yêu cầu triển khai thời gian thực.

Bảng 4.1: Kết quả thực nghiệm của mô hình RaDecNet trên tập dữ liệu CRUW.

Model	AP (%)	AR (%)	Params. (M)	FLOPs (G)	Latency (ms)
RaDecNet	88.41	91.74	1.26	5.78	18

Kết quả trong Bảng 4.1 cho thấy RaDecNet đạt AP 88.41% và AR 91.74% trên tập dữ liệu CRUW. Giá trị AP cao phản ánh khả năng dự đoán chính xác vị trí và lớp đối tượng trên bản đồ radar, trong khi giá trị AR cao cho thấy mô hình có khả năng bao phủ tốt các mục tiêu xuất hiện trong cảnh quan sát. Đáng chú ý, mô hình chỉ sử dụng 1.26M tham số và 5.78G FLOPs, cho thấy kiến trúc đề xuất duy trì được độ gọn nhẹ đáng kể. Với độ trễ suy luận 18 ms cho mỗi mẫu đầu vào, tốc độ xử lý tương ứng của RaDecNet có thể được ước lượng theo số khung hình mỗi giây xấp xỉ 55 FPS, cao hơn ngưỡng thời gian thực phổ biến 30 FPS. Điều này chứng minh rằng RaDecNet không chỉ đạt hiệu quả phát hiện tốt trên tập dữ liệu CRUW, mà còn có tiềm năng triển khai trong các hệ thống radar thời gian thực trên phương tiện, nơi yêu cầu mô hình phải phản hồi nhanh trước sự thay đổi liên tục của môi trường giao thông.



Hình 4.1: Kết quả minh họa khả năng phát hiện đối tượng của RaDecNet trên tập dữ liệu CRUW.

Bên cạnh các chỉ số định lượng, Hình 4.1 minh họa trực quan khả năng phát hiện của RaDecNet trong nhiều bối cảnh khác nhau. Mỗi cột thể hiện một mẫu dữ liệu, bao gồm ảnh RGB, ảnh RF radar, bản đồ nhãn gốc và kết quả dự đoán của mô hình. Cách trình

bày này giúp quan sát trực tiếp mức độ tương đồng giữa vùng dự đoán của RaDecNet và vùng mục tiêu trong thực tế.

Quan sát Hình 4.1 cho thấy các vùng phản hồi do RaDecNet dự đoán có xu hướng trùng khớp tốt với bản đồ thực tế ở nhiều tình huống khác nhau. Đối với các mục tiêu có tín hiệu phản xạ rõ ràng, mô hình tạo ra vùng kích hoạt tập trung và có cường độ cao tại vị trí đối tượng. Trong các trường hợp nhiễu nền hoặc mục tiêu có kích thước nhỏ, kết quả dự đoán vẫn giữ được cấu trúc tương đối ổn định, cho thấy mô hình có khả năng khai thác hiệu quả thông tin từ ảnh RF radar. Điều này phản ánh vai trò của các mô-đun ARSC, DTSA và SRA trong việc học đặc trưng cục bộ, bổ sung quan hệ động học theo thời gian và tập trung vào các vùng tín hiệu thưa nhưng giàu thông tin.

Nhìn chung, kết quả định lượng và trực quan cho thấy RaDecNet đạt được sự cân bằng tốt giữa hiệu quả phát hiện và chi phí tính toán. Mô hình không chỉ tạo ra bản đồ dự đoán có độ tương đồng cao với nhãn gốc, mà còn duy trì quy mô tham số nhỏ và độ trễ suy luận phù hợp với định hướng triển khai trên các hệ thống radar thời gian thực.

4.2 SO SÁNH HIỆU QUẢ PHÁT HIỆN QUA TỪNG MÔ-ĐUN CẢI TIẾN

Kết quả đánh giá thành phần trong Bảng 4.2 được thực hiện nhằm làm rõ vai trò riêng biệt cũng như mức độ hỗ trợ lẫn nhau của ba mô-đun cải tiến chính trong kiến trúc RaDecNet, bao gồm ARSC, DTSA và SRA. Đây là bước đánh giá cần thiết, bởi hiệu năng của một mô hình học sâu không chỉ cần được chứng minh bằng kết quả cuối cùng, mà còn cần được lý giải thông qua đóng góp của từng thành phần bên trong kiến trúc. Đối với bài toán phát hiện đối tượng bằng radar sóng milimet, dữ liệu đầu vào thường có cường độ phản xạ thưa, nhiễu nền lớn, hình dạng mục tiêu không ổn định và biến đổi mạnh theo chuỗi thời gian. Vì vậy, việc khảo sát các cấu hình từ R_0 đến R_5 cho phép đánh giá liệu từng mô-đun có thực sự cải thiện khả năng phát hiện hay chỉ làm gia tăng độ phức tạp của mô hình.

Trước hết, các cấu hình chỉ sử dụng một mô-đun riêng lẻ cho thấy rõ đặc điểm chức năng của từng thành phần. Với cấu hình R_0 , khi chỉ sử dụng SRA, mô hình đạt 85.40% AP và 89.34% AR với 0.609M tham số. Kết quả này cho thấy cơ chế chọn lọc vùng thưa có khả năng hỗ trợ mô hình tập trung vào các khu vực có khả năng chứa đối tượng, phù hợp với bản chất dữ liệu radar khi phần lớn không gian quan sát là nền hoặc nhiễu, còn tín hiệu có ý nghĩa thường chỉ tập trung tại một số vùng phản xạ nhỏ. Tuy nhiên, do chưa có khả năng học đặc trưng bất đẳng hướng và chưa mô hình hóa quan hệ chuyển động

theo thời gian, hiệu năng của cấu hình này vẫn còn bị giới hạn.

Bảng 4.2: Ablation Study của mô hình với các thành phần khác nhau (ARSC, DTSA, SRA).

Model	Components			AP	AR	Params	FLOPs	Time
	ARSC	DTSA	SRA	(%)	(%)	(M)	(G)	(ms)
$\mathcal{R}_0$	✗	✗	✓	85.40	89.34	0.609	6.140	10
$\mathcal{R}_1$	✗	✓	✗	84.75	89.18	1.008	6.125	10
$\mathcal{R}_2$	✓	✗	✗	87.44	91.05	0.338	5.879	8
$\mathcal{R}_3$	✗	✓	✓	85.76	89.71	1.272	6.151	20
$\mathcal{R}_4$	✓	✗	✓	87.94	91.51	0.602	5.904	10
$\mathcal{R}_5$	✓	✓	✗	87.95	91.51	1.000	5.889	8
RaDecNet	✓	✓	✓	88.41	91.74	1.264	5.915	18

Đối với cấu hình $\mathcal{R}_1$, khi chỉ sử dụng ARSC, mô hình đạt 84.75% AP và 89.18% AR với 1.008M tham số. Mặc dù kết quả chưa vượt trội so với $\mathcal{R}_0$, cấu hình này vẫn cho thấy vai trò của ARSC trong việc khai thác đặc trưng cục bộ theo ba chiều: khoảng cách, góc phương vị và thời gian. Đây là một thiết kế phù hợp với dữ liệu radar, bởi các chiều này không mang ý nghĩa đồng nhất như hai chiều không gian trong ảnh RGB. Tuy nhiên, khi hoạt động độc lập, ARSC chủ yếu làm giàu đặc trưng cục bộ mà chưa có cơ chế chọn lọc vùng quan trọng hoặc nắm bắt phụ thuộc động học dài hạn, nên chưa đủ để tạo ra biểu diễn mạnh trong môi trường radar nhiễu nhiều và phản xạ thừa.

Một quan sát nổi bật xuất hiện ở cấu hình $\mathcal{R}_2$, khi mô hình chỉ sử dụng DTSA. Cấu hình này đạt 87.44% AP và 91.05% AR, trong khi chỉ cần 0.338M tham số và 5.879G FLOPs. Đây là kết quả quan trọng vì cho thấy DTSA có đóng góp rất lớn vào hiệu quả phát hiện. Khác với ảnh tĩnh, radar không chỉ phản ánh vị trí tức thời của mục tiêu mà còn chứa thông tin liên quan đến chuyển động, vận tốc tương đối và sự thay đổi phản xạ theo thời gian. Do đó, việc mô hình hóa quan hệ Doppler-thời gian giúp mạng khai thác tính liên tục động học của đối tượng qua nhiều khung radar liên tiếp, đặc biệt trong các trường hợp tín hiệu mục tiêu không ổn định ở từng khung đơn lẻ.

Khi xét các cấu hình kết hợp hai mô-đun, vai trò trung tâm của DTSA tiếp tục được thể hiện rõ. Cấu hình $\mathcal{R}_3$, kết hợp ARSC và SRA, đạt 85.76% AP và 89.71% AR, chỉ cải thiện nhẹ so với khi sử dụng riêng từng mô-đun. Điều này cho thấy việc kết hợp giữa học đặc trưng bất đẳng hướng và chọn lọc vùng quan trọng có đem lại lợi ích nhất định, nhưng vẫn chưa đủ khi thiếu thành phần mô hình hóa phụ thuộc thời gian. Ngược lại, hai cấu hình có DTSA đều đạt kết quả cao hơn rõ rệt: $\mathcal{R}_4$ kết hợp ARSC và DTSA đạt 87.94% AP và 91.51% AR, trong khi $\mathcal{R}_5$ kết hợp DTSA và SRA đạt 87.95% AP và

91.51% AR. Hai kết quả gần như tương đương này cho thấy DTSA là thành phần then chốt giúp duy trì hiệu năng phát hiện cao, còn ARSC và SRA đóng vai trò bổ trợ theo hai hướng khác nhau: một bên làm giàu đặc trưng cục bộ theo cấu trúc radar, một bên tập trung vào các vùng tín hiệu thưa nhưng có giá trị.

Bước cải thiện rõ ràng nhất đạt được khi cả ba mô-đun ARSC, DTSA và SRA được tích hợp đồng thời trong mô hình RaDecNet đầy đủ. Khi đó, mô hình đạt 88.41% AP và 91.74% AR, cao nhất trong tất cả các cấu hình được khảo sát. Kết quả này chứng minh rằng ba mô-đun không hoạt động rời rạc, mà tạo thành một chuỗi bổ trợ có ý nghĩa về mặt kiến trúc. ARSC giúp khai thác đặc trưng cục bộ phù hợp với tính bất đẳng hướng của dữ liệu radar; DTSA mở rộng biểu diễn bằng cách mô hình hóa phụ thuộc Doppler-thời gian; còn SRA tập trung năng lực trích xuất đặc trưng vào các vùng tín hiệu thưa nhưng giàu thông tin. Sự kết hợp này tạo nên một dòng xử lý hợp lý: học đúng cấu trúc vật lý của radar, khai thác quan hệ động học theo thời gian và chọn lọc những vùng có giá trị cao nhất cho nhiệm vụ phát hiện.

Xét về độ phức tạp, RaDecNet đầy đủ sử dụng 1.264M tham số, 5.915G FLOPs và đạt thời gian suy luận 18 ms. Mặc dù số lượng tham số cao hơn một số biến thể rút gọn, mức tăng này vẫn hợp lý khi đặt trong tương quan với hiệu quả phát hiện đạt được. Đáng chú ý, FLOPs của mô hình đầy đủ không tăng quá mạnh so với các cấu hình có DTSA, nhưng AP và AR lại đạt mức cao nhất. Điều này cho thấy RaDecNet không cải thiện hiệu năng bằng cách mở rộng quy mô mô hình một cách thuần túy, mà bằng cách phân bổ năng lực biểu diễn vào những thành phần có ý nghĩa trực tiếp đối với dữ liệu radar.

Từ các kết quả trên, có thể khẳng định rằng DTSA là thành phần có ảnh hưởng mạnh nhất đến hiệu quả phát hiện, bởi các cấu hình có DTSA đều đạt AP và AR cao hơn rõ rệt so với các cấu hình không có DTSA. Tuy nhiên, DTSA không thể thay thế hoàn toàn các thành phần còn lại. ARSC giúp khai thác tốt hơn cấu trúc bất đẳng hướng trong không gian radar, còn SRA giúp mô hình tập trung vào các vùng mục tiêu thưa và giảm ảnh hưởng của nhiễu nền. Khi ba thành phần này được kết hợp trong kiến trúc đầy đủ, RaDecNet đạt được sự cân bằng giữa độ chính xác, khả năng bao phủ đối tượng, chi phí tính toán và tiềm năng triển khai thực tế. Do đó, kết quả đánh giá thành phần đã khẳng định tính hợp lý của chiến lược thiết kế RaDecNet, đồng thời cho thấy các cải tiến được đề xuất phù hợp với bản chất vật lý và đặc trưng biểu diễn của tín hiệu radar sóng milimet.

4.3 SO SÁNH HIỆU QUẢ PHÁT HIỆN SO VỚI CÁC MÔ HÌNH HỌC SÂU ĐÃ ĐƯỢC ĐỀ XUẤT TRƯỚC ĐÂY

Bảng 4.3 trình bày kết quả so sánh mô hình RaDecNet với các kiến trúc học sâu tiêu biểu trên tập dữ liệu CRUW. Các mô hình được đối chiếu đại diện cho nhiều hướng tiếp cận khác nhau trong bài toán phát hiện đối tượng bằng radar sóng milimet, bao gồm nhóm 3D CNN dạng hourglass như RODNet-CDC, RODNet-HG và RODNet-HGwI, mô hình lai ghép CNN-Transformer như T-RODNet, các kiến trúc tăng cường biểu diễn như Mask-RadarNet, E-RODNet, RAMP-CNN, và mô hình gọn nhẹ CompactRADNet. Do đó, việc so sánh không chỉ tập trung vào chỉ số AP và AR tổng thể, mà còn cần xem xét đồng thời hiệu quả trên từng lớp đối tượng, số lượng tham số, FLOPs và độ trễ suy luận để đánh giá đầy đủ tính cân bằng giữa hiệu năng và khả năng triển khai thực tế.

Xét trên kết quả tổng thể, RaDecNet đạt Overall AP 88.41% và Overall AR 91.74%, thuộc nhóm cao nhất trong các mô hình được so sánh. Đáng chú ý, mô hình chỉ sử dụng 1.26M tham số và 5.78G FLOPs, thấp hơn đáng kể so với hầu hết các phương pháp trước đó. So với nhóm RODNet truyền thống, RaDecNet cải thiện rõ rệt cả về độ chính xác lẫn độ gọn nhẹ. Chẳng hạn, RODNet-HG sử dụng tới 129.19M tham số và 2144.86G FLOPs nhưng chỉ đạt 79.43% AP và 83.59% AR, trong khi RaDecNet đạt hiệu quả cao hơn với quy mô nhỏ hơn rất nhiều. Điều này cho thấy việc mở rộng mạng 3D CNN không phải lúc nào cũng là hướng tối ưu đối với dữ liệu radar, bởi các phép tích chập cục bộ có thể gặp hạn chế trong việc mô hình hóa quan hệ động học dài hạn và các vùng tín hiệu thưa.

Khi so sánh với T-RODNet, một mô hình sử dụng Transformer nhằm tăng khả năng học phụ thuộc toàn cục, RaDecNet tiếp tục cho thấy ưu thế rõ rệt. T-RODNet đạt 83.27% AP và 86.98% AR với 43.11M tham số và 182.53G FLOPs, trong khi RaDecNet đạt AP và AR cao hơn nhưng chỉ cần 1.26M tham số và 5.78G FLOPs. Kết quả này cho thấy RaDecNet không phủ nhận vai trò của attention, mà sử dụng attention theo hướng chọn lọc và phù hợp hơn với bản chất radar. Thay vì áp dụng cơ chế attention rộng trên toàn bộ không gian đặc trưng, mô hình tập trung khai thác phụ thuộc Doppler-thời gian thông qua DTSA, nhờ đó nắm bắt được thông tin chuyển động quan trọng nhưng vẫn kiểm soát tốt chi phí tính toán.

So với các mô hình tăng cường biểu diễn như Mask-RadarNet và E-RODNet, RaDecNet cũng đạt kết quả cạnh tranh hơn. Mask-RadarNet đạt 84.29% AP và 87.36% AR với 32.12M tham số, còn E-RODNet đạt 85.46% AP và 89.19% AR với 6.10M tham số và độ trễ 36 ms. Trong khi đó, RaDecNet đạt 88.41% AP, 91.74% AR và độ trễ 18 ms. Sự cải thiện này phản ánh hiệu quả của việc thiết kế mô hình theo đúng đặc trưng vật lý

Bảng 4.3: So sánh hiệu quả phát hiện đối tượng giữa các mô hình tiên tiến hiện nay trên tập dữ liệu CRUW. Các chỉ số đo đối chiếu bao gồm Average Precision (AP) và Average Recall (AR) cho từng lớp đối tượng (Pedestrian, Cyclist, Car) cùng với Overall, tính theo đơn vị phần trăm (%). Ngoài ra còn so sánh số lượng tham số (Params.), FLOPs và độ trễ (Latency).

Model	Overall		Pedestrian		Cyclist		Car		Params. (M)	FLOPs (G)	Latency (ms)
	AP (%)	AR (%)	AP (%)	AR (%)	AP (%)	AR (%)	AP (%)	AR (%)			
RODNet-CDC [2]	76.33	79.28	77.11	79.64	69.39	70.02	82.91	89.13	34.52	280.03	1
RODNet-HG [2]	79.43	83.59	78.90	83.81	76.69	78.85	83.36	88.55	129.19	2144.86	7
RODNet-HGWI [2]	78.06	81.07	79.47	81.85	70.35	71.40	84.39	90.05	61.29	5949.68	5
T-RODNet [6]	83.27	86.98	82.19	85.41	82.28	84.30	86.22	92.53	44.31	182.53	20
Mask-RadarNet [7]	84.29	87.36	82.74	85.80	85.06	86.67	85.96	90.66	32.12	176.91	20
E-RODNet [13]	85.46	89.19	84.30	88.37	88.56	90.95	83.87	90.14	6.10	33.25	36
mRadNet [8]	86.72	91.18	84.00	88.60	87.13	91.93	90.59	94.17	4.93	32.79	9
CompactRADNet [23]	88.15	90.77	86.00	88.00	91.00	94.00	88.40	91.70	1.65	18.85	33
RaDecNet (Ours)	88.41	91.74	87.09	91.52	93.06	95.33	87.25	88.98	1.26	5.78	18

của radar: ARSC khai thác đặc trưng bất đẳng hướng theo range, azimuth và thời gian; DTSA mô hình hóa quan hệ Doppler-thời gian; còn SRA tập trung vào các vùng tín hiệu thưa nhưng giàu thông tin. Nhờ vậy, mô hình không cần tăng độ phức tạp quá mức nhưng vẫn nâng cao chất lượng phát hiện.

Đối với nhóm mô hình gọn nhẹ, CompactRADNet là đối thủ gần nhất với RaDecNet. CompactRADNet đạt 88.15% AP và 90.77% AR với 1.65M tham số và 18.85G FLOPs. So với mô hình này, RaDecNet đạt AP cao hơn 0.26 điểm phần trăm và AR cao hơn 0.97 điểm phần trăm, đồng thời giảm số tham số xuống 1.26M và FLOPs xuống 5.78G. Điều này cho thấy RaDecNet không đánh đổi độ chính xác để đạt được sự gọn nhẹ, mà đạt được cả hai nhờ tổ chức kiến trúc hợp lý hơn. Với RAMP-CNN, mặc dù mô hình này có AR tổng thể 91.80% và độ trễ 9 ms, RaDecNet vẫn đạt AP cao hơn trong khi số tham số thấp hơn rất nhiều, 1.26M so với 49.45M. Vì vậy, xét trên tương quan giữa độ chính xác, độ bao phủ và tài nguyên tính toán, RaDecNet thể hiện điểm cân bằng tốt hơn.

Phân tích theo từng lớp đối tượng cũng cho thấy ưu thế đáng chú ý của mô hình đề xuất. Với pedestrian, RaDecNet đạt 87.09% AP và 91.52% AR, thể hiện khả năng phát hiện tốt các đối tượng nhỏ, có phản xạ yếu và dễ bị lẫn với nhiễu nền. Với cyclist, mô hình đạt 93.06% AP và 95.33% AR, cao nhất trong toàn bộ các mô hình được so sánh. Đây là kết quả đặc biệt quan trọng, bởi cyclist là lớp có cấu trúc phản xạ phức tạp và chuyển động rõ rệt theo thời gian. Kết quả này cho thấy DTSA đã khai thác hiệu quả thông tin động học, trong khi ARSC và SRA hỗ trợ giữ lại các đặc trưng cục bộ và vùng tín hiệu quan trọng. Đối với lớp car, RaDecNet đạt 87.25% AP và 88.98% AR. Mặc dù chưa phải là kết quả cao nhất ở lớp này, mô hình vẫn duy trì hiệu năng ổn định trong khi có số lượng tham số và FLOPs thấp hơn đáng kể so với các phương pháp có kết quả cao hơn trên lớp car.

Nhìn chung, kết quả trong Bảng 4.3 cho thấy RaDecNet là một kiến trúc có tính cạnh tranh cao trong bài toán phát hiện đối tượng bằng radar sóng milimet. So với các mô hình 3D CNN truyền thống, mô hình đề xuất cải thiện đáng kể hiệu quả phát hiện mà không cần mở rộng mạng quá lớn. So với các kiến trúc Transformer, RaDecNet khai thác attention theo hướng có chọn lọc hơn, tập trung vào miền Doppler-thời gian có ý nghĩa vật lý rõ ràng. So với các mô hình gọn nhẹ, RaDecNet vẫn đạt hiệu năng cao hơn trong khi giảm chi phí tính toán. Từ đó có thể khẳng định rằng ưu thế của RaDecNet không chỉ nằm ở các chỉ số AP và AR, mà còn ở chiến lược thiết kế phù hợp với bản chất của dữ liệu radar: học đặc trưng bất đẳng hướng, mô hình hóa quan hệ thời gian và tập trung vào các vùng tín hiệu thưa. Đây là cơ sở quan trọng để khẳng định tiềm năng ứng dụng của mô hình trong các hệ thống hỗ trợ lái xe thông minh.

Chương 5

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 KẾT LUẬN

Mô hình RaDecNet được đề xuất trong đề tài đã đáp ứng tốt các yêu cầu quan trọng của bài toán phát hiện đối tượng bằng radar sóng milimet, đồng thời cho thấy một hướng tiếp cận hiệu quả trong việc xây dựng mô hình học sâu gọn nhẹ, chính xác và phù hợp với bản chất vật lý của tín hiệu radar. Thay vì mở rộng kiến trúc theo hướng tăng mạnh số lượng tham số hoặc độ sâu mạng, RaDecNet tập trung khai thác ba đặc trưng cốt lõi của dữ liệu radar: tính bất đẳng hướng theo miền khoảng cách – góc phương vị, phụ thuộc Doppler-thời gian và sự phân bố thưa của các vùng phản xạ mục tiêu. Nhờ đó, mô hình đạt được sự cân bằng đáng chú ý giữa hiệu quả phát hiện, chi phí tính toán và khả năng triển khai thực tế.

Về hiệu quả phát hiện đối tượng: RaDecNet đạt Overall AP 88.41% và Overall AR 91.74% trên tập dữ liệu CRUW, cho thấy khả năng phát hiện ổn định và cạnh tranh so với các mô hình đã được đề xuất trước đây. Khi xét theo từng lớp, mô hình đạt 87.09% AP và 91.52% AR đối với người đi bộ, 93.06% AP và 95.33% AR đối với người đi xe đạp, đồng thời đạt 87.25% AP và 88.98% AR đối với xe ô tô. Những kết quả này cho thấy RaDecNet không chỉ phát hiện tốt các đối tượng có phản xạ mạnh, mà còn có khả năng xử lý hiệu quả các mục tiêu nhỏ, thưa và dễ bị nhiễu che khuất như pedestrian và cyclist. Đặc biệt, hiệu quả cao trên lớp cyclist khẳng định vai trò quan trọng của việc khai thác thông tin chuyển động và sự biến đổi phản xạ qua chuỗi thời gian.

Về hiệu quả của các mô-đun cải tiến: Kết quả đánh giá thành phần đã chứng minh rằng ARSC, DTSA và SRA không phải là các thành phần bổ sung rời rạc, mà tạo thành một chuỗi xử lý có tính hỗ trợ rõ ràng. ARSC giúp mô hình học đặc trưng cục bộ phù hợp với tính bất đẳng hướng của radar theo các chiều khoảng cách, góc phương vị và thời gian. DTSA giữ vai trò quan trọng trong việc mô hình hóa phụ thuộc Doppler-thời gian, từ đó khai thác tốt hơn sự liên tục động học của mục tiêu qua nhiều khung radar liên tiếp. Trong khi đó, SRA tập trung năng lực trích xuất đặc trưng vào các vùng tín hiệu thưa nhưng giàu thông tin, giúp giảm ảnh hưởng của nhiễu nền và các vùng ít liên quan. Khi kết hợp đầy đủ ba mô-đun, RaDecNet đạt hiệu quả phát hiện cao nhất, khẳng định tính hợp lý của chiến lược thiết kế đề xuất.

Về độ gọn nhẹ và khả năng triển khai: RaDecNet chỉ sử dụng khoảng 1.26M tham

số, FLOPs xấp xỉ 5.78G và đạt độ trễ suy luận 18 ms. So với nhiều mô hình radar object detection trước đây có quy mô hàng chục đến hàng trăm triệu tham số, mô hình đề xuất thể hiện ưu thế rõ rệt về hiệu quả sử dụng tài nguyên. Điều này cho thấy hiệu năng cao không nhất thiết phải đến từ việc mở rộng quy mô mô hình một cách thuần túy, mà có thể đạt được thông qua thiết kế kiến trúc có định hướng và phù hợp với dữ liệu đầu vào. Nhờ sự cân bằng giữa độ chính xác, chi phí tính toán và tốc độ suy luận, RaDecNet có tiềm năng ứng dụng trong các hệ thống radar thời gian thực, thiết bị biên và hệ thống hỗ trợ lái xe thông minh.

Nhìn chung, kết quả nghiên cứu đã khẳng định RaDecNet là một kiến trúc có giá trị đối với bài toán phát hiện đối tượng bằng radar sóng milimet. Mô hình không chỉ đạt hiệu quả cạnh tranh trên tập dữ liệu CRUW, mà còn thể hiện rõ ưu điểm ở khả năng khai thác đặc trưng radar theo hướng có cơ sở vật lý, gọn nhẹ và phù hợp với yêu cầu triển khai thực tế.

5.2 HƯỚNG PHÁT TRIỂN

Mặc dù RaDecNet đã đạt được những kết quả khả quan, mô hình vẫn còn nhiều hướng phát triển nhằm nâng cao hơn nữa hiệu quả phát hiện và khả năng ứng dụng trong thực tế. Trước hết, cần mở rộng phạm vi dữ liệu huấn luyện và đánh giá trên nhiều tập dữ liệu radar khác nhau, bao gồm các kịch bản đô thị phức tạp, điều kiện thời tiết bất lợi, mật độ giao thông cao và các tình huống có nhiều vật cản. Việc này sẽ giúp kiểm chứng tốt hơn khả năng tổng quát hóa của mô hình trong các môi trường vận hành đa dạng.

Bên cạnh đó, mô hình có thể tiếp tục được cải thiện ở các lớp đối tượng có đặc trưng phản xạ phức tạp, đặc biệt là xe ô tô trong các tình huống khoảng cách xa, góc quan sát thay đổi hoặc xuất hiện chồng lấn tín hiệu. Các cơ chế hợp nhất đa tỷ lệ, cải tiến bộ giải mã hoặc tăng cường biểu diễn không gian có thể được nghiên cứu thêm nhằm giúp mô hình phục hồi chi tiết tốt hơn trong các trường hợp khó. Một hướng phát triển quan trọng khác là tối ưu hóa RaDecNet cho triển khai thời gian thực trên thiết bị biên. Với quy mô tham số nhỏ và độ trễ suy luận tương đối thấp, mô hình đã có nền tảng thuận lợi để áp dụng các kỹ thuật như lượng tử hóa, cắt tỉa mô hình, tối ưu bằng TensorRT hoặc triển khai trên GPU nhúng/FPGA. Những cải tiến này sẽ giúp giảm độ trễ, tiết kiệm năng lượng và tăng khả năng vận hành ổn định trên phần cứng giới hạn tài nguyên. Ngoài ra, RaDecNet có thể được mở rộng theo hướng kết hợp đa cảm biến với camera hoặc LiDAR. Radar có ưu thế trong điều kiện ánh sáng yếu, mưa, sương mù và môi trường nhiễu, trong khi camera và LiDAR cung cấp thêm thông tin hình dạng và ngữ nghĩa. Sự kết hợp này có thể tạo ra một hệ thống nhận thức toàn diện hơn, vừa tận dụng được độ

ổn định của radar, vừa bổ sung khả năng hiểu ngữ cảnh từ các cảm biến khác.

Nhìn chung, các hướng phát triển tiếp theo của RaDecNet có thể tập trung vào bốn vấn đề chính: mở rộng dữ liệu để kiểm chứng khả năng tổng quát hóa, cải thiện hiệu quả phát hiện trong các kịch bản khó, tối ưu triển khai trên thiết bị biên và mở rộng sang hệ thống nhận thức đa cảm biến. Những định hướng này sẽ giúp RaDecNet tiến gần hơn đến vai trò của một giải pháp radar object detection thực tiễn, ổn định và đáng tin cậy trong các hệ thống giao thông thông minh.

Phụ lục

Nhằm tạo điều kiện thuận lợi cho việc truy cập, và theo dõi, toàn bộ mã nguồn liên quan đến đề tài đã được biên soạn và công khai trên kho lưu trữ trực tuyến. Với đường dẫn: https://github.com/NHN4464/RaDecNet-FMCW_Radar_Object_Detection

Tài liệu tham khảo

- [1] H. Caesar, V. Bankiti, A. H. Lang, S. Vora, V. E. Liong, Q. Xu, A. Krishnan, Y. Pan, G. Baldan, and O. Beijbom, “nusenes: A multimodal dataset for autonomous driving,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020, pp. 11 621–11 631.
- [2] Y. Wang, Z. Jiang, X. Gao, J.-N. Hwang, G. Xing, and H. Liu, “Rodnet: Radar object detection using cross-modal supervision,” in *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 2021, pp. 504–513.
- [3] M. I. Skolnik, *Introduction to Radar Systems*. New York: McGraw-Hill, 1962.
- [4] O. Boric-Lubecke, V. M. Lubecke, A. D. Droitcour, B.-K. Park, and A. Singh, *Doppler Radar Physiological Sensing*. Hoboken, NJ: John Wiley & Sons, 2015.
- [5] Q. Chaudhari, “FMCW radar part 2-Velocity, angle and radar data cube,” <https://wirelesspi.com/fmcw-radar-part-2-velocity-angle-and-radar-data-cube/>, Nov. 2023, accessed: 2026-03.
- [6] T. Jiang, L. Zhuang, Q. An, J. Wang, K. Xiao, and A. Wang, “T-rodnet: Transformer for vehicular millimeter-wave radar object detection,” *IEEE Transactions on Instrumentation and Measurement*, vol. 72, pp. 1–12, 2023.
- [7] Y. Wu, J. Liu, G. Jiang, W. Liu, and D. Orlando, “Mask-radarnet: Enhancing transformer with spatial-temporal semantic context for radar object detection in autonomous driving,” *arXiv preprint arXiv:2412.15595*, 2024. [Online]. Available: <https://arxiv.org/abs/2412.15595>
- [8] H. Chen, F. Hassanat, R. Laganier, and M. Bouchard, “mradnet: A compact radar object detector with metaformer,” *arXiv preprint arXiv:2509.16223*, 2025. [Online]. Available: <https://arxiv.org/abs/2509.16223>
- [9] X. Gao, G. Xing, S. Roy, and H. Liu, “Ramp-cnn: A novel neural network for enhanced automotive radar object recognition,” *IEEE Sensors Journal*, vol. 21, no. 4, pp. 5119–5132, Feb. 2021.
- [10] S. Targ, D. Almeida, and K. Lyman, “Resnet in resnet: Generalizing residual architectures,” *arXiv preprint arXiv:1603.08029*, 2016. [Online]. Available: <https://arxiv.org/abs/1603.08029>

- [11] M. Z. Alom, T. M. Taha, C. Yakopcic, S. Westberg, P. Sidike, M. S. Nasrin, B. C. Van Esesn, A. A. S. Awwal, and V. K. Asari, “The history began from AlexNet: A comprehensive survey on deep learning approaches,” *arXiv preprint arXiv:1803.01164*, 2018. [Online]. Available: <https://arxiv.org/abs/1803.01164>
- [12] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Proceedings of the 31st International Conference on Neural Information Processing Systems (NeurIPS)*. Curran Associates, Inc., 2017, pp. 5998–6008. [Online]. Available: <https://papers.nips.cc/paper/7181-attention-is-all-you-need.pdf>
- [13] W. Xu, P. Lu, and Y. Zhao, “E-RODNet: Lightweight approach to object detection by vehicular millimeter-wave radar,” *IEEE Transactions on Intelligent Transportation Systems*, 2026.
- [14] D. Feng, C. Haase-Schütz, L. Rosenbaum, H. Hertlein, C. Glaeser, F. Timm, W. Wiesbeck, and K. Dietmayer, “Deep multi-modal object detection and semantic segmentation for autonomous driving: Datasets, methods, and challenges,” *IEEE Transactions on Intelligent Transportation Systems*, 2020.
- [15] M. Zhao, T. Li, M. A. Alsheikh, Y. Tian, H. Zhao, A. Torralba, and D. Katabi, “Through-wall human pose estimation using radio signals,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2018, pp. 7356–7365.
- [16] X. Gao, G. Xing, S. Roy, and H. Liu, “Experiments with mmwave automotive radar test-bed,” in *Asilomar Conference on Signals, Systems, and Computers*, 2019.
- [17] B. Major, D. Fontijne, A. Ansari, R. T. Sukhavasi, R. Gowaikar, M. Hamilton, S. Lee, S. Grzechnik, and S. Subramanian, “Vehicle detection with automotive radar using deep learning on range-azimuth-doppler tensors,” in *Proceedings of the IEEE International Conference on Computer Vision Workshops*, 2019.
- [18] S. Ren, K. He, R. Girshick, and J. Sun, “Faster r-cnn: Towards real-time object detection with region proposal networks,” in *Advances in Neural Information Processing Systems*, 2015, pp. 91–99.
- [19] Y. Wang, Y.-T. Huang, and J.-N. Hwang, “Monocular visual object 3d localization in road scenes,” in *Proceedings of the 27th ACM International Conference on Multimedia*. ACM, 2019, pp. 917–925.

- [20] G. Wang, Y. Wang, H. Zhang, R. Gu, and J.-N. Hwang, “Exploit the connectivity: Multi-object tracking with trackletnet,” in *Proceedings of the 27th ACM International Conference on Multimedia*. ACM, 2019, pp. 482–490.
- [21] W. Yu, M. Luo, P. Zhou, C. Si, Y. Zhou, X. Wang, J. Feng, and S. Yan, “Metaformer is actually what you need for vision,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022, pp. 10 819–10 829.
- [22] C. M. Bishop and H. Bishop, *Deep Learning: Foundations and Concepts*. MIT Press, 2023, pp. 147–148, 245–246.
- [23] F. Hassanat and R. Laganière, “Compactradnet: Embeddable temporal road-user detection from radar,” *IEEE Transactions on Radar Systems*, vol. 4, pp. 650–660, 2026.

BÁO CÁO ĐỘC SÁNG

21%

CHỈ SỐ TƯƠNG ĐỒNG

19%

NGUỒN INTERNET

13%

ẤN PHẨM XUẤT BẢN

%

BÀI CỦA HỌC SINH

ĐỐI CHIẾU TẤT CẢ CÁC NGUỒN (CHỈ IN CÁC NGUỒN ĐÃ CHỌN)

7%

★ www.ctu.edu.vn

Nguồn Internet

Loại trừ Trích dẫn Mở

Loại trừ trùng khớp < 10 words

Loại trừ mục lục tham khảo Mở