

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH

KHOA ĐIỆN – ĐIỆN TỬ

BỘ MÔN KỸ THUẬT MÁY TÍNH – VIỄN THÔNG



HCM-UTE

ĐỒ ÁN TỐT NGHIỆP

NGÀNH CÔNG NGHỆ KỸ THUẬT MÁY TÍNH

**XÂY DỰNG ỨNG DỤNG DỰA TRÊN ZERO-SHOT
CONCEPT BOTTLENECK MODEL VÀ KHẢO SÁT
QUY TRÌNH PHÁT TRIỂN PHẦN MỀM AI BẰNG MÔ
HÌNH NGÔN NGỮ LỚN**

SVTH: HUỲNH KIM THIÊN

MSSV: 22119232

VÕ DUY TRƯỜNG

MSSV: 22119249

GVHD: PGS.TS NGUYỄN MẠNH HÙNG

TP. Hồ Chí Minh – 06/2026

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH

KHOA ĐIỆN – ĐIỆN TỬ

BỘ MÔN KỸ THUẬT MÁY TÍNH – VIỄN THÔNG



HCM-UTE

ĐỒ ÁN TỐT NGHIỆP

NGÀNH CÔNG NGHỆ KỸ THUẬT MÁY TÍNH

**XÂY DỰNG ỨNG DỤNG DỰA TRÊN ZERO-SHOT
CONCEPT BOTTLENECK MODEL VÀ KHẢO SÁT
QUY TRÌNH PHÁT TRIỂN PHẦN MỀM AI BẰNG MÔ
HÌNH NGÔN NGỮ LỚN**

SVTH: HUỲNH KIM THIÊN

MSSV: 22119232

VÕ DUY TRƯỜNG

MSSV: 22119249

GVHD: PGS.TS NGUYỄN MẠNH HÙNG

TP. Hồ Chí Minh – 06/2026

TRANG THÔNG TIN LUẬN VĂN

1. Thông tin sinh viên

Họ và tên: Huỳnh Kim Thiên

MSSV: 22119232

Họ và tên: Võ Duy Trường

MSSV: 22119249

2. Thông tin đề tài

- Tên đề tài: Xây dựng ứng dụng dựa trên Zero-Shot Concept Bottleneck Model và khảo sát quy trình phát triển phần mềm AI bằng mô hình ngôn ngữ lớn.
- Mục đích đề tài: Khai thác sức mạnh của kiến trúc Zero-Shot Concept Bottleneck (Z-CBM) nhằm phát triển một ứng dụng AI có tính minh bạch cao, có khả năng tự giải thích quyết định thông qua các khái niệm ngữ nghĩa và cho phép người dùng trực tiếp can thiệp vào quá trình suy luận.
- Đơn vị quản lý: Bộ môn Kỹ thuật Máy tính – Viễn thông, Khoa Điện – Điện tử, Trường Đại học Công nghệ Kỹ thuật Tp. Hồ Chí Minh.
- Thời gian thực hiện: Từ ngày 03 / 03 / 2026 đến ngày 26 / 06 / 2026.
- Thời gian bảo vệ: Ngày 03 / 07 / 2026.

3. Lời cam đoan của sinh viên

Chúng tôi cam đoan đồ án tốt nghiệp này là kết quả nghiên cứu và thực hiện của nhóm dưới sự hướng dẫn của giảng viên hướng dẫn. Các kết quả, số liệu và nội dung trình bày trong đồ án là trung thực, được trích dẫn đầy đủ theo quy định và chưa từng được sử dụng để bảo vệ bất kỳ học vị nào trước đây. Chúng tôi hoàn toàn chịu trách nhiệm về nội dung cam đoan này.

Tp. HCM, ngày 25 tháng 6 năm 2026

Người thực hiện

Huỳnh Kim Thiên

Võ Duy Trường

BẢN NHẬN XÉT KHÓA LUẬN TỐT NGHIỆP

(Dành cho giảng viên hướng dẫn)

Đề tài: Xây dựng ứng dụng dựa trên Zero-Shot Concept Bottleneck Model

Và khảo sát quy trình phân tích phân miền AI bằng mô hình ngôn ngữ lớn

Sinh viên: + Huỳnh Kim Thiên

MSSV: 22119232

+ Võ Duy Tường

MSSV: 22111219

Hướng dẫn: PGS TS Nguyễn Mạnh Hùng

Nhận xét bao gồm các nội dung sau đây:

1. Tính hợp lý trong cách đặt vấn đề và giải quyết vấn đề; ý nghĩa khoa học và thực tiễn:

Đặt vấn đề rõ ràng, mục tiêu cụ thể; đề tài có tính mới, cấp thiết; đề tài có khả năng ứng dụng, tính sáng tạo.

2. Phương pháp thực hiện/ phân tích/ thiết kế:

Phương pháp hợp lý và tin cậy dựa trên cơ sở lý thuyết; có phân tích và đánh giá phù hợp; có tính mới và tính sáng tạo.

3. Kết quả thực hiện/ phân tích và đánh giá kết quả/ kiểm định thiết kế:

Phù hợp với mục tiêu đề tài; phân tích và đánh giá/ kiểm thử thiết kế hợp lý; có tính sáng tạo/ kiểm định chặt chẽ và đảm bảo độ tin cậy.

4. Kết luận và đề xuất:

Kết luận phù hợp với cách đặt vấn đề, đề xuất mang tính cải tiến và thực tiễn; kết luận có đóng góp mới mẻ, đề xuất sáng tạo và thuyết phục.

5. Hình thức trình bày và bố cục báo cáo:

Văn phong nhất quán, bố cục hợp lý, cấu trúc rõ ràng, đúng định dạng mẫu; có tính hấp dẫn, thể hiện năng lực tốt, văn bản trau chuốt.

6. Kỹ năng chuyên nghiệp và tính sáng tạo:

Thể hiện các kỹ năng giao tiếp, kỹ năng làm việc nhóm, và các kỹ năng chuyên nghiệp khác trong việc thực hiện đề tài.

7. Tài liệu trích dẫn

Tính trung thực trong việc trích dẫn tài liệu tham khảo; tính phù hợp của các tài liệu trích dẫn; trích dẫn theo đúng chỉ dẫn APA.

8. Đánh giá về sự trùng lặp của đề tài

Cần khẳng định đề tài có trùng lặp hay không? Nếu có, đề nghị ghi rõ mức độ, tên đề tài, nơi công bố, năm công bố của đề tài đã công bố.

9. Những nhược điểm và thiếu sót, những điểm cần được bổ sung và chỉnh sửa*

Mảng CHIP chưa hiện qua các với các ảnh phức tạp, khác
sai ý cần báo chế với một LLM

10. Nhận xét tinh thần, thái độ học tập, nghiên cứu của sinh viên

tích cực học tập theo qua định thực hiện ĐATN

Đề nghị của giảng viên hướng dẫn

Ghi rõ: "Báo cáo đạt/ không đạt yêu cầu của một khóa luận tốt nghiệp kỹ sư, và được phép/ không được phép bảo vệ khóa luận tốt nghiệp"

báo cáo đạt là được bảo vệ

Tp. HCM, ngày 20 tháng 06 năm 2026

Người nhận xét
(Ký và ghi rõ họ tên)

Ng' Mạnh Hùng

* Giảng viên hướng dẫn có thể ghi tiếp vào mặt sau

LỜI CẢM ƠN

Trước tiên, chúng em xin gửi lời cảm ơn chân thành đến quý thầy cô khoa Điện – Điện tử, Trường Đại học Công Nghệ Kỹ thuật Thành phố Hồ Chí Minh, đã tạo điều kiện học tập và trang bị cho em những nền tảng kiến thức vững chắc trong suốt thời gian học tập tại trường.

Tiếp theo, chúng em xin bày tỏ lòng biết ơn sâu sắc đến PGS.TS Nguyễn Mạnh Hùng đã tận tình chỉ bảo, truyền đạt kiến thức và định hướng nghiên cứu trong suốt quá trình thực hiện đồ án tốt nghiệp. Sự tận tâm, nghiêm túc và những góp ý quý báu của thầy là nguồn động lực lớn giúp chúng em hoàn thành đồ án này.

Cuối cùng, chúng em xin cảm ơn gia đình và bạn bè đã luôn đồng hành, động viên và hỗ trợ trong suốt quá trình học tập và thực hiện đồ án.

Do thời gian nghiên cứu còn hạn chế và năng lực bản thân vẫn còn nhiều thiếu sót, trong quá trình thực hiện đồ án không tránh khỏi những điểm chưa hoàn thiện, chúng em rất mong nhận được sự góp ý và chỉ dẫn từ quý thầy cô để có thể tiếp tục hoàn thiện và rút kinh nghiệm cho các nghiên cứu, dự án sau này.

Một lần nữa, chúng em xin chân thành cảm ơn!

TÓM TẮT

Trong những năm gần đây, sự phát triển mạnh mẽ của trí tuệ nhân tạo, đặc biệt là các mô hình học sâu trong lĩnh vực thị giác máy tính, đã mang lại những thành tựu vượt bậc trong nhiều bài toán như phân loại ảnh và phát hiện đối tượng. Tuy nhiên, phần lớn các mô hình hiện đại vẫn hoạt động như những “hộp đen”, đưa ra dự đoán với độ chính xác cao nhưng thiếu khả năng giải thích rõ ràng nguyên nhân dẫn đến quyết định của mình. Điều này làm dấy lên nhu cầu nghiên cứu các phương pháp học máy có tính minh bạch và khả năng diễn giải, đặc biệt trong những lĩnh vực đòi hỏi mức độ tin cậy cao.

Một trong những hướng tiếp cận nổi bật nhằm nâng cao khả năng giải thích của mô hình là Concept Bottleneck Model (CBM), trong đó quá trình dự đoán được thực hiện thông qua các khái niệm trung gian có ý nghĩa đối với con người. Tuy nhiên, CBM truyền thống đòi hỏi dữ liệu được gán nhãn khái niệm chi tiết, gây tốn kém chi phí xây dựng và khó mở rộng. Để khắc phục hạn chế này, Zero-shot Concept Bottleneck Model (ZCBM) kết hợp CBM với các mô hình thị giác - ngôn ngữ tiền huấn luyện như CLIP và ngân hàng khái niệm, cho phép suy luận mà không cần dữ liệu gán nhãn khái niệm thủ công.

Đề án thực hiện hai hướng nghiên cứu. Thứ nhất, nghiên cứu, triển khai và cải tiến ZCBM dựa trên công trình của Yamaguchi và cộng sự (2025) thành một ứng dụng MVP hỗ trợ tải ảnh, bổ sung khái niệm tùy chỉnh, truy hồi khái niệm liên quan, dự đoán và can thiệp vào kết quả đầu ra. Thứ hai, khảo sát quá trình phát triển ứng dụng bằng Claude Opus 4.8 thông qua Claude Code, ghi nhận các prompt, kết quả sinh mã và quá trình tinh chỉnh. Kết quả của đề án là một ứng dụng xác minh ảnh tương tác dựa trên ZCBM cùng bộ tài liệu phân tích định tính về quy trình phát triển phần mềm với sự hỗ trợ của LLM, qua đó cung cấp góc nhìn thực tiễn cho cả lĩnh vực AI giải thích được và kỹ thuật phần mềm hỗ trợ bởi AI.

MỤC LỤC

LỜI CẢM ƠN.....	I
TÓM TẮT	V
MỤC LỤC.....	VI
DANH MỤC HÌNH.....	IX
DANH MỤC BẢNG.....	X
CÁC TỪ VIẾT TẮT	XI
CHƯƠNG 1 GIỚI THIỆU	1
1.1 ĐẶT VẤN ĐỀ	1
1.2 MỤC TIÊU NGHIÊN CỨU	2
1.3 PHẠM VI VÀ GIỚI HẠN CỦA ĐỀ TÀI.....	3
1.4 PHƯƠNG PHÁP TIẾP CẬN VÀ NGHIÊN CỨU	4
1.5 CẤU TRÚC ĐỒ ÁN.....	5
CHƯƠNG 2 CƠ SỞ LÝ THUYẾT	6
2.1 TỔNG QUAN VỀ QUY TRÌNH PHÁT TRIỂN VÀ TRIỂN KHAI.....	6
2.2 MÔ HÌNH CLIP	7
2.2.1 Kiến trúc và nguyên lý hoạt động của CLIP.....	7
2.2.2 Học biểu diễn ảnh – văn bản trong CLIP.....	8
2.3 ZERO-SHOT LEARNING	10
2.3.1 Khái niệm và nguyên lý của Zero-shot Learning	10
2.3.2 Zero-shot Learning dựa trên mô hình thị giác – ngôn ngữ.....	12
2.4 CONCEPT BOTTLENECK MODEL	12
2.4.1 Tổng quan về Concept Bottleneck Model	12
2.4.2 Kiến trúc và cơ chế hoạt động của CBM.....	13
2.5 ZERO-SHOT CONCEPT BOTTLENECK MODEL	15
2.5.1 Từ Concept Bottleneck Model đến Zero-shot Concept Bottleneck Model .	15

2.5.2 Kiến trúc và cơ chế suy luận của ZCBM.....	15
2.5.3 Khả năng can thiệp động và ý nghĩa thực tiễn.....	17
2.6 MÔ HÌNH NGÔN NGỮ LỚN VÀ CLAUDE AI.....	17
2.6.1 Tổng quan về mô hình ngôn ngữ lớn.....	17
2.6.2 Claude AI và Claude Code trong hỗ trợ phát triển phần mềm	18
CHƯƠNG 3 PHƯƠNG PHÁP ĐỀ NGHỊ	20
3.1 TỔNG QUAN PHƯƠNG PHÁP	20
3.1.1 Phát biểu bài toán.....	22
3.1.2 Giai đoạn xây dựng hồ sơ lớp (Builder)	23
3.1.2.1 Trích xuất khái niệm bằng LLM.....	23
3.1.2.2 Lọc nhiễu và chống vọng lại.....	24
3.1.2.3 Nhúng khái niệm, dựng nguyên mẫu và hiệu chuẩn hồ sơ lớp.....	24
3.1.3 Giai đoạn xác minh (Verifier).....	26
3.1.3.1 Nhúng ảnh truy vấn đầu vào	26
3.1.3.2 Tính toán bằng chứng khái niệm (Concept Evidence)	26
3.1.4 Cơ chế ra quyết định	28
3.1.5 Khả năng giải thích	30
3.1.6 Khả năng mở rộng và cập nhật linh hoạt	31
3.2 ĐẶC TẢ KIẾN TRÚC THAM CHIẾU VÀ TIÊU CHÍ KỸ THUẬT KỶ VỌNG CỦA MỘT SẢN PHẨM KHẢ DỤNG TỐI THIỂU (MINIMUM VIABLE PRODUCT).....	32
3.2.1 Kiến trúc tổng thể.....	32
3.2.2 Các thành phần và luồng xử lý	35
3.2.3 Tiêu chí kỹ thuật kỷ vọng	36
3.2.4 Ranh giới của sản phẩm khả dụng tối thiểu	36
3.3 QUY TRÌNH VÒNG LẶP TINH CHỈNH	37
3.3.1 Tổng quan vòng đời tinh chỉnh.....	37
3.3.2 Các bước của vòng đời	37
3.3.3 Áp dụng cho hai phân hệ Frontend và Backend	40

CHƯƠNG 4 THỰC NGHIỆM VÀ KẾT QUẢ	42
4.1 KẾT QUẢ MÔ HÌNH ZERO-SHOT CBM.....	42
4.1.1 Bộ dữ liệu và giao thức	42
4.1.2 Kết quả định tính.....	43
4.1.3 Kết quả và phân tích	46
4.1.3.1 Kết quả xác minh một-lớp (One-Class Verification).....	46
4.1.3.2 Kết quả phân loại đóng	49
4.2 KẾT QUẢ NGHIÊN CỨU PHÁT TRIỂN PHẦN MỀM BẰNG LLM	51
4.2.1 Thiết lập và phương pháp	51
4.2.2 Kết quả và phân tích	52
4.2.2.1 Quá trình phát triển	52
4.2.2.2 Mức độ đáp ứng kỳ vọng	54
4.2.2.3 Đánh giá tổng quan	58
4.2.3 Phát triển bằng đội tác nhân.....	59
CHƯƠNG 5 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	60
5.1 KẾT LUẬN	60
5.1.1 Ứng dụng xác minh dùng kỹ thuật zero-shot.....	60
5.1.2 Quy trình phát triển phần mềm bằng mô hình ngôn ngữ lớn (LLM)	60
5.2 HẠN CHẾ	61
5.3 HƯỚNG PHÁT TRIỂN	62
TÀI LIỆU THAM KHẢO	63

DANH MỤC HÌNH

Hình 2.1: Kiến trúc tổng quan mô hình CLIP [3].	8
Hình 2.2: Minh họa việc ánh xạ ảnh và văn bản vào cùng một không gian biểu diễn của CLIP	9
Hình 2.3: Hình mô tả kiến trúc của Zero-shot	11
Hình 2.4: Minh họa Concept Bottleneck Model với các khái niệm trung gian được trích xuất từ ảnh để thực hiện dự đoán [6].	14
Hình 2.5: Kiến trúc tổng quát của Zero-shot Concept Bottleneck Model và cơ chế suy luận thông qua tầng khái niệm trung gian [7].	16
Hình 2.6: Giao diện dòng lệnh của công cụ Claude Code	18
Hình 3.1: Sơ đồ tổng quan phương pháp đề xuất	21
Hình 3.2: Sơ đồ kiến trúc tổng thể	34
Hình 3.3: Vòng lặp tinh chỉnh sử dụng prompt	38
Hình 4.1: Trọng số các concept của class banana	44
Hình 4.2: Bản đồ nhiệt mức độ hiện diện của concept	45
Hình 4.3: Phân bố ROC-AUC xác minh theo từng lớp trên các bộ dữ liệu	48
Hình 4.4: Tỷ lệ dự đoán đúng (Top-1) và nhầm lẫn trên các bộ dữ liệu.	50
Hình 4.5: (a), (b) Kết quả giao diện được Claude code xây dựng	55
Hình 4.6: Kết quả logic xử lý AI xác minh	57

DANH MỤC BẢNG

Bảng 4.1: Thống kê các bộ dữ liệu.....	43
Bảng 4.2: Kết quả xác minh với 3 ảnh tham chiếu mỗi lớp.....	46
Bảng 4.3: Kết quả phân loại đóng	49
Bảng 4.4: Quá trình lịch sử xây dựng ứng dụng	53

CÁC TỪ VIẾT TẮT

Viết tắt	Tên đầy đủ
AI	Artificial Intelligence
LLM	Large Language Model
CLIP	Contrastive Language-Image Pre-training
CBM	Concept Bottleneck Model
ZCBM	Zero-Shot Concept Bottleneck Model
CNN	Convolutional Neural Network
ViT	Vision Transformer
LOO	Leave-One-Out
OOD	Out-of-Distribution
ROC	Receiver Operating Characteristic
AUC	Area Under the Curve
FAR	False Acceptance Rate
FRR	False Rejection Rate
EER	Equal Error Rate
TP	True Positive

TN	True Negative
FP	False Positive
FN	False Negative
API	Application Programming Interface
JSON	JavaScript Object Notation
L2	Euclidean Norm (L2 Norm)

CHƯƠNG 1 GIỚI THIỆU

1.1 ĐẶT VẤN ĐỀ

Trong những năm gần đây, trí tuệ nhân tạo, đặc biệt là học sâu, đã đạt được những bước tiến vượt bậc trong các bài toán thị giác máy tính như phân loại ảnh, phát hiện đối tượng và phân đoạn ngữ nghĩa. Tuy nhiên, các mô hình hiện đại như Vision Transformer hay các mạng nơ-ron tích chập sâu thường được xem như những chiếc hộp đen bí ẩn, quyết định của chúng khó được giải thích bằng các khái niệm mà con người có thể hiểu được. Trong nhiều lĩnh vực ứng dụng nhạy cảm như y tế, pháp lý hay giáo dục, sự thiếu minh bạch này là một rào cản lớn cản trở việc đưa AI vào sử dụng thực tế.

Mô hình Concept Bottleneck Model (CBM) được đề xuất bởi Koh và cộng sự vào năm 2020 là một hướng tiếp cận giàu hứa hẹn nhằm giải quyết vấn đề này. Thay vì ánh xạ trực tiếp từ ảnh đầu vào sang nhãn dự đoán, CBM đưa thêm một lớp trung gian gọi là “tầng cổ chai khái niệm” (concept bottleneck), trong đó mỗi đơn vị tương ứng với một khái niệm có ý nghĩa đối với con người. Cách tiếp cận này không chỉ làm cho mô hình trở nên dễ giải thích hơn mà còn cho phép người dùng can thiệp (intervene) vào các kích hoạt khái niệm để điều chỉnh kết quả dự đoán. Tuy vậy, CBM truyền thống đòi hỏi tập dữ liệu được gán nhãn khái niệm chi tiết, một yêu cầu tốn kém và khó mở rộng.

Để khắc phục giới hạn này, hướng nghiên cứu Zero-shot Concept Bottleneck Model (ZCBM) đã được phát triển. Bằng cách tận dụng các mô hình thị giác - ngôn ngữ tiền huấn luyện như CLIP cùng với một ngân hàng khái niệm (concept bank) được xây dựng sẵn, ZCBM cho phép phân loại ảnh dựa trên các khái niệm mà không cần huấn luyện lại trên tập dữ liệu mục tiêu. Đây là một bước tiến quan trọng giúp đưa CBM trở nên thực tiễn hơn, đặc biệt với các bài toán có ít dữ liệu hoặc cần triển khai nhanh.

Song song với sự phát triển của các mô hình AI, sự ra đời của các mô hình ngôn ngữ lớn (Large Language Model) như Claude của Anthropic đã mở ra một phương thức phát triển phần mềm mới. Với khả năng sinh mã nguồn, suy luận về kiến trúc, đọc hiểu tài liệu và phối hợp nhiều tác nhân (multi-agent), LLM ngày càng được sử dụng như

một thành viên trong đội ngũ phát triển. Tuy nhiên, làm thế nào để khai thác hiệu quả LLM vào việc xây dựng một ứng dụng AI từ đầu đến cuối bao gồm giao diện, dịch vụ phía sau, cơ sở dữ liệu và triển khai vẫn là một câu hỏi mở, đặc biệt khi xét tới chất lượng mã sinh ra, kiến trúc hệ thống và khả năng đáp ứng các tiêu chí của một sản phẩm khả dụng tối thiểu (Minimum Viable Product).

Từ những bối cảnh trên, đề án lựa chọn nghiên cứu mô hình ZCBM và triển khai thành một ứng dụng thử nghiệm có khả năng giải thích kết quả dự đoán thông qua các khái niệm trung gian. Đồng thời, đề án cũng khảo sát việc ứng dụng Claude Code trong toàn bộ quy trình phát triển hệ thống nhằm đánh giá khả năng, ưu điểm và những hạn chế của phương pháp phát triển phần mềm có sự hỗ trợ của LLM.

1.2 MỤC TIÊU NGHIÊN CỨU

Đề án đặt ra hai nhóm mục tiêu chính, tương ứng với hai trục nghiên cứu đã nêu ở phần đặt vấn đề.

Nhóm mục tiêu thứ nhất liên quan đến mô hình ZCBM:

- Nghiên cứu nguyên lý hoạt động của Zero-shot Concept Bottleneck Model dựa trên công trình của Yamaguchi và cộng sự.
- Cải tiến mô hình thành một ứng dụng MVP cho phép người dùng tải lên ảnh đầu vào, bổ sung các khái niệm tùy chỉnh ngoài ngân hàng có sẵn, thực hiện truy hồi khái niệm gần nhất với các nhãn mục tiêu và đưa ra dự đoán.
- Cài đặt cơ chế can thiệp (intervention) cho phép người dùng tác động trực tiếp lên các giá trị kích hoạt khái niệm để quan sát ảnh hưởng tới đầu ra.
- Đóng gói mô hình thành dịch vụ phía sau (backend service) có thể tích hợp với giao diện người dùng và tầng lưu trữ dữ liệu

Nhóm mục tiêu thứ hai liên quan đến quy trình phát triển bằng LLM:

- Sử dụng mô hình Claude Opus 4.8 thông qua công cụ Claude Code làm thành viên hỗ trợ phát triển toàn bộ ứng dụng từ giao diện, dịch vụ phía sau, tầng lưu trữ dữ liệu cho tới khâu triển khai.

- Xây dựng đội ngũ tác nhân (agent team) chuyên biệt cho từng giai đoạn phát triển, bao gồm thiết kế, lập trình, kiểm thử và rà soát mã nguồn.
- Ghi lại có hệ thống các prompt được sử dụng, kết quả mã nguồn sinh ra, các lỗi gặp phải và các lần tinh chỉnh prompt nhằm đạt kết quả mong muốn.
- Đánh giá so sánh giữa ứng dụng do LLM sinh ra với kỳ vọng ban đầu của người phát triển trên các tiêu chí về chất lượng mã, kiến trúc hệ thống, độ chính xác chức năng và mức độ phù hợp với chuẩn của một MVP.

1.3 PHẠM VI VÀ GIỚI HẠN CỦA ĐỀ TÀI

Về mặt mô hình AI, đề án giới hạn ở bài toán xác minh ảnh một lớp (one-class verification) dựa trên ngân hàng khái niệm, thay vì phân loại nhiều lớp như trong bài báo gốc. Mô hình thị giác-ngôn ngữ nền được sử dụng là CLIP (ViT-B/32) của OpenAI, được giữ đông cứng (frozen), không huấn luyện lại. Ngân hàng khái niệm được xây dựng trực tiếp từ dữ liệu tùy chỉnh do người dùng cung cấp, đồng thời cho phép bổ sung khái niệm mới ở thời điểm chạy mà không cần huấn luyện lại mô hình. Việc đánh giá được thực hiện trên bộ dữ liệu tham chiếu Caltech-101 cùng một số tập ảnh tùy chỉnh; đề án không hướng tới việc tổng quát hóa trên toàn bộ các bộ dữ liệu chuẩn (ImageNet, FGVC, v.v.) như khảo sát của bài báo gốc.

Về mặt ứng dụng, sản phẩm xây dựng là một MVP với các chức năng cốt lõi: tải ảnh, thêm khái niệm, dự đoán, can thiệp đầu ra (intervention) và lưu lại lịch sử. MVP không hướng tới khả năng mở rộng quy mô (scalability) ở mức sản phẩm thương mại, không bao gồm các tính năng quản lý người dùng phức tạp như phân quyền nhiều cấp, thanh toán hay hệ thống thông báo đẩy.

Về mặt quy trình phát triển bằng LLM, đề án giới hạn ở việc sử dụng mô hình Claude Opus 4.8 thông qua công cụ Claude Code. Việc đánh giá chất lượng được thực hiện thủ công dựa trên các tiêu chí chất lượng mã nguồn (quy ước đặt tên, tổ chức tệp, độ rõ ràng), kiến trúc (tính module, phân tách trách nhiệm), độ chính xác chức năng và sự tương thích với một số mẫu thiết kế tham chiếu phổ biến trên GitHub. Phân tích mang

tính định tính, không bao gồm khảo sát người dùng quy mô lớn hay so sánh thống kê với các LLM khác.

1.4 PHƯƠNG PHÁP TIẾP CẬN VÀ NGHIÊN CỨU

Đồ án được thực hiện theo bốn bước chính.

Bước thứ nhất là khảo sát tài liệu, bao gồm các công trình về Concept Bottleneck Model, Zero-shot Learning, mô hình thị giác – ngôn ngữ CLIP và đặc biệt là bài báo Zero-shot Concept Bottleneck Models cùng mã nguồn công khai trên GitHub. Đồng thời, các tài liệu về quy trình phát triển phần mềm hiện đại, mô hình ngôn ngữ lớn và kỹ thuật prompt engineering cũng được tham khảo nhằm xây dựng cơ sở lý thuyết cho trực thứ hai của đồ án.

Bước thứ hai là phân tích, thiết kế và cải tiến mô hình ZCBM. Tác giả nghiên cứu kỹ mã nguồn tham khảo, xác định các điểm cần mở rộng để biến mô hình từ một thí nghiệm khoa học trở thành một dịch vụ có thể tương tác. Cụ thể, các thành phần cần bổ sung bao gồm cơ chế nhận khái niệm động từ người dùng, cơ chế truy hồi từ ngân hàng khái niệm và giao diện can thiệp lên kích hoạt khái niệm.

Bước thứ ba là triển khai ứng dụng dưới sự hỗ trợ của Claude Opus 4.8. Tác giả định nghĩa các yêu cầu chức năng và phi chức năng, sau đó giao cho LLM thực hiện thông qua các phiên làm việc với Claude Code. Mỗi phiên làm việc được ghi lại đầy đủ về prompt đầu vào, kết quả đầu ra, các lỗi gặp phải, các lần tinh chỉnh prompt và phiên bản mã cuối cùng. Nhiều tác nhân chuyên biệt được tạo lập cho các nhiệm vụ khác nhau như thiết kế kiến trúc, sinh mã, viết kiểm thử và rà soát mã nguồn.

Bước thứ tư là thực nghiệm và đánh giá. Mô hình AI được thử nghiệm trên các ảnh đầu vào thuộc tập nhãn mục tiêu, đánh giá độ chính xác và tính nhất quán khi can thiệp khái niệm. Quy trình phát triển bằng LLM được phân tích định tính dựa trên các nhật ký prompt và mã nguồn sinh ra, từ đó rút ra nhận xét về điểm mạnh, hạn chế và các bài học kinh nghiệm.

1.5 CẤU TRÚC ĐỒ ÁN

Đồ án được tổ chức thành năm chương như sau:

Chương 1: Đặt vấn đề, nêu mục tiêu, phạm vi, phương pháp tiếp cận và cấu trúc của đồ án.

Chương 2: Trình bày cơ sở lý thuyết, bao gồm quy trình phát triển và triển khai ứng dụng AI, các lý thuyết về CLIP, Zero-shot Learning, Concept Bottleneck Model, Zero-shot Concept Bottleneck Model và mô hình ngôn ngữ lớn Claude.

Chương 3: Mô tả phương pháp đề nghị, bao gồm việc cải tiến ZCBM thành ứng dụng MVP và thiết kế quy trình phát triển bằng LLM (định nghĩa prompt, cấu hình tác nhân, vòng lặp đánh giá và tinh chỉnh).

Chương 4: Trình bày quá trình thực nghiệm và kết quả thu được trên cả hai trục: đánh giá mô hình ZCBM trên dữ liệu thử nghiệm và đánh giá quy trình phát triển bằng LLM thông qua phân tích nhật ký và mã nguồn sinh ra.

Chương 5: Tổng kết các kết quả đạt được, các hạn chế còn tồn tại và đề xuất hướng phát triển trong tương lai.

CHƯƠNG 2 CƠ SỞ LÝ THUYẾT

2.1 TỔNG QUAN VỀ QUY TRÌNH PHÁT TRIỂN VÀ TRIỂN KHAI

Việc phát triển một ứng dụng trí tuệ nhân tạo không chỉ bao gồm xây dựng mô hình học máy mà còn đòi hỏi sự kết hợp với quy trình phát triển phần mềm truyền thống. Trong kỹ nghệ phần mềm, vòng đời phát triển hệ thống (Software Development Life Cycle – SDLC) thường bao gồm các giai đoạn như khảo sát yêu cầu, phân tích, thiết kế, hiện thực, kiểm thử, triển khai và bảo trì. Đối với các ứng dụng tích hợp trí tuệ nhân tạo, các giai đoạn này vẫn được duy trì, đồng thời cần xem xét thêm những yếu tố đặc thù như lựa chọn mô hình phù hợp, chuẩn bị dữ liệu đầu vào và đánh giá hiệu quả của mô hình trong bối cảnh sử dụng thực tế.

Trong phạm vi đồ án này, quá trình phát triển được định hướng theo mô hình Minimum Viable Product (MVP). Theo Ries [1], MVP là phiên bản tối thiểu của sản phẩm nhưng vẫn đảm bảo cung cấp được giá trị cốt lõi cho người dùng. Cách tiếp cận này cho phép kiểm chứng sớm tính khả thi của giải pháp, thu thập phản hồi từ người dùng và từng bước cải tiến sản phẩm dựa trên nhu cầu thực tế. Đối với các ứng dụng AI mang tính thử nghiệm, việc phát triển theo hướng MVP giúp rút ngắn thời gian triển khai ban đầu và giảm thiểu rủi ro trước khi mở rộng hệ thống ở quy mô lớn.

Về mặt kiến trúc, các ứng dụng AI thường được xây dựng theo mô hình nhiều tầng nhằm tách biệt trách nhiệm giữa các thành phần của hệ thống. Một trong những kiến trúc phổ biến là kiến trúc ba tầng (three-tier architecture), bao gồm tầng giao diện người dùng (Frontend), tầng xử lý nghiệp vụ (Backend) và tầng dữ liệu (Data Layer). Theo Bass và cộng sự [2], việc phân tách các thành phần theo kiến trúc nhiều tầng giúp tăng tính mô-đun, cải thiện khả năng bảo trì và tạo điều kiện thuận lợi cho việc mở rộng hệ thống trong tương lai. Trong đồ án này, kiến trúc ba tầng được lựa chọn nhằm hỗ trợ tích hợp mô hình ZCBM vào một ứng dụng hoàn chỉnh, đảm bảo khả năng triển khai và phát triển lâu dài.


2.2 MÔ HÌNH CLIP

CLIP (Contrastive Language Image Pre-training) là mô hình học biểu diễn đa phương thức được đề xuất bởi OpenAI nhằm khai thác mối liên hệ ngữ nghĩa giữa ảnh và văn bản. Khác với các mô hình phân loại truyền thống vốn được huấn luyện trên một tập lớp cố định, CLIP được huấn luyện trên một tập dữ liệu quy mô lớn gồm các cặp ảnh - mô tả văn bản thu thập từ Internet [3]. Nhờ đó, mô hình có khả năng học được các biểu diễn mang tính khái quát cao và thiết lập một không gian đặc trưng chung giữa dữ liệu thị giác và ngôn ngữ tự nhiên.

Theo Radford và cộng sự [3], việc tận dụng giám sát từ ngôn ngữ tự nhiên giúp CLIP vượt qua những hạn chế của các hệ thống phân loại đóng (closed-set classification), đồng thời mở ra khả năng thực hiện nhiều tác vụ mới mà không cần huấn luyện lại mô hình trên dữ liệu mục tiêu. Khảo sát của Du và cộng sự [4] cũng chỉ ra rằng CLIP là một trong những mô hình thị giác - ngôn ngữ tiền huấn luyện có ảnh hưởng lớn, đặt nền tảng cho nhiều nghiên cứu theo hướng học đa phương thức và suy luận zero-shot trong những năm gần đây.

2.2.1 Kiến trúc và nguyên lý hoạt động của CLIP

Kiến trúc của CLIP bao gồm hai thành phần chính: bộ mã hóa ảnh (image encoder) và bộ mã hóa văn bản (text encoder). Bộ mã hóa ảnh có thể được xây dựng dựa trên các kiến trúc như ResNet hoặc Vision Transformer (ViT), trong khi bộ mã hóa văn bản thường sử dụng Transformer để trích xuất đặc trưng từ các mô tả ngôn ngữ tự nhiên [3]. Hình 2.1 mô tả chi tiết về kiến trúc để trích xuất đặc trưng từ ảnh và văn bản của CLIP.

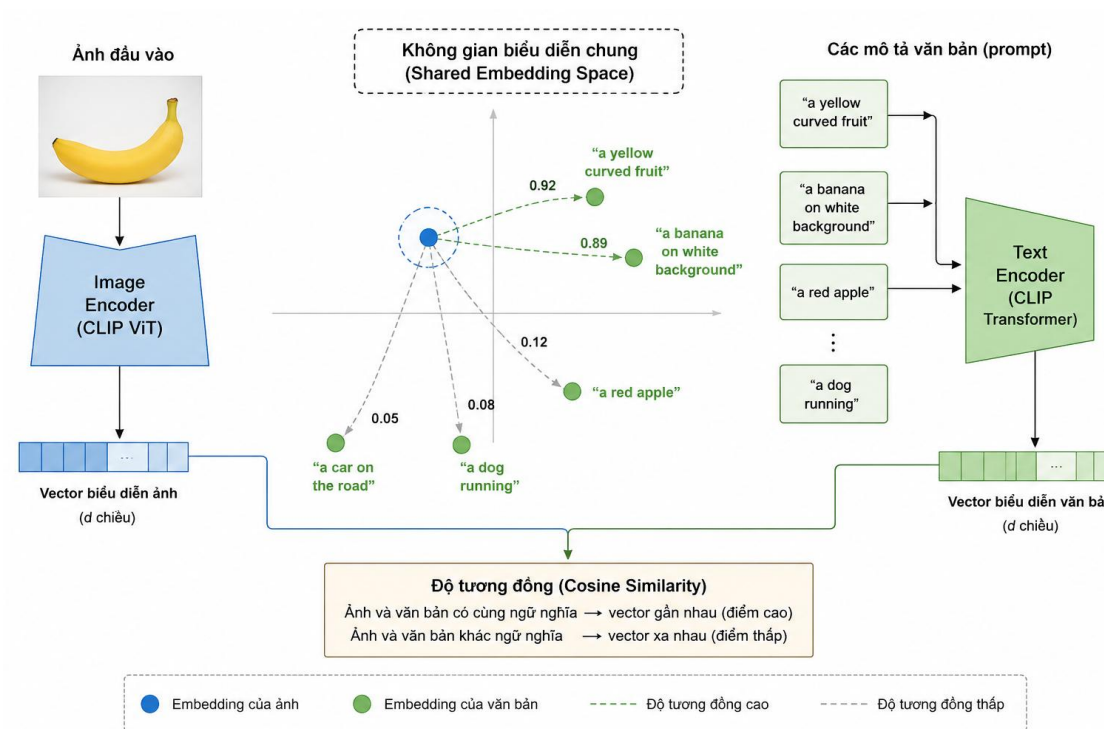


Hình 2.1: Kiến trúc tổng quan mô hình CLIP [3].

Trong quá trình huấn luyện, mỗi ảnh và đoạn văn bản tương ứng sẽ được chuyển đổi thành các vector đặc trưng có cùng số chiều. Mô hình sử dụng phương pháp học tương phản (contrastive learning) nhằm tối đa hóa độ tương đồng giữa các cặp ảnh - văn bản phù hợp, đồng thời giảm độ tương đồng đối với các cặp không liên quan trong cùng một batch huấn luyện. Thông qua cơ chế này, CLIP học được một không gian biểu diễn chung, trong đó các ảnh và văn bản mang cùng ý nghĩa ngữ nghĩa sẽ nằm gần nhau. Đây là nền tảng quan trọng giúp mô hình có khả năng liên kết thông tin giữa hai miền dữ liệu khác nhau mà không cần huấn luyện riêng cho từng tác vụ cụ thể.

2.2.2 Học biểu diễn ảnh - văn bản trong CLIP

Một trong những đóng góp quan trọng của CLIP là khả năng học biểu diễn chung cho dữ liệu ảnh và văn bản. Thông qua cơ chế học tương phản, mô hình ánh xạ các cặp ảnh - mô tả văn bản có cùng nội dung ngữ nghĩa vào những vị trí gần nhau trong không gian đặc trưng, đồng thời đẩy xa các cặp không liên quan [3]. Không gian biểu diễn chung này cho phép mô hình thiết lập mối liên hệ trực tiếp giữa thông tin thị giác và ngôn ngữ tự nhiên, hình 2.2 mô tả rõ hơn về quá trình trích xuất đặc trưng từ ảnh và văn bản.



Hình 2.2: Minh họa việc ánh xạ ảnh và văn bản vào cùng một không gian biểu diễn của CLIP

Qua minh họa hình 2.2 có thể thấy một ảnh chứa quả chuối và cụm từ "a photo of a banana" sẽ có độ tương đồng cao trong không gian đặc trưng sau khi được mã hóa bởi các bộ mã hóa tương ứng. Ngược lại, các mô tả không phù hợp sẽ có độ tương đồng thấp hơn. Khả năng học biểu diễn đa phương thức của CLIP mang lại nhiều lợi ích cho các bài toán thị giác máy tính hiện đại. Thay vì phụ thuộc hoàn toàn vào các nhãn rời rạc được định nghĩa trước, mô hình có thể tận dụng tri thức ngữ nghĩa từ văn bản để hỗ trợ quá trình biểu diễn và suy luận. Điều này góp phần nâng cao khả năng tổng quát hóa của hệ thống khi áp dụng trên các miền dữ liệu khác nhau.

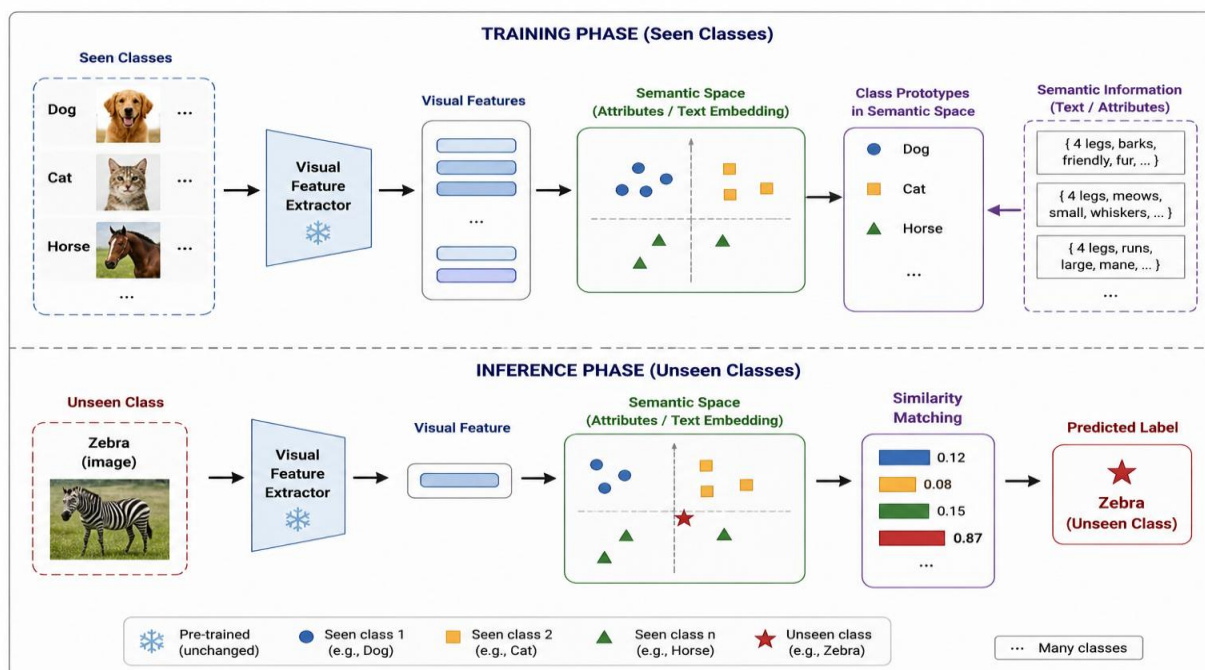
Trong nghiên cứu này, khả năng biểu diễn ảnh - văn bản của CLIP được khai thác để xây dựng các biểu diễn ngữ nghĩa cho các khái niệm (concept) và lớp mục tiêu, tạo tiền đề cho việc phát triển mô hình Zero-shot Concept Bottleneck ở các phần tiếp theo.

2.3 ZERO-SHOT LEARNING

Zero-shot Learning (ZSL) là một nhánh của học máy tập trung vào khả năng dự đoán trên các lớp chưa từng xuất hiện trong quá trình huấn luyện. Khác với các mô hình phân loại truyền thống chỉ có thể nhận diện những lớp đã được học từ dữ liệu gán nhãn, ZSL tận dụng các thông tin ngữ nghĩa bổ sung để xây dựng mối liên hệ giữa các lớp đã biết và các lớp chưa biết. Nhờ đó, mô hình có thể suy luận và đưa ra dự đoán đối với các lớp mới mà không cần thu thập dữ liệu huấn luyện tương ứng [5].

2.3.1 Khái niệm và nguyên lý của Zero-shot Learning

Ý tưởng cốt lõi của Zero-shot Learning là xây dựng một không gian ngữ nghĩa chung, đóng vai trò cầu nối giữa dữ liệu đầu vào và các lớp mục tiêu. Không gian này có thể được biểu diễn thông qua các thuộc tính mô tả, vector ngữ nghĩa của từ hoặc các biểu diễn văn bản [5]. Trong giai đoạn huấn luyện, mô hình học cách ánh xạ dữ liệu từ các lớp đã biết vào không gian ngữ nghĩa này. Khi suy luận, các lớp chưa từng xuất hiện trong tập huấn luyện cũng được biểu diễn trong cùng không gian đó, cho phép mô hình thực hiện việc so khớp và đưa ra dự đoán, hình 2.3 mô tả chi tiết về quá trình zero-shot trên một số class.



Hình 2.3: Hình mô tả kiến trúc của Zero-shot

Hình trên minh họa quy trình zero-shot learning trong phân loại ảnh, trong đó ở giai đoạn huấn luyện mô hình học cách trích xuất đặc trưng từ các lớp đã biết (seen classes) như Dog, Cat, Horse và ánh xạ chúng vào một không gian ngữ nghĩa chung (semantic space) dựa trên thuộc tính hoặc embedding văn bản, với mỗi lớp được biểu diễn bằng một prototype trong không gian này. Trong giai đoạn suy luận, khi gặp lớp chưa từng thấy (unseen class) như Zebra, mô hình ánh xạ đặc trưng ảnh vào cùng không gian ngữ nghĩa và so khớp độ tương đồng với các prototype để gán nhãn theo lớp có mức độ phù hợp cao nhất, qua đó cho phép tổng quát hóa sang các lớp mới mà không cần dữ liệu huấn

Một thách thức quan trọng của Zero-shot Learning là khoảng cách miền (domain gap) giữa các lớp đã biết và các lớp chưa biết. Theo các phân tích từ Xian và cộng sự [5], sự khác biệt này có thể làm suy giảm đáng kể hiệu năng của mô hình khi áp dụng trên các lớp mới. Do đó, việc xây dựng các biểu diễn ngữ nghĩa có khả năng khái quát hóa tốt đóng vai trò then chốt đối với hiệu quả của các phương pháp Zero-shot Learning.

2.3.2 Zero-shot Learning dựa trên mô hình thị giác - ngôn ngữ

Trong những năm gần đây, sự ra đời của các mô hình thị giác - ngôn ngữ tiên huấn luyện đã tạo ra bước tiến đáng kể cho Zero-shot Learning trong lĩnh vực thị giác máy tính. Thay vì phụ thuộc vào các thuộc tính được xây dựng thủ công hoặc các biểu diễn ngữ nghĩa cố định, các mô hình này học trực tiếp mối liên hệ giữa dữ liệu hình ảnh và ngôn ngữ tự nhiên từ các tập dữ liệu quy mô lớn.

Tiêu biểu cho hướng tiếp cận này là CLIP, mô hình được huấn luyện trên hàng trăm triệu cặp ảnh – văn bản nhằm xây dựng một không gian biểu diễn chung cho hai miền dữ liệu [3]. Nhờ khả năng liên kết giữa đặc trưng thị giác và mô tả ngôn ngữ, CLIP có thể được sử dụng để thực hiện các tác vụ nhận diện đối với những lớp chưa xuất hiện trong quá trình huấn luyện.

Trong thiết lập Zero-shot, tập lớp mục tiêu (target class set) được mô tả dưới dạng văn bản thay vì yêu cầu dữ liệu huấn luyện có gán nhãn cho từng lớp. Quá trình dự đoán được thực hiện thông qua việc so sánh độ tương đồng biểu diễn của ảnh đầu vào với biểu diễn ngữ nghĩa của các lớp mục tiêu trong không gian đặc trưng đã học. Cách tiếp cận này giúp mở rộng khả năng nhận diện sang các lớp mới một cách linh hoạt, đồng thời giảm đáng kể chi phí thu thập và gán nhãn dữ liệu. Sự kết hợp giữa các mô hình thị giác – ngôn ngữ và Zero-shot Learning đã mở ra nhiều tiềm năng ứng dụng trong các bài toán nhận diện quy mô lớn, nơi tập lớp có thể thay đổi thường xuyên hoặc khó thu thập đầy đủ dữ liệu huấn luyện.

2.4 CONCEPT BOTTLENECK MODEL

2.4.1 Tổng quan về Concept Bottleneck Model

Concept Bottleneck Model (CBM) được giới thiệu bởi Koh và cộng sự vào năm 2020 như một hướng tiếp cận nhằm kết hợp hiệu năng dự đoán của các mô hình học sâu với khả năng giải thích dựa trên các khái niệm có ý nghĩa đối với con người [6]. Thay vì ánh xạ trực tiếp từ dữ liệu đầu vào sang nhãn đầu ra như các mô hình end-to-end

truyền thống, CBM đưa vào một tầng trung gian biểu diễn các khái niệm (concepts) mà con người có thể quan sát và diễn giải được.

Theo Koh và cộng sự [6], ý tưởng cốt lõi của CBM là buộc mô hình phải thực hiện quá trình suy luận thông qua tập khái niệm đã được xác định trước. Điều này giúp quá trình ra quyết định của mô hình trở nên minh bạch hơn, đồng thời tạo điều kiện để con người có thể kiểm tra và can thiệp vào từng bước dự đoán khi cần thiết. Khái niệm trong CBM thường được lựa chọn dựa trên kiến thức chuyên môn của miền ứng dụng. Chẳng hạn, trong bài toán chẩn đoán viêm khớp từ ảnh X-quang, các khái niệm có thể bao gồm tình trạng xơ cứng xương (sclerosis), sự xuất hiện của gai xương (bone spurs) hoặc mức độ hẹp khe khớp (narrow joint space). Trong khi đó, đối với bài toán phân loại loài chim, các khái niệm có thể là màu cánh, màu phần đuôi dưới hoặc chiều dài mỏ [6].


2.4.2 Kiến trúc và cơ chế hoạt động của CBM

Kiến trúc CBM bao gồm hai thành phần chính: bộ dự đoán khái niệm và bộ dự đoán nhãn. Với dữ liệu đầu vào (x), bộ dự đoán khái niệm (g) sẽ sinh ra vector khái niệm (c), trong đó mỗi phần tử biểu diễn xác suất hoặc mức độ hiện diện của một khái niệm cụ thể. Vector khái niệm này sau đó được sử dụng làm đầu vào cho bộ dự đoán nhãn (f) để đưa ra kết quả cuối cùng (y).

Quá trình suy luận của CBM có thể được mô tả như sau:

$$y = f(g(x)) = f(c)$$

Trong nghiên cứu gốc, Koh và cộng sự [6] nhấn mạnh rằng việc sử dụng tầng khái niệm như một "nút thắt" (bottleneck) buộc toàn bộ thông tin phục vụ cho nhiệm vụ dự đoán phải đi qua tập khái niệm đã được định nghĩa trước. Nhờ đó, mô hình không chỉ học cách phân loại mà còn học cách biểu diễn dữ liệu dưới dạng các thuộc tính mà con người có thể hiểu được. Hình 2.4 mô tả quá trình trích xuất concept trong 2 bài toán dựa trên các đặc trưng hình thái học.



Hình 2.4: Minh họa Concept Bottleneck Model với các khái niệm trung gian được trích xuất từ ảnh để thực hiện dự đoán [6].

Concept Bottleneck Model tách quá trình suy luận thành hai bước: đầu tiên, CNN trích xuất các “concept” có ý nghĩa (ví dụ: hẹp khe khớp, gai xương hoặc màu cánh, chiều dài mỏ), sau đó các concept này được đưa vào bộ hồi quy hoặc bộ phân loại để dự đoán đầu ra nhiệm vụ. Cách tiếp cận này giúp mô hình vừa dễ giải thích hơn, vừa kiểm soát được quyết định thông qua các đặc trưng trung gian có ý nghĩa.

Mặc dù CBM mang lại khả năng giải thích vượt trội thông qua tầng khái niệm trung gian, việc yêu cầu nhãn khái niệm chi tiết đã hạn chế khả năng ứng dụng của mô hình trên quy mô lớn. Theo Koh và cộng sự [6], quá trình thu thập các nhãn này thường cần đến chuyên gia (expert) trong từng lĩnh vực cụ thể. Ngoài ra, tập khái niệm được xác định trước cũng làm giảm khả năng chuyển giao của mô hình sang các miền dữ liệu mới. Những hạn chế này đã trở thành động lực thúc đẩy sự phát triển của các phương pháp mở rộng CBM, trong đó nổi bật là Zero-shot Concept Bottleneck Models.

2.5 ZERO-SHOT CONCEPT BOTTLENECK MODEL

2.5.1 Từ Concept Bottleneck Model đến Zero-shot Concept Bottleneck Model


Mặc dù Concept Bottleneck Model (CBM) mang lại khả năng giải thích thông qua tầng khái niệm trung gian, việc phụ thuộc vào dữ liệu được gán nhãn khái niệm đã hạn chế đáng kể khả năng mở rộng của phương pháp này. Trong nhiều bài toán thực tế, đặc biệt là các miền yêu cầu tri thức chuyên sâu như y tế hoặc công nghiệp, quá trình xây dựng tập nhãn khái niệm thường tiêu tốn nhiều thời gian và chi phí.

Sự phát triển của các mô hình thị giác ngôn ngữ tiên huấn luyện đã mở ra một hướng tiếp cận mới nhằm giải quyết bài toán trên. Zero-shot Concept Bottleneck Model (ZCBM) được đề xuất với mục tiêu duy trì khả năng giải thích của CBM nhưng không cần huấn luyện bộ dữ liệu đoán khái niệm trên dữ liệu mục tiêu [7]. Thay vào đó, ZCBM tận dụng không gian biểu diễn chung giữa ảnh và văn bản của các mô hình như CLIP để suy diễn sự hiện diện của các khái niệm một cách trực tiếp.


Nhờ đặc tính này, ZCBM có khả năng thích nghi với các tập nhãn mới mà không cần xây dựng lại toàn bộ hệ thống, đồng thời giảm đáng kể yêu cầu về dữ liệu chú thích ở mức khái niệm.

2.5.2 Kiến trúc và cơ chế suy luận của ZCBM

Kiến trúc của ZCBM được tổ chức thành hai giai đoạn chính, bao gồm suy luận từ đầu vào sang khái niệm (input-to-concept inference) và suy luận từ khái niệm sang nhãn (concept-to-label inference), hình 2.5 minh họa chi tiết cả 2 giai đoạn như sau:



(a) Overview of Z-CBMs



(b) Comparison of Intervention

Hình 2.5: Kiến trúc tổng quát của Zero-shot Concept Bottleneck Model và cơ chế suy luận thông qua tầng khái niệm trung gian [7].

Ở giai đoạn đầu tiên, một ngân hàng khái niệm (concept bank) được xây dựng từ tập lớn các mô tả ngôn ngữ liên quan đến đặc trưng thị giác. Các mô tả này có thể được thu thập từ cơ sở tri thức có sẵn hoặc sinh tự động bằng mô hình ngôn ngữ lớn. Sau đó, bộ mã hóa văn bản của CLIP được sử dụng để chuyển đổi từng khái niệm thành vector đặc trưng và lưu trữ để tái sử dụng trong các lần suy luận tiếp theo.

Theo Yamaguchi và cộng sự [7], khi nhận ảnh đầu vào, bộ mã hóa ảnh của CLIP sẽ trích xuất vector biểu diễn của ảnh. Độ tương đồng giữa vector ảnh và các vector trong concept bank được tính toán nhằm xác định mức độ liên quan của từng khái niệm đối với ảnh đang xét. Từ đó, mô hình lựa chọn tập các khái niệm có mức kích hoạt cao nhất để tạo thành biểu diễn trung gian phục vụ cho quá trình dự đoán.

Trong giai đoạn thứ hai, mối quan hệ giữa khái niệm và nhãn được khai thác để đưa ra quyết định cuối cùng. Để tăng tính diễn giải và hạn chế ảnh hưởng của các khái niệm không liên quan, ZCBM sử dụng cơ chế lựa chọn thưa (sparse selection), chỉ giữ lại một số lượng nhỏ khái niệm có đóng góp lớn nhất đối với từng lớp [7].

2.5.3 Khả năng can thiệp động và ý nghĩa thực tiễn

Một điểm khác biệt đáng chú ý giữa ZCBM và CBM truyền thống nằm ở cách các khái niệm được sử dụng trong quá trình suy luận. Trong CBM, tập khái niệm thường được xác định cố định trước khi huấn luyện. Ngược lại, ZCBM cho phép truy hồi động các khái niệm phù hợp với từng nhiệm vụ và từng đầu vào cụ thể [7].

Hình 2.5 (b) minh họa sự khác biệt này thông qua cơ chế can thiệp của người dùng. Đối với CBM, việc điều chỉnh chỉ diễn ra trên tập khái niệm tĩnh đã được định nghĩa từ trước. Trong khi đó, ZCBM có thể bổ sung, loại bỏ hoặc thay đổi các khái niệm được lựa chọn trong quá trình suy luận, từ đó mang lại tính linh hoạt cao hơn khi triển khai trên nhiều miền dữ liệu khác nhau.

Khả năng tận dụng tri thức từ mô hình thị giác – ngôn ngữ tiền huấn luyện giúp ZCBM giảm đáng kể chi phí chuẩn bị dữ liệu và rút ngắn thời gian phát triển hệ thống. Tuy nhiên, hiệu quả của phương pháp vẫn phụ thuộc vào chất lượng của concept bank cũng như năng lực biểu diễn của mô hình nền. Khi áp dụng cho các miền dữ liệu chuyên biệt, việc xây dựng tập khái niệm phù hợp vẫn là một thách thức cần được xem xét cẩn thận nhằm đảm bảo độ tin cậy của kết quả dự đoán.

2.6 MÔ HÌNH NGÔN NGỮ LỚN VÀ CLAUDE AI

2.6.1 Tổng quan về mô hình ngôn ngữ lớn

Mô hình ngôn ngữ lớn (Large Language Model – LLM) là các mạng nơ-ron sâu được huấn luyện trên khối lượng dữ liệu văn bản quy mô lớn nhằm học cách biểu diễn và sinh ngôn ngữ tự nhiên. Phần lớn các LLM hiện đại được xây dựng dựa trên kiến trúc Transformer do Vaswani và cộng sự đề xuất [8]. Nhờ cơ chế self-attention, Transformer có khả năng nắm bắt mối quan hệ phụ thuộc dài hạn trong chuỗi dữ liệu, đồng thời hỗ trợ quá trình huấn luyện song song với hiệu quả cao.


Sau giai đoạn tiền huấn luyện, các LLM thường được tinh chỉnh nhằm nâng cao khả năng tuân theo hướng dẫn và cải thiện tính an toàn trong quá trình tương tác. Một trong

những hướng tiếp cận phổ biến là học tăng cường từ phản hồi của con người (Reinforcement Learning from Human Feedback – RLHF). Ouyang và cộng sự [9] đã chỉ ra rằng phương pháp này giúp cải thiện đáng kể mức độ hữu ích và phù hợp của phản hồi do mô hình tạo ra. Các họ mô hình tiêu biểu hiện nay bao gồm GPT của OpenAI, Claude của Anthropic, Gemini của Google và Llama của Meta.

Bên cạnh các ứng dụng xử lý ngôn ngữ tự nhiên, LLM ngày càng được sử dụng rộng rãi trong lĩnh vực phát triển phần mềm. Nhờ được huấn luyện trên lượng lớn mã nguồn công khai, các mô hình này có khả năng phân tích cấu trúc dự án, sinh mã nguồn, hỗ trợ gỡ lỗi và đề xuất giải pháp cho các vấn đề kỹ thuật. Khi được tích hợp với các công cụ thao tác tệp và thực thi lệnh, LLM có thể tham gia vào nhiều giai đoạn của quy trình phát triển phần mềm, từ xây dựng chức năng mới đến kiểm thử và bảo trì hệ thống.

2.6.2 Claude AI và Claude Code trong hỗ trợ phát triển phần mềm

Claude là họ mô hình ngôn ngữ lớn do Anthropic phát triển, được thiết kế nhằm cân bằng giữa khả năng suy luận, tính hữu ích và mức độ an toàn trong quá trình sử dụng. Trong phạm vi đồ án này, Claude được khai thác như một công cụ hỗ trợ phát triển phần mềm, đặc biệt trong các nhiệm vụ như phân tích yêu cầu, đề xuất cấu trúc mã nguồn, hỗ trợ triển khai chức năng và rà soát lỗi trong quá trình xây dựng ứng dụng.



Hình 2.6: Giao diện dòng lệnh của công cụ Claude Code

Để tích hợp mô hình vào quy trình làm việc thực tế, Anthropic cung cấp Claude Code - công cụ dòng lệnh cho phép tương tác trực tiếp với Claude trong môi trường phát

triển phần mềm [10]. Theo tài liệu chính thức của Anthropic [10], Claude Code hỗ trợ đọc và chỉnh sửa tệp, thực thi lệnh shell, kiểm thử mã nguồn và tương tác với hệ thống quản lý phiên bản. Điều này giúp rút ngắn thời gian thực hiện các tác vụ lặp lại và hỗ trợ lập trình viên trong quá trình phát triển dự án [11]. Ngoài ra, Claude Code còn hỗ trợ nhiều cơ chế mở rộng như slash commands, hooks, giao thức Model Context Protocol (MCP) và hệ thống sub-agent. Các cơ chế này cho phép phân chia nhiệm vụ thành các tác nhân chuyên biệt với ngữ cảnh và công cụ riêng, góp phần nâng cao hiệu quả xử lý đối với những bài toán phát triển phần mềm có quy mô lớn và nhiều bước thực hiện.

Trong đồ án này, Claude Code được sử dụng như một công cụ hỗ trợ quá trình hiện thực hóa hệ thống Zero-shot Concept Bottleneck Model. Việc ứng dụng LLM vào quy trình phát triển không thay thế vai trò của người phát triển mà đóng vai trò như một trợ lý kỹ thuật, hỗ trợ tăng năng suất, rút ngắn thời gian triển khai và tạo điều kiện thuận lợi cho việc thử nghiệm các ý tưởng mới trong quá trình xây dựng sản phẩm.

CHƯƠNG 3 PHƯƠNG PHÁP ĐỀ NGHỊ

3.1 TỔNG QUAN PHƯƠNG PHÁP


Trong nghiên cứu này thì phương pháp được đề xuất là một hệ thống xác minh mình ảnh một lớp (one-class verification) hoàn toàn không cần phải thông quan huấn luyện (hay gọi là zero-shot), nó được xây dựng dựa trên sự biểu diễn đặc trưng đa phương thức của mô hình CLIP. Điểm cốt lõi của phương pháp nằm ở khả năng minh bạch hóa quyết định phân loại thông qua các khái niệm ngữ nghĩa, đồng thời cho phép người dùng (expert) có thể tự định nghĩa các lớp một cách linh hoạt mà không cần thu thập bộ dữ liệu lớn để huấn luyện lại.

Hệ thống được chia thành hai giai đoạn chính:

- Giai đoạn xây dựng hồ sơ lớp (Builder): chỉ thực thi một lần khi người dùng muốn khởi tạo một lớp mới.
- Giai đoạn xác minh (Verify): được dùng khi người dùng muốn hệ thống xác minh, đánh giá hình ảnh.

Ba đặc trưng đóng góp chính của phương pháp bao gồm:

- Sử dụng hai nguồn bằng chứng độc lập: dựa trên ngữ nghĩa cả khái niệm mà đo độ tương đồng với ảnh, từ đó củng cố độ tin cậy về khả năng giải thích.
- Cơ chế cổng đa ngưỡng (multi-floor gate): khắc phục điểm yếu của các hệ thống sử dụng cố định một ngưỡng từ chối làm mất đi sự cân bằng. Cơ chế này đánh giá linh hoạt qua nhiều tầng tiêu chí gồm điểm số bằng chứng và độ phủ khái niệm từ đó đưa ra đánh giá hoặc từ chối thay vì ép buộc gán sai nhãn.
- Cung cấp khả năng giải thích được theo các khái niệm: quá trình suy luận của hệ thống được minh bạch thông qua việc cung cấp khả năng giải thích chi tiết, xóa bỏ rào cản “hộp đen” của các mạng nơ-ron truyền thống hoạt động ánh xạ trực tiếp mà không có khả năng giải thích.



Hình 3.1: Sơ đồ tổng quan phương pháp đề xuất

3.1.1 Phát biểu bài toán

Nghiên cứu này tập trung vào việc giải quyết bài toán xác minh và phân loại mở. Hình thức là cho trước một tập hợp các hồ sơ lớp do người dùng tự định nghĩa và một hình ảnh đầu vào x , mục tiêu của hệ thống là trả về một dự đoán nhãn dự đoán y sao cho:

$$\hat{y} \in \{P_1, \dots, P_M, reject\} \quad (3.1)$$

Trong đó:

- $\hat{y}$: nhãn dự đoán cuối cùng (predicted output) mà hệ thống quyết định gán cho một bức ảnh đầu vào sau khi đã chạy qua toàn bộ luồng suy luận.
- $P_1, \dots, P_M$: đại diện cho tập hợp gồm M lớp đối tượng mục tiêu hợp lệ. Đây chính là các hồ sơ lớp (profiles) đã được người dùng định nghĩa zero-shot thông qua quy trình Builder.
- *reject*: trả về kết quả không khớp.

Bên cạnh nhãn dự đoán $\hat{y}$, đầu ra của hệ thống bắt buộc phải đi kèm một điểm số độ tin cậy (confidence score) và một biên bản giải thích chi tiết. Điểm khác biệt cốt lõi của phương pháp này so với các bài toán phân loại truyền thống chính là sự tồn tại của tùy chọn từ chối (*reject*). Ở các mạng nơ-ron thông thường, hàm kích hoạt softmax luôn ép buộc đầu vào phải được ánh xạ vào một trong các lớp đã biết, bất chấp việc bằng chứng và độ tự tin của lớp đó cực kỳ yếu. Ngược lại, hệ thống đề xuất phá vỡ rào cản này bằng cách tuân thủ ba ràng buộc thiết kế nghiêm ngặt: (1) không sử dụng thêm các trọng số học được, (2) mở rộng không gian phân loại linh hoạt thông qua việc bổ sung hồ sơ lớp mới, và (3) chỉ ra quyết định dựa trên một chuỗi bằng chứng minh bạch, có khả năng giải thích ở cấp độ khái niệm. Cách tiếp cận này tuân theo tư tưởng của các hệ thống xác minh mở, trong đó hành vi từ chối (*reject*) được tích hợp để xử lý dữ liệu

ngoài phân bố, tương tự như các cơ chế được thảo luận Zero-shot Concept Bottleneck Models.

3.1.2 Giai đoạn xây dựng hồ sơ lớp (Builder)

Giai đoạn xây dựng hồ sơ lớp (Builder) có nhiệm vụ tạo ra biểu diễn tri thức cho từng lớp dưới dạng một hồ sơ lớp (class profile) có khả năng tái sử dụng trong suốt quá trình xác minh. Hồ sơ này được hình thành thông qua ba bước chính: (1) trích xuất các khái niệm thị giác từ mô tả ngôn ngữ tự nhiên bằng mô hình ngôn ngữ lớn, (2) lọc nhiễu và loại bỏ các khái niệm không phù hợp, và (3) chuyển đổi các khái niệm thành biểu diễn số kết hợp với thông tin nguyên mẫu ảnh để hoàn thiện hồ sơ lớp.

3.1.2.1 Trích xuất khái niệm bằng LLM

Đầu vào của quá trình này là tên lớp (class) kèm theo một đoạn mô tả bằng ngôn ngữ tự nhiên. Hệ thống sử dụng Mô hình ngôn ngữ lớn (LLM - Large Language Model), cụ thể là Gemini, với một chỉ thị hệ thống (system prompt) được thiết kế chặt chẽ nhằm giới hạn phạm vi thông tin được trích xuất. Theo đó, LLM chỉ được phép sinh ra các thuộc tính có thể quan sát trực tiếp bằng thị giác như bộ phận, hình dạng, màu sắc, hoa văn bề mặt hoặc chất liệu, đồng thời loại bỏ hoàn toàn các thuộc tính mang tính hành vi hoặc khái niệm trừu tượng.

Mỗi khái niệm được sinh ra đều được gán kèm một mức độ quan trọng (importance) nhằm phản ánh mức đóng góp tương đối của khái niệm đó đối với việc nhận diện lớp. Ngoài ra, hệ thống còn áp dụng cơ chế giới hạn số lượng khái niệm và khử trùng lặp về mặt ngữ nghĩa nhằm đảm bảo hồ sơ lớp vừa đầy đủ thông tin nhưng không dư thừa.

3.1.2.2 Lọc nhiễu và chống vọng lại

Mặc dù LLM có khả năng sinh khái niệm chất lượng cao, kết quả đầu ra vẫn có thể xuất hiện các trường hợp không mong muốn như sai định dạng, chứa ký tự bất thường, quá ngắn, quá dài hoặc lặp lại thông tin đã có. Do đó, trước khi chuyển sang bước nhúng bằng CLIP, toàn bộ các khái niệm đều được xử lý bởi một tập luật kiểm tra nhằm loại bỏ các trường hợp nhiễu này.

Bên cạnh đó, hệ thống đặc biệt loại bỏ các khái niệm trùng hoặc gần trùng với chính tên lớp cần xác minh. Cơ chế này giúp hạn chế hiện tượng “vọng lại” (echoing), trong đó mô hình vô tình sử dụng lại tên lớp như một bằng chứng nhận dạng. Nhờ vậy, mỗi khái niệm được giữ lại đều mang ý nghĩa giải thích độc lập và có giá trị hỗ trợ cho quá trình xác minh.

3.1.2.3 Nhúng khái niệm, dựng nguyên mẫu và hiệu chuẩn hồ sơ lớp

Sau khi hoàn thành quá trình tinh lọc, các khái niệm còn lại được sử dụng để xây dựng hồ sơ lớp hoàn chỉnh. Hồ sơ này là thành phần dữ liệu cốt lõi của hệ thống và chỉ được tính toán một lần trong giai đoạn khởi tạo. Một hồ sơ lớp bao gồm ba thành phần chính: ma trận vector nhúng khái niệm (concept embeddings), nguyên mẫu hình ảnh (image prototype) và cửa sổ hiệu chuẩn (calibration window). Các thành phần trên lần lượt được tạo ra thông qua quá trình nhúng khái niệm bằng mô hình CLIP, xây dựng nguyên mẫu đại diện từ tập ảnh tham chiếu và hiệu chuẩn phân bố điểm tương đồng của từng lớp. Kết quả cuối cùng là một biểu diễn đa phương thức có khả năng lưu trữ cả tri thức ngôn ngữ lẫn đặc trưng thị giác, tạo nền tảng cho giai đoạn xác minh ở các bước tiếp theo.

a) Nhúng khái niệm bằng mô hình Ngôn ngữ - Thị giác (CLIP)

Mỗi khái niệm thị giác (concept) được đưa vào một cấu trúc câu mẫu (prompt template) dưới định dạng *"a photo of {concept}"*. Dữ liệu văn bản này sau đó được

truyền qua bộ mã hóa văn bản (text encoder) của mô hình CLIP để trích xuất thành một vector đặc trưng ngữ nghĩa trong không gian đa phương thức. Nhằm đảm bảo phép tính tích vô hướng (dot product) tương đương với phép đo độ tương đồng cosine (cosine similarity), toàn bộ các vector đều được chuẩn hóa theo chuẩn L2.

Các vector đặc trưng sau đó được tổng hợp thành một ma trận, trong đó mỗi hàng đại diện cho một khái niệm và được gắn kèm một trọng số mức độ quan trọng (importance) có giá trị từ 1 đến 5. Cách tiếp cận này hình thành một tầng nút thắt khái niệm (concept bottleneck) theo cơ chế zero-shot hoàn toàn, cho phép mô hình dự đoán các khái niệm liên quan mà không yêu cầu thu thập dữ liệu đích hoặc huấn luyện bổ sung bất kỳ mạng nơ-ron nào.

b) Xây dựng nguyên mẫu ảnh (Prototype)

Trong trường hợp hồ sơ lớp được cung cấp kèm theo tập hình ảnh tham chiếu, mỗi hình ảnh sẽ được mã hóa thông qua bộ mã hóa hình ảnh (image encoder) của CLIP để tạo thành một vector đặc trưng. Để xây dựng một đại diện tổng quát cho toàn bộ lớp, phương pháp tiến hành tính trung bình cộng của tất cả các vector đặc trưng này, sau đó thực hiện chuẩn hóa L2 một lần nữa nhằm tạo ra vector nguyên mẫu (prototype).

Ý tưởng sử dụng vector trung bình của tập tham chiếu làm đại diện cho lớp được kế thừa từ nguyên lý của mạng nguyên mẫu (Prototypical Networks) trong bài toán học ít mẫu (few-shot learning). Trong trường hợp lớp chỉ được định nghĩa bằng văn bản và không có ảnh tham chiếu, vector nguyên mẫu sẽ được gán giá trị bằng 0. Khi đó, hệ thống sẽ tự động vô hiệu hóa nhánh bằng chứng nguyên mẫu trong giai đoạn xác minh và điểm số cuối cùng sẽ hoàn toàn phụ thuộc vào nhánh bằng chứng khái niệm.

c) Hiệu chuẩn cửa sổ nguyên mẫu (Prototype Calibration)

Do giá trị tương đồng cosine có sự phân bố khác nhau giữa các lớp, việc sử dụng một ngưỡng (threshold) cố định cho toàn bộ hệ thống thường không mang lại hiệu quả

tối ưu. Để giải quyết vấn đề này, nghiên cứu đề xuất cơ chế hiệu chuẩn tự động dựa trên kỹ thuật Leave-One-Out (LOO).

Cụ thể, khi một lớp được cung cấp từ ba ảnh tham chiếu trở lên, hệ thống sẽ lặp lại quá trình chọn một ảnh làm mẫu kiểm thử và sử dụng các ảnh còn lại để xây dựng nguyên mẫu. Mỗi vòng lặp tạo ra một điểm số tương đồng giữa ảnh bị giữ lại và nguyên mẫu được xây dựng từ các ảnh còn lại. Tập hợp các điểm số này phản ánh trực tiếp mức độ phân tán và độ đa dạng nội tại của dữ liệu thuộc lớp đó, từ đó được sử dụng để xác định cửa sổ hiệu chuẩn phục vụ cho giai đoạn xác minh sau này.

3.1.3 Giai đoạn xác minh (Verifier)

3.1.3.1 Nhúng ảnh truy vấn đầu vào

Hình ảnh kiểm thử (x) được đưa qua bộ mã hóa hình ảnh (image encoder) của mô hình CLIP để tạo thành một vector đặc trưng trong không gian đa phương thức. Sau đó, vector này được chuẩn hóa theo chuẩn L2 nhằm đảm bảo phép tính tích vô hướng tương đương với độ tương đồng cosine.

Quá trình nhúng ảnh chỉ được thực hiện một lần duy nhất đối với mỗi ảnh truy vấn. Vector đặc trưng thu được sau đó được tái sử dụng để đối chiếu với toàn bộ các hồ sơ lớp hiện có trong hệ thống, giúp giảm đáng kể chi phí tính toán trong giai đoạn xác minh.

3.1.3.2 Tính toán bằng chứng khái niệm (Concept Evidence)

Để đo lường sự hiện diện của từng khái niệm, hệ thống đối chiếu hình ảnh đầu vào với các thuộc tính do LLM sinh ra thông qua không gian đặc trưng của CLIP. Khác với các mô hình phân loại đóng sử dụng hàm Softmax để ép buộc chọn một lớp duy nhất, bài toán xác minh đòi hỏi đánh giá độc lập từng khái niệm. Do đó, hệ thống mô hình hóa mỗi khái niệm như một phép kiểm định nhị phân và sử dụng hàm kích hoạt

Sigmoid. Logit thô ban đầu được tính toán từ độ tương đồng cosine nhân với hệ số nhiệt độ nghịch đảo τ (logit scale) của CLIP [3].

Đồng thời, để khắc phục hiện tượng thiên lệch - khi mô hình luôn có một mức "độ tương đồng nền" nhất định với mọi văn bản - nghiên cứu áp dụng kỹ thuật hiệu chuẩn zero-shot: trừ điểm tương đồng của khái niệm ($s_{concept}$) cho điểm của một lời nhắc trung tính ($s_{neutral}$) [12]. Cơ chế này đảm bảo xác suất đầu ra chỉ phản ánh phần đặc trưng thực sự vượt trội của khái niệm:

$$P(concept) = \sigma(\tau \cdot (s_{concept} - s_{neutral})) \quad (3.2)$$

Trong đó:

- $P(concept)$: xác suất hiện diện của khái niệm thị giác trong hình ảnh đầu vào, có giá trị trong dải $[0, 1]$.
- σ : hàm kích hoạt Sigmoid, có nhiệm vụ ánh xạ giá trị logit thô về không gian xác suất phân bố.
- τ : hệ số nhiệt độ nghịch đảo (inverse temperature) hay thang đo logit (logit scale) đặc trưng của mô hình CLIP, được sử dụng để khuếch đại sự chênh lệch của các giá trị tương đồng.
- $s_{concept}$: điểm độ tương đồng cosine (cosine similarity) giữa vector đặc trưng của hình ảnh truy vấn và vector đặc trưng của văn bản khái niệm mục tiêu.
- $s_{neutral}$: điểm độ tương đồng cosin giữa vector đặc trưng của hình ảnh truy vấn và vector đặc trưng của một lời nhắc văn bản trung tính (ví dụ: "a photo"), đóng vai trò làm đường cơ sở (baseline) để hiệu chuẩn.

Cuối cùng, để đánh giá mức độ khớp toàn diện của bức ảnh với một hồ sơ lớp, hệ thống tính toán điểm bằng chứng khái niệm tổng hợp dựa trên phương pháp trung bình cộng có trọng số. Xác suất hiện diện của từng khái niệm sẽ được nhân với mức độ quan trọng tương ứng (có giá trị từ 1 đến 5) đã được LLM thiết lập từ pha xây dựng hồ sơ, sau đó chia cho tổng các trọng số. Việc tính toán này đóng vai trò mấu chốt, giúp hệ thống luôn ưu tiên mức độ khớp của các đặc điểm định danh cốt lõi, đồng thời tránh việc bị bù đắp sai lệch bởi các chi tiết phụ trợ.

3.1.4 Cơ chế ra quyết định

Sau khi tổng hợp điểm số từ các nguồn bằng chứng, hệ thống không đưa dữ liệu qua một lớp phân loại (classification layer) học được như các mạng nơ-ron truyền thống. Thay vào đó, quyết định cuối cùng được thực thi bởi một cơ chế xếp hạng và lọc đa ngưỡng dựa trên bộ quy tắc tĩnh. Cơ chế này đảm bảo mọi quyết định đều minh bạch, khát khe và bảo toàn quyền từ chối của hệ thống.

a) Xếp hạng độc lập

Hệ thống tiến hành chấm điểm ảnh đầu vào với từng hồ sơ lớp một cách hoàn toàn độc lập. Quá trình này không sử dụng hàm Softmax để ép tổng xác suất của tất cả các lớp thành 100%, do đó loại bỏ triệt để hiện tượng cạnh tranh xác suất chéo. Một bức ảnh hoàn toàn có thể đạt điểm tuyệt đối ở nhiều lớp (nếu các lớp có định nghĩa tương đồng) hoặc 0 điểm ở tất cả các lớp. Các ứng viên sau đó được sắp xếp thành một danh sách với điểm số tổng hợp s giảm dần. Lựa chọn thiết kế này cho phép hệ thống mở rộng quy mô (thêm, bớt hồ sơ lớp) một cách vô hạn mà không cần tái định chuẩn (re-normalize) hoặc huấn luyện lại toàn cục.

b) Cổng đa ngưỡng

Trong cơ chế ra quyết định của hệ thống, ứng viên đạt điểm số tổng hợp cao nhất không mặc nhiên trở thành kết quả dự đoán cuối cùng. Nhằm giảm thiểu rủi ro nhận diện sai (False Positive), thuật toán được thiết kế để duyệt tuần tự qua danh sách các ứng viên đã xếp hạng và chỉ chấp nhận lớp đầu tiên vượt qua được một "cổng lọc đa ngưỡng" khát khe.

Cụ thể, để lọt qua cổng lọc này, một ứng viên phải đồng thời thỏa mãn bốn rào cản kiểm định độc lập. Thứ nhất, điểm số tổng hợp của ứng viên phải đạt một ngưỡng đối khớp tối thiểu để đảm bảo độ tin cậy chung. Thứ hai, điểm số đánh giá của nhánh bằng chứng khái niệm bắt buộc phải vượt qua mức sàn quy định nhằm khẳng định sự tồn tại của các đặc trưng ngữ nghĩa. Thứ ba, trong trường hợp hồ sơ lớp có cung cấp ảnh

tham chiếu, điểm số của nhánh bằng chứng nguyên mẫu cũng phải đạt một ngưỡng tương đồng cấu trúc nhất định. Thứ tư, hệ thống áp đặt một điều kiện thiết yếu về độ phủ khái niệm (coverage), yêu cầu tỷ lệ giữa số lượng khái niệm thực tế hiện diện và tổng số khái niệm định nghĩa của lớp phải đạt mức tiêu chuẩn.

Trong bốn rào cản trên, kiểm định độ phủ khái niệm đóng vai trò cốt lõi nhằm bảo vệ tính toàn diện của bằng chứng. Cơ chế này trực tiếp ngăn chặn tình trạng một vài đặc điểm đạt điểm tương đồng cực cao kéo lệch điểm trung bình, trong khi bức ảnh lại thiếu hụt trầm trọng các chi tiết nhận dạng mang tính định danh khác. Nhờ việc kết hợp cơ chế quét tuần tự và hệ thống bốn rào cản này, hệ thống có khả năng chủ động từ chối những ứng viên có "điểm cao nhưng thiếu sót", để nhường cơ hội cho các ứng viên xếp hạng thấp hơn nhưng đáp ứng đồng đều và trọn vẹn mọi tiêu chí xác minh.

c) Cơ chế chọn lớp chiến thắng

Sau khi thiết lập hệ thống rào cản, thuật toán tiến hành quét tuần tự từ trên xuống dưới theo danh sách các ứng viên đã được xếp hạng. Lớp chiến thắng (winner) được xác định là lớp đầu tiên vượt qua thành công toàn bộ các công kiểm định. Việc tiếp tục duyệt qua các ứng viên xếp sau, thay vì chỉ xét duyệt duy nhất lớp đứng đầu, là một thiết kế có chủ đích. Cơ chế này cho phép một ứng viên xếp hạng dưới nhưng có phổ điểm cân đối giành chiến thắng trước một ứng viên đứng đầu có điểm số cao nhưng bị lệch. Điển hình như trường hợp lớp đứng đầu có thể sở hữu điểm tổng hợp rất cao nhờ sự tương đồng lớn về mặt nguyên mẫu, nhưng lại đánh mất quyền lựa chọn do trượt mức sàn khái niệm. Khi đó, lớp xếp kế tiếp đáp ứng trọn vẹn và đồng đều mọi rào cản sẽ chính thức được hệ thống lựa chọn.

Dựa trên kết quả của quá trình chọn lọc, hệ thống sẽ đưa ra một trong hai phán quyết cuối cùng. Nếu hệ thống tìm được lớp chiến thắng, quyết định chấp nhận (match) sẽ được kích hoạt. Lúc này, hệ thống xác nhận hình ảnh đầu vào thuộc về lớp đã chọn, đồng thời xuất ra độ tin cậy và danh sách các khái niệm hiện diện để làm biên bản giải thích.

Ngược lại, nếu toàn bộ danh sách bị quét cạn mà không có bất kỳ lớp nào vượt qua được hệ thống rào cản, quyết định từ chối tường minh (`no_match`) sẽ được đưa ra. Trong trường hợp này, kết quả trả về sẽ đi kèm với một lý do cụ thể, chỉ rõ ứng viên tiềm năng nhất đã thất bại ở rào cản nào, chẳng hạn như do điểm tổng hợp dưới ngưỡng, số lượng khái niệm được phát hiện quá ít, hoặc đặc điểm cấu trúc quá khác biệt so với ảnh tham chiếu.

Khả năng trả về quyết định từ chối chính là đặc tính cốt lõi giúp phương pháp này xử lý hiệu quả các dữ liệu nằm ngoài phân bố (*out-of-distribution*). Những hình ảnh không thuộc bất kỳ tập hợp lớp nào đã định nghĩa từ trước sẽ bị từ chối một cách an toàn, thay vì bị ép buộc gán vào một nhãn sai lệch như trong các mô hình phân loại đóng. Đặc điểm này đánh dấu sự chuyển dịch quan trọng của cấu trúc hệ thống: bước ra khỏi giới hạn của bài toán phân loại đóng thông thường để tiến tới một cơ chế xác minh linh hoạt, được trang bị năng lực tự chối từ để bảo vệ tính chính xác.

3.1.5 Khả năng giải thích

Điểm ưu việt của kiến trúc đề xuất so với các mạng nơ-ron "hộp đen" truyền thống là khả năng giải thích minh bạch (*interpretability*). Mọi phán quyết của hệ thống đều được minh chứng bằng một biên bản truy vết dựa trên các đặc trưng ngữ nghĩa:

- Đối với quyết định chấp nhận (*Match*): hệ thống xuất ra độ tin cậy tổng thể kèm theo danh sách chi tiết các khái niệm được phát hiện và xác suất hiện diện của chúng. Dữ liệu này cho phép người dùng đối chiếu và kiểm chứng chéo tính logic của thuật toán.
- Đối với quyết định từ chối (*No Match*): hệ thống cung cấp khả năng truy vết nguyên nhân gốc rễ (*root-cause traceability*). Thay vì một thông báo lỗi chung chung, biên bản sẽ chỉ rõ lý do ứng viên tiềm năng nhất bị loại (ví dụ: vi phạm ngưỡng độ phủ khái niệm hoặc trượt mức sàn nguyên mẫu).

Khả năng diễn giải rành mạch này không chỉ củng cố độ tin cậy của mô hình, mà còn đóng vai trò như một công cụ gỡ lỗi (debug) đắc lực, hỗ trợ quản trị viên tinh chỉnh và tối ưu hóa các hồ sơ lớp trong quá trình triển khai thực tế.

3.1.6 Khả năng mở rộng và cập nhật linh hoạt

Khắc phục hạn chế phải huấn luyện lại (retraining) toàn bộ mạng nơ-ron mỗi khi cập nhật dữ liệu của các mô hình phân loại truyền thống, kiến trúc đề xuất cho phép mở rộng quy mô hệ thống một cách linh hoạt. Quản trị viên có thể thêm, bớt hoặc cập nhật các hồ sơ lớp thông qua pha Xây dựng (Builder) và đưa vào luồng xác minh trực tuyến ngay lập tức (hot-swapping) mà không làm gián đoạn hệ thống hay yêu cầu bất kỳ thao tác tái định chuẩn nào.

Bên cạnh đó, tính cô lập của từng hồ sơ lớp cho phép can thiệp tinh chỉnh trọng số khái niệm hoặc cấu hình lại các ngưỡng kiểm định cho từng đối tượng đặc thù một cách độc lập. Đặc tính này mang lại khả năng bảo trì tối ưu, giúp hệ thống dễ dàng thích ứng với sự biến động liên tục của dữ liệu trong môi trường vận hành thực tế.

Tóm lại, phương pháp đề xuất đã xây dựng thành công một kiến trúc xác minh hình ảnh theo hướng tiếp cận zero-shot dựa trên nút thắt khái niệm (Concept Bottleneck), giúp cân bằng hiệu quả giữa hiệu năng đối khớp và tính minh bạch của hệ thống. Bằng cách kết hợp khả năng suy luận của mô hình ngôn ngữ lớn (LLM) và không gian đặc trưng đa phương thức (CLIP), hệ thống tự động hóa hoàn toàn việc khởi tạo hồ sơ lớp, cho phép mở rộng quy mô linh hoạt mà không đòi hỏi quá trình tái huấn luyện. Đặc biệt, quá trình đánh giá bằng chứng khái niệm được tối ưu hóa thông qua kỹ thuật hiệu chuẩn zero-shot nhằm khử nhiễu nền trung tính, kết hợp cùng hàm kích hoạt Sigmoid để tính toán xác suất hiện diện của từng đặc trưng ngữ nghĩa một cách độc lập và chính xác. Cuối cùng, quyết định xác minh được kiểm soát bởi cơ chế cổng lọc đa ngưỡng (Multi-floor Gate) với các rào cản nghiêm ngặt về điểm số tổng hợp, độ phủ khái niệm và độ tương đồng nguyên mẫu. Thiết kế đồng bộ này không chỉ cấp cho hệ thống khả năng từ chối tường minh để xử lý an toàn dữ liệu nằm ngoài phân bố (out-of-distribution), mà

còn đảm bảo mọi phán quyết đều có thể được truy vết và diễn giải rành mạch, đáp ứng trọn vẹn yêu cầu khắt khe của một ứng dụng thực tiễn.

3.2 ĐẶC TẢ KIẾN TRÚC THAM CHIẾU VÀ TIÊU CHÍ KỸ THUẬT KỶ VỌNG CỦA MỘT SẢN PHẨM KHẢ DỤNG TỐI THIỂU (MINIMUM VIABLE PRODUCT)

Nhằm thiết lập một mốc đối chiếu chuẩn phục vụ cho việc đánh giá năng lực lập trình tự động của AI ở các phần sau, nghiên cứu tiến hành đặc tả một sản phẩm khả dụng tối thiểu (Minimum Viable Product - MVP) với tên gọi xplaincv. Sản phẩm này không chỉ là một bản thử nghiệm chứng minh tính khả thi của phương pháp đề xuất, mà còn đóng vai trò là kiến trúc tham chiếu. Nó cụ thể hóa toàn diện hai pha xử lý cốt lõi (Builder và Verify), đồng thời thiết lập tập ràng buộc kỹ thuật tối thiểu mà một hệ thống xác minh hình ảnh có khả năng giải thích bắt buộc phải thỏa mãn.

3.2.1 Kiến trúc tổng thể


Hệ thống được tổ chức theo mô hình client-server phân tầng, trong đó trách nhiệm xử lý được tách bạch rõ ràng qua năm lớp: giao diện người dùng, điều phối API, xử lý nghiệp vụ, suy luận học sâu và lưu trữ.

Tầng giao diện được xây dựng trên nền tảng React kết hợp TypeScript, cung cấp hai không gian làm việc chuyên biệt tương ứng với hai pha xử lý: khu vực Builder cho phép người dùng định nghĩa lớp mới (nhập mô tả, hiệu chỉnh khái niệm, tải lên ảnh tham chiếu); và khu vực Verify cho phép tải lên ảnh truy vấn để nhận kết quả xác minh kèm biên bản giải thích. Tầng giao diện giao tiếp với máy chủ hoàn toàn thông qua giao thức HTTP với định dạng dữ liệu JSON.

Tại máy chủ, tầng điều phối API được hiện thực bằng FastAPI, đảm nhiệm vai trò tiếp nhận yêu cầu, kiểm tra tính hợp lệ của dữ liệu đầu vào và phân phối tải xuống tầng nghiệp vụ. Tầng nghiệp vụ bao gồm các mô-đun độc lập, phụ trách các tác vụ chuyên biệt như: trích xuất khái niệm thông qua LLM, lọc nhiễu, tính toán điểm số xác

minh và quản lý hồ sơ. Đóng vai trò nền tảng bên dưới là tầng suy luận bọc gói mô hình thị giác - ngôn ngữ CLIP, và tầng lưu trữ chịu trách nhiệm duy trì bền vững các hồ sơ lớp trên hệ thống tệp (file system).

Điểm tối ưu quan trọng trong kiến trúc này là mô hình CLIP được tải lên bộ nhớ (RAM/VRAM) một lần duy nhất theo mẫu thiết kế Singleton tại thời điểm khởi động máy chủ và được dùng chung cho toàn bộ các yêu cầu. Thiết kế này giúp giảm thiểu chi phí tính toán của mỗi lượt xác minh xuống chỉ còn thao tác mã hóa ảnh truy vấn và tính toán tích vô hướng, đảm bảo thời gian phản hồi gần với thời gian thực (near real-time). Hơn nữa, việc đóng băng (freeze) trọng số của CLIP giúp thao tác bổ sung lớp mới chỉ tương đương với quá trình trích xuất và lưu trữ vector đặc trưng, hoàn toàn không đòi hỏi chi phí tái huấn luyện.



Hình 3.2: Sơ đồ kiến trúc tổng thể

3.2.2 Các thành phần và luồng xử lý

Thành phần cốt lõi của tầng suy luận là bộ máy mã hóa CLIP, cung cấp hai luồng mã hóa ảnh và văn bản để trích xuất các vector đặc trưng đã chuẩn hóa L2. Nhằm đảm bảo an toàn luồng (thread-safety) khi có nhiều yêu cầu truy cập đồng thời vào một thực thể mô hình duy nhất, hệ thống áp dụng cơ chế khóa luồng (mutex lock) để tuần tự hóa các truy cập. Bộ máy này cũng được tích hợp cơ chế tự động nhận diện phần cứng, ưu tiên sử dụng GPU khi khả dụng và tự động chuyển đổi sang CPU trong trường hợp ngược lại.

Tại tầng nghiệp vụ, luồng xử lý được chia nhỏ:

- Mô-đun trích xuất khái niệm: giao tiếp với LLM bên ngoài để sinh danh sách khái niệm từ mô tả. Nếu dịch vụ gián đoạn, hệ thống cung cấp luồng dự phòng cho phép người dùng nhập thủ công.
- Mô-đun lọc: chịu trách nhiệm tiền xử lý, loại bỏ các khái niệm nhiễu hoặc trùng lặp với tên lớp.
- Mô-đun chấm điểm: thực thi toàn bộ toán lượng của phương pháp zero-shot, bao gồm tính toán xác suất khái niệm, điểm nguyên mẫu, khử nhiễu zero-shot và đối khớp đa ngưỡng.
- Mô-đun quản lý hồ sơ: đảm nhiệm việc tuần tự hóa (serialize) và giải tuần tự (deserialize) dữ liệu.

Về giao thức mạng, hệ thống tuân thủ nghiêm ngặt tiêu chuẩn RESTful API với các lược đồ (schema) định kiểu chặt chẽ. Về phương thức lưu trữ, áp dụng tư tưởng "mỗi lớp một thư mục", mỗi hồ sơ lớp được cô lập trong một thư mục riêng biệt chứa tệp siêu dữ liệu JSON, tệp nhị phân lưu vector đặc trưng và thư mục chứa ảnh tham chiếu gốc. Cách tiếp cận này cho phép thao tác thêm/xóa độc lập, cực kỳ phù hợp với mô hình MVP mà không cần triển khai hệ quản trị cơ sở dữ liệu công kênh.

3.2.3 Tiêu chí kỹ thuật kỳ vọng

Dựa trên đặc tả kiến trúc tham chiếu, hệ thống thiết lập một bộ tiêu chí đánh giá chuẩn mực, chia làm hai nhóm chính:

Nhóm tiêu chí chức năng:

- Hỗ trợ định nghĩa hồ sơ lớp mới zero-shot (không huấn luyện lại).
- Tách bạch rõ ràng và hoàn thiện hai quy trình Builder và Verify.
- Tự động hóa trích xuất khái niệm nhưng phải kèm luồng dự phòng thủ công.
- Kết quả xác minh bắt buộc đi kèm độ tin cậy và biên bản giải thích minh bạch ở cấp độ khái niệm.
- Hệ thống phải có năng lực từ chối tường minh (trả về kết quả "không khớp") đối với ảnh nằm ngoài phân bố, thay vì ép buộc gán nhãn.

Nhóm tiêu chí phi chức năng:

- Độ trễ thấp: phản hồi mượt mà nhờ chiến lược nạp mô hình dùng chung.
- Linh hoạt phần cứng: khả năng vận hành chéo trên cả kiến trúc CPU và GPU.
- Khả năng duy trì hoạt động (Graceful Degradation): hệ thống không được sập toàn cục khi một dịch vụ phụ trợ (như LLM) gặp sự cố hoặc khi một lớp thiếu ảnh tham chiếu, mà chỉ suy giảm tính năng tương ứng.
- Bảo mật và an toàn: kiểm tra chặt chẽ định dạng/kích thước dữ liệu đầu vào và đảm bảo an toàn truy cập đồng thời.

3.2.4 Ranh giới của sản phẩm khả dụng tối thiểu

Tuân thủ đúng triết lý của một MVP, bản tham chiếu chủ đích vạch ra các ranh giới giới hạn nhằm tối ưu hóa chi phí kiểm chứng phương pháp lý thuyết. Cụ thể, hệ thống lưu trữ trực tiếp trên hệ tệp thay vì sử dụng cơ sở dữ liệu chuyên dụng; cơ chế khóa luồng tuần tự chưa được tối ưu hóa cho môi trường chịu tải thông lượng siêu cao (high-throughput); và các ngưỡng quyết định tại cổng lọc đa ngưỡng hiện đang được

thiết lập tính dựa trên kinh nghiệm thay vì học tự động từ dữ liệu. Những ranh giới này không làm suy giảm tính đúng đắn của phương pháp đề xuất mà sẽ đóng vai trò là tiền đề cho các hướng nghiên cứu nâng cấp hệ thống trong tương lai.

3.3 QUY TRÌNH VÒNG LẶP TÍNH CHÍNH


Việc sử dụng mô hình ngôn ngữ lớn để phát triển phần mềm không diễn ra qua một lần ra lệnh duy nhất (one-shot), mà là một quá trình lặp. Rất hiếm khi đầu ra của lần sinh mã đầu tiên thỏa mãn trọn vẹn yêu cầu kiến trúc, do đó cần nhiều vòng đánh giá và tinh chỉnh câu lệnh cho đến khi sản phẩm hội tụ về mốc kỳ vọng. Nghiên cứu này hình thức hóa quá trình đó thành một vòng đời tinh chỉnh lặp (Iterative Prompting Lifecycle), áp dụng thống nhất cho cả phân hệ giao diện (Frontend) lẫn phân hệ máy chủ (Backend).

3.3.1 Tổng quan vòng đời tinh chỉnh

Vòng đời được tổ chức thành một chu trình khép kín gồm năm bước tuần tự, trong đó đầu ra của mỗi vòng lặp trở thành điểm xuất phát để cải thiện ở vòng kế tiếp. Điểm tham chiếu xuyên suốt của toàn bộ chu trình chính là ứng dụng tham chiếu đã được đặc tả. Mọi đánh giá "đạt" hay "không đạt" đều được xác định bằng cách đối chiếu sản phẩm do AI tạo ra với mốc chuẩn này. Chu trình chỉ kết thúc khi sản phẩm thỏa mãn toàn bộ các điều kiện nghiệm thu.

3.3.2 Các bước của vòng đời

Để hiện thực hóa quy trình tinh chỉnh lặp một cách có kiểm soát, nghiên cứu định nghĩa một chu trình khép kín gồm năm bước tuần tự. Cơ chế rẽ nhánh của vòng đời này như sau: đầu ra của mỗi lần sinh mã sẽ phải đi qua một trạm kiểm định khắt khe; mọi điểm nghẽn hoặc sai lệch phát sinh tại đây đều sẽ kích hoạt một vòng lặp tinh chỉnh mới. Quá trình này đảm bảo sản phẩm liên tục tiến hóa và chỉ thoát khỏi chu trình khi đã đạt điểm hội tụ với yêu cầu gốc.



Hình 3.3: Vòng lặp tinh chỉnh sử dụng prompt

- Bước 1 - Khởi tạo câu lệnh ban đầu: mỗi phân hệ được khởi động bằng một câu lệnh mô tả yêu cầu ở mức tổng quát, bao gồm: phạm vi chức năng, công nghệ nền tảng, ràng buộc kiến trúc và kết quả mong đợi. Câu lệnh này đóng vai trò thiết lập bối cảnh (context) cho mô hình, định hình khung sản phẩm trước khi đi sâu vào các chi tiết nghiệp vụ.
- Bước 2 - Sinh và kiểm thử mã nguồn đầu ra: mô hình tiến hành sinh mã nguồn tương ứng với câu lệnh. Đầu ra này lập tức được đưa vào môi trường thực thi cục bộ để kiểm thử: biên dịch, chạy thử và quan sát hành vi thực tế. Mục tiêu của bước này là xác lập một bằng chứng khách quan về trạng thái hiện tại của phần mềm, thay vì chỉ đánh giá mã nguồn trên phương diện hình thức văn bản.
- Bước 3 - Phân tích và đối chiếu với ứng dụng kỳ vọng: hành vi và cấu trúc của đầu ra được đối chiếu trực tiếp với Ứng dụng kỳ vọng theo các phương diện đã định nghĩa: mức độ đáp ứng yêu cầu kỹ thuật, tính đúng đắn của luồng nghiệp vụ và độ phù hợp của thiết kế giao diện. Kết quả thu được là một danh sách phân loại rõ ràng các yếu tố "đạt" (khớp mốc kỳ vọng, cần giữ nguyên) và "không đạt" (sai lệch, thiếu sót hoặc sinh lỗi, cần khắc phục).
- Bước 4 - Tinh chỉnh câu lệnh: dựa trên danh sách "không đạt", câu lệnh được cập nhật và bổ sung để dẫn hướng mô hình khắc phục các sai lệch. Quá trình này bao gồm việc làm rõ những yêu cầu AI đang hiểu sai, bổ sung các ràng buộc còn thiếu, hoặc chỉ định cụ thể cách xử lý ngoại lệ. Đặc trưng cốt lõi của nghiên cứu là toàn bộ sự can thiệp chỉ diễn ra ở cấp độ kỹ sư câu lệnh (prompt engineering), tuyệt đối không có thao tác viết mã thủ công, nhằm bảo đảm sản phẩm cuối cùng phản ánh chân thực năng lực lập trình tự động của mô hình.
- Bước 5 - Lặp và nghiệm thu: câu lệnh đã tinh chỉnh được đưa trở lại Bước 2, mở ra một vòng lặp mới. Quá trình này tiếp diễn cho đến khi sản phẩm không còn yếu tố "không đạt" trọng yếu so với ứng dụng kỳ vọng. Khi đó, vòng đời khép lại và phần mềm được ghi nhận làm kết quả chính thức của phân hệ tương ứng.

3.3.3 Áp dụng cho hai phân hệ Frontend và Backend

Vòng đời tinh chỉnh lặp được triển khai cho cả hai phân hệ, song mỗi phân hệ sở hữu trọng tâm đánh giá riêng biệt phù hợp với bản chất kỹ thuật:

- Đối với Backend: các yếu tố đánh giá tập trung vào tính đúng đắn của thuật toán zero-shot, sự tuân thủ hợp đồng API (RESTful), logic quản lý hệ tệp và khả năng duy trì ổn định (thread-safety) khi thực thi tải thực tế.
- Đối với Frontend: việc đánh giá nghiêng về độ trung thực của bố cục hiển thị, luồng tương tác (UX/UI) của người dùng, cách thức quản lý trạng thái (state management) và khả năng bắt đúng các phản hồi lỗi từ API.

Đặc biệt, do tính chất phụ thuộc lẫn nhau - giao diện cần một máy chủ vận hành đúng logic để kiểm thử luồng dữ liệu - thực nghiệm ưu tiên thiết lập Backend đạt trạng thái hoàn thiện trước. Sau khi API đã sẵn sàng và ổn định, quá trình tinh chỉnh Frontend mới được tiến hành trên nền tảng đó. Mỗi phân hệ dù trải qua chu trình năm bước một cách độc lập, nhưng luôn chia sẻ một mốc đối chiếu duy nhất là Ứng dụng kỳ vọng, bảo đảm tính nhất quán và toàn vẹn của toàn bộ hệ thống xplaincv.

Tóm lại, nền tảng phương pháp luận cho bài toán xác minh hình ảnh zero-shot đã được thiết lập một cách toàn diện dựa trên kiến trúc Concept Bottleneck, qua đó đảm bảo tính minh bạch và khả năng giải thích rành mạch cho từng phán quyết của hệ thống. Nhằm kiểm chứng tính khả thi của mô hình lý thuyết này trong thực tiễn, một khung thực nghiệm đánh giá năng lực phát triển phần mềm tự động của trí tuệ nhân tạo đã được định hình. Việc đặc tả chi tiết kiến trúc tham chiếu cho một sản phẩm khả dụng tối thiểu cung cấp một mốc đối chiếu (ground truth) khách quan và nghiêm ngặt. Phối hợp cùng mốc chuẩn này là một vòng đời tinh chỉnh lặp (Iterative Prompting Lifecycle) khép kín gồm năm bước tuần tự, giúp điều phối và kiểm soát chặt chẽ quá trình sinh mã nguồn. Sự gắn kết giữa bộ tiêu chí kỹ thuật rõ ràng và quy trình kỹ nghệ câu lệnh có tính hệ thống đảm bảo quá trình phát triển phần mềm không diễn ra một cách ngẫu nhiên, mà hoàn toàn có thể đo lường và kiểm chứng định lượng. Toàn bộ nền tảng phương pháp

luận này tạo ra một tiền đề vững chắc, sẵn sàng cho công tác triển khai cài đặt và phân tích kết quả thực nghiệm ở giai đoạn tiếp nối.

CHƯƠNG 4 THỰC NGHIỆM VÀ KẾT QUẢ

4.1 KẾT QUẢ MÔ HÌNH ZERO-SHOT CBM

4.1.1 Bộ dữ liệu và giao thức

Để đánh giá đồng thời độ chính xác và khả năng tổng quát hóa của hệ thống, mô hình được thực nghiệm trên sáu bộ dữ liệu, gồm năm bộ benchmark chuẩn và một bộ tự xây dựng. Năm bộ benchmark chuẩn được lựa chọn nhằm bao phủ nhiều miền ảnh khác biệt, qua đó kiểm tra tính ổn định của phương pháp khi chuyển miền: Caltech-101 (vật thể tổng quát, ảnh đời thực nhiều nền), Oxford Flowers-102 và Oxford-IIIT Pet (phân loại mịn, fine-grained giữa các loài hoa và giống chó/mèo có hình thái gần nhau), DTD (kết cấu) và EuroSAT (ảnh vệ tinh). Đây đều là các bộ dữ liệu được sử dụng phổ biến trong các nghiên cứu về mô hình thị giác-ngôn ngữ, cho phép so sánh kết quả với mặt bằng đã công bố. Bộ dữ liệu thứ sáu là Custom-Set, do nhóm nghiên cứu tự xây dựng, gồm các ảnh có chủ thể rõ ràng. Bộ này không nhằm mục đích benchmark mà để mô phỏng kịch bản sử dụng thực tế, khi người dùng chủ động cung cấp ảnh sản phẩm sạch để cấu hình hệ thống.

Giao thức đánh giá được giữ thống nhất cho cả sáu bộ. Với mỗi lớp, ba ảnh tham chiếu được dùng để xây dựng hồ sơ đại diện (profile) của lớp, bao gồm véc-tơ nguyên mẫu (prototype) và tập khái niệm trực quan được trích xuất tự động. Các ảnh còn lại được giữ làm tập truy vấn độc lập (held-out query set), tối đa 25 ảnh mỗi lớp đối với các bộ chuẩn. Việc tách rời ảnh xây dựng profile khỏi ảnh đánh giá đảm bảo không xảy ra rò rỉ dữ liệu trong thực nghiệm. Thống kê chi tiết của sáu bộ dữ liệu được trình bày trong Bảng 4.1.


Bảng 4.1: Thống kê các bộ dữ liệu

Bộ dữ liệu	Loại ảnh	Số lớp	Số ảnh tham chiếu mỗi lớp	Số ảnh truy vấn
Caltech-101	Vật thể tổng quát, ảnh đời thực có nhiều nền	100	3	1.975
Oxford Flowers-102	các loài hoa	102	3	2.487
Oxford-IIIT Pet	các giống chó và mèo	37	3	925
DTD	Kết cấu bề mặt	47	3	1.175
EuroSAT	Ảnh vệ tinh viễn thám	10	3	250
Custom-set	Ảnh thu thập từ web, chủ thể rõ ràng	100	3	495

4.1.2 Kết quả định tính


Khác với các mô hình phân loại truyền thống chỉ đưa ra nhãn dự đoán cuối cùng, hệ thống đề xuất cung cấp thêm thông tin giải thích cho quá trình ra quyết định. Đối với mỗi ảnh truy vấn và một lớp mục tiêu, hệ thống trả về quyết định xác minh (khớp hoặc không khớp), điểm xác minh tương ứng và mức độ hiện diện của từng concept cấu thành lớp đó. Nhờ vậy, người dùng không chỉ biết kết quả cuối cùng mà còn có thể hiểu được cơ sở dẫn đến quyết định của mô hình.

Hình 4.1 minh họa mức độ quan trọng của các concept đối với một lớp cụ thể. Mỗi concept được gán một trọng số phản ánh mức độ đóng góp của nó vào quá trình xác minh. Chẳng hạn, đối với lớp "banana", các concept như curved shape và yellow peel có trọng số cao hơn so với các concept mang tính khái quát hơn. Các trọng số này được sử dụng để tổng hợp thông tin concept và tạo thành điểm xác minh cuối cùng của hệ thống.



Hình 4.1: Trọng số các concept của class banana

Bên cạnh trọng số của concept, hệ thống còn cung cấp thông tin về mức độ hiện diện của từng concept trên các ảnh đầu vào. Hình 4.2 trình bày bản đồ nhiệt thể hiện mức kích hoạt của các concept đối với một số trường hợp xác minh điển hình. Các ảnh thuộc đúng lớp thường kích hoạt mạnh các concept đặc trưng của lớp đó, trong khi các ảnh khác lớp có xu hướng chỉ kích hoạt một số concept chung hoặc đạt mức kích hoạt thấp.



Hình 4.2: Bản đồ nhiệt mức độ hiện diện của concept

Ví dụ, đối với lớp "banana", các ảnh đúng lớp thể hiện mức hiện diện cao ở các concept như "yellow peel" hoặc "curved shape". Ngược lại, mặc dù một số loại trái cây khác có thể chia sẻ các concept mang tính tổng quát như "fruit", chúng vẫn được phân biệt thông qua các concept đặc trưng của lớp mục tiêu. Chẳng hạn, ảnh "strawberry" có thể kích hoạt concept liên quan đến trái cây nhưng có mức hiện diện rất thấp đối với concept "yellow peel", từ đó dẫn đến quyết định không khớp.

Các kết quả định tính trên cho thấy quá trình ra quyết định của hệ thống được hình thành thông qua những concept có ý nghĩa ngữ nghĩa rõ ràng, thay vì dựa trên các đặc trưng tiềm ẩn khó diễn giải. Điều này phản ánh đúng tinh thần của Concept Bottleneck Model, đồng thời mang lại khả năng giải thích và kiểm chứng quyết định của mô hình trong quá trình sử dụng thực tế. Ngoài ra, do người dùng có thể quan sát và đánh giá mức độ phù hợp của từng concept, hệ thống tạo điều kiện thuận lợi cho việc can thiệp và điều chỉnh khi cần thiết. Đây là một ưu điểm quan trọng trong các ứng dụng yêu cầu tính minh bạch và khả năng giải trình của mô hình trí tuệ nhân tạo.

4.1.3 Kết quả và phân tích

4.1.3.1 Kết quả xác minh một-lớp (One-Class Verification)

Để đánh giá toàn diện hiệu năng của mô hình đề xuất, nghiên cứu tiến hành phân tích kết quả theo ba hướng. Thứ nhất, khả năng xác minh của hệ thống được đánh giá thông qua các độ đo đặc trưng cho bài toán xác minh một-lớp. Thứ hai, kết quả phân loại đóng được báo cáo nhằm cung cấp thêm góc nhìn tham chiếu về năng lực nhận diện của mô hình. Cuối cùng, ảnh hưởng của chất lượng ảnh đầu vào đến hiệu năng hệ thống được khảo sát thông qua việc so sánh hai kịch bản dữ liệu khác nhau. Bảng 4.2 trình bày kết quả đánh giá khả năng xác minh của mô hình trên sáu bộ dữ liệu.


Bảng 4.2: Kết quả xác minh với 3 ảnh tham chiếu mỗi lớp

Bộ dữ liệu	Macro ROC-AUC	EER	FAR
Caltech-101	0,981	5,7%	2,1%
Oxford Flowers-102	0,973	6,4%	14,7%
Oxford-IIIT Pet	0,884	18,7%	20,2%
DTD	0,851	22,4%	38,8%
EuroSAT	0,880	18,6%	32,3%
Custom-Set	0,983	3,4%	1,1%

Chỉ số đầu tiên, ROC-AUC, đo khả năng hệ thống phân tách ảnh đúng lớp khỏi ảnh khác lớp trên toàn bộ dải ngưỡng quyết định giá trị càng gần 1 càng tốt. Trên các bộ ảnh vật thể tổng quát (Caltech-101, Custom-Set) và hoa (Flowers-102), ROC-AUC đạt xấp xỉ 0,97–0,98, cho thấy không gian đặc trưng do hệ thống dựng lên tách hai nhóm gần như hoàn hảo. Ở các miền khó hơn — chó/mèo phân loại mịn (Oxford-Pet), kết cấu (DTD) và ảnh vệ tinh (EuroSAT) — giá trị giảm còn 0,85–0,88, phản ánh việc các lớp trong những miền này có đặc trưng thị giác gần nhau, khó tách hơn.

Chỉ số thứ hai, EER (Equal Error Rate), là mức lỗi tại điểm mà tỷ lệ chấp nhận nhầm và từ chối nhầm bằng nhau; vì không gắn với một ngưỡng cụ thể, EER được dùng làm thước đo tổng quát để so sánh giữa các bộ. EER thấp nhất trên Custom-Set (3,4%) và Caltech-101 (5,7%), và cao hơn đáng kể trên DTD (22,4%) — đồng nhất với xu hướng của ROC-AUC.

Chỉ số FAR (False Acceptance Rate) là tỷ lệ chấp nhận nhầm ảnh không thuộc lớp được báo cáo tại ngưỡng vận hành thực tế của ứng dụng (0,55). Trên các miền dễ, FAR rất thấp (Custom-Set 1,1%, Caltech-101 2,1%), tức hệ thống hiếm khi nhận nhầm. Trên DTD và EuroSAT, FAR tại ngưỡng cố định này tăng cao (32–39%), cho thấy một ngưỡng duy nhất không phù hợp đồng đều cho mọi miền — đây cũng là lý do EER (không phụ thuộc ngưỡng) được ưu tiên làm chỉ số so sánh.



Hình 4.3: Phân bố ROC-AUC xác minh theo từng lớp trên các bộ dữ liệu

Hình 4.3 biểu diễn phân bố ROC-AUC của từng lớp (thay vì chỉ giá trị trung bình), qua đó cho thấy độ ổn định của hệ thống: ở Caltech-101, Flowers-102 và Custom-Set, phần lớn các lớp tập trung sát mức 1,0 với rất ít ngoại lệ; trong khi ở DTD, phân bố trải rộng xuống tới khoảng 0,62, cho thấy một số lớp kết cấu rất khó xác minh.

4.1.3.2 Kết quả phân loại đóng


Mặc dù trọng tâm là xác minh, kết quả phân loại đóng vẫn được báo cáo để tham chiếu. Ở đây, cơ chế công quyết định là bắt buộc: một dự đoán chỉ được chấp nhận khi vượt đồng thời các ngưỡng về điểm số và độ phủ khái niệm, nếu không mẫu bị đưa vào nhóm từ chối (no-match).

Bảng 4.3: Kết quả phân loại đóng

Bộ dữ liệu	Top-1 Accuracy	Misclassification Rate	Rejection Rate	Macro-F1
Caltech-101	53,7%	22,1%	24,2%	0,565
Oxford Flowers-102	43,2%	53,4%	3,4%	0,427
Oxford-IIIT Pet	34,5%	52,9%	12,6%	0,336
DTD	26,6%	68,8%	4,6%	0,251
EuroSAT	45,6%	41,6%	12,8%	0,458
Custom-Set	62,0%	14,3%	23,6%	0,688

Trong đó Top-1 là tỷ lệ ảnh được dự đoán đúng ngay ở lớp xếp hạng cao nhất, nhầm lẫn là tỷ lệ chấp nhận nhưng sai lớp, từ chối là tỷ lệ bị công loại; ba giá trị cộng lại bằng 100%. Macro-F1 là trung bình F1 trên các lớp. Trên Caltech-101, Top-1 đạt

53,7%, nằm đúng khoảng đã công bố cho dòng Zero-shot Concept Bottleneck Model (CLIP zero-shot ~53,73%; ZCBM 52,6–54,3%), xác nhận hệ thống đạt đúng mặt bằng phương pháp. Hình 4.4 so sánh trực quan tỷ lệ đúng và nhầm lẫn giữa các bộ.



Hình 4.4: Tỷ lệ dự đoán đúng (Top-1) và nhầm lẫn trên các bộ dữ liệu.

Qua Hình 4.4 có thể thấy rõ sự phân hóa giữa các miền dữ liệu. Trên Caltech-101 và đặc biệt là Custom-Set, cột "đúng" (xanh) cao vượt hẳn cột "nhầm lẫn" (đỏ), cho thấy số dự đoán đúng cao hơn số dự đoán sai từ 2 đến 4 lần. Ngược lại, ở Flowers-102, Oxford-Pet và đặc biệt là DTD, cột đỏ vượt lên trên cột xanh, phản ánh việc hệ thống nhầm lẫn nhiều hơn số trường hợp dự đoán đúng; riêng EuroSAT ở trạng thái gần cân bằng. Khoảng cách giữa hai cột vì vậy phản ánh trực quan mức độ an toàn của hệ thống trên từng miền dữ liệu: các lớp đối tượng hoặc sản phẩm có đặc trưng thị giác rõ ràng thường đạt tỷ lệ nhận dạng đúng cao và ít nhầm lẫn hơn.

Kết hợp kết quả từ các bảng và biểu đồ cho thấy hiệu năng của hệ thống phụ thuộc mạnh vào đặc thù miền dữ liệu. Hệ thống hoạt động tốt và ổn định trên ảnh vật thể tổng quát (Caltech-101, Custom-Set), đồng thời đạt khả năng xác minh cao trên Flowers-102 (AUC = 0,973). Tuy nhiên, hiệu năng suy giảm đáng kể trên các bài toán

phân loại mịn (Oxford-Pet) và nhận dạng kết cấu (DTD), nơi tỷ lệ nhầm lẫn vượt quá tỷ lệ dự đoán đúng. Nguyên nhân xuất phát từ chính cơ chế của phương pháp: hệ thống dựa trên các khái niệm thị giác như màu sắc, hình dạng và bộ phận để thực hiện xác minh. Với các đối tượng đời thường, những khái niệm này có khả năng phân tách lớp hiệu quả; ngược lại, đối với các lớp có mức độ tương đồng cao như các giống chó gần giống nhau hoặc các mẫu kết cấu tương tự, tập khái niệm trở nên chồng lấn và khó phân biệt, khiến cả CLIP zero-shot lẫn tầng khái niệm đều gặp hạn chế. Đây cũng là thách thức đã được ghi nhận rộng rãi trong các nghiên cứu zero-shot learning trên dữ liệu fine-grained.

Bên cạnh đó, cơ chế cổng quyết định cho thấy vai trò quan trọng trong việc nâng cao độ an toàn của hệ thống. Trên các miền dữ liệu thuận lợi, cơ chế này giúp duy trì tỷ lệ nhầm lẫn ở mức thấp (14,3% trên Custom-Set và 22,1% trên Caltech-101) bằng cách chuyển các trường hợp có độ tin cậy thấp sang nhóm từ chối. Tuy nhiên, đối với các miền dữ liệu khó, khi bằng chứng khái niệm vốn đã không đủ mạnh, cơ chế cổng không thể bù đắp hoàn toàn hạn chế của mô hình. Tổng thể, kết quả thực nghiệm cho thấy phương pháp phù hợp nhất với các bài toán xác minh vật thể hoặc sản phẩm có đặc trưng thị giác rõ ràng, đúng với kịch bản mà Custom-Set mô phỏng và cũng là miền dữ liệu mà hệ thống đạt hiệu năng cao nhất.

4.2 KẾT QUẢ NGHIÊN CỨU PHÁT TRIỂN PHẦN MỀM BẰNG LLM

Phần này tập trung đánh giá quy trình ứng dụng mô hình ngôn ngữ lớn trong quá trình phát triển phần mềm, với công cụ chính được sử dụng là Claude Code. Nội dung đánh giá bao gồm thiết lập thực nghiệm, phương pháp triển khai, cũng như phân tích các kết quả thu được trong quá trình phát triển ứng dụng.

4.2.1 Thiết lập và phương pháp

Đối tượng và công cụ: Ứng dụng xplaincv - bao gồm phân hệ Backend (Python, FastAPI) và Frontend (React, TypeScript) - được phát triển hoàn toàn thông qua tương tác bằng ngôn ngữ tự nhiên với công cụ Claude Code, và không có thao tác viết mã thủ

công của con người. Vai trò của người thực hiện là đặc tả yêu cầu, kiểm thử đầu ra và tinh chỉnh câu lệnh qua từng vòng lặp, tuân thủ nghiêm ngặt quy trình tinh chỉnh lặp đã trình bày.

Quá trình phát triển được đánh giá dựa trên lịch sử commit của ứng dụng (nhánh `xplainev-mvp-history`). Trong đó, commit khởi tạo chứa nguyên văn câu lệnh khởi tạo (`prompt init`) - đặc tả đầy đủ mục tiêu, công nghệ và yêu cầu; mỗi commit kế tiếp tương ứng với một bước sửa lỗi hoặc cải tiến trong vòng đời tinh chỉnh lặp, đi kèm thay đổi mã nguồn cụ thể. Cách biểu diễn này cô đọng và có cấu trúc hơn nhật ký tương tác thô - vốn chứa nhiều câu lệnh phụ trợ (chào hỏi, hỏi tiến độ, thao tác lặp lại hoặc hoàn tác) không phản ánh trực tiếp tiến trình kỹ thuật - nên được chọn làm cơ sở phân tích chính.

Mức độ bám sát ứng dụng kỳ vọng được đối chiếu theo bộ tiêu chí chuẩn mực đã thiết lập. Trong đó, nhóm tiêu chí chức năng bao gồm: định nghĩa hồ sơ lớp zero-shot không cần huấn luyện lại; tách bạch hai quy trình Builder và Verify; tự động trích xuất khái niệm kèm luồng dự phòng thủ công; kết quả xác minh đi kèm độ tin cậy và biên bản giải thích ở cấp độ khái niệm; và năng lực từ chối tường minh với ảnh ngoài phân bố. Nhóm tiêu chí phi chức năng bao gồm: độ trễ thấp nhờ nạp mô hình dùng chung; linh hoạt chạy chéo kiến trúc CPU/GPU; khả năng duy trì hoạt động (*graceful degradation*) khi một dịch vụ phụ trợ gặp sự cố; và đảm bảo an toàn đầu vào cũng như truy cập đồng thời. Ngoài ra, thực nghiệm ghi nhận số vòng lặp và bản chất của từng can thiệp để phản ánh đặc tính lặp của phương pháp.

4.2.2 Kết quả và phân tích

4.2.2.1 Quá trình phát triển

Bảng 4.4 trình bày chuỗi commit của quá trình hiện thực hóa hệ thống. Dữ liệu quan sát cho thấy một câu lệnh khởi tạo duy nhất đã đủ điều kiện để sinh ra bộ khung ứng dụng khả thi ban đầu, bao phủ phần lớn các yêu cầu chức năng cơ bản. Quá trình phát triển ở các vòng lặp tiếp theo chủ yếu tập trung vào việc tinh chỉnh logic quyết định và nâng cao chất lượng khái niệm, không phát sinh nhu cầu tái cấu trúc toàn bộ hệ thống.

Bảng 4.4: Quá trình lịch sử xây dựng ứng dụng


#	Loại	Nội dung thực thi	Bước phát triển
1	feat	Khởi tạo bộ khung ứng dụng (FastAPI + CLIP + React) từ prompt init	Khởi tạo
2	feat	Tinh chỉnh trích xuất khái niệm bằng LLM (chỉ thuộc tính thị giác)	Cải tiến
3	feat	Thêm nguyên mẫu ảnh, hiệu chuẩn LOO và trọng số quan trọng	Cải tiến
4	feat	Tích hợp cơ chế từ chối "no_match" khi điểm cao nhất dưới ngưỡng	Sửa/Hoàn thiện
5	fix	Hỗ trợ mở rộng định dạng ảnh đầu vào (AVIF...)	Sửa lỗi
6	fix	Nâng ngưỡng đối khớp để giảm tỷ lệ chấp nhận nhầm (False Positive)	Sửa lỗi
7	feat	Bổ sung cơ chế lọc nhiễu khái niệm trước khi nhúng vector	Cải tiến
8	feat	Xây dựng công lọc đa sàn (per-evidence floors và độ phủ)	Cải tiến

9	fix	Hiệu chỉnh sản độ phủ nhằm từ chối ảnh thiếu hụt khái niệm	Sửa lỗi
10	feat	Áp dụng cơ chế chống vọng lại tên lớp (anti-echo)	Cải tiến
11	feat	Nâng cấp giao diện người dùng	Cải tiến
12	docs	Hoàn thiện tài liệu và kịch bản triển khai cục bộ	Hoàn tất

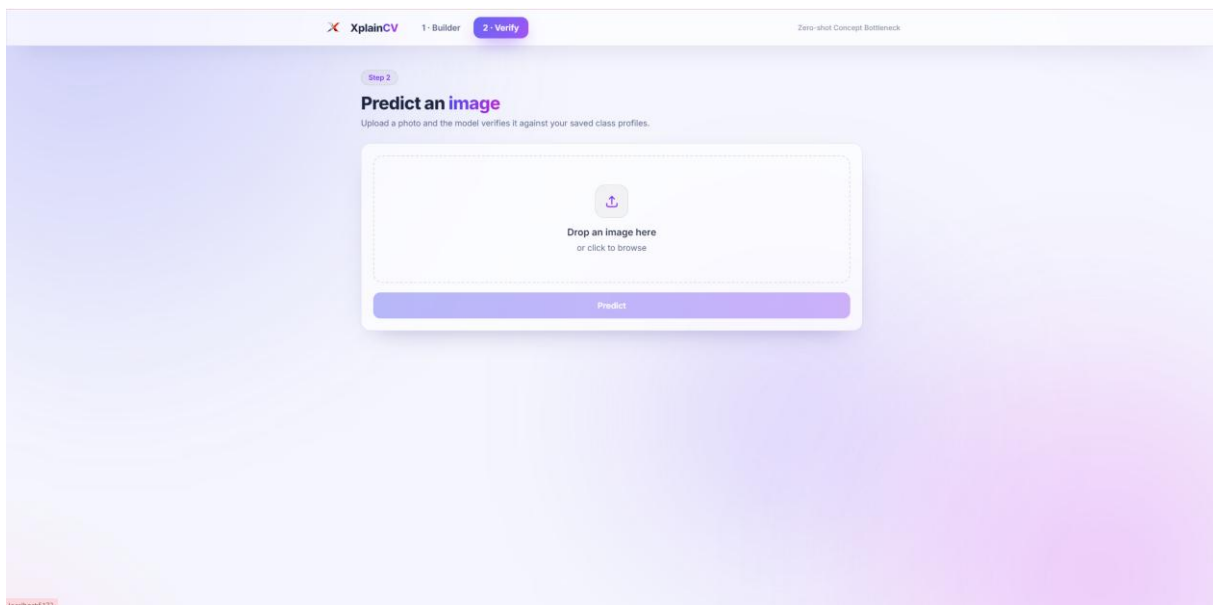
4.2.2.2 Mức độ đáp ứng kỳ vọng

Sau khi đối chiếu với bộ tiêu chí tham chiếu đã được định nghĩa ở trên, kết quả thực nghiệm cho thấy có sự phân chia rõ rệt giữa hai nhóm yêu cầu:

- Nhóm yêu cầu được đáp ứng từ đầu (từ prompt khởi tạo): các yêu cầu mang tính xây dựng cấu trúc được LLM hiện thực chính xác ngay từ câu lệnh đầu tiên. Về mặt chức năng, hệ thống đã dựng được thành công hai quy trình Builder và Verify, cho phép định nghĩa hồ sơ lớp zero-shot, và hỗ trợ trích xuất khái niệm tự động kèm luồng dự phòng. Tương tự, phần lớn tiêu chí phi chức năng cũng được thỏa mãn sớm: đạt độ trễ thấp nhờ chiến lược nạp mô hình dùng chung, thiết lập linh hoạt môi trường CPU/GPU, đảm bảo khả năng duy trì hoạt động (vẫn vận hành khi thiếu LLM hoặc thiếu ảnh tham chiếu) và kiểm tra an toàn dữ liệu đầu vào. Điều này chứng tỏ mô hình ngôn ngữ lớn nắm bắt rất tốt các khuôn mẫu kiến trúc phần mềm phổ biến từ một đặc tả bằng ngôn ngữ tự nhiên.



(a)




(b)

Hình 4.5: (a), (b) Kết quả giao diện được Claude code xây dựng

Hình 4.5 là minh chứng trực quan cho năng lực này: giao diện người dùng (UI) được xây dựng mạch lạc với các phân hệ 'Profile Builder' và 'Verify' tách biệt, phản ánh

chính xác yêu cầu về phân luồng nghiệp vụ. Việc AI tự động thiết lập bố cục các thành phần điều khiển và luồng tương tác một cách logic từ prompt ban đầu khẳng định rằng LLM không chỉ dừng lại ở việc sinh mã nguồn backend, mà còn có khả năng chuyển hóa đặc tả cấu trúc thành một giao diện người dùng hoàn thiện và tuân thủ đúng các tiêu chuẩn thiết kế phần mềm.

- Nhóm yêu cầu chỉ được đáp ứng sau nhiều lần tinh chỉnh: trái ngược với sự dễ triển khai của yêu cầu về kiến trúc thì các yêu cầu gắn liền với logic suy luận và cơ chế ra quyết định bắt buộc phải trải qua nhiều vòng lặp tinh chỉnh. Tiêu biểu nhất là năng lực từ chối tường minh đối với các hình ảnh nằm ngoài phân bố. Từ trạng thái ban đầu có xu hướng ép gán nhãn bằng cách luôn chọn lớp có điểm số cao nhất, hệ thống đã phải trải qua một chuỗi nâng cấp liên tục thông qua việc thiết lập và nâng dần ngưỡng từ chối nhằm giảm thiểu tỷ lệ chấp nhận nhầm, trước khi tiến tới tích hợp kiến trúc công lọc đa sàn và hiệu chỉnh ngưỡng độ phủ. Tương tự, do chất lượng của biên bản giải thích phụ thuộc trực tiếp vào độ sạch của dữ liệu, quy trình phát triển đã phải thực hiện các vòng can thiệp bổ sung nhằm xây dựng cơ chế lọc nhiễu và chống hiện tượng tự quy chiếu (vòng lại) tên lớp sau khi pha kiểm thử làm lộ ra các khái niệm rác. Diễn tiến này khẳng định một thực tế quan trọng: chính phần giá trị cốt lõi nhất của ứng dụng — bao gồm năng lực quyết định xác minh và tính minh bạch — lại là thách thức lớn nhất đối với mô hình ngôn ngữ lớn. Những logic phân nhánh phức tạp này không thể được hiện thực hóa trọn vẹn trong một lần sinh mã, mà bắt buộc phải dựa vào vòng đời kiểm thử và tinh chỉnh liên tục dưới sự dẫn dắt của con người.



Hình 4.6: Kết quả logic xử lý AI xác minh

Hình 4.6 là minh chứng trực quan nhất cho năng lực giải thích của hệ thống sau khi đã hoàn thiện logic xác minh. Kết quả dự đoán 'dog' với độ tin cậy 97% không tồn tại độc lập mà được củng cố bởi danh sách các khái niệm trung gian (như 'four legs', 'furry coat', 'snout'...) với mức kích hoạt cụ thể. Điều này xác nhận rằng hệ thống đã hiện thực hóa thành công kiến trúc Zero-shot CBM: loại bỏ tính 'hộp đen' của mô hình học sâu truyền thống bằng cách phơi bày toàn bộ quá trình suy luận dựa trên các đặc trưng thị giác có ý nghĩa. Sự phản hồi này không chỉ giúp người dùng tin tưởng vào quyết định của máy, mà còn chứng minh rằng logic xác minh do các tác tử xây dựng đã đáp ứng chính xác các đặc tả kỹ thuật khắt khe về tính minh bạch đã đặt ra.

4.2.2.3 Đánh giá tổng quan

Qua quá trình khởi tạo và vòng lặp tinh chỉnh và đối chiếu kết quả với yêu cầu kỹ thuật thì có thể đánh giá về năng lực cũng như giới hạn của mô hình ngôn ngữ lớn trong quy trình phát triển phần mềm như sau:

- Ưu điểm: thực nghiệm cho thấy sức mạnh nổi bật của mô hình ngôn ngữ lớn nằm ở khả năng khởi tạo nhanh chóng một bộ khung ứng dụng hoàn chỉnh và khả thi chỉ từ một bản đặc tả bằng ngôn ngữ tự nhiên. Đồng thời, mô hình thể hiện năng lực tiếp thu rất tốt các tiêu chuẩn về chất lượng mã nguồn (như nguyên tắc mã sạch, tối giản hóa mã lặp) và có độ linh hoạt cao khi cần thực thi các thay đổi kiến trúc quy mô lớn.
- Hạn chế: chất lượng mã nguồn đầu ra có tỷ lệ thuận tuyệt đối với độ tường minh và mức độ chi tiết của câu lệnh yêu cầu. Những đặc tả thiếu rõ ràng thường dẫn đến các lỗi logic ngầm chỉ bộc lộ khi đưa vào vận hành. Bên cạnh đó, nếu không có các ràng buộc kỹ thuật được thiết lập chặt chẽ từ người điều phối, mô hình có xu hướng phức tạp hóa thiết kế hệ thống mức cần thiết.

Từ những phân tích trên, có thể nhận định rằng mô hình ngôn ngữ đóng vai trò như một cộng sự đắc lực giúp tăng tốc độ hiện thực hóa bộ khung phần mềm. Tuy nhiên, giới hạn cốt lõi của AI hiện tại là không có khả năng tự phát hiện các sai lệch về mặt ngữ nghĩa nghiệp vụ. Phần lớn các cải tiến mang tính đột phá của hệ thống như xử lý ngoại lệ định dạng ảnh mới, thiết lập cơ chế chống tự quy chiếu tên lớp, hay chuỗi tinh chỉnh công quyết định đa ngưỡng đều chỉ xuất hiện sau khi quá trình kiểm thử thực tế làm lộ ra sai số. Do đó, đối với các phân hệ mang tính chất suy luận và ra quyết định, khâu kiểm thử và dữ liệu phản hồi từ con người là yếu tố tiên quyết. Vòng đời "đặc tả - kiểm thử - tinh chỉnh" do kỹ sư dẫn dắt chính là minh chứng rõ nét nhất cho mô hình hợp tác người - AI hiệu quả, nơi máy móc đảm nhận việc sinh mã, còn con người giữ vững vai trò định hướng và thẩm định chất lượng cuối cùng.

4.2.3 Phát triển bằng đội tác nhân

Bên cạnh quy trình tinh chỉnh lập đơn lẻ, quá trình phát triển còn mở rộng sang cơ chế điều phối đa tác tử (agent team) thông qua Claude Code để song song hóa công việc. Theo mô hình tác tử điều phối - tác nhân chuyên trách: một tác tử điều phối đảm nhận việc nhận đặc tả tổng thể, hoạch định kiến trúc, xác lập giao kèo API (danh sách điểm cuối và lược đồ JSON), sau đó phân rã bài toán thành ba tuyến thực thi song song:

- Tác nhân con backend: hiện thực hóa dịch vụ FastAPI, tích hợp CLIP, xây dựng cơ chế Builder/Verify và các điểm cuối (endpoints) REST.
- Tác nhân con frontend: xây dựng giao diện trên nền tảng React/Vite/Tailwind với cấu trúc hai tab, thực hiện tương tác với API và trực quan hóa các quyết định cùng thanh giải thích khái niệm.
- Tác nhân con kiểm thử: sinh mã và thực thi các bộ kiểm thử đơn vị (unit test) cho logic chấm điểm/cổng quyết định; kiểm thử tích hợp cho luồng tạo hồ sơ → xác minh; và kiểm thử biên (boundary testing) cho khả năng từ chối (đảm bảo ảnh ngoài phân bố trả về kết quả no_match).

Nhờ giao kèo API xác định từ đầu, frontend và backend phát triển độc lập trên không gian cô lập, loại bỏ xung đột tệp. Quy trình kiểm thử được nội bộ hóa: tác tử Kiểm thử phản hồi lỗi trực tiếp đến tác tử phụ trách, giúp con người tập trung thiết lập tiêu chí nghiệm thu thay vì can thiệp thủ công.

Mô hình này đặc biệt tối ưu cho các phân hệ có ranh giới rõ ràng. Ngược lại, các phần logic quyết định cốt lõi như cổng đa ngưỡng vẫn cần sự dẫn dắt của con người thông qua luồng tinh chỉnh đơn do tính chất phức tạp về ngữ nghĩa. Do đó, hai phương pháp bổ trợ nhau: đội tác tử đảm nhận dựng khung, còn luồng đơn tập trung tối ưu hóa lỗi suy luận.

CHƯƠNG 5 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 KẾT LUẬN

Đề tài đã hoàn thành trọn vẹn hai mục tiêu nghiên cứu cốt lõi được đặt ra:

- Thiết kế và hiện thực hóa một hệ thống xác minh hình ảnh zero-shot có khả năng giải thích.
- Thực chứng năng lực phát triển phần mềm tự động của mô hình ngôn ngữ lớn thông qua chính quá trình xây dựng ứng dụng nói trên.

5.1.1 Ứng dụng xác minh dùng kỹ thuật zero-shot

Trên nền tảng mô hình CLIP và tư tưởng cốt lõi của kiến trúc Concept Bottleneck, nghiên cứu đã đề xuất và hiện thực hóa thành công một phương pháp xác minh một-lớp, vượt qua những giới hạn của bài toán phân loại đóng truyền thống. Hệ thống cho phép người dùng định nghĩa các lớp đối tượng mới mà hoàn toàn không cần tiến hành tái huấn luyện. Cơ chế này được xây dựng dựa trên việc tổng hợp hai nguồn bằng chứng (khái niệm và nguyên mẫu), kết hợp cùng công quyết định đa sán nhằm cung cấp khả năng từ chối dứt khoát đối với các hình ảnh nằm ngoài phân bố. Đồng thời, quá trình ra quyết định luôn đi kèm kết quả giải thích được một cách minh bạch ở cấp độ khái niệm. Kết quả thực nghiệm trên bộ dữ liệu tự xây dựng minh chứng hệ thống vận hành ổn định, đạt mức hiệu năng phù hợp với dòng phương pháp zero-shot concept bottleneck hiện hành. Trọng tâm hơn, ứng dụng đã thể hiện xuất sắc tính minh bạch và năng lực từ chối - những đặc tính then chốt đáp ứng đúng yêu cầu khắt khe của một bài toán xác minh trong thực tế.

5.1.2 Quy trình phát triển phần mềm bằng mô hình ngôn ngữ lớn (LLM)

Thông qua việc hiện thực hóa toàn bộ ứng dụng bằng phương pháp kỹ sư câu lệnh kết hợp cùng công cụ Claude Code, nghiên cứu đã khẳng định vai trò của mô hình ngôn ngữ lớn như một cộng tác viên lập trình đắc lực. Chỉ từ một bản đặc tả khởi tạo,

hệ thống trí tuệ nhân tạo có khả năng thiết lập nhanh chóng bộ khung ứng dụng khả thi, đáp ứng trọn vẹn các yêu cầu nền tảng về cấu trúc và kiến trúc phần mềm. Tuy nhiên, đối với những phân hệ mang tính chất logic suy luận và ra quyết định cốt lõi, sản phẩm chỉ có thể đạt đến trạng thái hội tụ thông qua nhiều vòng lặp kiểm thử và tinh chỉnh dưới sự dẫn dắt của con người. Hạn chế này xuất phát từ việc mô hình không thể tự nhận diện các sai lệch về mặt ngữ nghĩa nghiệp vụ nếu thiếu vắng dữ liệu phản hồi từ khâu kiểm thử thực tế. Kết quả nghiên cứu củng cố vững chắc cho mô hình hợp tác Người - AI (Human-AI Collaboration). Trong tiến trình này, hệ thống AI đảm nhận khối lượng công việc sinh mã, trong khi kỹ sư phần mềm vẫn nắm giữ vai trò chiến lược ở các khâu đặc tả yêu cầu, rà soát kiểm thử và thẩm định chất lượng cuối cùng.

5.2 HẠN CHẾ

Mặc dù đạt được những kết quả khả quan, nghiên cứu vẫn tồn tại một số giới hạn nhất định trên cả ba phương diện:

- Về mô hình xác minh hình ảnh: việc sử dụng mạng xương sống (backbone) CLIP ViT-B/32 gặp giới hạn về độ phân giải biểu diễn. Các ngưỡng quyết định tại cổng phân loại hiện chỉ được thiết lập dựa trên kinh nghiệm (heuristic) thay vì được học tự động từ dữ liệu. Ngoài ra, hiệu năng của hệ thống có xu hướng suy giảm khi phải xử lý các hình ảnh chứa nhiều nhiễu hoặc có bối cảnh đa vật thể phức tạp.
- Về kiến trúc sản phẩm: do giới hạn trong phạm vi của một sản phẩm khả dụng tối thiểu (MVP), hệ thống hiện tại đang sử dụng hệ tệp (file system) làm phương thức lưu trữ chính và áp dụng cơ chế suy luận tuần tự. Thiết kế này giải quyết tốt bài toán kiểm chứng khái niệm nhưng chưa được tối ưu hóa để đáp ứng hiệu năng ở quy mô lớn.
- Về đánh giá quy trình phát triển bằng LLM: khung thực nghiệm mới chỉ được giới hạn trên một công cụ (Claude Code) và áp dụng cho một dự án cụ thể. Vì

vậy, các kết luận rút ra hiện mang tính chất của một nghiên cứu điển hình (case study) và cần thêm dữ liệu để đạt được độ tổng quát hóa cao hơn.

5.3 HƯỚNG PHÁT TRIỂN

Nhằm tối ưu hóa giá trị thực tiễn của giải pháp và khắc phục những giới hạn còn tồn tại, nghiên cứu đề xuất lộ trình phát triển tập trung vào hai khía cạnh cốt lõi:

- Đối với ứng dụng xác minh: cải thiện độ chính xác thuật toán bằng cách nâng cấp lên các mạng xương sống mạnh mẽ hơn (như ViT-L, OpenCLIP, SigLIP) và áp dụng cơ chế học tự động cho các cổng quyết định, áp dụng vào các bài toán thực tế trong y tế và khoa học để kiểm chứng.
- Đối với nghiên cứu phát triển phần mềm bằng LLM: mở rộng quy mô thực nghiệm trên đa dạng các mô hình và loại hình ứng dụng nhằm củng cố tính tổng quát của kết luận. Đồng thời, việc thiết lập bộ công cụ đo lường định lượng và tích hợp kiểm thử tự động (automated testing) trực tiếp vào vòng đời tinh chỉnh lập sẽ là chìa khóa để giảm thiểu sự phụ thuộc vào thao tác rà soát thủ công của kỹ sư.

TÀI LIỆU THAM KHẢO

- [1] E. Ries, *The Lean Startup: How Today's Entrepreneurs Use Continuous Innovation to Create Radically Successful Businesses*. New York, NY, USA: Crown Business, 2011.
- [2] L. Bass, P. Clements, and R. Kazman, *Software Architecture in Practice*, 3rd ed. Boston, MA, USA: Addison-Wesley, 2012.
- [3] A. Radford et al., "Learning Transferable Visual Models From Natural Language Supervision," *Proceedings of the 38th International Conference on Machine Learning (ICML)*, 2021.
- [4] J. Du et al., "A Survey of Vision-Language Pre-trained Models," in *Proc. 31st Int. Joint Conf. Artif. Intell. (IJCAI)*, 2022, pp. 5436–5443.
- [5] Y. Xian et al., "Zero-Shot Learning—A Comprehensive Evaluation of the Good, the Bad and the Ugly," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 41, no. 9, pp. 2251–2265, Sep. 2019.
- [6] P. W. Koh et al., "Concept Bottleneck Models," *Proceedings of the 37th International Conference on Machine Learning (ICML)*, 2020.
- [7] S. Yamaguchi et al., "Zero-shot Concept Bottleneck Models," *arXiv preprint arXiv:2502.09018*, 2025.
- [8] A. Vaswani et al., "Attention Is All You Need," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [9] L. Ouyang et al., "Training Language Models to Follow Instructions with Human Feedback," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.

[10] Anthropic, "Claude Code Documentation," 2026. [Online]. Available: <https://code.claude.com/docs>. [Accessed: Jun. 14, 2026].

[11] S. Peng et al., "The Impact of AI on Developer Productivity: Evidence from GitHub Copilot," arXiv preprint arXiv:2302.06590, 2023.

[12] K. Zhou et al., "Learning to Prompt for Vision-Language Models," *International Journal of Computer Vision*, vol. 130, no. 9, pp. 2337–2348, 2022.