

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH
KHOA ĐIỆN ĐIỆN TỬ
BỘ MÔN KỸ THUẬT MÁY TÍNH



ĐỒ ÁN TỐT NGHIỆP

**THIẾT KẾ MÔ HÌNH HỌC SÂU HIỆU CHỈNH ĐẶC
TRUNG TIỀM ẨN CHO PHÂN ĐOẠN PHỔ TÍN HIỆU
VÔ TUYẾN TRONG ĐIỀU KIỆN NHIỀU**

NGÀNH CÔNG NGHỆ KỸ THUẬT MÁY TÍNH

**Sinh viên: TRƯỞNG HOÀI THƯƠNG
MSSV: 22119237**

TP. Hồ Chí Minh – Tháng 06, 2026

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH
KHOA ĐIỆN ĐIỆN TỬ
BỘ MÔN KỸ THUẬT MÁY TÍNH



ĐỒ ÁN TỐT NGHIỆP

**THIẾT KẾ MÔ HÌNH HỌC SÂU HIỆU CHỈNH ĐẶC
TRUNG TIỀM ẨN CHO PHÂN ĐOẠN PHỔ TÍN HIỆU
VÔ TUYẾN TRONG ĐIỀU KIỆN NHIỀU**

NGÀNH CÔNG NGHỆ KỸ THUẬT MÁY TÍNH

**Sinh viên: TRƯƠNG HOÀI THƯƠNG
MSSV: 22119237**

GVHD: TS. Huỳnh Thế Thiện

TP. Hồ Chí Minh – Tháng 06, 2026

BẢN NHẬN XÉT KHÓA LUẬN TỐT NGHIỆP

(Dành cho giảng viên hướng dẫn)

Đề tài: THIẾT KẾ MÔ HÌNH HỌC SÂU HIỆU CHÍNH ĐẶC TRƯNG TIỀM ẨN CHO PHÂN ĐOẠN PHỔ TÍN HIỆU VÔ TUYẾN TRONG ĐIỀU KIỆN NHIỀU

Sinh viên: Trương Hoài Thương

MSSV: 22119237

Hướng dẫn: TS. Huỳnh Thế Thiện

Nhận xét bao gồm các nội dung sau đây:

- Tính hợp lý trong cách đặt vấn đề và giải quyết vấn đề; ý nghĩa khoa học và thực tiễn:** Đề tài đi sâu giải quyết bài toán cảm nhận phổ thông minh trong môi trường nhiễu bằng phương pháp phân đoạn ngữ nghĩa ảnh phổ. Hướng tiếp cận bằng học sâu là hoàn toàn hợp lý, mang tính thời sự và có ý nghĩa ứng dụng cho các mạng thông tin vô tuyến hiện đại.
- Phương pháp thực hiện/ phân tích/ thiết kế:** Sinh viên có tư duy thiết kế mô hình khá sáng tạo. Thay vì dùng mô hình khuếch tán để sinh trực tiếp toàn cục, sinh viên thiết kế kiến trúc DiffRefiner dùng khuếch tán để hiệu chỉnh đặc trưng trong không gian tiềm ẩn (latent space), kết hợp xuất sắc với cơ chế phản hồi độ bất định (uncertainty feedback).
- Kết quả thực hiện/ phân tích và đánh giá kết quả/ kiểm định thiết kế:** Kết quả thực nghiệm vô cùng ấn tượng. Mô hình đạt hiệu năng tốt với mIoU 95.57% và mAcc 97.39% dưới điều kiện nhiễu khắc khe. Việc tối ưu hóa quy mô mô hình xuống chỉ còn 4.05 triệu tham số và tốc độ suy luận 5.61 ms chứng tỏ phương pháp đạt hiệu suất cao, sẵn sàng triển khai trên phần cứng thực tế.
- Kết luận và đề xuất:** Kết luận rõ ràng, trung thực. Đề xuất mở rộng kiểm chứng trên hệ thống vô tuyến định nghĩa bằng phần mềm (SDR) và các kỹ thuật nén mô hình (quantization, pruning) cho thiết bị biên là những hướng phát triển mang tính thực tiễn.
- Hình thức trình bày và bố cục báo cáo:** Bố cục khóa luận logic, văn phong học thuật chuẩn mực, các biểu đồ và hình ảnh minh họa kiến trúc được đầu tư công phu, sắc nét. Sinh viên đã nghiêm túc khắc phục các lỗi chế bản nhỏ lẻ và lỗi công thức toán học theo góp ý của giảng viên.
- Kỹ năng chuyên nghiệp và tính sáng tạo:** Sinh viên sở hữu tư duy thuật toán nhạy bén, khả năng làm việc độc lập tốt và làm chủ hoàn toàn các kiến thức phức tạp về xử lý tín hiệu số, kiến trúc Transformer và mô hình khuếch tán xác suất (DDPM).
- Tài liệu trích dẫn:** Danh mục tài liệu tham khảo phong phú, mang tính cập nhật cao, được trích dẫn và tổng hợp đầy đủ theo đúng tiêu chuẩn khoa học IEEE.
- Đánh giá về sự trùng lặp của đề tài:** Đề tài mang tính độc lập hoàn toàn. Phương pháp hiệu chỉnh đặc trưng tiềm ẩn bằng khuếch tán là kết quả nghiên cứu tự thân của sinh viên, không có sự trùng lặp với các công trình trước đó.
- Những nhược điểm và thiếu sót, những điểm cần được bổ sung và chỉnh sửa:** Báo cáo không còn khuyết điểm về mặt chuyên môn sau khi đã chỉnh sửa theo góp ý của giảng viên hướng dẫn. Các sơ sót liên quan lỗi đánh máy công thức STFT đã được sinh viên hiệu đính hoàn chỉnh.
- Nhận xét tinh thần, thái độ học tập, nghiên cứu của sinh viên:** Thái độ nghiên cứu khoa học nghiêm túc, đam mê học hỏi, luôn chủ động tìm tòi giải pháp tối ưu nhất để vượt qua giới hạn của các công trình đi trước.

Đề nghị của giảng viên hướng dẫn:

Báo cáo hoàn toàn đạt yêu cầu của một khóa luận tốt nghiệp kỹ sư, và được phép bảo vệ khóa luận tốt nghiệp trước Hội đồng.

Tp. HCM, ngày 23 tháng 06 năm 2026

Người nhận xét

(Ký và ghi rõ họ tên)

TS. Huỳnh Thế Thiện

Lời Cam Đoan

Tôi tên là Trương Hoài Thương, hiện đang theo học ngành Công nghệ Kỹ thuật Máy tính, Khoa Điện - Điện tử, Trường Đại học Công nghệ Kỹ thuật TP. Hồ Chí Minh. Tôi xin cam đoan khóa luận tốt nghiệp này là công trình nghiên cứu do tôi thực hiện dưới sự hướng dẫn của giảng viên hướng dẫn. Các nội dung, kết quả thực nghiệm, nhận xét và đánh giá được trình bày trong khóa luận là trung thực, phản ánh quá trình tìm hiểu, triển khai và phân tích của bản thân tôi trong suốt quá trình thực hiện đề tài. Tôi cam kết không sao chép nội dung từ bất kỳ đồ án, khóa luận, bài báo, công trình nghiên cứu hoặc tài liệu nào khác mà không trích dẫn nguồn. Những tài liệu, số liệu, phương pháp và công trình liên quan được sử dụng trong khóa luận đều được tham khảo, kế thừa và ghi nhận đầy đủ theo đúng quy định về trích dẫn học thuật. Tôi hoàn toàn chịu trách nhiệm về tính trung thực, chính xác và nguyên bản của khóa luận này và chấp nhận mọi hình thức xử lý theo quy định hiện hành nếu phát hiện bất kỳ vi phạm nào đối với bản cam kết này.

Người thực hiện khóa luận
(Ký và ghi rõ họ tên)

Trương Hoài Thương

Lời Cảm Ơn

Trong quá trình thực hiện khóa luận tốt nghiệp, tôi đã nhận được nhiều sự quan tâm, hướng dẫn và hỗ trợ quý báu từ quý Thầy Cô, bạn bè và những người đã đồng hành cùng tôi trong suốt thời gian học tập, nghiên cứu tại Khoa Điện - Điện tử, Trường Đại học Công nghệ Kỹ thuật TP. Hồ Chí Minh. Tôi xin gửi lời cảm ơn chân thành đến quý Thầy Cô đã truyền đạt kiến thức nền tảng, tạo điều kiện học tập và định hướng chuyên môn để tôi có thể từng bước hoàn thiện đề tài này. Đặc biệt, tôi xin bày tỏ lòng biết ơn sâu sắc đến Thầy Huỳnh Thế Thiện, người đã tận tình hướng dẫn, góp ý và hỗ trợ tôi trong quá trình xây dựng ý tưởng, triển khai phương pháp nghiên cứu cũng như hoàn thiện nội dung khóa luận. Những chỉ dẫn và nhận xét của Thầy là cơ sở quan trọng giúp tôi hiểu rõ hơn vấn đề nghiên cứu, điều chỉnh hướng tiếp cận và nâng cao chất lượng của đề tài. Mặc dù đã nỗ lực hoàn thành khóa luận trong khả năng của bản thân, nhưng do kiến thức và kinh nghiệm nghiên cứu còn hạn chế, nội dung khóa luận khó tránh khỏi những thiếu sót. Tôi rất mong nhận được sự góp ý và đánh giá từ quý Thầy Cô để có thể tiếp tục hoàn thiện kiến thức, cải thiện kỹ năng nghiên cứu và phát triển tốt hơn trong các công việc học thuật sau này. Tôi xin chân thành cảm ơn!

Tóm Tắt

Nghiên cứu này đề xuất một phương pháp học sâu cho bài toán nhận diện và phân đoạn phổ tín hiệu vô tuyến trong môi trường phổ dùng chung, tập trung vào các tín hiệu LTE, 5G NR và radar giám sát hàng không ASR. Trong các kịch bản vô tuyến hiện đại, nhiều nguồn phát có thể cùng tồn tại trên miền thời gian-tần số, đồng thời chịu ảnh hưởng bởi các yếu tố suy giảm của kênh truyền như nhiễu, fading đa đường và dịch Doppler. Những tác động này làm cho cấu trúc phổ của tín hiệu trở nên phức tạp hơn, gây ra hiện tượng biên tín hiệu bị mờ, vùng phổ bị phân mảnh hoặc chồng lấn giữa các lớp tín hiệu. Do đó, việc chỉ phát hiện sự tồn tại của tín hiệu là chưa đủ; mô hình cần có khả năng khoanh vùng và gán nhãn chính xác từng vùng tín hiệu trên ảnh phổ.

Để biểu diễn tín hiệu đầu vào theo cách phù hợp với bài toán phân đoạn, tín hiệu thu trong miền thời gian được chuyển đổi sang ảnh phổ bằng phép biến đổi Fourier thời gian ngắn. Biểu diễn này cho phép mô tả sự phân bố năng lượng của tín hiệu theo cả thời gian và tần số, từ đó làm nổi bật các đặc trưng như vùng chiếm dụng phổ, hình dạng tín hiệu và ranh giới giữa các nguồn phát. Trên cơ sở ảnh phổ thu được, luận văn xây dựng mô hình theo kiến trúc mã hóa-hiệu chỉnh tiềm ẩn-giải mã. Bộ mã hóa có nhiệm vụ trích xuất các đặc trưng phân cấp từ ảnh phổ đầu vào, trong khi một phần đặc trưng trung gian được ánh xạ vào không gian tiềm ẩn nén để phục vụ quá trình hiệu chỉnh. Thay vì dự đoán trực tiếp mặt nạ phân đoạn từ đặc trưng ban đầu, mô hình sử dụng cơ chế khuếch tán trong không gian tiềm ẩn để cải thiện biểu diễn đặc trưng trước khi đưa vào bộ giải mã.

Sau quá trình hiệu chỉnh, biểu diễn tiềm ẩn đã được tinh chỉnh được ánh xạ trở lại miền đặc trưng để tạo tín hiệu sửa lỗi cho các đặc trưng sâu. Tín hiệu này không thay thế hoàn toàn đặc trưng ban đầu, mà được tích hợp theo dạng phần dư nhằm hỗ trợ mô hình phục hồi các cấu trúc phổ bị suy giảm. Bên cạnh đó, phương pháp đề xuất còn sử dụng cơ chế phản hồi có xét độ bất định của dự đoán. Cụ thể, các thông tin như entropy và độ chênh lệch xác suất giữa các lớp được khai thác để xác định những vùng phổ khó phân biệt, chẳng hạn như vùng biên giữa các tín hiệu, vùng bị nhiễu mạnh hoặc vùng tín hiệu bị đứt đoạn. Nhờ cơ chế này, mô hình có thể tập trung hiệu chỉnh nhiều hơn tại các vùng không chắc chắn, đồng thời hạn chế làm thay đổi những vùng đã có dự đoán ổn định.

Kết quả thực nghiệm cho thấy phương pháp đề xuất đạt độ chính xác trung bình 97,39% và mIoU 95,57% trên bài toán phân đoạn ảnh phổ đa lớp. Đồng thời, mô hình chỉ sử dụng khoảng

4,05 triệu tham số và đạt thời gian suy luận 5,61 ms cho mỗi ảnh phổ đầu vào. Các kết quả này cho thấy hướng tiếp cận hiệu chỉnh đặc trưng tiềm ẩn dựa trên khuếch tán có khả năng cải thiện chất lượng phân đoạn trong môi trường vô tuyến phức tạp, đặc biệt tại các vùng phổ bị nhiễu, biên yếu hoặc có sự chồng lấn giữa nhiều nguồn phát. Qua đó, phương pháp đề xuất thể hiện tiềm năng ứng dụng trong các hệ thống giám sát và phân tích phổ tín hiệu vô tuyến gần thời gian thực.

Mục Lục

1	TỔNG QUAN	1
1.1	GIỚI THIỆU	1
1.2	MỤC TIÊU	3
1.3	PHƯƠNG PHÁP NGHIÊN CỨU	4
1.4	GIỚI HẠN NGHIÊN CỨU	6
1.5	BỐ CỤC	8
2	CƠ SỞ LÝ THUYẾT	9
2.1	LÝ THUYẾT VỀ TÍN HIỆU LTE, 5G NR VÀ ASR	9
2.1.1	Truyền nhận tín hiệu trong truyền thông không dây	9
2.1.2	Tổng quan về LTE	11
2.1.3	Tổng quan về 5G NR	13
2.1.4	Tổng quan về tín hiệu radar ASR	15
2.2	LÝ THUYẾT VỀ PHÂN TÍCH THỜI GIAN–TẦN SỐ	17
2.2.1	Phân tích trong miền thời gian	17
2.2.2	Phân tích trong miền tần số	17
2.2.3	Phân tích thời gian–tần số	18
2.2.4	So sánh các phương pháp biểu diễn thời gian–tần số	19
2.3	TỔNG QUAN VỀ LÝ THUYẾT HỌC SÂU	20
2.3.1	Mạng nơ-ron sâu	21
2.3.2	Mạng nơ-ron tích chập	23

2.3.3	Phân đoạn ngữ nghĩa và phân đoạn đối tượng	28
2.3.4	Phân đoạn ngữ nghĩa trong ảnh bằng học sâu	29
2.4	TỔNG QUAN VỀ CÁC MẠNG HỌC SÂU TRONG PHÂN ĐOẠN NGỮ NGHĨA HÌNH ẢNH	30
2.4.1	UNet++	31
2.4.2	DeepLabV3+	32
2.4.3	BiSeNetV2	34
2.4.4	SegFormer	36
2.4.5	So sánh tổng quan giữa các kiến trúc mạng phân đoạn ngữ nghĩa	38
3	KIẾN TRÚC VÀ PHƯƠNG PHÁP ĐỀ XUẤT	41
3.1	YÊU CẦU BÀI TOÁN	41
3.2	TỔNG QUAN KIẾN TRÚC ĐỀ XUẤT	42
3.3	CƠ SỞ THIẾT KẾ TỪ MÔ HÌNH KHUẾCH TÁN DDPM	44
3.4	PHƯƠNG PHÁP ĐỀ XUẤT	46
3.4.1	Phân tích thời gian–tần số bằng phép biến đổi Fourier thời gian ngắn . . .	47
3.4.2	Bộ mã hóa và ánh xạ không gian tiềm ẩn	49
3.4.3	Hiệu chỉnh biểu diễn tiềm ẩn dựa trên khuếch tán	52
3.4.4	Phản hồi độ bất định cho tín hiệu hiệu chỉnh	54
3.4.5	Bộ giải mã phân đoạn	56
3.5	CÀI ĐẶT MÔ PHỎNG VÀ HUẤN LUYỆN	59
3.5.1	Tạo bộ dữ liệu tín hiệu mô phỏng	59
3.5.2	Cấu hình huấn luyện	60
3.5.3	Phương pháp đánh giá	61
4	KẾT QUẢ VÀ THẢO LUẬN	63

4.1	DÁNH GIÁ HIỆU SUẤT PHÂN ĐOẠN CỦA MÔ HÌNH ĐỀ XUẤT	63
4.2	NGHIÊN CỨU LOẠI BỎ CÁC THÀNH PHẦN CỦA MÔ HÌNH	67
4.3	SO SÁNH HIỆU SUẤT PHÂN ĐOẠN VỚI CÁC MÔ HÌNH TIỀN TIẾN	70
5	KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	75
5.1	KẾT LUẬN	75
5.2	HƯỚNG PHÁT TRIỂN	77

Danh sách hình

2.1	Mô hình thu nhận tín hiệu LTE, 5G NR và ASR.	10
2.2	Kiến trúc tổng quan của mạng LTE.	11
2.3	Kiến trúc tổng quan của mạng 5G NR.	13
2.4	Kiến trúc tổng quan của hệ thống radar ASR.	16
2.5	Kiến trúc cơ bản của một mạng nơ-ron sâu.	22
2.6	Kiến trúc cơ bản của một mạng CNN.	24
2.7	Minh họa tích chập theo chiều sâu và tích chập điểm.	25
2.8	Minh họa tích chập chuẩn và tích chập giãn.	27
2.9	Ví dụ minh họa phân đoạn ngữ nghĩa.	28
2.10	Kiến trúc của mạng UNet++.	31
2.11	Kiến trúc của mạng DeepLabV3+.	33
2.12	Kiến trúc của mạng BiSeNetV2.	35
2.13	Kiến trúc của mạng SegFormer.	37
3.1	Tổng quan hệ thống phân đoạn ảnh phổ đề xuất.	43
3.2	Minh họa tiến trình khuếch tán và khử nhiễu.	45
3.3	Kiến trúc của mô hình đề xuất.	48
3.4	Bộ mã hóa và ánh xạ không gian tiềm ẩn.	50
3.5	Khối hiệu chỉnh biểu diễn tiềm ẩn dựa trên khuếch tán.	53
3.6	Phản hồi độ bất định cho tín hiệu hiệu chỉnh.	55
3.7	Bộ giải mã đa tỷ lệ thích nghi.	57

3.8	Ví dụ ảnh phổ và nhãn phân đoạn trong bộ dữ liệu.	59
4.1	Kết quả đánh giá tổng thể của mô hình đề xuất	64
4.2	Hiệu suất theo từng lớp của mô hình đề xuất	65
4.3	Trực quan hóa kết quả phân đoạn của mô hình đề xuất	66

Danh sách bảng

4.1	Nghiên cứu loại bỏ các thành phần của DiffRefiner	67
4.2	So sánh hiệu suất của DiffRefiner với các mô hình phân đoạn tiên tiến	72

Danh sách các từ viết tắt

Các từ viết tắt	Định nghĩa
3GPP	3rd Generation Partnership Project
5G	Fifth Generation
6G	Sixth Generation
AMF	Access and Mobility Management Function
ASR	Airport Surveillance Radar
CNN	Convolutional Neural Network
DDPM	Denoising Diffusion Probabilistic Model
DL	Deep Learning
DNN	Deep Neural Network
E-UTRAN	Evolved UMTS Terrestrial Radio Access Network
FDD	Frequency Division Duplex
LTE	Long-Term Evolution
mAcc	Mean Accuracy
IoU	Intersection over Union
mIoU	Mean Intersection over Union
MLP	Multi-Layer Perceptron
NG-RAN	Next Generation Radio Access Network
NR	New Radio
SCS	Subcarrier Spacing
SNR	Signal-to-Noise Ratio
SS	Spectrum Sensing
SSB	Synchronization Signal Block
STFT	Short-Time Fourier Transform
TDD	Time Division Duplex
UE	User Equipment
ASPP	Atrous Spatial Pyramid Pooling
AUSF	Authentication Server Function
BN	Batch Normalization
FB	Feedback Block
FG	FusionGate
GN	Group Normalization
IoT	Internet of Things
IRD	Inverted Residual Depthwise
LDR	Latent Diffusion Refiner
MME	Mobility Management Entity
PCF	Policy Control Function
SiLU	Sigmoid Linear Unit
SMF	Session Management Function
SPD	Space-to-Depth
UDM	Unified Data Management
UFM	Uncertainty Feedback Module
UPF	User Plane Function

Chương 1

TỔNG QUAN

1.1 GIỚI THIỆU

Trong kỷ nguyên kết nối vạn vật, sự phát triển nhanh chóng của các hệ thống thông tin vô tuyến từ thế hệ thứ năm (5G) đến thế hệ thứ sáu (6G) đang thúc đẩy sự hình thành của một môi trường truyền thông siêu kết nối. Trong môi trường đó, hàng tỷ thiết bị như cảm biến IoT, phương tiện tự hành, thiết bị công nghiệp thông minh và các ứng dụng thực tế tăng cường đều cần được kết nối liên tục với độ tin cậy cao. Tuy nhiên, sự gia tăng mạnh mẽ về số lượng thiết bị đầu cuối và lưu lượng dữ liệu truyền tải đã tạo ra áp lực lớn lên tài nguyên phổ tần, vốn là một tài nguyên hữu hạn trong các hệ thống thông tin không dây. Khi nhiều hệ thống cùng khai thác các vùng phổ gần nhau, hiện tượng tranh chấp phổ, nhiễu xuyên kênh và suy giảm chất lượng dịch vụ có thể xảy ra thường xuyên hơn. Do đó, các giải pháp quản lý và khai thác phổ một cách thông minh, linh hoạt và thích ứng theo điều kiện môi trường là yêu cầu quan trọng đối với các mạng vô tuyến thế hệ mới [1, 2, 3, 4].

Trong bối cảnh đó, cảm nhận phổ (spectrum sensing – SS) đóng vai trò nền tảng trong việc nâng cao hiệu quả sử dụng phổ tần và hỗ trợ hoạt động của các hệ thống vô tuyến nhận thức. Thông qua việc phát hiện trạng thái chiếm dụng phổ, hệ thống có thể xác định các vùng tần số đang được sử dụng hoặc còn trống, từ đó phục vụ cho cơ chế truy cập phổ động. Cơ chế này cho phép các thiết bị thứ cấp khai thác cơ hội các khoảng phổ chưa được sử dụng mà vẫn hạn chế gây nhiễu cho người dùng chính. Vì vậy, độ chính xác và độ tin cậy của cảm nhận phổ có ảnh hưởng trực tiếp đến hiệu quả quản lý tài nguyên vô tuyến. Trong nhiều năm qua, các phương pháp cảm nhận phổ đã phát triển theo hai hướng chính: nhóm phương pháp truyền thống dựa trên các đặc trưng được thiết kế thủ công và nhóm phương pháp học máy, đặc biệt là các mô hình học sâu có khả năng tự động học đặc trưng từ dữ liệu.

Các phương pháp truyền thống như phát hiện đặc trưng chu kỳ, phát hiện bằng bộ lọc phù hợp hoặc các phương pháp dựa trên entropy miền tần số [5] thường đạt hiệu quả tốt trong các điều kiện lý tưởng, khi mô hình tín hiệu và tham số kênh truyền được biết trước tương đối chính xác. Bên cạnh đó, các kỹ thuật học máy như Support Vector Machine cũng đã được áp dụng nhằm cải thiện khả năng phân biệt tín hiệu và nhiễu [6]. Tuy nhiên, các phương pháp này vẫn phụ thuộc nhiều vào đặc trưng thủ công hoặc giả thiết thống kê của tín hiệu. Trong các kịch bản thực tế, tín hiệu vô tuyến có thể bị suy giảm bởi nhiễu, fading đa đường, dịch Doppler và sự chồng lấn giữa nhiều nguồn phát khác nhau. Đặc biệt ở điều kiện tỷ số tín hiệu trên nhiễu thấp, các đặc trưng truyền thống trở nên kém rõ ràng, làm giảm đáng kể độ tin cậy của quá trình phát hiện. Điều này thúc đẩy việc ứng dụng học sâu vào cảm nhận phổ, nhờ khả năng học các biểu diễn phi tuyến và phức tạp trực tiếp từ dữ liệu.

Sự phát triển của học sâu đã mở ra nhiều hướng tiếp cận mới cho bài toán cảm nhận phổ. Một số nghiên cứu sử dụng các kiến trúc kết hợp giữa mạng tích chập, mạng hồi tiếp và mạng nơ-ron sâu để khai thác đồng thời đặc trưng không gian và quan hệ tuần tự của tín hiệu [7]. Một số hướng khác đưa các đặc trưng thống kê như ma trận hiệp phương sai vào mạng CNN nhằm nâng cao khả năng phát hiện [8]. Gần đây, các kiến trúc dựa trên Transformer cũng được nghiên cứu nhờ khả năng mô hình hóa quan hệ tầm xa thông qua cơ chế tự chú ý [9]. Tuy nhiên, nhiều phương pháp trong số này chủ yếu tập trung vào bài toán phân loại hoặc phát hiện trạng thái chiếm dụng phổ, trong khi chưa khai thác đầy đủ thông tin không gian–tần số của tín hiệu. Đối với các môi trường phổ phức tạp, nơi nhiều tín hiệu như LTE, 5G NR và radar giám sát hàng không ASR có thể cùng tồn tại hoặc chồng lấn, việc chỉ xác định sự có mặt của tín hiệu là chưa đủ. Khi đó, bài toán phân đoạn ảnh phổ trở nên cần thiết vì cho phép xác định chính xác vùng thời gian–tần số mà từng loại tín hiệu chiếm dụng.

Các nghiên cứu gần đây đã chuyển hướng cảm nhận phổ sang bài toán phân đoạn ngữ nghĩa trên ảnh phổ, trong đó tín hiệu thu được được biến đổi sang miền thời gian–tần số bằng phép biến đổi Fourier thời gian ngắn [10, 11, 12]. Cách biểu diễn này giúp trực quan hóa cấu trúc năng lượng của tín hiệu và cho phép tận dụng các mô hình phân đoạn trong thị giác máy tính để nhận diện từng vùng phổ. Một số kiến trúc mã hóa–giải mã hoặc mạng phân đoạn nhẹ đã cho thấy hiệu quả đáng kể trong việc nhận diện các tín hiệu vô tuyến hiện đại như LTE và 5G NR [13, 10, 11]. Tuy nhiên, phần lớn các mô hình phân đoạn hiện nay vẫn hoạt động theo cơ chế truyền thẳng một lần, nghĩa là kết quả phân đoạn được tạo trực tiếp từ các đặc trưng đã được trích xuất. Khi đặc trưng ban đầu đã bị sai lệch do nhiễu mạnh, fading hoặc biên tín hiệu bị mờ, các mô hình này thường thiếu một cơ chế rõ ràng để hiệu chỉnh lại những sai lệch cấu trúc trước khi đưa ra dự đoán cuối cùng.

Từ những hạn chế trên, có thể thấy rằng thách thức của cảm nhận phổ hiện đại không chỉ nằm ở việc đạt độ chính xác cao, mà còn ở khả năng duy trì độ bền vững trong môi trường nhiễu và suy hao kênh phức tạp. Các mô hình có độ chính xác cao thường đi kèm với kiến trúc sâu, số

lượng tham số lớn và chi phí tính toán cao, gây khó khăn cho việc triển khai trên các thiết bị biên. Ngược lại, các mô hình gọn nhẹ tuy phù hợp hơn với yêu cầu tài nguyên hạn chế nhưng có thể suy giảm hiệu suất trong các điều kiện phổ phức tạp, đặc biệt khi tín hiệu bị phân mảnh hoặc chồng lấn. Khoảng trống này cho thấy nhu cầu về một phương pháp phân đoạn phổ vừa có khả năng nhận diện chính xác các cấu trúc tín hiệu, vừa có cơ chế hiệu chỉnh đặc trưng nhằm tăng độ bền vững trước nhiễu, đồng thời vẫn duy trì chi phí tính toán hợp lý.

Do đó, luận văn này tập trung nghiên cứu một phương pháp phân đoạn phổ tín hiệu vô tuyến dựa trên kiến trúc mã hóa–hiệu chỉnh tiềm ẩn–giải mã. Thay vì dự đoán mặt nạ phân đoạn chỉ từ đặc trưng ban đầu, phương pháp xem biểu diễn được trích xuất bởi bộ mã hóa như một giả thuyết ngữ nghĩa sơ khởi và tiếp tục hiệu chỉnh biểu diễn này trong không gian tiềm ẩn. Quá trình hiệu chỉnh được định hướng bởi cơ chế khuếch tán nhằm khôi phục các cấu trúc phổ bị suy giảm, sau đó các tín hiệu hiệu chỉnh được đưa trở lại miền đặc trưng để hỗ trợ bộ giải mã tạo ra kết quả phân đoạn. Bên cạnh đó, cơ chế phản hồi dựa trên bất định được sử dụng để xác định các vùng phổ khó phân biệt, chẳng hạn như vùng biên hoặc vùng chịu nhiễu mạnh, qua đó tập trung hiệu chỉnh vào những vị trí cần thiết. Hướng tiếp cận này nhằm nâng cao độ chính xác và độ tin cậy của phân đoạn phổ trong môi trường vô tuyến phức tạp, đồng thời hướng đến khả năng triển khai hiệu quả trong các hệ thống giám sát phổ thể hệ tiếp theo.

1.2 MỤC TIÊU

Trước bối cảnh các hệ thống cảm nhận phổ hiện đại đang phải xử lý môi trường vô tuyến ngày càng phức tạp, luận văn này đặt ra mục tiêu tổng quát là nghiên cứu, thiết kế và đánh giá một phương pháp phân đoạn phổ tín hiệu dựa trên học sâu, có khả năng xác định chính xác vùng chiếm dụng phổ của các tín hiệu LTE, 5G NR và ASR trên ảnh phổ. Khác với các phương pháp chỉ tập trung vào việc phát hiện sự tồn tại của tín hiệu, nghiên cứu này hướng đến việc phân đoạn chi tiết các vùng thời gian–tần số tương ứng với từng loại tín hiệu, đặc biệt trong điều kiện có nhiễu, fading đa đường, dịch Doppler và sự chồng lấn giữa nhiều nguồn phát. Bên cạnh yêu cầu về độ chính xác, luận văn cũng quan tâm đến hiệu quả tính toán của mô hình, nhằm hướng đến khả năng ứng dụng trong các hệ thống cảm nhận và giám sát phổ vô tuyến thể hệ tiếp theo. Để hiện thực hóa mục tiêu trên, luận văn tập trung vào các nội dung cụ thể sau:

- **Biểu diễn tín hiệu trong miền thời gian–tần số:** Luận văn sử dụng phép biến đổi Fourier thời gian ngắn (Short-Time Fourier Transform – STFT) để chuyển đổi tín hiệu thu được thành ảnh phổ hai chiều. Cách biểu diễn này giúp mô tả sự phân bố năng lượng của tín hiệu theo thời gian và tần số, từ đó chuyển bài toán cảm nhận phổ thành bài toán phân đoạn ngữ nghĩa trên ảnh phổ.

- **Xây dựng mô hình phân đoạn phổ dựa trên học sâu:** Nghiên cứu thiết kế một kiến trúc mã hóa–hiệu chỉnh tiềm ẩn–giải mã, trong đó bộ mã hóa trích xuất đặc trưng từ ảnh phổ đầu vào và bộ giải mã tạo ra mặt nạ phân đoạn tương ứng với từng lớp tín hiệu. Kiến trúc này được định hướng nhằm nhận diện chính xác các vùng phổ của LTE, 5G NR và ASR trong môi trường có nhiễu và chồng lấn.
- **Hiệu chỉnh đặc trưng trong không gian tiềm ẩn:** Thay vì dự đoán trực tiếp kết quả phân đoạn từ đặc trưng ban đầu, mô hình ánh xạ một phần đặc trưng vào không gian tiềm ẩn nén và thực hiện quá trình hiệu chỉnh trên biểu diễn này. Cơ chế hiệu chỉnh dựa trên quá trình khuếch tán giúp khôi phục các vùng phổ bị mờ biên, bị phân mảnh hoặc bị suy giảm do tác động của kênh truyền.
- **Điều tiết quá trình hiệu chỉnh bằng phản hồi bất định:** Luận văn khai thác thông tin bất định từ dự đoán trung gian, chẳng hạn như entropy xác suất lớp và độ chênh lệch giữa các lớp có xác suất cao nhất, để xác định các vùng phổ khó phân biệt. Nhờ đó, tín hiệu hiệu chỉnh được tập trung vào vùng biên, vùng chồng lấn hoặc vùng nhiễu mạnh, đồng thời hạn chế ảnh hưởng đến các vùng đã được dự đoán ổn định.
- **Đánh giá hiệu quả và độ phức tạp của mô hình:** Phương pháp đề xuất được đánh giá thông qua các chỉ số phân đoạn như độ chính xác trung bình theo lớp và giao trên hợp trung bình. Bên cạnh đó, số lượng tham số và thời gian suy luận cũng được xem xét nhằm phân tích sự cân bằng giữa hiệu suất nhận diện và chi phí tính toán của mô hình.

Thông qua các mục tiêu trên, luận văn hướng tới việc xây dựng một phương pháp phân đoạn phổ tín hiệu vô tuyến có khả năng hoạt động hiệu quả trong môi trường phổ phức tạp. Kết quả nghiên cứu kỳ vọng góp phần cung cấp một hướng tiếp cận tiềm năng cho các hệ thống cảm nhận phổ thông minh, giám sát phổ động và quản lý tài nguyên vô tuyến trong các mạng thông tin không dây thế hệ tiếp theo.

1.3 PHƯƠNG PHÁP NGHIÊN CỨU

Để thực hiện các mục tiêu của luận văn, nghiên cứu được triển khai theo một quy trình gồm ba nhóm phương pháp chính: nghiên cứu lý thuyết, thực nghiệm mô phỏng và đánh giá định lượng. Các nhóm phương pháp này được kết hợp nhằm xây dựng cơ sở khoa học cho bài toán, thiết kế hệ thống phân đoạn ảnh phổ và kiểm chứng hiệu quả của mô hình trong nhiều điều kiện tín hiệu khác nhau.

Phương pháp nghiên cứu lý thuyết: Giai đoạn nghiên cứu lý thuyết được thực hiện nhằm xây dựng nền tảng kiến thức cho toàn bộ đề tài. Trước hết, luận văn khảo sát các đặc trưng

cơ bản của tín hiệu vô tuyến trong môi trường đồng tồn tại, bao gồm LTE, 5G NR và radar ASR. Các nội dung liên quan đến quá trình truyền nhận tín hiệu, ảnh hưởng của kênh truyền, nhiễu, fading và dịch Doppler được xem xét để làm rõ những yếu tố gây suy giảm chất lượng tín hiệu tại máy thu. Bên cạnh đó, các đặc tả kỹ thuật của LTE và 5G NR theo chuẩn 3GPP cũng được nghiên cứu nhằm nắm bắt các tham số quan trọng như băng thông, khoảng cách sóng mang con, chế độ truyền dẫn và cấu trúc tín hiệu. Đối với ASR, luận văn tập trung vào nguyên lý phát-thu xung radar, tín hiệu phản xạ và các đặc trưng phổ khác biệt so với tín hiệu truyền thông di động.

Song song với đó, luận văn nghiên cứu các phương pháp phân tích thời gian-tần số, đặc biệt là STFT, để chuyển tín hiệu thu được thành biểu diễn ảnh phổ. Đây là bước quan trọng vì bài toán cảm nhận phổ được mô hình hóa thành bài toán phân đoạn ngữ nghĩa trên ảnh. Ngoài ra, các kiến thức nền tảng về học sâu, mạng nơ-ron tích chập, kiến trúc mã hóa-giải mã, biểu diễn tiềm ẩn và mô hình khuếch tán cũng được khảo sát. Các công trình liên quan trong lĩnh vực phân đoạn ảnh phổ và phân đoạn ngữ nghĩa bằng học sâu được phân tích nhằm xác định ưu điểm, hạn chế và khoảng trống nghiên cứu mà luận văn hướng đến.

Phương pháp thực nghiệm mô phỏng: Do việc thu thập dữ liệu phổ thực tế có nhân chi tiết ở mức điểm ảnh là khó khăn và tốn kém, luận văn sử dụng phương pháp mô phỏng để xây dựng bộ dữ liệu phục vụ huấn luyện và đánh giá. Các tín hiệu LTE, 5G NR và ASR được tạo ra với nhiều cấu hình tham số khác nhau, sau đó được đưa qua các mô hình kênh truyền có xét đến các yếu tố như nhiễu nền, fading, Doppler và sự thay đổi SNR. Tín hiệu thu được sau kênh truyền được biến đổi sang miền thời gian-tần số bằng STFT để tạo ảnh phổ. Đồng thời, các mặt nạ nhân tương ứng được xây dựng để biểu diễn vị trí của từng lớp tín hiệu trên ảnh phổ, bao gồm Noise, LTE, 5G NR và ASR.

Trên cơ sở bộ dữ liệu đã tạo, luận văn thiết kế và triển khai mô hình phân đoạn ảnh phổ dựa trên học sâu. Kiến trúc đề xuất tập trung vào việc trích xuất đặc trưng từ ảnh phổ, ánh xạ sang không gian tiềm ẩn và thực hiện hiệu chỉnh biểu diễn tiềm ẩn nhằm cải thiện chất lượng phân đoạn trong điều kiện tín hiệu bị suy giảm. Các thành phần của mô hình được xây dựng theo hướng khai thác đồng thời thông tin không gian-ngữ nghĩa và khả năng khôi phục đặc trưng bị ảnh hưởng bởi nhiễu hoặc chồng lấn tín hiệu. Sau khi hoàn thiện kiến trúc, mô hình được huấn luyện trên tập dữ liệu mô phỏng với các siêu tham số phù hợp như tốc độ học, kích thước lô, số epoch và hàm mất mát. Tập kiểm định không tham gia cập nhật trọng số được sử dụng để theo dõi hiệu suất huấn luyện và đánh giá khả năng tổng quát hóa của mô hình trong phạm vi bộ dữ liệu mô phỏng.

Phương pháp phân tích và đánh giá: Sau khi thu được kết quả thực nghiệm, luận văn tiến hành đánh giá hiệu quả của mô hình bằng các chỉ số định lượng thường dùng trong phân đoạn ngữ nghĩa. Các chỉ số chính bao gồm độ chính xác trung bình theo lớp (mAcc) và giao trên hợp trung bình (mIoU). Những chỉ số này cho phép đánh giá mức độ chính xác của mô hình theo từng

lớp tín hiệu, đồng thời phản ánh chất lượng chồng khớp giữa vùng dự đoán và vùng nhân thực tế. Ngoài ra, các yếu tố liên quan đến độ phức tạp mô hình như số lượng tham số và thời gian suy luận cũng được xem xét nhằm đánh giá khả năng triển khai của phương pháp trong các hệ thống yêu cầu xử lý nhanh.

Bên cạnh đánh giá tổng thể, luận văn còn phân tích hiệu suất của mô hình trong các điều kiện SNR khác nhau để khảo sát độ bền vững trước nhiễu. Việc đánh giá theo SNR giúp làm rõ khả năng duy trì chất lượng phân đoạn khi tín hiệu bị suy giảm, đặc biệt tại các mức SNR thấp. Ngoài ra, kết quả phân đoạn theo từng lớp cũng được phân tích để xác định những lớp tín hiệu dễ nhầm lẫn, chẳng hạn giữa vùng nhiễu và tín hiệu ASR yếu, hoặc giữa các vùng phổ của LTE và 5G NR trong trường hợp chồng lấn.

Cuối cùng, mô hình đề xuất được so sánh với các kiến trúc phân đoạn ngữ nghĩa khác trong cùng điều kiện dữ liệu và thiết lập đánh giá. Các mô hình đối chiếu bao gồm những kiến trúc đại diện cho các hướng tiếp cận khác nhau, chẳng hạn mô hình encoder-decoder dựa trên CNN, mô hình phân đoạn nhẹ thời gian thực và mô hình dựa trên Transformer. Kết quả so sánh được trình bày thông qua bảng số liệu, đồ thị và ví dụ trực quan, từ đó làm rõ ưu điểm, hạn chế và mức độ phù hợp của phương pháp đề xuất đối với bài toán phân đoạn ảnh phổ trong môi trường đồng tồn tại tại LTE, 5G NR và ASR.

1.4 GIỚI HẠN NGHIÊN CỨU

Để bảo đảm phạm vi nghiên cứu rõ ràng và phù hợp với mục tiêu của luận văn, các nội dung thực nghiệm và đánh giá được giới hạn trong một số điều kiện nhất định. Những giới hạn này giúp luận văn tập trung vào bài toán phân đoạn ảnh phổ trong môi trường đồng tồn tại giữa LTE, 5G NR và ASR, đồng thời làm rõ các hướng có thể mở rộng trong tương lai.

Về dữ liệu và phạm vi tín hiệu khảo sát: Dữ liệu sử dụng trong luận văn được xây dựng bằng phương pháp mô phỏng thay vì thu thập trực tiếp từ môi trường thực tế. Cách tiếp cận này cho phép kiểm soát các tham số tín hiệu, kênh truyền và tạo nhân phân đoạn chính xác ở mức điểm ảnh. Tuy nhiên, dữ liệu mô phỏng chưa thể phản ánh đầy đủ các yếu tố phức tạp của môi trường thực như nhiễu ngoài ý muốn, sai lệch phần cứng, can nhiễu từ các nguồn không xác định hoặc sự thay đổi kênh truyền theo vị trí. Bên cạnh đó, luận văn chỉ tập trung vào bốn lớp chính trên ảnh phổ, bao gồm Noise, LTE, 5G NR và ASR. Các loại tín hiệu khác như Wi-Fi, Bluetooth, tín hiệu vệ tinh, các dạng radar khác hoặc nhiễu chủ động có chủ đích chưa được khảo sát trong phạm vi nghiên cứu này.

Về phương pháp biểu diễn tín hiệu: Luận văn sử dụng STFT để chuyển tín hiệu thu được sang dạng ảnh phổ. Lựa chọn này xuất phát từ ưu điểm của STFT về tính trực quan, độ ổn

định và khả năng tạo biểu diễn hai chiều phù hợp với các mô hình phân đoạn ảnh. Nghiên cứu không đi sâu so sánh STFT với các kỹ thuật biểu diễn thời gian–tần số khác như CWT, WVD hoặc S-transform. Do đó, STFT được sử dụng như một biểu diễn đầu vào thống nhất nhằm tập trung đánh giá hiệu quả của mô hình phân đoạn đề xuất.

Về kiến trúc mô hình và phạm vi so sánh: Trọng tâm của luận văn là xây dựng và đánh giá mô hình DiffRefiner cho bài toán phân đoạn ảnh phổ. Vì vậy, nghiên cứu tập trung vào các thành phần chính của phương pháp đề xuất, bao gồm bộ trích xuất đặc trưng, biểu diễn tiềm ẩn, cơ chế hiệu chỉnh tiềm ẩn dựa trên khuếch tán và phản hồi độ bất định. Luận văn không khảo sát toàn diện tất cả các họ kiến trúc phân đoạn hiện có, mà chỉ lựa chọn một số mô hình tiêu biểu để làm cơ sở đối chiếu. Ngoài ra, luận văn tập trung so sánh với các kiến trúc học sâu trong bài toán phân đoạn ảnh, thay vì so sánh toàn diện với các phương pháp cảm nhận phổ truyền thống dựa trên ngưỡng năng lượng hoặc đặc trưng thủ công, do hai nhóm phương pháp này không hoàn toàn tương đương về mục tiêu đầu ra.

Về phương pháp đánh giá và triển khai thực tế: Hiệu quả của mô hình được đánh giá chủ yếu thông qua các chỉ số phân đoạn ngữ nghĩa như độ chính xác trung bình theo lớp và giao trên hợp trung bình, cùng với số lượng tham số và thời gian suy luận. Việc đánh giá được thực hiện trên cùng bộ dữ liệu và cùng điều kiện thiết lập để bảo đảm tính công bằng giữa các mô hình. Tuy nhiên, luận văn chưa đi sâu vào các yếu tố triển khai phần cứng như mức tiêu thụ năng lượng, bộ nhớ sử dụng, độ trễ trên thiết bị nhúng hoặc khả năng vận hành trong hệ thống thời gian thực. Những nội dung này, cùng với việc đánh giá trên dữ liệu đo thực tế và mở rộng sang nhiều loại tín hiệu hơn, có thể được xem là các hướng phát triển tiếp theo.

1.5 BỐ CỤC

Luận văn được cấu trúc thành 5 chương:

- Chương 1: Tổng quan.
- Chương 2: Cơ sở lý thuyết.
- Chương 3: Kiến trúc mô hình đề xuất.
- Chương 4: Kết quả và thảo luận.
- Chương 5: Kết luận và hướng phát triển.

Chương 2

CƠ SỞ LÝ THUYẾT

2.1 LÝ THUYẾT VỀ TÍN HIỆU LTE, 5G NR VÀ ASR


2.1.1 Truyền nhận tín hiệu trong truyền thông không dây

Trong bài toán cảm nhận phổ, máy thu thường không tiếp nhận một tín hiệu riêng lẻ trong điều kiện lý tưởng, mà quan sát một môi trường vô tuyến có thể bao gồm nhiều nguồn phát cùng hoạt động. Các nguồn này có thể là tín hiệu truyền thông di động như LTE và 5G NR, hoặc tín hiệu radar giám sát hàng không ASR. Sau khi được phát ra môi trường, tín hiệu lan truyền qua kênh vô tuyến trước khi đến máy thu. Trong quá trình này, dạng sóng ban đầu có thể bị thay đổi bởi suy hao đường truyền, phản xạ, tán xạ, fading đa đường, dịch Doppler và nhiễu nền. Vì vậy, tín hiệu tại đầu thu không chỉ phản ánh đặc trưng của hệ thống phát, mà còn chứa các biến dạng do môi trường truyền dẫn gây ra. Trong mô hình truyền nhận tín hiệu vô tuyến cơ bản, tín hiệu thu được có thể được mô tả như sau:

$$y(t) = x(t) * h(t) + n(t), \quad (2.1)$$

trong đó $y(t)$ là tín hiệu thu tại máy thu, $x(t)$ là tín hiệu phát, $h(t)$ là đáp ứng xung của kênh truyền và $n(t)$ là nhiễu cộng trong hệ thống. Ký hiệu $*$ biểu thị phép tích chập trong miền thời gian. Công thức trên cho thấy tín hiệu quan sát tại đầu thu không còn giữ nguyên dạng ban đầu, mà đã chịu tác động của kênh truyền và nhiễu trước khi được đưa vào các bước xử lý tiếp theo.

Trong môi trường phổ có nhiều hệ thống cùng tồn tại, tín hiệu mà máy thu quan sát được có thể là sự chồng lấn của nhiều thành phần khác nhau, chẳng hạn LTE, 5G NR và ASR. Khi đó,




Hình 2.1: Mô hình thu nhận tín hiệu trong môi trường đồng tồn tại LTE, 5G NR và ASR.

mỗi thành phần tín hiệu đều có thể chịu ảnh hưởng của kênh truyền và nhiễu trước khi xuất hiện trên ảnh phổ. Vì vậy, dữ liệu đầu vào của hệ thống phân tích phổ thường không phải là một dạng sóng sạch và tách biệt, mà là tín hiệu đã bị biến dạng bởi môi trường truyền dẫn, nhiễu nền và sự chồng lấn giữa các nguồn phát.

Các tác động của kênh truyền có ảnh hưởng trực tiếp đến hình thái của tín hiệu trên miền thời gian–tần số. Fading đa đường xuất hiện khi tín hiệu đến máy thu thông qua nhiều đường truyền khác nhau, làm cho các bản sao của tín hiệu có độ trễ, pha và biên độ khác nhau. Khi các thành phần này chồng lấn, năng lượng tín hiệu có thể bị tăng cường hoặc suy giảm tại một số vùng tần số nhất định. Dịch Doppler xảy ra khi có chuyển động tương đối giữa nguồn phát, máy thu hoặc vật phản xạ, khiến tần số quan sát được bị thay đổi. Hiện tượng này đặc biệt đáng chú ý đối với các kịch bản có tín hiệu ASR, do radar thường liên quan đến mục tiêu chuyển động. Ngoài ra, trong điều kiện SNR thấp, nhiễu nền có thể che khuất một phần năng lượng tín hiệu, làm cho ranh giới giữa vùng tín hiệu và vùng nhiễu trở nên mờ hoặc bị đứt đoạn. Những yếu tố này làm tăng độ khó của bài toán phân đoạn ảnh phổ, vì mô hình cần xác định đúng lớp tín hiệu tại từng vị trí thời gian–tần số ngay cả khi tín hiệu bị suy giảm hoặc chồng lấn.

Hình 2.1 minh họa một kịch bản thu nhận tín hiệu trong môi trường có nhiều hệ thống vô tuyến cùng tồn tại. Đối với LTE và 5G NR, tín hiệu thường được phát từ trạm gốc hoặc các phần tử truy nhập vô tuyến, sau đó được truyền đến thiết bị người dùng hoặc máy thu phục vụ cảm nhận phổ. Đối với ASR, tín hiệu radar được phát theo cơ chế xung và có thể xuất hiện ngắt quãng trên mặt phẳng thời gian–tần số. Khi các tín hiệu này cùng được quan sát, ảnh phổ thu được có thể chứa đồng thời các vùng năng lượng tương đối rộng của tín hiệu truyền thông và các cấu trúc cục bộ, rời rạc của tín hiệu radar. Vì vậy, mục tiêu của hệ thống không chỉ là phát hiện sự tồn tại của tín hiệu, mà còn phải phân tách chính xác vùng phổ tương ứng với từng lớp. Đây là cơ sở để luận văn mô hình hóa bài toán dưới dạng phân đoạn ngữ nghĩa ảnh phổ, trong đó mỗi điểm ảnh trên miền thời gian–tần số được gán vào một trong các lớp Noise, LTE, 5G NR hoặc ASR.



Hình 2.2: Kiến trúc tổng quan của mạng LTE, bao gồm thiết bị người dùng UE, mạng truy nhập vô tuyến E-UTRAN, mạng lõi EPC và mạng dữ liệu gói bên ngoài. Đường liền thể hiện mặt phẳng người dùng, trong khi đường nét đứt thể hiện mặt phẳng điều khiển.

2.1.2 Tổng quan về LTE

LTE (Long-Term Evolution) là công nghệ truyền thông di động thế hệ thứ tư, được xây dựng nhằm nâng cao tốc độ truyền dữ liệu, giảm độ trễ và cải thiện hiệu quả sử dụng phổ tần so với các hệ thống di động trước đó. LTE hỗ trợ truyền dữ liệu gói tốc độ cao và được triển khai rộng rãi trong nhiều hệ thống thông tin vô tuyến hiện nay. Một đặc điểm quan trọng của LTE là khả năng cấu hình băng thông linh hoạt, thường từ 1.4 MHz đến 20 MHz, giúp hệ thống có thể thích ứng với nhiều quy hoạch phổ khác nhau. Trong phạm vi bài toán phân đoạn ảnh phổ của luận văn, LTE được xem là một trong các lớp tín hiệu truyền thông di động cần nhận dạng, có thể cùng tồn tại với 5G NR và ASR trong cùng môi trường quan sát.

Kiến trúc của mạng LTE: Kiến trúc tổng quan của LTE được minh họa trong Hình 2.2. Về cơ bản, hệ thống LTE gồm bốn phần chính: thiết bị người dùng UE, mạng truy nhập vô tuyến E-UTRAN, mạng lõi EPC và mạng dữ liệu gói bên ngoài. UE là thiết bị đầu cuối như điện thoại di động, máy tính bảng hoặc thiết bị thu phát vô tuyến, có nhiệm vụ trao đổi dữ liệu và thông tin báo hiệu với mạng thông qua giao diện vô tuyến. E-UTRAN là phần truy nhập vô tuyến của LTE, trong đó các trạm eNodeB thực hiện truyền nhận tín hiệu vô tuyến với UE, quản lý tài nguyên vô tuyến, lập lịch truyền dẫn và chuyển tiếp dữ liệu về mạng lõi. EPC là phần lõi mạng gói, chịu trách nhiệm xử lý báo hiệu, quản lý thuê bao, định tuyến dữ liệu và kết nối người dùng đến mạng


dữ liệu bên ngoài như Internet hoặc các dịch vụ IP. Trong kiến trúc này, mặt phẳng người dùng đảm nhiệm việc truyền dữ liệu từ UE qua eNodeB, S-GW và P-GW đến PDN/Internet, trong khi mặt phẳng điều khiển xử lý các thông tin báo hiệu phục vụ xác thực, quản lý di động, thiết lập phiên và chính sách dịch vụ.

Các thành phần chính trong EPC gồm MME, HSS, S-GW, P-GW và PCRF. MME (Mobility Management Entity) là thực thể quản lý di động và báo hiệu điều khiển, phụ trách các thủ tục như đăng ký mạng, xác thực, thiết lập kết nối và quản lý trạng thái của UE. HSS (Home Subscriber Server) là cơ sở dữ liệu thuê bao, lưu trữ thông tin nhận dạng người dùng, quyền truy nhập dịch vụ và các tham số xác thực. S-GW (Serving Gateway) đóng vai trò cổng phục vụ, chuyển tiếp dữ liệu người dùng giữa E-UTRAN và EPC, đồng thời hỗ trợ duy trì phiên dữ liệu khi UE di chuyển giữa các vùng phủ sóng. P-GW (Packet Data Network Gateway) là cổng kết nối giữa EPC và mạng dữ liệu gói bên ngoài, thực hiện cấp phát địa chỉ IP, định tuyến lưu lượng và kết nối người dùng đến các dịch vụ mạng. PCRF (Policy and Charging Rules Function) chịu trách nhiệm quản lý chính sách và quy tắc tính cước, hỗ trợ điều khiển chất lượng dịch vụ và áp dụng các chính sách truyền dữ liệu phù hợp.

Các tham số của tín hiệu LTE: Tín hiệu LTE được thiết kế theo các tham số kỹ thuật được quy định trong chuẩn truyền thông di động, trong đó các tham số quan trọng gồm băng thông, chế độ song công, cấu hình tài nguyên vô tuyến, sơ đồ điều chế và mã hóa kênh [14]. Băng thông quyết định phạm vi tần số mà tín hiệu LTE chiếm dụng; khi băng thông càng lớn, vùng năng lượng của tín hiệu trên ảnh phổ càng rộng và khả năng truyền dữ liệu càng cao. LTE hỗ trợ các mức băng thông linh hoạt từ 1.4 MHz đến 20 MHz, giúp hệ thống có thể triển khai trong nhiều dải phổ khác nhau. Về chế độ song công, LTE có thể hoạt động theo FDD hoặc TDD. Trong FDD, đường lên và đường xuống sử dụng hai dải tần riêng biệt, trong khi TDD sử dụng cùng một dải tần nhưng phân chia theo thời gian. Các cấu hình này ảnh hưởng đến cách tín hiệu LTE xuất hiện trên miền thời gian–tần số, đặc biệt là phạm vi chiếm dụng phổ, mức độ liên tục theo thời gian và sự phân bố năng lượng của tín hiệu.

Nhìn chung, LTE là tín hiệu truyền thông di động có cấu trúc tương đối ổn định và thường chiếm một dải tần xác định. Khi được biểu diễn dưới dạng ảnh phổ, tín hiệu LTE có xu hướng tạo thành các vùng năng lượng tương đối liên tục theo thời gian và có biên phổ phụ thuộc vào băng thông cấu hình. Tuy nhiên, trong điều kiện SNR thấp, fading hoặc khi xuất hiện đồng thời với 5G NR và ASR, vùng tín hiệu LTE có thể bị mờ biên, suy giảm năng lượng hoặc chồng lấn với các lớp tín hiệu khác. Vì vậy, trong bài toán phân đoạn ảnh phổ, mô hình học sâu cần khai thác đồng thời đặc trưng về phạm vi tần số, độ liên tục theo thời gian và ngữ cảnh lân cận để phân biệt LTE với 5G NR, ASR và nhiễu nền.

Kiến trúc mạng 5G NR



Hình 2.3: Kiến trúc tổng quan của mạng 5G NR, bao gồm thiết bị người dùng UE, mạng truy nhập vô tuyến NG-RAN, mạng lõi 5G Core và mạng dữ liệu bên ngoài DN/Internet. Đường liền thể hiện mặt phẳng người dùng, trong khi đường nét đứt thể hiện mặt phẳng điều khiển.

2.1.3 Tổng quan về 5G NR

5G NR (Fifth Generation New Radio) là chuẩn giao diện vô tuyến của mạng thông tin di động thế hệ thứ năm, được phát triển nhằm đáp ứng các yêu cầu ngày càng cao về tốc độ truyền dữ liệu, độ trễ thấp, độ tin cậy và khả năng kết nối số lượng lớn thiết bị. So với LTE, 5G NR có mức độ linh hoạt cao hơn trong cấu hình truyền dẫn, đặc biệt ở khả năng hỗ trợ nhiều dải tần, nhiều độ rộng băng thông và nhiều khoảng cách sóng mang con khác nhau. Nhờ đó, 5G NR có thể phục vụ nhiều nhóm ứng dụng như băng rộng di động nâng cao, truyền thông độ trễ thấp, kết nối thiết bị số lượng lớn, xe tự hành, hệ thống công nghiệp thông minh và các dịch vụ dữ liệu tốc độ cao. Trong phạm vi luận văn, 5G NR được xem là một trong các lớp tín hiệu truyền thông chính cần nhận dạng trên ảnh phổ, có thể cùng tồn tại với LTE và ASR trong cùng vùng thời gian-tần số.

Kiến trúc của mạng 5G NR: Kiến trúc tổng quan của mạng 5G NR được minh họa trong Hình 2.3. Hệ thống có thể được chia thành bốn khối chính, bao gồm thiết bị người dùng UE, mạng truy nhập vô tuyến NG-RAN, mạng lõi 5G Core và mạng dữ liệu bên ngoài DN/Internet. UE là thiết bị đầu cuối như điện thoại di động, máy tính bảng, thiết bị IoT hoặc các thiết bị thu

phát vô tuyến, có nhiệm vụ trao đổi dữ liệu và thông tin báo hiệu với mạng thông qua giao diện vô tuyến. NG-RAN là mạng truy nhập vô tuyến của 5G NR, trong đó các trạm gốc gNB thực hiện truyền nhận tín hiệu vô tuyến, quản lý tài nguyên vô tuyến, lập lịch truyền dẫn và kết nối UE với mạng lõi. So với eNodeB trong LTE, gNB trong 5G NR hỗ trợ cấu hình linh hoạt hơn về băng thông, khoảng cách sóng mang con, beamforming và các chức năng truyền dẫn phù hợp với nhiều dải tần khác nhau. Mạng lõi 5G Core đảm nhiệm các chức năng điều khiển truy nhập, quản lý di động, quản lý phiên, xác thực, quản lý thuê bao, chính sách dịch vụ và chuyển tiếp dữ liệu người dùng đến DN/Internet.

Trong mạng 5G Core, các chức năng chính gồm AMF, SMF, UPF, UDM, AUSF và PCF. AMF (Access and Mobility Management Function) chịu trách nhiệm quản lý truy nhập và di động của UE, bao gồm các thủ tục đăng ký mạng, quản lý kết nối và xử lý báo hiệu điều khiển. SMF (Session Management Function) quản lý phiên truyền dữ liệu, lựa chọn UPF phù hợp và điều khiển các tham số liên quan đến kết nối dữ liệu của người dùng. UPF (User Plane Function) là thành phần thuộc mặt phẳng người dùng, chịu trách nhiệm chuyển tiếp lưu lượng dữ liệu giữa NG-RAN và mạng dữ liệu bên ngoài. UDM (Unified Data Management) lưu trữ và quản lý dữ liệu thuê bao, hỗ trợ quá trình nhận dạng và cấp quyền dịch vụ. AUSF (Authentication Server Function) thực hiện chức năng xác thực người dùng khi truy nhập mạng. PCF (Policy Control Function) quản lý chính sách, quy tắc dịch vụ và hỗ trợ điều khiển chất lượng dịch vụ. Trong kiến trúc này, mặt phẳng điều khiển chủ yếu đi qua các chức năng như AMF, SMF, UDM, AUSF và PCF để quản lý kết nối, xác thực và chính sách, trong khi mặt phẳng người dùng đi theo luồng UE, gNB, UPF và DN/Internet để truyền dữ liệu thực tế.

Các tham số của tín hiệu 5G NR: Tín hiệu 5G NR được thiết kế linh hoạt thông qua nhiều tham số kỹ thuật, trong đó quan trọng nhất là băng thông, khoảng cách sóng mang con, cấu trúc khung và khối tín hiệu đồng bộ [15]. Băng thông quyết định phạm vi tần số mà tín hiệu chiếm dụng; khi băng thông lớn hơn, vùng năng lượng của tín hiệu trên ảnh phổ cũng mở rộng hơn. 5G NR có thể hoạt động trên cả các dải tần thấp, dải sub-6 GHz và các dải tần cao hơn, nhờ đó hỗ trợ nhiều kịch bản truyền dẫn khác nhau. Khoảng cách sóng mang con (subcarrier spacing – SCS) là một tham số quan trọng trong hệ numerology của 5G NR. Khi SCS thay đổi, mật độ sóng mang con, cấu trúc tài nguyên và hình thái phổ của tín hiệu cũng thay đổi theo. Ngoài ra, khối tín hiệu đồng bộ (synchronization signal block – SSB) được phát định kỳ để hỗ trợ quá trình đồng bộ và truy nhập ban đầu của UE vào mạng. SSB có thể tạo ra các mẫu năng lượng đặc trưng trong miền thời gian–tần số, góp phần làm cho tín hiệu 5G NR có hình thái phổ đa dạng hơn so với LTE.

Nhìn chung, 5G NR là một hệ thống truyền thông có cấu hình linh hoạt và khả năng thích ứng cao với nhiều điều kiện triển khai khác nhau. Khi được biểu diễn dưới dạng ảnh phổ, tín hiệu 5G NR thường tạo thành vùng năng lượng có băng thông tương đối rộng, nhưng mức độ liên tục, mật độ năng lượng và biên phổ có thể thay đổi tùy theo cấu hình băng thông, SCS, tài nguyên

truyền dẫn và điều kiện kênh. Trong môi trường có nhiễu, fading hoặc sự đồng tồn tại với LTE và ASR, ranh giới giữa 5G NR với các lớp tín hiệu khác có thể trở nên khó phân biệt. Vì vậy, trong bài toán phân đoạn ảnh phổ, mô hình học sâu cần học được các đặc trưng phổ có tính khái quát, vừa đủ khả năng nhận diện vùng chiếm dụng linh hoạt của 5G NR, vừa phân biệt được nó với LTE, ASR và nền nhiễu.


2.1.4 Tổng quan về tín hiệu radar ASR

ASR (Airport Surveillance Radar) là hệ thống radar giám sát hàng không, được sử dụng nhằm phát hiện, giám sát và hỗ trợ theo dõi các mục tiêu bay trong vùng không phận quan sát. Khác với LTE và 5G NR là các hệ thống truyền thông di động phục vụ trao đổi dữ liệu giữa thiết bị người dùng và mạng, ASR hoạt động dựa trên nguyên lý phát tín hiệu điện từ ra môi trường và thu nhận tín hiệu phản xạ từ mục tiêu. Khi xung radar gặp một mục tiêu như máy bay, một phần năng lượng sẽ phản xạ trở lại phía radar. Từ tín hiệu phản hồi này, hệ thống có thể thực hiện các bước xử lý để phát hiện mục tiêu, ước lượng các thông tin liên quan đến vị trí, hướng, vận tốc và hỗ trợ hiển thị cho hệ thống kiểm soát không lưu. Do đặc trưng phát-thu theo xung, tín hiệu ASR có hình thái khác biệt rõ rệt so với các tín hiệu truyền thông di động, đặc biệt ở tính chất xuất hiện ngắt theo thời gian, năng lượng tập trung cục bộ và phụ thuộc mạnh vào quá trình phản xạ từ mục tiêu.

Kiến trúc của hệ thống radar ASR: Kiến trúc tổng quan của hệ thống radar ASR được minh họa trong Hình 2.4. Hệ thống có thể được nhìn nhận như một chuỗi xử lý gồm các khối chính: khối điều khiển, bộ phát radar, ăng-ten ASR, mục tiêu trong vùng quan sát, khối thu và xử lý, và hệ thống hiển thị hoặc kiểm soát không lưu (Air Traffic Control – ATC). Khối điều khiển có nhiệm vụ thiết lập và điều phối hoạt động của hệ thống, bao gồm cấu hình dạng sóng phát, chu kỳ phát xung, thời điểm chuyển mạch phát-thu và các tham số vận hành liên quan. Tín hiệu điều khiển được đưa đến bộ phát radar để tạo ra dạng sóng phù hợp với nhiệm vụ giám sát. Trong bộ phát, khối tạo dạng sóng sinh tín hiệu radar ban đầu, sau đó tín hiệu được khuếch đại công suất trước khi đi qua bộ chuyển mạch phát-thu. Bộ chuyển mạch này đóng vai trò tách biệt quá trình phát và thu, giúp cùng một hệ thống ăng-ten có thể phát xung ra môi trường và tiếp nhận tín hiệu phản hồi quay trở lại.

Sau khi được phát qua ăng-ten ASR, tín hiệu radar lan truyền trong không gian theo hướng vùng không phận cần giám sát. Khi tín hiệu gặp mục tiêu, chẳng hạn như máy bay, mức phản xạ phụ thuộc vào tiết diện phản xạ radar của mục tiêu (Radar Cross Section – RCS). Mục tiêu có RCS lớn thường tạo ra tín hiệu phản hồi mạnh hơn, trong khi mục tiêu có RCS nhỏ hoặc ở xa có thể tạo tín hiệu phản hồi yếu hơn và dễ bị che khuất bởi nhiễu. Tín hiệu phản hồi được ăng-ten thu lại và đưa vào khối thu, nơi tín hiệu được khuếch đại, lọc và chuyển đến chuỗi xử lý radar. Trong khối thu và xử lý, các bước như nén xung, loại bỏ clutter, phát hiện mục tiêu và theo dõi

Kiến trúc tổng quan của hệ thống radar ASR



Hình 2.4: Kiến trúc tổng quan của hệ thống radar ASR. Luồng tín hiệu chính bao gồm quá trình tạo xung, khuếch đại, phát qua ăng-ten, thu tín hiệu phản hồi từ mục tiêu, xử lý tín hiệu radar và hiển thị kết quả tại hệ thống ATC. Đường liền thể hiện luồng tín hiệu chính, trong khi đường nét đứt thể hiện tín hiệu điều khiển.

mục tiêu được thực hiện tuần tự. Nén xung giúp cải thiện khả năng phân giải, khối loại bỏ clutter giảm ảnh hưởng của phản xạ không mong muốn từ mặt đất, công trình hoặc thời tiết, còn khối phát hiện và theo dõi giúp xác định mục tiêu thật và duy trì thông tin chuyển động của mục tiêu theo thời gian. Kết quả cuối cùng được chuyển đến hệ thống ATC để hiển thị thông tin giám sát, hỗ trợ người vận hành trong quá trình theo dõi và điều phối không lưu.

Các tham số của tín hiệu ASR: Tín hiệu ASR được đặc trưng bởi nhiều tham số như tần số sóng mang, công suất phát, độ rộng xung, băng thông xung, chu kỳ lặp xung, tốc độ quét của ăng-ten và đặc tính phản xạ của mục tiêu. Công suất phát quyết định mức năng lượng của xung radar và ảnh hưởng đến khả năng phát hiện mục tiêu ở khoảng cách xa. Độ rộng xung và băng thông liên quan trực tiếp đến khả năng phân giải theo khoảng cách, trong khi chu kỳ lặp xung quyết định mật độ xuất hiện của các xung radar theo thời gian. Ngoài ra, quá trình quét của ăng-ten làm cho tín hiệu radar có thể chỉ xuất hiện mạnh tại một số thời điểm nhất định khi chùm tia quét qua vùng mục tiêu. Chuyển động của mục tiêu cũng có thể gây ra dịch Doppler, làm thay đổi tần số quan sát được của tín hiệu phản hồi. Bên cạnh đó, clutter và nhiễu nền là các yếu tố quan trọng vì chúng có thể tạo ra các thành phần năng lượng không mong muốn, gây khó khăn cho việc tách tín hiệu mục tiêu khỏi môi trường xung quanh.

Nhìn chung, ASR có đặc trưng phổ khác biệt so với LTE và 5G NR. Nếu LTE và 5G NR thường tạo ra các vùng năng lượng tương đối rộng và có xu hướng liên tục hơn trên ảnh phổ, thì ASR thường xuất hiện dưới dạng các vệt hoặc xung năng lượng ngắn, cục bộ và không liên tục theo thời gian. Trong điều kiện SNR thấp, các xung ASR yếu có thể bị nhiễu nền che khuất, làm cho mô hình khó phân biệt giữa tín hiệu radar và lớp Noise. Ngược lại, một số vùng nhiễu hoặc clutter có năng lượng cao cũng có thể gây nhầm lẫn với tín hiệu ASR. Khi ASR cùng tồn tại với LTE và 5G NR, các xung radar có thể chồng lấn lên vùng phổ của tín hiệu truyền thông, khiến ranh giới phân đoạn trở nên phức tạp hơn. Vì vậy, trong bài toán phân đoạn ảnh phổ, mô hình cần học được đồng thời đặc trưng vùng phổ rộng của tín hiệu truyền thông và đặc trưng xung ngắn, rời rạc của ASR để gán nhãn chính xác từng điểm ảnh trên miền thời gian–tần số.

2.2 LÝ THUYẾT VỀ PHÂN TÍCH THỜI GIAN–TẦN SỐ

2.2.1 Phân tích trong miền thời gian

Trong miền thời gian, tín hiệu được quan sát thông qua sự thay đổi biên độ theo thời gian. Cách biểu diễn này thường được thể hiện dưới dạng dạng sóng, cho phép xác định trực tiếp thời điểm xuất hiện của các sự kiện như xung, đỉnh biên độ, đoạn tín hiệu bắt đầu hoặc kết thúc. Đối với các tín hiệu có tính chất ngắn hạn như radar ASR, miền thời gian có thể giúp nhận biết thời điểm xuất hiện của các xung phát hoặc tín hiệu phản hồi. Đây là ưu điểm quan trọng của biểu diễn thời gian, vì nó giữ lại thông tin về thứ tự và vị trí xảy ra của các biến thiên tín hiệu.

Tuy nhiên, việc chỉ quan sát tín hiệu theo thời gian không cung cấp đầy đủ thông tin về thành phần tần số mà tín hiệu chiếm dụng. Hai tín hiệu có dạng biến thiên biên độ tương đối giống nhau vẫn có thể khác biệt đáng kể về phổ tần. Trong bài toán nhận dạng tín hiệu vô tuyến, hạn chế này đặc biệt rõ ràng vì LTE, 5G NR và ASR có thể khác nhau ở băng thông, cấu trúc sóng mang, mật độ năng lượng và vùng chiếm dụng tần số. Nếu chỉ dựa vào dạng sóng thời gian, rất khó xác định tín hiệu đang nằm ở dải tần nào hoặc phân biệt các tín hiệu có đặc trưng phổ gần nhau. Vì vậy, miền thời gian tuy hữu ích trong việc định vị sự kiện, nhưng chưa đủ để mô tả toàn diện các tín hiệu vô tuyến không dừng.

2.2.2 Phân tích trong miền tần số

Miền tần số cho phép quan sát tín hiệu thông qua các thành phần phổ cấu thành. Phương pháp phổ biến nhất là biến đổi Fourier, cùng với biến đổi Fourier nhanh, nhằm chuyển tín hiệu từ miền thời gian sang miền tần số. Kết quả thu được thường là phổ biên độ hoặc phổ công suất,

cho biết năng lượng của tín hiệu tập trung tại những thành phần tần số nào. Trong các hệ thống vô tuyến, biểu diễn tần số rất hữu ích để đánh giá phạm vi chiếm dụng phổ, băng thông tín hiệu và mức năng lượng tại từng dải tần. Nhờ đó, miền tần số cung cấp cái nhìn tổng quát về cấu trúc phổ của tín hiệu.

Dù vậy, phổ Fourier truyền thống thường được tính trên toàn bộ khoảng thời gian quan sát, nên thông tin về sự thay đổi theo thời gian bị mất đi. Điều này phù hợp với các tín hiệu dừng, tức là tín hiệu có đặc tính phổ gần như không đổi trong suốt thời gian phân tích. Tuy nhiên, các tín hiệu vô tuyến trong thực tế thường không dừng. ASR có thể xuất hiện theo dạng xung ngắn, LTE và 5G NR có thể thay đổi tài nguyên truyền dẫn theo thời gian, còn kênh truyền có thể gây ra fading hoặc dịch Doppler. Khi đó, một phổ tần số duy nhất chỉ thể hiện thành phần trung bình của tín hiệu, nhưng không cho biết thời điểm các thành phần tần số xuất hiện, tồn tại hoặc suy giảm. Do đó, miền tần số tuy cung cấp thông tin về phổ, nhưng không thể mô tả đầy đủ sự biến đổi động của tín hiệu.

2.2.3 Phân tích thời gian–tần số

Phân tích thời gian–tần số được sử dụng nhằm kết hợp ưu điểm của hai miền biểu diễn trên. Thay vì chỉ mô tả tín hiệu theo thời gian hoặc chỉ mô tả thành phần phổ tổng thể, phương pháp này biểu diễn sự phân bố năng lượng của tín hiệu đồng thời theo cả thời gian và tần số [16]. Biểu diễn thu được thường là một hàm hai chiều, ký hiệu là $\text{TFR}(t, f)$, trong đó mỗi giá trị tại vị trí (t, f) phản ánh mức năng lượng hoặc cường độ tín hiệu xung quanh thời điểm t và tần số f . Nhờ cách biểu diễn này, có thể quan sát được không chỉ tín hiệu chiếm dụng dải tần nào, mà còn biết được dải tần đó xuất hiện vào thời điểm nào và thay đổi ra sao theo thời gian.

Đối với bài toán phân đoạn ảnh phổ trong luận văn, biểu diễn thời gian–tần số giữ vai trò đặc biệt quan trọng. LTE thường tạo ra vùng năng lượng tương đối liên tục trên một dải tần nhất định, 5G NR có thể có vùng chiếm dụng phổ linh hoạt hơn do thay đổi băng thông và khoảng cách sóng mang con, trong khi ASR thường xuất hiện dưới dạng các vệt năng lượng ngắn và rời rạc. Những đặc điểm này khó được mô tả đầy đủ nếu chỉ sử dụng riêng miền thời gian hoặc miền tần số. Khi chuyển tín hiệu thành ảnh phổ, các cấu trúc này trở nên trực quan hơn và có thể được xử lý như một ảnh hai chiều. Đây là cơ sở để áp dụng các mô hình phân đoạn ngữ nghĩa nhằm gán nhãn từng điểm ảnh trên mặt phẳng thời gian–tần số cho các lớp Noise, LTE, 5G NR và ASR.

2.2.4 So sánh các phương pháp biểu diễn thời gian–tần số

Các kỹ thuật biểu diễn thời gian–tần số đều nhằm mô tả sự phân bố năng lượng của tín hiệu trên hai chiều thời gian và tần số. Tuy nhiên, mỗi phương pháp có cách xây dựng biểu diễn khác nhau, dẫn đến sự khác biệt về độ phân giải, độ phức tạp tính toán và mức độ phù hợp với từng loại tín hiệu. Trong phạm vi luận văn, một số kỹ thuật tiêu biểu được trình bày như sau:

- **Biến đổi Fourier thời gian ngắn (Short-Time Fourier Transform – STFT):** STFT phân tích tín hiệu bằng cách sử dụng một hàm cửa sổ để trích xuất các đoạn tín hiệu ngắn theo thời gian, sau đó áp dụng biến đổi Fourier cho từng đoạn. Với tín hiệu $s(t)$ và hàm cửa sổ $w(t)$, STFT được biểu diễn bởi:

$$\text{STFT}_s(\tau, f) = \int_{-\infty}^{\infty} s(t)w(t - \tau)e^{-j2\pi ft} dt, \quad (2.2)$$

trong đó τ là vị trí dịch của cửa sổ và f là tần số. Biểu diễn STFT cho biết thành phần tần số của tín hiệu tại từng khoảng thời gian cục bộ. Ưu điểm của phương pháp này là đơn giản, dễ triển khai và có thể tính toán hiệu quả nhờ FFT, nên STFT thường được sử dụng trong các hệ thống phân tích thời gian–tần số của tín hiệu không dừng [16, 17]. Kết quả thu được thường được gọi là spectrogram, có dạng ảnh hai chiều nên rất phù hợp làm đầu vào cho các mô hình học sâu. Hạn chế chính của STFT là độ phân giải thời gian và tần số bị cố định bởi độ dài cửa sổ. Cửa sổ ngắn giúp mô tả tốt các biến đổi nhanh theo thời gian nhưng làm giảm độ phân giải tần số, trong khi cửa sổ dài cho phổ tần rõ hơn nhưng làm mờ thông tin thời gian.

- **Biến đổi wavelet liên tục (Continuous Wavelet Transform – CWT):** CWT phân tích tín hiệu bằng các phiên bản co giãn và dịch chuyển của một wavelet mẹ [18]. Với wavelet mẹ $\psi(t)$, CWT của tín hiệu $s(t)$ được viết dưới dạng:

$$\text{CWT}_s(a, b) = \frac{1}{\sqrt{|a|}} \int_{-\infty}^{\infty} s(t)\psi^*\left(\frac{t-b}{a}\right) dt, \quad (2.3)$$

trong đó a là tham số tỉ lệ, b là tham số dịch chuyển và $\psi^*(t)$ là liên hợp phức của wavelet mẹ. Khác với STFT, CWT không dùng một cửa sổ cố định mà thay đổi độ rộng hàm phân tích theo tỉ lệ. Nhờ vậy, phương pháp này có khả năng cung cấp độ phân giải thời gian tốt hơn ở vùng tần số cao và độ phân giải tần số tốt hơn ở vùng tần số thấp. Điều này hữu ích với các tín hiệu có cấu trúc thay đổi trên nhiều thang thời gian khác nhau. Tuy nhiên, CWT thường có chi phí tính toán cao hơn STFT, biểu diễn thu được có thể dư thừa và kết quả phụ thuộc đáng kể vào việc lựa chọn wavelet mẹ.

- **Phân bố Wigner–Ville (Wigner–Ville Distribution – WVD):** WVD là một phương

pháp biểu diễn thời gian–tần số thuộc nhóm song tuyến tính [16, 19]. Phương pháp này xây dựng biểu diễn dựa trên tương quan tức thời của tín hiệu. Với tín hiệu $s(t)$, WVD được định nghĩa như sau:

$$W_s(t, f) = \int_{-\infty}^{\infty} s\left(t + \frac{\tau}{2}\right) s^*\left(t - \frac{\tau}{2}\right) e^{-j2\pi f\tau} d\tau, \quad (2.4)$$

trong đó $s^*(t)$ là liên hợp phức của tín hiệu và τ là biến trễ. Ưu điểm của WVD là khả năng tạo biểu diễn có độ tập trung cao trên mặt phẳng thời gian–tần số, đặc biệt đối với tín hiệu đơn thành phần. Tuy nhiên, khi tín hiệu có nhiều thành phần hoặc nhiều nguồn cùng xuất hiện, WVD dễ sinh ra các thành phần chéo. Các thành phần này không tương ứng với tín hiệu thật mà xuất hiện do sự tương tác giữa các thành phần phổ khác nhau. Trong môi trường đồng tồn tại LTE, 5G NR và ASR, hiện tượng này có thể làm biểu diễn trở nên khó diễn giải và gây bất lợi cho bài toán phân đoạn.

- **S-transform:** S-transform là một phương pháp có thể xem như kết hợp giữa ý tưởng của sổ của STFT và khả năng thay đổi độ rộng theo tần số của wavelet. Một dạng biểu diễn của S-transform đối với tín hiệu $s(t)$ được viết như sau:

$$S_s(\tau, f) = \int_{-\infty}^{\infty} s(t) \frac{|f|}{\sqrt{2\pi}} e^{-\frac{(t-\tau)^2 f^2}{2}} e^{-j2\pi f t} dt, \quad (2.5)$$

trong đó τ là thời điểm quan sát và f là tần số. Điểm khác biệt của S-transform so với STFT là cửa sổ phân tích có độ rộng phụ thuộc vào tần số. Nhờ vậy, phương pháp này có thể mô tả tín hiệu không dừng linh hoạt hơn trong một số trường hợp. Tuy nhiên, S-transform phức tạp hơn STFT và không phải lúc nào cũng cần thiết nếu mục tiêu chính là tạo ảnh phổ ổn định, dễ diễn giải và phù hợp với mô hình phân đoạn học sâu.

Từ các phương pháp trên, STFT được lựa chọn làm kỹ thuật tạo ảnh phổ đầu vào cho hệ thống trong luận văn. Mặc dù tồn tại sự đánh đổi cố định giữa độ phân giải thời gian và tần số, STFT vẫn có ưu điểm lớn về tính ổn định, tốc độ tính toán và khả năng tạo ra biểu diễn trực quan. Đối với các tín hiệu vô tuyến cần khảo sát, spectrogram tạo bởi STFT có thể thể hiện vùng chiếm dụng tương đối liên tục của LTE, cấu trúc phổ linh hoạt của 5G NR, các thành phần xung ngắn của ASR và vùng nhiễu nền. Nhờ đó, biểu diễn này phù hợp để chuyển bài toán phân tích tín hiệu sang bài toán phân đoạn ảnh, trong đó mỗi điểm ảnh trên mặt phẳng thời gian–tần số được gán nhãn tương ứng với Noise, LTE, 5G NR hoặc ASR.

2.3 TỔNG QUAN VỀ LÝ THUYẾT HỌC SÂU

Học sâu (deep learning – DL) là một nhánh quan trọng của trí tuệ nhân tạo, tập trung vào việc xây dựng các mô hình có khả năng tự học đặc trưng từ dữ liệu thông qua nhiều tầng xử lý

liên tiếp. Khác với các phương pháp học máy truyền thống thường phụ thuộc nhiều vào đặc trưng được thiết kế thủ công, học sâu cho phép mô hình tự động biến đổi dữ liệu đầu vào thành các biểu diễn có mức độ trừu tượng ngày càng cao. Nhờ khả năng này, học sâu đã được ứng dụng rộng rãi trong nhiều lĩnh vực như thị giác máy tính, xử lý tín hiệu, nhận dạng giọng nói, xử lý ngôn ngữ tự nhiên và các hệ thống ra quyết định dựa trên dữ liệu.


Một đặc điểm quan trọng của học sâu là khả năng học biểu diễn phân cấp. Ở các tầng đầu, mô hình thường học các đặc trưng đơn giản và mang tính cục bộ, chẳng hạn như biên, vùng chuyển tiếp, kết cấu hoặc các mẫu lặp lại trong dữ liệu. Khi đi qua các tầng sâu hơn, các đặc trưng đơn giản này được kết hợp để hình thành những biểu diễn có ý nghĩa cao hơn, giúp mô hình nhận biết được cấu trúc, quan hệ và ngữ cảnh của dữ liệu đầu vào. Cơ chế học biểu diễn nhiều tầng này giúp học sâu trở nên phù hợp với các bài toán phức tạp, nơi dữ liệu có tính phi tuyến cao và khó mô tả đầy đủ bằng các quy tắc thủ công.

Trong các bài toán liên quan đến hình ảnh, học sâu cho phép mô hình khai thác đồng thời thông tin cục bộ và thông tin ngữ nghĩa ở nhiều mức độ khác nhau. Các kiến trúc học sâu có thể học cách nhận biết những đặc điểm nhỏ trong ảnh, đồng thời tổng hợp chúng thành các biểu diễn toàn cục phục vụ cho các nhiệm vụ như phân loại ảnh, phát hiện đối tượng và phân đoạn ngữ nghĩa. Do đó, học sâu trở thành nền tảng quan trọng cho nhiều mô hình thị giác máy tính hiện đại. Trong các phần tiếp theo, luận văn trình bày một số kiến trúc và thành phần học sâu thường được sử dụng trong bài toán phân đoạn ảnh, bao gồm mạng nơ-ron sâu, mạng nơ-ron tích chập, biểu diễn tiềm ẩn và các mô hình liên quan.

2.3.1 Mạng nơ-ron sâu

Mạng nơ-ron sâu (deep neural network – DNN) là một trong những mô hình nền tảng của học sâu. Về mặt cấu trúc, DNN được hình thành từ nhiều lớp nơ-ron được xếp nối tiếp nhau, bao gồm lớp đầu vào, một hoặc nhiều lớp ẩn và lớp đầu ra. Dữ liệu được đưa vào mạng thông qua lớp đầu vào, sau đó lần lượt đi qua các lớp ẩn để được biến đổi thành các biểu diễn trung gian trước khi tạo ra kết quả dự đoán ở lớp cuối. Hình 2.5 minh họa kiến trúc cơ bản của một mạng nơ-ron sâu kết nối đầy đủ, trong đó các nơ-ron giữa hai lớp liên tiếp được liên kết với nhau thông qua các trọng số có thể học được.

Trong một mạng DNN, mỗi nơ-ron nhận các giá trị đầu vào từ lớp trước, kết hợp chúng thông qua các trọng số và độ lệch, sau đó đưa kết quả qua một hàm kích hoạt phi tuyến. Nhờ sự xuất hiện của các hàm kích hoạt, mạng không chỉ thực hiện các phép biến đổi tuyến tính đơn giản mà còn có khả năng mô hình hóa các quan hệ phi tuyến phức tạp trong dữ liệu. Đây là yếu tố quan trọng giúp DNN có thể giải quyết nhiều bài toán khác nhau như phân loại, hồi quy, nhận dạng mẫu và dự đoán dữ liệu.



Hình 2.5: Kiến trúc cơ bản của một mạng nơ-ron sâu. Mạng gồm lớp đầu vào, nhiều lớp ẩn và lớp đầu ra. Các đường nối biểu diễn các kết nối có trọng số giữa các nơ-ron, trong khi mũi tên thể hiện hướng truyền dữ liệu qua mạng.

Các lớp ẩn đóng vai trò trung tâm trong DNN vì đây là nơi dữ liệu được biến đổi qua nhiều mức biểu diễn khác nhau. Ở những lớp gần đầu vào, mạng thường học các đặc trưng còn tương đối đơn giản và gần với dữ liệu gốc. Khi đi sâu hơn, các lớp phía sau có thể kết hợp những đặc trưng đơn giản này để tạo thành các biểu diễn trừu tượng và có ý nghĩa hơn. Quá trình này được gọi là học biểu diễn phân cấp, cho phép mô hình tự động xây dựng đặc trưng từ dữ liệu thay vì phụ thuộc hoàn toàn vào các đặc trưng được thiết kế thủ công.

Quá trình huấn luyện DNN nhằm tìm ra tập trọng số phù hợp để mô hình có thể đưa ra dự đoán chính xác. Trong giai đoạn huấn luyện, dữ liệu đầu vào được truyền qua mạng để tạo ra kết quả dự đoán. Kết quả này sau đó được so sánh với nhãn hoặc giá trị mục tiêu thông qua một hàm mất mát. Sai số thu được được lan truyền ngược qua các lớp bằng thuật toán lan truyền ngược, từ đó cập nhật các trọng số của mạng thông qua một thuật toán tối ưu như gradient descent hoặc các biến thể của nó. Sau nhiều vòng lặp huấn luyện, mô hình dần điều chỉnh các tham số để giảm sai số và cải thiện khả năng tổng quát hóa trên dữ liệu chưa quan sát.

Mặc dù DNN có khả năng học biểu diễn mạnh, kiến trúc kết nối đầy đủ cũng tồn tại một số hạn chế khi áp dụng cho dữ liệu có cấu trúc lớn như hình ảnh. Nếu ảnh được làm phẳng thành một vector trước khi đưa vào mạng, các quan hệ không gian tự nhiên giữa những điểm ảnh lân cận có thể bị suy giảm. Ngoài ra, khi kích thước đầu vào lớn, số lượng kết nối và tham số trong mạng tăng rất nhanh, làm cho mô hình trở nên nặng hơn và dễ gặp nguy cơ quá khớp nếu dữ liệu huấn luyện không đủ lớn. Vì vậy, DNN kết nối đầy đủ thường phù hợp hơn với dữ liệu dạng vector hoặc

được sử dụng ở các tầng cuối của mô hình, thay vì trực tiếp xử lý toàn bộ ảnh ở độ phân giải cao.

Từ những hạn chế trên, các kiến trúc chuyên biệt hơn đã được phát triển để xử lý dữ liệu có cấu trúc không gian, trong đó mạng nơ-ron tích chập là một ví dụ tiêu biểu. CNN vẫn kế thừa nguyên lý học biểu diễn nhiều tầng của DNN, nhưng thay thế các kết nối dày đặc bằng phép tích chập cục bộ và cơ chế chia sẻ trọng số. Nhờ đó, CNN có thể khai thác hiệu quả hơn cấu trúc không gian của dữ liệu, giảm số lượng tham số và trở thành một trong những kiến trúc quan trọng trong các bài toán thị giác máy tính.

2.3.2 Mạng nơ-ron tích chập

Mạng nơ-ron tích chập (convolutional neural network – CNN) là một kiến trúc học sâu được thiết kế để xử lý dữ liệu có cấu trúc dạng lưới, điển hình là ảnh hai chiều. Khác với mạng nơ-ron kết nối đầy đủ, CNN không làm phẳng toàn bộ ảnh thành một vector ngay từ đầu, mà khai thác trực tiếp cấu trúc không gian của dữ liệu thông qua các bộ lọc tích chập. Các bộ lọc này trượt trên ảnh đầu vào hoặc bản đồ đặc trưng để phát hiện các mẫu cục bộ như biên, góc, vùng chuyển tiếp, kết cấu hoặc các cấu trúc lặp lại. Nhờ cơ chế kết nối cục bộ và chia sẻ trọng số, CNN có thể giảm đáng kể số lượng tham số so với mạng kết nối đầy đủ, đồng thời vẫn duy trì khả năng học đặc trưng hiệu quả.


Một ưu điểm quan trọng của CNN là khả năng học đặc trưng theo nhiều mức độ khác nhau. Ở các tầng đầu, mạng thường học các đặc trưng đơn giản và mang tính cục bộ. Khi đi qua nhiều lớp tích chập liên tiếp, các đặc trưng này được kết hợp để tạo thành những biểu diễn phức tạp và có ý nghĩa hơn. Nhờ đó, CNN có thể được sử dụng trong nhiều bài toán thị giác máy tính như phân loại ảnh, phát hiện đối tượng, nhận dạng mẫu và phân đoạn ngữ nghĩa. Trong các bài toán phân đoạn ảnh, CNN thường đóng vai trò là bộ trích xuất đặc trưng, giúp mô hình nhận biết các vùng có cấu trúc khác nhau trên ảnh đầu vào.

Cấu trúc cơ bản của một CNN thường bao gồm một số thành phần chính như sau:

- **Lớp tích chập (convolutional layer):** Lớp tích chập là thành phần cốt lõi của CNN, có nhiệm vụ trích xuất đặc trưng từ dữ liệu đầu vào thông qua các bộ lọc có kích thước nhỏ. Mỗi bộ lọc được học trong quá trình huấn luyện và có thể phản ứng với một dạng mẫu nhất định trong ảnh. Ở các lớp đầu, bộ lọc thường phát hiện các đặc trưng đơn giản như cạnh, biên, vùng thay đổi cường độ hoặc các mẫu cục bộ. Ở các lớp sâu hơn, mạng có thể kết hợp nhiều đặc trưng đơn giản để hình thành các biểu diễn phức tạp hơn, phục vụ cho quá trình nhận dạng hoặc phân đoạn.

Về mặt tổng quát, phép tích chập trong CNN có thể được mô tả như sau:

$$\mathbf{Y}_k = \phi(\mathbf{W}_k * \mathbf{X} + b_k), \quad (2.6)$$



Hình 2.6: Kiến trúc cơ bản của một mạng CNN. Các lớp tích chập trích xuất bản đồ đặc trưng từ ảnh đầu vào, các lớp gộp làm giảm kích thước không gian, sau đó đặc trưng được đưa đến các lớp phía sau để tạo ra kết quả dự đoán.


trong đó $\mathbf{X}$ là đầu vào, $\mathbf{W}_k$ là bộ lọc thứ k , b_k là hệ số lệch, $*$ biểu thị phép tích chập, $\phi(\cdot)$ là hàm kích hoạt phi tuyến và $\mathbf{Y}_k$ là bản đồ đặc trưng được tạo ra bởi bộ lọc tương ứng.

- **Hàm kích hoạt phi tuyến (activation function):** Sau lớp tích chập, CNN thường sử dụng một hàm kích hoạt phi tuyến để tăng khả năng biểu diễn của mô hình. Nếu mạng chỉ bao gồm các phép biến đổi tuyến tính, việc xếp chồng nhiều lớp vẫn không đủ để mô tả các quan hệ phức tạp trong dữ liệu. Các hàm kích hoạt như sigmoid, tanh hoặc ReLU giúp mô hình học được các ánh xạ phi tuyến giữa đầu vào và đầu ra. Trong thực tế, ReLU được sử dụng phổ biến nhờ dạng đơn giản, chi phí tính toán thấp và khả năng hỗ trợ huấn luyện các mạng sâu hiệu quả hơn.

- **Lớp gộp (pooling layer):** Lớp gộp được sử dụng để giảm kích thước không gian của bản đồ đặc trưng, từ đó làm giảm chi phí tính toán và giúp mô hình tập trung vào các đặc trưng nổi bật. Hai dạng thường gặp là gộp cực đại (max pooling) và gộp trung bình (average pooling). Gộp cực đại chọn giá trị lớn nhất trong một vùng cục bộ, nhờ đó giữ lại các đáp ứng mạnh của đặc trưng. Gộp trung bình lấy giá trị trung bình trong vùng quan sát, giúp biểu diễn trở nên mượt hơn. Tuy nhiên, trong các bài toán yêu cầu dự đoán ở mức điểm ảnh, việc giảm kích thước đặc trưng cần được kiểm soát để tránh làm mất quá nhiều thông tin không gian.

- **Lớp chuẩn hóa (normalization layer):** Trong nhiều kiến trúc CNN hiện đại, các lớp chuẩn hóa như batch normalization thường được đặt sau lớp tích chập nhằm ổn định phân bố đặc trưng trong quá trình huấn luyện. Việc chuẩn hóa giúp mô hình hội tụ ổn định hơn, giảm sự phụ thuộc vào cách khởi tạo tham số và hỗ trợ huấn luyện các mạng sâu. Ngoài batch normalization, một số dạng chuẩn hóa khác như layer normalization, instance normalization hoặc group normalization cũng có thể được sử dụng tùy theo loại dữ liệu, kích thước lô và kiến trúc mạng.

- **Lớp kết nối đầy đủ hoặc khối dự đoán đầu ra:** Trong các mạng CNN dùng cho phân loại ảnh, sau khi đặc trưng được trích xuất qua các lớp tích chập và gộp, bản đồ đặc trưng



Hình 2.7: Minh họa tích chập theo chiều sâu và tích chập điểm. Tích chập theo chiều sâu áp dụng một bộ lọc không gian riêng cho từng kênh đầu vào, trong khi tích chập điểm sử dụng các bộ lọc 1×1 để kết hợp thông tin giữa các kênh và tạo ra số kênh đầu ra mong muốn.

thường được làm phẳng và đưa vào các lớp kết nối đầy đủ để dự đoán nhãn của toàn bộ ảnh. Tuy nhiên, trong bài toán phân đoạn ngữ nghĩa, mục tiêu không phải là dự đoán một nhãn duy nhất cho toàn ảnh, mà là gán nhãn cho từng điểm ảnh. Vì vậy, các mô hình phân đoạn hiện đại thường thay thế phần kết nối đầy đủ bằng các khối giải mã, upsampling, tích chập chuyển vị hoặc các lớp tích chập để tạo ra bản đồ phân đoạn ở độ phân giải mong muốn.

Hình 2.6 minh họa một kiến trúc CNN cơ bản trong xử lý ảnh. Có thể thấy, CNN xử lý dữ liệu bằng cách duy trì cấu trúc không gian của ảnh qua các bản đồ đặc trưng, thay vì làm phẳng toàn bộ ảnh ngay từ đầu như mạng kết nối đầy đủ. Đặc điểm này giúp CNN khai thác hiệu quả quan hệ cục bộ giữa các điểm ảnh lân cận. Vì vậy, CNN trở thành một nền tảng quan trọng cho nhiều kiến trúc thị giác máy tính hiện đại, đặc biệt là các mô hình phân đoạn ảnh dựa trên cơ chế mã hóa–giải mã.

Các biến thể tích chập hiệu quả trong CNN

Từ phép tích chập chuẩn đã trình bày ở phần trên, có thể thấy một lớp tích chập thông thường đồng thời thực hiện hai thao tác: lọc đặc trưng trong miền không gian và kết hợp thông tin giữa các kênh đầu vào. Khi số lượng kênh đặc trưng tăng, số lượng tham số và chi phí tính toán của tích chập chuẩn cũng tăng đáng kể. Để khắc phục hạn chế này, nhiều kiến trúc CNN gọn nhẹ sử dụng các biến thể tích chập hiệu quả hơn, chẳng hạn như tích chập theo chiều sâu (depthwise convolution), tích chập điểm (pointwise convolution), tích chập tách biệt theo chiều sâu (depthwise separable convolution) và tích chập giãn (dilated convolution). Các phép toán này giúp giảm chi phí tính toán hoặc mở rộng trường tiếp nhận của mạng mà không làm tăng đáng kể số lượng tham số. Cơ chế tổng quát của tích chập theo chiều sâu và tích chập điểm được minh họa trong Hình 2.7.

- **Tích chập theo chiều sâu:** Tích chập theo chiều sâu (depthwise convolution) thực hiện phép lọc không gian độc lập trên từng kênh đầu vào. Thay vì sử dụng một tập bộ lọc có chiều sâu bằng toàn bộ số kênh đầu vào như trong tích chập chuẩn, phép toán này áp dụng riêng một bộ lọc kích thước $k \times k$ cho mỗi kênh. Do đó, nếu đầu vào có C_{in} kênh, lớp tích chập theo chiều sâu sẽ sử dụng C_{in} bộ lọc không gian. Khi bỏ qua hệ số lệch, số lượng tham số của phép toán này là:

$$N_{\text{dw}} = k^2 C_{\text{in}}. \quad (2.7)$$

Cách xử lý này giúp giảm đáng kể số lượng tham số so với tích chập chuẩn. Tuy nhiên, do mỗi kênh được xử lý độc lập, tích chập theo chiều sâu chỉ khai thác đặc trưng không gian trong từng kênh mà chưa thực hiện việc kết hợp thông tin giữa các kênh khác nhau.

- **Tích chập điểm:** Tích chập điểm (pointwise convolution) là phép tích chập sử dụng bộ lọc có kích thước 1×1 . Khác với tích chập theo chiều sâu, phép toán này không mở rộng vùng quan sát không gian, mà thực hiện trộn thông tin giữa các kênh tại cùng một vị trí. Một bộ lọc pointwise có kích thước $1 \times 1 \times C_{\text{in}}$ tạo ra một kênh đầu ra. Khi sử dụng C_{out} bộ lọc như vậy, lớp tích chập điểm tạo ra đầu ra có C_{out} kênh. Khi bỏ qua hệ số lệch, số lượng tham số của tích chập điểm là:

$$N_{\text{pw}} = C_{\text{in}} C_{\text{out}}. \quad (2.8)$$


Nhờ khả năng kết hợp thông tin giữa các kênh, tích chập điểm thường được đặt sau tích chập theo chiều sâu để tạo ra biểu diễn đặc trưng đầy đủ hơn.

- **Tích chập tách biệt theo chiều sâu:** Tích chập tách biệt theo chiều sâu (depthwise separable convolution) kết hợp hai bước xử lý liên tiếp. Trước hết, tích chập theo chiều sâu được sử dụng để lọc đặc trưng không gian trên từng kênh riêng biệt. Sau đó, tích chập điểm được dùng để trộn thông tin giữa các kênh và tạo ra số kênh đầu ra mong muốn. Khi bỏ qua hệ số lệch, số lượng tham số của toàn bộ phép toán là:

$$N_{\text{sep}} = k^2 C_{\text{in}} + C_{\text{in}} C_{\text{out}}. \quad (2.9)$$

So với tích chập chuẩn có số lượng tham số là $k^2 C_{\text{in}} C_{\text{out}}$, tích chập tách biệt theo chiều sâu thường giúp giảm đáng kể độ phức tạp, đặc biệt khi k , C_{in} và C_{out} có giá trị lớn.

- **Tích chập giãn:** Bên cạnh các phép tích chập nhằm giảm số lượng tham số và chi phí tính toán, một hướng thiết kế khác là mở rộng trường tiếp nhận của bộ lọc mà không cần tăng kích thước kernel hoặc thực hiện thêm phép giảm mẫu. Cơ chế này được thực hiện thông qua tích chập giãn (dilated convolution). Trong tích chập giãn, các phần tử của bộ lọc không được áp dụng liên tiếp trên lưới điểm ảnh mà được lấy mẫu cách nhau theo một hệ số giãn d . Khi $d = 1$, phép toán trở về tích chập chuẩn. Khi $d > 1$, vùng quan sát hiệu dụng của bộ lọc được mở rộng mà không làm tăng số lượng tham số học được. Với bộ lọc có kích thước



Hình 2.8: Minh họa tích chập chuẩn và tích chập giãn. (a) Tích chập chuẩn với hệ số giãn $d = 1$, trong đó các phần tử của bộ lọc được áp dụng liên tiếp trên lưới đầu vào. (b) Tích chập giãn với hệ số giãn $d = 2$, trong đó các phần tử của bộ lọc được giãn cách nhau, giúp mở rộng trường tiếp nhận hiệu dụng mà không làm tăng số lượng tham số của bộ lọc.


$k \times k$, kích thước trường tiếp nhận hiệu dụng được xác định bởi:

$$k_{\text{eff}} = k + (k - 1)(d - 1). \quad (2.10)$$

Chẳng hạn, một bộ lọc 3×3 với hệ số giãn $d = 2$ có trường tiếp nhận hiệu dụng tương đương 5×5 , nhưng vẫn chỉ sử dụng số tham số của bộ lọc 3×3 .

Sự khác nhau giữa tích chập chuẩn và tích chập giãn được minh họa trong Hình 2.8. Trong đó, Hình 2.8(a) biểu diễn tích chập chuẩn với hệ số giãn $d = 1$, tức các phần tử của kernel được áp dụng liên tiếp trên các vị trí lân cận của đầu vào. Ngược lại, Hình 2.8(b) biểu diễn tích chập giãn với hệ số giãn $d = 2$, trong đó các phần tử của kernel được giãn cách nhau trên lưới đầu vào. Nhờ đó, tích chập giãn có thể khai thác ngữ cảnh không gian rộng hơn mà vẫn duy trì độ phân giải không gian của bản đồ đặc trưng.

Nhờ khả năng tách riêng quá trình lọc không gian, trộn kênh và mở rộng trường tiếp nhận, các biến thể tích chập trên được sử dụng rộng rãi trong các kiến trúc CNN gọn nhẹ. Tích chập theo chiều sâu và tích chập điểm giúp giảm số lượng tham số cũng như chi phí tính toán, trong khi tích chập giãn hỗ trợ khai thác ngữ cảnh rộng hơn mà vẫn giữ nguyên độ phân giải không gian của đặc trưng. Vì vậy, các phép toán này thường xuất hiện trong các mạng học sâu cần cân bằng giữa độ chính xác, tốc độ xử lý và tài nguyên tính toán.



Hình 2.9: Ví dụ minh họa phân đoạn ngữ nghĩa trên ảnh tự nhiên. Ảnh đầu vào được chuyển thành bản đồ nhãn, trong đó mỗi điểm ảnh được gán vào một lớp ngữ nghĩa như Cat, Cow, Sky, Trees hoặc Grass.

2.3.3 Phân đoạn ngữ nghĩa và phân đoạn đối tượng

Phân đoạn ảnh là một bài toán quan trọng trong xử lý ảnh và thị giác máy tính, trong đó mục tiêu là chia ảnh đầu vào thành các vùng có ý nghĩa ở mức điểm ảnh. Khác với bài toán phân loại ảnh, nơi mô hình chỉ đưa ra một nhãn chung cho toàn bộ ảnh, phân đoạn ảnh yêu cầu xác định nhãn cho từng điểm ảnh trong ảnh đầu vào. Vì vậy, kết quả của phân đoạn ảnh không chỉ cho biết ảnh chứa những lớp nào, mà còn mô tả vị trí, hình dạng và ranh giới của từng vùng thuộc các lớp đó. Đây là một bước quan trọng trong các hệ thống cần hiểu chi tiết nội dung của ảnh, chẳng hạn nhận dạng vùng đường trong ảnh giao thông, tách vùng cơ quan trong ảnh y tế hoặc xác định các vùng có ý nghĩa trong một ảnh quan sát.

Trong các dạng phân đoạn ảnh, phân đoạn ngữ nghĩa (semantic segmentation) là phương pháp gán cho mỗi điểm ảnh một nhãn lớp tương ứng. Các điểm ảnh thuộc cùng một lớp sẽ được xem như một nhóm chung, không phân biệt từng cá thể riêng biệt trong lớp đó. Ví dụ, nếu trong ảnh có nhiều vùng cây hoặc nhiều vùng cỏ, tất cả các điểm ảnh thuộc lớp cây đều được gán nhãn Trees và tất cả các điểm ảnh thuộc lớp cỏ đều được gán nhãn Grass. Như vậy, phân đoạn ngữ nghĩa tập trung vào câu hỏi mỗi điểm ảnh thuộc lớp nào, thay vì điểm ảnh đó thuộc về cá thể nào.

Hình 2.9 minh họa trực quan nguyên lý của phân đoạn ngữ nghĩa. Ở hàng trên là các ảnh tự nhiên đầu vào gồm những đối tượng như mèo, bò, bầu trời, cây và cỏ. Ở hàng dưới là bản đồ phân đoạn tương ứng, trong đó mỗi vùng ảnh được tô màu và gán nhãn theo lớp ngữ nghĩa. Có thể thấy, mô hình không chỉ xác định trong ảnh có mèo hoặc bò, mà còn chỉ ra chính xác vùng điểm ảnh nào thuộc về mèo, vùng nào thuộc về bò và vùng nào thuộc về nền như bầu trời, cây hoặc cỏ. Điều này cho thấy phân đoạn ngữ nghĩa cung cấp thông tin chi tiết hơn so với phân loại

ảnh thông thường.

Phân đoạn đối tượng (instance segmentation) cũng thực hiện dự đoán nhãn ở mức điểm ảnh, nhưng có thêm yêu cầu phân biệt từng cá thể riêng biệt thuộc cùng một lớp. Chẳng hạn, nếu trong một ảnh có nhiều con bò, phân đoạn ngữ nghĩa chỉ gán tất cả các điểm ảnh của chúng vào lớp Cow, trong khi phân đoạn đối tượng sẽ tách từng con bò thành các thực thể khác nhau. Do đó, phân đoạn đối tượng phù hợp với các bài toán cần đếm số lượng hoặc theo dõi từng cá thể riêng biệt, chẳng hạn đếm người, đếm xe hoặc tách từng vật thể trong ảnh tự nhiên.

Trong phạm vi luận văn, mục tiêu chính là xác định vùng ảnh thuộc từng lớp trên ảnh phổ thời gian–tần số, thay vì tách từng cá thể riêng biệt của cùng một loại tín hiệu. Nói cách khác, mỗi điểm ảnh trên ảnh phổ cần được gán vào một lớp ngữ nghĩa cụ thể như Noise, LTE, 5G NR hoặc ASR. Các vùng thuộc cùng một lớp tín hiệu được xem là một nhóm chung, tương tự như cách các vùng Cat, Cow, Sky hoặc Grass được gán nhãn trong Hình 2.9. Vì vậy, bài toán trong luận văn phù hợp với hướng phân đoạn ngữ nghĩa hơn là phân đoạn đối tượng.

Cách mô hình hóa này giúp bài toán cảm nhận phổ được chuyển thành bài toán gán nhãn điểm ảnh. Ảnh phổ đầu vào được xem như một ảnh hai chiều, trong đó mỗi điểm ảnh biểu diễn thông tin tại một vị trí thời gian–tần số. Đầu ra của mô hình là một bản đồ nhãn có cùng kích thước hoặc được nội suy về cùng kích thước với ảnh đầu vào. Thông qua bản đồ nhãn này, có thể xác định vùng nào thuộc về nhiều nền, vùng nào thuộc về LTE, 5G NR hoặc ASR. Điều này cho phép đánh giá trực tiếp khả năng khoanh vùng tín hiệu, độ chính xác tại biên và mức độ nhầm lẫn giữa các lớp trong môi trường phổ đồng tồn tại.

2.3.4 Phân đoạn ngữ nghĩa trong ảnh bằng học sâu

Phân đoạn ngữ nghĩa bằng học sâu là hướng tiếp cận trong đó các mô hình mạng nơ-ron được huấn luyện để dự đoán nhãn cho từng điểm ảnh của ảnh đầu vào [20]. Thay vì phụ thuộc vào các đặc trưng thủ công như ngưỡng cường độ, biên ảnh hoặc các quy tắc hình học cố định, mô hình học sâu có khả năng tự học đặc trưng từ dữ liệu thông qua quá trình huấn luyện. Điều này giúp mô hình thích nghi tốt hơn với các trường hợp ảnh có cấu trúc phức tạp, ranh giới giữa các lớp không rõ ràng hoặc dữ liệu bị ảnh hưởng bởi nhiễu và biến dạng.

Phần lớn các mô hình phân đoạn ngữ nghĩa hiện đại được xây dựng theo kiến trúc mã hóa–giải mã [21, 20]. Bộ mã hóa (encoder) có nhiệm vụ trích xuất đặc trưng từ ảnh đầu vào và chuyển ảnh sang các biểu diễn có mức ngữ nghĩa cao hơn. Ở các tầng đầu, mô hình thường học các đặc trưng cục bộ như biên, vùng chuyển tiếp, kết cấu hoặc các mẫu nhỏ trong ảnh. Khi đi sâu hơn, các đặc trưng này được kết hợp để tạo thành biểu diễn trừu tượng hơn, giúp mô hình nhận biết cấu trúc lớn và ngữ cảnh tổng thể của ảnh.

Bộ giải mã (decoder) sử dụng các đặc trưng đã được trích xuất để tạo ra bản đồ phân đoạn ở độ phân giải mong muốn. Do quá trình mã hóa thường làm giảm kích thước không gian của đặc trưng, decoder cần thực hiện các bước tăng kích thước như upsampling, nội suy, tích chập chuyển vị hoặc các khối giải mã chuyên biệt. Trong nhiều kiến trúc, đặc trưng từ các tầng nông của encoder cũng được truyền sang decoder thông qua các kết nối tắt. Các kết nối này giúp bổ sung thông tin không gian bị suy giảm trong quá trình mã hóa, từ đó cải thiện khả năng xác định ranh giới giữa các vùng khác nhau trên ảnh.


Các kiến trúc dựa trên CNN thường được sử dụng rộng rãi trong phân đoạn ngữ nghĩa nhờ khả năng khai thác đặc trưng cục bộ hiệu quả. Thông qua các bộ lọc tích chập, mô hình có thể nhận biết các mẫu không gian lặp lại trong ảnh như đường biên, vùng chuyển tiếp hoặc các cấu trúc có hình dạng đặc trưng. Tuy nhiên, đối với các bài toán cần kết hợp thông tin ở nhiều mức khác nhau, mô hình phân đoạn thường cần thêm các cơ chế như hợp nhất đặc trưng đa mức, kết nối tắt, mô-đun ngữ cảnh hoặc bộ giải mã phù hợp. Nhờ đó, mô hình vừa giữ được chi tiết cục bộ, vừa khai thác được thông tin ngữ nghĩa ở các tầng sâu.

Đối với ảnh phổ thời gian–tần số, phân đoạn ngữ nghĩa bằng học sâu cho phép chuyển nhiệm vụ phân tích tín hiệu thành bài toán phân loại từng điểm ảnh. Các vùng tín hiệu trong ảnh phổ có thể khác nhau về hình dạng, kích thước, mức năng lượng và mức độ liên tục. Một số vùng có biên rõ ràng, trong khi các vùng khác có thể bị mờ, đứt đoạn hoặc chồng lấn do ảnh hưởng của nhiễu và kênh truyền. Vì vậy, mô hình cần học được cả đặc trưng cục bộ tại vùng biên lẫn cấu trúc tổng thể của vùng tín hiệu trên ảnh.

Trong luận văn, hướng tiếp cận phân đoạn ngữ nghĩa được sử dụng để xác định các lớp Noise, LTE, 5G NR và ASR trên ảnh phổ. Tương tự như ví dụ trong Hình 2.9, nơi từng điểm ảnh được gán vào các lớp như Cat, Cow, Sky, Trees hoặc Grass, mỗi điểm ảnh trên ảnh phổ cũng được gán vào một lớp tín hiệu tương ứng. Sự khác biệt nằm ở chỗ dữ liệu đầu vào của luận văn không phải là ảnh tự nhiên, mà là ảnh biểu diễn tín hiệu trên miền thời gian–tần số. Do đó, phân đoạn ngữ nghĩa bằng học sâu cung cấp một cách tiếp cận phù hợp để nhận dạng, khoanh vùng và đánh giá sự xuất hiện của các tín hiệu trong môi trường phổ đồng tồn tại.

2.4 TỔNG QUAN VỀ CÁC MẠNG HỌC SÂU TRONG PHÂN ĐOẠN NGỮ NGHĨA HÌNH ẢNH

Phần này tập trung trình bày một số kiến trúc học sâu tiêu biểu thường được sử dụng trong bài toán phân đoạn ngữ nghĩa hình ảnh. Trong phạm vi luận văn, bốn mô hình được xem xét gồm



Hình 2.10: Kiến trúc tổng quan của mạng UNet++ [22]. Mô hình mở rộng kiến trúc encoder-decoder của U-Net bằng các kết nối tắt lồng nhau, giúp hợp nhất đặc trưng đa mức hiệu quả hơn trong bài toán phân đoạn.

UNet++, DeepLabV3+, BiSeNetV2 và SegFormer. Các mô hình này đại diện cho những hướng tiếp cận khác nhau: UNet++ nhấn mạnh khả năng hợp nhất đặc trưng đa mức trong kiến trúc encoder-decoder; DeepLabV3+ khai thác ngữ cảnh đa tỉ lệ thông qua tích chập atrous và mô-đun ASPP; BiSeNetV2 hướng đến phân đoạn thời gian thực với thiết kế hai nhánh gọn nhẹ; trong khi SegFormer sử dụng bộ mã hóa Transformer phân cấp kết hợp với bộ giải mã MLP đơn giản. Việc khảo sát các kiến trúc này giúp tạo cơ sở đối chiếu cho mô hình đề xuất trong các phần thực nghiệm.

2.4.1 UNet++

UNet++ [22] là một kiến trúc phân đoạn ngữ nghĩa được phát triển dựa trên nền tảng của U-Net, với mục tiêu cải thiện khả năng kết hợp đặc trưng giữa bộ mã hóa và bộ giải mã. Trong U-Net truyền thống, các đặc trưng từ encoder thường được truyền trực tiếp sang decoder thông qua các kết nối tắt. Cách làm này giúp khôi phục chi tiết không gian, nhưng vẫn tồn tại sự khác biệt ngữ nghĩa giữa đặc trưng tầng nông và đặc trưng tầng sâu. UNet++ giải quyết vấn đề này bằng cách thay thế các kết nối tắt đơn giản bằng các đường kết nối lồng nhau và dày đặc hơn, giúp giảm khoảng cách ngữ nghĩa giữa encoder và decoder trước khi hợp nhất đặc trưng.

- **Kiến trúc encoder-decoder:** Tương tự U-Net, UNet++ vẫn duy trì cấu trúc mã hóa-giải mã. Bộ mã hóa có nhiệm vụ giảm dần kích thước không gian của ảnh đầu vào và trích xuất các đặc trưng có mức ngữ nghĩa ngày càng cao. Ngược lại, bộ giải mã thực hiện quá trình tăng kích thước đặc trưng để khôi phục bản đồ phân đoạn ở độ phân giải mong muốn. Cách tổ chức

này phù hợp với các bài toán phân đoạn vì mô hình vừa cần hiểu ngữ cảnh tổng thể của ảnh, vừa cần giữ lại chi tiết không gian để xác định ranh giới giữa các vùng.

- **Kết nối tắt lồng nhau:** Điểm khác biệt quan trọng nhất của UNet++ nằm ở các kết nối tắt được thiết kế theo dạng lồng nhau. Thay vì truyền trực tiếp đặc trưng từ encoder sang decoder, UNet++ chèn thêm các khối tích chập trung gian trên đường kết nối. Các khối này giúp tinh chỉnh đặc trưng tăng nông trước khi hợp nhất với đặc trưng tăng sâu. Nhờ vậy, decoder nhận được thông tin đã được xử lý phù hợp hơn về mặt ngữ nghĩa, từ đó cải thiện chất lượng dự đoán. Trong bài toán ảnh phổ, cơ chế này có thể hỗ trợ mô hình khôi phục tốt hơn ranh giới giữa Noise, LTE, 5G NR và ASR, đặc biệt tại các vùng biên mờ hoặc vùng tín hiệu bị suy giảm bởi nhiễu.


- **Hợp nhất đặc trưng đa mức:** UNet++ khai thác đặc trưng ở nhiều độ sâu khác nhau thông qua mạng kết nối dày đặc giữa các tầng. Các đặc trưng nông thường chứa nhiều thông tin chi tiết như biên và cấu trúc cục bộ, trong khi các đặc trưng sâu mang nhiều thông tin ngữ nghĩa và ngữ cảnh hơn. Việc kết hợp các mức đặc trưng này giúp mô hình tạo ra bản đồ phân đoạn cân bằng hơn giữa độ chính xác tại biên và khả năng nhận diện vùng tín hiệu. Đối với ảnh phổ thời gian-tần số, điều này có ý nghĩa vì các tín hiệu có thể xuất hiện với nhiều kích thước và hình thái khác nhau, từ vùng phổ rộng của LTE/5G NR đến các vệt xung hẹp của ASR.

- **Giám sát sâu:** Một đặc điểm khác của UNet++ là có thể sử dụng cơ chế giám sát sâu tại nhiều mức đầu ra khác nhau. Thay vì chỉ tính mất mát ở bản đồ phân đoạn cuối cùng, mô hình có thể tạo ra các dự đoán trung gian để hỗ trợ quá trình huấn luyện. Cách làm này giúp các tầng trung gian học đặc trưng hữu ích hơn và cải thiện khả năng lan truyền gradient. Tuy nhiên, việc sử dụng giám sát sâu cũng có thể làm tăng độ phức tạp trong quá trình huấn luyện và cần được thiết kế phù hợp với bài toán cụ thể.

Nhìn chung, UNet++ là một kiến trúc mạnh trong nhóm mô hình encoder-decoder nhờ khả năng hợp nhất đặc trưng đa mức và giảm khoảng cách ngữ nghĩa giữa encoder và decoder. So với U-Net truyền thống, các kết nối tắt lồng nhau giúp mô hình khai thác thông tin chi tiết hiệu quả hơn, từ đó cải thiện chất lượng phân đoạn trong nhiều bài toán có ranh giới phức tạp. Tuy nhiên, do sử dụng nhiều khối kết nối trung gian, UNet++ thường có số lượng tham số và chi phí tính toán cao hơn so với các kiến trúc nhẹ như BiSeNetV2 hoặc SegFormer phiên bản nhỏ. Trong luận văn, UNet++ được xem như một kiến trúc tham khảo quan trọng cho hướng tiếp cận encoder-decoder giàu kết nối, giúp đánh giá vai trò của hợp nhất đặc trưng đa mức trong bài toán phân đoạn ảnh phổ.

2.4.2 DeepLabV3+

DeepLabV3+ [23] là một kiến trúc phân đoạn ngữ nghĩa được phát triển từ họ mô hình DeepLab, với mục tiêu cải thiện khả năng khai thác ngữ cảnh và khôi phục ranh giới đối tượng



Hình 2.11: Kiến trúc tổng quan của mạng DeepLabV3+ [23]. Mô hình gồm bộ mã hóa trích xuất đặc trưng, mô-đun ASPP để khai thác ngữ cảnh đa tỉ lệ và bộ giải mã để khôi phục bản đồ phân đoạn.

trong ảnh. Kiến trúc này kết hợp bộ mã hóa dựa trên mạng tích chập sâu, phép tích chập atrous và mô-đun atrous spatial pyramid pooling (ASPP), sau đó sử dụng bộ giải mã đơn giản để tái tạo bản đồ phân đoạn ở độ phân giải cao hơn. Nhờ cách tổ chức này, DeepLabV3+ có thể mở rộng vùng quan sát của mô hình mà không cần giảm mạnh độ phân giải không gian của đặc trưng. Đây là một ưu điểm quan trọng trong các bài toán phân đoạn, nơi mô hình cần đồng thời nắm bắt ngữ cảnh rộng và giữ được chi tiết tại biên giữa các lớp.

Kiến trúc tổng quan của DeepLabV3+ được minh họa trong Hình 2.11. Các thành phần chính của mô hình có thể được mô tả như sau:

- **Bộ mã hóa dựa trên mạng tích chập sâu:** Trong DeepLabV3+, bộ mã hóa thường sử dụng một mạng CNN sâu như ResNet hoặc Xception để trích xuất đặc trưng từ ảnh đầu vào. Các backbone này có khả năng học biểu diễn phân cấp, trong đó các tầng đầu giữ nhiều thông tin cục bộ như biên và kết cấu, còn các tầng sâu hơn mang nhiều thông tin ngữ nghĩa và ngữ cảnh. Đối với ảnh phổ thời gian-tần số, bộ mã hóa giúp mô hình nhận biết các cấu trúc đặc trưng như vùng phổ liên tục của LTE, vùng chiếm dụng linh hoạt của 5G NR hoặc các vệt năng lượng cục bộ của ASR. Tuy nhiên, khi mạng đi sâu hơn, độ phân giải không gian của đặc trưng thường bị giảm, do đó cần có các cơ chế bổ sung để giữ lại thông tin vị trí và ranh giới.

- **Tích chập atrous:** Còn được gọi là dilated convolution, là một thành phần quan trọng trong DeepLabV3+. Khác với tích chập thông thường, tích chập atrous chèn các khoảng trống giữa các phần tử của bộ lọc, nhờ đó mở rộng vùng quan sát mà không làm tăng số lượng tham số và không cần giảm thêm kích thước đặc trưng. Điều này giúp mô hình thu nhận thông tin ngữ cảnh trên phạm vi rộng hơn trong khi vẫn duy trì độ phân giải không gian tương đối tốt. Trong bài toán phân đoạn ảnh phổ, đặc điểm này có ích khi cần phân biệt các vùng tín hiệu có kích

thước khác nhau, từ các dải phổ rộng của tín hiệu truyền thông đến các cấu trúc hẹp hoặc ngắn của radar ASR.

- **Mô-đun ASPP:** Mô-đun atrous spatial pyramid pooling (ASPP) được sử dụng để khai thác ngữ cảnh ở nhiều tỉ lệ khác nhau. ASPP bao gồm nhiều nhánh tích chập atrous với các hệ số giãn khác nhau, cho phép mô hình quan sát đặc trưng trên nhiều phạm vi không gian trong cùng một tầng xử lý. Ngoài ra, ASPP thường kết hợp thêm nhánh pooling toàn cục để bổ sung thông tin ngữ cảnh tổng thể của ảnh. Nhờ đó, mô hình có thể xử lý tốt hơn các đối tượng hoặc vùng tín hiệu có kích thước và hình thái khác nhau. Đối với ảnh phổ, ASPP giúp mô hình kết hợp thông tin từ cả vùng cục bộ và vùng phổ rộng, góp phần giảm nhầm lẫn giữa các lớp tín hiệu khi chúng bị chồng lấn hoặc suy giảm bởi nhiễu.


- **Bộ giải mã:** So với DeepLabV3, DeepLabV3+ bổ sung thêm bộ giải mã nhằm cải thiện khả năng khôi phục chi tiết không gian của bản đồ phân đoạn. Bộ giải mã kết hợp đặc trưng cấp cao từ ASPP với đặc trưng cấp thấp từ các tầng nông của bộ mã hóa. Đặc trưng cấp cao cung cấp thông tin ngữ nghĩa, trong khi đặc trưng cấp thấp hỗ trợ khôi phục ranh giới và chi tiết cục bộ. Sau quá trình hợp nhất, các lớp tích chập và upsampling được sử dụng để tạo ra bản đồ phân đoạn cuối cùng. Cơ chế này đặc biệt quan trọng trong các bài toán yêu cầu dự đoán chính xác tại biên, chẳng hạn phân biệt ranh giới giữa LTE, 5G NR, ASR và Noise trên ảnh phổ.

Nhìn chung, DeepLabV3+ là một kiến trúc mạnh trong nhóm mô hình encoder-decoder dựa trên CNN. Ưu điểm của mô hình nằm ở khả năng khai thác ngữ cảnh đa tỉ lệ thông qua ASPP và khả năng khôi phục chi tiết không gian nhờ bộ giải mã. Tuy nhiên, do thường sử dụng backbone sâu và các nhánh xử lý song song trong ASPP, DeepLabV3+ có thể có chi phí tính toán cao hơn so với các mô hình phân đoạn nhẹ như BiSeNetV2. Trong luận văn, DeepLabV3+ được xem như một kiến trúc tham khảo quan trọng cho hướng tiếp cận CNN có khả năng khai thác ngữ cảnh mạnh, từ đó làm cơ sở so sánh với mô hình đề xuất trong bài toán phân đoạn ảnh phổ.

2.4.3 BiSeNetV2

BiSeNetV2 [24] là một kiến trúc phân đoạn ngữ nghĩa thời gian thực, được thiết kế nhằm đạt sự cân bằng giữa tốc độ xử lý và độ chính xác phân đoạn. Khác với các mô hình phân đoạn có bộ mã hóa lớn và chi phí tính toán cao, BiSeNetV2 tách quá trình trích xuất đặc trưng thành hai nhánh chính: nhánh chi tiết (detail branch) và nhánh ngữ nghĩa (semantic branch). Nhánh chi tiết giữ lại thông tin không gian ở độ phân giải tương đối cao, trong khi nhánh ngữ nghĩa khai thác đặc trưng cấp cao và ngữ cảnh rộng hơn ở độ phân giải thấp. Sau đó, thông tin từ hai nhánh được kết hợp thông qua lớp hợp nhất có hướng dẫn, giúp mô hình vừa bảo toàn được ranh giới không gian, vừa sử dụng được thông tin ngữ nghĩa cần thiết cho quá trình phân đoạn.

- **Nhánh chi tiết (detail branch):** Nhánh chi tiết được xây dựng nhằm bảo toàn thông



Hình 2.12: Kiến trúc tổng quan của mạng BiSeNetV2 [24]. Mô hình gồm nhánh chi tiết, nhánh ngữ nghĩa, lớp hợp nhất đặc trưng và các nhánh giám sát phụ được sử dụng trong giai đoạn huấn luyện.

tin không gian của ảnh đầu vào. Nhánh này thường sử dụng các lớp tích chập đơn giản với mức giảm kích thước không quá mạnh, nhờ đó giữ lại các đặc trưng như biên, vùng chuyển tiếp và cấu trúc cục bộ. Trong bài toán phân đoạn ảnh phổ, các thông tin này có vai trò quan trọng vì ranh giới giữa LTE, 5G NR, ASR và Noise có thể mỏng, mờ hoặc bị ảnh hưởng bởi nhiễu. Nếu đặc trưng bị giảm mẫu quá sâu, các vùng tín hiệu nhỏ hoặc các vết xung ngắn của ASR có thể bị mất chi tiết. Vì vậy, nhánh chi tiết giúp mô hình duy trì thông tin không gian cần thiết cho dự đoán ở mức điểm ảnh.

- **Nhánh ngữ nghĩa (semantic branch):** Nhánh ngữ nghĩa tập trung vào việc trích xuất đặc trưng cấp cao và mở rộng phạm vi ngữ cảnh của mô hình. Khác với nhánh chi tiết, nhánh này giảm kích thước không gian nhanh hơn để giảm chi phí tính toán, đồng thời sử dụng các khối xử lý gọn nhẹ để học biểu diễn ngữ nghĩa. Thông qua nhánh này, mô hình có thể nắm bắt cấu trúc tổng thể của vùng tín hiệu, chẳng hạn vùng phổ tương đối liên tục của LTE, vùng chiếm dụng linh hoạt của 5G NR hoặc các vết năng lượng rời rạc của ASR. Các đặc trưng ngữ nghĩa này giúp mô hình phân biệt tốt hơn giữa những vùng có cường độ gần nhau nhưng thuộc các lớp khác nhau.

- **Lớp hợp nhất có hướng dẫn (bilateral guided aggregation layer):** Sau khi hai nhánh tạo ra các đặc trưng ở hai mức khác nhau, BiSeNetV2 sử dụng lớp hợp nhất có hướng dẫn để kết hợp thông tin chi tiết và thông tin ngữ nghĩa. Lớp này không chỉ ghép đặc trưng một cách trực tiếp, mà còn điều phối quá trình hợp nhất để đặc trưng ngữ nghĩa hỗ trợ lựa chọn các chi tiết quan trọng, trong khi đặc trưng chi tiết giúp khôi phục tốt hơn ranh giới không gian. Nhờ đó, bản đồ đặc trưng sau hợp nhất vừa chứa thông tin ngữ cảnh, vừa giữ được độ chính xác tại biên. Đây là yếu tố quan trọng giúp BiSeNetV2 duy trì hiệu quả phân đoạn trong khi vẫn đảm bảo tốc độ xử lý cao.

- **Các nhánh giám sát phụ (booster/auxiliary segmentation heads):** Trong giai đoạn huấn luyện, BiSeNetV2 còn sử dụng các nhánh giám sát phụ tại một số tầng trung gian của

nhánh ngữ nghĩa. Các nhánh này tạo thêm tín hiệu mất mát để hỗ trợ quá trình học đặc trưng ở nhiều mức độ khác nhau. Nhờ vậy, mô hình được hướng dẫn tốt hơn trong quá trình tối ưu, đặc biệt ở các tầng sâu nơi đặc trưng đã bị giảm kích thước không gian. Tuy nhiên, các nhánh giám sát phụ chủ yếu được dùng trong huấn luyện và thường không tham gia vào quá trình suy luận cuối cùng.


Nhìn chung, BiSeNetV2 là một kiến trúc phù hợp với các bài toán phân đoạn yêu cầu tốc độ cao nhờ thiết kế hai nhánh gọn nhẹ và cơ chế hợp nhất đặc trưng hiệu quả. Đối với bài toán phân đoạn ảnh phổ, mô hình này có lợi thế ở khả năng giữ lại chi tiết cục bộ thông qua nhánh chi tiết, đồng thời khai thác ngữ cảnh rộng hơn thông qua nhánh ngữ nghĩa. Tuy nhiên, do định hướng chính của BiSeNetV2 là phân đoạn thời gian thực, khả năng biểu diễn của mô hình có thể bị giới hạn trong các trường hợp phổ phức tạp, tín hiệu bị chồng lấn hoặc nhiễu nền mạnh. Vì vậy, BiSeNetV2 được xem như một kiến trúc tham khảo quan trọng cho nhóm mô hình phân đoạn nhẹ, giúp đánh giá sự cân bằng giữa tốc độ, độ phức tạp và độ chính xác trong bài toán phân đoạn ảnh phổ.

2.4.4 SegFormer

SegFormer [25] là một kiến trúc phân đoạn ngữ nghĩa dựa trên Transformer, được thiết kế nhằm kết hợp khả năng mô hình hóa ngữ cảnh toàn cục với bộ giải mã đơn giản và hiệu quả. Khác với nhiều mô hình phân đoạn truyền thống dựa chủ yếu trên CNN, SegFormer sử dụng bộ mã hóa Transformer phân cấp để trích xuất đặc trưng ở nhiều mức độ phân giải khác nhau. Nhờ đó, mô hình có thể vừa giữ được thông tin không gian ở các tầng nông, vừa học được đặc trưng ngữ nghĩa cấp cao ở các tầng sâu. Điểm nổi bật của SegFormer là không sử dụng bộ giải mã phức tạp, mà dùng một decoder dựa trên MLP để hợp nhất các đặc trưng đa mức và tạo ra bản đồ phân đoạn cuối cùng. Kiến trúc tổng quan của SegFormer được minh họa trong Hình 2.13.

- **Bộ mã hóa Transformer phân cấp:** Bộ mã hóa của SegFormer được xây dựng dựa trên Mix Transformer (MiT), trong đó ảnh đầu vào được biến đổi thành các đặc trưng ở nhiều tỉ lệ không gian khác nhau. Thay vì chỉ tạo ra một bản đồ đặc trưng duy nhất, encoder tạo ra các đặc trưng phân cấp từ mức nông đến mức sâu. Các tầng nông thường giữ nhiều thông tin về vị trí, biên và chi tiết cục bộ, trong khi các tầng sâu chứa nhiều thông tin ngữ nghĩa và ngữ cảnh hơn. Cách tổ chức này đặc biệt phù hợp với bài toán phân đoạn, vì mô hình cần đồng thời nhận biết cấu trúc tổng thể của đối tượng và giữ được ranh giới không gian đủ chính xác.

- **Cơ chế chú ý hiệu quả:** SegFormer sử dụng self-attention trong bộ mã hóa để khai thác quan hệ giữa các vùng khác nhau trong ảnh. Tuy nhiên, so với Transformer tiêu chuẩn, mô hình được thiết kế theo hướng giảm chi phí tính toán, giúp việc xử lý ảnh có độ phân giải lớn trở nên khả thi hơn. Cơ chế chú ý cho phép mô hình tổng hợp thông tin ngữ cảnh rộng, thay vì chỉ dựa



Hình 2.13: Kiến trúc tổng quan của mạng SegFormer [25]. Mô hình gồm bộ mã hóa Transformer phân cấp để trích xuất đặc trưng đa mức và bộ giải mã MLP gọn nhẹ để hợp nhất các đặc trưng này thành bản đồ phân đoạn.

vào vùng lân cận như các phép tích chập cục bộ [26, 25]. Đối với ảnh phổ thời gian-tần số, điều này giúp mô hình liên kết các vùng tín hiệu nằm cách xa nhau, chẳng hạn các vùng năng lượng bị đứt đoạn do nhiễu hoặc các cấu trúc phổ có quan hệ theo thời gian và tần số.

- **Khối Mix-FFN:** Một thành phần quan trọng khác trong encoder của SegFormer là Mix-FFN. Khối này kết hợp phép biến đổi tuyến tính với tích chập cục bộ nhằm bổ sung thông tin vị trí vào đặc trưng. Nhờ vậy, SegFormer không cần phụ thuộc vào mã hóa vị trí cố định như một số kiến trúc Transformer khác. Điều này giúp mô hình linh hoạt hơn khi xử lý ảnh có kích thước hoặc độ phân giải thay đổi. Trong bài toán ảnh phổ, đặc điểm này có lợi vì tín hiệu có thể xuất hiện ở nhiều vị trí thời gian-tần số khác nhau, đồng thời có hình dạng và kích thước thay đổi theo điều kiện kênh truyền.

- **Bộ giải mã MLP:** Bộ giải mã của SegFormer được thiết kế đơn giản hơn so với nhiều kiến trúc phân đoạn khác. Các đặc trưng từ nhiều tầng của encoder được đưa về cùng số kênh thông qua các lớp MLP, sau đó được tăng kích thước và hợp nhất để tạo ra bản đồ phân đoạn. Thiết kế này giúp giảm độ phức tạp của decoder, trong khi vẫn tận dụng được thông tin đa mức từ bộ mã hóa. Nhờ đó, SegFormer đạt được sự cân bằng giữa độ chính xác và hiệu quả tính toán, đặc biệt phù hợp với các bài toán cần xử lý ảnh có cấu trúc phức tạp nhưng vẫn yêu cầu mô hình tương đối gọn.

Đối với bài toán phân đoạn ảnh phổ trong luận văn, SegFormer là một kiến trúc tham khảo quan trọng vì mô hình có khả năng kết hợp thông tin cục bộ và ngữ cảnh rộng. Các đặc trưng ở tầng nông có thể hỗ trợ nhận biết biên giữa các vùng Noise, LTE, 5G NR và ASR, trong khi các đặc trưng sâu giúp mô hình phân biệt các cấu trúc phổ có tính ngữ nghĩa cao hơn. Tuy nhiên, do sử dụng Transformer trong bộ mã hóa, SegFormer có thể yêu cầu chi phí tính toán cao hơn so với

một số mô hình CNN nhẹ. Vì vậy, kiến trúc này thường được xem là một hướng tiếp cận mạnh về khả năng biểu diễn, đồng thời là cơ sở so sánh với các mô hình phân đoạn nhẹ hoặc các mô hình được thiết kế riêng cho ảnh phổ.

2.4.5 So sánh tổng quan giữa các kiến trúc mạng phân đoạn ngữ nghĩa

Các kiến trúc phân đoạn ngữ nghĩa có thể được thiết kế theo nhiều hướng khác nhau, tùy thuộc vào mục tiêu ưu tiên là độ chính xác, tốc độ xử lý, khả năng khai thác ngữ cảnh hay mức độ gọn nhẹ của mô hình. Trong phạm vi luận văn, bốn kiến trúc tiêu biểu được xem xét gồm UNet++, DeepLabV3+, BiSeNetV2 và SegFormer. Các mô hình này đại diện cho những hướng tiếp cận khác nhau: UNet++ nhấn mạnh khả năng hợp nhất đặc trưng đa mức trong kiến trúc encoder-decoder; DeepLabV3+ tập trung vào khai thác ngữ cảnh đa tỉ lệ bằng tích chập atrous và ASPP; BiSeNetV2 hướng đến phân đoạn thời gian thực với thiết kế hai nhánh gọn nhẹ; còn SegFormer sử dụng bộ mã hóa Transformer phân cấp kết hợp với bộ giải mã MLP đơn giản.

Về khả năng phân đoạn

- **UNet++** ưu điểm trong việc kết hợp đặc trưng từ nhiều mức độ khác nhau thông qua các kết nối tắt lồng nhau. Các kết nối này giúp giảm khoảng cách ngữ nghĩa giữa đặc trưng tầng nông và tầng sâu trước khi đưa vào bộ giải mã. Nhờ đó, mô hình có khả năng khôi phục chi tiết không gian và ranh giới vùng phân đoạn tốt hơn so với các kết nối tắt đơn giản. Đối với ảnh phổ, đặc điểm này có lợi khi cần phân biệt các vùng biên giữa Noise, LTE, 5G NR và ASR, đặc biệt trong trường hợp tín hiệu bị mờ biên hoặc suy giảm bởi nhiễu. Tuy nhiên, do sử dụng nhiều khối kết nối trung gian, UNet++ thường có cấu trúc nặng hơn và chi phí tính toán cao hơn so với các mô hình nhẹ.

- **DeepLabV3+** có ưu thế ở khả năng khai thác ngữ cảnh đa tỉ lệ. Thông qua tích chập atrous và mô-đun ASPP, mô hình có thể mở rộng vùng quan sát mà không cần giảm mạnh độ phân giải đặc trưng. Điều này giúp DeepLabV3+ xử lý tốt các vùng tín hiệu có kích thước khác nhau, từ các vùng phổ rộng của LTE và 5G NR đến các cấu trúc hẹp hơn của ASR. Bộ giải mã trong DeepLabV3+ cũng hỗ trợ khôi phục chi tiết không gian bằng cách kết hợp đặc trưng cấp cao với đặc trưng cấp thấp. Tuy nhiên, khi sử dụng backbone sâu và ASPP đa nhánh, mô hình có thể yêu cầu nhiều tài nguyên tính toán hơn so với các kiến trúc tối ưu cho thời gian thực.

- **BiSeNetV2** được thiết kế nhằm cân bằng giữa tốc độ xử lý và chất lượng phân đoạn. Mô hình tách quá trình trích xuất đặc trưng thành nhánh chi tiết và nhánh ngữ nghĩa. Nhánh chi tiết giữ lại các thông tin không gian như biên và cấu trúc cục bộ, trong khi nhánh ngữ nghĩa khai

thác ngữ cảnh ở mức sâu hơn với chi phí tính toán thấp. Lớp hợp nhất có hướng dẫn giúp kết hợp hai loại thông tin này để tạo bản đồ đặc trưng phù hợp cho phân đoạn. Trong bài toán ảnh phổ, BiSeNetV2 có lợi thế khi cần mô hình nhẹ và tốc độ nhanh. Tuy nhiên, do định hướng chính là phân đoạn thời gian thực, khả năng biểu diễn của mô hình có thể bị hạn chế khi ảnh phổ có nhiều tín hiệu chồng lấn, nhiễu mạnh hoặc cấu trúc tín hiệu phức tạp.

- **SegFormer** khai thác bộ mã hóa Transformer phân cấp để học đặc trưng ở nhiều mức độ phân giải. Cơ chế self-attention giúp mô hình nắm bắt quan hệ ngữ cảnh rộng hơn so với các phép tích chập cục bộ truyền thống. Điều này có lợi trong các trường hợp vùng tín hiệu bị đứt đoạn, bị che khuất bởi nhiễu hoặc có quan hệ trên phạm vi rộng trong ảnh phổ. Bộ giải mã MLP của SegFormer được thiết kế đơn giản, giúp hợp nhất các đặc trưng đa mức mà không cần một decoder quá nặng. Tuy nhiên, do dựa trên Transformer, SegFormer vẫn có thể có chi phí tính toán cao hơn các mô hình CNN nhẹ, đặc biệt khi kích thước đặc trưng đầu vào lớn.

Về độ phức tạp tính toán.

UNet++ thường có độ phức tạp tương đối cao do sử dụng nhiều khối kết nối lồng nhau giữa encoder và decoder. Các kết nối này giúp cải thiện khả năng hợp nhất đặc trưng, nhưng đồng thời làm tăng số lượng phép tính và tham số. DeepLabV3+ cũng có chi phí đáng kể do phụ thuộc vào backbone CNN sâu và mô-đun ASPP gồm nhiều nhánh xử lý song song. Hai mô hình này phù hợp hơn trong các kịch bản ưu tiên độ chính xác và khả năng khai thác đặc trưng mạnh.

Ngược lại, BiSeNetV2 được thiết kế theo hướng gọn nhẹ hơn. Việc tách nhánh chi tiết và nhánh ngữ nghĩa giúp mô hình giảm chi phí tính toán nhưng vẫn giữ được một phần thông tin không gian cần thiết. Đây là lợi thế khi cần xử lý nhanh hoặc triển khai trong môi trường tài nguyên hạn chế. SegFormer có mức độ phức tạp phụ thuộc vào kích thước biến thể được sử dụng. Với các phiên bản nhỏ, SegFormer có thể đạt sự cân bằng tốt giữa hiệu quả và khả năng biểu diễn; tuy nhiên, cơ chế Transformer vẫn có thể làm tăng chi phí so với các mạng CNN nhẹ thuần túy.

Về mức độ phù hợp với bài toán ảnh phổ.

Đối với phân đoạn ảnh phổ, mô hình cần xử lý đồng thời các vùng tín hiệu có hình thái khác nhau. LTE và 5G NR thường tạo ra các vùng năng lượng có tính liên tục theo thời gian hoặc tần số, trong khi ASR có thể xuất hiện dưới dạng các vệt xung ngắn và cục bộ. Ngoài ra, nhiễu nền, fading và Doppler có thể làm cho ranh giới tín hiệu bị mờ hoặc đứt đoạn. Vì vậy, một mô hình phù hợp cần vừa khai thác được chi tiết cục bộ, vừa hiểu được ngữ cảnh rộng hơn của toàn ảnh.

UNet++ phù hợp với yêu cầu giữ chi tiết và ranh giới nhờ cơ chế kết nối tắt lồng nhau.

DeepLabV3+ phù hợp với việc khai thác các vùng phổ ở nhiều tỉ lệ nhờ ASPP và tích chập atrous. BiSeNetV2 phù hợp khi cần một mô hình nhẹ, có tốc độ xử lý nhanh và vẫn duy trì được thông tin không gian cơ bản. SegFormer có lợi thế trong việc mô hình hóa quan hệ ngữ cảnh rộng, đặc biệt khi các vùng tín hiệu nằm rời rạc hoặc có sự phụ thuộc trên phạm vi lớn. Tuy nhiên, mỗi kiến trúc đều có sự đánh đổi riêng giữa độ chính xác, tốc độ và độ phức tạp tính toán.

Nhìn chung, bốn kiến trúc trên cung cấp các hướng tiếp cận khác nhau cho bài toán phân đoạn ngữ nghĩa. Việc khảo sát các mô hình này giúp làm rõ ưu điểm và hạn chế của từng nhóm kiến trúc khi áp dụng vào ảnh phổ. Đây cũng là cơ sở để đánh giá mô hình đề xuất trong luận văn, đặc biệt ở khả năng cân bằng giữa chất lượng phân đoạn, số lượng tham số và tốc độ suy luận trong môi trường đồng tồn tại LTE, 5G NR và ASR.

Chương 3

KIẾN TRÚC VÀ PHƯƠNG PHÁP ĐỀ XUẤT

3.1 YÊU CẦU BÀI TOÁN

Để giải quyết bài toán phân đoạn phổ tín hiệu trong môi trường vô tuyến phức tạp, hệ thống đề xuất cần đáp ứng đồng thời các yêu cầu về độ chính xác, khả năng hoạt động ổn định trong điều kiện kênh truyền bất lợi và hiệu quả triển khai. Trong các kịch bản phổ dùng chung, nhiều nguồn phát như LTE, 5G NR và ASR có thể cùng tồn tại trong miền thời gian–tần số. Khi tín hiệu thu chịu ảnh hưởng bởi nhiễu, fading đa đường và dịch Doppler, cấu trúc phổ có thể bị biến dạng, dẫn đến hiện tượng biên tín hiệu bị mờ, vùng phổ bị phân mảnh hoặc nhầm lẫn giữa các lớp có đặc trưng gần nhau. Do đó, hệ thống không chỉ cần nhận biết sự xuất hiện của tín hiệu, mà còn phải xác định chính xác vùng chiếm dụng phổ của từng loại tín hiệu trên ảnh phổ.

Yêu cầu cốt lõi của hệ thống là khả năng phân đoạn ngữ nghĩa chính xác trên biểu diễn ảnh phổ. Từ tín hiệu thu trong miền thời gian, hệ thống sử dụng phép biến đổi Fourier thời gian ngắn để tạo biểu diễn thời gian–tần số. Ảnh phổ thu được đóng vai trò là đầu vào cho mô hình học sâu, trong đó mỗi điểm ảnh mang thông tin về sự phân bố năng lượng của tín hiệu theo thời gian và tần số. Dựa trên biểu diễn này, mô hình cần phân loại từng điểm ảnh vào các lớp tương ứng, bao gồm nhiễu nền, LTE, 5G NR và ASR. Cụ thể, hệ thống cần đáp ứng các yêu cầu sau:

- Phân tích và khoanh vùng tín hiệu: Mô hình phải xác định được vị trí, hình dạng và phạm vi phân bố của từng loại tín hiệu trên ảnh phổ. Yêu cầu này đặc biệt quan trọng đối với các vùng tín hiệu có biên yếu, bị che khuất bởi nhiễu hoặc có sự chồng lấn trong miền thời gian–tần số.


- Gán nhãn ngữ nghĩa theo điểm ảnh: Mỗi điểm ảnh trên ảnh phổ cần được gán nhãn phù hợp với lớp tín hiệu tương ứng. Kết quả đầu ra của hệ thống là bản đồ phân đoạn có cùng kích thước không gian với ảnh phổ đầu vào, thể hiện rõ vùng nhiễu nền, LTE, 5G NR và ASR.
- Bảo toàn cấu trúc và ranh giới tín hiệu: Hệ thống cần hạn chế hiện tượng phân đoạn đứt gãy, sai lệch biên hoặc làm mất các vùng tín hiệu nhỏ. Đây là yêu cầu quan trọng vì các tín hiệu vô tuyến, đặc biệt trong điều kiện SNR thấp, thường có cấu trúc không liên tục và dễ bị nhiễu làm biến dạng.

Bên cạnh yêu cầu về độ chính xác phân đoạn, hệ thống cũng cần khắc phục hạn chế của các kiến trúc phân đoạn một lượt. Các mô hình này thường ánh xạ trực tiếp ảnh phổ đầu vào sang bản đồ phân đoạn đầu ra. Cách tiếp cận này có thể đạt tốc độ xử lý cao, nhưng lại thiếu cơ chế hiệu chỉnh rõ ràng khi đặc trưng ban đầu đã bị sai lệch do nhiễu hoặc suy giảm kênh truyền. Vì vậy, hệ thống đề xuất cần có khả năng hiệu chỉnh biểu diễn bên trong mô hình trước khi đưa ra kết quả phân đoạn cuối cùng. Trong nghiên cứu này, biểu diễn tiềm ẩn từ bộ mã hóa được xem như một giả thuyết ngữ nghĩa ban đầu và được tinh chỉnh thông qua quá trình hiệu chỉnh dựa trên khuếch tán, kế thừa khả năng khử nhiễu lặp của các mô hình khuếch tán trong không gian biểu diễn [27, 28, 29]. Cách tiếp cận này giúp mô hình phục hồi tốt hơn các cấu trúc phổ bị phân mảnh, đồng thời tránh chi phí tính toán lớn nếu thực hiện quá trình khuếch tán trực tiếp trên không gian ảnh có độ phân giải cao.

Ngoài ra, hệ thống cần có khả năng xử lý các vùng có độ bất định cao. Trên ảnh phổ, các vùng biên giữa hai loại tín hiệu hoặc các vùng bị nhiễu mạnh thường gây ra dự đoán thiếu ổn định. Do đó, hệ thống cần đánh giá mức độ không chắc chắn của dự đoán để điều tiết quá trình hiệu chỉnh đặc trưng. Việc khai thác các thông tin như entropy và độ chênh lệch xác suất giữa các lớp giúp mô hình tập trung hơn vào những vùng khó phân loại, đồng thời hạn chế làm thay đổi các vùng đã có dự đoán đáng tin cậy. Cuối cùng, hệ thống cần đảm bảo hiệu quả tính toán để phù hợp với các ứng dụng giám sát phổ gần thời gian thực. Mô hình phải duy trì số lượng tham số và thời gian suy luận ở mức hợp lý, trong khi vẫn đạt hiệu năng cao theo các chỉ số đánh giá như độ chính xác trung bình theo lớp (mAcc) và mIoU. Sự cân bằng giữa độ chính xác, độ phức tạp mô hình và tốc độ xử lý là tiêu chí quan trọng để đánh giá tính khả thi của hệ thống khi triển khai trong các môi trường vô tuyến thực tế.

3.2 TỔNG QUAN KIẾN TRÚC ĐỀ XUẤT

Trong các hệ thống vô tuyến hiện đại, sự phát triển nhanh chóng của 5G, LTE và các hệ thống radar làm cho môi trường phổ tần ngày càng trở nên phức tạp. Nhiều loại tín hiệu có thể cùng tồn tại trong một miền thời gian–tần số, đồng thời chịu ảnh hưởng bởi các yếu tố suy giảm



Hình 3.1: Tổng quan hệ thống phân đoạn ảnh phổ đề xuất, gồm bước tạo ảnh phổ bằng STFT và bước phân đoạn các lớp Noise, LTE, 5G NR và ASR.

của kênh truyền như nhiễu, fading đa đường và dịch Doppler. Các tác động này làm thay đổi cấu trúc phổ ban đầu của tín hiệu, khiến ranh giới giữa các vùng tín hiệu trở nên không rõ ràng, thậm chí gây ra hiện tượng phân mảnh hoặc nhầm lẫn giữa các lớp tín hiệu khác nhau. Do đó, việc xây dựng một hệ thống có khả năng phân tích và phân đoạn phổ tín hiệu một cách chính xác là cần thiết cho các bài toán giám sát phổ trong môi trường vô tuyến phức tạp.

Tín hiệu thu ở dạng chuỗi thời gian thường chưa thể hiện rõ sự phân bố năng lượng của các thành phần phổ, đặc biệt khi nhiều nguồn phát cùng tồn tại hoặc bị ảnh hưởng bởi nhiễu và suy hao kênh truyền. Vì vậy, quy trình xử lý sử dụng phép biến đổi Fourier thời gian ngắn để ánh xạ tín hiệu từ miền thời gian sang miền thời gian–tần số. Trong quá trình này, tín hiệu được chia thành các đoạn ngắn theo thời gian, sau đó phép biến đổi Fourier được áp dụng trên từng đoạn để xác định sự thay đổi của thành phần tần số theo thời gian. Kết quả thu được là ảnh phổ tín hiệu, một biểu diễn trực quan hóa cường độ năng lượng của tín hiệu theo cả trục thời gian và trục tần số. Trên biểu diễn này, các đặc điểm của từng loại tín hiệu như vùng chiếm dụng phổ, hình dạng cấu trúc và mức độ chồng lấn giữa các nguồn phát được thể hiện rõ ràng hơn. Nhờ đó, bài toán nhận dạng tín hiệu vô tuyến có thể được chuyển thành bài toán phân đoạn ngữ nghĩa trên ảnh, trong đó mô hình thực hiện phân loại từng điểm ảnh trên ảnh phổ theo lớp tín hiệu tương ứng. Từ biểu diễn ảnh phổ, mô hình học sâu được sử dụng để học các đặc trưng phân biệt giữa các nguồn phát khác nhau. Đầu ra của mô hình là bản đồ phân đoạn có cùng kích thước với ảnh phổ đầu vào, trong đó mỗi vị trí thời gian–tần số được gán nhãn tương ứng với một lớp tín hiệu, bao gồm nhiễu nền, LTE, 5G NR và ASR. Nhờ đó, hệ thống không chỉ nhận biết được sự xuất hiện của từng loại tín hiệu, mà còn xác định được vị trí, phạm vi chiếm dụng và hình dạng phân bố của chúng trên miền thời gian–tần số.

Kiến trúc tổng thể của hệ thống đề xuất được minh họa trong Hình 3.1. Hệ thống bao gồm hai giai đoạn xử lý chính. Giai đoạn thứ nhất là tiền xử lý và tạo ảnh phổ, trong đó tín hiệu đầu

vào được biến đổi từ miền thời gian sang miền thời gian–tần số bằng STFT. Giai đoạn này đóng vai trò chuyển đổi dữ liệu tín hiệu ban đầu thành biểu diễn hai chiều phù hợp cho mô hình học sâu. Giai đoạn thứ hai là phân đoạn ngữ nghĩa ảnh phổ. Ảnh phổ đầu vào được đưa vào mô hình đề xuất để phân tích và dự đoán nhãn cho từng điểm ảnh. Kết quả đầu ra cuối cùng là bản đồ phân đoạn có cùng kích thước với ảnh phổ đầu vào, thể hiện rõ vùng tương ứng với từng loại tín hiệu. Bản đồ này giúp trực quan hóa sự phân bố của các nguồn phát trong miền thời gian–tần số, đồng thời hỗ trợ đánh giá khả năng nhận dạng và khoanh vùng tín hiệu trong các điều kiện truyền dẫn khác nhau.

3.3 CƠ SỞ THIẾT KẾ TỪ MÔ HÌNH KHUẾCH TÁN DDPM

Mô hình khuếch tán khử nhiễu (denoising diffusion probabilistic model – DDPM) là một hướng tiếp cận dựa trên việc mô hình hóa dữ liệu thông qua hai tiến trình ngược chiều nhau: tiến trình khuếch tán thuận và tiến trình khử nhiễu ngược [27]. Trong tiến trình thuận, nhiễu Gaussian được thêm dần vào dữ liệu sạch qua nhiều bước thời gian cho đến khi dữ liệu ban đầu gần như bị che phủ bởi nhiễu. Ngược lại, trong tiến trình khử nhiễu, một mạng học sâu được huấn luyện để ước lượng thành phần nhiễu tại mỗi bước, từ đó từng bước khôi phục biểu diễn ít nhiễu hơn. Ý tưởng quan trọng của DDPM không chỉ nằm ở khả năng sinh dữ liệu, mà còn ở khả năng học một quá trình hiệu chỉnh từ biểu diễn bị nhiễu hoặc chưa ổn định về biểu diễn có cấu trúc rõ ràng hơn.

Gọi $\mathbf{x}_0$ là dữ liệu sạch ban đầu và $\mathbf{x}_t$ là dữ liệu sau khi đã được thêm nhiễu tại bước thời gian t . Với lịch phương sai $\{\beta_t\}_{t=1}^T$, ta đặt $\alpha_t = 1 - \beta_t$ và $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$. Từ tiến trình khuếch tán thuận theo chuỗi Markov, phân phối biên của $\mathbf{x}_t$ theo dữ liệu sạch $\mathbf{x}_0$ có thể được viết dưới dạng:

$$q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t}\mathbf{x}_0, (1 - \bar{\alpha}_t)\mathbf{I}), \quad (3.1)$$


trong đó $\mathbf{I}$ là ma trận đơn vị. Từ phân phối trên, dữ liệu nhiễu tại bước t có thể được viết lại dưới dạng:

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t}\boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \quad (3.2)$$

Công thức (3.2) cho thấy $\mathbf{x}_t$ được tạo bằng cách kết hợp dữ liệu sạch $\mathbf{x}_0$ với nhiễu Gaussian $\boldsymbol{\epsilon}$. Khi t càng lớn, hệ số $\sqrt{\bar{\alpha}_t}$ giảm dần, trong khi hệ số $\sqrt{1 - \bar{\alpha}_t}$ tăng lên, làm cho thông tin cấu trúc ban đầu trong $\mathbf{x}_0$ ngày càng bị che khuất bởi nhiễu.

Tiến trình ngược của DDPM học cách khôi phục dữ liệu từ trạng thái nhiễu về trạng thái sạch hơn. Quá trình này được mô hình hóa thông qua phân phối có điều kiện:

$$p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_\theta(\mathbf{x}_t, t), \sigma_t^2\mathbf{I}), \quad (3.3)$$



Hình 3.2: Minh họa tiến trình khuếch tán thuận và khử nhiễu ngược trong DDPM.

trong đó $\mu_\theta(\mathbf{x}_t, t)$ là trung bình của phân phối ngược và σ_t^2 là phương sai tại bước thời gian t . Trong tham số hóa dự đoán nhiễu, mạng học sâu không nhất thiết dự đoán trực tiếp dữ liệu sạch $\mathbf{x}_0$, mà được huấn luyện để ước lượng thành phần nhiễu đã được thêm vào dữ liệu:

$$\hat{\epsilon} = \epsilon_\theta(\mathbf{x}_t, t). \quad (3.4)$$

Hàm mất mát huấn luyện tương ứng được định nghĩa bằng sai số bình phương trung bình giữa nhiễu thực tế và nhiễu dự đoán:

$$\mathcal{L}_{\text{ddpm}} = \mathbb{E}_{\mathbf{x}_0, t, \epsilon} \left[\|\epsilon - \epsilon_\theta(\mathbf{x}_t, t)\|_2^2 \right]. \quad (3.5)$$

Việc tối ưu hàm mất mát này buộc mạng khử nhiễu học được mối quan hệ giữa biểu diễn bị nhiễu $\mathbf{x}_t$ và biểu diễn sạch $\mathbf{x}_0$. Nhờ đó, mô hình có thể từng bước loại bỏ nhiễu và phục hồi lại cấu trúc dữ liệu ban đầu.

Hình 3.2 minh họa trực quan tiến trình khử nhiễu ngược trong mô hình khuếch tán. Từ trạng thái nhiễu mạnh $\mathbf{x}_T$, mô hình lần lượt đi qua các trạng thái trung gian $\mathbf{x}_t$ và $\mathbf{x}_{t-1}$ để tiến về trạng thái ít nhiễu hơn $\mathbf{x}_0$. Trong các mô hình khuếch tán truyền thống, quá trình này thường được sử dụng để sinh dữ liệu mới từ nhiễu. Tuy nhiên, trong bài toán phân đoạn ảnh phổ, mục tiêu chính không phải là sinh ảnh phổ mới mà là cải thiện chất lượng biểu diễn đặc trưng trước khi đưa ra bản đồ phân đoạn.

Từ cơ sở trên, luận văn khai thác DDPM như một cơ chế hiệu chỉnh biểu diễn thay vì một mô hình sinh dữ liệu độc lập. Cụ thể, quá trình thêm nhiễu và khử nhiễu không được áp dụng trực tiếp trên ảnh phổ đầu vào hoặc trên mặt nạ phân đoạn, mà được chuyển sang không gian tiềm ẩn của bộ mã hóa. Cách sử dụng này cho phép mô hình tận dụng khả năng học hướng khử nhiễu của DDPM để điều chỉnh các biểu diễn chưa ổn định, trong khi vẫn giữ vai trò phân đoạn chính cho bộ giải mã. Thiết kế chi tiết của khối hiệu chỉnh biểu diễn tiềm ẩn được trình bày trong Mục 3.4.3.

3.4 PHƯƠNG PHÁP ĐỀ XUẤT

Mục tiêu của luận văn là phát triển một hệ thống phân đoạn ảnh phổ có khả năng nhận dạng chính xác các tín hiệu vô tuyến trong môi trường truyền dẫn phức tạp. Trong các kịch bản thực tế, nhiều nguồn phát như LTE, 5G NR và ASR có thể cùng tồn tại trên miền thời gian–tần số, đồng thời chịu tác động của nhiễu, fading đa đường và dịch Doppler. Những yếu tố này làm suy giảm cấu trúc phổ của tín hiệu, gây ra hiện tượng biên tín hiệu bị mờ, vùng phổ bị phân mảnh và làm tăng khả năng nhầm lẫn giữa các lớp có đặc trưng gần nhau. Các phương pháp truyền thống dựa trên đặc trưng thủ công hoặc ngưỡng năng lượng thường gặp nhiều hạn chế trong những điều kiện như vậy, đặc biệt khi tín hiệu bị suy giảm mạnh hoặc có sự chồng lấn giữa nhiều nguồn phát.

Bên cạnh đó, nhiều mô hình học sâu phân đoạn ngữ nghĩa hiện nay vẫn hoạt động theo cơ chế một lượt, tức là ánh xạ trực tiếp ảnh phổ đầu vào sang bản đồ phân đoạn đầu ra. Cơ chế này xuất hiện phổ biến trong nhiều kiến trúc phân đoạn dạng mã hóa–giải mã hoặc phân đoạn hiệu quả, vốn đã đạt kết quả tốt trong các bài toán phân đoạn dày đặc [22, 23, 25, 24, 30]. Cách tiếp cận này có thể đạt hiệu quả nhất định, nhưng thiếu cơ chế hiệu chỉnh rõ ràng đối với các sai lệch cấu trúc đã xuất hiện trong quá trình mã hóa đặc trưng. Vì vậy, phương pháp đề xuất xem biểu diễn tiềm ẩn của mô hình như một giả thuyết ngữ nghĩa ban đầu và tiến hành hiệu chỉnh trước khi đưa ra dự đoán cuối cùng. Ý tưởng này được định hướng từ khả năng khử nhiễu lặp của các mô hình khuếch tán [27, 28] và cách thực hiện quá trình hiệu chỉnh trong không gian biểu diễn nén của mô hình khuếch tán tiềm ẩn [29]; tuy nhiên, khác với hướng sinh trực tiếp mặt nạ phân đoạn toàn cục như SpecDiff [31], mô hình chỉ sử dụng khuếch tán để tạo tín hiệu hiệu chỉnh cho đặc trưng sâu. Quá trình này giúp mô hình phục hồi tốt hơn các cấu trúc phổ bị suy giảm, đặc biệt tại các vùng biên không rõ ràng hoặc vùng tín hiệu chịu ảnh hưởng mạnh bởi nhiễu, từ đó nâng cao độ tin cậy của kết quả phân đoạn ảnh phổ.

Kiến trúc tổng thể của mô hình đề xuất được minh họa trong Hình 3.3. Mô hình bao gồm ba thành phần chính:

- Bộ mã hóa đặc trưng: Thành phần này có nhiệm vụ trích xuất các đặc trưng phân cấp từ ảnh phổ đầu vào. Các đặc trưng thu được không chỉ biểu diễn thông tin cục bộ của tín hiệu mà còn dần hình thành các biểu diễn ngữ nghĩa ở mức cao hơn, phục vụ cho quá trình phân loại từng vùng phổ.
- Mô-đun hiệu chỉnh tiềm ẩn: Từ đặc trưng trung gian của bộ mã hóa, mô hình xây dựng một biểu diễn tiềm ẩn nhỏ gọn và thực hiện quá trình hiệu chỉnh dựa trên khuếch tán. Mô-đun này không sinh trực tiếp bản đồ phân đoạn, mà tạo ra tín hiệu hiệu chỉnh nhằm cải thiện các cấu trúc phổ bị mờ hoặc bị phân mảnh.
- Bộ giải mã phân đoạn: Sau khi đặc trưng được hiệu chỉnh, bộ giải mã kết hợp các thông tin

ngữ nghĩa và chi tiết không gian để tạo ra bản đồ phân đoạn cuối cùng. Kết quả đầu ra là bản đồ nhãn có cùng kích thước với ảnh phổ đầu vào, trong đó mỗi điểm ảnh được phân loại vào một trong các lớp gồm nhiều nền, LTE, 5G NR và ASR.


Ngoài quá trình hiệu chỉnh tiềm ẩn, mô hình đề xuất còn khai thác thông tin về độ bất định của dự đoán để điều tiết mức độ hiệu chỉnh đặc trưng. Các vùng có độ tin cậy thấp, chẳng hạn như vùng biên giữa hai lớp tín hiệu hoặc vùng bị nhiễu mạnh, sẽ được ưu tiên hiệu chỉnh nhiều hơn. Ngược lại, các vùng đã có dự đoán ổn định được giữ nguyên ở mức cao hơn nhằm tránh làm thay đổi không cần thiết các đặc trưng đáng tin cậy. Nhờ đó, mô hình có thể cải thiện chất lượng phân đoạn trong điều kiện truyền dẫn bất lợi mà vẫn duy trì hiệu quả tính toán.

Nhìn chung, phương pháp đề xuất kết hợp khả năng trích xuất đặc trưng của mô hình học sâu với cơ chế hiệu chỉnh trong không gian tiềm ẩn. Thiết kế này cho phép mô hình xử lý tốt hơn các sai lệch cấu trúc trên ảnh phổ, đồng thời tránh chi phí tính toán lớn khi thực hiện hiệu chỉnh trực tiếp trên không gian ảnh có độ phân giải cao. Các thành phần chi tiết của mô hình sẽ được trình bày trong các mục tiếp theo.

3.4.1 Phân tích thời gian–tần số bằng phép biến đổi Fourier thời gian ngắn

Đối với các tín hiệu vô tuyến, đặc trưng phổ thường không cố định trên toàn bộ khoảng thời gian quan sát mà có thể thay đổi theo từng thời điểm. Nói cách khác, đây là dạng tín hiệu không dừng, trong đó các thành phần tần số có thể xuất hiện, biến mất hoặc thay đổi cường độ trong các khoảng thời gian khác nhau. Nếu chỉ sử dụng phép biến đổi Fourier thông thường trên toàn bộ tín hiệu, kết quả thu được chủ yếu cho biết các thành phần tần số tổng quát có trong tín hiệu, nhưng không thể hiện rõ những thành phần đó xuất hiện tại thời điểm nào. Điều này gây hạn chế khi phân tích các tín hiệu có cấu trúc biến thiên theo thời gian, đặc biệt trong bài toán phân đoạn phổ, nơi vị trí của tín hiệu trên cả trục thời gian và trục tần số đều đóng vai trò quan trọng.

Để khắc phục hạn chế trên, phép biến đổi Fourier thời gian ngắn được sử dụng nhằm biểu diễn tín hiệu trong miền thời gian–tần số. Nguyên lý của phương pháp này là chia tín hiệu ban đầu thành nhiều đoạn ngắn theo thời gian, trong đó mỗi đoạn được giới hạn bởi một hàm cửa sổ. Sau đó, phép biến đổi Fourier được áp dụng riêng trên từng đoạn đã được nhân cửa sổ, tạo ra một phổ cục bộ tương ứng với từng khoảng thời gian. Khi ghép các phổ cục bộ này lại, ta thu được một biểu diễn cho phép theo dõi sự thay đổi của nội dung tần số theo thời gian. Cách biểu diễn này giúp giữ lại thông tin động của tín hiệu tốt hơn so với phép biến đổi Fourier thông thường, đồng thời tạo cơ sở để xây dựng ảnh phổ phục vụ cho các mô hình học sâu.



Hình 3.3: Kiến trúc của mô hình đề xuất, gồm bộ mã hóa đặc trưng, khối hiệu chỉnh tiềm ẩn dựa trên khuếch tán, phần hồi độ bất định và bộ giải mã phân đoạn.

Về mặt toán học, với tín hiệu rời rạc $x[n]$, phép biến đổi Fourier thời gian ngắn được định nghĩa như sau:

$$X(t, f) = \sum_{n=0}^{N-1} x(n)w(n-t)e^{-j2\pi\frac{fn}{N}}, \quad (3.6)$$

trong đó $x[n]$ là giá trị của tín hiệu tại thời điểm n , $w(n-t)$ là hàm cửa sổ được dịch theo vị trí thời gian t , f là chỉ số tần số và N là độ dài của phép biến đổi Fourier. Kết quả $X(t, f)$ là một đại lượng phức, chứa thông tin về biên độ và pha của tín hiệu tại từng vị trí thời gian–tần số. Nhờ việc dịch chuyển của sổ dọc theo trục thời gian, phép biến đổi này cho phép mô tả tín hiệu dưới dạng một chuỗi các phổ liên tiếp, phản ánh sự biến thiên của năng lượng tín hiệu theo thời gian.

Từ kết quả của phép biến đổi Fourier ngắn hạn, ảnh phổ được tạo ra bằng cách lấy bình phương độ lớn của các hệ số biến đổi:


$$S(t, f) = |X(t, f)|^2. \quad (3.7)$$

Trong đó, $S(t, f)$ biểu diễn cường độ năng lượng của tín hiệu tại thời điểm t và tần số f . Ảnh phổ thu được là một biểu diễn hai chiều, trong đó trục hoành thường tương ứng với thời gian, trục tung tương ứng với tần số và giá trị tại mỗi điểm thể hiện mức năng lượng của tín hiệu. Trên biểu diễn này, các loại tín hiệu khác nhau có thể tạo ra những vùng phổ với hình dạng, mức năng lượng và phạm vi chiếm dụng khác nhau. Do đó, ảnh phổ không chỉ trực quan hóa cấu trúc của tín hiệu mà còn làm nổi bật các đặc trưng quan trọng phục vụ cho quá trình nhận dạng và phân đoạn.

Việc chuyển đổi tín hiệu thu từ chuỗi thời gian một chiều sang ảnh phổ hai chiều giúp đưa bài toán phân tích tín hiệu vô tuyến về dạng bài toán xử lý ảnh. Mỗi điểm trên ảnh phổ tương ứng với một vị trí cụ thể trong miền thời gian–tần số, nhờ đó mô hình học sâu có thể học các mẫu không gian đặc trưng của từng loại tín hiệu và dự đoán nhãn cho từng điểm ảnh. Đây là bước tiền xử lý quan trọng trong hệ thống đề xuất, vì chất lượng biểu diễn ảnh phổ ảnh hưởng trực tiếp đến khả năng mô hình phân biệt giữa nhiễu nền và các nguồn phát vô tuyến như LTE, 5G NR và ASR.

3.4.2 Bộ mã hóa và ánh xạ không gian tiềm ẩn

Sau khi ảnh phổ được tạo từ tín hiệu thu, mô hình cần chuyển biểu diễn đầu vào sang một không gian đặc trưng phù hợp trước khi thực hiện quá trình hiệu chỉnh. Ảnh phổ vô tuyến thường chứa đồng thời các cấu trúc thời gian–tần số của tín hiệu và các thành phần nhiễu cục bộ phân bố trên nhiều vùng khác nhau. Nếu thực hiện hiệu chỉnh trực tiếp trên không gian ảnh có độ phân giải cao, chi phí tính toán sẽ lớn, đồng thời việc kiểm soát mức độ thay đổi của đặc trưng trong quá trình tinh chỉnh cũng trở nên khó khăn hơn. Định hướng này phù hợp với ý tưởng của các mô hình khuếch tán tiềm ẩn, trong đó quá trình xử lý được chuyển từ không gian ảnh sang một



Hình 3.4: Bộ mã hóa và ánh xạ không gian tiềm ẩn, trong đó ảnh phổ được chuyển thành đặc trưng phân cấp và biểu diễn tiềm ẩn trung tâm $\mathbf{Z}_c$.

không gian biểu diễn nén nhằm giảm chi phí tính toán [29]. Vì vậy, mô hình đề xuất trước hết sử dụng một bộ mã hóa hiệu quả để trích xuất các đặc trưng phân cấp từ ảnh phổ đầu vào, đồng thời ánh xạ một phần đặc trưng sang một không gian tiềm ẩn nhỏ gọn hơn. Cấu trúc tổng quát của giai đoạn này được minh họa trong Hình 3.4, bao gồm khối tiền xử lý đầu vào, các giai đoạn mã hóa đặc trưng và nhánh ánh xạ xuống không gian tiềm ẩn trung tâm.

Với ảnh phổ đầu vào $\mathbf{X}_{in} \in \mathbb{R}^{3 \times H \times W}$, quá trình mã hóa bắt đầu bằng phép tái sắp xếp điểm ảnh vào chiều kênh với hệ số tỉ lệ bằng 2:

$$\mathbf{F}_0 = \text{PU}_2(\mathbf{X}_{in}), \quad \mathbf{F}_0 \in \mathbb{R}^{12 \times \frac{H}{2} \times \frac{W}{2}}, \quad (3.8)$$

trong đó $\text{PU}_2(\cdot)$ thực hiện việc chuyển thông tin của mỗi vùng lân cận 2×2 trong không gian ảnh sang chiều kênh. Nhờ vậy, kích thước không gian của đặc trưng được giảm xuống nhưng vẫn bảo toàn tốt hơn các thông tin cấu trúc cục bộ so với các phép giảm mẫu thông thường. Đối với bài toán ảnh phổ, điều này đặc biệt quan trọng vì nhiều tín hiệu có thể xuất hiện dưới dạng các vùng hẹp hoặc có biên yếu trên miền thời gian–tần số. Do đó, bước giảm kích thước ban đầu được thiết kế theo hướng tái sắp xếp thông tin không gian sang chiều kênh, thay vì loại bỏ trực tiếp một phần đáp ứng không gian như các phép giảm mẫu mạnh. Sau bước tái sắp xếp, đặc trưng tiếp tục được đưa qua lớp khởi tạo gồm tích chập 3×3 , chuẩn hóa theo lô và hàm kích hoạt SiLU $\phi(\cdot)$ để tạo biểu diễn đặc trưng ban đầu:

$$\mathbf{F}_0^e = \phi(\text{BN}(\mathcal{C}_{3 \times 3}(\mathbf{F}_0))). \quad (3.9)$$

Lớp khởi tạo này có vai trò chuẩn hóa và làm giàu biểu diễn đầu vào trước khi đưa qua các giai đoạn mã hóa sâu hơn.

Sau lớp khởi tạo, bộ mã hóa được xây dựng từ các khối dư ngược dùng tích chập theo chiều sâu. Mỗi khối mã hóa được thiết kế nhằm duy trì khả năng biểu diễn đặc trưng trong khi vẫn hạn chế số lượng tham số và chi phí tính toán. Với đầu vào là đặc trưng $\mathbf{F}_{i-1}^e$, khối mã hóa lần lượt thực hiện ba bước gồm mở rộng số kênh, trộn thông tin không gian bằng tích chập theo chiều sâu

và chiều đặc trưng trở lại không gian đầu ra:

$$\begin{aligned}\mathbf{U}_{\text{exp}} &= \phi\left(\text{GN}\left(\mathcal{C}_{1 \times 1}^{(r)}(\mathbf{F}_{i-1}^e)\right)\right), \\ \mathbf{U}_{\text{dw}} &= \phi(\text{GN}(\mathcal{D}_{3 \times 3}(\mathbf{U}_{\text{exp}}))), \\ \mathbf{F}_i^e &= \phi(\text{GN}(\mathcal{C}_{1 \times 1}(\mathbf{U}_{\text{dw}})) + \mathbf{F}_{i-1}^e),\end{aligned}\tag{3.10}$$

trong đó $\mathcal{C}_{1 \times 1}^{(r)}$ là phép tích chập 1×1 dùng để mở rộng số kênh với hệ số r , còn $\mathcal{D}_{3 \times 3}$ là phép tích chập theo chiều sâu kích thước 3×3 . Trong kiến trúc này, hệ số mở rộng được đặt là $r = 4$ ở giai đoạn đầu và $r = 3$ ở các giai đoạn tiếp theo. Việc sử dụng chuẩn hóa nhóm GN giúp quá trình huấn luyện ổn định hơn trong các trường hợp kích thước batch nhỏ hoặc thay đổi, trong khi tích chập theo chiều sâu làm giảm đáng kể chi phí tính toán so với tích chập chuẩn. Đồng thời, quá trình giảm kích thước không gian được thực hiện thông qua các phép tích chập theo chiều sâu có bước trượt bằng 2, nhờ đó đặc trưng được nén dần theo không gian và ngày càng mang nhiều thông tin ngữ nghĩa hơn. Trong thiết kế của luận văn, liên kết dư chỉ được áp dụng tại các khối IRD có đầu vào và đầu ra cùng kích thước không gian cũng như cùng số kênh. Đối với các khối làm thay đổi kích thước hoặc số kênh, phép cộng dư không được sử dụng, nhằm bảo đảm phép cộng đặc trưng theo từng phần tử là hợp lệ.

Sau ba giai đoạn mã hóa, đặc trưng $\mathbf{F}_3^e$ đạt độ phân giải $(\frac{H}{16}, \frac{W}{16})$. Đây là mức đặc trưng phù hợp để xây dựng không gian tiềm ẩn, vì kích thước không gian đã được giảm đáng kể nhưng vẫn còn giữ lại các cấu trúc quan trọng của ảnh phổ. Để mở rộng vùng tiếp nhận mà không tiếp tục làm giảm độ phân giải, mô hình áp dụng thêm một khối mã hóa không giảm mẫu với hệ số giãn bằng 2, tạo ra đặc trưng $\mathbf{F}_{3b}^e = \text{IRD}_{3b}(\mathbf{F}_3^e)$. Từ đặc trưng này, kiến trúc được tách thành hai nhánh xử lý. Một nhánh tiếp tục đi sâu hơn trong bộ mã hóa để tạo đặc trưng cấp cao $\mathbf{F}_4^e$, phục vụ cho quá trình giải mã phân đoạn ở các bước sau. Nhánh còn lại ánh xạ $\mathbf{F}_{3b}^e$ sang biểu diễn tiềm ẩn trung tâm:

$$\mathbf{Z}_c = \text{Map}_d(\mathbf{F}_{3b}^e), \quad \mathbf{Z}_c \in \mathbb{R}^{C_r \times \frac{H}{16} \times \frac{W}{16}},\tag{3.11}$$

trong đó C_r là số kênh rút gọn của không gian tiềm ẩn. Mô-đun ánh xạ xuống $\text{Map}_d(\cdot)$ được xây dựng bằng các lớp tích chập 1×1 nhẹ kết hợp với chuẩn hóa nhóm và hàm kích hoạt SiLU, nhằm thực hiện nén đặc trưng theo chiều kênh một cách hiệu quả. Biểu diễn $\mathbf{Z}_c$ đóng vai trò là giả thuyết ngữ nghĩa ban đầu của mô hình và là đầu vào trực tiếp cho quá trình hiệu chỉnh dựa trên khuếch tán ở bước tiếp theo. Nhờ thực hiện hiệu chỉnh trong không gian tiềm ẩn nhỏ gọn này, mô hình có thể tập trung vào việc sửa các sai lệch cấu trúc quan trọng với chi phí thấp hơn đáng kể so với việc thao tác trực tiếp trên ảnh phổ gốc.

3.4.3 Hiệu chỉnh biểu diễn tiềm ẩn dựa trên khuếch tán

Dựa trên cơ sở khuếch tán đã trình bày trong Mục 3.3, khối hiệu chỉnh tiềm ẩn của mô hình đề xuất được thiết kế để tinh chỉnh biểu diễn trung gian của bộ mã hóa thay vì sinh trực tiếp ảnh phổ hoặc bản đồ phân đoạn. Sau khi bộ mã hóa tạo ra biểu diễn tiềm ẩn trung tâm $\mathbf{Z}_c$, biểu diễn này được xem như trạng thái đặc trưng ban đầu chứa thông tin ngữ nghĩa của ảnh phổ. Tuy nhiên, trong các điều kiện nhiễu mạnh, fading đa đường hoặc dịch Doppler, $\mathbf{Z}_c$ có thể vẫn chứa các sai lệch cục bộ, đặc biệt tại vùng biên tín hiệu, vùng phổ yếu hoặc vùng có sự chồng lấn giữa nhiều nguồn phát. Vì vậy, mô hình sử dụng một khối khử nhiễu có điều kiện để hiệu chỉnh $\mathbf{Z}_c$ trong không gian tiềm ẩn trước khi đưa tín hiệu này trở lại nhánh đặc trưng sâu.

Cấu trúc tổng quát của khối hiệu chỉnh biểu diễn tiềm ẩn được minh họa trong Hình 3.5. Trước hết, biểu diễn tiềm ẩn trung tâm $\mathbf{Z}_c$ được làm nhiễu thành $\mathbf{Z}_t$ tại bước thời gian t . Sau đó, bộ khử nhiễu có điều kiện nhận đầu vào gồm $\mathbf{Z}_t$, bước thời gian t và đặc trưng điều kiện $\mathbf{C}\mathbf{d}_t$ để ước lượng hướng hiệu chỉnh phù hợp. Đặc trưng điều kiện $\mathbf{C}\mathbf{d}_t$ được trích xuất từ trạng thái hiện tại của biểu diễn nhiễu, giúp quá trình khử nhiễu vẫn bám theo nội dung ảnh phổ ban đầu thay vì tạo ra một biểu diễn tách rời khỏi đặc trưng của bộ mã hóa. Khi quá trình khử nhiễu hoàn tất, mô hình thu được biểu diễn tiềm ẩn đã hiệu chỉnh $\mathbf{Z}_0$.

Tương tự cơ chế khuếch tán thuận trong DDPM chuẩn, quá trình làm nhiễu trong khối hiệu chỉnh được áp dụng trên biểu diễn tiềm ẩn thay vì trên dữ liệu ảnh đầu vào. Với cùng lịch nhiễu đã trình bày trong Mục 3.3, biểu diễn nhiễu tại bước thời gian t được tạo từ $\mathbf{Z}_c$ như sau:

$$\mathbf{Z}_t = \sqrt{\alpha_t} \mathbf{Z}_c + \sqrt{1 - \alpha_t} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \quad (3.12)$$


Bộ khử nhiễu có điều kiện được huấn luyện theo tham số hóa dự đoán nhiễu, trong đó mạng ϵ_θ nhận $\mathbf{Z}_t$, bước thời gian t và đặc trưng điều kiện $\mathbf{C}\mathbf{d}_t$ để ước lượng thành phần nhiễu đã được thêm vào biểu diễn tiềm ẩn. Hàm mất mát khử nhiễu trong không gian tiềm ẩn được định nghĩa là:

$$\mathcal{L}_{\text{diff}} = \mathbb{E}_{\mathbf{Z}_c, t, \boldsymbol{\epsilon}} \left[\|\boldsymbol{\epsilon} - \epsilon_\theta(\mathbf{Z}_t, t, \mathbf{C}\mathbf{d}_t)\|_2^2 \right]. \quad (3.13)$$

Về mặt toán học, bước khử nhiễu có điều kiện trong không gian tiềm ẩn được mô hình hóa dưới dạng:

$$p_\theta(\mathbf{Z}_{t'} \mid \mathbf{Z}_t, \mathbf{C}\mathbf{d}_t, t), \quad (3.14)$$

trong đó $\mathbf{Z}_t$ là biểu diễn tiềm ẩn tại bước thời gian t , $\mathbf{Z}_{t'}$ là biểu diễn được đề xuất tại bước thời gian nhỏ hơn $t' < t$, và $\mathbf{C}\mathbf{d}_t$ là đặc trưng điều kiện phụ thuộc theo bước thời gian. Khác với mô hình khuếch tán sinh dữ liệu thông thường, phân phối trên không được sử dụng để tạo mẫu ảnh



Hình 3.5: Khối hiệu chỉnh biểu diễn tiềm ẩn dựa trên khuếch tán, tạo biểu diễn $\mathbf{Z}_0$ và tín hiệu hiệu chỉnh Δ_3, Δ_4 cho đặc trưng sâu.

hoặc mặt nạ phân đoạn mới, mà nhằm tạo ra một biểu diễn tiềm ẩn ổn định hơn để hỗ trợ quá trình phân đoạn.

Trong giai đoạn suy luận, quá trình khử nhiễu được thực hiện theo một chuỗi các bước cập nhật trong không gian tiềm ẩn. Tại mỗi bước thời gian t , bộ khử nhiễu tạo ra một biểu diễn đề xuất $\mathbf{Z}_{t'}$ ở bước thời gian nhỏ hơn. Tuy nhiên, nếu cập nhật trực tiếp từ $\mathbf{Z}_t$ sang $\mathbf{Z}_{t'}$, biểu diễn tiềm ẩn có thể thay đổi quá mạnh và lệch khỏi không gian đặc trưng ban đầu của bộ mã hóa. Điều này có thể làm giảm tính ổn định của quá trình hiệu chỉnh, đặc biệt tại các vùng ảnh phở vốn đã được biểu diễn tốt.

Để kiểm soát biên độ cập nhật, mô hình sử dụng một hệ số điều tiết học được tại từng bước:

$$\mathbf{Z}_t \leftarrow \mathbf{Z}_t + s_i(\mathbf{Z}_{t'} - \mathbf{Z}_t), \quad (3.15)$$

trong đó s_i là hệ số điều tiết tại bước cập nhật thứ i . Khi s_i nhỏ, biểu diễn sau cập nhật chỉ dịch chuyển nhẹ theo hướng của biểu diễn đề xuất, giúp bảo toàn nhiều hơn thông tin ban đầu. Khi s_i lớn hơn, khối hiệu chỉnh cho phép biểu diễn thay đổi mạnh hơn để phục hồi các cấu trúc bị suy giảm. Nhờ đó, quá trình khuếch tán hoạt động như một cơ chế hiệu chỉnh có kiểm soát, thay vì thay thế hoàn toàn biểu diễn tiềm ẩn của bộ mã hóa.

Sau khi quá trình khử nhiễu đạt đến bước cuối, biểu diễn tiềm ẩn đã hiệu chỉnh $\mathbf{Z}_0$ được ánh xạ trở lại miền đặc trưng bằng mô-đun ánh xạ lên $\text{Map}_u(\cdot)$:

$$\mathbf{F}_{3,\text{ref}}^e = \text{Map}_u(\mathbf{Z}_0). \quad (3.16)$$

Đặc trưng $\mathbf{F}_{3,\text{ref}}^e$ có cùng mức không gian với đặc trưng trung gian ban đầu $\mathbf{F}_{3b}^e$, do đó mô hình có thể xây dựng tín hiệu hiệu chỉnh dư:

$$\Delta_3 = \mathbf{F}_{3,\text{ref}}^e - \mathbf{F}_{3b}^e. \quad (3.17)$$

Tín hiệu Δ_3 biểu diễn phần sai khác giữa đặc trưng đã được hiệu chỉnh và đặc trưng gốc tại mức $(\frac{H}{16}, \frac{W}{16})$. Nói cách khác, khối refiner không cần tạo lại toàn bộ đặc trưng phân đoạn, mà chỉ học phần điều chỉnh cần bổ sung cho biểu diễn ban đầu. Cách thiết kế dạng phần dư này giúp quá trình hiệu chỉnh ổn định hơn và hạn chế làm thay đổi quá mức những vùng đặc trưng đã đáng tin cậy.

Để đưa tín hiệu hiệu chỉnh đến tầng đặc trưng sâu hơn, Δ_3 được chiếu xuống bằng một mô-đun có bước trượt bằng 2 để tạo ra Δ_4 :

$$\Delta_4 = \text{Proj}_{s=2}(\Delta_3), \quad (3.18)$$

trong đó Δ_4 có độ phân giải $(\frac{H}{32}, \frac{W}{32})$ và số kênh tương thích với đặc trưng sâu $\mathbf{F}_4^e$. Tín hiệu này đóng vai trò cầu nối giữa quá trình hiệu chỉnh trong không gian tiềm ẩn và quá trình phân đoạn ở miền đặc trưng sâu.

Đặc trưng sâu sau hiệu chỉnh ban đầu được xác định bằng cách cộng tín hiệu dư Δ_4 vào đặc trưng sâu ban đầu:


$$\mathbf{F}_{4,\text{temp}}^e = \mathbf{F}_4^e + \alpha \Delta_4, \quad (3.19)$$

trong đó $\alpha \in [0, 1]$ là trọng số hiệu chỉnh toàn cục. Tham số này điều khiển mức độ ảnh hưởng của tín hiệu hiệu chỉnh lên đặc trưng sâu. Khi α nhỏ, mô hình ưu tiên bảo toàn đặc trưng ban đầu; khi α lớn, tác động của tín hiệu hiệu chỉnh từ khối khuếch tán được tăng cường. Đặc trưng tạm thời $\mathbf{F}_{4,\text{temp}}^e$ sau đó được đưa vào cơ chế phản hồi độ bất định để điều tiết tín hiệu hiệu chỉnh theo từng vị trí không gian trước khi giải mã phân đoạn.

3.4.4 Phản hồi độ bất định cho tín hiệu hiệu chỉnh

Sau khi khối hiệu chỉnh tiềm ẩn tạo ra tín hiệu hiệu chỉnh Δ_4 , đặc trưng sâu ban đầu được cập nhật tạm thời thành $\mathbf{F}_{4,\text{temp}}^e$. Tuy nhiên, nếu toàn bộ tín hiệu hiệu chỉnh được cộng trực tiếp vào đặc trưng sâu với cùng một mức độ trên mọi vị trí không gian, mô hình có thể làm thay đổi cả những vùng vốn đã có biểu diễn ổn định. Điều này không phù hợp với bài toán phân đoạn ảnh phổ, vì trên ảnh phổ thường tồn tại đồng thời hai loại vùng khác nhau: các vùng tín hiệu rõ ràng, có cấu trúc ổn định và các vùng khó phân loại như biên tín hiệu, vùng bị nhiễu mạnh hoặc vùng có sự chồng lấn giữa nhiều nguồn phát. Do đó, sau khi tạo ra tín hiệu hiệu chỉnh từ khối khuếch tán, mô hình cần thêm một cơ chế điều tiết để xác định vị trí nào nên được hiệu chỉnh mạnh hơn và vị trí nào nên được giữ ổn định hơn. Nói cách khác, thay vì xem tín hiệu hiệu chỉnh là đồng nhất trên toàn bộ ảnh phổ, mô hình sử dụng độ bất định của dự đoán như một tín hiệu phản hồi để điều hướng quá trình cập nhật đặc trưng.

Cơ chế phản hồi dựa trên độ bất định được sử dụng nhằm giải quyết vấn đề trên. Thay vì



Hình 3.6: Phản hồi độ bất định cho tín hiệu hiệu chỉnh, sử dụng xác suất dự đoán để tạo bản đồ cổng $\mathbf{B}$ điều tiết Δ_4 .

áp dụng đồng đều tín hiệu hiệu chỉnh Δ_4 , mô hình đánh giá mức độ không chắc chắn của dự đoán tại từng vị trí không gian, sau đó dùng thông tin này để tạo ra một bản đồ điều tiết. Những vùng có độ bất định cao thường tương ứng với các vị trí mà mô hình khó đưa ra quyết định rõ ràng, chẳng hạn như ranh giới giữa LTE và 5G NR, biên của tín hiệu ASR hoặc các vùng phổ bị che khuất bởi nhiễu nền. Ngược lại, những vùng có độ bất định thấp thường là các vùng mà dự đoán của mô hình đã tương đối chắc chắn. Vì vậy, việc sử dụng độ bất định giúp tín hiệu hiệu chỉnh từ khối khuếch tán được phân bổ có chọn lọc hơn, tập trung vào những vùng thật sự cần được sửa.

Cụ thể, từ đặc trưng trung gian $\mathbf{F}_{4,temp}^e$, một nhánh dự đoán phụ được sử dụng để tạo ra các logits phân đoạn. Các logits này sau đó được chuyển thành bản đồ xác suất lớp theo từng điểm ảnh thông qua phép chuẩn hóa softmax, ký hiệu là $\mathbf{P}$. Từ bản đồ xác suất $\mathbf{P}$, mô hình trích xuất hai đại lượng bổ trợ để mô tả độ bất định của dự đoán, bao gồm entropy Shannon $H(\mathbf{P})$ và độ chênh lệch xác suất $M(\mathbf{P})$ giữa hai lớp có xác suất cao nhất. Entropy phản ánh mức độ phân tán của phân phối xác suất dự đoán: nếu xác suất được phân bố đều cho nhiều lớp, entropy sẽ cao và cho thấy mô hình chưa tự tin. Trong khi đó, độ chênh lệch xác suất giữa hai lớp cao nhất cho biết mức độ cạnh tranh giữa hai nhãn có khả năng nhất. Nếu hai lớp có xác suất gần nhau, vùng đó thường là vùng biên hoặc vùng dễ nhầm lẫn.

Hai thông tin này có vai trò bổ sung cho nhau. Entropy Shannon giúp phát hiện các vùng có độ tin cậy tổng thể thấp, trong khi độ chênh lệch xác suất giúp nhấn mạnh các vùng có sự cạnh tranh trực tiếp giữa hai lớp tín hiệu. Đối với ảnh phổ vô tuyến, sự kết hợp này đặc biệt hữu ích vì các lỗi phân đoạn không chỉ xuất hiện tại vùng nhiễu mạnh, mà còn thường xảy ra tại các ranh giới thời gian–tần số nơi hai nguồn phát có đặc trưng gần nhau. Do đó, thay vì chỉ dựa vào một thước đo độ bất định duy nhất, mô hình khai thác đồng thời cả hai dạng thông tin để xác định chính xác hơn các vùng cần được hiệu chỉnh.

Sau khi thu được các bản đồ độ bất định, mô hình ghép chúng với một biểu diễn đã được chiếu của $\mathbf{F}_{4,temp}^e$. Biểu diễn ghép này được đưa qua một mô-đun chiếu nhẹ để tạo ra bản đồ cổng không gian $\mathbf{B} \in [0, 1]$. Bản đồ $\mathbf{B}$ có cùng vai trò như một hệ số điều tiết theo vị trí, quyết định mức độ tín hiệu hiệu chỉnh Δ_4 được đưa vào từng vùng của đặc trưng sâu. Những vị trí có giá trị $\mathbf{B}$ lớn sẽ nhận tín hiệu hiệu chỉnh mạnh hơn, trong khi những vị trí có giá trị nhỏ sẽ chịu tác động

yếu hơn từ khối khuếch tán. Nhờ đó, mô hình tránh được việc thay đổi quá mức các vùng đã ổn định, đồng thời vẫn tăng cường hiệu chỉnh tại các vùng khó.

Đặc trưng sâu sau khi được điều tiết bởi phản hồi độ bất định được xác định theo công thức:

$$\mathbf{F}_{4,\text{corr}}^e = \mathbf{F}_4^e + \alpha(\mathbf{B} \odot \Delta_4), \quad (3.20)$$


trong đó $\odot$ là phép nhân Hadamard theo từng phần tử, α là trọng số hiệu chỉnh toàn cục, Δ_4 là tín hiệu hiệu chỉnh được tạo ra từ khối khuếch tán, và $\mathbf{B}$ là bản đồ cổng không gian sinh ra từ thông tin độ bất định. So với công thức hiệu chỉnh tạm thời $\mathbf{F}_{4,\text{temp}}^e = \mathbf{F}_4^e + \alpha\Delta_4$, công thức trên cho phép mô hình kiểm soát tín hiệu hiệu chỉnh chi tiết hơn theo từng vùng không gian. Như vậy, cơ chế phản hồi không tạo ra tín hiệu hiệu chỉnh mới, mà đóng vai trò điều tiết cách tín hiệu hiệu chỉnh được áp dụng lên đặc trưng sâu.

Về mặt ý nghĩa, cơ chế phản hồi độ bất định giúp khối refiner hoạt động có chọn lọc hơn. Nếu chỉ sử dụng Δ_4 trực tiếp, quá trình hiệu chỉnh có thể cải thiện các vùng khó nhưng đồng thời cũng có nguy cơ làm nhiễu các vùng đã đúng. Ngược lại, khi sử dụng bản đồ cổng $\mathbf{B}$, mô hình có khả năng tập trung năng lực hiệu chỉnh vào các vùng có độ bất định cao, chẳng hạn như biên tín hiệu mờ, vùng phổ bị phân mảnh hoặc vùng có sự giao thoa giữa các lớp. Điều này giúp tăng độ ổn định của quá trình phân đoạn và làm cho tín hiệu hiệu chỉnh từ khối khuếch tán phù hợp hơn với đặc điểm cục bộ của từng vùng trên ảnh phổ.

3.4.5 Bộ giải mã phân đoạn

Sau khi đặc trưng sâu đã được hiệu chỉnh bởi khối khuếch tán và cơ chế phản hồi độ bất định, mô hình cần chuyển các biểu diễn đặc trưng này thành bản đồ phân đoạn có cùng kích thước với ảnh phổ đầu vào. Tuy nhiên, việc giải mã trực tiếp từ đặc trưng sâu không phải lúc nào cũng đủ để tạo ra kết quả phân đoạn chính xác. Nguyên nhân là các đặc trưng sâu thường chứa thông tin ngữ nghĩa mạnh, giúp nhận biết lớp tín hiệu tốt hơn, nhưng do đã trải qua nhiều bước giảm kích thước không gian nên có thể làm mất một phần chi tiết biên. Trong bài toán ảnh phổ vô tuyến, các chi tiết biên này rất quan trọng vì nhiều tín hiệu có dạng hẹp, không liên tục hoặc bị nhiễu làm mờ trên miền thời gian–tần số. Nếu bộ giải mã chỉ dựa vào đặc trưng sâu, kết quả phân đoạn có thể đúng về lớp tín hiệu nhưng thiếu chính xác ở vùng ranh giới.

Ngược lại, các đặc trưng ở tầng nông hơn vẫn giữ được nhiều thông tin không gian và chi tiết cục bộ của ảnh phổ. Những đặc trưng này có ích trong việc xác định biên tín hiệu, vùng chuyển tiếp giữa các lớp và các cấu trúc phổ nhỏ. Tuy nhiên, đặc trưng nông thường thiếu thông tin ngữ nghĩa cấp cao, nên nếu sử dụng độc lập cũng dễ gây nhầm lẫn trong các vùng bị nhiễu hoặc có sự chồng lấn giữa nhiều nguồn phát. Vì vậy, bộ giải mã của mô hình đề xuất được thiết kế theo hướng hợp nhất đặc trưng đa tỷ lệ, trong đó đặc trưng sâu cung cấp thông tin ngữ nghĩa,



Hình 3.7: Bộ giải mã đa tỷ lệ thích nghi, kết hợp đặc trưng cấp thấp và cấp cao để tạo bản đồ phân đoạn cuối cùng.

còn đặc trưng nông bỏ sung chi tiết không gian và ranh giới tín hiệu. Cách thiết kế này kế thừa ý tưởng hợp nhất đặc trưng đa tỷ lệ thường gặp trong các bộ giải mã phân đoạn, nhưng được điều chỉnh theo hướng thích nghi hơn: thay vì sử dụng một quy tắc hợp nhất cố định cho toàn bộ ảnh phổ, mô hình tự học cách phân bổ vai trò giữa chi tiết biên và ngữ nghĩa lớp theo từng vị trí không gian.

Cấu trúc tổng quát của bộ giải mã đa tỷ lệ thích nghi được minh họa trong Hình 3.7. Trong đó, đặc trưng cấp cao $\mathbf{H}$ được lấy từ nhánh đặc trưng đã hiệu chỉnh, còn đặc trưng cấp thấp $\mathbf{L}$ được lấy từ các tầng trước của bộ mã hóa. Đặc trưng cấp cao trước hết được nội suy song tuyến tính để có cùng kích thước không gian với đặc trưng cấp thấp. Sau đó, cả hai đặc trưng được đưa qua các lớp tích chập 1×1 nhằm đưa về cùng không gian kênh, tạo ra hai biểu diễn đã căn chỉnh là $\mathbf{L}'$ và $\mathbf{H}'$. Việc căn chỉnh này giúp hai nguồn đặc trưng có thể được kết hợp trực tiếp trong cùng một không gian biểu diễn.

Điểm quan trọng của bộ giải mã là không cộng hoặc nối đặc trưng một cách cố định, mà sử dụng một cơ chế điều hướng thích nghi để xác định mức đóng góp của từng loại đặc trưng tại mỗi vị trí không gian. Trước hết, mô hình tính một bản đồ đồng thuận $\mathbf{A}$ dựa trên tương tác theo chiều kênh giữa $\mathbf{L}'$ và $\mathbf{H}'$. Bản đồ này phản ánh mức độ nhất quán cục bộ giữa thông tin chi tiết từ tầng thấp và thông tin ngữ nghĩa từ tầng cao. Nếu hai loại đặc trưng cùng hỗ trợ một cấu trúc tín hiệu, vùng đó có thể được xem là đáng tin cậy hơn. Ngược lại, nếu đặc trưng biên và đặc trưng ngữ nghĩa không thống nhất, vùng đó có thể là vùng khó, chẳng hạn như biên mờ hoặc vùng bị nhiễu.

Dựa trên biểu diễn kết hợp $[\mathbf{L}', \mathbf{H}', \mathbf{A}]$, mô hình dự đoán hai trọng số điều hướng không gian $\mathbf{w}_l$ và $\mathbf{w}_h$, tương ứng với mức đóng góp của đặc trưng cấp thấp và đặc trưng cấp cao. Hai trọng số này cho phép bộ giải mã lựa chọn động giữa chi tiết biên và ngữ nghĩa lớp tùy theo từng vị trí.

Ở những vùng có ranh giới rõ hoặc tín hiệu hẹp, mô hình có thể ưu tiên đặc trưng cấp thấp để giữ chi tiết không gian. Trong khi đó, ở những vùng bị nhiễu mạnh hoặc tín hiệu bị phân mảnh, đặc trưng cấp cao có thể được ưu tiên hơn vì chứa thông tin ngữ nghĩa ổn định hơn.

Đặc trưng sau hợp nhất được xác định theo công thức:


$$\mathbf{F}^d = \mathbf{w}_l \odot \mathbf{L}' + \mathbf{w}_h \odot \mathbf{H}', \quad (3.21)$$

trong đó $\odot$ là phép nhân Hadamard theo từng phần tử, $\mathbf{w}_l$ và $\mathbf{w}_h$ là các trọng số điều hướng không gian, còn $\mathbf{F}^d$ là đặc trưng hợp nhất được đưa vào các lớp giải mã cuối cùng. Công thức này cho thấy bộ giải mã không sử dụng một tỉ lệ cố định giữa đặc trưng nông và đặc trưng sâu, mà tự học cách phân bổ vai trò của từng nguồn đặc trưng theo nội dung cục bộ của ảnh phổ.

Trong Hình 3.7, ký hiệu $\times 4$ biểu diễn bước phóng đại độ phân giải ở cuối bộ giải mã. Sau khi đặc trưng hợp nhất $\mathbf{F}^d$ được tạo ra, đặc trưng này vẫn có kích thước không gian thấp hơn so với ảnh phổ đầu vào do đã trải qua các giai đoạn giảm mẫu trong bộ mã hóa. Vì vậy, bộ giải mã sử dụng khối phóng đại với hệ số 4 để đưa đặc trưng về kích thước phù hợp trước khi tạo bản đồ phân đoạn cuối cùng. Bước này giúp khôi phục độ phân giải không gian của đầu ra, đảm bảo rằng bản đồ nhãn dự đoán có thể được so khớp theo từng điểm ảnh với ảnh phổ ban đầu.

Sau khi thu được đặc trưng hợp nhất $\mathbf{F}^d$, đặc trưng này được đưa qua khối phóng đại độ phân giải $\times 4$ và các lớp dự đoán cuối cùng để tạo ra logits phân đoạn. Logits sau đó được ánh xạ về kích thước của ảnh phổ đầu vào, tạo thành bản đồ phân đoạn cuối cùng. Mỗi điểm ảnh trên bản đồ đầu ra được gán vào một trong các lớp gồm nhiều nền, LTE, 5G NR và ASR. Nhờ cơ chế hợp nhất đa tỷ lệ thích nghi kết hợp với bước khôi phục độ phân giải cuối, bộ giải mã có thể đồng thời khai thác thông tin ngữ nghĩa từ đặc trưng sâu đã hiệu chỉnh và thông tin biên từ đặc trưng nông, giúp cải thiện độ chính xác của kết quả phân đoạn, đặc biệt tại các vùng tín hiệu nhỏ, biên yếu hoặc bị che khuất bởi nhiễu.

Nhìn chung, bộ giải mã đóng vai trò chuyển các đặc trưng đã được hiệu chỉnh thành kết quả phân đoạn hoàn chỉnh. Nếu khối khuếch tán và phản hồi độ bất định tập trung vào việc sửa các sai lệch cấu trúc trong miền đặc trưng, thì bộ giải mã đa tỷ lệ thích nghi đảm nhiệm việc kết hợp các mức thông tin khác nhau để tạo bản đồ nhãn cuối cùng. Sự kết hợp giữa ngữ nghĩa cấp cao và chi tiết biên giúp mô hình duy trì khả năng nhận dạng lớp tín hiệu, đồng thời hạn chế hiện tượng mất ranh giới trong các điều kiện phổ phức tạp.



Hình 3.8: Ví dụ ảnh phổ và bản đồ nhãn phân đoạn trong bộ dữ liệu, gồm các lớp ASR, 5G NR, LTE và Noise.

3.5 CÀI ĐẶT MÔ PHỎNG VÀ HUẤN LUYỆN

3.5.1 Tạo bộ dữ liệu tín hiệu mô phỏng

Để đánh giá hiệu quả của mô hình đề xuất trong bài toán phân đoạn ảnh phổ vô tuyến, luận văn sử dụng bộ dữ liệu tín hiệu tổng hợp được giới thiệu trong [31]. Bộ dữ liệu này được xây dựng nhằm mô phỏng môi trường phổ dùng chung, trong đó tín hiệu ASR và các tín hiệu thông tin di động có thể cùng xuất hiện trong một vùng quan sát. Việc sử dụng dữ liệu mô phỏng giúp kiểm soát được các điều kiện truyền dẫn như nhiễu, truyền đa đường và dịch Doppler, từ đó tạo ra nhiều kịch bản khác nhau để đánh giá khả năng phân đoạn của mô hình trong môi trường vô tuyến phức tạp.

Bộ dữ liệu được tạo bằng trình mô phỏng lớp vật lý trên MATLAB. Trong đó, các dạng sóng LTE và 5G NR được sinh theo các đặc tả của chuẩn 3GPP, còn tín hiệu ASR được mô phỏng theo dạng radar giám sát sân bay băng S, hoạt động tại tần số trung tâm 2.8 GHz. Tần số lấy mẫu được đặt là 61.44 MHz. Môi trường truyền dẫn được mô phỏng với các suy hao vô tuyến, bao gồm truyền đa đường với tối đa 30 vật tán xạ được đặt ngẫu nhiên, dịch Doppler được chọn từ tập $\{0, 5, 70, 500\}$ Hz và nhiễu trắng Gaussian cộng với dải SNR từ -10 dB đến 30 dB. Các thiết lập này giúp bộ dữ liệu bao phủ nhiều điều kiện truyền dẫn khác nhau, từ trường hợp tín hiệu bị che khuất mạnh bởi nhiễu đến trường hợp tín hiệu rõ ràng hơn ở mức SNR cao.

Mỗi mẫu dữ liệu tương ứng với một khung tín hiệu có độ dài 40 ms. Tín hiệu trong miền thời gian được chuyển sang biểu diễn thời gian–tần số bằng phép biến đổi Fourier thời gian ngắn, sau đó được biểu diễn dưới dạng ảnh phổ RGB có kích thước 256×256 pixel. Mỗi ảnh phổ đi kèm với một bản đồ nhãn theo từng điểm ảnh, trong đó mỗi điểm ảnh được gán vào một trong bốn lớp gồm Noise, LTE, 5G NR và ASR. Nhờ đó, bài toán nhận dạng và khoanh vùng tín hiệu vô tuyến được mô hình hóa thành bài toán phân đoạn ngữ nghĩa trên ảnh phổ.

Hình 3.8 minh họa một số mẫu dữ liệu được sử dụng trong luận văn. Hàng trên là các ảnh

phổ đầu vào sau khi tín hiệu được biến đổi sang miền thời gian–tần số. Có thể thấy các vùng năng lượng của tín hiệu xuất hiện với hình dạng và mức độ rõ ràng khác nhau tùy theo điều kiện truyền dẫn. Hàng dưới là các bản đồ nhân thực tế tương ứng, trong đó mỗi màu đại diện cho một lớp tín hiệu. Cụ thể, các vùng ASR, 5G NR, LTE và Noise được gán nhãn riêng biệt ở mức điểm ảnh. Cách biểu diễn này cho phép mô hình học trực tiếp mối quan hệ giữa cấu trúc trên ảnh phổ và lớp tín hiệu tương ứng, đồng thời hỗ trợ đánh giá định lượng bằng các chỉ số phân đoạn như mAcc và mIoU.

Bộ dữ liệu cuối cùng bao gồm khoảng 120,000 mẫu và được chia thành hai phần huấn luyện và kiểm định theo tỉ lệ 8:2. Tập huấn luyện được sử dụng để tối ưu các tham số của mô hình, trong khi tập kiểm định được dùng để theo dõi hiệu suất trong quá trình huấn luyện và đánh giá khả năng tổng quát hóa của mô hình. Với sự kết hợp của nhiều mức SNR, nhiều mức dịch Doppler và các điều kiện truyền đa đường khác nhau, bộ dữ liệu cho phép kiểm tra khả năng của mô hình trong các tình huống phổ biến, bị phân mảnh hoặc có sự chồng lấn giữa nhiều nguồn phát.

3.5.2 Cấu hình huấn luyện

Toàn bộ mô hình được cài đặt bằng thư viện PyTorch và huấn luyện trên nền tảng GPU NVIDIA Tesla T4. Quá trình huấn luyện được thực hiện trong 50 epoch với thuật toán tối ưu AdamW. Tốc độ học ban đầu được đặt là 10^{-3} và được điều chỉnh bằng lịch trình cosine annealing trong suốt quá trình huấn luyện. Việc sử dụng AdamW giúp tách riêng quá trình cập nhật gradient và điều chuẩn trọng số, trong khi lịch trình cosine annealing cho phép tốc độ học giảm dần một cách mượt hơn ở các giai đoạn cuối, hỗ trợ mô hình hội tụ ổn định hơn.

Trong quá trình huấn luyện, ảnh phổ đầu vào có kích thước 256×256 và được đưa vào mô hình để dự đoán bản đồ phân đoạn tương ứng. Hàm mất mát chính của nhiệm vụ phân đoạn là hàm cross-entropy đa lớp, dùng để giám sát dự đoán nhãn theo từng điểm ảnh. Bên cạnh đó, do mô hình đề xuất có thêm khối hiệu chỉnh biểu diễn tiềm ẩn dựa trên khuếch tán, quá trình huấn luyện còn bao gồm hàm mất mát khử nhiễu trong không gian tiềm ẩn. Hai thành phần mất mát này được kết hợp trong hàm mục tiêu tổng quát:

$$\mathcal{L} = \lambda_{\text{seg}} \mathcal{L}_{\text{seg}} + \lambda_{\text{diff}} \mathcal{L}_{\text{diff}}, \quad (3.22)$$

trong đó $\mathcal{L}_{\text{seg}}$ là hàm mất mát cross-entropy cho nhiệm vụ phân đoạn, $\mathcal{L}_{\text{diff}}$ là hàm mất mát khử nhiễu trong không gian tiềm ẩn được định nghĩa ở Công thức (3.13), còn λ_{seg} và λ_{diff} là các hệ số điều chỉnh mức đóng góp của từng thành phần.

Mục tiêu của quá trình huấn luyện là đồng thời tối ưu khả năng phân loại từng điểm ảnh và khả năng hiệu chỉnh cấu trúc trong không gian tiềm ẩn. Thành phần mất mát phân đoạn giúp

bộ mã hóa–giải mã học được các đặc trưng phân biệt giữa nhiều nền, LTE, 5G NR và ASR. Trong khi đó, thành phần mất mát khuếch tán giúp không gian tiềm ẩn học được quá trình khử nhiễu và phục hồi các cấu trúc phổ bị suy giảm. Nhờ cơ chế huấn luyện kết hợp này, mô hình không chỉ tối ưu kết quả phân đoạn cuối cùng mà còn cải thiện chất lượng của biểu diễn trung gian, từ đó tăng độ ổn định trong các điều kiện SNR thấp hoặc có nhiễu mạnh.

Mô hình cuối cùng được lựa chọn dựa trên hiệu suất trên tập kiểm định. Trong quá trình đánh giá, ngoài các chỉ số về độ chính xác phân đoạn, luận văn cũng ghi nhận số lượng tham số và thời gian suy luận của mô hình để đánh giá sự cân bằng giữa hiệu năng và chi phí tính toán. Đây là tiêu chí quan trọng vì bài toán giám sát phổ thường yêu cầu mô hình vừa đạt độ chính xác cao, vừa có khả năng suy luận nhanh để phù hợp với các ứng dụng gần thời gian thực.

3.5.3 Phương pháp đánh giá

Hiệu suất của mô hình phân đoạn ảnh phổ được đánh giá bằng các chỉ số thường dùng trong bài toán phân đoạn ngữ nghĩa, bao gồm độ chính xác trung bình theo lớp (mAcc) và giao trên hợp trung bình (mIoU) [32]. Các chỉ số này được tính dựa trên kết quả so sánh giữa bản đồ phân đoạn dự đoán và bản đồ nhãn thực tế trên tập kiểm định. Trong bài toán này, số lớp được ký hiệu là K , với $K = 4$ tương ứng với bốn lớp gồm nhiễu nền, LTE, 5G NR và ASR.

Chỉ số độ chính xác trung bình theo lớp, ký hiệu là mAcc, đo lường trung bình tỷ lệ điểm ảnh được phân loại đúng trong từng lớp. Với mỗi lớp i , độ chính xác của lớp đó được tính bằng tỷ lệ giữa số điểm ảnh thuộc lớp i được dự đoán đúng và tổng số điểm ảnh thực sự thuộc lớp i . Chỉ số mAcc được xác định như sau:

$$\text{mAcc} = \frac{1}{K} \sum_{i=1}^K \frac{\text{TP}_i}{\text{TP}_i + \text{FN}_i}, \quad (3.23)$$

trong đó TP_i là số điểm ảnh thuộc lớp i và được dự đoán đúng là lớp i , còn FN_i là số điểm ảnh thuộc lớp i nhưng bị dự đoán sang lớp khác. Khác với độ chính xác toàn cục, mAcc tính trung bình theo từng lớp nên phản ánh tốt hơn hiệu suất của mô hình trong trường hợp dữ liệu có sự mất cân bằng giữa các lớp.

Chỉ số giao trên hợp trung bình, ký hiệu là mIoU, được sử dụng để đánh giá mức độ chồng lấp giữa vùng dự đoán và vùng nhãn thực tế của từng lớp. Với lớp i , IoU được tính bằng tỷ lệ giữa phần giao và phần hợp của vùng dự đoán với vùng nhãn thực tế:

$$\begin{aligned} \text{IoU}_i &= \frac{\text{TP}_i}{\text{TP}_i + \text{FP}_i + \text{FN}_i}, \\ \text{mIoU} &= \frac{1}{K} \sum_{i=1}^K \text{IoU}_i. \end{aligned} \quad (3.24)$$

Trong đó, FP_i là số điểm ảnh không thuộc lớp i nhưng bị dự đoán nhầm là lớp i . Chỉ số mIoU là thước đo quan trọng đối với bài toán phân đoạn vì nó không chỉ phản ánh khả năng phân loại đúng điểm ảnh, mà còn đánh giá chất lượng khoanh vùng của từng lớp tín hiệu. Đối với ảnh phổ vô tuyến, mIoU đặc biệt có ý nghĩa vì các lỗi tại biên tín hiệu, vùng phổ hẹp hoặc vùng bị chồng lấn đều ảnh hưởng trực tiếp đến phân giao và phân hợp của từng lớp.

Bên cạnh mAcc và mIoU, luận văn còn sử dụng số lượng tham số và thời gian suy luận để đánh giá hiệu quả tính toán của mô hình. Số lượng tham số cho biết độ phức tạp của kiến trúc và mức tài nguyên bộ nhớ cần thiết khi triển khai. Thời gian suy luận phản ánh tốc độ xử lý của mô hình đối với một ảnh phổ đầu vào. Hai tiêu chí này được xem xét cùng với độ chính xác phân đoạn nhằm đánh giá sự cân bằng giữa hiệu năng và chi phí tính toán, đặc biệt trong bối cảnh các hệ thống giám sát phổ cần hoạt động nhanh và ổn định trong môi trường vô tuyến phức tạp.


Chương 4

KẾT QUẢ VÀ THẢO LUẬN


Chương này trình bày các kết quả mô phỏng nhằm đánh giá hiệu quả của phương pháp phân đoạn ảnh phổ được đề xuất. Trọng tâm của chương là phân tích khả năng nhận dạng và khoanh vùng các tín hiệu vô tuyến trong những điều kiện truyền dẫn khác nhau, đồng thời xem xét sự cân bằng giữa độ chính xác phân đoạn, độ phức tạp mô hình và tốc độ suy luận. Các thí nghiệm được tổ chức theo ba nhóm nội dung chính. Trước hết, hiệu suất phân đoạn của mô hình được khảo sát trên nhiều mức SNR khác nhau nhằm đánh giá khả năng hoạt động ổn định trong môi trường nhiễu, đặc biệt khi các tín hiệu LTE, 5G NR và ASR cùng tồn tại trên miền thời gian–tần số. Tiếp theo, nghiên cứu loại bỏ được thực hiện để phân tích vai trò của hai thành phần cải tiến chính trong kiến trúc, bao gồm khối hiệu chỉnh tiềm ẩn dựa trên khuếch tán và cơ chế phản hồi độ bất định. Cuối cùng, mô hình đề xuất được so sánh với các phương pháp phân đoạn ngữ nghĩa tiên tiến nhằm làm rõ hiệu quả tổng thể cũng như tiềm năng ứng dụng trong các bài toán giám sát phổ thực tế.

4.1 ĐÁNH GIÁ HIỆU SUẤT PHÂN ĐOẠN CỦA MÔ HÌNH ĐỀ XUẤT

Ma trận nhầm lẫn trong Hình 4.1(a) cung cấp cái nhìn tổng quát về khả năng phân loại của mô hình đề xuất đối với bốn lớp trên ảnh phổ, bao gồm Noise, LTE, 5G NR và ASR. Nhìn chung, các giá trị lớn tập trung chủ yếu trên đường chéo chính của ma trận, cho thấy phần lớn điểm ảnh trong tập đánh giá được mô hình gán đúng nhãn tương ứng. Cụ thể, tỷ lệ phân loại đúng đạt 98.94% đối với Noise và 97.74% đối với Radar, trong khi LTE và 5G NR lần lượt đạt 94.45% và 95.91%. Các kết quả này cho thấy mô hình có khả năng phân biệt tốt giữa vùng nhiễu nền, các tín hiệu thông tin di động và tín hiệu ASR trong cùng một ảnh phổ. Đối với lớp Noise, tỷ lệ đúng cao



(a) Ma trận nhầm lẫn tổng thể




(b) Mean Accuracy và Mean IoU theo SNR

Hình 4.1: Kết quả đánh giá tổng thể của mô hình đề xuất. (a) Ma trận nhầm lẫn trên toàn bộ tập đánh giá đối với bốn lớp Noise, LTE, 5G NR và ASR. Trục tung biểu diễn lớp thực tế, trong khi trục hoành biểu diễn lớp dự đoán. (b) Hiệu suất của mô hình thông qua hai chỉ số mAcc và mIoU tại các mức SNR khác nhau, từ -10 dB đến 30 dB.

nhất phản ánh rằng mô hình nhận dạng ổn định các vùng không chứa tín hiệu, vốn có phân bố phổ khác biệt so với các vùng có cấu trúc tín hiệu rõ ràng. Đối với lớp Radar, tỷ lệ đúng 97.74% cho thấy mô hình vẫn phát hiện tốt các thành phần tín hiệu có dạng hẹp hoặc rời rạc, mặc dù loại tín hiệu này thường dễ bị ảnh hưởng bởi sai lệch biên do diện tích vùng chiếm dụng nhỏ. Trong khi đó, LTE và 5G NR có tỷ lệ đúng thấp hơn một phần so với Noise và Radar. Điều này là hợp lý vì hai lớp này đều thuộc nhóm tín hiệu thông tin di động, có thể có các đặc điểm phổ gần nhau trong một số điều kiện truyền dẫn, đặc biệt tại vùng biên, vùng bị nhiễu mạnh hoặc vùng chịu ảnh hưởng bởi fading và Doppler. Một số nhầm lẫn ngoài đường chéo vì vậy chủ yếu phản ánh các trường hợp mà năng lượng tín hiệu bị suy giảm, bị phân tán hoặc có đặc trưng gần với lớp lân cận. Tuy nhiên, mức độ tập trung cao trên đường chéo chính cho thấy mô hình không chỉ phát hiện được vùng phổ có tín hiệu, mà còn phân loại được loại tín hiệu tương ứng với độ ổn định cao trong bài toán phân đoạn ảnh phổ đa lớp.


Hình 4.1(b) trình bày xu hướng thay đổi của hiệu suất tổng thể theo các mức SNR từ -10 dB đến 30 dB. Đây là phân tích quan trọng vì bài toán giám sát phổ trong môi trường thực tế thường chịu ảnh hưởng bởi nhiễu nền, fading, Doppler và sự đồng tồn tại của nhiều nguồn phát. Khi SNR thấp, đặc biệt ở mức -10 dB, ảnh phổ bị nhiễu mạnh nên các cấu trúc thời gian–tần số của LTE, 5G NR và Radar trở nên kém rõ ràng hơn. Nhiễu nền làm giảm độ tương phản giữa vùng tín hiệu và vùng nền, khiến ranh giới giữa các lớp bị mờ và làm tăng khả năng nhầm lẫn tại các vùng tín hiệu yếu hoặc vùng biên. Vì vậy, việc hiệu suất ở mức SNR thấp thấp hơn so với các mức SNR còn lại là phù hợp với đặc điểm của bài toán. Khi SNR tăng, năng lượng tín hiệu trở nên nổi bật hơn so với nền nhiễu, các đường biên và cấu trúc phổ được thể hiện rõ hơn, nhờ đó mô hình có thêm thông tin để khoanh vùng và phân loại từng lớp tín hiệu chính xác hơn. Trên toàn bộ tập đánh giá, mô hình đạt 97.39% mAcc và 95.57% mIoU. Hai chỉ số này phản ánh hai khía cạnh bổ sung cho nhau: mAcc cho thấy khả năng phân loại đúng theo từng lớp, trong khi



Hình 4.2: Hiệu suất theo từng lớp của mô hình đề xuất tại các mức SNR khác nhau, từ -10 dB đến 30 dB. (a) Accuracy theo từng lớp đối với Noise, LTE, 5G NR và ASR. (b) IoU theo từng lớp đối với Noise, LTE, 5G NR và Radar.

mIoU đánh giá mức độ chồng khớp giữa vùng dự đoán và vùng nhãn thực tế. Việc mAcc và mIoU đều đạt giá trị cao cho thấy mô hình không chỉ dự đoán đúng nhãn ở mức điểm ảnh, mà còn giữ được hình dạng vùng chiếm dụng phổ tương đối chính xác. Điều này đặc biệt quan trọng trong bài toán cảm nhận phổ, vì hệ thống không chỉ cần xác định tín hiệu nào xuất hiện, mà còn cần định vị đúng vùng thời gian–tần số mà tín hiệu đó chiếm dụng.

Hình 4.2 cho phép phân tích chi tiết hơn mức độ ảnh hưởng của SNR lên từng lớp tín hiệu. Ở điều kiện nhiễu mạnh tại -10 dB, mô hình vẫn duy trì khả năng nhận dạng tương đối tốt đối với Noise và Radar. Cụ thể, lớp Noise đạt 96.73% accuracy và 91.68% IoU, trong khi lớp Radar đạt 94.50% accuracy và 88.48% IoU. Điều này cho thấy mô hình vẫn có thể phân biệt vùng nền và phát hiện phần lớn cấu trúc ASR ngay cả khi ảnh phổ bị nhiễu nặng. Ngược lại, LTE và 5G NR nhạy cảm hơn với nhiễu nền ở mức SNR thấp, với accuracy lần lượt đạt 89.03% và 90.96%. Sự suy giảm này có thể được giải thích bởi đặc trưng của các tín hiệu thông tin di động, vốn có cấu trúc sóng mang con dày đặc và dễ bị che khuất khi nền nhiễu tăng cao. Khi SNR tăng lên 0 dB, accuracy của tất cả các lớp đều vượt 95%, trong khi IoU đạt khoảng 94%–97%. Điều này cho thấy chỉ cần chất lượng tín hiệu được cải thiện khỏi vùng nhiễu cực mạnh, mô hình đã có khả năng phục hồi rõ rệt cả về nhận dạng lớp lẫn mức độ trùng khớp vùng phân đoạn. Ở các mức SNR lớn hơn 10 dB, hiệu suất có xu hướng ổn định hơn, với IoU của các lớp nằm trong khoảng 95%–98%. Tuy nhiên, mức độ ổn định giữa các lớp không hoàn toàn giống nhau. Noise là lớp ổn định nhất do vùng nền có đặc trưng tương đối khác biệt. LTE và 5G NR cải thiện mạnh khi SNR tăng vì cấu trúc phổ dày đặc của chúng trở nên rõ hơn. Radar vẫn là lớp khó hơn về mặt IoU do vùng tín hiệu thường hẹp, rời rạc hoặc chiếm diện tích nhỏ trên ảnh phổ; do đó, chỉ một sai lệch nhỏ tại biên cũng có thể làm giảm IoU đáng kể. Nhìn chung, kết quả theo từng lớp cho thấy mô hình không chỉ đạt hiệu suất trung bình cao, mà còn duy trì được khả năng phân đoạn ổn định trên các loại tín hiệu có hình thái phổ khác nhau.



Hình 4.3: Trực quan hóa kết quả phân đoạn của mô hình đề xuất trên ảnh phổ ở các mức SNR khác nhau, bao gồm ảnh phổ đầu vào, mặt nạ phân đoạn thực tế và mặt nạ phân đoạn dự đoán. Cụ thể: (a) SNR = -10 dB và (b) SNR = 10 dB. Trục hoành biểu diễn tần số (MHz), trong khi trục tung biểu diễn thời gian (ms).

Ngoài các kết quả định lượng, Hình 4.3 trình bày trực quan kết quả phân đoạn của mô hình tại hai mức SNR khác nhau. Mỗi ví dụ bao gồm ảnh phổ đầu vào, mặt nạ phân đoạn thực tế và mặt nạ phân đoạn dự đoán bởi mô hình. Ở mức SNR thấp, nhiễu nền làm giảm độ tương phản giữa vùng tín hiệu và vùng nền, khiến một số cấu trúc phổ trở nên mờ và làm cho ranh giới giữa các lớp khó xác định hơn. Trong trường hợp này, mặt nạ dự đoán có thể xuất hiện một số sai lệch cục bộ tại vùng biên hoặc tại các vùng tín hiệu yếu, nhưng mô hình vẫn giữ được cấu trúc tổng thể của các vùng tín hiệu chính và tránh được các lỗi phân đoạn diện rộng. Điều này phù hợp với xu hướng định lượng: hiệu suất ở SNR thấp bị suy giảm, nhưng mô hình vẫn không mất hoàn toàn khả năng nhận dạng các vùng chiếm dụng phổ. Khi SNR cao hơn, ảnh phổ đầu vào rõ ràng hơn, các vùng tín hiệu có biên sắc nét hơn và sự khác biệt giữa LTE, 5G NR, ASR và Noise trở nên dễ nhận biết hơn. Vì vậy, mặt nạ dự đoán bám sát hơn với mặt nạ thực tế, đặc biệt tại các vùng biên và các cấu trúc tín hiệu hẹp. Kết quả trực quan này bổ sung cho các phân tích trong Hình 4.1 và Hình 4.2, cho thấy mô hình đề xuất không chỉ đạt kết quả tốt trên các chỉ số mAcc và mIoU, mà còn tạo ra mặt nạ phân đoạn có chất lượng trực quan hợp lý trong môi trường phổ phức tạp. Nhìn chung, các kết quả định lượng và định tính cùng cho thấy mô hình có khả năng phân đoạn ổn định trong điều kiện nhiễu đồng tồn tại, chịu ảnh hưởng của nhiễu, fading và Doppler.

Bảng 4.1: Nghiên cứu loại bỏ các thành phần của DiffRefiner, so sánh ảnh hưởng của khối refiner và cơ chế phản hồi độ bất định đến mAcc, mIoU, số lượng tham số và tốc độ suy luận.

Phương pháp	Thành phần		mAcc (%)	mIoU (%)	Tham số (M)	Tốc độ (ms)
	Refiner	Feedback				
Mô hình cơ sở	×	×	95.14	91.95	2.25	2.39
DiffRefiner	✓	×	97.19	95.06	3.69	5.56
	✓	✓	97.39	95.57	4.05	5.61

4.2 NGHIÊN CỨU LOẠI BỎ CÁC THÀNH PHẦN CỦA MÔ HÌNH

Để đánh giá vai trò của các thành phần chính trong kiến trúc DiffRefiner, nghiên cứu loại bỏ được thực hiện và kết quả được trình bày trong Bảng 4.1. Mục tiêu của thí nghiệm này là phân tích mức độ đóng góp của từng mô-đun đối với hiệu suất phân đoạn tổng thể, đồng thời xem xét sự đánh đổi giữa độ chính xác, số lượng tham số và thời gian suy luận. Cụ thể, mô hình cơ sở không sử dụng khối refiner và cơ chế phản hồi độ bất định được dùng làm mốc so sánh ban đầu. Sau đó, khối refiner được bổ sung nhằm đánh giá ảnh hưởng của quá trình hiệu chỉnh biểu diễn tiềm ẩn đối với chất lượng phân đoạn. Cuối cùng, cơ chế phản hồi độ bất định được tích hợp thêm để kiểm tra khả năng điều tiết tín hiệu hiệu chỉnh dựa trên độ bất định của dự đoán. Cách thiết kế thí nghiệm này giúp làm rõ liệu sự cải thiện của DiffRefiner đến từ việc tăng quy mô mô hình đơn thuần hay thực sự đến từ vai trò chức năng của từng thành phần được đề xuất.

Phân tích mô hình cơ sở. Từ kết quả trong Bảng 4.1, mô hình cơ sở đạt 95.14% mAcc và 91.95% mIoU với 2.25 triệu tham số và tốc độ suy luận 2.39 ms. Đây là cấu hình không sử dụng khối refiner và cũng không có cơ chế phản hồi độ bất định, do đó kết quả này phản ánh trực tiếp năng lực của kiến trúc encoder-decoder ban đầu trong việc trích xuất đặc trưng và tạo mặt nạ phân đoạn. Giá trị mAcc tương đối cao cho thấy mô hình cơ sở đã học được các đặc trưng phân biệt chính giữa Noise, LTE, 5G NR và ASR. Ở các vùng phổ có cấu trúc rõ ràng, chẳng hạn vùng nền ổn định hoặc vùng tín hiệu có năng lượng nổi bật, đặc trưng được trích xuất từ encoder có thể đủ để decoder gán nhãn đúng cho phần lớn điểm ảnh. Tuy nhiên, mIoU chỉ đạt 91.95%, thấp hơn đáng kể so với các cấu hình có bổ sung thành phần hiệu chỉnh. Điều này cho thấy hạn chế chính của mô hình cơ sở không chỉ nằm ở khả năng phân loại lớp, mà nằm nhiều hơn ở khả năng xác định chính xác hình dạng, biên và vùng chiếm dụng phổ của từng tín hiệu. Trong bài toán phân đoạn ảnh phổ, mAcc có thể vẫn cao nếu phần lớn điểm ảnh được dự đoán đúng, trong khi mIoU sẽ giảm mạnh khi mặt nạ dự đoán bị lệch biên, bị đứt đoạn, hoặc dự đoán thừa sang vùng nền. Vì vậy, sự chênh lệch giữa mAcc và mIoU cho thấy mô hình cơ sở vẫn còn gặp khó trong việc tạo ra mặt nạ phân đoạn có độ khớp hình học cao với nhãn thực tế.

Nguyên nhân của hiện tượng này đến từ cách mô hình cơ sở xử lý biểu diễn đặc trưng. Khi

không có refiner, toàn bộ quá trình phân đoạn phụ thuộc trực tiếp vào đặc trưng được encoder trích xuất từ ảnh phổ đầu vào. Trong điều kiện lý tưởng, các đặc trưng này có thể biểu diễn tốt sự khác biệt giữa các lớp. Tuy nhiên, trong môi trường phổ thực tế hơn, tín hiệu thường chịu ảnh hưởng của nhiễu nền, fading và Doppler, làm cho ranh giới giữa các vùng tín hiệu trở nên mờ hoặc không liên tục. Các tín hiệu LTE và 5G NR có thể có cấu trúc phổ dày đặc và gần nhau, trong khi Radar có thể xuất hiện dưới dạng vùng hẹp hoặc rời rạc. Những đặc điểm này làm cho đặc trưng sâu tại các vùng biên dễ bị nhiễu hoặc thiếu ổn định. Nếu không có cơ chế hiệu chỉnh bổ sung, các sai lệch trong đặc trưng sâu sẽ được truyền trực tiếp sang decoder, khiến decoder tạo ra mặt nạ phân đoạn chưa thật sự bám sát vùng tín hiệu thực tế. Do đó, mô hình cơ sở có ưu điểm là gọn và nhanh, nhưng vẫn bị giới hạn bởi khả năng tự sửa lỗi đặc trưng, đặc biệt ở các vùng phổ khó, vùng tín hiệu yếu hoặc vùng chuyển tiếp giữa các lớp.

Ảnh hưởng của khối refiner. Khi bổ sung khối refiner, hiệu suất của mô hình được cải thiện rõ rệt, với mAcc tăng từ 95.14% lên 97.19% và mIoU tăng từ 91.95% lên 95.06%. Mức cải thiện tương ứng là 2.05% đối với mAcc và 3.11% đối với mIoU. Việc mIoU tăng mạnh hơn mAcc là một điểm đáng chú ý, vì nó cho thấy refiner không chỉ giúp mô hình dự đoán đúng thêm một số điểm ảnh, mà còn cải thiện đáng kể chất lượng không gian của mặt nạ phân đoạn. Nói cách khác, refiner giúp vùng dự đoán trở nên liền mạch hơn, ít bị đứt gãy hơn và bám sát hơn với hình dạng thực tế của tín hiệu trên miền thời gian-tần số. Đây là cải thiện quan trọng trong bài toán phân đoạn phổ, vì mục tiêu không chỉ là xác định loại tín hiệu xuất hiện, mà còn phải xác định đúng phạm vi chiếm dụng phổ của từng tín hiệu.

Về mặt cơ chế, khối refiner không được thiết kế như một nhánh dự đoán độc lập hay một bộ sinh mặt nạ phân đoạn riêng biệt. Thay vào đó, refiner đóng vai trò như một bộ hiệu chỉnh biểu diễn tiềm ẩn, tức là can thiệp vào đặc trưng sâu trước khi decoder tạo ra mặt nạ cuối cùng. Điều này khác với việc chỉ tăng số lớp hoặc tăng số kênh trong encoder, vì refiner tập trung vào việc sửa các sai lệch đã tồn tại trong biểu diễn đặc trưng. Khi encoder tạo ra một biểu diễn ban đầu còn bị ảnh hưởng bởi nhiễu hoặc suy hao kênh truyền, refiner giúp tái tổ chức lại thông tin trong không gian tiềm ẩn, làm nổi bật các cấu trúc tín hiệu quan trọng và giảm tác động của các thành phần nhiễu không liên quan. Cơ chế hiệu chỉnh này đặc biệt hữu ích đối với các vùng biên tín hiệu, vùng tín hiệu yếu hoặc các cấu trúc phổ không liên tục, nơi decoder thường khó phân biệt chính xác nếu chỉ dựa vào đặc trưng ban đầu. Vì vậy, sự cải thiện lớn ở mIoU có thể được hiểu là kết quả của việc refiner giúp mô hình khôi phục tốt hơn hình dạng vùng tín hiệu, thay vì chỉ cải thiện khả năng phân loại lớp một cách tổng quát.

Tuy nhiên, khối refiner cũng là thành phần làm tăng chi phí tính toán đáng kể nhất trong nghiên cứu loại bỏ. Khi thêm refiner, số lượng tham số tăng từ 2.25 triệu lên 3.69 triệu, tức tăng 1.44 triệu tham số, trong khi thời gian suy luận tăng từ 2.39 ms lên 5.56 ms. Điều này cho thấy quá trình hiệu chỉnh biểu diễn tiềm ẩn yêu cầu thêm năng lực mô hình và thời gian xử lý. Tuy vậy, mức tăng chi phí này đi kèm với mức cải thiện 3.11% mIoU, là mức cải thiện lớn nhất trong

toàn bộ nghiên cứu loại bỏ. Do đó, có thể xem refiner là thành phần đóng góp chính vào hiệu quả của DiffRefiner. Nó giải quyết đúng điểm yếu của mô hình cơ sở: không phải là thiếu khả năng nhận biết lớp, mà là thiếu khả năng sửa các sai lệch cục bộ trong biểu diễn đặc trưng để tạo ra mặt nạ phân đoạn chính xác hơn.

Ảnh hưởng của cơ chế phản hồi độ bất định. Khi tiếp tục tích hợp cơ chế phản hồi độ bất định, mô hình đầy đủ đạt 97.39% mAcc và 95.57% mIoU với 4.05 triệu tham số và tốc độ suy luận 5.61 ms. So với cấu hình chỉ sử dụng refiner, cơ chế phản hồi độ bất định giúp cải thiện thêm 0.20% mAcc và 0.51% mIoU. Mức tăng này nhỏ hơn so với khi bổ sung refiner, nhưng vẫn có ý nghĩa vì feedback không nhằm thay thế vai trò hiệu chỉnh chính của refiner, mà đóng vai trò điều tiết quá trình hiệu chỉnh. Nếu refiner tạo ra tín hiệu hiệu chỉnh cho biểu diễn sâu, thì feedback quyết định cách sử dụng tín hiệu đó sao cho hợp lý hơn. Nói cách khác, cơ chế phản hồi độ bất định giúp mô hình trả lời câu hỏi: vùng nào cần được hiệu chỉnh mạnh hơn và vùng nào nên được giữ ổn định hơn. Đây là điểm quan trọng, vì không phải mọi vị trí trên ảnh phổ đều có cùng mức độ khó. Một số vùng có tín hiệu rõ ràng và dự đoán chắc chắn, trong khi một số vùng khác có độ bất định cao do nhiễu, biên mờ hoặc sự tương đồng giữa các lớp tín hiệu.

Về mặt cơ chế, cơ chế phản hồi độ bất định khai thác thông tin độ bất định của dự đoán để điều tiết tín hiệu hiệu chỉnh được đưa trở lại đặc trưng sâu. Nếu áp dụng hiệu chỉnh đồng đều trên toàn bộ ảnh phổ, mô hình có thể can thiệp không cần thiết vào các vùng đã được dự đoán đúng, thậm chí làm thay đổi các đặc trưng vốn đã ổn định. Điều này có thể gây ra hiện tượng hiệu chỉnh quá mức ở các vùng dễ, làm giảm tính nhất quán của mặt nạ phân đoạn. Ngược lại, các vùng có độ bất định cao như biên giữa Noise và tín hiệu, vùng LTE hoặc 5G NR bị suy giảm, hoặc các cấu trúc ASR hẹp và rời rạc lại cần được bổ sung nhiều thông tin hiệu chỉnh hơn. Feedback giúp mô hình phân biệt hai loại vùng này, từ đó tập trung quá trình hiệu chỉnh vào các vị trí thật sự cần thiết. Nhờ vậy, mô hình đầy đủ có thể cải thiện thêm mIoU mà không cần tăng đáng kể độ phức tạp.

Sự khác biệt về chi phí giữa khối refiner và cơ chế phản hồi độ bất định cũng cho thấy vai trò riêng của từng thành phần. Khi thêm cơ chế phản hồi độ bất định, số lượng tham số chỉ tăng từ 3.69 triệu lên 4.05 triệu, tức tăng 0.36 triệu tham số, và thời gian suy luận chỉ tăng từ 5.56 ms lên 5.61 ms. Mức tăng thời gian 0.05 ms là rất nhỏ so với lợi ích đạt được về mIoU. Điều này cho thấy feedback là một thành phần có hiệu quả cao về mặt chi phí: nó không tạo ra mức tăng lớn như refiner, nhưng giúp tinh chỉnh kết quả cuối cùng theo hướng ổn định và chính xác hơn. Trong bối cảnh phân đoạn ảnh phổ, cải thiện 0.51% mIoU sau khi đã có refiner là đáng chú ý, vì ở giai đoạn này mô hình đã đạt hiệu suất cao và các lỗi còn lại thường tập trung ở những vùng khó. Do đó, feedback có thể được xem là cơ chế tinh chỉnh cuối, giúp mô hình xử lý tốt hơn các sai lệch nhỏ còn sót lại sau quá trình hiệu chỉnh tiềm ẩn.

Nhận xét chung. Nhìn chung, kết quả nghiên cứu loại bỏ cho thấy hiệu quả của DiffRefiner

không đến từ việc tăng quy mô mô hình một cách đơn thuần, mà đến từ cách các thành phần được thiết kế để giải quyết những hạn chế khác nhau trong quá trình phân đoạn ảnh phổ. Mô hình cơ sở cung cấp năng lực phân đoạn ban đầu với số lượng tham số thấp và tốc độ suy luận nhanh, nhưng vẫn bị giới hạn bởi việc phụ thuộc trực tiếp vào đặc trưng encoder. Khi ảnh phổ bị nhiễu hoặc các vùng tín hiệu có biên không rõ ràng, các sai lệch trong đặc trưng sâu có thể dẫn đến mất nạ phân đoạn chưa khớp chính xác với vùng tín hiệu thực tế. Khối refiner giải quyết hạn chế này bằng cách hiệu chỉnh biểu diễn tiềm ẩn, từ đó cải thiện mạnh chất lượng vùng phân đoạn. Cơ chế feedback tiếp tục bổ sung một tầng điều tiết, giúp quá trình hiệu chỉnh trở nên chọn lọc và thích nghi hơn với độ khó của từng vùng trên ảnh phổ.

Xét về mức cải thiện, mô hình đầy đủ tăng từ 95.14% lên 97.39% mAcc và từ 91.95% lên 95.57% mIoU so với mô hình cơ sở, tương ứng với mức tăng 2.25% mAcc và 3.62% mIoU. Việc mIoU tăng nhiều hơn mAcc cho thấy mô hình đầy đủ đặc biệt hiệu quả trong việc cải thiện chất lượng mặt nạ phân đoạn, bao gồm độ khớp vùng, độ liên tục của cấu trúc tín hiệu và độ chính xác tại biên. Đây là kết quả phù hợp với mục tiêu thiết kế của DiffRefiner: không chỉ tăng khả năng phân loại điểm ảnh, mà còn nâng cao khả năng hiệu chỉnh và định vị vùng chiếm dụng phổ. Mặc dù số lượng tham số tăng từ 2.25 triệu lên 4.05 triệu và thời gian suy luận tăng từ 2.39 ms lên 5.61 ms, mô hình đầy đủ vẫn giữ quy mô tương đối gọn và tốc độ ở mức chấp nhận được. Do đó, sự kết hợp giữa khối refiner và cơ chế phản hồi độ bất định tạo ra một sự đánh đổi hợp lý giữa độ chính xác và chi phí tính toán. Refiner đóng vai trò là thành phần cải thiện chính bằng cách sửa biểu diễn tiềm ẩn, trong khi cơ chế phản hồi độ bất định đóng vai trò điều tiết và ổn định quá trình hiệu chỉnh. Sự phối hợp này giúp DiffRefiner đạt được hiệu suất phân đoạn cao hơn, đặc biệt trong các điều kiện phổ phức tạp có nhiễu, fading, Doppler và nhiễu loại tín hiệu đồng tồn tại.

4.3 SO SÁNH HIỆU SUẤT PHÂN ĐOẠN VỚI CÁC MÔ HÌNH TIỀN TIẾN

Trong phần này, mô hình đề xuất DiffRefiner được so sánh với một số kiến trúc phân đoạn ngữ nghĩa tiêu biểu và các phương pháp có liên quan đến bài toán phân đoạn ảnh phổ. Kết quả so sánh được trình bày trong Bảng 4.2. Việc đánh giá không chỉ dựa trên các chỉ số độ chính xác như mAcc và mIoU, mà còn xét đến số lượng tham số và thời gian suy luận của từng mô hình. Đây là các yếu tố quan trọng trong bối cảnh giám sát phổ, vì một mô hình phân đoạn tốt không chỉ cần nhận dạng chính xác các vùng tín hiệu LTE, 5G NR, ASR và Noise, mà còn cần duy trì mức độ phức tạp hợp lý để có thể triển khai trong các hệ thống xử lý gần thời gian thực. Đặc biệt, trong môi trường phổ động, nơi tín hiệu có thể thay đổi nhanh theo thời gian và chịu ảnh hưởng của nhiễu, fading hoặc Doppler, sự cân bằng giữa độ chính xác phân đoạn và hiệu quả tính

toán trở thành một tiêu chí đánh giá quan trọng. Do đó, phần so sánh này tập trung phân tích không chỉ mô hình nào đạt kết quả cao nhất, mà còn làm rõ nguyên nhân vì sao các mô hình có sự khác biệt về hiệu suất và chi phí tính toán.

Phân tích nhóm mô hình phân đoạn tổng quát và mô hình nhẹ. Từ kết quả trong Bảng 4.2, có thể thấy nhóm các mô hình phân đoạn ngữ nghĩa phổ biến như DeepLabV3+, BiSeNetV2 và SegFormer đạt hiệu suất thấp hơn đáng kể so với DiffRefiner. DeepLabV3+ đạt 81.77% mAcc và 77.60% mIoU, trong khi BiSeNetV2 và SegFormer lần lượt đạt 84.21%, 85.54% mAcc và 80.10%, 80.96% mIoU. Mặc dù đây đều là các kiến trúc đã được sử dụng rộng rãi trong phân đoạn ảnh tự nhiên, kết quả này cho thấy việc áp dụng trực tiếp chúng vào ảnh phổ không phải lúc nào cũng đem lại hiệu quả cao. Nguyên nhân là ảnh phổ có đặc trưng khác đáng kể so với ảnh tự nhiên: các vùng tín hiệu không được xác định bởi hình dạng vật thể thông thường, màu sắc hay kết cấu không gian quen thuộc, mà bởi cấu trúc năng lượng trên miền thời gian–tần số. Ngoài ra, các vùng này có thể bị biến dạng bởi nhiễu nền, fading, Doppler hoặc sự thay đổi công suất tín hiệu, khiến ranh giới giữa tín hiệu và nền không còn rõ ràng. BiSeNetV2 và SegFormer là hai mô hình có số lượng tham số khá gần với DiffRefiner, lần lượt là 3.62 triệu và 3.72 triệu tham số, đồng thời có tốc độ suy luận nhanh hơn với 3.04 ms và 3.20 ms. Tuy nhiên, mIoU của chúng chỉ đạt 80.10% và 80.96%, thấp hơn rất nhiều so với 95.57% của DiffRefiner. Điều này cho thấy mô hình gọn nhẹ chưa đủ để đảm bảo hiệu quả trong bài toán phân đoạn ảnh phổ. BiSeNetV2 được thiết kế theo hướng ưu tiên tốc độ, thường dựa vào việc tách nhánh chi tiết và nhánh ngữ cảnh để đạt suy luận nhanh. Tuy nhiên, trong ảnh phổ, ranh giới giữa tín hiệu và nhiễu có thể không sắc nét như ranh giới vật thể trong ảnh tự nhiên, nên việc ưu tiên tốc độ và giảm mạnh chi phí biểu diễn có thể làm mô hình mất đi các thông tin tinh tế cần thiết để phân biệt lớp. SegFormer sử dụng backbone MiT-B0 và decoder nhẹ, có khả năng trích xuất đặc trưng đa tỷ lệ tốt hơn, nhưng vẫn chưa đủ để mô hình hóa các biến dạng phổ do nhiễu và kênh truyền. DeepLabV3+ sử dụng backbone EfficientNet-B3 và mô-đun ASPP để khai thác ngữ cảnh đa tỷ lệ, nhưng vẫn chỉ đạt 77.60% mIoU với 11.68 triệu tham số và tốc độ 6.26 ms. Kết quả này cho thấy cơ chế đa tỷ lệ của ASPP không tự động đảm bảo hiệu quả cao trong bài toán ảnh phổ. Với ảnh tự nhiên, ASPP giúp mô hình nhận diện đối tượng ở nhiều kích thước khác nhau bằng cách mở rộng trường tiếp nhận. Tuy nhiên, trong ảnh phổ, sự khác biệt giữa các lớp tín hiệu không chỉ nằm ở kích thước vùng, mà còn nằm ở cấu trúc thời gian–tần số, mật độ năng lượng, độ liên tục và sự biến đổi theo SNR. Nếu đặc trưng ban đầu đã bị nhiễu hoặc bị suy giảm bởi kênh truyền, việc mở rộng ngữ cảnh bằng các tích chập giãn nở có thể chưa đủ để khôi phục ranh giới tín hiệu. Nói cách khác, nhóm mô hình này có ưu điểm về tính phổ biến, độ gọn hoặc tốc độ, nhưng thiếu cơ chế chuyên biệt để hiệu chỉnh các vùng khó trong phân đoạn phổ, dẫn đến mIoU thấp hơn rõ rệt.

Phân tích nhóm mô hình có hiệu suất cao. Nhóm mô hình có hiệu suất cao hơn gồm UNet++, SpecDiff và SRNet cho thấy khả năng thích nghi tốt hơn với bài toán phân đoạn ảnh phổ, nhưng đồng thời cũng bộc lộ các đánh đổi khác nhau về độ phức tạp. UNet++ đạt 96.60%

Bảng 4.2: So sánh hiệu suất của DiffRefiner với các mô hình phân đoạn tiên tiến trên bài toán phân đoạn ảnh phổ, xét theo mAcc, mIoU, số lượng tham số và tốc độ suy luận.

Mô hình	Backbone	mAcc (%)	mIoU (%)	Tham số (M)	Tốc độ (ms)
DeepLabV3+	EfficientNet-B3	81.77	77.60	11.68	6.26
BiSeNetV2	–	84.21	80.10	3.62	3.04
SegFormer	MiT-B0	85.54	80.96	3.72	3.20
UNet++	ResNet18	96.60	94.35	15.97	8.05
SpecDiff	–	97.03	94.97	9.70	7.50
SRNet	–	96.98	95.20	19.37	5.65
DiffRefiner	–	97.39	95.57	4.05	5.61

mAcc và 94.35% mIoU, cao hơn rõ rệt so với DeepLabV3+, BiSeNetV2 và SegFormer. Điều này có thể đến từ cấu trúc encoder–decoder với các kết nối lồng nhau, giúp mô hình phục hồi chi tiết không gian tốt hơn và giảm khoảng cách ngữ nghĩa giữa các tầng đặc trưng. Trong bài toán phân đoạn phổ, các kết nối như vậy có thể hỗ trợ bảo toàn thông tin biên và cấu trúc vùng tín hiệu. Tuy nhiên, UNet++ cần 15.97 triệu tham số và thời gian suy luận 8.05 ms, cao hơn đáng kể so với DiffRefiner. Điều này cho thấy UNet++ đạt hiệu suất tốt nhờ một kiến trúc giàu kết nối và nhiều tham số hơn, nhưng đánh đổi bằng chi phí tính toán lớn hơn. SRNet đạt 96.98% mAcc và 95.20% mIoU, là một trong những mô hình có hiệu suất gần nhất với DiffRefiner. Kết quả này cho thấy SRNet có khả năng xử lý tốt các cấu trúc phổ và tạo ra mặt nạ phân đoạn chất lượng cao. Tuy nhiên, mô hình này sử dụng đến 19.37 triệu tham số, lớn hơn DiffRefiner khoảng 4.78 lần. Mặc dù tốc độ suy luận của SRNet là 5.65 ms, gần tương đương với 5.61 ms của DiffRefiner, sự khác biệt lớn về số lượng tham số cho thấy SRNet cần quy mô mô hình lớn hơn để đạt hiệu suất cạnh tranh. SpecDiff cũng đạt hiệu suất cao với 97.03% mAcc và 94.97% mIoU, nhưng cần 9.70 triệu tham số và thời gian suy luận 7.50 ms. Nhìn chung, nhóm mô hình này cho thấy rằng để đạt chất lượng phân đoạn cao trên ảnh phổ, mô hình cần có khả năng biểu diễn mạnh hơn so với các kiến trúc nhẹ thông thường. Tuy nhiên, nếu năng lực biểu diễn được tăng chủ yếu thông qua nhiều tham số, nhiều kết nối hoặc các mô-đun xử lý nặng, chi phí triển khai sẽ tăng theo. Đây chính là điểm khác biệt quan trọng giữa DiffRefiner và nhóm mô hình này, vì DiffRefiner hướng đến cải thiện chất lượng đặc trưng thông qua cơ chế hiệu chỉnh tiềm ẩn thay vì chỉ mở rộng quy mô mạng.

So sánh trực tiếp DiffRefiner với các mô hình cạnh tranh gần nhất. So với các mô hình có hiệu suất cao trong bảng, DiffRefiner đạt kết quả tốt hơn trong khi vẫn duy trì quy mô mô hình nhỏ hơn đáng kể. Cụ thể, DiffRefiner đạt 97.39% mAcc và 95.57% mIoU với chỉ 4.05 triệu tham số và tốc độ suy luận 5.61 ms. So với UNet++, DiffRefiner cải thiện 0.79% mAcc và 1.22% mIoU, đồng thời giảm số lượng tham số từ 15.97 triệu xuống 4.05 triệu. So với SRNet, DiffRefiner cải thiện 0.41% mAcc và 0.37% mIoU, trong khi số lượng tham số giảm từ 19.37 triệu xuống 4.05 triệu. Như vậy, DiffRefiner không chỉ cải thiện chất lượng phân đoạn so với SRNet, mà còn giảm mạnh quy mô mô hình, cho thấy khả năng sử dụng tham số hiệu quả hơn. Một so sánh quan trọng khác là giữa DiffRefiner và SpecDiff, vì cả hai đều có liên quan đến hướng khai

thác diffusion trong bài toán phân đoạn ảnh phổ. SpecDiff đạt 97.03% mAcc và 94.97% mIoU với 9.70 triệu tham số và thời gian suy luận 7.50 ms. Trong khi đó, DiffRefiner đạt 97.39% mAcc và 95.57% mIoU với 4.05 triệu tham số và tốc độ 5.61 ms. Như vậy, DiffRefiner cải thiện 0.36% mAcc và 0.60% mIoU so với SpecDiff, đồng thời giảm 5.65 triệu tham số và nhanh hơn 1.89 ms. Nếu xét tương đối theo số lượng tham số của SpecDiff, mức giảm từ 9.70 triệu xuống 4.05 triệu tương ứng với khoảng 58%. Kết quả này cho thấy DiffRefiner đạt được hiệu quả sử dụng tham số tốt hơn, tức là mô hình không cần một cấu trúc diffusion lớn hơn nhưng vẫn cải thiện được độ chính xác phân đoạn. Sự khác biệt này có thể được giải thích từ vai trò của diffusion trong từng hướng tiếp cận. SpecDiff khai thác diffusion trong không gian tiềm ẩn để hỗ trợ quá trình tái dựng hoặc khôi phục mặt nạ phân đoạn, trong khi DiffRefiner không xem diffusion như một nhánh sinh mặt nạ chính. Thay vào đó, DiffRefiner sử dụng quá trình khuếch tán như một cơ chế hiệu chỉnh biểu diễn tiềm ẩn. Đầu ra ban đầu từ encoder có thể được xem như một giả thuyết ngữ nghĩa ban đầu, sau đó refiner tạo ra tín hiệu hiệu chỉnh để làm rõ hơn các cấu trúc bị nhiễu, các vùng biên không chắc chắn hoặc các phần tín hiệu bị suy giảm. Cách tiếp cận này giúp mô hình tận dụng khả năng khử nhiễu và phục hồi cấu trúc của diffusion, nhưng không làm cho toàn bộ quá trình phân đoạn phụ thuộc vào một mô-đun sinh mặt nạ nặng. Vì vậy, DiffRefiner có thể đạt được mIoU cao hơn SpecDiff trong khi số tham số và thời gian suy luận đều thấp hơn. Đây là điểm khác biệt quan trọng, vì nó cho thấy hiệu quả của việc dùng diffusion như một công cụ hiệu chỉnh đặc trưng thay vì dùng nó như một bộ sinh đầu ra toàn cục.

Nhận xét chung về sự cân bằng giữa độ chính xác và độ phức tạp. Hiệu quả của DiffRefiner cũng phù hợp với các kết quả nghiên cứu loại bỏ đã trình bày ở phần trước. Khối refiner là thành phần tạo ra cải thiện chính, vì nó giúp sửa các sai lệch trong biểu diễn sâu trước khi decoder tạo mặt nạ phân đoạn cuối cùng. Trong ảnh phổ, các sai lệch này thường xuất hiện ở những vùng khó như biên giữa tín hiệu và nhiễu, vùng tín hiệu có năng lượng thấp, hoặc các vị trí mà LTE, 5G NR và Radar có cấu trúc thời gian–tần số gần nhau. Khi refiner được thêm vào, mô hình có khả năng làm rõ hơn cấu trúc vùng tín hiệu, giúp mặt nạ dự đoán bám sát hơn với nhãn thực tế. Cơ chế feedback tiếp tục nâng cao hiệu quả bằng cách sử dụng độ bất định để điều tiết tín hiệu hiệu chỉnh. Thay vì cập nhật toàn bộ bản đồ đặc trưng một cách đồng đều, cơ chế phản hồi độ bất định giúp mô hình tập trung nhiều hơn vào các vùng khó và hạn chế can thiệp vào các vùng đã có dự đoán chắc chắn. Sự kết hợp này giúp DiffRefiner cải thiện mIoU mà không cần tăng số lượng tham số lên mức quá lớn như một số mô hình khác. Xét theo từng tiêu chí, DiffRefiner không phải là mô hình nhanh nhất trong Bảng 4.2. BiSeNetV2 và SegFormer có tốc độ suy luận nhanh hơn, lần lượt là 3.04 ms và 3.20 ms. Tuy nhiên, hai mô hình này có mIoU thấp hơn DiffRefiner trên 14 điểm phần trăm, cho thấy lợi thế về tốc độ đi kèm với tổn thất lớn về chất lượng phân đoạn. Ngược lại, các mô hình có mIoU gần DiffRefiner hơn như UNet++, SpecDiff và SRNet lại có số lượng tham số lớn hơn hoặc thời gian suy luận cao hơn. UNet++ có 15.97 triệu tham số và tốc độ 8.05 ms, SpecDiff có 9.70 triệu tham số và tốc độ 7.50 ms, trong khi SRNet có đến 19.37 triệu tham số. Do đó, DiffRefiner nằm ở một điểm cân bằng thuận lợi hơn:

không nhanh nhất tuyệt đối, nhưng đạt độ chính xác cao nhất với số lượng tham số thấp hơn đáng kể so với các mô hình mạnh nhất trong bảng. Nhìn chung, kết quả so sánh cho thấy DiffRefiner đạt hiệu suất phân đoạn tốt nhất trong các mô hình được đánh giá, với 97.39% mAcc và 95.57% mIoU. Quan trọng hơn, kết quả này đạt được với chỉ 4.05 triệu tham số và thời gian suy luận 5.61 ms, cho thấy mô hình duy trì được sự cân bằng tốt giữa độ chính xác và độ phức tạp. Các mô hình nhẹ như BiSeNetV2 và SegFormer có ưu điểm về tốc độ nhưng chưa đủ mạnh để xử lý các cấu trúc phổ phức tạp. Các mô hình mạnh hơn như UNet++, SpecDiff và SRNet đạt hiệu suất cao hơn nhưng thường đánh đổi bằng số lượng tham số lớn hơn hoặc thời gian suy luận cao hơn. Trong khi đó, DiffRefiner tận dụng cơ chế hiệu chỉnh biểu diễn tiềm ẩn và phản hồi độ bất định để cải thiện chất lượng mặt nạ phân đoạn mà không cần mở rộng quá nhiều quy mô kiến trúc. Điều này khẳng định rằng hướng tiếp cận của DiffRefiner là phù hợp cho bài toán phân đoạn ảnh phổ trong môi trường có nhiều tín hiệu đồng tồn tại, đặc biệt khi yêu cầu đặt ra không chỉ là độ chính xác cao mà còn là khả năng suy luận hiệu quả và mô hình có quy mô gọn.

Chương 5

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 KẾT LUẬN

Trong bối cảnh các hệ thống thông tin vô tuyến ngày càng phát triển và mật độ sử dụng phổ tần ngày càng cao, việc giám sát, nhận dạng và phân đoạn tín hiệu trên miền thời gian–tần số trở thành một yêu cầu quan trọng đối với các hệ thống quản lý phổ thông minh. Các phương pháp xử lý tín hiệu truyền thống thường phụ thuộc vào giả thiết về dạng tín hiệu, ngưỡng quyết định hoặc điều kiện kênh truyền tương đối ổn định, do đó có thể gặp hạn chế khi phổ vô tuyến xuất hiện nhiều tín hiệu đồng tồn tại và chịu ảnh hưởng bởi nhiễu, fading cũng như Doppler. Trước yêu cầu đó, luận văn đã nghiên cứu bài toán phân đoạn ảnh phổ nhằm nhận dạng đồng thời các vùng Noise, LTE, 5G NR và ASR. Tín hiệu đầu vào được chuyển đổi sang biểu diễn ảnh phổ bằng phép biến đổi Fourier thời gian ngắn, qua đó mô hình hóa bài toán nhận dạng tín hiệu thành bài toán phân đoạn ngữ nghĩa trên miền thời gian–tần số. Cách tiếp cận này cho phép tận dụng khả năng biểu diễn mạnh của các mô hình học sâu, đồng thời vẫn giữ được ý nghĩa vật lý của tín hiệu trong không gian phổ. Trên cơ sở đó, luận văn đã đề xuất mô hình DiffRefiner với mục tiêu nâng cao chất lượng phân đoạn ảnh phổ trong điều kiện tín hiệu phức tạp. Điểm chính của phương pháp không chỉ nằm ở việc trích xuất đặc trưng bằng mạng học sâu, mà còn ở quá trình hiệu chỉnh biểu diễn tiềm ẩn trước khi tạo mặt nạ phân đoạn cuối cùng. Cụ thể, bộ mã hóa được dùng để tạo biểu diễn đặc trưng ban đầu từ ảnh phổ, sau đó khối refiner dựa trên cơ chế khuếch tán được sử dụng để hiệu chỉnh biểu diễn này trong không gian tiềm ẩn. Thay vì dùng khuếch tán như một nhánh sinh trực tiếp mặt nạ phân đoạn, DiffRefiner khai thác nó như một cơ chế sửa sai đặc trưng, giúp làm rõ hơn các vùng tín hiệu bị nhiễu, các vùng biên không chắc chắn và các cấu trúc phổ bị suy giảm. Bên cạnh đó, cơ chế phản hồi độ bất định được tích hợp nhằm điều tiết tín hiệu hiệu chỉnh

theo mức độ khó của từng vùng trên ảnh phổ, từ đó giúp mô hình tập trung tốt hơn vào các vị trí dễ nhầm lẫn giữa các lớp.

Các kết quả thực nghiệm cho thấy DiffRefiner đạt hiệu suất phân đoạn cao và ổn định trên tập dữ liệu mô phỏng. Trên toàn bộ tập đánh giá, mô hình đạt 97.39% mAcc và 95.57% mIoU, đồng thời duy trì quy mô tương đối gọn với 4.05 triệu tham số và tốc độ suy luận 5.61 ms. Kết quả phân tích theo SNR cho thấy mô hình vẫn duy trì khả năng phân đoạn đáng kể trong điều kiện nhiễu mạnh, đặc biệt tại các mức SNR thấp, nơi ranh giới giữa tín hiệu và nhiễu nền trở nên kém rõ ràng. Khi SNR tăng, hiệu suất của mô hình được cải thiện và ổn định hơn, phản ánh khả năng khai thác tốt hơn các cấu trúc thời gian–tần số khi tín hiệu trở nên rõ nét. Phân tích theo từng lớp cũng cho thấy mô hình có khả năng nhận dạng tốt cả vùng nền lẫn các tín hiệu LTE, 5G NR và Radar, trong đó các sai lệch chủ yếu xuất hiện tại vùng biên hoặc các vùng tín hiệu yếu. Bên cạnh đó, nghiên cứu loại bỏ đã làm rõ vai trò của từng thành phần trong kiến trúc DiffRefiner. Mô hình cơ sở không sử dụng khối refiner và cơ chế phản hồi độ bất định đạt 95.14% mAcc và 91.95% mIoU, cho thấy kiến trúc ban đầu đã có khả năng phân đoạn tương đối tốt nhưng vẫn còn hạn chế trong việc xác định chính xác hình dạng vùng tín hiệu. Khi bổ sung khối refiner, mIoU tăng lên 95.06%, tương ứng mức cải thiện 3.11% so với mô hình cơ sở. Điều này chứng minh rằng hiệu chỉnh biểu diễn tiềm ẩn đóng vai trò quan trọng trong việc cải thiện độ khớp vùng phân đoạn, đặc biệt tại các vùng phổ khó. Khi tiếp tục tích hợp cơ chế phản hồi độ bất định, mô hình đầy đủ đạt 95.57% mIoU, cho thấy phản hồi độ bất định giúp tinh chỉnh thêm kết quả phân đoạn với chi phí suy luận tăng rất nhỏ. Nhìn chung, kết quả nghiên cứu loại bỏ khẳng định rằng hiệu quả của DiffRefiner không đến từ việc tăng quy mô mô hình một cách đơn thuần, mà đến từ sự phối hợp giữa cơ chế hiệu chỉnh biểu diễn và cơ chế điều tiết theo độ bất định.

Khi so sánh với các mô hình phân đoạn tiên tiến, DiffRefiner cũng cho thấy ưu thế rõ rệt về sự cân bằng giữa độ chính xác và độ phức tạp. Các mô hình nhẹ như BiSeNetV2 và SegFormer có tốc độ suy luận nhanh nhưng mIoU thấp hơn đáng kể, cho thấy việc tối ưu tốc độ đơn thuần chưa đủ để xử lý các cấu trúc phổ phức tạp. Các mô hình có hiệu suất cao hơn như UNet++, SpecDiff và SRNet đạt kết quả cạnh tranh hơn, nhưng thường yêu cầu số lượng tham số lớn hơn hoặc thời gian suy luận cao hơn. DiffRefiner đạt mAcc và mIoU cao nhất trong bảng so sánh, trong khi chỉ sử dụng 4.05 triệu tham số. Đặc biệt, so với SpecDiff, DiffRefiner đạt mIoU cao hơn đồng thời giảm đáng kể số lượng tham số và thời gian suy luận. Kết quả này cho thấy hướng tiếp cận sử dụng khuếch tán như một cơ chế hiệu chỉnh đặc trưng là phù hợp và hiệu quả hơn so với việc sử dụng một nhánh khuếch tán nặng để tái dựng đầu ra toàn cục. Tóm lại, luận văn đã hoàn thành mục tiêu đề ra bằng cách xây dựng một mô hình phân đoạn ảnh phổ có độ chính xác cao, có khả năng chống chịu tốt hơn trước nhiễu và suy hao kênh truyền, đồng thời duy trì quy mô đủ gọn để hướng tới các ứng dụng giám sát phổ thực tế.

5.2 HƯỚNG PHÁT TRIỂN

Trên cơ sở các kết quả đã đạt được, hướng phát triển đầu tiên là mở rộng và kiểm chứng mô hình trên dữ liệu thu thập từ môi trường thực tế. Trong luận văn này, các thí nghiệm được thực hiện trên tập dữ liệu mô phỏng nhằm kiểm soát tốt các yếu tố như SNR, Doppler và cấu hình tín hiệu. Tuy nhiên, trong môi trường vô tuyến thực, tín hiệu có thể chịu ảnh hưởng bởi nhiều yếu tố khó mô hình hóa đầy đủ, chẳng hạn như nhiễu không Gaussian, sai lệch phần cứng, đồng bộ thời gian-tần số không hoàn hảo hoặc méo phi tuyến. Do đó, việc thu thập dữ liệu bằng các nền tảng vô tuyến định nghĩa bằng phần mềm và đánh giá mô hình trên tín hiệu đo thực tế là bước cần thiết để kiểm chứng khả năng khái quát hóa của DiffRefiner. Bên cạnh đó, phạm vi nhận dạng cũng cần được mở rộng sang nhiều loại tín hiệu hơn. Hiện tại, mô hình tập trung vào các lớp Noise, LTE, 5G NR và ASR, trong khi môi trường phổ thực tế có thể bao gồm nhiều dạng tín hiệu khác như Wi-Fi, Bluetooth, tín hiệu vệ tinh, tín hiệu IoT hoặc các dạng radar khác nhau. Việc mở rộng số lượng lớp sẽ giúp mô hình trở thành một công cụ giám sát phổ tổng quát hơn, đồng thời đặt ra yêu cầu nghiên cứu thêm các chiến lược học biểu diễn mạnh hơn để phân biệt các tín hiệu có đặc trưng gần nhau.

Hướng phát triển tiếp theo là tối ưu hóa DiffRefiner để phục vụ triển khai trên các nền tảng tài nguyên hạn chế. Mặc dù mô hình hiện tại đã có quy mô tương đối gọn so với nhiều phương pháp cạnh tranh, việc đưa mô hình vào các thiết bị biên, hệ thống nhúng hoặc nền tảng xử lý thời gian thực vẫn đòi hỏi tối ưu thêm về tốc độ, bộ nhớ và năng lượng tiêu thụ. Các kỹ thuật như lượng tử hóa, tỉa mạng, chưng cất tri thức hoặc thiết kế phiên bản refiner nhẹ hơn có thể được nghiên cứu nhằm giảm chi phí suy luận mà vẫn duy trì phần lớn hiệu suất phân đoạn. Đồng thời, cần khảo sát ảnh hưởng của các kỹ thuật tối ưu này đến từng lớp tín hiệu, đặc biệt là các lớp khó như ASR hoặc các vùng biên giữa tín hiệu và nhiễu, để đảm bảo rằng việc giảm độ phức tạp không làm suy giảm đáng kể chất lượng mặt nạ phân đoạn. Ngoài ra, có thể nghiên cứu các cơ chế học thích nghi miền, học bán giám sát hoặc tự giám sát để mô hình tận dụng dữ liệu chưa gán nhãn trong môi trường triển khai mới. Việc kết hợp các thông tin vật lý của kênh truyền, chẳng hạn như ước lượng SNR, Doppler hoặc đặc trưng fading, vào quá trình hiệu chỉnh tiềm ẩn cũng là một hướng đáng quan tâm, vì các thông tin này có thể giúp khối refiner và cơ chế phản hồi độ bất định đưa ra quyết định hiệu chỉnh phù hợp hơn với từng điều kiện truyền dẫn cụ thể.

Cuối cùng, một hướng nghiên cứu quan trọng là tăng khả năng diễn giải của mô hình. Các mô hình học sâu thường có hiệu suất cao nhưng khó giải thích đầy đủ cơ chế ra quyết định, đặc biệt trong các ứng dụng liên quan đến quản lý phổ tần, nơi độ tin cậy của hệ thống có vai trò quan trọng. Trong tương lai, có thể phân tích sâu hơn bản đồ độ bất định, tín hiệu hiệu chỉnh của refiner hoặc các vùng mà cơ chế phản hồi độ bất định tập trung tác động để hiểu rõ mô hình đang sửa sai ở đâu và vì sao. Việc trực quan hóa các biểu diễn tiềm ẩn trước và sau hiệu chỉnh cũng có

thể giúp làm rõ vai trò của khối refiner trong việc khôi phục cấu trúc phổ. Những phân tích này không chỉ giúp cải thiện độ tin cậy của mô hình, mà còn hỗ trợ việc thiết kế các phiên bản nâng cấp có cơ chế hoạt động rõ ràng và phù hợp hơn với các yêu cầu của hệ thống thông tin vô tuyến thực tế.

CÔNG BỐ KHOA HỌC

Bài báo thuộc tạp chí quốc tế SCI(E)

- **Hoai-Thuong Truong**, Minh-Thanh Le, Quynh-Nhu Thi Tran, and Thien Huynh-The, “DiffRefiner: Uncertainty-Aware Diffusion-Driven Latent Correction for Robust Spectrogram Analysis,” *IEEE Communications Letters*, (SCI(E), Q1 JCR, IF: 4.5) (under review).

TÀI LIỆU THAM KHẢO

- [1] D. Kumar R. and S. Chavhan, “Shift to 6G: Exploration on trends, vision, requirements, technologies, research, and standardization efforts,” *Sustainable Energy Technologies and Assessments*, vol. 54, p. 102666, Dec. 2022.
- [2] J. Kumar, A. Gupta, S. Tanwar, and M. K. Khan, “A review on 5g and beyond wireless communication channel models: Applications and challenges,” *Physical Communication*, vol. 67, p. 102488, Dec. 2024.
- [3] V. Shatov *et al.*, “Integrated radio sensing capabilities for 6G networks: AI/ML perspective,” *IEEE Commun. Surv. Tutor.*, vol. 28, pp. 5081–5120, 2026.
- [4] D. Zhang *et al.*, “Integrated sensing and communications over the years: An evolution perspective,” *IEEE Commun. Surv. Tutor.*, vol. 28, pp. 5014–5048, 2026.
- [5] Y. Zhang and Z. Zhao, “Limited data spectrum sensing based on semi-supervised deep neural network,” *IEEE Access*, vol. 9, pp. 166 423–166 435, Dec. 2021.
- [6] R. Deshpande, F. A. Khan, and Q. Z. Ahmed, “Support vector machine based spectrum sensing in beyond 5g wireless networks,” in *11th International Conference on Wireless Networks and Mobile Communications 2024*, Leeds, United Kingdom, July 2024, pp. 1–5.
- [7] J. Gao, X. Yi, C. Zhong, X. Chen, and Z. Zhang, “Deep learning for spectrum sensing,” *IEEE Wireless Communications Letters*, vol. 8, no. 6, pp. 1727–1730, Sep. 2019.
- [8] C. Liu, J. Wang, X. Liu, and Y.-C. Liang, “Deep CM-CNN for spectrum sensing in cognitive radio,” *IEEE Journal on Selected Areas in Communications*, vol. 37, no. 10, pp. 2306–2321, Aug. 2019.
- [9] W. Zhang, Y. Wang, X. Chen, Z. Cai, and Z. Tian, “Spectrum transformer: An attention-based wideband spectrum detector,” *IEEE Transactions on Wireless Communications*, vol. 23, no. 9, pp. 12 343–12 353, Apr. 2024.
- [10] T. Huynh-The *et al.*, “SRNet: Deep semantic segmentation network for spectrum sensing in wireless communications,” *IEEE Wirel. Commun. Lett.*, vol. 14, no. 2, pp. 355–359, Feb. 2025.
- [11] T.-T. Le *et al.*, “Efficient spectrum sensing via a multi-scale dual-path segmentation network,” *IEEE Wirel. Commun. Lett.*, vol. 14, no. 7, pp. 2134–2138, Jul. 2025.

- [12] D. Uvaydov *et al.*, “DeepSense: Fast wideband spectrum sensing through real-time in-the-loop deep learning,” in *Proc. IEEE INFOCOM*, Vancouver, Canada, May 2021, pp. 1–10.
- [13] T. Huynh-The, Q.-V. Pham, T.-H. Vu, D. B. da Costa, and V.-P. Hoang, “Intelligent spectrum sensing with ConvNet for 5g and lte signals identification,” in *IEEE Statistical Signal Processing Workshop 2023*, Hanoi, Vietnam, July 2023, pp. 140–144.
- [14] 3GPP TS 36.101, “Evolved universal terrestrial radio access; user equipment radio transmission and reception,” 3rd Generation Partnership Project; Technical Specification Group Radio Access Network, Technical Specification, Sep. 2019, version 15.8.0.
- [15] 3GPP TS 38.901, “Study on channel model for frequencies from 0.5 to 100 GHz,” 3rd Generation Partnership Project; Technical Specification Group Radio Access Network, Technical Specification, Sep. 2019, version 15.1.0.
- [16] B. Boashash, *Time-frequency signal analysis and processing: a comprehensive reference*. Academic press, Dec. 2015.
- [17] H. Jeon, Y. Jung, S. Lee, and Y. Jung, “Area-efficient short-time fourier transform processor for time–frequency analysis of non-stationary signals,” *Applied Sciences*, vol. 10, no. 20, Oct. 2020.
- [18] L. Aguiar-Conraria and M. J. Soares, “The continuous wavelet transform: Moving beyond uni-and bivariate analysis,” *Journal of economic surveys*, vol. 28, no. 2, pp. 344–375, Feb. 2014.
- [19] N. Aunsri, P. Jakkaew, and C. Kuptamettee, “Investigation and evaluation of cross-term reduction in masked wigner-ville distributions using s-transforms,” *PloS one*, vol. 19, no. 11, Nov. 2024.
- [20] S. Minaee *et al.*, “Image segmentation using deep learning: A survey,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 44, no. 7, pp. 3523–3542, Jul. 2022.
- [21] O. Ronneberger, P. Fischer, T. Brox, J. Hornegger, W. M. Wells, and A. F. Frangi, “U-Net: Convolutional networks for biomedical image segmentation,” in *International Conference on Medical Image Computing and Computer-Assisted Intervention 2015*, Munich, Germany, Nov. 2015, pp. 234–241.
- [22] Z. Zhou *et al.*, “U-Net++: A nested U-Net architecture for medical image segmentation,” in *Proc. DLMIA*, Granada, Spain, Sep. 2018, pp. 3–11.
- [23] L.-C. Chen *et al.*, “Encoder–decoder with atrous separable convolution for semantic image segmentation,” in *Proc. ECCV*, Munich, Germany, Oct. 2018, pp. 833–851.
- [24] C. Yu *et al.*, “BiSeNet V2: Bilateral network with guided aggregation for real-time semantic segmentation,” *Int. J. Comput. Vis.*, vol. 129, no. 11, pp. 3051–3068, Nov. 2021.

- [25] E. Xie *et al.*, “SegFormer: Simple and efficient design for semantic segmentation with transformers,” in *Annual Conference on Neural Information Processing Systems 2021*, vol. 34, Virtual Event, Dec. 2021, pp. 12 077–12 090.
- [26] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. u. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Advances in Neural Information Processing Systems*, I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, Eds., vol. 30. Curran Associates, Inc., 2017.
- [27] J. Ho *et al.*, “Denoising diffusion probabilistic models,” in *Proc. NeurIPS*, vol. 33, Dec. 2020, pp. 6840–6851.
- [28] Y. Song *et al.*, “Score-based generative modeling through stochastic differential equations,” in *Proc. ICLR*, 2021.
- [29] R. Rombach *et al.*, “High-resolution image synthesis with latent diffusion models,” in *Proc. IEEE/CVF CVPR*, Los Alamitos, CA, USA, Jun. 2022, pp. 10 674–10 685.
- [30] H. Pan *et al.*, “Deep dual-resolution networks for real-time and accurate semantic segmentation of traffic scenes,” *IEEE Trans. Intell. Transp. Syst.*, vol. 24, no. 3, pp. 3448–3460, Mar. 2023.
- [31] T. Huynh-The *et al.*, “Latent diffusion for spectrum sensing of coexisting radar and communication signals,” *IEEE Wirel. Commun. Lett.*, 2026.
- [32] G. Csurka, D. Larlus, F. Perronnin, and F. Meylan, “What is a good evaluation measure for semantic segmentation?.” in *24th British Machine Vision Conference*, vol. 27, University of Bristol, 2013, pp. 10–5244.