

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH  
KHOA ĐIỆN ĐIỆN TỬ  
BỘ MÔN ĐIỆN TỬ – THÔNG TIN



**ĐỒ ÁN TỐT NGHIỆP**

**NGHIÊN CỨU CÁC MÔ HÌNH HỌC SÂU CHO  
PHÂN ĐOẠN ẢNH PHỔ TRONG MÔI TRƯỜNG  
ĐỒNG TỒN TẠI RADAR VÀ TRUYỀN THÔNG**

**NGÀNH HỆ THỐNG NHÚNG VÀ IOT**

**Sinh viên: MAI NGỌC HOÀNG  
MSSV: 22139023**

TP. Hồ Chí Minh – 06/2026

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH  
KHOA ĐIỆN ĐIỆN TỬ  
BỘ MÔN ĐIỆN TỬ – THÔNG TIN



**ĐỒ ÁN TỐT NGHIỆP**

**NGHIÊN CỨU CÁC MÔ HÌNH HỌC SÂU CHO  
PHÂN ĐOẠN ẢNH PHỔ TRONG MÔI TRƯỜNG  
ĐỒNG TỒN TẠI RADAR VÀ TRUYỀN THÔNG**

**NGÀNH HỆ THỐNG NHÚNG VÀ IOT**

**Sinh viên: MAI NGỌC HOÀNG  
MSSV: 22139023**

**GVHD: TS. Huỳnh Thế Thiện**

TP. Hồ Chí Minh – 06/2026

# BẢN NHẬN XÉT KHÓA LUẬN TỐT NGHIỆP

(Dành cho giảng viên hướng dẫn)

**Đề tài:** NGHIÊN CỨU CÁC MÔ HÌNH HỌC SÂU CHO PHÂN ĐOẠN ẢNH PHỔ TRONG MÔI TRƯỜNG ĐỒNG TỒN TẠI RADAR VÀ TRUYỀN THÔNG

**Sinh viên:** Mai Ngọc Hoàng

**MSSV:** 22139023

**Hướng dẫn:** TS. Huỳnh Thế Thiện

**Nhận xét bao gồm các nội dung sau đây:**

- Tính hợp lý trong cách đặt vấn đề và giải quyết vấn đề; ý nghĩa khoa học và thực tiễn:** Đề tài có tính đột phá, tiếp cận trực diện bài toán phân đoạn ngữ nghĩa ảnh phổ (semantic signal segmentation) để giải quyết thách thức nhiễu vô tuyến trong môi trường Integrated Sensing and Communications (ISAC) hướng tới 6G. Giải pháp có tính mới học thuật tốt và giá trị khoa học cao.
- Phương pháp thực hiện/ phân tích/ thiết kế:** Sinh viên có năng lực nghiên cứu tốt, tự thiết kế thành công ba kiến trúc mạng nơ-ron tiên tiến (HKANet, Denoise2Seg, ReSegNet). Việc áp dụng cơ chế lấy mẫu chủ động (DAS) và hàm mất mát nhận thức cấu trúc (SUR) cho thấy nền tảng toán học và tư duy kiến trúc mô hình cực kỳ vững vàng.
- Kết quả thực hiện/ phân tích và đánh giá kết quả/ kiểm định thiết kế:** Quá trình thực nghiệm được tổ chức chặt chẽ thông qua ablation study toàn diện. Các mô hình đề xuất đã vượt qua các kiến trúc tiên tiến hiện hành, đạt mức mIoU 66.45% dưới điều kiện nhiễu khắc nghiệt. Sự đánh đổi giữa hiệu năng và chi phí phần cứng được phân tích vô cùng thuyết phục.
- Kết luận và đề xuất:** Kết luận súc tích, bám sát các phát hiện cốt lõi. Những đề xuất mở rộng đánh giá dữ liệu thực địa ngoài trời và nâng cấp hệ sinh thái giao thức vô tuyến thể hiện tầm nhìn nghiên cứu dài hạn, logic và hoàn toàn khả thi.
- Hình thức trình bày và bố cục báo cáo:** Cuốn khóa luận được trình bày chuyên nghiệp, chuẩn mực văn phong khoa học quốc tế. Sinh viên đã hiệu đính cẩn thận các lỗi chế bản nhỏ về định dạng công thức toán học và chính tả để mang lại một văn bản hoàn chỉnh nhất.
- Kỹ năng chuyên nghiệp và tính sáng tạo:** Khả năng làm việc độc lập, tư duy phản biện và kỹ năng lập trình mạng học sâu của sinh viên ở mức hiếm có đối với bậc đại học. Sinh viên hoàn toàn làm chủ được các khái niệm phức tạp trong xử lý tín hiệu vô tuyến và trí tuệ nhân tạo.
- Tài liệu trích dẫn:** Hệ thống tài liệu tham khảo phong phú, chất lượng cao, trích dẫn chuẩn xác theo quy định của IEEE. Phản ánh quá trình tổng quan tài liệu nghiêm túc và có chọn lọc.
- Đánh giá về sự trùng lặp của đề tài:** Đề tài hoàn toàn độc lập và mang tính tiên phong. Kết quả nghiên cứu đã được bảo chứng thông qua 3 bài báo khoa học xuất bản trên các tạp chí quốc tế uy tín hàng đầu (SCI/SCIE Q1 của IEEE) với tư cách tác giả chính/đồng tác giả.
- Những nhược điểm và thiếu sót, những điểm cần được bổ sung và chỉnh sửa:** Báo cáo gần như có rất ít khuyết điểm về mặt chuyên môn. Các lỗi định dạng hiển thị nhỏ lẻ đã được sinh viên tiếp thu và khắc phục triệt để trước khi nộp bản cuối.
- Nhận xét tinh thần, thái độ học tập, nghiên cứu của sinh viên:** Sinh viên có niềm đam mê nghiên cứu khoa học, thái độ làm việc nghiêm túc, kỷ luật và cầu thị. Là một cá nhân xuất sắc với tiềm năng lớn để tiến xa ở các bậc học sau đại học.

**Đề nghị của giảng viên hướng dẫn:**

Báo cáo hoàn toàn đạt yêu cầu của một khóa luận tốt nghiệp kỹ sư, và được phép bảo vệ khóa luận tốt nghiệp trước Hội đồng.

Tp. HCM, ngày 23 tháng 06 năm 2026

**Người nhận xét**

(Ký và ghi rõ họ tên)



**TS. Huỳnh Thế Thiện**

# Lời Cam Đoan

Tôi tên là Mai Ngọc Hoàng, mã số sinh viên 22139023, sinh viên thực hiện khóa luận tốt nghiệp ngành Hệ thống nhúng và IoT tại Khoa Điện – Điện tử, Trường Đại học Công nghệ Kỹ thuật TP.HCM. Tôi xin khẳng định đây là công trình nghiên cứu do chính tôi thực hiện dưới sự hướng dẫn của TS. Huỳnh Thế Thiện. Nội dung và kết quả mô phỏng trong luận văn phản ánh quá trình làm việc độc lập, năng lực nghiên cứu và kết quả thực nghiệm thực tế của cá nhân tôi. Tôi xin cam đoan các kiến trúc mô hình và dữ liệu sử dụng là trung thực, không có hành vi sao chép hay vay mượn trái phép từ các công trình nghiên cứu khác. Các tài liệu, bài báo khoa học và chuẩn kỹ thuật được tham khảo trong luận văn đều đã được trích dẫn rõ ràng, tuân thủ đúng quy định về đạo đức học thuật của Nhà trường. Tôi xin chịu hoàn toàn trách nhiệm trước Hội đồng về tính nguyên bản của công trình này và chấp nhận mọi hình thức kỷ luật nếu có bất kỳ vi phạm nào bị phát hiện.

Người thực hiện tiểu luận  
(Ký và ghi rõ họ tên)

Mai Ngọc Hoàng

# Lời Cảm Tạ

Để hoàn thành khóa luận tốt nghiệp này, tôi đã nhận được sự hỗ trợ và động viên vô cùng quý giá. Trước hết, tôi xin gửi lời cảm ơn sâu sắc đến quý Thầy Cô Khoa Điện – Điện tử, Trường Đại học Công nghệ Kỹ thuật TP.HCM, những người đã truyền đạt nền tảng chuyên môn vững chắc cho tôi trong suốt thời gian học tập tại trường. Đặc biệt, tôi xin dành sự tri ân chân thành nhất đến người thầy hướng dẫn trực tiếp của mình là TS. Huỳnh Thế Thiện; sự chỉ dẫn sát sao, những định hướng chuyên môn sắc bén cùng sự kiên nhẫn khích lệ của Thầy đóng vai trò then chốt, giúp tôi vượt qua mọi khó khăn để hoàn thành đề tài này. Tôi cũng xin cảm ơn bạn bè đã luôn đồng hành, cùng trao đổi và hỗ trợ tôi giải quyết các vấn đề kỹ thuật phát sinh trong suốt quá trình nghiên cứu. Dù đã nỗ lực hết mình, luận văn chắc chắn vẫn không tránh khỏi những thiếu sót, vì vậy tôi rất mong nhận được những góp ý, phản biện từ quý Thầy Cô để công trình được hoàn thiện hơn cũng như giúp tôi khắc phục các hạn chế để phát triển tốt hơn trong tương lai. Xin chân thành cảm ơn!

# Tóm Tắt

Luận văn này trình bày các phương pháp học sâu tiên tiến nhằm giải quyết bài toán phân đoạn ngữ nghĩa cho tín hiệu fifth generation new radio (5G NR), long-term evolution (LTE) và Radar trong môi trường phổ vô tuyến đồng tồn tại. Trong thực tế, các hệ thống vô tuyến thế hệ mới thường xuyên đối mặt với tình trạng nhiễu môi trường phức tạp, hiệu ứng dịch tần Doppler và hiện tượng chồng lấn tín hiệu, làm giảm đáng kể độ chính xác của các kỹ thuật định vị phổ truyền thống. Để khắc phục, nghiên cứu chuyển đổi tín hiệu thu thập được sang dạng ảnh phổ thời gian - tần số thông qua phép biến đổi Fourier thời gian ngắn (short-time Fourier transform - STFT), tạo ra không gian dữ liệu trực quan giúp các mạng nơ-ron khai thác hiệu quả các dải năng lượng.

Trọng tâm của công trình là việc thiết kế và đánh giá bộ ba kiến trúc phân đoạn chuyên biệt, được tối ưu hóa cho từng điều kiện kênh truyền. Cụ thể, Hierarchical Kernel Attention Network (HKANet) được phát triển để nâng cao năng lực trích xuất các đặc trưng hình thái tín hiệu đa hướng; Denoising-to-Segmentation (Denoise2Seg) tập trung gia tăng khả năng chống chịu nhiễu thông qua cơ chế học đa nhiệm tích hợp nhánh phụ trợ khử nhiễu; và Reconstructive Consistency for High-Fidelity Spectrogram Segmentation (ReSegNet) tiếp cận bài toán theo hướng tái tạo mặt nạ phân đoạn với độ trung thực cao dựa trên mạng tạo sinh. Bên cạnh đó, nghiên cứu đề xuất chiến lược huấn luyện lấy mẫu chủ động và hàm mất mát nhận thức cấu trúc để giúp hệ thống thích ứng tốt hơn với các biến động phổ khắc nghiệt.

Kết quả thực nghiệm toàn diện khẳng định sự vượt trội của các giải pháp đề xuất so với các mô hình hiện hành. Tiêu biểu, ReSegNet đạt mức trung bình chỉ số giao nhau trên hợp (mean intersection over union - mIoU) là 66.45% với cấu trúc tinh gọn chỉ 1.83 triệu tham số. Các kiến trúc còn lại cũng duy trì độ chính xác trung bình theo từng lớp (mean accuracy - mAcc) rất ổn định, ngay cả khi tỷ số tín hiệu trên nhiễu hạ xuống mức cực đoan  $-10$  dB. Thành quả của nghiên cứu không chỉ mang giá trị học thuật mà còn cung cấp một giải pháp công nghệ thiết thực, sẵn sàng triển khai trên các hệ thống vô tuyến nhận thức có tài nguyên phần cứng hạn chế.

# Mục Lục

|          |                                                                      |          |
|----------|----------------------------------------------------------------------|----------|
| <b>1</b> | <b>TỔNG QUAN</b>                                                     | <b>1</b> |
| 1.1      | Giới thiệu . . . . .                                                 | 1        |
| 1.2      | Mục tiêu . . . . .                                                   | 3        |
| 1.2.1    | Mục tiêu tổng quát . . . . .                                         | 3        |
| 1.2.2    | Mục tiêu cụ thể . . . . .                                            | 4        |
| 1.3      | Phương pháp nghiên cứu . . . . .                                     | 4        |
| 1.4      | Giới hạn đề tài . . . . .                                            | 5        |
| 1.5      | Bố cục nội dung . . . . .                                            | 6        |
| <b>2</b> | <b>CƠ SỞ LÝ THUYẾT</b>                                               | <b>7</b> |
| 2.1      | Mô hình tín hiệu vô tuyến và đặc trưng tín hiệu nghiên cứu . . . . . | 7        |
| 2.1.1    | Mô hình tín hiệu vô tuyến . . . . .                                  | 7        |
| 2.1.2    | Đặc trưng tín hiệu nghiên cứu . . . . .                              | 9        |
| 2.2      | Phân tích và so sánh các miền biểu diễn tín hiệu . . . . .           | 11       |
| 2.2.1    | Miền thời gian . . . . .                                             | 11       |
| 2.2.2    | Miền tần số . . . . .                                                | 12       |
| 2.2.3    | Miền thời gian–tần số . . . . .                                      | 13       |
| 2.2.4    | So sánh các miền biểu diễn tín hiệu . . . . .                        | 14       |
| 2.3      | Cơ sở học sâu cho bài toán phân đoạn ảnh . . . . .                   | 16       |

|          |                                                                      |           |
|----------|----------------------------------------------------------------------|-----------|
| 2.3.1    | Mạng nơ-ron sâu và trích xuất đặc trưng ảnh . . . . .                | 16        |
| 2.3.2    | Phân đoạn ngữ nghĩa và kiến trúc phân đoạn ảnh . . . . .             | 19        |
| <b>3</b> | <b>PHƯƠNG PHÁP ĐỀ XUẤT</b>                                           | <b>26</b> |
| 3.1      | Yêu cầu thiết kế phương pháp . . . . .                               | 26        |
| 3.1.1    | Chất lượng phân đoạn . . . . .                                       | 26        |
| 3.1.2    | Độ bền vững và khả năng tổng quát . . . . .                          | 27        |
| 3.1.3    | Độ phức tạp và hiệu quả tính toán . . . . .                          | 28        |
| 3.2      | Tổng quan phương pháp đề xuất . . . . .                              | 29        |
| 3.3      | Phương pháp phân đoạn ảnh phổ đề xuất . . . . .                      | 30        |
| 3.3.1    | Thiết kế dữ liệu đầu vào và nhãn phân đoạn . . . . .                 | 30        |
| 3.3.2    | Thiết kế các mô hình phân đoạn đề xuất . . . . .                     | 32        |
| 3.4      | Cài đặt huấn luyện và phương pháp đánh giá . . . . .                 | 47        |
| 3.4.1    | Cấu hình huấn luyện . . . . .                                        | 47        |
| 3.4.2    | Phương pháp đánh giá . . . . .                                       | 47        |
| <b>4</b> | <b>KẾT QUẢ THỰC NGHIỆM</b>                                           | <b>49</b> |
| 4.1      | Đánh giá hiệu năng theo điều kiện phổ . . . . .                      | 49        |
| 4.1.1    | Hiệu năng theo tỷ số tín hiệu trên nhiễu (SNR) . . . . .             | 49        |
| 4.1.2    | Hiệu năng theo Doppler . . . . .                                     | 51        |
| 4.1.3    | Phân tích độ chính xác phân lớp thông qua Ma trận nhầm lẫn . . . . . | 52        |
| 4.2      | Phân tích vai trò các thành phần thiết kế . . . . .                  | 53        |
| 4.2.1    | Nghiên cứu cắt bỏ các thành phần của HKANet . . . . .                | 53        |
| 4.2.2    | Nghiên cứu cắt bỏ các thành phần của Denoise2Seg . . . . .           | 55        |
| 4.2.3    | Nghiên cứu cắt bỏ các thành phần của ReSegNet . . . . .              | 57        |
| 4.3      | So sánh với các mô hình tiêu biểu . . . . .                          | 59        |



|                                                            |           |
|------------------------------------------------------------|-----------|
| <i>MỤC LỤC</i>                                             | vi        |
| 4.4 Phân tích tính khả thi và ứng dụng thực tiễn . . . . . | 61        |
| <b>5 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN</b>                      | <b>64</b> |
| 5.1 Kết luận . . . . .                                     | 64        |
| 5.2 Hướng phát triển . . . . .                             | 65        |

# Danh sách hình

|                                                                                                                                                                                                             |    |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 2.1.1 Sơ đồ mô hình tín hiệu thu trong môi trường đồng tồn tại radar–truyền thông. . .                                                                                                                      | 8  |
| 2.2.2 Sơ đồ khái niệm minh họa ba miền biểu diễn tín hiệu vô tuyến. . . . .                                                                                                                                 | 12 |
| 2.3.3 Minh họa quá trình học đặc trưng qua nhiều lớp trong mạng nơ-ron sâu. . . . .                                                                                                                         | 17 |
| 2.3.4 Minh họa quá trình trích xuất đặc trưng bằng mạng nơ-ron tích chập. . . . .                                                                                                                           | 18 |
| 2.3.5 Minh họa sự khác biệt giữa phân loại ảnh, phát hiện đối tượng và phân đoạn ngữ nghĩa. . . . .                                                                                                         | 19 |
| 2.3.6 Minh họa kiến trúc Encoder–Decoder tích chập cho bài toán phân đoạn ảnh. . . .                                                                                                                        | 20 |
| 2.3.7 Kiến trúc tổng quát của SegFormer với bộ mã hóa Transformer phân cấp và decoder sử dụng MLP [1]. . . . .                                                                                              | 22 |
| 2.3.8 Minh họa khối ESP và khối EESP được sử dụng trong ESPNetv2 [2]. . . . .                                                                                                                               | 23 |
| 2.3.9 Kiến trúc tổng quát của DeepLabV3+ với khối ASPP và decoder khôi phục chi tiết không gian [3]. . . . .                                                                                                | 24 |
| 2.3.10 Kiến trúc UNet++ với các skip connection lồng nhau giữa encoder và decoder [4].                                                                                                                      | 24 |
| 2.3.11 Kiến trúc tổng quát của SRNet với encoder, khối SE, module trích xuất đặc trưng đa tỉ lệ và decoder. . . . .                                                                                         | 25 |
| 3.2.1 Sơ đồ tổng quan phương pháp đề xuất cho bài toán phân đoạn ảnh phổ. . . . .                                                                                                                           | 29 |
| 3.3.2 Ví dụ ảnh phổ đầu vào theo mức SNR và bản đồ nhãn phân đoạn tương ứng: (a)–(e) ảnh phổ tại các mức SNR lần lượt là $-10$ , $0$ , $10$ , $20$ và $30$ dB; (f) bản đồ nhãn phân đoạn tương ứng. . . . . | 31 |

|                                                                                                                                                                                                                                                                                                                                         |    |
|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 3.3.3 Kiến trúc tổng thể của HKANet với các khối HKA tích hợp MCA trong đường mã hóa và khối TDPP trong đường giải mã. . . . .                                                                                                                                                                                                          | 33 |
| 3.3.4 Cấu trúc khối TDPP trong HKANet với các nhánh pooling theo không gian, thời gian và tần số. . . . .                                                                                                                                                                                                                               | 36 |
| 3.3.5 Kiến trúc tổng thể của Denoise2Seg với bộ mã hóa dùng chung, nhánh khử nhiễu phụ trợ và nhánh phân đoạn chính [5]. . . . .                                                                                                                                                                                                        | 37 |
| 3.3.6 Cấu trúc khối CSF dùng để hợp nhất đặc trưng từ bộ mã hóa và nhánh khử nhiễu thông qua mặt nạ chú ý dựa trên độ nổi bật [5]. . . . .                                                                                                                                                                                              | 39 |
| 3.3.7 Cấu trúc khối ASTF với hai nhánh không gian và thời gian, kết hợp cơ chế chú ý theo tần số để tinh chỉnh đặc trưng phân đoạn [5]. . . . .                                                                                                                                                                                         | 40 |
| 3.3.8 Kiến trúc tổng thể của ReSegNet với VAE Encoder, không gian tiềm ẩn, các khối CIB và cơ chế điều khiển toàn cục $\theta_{\text{control}}$ . . . . .                                                                                                                                                                               | 42 |
| 3.3.9 Minh họa cơ chế DAS trong ReSegNet. Các bước thời gian được chia thành nhiều bin, sau đó Focus Policy chọn bin bắt đầu và Intensity Policy chọn kích thước bước nhảy thích nghi dựa trên mất mát lịch sử. . . . .                                                                                                                 | 43 |
| 4.1.1 Hiệu năng phân đoạn mIoU và mAcc theo SNR của ba mô hình đề xuất. . . . .                                                                                                                                                                                                                                                         | 50 |
| 4.1.2 Hiệu năng phân đoạn mIoU và mAcc theo dịch chuyển Doppler của ba mô hình đề xuất. . . . .                                                                                                                                                                                                                                         | 51 |
| 4.1.3 Ma trận nhầm lẫn chuẩn hóa trung bình qua toàn dải SNR của ba mô hình đề xuất. . . . .                                                                                                                                                                                                                                            | 52 |
| 4.2.4 Nghiên cứu cắt bỏ chi tiết của HKANet: (a) tối ưu hóa cân bằng giữa hiệu năng và chi phí của các kernel HKA, với chú giải theo định dạng Mô hình – Tham số (M) – Tốc độ (ms) – mIoU (%); và đóng góp của từng mô-đun đối với (b) độ bền vững trước hiệu ứng Doppler, và (c) khả năng chống chịu trong điều kiện SNR thấp. . . . . | 56 |
| 4.2.5 Phân tích cắt bỏ và siêu tham số chi tiết của ReSegNet: (a) ảnh hưởng của các tham số DAS $k_{\text{DAS}}$ và $B$ ; (b) đánh giá cắt bỏ kiến trúc dưới các mức SNR khác nhau; và (c, d) ảnh hưởng của các tham số SUR, bao gồm kích thước patch $s$ và trọng số thành phần $\lambda$ . . . . .                                    | 58 |
| 4.3.6 So sánh hiệu năng phân đoạn của HKANet, Denoise2Seg và ReSegNet với các mô hình SOTA theo tỷ số tín hiệu trên nhiễu (SNR). . . . .                                                                                                                                                                                                | 60 |

|                                                                                                                                                |    |
|------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 4.4.7 Biểu đồ đánh đổi giữa độ phức tạp tính toán (GFLOPs), chất lượng phân đoạn (mIoU) và kích thước tham số mạng (độ lớn bong bóng). . . . . | 62 |
|------------------------------------------------------------------------------------------------------------------------------------------------|----|

# Danh sách bảng

|                                                                                         |    |
|-----------------------------------------------------------------------------------------|----|
| 2.1.1 Tóm tắt các đặc trưng liên quan đến phân tích tín hiệu nghiên cứu . . . . .       | 10 |
| 2.2.2 So sánh các miền biểu diễn tín hiệu . . . . .                                     | 15 |
| 4.2.1 Nghiên cứu cắt bỏ các thành phần kiến trúc của HKANet . . . . .                   | 54 |
| 4.2.2 Đánh giá ảnh hưởng của các thành phần kiến trúc trong Denoise2Seg . . . . .       | 55 |
| 4.2.3 Đánh giá ảnh hưởng của các thành phần kiến trúc và hàm mất mát trong ReSegNet     | 57 |
| 4.3.4 So sánh các phương pháp phân đoạn ảnh phổ tín hiệu . . . . .                      | 59 |
| 4.4.5 Tổng hợp các chỉ số hiệu năng và chi phí phần cứng cốt lõi của ba mô hình đề xuất | 62 |

# Danh sách các từ viết tắt

| Từ viết tắt | Định nghĩa                                 |
|-------------|--------------------------------------------|
| 5G NR       | Fifth Generation New Radio                 |
| 3GPP        | 3rd Generation Partnership Project         |
| ASPP        | Atrous Spatial Pyramid Pooling             |
| ASTF        | Attentive Spatio-Temporal Fusion           |
| CE          | Cross-Entropy                              |
| CIB         | Conditional Interaction Bridge             |
| CNN         | Convolutional Neural Network               |
| CSF         | Consensus Saliency Fusion                  |
| DAS         | Dual Adaptive Sampling                     |
| Denoise2Seg | Denoising-to-Segmentation                  |
| DNN         | Deep Neural Network                        |
| DSSC        | Decoupled Strategic-Spatial Conditioning   |
| FiLM        | Feature-wise Linear Modulation             |
| FMCW        | Frequency-Modulated Continuous-Wave        |
| GAP         | Global Average Pooling                     |
| GCS         | Global Context Squeeze                     |
| GTS         | Gaussian-Transformed Skewness              |
| HAB         | Horizontal Anisotropic Branch              |
| HFF         | Hierarchical Feature Funnel                |
| HKA         | Hierarchical Kernel Attention              |
| HKANet      | Hierarchical Kernel Attention Network      |
| IB          | Isotropic Branch                           |
| IoT         | Internet of Things                         |
| LTE         | Long-Term Evolution                        |
| MCA         | Moment Channel Attention                   |
| MLP         | Multilayer Perceptron                      |
| MSTS        | Multi-Stage Training Strategy              |
| OFDM        | Orthogonal Frequency Division Multiplexing |

| Từ viết tắt | Định nghĩa                                                            |
|-------------|-----------------------------------------------------------------------|
| ReSegNet    | Reconstructive Consistency for High-Fidelity Spectrogram Segmentation |
| SE          | Squeeze-and-Excitation                                                |
| SNR         | Signal-to-Noise Ratio                                                 |
| SOTA        | State-of-the-Art                                                      |
| STD         | Standard Deviation                                                    |
| STFT        | Short-Time Fourier Transform                                          |
| SUR         | Structure and Uniformity Reconstruction                               |
| TDPP        | Tri-Dimensional Pyramid Pooling                                       |
| VAB         | Vertical Anisotropic Branch                                           |
| VAE         | Variational Autoencoder                                               |
| YOLO        | You Only Look Once                                                    |

# Chương 1

## TỔNG QUAN

### 1.1 Giới thiệu

Sự phát triển nhanh của các hệ thống thông tin vô tuyến thế hệ mới đang làm gia tăng mạnh mẽ nhu cầu sử dụng phổ tần [6]. Trong các mạng 5G và hướng tới 6G, nhiều ứng dụng như Internet vạn vật, giao thông thông minh, xe tự hành, truyền thông xe—mọi vật và các hệ thống cảm biến thông minh đều yêu cầu khả năng kết nối tin cậy, độ trễ thấp và truyền dữ liệu ổn định [7]. Đặc biệt trong môi trường giao thông thông minh, phương tiện hiện đại không chỉ đóng vai trò là thiết bị di chuyển mà còn trở thành các nút thông minh có khả năng truyền thông, cảm biến và xử lý thông tin [8]. Khi số lượng thiết bị và dịch vụ vô tuyến cùng hoạt động tăng lên, tài nguyên phổ tần phải phục vụ nhiều mục đích hơn trong khi bản thân phổ vô tuyến là hữu hạn [9]. Điều này khiến môi trường phổ ngày càng đông đúc, phức tạp và đặt ra yêu cầu phải sử dụng phổ tần một cách linh hoạt, hiệu quả hơn [10].

Trong các hệ thống vô tuyến truyền thống, tài nguyên phổ tần thường được quản lý theo mô hình cấp phát cố định [11]. Theo mô hình này, một dải tần nhất định được gán cho một hệ thống hoặc một dịch vụ cụ thể trong thời gian dài, chẳng hạn như thông tin di động, phát thanh, vệ tinh hoặc radar [12]. Cách quản lý này có ưu điểm là rõ ràng, dễ kiểm soát và giúp hạn chế nhiễu giữa các hệ thống. Tuy nhiên, trong thực tế, không phải dải tần nào sau khi được cấp phát cũng được sử dụng liên tục tại mọi thời điểm và mọi vị trí. Do đó, có thể xuất hiện tình huống một số vùng phổ đang tạm thời chưa được khai thác, trong khi các hệ thống mới như 5G, 6G, Internet of Things (IoT) hoặc truyền thông xe—mọi vật lại cần thêm tài nguyên để đáp ứng nhu cầu kết nối ngày càng tăng [13]. Từ hạn chế đó, chia sẻ phổ động trở thành một hướng tiếp cận quan trọng nhằm khai thác tài nguyên phổ linh hoạt hơn [14]. Thay vì cố định một dải tần cho một hệ thống duy nhất trong mọi thời điểm, chia sẻ phổ động cho phép các hệ thống khác sử dụng tạm thời những vùng phổ đang chưa được khai thác, miễn là không gây nhiễu có hại cho hệ thống



được ưu tiên [15]. Trong bối cảnh đồng tồn tại radar–truyền thông, radar có thể đóng vai trò là hệ thống cần được bảo vệ do liên quan đến chức năng cảm biến và an toàn [16], trong khi các hệ thống truyền thông như 5G NR và LTE có thể cần truy cập phổ trong cùng dải tần hoặc các dải tần lân cận [17]. Vì vậy, cảm nhận phổ trở thành kỹ thuật đóng vai trò trung tâm, giúp hệ thống nhận biết vùng phổ nào đang bị chiếm dụng, loại tín hiệu nào đang xuất hiện và tín hiệu đó nằm ở vị trí nào trong miền thời gian–tần số [18]. Trong các môi trường phổ hiện đại, cảm nhận phổ không chỉ dừng lại ở quyết định đơn giản rằng phổ đang rảnh hay bị chiếm dụng, mà còn cần nhận dạng loại tín hiệu, xác định vị trí xuất hiện và khoanh vùng chiếm dụng cụ thể của từng tín hiệu [19].

Các phương pháp xử lý tín hiệu truyền thống như Energy Detection [20], Cyclostationary Feature Detection [12] và Matched Filtering [21] đã được sử dụng rộng rãi trong các bài toán cảm nhận phổ nhờ nguyên lý đơn giản và nền tảng toán học rõ ràng. Tuy nhiên, các phương pháp này thường phụ thuộc vào giả định về tín hiệu hoặc thông tin biết trước của hệ thống, đồng thời dễ suy giảm hiệu năng trong điều kiện tỷ số tín hiệu trên nhiễu thấp [22]. Sau đó, các phương pháp học máy cổ điển như Support Vector Machine [23], k-Nearest Neighbors và K-Means được nghiên cứu nhằm cải thiện khả năng thích nghi của hệ thống [24]. Mặc dù linh hoạt hơn so với các phương pháp truyền thống, các mô hình này vẫn phụ thuộc nhiều vào đặc trưng thủ công, khiến hiệu quả bị hạn chế khi điều kiện kênh, nhiễu và dạng tín hiệu thay đổi [25].

Sự phát triển của học sâu đã mở ra hướng tiếp cận hiệu quả hơn cho cảm nhận phổ nhờ khả năng tự động học đặc trưng trực tiếp từ dữ liệu [26]. Một số nghiên cứu ban đầu xem cảm nhận phổ như bài toán phân loại tín hiệu, trong đó các mô hình dựa trên convolutional neural network (CNN) [27] hoặc các kiến trúc lai CNN–Transformer [3] được sử dụng để nhận dạng loại tín hiệu. Cách tiếp cận này giúp cải thiện khả năng học đặc trưng so với các phương pháp thủ công, nhưng đầu ra phân loại chỉ cho biết nhãn tổng thể của tín hiệu mà không mô tả được vị trí và vùng chiếm dụng của tín hiệu trên phổ. Để bổ sung thông tin không gian, các mô hình phát hiện đối tượng như Faster R-CNN [28], You only look once (YOLO) [29] và các biến thể của YOLO đã được áp dụng để định vị tín hiệu trên ảnh phổ thông qua hộp bao [30]. Tuy nhiên, tín hiệu vô tuyến trên ảnh phổ thường có hình dạng không đều, biên không rõ, có thể bị đứt đoạn, suy yếu hoặc chồng lấn với các tín hiệu khác. Vì vậy, hộp bao chữ nhật chỉ cung cấp thông tin xấp xỉ và không thể biểu diễn chính xác ranh giới thực sự của vùng tín hiệu [31].

Từ các hạn chế đó, phân đoạn ngữ nghĩa trên ảnh phổ trở thành một hướng tiếp cận phù hợp hơn cho cảm nhận phổ độ phân giải cao. Thay vì dự đoán một nhãn duy nhất cho toàn bộ ảnh hoặc một hộp bao xấp xỉ, mô hình phân đoạn gán nhãn cho từng điểm ảnh trên ảnh phổ [32]. Nhờ vậy, hệ thống có thể xác định vùng nào thuộc về nền hoặc nhiễu, vùng nào thuộc tín hiệu 5G NR, LTE hoặc radar. Các kiến trúc phân đoạn tổng quát như U-Net [33], DeepLabV3+ [3], SegFormer [1] và UNet++ [4] đã được sử dụng hoặc điều chỉnh trong nhiều bài toán phân đoạn ảnh, trong khi một số mô hình chuyên biệt hơn cho ảnh phổ như SRNet [34] được đề xuất để khai

thác đặc trưng thời gian—tần số của tín hiệu. Các mô hình này cho thấy tiềm năng của phân đoạn ngữ nghĩa trong việc mô tả chi tiết vị trí, hình dạng, biên và mức độ chiếm dụng phổ của từng tín hiệu [35]. Tuy nhiên, trong các điều kiện phổ nhiễu mạnh, việc duy trì chất lượng phân đoạn ổn định vẫn là một thách thức [36]. Đồng thời, cần cân nhắc độ phức tạp tính toán để mô hình có khả năng ứng dụng trong các hệ thống yêu cầu xử lý nhanh [2]. Vì vậy, việc nghiên cứu các kiến trúc chuyên biệt hơn cho ảnh phổ là cần thiết nhằm cân bằng giữa chất lượng phân đoạn, độ bền vững và hiệu quả tính toán.

Xuất phát từ các vấn đề trên, luận văn này nghiên cứu bài toán phân đoạn ảnh phổ cho các tín hiệu 5G NR, LTE và radar trong môi trường đồng tồn tại và nhiễu. Tín hiệu vô tuyến được chuyển sang biểu diễn thời gian—tần số dưới dạng ảnh phổ, sau đó mô hình học sâu thực hiện phân đoạn để tạo bản đồ nhãn theo từng điểm ảnh. Trọng tâm của luận văn là thiết kế khối phân đoạn ảnh phổ chuyên biệt. Thay vì chỉ đề xuất một kiến trúc đơn lẻ, luận văn tiếp cận bài toán dưới ba triết lý thiết kế khác nhau, tương ứng với ba mô hình: HKANet [37], Denoise2Seg [5], và ReSegNet. Các mô hình này không tồn tại rời rạc mà bổ trợ nhau để giải quyết các thách thức cụ thể của kênh truyền vô tuyến:

- HKANet tập trung vào học đặc trưng hình thái của ảnh phổ nhằm nhận biết tốt hơn cấu trúc và biên tín hiệu.
- Denoise2Seg khai thác nhiệm vụ khử nhiễu như một cơ chế hỗ trợ để tăng khả năng học biểu diễn bền vững trong môi trường nhiễu.
- ReSegNet tiếp cận bài toán theo hướng tái tạo và nhất quán biểu diễn nhằm cải thiện khả năng giữ cấu trúc phân đoạn trong các điều kiện đầu vào bị suy giảm.

## 1.2 Mục tiêu

### 1.2.1 Mục tiêu tổng quát

Mục tiêu tổng quát của luận văn là nghiên cứu và đánh giá các mô hình học sâu cho bài toán phân đoạn ảnh phổ trong môi trường đồng tồn tại radar—truyền thông. Luận văn hướng đến việc xác định vùng chiếm dụng của các tín hiệu vô tuyến trên ảnh phổ, từ đó hỗ trợ quá trình cảm nhận phổ trong các hệ thống thông tin vô tuyến thế hệ mới.

Bên cạnh việc xem xét chất lượng phân đoạn, luận văn cũng quan tâm đến khả năng hoạt động của mô hình trong các điều kiện phổ phức tạp và mức độ phù hợp về mặt tính toán. Qua đó, đề tài nhằm làm rõ tiềm năng của hướng tiếp cận phân đoạn ngữ nghĩa trên ảnh phổ đối với bài toán nhận dạng và khoanh vùng các tín hiệu đồng tồn tại.

Trong luận văn này, các mô hình được nghiên cứu không được xem như những hệ thống độc lập, mà là các hướng thiết kế khác nhau cho cùng một bài toán phân đoạn ảnh phổ. Trên cơ sở đó, luận văn tập trung phân tích đặc điểm, ưu điểm, hạn chế và mức độ phù hợp của từng hướng mô hình trong phạm vi dữ liệu và điều kiện thực nghiệm đã xác định.

## 1.2.2 Mục tiêu cụ thể

*Thứ nhất, xác lập bài toán phân đoạn ảnh phổ trong môi trường đồng tồn tại tín hiệu.* Nội dung này nhằm làm rõ đối tượng nghiên cứu, dạng dữ liệu đầu vào và dạng kết quả đầu ra cần đạt được. Trong bài toán này, mỗi vùng trên ảnh phổ cần được xác định và gán nhãn theo loại tín hiệu tương ứng hoặc vùng nền. Việc xác lập bài toán là cơ sở để định hướng các nội dung thiết kế, huấn luyện và đánh giá mô hình ở các chương sau.

*Thứ hai, nghiên cứu các hướng mô hình học sâu phù hợp với đặc thù của ảnh phổ.* Các hướng mô hình được xem xét cần có khả năng khai thác cấu trúc tín hiệu trên ảnh phổ, hỗ trợ nhận dạng vùng tín hiệu và cải thiện khả năng phân đoạn trong điều kiện phổ phức tạp. Mục tiêu này nhằm làm rõ cách các hướng thiết kế khác nhau có thể được áp dụng cho cùng một bài toán phân đoạn ảnh phổ.

*Thứ ba, phân tích ưu điểm, hạn chế và mức độ phù hợp của từng hướng mô hình.* Trên cơ sở kết quả thực nghiệm, luận văn đưa ra nhận xét về đặc điểm hoạt động của từng phương án mô hình đối với bài toán phân đoạn ảnh phổ. Nội dung này giúp làm rõ hướng mô hình nào phù hợp hơn trong từng trường hợp, chẳng hạn khi ưu tiên chất lượng phân đoạn, độ ổn định trong điều kiện nhiễu hoặc hiệu quả tính toán.

## 1.3 Phương pháp nghiên cứu

Để đạt được các mục tiêu trên, luận văn được thực hiện theo quy trình nghiên cứu gồm các nội dung chính, tương ứng với các mục tiêu cụ thể đã đặt ra.

*Thứ nhất, nghiên cứu cơ sở lý thuyết và các công trình liên quan.* Nội dung này được thực hiện nhằm xác lập nền tảng cho bài toán phân đoạn ảnh phổ trong môi trường đồng tồn tại tín hiệu. Luận văn tập trung tìm hiểu vai trò của cảm nhận phổ, đặc điểm của dữ liệu ảnh phổ, nguyên lý phân đoạn theo từng điểm ảnh và các hướng tiếp cận học sâu đã được sử dụng trong các bài toán liên quan. Từ đó, luận văn xác định phạm vi nghiên cứu, đối tượng tín hiệu, dạng dữ liệu đầu vào, dạng nhãn đầu ra và các tiêu chí đánh giá phù hợp.

*Thứ hai, nghiên cứu và xây dựng các phương án mô hình học sâu cho bài toán phân đoạn*

*ảnh phổ*. Các phương án này được xem như những hướng thiết kế khác nhau cho cùng một khối phân đoạn ảnh phổ. Mỗi hướng thiết kế tập trung khai thác một số đặc điểm nhất định của ảnh phổ, chẳng hạn cấu trúc tín hiệu, vùng biên, ảnh hưởng của nhiễu hoặc khả năng duy trì biểu diễn ổn định. Việc nghiên cứu nhiều hướng mô hình giúp luận văn có cơ sở để so sánh và đánh giá mức độ phù hợp của từng phương án trong cùng một bài toán.

*Thứ ba, phân tích và thảo luận kết quả thực nghiệm.* Nội dung phân tích tập trung vào hiệu năng phân đoạn tổng thể, khả năng duy trì kết quả trong các điều kiện phổ khác nhau, kết quả đối với từng loại tín hiệu và sự đánh đổi giữa chất lượng phân đoạn với độ phức tạp tính toán. Từ các phân tích này, luận văn rút ra nhận xét về ưu điểm, hạn chế và mức độ phù hợp của từng phương án mô hình đối với bài toán phân đoạn ảnh phổ trong môi trường đồng tồn tại radar–truyền thông.

## 1.4 Giới hạn đề tài

Trong phạm vi luận văn này, đề tài tập trung nghiên cứu bài toán phân đoạn ảnh phổ cho môi trường đồng tồn tại radar–truyền thông. Do giới hạn về thời gian, dữ liệu và điều kiện triển khai thực nghiệm, phạm vi nghiên cứu được xác định như sau:

- *Đề tài tập trung vào một số loại tín hiệu vô tuyến cụ thể.* Các loại tín hiệu được xem xét trong luận văn gồm 5G NR, LTE và radar. Đây là các tín hiệu đại diện cho kịch bản đồng tồn tại giữa hệ thống truyền thông và hệ thống cảm biến trong môi trường phổ hiện đại. Luận văn chưa mở rộng sang các loại tín hiệu khác như Wi-Fi, Bluetooth, vệ tinh, tín hiệu gây nhiễu chủ động hoặc các dạng truyền thông đặc thù khác.
- *Dữ liệu sử dụng trong luận văn chủ yếu được xây dựng từ mô phỏng.* Cách tiếp cận này giúp tạo được dữ liệu có nhãn rõ ràng cho bài toán phân đoạn theo từng điểm ảnh, đồng thời cho phép kiểm soát các điều kiện phổ như mức nhiễu, điều kiện kênh và sự xuất hiện đồng thời của nhiều tín hiệu. Tuy nhiên, luận văn chưa đánh giá trực tiếp trên dữ liệu thu thực tế từ thiết bị vô tuyến hoặc môi trường truyền dẫn ngoài thực địa. Do đó, khả năng tổng quát của mô hình đối với dữ liệu thực tế vẫn cần được tiếp tục kiểm chứng trong các nghiên cứu sau.
- *Luận văn tập trung vào bài toán phân đoạn ảnh phổ, không mở rộng sang toàn bộ hệ thống cảm nhận phổ hoàn chỉnh.* Cụ thể, đề tài xem xét phương pháp xử lý có nhiệm vụ nhận dạng và khoanh vùng tín hiệu trên ảnh phổ. Các bước khác trong một hệ thống cảm nhận phổ thực tế, chẳng hạn như thu nhận tín hiệu bằng phần cứng, đồng bộ hệ thống, ra quyết định truy cập phổ, cấp phát tài nguyên hoặc điều khiển truyền thông sau cảm nhận phổ, không nằm trong phạm vi chính của luận văn.

## 1.5 Bố cục nội dung

Nội dung của luận văn được tổ chức thành năm chương chính.

- Chương 1: Tổng quan về đề tài.
- Chương 2: Cơ sở lý thuyết liên quan đến bài toán phân đoạn ảnh phổ.
- Chương 3: Phương pháp đề xuất cho bài toán phân đoạn ảnh phổ.
- Chương 4: Kết quả thực nghiệm.
- Chương 5: Kết luận của luận văn và đề xuất một số hướng phát triển trong tương lai.

## Chương 2

# CƠ SỞ LÝ THUYẾT


Chương này trình bày các cơ sở lý thuyết phục vụ cho bài toán phân đoạn ảnh phổ trong môi trường đồng tồn tại radar–truyền thông. Nội dung chương bao gồm mô hình tín hiệu vô tuyến, đặc trưng của các tín hiệu nghiên cứu, các miền biểu diễn tín hiệu và nền tảng học sâu cho phân đoạn ảnh. Trên cơ sở đó, chương làm rõ vai trò của biểu diễn thời gian–tần số và các kiến trúc phân đoạn ảnh trong việc xây dựng phương pháp và các mô hình đề xuất ở chương tiếp theo.

## 2.1 Mô hình tín hiệu vô tuyến và đặc trưng tín hiệu nghiên cứu

### 2.1.1 Mô hình tín hiệu vô tuyến

Trong các hệ thống vô tuyến, tín hiệu phát ra từ máy phát thường bị biến đổi trong quá trình truyền đến máy thu. Sự biến đổi này xuất phát từ ảnh hưởng của kênh truyền, nhiễu và các yếu tố môi trường như suy hao đường truyền, phản xạ đa đường hoặc dịch Doppler [38]. Do đó, tín hiệu thu được tại máy thu thường không còn giữ nguyên dạng lý tưởng của tín hiệu phát ban đầu.

Trong bối cảnh đồng tồn tại radar–truyền thông, tín hiệu thu tại máy thu có thể bao gồm nhiều thành phần tín hiệu khác nhau, chẳng hạn 5G NR, LTE và radar. Các thành phần tín hiệu này sau đó chịu ảnh hưởng của kênh truyền và nhiễu trước khi được hệ thống quan sát ở phía thu [39]. Sơ đồ minh họa quá trình hình thành tín hiệu thu được trình bày trong Hình 2.1.1. Một cách tổng quát, tín hiệu thu có thể được mô hình hóa như kết quả của tín hiệu phát sau khi truyền



Hình 2.1.1: Sơ đồ mô hình tín hiệu thu trong môi trường đồng tồn tại radar–truyền thông.

qua kênh vô tuyến và chịu ảnh hưởng của nhiễu:

$$r(t) = s(t) * h(t) + n(t), \quad (2.1.1)$$

trong đó  $r(t)$  là tín hiệu thu tại máy thu,  $s(t)$  là tín hiệu phát,  $h(t)$  là đáp ứng kênh truyền,  $n(t)$  là nhiễu cộng và ký hiệu  $*$  biểu diễn phép chập. Trong trường hợp có nhiều tín hiệu cùng tồn tại trong cùng khoảng quan sát, tín hiệu phát có thể được biểu diễn dưới dạng tổng của nhiều thành phần:

$$s(t) = \sum_{k=1}^K s_k(t), \quad (2.1.2)$$

trong đó  $s_k(t)$  là thành phần tín hiệu thứ  $k$  và  $K$  là số lượng thành phần tín hiệu xuất hiện.

Mô hình trên cho thấy tín hiệu mà hệ thống quan sát được là  $r(t)$ , không phải tín hiệu phát lý tưởng  $s(t)$ . Tín hiệu thu này vừa chịu ảnh hưởng của kênh truyền và nhiễu, vừa có thể chứa nhiều loại tín hiệu khác nhau. Trong bối cảnh đồng tồn tại radar–truyền thông, các thành phần  $s_k(t)$  có thể tương ứng với tín hiệu 5G NR, LTE hoặc radar. Các tín hiệu này có thể xuất hiện riêng lẻ, đồng thời hoặc chồng lấn một phần trong cùng khoảng thời gian và dải tần.

Kênh truyền  $h(t)$  mô tả ảnh hưởng của môi trường truyền dẫn lên tín hiệu. Trong thực tế, tín hiệu vô tuyến có thể truyền đến máy thu theo nhiều đường khác nhau do phản xạ, tán xạ hoặc nhiễu xạ từ các vật thể xung quanh. Hiện tượng đa đường có thể làm tín hiệu bị suy giảm, méo dạng hoặc thay đổi theo thời gian. Ngoài ra, trong các môi trường có chuyển động, hiệu ứng Doppler có thể làm thay đổi đặc tính tần số của tín hiệu thu [38].

Nhiễu  $n(t)$  là thành phần không mong muốn xuất hiện trong quá trình truyền và thu tín hiệu. Khi mức nhiễu lớn hoặc tỷ số tín hiệu trên nhiễu thấp, ranh giới giữa tín hiệu thật và nền nhiễu trở nên khó phân biệt hơn. Đây là một nguyên nhân làm tăng độ khó của bài toán cảm nhận phổ, đặc biệt khi cần nhận biết nhiều loại tín hiệu trong cùng một môi trường quan sát.

Như vậy, mô hình tín hiệu thu cho thấy bài toán nghiên cứu không làm việc với tín hiệu sạch và đơn lẻ, mà với tín hiệu thu có thể chứa nhiều thành phần và chịu tác động của kênh truyền,

nhiều hoặc Doppler. Đây là cơ sở để tiếp tục xem xét đặc trưng của các loại tín hiệu được nghiên cứu trước khi lựa chọn miền biểu diễn phù hợp ở phần tiếp theo.

### 2.1.2 Đặc trưng tín hiệu nghiên cứu

Trong phạm vi luận văn này, ba loại tín hiệu được xem xét gồm 5G NR, LTE và radar. Các tín hiệu này đại diện cho hai nhóm hệ thống vô tuyến chính: hệ thống truyền thông di động và hệ thống cảm biến. Phần này không nhằm trình bày toàn bộ đặc tả kỹ thuật của từng hệ thống, mà tập trung vào những đặc trưng có liên quan đến quá trình quan sát và phân tích phổ, gồm cấu trúc truyền dẫn hoặc dạng sóng, đặc điểm tần số, đặc điểm thời gian và khả năng cùng tồn tại trong môi trường phổ.

**5G NR:** Các đặc trưng vật lý của 5G NR được quy định trong các tài liệu chuẩn 3GPP, đặc biệt là các nội dung liên quan đến cấu trúc tài nguyên, khoảng cách sóng mang con, băng thông kênh và cấu trúc thời gian [40]. 5G NR sử dụng orthogonal frequency division multiplexing (OFDM), một kỹ thuật ghép kênh phân chia theo tần số trực giao, trong đó băng thông được chia thành nhiều sóng mang con hẹp và trực giao với nhau. Tài nguyên vô tuyến được tổ chức theo các đơn vị như resource element, resource block, slot và frame. Một resource block gồm 12 sóng mang con liên tiếp trong miền tần số.

Một đặc điểm quan trọng của 5G NR là khả năng hỗ trợ nhiều khoảng cách sóng mang con khác nhau, chẳng hạn 15 kHz, 30 kHz, 60 kHz, 120 kHz và 240 kHz. Điều này cho phép hệ thống thích ứng với nhiều dải tần, băng thông và yêu cầu dịch vụ khác nhau. Băng thông kênh của 5G NR cũng có thể được cấu hình linh hoạt, với giá trị có thể lên đến 100 MHz trong dải tần số FR1 (Frequency Range 1, từ 410 MHz đến 7.125 GHz) và 400 MHz trong dải tần số FR2 (Frequency Range 2, từ 24.25 GHz đến 71 GHz). Về mặt thời gian, frame có độ dài 10 ms, subframe có độ dài 1 ms, còn độ dài slot thay đổi theo khoảng cách sóng mang con.

Những đặc điểm trên cho thấy 5G NR có tính linh hoạt cao về tổ chức tài nguyên theo thời gian và tần số. Vì vậy, khi phân tích tín hiệu thu, cần chú ý rằng vùng chiếm dụng của 5G NR có thể thay đổi tùy theo cấu hình băng thông, khoảng cách sóng mang con và cách cấp phát tài nguyên.

**LTE:** Các đặc trưng vật lý của LTE được quy định trong các tài liệu chuẩn 3rd generation partnership project (3GPP), bao gồm cấu trúc OFDM, resource block, khoảng cách sóng mang con, băng thông kênh và cấu trúc thời gian [39]. Ở đường xuống, LTE sử dụng OFDM và tổ chức tài nguyên theo resource block. Một resource block gồm 12 sóng mang con liên tiếp trong miền tần số.

So với 5G NR, LTE có cấu hình ổn định hơn. Khoảng cách sóng mang con chủ yếu là 15



Bảng 2.1.1: Tóm tắt các đặc trưng liên quan đến phân tích tín hiệu nghiên cứu

| Tiêu chí                           | 5G NR                                                                    | LTE                                                                      | Radar                                                                            |
|------------------------------------|--------------------------------------------------------------------------|--------------------------------------------------------------------------|----------------------------------------------------------------------------------|
| Nhóm tín hiệu                      | Truyền thông di động thế hệ mới                                          | Truyền thông di động băng rộng                                           | Tín hiệu cảm biến                                                                |
| Cơ chế truyền dẫn                  | OFDM                                                                     | OFDM                                                                     | Radar xung, sóng liên tục, FMCW hoặc chirp tuyến tính                            |
| Cách tổ chức theo thời gian–tần số | Resource element, resource block, slot, frame                            | Resource block, subframe, radio frame                                    | Theo xung, chu kỳ lặp xung, băng thông quét hoặc tần số thay đổi theo thời gian  |
| Đặc trưng tần số                   | Khoảng cách sóng mang con và băng thông kênh linh hoạt                   | Khoảng cách sóng mang con chủ yếu 15 kHz; băng thông kênh được chuẩn hóa | Băng thông phụ thuộc dạng sóng; chirp/FMCW có thể thay đổi tần số theo thời gian |
| Đặc trưng thời gian                | Frame 10 ms, subframe 1 ms, slot thay đổi theo khoảng cách sóng mang con | Radio frame 10 ms, gồm 10 subframe, mỗi subframe 1 ms                    | Độ rộng xung, chu kỳ lặp xung, tần số lặp xung và duty cycle                     |
| Đặc điểm cần chú ý khi phân tích   | Vùng chiếm dụng có thể thay đổi theo cấu hình tài nguyên và băng thông   | Cấu trúc tương đối ổn định nhưng có thể gần với các tín hiệu OFDM khác   | Có thể xuất hiện ngắn, ngắt quãng hoặc thay đổi tần số theo thời gian            |

kHz, do đó một resource block có độ rộng tần số 180 kHz. Băng thông kênh của LTE được chuẩn hóa theo các mức 1.4 MHz, 3 MHz, 5 MHz, 10 MHz, 15 MHz và 20 MHz, tương ứng với số lượng resource block xác định. Về mặt thời gian, một radio frame có độ dài 10 ms, gồm 10 subframe, mỗi subframe có độ dài 1 ms.

Các đặc điểm này làm cho LTE có cấu trúc tài nguyên tương đối ổn định và dễ mô tả hơn so với 5G NR. Tuy nhiên, do LTE và 5G NR đều dựa trên OFDM, chúng có thể có một số đặc điểm phổ tương đồng. Vì vậy, trong môi trường đồng tồn tại, việc phân biệt LTE với các tín hiệu truyền thông khác vẫn cần dựa trên sự khác biệt về băng thông, cấu trúc tài nguyên và đặc điểm xuất hiện của tín hiệu.

**Radar:** Khác với 5G NR và LTE, radar là tín hiệu cảm biến, thường được sử dụng cho các nhiệm vụ như phát hiện, định vị hoặc theo dõi mục tiêu. Tín hiệu radar có thể được mô tả thông qua dạng sóng, độ rộng xung, chu kỳ lặp xung, tần số lặp xung, băng thông và Doppler [41]. Với radar xung, tín hiệu được phát trong các khoảng thời gian ngắn và lặp lại theo chu kỳ. Một dạng tín hiệu radar thường được sử dụng là tín hiệu frequency-modulated continuous-wave (FMCW). Đối với radar FMCW hoặc tín hiệu chirp tuyến tính, tần số tức thời của tín hiệu thay đổi liên tục theo thời gian. Do đó, băng thông quét và tốc độ thay đổi tần số là các thông số quan trọng để đặc trưng cho dạng sóng phát.

So với các tín hiệu truyền thông di động, radar có hình thái xuất hiện khác biệt hơn. Radar có thể xuất hiện trong thời gian ngắn, có dạng xung rời rạc hoặc có tần số thay đổi theo thời gian. Ngoài ra, hiệu ứng Doppler cũng có thể làm thay đổi đặc tính tần số của tín hiệu radar thu được. Những đặc điểm này khiến radar cần được xem xét riêng khi phân tích tín hiệu trong môi trường đồng tồn tại radar–truyền thông.

Từ các đặc trưng trên có thể thấy 5G NR, LTE và radar khác nhau về mục đích sử dụng, cấu trúc truyền dẫn hoặc dạng sóng, băng thông, đặc điểm thời gian và cách xuất hiện trong môi trường phổ. Bảng 2.1.1 tóm tắt các khác biệt có ảnh hưởng trực tiếp đến việc quan sát và phân tích tín hiệu thu.

Tóm lại, phần này xác định hai nội dung nền tảng: tín hiệu thu là đối tượng trực tiếp được phân tích, và các tín hiệu nghiên cứu có đặc trưng khác nhau về cấu trúc, thời gian và tần số. Những khác biệt này là cơ sở để phần tiếp theo trình bày các miền biểu diễn tín hiệu và đánh giá miền biểu diễn phù hợp cho bài toán nghiên cứu.

## 2.2 Phân tích và so sánh các miền biểu diễn tín hiệu

Tín hiệu vô tuyến có thể được biểu diễn và phân tích trong nhiều miền khác nhau tùy theo mục tiêu xử lý. Ba miền biểu diễn cơ bản thường được sử dụng gồm miền thời gian, miền tần số và miền thời gian–tần số. Mỗi miền cung cấp một góc nhìn khác nhau về tín hiệu: miền thời gian cho biết sự biến thiên của biên độ theo thời gian, miền tần số cho biết thành phần phổ và vùng tần số bị chiếm dụng, trong khi miền thời gian–tần số cho phép quan sát đồng thời sự thay đổi của tín hiệu theo cả thời gian và tần số. Sơ đồ khái niệm minh họa ba miền biểu diễn tín hiệu vô tuyến được trình bày trong Hình 2.2.2. Trong phạm vi luận văn này, các miền biểu diễn được trình bày ở mức khái niệm nhằm làm rõ đặc điểm, ưu điểm và hạn chế của từng miền. Việc lựa chọn miền biểu diễn phù hợp cho bài toán phân đoạn ảnh phổ sẽ được phân tích ở phần so sánh cuối mục này.


### 2.2.1 Miền thời gian

**Khái niệm:** Miền thời gian là cách biểu diễn trực tiếp tín hiệu theo biến thời gian. Đối với tín hiệu liên tục, tín hiệu thường được ký hiệu là  $x(t)$ , trong đó  $t$  biểu thị thời gian. Đối với tín hiệu rời rạc sau quá trình lấy mẫu, tín hiệu có thể được biểu diễn dưới dạng:

$$x[n] = x(nT_s), \quad (2.2.3)$$

trong đó  $T_s$  là chu kỳ lấy mẫu và  $n$  là chỉ số mẫu. Biểu diễn này cho phép quan sát sự thay đổi của biên độ tín hiệu tại từng thời điểm lấy mẫu [20].

**Kỹ thuật và đại lượng tiêu biểu:** Trong miền thời gian, tín hiệu thường được quan sát thông qua dạng sóng, biên độ tức thời, năng lượng tín hiệu, đường bao tín hiệu hoặc tự tương quan. Chẳng hạn, năng lượng của tín hiệu liên tục trên một khoảng quan sát có thể được biểu



Hình 2.2.2: Sơ đồ khái niệm minh họa ba miền biểu diễn tín hiệu vô tuyến.

diễn tổng quát dưới dạng:

$$E = \int_{-\infty}^{\infty} |x(t)|^2 dt. \quad (2.2.4)$$

Các đại lượng này giúp mô tả mức độ mạnh yếu, sự thay đổi biên độ và một số đặc điểm lặp lại của tín hiệu theo thời gian.

**Thông tin thu được:** Phân tích trong miền thời gian giúp xác định thời điểm tín hiệu xuất hiện, khoảng thời gian tồn tại và sự thay đổi biên độ của tín hiệu. Đối với tín hiệu radar dạng xung, miền thời gian có thể giúp quan sát vị trí xung, độ rộng xung và khoảng cách giữa các xung. Đối với tín hiệu truyền thông, miền thời gian có thể phản ánh sự biến thiên của tín hiệu thu dưới tác động của kênh truyền, nhiễu hoặc fading.

**Ý nghĩa đối với xử lý tín hiệu vô tuyến:** Miền thời gian cung cấp cái nhìn trực tiếp và trực quan về sự xuất hiện của tín hiệu. Tuy nhiên, nếu chỉ quan sát trong miền thời gian, việc xác định tín hiệu chiếm dụng vùng tần số nào hoặc năng lượng phân bố ra sao trên phổ sẽ không rõ ràng. Vì vậy, miền thời gian thường phù hợp cho việc quan sát sự biến thiên theo thời gian, nhưng chưa đủ để mô tả đầy đủ đặc điểm phổ của tín hiệu vô tuyến.

## 2.2.2 Miền tần số

**Khái niệm:** Miền tần số biểu diễn tín hiệu thông qua các thành phần tần số cấu thành nên tín hiệu. Thay vì quan sát sự thay đổi biên độ theo thời gian, miền tần số cho biết năng lượng hoặc công suất của tín hiệu phân bố trên các dải tần như thế nào. Với tín hiệu liên tục  $x(t)$ , biến

đổi Fourier có thể được sử dụng để chuyển tín hiệu từ miền thời gian sang miền tần số [42]:

$$\mathbf{X}(f) = \int_{-\infty}^{\infty} x(t)e^{-j2\pi ft} dt, \quad (2.2.5)$$

trong đó  $\mathbf{X}(f)$  là biểu diễn của tín hiệu trong miền tần số và  $f$  là tần số.

**Kỹ thuật và đại lượng tiêu biểu:** Trong miền tần số, các kỹ thuật và đại lượng thường gặp gồm biến đổi Fourier, biến đổi Fourier rời rạc, biến đổi Fourier nhanh, phổ biên độ, phổ công suất và mật độ phổ công suất. Phổ biên độ thường được biểu diễn thông qua  $|\mathbf{X}(f)|$ , cho biết mức biên độ của tín hiệu tại từng thành phần tần số. Trong khi đó, phổ công suất có thể được biểu diễn dưới dạng:

$$P(f) = |\mathbf{X}(f)|^2. \quad (2.2.6)$$

Đối với tín hiệu rời rạc, DFT hoặc FFT thường được sử dụng để tính toán biểu diễn tần số trên dữ liệu đã lấy mẫu.

**Thông tin thu được:** Phân tích trong miền tần số giúp xác định các thành phần tần số chính, băng thông, vùng phổ bị chiếm dụng và mức năng lượng của tín hiệu theo từng dải tần. Đối với tín hiệu truyền thông như 5G NR hoặc LTE, biểu diễn tần số có thể cho biết tín hiệu chiếm dụng dải tần rộng hay hẹp. Đối với một số tín hiệu radar, miền tần số có thể phản ánh băng thông tổng quát của dạng sóng.

**Ý nghĩa đối với xử lý tín hiệu vô tuyến:** Miền tần số có vai trò quan trọng vì phổ tần là tài nguyên cần được quan sát và quản lý. Tuy nhiên, khi biến đổi Fourier được xét trên toàn bộ khoảng tín hiệu quan sát, kết quả phổ cho biết thành phần tần số tồn tại trong tín hiệu nhưng không chỉ rõ các thành phần đó xuất hiện tại thời điểm nào. Hạn chế này đặc biệt đáng chú ý đối với các tín hiệu không dừng hoặc môi trường có nhiều tín hiệu xuất hiện theo từng khoảng thời gian khác nhau.

### 2.2.3 Miền thời gian–tần số

**Khái niệm:** Miền thời gian–tần số là cách biểu diễn tín hiệu đồng thời theo hai chiều thời gian và tần số. Thay vì chỉ mô tả sự thay đổi của tín hiệu theo thời gian hoặc chỉ biểu diễn thành phần phổ trên toàn bộ khoảng quan sát, miền thời gian–tần số mô tả sự phân bố năng lượng của tín hiệu trên mặt phẳng thời gian–tần số. Một cách tổng quát, biểu diễn thời gian–tần số của tín hiệu  $x(t)$  có thể được ký hiệu là:

$$T_x(t, f) = \mathcal{T}\{x(t)\}, \quad (2.2.7)$$

trong đó  $\mathcal{T}\{\cdot\}$  biểu thị một phép biến đổi thời gian–tần số tổng quát, còn  $T_x(t, f)$  mô tả biểu diễn của tín hiệu tại thời điểm  $t$  và tần số  $f$ .

**Kỹ thuật và đại lượng tiêu biểu:** Một số kỹ thuật tiêu biểu để xây dựng biểu diễn thời gian–tần số gồm biến đổi STFT, biến đổi wavelet liên tục và phân bố Wigner-Ville. Trong đó, STFT chia tín hiệu thành các đoạn ngắn bằng một cửa sổ trượt, sau đó áp dụng biến đổi Fourier cho từng đoạn [43]:

$$\mathbf{M}(\tau, f) = \int_{-\infty}^{\infty} x(t)w(t - \tau)e^{-j2\pi ft}dt, \quad (2.2.8)$$

trong đó  $w(t - \tau)$  là hàm cửa sổ tại thời điểm  $\tau$ ,  $f$  là tần số và  $\mathbf{M}(\tau, f)$  là biểu diễn thời gian–tần số thu được từ STFT. Từ kết quả này, spectrogram thường được tính bằng bình phương độ lớn của STFT [44]:

$$S(\tau, f) = |\mathbf{M}(\tau, f)|^2. \quad (2.2.9)$$

Các kỹ thuật thời gian–tần số khác nhau có thể khác nhau về cách phân tích tín hiệu, độ phân giải thời gian và độ phân giải tần số, nhưng cùng hướng đến mục tiêu mô tả sự thay đổi của nội dung phổ theo thời gian.

**Thông tin thu được:** Phân tích trong miền thời gian–tần số giúp quan sát tín hiệu theo cả vị trí thời gian và vị trí tần số. Nói cách khác, biểu diễn này cho biết tín hiệu xuất hiện tại thời điểm nào, chiếm dải tần nào và năng lượng thay đổi ra sao theo thời gian. Đối với tín hiệu truyền thông, miền thời gian–tần số có thể thể hiện vùng phổ được sử dụng trong từng khoảng thời gian. Đối với tín hiệu radar dạng xung hoặc tín hiệu có tần số thay đổi theo thời gian, biểu diễn này có thể thể hiện các vùng năng lượng ngắn, ngắn quãng hoặc có xu hướng dịch chuyển trên trục tần số.

**Ý nghĩa đối với xử lý tín hiệu vô tuyến:** Miền thời gian–tần số cung cấp một cách mô tả trực quan cho các tín hiệu vô tuyến có đặc trưng phổ thay đổi theo thời gian. Trong biểu diễn này, mỗi vị trí trên mặt phẳng thời gian–tần số tương ứng với một vùng thời gian và tần số cụ thể, còn giá trị tại vị trí đó phản ánh mức năng lượng hoặc công suất của tín hiệu. Khi được trực quan hóa dưới dạng ảnh phổ, biểu diễn thời gian–tần số tạo ra một cấu trúc hai chiều có thể tiếp tục được sử dụng trong các bước phân tích và xử lý bằng mô hình học sâu.

## 2.2.4 So sánh các miền biểu diễn tín hiệu

Việc so sánh các miền biểu diễn cần được đặt trong mối liên hệ với yêu cầu của bài toán phân đoạn phổ tín hiệu, tức là không chỉ nhận biết sự tồn tại của tín hiệu mà còn cần xác định vùng tín hiệu trên mặt phẳng thời gian–tần số. Bảng 2.2.2 trình bày sự khác biệt giữa ba miền biểu diễn theo các tiêu chí liên quan đến thông tin thời gian, thông tin tần số, khả năng mô tả tín hiệu không dừng và mức độ phù hợp với phân đoạn ảnh phổ.

Từ bảng so sánh có thể thấy, miền thời gian và miền tần số đều cung cấp thông tin quan trọng nhưng chưa đầy đủ nếu sử dụng riêng lẻ cho bài toán phân đoạn phổ tín hiệu. Miền thời

Bảng 2.2.2: So sánh các miền biểu diễn tín hiệu

| Tiêu chí                              | Miền thời gian                                                                        | Miền tần số                                                                        | Miền thời gian–tần số                                                                                                     |
|---------------------------------------|---------------------------------------------------------------------------------------|------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------|
| Dạng biểu diễn                        | Dạng sóng theo thời gian                                                              | Phổ theo tần số                                                                    | Bản đồ hoặc ảnh phổ trên mặt phẳng thời gian–tần số                                                                       |
| Thông tin thời gian                   | Thể hiện rõ thời điểm xuất hiện và sự thay đổi biên độ                                | Không thể hiện rõ thời điểm xuất hiện của từng thành phần phổ                      | Thể hiện được tín hiệu xuất hiện tại thời điểm nào                                                                        |
| Thông tin tần số                      | Không thể hiện trực tiếp vùng tần số bị chiếm dụng                                    | Thể hiện rõ thành phần tần số, băng thông và vùng phổ bị chiếm dụng                | Thể hiện được tín hiệu chiếm dải tần nào tại từng thời điểm                                                               |
| Khả năng mô tả tín hiệu không dừng    | Quan sát được sự thay đổi theo thời gian nhưng khó mô tả sự thay đổi phổ              | Chỉ phản ánh nội dung phổ tổng thể trên khoảng quan sát                            | Mô tả được sự thay đổi của phổ theo thời gian                                                                             |
| Khả năng xác định vùng chiếm dụng phổ | Hạn chế do thiếu thông tin tần số rõ ràng                                             | Xác định được vùng tần số bị chiếm dụng nhưng thiếu vị trí theo thời gian          | Xác định được vùng chiếm dụng theo cả thời gian và tần số                                                                 |
| Hạn chế chính                         | Khó xác định tín hiệu nằm ở dải tần nào nếu sử dụng riêng lẻ                          | Làm mất thông tin về thời điểm xuất hiện của các thành phần phổ                    | Có sự đánh đổi giữa độ phân giải thời gian và độ phân giải tần số                                                         |
| Mức độ phù hợp với phân đoạn ảnh phổ  | Chưa phù hợp nếu sử dụng riêng lẻ vì không tạo ra cấu trúc thời gian–tần số hai chiều | Chưa phù hợp nếu sử dụng riêng lẻ vì không thể hiện sự thay đổi phổ theo thời gian | Phù hợp hơn vì có thể biểu diễn tín hiệu dưới dạng ảnh phổ, trong đó mỗi điểm ảnh tương ứng với một vùng thời gian–tần số |

gian cho biết tín hiệu xuất hiện và thay đổi như thế nào theo thời gian, nhưng không thể hiện rõ tín hiệu đang chiếm dụng vùng tần số nào. Ngược lại, miền tần số cho biết năng lượng tín hiệu tập trung ở những dải tần nào, nhưng không chỉ ra các thành phần phổ đó xuất hiện tại thời điểm nào trong khoảng quan sát.

Hạn chế này trở nên rõ hơn trong môi trường phổ động, nơi nhiều loại tín hiệu vô tuyến có thể xuất hiện không liên tục, thay đổi theo thời gian hoặc chồng lấn một phần trên phổ. Ví dụ, tín hiệu truyền thông như 5G NR và LTE có thể chiếm dụng các vùng băng thông khác nhau theo từng khoảng thời gian, trong khi tín hiệu radar dạng xung hoặc chirp có thể chỉ xuất hiện trong thời gian ngắn và có đặc trưng tần số thay đổi. Do đó, nếu chỉ sử dụng miền thời gian, việc xác định vùng phổ bị chiếm dụng sẽ gặp hạn chế; nếu chỉ sử dụng miền tần số, việc xác định thời điểm xuất hiện của từng thành phần tín hiệu cũng không rõ ràng.

Trong khi đó, miền thời gian–tần số cho phép biểu diễn đồng thời thời điểm xuất hiện và vùng tần số chiếm dụng của tín hiệu. Đặc điểm này phù hợp với bài toán phân đoạn phổ tín hiệu, vì mục tiêu của bài toán không chỉ là xác định có tín hiệu hay không, mà còn cần khoanh vùng chính xác khu vực tín hiệu trên mặt phẳng thời gian–tần số. Khi biểu diễn thời gian–tần số được trực quan hóa thành ảnh phổ, mỗi vị trí trên ảnh tương ứng với một vùng thời gian–tần số cụ thể, còn cường độ điểm ảnh phản ánh mức năng lượng của tín hiệu tại vùng đó.

Vì vậy, trong phạm vi luận văn này, miền thời gian–tần số được lựa chọn làm cơ sở để xây dựng ảnh phổ đầu vào cho mô hình học sâu. Cách biểu diễn này tạo ra sự tương ứng tự nhiên giữa bài toán cảm nhận phổ và bài toán phân đoạn ảnh: mỗi điểm ảnh trong ảnh phổ có thể được

gán nhãn tương ứng với nhiều nền hoặc một loại tín hiệu vô tuyến cụ thể. Nhờ đó, mô hình học sâu có thể học cách phân biệt và khoanh vùng các tín hiệu như 5G NR, LTE và radar ở mức điểm ảnh, thay vì chỉ đưa ra nhãn tổng thể hoặc vùng bao thô [32].

## 2.3 Cơ sở học sâu cho bài toán phân đoạn ảnh

Học sâu đóng vai trò quan trọng trong các bài toán phân đoạn ảnh nhờ khả năng tự động học đặc trưng từ dữ liệu. Đối với ảnh phổ, các mô hình học sâu có thể khai thác cấu trúc không gian trên mặt phẳng thời gian–tần số để nhận diện và phân vùng các tín hiệu vô tuyến. Phần này trình bày các cơ sở học sâu liên quan đến bài toán phân đoạn ảnh phổ, bao gồm mạng nơ-ron sâu, mạng nơ-ron tích chập, phân đoạn ngữ nghĩa, kiến trúc mã hóa–giải mã và một số mô hình phân đoạn tiêu biểu.

### 2.3.1 Mạng nơ-ron sâu và trích xuất đặc trưng ảnh

#### Mạng nơ-ron sâu DNN


Trong mạng nơ-ron nhân tạo, nơ-ron là đơn vị xử lý cơ bản. Mỗi nơ-ron nhận một tập giá trị đầu vào, kết hợp chúng thông qua các trọng số, cộng thêm hệ số bias và đưa kết quả qua một hàm kích hoạt để tạo đầu ra. Về bản chất, cơ chế này mô phỏng ở mức “trừu tượng” khả năng xử lý và truyền thông tin của nơ-ron sinh học, nhưng trong học sâu, nơ-ron được xem như một phép biến đổi toán học có khả năng tự động tối ưu hóa các tham số từ dữ liệu.

Mạng nơ-ron sâu deep neural network (DNN) là kiến trúc được cấu thành từ nhiều lớp nơ-ron xếp nối tiếp. Mỗi lớp nhận đầu vào từ lớp trước, thực hiện một phép biến đổi có tham số và tạo ra một biểu diễn mới cho lớp tiếp theo. Nhờ cấu trúc nhiều lớp, DNN có khả năng học các đặc trưng của dữ liệu theo nhiều mức độ khác nhau, từ các đặc trưng đơn giản ở những lớp đầu đến các đặc trưng “trừu tượng” hơn ở những lớp sâu hơn. Quá trình này được minh họa trong Hình 2.3.3. Một cách tổng quát, đầu ra của một lớp trong mạng nơ-ron có thể được biểu diễn như sau:

$$\mathbf{y}^{(l)} = \phi \left( \mathbf{W}^{(l)} \mathbf{x}^{(l-1)} + \mathbf{b}^{(l)} \right), \quad (2.3.10)$$

trong đó  $\mathbf{x}^{(l-1)}$  là đầu vào của lớp thứ  $l$ ,  $\mathbf{y}^{(l)}$  là đầu ra của lớp đó,  $\mathbf{W}^{(l)}$  là ma trận trọng số,  $\mathbf{b}^{(l)}$  là vector bias và  $\phi(\cdot)$  là hàm kích hoạt phi tuyến. Với lớp đầu tiên,  $\mathbf{x}^{(0)}$  chính là dữ liệu đầu vào  $\mathbf{x}$ .

Vai trò của hàm kích hoạt phi tuyến là giúp mạng có khả năng mô hình hóa các quan hệ phức tạp giữa đầu vào và đầu ra [45]. Nếu chỉ gồm các phép biến đổi tuyến tính, nhiều lớp liên



Hình 2.3.3: Minh họa quá trình học đặc trưng qua nhiều lớp trong mạng nơ-ron sâu.

tiếp vẫn có thể được rút gọn thành một phép biến đổi tuyến tính duy nhất. Do đó, tính phi tuyến là yếu tố quan trọng giúp DNN học được các đặc trưng phức tạp từ dữ liệu.

Trong quá trình huấn luyện, các tham số  $\mathbf{W}$  và  $\mathbf{b}$  được cập nhật nhằm giảm sai số giữa đầu ra dự đoán và nhãn mục tiêu. Thay vì phải thiết kế đặc trưng thủ công, mô hình học sâu có thể tự động học các đặc trưng phù hợp với nhiệm vụ thông qua dữ liệu huấn luyện. Đây là điểm khác biệt quan trọng giữa học sâu và nhiều phương pháp xử lý tín hiệu hoặc xử lý ảnh truyền thống [25].


Đối với dữ liệu ảnh, khả năng học đặc trưng của DNN tạo nền tảng cho các mô hình phân tích ảnh hiện đại. Các lớp đầu có thể học những đặc trưng đơn giản, trong khi các lớp sâu hơn kết hợp chúng thành các biểu diễn có ý nghĩa hơn cho nhiệm vụ xử lý ảnh. Tuy nhiên, do ảnh có cấu trúc không gian rõ ràng, việc khai thác quan hệ giữa các điểm ảnh lân cận là yếu tố quan trọng trong quá trình học đặc trưng.

## Mạng nơ-ron tích chập CNN trong xử lý ảnh

Mạng nơ-ron tích chập CNN là một kiến trúc học sâu được thiết kế nhằm khai thác cấu trúc không gian của dữ liệu ảnh. Khác với cách biểu diễn ảnh dưới dạng một vector một chiều, vốn có thể làm mất đi quan hệ cục bộ giữa các điểm ảnh lân cận, CNN sử dụng các bộ lọc tích chập (kernel) để quan sát từng vùng nhỏ trên ảnh. Nhờ đó, mô hình có thể học được các đặc trưng có ý nghĩa như biên, vùng sáng tối, kết cấu hoặc hình dạng cục bộ.

Sức mạnh của CNN đến từ cơ chế chia sẻ trọng số trong các lớp tích chập. Một bộ lọc được trượt qua nhiều vị trí khác nhau trên đầu vào, cho phép mô hình phát hiện cùng một kiểu đặc trưng tại nhiều vùng không gian khác nhau. Quá trình này tạo ra các bản đồ đặc trưng, trong đó số lượng bản đồ đặc trưng đầu ra phụ thuộc vào số lượng bộ lọc được sử dụng. Chẳng hạn như ví dụ được minh họa ở Hình 2.3.4, với ảnh đầu vào kích thước  $36 \times 36$  có một kênh, lớp tích chập đầu tiên sử dụng bốn bộ lọc kích thước  $9 \times 9 \times 1$  và tạo ra bốn bản đồ đặc trưng đầu ra.





Hình 2.3.4: Minh họa quá trình trích xuất đặc trưng bằng mạng nơ-ron tích chập.

Sự thay đổi kích thước không gian của bản đồ đặc trưng phụ thuộc vào kích thước bộ lọc, phần đệm và bước trượt. Với đầu vào có chiều cao  $H_{in}$  và chiều rộng  $W_{in}$ , kích thước đầu ra có thể được xác định bởi:

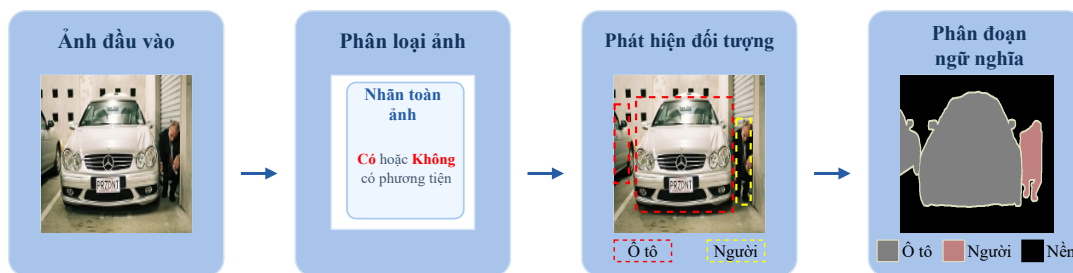
$$H_{out} = \left\lfloor \frac{H_{in} - K + 2P}{S} \right\rfloor + 1, \quad (2.3.11)$$

$$W_{out} = \left\lfloor \frac{W_{in} - K + 2P}{S} \right\rfloor + 1, \quad (2.3.12)$$

trong đó  $K$  là kích thước bộ lọc,  $P$  là kích thước phần đệm và  $S$  là bước trượt. Công thức này cho thấy phép tích chập có thể làm thay đổi kích thước không gian của đầu ra tùy theo cách lựa chọn các tham số trên. Ví dụ, khi  $H_{in} = W_{in} = 36$ ,  $K = 9$ ,  $P = 0$  và  $S = 1$ , kích thước không gian đầu ra là  $28 \times 28$ .

Bên cạnh lớp tích chập, CNN thường sử dụng lớp gộp như max pooling để giảm kích thước không gian của bản đồ đặc trưng. Max pooling chọn giá trị lớn nhất trong một vùng cục bộ, thường là  $2 \times 2$ , qua đó làm giảm số lượng tính toán và giúp biểu diễn ít nhạy hơn với những thay đổi nhỏ về vị trí của đặc trưng. Với cửa sổ  $2 \times 2$  và bước trượt bằng 2, kích thước không gian của bản đồ đặc trưng được giảm một nửa, trong khi số kênh thường được giữ nguyên.

Thông qua việc xếp chồng nhiều lớp tích chập và pooling, CNN thực hiện quá trình học đặc trưng theo thứ bậc. Các lớp đầu thường học những đặc trưng cục bộ đơn giản, còn các lớp sâu hơn có xu hướng kết hợp các đặc trưng này để tạo ra biểu diễn cô đọng và trừu tượng hơn. Trong quá trình đó, kích thước không gian thường giảm dần, trong khi số kênh đặc trưng có thể tăng lên nhằm biểu diễn nhiều mẫu đặc trưng hơn. Nhờ khả năng khai thác quan hệ không gian và học đặc trưng trực tiếp từ dữ liệu, CNN trở thành nền tảng quan trọng trong nhiều bài toán xử lý ảnh, bao gồm phân loại ảnh, phát hiện đối tượng và phân đoạn ảnh.



Hình 2.3.5: Minh họa sự khác biệt giữa phân loại ảnh, phát hiện đối tượng và phân đoạn ngữ nghĩa.

## 2.3.2 Phân đoạn ngữ nghĩa và kiến trúc phân đoạn ảnh


### Phân đoạn ngữ nghĩa trong ảnh

Phân đoạn ảnh là nhóm bài toán trong thị giác máy tính nhằm chia ảnh đầu vào thành các vùng có ý nghĩa. Tùy theo mục tiêu dự đoán, các bài toán phân đoạn thường được chia thành ba dạng chính: phân đoạn ngữ nghĩa, phân đoạn thực thể và phân đoạn toàn cảnh. Trong đó, phân đoạn ngữ nghĩa là bài toán gán nhãn lớp cho từng điểm ảnh trong ảnh đầu vào. Phân đoạn thực thể không chỉ xác định lớp của từng điểm ảnh, mà còn phân biệt từng đối tượng riêng biệt trong cùng một lớp. Phân đoạn toàn cảnh kết hợp hai hướng trên, vừa gán nhãn cho toàn bộ điểm ảnh, vừa tách riêng các cá thể đối tượng khi cần thiết.

Trong phạm vi luận văn này, nội dung tập trung vào phân đoạn ngữ nghĩa, vì mục tiêu chính là xác định mỗi vị trí trong ảnh thuộc về lớp nào, thay vì phân biệt từng cá thể riêng biệt. Khác với phân loại ảnh, vốn chỉ dự đoán một hoặc một vài nhãn cho toàn bộ ảnh, phân đoạn ngữ nghĩa cần xác định cụ thể từng vùng trong ảnh thuộc về lớp nào. So với phát hiện đối tượng, vốn biểu diễn vị trí đối tượng bằng các hộp bao chữ nhật, phân đoạn ngữ nghĩa cung cấp mô tả chi tiết hơn về hình dạng và biên của từng vùng đối tượng. Sự khác biệt giữa ba dạng bài toán này được minh họa trong Hình 2.3.5.

Trong bài toán phân loại ảnh, mô hình chỉ cần trả lời ảnh đầu vào chứa đối tượng hoặc lớp nội dung nào. Ví dụ, với một ảnh có phương tiện giao thông, đầu ra của mô hình chỉ là “có phương tiện” hoặc “không có phương tiện”. Cách biểu diễn này phù hợp khi mục tiêu là nhận biết sự xuất hiện của đối tượng, nhưng không cho biết đối tượng nằm ở đâu hoặc có hình dạng như thế nào trong ảnh.

Trong bài toán phát hiện đối tượng, mô hình không chỉ dự đoán lớp đối tượng mà còn xác định vị trí của đối tượng thông qua hộp bao. Nhờ đó, hệ thống có thể biết đối tượng nằm ở vùng nào trong ảnh. Tuy nhiên, hộp bao chỉ mô tả vị trí ở mức xấp xỉ bằng một vùng chữ nhật. Đối



Hình 2.3.6: Minh họa kiến trúc Encoder–Decoder tích chập cho bài toán phân đoạn ảnh.

với các đối tượng có hình dạng phức tạp, biên không đều hoặc bị che khuất một phần, hộp bao không thể thể hiện chính xác ranh giới thực sự của đối tượng.

Phân đoạn ngữ nghĩa giải quyết hạn chế này bằng cách thực hiện phân loại ở mức điểm ảnh. Với một ảnh đầu vào có kích thước  $H \times W$ , mô hình phân đoạn tạo ra một bản đồ nhãn có kích thước tương ứng, trong đó mỗi vị trí điểm ảnh được gán vào một lớp cụ thể. Đầu ra này được gọi là mặt nạ phân đoạn (segmentation mask). Nếu ảnh đầu vào có  $C$  lớp cần phân biệt, mô hình có thể tạo ra bản đồ xác suất theo từng điểm ảnh cho  $C$  lớp, sau đó chọn lớp có xác suất cao nhất làm nhãn dự đoán tại mỗi vị trí.

## Kiến trúc mã hóa–giải mã cho phân đoạn ảnh

Kiến trúc mã hóa–giải mã (Encoder–Decoder) là một khung kiến trúc thường được sử dụng trong các bài toán cần chuyển đổi dữ liệu đầu vào thành một đầu ra có cấu trúc. Ý tưởng chính của kiến trúc này là chia quá trình xử lý thành hai giai đoạn: giai đoạn mã hóa và giai đoạn giải mã. Bộ mã hóa (encoder) có nhiệm vụ biến đổi dữ liệu đầu vào thành một biểu diễn đặc trưng cô đọng hơn, trong khi bộ giải mã (decoder) sử dụng biểu diễn này để tái tạo hoặc dự đoán đầu ra theo yêu cầu của bài toán.

Trong bài toán phân đoạn ảnh, đầu ra không phải là một nhãn duy nhất cho toàn bộ ảnh, mà là một bản đồ nhãn theo từng điểm ảnh. Vì vậy, kiến trúc Encoder–Decoder đặc biệt phù hợp do có thể kết hợp hai yêu cầu: encoder học các đặc trưng ngữ nghĩa, còn decoder khôi phục dần độ phân giải không gian để tạo mặt nạ phân đoạn. Hình 2.3.6 minh họa một ví dụ của kiến trúc Encoder–Decoder cho phân đoạn ảnh, trong đó các khối xử lý chính được hiện thực bằng các phép tích chập.

Trong ví dụ này, phần encoder gồm nhiều khối tích chập liên tiếp, thường kết hợp với chuẩn hóa batch và hàm kích hoạt ReLU để trích xuất đặc trưng từ ảnh đầu vào. Sau các khối tích chập, các phép pooling được sử dụng để giảm kích thước không gian của bản đồ đặc trưng. Quá trình này giúp mô hình mở rộng vùng tiếp nhận và học được các đặc trưng có tính ngữ nghĩa cao hơn, nhưng đồng thời cũng làm giảm độ chi tiết không gian của biểu diễn.

Phần decoder thực hiện quá trình ngược lại bằng cách tăng dần kích thước không gian của đặc trưng. Các phép upsampling được sử dụng để khôi phục độ phân giải [33], sau đó các lớp tích chập tiếp tục tinh chỉnh bản đồ đặc trưng để tạo ra dự đoán chi tiết hơn. Nhờ đó, mô hình có thể chuyển biểu diễn cô đọng từ encoder thành mặt nạ phân đoạn có độ phân giải phù hợp với ảnh đầu vào. Ở lớp cuối, mô hình tạo ra bản đồ xác suất theo từng điểm ảnh cho các lớp cần phân đoạn. Với bài toán có  $C$  lớp, đầu ra có thể được biểu diễn dưới dạng tensor kích thước  $H \times W \times C$ , trong đó  $H$  và  $W$  là chiều cao và chiều rộng của ảnh đầu vào. Hàm softmax thường được sử dụng để chuẩn hóa xác suất trên các lớp tại từng vị trí điểm ảnh, và nhãn cuối cùng được xác định bởi lớp có xác suất cao nhất.


## Một số mô hình phân đoạn tiêu biểu

Các mô hình phân đoạn ảnh có thể được xây dựng theo nhiều định hướng kiến trúc khác nhau, tùy thuộc vào cách mô hình trích xuất đặc trưng, mở rộng ngữ cảnh và khôi phục bản đồ nhãn ở mức điểm ảnh. Một số kiến trúc dựa trên Transformer nhằm mô hình hóa quan hệ không gian rộng, một số mô hình tập trung vào thiết kế gọn nhẹ, trong khi các kiến trúc CNN thường nhấn mạnh khả năng khai thác đặc trưng cục bộ, đặc trưng đa tỉ lệ và khôi phục chi tiết không gian. Phần này trình bày một số mô hình phân đoạn tiêu biểu theo ba nhóm chính, qua đó làm rõ các nguyên lý thiết kế thường gặp trong bài toán phân đoạn ảnh.

**Nhóm mô hình dựa trên Transformer và khai thác ngữ cảnh rộng.** Các mô hình phân đoạn dựa trên Transformer khai thác cơ chế tự chú ý để mô hình hóa quan hệ không gian giữa các vùng đặc trưng trong ảnh. Khác với CNN, vốn ưu tiên trích xuất đặc trưng cục bộ thông qua các phép tích chập, Transformer có khả năng tổng hợp thông tin trên phạm vi rộng hơn, qua đó hỗ trợ biểu diễn ngữ cảnh toàn cục trong bài toán phân đoạn ảnh.

**SegFormer** là một kiến trúc tiêu biểu của nhóm này, kết hợp bộ mã hóa Transformer phân cấp với bộ giải mã dựa trên multilayer perceptron (MLP) có cấu trúc gọn nhẹ [1]. Kiến trúc tổng quát của SegFormer được trình bày trong Hình 2.3.7. Ảnh đầu vào trước hết được ánh xạ thành các token đặc trưng thông qua lớp overlap patch embedding, tức là quá trình chia ảnh thành các vùng nhỏ có chồng lấn và biểu diễn mỗi vùng dưới dạng một vector đặc trưng. Các token này sau đó được xử lý bởi bộ mã hóa Mix Transformer gồm nhiều tầng, trong đó độ phân giải không gian giảm dần theo chiều sâu mạng, còn số kênh đặc trưng tăng lên. Nhờ cấu trúc phân cấp này, SegFormer tạo ra các đặc trưng đa tỉ lệ phục vụ cho quá trình phân đoạn.

Ở phía decoder, SegFormer sử dụng các lớp MLP để chuẩn hóa chiều biểu diễn của đặc trưng từ nhiều tầng encoder, sau đó hợp nhất chúng để tạo bản đồ phân đoạn. Cách thiết kế này làm giảm sự phụ thuộc vào decoder phức tạp, đồng thời giữ được khả năng kết hợp thông tin đa mức. Ngoài ra, SegFormer không sử dụng positional encoding cố định, tức là không gắn trực tiếp



Hình 2.3.7: Kiến trúc tổng quát của SegFormer với bộ mã hóa Transformer phân cấp và decoder sử dụng MLP [1].


một mã vị trí cố định vào các token ảnh. Điều này giúp hạn chế vấn đề nội suy mã vị trí khi kích thước ảnh đầu vào thay đổi. Nhìn chung, SegFormer thể hiện hướng tiếp cận trong đó encoder Transformer giữ vai trò chính trong học biểu diễn ngữ cảnh rộng, còn decoder được tổ chức đơn giản để hợp nhất đặc trưng và tạo đầu ra phân đoạn.

**Nhóm mô hình phân đoạn nhẹ và hiệu quả tính toán.** Các mô hình phân đoạn nhẹ được phát triển nhằm giảm chi phí tính toán và số lượng tham số, trong khi vẫn duy trì khả năng trích xuất đặc trưng cần thiết cho bài toán phân đoạn. Về mặt kiến trúc, nhóm mô hình này thường thay thế các phép tích chập tiêu chuẩn bằng các phép tích chập hiệu quả hơn, hoặc sử dụng các backbone gọn nhẹ để giảm độ phức tạp của bộ mã hóa.

**ESPNetv2** là một kiến trúc CNN nhẹ sử dụng khối Extremely Efficient Spatial Pyramid (EESP) làm đơn vị xử lý chính [2]. Ý tưởng trung tâm của EESP là mở rộng vùng tiếp nhận của mô hình nhưng vẫn kiểm soát chi phí tính toán. Để đạt được điều này, EESP sử dụng group point-wise convolution, tức là phép tích chập  $1 \times 1$  được chia theo nhóm kênh để giảm số phép tính khi biến đổi số kênh đặc trưng. Bên cạnh đó, EESP sử dụng depth-wise dilated convolution, tức là phép tích chập giãn được thực hiện riêng trên từng kênh, giúp mô hình quan sát vùng không gian rộng hơn mà không cần tăng mạnh số lượng tham số.

Như thể hiện trong Hình 2.3.8, EESP kế thừa cấu trúc xử lý đa nhánh của ESP. Các nhánh song song sử dụng các dilation rate khác nhau, nghĩa là mỗi nhánh có phạm vi quan sát không gian khác nhau. Nhờ đó, khối EESP có thể học đặc trưng ở nhiều mức vùng tiếp nhận. Ngoài ra, hierarchical feature fusion, hay cơ chế hợp nhất đặc trưng theo thứ bậc, được sử dụng để kết hợp thông tin giữa các nhánh. Cơ chế này giúp giảm hiện tượng gridding artifact, tức là hiện tượng đặc trưng bị rời rạc hoặc thiếu liên tục do sử dụng tích chập giãn.

**U-Net-MobileNetV2** là một hướng thiết kế nhẹ khác, trong đó MobileNetV2 được sử



Hình 2.3.8: Minh họa khối ESP và khối EESP được sử dụng trong ESPNetv2 [2].

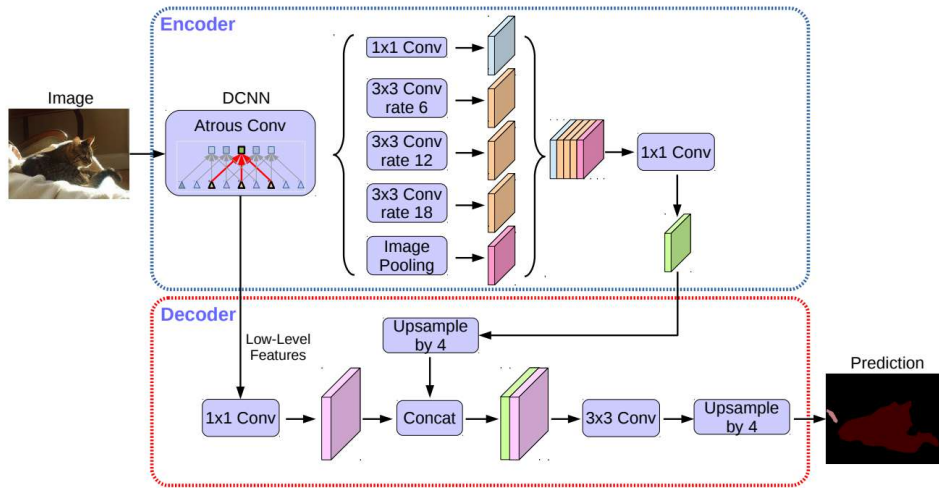
dùng làm encoder cho kiến trúc U-Net. MobileNetV2 dựa trên khối inverted residual và linear bottleneck [46]. Inverted residual có thể hiểu là cấu trúc mở rộng số kênh đặc trưng tạm thời để xử lý thông tin, sau đó nén trở lại số kênh nhỏ hơn; còn linear bottleneck là lớp nén đặc trưng không sử dụng hàm kích hoạt phi tuyến ở đầu ra nhằm hạn chế mất mát thông tin. Khi kết hợp với U-Net, MobileNetV2 đảm nhiệm vai trò trích xuất đặc trưng gọn nhẹ, trong khi decoder của U-Net sử dụng upsampling và skip connection để khôi phục độ phân giải không gian của bản đồ phân đoạn [33].

Nhìn chung, ESPNetv2 tối ưu hóa ở cấp độ khối xử lý đặc trưng bằng cách thay thế các phép tích chập tốn kém bằng các phép tích chập hiệu quả hơn. Trong khi đó, U-Net-MobileNetV2 tối ưu hóa ở cấp độ kiến trúc bằng cách sử dụng MobileNetV2 làm encoder gọn nhẹ trong cấu trúc U-Net.

**Nhóm mô hình CNN khai thác đặc trưng đa tỉ lệ và khôi phục chi tiết không gian.** Nhóm mô hình này vẫn dựa chủ yếu trên các phép tích chập, nhưng tập trung giải quyết hai yêu cầu quan trọng của bài toán phân đoạn ảnh. Thứ nhất, mô hình cần khai thác đặc trưng ở nhiều tỉ lệ khác nhau để nhận biết cả cấu trúc cục bộ lẫn ngữ cảnh rộng hơn trong ảnh. Thứ hai, mô hình cần khôi phục thông tin không gian đã bị suy giảm trong quá trình mã hóa, từ đó tạo ra bản đồ phân đoạn có biên và vùng đối tượng rõ ràng hơn.

**DeepLabV3+** là một kiến trúc phân đoạn tiêu biểu theo hướng kết hợp bộ mã hóa–giải mã với cơ chế trích xuất đặc trưng đa tỉ lệ [3]. Thành phần quan trọng của mô hình là atrous convolution, hay tích chập giãn, trong đó kernel được mở rộng bằng các khoảng trống giữa các điểm lấy mẫu. Cách thiết kế này giúp mô hình tăng vùng tiếp nhận mà không cần giảm mạnh độ phân giải không gian của đặc trưng.


Như minh họa trong Hình 2.3.9, DeepLabV3+ sử dụng khối Atrous Spatial Pyramid Pooling (ASPP) để xử lý đặc trưng bằng nhiều nhánh song song với các dilation rate khác nhau. Mỗi dilation rate tương ứng với một phạm vi quan sát khác nhau của phép tích chập, nhờ đó mô hình có thể thu nhận thông tin ở nhiều mức ngữ cảnh. Sau khi các đặc trưng đa tỉ lệ được hợp nhất, phần decoder kết hợp chúng với đặc trưng mức thấp từ các tầng nông hơn. Đặc trưng mức thấp thường còn giữ nhiều thông tin về biên và vị trí không gian, do đó việc đưa chúng vào decoder



Hình 2.3.9: Kiến trúc tổng quát của DeepLabV3+ với khối ASPP và decoder khôi phục chi tiết không gian [3].


giúp cải thiện khả năng khôi phục chi tiết trong bản đồ phân đoạn.

**UNet++** là một biến thể mở rộng của U-Net, được thiết kế nhằm cải thiện cách truyền thông tin giữa encoder và decoder [4]. Trong U-Net gốc, các skip connection nối trực tiếp đặc trưng từ encoder sang decoder ở cùng mức độ phân giải. Cách kết nối này giúp decoder sử dụng lại thông tin không gian từ các tầng nông. Tuy nhiên, giữa đặc trưng encoder và decoder vẫn tồn tại khoảng cách ngữ nghĩa, do đặc trưng tầng nông thường chứa nhiều chi tiết cục bộ, trong khi đặc trưng tầng sâu mang tính trừu tượng hơn.



Hình 2.3.10: Kiến trúc UNet++ với các skip connection lồng nhau giữa encoder và decoder [4].

Để giảm khoảng cách này, UNet++ thay thế skip connection trực tiếp bằng các đường kết nối lồng nhau và dày đặc, như thể hiện trong Hình 2.3.10. Các nút trung gian trên đường truyền đặc trưng thực hiện thêm các phép tích chập trước khi đặc trưng được đưa tới decoder. Nhờ đó, thông tin từ encoder được tinh chỉnh dần, giúp đặc trưng mức thấp trở nên phù hợp hơn với đặc trưng mức cao trong quá trình giải mã. Về mặt lý thuyết, UNet++ nhấn mạnh vai trò của việc



Hình 2.3.11: Kiến trúc tổng quát của SRNet với encoder, khối SE, module trích xuất đặc trưng đa tỉ lệ và decoder.

tổ chức lại luồng truyền đặc trưng, đặc biệt là giữa các tầng có độ phân giải khác nhau, để hỗ trợ khôi phục cấu trúc không gian trong phân đoạn ảnh.

**SRNet** là một kiến trúc phân đoạn dựa trên CNN, trong đó quá trình trích xuất và khôi phục đặc trưng được tổ chức theo dạng encoder-decoder [34]. Phần encoder sử dụng backbone gồm nhiều stage để trích xuất đặc trưng theo chiều sâu. Khi đi qua các stage này, đặc trưng thường giảm dần độ phân giải không gian nhưng tăng khả năng biểu diễn ngữ nghĩa. Đây là nguyên lý chung của nhiều kiến trúc CNN cho phân đoạn: encoder cô đọng thông tin, còn decoder khôi phục lại bản đồ phân đoạn ở độ phân giải cao hơn.

Trong Hình 2.3.11, SRNet sử dụng khối squeeze-and-excitation (SE) để hiệu chỉnh mức độ quan trọng của các kênh đặc trưng. Về bản chất, khối SE giúp mô hình nhấn mạnh các kênh chứa thông tin hữu ích hơn và giảm ảnh hưởng của các kênh ít quan trọng. Bên cạnh đó, module FS khai thác đặc trưng bằng nhiều nhánh tích chập với các kích thước hoặc mức dilation khác nhau. Cách tổ chức đa nhánh này giúp mô hình thu nhận thông tin ở nhiều phạm vi không gian trước khi hợp nhất đặc trưng. Sau đó, decoder sử dụng các phép tích chập và upsampling để khôi phục kích thước không gian và tạo đầu ra phân đoạn.

Tóm lại, DeepLabV3+, UNet++ và SRNet đều thuộc nhóm mô hình CNN nhưng nhấn mạnh các khía cạnh khác nhau của bài toán phân đoạn. DeepLabV3+ tập trung vào khai thác ngữ cảnh đa tỉ lệ thông qua ASPP và atrous convolution. UNet++ cải thiện quá trình truyền đặc trưng giữa encoder và decoder bằng các skip connection lồng nhau. SRNet kết hợp encoder, cơ chế chú ý theo kênh và module đặc trưng đa nhánh để tăng khả năng biểu diễn trước khi khôi phục bản đồ phân đoạn.



## Chương 3

# PHƯƠNG PHÁP ĐỀ XUẤT

Chương này trình bày phương pháp được đề xuất cho bài toán phân đoạn ảnh phổ. Nội dung chương bao gồm các yêu cầu thiết kế, quy trình xử lý tổng thể, phương pháp xây dựng dữ liệu đầu vào và nhãn phân đoạn, cùng với thiết kế của các mô hình HKANet, Denoise2Seg và ReSegNet. Cuối chương, các thiết lập huấn luyện và phương pháp đánh giá được mô tả nhằm chuẩn bị cho phần phân tích thực nghiệm ở chương sau.

### 3.1 Yêu cầu thiết kế phương pháp

Từ đặc điểm của bài toán phân đoạn ảnh phổ, phương pháp được đề xuất cần đáp ứng các yêu cầu về chất lượng phân đoạn, độ bền vững và hiệu quả tính toán. Các yêu cầu này xuất phát từ bản chất dự đoán theo từng điểm ảnh của bài toán phân đoạn, trong đó mỗi vị trí trên mặt phẳng thời gian-tần số cần được gán vào lớp nền hoặc một lớp tín hiệu tương ứng. Đồng thời, tín hiệu thu có thể chịu ảnh hưởng của nhiễu, kênh truyền, Doppler và sự đồng tồn tại giữa nhiều thành phần tín hiệu, làm tăng độ khó của quá trình phân đoạn.

#### 3.1.1 Chất lượng phân đoạn

Yêu cầu về chất lượng phân đoạn liên quan trực tiếp đến mức độ chính xác của mặt nạ đầu ra. Trong bài toán phân đoạn ảnh phổ, mô hình cần dự đoán nhãn cho từng điểm ảnh trên mặt phẳng thời gian-tần số, trong đó mỗi điểm ảnh thuộc về lớp nền hoặc một loại tín hiệu cụ thể như 5G NR, LTE hoặc radar. Vì vậy, chất lượng phân đoạn không chỉ được hiểu là khả năng nhận biết đúng sự xuất hiện của tín hiệu, mà còn là khả năng xác định đúng vùng chiếm dụng của từng loại tín hiệu trên ảnh phổ. Dựa trên cách đánh giá trong các nghiên cứu liên quan, yêu cầu này có thể

được xem xét theo ba khía cạnh chính:

- *Mức độ trùng khớp của mặt nạ phân đoạn.* Đây là khía cạnh cơ bản nhất của chất lượng phân đoạn. Nếu mô hình dự đoán thiếu một phần vùng tín hiệu, mở rộng vùng tín hiệu sang nền hoặc gán sai lớp cho một vùng thời gian–tần số, kết quả phân đoạn sẽ không phản ánh đúng vùng phổ bị chiếm dụng. Vì vậy, các chỉ số như mAcc và mIoU thường được sử dụng để đánh giá mức độ chính xác của mặt nạ phân đoạn. Trong đó, mIoU có vai trò quan trọng vì phản ánh trực tiếp mức độ giao nhau giữa vùng dự đoán và vùng nhãn thật trên từng lớp.
- *Khả năng phân biệt giữa các lớp tín hiệu và nền.* Trong môi trường đồng tồn tại radar–truyền thông, ảnh phổ có thể chứa nhiều thành phần khác nhau như 5G NR, LTE, radar và vùng nền. Một mô hình có chất lượng tốt cần phân biệt được vùng tín hiệu với vùng nền, đồng thời hạn chế nhầm lẫn giữa các loại tín hiệu. Do đó, các phân tích theo từng lớp và ma trận nhầm lẫn có ý nghĩa quan trọng trong việc xác định mô hình đang sai ở đâu, chẳng hạn nhầm tín hiệu thành nền hoặc nhầm giữa các tín hiệu có cấu trúc phổ tương đồng.

### 3.1.2 Độ bền vững và khả năng tổng quát

Trong môi trường đồng tồn tại radar–truyền thông, tín hiệu thu có thể chịu ảnh hưởng của nhiễu, fading, Doppler và sự xuất hiện đồng thời của nhiều thành phần tín hiệu. Những yếu tố này có thể làm vùng tín hiệu trên ảnh phổ trở nên mờ, đứt đoạn, biến dạng hoặc khó phân biệt với nền. Vì vậy, độ bền vững và khả năng tổng quát là yêu cầu quan trọng đối với mô hình phân đoạn ảnh phổ.

Trong luận văn này, yêu cầu về độ bền vững và khả năng tổng quát được xem xét theo các khía cạnh chính sau:

- *Khả năng duy trì kết quả trong điều kiện nhiễu và tỉ số tín hiệu trên nhiễu (signal-to-noise ratio – SNR) thay đổi.* Khi tỷ số tín hiệu trên nhiễu thấp, vùng năng lượng của tín hiệu có thể bị suy giảm và hòa lẫn với nền nhiễu. Điều này làm tăng nguy cơ mô hình bỏ sót tín hiệu yếu hoặc gán nhầm tín hiệu thành nền. Do đó, mô hình cần học được các đặc trưng đủ ổn định để vẫn nhận diện và khoanh vùng tín hiệu trong các điều kiện đầu vào bị suy giảm.
- *Khả năng thích ứng với biến thiên kênh truyền và Doppler.* Trong các môi trường có chuyển động hoặc truyền dẫn đa đường, đặc trưng của tín hiệu thu có thể thay đổi theo thời gian và tần số. Hiệu ứng Doppler có thể làm dịch chuyển hoặc biến đổi đặc điểm tần số của tín hiệu, trong khi fading có thể làm suy giảm hoặc làm méo vùng tín hiệu trên ảnh phổ. Vì vậy, mô hình không nên chỉ phụ thuộc vào các mẫu phổ cố định, mà cần có khả năng học các biểu diễn ổn định trước những biến thiên hợp lý của môi trường truyền dẫn.


- *Khả năng xử lý các cấu hình và tổ hợp tín hiệu mới.* Trong thực tế, tín hiệu có thể thay đổi về băng thông, khoảng cách sóng mang con, vị trí xuất hiện trên ảnh phổ hoặc mức độ chồng lấn với các tín hiệu khác. Ngoài ra, các loại tín hiệu có thể xuất hiện theo những tổ hợp khác nhau, chẳng hạn mô hình được huấn luyện trên các trường hợp hai tín hiệu đồng thời nhưng khi kiểm thử có thể gặp trường hợp nhiều tín hiệu cùng xuất hiện. Vì vậy, mô hình cần học được đặc trưng đại diện của từng loại tín hiệu, thay vì chỉ ghi nhớ các mẫu hoặc tổ hợp đã xuất hiện trong dữ liệu huấn luyện.

### 3.1.3 Độ phức tạp và hiệu quả tính toán

Bên cạnh chất lượng phân đoạn và khả năng duy trì hiệu quả trong các điều kiện phổ khác nhau, độ phức tạp tính toán là một yêu cầu quan trọng đối với phương pháp phân đoạn ảnh phổ. Khác với các bài toán chỉ tạo ra một nhãn dự đoán cho toàn bộ tín hiệu, phân đoạn ảnh phổ yêu cầu mô hình tạo mặt nạ nhãn theo từng điểm ảnh. Vì vậy, mô hình phải xử lý nhiều bản đồ đặc trưng trung gian, kết hợp thông tin ở các mức khác nhau và khôi phục độ phân giải không gian để tạo đầu ra phân đoạn. Nếu kiến trúc quá phức tạp, chi phí tính toán có thể tăng cao và làm giảm khả năng ứng dụng trong các kịch bản cần xử lý nhanh.

Trong luận văn này, độ phức tạp và hiệu quả tính toán được xem xét thông qua các khía cạnh sau:

- *Số lượng tham số của mô hình.* Số lượng tham số cho biết quy mô của kiến trúc, thường được tính theo triệu tham số. Trong các mô hình phân đoạn ảnh phổ, tham số chủ yếu đến từ encoder, decoder, các khối tích chập, cơ chế chú ý hoặc các nhánh xử lý bổ sung. Yêu cầu đặt ra là mô hình không nên cải thiện chất lượng phân đoạn chỉ bằng cách tăng mạnh số lượng tham số hoặc phụ thuộc vào các backbone lớn. Thay vào đó, kiến trúc cần sử dụng tham số một cách hiệu quả, tức là mỗi thành phần được bổ sung phải đóng góp rõ ràng cho khả năng phân đoạn.
- *Chi phí suy luận.* Chi phí suy luận được phản ánh qua số phép tính và thời gian xử lý trên mỗi ảnh phổ. Số phép tính thường được biểu diễn bằng floating point operations (FLOPs), trong khi thời gian suy luận thường được đo bằng mili giây trên mỗi mẫu. Đối với kiến trúc encoder-decoder, chi phí này có thể tăng do các tầng trích xuất đặc trưng, cơ chế hợp nhất đa tỉ lệ, attention hoặc các nhánh decoder bổ sung. Vì vậy, khi thiết kế mô hình, cần xem xét mức tăng chi phí này có tương xứng với mức cải thiện chất lượng phân đoạn hay không.



Hình 3.2.1: Sơ đồ tổng quan phương pháp đề xuất cho bài toán phân đoạn ảnh phổ.

## 3.2 Tổng quan phương pháp đề xuất

Phương pháp phân đoạn ảnh phổ được đề xuất trong luận văn bao gồm một chuỗi các khối xử lý liên kết chặt chẽ với nhau, từ khâu tiếp nhận tín hiệu thô, biểu diễn dữ liệu, cho đến cốt lõi là các mô hình học sâu và cuối cùng là quá trình đánh giá hiệu năng. Sơ đồ tổng quan của phương pháp này được minh họa trong Hình 3.2.1. Về cơ bản, phương pháp được cấu trúc thành các khối chức năng chính như sau:

**Thiết lập dữ liệu và biểu diễn đầu vào:** Quá trình bắt đầu bằng việc thu thập và mô phỏng tín hiệu vô tuyến tổng hợp (bao gồm 5G NR, LTE và radar) chịu tác động của môi trường vật lý như kênh truyền, nhiễu cộng và hiệu ứng Doppler. Do các mô hình phân đoạn đề xuất được thiết kế dựa trên kiến trúc mạng tích chập 2D, tín hiệu chuỗi thời gian 1D bắt buộc phải được chuyển đổi sang miền không gian thời gian–tần số. Phép biến đổi STFT được áp dụng để tính toán và trích xuất ảnh phổ công suất. Song song với đó, dựa trên vùng chiếm dụng thực tế của từng tín hiệu, bản đồ nhãn phân đoạn chi tiết theo từng điểm ảnh cũng được thiết lập, tạo thành cặp dữ liệu chuẩn ( $\mathbf{X}$ ,  $\mathbf{Y}$ ) phục vụ cho quá trình huấn luyện và kiểm thử.

**Phân đoạn ảnh phổ bằng học sâu:** Đây là thành phần lõi của phương pháp. Ảnh phổ đầu vào được đưa qua các kiến trúc mạng nơ-ron chuyên biệt để tự động trích xuất đặc trưng và tiến hành khoanh vùng tín hiệu. Luận văn giới thiệu ba mô hình khác nhau nhằm giải quyết các thách thức cụ thể của bài toán: HKANet tập trung vào khả năng học các đặc trưng hình thái đa hướng; Denoise2Seg khai thác cơ chế hỗ trợ khử nhiễu để phục hồi tín hiệu yếu; và ReSegNet tiếp cận theo hướng tái tạo cấu trúc để bảo đảm tính nhất quán của biểu diễn. Kết quả đầu ra của khối này là một mặt nạ dự đoán, trong đó mỗi điểm ảnh được phân loại chính xác thành vùng nhiễu, 5G NR, LTE hoặc radar.

**Đánh giá và kiểm định kết quả:** Mặt nạ phân đoạn dự đoán sau đó được đối chiếu trực tiếp với bản đồ nhãn chuẩn để định lượng hiệu quả của phương pháp. Quá trình đánh giá được

thực hiện toàn diện trên hai phương diện: chất lượng phân đoạn (sử dụng các chỉ số mIoU và mAcc để đo lường độ chính xác không gian) và hiệu quả tính toán (thông qua số lượng tham số Params, số phép toán FLOPs và thời gian suy luận). Khối chức năng này giúp xác định tính khả thi của các giải pháp khi triển khai thực tế trên các thiết bị giới hạn về tài nguyên.

## 3.3 Phương pháp phân đoạn ảnh phổ đề xuất

### 3.3.1 Thiết kế dữ liệu đầu vào và nhãn phân đoạn

#### Thiết kế ảnh phổ đầu vào và bản đồ nhãn phân đoạn

Trên cơ sở lựa chọn biểu diễn thời gian–tần số đã phân tích ở Chương 2, STFT được sử dụng để xây dựng ảnh phổ đầu vào. Lý do chính là STFT tạo ra biểu diễn thời gian–tần số dưới dạng một ma trận có cấu trúc đều, trong đó mỗi phần tử tương ứng với một khung thời gian và một ô tần số xác định. Cấu trúc này phù hợp với bài toán phân đoạn ảnh phổ vì có thể được chuyển trực tiếp thành ảnh đầu vào, đồng thời cho phép xây dựng bản đồ nhãn theo từng điểm ảnh trên cùng hệ tọa độ thời gian–tần số [43]. Ngoài ra, STFT có các tham số dễ kiểm soát như độ dài cửa sổ, bước nhảy giữa hai khung liên tiếp và kích thước Fast Fourier Transform (FFT), giúp quá trình tạo ảnh phổ nhất quán giữa các mẫu dữ liệu.

Tín hiệu thu liên tục  $r(t)$  sau khi lấy mẫu được ký hiệu là  $r[n]$ . Biến đổi STFT rời rạc của  $r[n]$  được biểu diễn dưới dạng ma trận  $\mathbf{Z}$ , trong đó phần tử tại khung thời gian  $m$  và ô tần số  $k$  được tính như sau:

$$Z[m, k] = \sum_{n=0}^{\mathfrak{N}-1} r[n + m\mathfrak{H}]w[n]e^{-j2\pi kn/\mathfrak{N}}, \quad (3.3.1)$$


trong đó  $w[n]$  là hàm cửa sổ,  $\mathfrak{H}$  là bước nhảy giữa hai khung liên tiếp và  $\mathfrak{N}$  là kích thước FFT [44]. Bản chất  $Z[m, k]$  là một hệ số Fourier phức mang cả thông tin biên độ và pha.

Kết quả STFT sau đó được chuyển thành giá trị công suất trên thang logarit để tạo thành ma trận ảnh phổ  $\mathfrak{K}$ :

$$\mathfrak{K}[m, k] = 10\log_{10}(|Z[m, k]|^2 + \epsilon), \quad (3.3.2)$$

trong đó  $\epsilon$  là một hằng số nhỏ nhằm tránh lỗi tính toán khi giá trị công suất tiến gần về không. Sau bước chuẩn hóa và thay đổi kích thước, ảnh phổ  $\mathfrak{K}$  được sử dụng làm đầu vào cho mô hình phân đoạn. Trong ảnh phổ này, trục ngang biểu diễn thời gian, trục dọc biểu diễn tần số, còn giá trị điểm ảnh phản ánh mức năng lượng tại vị trí thời gian–tần số tương ứng.

Tương ứng với mỗi ảnh phổ đầu vào  $\mathfrak{K}$ , bản đồ nhãn phân đoạn  $\mathfrak{V}$  được xây dựng để biểu diễn vùng chiếm dụng của từng loại tín hiệu. Bản đồ nhãn có cùng kích thước không gian với ảnh



Hình 3.3.2: Ví dụ ảnh phổ đầu vào theo mức SNR và bản đồ nhãn phân đoạn tương ứng: (a)–(e) ảnh phổ tại các mức SNR lần lượt là  $-10$ ,  $0$ ,  $10$ ,  $20$  và  $30$  dB; (f) bản đồ nhãn phân đoạn tương ứng.

phổ đầu vào, trong đó mỗi điểm ảnh được gán vào một lớp cụ thể. Trong phạm vi luận văn này, các lớp nhãn gồm nền/nhiều, 5G NR, LTE và radar. Các vùng thuộc về từng tín hiệu được gán nhãn theo lớp tương ứng, trong khi các vùng không thuộc các tín hiệu cần nhận dạng được gán vào lớp nền/nhiều. Như vậy, cặp dữ liệu  $(\mathbf{X}, \mathbf{Y})$  thể hiện sự tương ứng trực tiếp giữa ảnh phổ đầu vào và nhãn phân đoạn theo từng điểm ảnh. Ảnh phổ  $\mathbf{X}$  được sử dụng làm đầu vào cho mô hình học sâu, trong khi bản đồ nhãn  $\mathbf{Y}$  đóng vai trò là nhãn tham chiếu trong quá trình huấn luyện và đánh giá.

## Bộ dữ liệu thực nghiệm sử dụng trong luận văn

Do bài toán phân đoạn ảnh phổ yêu cầu bản đồ nhãn ở mức điểm ảnh, việc sử dụng dữ liệu đo thực tế gặp nhiều khó khăn trong quá trình xây dựng nhãn phân đoạn. Trong môi trường đồng tồn tại nhiều tín hiệu, máy thu chỉ quan sát được tín hiệu tổng hợp sau khi các thành phần tín hiệu đã đi qua kênh truyền, chịu ảnh hưởng của nhiễu, Doppler và các sai lệch phần cứng [25]. Vì vậy, rất khó xác định chính xác từng điểm ảnh trên ảnh phổ thuộc về 5G NR, LTE, radar hay vùng nền, đặc biệt tại các vùng chồng lấn hoặc vùng biên tín hiệu. Để bảo đảm tính chính xác của nhãn phân đoạn, luận văn sử dụng bộ dữ liệu tổng hợp, trong đó quá trình sinh tín hiệu, điều kiện kênh truyền và nhãn phân đoạn được kiểm soát đồng thời.

Bộ dữ liệu được xây dựng dựa trên các đặc trưng tín hiệu đã trình bày ở phần trước. Cụ thể, tín hiệu 5G NR được tạo với khoảng cách sóng mang con  $15$  và  $30$  kHz, băng thông từ  $10$  đến  $50$  MHz; tín hiệu LTE sử dụng các cấu hình kênh tham chiếu R.6, R.8 và R.9; trong khi tín hiệu radar được mô phỏng bằng các xung có độ rộng  $1 \mu s$ . Các lựa chọn này phản ánh sự khác biệt giữa tín hiệu truyền thông di động dựa trên OFDM và tín hiệu radar có đặc điểm xuất hiện ngắn theo thời gian [41]. Ngoài ra, dữ liệu cũng xét đến các điều kiện phổ khác nhau thông qua các mức SNR  $\{-10, 0, 10, 20, 30\}$  dB và các mức Doppler  $\{0, 5, 70, 500\}$  Hz. Nhờ đó, bộ dữ liệu không chỉ phù hợp với cơ sở lý thuyết về đặc trưng tín hiệu nghiên cứu, mà còn tạo ra các tình huống đa dạng để đánh giá khả năng phân đoạn trong môi trường phổ phức tạp.

Từ các tín hiệu miền thời gian được mô phỏng, ảnh phổ đầu vào được xây dựng theo phương

pháp đã trình bày ở phần thiết kế ảnh phổ và bản đồ nhân phân đoạn. Cụ thể, các khung tín hiệu có độ dài 40 ms được biến đổi sang miền thời gian–tần số bằng STFT với cửa sổ Hann 256 mẫu, độ chồng lấn 10 mẫu và FFT 4096 điểm. Kết quả sau đó được chuẩn hóa và resize thành ảnh phổ RGB kích thước  $256 \times 256$ . Do toàn bộ quá trình sinh tín hiệu được kiểm soát, bản đồ nhân phân đoạn tương ứng cũng được tạo đồng thời với ảnh phổ đầu vào, trong đó mỗi điểm ảnh được gán vào lớp tín hiệu tương ứng hoặc vùng nền.


### 3.3.2 Thiết kế các mô hình phân đoạn đề xuất

Sau khi xây dựng dữ liệu đầu vào và bản đồ nhân phân đoạn, bước tiếp theo là thiết kế các mô hình học sâu để ánh xạ ảnh phổ đầu vào thành mặt nạ phân đoạn tương ứng. Trong luận văn này, các mô hình phân đoạn được thiết kế và khảo sát dựa trên ba yêu cầu chính bao gồm chất lượng phân đoạn, độ bền vững trong các điều kiện phổ phức tạp và hiệu quả tính toán. Do đặc trưng tín hiệu trên ảnh phổ có thể thay đổi theo thời gian, tần số, mức nhiễu và mức độ chồng lấn, mô hình phân đoạn cần có khả năng trích xuất đặc trưng cục bộ, khai thác thông tin ngữ cảnh, hạn chế ảnh hưởng của nhiễu và khôi phục ranh giới tín hiệu một cách chính xác.

Trên cơ sở đó, luận văn trình bày ba mô hình phân đoạn ảnh phổ đề xuất, gồm HKANet [37], Denoise2Seg [5] và ReSegNetReconstructive Consistency for High-Fidelity Spectrogram Segmentation (ReSegNet). Các mô hình này không được sử dụng như các bước xử lý nối tiếp, mà là các kiến trúc phân đoạn riêng biệt, cùng nhận ảnh phổ đầu vào và tạo ra mặt nạ phân đoạn đầu ra. HKANet hướng đến việc nâng cao khả năng trích xuất và kết hợp đặc trưng trên ảnh phổ; Denoise2Seg khai thác định hướng khử nhiễu để hỗ trợ quá trình học đặc trưng phục vụ phân đoạn; trong khi ReSegNet tập trung vào việc tăng cường biểu diễn phân đoạn, làm rõ vùng tín hiệu và nâng cao độ bền vững của mô hình trong các điều kiện phổ phức tạp. Các phần tiếp theo lần lượt trình bày nguyên lý thiết kế, kiến trúc tổng thể và vai trò của từng mô hình trong bài toán phân đoạn ảnh phổ.

#### Mô hình HKANet

HKANet là mô hình phân đoạn ảnh phổ được thiết kế theo kiến trúc mã hóa–giải mã. Mục tiêu của mô hình là khai thác hiệu quả cấu trúc hình thái của tín hiệu trên mặt phẳng thời gian–tần số, đồng thời duy trì độ phức tạp tính toán ở mức hợp lý. Khác với ảnh tự nhiên, ảnh phổ có các đặc trưng gắn trực tiếp với sự phân bố năng lượng theo thời gian và tần số. Do đó, vùng tín hiệu có thể xuất hiện dưới nhiều dạng khác nhau, chẳng hạn vùng dạng khối, vùng kéo dài theo thời gian, vùng kéo dài theo tần số hoặc vùng có biên bị suy giảm do nhiễu, fading và Doppler. Vì vậy, mô hình phân đoạn ảnh phổ cần có khả năng nhận biết nhiều dạng hình thái tín hiệu, đồng thời hiệu chỉnh đặc trưng để hạn chế ảnh hưởng của nhiễu nền.



Hình 3.3.3: Kiến trúc tổng thể của HKANet với các khối HKA tích hợp MCA trong đường mã hóa và khối TDPP trong đường giải mã.

Kiến trúc tổng thể của HKANet được minh họa trong Hình 3.3.3. Mô hình gồm hai phần chính: đường mã hóa và đường giải mã. Đường mã hóa sử dụng các khối Hierarchical Kernel Attention (HKA) kết hợp với Moment Channel Attention (MCA) để trích xuất và hiệu chỉnh đặc trưng. Trong đó, HKA tập trung vào việc khai thác đặc trưng hình thái của tín hiệu theo nhiều hướng khác nhau, còn MCA thực hiện hiệu chỉnh đặc trưng theo kênh dựa trên các thống kê của bản đồ đặc trưng. Đường giải mã sử dụng Tri-Dimensional Pyramid Pooling (TDPP) để hợp nhất đặc trưng đa mức và khôi phục mặt nạ phân đoạn đầu ra.

**Đường mã hóa:** Đường mã hóa của HKANet gồm các khối HKA được sắp xếp theo cấu trúc phân cấp. Qua từng tầng mã hóa, độ phân giải không gian của bản đồ đặc trưng giảm dần, trong khi số kênh đặc trưng tăng dần từ độ rộng cơ sở  $N = 16$ . Cách tổ chức này tương tự nguyên lý chung của kiến trúc encoder trong phân đoạn ảnh: các tầng đầu giữ nhiều thông tin cục bộ như biên và vùng năng lượng nhỏ, trong khi các tầng sâu hơn học các đặc trưng ngữ nghĩa và ngữ cảnh rộng hơn. Đối với ảnh phổ, điều này có ý nghĩa quan trọng vì mô hình cần đồng thời nhận biết chi tiết biên tín hiệu và vùng chiếm dụng phổ tổng thể.

**HKA:** Khối này sử dụng ba nhánh tích chập để phân tích hình thái tín hiệu theo các hướng khác nhau. Isotropic Branch (IB) sử dụng các kernel đối xứng để khai thác các vùng tín hiệu có hình dạng tương đối cân bằng theo cả thời gian và tần số. Horizontal Anisotropic Branch (HAB) sử dụng kernel dạng  $1 \times v$  để khai thác các cấu trúc kéo dài theo chiều ngang của ảnh phổ. Vertical



Anisotropic Branch (VAB) sử dụng kernel dạng  $n \times l$  để khai thác các cấu trúc kéo dài theo chiều dọc hoặc làm rõ các thay đổi theo trục tần số. Việc kết hợp ba nhánh này giúp mô hình không chỉ phụ thuộc vào một dạng kernel duy nhất, mà có thể quan sát tín hiệu theo nhiều hướng hình thái khác nhau.

Sau khi ba nhánh IB, HAB và VAB trích xuất đặc trưng, các đặc trưng này được nối theo chiều kênh và đưa qua tích chập  $1 \times 1$  để tạo đầu vào cho khối MCA. Quá trình xử lý trong khối HKA được biểu diễn như sau:

$$\mathbf{W}_{\mathbf{I} \times \mathbf{K} \times \mathbf{L}}^{out} = \mathcal{D}_{2 \times} \left( \mathbf{W}_{\mathbf{M} \times \mathbf{C} \times \mathbf{L}}^{in} \circ \mathbf{M} \times \mathbf{C} \times \mathbf{L} \left( \mathbf{W}_{\mathbf{M} \times \mathbf{C} \times \mathbf{L}}^{in} \right) \right), \quad (3.3.3)$$

với

$$\mathbf{W}_{\mathbf{M} \times \mathbf{C} \times \mathbf{L}}^{in} = \mathcal{C}_{l \times l} \left( \langle \mathbf{W}_{\mathbf{I} \times \mathbf{B}}, \mathbf{W}_{\mathbf{I} \times \mathbf{L} \times \mathbf{B}}, \mathbf{W}_{\mathbf{V} \times \mathbf{L} \times \mathbf{B}} \rangle \right), \quad (3.3.4)$$

trong đó  $\mathcal{D}_{k \times}$  là phép giảm kích thước không gian  $k$  lần,  $\mathcal{C}_{n \times v}$  là phép tích chập tiêu chuẩn với kernel kích thước  $n \times v$ ,  $\circ$  là phép nhân theo từng phần tử, còn  $\langle \cdot \rangle$  biểu diễn phép nối đặc trưng theo chiều kênh.

Trong công thức trên,  $\mathbf{W}_{\mathbf{M} \times \mathbf{C} \times \mathbf{L}}^{in}$  là đặc trưng đã được hợp nhất từ ba nhánh hình thái. Sau đó, MCA tạo ra trọng số chú ý theo kênh và nhân với chính đặc trưng đầu vào. Cơ chế này cho phép mô hình nhấn mạnh các kênh có liên quan nhiều hơn đến vùng tín hiệu, đồng thời giảm ảnh hưởng của các kênh ít quan trọng hoặc bị nhiễu chi phối. Cuối cùng, phép giảm kích thước  $\mathcal{D}_{2 \times}$  được áp dụng để chuyển đặc trưng sang tầng mã hóa tiếp theo.

**MCA:** Mục đích MCA dùng để hiệu chỉnh đặc trưng theo kênh sau khi các đặc trưng hình thái từ HKA đã được hợp nhất. Trong ảnh phổ, nhiễu nền và tín hiệu yếu có thể có mức năng lượng trung bình gần nhau, đặc biệt ở điều kiện SNR thấp. Nếu chỉ dựa trên trung bình năng lượng, mô hình có thể khó phân biệt đâu là cấu trúc tín hiệu thật và đâu là nhiễu. Vì vậy, MCA không chỉ sử dụng thống kê bậc nhất mà còn khai thác thêm các thống kê bậc cao hơn để mô tả phân bố năng lượng trong từng kênh đặc trưng.

Trước hết, global average pooling (GAP) được sử dụng để ước lượng mức năng lượng trung bình theo từng kênh:

$$x^c = \frac{1}{\mathbf{I} \times \mathbf{V}} \sum_{j=1}^H \sum_{k=1}^{\mathbf{V}} (\mathbf{W}_{\mathbf{M} \times \mathbf{C} \times \mathbf{L}}^{in})^c(j, k), \quad (3.3.5)$$

trong đó  $x^c$  là giá trị GAP của kênh  $c$ , được tính trên toàn bộ kích thước không gian  $\mathbf{I} \times \mathbf{V}$  của  $\mathbf{W}_{\mathbf{M} \times \mathbf{C} \times \mathbf{L}}^{in}$ . Giá trị này phản ánh mức kích hoạt trung bình của một kênh đặc trưng. Tuy nhiên, hai kênh có cùng giá trị trung bình vẫn có thể khác nhau về mức phân tán năng lượng. Vì vậy, MCA tiếp tục tính độ lệch chuẩn, tức standard deviation (STD), để mô tả mức độ phân tán của năng

lượng đặc trưng:

$$y^c = \sqrt{\frac{1}{H \times W} \sum_{j=1}^H \sum_{k=1}^W ((\mathcal{H}_{MC\downarrow}^{in})^c(j, k) - x^c)^2 + \epsilon}, \quad (3.3.6)$$

trong đó  $y^c$  là STD của kênh  $c$ , còn  $\epsilon$  là hằng số nhỏ nhằm bảo đảm ổn định số học.

Bên cạnh trung bình và độ lệch chuẩn, MCA còn sử dụng gaussian-transformed skewness (GTS) để mô tả mức độ bất đối xứng trong phân bố năng lượng đặc trưng. Đại lượng này giúp mô hình nhận biết các kênh có phân bố kích hoạt không đều, vốn có thể liên quan đến sự xuất hiện của tín hiệu hoặc các biến dạng do điều kiện kênh truyền:

$$z^c = \exp\left(-(\mathcal{F}_{CW}(\text{skew}^c, -2, 2))^2\right), \quad (3.3.7)$$

với

$$\text{skew}^c = \frac{1}{H \times W} \sum_{j=1}^H \sum_{k=1}^W \left( \frac{(\mathcal{H}_{MC\downarrow}^{in})^c(j, k) - x^c}{y^c} \right)^3, \quad (3.3.8)$$

trong đó  $\text{skew}^c$  là moment bậc ba của kênh  $c$ . Hàm  $\mathcal{F}_{CW}$  được dùng để giới hạn giá trị  $\text{skew}^c$  trong khoảng  $[-2, 2]$ , từ đó giúp việc tính GTS ổn định hơn và tránh các giá trị quá lớn ảnh hưởng đến quá trình học.

Ba vector thống kê theo kênh gồm  $\mathbf{x}$ ,  $\mathbf{y}$  và  $\mathbf{z}$  sau đó được nối lại để tạo thành một mô tả tổng hợp cho từng kênh đặc trưng. Mô tả này được đưa qua MLP và hàm sigmoid để tạo trọng số chú ý thích nghi:


$$\mathbf{f}_{MC\downarrow}^{out} = \sigma(\mathcal{F}_{MLP}(\langle \mathbf{x}, \mathbf{y}, \mathbf{z} \rangle)), \quad (3.3.9)$$

trong đó  $\sigma$  là hàm sigmoid,  $\mathcal{F}_{MLP}$  biểu diễn phép xử lý của MLP, còn  $\mathbf{x}$ ,  $\mathbf{y}$  và  $\mathbf{z}$  lần lượt là các vector mô tả theo kênh được tạo từ GAP, STD và GTS. Trọng số chú ý đầu ra của MCA được dùng để hiệu chỉnh các kênh đặc trưng, giúp mô hình tăng cường các kênh chứa thông tin tín hiệu và hạn chế các kênh bị nhiễu chi phối.

**TDPP:** Sau khi đường mã hóa trích xuất các đặc trưng đa mức, đường giải mã có nhiệm vụ hợp nhất các đặc trưng này và khôi phục mặt nạ phân đoạn ở độ phân giải không gian phù hợp. Trong HKANet, quá trình giải mã được hỗ trợ bởi TDPP, như minh họa trong Hình 3.3.4. Khối TDPP được thiết kế để khai thác ngữ cảnh theo nhiều chiều khác nhau của ảnh phổ, bao gồm ngữ cảnh cục bộ, ngữ cảnh toàn cục, ngữ cảnh theo thời gian và ngữ cảnh theo tần số. Đây là điểm quan trọng vì ảnh phổ không chỉ là ảnh hai chiều thông thường, mà mỗi trục của ảnh có ý nghĩa vật lý riêng: một trục biểu diễn thời gian và trục còn lại biểu diễn tần số. Đầu ra của đường giải mã được xác định như sau:

$$\mathbf{x}^{out} = \mathcal{U}_{2 \times}(\mathcal{C}_{l \times l}(\mathcal{TDPP}(\mathbf{H}_{TDPP}^{in}))), \quad (3.3.10)$$

trong đó  $\mathbf{H}_{TDPP}^{in}$  là đặc trưng được hợp nhất từ các mức đặc trưng của đường mã hóa, còn  $\mathcal{U}_{k \times}$  là



Hình 3.3.4: Cấu trúc khối TDPP trong HKANet với các nhánh pooling theo không gian, thời gian và tần số.

phép tăng kích thước không gian  $k$  lần, được hiện thực bằng tích chập chuyển vị với kernel kích thước  $Q = 6$ .


Trong khối TDPP, nhánh local preservation giữ lại đặc trưng cục bộ  $\mathbf{V}_{loc}$  nhằm bảo toàn hình thái tín hiệu và các chi tiết biên. Nhánh global context tạo đặc trưng  $\mathbf{V}_{glob}$  nhằm cung cấp thông tin ngữ cảnh toàn cục, giúp mô hình nhận biết phân bố tổng thể của vùng tín hiệu và nền. Bên cạnh đó, nhánh temporal-context khai thác đặc trưng theo chiều thời gian thông qua việc nén trực tần số, trong khi nhánh frequency-context khai thác đặc trưng theo chiều tần số thông qua việc tổng hợp theo trục thời gian. Cách tách riêng hai chiều này phù hợp với bản chất của ảnh phổ, vì sự thay đổi theo thời gian và sự thay đổi theo tần số có thể mang các ý nghĩa khác nhau đối với từng loại tín hiệu.

Các biểu diễn từ các nhánh của TDPP sau đó được nội suy song tuyến tính và hợp nhất để tạo bản đồ đặc trưng đầu ra:

$$\mathbf{V}_{\text{TDPP}}^{\text{out}} = \mathcal{F}_{l \times l} (\langle \mathcal{U}_B(\mathbf{V}_k) \rangle_{k \in \mathcal{K}}), \quad (3.3.11)$$

trong đó  $\mathcal{K} = \{loc, glob, time, freq\}$  là tập chỉ số tương ứng với các nhánh local, global, temporal và frequency, còn  $\mathcal{U}_B$  là phép nội suy song tuyến tính không học được.

Như vậy, HKANet kết hợp ba thành phần chính gồm HKA, MCA và TDPP. HKA giúp mô hình khai thác hình thái tín hiệu theo nhiều hướng trên ảnh phổ; MCA hiệu chỉnh đặc trưng theo kênh dựa trên các thống kê bậc cao nhằm tăng khả năng phân biệt tín hiệu với nhiễu; còn TDPP hỗ trợ khôi phục mặt nạ phân đoạn bằng cách tổng hợp ngữ cảnh theo không gian, thời gian và



Hình 3.3.5: Kiến trúc tổng thể của Denoise2Seg với bộ mã hóa dùng chung, nhánh khử nhiễu phụ trợ và nhánh phân đoạn chính [5].

tần số. Nhờ cấu trúc này, HKANet phù hợp với bài toán phân đoạn ảnh phổ, trong đó mục tiêu là xác định chính xác vùng chiếm dụng của từng loại tín hiệu trên mặt phẳng thời gian–tần số.

## Mô hình Denoise2Seg

Denoise2Seg là mô hình phân đoạn ảnh phổ được thiết kế theo hướng học đa nhiệm, trong đó nhiệm vụ khử nhiễu được sử dụng như một cơ chế hỗ trợ cho nhiệm vụ phân đoạn chính. Động cơ của mô hình xuất phát từ đặc điểm của ảnh phổ trong điều kiện SNR thấp, khi vùng năng lượng của tín hiệu có thể bị che khuất bởi nhiễu và ranh giới giữa tín hiệu với nền trở nên khó xác định. Thay vì chỉ học ánh xạ trực tiếp từ ảnh phổ nhiễu sang mặt nạ phân đoạn, Denoise2Seg bổ sung một nhánh khử nhiễu phụ trợ nhằm buộc bộ mã hóa học các đặc trưng ổn định hơn trước nhiễu.

Kiến trúc tổng thể của Denoise2Seg được minh họa trong Hình 3.3.5. Mô hình gồm ba thành phần chính: bộ mã hóa dùng chung, nhánh giải mã khử nhiễu và nhánh giải mã phân đoạn. Bộ mã hóa dùng chung sử dụng các khối Hierarchical Feature Funnel (HFF) để trích xuất đặc trưng đa tỉ lệ từ ảnh phổ đầu vào. Nhánh giải mã khử nhiễu (denoising decoder -  $D^2$ ), có nhiệm vụ tái tạo ảnh phổ sạch hơn và đóng vai trò như một cơ chế điều chuẩn trong quá trình học. Nhánh giải mã phân đoạn là nhánh chính, sử dụng các khối Consensus Saliency Fusion (CSF) và Attentive Spatio-Temporal Fusion (ASTF) để hợp nhất, chọn lọc và tinh chỉnh đặc trưng trước khi tạo mặt nạ phân đoạn cuối cùng.

**Bộ mã hóa dùng chung:** Bộ mã hóa của Denoise2Seg nhận ảnh phổ đầu vào  $\mathbf{X} \in \mathbb{R}^{3 \times H \times W}$  và biến đổi thành các đặc trưng phân cấp thông qua bốn tầng HFF. Qua mỗi tầng, độ phân giải không gian giảm đi một nửa, trong khi số kênh đặc trưng tăng gấp đôi, với độ rộng cơ sở  $M = 16$ . Quá trình này được biểu diễn đệ quy như sau:

$$\mathbf{V}_i = \Phi_{\mathbf{HFF}}^{(i)}(\mathbf{V}_{i-1}), \quad \text{with } \mathbf{V}_0 = \mathbf{X}, \quad (3.3.12)$$

trong đó  $\Phi_{\mathbf{I}, \mathbf{V}}^{(i)}$  biểu diễn phép xử lý của khối HFF thứ  $i$ . Cấu trúc phân cấp này cho phép mô hình trích xuất đặc trưng theo tiến trình từ các chi tiết cục bộ ở tầng nông đến các đặc trưng ngữ nghĩa hơn ở tầng sâu.

**Thành phần trung tâm của bộ mã hóa là khối HFF.** Khối này được thiết kế để khai thác sự đa dạng về băng thông và hình thái của các tín hiệu đồng tồn tại như 5G NR, LTE và radar. HFF sử dụng ba nhánh song song với các vùng tiếp nhận khác nhau để thu nhận đặc trưng ở nhiều tỉ lệ. Cơ chế chú ý phân cấp trong khối này cho phép thông tin ngữ cảnh từ các nhánh có vùng quan sát rộng hơn điều chỉnh và làm rõ các chi tiết từ nhánh có độ phân giải cao hơn. Nhờ đó, mô hình có thể đồng thời nhận biết cấu trúc tổng thể của tín hiệu và định vị vùng biên chính xác hơn.

Bản đồ đặc trưng  $\mathbf{I}_{\cdot, j}^{(i)}$  của nhánh  $j \in \{1, 2, 3\}$  được tính như sau:

$$\mathbf{I}_{\cdot, j}^{(i)} = \mathcal{F}_{5 \times 5}^l \left( \mathcal{F}_{5 \times 5}^s \left( \mathbf{I}_{in}^{(i)} \right) \right) \odot \mathcal{F}_{\text{GCS}}(\mathbf{I}_{\cdot, j+i}^{(i)}), \quad (3.3.13)$$

trong đó  $\mathcal{F}_{n \times v}^s$  biểu diễn chuỗi phép toán gồm tích chập, chuẩn hóa batch và hàm kích hoạt ReLU, với kích thước kernel là  $n \times v$  và stride là  $s$ . Lớp đầu tiên sử dụng stride thích ứng  $s = 2^{j-i}$  để giảm kích thước không gian, sau đó là một lớp tinh chỉnh với stride bằng 1. Ký hiệu  $\mathcal{F}_{\text{GCS}}(\cdot)$  biểu diễn mô-đun global context squeeze (GCS), tức mô-đun nén ngữ cảnh toàn cục, dùng để hiệu chỉnh đặc trưng theo kênh thông qua pooling toàn cục, tích chập và hàm sigmoid. Đối với nhánh thô nhất ( $j = 3$ ), tín hiệu điều khiển được tạo từ chính đầu vào, tức là  $\mathbf{I}_{\cdot, 4}^{(i)} \equiv \mathbf{I}_{in}^{(i)}$ .

Đầu ra của khối HFF được hợp nhất như sau:


$$\mathbf{I}_{out}^{(i)} = \mathcal{F}_{\text{DS}} \left( \left\langle \mathcal{U}_{1 \times} \left( \mathbf{I}_{\cdot, 1}^{(i)} \right), \mathcal{U}_{2 \times} \left( \mathbf{I}_{\cdot, 2}^{(i)} \right), \mathcal{U}_{4 \times} \left( \mathbf{I}_{\cdot, 3}^{(i)} \right) \right\rangle \right), \quad (3.3.14)$$

trong đó  $\mathcal{F}_{\text{DS}}$  là phép tích chập tách biệt theo chiều sâu, hay depthwise separable convolution,  $\langle \cdot \rangle$  biểu diễn phép nối theo chiều kênh, còn  $\mathcal{U}_{k \times}(\cdot)$  là khối tăng kích thước không gian  $k$  lần, được hiện thực bằng tích chập chuyển vị với kernel  $4 \times 4$ .

**Nhánh giải mã khử nhiễu:**  $\text{D}^2$  đóng vai trò là nhánh phụ trợ trong Denoise2Seg. Nhánh này nhận đặc trưng sâu từ bộ mã hóa và tái tạo lại ảnh phổ sạch hơn. Về mặt học biểu diễn, nhiệm vụ khử nhiễu tạo ra một ràng buộc bổ sung, buộc bộ mã hóa không chỉ học đặc trưng phục vụ phân đoạn mà còn phải giữ lại các cấu trúc tín hiệu ổn định trước nhiễu. Nhờ đó, đặc trưng được chia sẻ cho nhánh phân đoạn có xu hướng ít phụ thuộc hơn vào nhiễu nền.

Khi định nghĩa các trạng thái biên là  $\mathbf{D}_4 \equiv \mathbf{V}_4$  và  $\mathbf{D}_0 \equiv \mathbf{V}_{denoise}$ , quá trình tái tạo trong nhánh khử nhiễu được tính đệ quy như sau:

$$\mathbf{D}_{i-1} = \mathcal{U}_{2 \times}(\mathbf{D}_i), \quad \text{for } i \in \{1, 2, 3, 4\}. \quad (3.3.15)$$



Hình 3.3.6: Cấu trúc khối CSF dùng để hợp nhất đặc trưng từ bộ mã hóa và nhánh khử nhiễu thông qua mặt nạ chú ý dựa trên độ nổi bật [5].

**Nhánh giải mã phân đoạn:** Nhánh giải mã phân đoạn là nhánh chính của Denoise2Seg, có nhiệm vụ tạo mặt nạ phân đoạn cuối cùng. Ở mỗi bước giải mã, nhánh này thực hiện hai quá trình liên tiếp. Trước hết, khối CSF được sử dụng để điều phối và hợp nhất đặc trưng giữa bộ mã hóa và nhánh khử nhiễu. Sau đó, khối ASTF tiếp tục tinh chỉnh đặc trưng theo hướng không gian-thời gian trước khi tạo đầu ra phân đoạn.

Khi định nghĩa  $\mathbf{S}_0 \equiv \mathbf{W}_4$ , bản đồ đặc trưng  $\mathbf{S}_i$  tại tầng  $i$  được tính như sau:

$$\mathbf{S}_i = \Phi_{\mathbf{S}\mathbf{W}\mathbf{W}}^{(i)}(\langle \mathcal{U}_{2 \times}(\mathbf{S}_{i-1}), \mathbf{M}_{4-i} \rangle), \quad (3.3.16)$$


với

$$\mathbf{M}_j = \Phi_{\mathbf{CSF}}^{(j)}(\mathbf{W}_j, \mathbf{D}_j), \quad (3.3.17)$$

trong đó  $\Phi_{\mathbf{S}\mathbf{W}\mathbf{W}}^{(i)}$  biểu diễn phép xử lý của khối ASTF tại tầng  $i$ , còn  $\Phi_{\mathbf{CSF}}^{(j)}$  biểu diễn phép xử lý của khối CSF tại tầng  $j$ .

**Khối hợp nhất độ nổi bật đồng thuận:** Khối hợp nhất độ nổi bật đồng thuận CSF được minh họa trong Hình 3.3.6. Vai trò của khối này là điều phối hai nguồn đặc trưng: đặc trưng từ bộ mã hóa, vốn còn chứa nhiều thông tin gốc nhưng có thể bị ảnh hưởng bởi nhiễu, và đặc trưng từ nhánh khử nhiễu, vốn mang xu hướng sạch hơn sau quá trình tái tạo. CSF sử dụng cơ chế đồng thuận dựa trên năng lượng không gian để tạo mặt nạ chú ý, từ đó làm nổi bật các vùng đặc trưng đáng tin cậy và hạn chế các vùng bị nhiễu chi phối.

Cụ thể, CSF nhận hai đầu vào gồm đặc trưng từ bộ mã hóa  $\mathbf{C}_{in1}^{(i)}$  và đặc trưng từ nhánh khử nhiễu  $\mathbf{C}_{in2}^{(i)}$ . Để tăng khả năng tách biệt giữa tín hiệu và nhiễu, khối này tổng hợp năng lượng



Hình 3.3.7: Cấu trúc khối ASTF với hai nhánh không gian và thời gian, kết hợp cơ chế chú ý theo tần số để tinh chỉnh đặc trưng phân đoạn [5].

không gian của hai nguồn đặc trưng, sau đó sử dụng phép bình phương phi tuyến để khuếch đại các vùng kích hoạt có độ tin cậy cao. Mặt nạ điều khiển  $\mathbf{C}^{(i)}$  được tính như sau:

$$\mathbf{C}^{(i)} = \mathcal{C}_{i \times 1}^i \left( \mathcal{F}_{\mathbf{M}} \left( \left( \mathbf{E}^{(i)} \right)^2 \right) \right), \quad (3.3.18)$$

trong đó  $\mathbf{E} = \sum_{k=1}^2 \mathcal{F}_{\mathbf{M}}(\mathcal{F}_{\text{CAP}}(\mathbf{C}_{ink}^{(i)}))$  biểu diễn năng lượng đồng thuận,  $\mathcal{F}_{\text{CAP}}$  là phép lấy trung bình theo kênh, hay Channel-wise Average Pooling (CAP), và  $\mathcal{F}_{\mathbf{M}}$  là phép chuẩn hóa min-max. Sau đó, mặt nạ này được dùng để điều khiển không gian trên cả hai luồng đặc trưng, bảo đảm rằng các thông tin nổi bật hơn được ưu tiên trong quá trình hợp nhất:

$$\mathbf{C}_{out}^{(i)} = \mathcal{F}_{i \times 1}^i \left( \left\langle \mathbf{C}_{in1}^{(i)} \odot \mathbf{C}^{(i)}, \mathbf{C}_{in2}^{(i)} \odot \mathbf{C}^{(i)} \right\rangle \right). \quad (3.3.19)$$

**Khối hợp nhất không gian–thời gian có chú ý:** Khối hợp nhất không gian–thời gian có chú ý ASTF được minh họa trong Hình 3.3.7. Sau khi đặc trưng đã được điều phối bởi CSF, ASTF tiếp tục tinh chỉnh đặc trưng bằng cách tách quá trình xử lý thành hai nhánh song song. Nhánh không gian sử dụng các tích chập  $5 \times 5$  để khai thác ngữ cảnh rộng trên ảnh phổ, trong khi nhánh thời gian sử dụng các tích chập  $5 \times 1$  để hỗ trợ làm rõ ranh giới tín hiệu theo chiều thời gian. Ngoài ra, ASTF còn sử dụng cơ chế chú ý theo tần số để chọn lọc các thành phần tần số có ý nghĩa trước khi hợp nhất đặc trưng. Cơ chế chú ý theo tần số trong ASTF tạo ra mặt nạ nổi bật  $\mathbf{A}_{att}^{(i)}$  như sau:

$$\mathbf{A}_{att}^{(i)} = \sigma \left( \mathcal{C}_{i \times 5}^i \left( \mathcal{F}_{\text{CAP}} \left( \mathcal{C}_{i \times 1}^i \left( \mathbf{A}_{in}^{(i)} \right) \right) \right) \right), \quad (3.3.20)$$

trong đó  $\sigma$  là hàm sigmoid. Mặt nạ này được dùng để điều khiển hai nhánh đặc trưng, giúp giữ lại các thành phần tần số có nhiều thông tin trước khi hợp nhất bằng phép tích chập tách biệt theo chiều sâu  $\mathcal{F}_{DS}$ :

$$\mathbf{A}_i^{out} = \mathcal{F}_{DS} \left( \left\langle \mathbf{A}_1^{(i)} \odot \mathbf{A}_{att}^{(i)}, \mathbf{A}_2^{(i)} \odot \mathbf{A}_{att}^{(i)} \right\rangle \right). \quad (3.3.21)$$

**Chiến lược huấn luyện đa giai đoạn:** Để ổn định quá trình tối ưu và khai thác hiệu quả vai trò của nhánh khử nhiễu, Denoise2Seg sử dụng chiến lược huấn luyện đa giai đoạn, hay Multi-Stage Training Strategy (MSTS). Quá trình này giúp mô hình tránh việc phải học đồng thời hai nhiệm vụ khác nhau ngay từ đầu, đồng thời cho phép bộ mã hóa trước hết học được đặc trưng

có tính bền vững trước nhiễu, sau đó mới tối ưu cho nhiệm vụ phân đoạn. Cụ thể, quá trình huấn luyện gồm ba giai đoạn:

- *Tiền huấn luyện bộ mã hóa*: bộ mã hóa trước hết được huấn luyện cùng với nhánh  $D^2$  bằng hàm mất mát tái tạo trung bình bình phương  $\mathcal{L}_{\text{denoise}}$ . Giai đoạn này khuyến khích bộ mã hóa học các đặc trưng ít nhạy với nhiễu.
- *Huấn luyện nhánh phân đoạn*: sau khi tiền huấn luyện, bộ mã hóa được giữ cố định, còn nhánh giải mã phân đoạn được tối ưu bằng hàm mất mát cross-entropy (CE)  $\mathcal{L}_{\text{seg}}$  cho nhiệm vụ phân loại theo từng điểm ảnh.
- *Tinh chỉnh toàn bộ mô hình*: cuối cùng, toàn bộ mạng được huấn luyện đầu cuối bằng hàm mất mát phân đoạn  $\mathcal{L}_{\text{seg}}$ . Dựa trên các đặc trưng bền vững đã học được trong giai đoạn đầu, quá trình tinh chỉnh này giúp nhánh khử nhiễu chuyển từ vai trò tái tạo tín hiệu sang hỗ trợ tinh chỉnh đặc trưng phục vụ trực tiếp cho phân đoạn.


Như vậy, Denoise2Seg khác với mô hình phân đoạn đơn nhiệm ở chỗ mô hình không chỉ học ánh xạ trực tiếp từ ảnh phổ nhiễu sang mặt nạ phân đoạn, mà còn sử dụng nhiệm vụ khử nhiễu như một cơ chế hỗ trợ học biểu diễn. Bộ mã hóa dùng chung giúp hai nhiệm vụ chia sẻ đặc trưng, nhánh  $D^2$  định hướng mô hình học cấu trúc tín hiệu bền vững hơn trước nhiễu, còn các khối CSF và ASTF giúp hợp nhất và tinh chỉnh đặc trưng trước khi tạo mặt nạ phân đoạn. Cách thiết kế này phù hợp với bài toán phân đoạn ảnh phổ trong điều kiện nhiễu mạnh, nơi việc phân biệt tín hiệu yếu với nền nhiễu là một trong những khó khăn chính.

## Mô hình ReSegNet

ReSegNet là mô hình phân đoạn ảnh phổ được xây dựng theo hướng nhất quán tái tạo. Khác với các mô hình phân đoạn thông thường, vốn học trực tiếp ánh xạ từ ảnh phổ đầu vào sang mặt nạ phân đoạn, ReSegNet xem phân đoạn ảnh phổ như một quá trình tái tạo mặt nạ có độ trung thực cao từ đầu vào bị suy giảm bởi nhiễu. Cách tiếp cận này xuất phát từ đặc điểm của ảnh phổ trong môi trường đồng tồn tại radar–truyền thông, nơi tín hiệu có thể bị nhiễu che khuất, biên tín hiệu bị mờ, hoặc vùng phổ bị chồng lấn. Khi đó, nếu chỉ dựa trên ánh xạ phân loại theo từng điểm ảnh, mô hình có thể dễ bị ảnh hưởng bởi nhiễu và tạo ra mặt nạ phân đoạn đứt đoạn hoặc sai biên.

Về tổng thể, ReSegNet được xây dựng dựa trên ba thành phần chính. Thứ nhất, Dual Adaptive Sampling (DAS) được sử dụng để điều khiển quá trình huấn luyện theo hướng tập trung nhiều hơn vào các trạng thái nhiễu khó. Thứ hai, Decoupled Strategic–Spatial Conditioning (DSSC) được sử dụng để điều kiện hóa quá trình tái tạo thông qua hai đường bổ trợ: đường điều khiển toàn cục và đường tinh chỉnh cục bộ. Trong DSSC, Feature-wise Linear Modulation






Hình 3.3.8: Kiến trúc tổng thể của ReSegNet với VAE Encoder, không gian tiềm ẩn, các khối CIB và cơ chế điều khiển toàn cục  $\theta_{control}$ .

(FiLM) cung cấp điều khiển toàn cục cho decoder, còn Conditional Interaction Bridge (CIB) thực hiện hợp nhất có chọn lọc giữa đặc trưng encoder và decoder. Thứ ba, Structure and Uniformity Reconstruction Loss (SUR) được đề xuất để tối ưu quá trình tái tạo mặt nạ theo từng vùng, trong đó vùng đồng nhất và vùng có cấu trúc phức tạp được xử lý bằng các thành phần mất mát khác nhau.

Khác với hai mô hình trước chủ yếu dựa trên kiến trúc encoder-decoder tắt định, ReSegNet sử dụng variational autoencoder (VAE) [47] đã được tiền huấn luyện và cố định tham số để ánh xạ ảnh phổ vào không gian tiềm ẩn. Việc sử dụng VAE giúp biểu diễn đầu vào dưới dạng phân bố tiềm ẩn thay vì một đặc trưng tắt định duy nhất. Điều này phù hợp với bản chất không chắc chắn của tín hiệu vô tuyến thu được, do ảnh phổ có thể thay đổi dưới ảnh hưởng của nhiễu, fading, Doppler và các điều kiện kênh truyền khác nhau. Trong không gian tiềm ẩn này, mô hình U-Net [33] với số kênh cơ sở  $Q = 16$  được sử dụng cho quá trình tái tạo, trong khi VAE nén đầu vào với hệ số  $R = 8$ .

Kiến trúc tổng thể của ReSegNet được minh họa trong Hình 3.3.8. Ảnh phổ đầu vào trước hết được đưa qua VAE Encoder để tạo biểu diễn trong không gian tiềm ẩn. Sau đó, quá trình tái tạo được điều kiện hóa bởi bước thời gian  $t_n$ , nhiễu  $\mathbf{z}$ , các đặc trưng cục bộ được hợp nhất thông qua CIB và vector điều khiển toàn cục  $\theta_{control}$ . Cuối cùng, VAE Decoder tái tạo đầu ra tương ứng với mặt nạ phân đoạn.

**Huấn luyện chủ động bằng DAS:** DAS là cơ chế lấy mẫu thích nghi được sử dụng trong quá trình huấn luyện ReSegNet. Trong các mô hình consistency [48], quá trình huấn luyện thường xét các trạng thái nhiễu khác nhau trên một quỹ đạo từ dữ liệu sạch đến dữ liệu nhiễu. Nếu các bước thời gian được lấy mẫu đều nhau, mô hình có thể tiêu tốn nhiều tài nguyên huấn luyện cho các vùng dễ, trong khi chưa tập trung đủ vào các vùng khó, chẳng hạn các trạng thái nhiễu làm



Hình 3.3.9: Minh họa cơ chế DAS trong ReSegNet. Các bước thời gian được chia thành nhiều bin, sau đó Focus Policy chọn bin bắt đầu và Intensity Policy chọn kích thước bước nhảy thích nghi dựa trên mật mát lịch sử.

mật biên tín hiệu hoặc làm tín hiệu yếu bị lẫn với nền. DAS giải quyết vấn đề này bằng cách theo dõi mức độ khó của từng vùng thời gian huấn luyện dựa trên lịch sử mật mát, sau đó ưu tiên lấy mẫu những vùng có mật mát cao hơn.

Cơ chế DAS được minh họa trong Hình 3.3.9. Trước hết, lịch thời gian gồm  $M$  bước, ký hiệu  $\mathcal{T}_{\text{schedule}}$ , được chia thành  $M$  bin rời nhau  $B_i$ , trong đó mỗi bin chứa  $M/M$  chỉ số thời gian liên tiếp. DAS theo dõi độ khó của từng bin thông qua mật mát lịch sử  $l_i^{(s)}$ , được cập nhật với tốc độ học suy giảm  $\alpha_i^{(s)} = 1/C_i^{(s)}$ :

$$l_i^{(s)} = (1 - \alpha_i^{(s)}) l_i^{(s-1)} + \alpha_i^{(s)} \bar{l}_i^{(s)}, \quad (3.3.22)$$

trong đó  $\bar{l}_i^{(s)}$  là giá trị mật mát trung bình của các mẫu thuộc bin  $i$  trong batch hiện tại, còn  $C_i^{(s)}$  là số lần tích lũy mẫu của bin đó.

Sau khi có thông tin mật mát lịch sử, Focus Policy được sử dụng để chọn bin bắt đầu  $B_i$ . Chính sách này cân bằng giữa khai thác các bin khó và khám phá các bin ít được lấy mẫu thông qua hệ số  $\beta$ . Xác suất chọn bin được xác định như sau:

$$P(B_i) = (1 - \beta) \frac{\exp(l'_i)}{\sum_{j=1}^M \exp(l'_j)} + \beta \frac{1}{M}, \quad (3.3.23)$$

trong đó  $l'_i$  là mật mát lịch sử  $l_i^{(s)}$  nếu bin đã được lấy mẫu trước đó, tức  $C_i^{(s)} > 0$ . Nếu bin chưa được lấy mẫu, một giá trị mặc định cao, chẳng hạn 1.0, được sử dụng nhằm khuyến khích quá trình khám phá.

Sau khi chọn chỉ số bắt đầu  $n$  trong bin  $B_i$ , Intensity Policy xác định kích thước bước nhảy thích nghi  $k_i$  dựa trên độ khó của bin đã chọn:

$$k_i = \text{round} \left( k_{\text{max}} - \text{norm}(l_i^{(s)})(k_{\text{max}} - k_{\text{min}}) \right), \quad (3.3.24)$$

trong đó  $\text{norm}(l_i^{(s)})$  chuẩn hóa tuyến tính mật mát lịch sử của bin  $i$  về khoảng  $[0, 1]$  dựa trên giá trị nhỏ nhất và lớn nhất của vector mật mát lịch sử  $l^{(s)}$ . Hai giá trị  $k_{\text{min}}$  và  $k_{\text{max}}$  lần lượt là giới hạn dưới và giới hạn trên của kích thước bước nhảy. Nói cách khác, DAS không chỉ chọn vùng

thời gian cần học, mà còn điều chỉnh khoảng cách giữa hai trạng thái nhiễu được dùng để tính mất mát nhất quán.

Chính sách DAS, ký hiệu  $\pi_{D\blacktriangleleft S}$ , chọn  $n$  và  $k_i$ , từ đó xác định hai bước thời gian  $t_n$  và  $t_{n+k_i}$  thuộc  $\mathcal{T}_{\text{schedule}}$ . Hai bước thời gian này được áp dụng lên mẫu sạch  $\mathbf{x}$  và nhiễu Gaussian chuẩn  $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$  để tạo cặp đầu vào nhiễu  $(\mathbf{x} + t_n \mathbf{z}, \mathbf{x} + t_{n+k_i} \mathbf{z})$ . Mất mát nhất quán của DAS được tính bằng cách giảm sai khác giữa đầu ra của online network và target network [48]:

$$\mathcal{L}_{D\blacktriangleleft S}(\boldsymbol{\theta}, \boldsymbol{\theta}^-) := \mathbb{E}_{\mathbf{x} \sim \mathcal{D}, \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \pi_{D\blacktriangleleft S}} [d(\mathbf{f}_{\boldsymbol{\theta}}(\mathbf{x} + t_{n+k_i} \mathbf{z}, t_{n+k_i}), \mathbf{f}_{\boldsymbol{\theta}^-}(\mathbf{x} + t_n \mathbf{z}, t_n))], \quad (3.3.25)$$

trong đó  $d$  là khoảng cách mean squared error (MSE),  $\mathbf{f}_{\boldsymbol{\theta}}$  là online network,  $\mathbf{f}_{\boldsymbol{\theta}^-}$  là target network, còn kỳ vọng  $\mathbb{E}$  được lấy trên các mẫu từ tập dữ liệu  $\mathcal{D}$ , nhiễu Gaussian và chính sách lấy mẫu  $\pi_{DAS}$ . Về ý nghĩa, thành phần mất mát này buộc mô hình tạo ra các đầu ra nhất quán khi đầu vào nằm ở hai mức nhiễu khác nhau trên cùng một quỹ đạo, qua đó hỗ trợ học biểu diễn bền vững hơn trước nhiễu.

**Điều kiện hóa chiến lược và không gian:** Bên cạnh cơ chế lấy mẫu chủ động, ReSegNet còn sử dụng DSSC để cung cấp thông tin điều kiện cho quá trình tái tạo mặt nạ phân đoạn. Ý tưởng cốt lõi của DSSC là khai thác đồng thời hai loại thông tin: thông tin tổng thể của toàn bộ ảnh phổ và thông tin chi tiết tại từng vị trí không gian. Thông tin tổng thể giúp mô hình hiểu được bối cảnh chung của ảnh phổ, chẳng hạn số lượng vùng tín hiệu, mức độ phân bố năng lượng và cấu trúc tổng quát của cảnh quan phổ. Trong khi đó, thông tin cục bộ giúp bảo toàn các chi tiết quan trọng như biên tín hiệu, các vùng năng lượng nhỏ hoặc các cấu trúc phổ có kích thước hẹp.

Để thực hiện điều này, tại mỗi tầng encoder, một Conditioning Extractor được sử dụng để tạo ra bản đồ điều kiện  $\mathbf{C}_i$ . Có thể xem  $\mathbf{C}_i$  như một bản tóm tắt ngắn gọn về những thông tin quan trọng tại tầng đặc trưng tương ứng. Các bản đồ điều kiện này sau đó được khai thác thông qua hai nhánh xử lý: nhánh chiến lược (strategic pathway) và nhánh không gian (spatial pathway).

Nhánh chiến lược có nhiệm vụ cung cấp cho decoder một cái nhìn tổng quát về toàn bộ ảnh phổ. Thay vì chỉ dựa vào đặc trưng cục bộ tại từng vị trí, decoder được bổ sung thêm một tín hiệu điều khiển toàn cục phản ánh trạng thái chung của ảnh đầu vào.

Cụ thể, bản đồ điều kiện sâu nhất  $\mathbf{C}_0$  tại vị trí bottleneck được sử dụng để tạo ra vector điều khiển toàn cục  $\boldsymbol{\theta}_{\text{control}}$ . Trước hết, cơ chế attention-based pooling xác định các vùng đặc trưng quan trọng trên ảnh phổ và tổng hợp chúng thành một biểu diễn có kích thước nhỏ gọn. Biểu diễn này sau đó được đưa qua mạng MLP để tạo ra vector điều khiển:

$$\boldsymbol{\theta}_{\text{control}} = \mathcal{F}_{\text{MLP}} \left( \sum_{h,w} (\mathbf{C}_0 \odot \text{Softmax}(\mathcal{F}_{\blacktriangleleft \mathbf{h}}(\mathbf{C}_0))) \right), \quad (3.3.26)$$

trong đó  $\mathcal{F}_{\blacktriangleleft \mathbf{R}}(\cdot)$  là attention-logit function, được hiện thực bằng tích chập  $1 \times 1$  và hàm kích hoạt ReLU;  $\odot$  là phép nhân theo từng phần tử; còn  $\sum_{h,w}(\cdot)$  là phép cộng gộp theo không gian. Kết quả sau đó được đưa qua MLP để tạo vector  $\boldsymbol{\theta}_{\text{control}}$ . Vector  $\boldsymbol{\theta}_{\text{control}}$  có thể được hiểu như một tập hợp các tham số mô tả trạng thái chung của ảnh phổ. Vector này được sử dụng trong cơ chế FiLM để điều chỉnh các đặc trưng của decoder. Nói cách khác, FiLM cho phép decoder tự động nhấn mạnh những đặc trưng phù hợp với bối cảnh hiện tại và giảm ảnh hưởng của những đặc trưng ít quan trọng hơn. Nhờ đó, quá trình tái tạo mặt nạ không chỉ dựa trên thông tin cục bộ mà còn được định hướng bởi ngữ cảnh tổng thể của ảnh phổ.

Mặc dù thông tin toàn cục giúp mô hình hiểu được bối cảnh chung, việc phân đoạn chính xác vẫn phụ thuộc nhiều vào khả năng bảo toàn chi tiết không gian. Các chi tiết này bao gồm biên tín hiệu, các vùng phổ hẹp hoặc những cấu trúc có kích thước nhỏ. Trong các kiến trúc encoder-decoder truyền thống, đặc trưng thường được truyền trực tiếp từ encoder sang decoder thông qua skip connection. Tuy nhiên, cách truyền này có thể đưa cả những đặc trưng không hữu ích hoặc nhiễu vào quá trình giải mã. Để khắc phục hạn chế đó, ReSegNet sử dụng khối CIB nhằm lựa chọn và hợp nhất đặc trưng một cách có chọn lọc hơn.

Trong CIB, đặc trưng từ encoder và decoder trước hết được trao đổi thông tin thông qua cơ chế cross-attention. Có thể hiểu quá trình này như việc hai nhánh đặc trưng tham chiếu lẫn nhau để xác định những vùng thông tin quan trọng cần được giữ lại. Tiếp theo, bản đồ điều kiện cục bộ  $\mathbf{C}_i$  được sử dụng để sinh ra các cổng không gian. Các cổng này hoạt động tương tự như bộ lọc, cho phép mô hình tăng cường những vùng đặc trưng hữu ích và giảm ảnh hưởng của những vùng ít liên quan. Nhờ đó, thông tin được truyền từ encoder sang decoder mang tính chọn lọc hơn thay vì được sao chép trực tiếp như skip connection thông thường.

Quá trình hợp nhất trong CIB được biểu diễn như sau:

$$\mathbf{O}_i = \mathcal{C}_{1 \times 1}(\text{Concat}(\text{Cr}\blacktriangleleft(\mathbf{E}_i, \mathbf{D}_{i+1}), \mathbf{c}_{E,i} \odot \mathbf{E}_i, \text{Cr}\blacktriangleleft(\mathbf{D}_{i+1}, \mathbf{E}_i), \mathbf{c}_{D,i} \odot \mathbf{D}_{i+1})), \quad (3.3.27)$$

trong đó  $\text{Cr}\blacktriangleleft(\cdot, \cdot)$  là cross-attention module, với đối số thứ nhất đóng vai trò query và đối số thứ hai đóng vai trò key/value;  $\text{Concat}(\cdot)$  là phép nối theo chiều kênh;  $\odot$  là phép nhân theo từng phần tử; còn  $\mathcal{C}_{1 \times 1}(\cdot)$  là phép tích chập cuối cùng để hợp nhất đặc trưng. Nhờ sự kết hợp giữa FiLM ở mức toàn cục và CIB ở mức cục bộ, ReSegNet vừa có khả năng tận dụng thông tin ngữ cảnh của toàn bộ ảnh phổ, vừa duy trì được các chi tiết không gian quan trọng. Điều này đặc biệt hữu ích đối với bài toán phân đoạn ảnh phổ, nơi mô hình cần đồng thời xác định chính xác vị trí tín hiệu và bảo toàn hình dạng của các vùng chiếm dụng phổ trên mặt phẳng thời gian-tần số.

**Hàm mất mát SUR:** Là hàm mất mát được thiết kế riêng cho bài toán phân đoạn ảnh phổ theo hướng tái tạo, ký hiệu  $\mathcal{L}_{\text{SUR}}$ . Thay vì tính mất mát giống nhau cho mọi điểm ảnh, SUR xử lý mặt nạ theo các patch không chồng lấn có kích thước cố định  $(h_p, w_p)$ . Cách này phù hợp

với ảnh phổ vì trong mặt nạ phân đoạn có hai loại vùng rất khác nhau: vùng đồng nhất, chẳng hạn nền hoặc vùng thuộc cùng một lớp, và vùng phức tạp, thường nằm gần biên tín hiệu hoặc nơi có sự chuyển tiếp giữa các lớp.

SUR phân chia các patch dựa trên độ lệch chuẩn  $\sigma(\mathbf{p})$  của patch nhân thật. Các patch đồng nhất được đưa vào tập  $\mathcal{S}_1$  nếu  $\sigma(\mathbf{p}) \leq \tau_{\text{std}}$ , còn các patch phức tạp được đưa vào tập  $\mathcal{S}_2$  trong các trường hợp còn lại. Vì mặt nạ nhân thật là cấu trúc nhị phân không nhiễu, một patch hoàn toàn đồng nhất có phương sai lý tưởng bằng không. Do đó, ngưỡng  $\tau_{\text{std}} = 10^{-6}$  được dùng như ngưỡng dung sai số học thay vì một ngưỡng kinh nghiệm liên quan đến SNR. Hàm mất mát SUR tổng thể được xác định như sau:

$$\mathcal{L}_{\text{SUR}} = \mathcal{L}_{\text{avg\_c1}} + \lambda_{\text{cwp}} \mathcal{L}_{\text{avg\_c2}}, \quad (3.3.28)$$

trong đó  $\lambda_{\text{cwp}}$  là siêu tham số dùng để điều chỉnh trọng số của thành phần mất mát cho các vùng có cấu trúc phức tạp.

Đối với các patch đồng nhất trong tập  $\mathcal{S}_1$ , thành phần  $\mathcal{L}_{\text{avg\_c1}}$  được sử dụng để khuyến khích dự đoán phẳng và có giá trị trung bình phù hợp với nhân thật. Thành phần này vừa phạt phương sai không mong muốn trong dự đoán, vừa phạt sai lệch về giá trị trung bình:

$$\mathcal{L}_{\text{avg\_c1}} = \frac{1}{|\mathcal{S}_1|} \sum_{\mathbf{p} \in \mathcal{S}_1} [\text{max}(0, \sigma^2(\hat{\mathbf{p}})) + \lambda_{\mu} (\mu(\hat{\mathbf{p}}) - \mu(\mathbf{p}))^2], \quad (3.3.29)$$

trong đó  $\mathbf{p}$  và  $\hat{\mathbf{p}}$  lần lượt là patch nhân thật và patch dự đoán,  $|\mathcal{S}_1|$  là số lượng patch trong tập đồng nhất,  $\sigma^2(\cdot)$  là phương sai,  $\mu(\cdot)$  là giá trị trung bình, và  $\lambda_{\mu}$  là siêu tham số cân bằng. Phép  $\text{max}(0, \cdot)$  đảm bảo giá trị mất mát không âm trong trường hợp có sai số số học rất nhỏ trên các patch hoàn toàn phẳng.

Đối với các patch phức tạp trong tập  $\mathcal{S}_2$ , thành phần  $\mathcal{L}_{\text{avg\_c2}}$  được sử dụng để bảo toàn cấu trúc tín hiệu. Thành phần này gồm hai ý chính: giảm mất cân bằng giữa số điểm ảnh tín hiệu và nền trong patch, đồng thời giữ hình dạng hình học thông qua toán tử Laplacian:

$$\mathcal{L}_{\text{avg\_c2}} = \frac{1}{|\mathcal{S}_2|} \sum_{\mathbf{p} \in \mathcal{S}_2} \left( \sum_{i \in \text{vox}} \frac{|\hat{p}_i - p_i|}{\text{vox} + \epsilon} + \sum_{i \in \text{vox}} \frac{|\hat{p}_i - p_i|}{\text{vox} + \epsilon} \right) + \lambda_c \frac{1}{|\mathcal{S}_2|} \sum_{\mathbf{p} \in \mathcal{S}_2} \left( \frac{1}{\text{vox}} \sum_{j \in \mathbf{p}} |\Delta \hat{p}_j - \Delta p_j| \right), \quad (3.3.30)$$

trong đó  $p_i$  và  $\hat{p}_i$  là các điểm ảnh tương ứng trong patch nhân thật và patch dự đoán;  $\text{vox}$  và  $\text{vox}$  lần lượt là tập các điểm ảnh tín hiệu và nền trong patch  $\mathbf{p}$ ;  $\text{vox}$  và  $\text{vox}$  là số lượng điểm ảnh trong hai tập này;  $\Delta$  là toán tử Laplacian;  $\text{vox}$  là tổng số điểm ảnh trong một patch; còn  $\lambda_c$  là siêu tham số của thành phần mất mát độ cong. Thành phần Laplacian giúp mô hình chú ý hơn đến sự thay đổi hình học và vùng biên, nhờ đó mặt nạ dự đoán có thể giữ cấu trúc tín hiệu rõ hơn. Cuối cùng, mất mát SUR được kết hợp với mất mát DAS để tạo hàm mục tiêu tổng thể của ReSegNet:

$$\mathcal{L}_{\text{ReSegNet}} = \mathcal{L}_{\text{DAS}} + \lambda_{\text{seg}} \mathcal{L}_{\text{SUR}}, \quad (3.3.31)$$

trong đó  $\lambda_{\text{seg}}$  là siêu tham số cân bằng giữa mất mát nhất quán  $\mathcal{L}_{\text{DAS}}$  và mất mát tái tạo cấu trúc  $\mathcal{L}_{\text{SUR}}$ .

Tóm lại, ReSegNet tiếp cận bài toán phân đoạn ảnh phổ theo hướng nhất quán tái tạo thay vì chỉ phân loại từng điểm ảnh theo cách thông thường. DAS giúp quá trình huấn luyện tập trung hơn vào các trạng thái nhiễu khó; DSSC kết hợp FiLM và CIB để điều khiển quá trình tái tạo ở cả mức toàn cục và cục bộ; còn SUR giúp mô hình xử lý khác nhau giữa vùng đồng nhất và vùng có cấu trúc phức tạp trên mặt nạ phân đoạn. Nhờ đó, ReSegNet được thiết kế nhằm cải thiện khả năng tái tạo cấu trúc mặt nạ, đặc biệt trong các điều kiện ảnh phổ bị suy giảm bởi nhiễu và giao thoa.

## 3.4 Cài đặt huấn luyện và phương pháp đánh giá

### 3.4.1 Cấu hình huấn luyện

Các mô hình được huấn luyện trên các cặp dữ liệu  $(\mathbf{X}, \mathbf{Y})$ , trong đó  $\mathbf{X}$  là ảnh phổ đầu vào và  $\mathbf{Y}$  là bản đồ nhãn phân đoạn tương ứng. Mục tiêu huấn luyện là tối ưu tham số của mô hình để mặt nạ phân đoạn dự đoán  $\hat{\mathbf{Y}}$  gần với nhãn tham chiếu  $\mathbf{Y}$ .

Trong luận văn này, ảnh phổ đầu vào có kích thước  $256 \times 256$  và gồm bốn lớp nhãn: nền, 5G NR, LTE và radar. Các mô hình được hiện thực bằng PyTorch [49] và huấn luyện trên 1 GPU P100 với thuật toán Adam [50], tốc độ học ban đầu  $10^{-4}$ , kích thước batch là 32 và số epoch là 60. Đối với các mô hình có cơ chế huấn luyện riêng, chẳng hạn Denoise2Seg với nhánh khử nhiễu phụ trợ hoặc ReSegNet với cơ chế nhất quán tái tạo, quá trình huấn luyện được thực hiện theo đúng thiết kế của từng mô hình. Tuy nhiên, kết quả cuối cùng đều được đánh giá dựa trên mặt nạ phân đoạn dự đoán  $\hat{\mathbf{Y}}$  và bản đồ nhãn thật  $\mathbf{Y}$ .

### 3.4.2 Phương pháp đánh giá

Hiệu quả phân đoạn được đánh giá bằng hai chỉ số chính: mAcc và mean mIoU. Chỉ số mAcc đo độ chính xác trung bình theo từng lớp:

$$\text{mAcc} = \frac{1}{C} \sum_{c=1}^C \frac{TP_c}{TP_c + FN_c}, \quad (3.4.32)$$

trong đó  $C$  là số lớp,  $TP_c$  là số điểm ảnh của lớp  $c$  được dự đoán đúng, còn  $FN_c$  là số điểm ảnh thuộc lớp  $c$  nhưng bị dự đoán sai sang lớp khác.

Chỉ số IoU của lớp  $c$  đo mức độ trùng khớp giữa vùng dự đoán và vùng nhãn thật:

$$\text{IoU}_c = \frac{TP_c}{TP_c + FP_c + FN_c}, \quad (3.4.33)$$

trong đó  $FP_c$  là số điểm ảnh bị dự đoán nhầm thành lớp  $c$ . Từ đó, mIoU được tính bằng trung bình IoU trên tất cả các lớp:

$$\text{mIoU} = \frac{1}{C} \sum_{c=1}^C \text{IoU}_c, \quad (3.4.34)$$

trong đó, mAcc phản ánh khả năng dự đoán đúng theo từng lớp, còn mIoU phản ánh mức độ trùng khớp giữa mặt nạ dự đoán và nhãn thật.

Bên cạnh hai chỉ số chất lượng phân đoạn, luận văn cũng xem xét độ phức tạp tính toán thông qua số lượng tham số, FLOPs và thời gian suy luận. Số lượng tham số phản ánh quy mô của mô hình và lượng trọng số cần được lưu trữ. FLOPs biểu thị số phép toán dấu phẩy động cần thực hiện khi mô hình xử lý một ảnh phổ đầu vào. Với một lớp tích chập tiêu chuẩn, FLOPs được ước lượng bởi:

$$\text{FLOPs} = H_{\text{out}} W_{\text{out}} C_{\text{out}} (K_h K_w C_{\text{in}}), \quad (3.4.35)$$

trong đó  $H_{\text{out}}$  và  $W_{\text{out}}$  là kích thước không gian của đầu ra,  $C_{\text{in}}$  và  $C_{\text{out}}$  lần lượt là số kênh đầu vào và đầu ra, còn  $K_h$  và  $K_w$  là kích thước kernel.

Thời gian suy luận là thời gian trung bình để mô hình xử lý một ảnh phổ đầu vào và tạo ra mặt nạ phân đoạn dự đoán. Chỉ số này thường được đo bằng mili giây trên mỗi mẫu và phản ánh tốc độ xử lý của mô hình trong giai đoạn kiểm thử hoặc triển khai. Khi kết hợp với số lượng tham số và FLOPs, thời gian suy luận giúp đánh giá rõ hơn sự đánh đổi giữa chất lượng phân đoạn và hiệu quả tính toán.

## Chương 4

# KẾT QUẢ THỰC NGHIỆM

Chương này trình bày chi tiết các kết quả thực nghiệm nhằm đánh giá toàn diện hiệu năng của ba mô hình học sâu đề xuất: HKANet, Denoise2Seg và ReSegNet. Quá trình đánh giá được cấu trúc một cách hệ thống, bắt đầu từ việc kiểm thử khả năng chống chịu của mô hình trước các suy hao vật lý của điều kiện phổ vô tuyến, phân tích vai trò của các thành phần thiết kế, cho đến việc so sánh trực tiếp với các phương pháp tiêu biểu hiện hành. Cuối cùng, chương này sẽ cung cấp một bức tranh tổng hợp về hiệu quả tính toán phần cứng, từ đó đưa ra định hướng lựa chọn mô hình tối ưu cho từng kịch bản triển khai thực tế.

### 4.1 Đánh giá hiệu năng theo điều kiện phổ


Độ bền vững của kênh truyền là một trong những tiêu chí khắc khe nhất đối với các hệ thống vô tuyến. Phần này đánh giá chi tiết sự biến thiên về chất lượng phân đoạn của các mô hình khi chịu tác động từ SNR và Doppler [38].

#### 4.1.1 Hiệu năng theo tỷ số tín hiệu trên nhiễu (SNR)

Sự phụ thuộc của các mô hình vào SNR được đánh giá toàn diện bằng hai chỉ số mIoU và mAcc, quét qua dải môi trường từ cực đoan (-10 dB) đến lý tưởng (30 dB), như minh họa tại Hình 4.1.1. Kết quả định lượng cho thấy sự khác biệt rõ rệt về đặc tính kiến trúc của từng phương pháp.

Kết quả thực nghiệm chỉ ra rằng hiệu năng của ReSegNet bị ảnh hưởng mạnh mẽ nhất bởi sự thay đổi của SNR. Khi tín hiệu thoát khỏi vùng nhiễu nặng (từ 0 dB trở lên), mIoU của ReSegNet tăng vọt đáng kể từ 68.50% và nhanh chóng hội tụ về đỉnh 74.29% tại 30 dB. Mức hiệu năng này bỏ xa hai mô hình còn lại, khẳng định sức mạnh tái tạo nhân từ VAE khi cấu trúc tín






Hình 4.1.1: Hiệu năng phân đoạn mIoU và mAcc theo SNR của ba mô hình đề xuất.

hiệu có thể nhận diện được. Đánh giá trực quan cũng phản ánh xu hướng này: ở điều kiện 30 dB, ReSegNet xác định cực kỳ mạnh mẽ đặc tính phổ, tạo ra các mặt nạ thời gian - tần số sạch và chính xác tuyệt đối. Tuy nhiên, điểm yếu chí mạng của mô hình tạo sinh cũng bộc lộ tại môi trường nhiễu sâu (-10 dB), khi mIoU sụt giảm nghiêm trọng xuống mức thấp nhất là 42.51%. Ở mức nhiễu này, tín hiệu gốc bị phá hủy hoàn toàn, dẫn đến hiện tượng mạng VAE tạo sinh sai lệch và cho ra các mặt nạ bị phân mảnh.

Trái ngược với sự biến động của ReSegNet, Denoise2Seg thể hiện sự bền vững đáng kinh ngạc xuyên suốt mọi dải SNR. Đặc biệt, tại vùng nhiễu cực đoạn -10 dB, mô hình vươn lên dẫn đầu với mức mIoU đạt 51.87% và mAcc đạt 67.82%. Khoảng cách hiệu năng này chứng minh giá trị của nhánh khử nhiễu phụ trợ trong việc tách lọc các tín hiệu rất yếu khỏi nền nhiễu xung quanh. Phân tích bóc tách cho thấy phần lớn sai số ở mức -10 dB của Denoise2Seg chỉ đến từ việc phân loại nhầm một tỷ lệ nhỏ các tín hiệu LTE cực kỳ mờ nhạt thành nhiễu nền, thay vì sụp đổ hoàn toàn. Quan sát trực quan mặt nạ phân đoạn cho thấy Denoise2Seg vẫn bám sát được ranh giới tín hiệu bị che khuất nặng, với các khiếm khuyết nhỏ chỉ xuất hiện ở những ngưỡng nơi năng lượng tín hiệu hòa lẫn hoàn toàn vào nhiễu.

HKANet duy trì đường cong hiệu năng ổn định, nằm giữa hai thái cực trên. Tại -10 dB, mô hình chống chịu tương đối tốt với 48.36% mIoU, cao hơn mức sụp đổ của ReSegNet. Khi môi trường cải thiện (từ 0 dB đến 30 dB), hiệu năng của HKANet tăng đều và duy trì trạng thái bão hòa ổn định quanh mốc 58.92% mIoU và 71.29% mAcc. Dù không đạt được đỉnh hiệu năng xuất sắc như ReSegNet ở điều kiện lý tưởng, hình ảnh trực quan cho thấy HKANet vẫn phân định ranh giới tín hiệu tương đối sạch sẽ ở các vùng SNR dương, đảm bảo độ tin cậy cần thiết để khoan



Hình 4.1.2: Hiệu năng phân đoạn mIoU và mAcc theo dịch chuyển Doppler của ba mô hình đề xuất.

vùng tín hiệu băng hẹp.


Tóm lại, phân tích hiệu năng theo SNR đã làm rõ bản chất vật lý của từng phương pháp: ReSegNet tối ưu hóa độ sắc nét ở môi trường tiêu chuẩn, trong khi Denoise2Seg đóng vai trò là kiến trúc chống chịu nhiễu sâu tốt nhất.

### 4.1.2 Hiệu năng theo Doppler

Hiệu ứng Doppler gây ra sự dịch chuyển tần số trong ảnh phổ, tiềm ẩn nguy cơ làm biến dạng hình thái tín hiệu và gây khó khăn cho việc nhận diện ranh giới. Để đánh giá khả năng chống chịu đối với yếu tố này, nghiên cứu thực hiện kiểm thử sự biến thiên hiệu năng của các mô hình tại các mức dịch chuyển tần số Doppler từ 0 Hz đến 500 Hz trong điều kiện môi trường tiêu chuẩn. Kết quả định lượng được trình bày tại Hình 4.1.2.

Tổng quan kết quả cho thấy cả ba mô hình đề xuất đều thể hiện sự ổn định vượt trội trước các biến động tần số. Khi Doppler shift tăng dần từ 0 Hz lên đến ngưỡng khắc nghiệt 500 Hz, các chỉ số mIoU và mAcc chỉ ghi nhận mức sụt giảm rất nhẹ, dưới 1% trên tổng hiệu năng. Sự ổn định này khẳng định rằng kiến trúc trích xuất đặc trưng của các mô hình đã học được các thuộc tính bất biến đối với sự dịch chuyển ngang trên trục thời gian - tần số của ảnh phổ.

ReSegNet tiếp tục duy trì vị thế dẫn đầu với mIoU ổn định tại ngưỡng 66.45% khi không có Doppler và chỉ giảm xuống còn 65.82% tại 500 Hz. Việc giữ vững được khoảng cách hiệu năng



Hình 4.1.3: Ma trận nhầm lẫn chuẩn hóa trung bình qua toàn dải SNR của ba mô hình đề xuất.

đáng kể so với hai phương pháp còn lại minh chứng cho sức mạnh của khung nhất quán tái tạo. Cụ thể, thay vì trích xuất đặc trưng thụ động, sự phối hợp giữa chiến lược điều kiện hóa không gian và hàm mục tiêu nhận thức cấu trúc đã định hướng mô hình tập trung vào đặc tính hình học cốt lõi của tín hiệu. Điều này giúp ReSegNet học được các thuộc tính bất biến và tự điều chỉnh cực kỳ tốt trước sự méo mó, dịch chuyển biên dạng do hiệu ứng di động gây ra trên ảnh phổ.

Tương tự, HKANet và Denoise2Seg cũng cho thấy độ ổn định cao, với mIoU suy giảm không đáng kể (từ 56.25% xuống 55.58% đối với HKANet và từ 56.72% xuống 56.05% đối với Denoise2Seg). Kết quả này củng cố luận điểm rằng các mô hình đề xuất không bị phụ thuộc vào vị trí tuyệt đối của tín hiệu trên ảnh phổ, mà tập trung vào nhận diện cấu trúc đặc trưng cục bộ. Nhìn chung, khả năng duy trì hiệu năng bền vững trước dịch chuyển Doppler, kết hợp với độ lệch chuẩn thấp qua các thử nghiệm độc lập, xác nhận rằng các mô hình hoàn toàn phù hợp để triển khai trong các kịch bản mạng di động thực tế nơi thiết bị đầu cuối thường xuyên thay đổi vận tốc và hướng di chuyển.

### 4.1.3 Phân tích độ chính xác phân lớp thông qua Ma trận nhầm lẫn

Mặc dù các chỉ số mIoU và mAcc cung cấp cái nhìn tổng quan về hiệu năng, chúng chưa phản ánh đầy đủ đặc tính phân loại chéo giữa các giao thức vô tuyến. Để mở xẻ chi tiết tỷ lệ nhận diện đúng cũng như các xu hướng sai số đối với từng loại nhãn cụ thể (Nhiều nền, Radar, LTE, 5G NR), nghiên cứu tiến hành đánh giá ma trận nhầm lẫn chuẩn hóa của ba mô hình. Các ma trận này được tính giá trị trung bình trên toàn bộ dải nhiễu (từ  $-10$  dB đến  $30$  dB) nhằm đối chiếu trực tiếp với độ chính xác tổng thể mAcc. Kết quả trực quan được trình bày tại Hình 4.1.3.

Phân tích bộc lộ rõ xu hướng suy luận mang đậm bản chất kiến trúc của từng mô hình, giải thích chi tiết cấu trúc sai số đằng sau các mốc hiệu năng mAcc 69.95%, 70.48% và 79.56% đã được thống kê:

**Định vị ranh giới tín hiệu vô tuyến và nhiễu:** Denoise2Seg cho thấy năng lực kiểm soát nhiễu bền bỉ nhất khi tỷ lệ nhận diện đúng lớp nền đạt 89.0%. Đồng thời, tỷ lệ bỏ lọt tín hiệu (dự đoán nhầm tín hiệu vô tuyến thành nhiễu) của mô hình này cũng được kìm hãm ở mức an toàn (13.0% – 15.0%). Điều này tái khẳng định sức mạnh của nhánh tiền xử lý khử nhiễu  $D^2$  trong việc bảo toàn các dải năng lượng mờ nhạt xuyên suốt dải SNR. Ngược lại, ReSegNet có xu hướng tạo sinh, dẫn đến tỷ lệ dự đoán nhầm nhiễu nền thành các đốm tín hiệu giả (chủ yếu là 5G và LTE) cộng dồn lên tới 16.0%, khiến độ chính xác trên lớp nhiễu của nó bị kéo lùi xuống mức 82.0%.

**Khả năng phân biệt giữa các giao thức:** Đối với tín hiệu Radar băng rộng và sắc nét, cả ba mô hình đều xử lý tốt với độ nhận diện đúng từ 88.0% đến 93.0%, do hình thái của radar ít bị hòa lẫn. Tuy nhiên, rào cản lớn nhất kéo tụt điểm mAcc của các mô hình chính là việc phân tách hai giao thức có chung đặc tính đa sóng mang OFDM (LTE và 5G NR). Tại đây, sự nhầm lẫn chéo diễn ra rất nặng nề ở Denoise2Seg (nhầm lẫn lên tới 31.0% – 32.0%). Trong khi đó, HKANet phát huy tối đa sức mạnh của cơ chế trích xuất đặc trưng định hướng VAB và HAB. Nhờ khả năng phân định ranh giới phổ hẹp, HKANet kéo giảm mức độ nhầm lẫn chéo giữa LTE và 5G NR xuống còn 23.0% – 24.0%. Cuối cùng, ReSegNet lại tỏa sáng rực rỡ trong việc khôi phục toàn vẹn cấu trúc bên trong của các tín hiệu diện rộng. Khả năng tái tạo này giúp ReSegNet bứt phá, đạt độ chính xác phân lớp trung bình cho nhãn LTE và 5G NR ở mức trên 71.0% — tạo ra khoảng cách áp đảo so với mức xấp xỉ 51% – 55% của hai kiến trúc còn lại.

Tựu trung lại, việc đánh giá ma trận nhầm lẫn trung bình đã phơi bày trọn vẹn sự đánh đổi của từng kiến trúc: Denoise2Seg phòng thủ an toàn trước nhiễu, HKANet sắc bén ở ranh giới phổ hẹp, và ReSegNet mạnh mẽ tuyệt đối trong việc tái tạo hình thái tín hiệu tổng thể.

## 4.2 Phân tích vai trò các thành phần thiết kế

### 4.2.1 Nghiên cứu cắt bỏ các thành phần của HKANet

Để đánh giá sâu sắc mức độ đóng góp của từng mô-đun trong kiến trúc HKANet, nghiên cứu tiến hành phân tích cắt bỏ (ablation study) với kết quả định lượng chi tiết được tổng hợp tại Bảng 4.2.1 và Hình 4.2.4.

Khởi điểm với mô hình cơ sở  $\mathcal{M}_1$  chỉ sử dụng nhánh IB, mạng đạt mức mIoU ở ngưỡng 50.00%. Việc bổ sung tuần tự các nhánh dự hướng mang lại sự thăng tiến rõ rệt: tích hợp thêm HAB trong  $\mathcal{M}_2$  nâng mIoU lên 51.68%, và tiếp tục cấu hình thêm VAB trong  $\mathcal{M}_3$  giúp hiệu năng đạt 52.81%. Sự cải thiện mang tính bước ngoặt này xác thực độ hiệu quả của thiết kế tri-axial. Khác với IB chỉ bao quát đặc trưng cục bộ, canal HAB cung cấp trường nhìn mở rộng theo chiều

Bảng 4.2.1: Nghiên cứu cắt bỏ các thành phần kiến trúc của HKANet

| Model                         | HKA |     |     |     | TDPP | mAcc<br>(%) | mIoU<br>(%) | Params<br>(M) | Latency<br>(ms) |
|-------------------------------|-----|-----|-----|-----|------|-------------|-------------|---------------|-----------------|
|                               | IB  | HAB | VAB | MCA |      |             |             |               |                 |
| $\mathcal{M}_1$               | ✓   | ✗   | ✗   | ✗   | ✗    | 66.70       | 50.00       | 4.09          | 15.4            |
| $\mathcal{M}_2$               | ✓   | ✓   | ✗   | ✗   | ✗    | 67.54       | 51.68       | 4.41          | 16.7            |
| $\mathcal{M}_3$               | ✓   | ✓   | ✓   | ✗   | ✗    | 67.62       | 52.81       | 4.72          | 17.3            |
| $\mathcal{M}_3 + \text{CBAM}$ | ✓   | ✓   | ✓   | ✗   | ✗    | 67.81       | 53.13       | 4.73          | 18.3            |
| $\mathcal{M}_3 + \text{SE}$   | ✓   | ✓   | ✓   | ✗   | ✗    | 68.15       | 53.58       | 4.73          | 18.3            |
| $\mathcal{M}_4$               | ✓   | ✓   | ✓   | ✓   | ✗    | 69.07       | 54.88       | 4.74          | 18.4            |
| HKANet                        | ✓   | ✓   | ✓   | ✓   | ✓    | 69.95       | 56.25       | 4.76          | 18.9            |

ngang để thu trọn đặc tính của các tín hiệu radar băng rộng, trong khi VAB tập trung dọc theo trục tần số để phân định sắc nét các ranh giới phổ hẹp của 5G NR và LTE. Động lực chính đằng sau thành công này là cấu hình kernel tuần tự (7, 5, 3). Biểu đồ Hình 4.2.4a chứng minh cấu hình này tối ưu hóa hoàn hảo sự đánh đổi giữa hiệu năng và chi phí tính toán so với các thiết kế đối xứng (ví dụ: 7, 7, 7) hoặc bất đối xứng lớn hơn (ví dụ: 9, 7, 5). Mặc dù các cấu hình nặng nề này mang lại mức tăng mIoU không đáng kể (dưới 0.6%), chúng lại tạo ra gánh nặng hệ thống khi tiêu tốn thêm hơn 1.83M tham số và làm chậm tốc độ suy luận thực tế. Không dừng lại ở việc tối ưu phần cứng, Hình 4.2.4b còn cho thấy tích hợp HAB và VAB giúp mô hình kiến tạo độ bền vững vượt trội trước hiệu ứng Doppler 500 Hz. Nhờ khả năng bám sát các đặc trưng hình học bất biến,  $\mathcal{M}_2$  và  $\mathcal{M}_3$  đã thu hẹp biên độ sụt giảm mIoU xuống chỉ còn 1.44% và 1.25%, triệt tiêu đáng kể mức suy thoái 2.30% từng xuất hiện trên mô hình cơ sở  $\mathcal{M}_1$ .

Tiến đến giai đoạn tinh chỉnh đặc trưng, việc đưa mô-đun MCA vào  $\mathcal{M}_4$  đã tạo ra một bước nhảy vọt, kéo mIoU tăng thêm 2.07% lên mức 54.88%. Sự ưu việt của MCA so với các cơ chế chú ý tiêu chuẩn được bộc lộ rõ nét nhất dưới điều kiện nhiễu khắc nghiệt. Cụ thể tại Hình 4.2.4c, ở mức SNR -10 dB, trong khi CBAM và SE chỉ hỗ trợ  $\mathcal{M}_3$  nhích nhẹ hiệu năng từ 38.37% lên các mức tương ứng là 39.65% và 41.27%, thì MCA lại thiết lập một khoảng cách áp đảo khi vươn tới 46.71%. Khác biệt cốt lõi nằm ở phương pháp trích xuất: trong khi CBAM và SE phụ thuộc vào các phép gộp đặc trưng bậc một vốn dễ bị nhiễu nền làm lu mờ hoàn toàn thông tin, thì MCA khai thác các thống kê hiệp phương sai bậc cao. Cơ chế này cho phép mạng nắm bắt trọn vẹn các mối tương quan chéo giữa các kênh, qua đó nhận diện và phân tách thành công các dải năng lượng vô tuyến cực kỳ yếu ớt khỏi lớp nhiễu nền dày đặc.

Mảnh ghép cuối cùng hoàn thiện HKANet là mô-đun TDPP, giúp đẩy đỉnh hiệu năng lên 56.25% mIoU (+1.37% so với  $\mathcal{M}_4$ ) với mức chi phí tham số tăng thêm siêu việt, chỉ 0.02M. Đóng góp lớn nhất của TDPP là cơ chế gộp 1D độc lập, cho phép mô hình bóc tách chính xác các biến động tức thời theo thời gian khỏi sự bền vững theo dải tần. Cách tiếp cận này khắc phục triệt để nhược điểm làm mờ ranh giới đa hướng của các phép gộp 2D truyền thống, vốn thường gây ra sự nhầm lẫn giữa tín hiệu và nhiễu ở viền phổ. Vì các phép gộp định hướng này cùng quá trình lấy

Bảng 4.2.2: Đánh giá ảnh hưởng của các thành phần kiến trúc trong Denoise2Seg

| Model           | D <sup>2</sup> | MSTS         | ASTF         | CSF          | mAcc (%) | mIoU (%) | Params (M) | Latency (ms) |
|-----------------|----------------|--------------|--------------|--------------|----------|----------|------------|--------------|
| $\mathcal{M}_1$ | <del>✗</del>   | <del>✗</del> | <del>✗</del> | <del>✗</del> | 62.18    | 46.47    | 3.82       | 17.5         |
| $\mathcal{M}_2$ | ✓              | <del>✗</del> | <del>✗</del> | <del>✗</del> | 57.96    | 40.73    | 4.00       | 18.2         |
| $\mathcal{M}_3$ | ✓              | ✓            | <del>✗</del> | <del>✗</del> | 66.27    | 49.63    | 4.00       | 18.2         |
| $\mathcal{M}_4$ | ✓              | ✓            | ✓            | <del>✗</del> | 68.97    | 54.66    | 4.34       | 19.5         |
| Denoise2Seg     | ✓              | ✓            | ✓            | ✓            | 70.48    | 56.72    | 4.34       | 20.6         |

mẫu lên song tuyến tính hoàn toàn không chứa tham số học, toàn bộ mức chi phí 0.02M chỉ phát sinh từ lớp tích chập dung hợp  $1 \times 1$  cuối cùng, đưa HKANet trở thành một kiến trúc mạnh mẽ và tối ưu hóa tối đa cho các hệ thống quang phổ thời gian thực.


## 4.2.2 Nghiên cứu cắt bỏ các thành phần của Denoise2Seg

Để đánh giá chi tiết đóng góp của từng thành phần vào cơ chế học hợp tác trong kiến trúc Denoise2Seg, nghiên cứu tiến hành phân tích cắt bỏ (ablation study) với các kết quả định lượng được trình bày tại Bảng 4.2.2.

Quá trình phân tích bắt đầu với mô hình cơ sở  $\mathcal{M}_1$ , chỉ sử dụng các khối trích xuất đặc trưng thuần túy (HFF blocks), đạt hiệu năng tổng thể ở mức 46.47% mIoU và 62.18% mAcc. Một hiện tượng suy thoái đáng chú ý đã xảy ra tại  $\mathcal{M}_2$ : khi nhánh khử nhiễu D<sup>2</sup> được tích hợp trực tiếp vào mạng mà không có sự hỗ trợ của chiến lược huấn luyện MSTS, hiệu năng của mô hình tụt dốc nghiêm trọng xuống chỉ còn 40.73% mIoU. Nguyên nhân cốt lõi của sự sụt giảm này là do mô hình phải đồng thời học hai tác vụ có bản chất khác biệt về khôi phục mức tín hiệu và phân loại ngữ nghĩa, dẫn đến hiện tượng xung đột gradient cực kỳ gay gắt. Các mục tiêu tối ưu hóa này liên tục kéo trọng số của bộ mã hóa dùng chung theo các hướng ngược nhau, làm suy yếu nghiêm trọng khả năng trích xuất đặc trưng của mạng.

Nút thắt này được tháo gỡ hoàn toàn trong mô hình  $\mathcal{M}_3$  nhờ sự can thiệp của chiến lược không gian tác vụ cụ thể, MSTS cung cấp cơ chế phân tách và điều phối không gian đặc trưng, giải phóng bộ mã hóa khỏi các xung đột đa tác vụ. Kết quả là hiệu năng không chỉ được phục hồi mà còn tăng trưởng mạnh mẽ, vượt lên mức 49.63% mIoU và 66.27% mAcc. Đặc biệt, sự tối ưu hóa luồng gradient này mang lại bước nhảy vọt về độ chính xác mà không yêu cầu phát sinh thêm bất kỳ tham số hay độ trễ nào so với  $\mathcal{M}_2$  (giữ nguyên 4.00M tham số và thời gian suy luận 18.2 ms).

Ở bước tiếp theo, sự hiện diện của mô-đun dung hợp ASTF trong mô hình  $\mathcal{M}_4$  đã thiết lập một bước tiến lớn, thúc đẩy mIoU tăng thêm 5.03% để đạt 54.66%. Mặc dù phải đánh đổi một



Hình 4.2.4: Nghiên cứu cắt bỏ chi tiết của HKANet: (a) tối ưu hóa cân bằng giữa hiệu năng và chi phí của các kernel HKA, với chú giải theo định dạng Mô hình – Tham số (M) – Tốc độ (ms) – mIoU (%); và đóng góp của từng mô-đun đối với (b) độ bền vững trước hiệu ứng Doppler, và (c) khả năng chống chịu trong điều kiện SNR thấp.

lượng nhỏ chi phí tính toán (thêm 0.34M tham số), ASTF đóng vai trò sống còn trong việc tinh lọc các đặc trưng không gian - thời gian, giúp mô hình bắt giữ chính xác các biến động của tín hiệu vô tuyến thay vì bị xao nhãng bởi nhiễu nền.

Cuối cùng, sự bổ sung của khối CSF đã hoàn thiện kiến trúc Denoise2Seg, mang lại mức cải thiện thêm 2.06% mIoU để chạm mốc hiệu năng đỉnh 56.72% mIoU và 70.48% mAcc. Điểm sáng giá nhất của CSF nằm ở hiệu quả phần cứng vượt trội: nó giúp mô hình chấp nổi các ngữ cảnh đa tỷ lệ để làm sắc nét ranh giới phân đoạn mà hoàn toàn không làm tăng thêm bất kỳ tham số nào (giữ vững ở mức 4.34M). Đồng thời, module này chỉ gây ra một mức tăng độ trễ cận biên là 1.1 ms trong thời gian suy luận (từ 19.5 ms lên 20.6 ms). Phân tích hệ thống này tái khẳng định rằng mỗi thành phần thiết kế trong Denoise2Seg đều mang lại những đóng góp độc lập, thiết yếu và được tối ưu hóa chặt chẽ nhằm giải quyết bài toán đánh đổi giữa độ chính xác và tính năng thời gian thực.

Bảng 4.2.3: Đánh giá ảnh hưởng của các thành phần kiến trúc và hàm mất mát trong ReSegNet

| Model           | DAS          | FiLM         | CIB          | Loss       | mAcc (%)     | mIoU (%)     | T/epoch (min) | Params (M) | Latency (ms) |
|-----------------|--------------|--------------|--------------|------------|--------------|--------------|---------------|------------|--------------|
| $\mathcal{M}_1$ | $\times$     | $\times$     | $\times$     | SUR        | 76.14        | 58.37        | 41.3          | 1.65       | 18.5         |
| $\mathcal{M}_2$ | $\checkmark$ | $\times$     | $\times$     | SUR        | 79.11        | 61.54        | <b>40.6</b>   | 1.65       | 18.5         |
| $\mathcal{M}_3$ | $\checkmark$ | $\checkmark$ | $\times$     | SUR        | 76.95        | 64.15        | 42.3          | 1.77       | 19.7         |
| $\mathcal{M}_4$ | $\checkmark$ | $\times$     | $\checkmark$ | SUR        | 78.59        | 63.60        | 51.8          | 1.71       | 20.0         |
| <b>ReSegNet</b> | $\checkmark$ | $\checkmark$ | $\checkmark$ | <b>SUR</b> | <b>79.56</b> | <b>66.45</b> | 55.5          | 1.83       | 20.5         |
| ReSegNet        | $\checkmark$ | $\checkmark$ | $\checkmark$ | CE         | 75.11        | 63.02        | 54.2          | 1.83       | 20.5         |
| ReSegNet        | $\checkmark$ | $\checkmark$ | $\checkmark$ | FL         | 64.75        | 53.65        | 49.7          | 1.83       | 20.5         |
| ReSegNet        | $\checkmark$ | $\checkmark$ | $\checkmark$ | DL         | 61.83        | 50.33        | 51.3          | 1.83       | 20.5         |


### 4.2.3 Nghiên cứu cắt bỏ các thành phần của ReSegNet

Đầu tiên, phân tích cắt bỏ tại Bảng 4.2.3 làm rõ đóng góp của ba cải tiến cốt lõi trong kiến trúc ReSegNet, cùng với các kết quả khảo sát siêu tham số tương ứng được thể hiện ở Hình 4.2.5.

Việc kích hoạt chương trình huấn luyện chủ động DAS trong  $\mathcal{M}_2$  giúp mIoU của mô hình cơ sở  $\mathcal{M}_1$  tăng mạnh từ 58.37% lên 61.54% mà không hề phát sinh đánh đổi về chi phí tính toán (thời gian huấn luyện mỗi epoch của hai mô hình lần lượt là 41.3 và 40.6 phút, sự chênh lệch nhỏ này hoàn toàn nằm trong biên độ nhiễu đo lường hệ thống). Mức tăng trưởng này đạt được nhờ sự phối hợp chặt chẽ giữa hai chính sách Tập trung (Focus) và Cường độ (Intensity), với cấu hình tối ưu được xác định tại Hình 4.2.5a là  $B = 8$  và  $k_{\text{max}} = 5$ . Nhằm đánh giá độc lập các mô-đun điều kiện hóa tiếp theo, FiLM ( $\mathcal{M}_3$ ) và CIB ( $\mathcal{M}_4$ ) được lần lượt tích hợp vào nền tảng  $\mathcal{M}_2$ . Như được minh họa qua các đường cong hiệu năng theo SNR tại Hình 4.2.5b, các mô-đun này nâng mIoU tổng thể lên tương ứng 64.15% và 63.60%, chủ yếu nhờ việc gia cố khả năng chống chịu ở môi trường nhiễu nặng. Cụ thể, chúng đã thúc đẩy hiệu năng tại mức nhiễu  $-10$  dB từ ngưỡng 37.85% (của  $\mathcal{M}_2$ ) lên lần lượt là 41.95% và 39.07%. Cuối cùng, khi kết hợp trọn vẹn các thành phần, kiến trúc ReSegNet hoàn chỉnh đạt mức mIoU tổng thể ấn tượng 66.45% bằng cách đồng thời tối đa hóa độ bền vững tại mức nhiễu cực đoan  $-10$  dB (đạt 42.17%) và phá vỡ nút thắt hiệu năng ở dải SNR cao (từ 10 dB trở lên), nơi mà các thành phần đơn lẻ thường bị bão hòa sớm quanh mức 66% – 67%.

Tiếp theo, nghiên cứu kiểm chứng tính ưu việt của hàm mất mát nhận thức cấu trúc bằng cách so sánh ReSegNet với các phiên bản huấn luyện bằng hàm mục tiêu tiêu chuẩn. Mô hình sử dụng SUR (đạt 66.45% mIoU) vượt trội hoàn toàn so với các biến thể dùng hàm CE (63.02%), Focal Loss (53.65%), và Dice Loss (50.33%). Đáng chú ý, sự vượt trội này đòi hỏi một mức đánh đổi tính toán gần như không đáng kể: thời gian huấn luyện mỗi epoch của SUR (55.5 phút) chỉ nhỉnh hơn đôi chút so với đường cơ sở CE (54.5 phút). Độ hiệu quả này xuất phát từ mức độ phức





Hình 4.2.5: Phân tích cắt bỏ và siêu tham số chi tiết của ReSegNet: (a) ảnh hưởng của các tham số DAS  $k_{\max}$  và  $B$ ; (b) đánh giá cắt bỏ kiến trúc dưới các mức SNR khác nhau; và (c, d) ảnh hưởng của các tham số SUR, bao gồm kích thước patch  $s$  và trọng số thành phần  $\lambda$ .

tập thực tế của SUR. Mặc dù độ phức tạp lý thuyết là  $\mathcal{O}(\mathbf{N} + |\mathcal{S}_2|h_p w_p)$ , thành phần  $\mathcal{O}(|\mathcal{S}_2|h_p w_p)$  đóng góp rất nhỏ vì tính đồng nhất của các mặt nạ ground-truth giữ cho tập hợp các vùng phức tạp  $\mathcal{S}_2$  luôn ở quy mô tối thiểu, giúp độ phức tạp tổng thể tiệm cận  $\mathcal{O}(\mathbf{N})$ .

Bên cạnh đó, phân tích siêu tham số tại Hình 4.2.5c tiến hành đánh giá các cấu hình hình học của patch cắt (patch geometries), vốn được thiết kế có hệ thống để đồng bộ với kiến trúc xử lý tín hiệu nền tảng. Việc chủ ý giới hạn tham số tỷ lệ  $s$  theo các lũy thừa của 2 đảm bảo sự căn chỉnh cấu trúc hoàn hảo với thuật toán Radix-2 FFT dùng để tạo ảnh phổ, đồng thời tích hợp mượt mà với hệ thống lấy mẫu xuống nhị phân của mạng nơ-ron. Hoạt động trong không gian tỷ lệ bị giới hạn toán học này, phân tích cắt bỏ đi sâu vào bản chất định hướng của tín hiệu vô tuyến bằng cách đối chiếu trực tiếp các patch hình vuông đẳng hướng với các dạng hình học định hướng cực đoan. Qua thực nghiệm, cấu hình dọc tối ưu  $h_p = 32 \times w_p = 1$  cho thấy khả năng cô lập các kênh tần số riêng lẻ khỏi sự pha trộn của nhiễu, đồng thời vẫn theo vết chính xác tính chu kỳ thời gian của chúng.

Song song đó, để đạt được đỉnh hiệu năng mIoU, mô hình đòi hỏi sự cân bằng chặt chẽ giữa bốn thành phần trọng số, như thể hiện tại Hình 4.2.5d:  $\lambda_{seg} = 0.3$ ,  $\lambda_{cmp} = 0.3$ ,  $\lambda_{\mu} = 1.5$ , và

Bảng 4.3.4: So sánh các phương pháp phân đoạn ảnh phổ tín hiệu

| Model           | Backbone    | mAcc (%)     | mIoU (%)     | Params (M)  | FLOPs (G) | Latency (ms) |
|-----------------|-------------|--------------|--------------|-------------|-----------|--------------|
| SegFormer [1]   | MiT_B2      | 58.81        | 37.55        | 24.72       | 5.3       | 23.4         |
| ESPNetv2 [2]    | —           | 57.37        | 39.49        | 1.49        | 0.7       | 20.3         |
| U-Net [33]      | MobileNetV2 | 59.12        | 43.97        | 4.70        | 2.7       | 18.4         |
| DeepLabV3+ [3]  | ResNet18    | 66.07        | 50.43        | 12.33       | 4.6       | 16.7         |
| UNet++ [4]      | ResNet18    | 67.58        | 54.40        | 15.97       | 16.1      | 17.2         |
| SRNet [34]      | ResNet18    | 69.47        | 55.84        | 19.35       | 26.9      | 17.1         |
| HKANet          | —           | 69.95        | 56.25        | 4.76        | 16.5      | 18.9         |
| Denoise2Seg [5] | —           | 70.48        | 56.72        | 4.34        | 7.2       | 20.6         |
| ReSegNet        | —           | <b>79.56</b> | <b>66.45</b> | <b>1.83</b> | 14.4      | 20.5         |


$\lambda_c = 1.1$ , trong đó  $\lambda_c$  và  $\lambda_\mu$  thể hiện độ nhạy cảm lớn nhất. Sự cải thiện hiệu năng rõ rệt vượt xa mức độ biến động này khẳng định vững chắc rằng các lợi ích đạt được xuất phát từ đặc tính của kiến trúc thay vì yếu tố khởi tạo ngẫu nhiên.

## 4.3 So sánh với các mô hình tiêu biểu

Để xác định vị thế của nghiên cứu, chúng tôi tiến hành đánh giá đối chuẩn ba mô hình đề xuất (HKANet, Denoise2Seg, và ReSegNet) với các kiến trúc phân đoạn ngữ nghĩa tiên tiến nhất hiện nay (state-of-the-art – SOTA). Mục tiêu trọng tâm của phần này là giải quyết động lực nghiên cứu đã đặt ra: tìm kiếm sự cân bằng tối ưu giữa chất lượng phân đoạn, độ bền vững trong môi trường nhiễu cực đoan và hiệu quả tính toán phần cứng. Kết quả định lượng tổng thể được thống kê tại Bảng 4.3.4, trong khi biến thiên hiệu năng theo dải nhiễu được minh họa trực quan tại Hình 4.3.6.

Phân tích từ Bảng 4.3.4 bộc lộ một thực tế rằng, việc áp dụng nguyên bản các kiến trúc thị giác máy tính vào tác vụ phân tích phổ vô tuyến sẽ dẫn đến sự thất bại do sai lệch về bản chất hình thái học của dữ liệu. Đầu tiên, các mô hình dựa trên nền tảng Transformer như SegFormer mang một điểm yếu chí mạng khi xử lý ảnh phổ: chúng ưu tiên việc tổng hợp ngữ cảnh không gian toàn cục thông qua cơ chế tự chú ý (self-attention). Tuy nhiên, phổ tín hiệu vô tuyến thường có đặc tính thưa thớt, hẹp và mang tính định hướng cục bộ rất cao. Cơ chế chú ý toàn cục của SegFormer đã vô tình "làm mịn" các ranh giới tín hiệu sắc nét này, hòa lẫn năng lượng tín hiệu vào nhiễu nền xung quanh. Sự không tương thích sâu sắc về mặt kiến trúc này là nguyên nhân cốt lõi khiến SegFormer có cấu trúc đồ sộ (24.72M tham số) nhưng lại bị đánh tụt hiệu năng xuống mức thấp nhất bảng, chỉ đạt 37.55% mIoU.

Mặt khác, trong nhóm các mô hình CNN truyền thống, chúng ta quan sát thấy một sự đánh



Hình 4.3.6: So sánh hiệu năng phân đoạn của HKANet, Denoise2Seg và ReSegNet với các mô hình SOTA theo tỷ số tín hiệu trên nhiễu (SNR).

đổi khác giữa kích thước phần cứng và độ chính xác. Các kiến trúc hướng tới thiết bị biên như ESPNetv2 hay U-Net MobileNetV2 duy trì được ưu thế cực kỳ tiết kiệm tài nguyên (chỉ từ 1.49M đến 4.70M tham số). Dẫu vậy, dung lượng trích xuất đặc trưng và trường nhìn (receptive field) quá mỏng manh của chúng không đủ sức mô hình hóa các biến động phức tạp của kênh truyền, khiến mIoU bị khóa chặt dưới ngưỡng 44%. Để bứt phá khỏi giới hạn này, các mạng lớn như DeepLabV3+ và UNet++ buộc phải sử dụng các mô-đun gộp không gian kim tự tháp ASPP hoặc mạng lưới kết nối tắt (dense skip connections) chằng chịt để nâng mIoU lên mốc 50.43% – 54.40%. Sự cải thiện này phải đánh đổi bằng một độ phức tạp hệ thống tăng vọt (hơn 12M tham số), khiến chúng khó có thể triển khai trên các hệ thống viễn thông nhúng.

Để giải quyết sự kém hiệu quả của mô hình đa dụng, các kiến trúc được thiết kế chuyên biệt cho miền RF như SRNet đã ra đời. Bằng việc khai thác các khối trích xuất sâu đa tỷ lệ trên nền tảng ResNet18, SRNet vươn lên dẫn đầu nhóm SOTA với mức hiệu năng 55.84% mIoU. Mặc dù vậy, cái giá phải trả là một hệ thống khổng lồ và trì trệ với 19.35M tham số và tiêu thụ tới 26.9 GFLOPs. Nghiêm trọng hơn cả rào cản phần cứng, bất chấp việc sở hữu hàng chục triệu tham số, các kiến trúc này (bao gồm cả SRNet) vẫn chưa giải quyết được rào cản vật lý lớn nhất: **chúng thiếu đi cơ chế bóc tách nhiễu chủ động**. Quan sát quỹ đạo hiệu năng tại Hình 4.3.6 minh chứng rõ điều này. Khi môi trường vô tuyến bị suy thoái nghiêm trọng xuống mức nhiễu  $-10$  dB, các bộ lọc tích chập tiêu chuẩn của SRNet bị nhiễu nền "đánh lừa" hoàn toàn. Ranh giới tín hiệu

bị phá vỡ, dẫn đến sự sụp đổ thể thảm của mô hình này xuống chỉ còn khoảng 38.88% mIoU. Điều này khẳng định rằng, các mạng nơ-ron phân đoạn thuần túy chỉ thực sự hoạt động tốt ở các điều kiện kênh truyền lý tưởng.

Nhận diện rõ những điểm nghẽn trí mạng về cả sự tương thích kiến trúc lẫn độ bền vững vật lý, ba mô hình trong nghiên cứu này mang đến những triết lý thiết kế mang tính giải pháp, hoàn toàn phá vỡ sự bế tắc của các mô hình đương nhiệm:

- **HKANet:** Thay vì sử dụng tích chập 2D công kênh như UNet++, HKANet thiết lập cơ chế trích xuất đặc trưng định hướng nghiêm ngặt thông qua các nhánh dị hướng HAB, VAB kết hợp cùng thống kê hiệp phương sai MCA. Nhờ tập trung đúng vào cấu trúc phổ thay vì dàn trải, HKANet đạt 56.25% mIoU, chính thức đánh bại mô hình chuyên dụng nặng nhất là SRNet (55.84%) trong khi thiết kế lại nhỏ gọn hơn tới 4.1 lần.
- **Denoise2Seg:** Phản hồi trực tiếp thách thức về sự sụp đổ hiệu năng đã phân tích ở trên, Denoise2Seg vươn lên trở thành kiến trúc chống chịu xuất sắc nhất. Khác với SOTA thường trộn lẫn thông tin tín hiệu và nhiễu ở các tầng nông, Denoise2Seg sử dụng nhánh  $D^2$  hoạt động song song như một lớp tiền xử lý chủ động. Cơ chế này cô lập thành công năng lượng vô tuyến khỏi nhiễu nền, giúp mạng giữ vững mIoU ở mức 51.87% ngay tại mốc  $-10$  dB – tạo ra một khoảng cách tuyệt đối, bỏ xa mức 38.88% của SRNet tới gần 13%.
- **ReSegNet:** Định hình lại tiêu chuẩn học thuật hiện tại, ReSegNet không giải quyết nhiễu bằng cách lọc, mà bằng cách chuyển đổi từ bài toán "phân loại từng pixel" dễ đổ vỡ sang quy trình "tái tạo tạo sinh" (generative reconstruction). Sự kết hợp giữa không gian tiềm ẩn nén ( $R = 8, Q = 16$ ) và hàm mất mát nhận thức cấu trúc SUR giúp mô hình không bị phụ thuộc vào điểm ảnh bị nhiễu, mà dựa vào tri thức hình dáng đã học được. Nhờ đó, ReSegNet thiết lập đỉnh SOTA tuyệt đối ở mức 66.45% mIoU, bỏ xa SRNet tới hơn 10.6%. Kiến trúc này gia tăng sức mạnh vượt trội trên mọi dải phổ: từ +3.29% ở  $-10$  dB lên tới mức áp đảo +11.7% ở 10 dB chỉ với một bộ khung vốn vụn 1.83M tham số.


## 4.4 Phân tích tính khả thi và ứng dụng thực tiễn

Để đánh giá tính khả thi khi đưa các mô hình vào hoạt động thực tế, Bảng 4.4.5 tóm tắt lại các chỉ số hiệu năng và chi phí cốt lõi của riêng ba kiến trúc đề xuất. Dữ liệu chỉ ra một sự phân hóa rõ nét: mỗi mô hình đều sở hữu ít nhất một đặc tính phần cứng vượt trội tuyệt đối, đáp ứng hoàn hảo cho từng giới hạn vật lý riêng biệt.

Biểu đồ đánh đổi hiệu năng và độ phức tạp tại Hình 4.4.7 minh họa trực quan sự ưu việt

Bảng 4.4.5: Tổng hợp các chỉ số hiệu năng và chi phí phần cứng cốt lõi của ba mô hình đề xuất

| Mô hình     | Chất lượng tổng thể (mIoU - %) | Độ bền vững tại nhiễu sâu -10 db (mIoU - %) | Hiệu quả tính toán |           |              |
|-------------|--------------------------------|---------------------------------------------|--------------------|-----------|--------------|
|             |                                |                                             | Params (M)         | FLOPs (G) | Latency (ms) |
| HKANet      | 56.25                          | 48.36                                       | 4.76               | 16.5      | 18.9         |
| Denoise2Seg | 56.72                          | 51.87                                       | 4.34               | 7.2       | 20.6         |
| ReSegNet    | 66.45                          | 42.17                                       | 1.83               | 14.4      | 20.5         |



Hình 4.4.7: Biểu đồ đánh đổi giữa độ phức tạp tính toán (GFLOPs), chất lượng phân đoạn (mIoU) và kích thước tham số mạng (độ lớn bong bóng).

này so với các kiến trúc SOTA. Kích thước của các bong bóng đại diện cho số lượng tham số, cho thấy ReSegNet, Denoise2Seg và HKANet hoàn toàn chiếm lĩnh nơi hội tụ của độ chính xác cao nhất và chi phí phần cứng thấp nhất. Dựa trên các chỉ số về kích thước, tốc độ và năng lượng tiêu thụ, ba mô hình được đánh giá khả thi cho ba kịch bản mạng đặc thù sau:

**Ứng dụng cho các hệ thống yêu cầu thời gian thực:** Trong các kịch bản khẩn khe như hệ thống xe tự lái hay radar kiểm soát không lưu, việc xử lý tín hiệu chậm trễ có thể gây ra hậu quả nghiêm trọng. Với tốc độ phản hồi nhanh nhất (chỉ 18.9 ms), **HKANet** là lựa chọn tối ưu. Mô hình có thể được tích hợp trực tiếp vào các thiết bị điều khiển trên xe, giúp hệ thống ra quyết định tránh nhiễu sóng ngay lập tức để đảm bảo an toàn di chuyển.

**Ứng dụng cho các thiết bị di động chạy pin:** Đối với mạng cảm biến không dây hoặc thiết bị bay không người lái, dung lượng pin là một hạn chế rất lớn. **Denoise2Seg** giải quyết hoàn hảo vấn đề này nhờ mức tiêu thụ điện toán thấp nhất (chỉ 7.2 GFLOPs). Đồng thời, khả năng duy trì độ chính xác cao (51.87% mIoU) trong môi trường nhiễu nặng (-10 dB) giúp thiết

bị hoàn thành tốt nhiệm vụ trình sát sóng mà không làm sập nguồn hay gây nóng máy.

**Ứng dụng cho các trạm thu phát sóng trung tâm:** Tại các trạm phát sóng di động, hệ thống thường phải xử lý cùng lúc hàng nghìn kết nối nên không gian lưu trữ bộ nhớ bị giới hạn, nhưng lại đòi hỏi độ chính xác tuyệt đối để cấp phát tài nguyên phổ. Với kích thước siêu nhỏ gọn (chỉ 1.83M tham số) nhưng đạt chất lượng cao nhất (66.45% mIoU), **ReSegNet** là lựa chọn hoàn hảo. Mô hình có thể chạy thường trực trên bộ nhớ đệm của các vi xử lý tại trạm gốc, cung cấp khả năng nhận diện tín hiệu cực kỳ sắc nét mà không gây quá tải hệ thống.

## Chương 5

# KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Chương cuối cùng này sẽ tổng kết lại những đóng góp cốt lõi và các giá trị thực tiễn mà luận văn đã đạt được trong quá trình giải quyết bài toán phân đoạn phổ vô tuyến. Bên cạnh đó, dựa trên việc nhìn nhận một cách khách quan những hạn chế còn tồn tại, chương cũng đề xuất các hướng nghiên cứu mở rộng trong tương lai nhằm tiếp tục hoàn thiện hệ thống.

### 5.1 Kết luận

Luận văn đã giải quyết một trong những thách thức cốt lõi của hệ thống thông tin vô tuyến hiện đại: sự đánh đổi khắt khe giữa độ chính xác phân đoạn, khả năng chống chịu nhiễu vật lý và giới hạn tài nguyên phần cứng. Thông qua việc phân tích điểm nghẽn của các kiến trúc học sâu đương nhiệm, nghiên cứu đã đề xuất và phát triển thành công ba mô hình phân đoạn ngữ nghĩa ảnh phổ mang tính đột phá, bao gồm HKANet, Denoise2Seg và ReSegNet. Bằng việc thay đổi tư duy thiết kế, hệ thống đề xuất đã chứng minh sự vượt trội toàn diện:

- **HKANet** tái định nghĩa cách tiếp cận trích xuất đặc trưng bằng cơ chế dự hướng nghiêm ngặt. Sự kết hợp giữa các nhánh học đặc trưng theo hướng và cơ chế phân tích hiệp phương sai đa kênh giúp mạng nắm bắt hoàn hảo cấu trúc hình học bất biến của phổ vô tuyến. Với thiết kế tối giản và tốc độ phản hồi siêu nhạy, HKANet trở thành giải pháp tối ưu cho các hệ thống yêu cầu thời gian thực cực thấp như xe tự lái hay radar hàng không.
- **Denoise2Seg** cung cấp một triết lý thiết kế xuất sắc để sinh tồn trong các môi trường kênh truyền khắc nghiệt nhất. Việc lồng ghép nhánh tiền xử lý khử nhiễu song song và cơ chế điều

phối không gian đa tác vụ giúp cô lập triệt để năng lượng vô tuyến khỏi nền nhiễu. Bằng việc giữ vững độ chính xác ngay cả khi tín hiệu bị suy thoái cực đoan với một mức chi phí tính toán vô cùng khiêm tốn, kiến trúc này định hình một tiêu chuẩn mới cho các thiết bị trình sát di động chạy pin như UAV hay nút cảm biến IoT.

- **ReSegNet** tạo ra bước nhảy vọt về mặt học thuật khi chuyển đổi bài toán phân loại điểm ảnh truyền thống sang tư duy tái tạo sinh. Sự cộng hưởng giữa việc giải mã từ không gian tiềm ẩn nén, cơ chế điều kiện hóa và hàm mục tiêu nhận thức cấu trúc giúp mô hình bứt phá mọi giới hạn, thiết lập nên đỉnh hiệu năng mới. Việc gói gọn khả năng phân đoạn xuất sắc này trong một hình hài cực kỳ nhỏ gọn biến ReSegNet thành khối vi xử lý lý tưởng để nhúng trực tiếp vào các trạm thu phát vô tuyến nhận thức.

Nhìn chung, công trình nghiên cứu này không chỉ đóng góp các giá trị cải tiến về mặt thuật toán mà còn hoàn thiện khung đánh giá khả thi, thu hẹp khoảng cách giữa lý thuyết mạng nơ-ron và khả năng triển khai thực tiễn trên các nền tảng phần cứng viễn thông.

## 5.2 Hướng phát triển

Mặc dù các kiến trúc đề xuất đã đạt được những thành tựu đáng kể, việc phân tích phổ vô tuyến trong môi trường thực tế vẫn luôn tồn tại những biến số phức tạp. Để tiếp tục hoàn thiện và nâng tầm hệ thống, các hướng nghiên cứu trong tương lai sẽ tập trung vào ba trọng tâm sau:

- Thử nghiệm với dữ liệu thu thập thực tế: Hiện tại, mô hình đang thể hiện hiệu năng xuất sắc trên các tập dữ liệu được mô phỏng theo chuẩn 3GPP. Bước tiến tiếp theo sẽ là đưa hệ thống vào thử nghiệm với các tập dữ liệu được thu thập trực tiếp ngoài trời. Việc đối mặt với các suy hao không thể đoán trước như hiệu ứng đa đường phi tuyến tính hoặc nhiễu đồng kênh thực tế sẽ giúp củng cố tính bền vững của các mô hình.
- Mở rộng hệ sinh thái giao thức vô tuyến: Hệ thống hiện tại đang tối ưu hóa cực tốt cho các tín hiệu radar, LTE và 5G NR. Trong tương lai, nghiên cứu sẽ mở rộng tập dữ liệu và tinh chỉnh mạng để nhận diện đa dạng các giao thức truyền thông khác, đặc biệt là các tín hiệu dân dụng phổ biến như Wi-Fi, Bluetooth, hoặc các giao thức IoT tầm xa băng hẹp như LoRa. Điều này sẽ giúp mô hình trở thành một công cụ giám sát phổ vạn năng.
- Tối ưu hóa cơ chế tạo sinh với mô hình nhất quán: Đối với kiến trúc ReSegNet, điểm yếu tiềm ẩn được ghi nhận là hiện tượng phân mảnh mất nét khi môi trường suy thoái ở các mức cực đoan dưới  $-10$  dB. Để khắc phục triệt để vấn đề này, hướng nghiên cứu tiếp theo sẽ xem xét việc tích hợp các mô hình tạo sinh thế hệ mới. Cụ thể, việc áp dụng các Mô hình Nhất quán, đặc biệt là cơ chế chiếu không gian tiềm ẩn lên mặt cầu, hứa hẹn sẽ mang lại



khả năng tái tạo hình thái tín hiệu sắc nét hơn trong nhiễu sâu, đồng thời vẫn duy trì được ưu điểm vượt trội về tốc độ lấy mẫu so với các mô hình khuếch tán truyền thống.

Tóm lại, những định hướng mở rộng này tập trung vào việc khắc phục các hạn chế còn tồn tại và đưa hệ thống tiến gần hơn với điều kiện vận hành thực tế. Nghiên cứu hy vọng rằng, các kết quả bước đầu đạt được trong luận văn sẽ cung cấp một tài liệu tham khảo hữu ích, góp một phần nhỏ vào quá trình phát triển các hệ thống giám sát phổ vô tuyến thông minh trong tương lai.

# CÔNG BỐ KHOA HỌC

## Bài báo thuộc tạp chí quốc tế SCI(E)

- **Ngoc-Hoang Mai**, Son Ngoc Truong, Daniel Benevides da Costa, Quoc Viet Pham, Thien Huynh-The, “Learning Spectral Structures: Efficient Segmentation via Hierarchical Kernel Attention,” *IEEE Wireless Communications Letters*, (SCI(E), Q1 JCR, IF: 5.1), (accepted).[link]
- Thien Huynh-The, **Ngoc-Hoang Mai**, Quoc-Viet Pham, Hai-Trang Phuoc Dang, “De-noise2Seg: A Deep Denoising-Segmentation Model for Interference-Resilient Spectrum Sensing,” *IEEE Wireless Communications Letters*, (SCI(E), Q1 JCR, IF: 5.5), (accepted).[link]
- Thien Huynh-The, **Ngoc-Hoang Mai**, Ngoc-Ha Truong, Nguyen Cong Luong, Dong In Kim, Dusit Niyato, “ReSegNet: A Reconstructive Consistency for High-Fidelity Spectrogram Segmentation,” *IEEE Transactions on Vehicular Technology*, (SCI(E), Q1 JCR, IF: 7.5), (revision submitted).

# TÀI LIỆU THAM KHẢO

- [1] E. Xie *et al.*, “SegFormer: Simple and efficient design for semantic segmentation with transformers,” in *Proc. NeurIPS*, vol. 34, Virtual, Oct. 2021, pp. 12 077–12 090.
- [2] S. Mehta *et al.*, “ESPNetv2: A light-weight, power efficient, and general purpose convolutional neural network,” in *Pro. CVPR*, Long Beach, CA, USA, Jun. 2019.
- [3] T. Huynh-The *et al.*, “Intelligent spectrum sensing with convnet for 5G and LTE signals identification,” in *Proc. SSP*, Hanoi, Vietnam, Jul. 2023, pp. 140–144.
- [4] Z. Zhou *et al.*, “UNet++: A nested U-Net architecture for medical image segmentation,” in *Proc. MICCAI*, Granada, Spain, Sep. 2018, pp. 3–11.
- [5] T. Huynh-The *et al.*, “Denoise2seg: A deep denoising-segmentation model for interference-resilient spectrum sensing,” *IEEE Wireless Commun. Lett.*, vol. 15, pp. 3119–3123, May 2026.
- [6] P. Jain *et al.*, “Dynamic and efficient spectrum utilization for 6G with THz, mmWave, and RF band,” *IEEE Trans. Veh. Technol.*, vol. 72, no. 3, pp. 3264–3273, Mar. 2023.
- [7] W. Chen *et al.*, “5G-advanced toward 6G: Past, present, and future,” *IEEE J. Sel. Areas Commun.*, vol. 41, no. 6, pp. 1592–1619, 2023.
- [8] M. Elloumi *et al.*, “Digital-twin-empowered interference management for multihop internet of vehicles networks over millimeter wave bands,” *IEEE Internet Things J.*, vol. 12, no. 11, pp. 17 807–17 827, Jun. 2025.
- [9] R. Liu *et al.*, “The ITU vision and framework for 6G: Scenarios, capabilities, and enablers,” *IEEE Veh. Technol. Mag.*, vol. 20, no. 2, pp. 114–122, Jun. 2025.
- [10] A. U. Khan *et al.*, “On spectral intelligence in 6G URLLC networks,” *IEEE Trans. Veh. Technol.*, vol. 74, no. 7, pp. 11 176–11 193, Jul. 2025.
- [11] X. Cao *et al.*, “AI-empowered multiple access for 6G: A survey of spectrum sensing, protocol designs, and optimizations,” *Proc. IEEE*, vol. 112, no. 9, pp. 1264–1302, Sep. 2024.

- [12] A. Tani *et al.*, “Facing the SNR wall detection in full duplex cognitive radio networks using a GLRT multipath-based detector,” *IEEE Trans. Wireless Commun.*, vol. 21, no. 5, pp. 3116–3130, May 2022.
- [13] Y. Lin *et al.*, “Blockchain-based byzantine-resilient dynamic spectrum sharing,” *IEEE Internet Things J.*, pp. 1–1, Sep. 2025.
- [14] R. Ahmed *et al.*, “Hybrid machine-learning-based spectrum sensing and allocation with adaptive congestion-aware modeling in CR-Assisted IoV networks,” *IEEE Internet Things J.*, vol. 9, no. 24, pp. 25 100–25 116, Aug. 2022.
- [15] S. Wang *et al.*, “A fast-convergence, induced dynamic spectrum access based on accelerated q-learning for cognitive radio networks,” *IEEE Trans. Veh. Technol.*, vol. 74, no. 9, pp. 13 925–13 937, Sep. 2025.
- [16] P. Liu *et al.*, “Joint transmitter design for robust secure radar-communication coexistence systems,” *IEEE Commun. Lett.*, vol. 28, no. 8, pp. 1775–1779, Aug. 2024.
- [17] H.-T. P. Dang *et al.*, “Compact spectrum sensing with RpNet+CLRu: Reducing model size for 5G-LTE signal identification,” *IEEE Trans. Veh. Technol.*, pp. 1–12, Oct. 2025.
- [18] T.-T. Le *et al.*, “Efficient spectrum sensing via a multi-scale dual-path segmentation network,” *IEEE Wirel. Commun. Lett.*, pp. 1–1, Apr. 2025.
- [19] H.-T. Nguyen *et al.*, “Resolution-preserving multi-scale network for 5G-LTE spectrogram-based spectrum sensing,” *IEEE Wireless Commun. Lett.*, vol. 14, no. 6, pp. 1673–1677, Jun. 2025.
- [20] K. Tekbıyık *et al.*, “Spectrum sensing and signal identification with deep learning based on spectral correlation function,” *IEEE Trans. Veh. Technol.*, vol. 70, no. 10, pp. 10 514–10 527, Oct. 2021.
- [21] L. Yang *et al.*, “Improved-SOMP algorithm based on principal component estimation for wideband spectrum sensing,” *IEEE Trans. Veh. Technol.*, vol. 74, no. 6, pp. 9932–9937, Jan. 2025.
- [22] G. Xu *et al.*, “Deep semi-supervised learning-based spectrum sensing at low SNR,” *IEEE Commun. Lett.*, vol. 28, no. 11, pp. 2558–2562, Nov. 2024.
- [23] Y. Li *et al.*, “Enhanced support vector machine for cooperative spectrum sensing against byzantine attack in cognitive wireless sensor networks,” *IEEE Sens. J.*, vol. 24, no. 23, pp. 39 835–39 844, Dec. 2024.
- [24] Z. Shi *et al.*, “Machine learning-enabled cooperative spectrum sensing for non-orthogonal multiple access,” *IEEE Trans. Wireless Commun.*, vol. 19, no. 9, pp. 5692–5702, May 2020.

- [25] D. Adesina *et al.*, “Adversarial machine learning in wireless communications using RF data: A review,” *IEEE Commun. Surv. Tutor.*, vol. 25, no. 1, pp. 77–100, 2023.
- [26] M. Temiz *et al.*, “Deep-learning-based techniques for integrated sensing and communication systems: State-of-the-art, challenges, and opportunities,” *IEEE Open J. Commun. Soc.*, vol. 6, pp. 5940–5968, Jul. 2025.
- [27] A. Vagollari *et al.*, “Joint detection and classification of RF signals using deep learning,” in *Proc. IEEE VTC2021-Spring.*, Helsinki, Finland, May 2021, pp. 1–7.
- [28] K. N. R. S. V. Prasad *et al.*, “A downscaled Faster-RCNN framework for signal detection and time-frequency localization in wideband RF systems,” *IEEE Trans. Wireless Commun.*, vol. 19, no. 7, pp. 4847–4862, Jul. 2020.
- [29] T. Anna *et al.*, “YOLO for radio frequency signal classification,” in *Proc. IEEE DySPAN 2024*, USA, May 2024, pp. 177–178.
- [30] S. Sarkar *et al.*, “RadYOLOLet: Radar detection and parameter estimation using YOLO and wavelet,” *IEEE Trans. Cognit. Commun. Networking*, pp. 1–1, Dec. 2024.
- [31] Z. Gao *et al.*, “Intelligent spectrum sensing of consumer IoT based on GAN-GRU-YOLO,” *IEEE Trans. Consum. Electron.*, vol. 70, no. 3, pp. 6140–6148, Aug. 2024.
- [32] W. Deng *et al.*, “Semantic-segmentation-based deep spectrum sensing for cochannel signals,” *IEEE Internet Things J.*, vol. 11, no. 23, pp. 37 645–37 660, Dec. 2024.
- [33] O. Ronneberger *et al.*, “U-net: Convolutional networks for biomedical image segmentation,” in *Proc. MICCAI*, Munich, Germany, Oct. 2015, pp. 234–241.
- [34] T. Huynh-The *et al.*, “SRNet: Deep semantic segmentation network for spectrum sensing in wireless communications,” *IEEE Wireless Commun. Lett.*, vol. 14, no. 2, pp. 355–359, Feb. 2025.
- [35] N. C. Luong *et al.*, “Advanced learning algorithms for integrated sensing and communication (ISAC) systems in 6G and beyond: A comprehensive survey,” *IEEE Commun. Surv. Tutor.*, pp. 1–1, Jul. 2025.
- [36] Z. Su *et al.*, “Signal enhancement aided end-to-end deep learning approach for joint denoising and spectrum sensing,” *IEEE Trans. Veh. Technol.*, vol. 73, no. 3, pp. 4424–4428, Mar. 2024.
- [37] N.-H. Mai, S. N. Truong, D. B. D. Costa, Q.-V. Pham, and T. Huynh-The, “Learning spectral structures: Efficient segmentation via hierarchical kernel attention,” *IEEE Wireless Communications Letters*, pp. 1–1, Jun. 2026.
- [38] C.-X. Wang *et al.*, “6g wireless communication systems: Applications, requirements, technologies, challenges, and research directions,” *IEEE Open J. Commun. Soc.*, vol. 1, pp. 957–975, Jul. 2020.

- [39] 3GPP, “Evolved Universal Terrestrial Radio Access (E-UTRA); User Equipment (UE) radio transmission and reception,” 3GPP, Technical Specification TS 36.101, Mar. 2023.
- [40] —, “Study on channel model for frequencies from 0.5 to 100 GHz,” 3rd Generation Partnership Project; Technical Specification Group Radio Access Network, Technical Report TR 38.901, Jan. 2023.
- [41] L. M. Hoang *et al.*, “Frequency hopping joint radar-communications with hybrid sub-pulse frequency and duration modulation,” *IEEE Wireless Commun. Lett.*, vol. 11, no. 11, pp. 2300–2304, Nov. 2022.
- [42] F. Restuccia and T. Melodia, “Deep learning at the physical layer: System challenges and applications to 5g and beyond,” *IEEE Communications Magazine*, vol. 58, no. 10, pp. 58–64, Nov. 2020.
- [43] M. Yan *et al.*, “Cooperative spectrum sensing with degan and kancnn for nonorthogonal multiple access,” *IEEE Sens. J.*, vol. 25, no. 14, pp. 27 265–27 277, Jun. 2025.
- [44] L. Cai *et al.*, “Spectrum sensing based on spectrogram-aware CNN for cognitive radio network,” *IEEE Wirel. Commun. Lett.*, vol. 11, no. 10, pp. 2135–2139, Oct. 2022.
- [45] H. Huang *et al.*, “Deep learning for physical-layer 5g wireless techniques: Opportunities, challenges and solutions,” *IEEE Wireless Commun.*, vol. 27, no. 1, pp. 214–222, Aug. 2020.
- [46] M. Sandler *et al.*, “Mobilenetv2: Inverted residuals and linear bottlenecks,” in *Proc. IEEE/CVF CVPR*, UT, USA, Jun. 2018, pp. 4510–4520.
- [47] D. Kingma *et al.*, “An introduction to variational autoencoders,” *Found. Trends Mach. Learn.*, vol. 12, no. 4, pp. 307–392, Nov. 2019.
- [48] Y. Song *et al.*, “Consistency models,” in *Proc. ICML*, Honolulu, Hawaii USA, Jul. 2023.
- [49] A. Paszke *et al.*, “Pytorch: An imperative style, high-performance deep learning library,” in *Proc. NeurIPS*, Dec. 2019.
- [50] D. Kingma and J. Ba, “Adam: A method for stochastic optimization,” in *Proc. ICLR*, Dec. 2014.