

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH
KHOA ĐIỆN ĐIỆN TỬ
BỘ MÔN ĐIỆN TỬ - THÔNG TIN



HCM-UTE

ĐỒ ÁN TỐT NGHIỆP

**NGHIÊN CỨU VÀ PHÁT TRIỂN MÔ HÌNH PHÂN ĐOẠN
PHỔ TÍN HIỆU 5G NR, LTE VÀ ASR DỰA TRÊN MẠNG
HỌC SÂU**

NGÀNH CÔNG HỆ THỐNG NHÚNG VÀ IOT

**Sinh viên: HUỲNH PHƯỚC LONG
MSSV: 22139037**

TP. Hồ Chí Minh – Tháng 06, 2026

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH
KHOA ĐIỆN ĐIỆN TỬ
BỘ MÔN KỸ THUẬT ĐIỆN TỬ – THÔNG TIN



HCM-UTE

ĐỒ ÁN TỐT NGHIỆP

**NGHIÊN CỨU VÀ PHÁT TRIỂN MÔ HÌNH PHÂN ĐOẠN
PHỔ TÍN HIỆU 5G NR, LTE VÀ ASR DỰA TRÊN MẠNG
HỌC SÂU**

NGÀNH CÔNG HỆ THỐNG NHÚNG VÀ IOT

**Sinh viên: HUỲNH PHƯỚC LONG
MSSV: 22139037**

GVHD: TS. Huỳnh Thế Thiện

TP. Hồ Chí Minh – Tháng 06, 2026

BẢN NHẬN XÉT KHÓA LUẬN TỐT NGHIỆP

(Dành cho giảng viên hướng dẫn)

Đề tài: NGHIÊN CỨU VÀ PHÁT TRIỂN MÔ HÌNH PHÂN ĐOẠN PHỔ TÍN HIỆU 5G NR, LTE VÀ ASR DỰA TRÊN MẠNG HỌC SÂU

Sinh viên: Huỳnh Phước Long

MSSV: 22139037

Hướng dẫn: TS. Huỳnh Thế Thiện

Nhận xét bao gồm các nội dung sau đây:

- Tính hợp lý trong cách đặt vấn đề và giải quyết vấn đề; ý nghĩa khoa học và thực tiễn:** Đề tài tiếp cận bài toán phân đoạn ngữ nghĩa ảnh phổ trong môi trường vô tuyến phức tạp (đồng tồn tại 5G NR, LTE và radar ASR). Đây là hướng nghiên cứu mang tính tiên phong, đón đầu xu hướng cảm nhận phổ thông minh cho thế hệ mạng 6G, mang giá trị khoa học và tính thời sự cao.
- Phương pháp thực hiện/ phân tích/ thiết kế:** Sinh viên có năng lực kiến trúc mô hình học sâu xuất sắc. Việc thiết kế thành công ba cấu trúc mạng biệt lập (ASTRA-Net, SpecDiff, ASTA-Net) với ba định hướng rõ ràng (ưu tiên tốc độ, chất lượng và sự cân bằng) thể hiện tư duy hệ thống tốt. Đặc biệt, việc ứng dụng mô hình khuếch tán tạo sinh (Latent Diffusion) vào xử lý ảnh phổ là một bước đột phá.
- Kết quả thực hiện/ phân tích và đánh giá kết quả/ kiểm định thiết kế:** Kết quả mô phỏng vô cùng thuyết phục thông qua các phân tích ablation study chi tiết. Các mô hình đề xuất đã chứng minh được sự vượt trội (về mIoU và mAcc) so với hàng loạt các kiến trúc State-of-the-Art hiện hành (SegFormer, UPerNet, DeepLabV3+) dưới các điều kiện nhiễu SNR và dịch Doppler khắc nghiệt.
- Kết luận và đề xuất:** Kết luận súc tích, bám sát các phát hiện từ dữ liệu thực nghiệm. Các đề xuất mở rộng đánh giá dữ liệu thu nhận từ phần cứng SDR (Software-Defined Radio) trong tương lai thể hiện tầm nhìn nghiên cứu sắc bén.
- Hình thức trình bày và bố cục báo cáo:** Cuốn khóa luận được trình bày chuyên nghiệp, chuẩn mực theo văn phong học thuật quốc tế. Các công thức toán học, lưu đồ kiến trúc mạng nơ-ron được minh họa sắc nét. Sinh viên đã tiếp thu và sửa chữa triệt để các lỗi chế bản nhỏ trước khi nộp bản cuối.
- Kỹ năng chuyên nghiệp và tính sáng tạo:** Sinh viên làm chủ hoàn toàn các nền tảng toán học phức tạp của AI và xử lý tín hiệu vô tuyến. Khả năng làm việc độc lập và lập trình các kiến trúc mạng sâu (Transformer, Diffusion) ở mức hiếm có đối với một kỹ sư bậc đại học.
- Tài liệu trích dẫn:** Tài liệu tham khảo phong phú, mang tính cập nhật cao nhất và được trích dẫn chuẩn xác theo định dạng IEEE.
- Đánh giá về sự trùng lặp của đề tài:** Đề tài mang tính độc lập hoàn toàn. Kết quả nghiên cứu cốt lõi đã được cộng đồng quốc tế công nhận thông qua 2 bài báo chuẩn SCIE Q1 xuất bản trên tạp chí IEEE Wireless Communications Letters.
- Những nhược điểm và thiếu sót, những điểm cần được bổ sung và chỉnh sửa:** Báo cáo không có khuyết điểm về mặt chuyên môn. Các lỗi định dạng nhỏ (typo) trong công thức tính toán độ chính xác và danh mục viết tắt đã được sinh viên rà soát và hiệu đính triệt để.
- Nhận xét tinh thần, thái độ học tập, nghiên cứu của sinh viên:** Thái độ làm việc khoa học, nghiêm túc và say mê nghiên cứu. Sinh viên sở hữu tiềm năng nghiên cứu vượt trội để phát triển ở các bậc học cao hơn (Thạc sĩ/Tiến sĩ).

Đề nghị của giảng viên hướng dẫn:

Báo cáo hoàn toàn đạt yêu cầu của một khóa luận tốt nghiệp kỹ sư, và được phép bảo vệ khóa luận tốt nghiệp trước Hội đồng.

Tp. HCM, ngày 23 tháng 06 năm 2026

Người nhận xét

(Ký và ghi rõ họ tên)

TS. Huỳnh Thế Thiện

Lời Cam Đoan

Tôi là Huỳnh Phước Long, mã số sinh viên 22139037, sinh viên ngành Hệ thống nhúng và IoT, Khoa Điện - Điện tử, Trường Đại học Công nghệ Kỹ thuật TP.HCM. Tôi xin cam đoan khóa luận tốt nghiệp này là công trình nghiên cứu độc lập do chính tôi thực hiện. Toàn bộ nội dung và kết quả trong báo cáo là thành quả làm việc của cá nhân tôi, tuyệt đối không sao chép hay vay mượn từ bất kỳ đồ án, bài báo hoặc tài liệu nào đã được công bố trước đó.

Tôi khẳng định mọi số liệu và thông tin trình bày trong khóa luận đều hoàn toàn xác thực, khách quan. Các nguồn tài liệu tham khảo đều được tôi trích dẫn rõ ràng, đầy đủ và tuân thủ đúng quy chuẩn học thuật của Nhà trường. Dù đã nỗ lực hết sức, báo cáo chắc chắn khó tránh khỏi những hạn chế và sai sót nhất định do giới hạn về mặt kiến thức, tôi rất mong nhận được sự thông cảm từ quý Thầy Cô. Tôi xin chịu hoàn toàn trách nhiệm về lời cam đoan này và chấp nhận mọi hình thức xử lý kỷ luật nếu bị phát hiện có bất kỳ hành vi gian lận nào.

Người thực hiện tiểu luận
(Ký và ghi rõ họ tên)

Huỳnh Phước Long

Lời Cảm Tạ

Tôi xin gửi lời cảm ơn chân thành đến quý Thầy Cô và bạn bè ngành Hệ thống nhúng và IoT, Khoa Điện - Điện tử, Trường Đại học Công nghệ Kỹ thuật TP.HCM đã hỗ trợ tôi thực hiện khóa luận này. Đặc biệt, tôi xin tri ân sâu sắc Thầy Huỳnh Thế Thiện, người đã trực tiếp hướng dẫn và theo sát tôi suốt thời gian qua. Chính những định hướng chuyên môn, lộ trình nghiên cứu rõ ràng và sự chỉ bảo tận tình của Thầy từ những bước đầu tiên đã giúp tôi định hình tư duy và tìm ra phương pháp giải quyết đề tài một cách hiệu quả nhất.

Dù đã nỗ lực hoàn thiện, song do giới hạn về kiến thức và kinh nghiệm, khóa luận chắc chắn vẫn còn những thiếu sót. Tôi rất mong nhận được những đánh giá khách quan và góp ý thẳng thắn từ quý Thầy Cô. Những nhận xét này sẽ là cơ sở quý báu để tôi nhìn nhận lại vấn đề, khắc phục hạn chế và tiếp tục nâng cao năng lực chuyên môn trong tương lai. Xin chân thành cảm ơn!

TÓM TẮT

Trong bối cảnh các hệ thống vô tuyến hiện đại ngày càng phát triển, nhu cầu sử dụng phổ tần trở nên dày đặc hơn do sự cùng tồn tại của nhiều công nghệ truyền thông và radar. Các tín hiệu như tín hiệu vô tuyến mới thế hệ thứ năm (fifth-generation new radio, 5G NR), tiến hóa dài hạn (long-term evolution, LTE), radar giám sát hàng không (air surveillance radar, ASR) có thể xuất hiện đồng thời trong cùng một môi trường phổ, gây ra hiện tượng chồng lấn trong miền thời gian–tần số. Điều này làm cho bài toán cảm biến phổ trở nên phức tạp hơn, đặc biệt trong các điều kiện có nhiễu nền mạnh, fading đa đường, dịch Doppler hoặc khi tín hiệu có biên không rõ ràng. Các phương pháp cảm biến phổ truyền thống thường gặp hạn chế trong việc phân biệt chính xác từng vùng tín hiệu, do chủ yếu dựa trên các đặc trưng thủ công hoặc các tiêu chí phát hiện đơn giản. Vì vậy, việc phát triển các mô hình học sâu có khả năng phân đoạn ảnh phổ ở cấp pixel là một hướng nghiên cứu cần thiết nhằm hỗ trợ quản lý và sử dụng phổ tần hiệu quả hơn. Luận văn này tiếp cận bài toán cảm biến phổ thông minh dưới dạng bài toán phân đoạn ngữ nghĩa ảnh phổ. Tín hiệu vô tuyến được chuyển sang biểu diễn thời gian–tần số để tạo ảnh phổ, từ đó đưa bài toán nhận dạng tín hiệu về dạng phân đoạn ảnh ở cấp pixel. Trên ảnh phổ, mỗi điểm ảnh được gán nhãn tương ứng với một trong các lớp tín hiệu gồm 5G NR, LTE, ASR và Noise. Cách tiếp cận này cho phép hệ thống không chỉ nhận biết sự tồn tại của tín hiệu, mà còn xác định chi tiết vùng chiếm dụng phổ của từng loại tín hiệu theo thời gian và tần số. Trọng tâm của luận văn là thiết kế và đánh giá các mô hình học sâu chuyên biệt cho ảnh phổ, nhằm đạt được sự cân bằng giữa độ chính xác phân đoạn, tốc độ suy luận và chi phí tính toán.

Đóng góp đầu tiên của luận văn là mô hình mạng chú ý không gian–thời gian nhẹ thích nghi (ASTRA-Net), được thiết kế theo hướng gọn nhẹ và hiệu quả tính toán cho bài toán phân đoạn ảnh phổ. Mô hình này tập trung vào việc trích xuất các đặc trưng phổ quan trọng trong khi vẫn kiểm soát số lượng tham số, số lượng phép toán dấu phẩy động (FLOPs) và thời gian suy luận. ASTRA-Net phù hợp với các kịch bản yêu cầu xử lý nhanh hoặc triển khai trên các hệ thống có tài nguyên hạn chế. Kết quả thực nghiệm cho thấy ASTRA-Net đạt 69.42% mAcc và 55.36% mIoU, với 6.0M tham số, 3.89G FLOPs và thời gian suy luận 2.36 ms. So với nhiều mô hình phân đoạn tiên tiến, ASTRA-Net đạt hiệu năng cao hơn trong khi có chi phí tính toán thấp hơn, cho thấy tiềm năng của các kiến trúc nhẹ trong cảm biến phổ thông minh.

Đóng góp thứ hai là mô hình khuếch tán phân đoạn ảnh phổ (SpecDiff), một mô hình phân đoạn ảnh phổ theo hướng tạo sinh. Khác với các kiến trúc phân đoạn thông thường chỉ dựa trên

quá trình ánh xạ trực tiếp từ ảnh phổ sang bản đồ nhân, SpecDiff khai thác biểu diễn tiềm ẩn và cơ chế tinh chỉnh đặc trưng để cải thiện chất lượng tái tạo bản đồ phân đoạn. Hướng tiếp cận này đặc biệt hữu ích trong các trường hợp tín hiệu bị nhiễu, vùng phổ bị chồng lấn hoặc biên tín hiệu không rõ ràng. Kết quả thực nghiệm cho thấy SpecDiff đạt hiệu năng cao nhất trong ba mô hình được đề xuất, với 75.18% mAcc và 61.35% mIoU. Mô hình sử dụng 12.0M tham số, 12.25G FLOPs và có thời gian suy luận 8.60 ms. Kết quả này cho thấy các mô hình tạo sinh có tiềm năng đáng kể trong việc khôi phục cấu trúc vùng tín hiệu và nâng cao chất lượng phân đoạn ảnh phổ. Đồng thời, đây cũng là cơ sở để mở rộng nghiên cứu sang các hướng như diffusion models, rectified flow, flow matching hoặc các mô hình tạo sinh có số bước suy luận thấp hơn trong tương lai.

Đóng góp thứ ba là mạng hợp nhất chú ý không gian-thời gian thích nghi (ASTA-Net), một mô hình được phát triển nhằm cân bằng giữa hiệu năng phân đoạn và chi phí tính toán. ASTA-Net khai thác đồng thời các đặc trưng cục bộ, thông tin ngữ cảnh và cấu trúc không gian của ảnh phổ, qua đó cải thiện khả năng phân biệt giữa các lớp tín hiệu có hình thái gần nhau. Mô hình này đạt 72.59% độ chính xác trung bình (mAcc) và 58.10% chỉ số giao trên hợp trung bình (mIoU), với 11.0M tham số, 6.34G FLOPs và thời gian suy luận 5.06 ms. So với ASTRA-Net, ASTA-Net cải thiện đáng kể chất lượng phân đoạn, trong khi vẫn duy trì chi phí tính toán ở mức hợp lý. So với SpecDiff, ASTA-Net có hiệu năng thấp hơn nhưng có độ trễ và FLOPs thấp hơn, cho thấy vai trò của mô hình này như một lựa chọn cân bằng giữa độ chính xác và hiệu quả triển khai.

Các mô hình được đánh giá thông qua nhiều nhóm thí nghiệm khác nhau nhằm phân tích toàn diện hiệu năng trong các điều kiện hoạt động phức tạp. Trước hết, các thí nghiệm theo mức SNR cho thấy khi nhiễu nền giảm, cả mAcc và mIoU của các mô hình đều được cải thiện rõ rệt. Tuy nhiên, ở vùng SNR cao, tốc độ cải thiện bắt đầu giảm, cho thấy hiệu năng của mô hình dần bị giới hạn bởi các yếu tố khác như độ phân giải ảnh phổ, sự chồng lấn giữa các tín hiệu và năng lực biểu diễn của kiến trúc. Tiếp theo, các thí nghiệm theo dịch Doppler cho thấy khi Doppler tăng, đặc biệt ở các mức 70 Hz và 500 Hz, hiệu năng tại các mức SNR thấp bị suy giảm đáng kể do cấu trúc phổ bị biến dạng. Ngoài ra, phân tích theo kích thước ảnh phổ cho thấy kích thước 256×256 là lựa chọn cân bằng giữa độ chi tiết và chi phí tính toán, trong khi việc tăng lên 512×512 chỉ mang lại mức cải thiện hạn chế. Ma trận nhầm lẫn cũng cho thấy các lớp như LTE và Noise vẫn là những lớp dễ nhầm lẫn hơn do đặc trưng phổ có thể bị suy yếu hoặc chồng lấn trong điều kiện nhiễu. So sánh với các mô hình phân đoạn tiên tiến như Twins, SegFormer, SegNeXt, DeepLabV3+, DPSEgNet, PRMNet, SRNet, UNet++ và UPerNet cho thấy các mô hình đề xuất đạt kết quả cạnh tranh hơn cả về độ chính xác và hiệu quả tính toán. ASTRA-Net là mô hình có tốc độ nhanh nhất và chi phí thấp nhất trong ba mô hình đề xuất. SpecDiff đạt chất lượng phân đoạn cao nhất, đặc biệt ở mAcc và mIoU. ASTA-Net thể hiện sự cân bằng tốt giữa hiệu năng và chi phí tính toán. Như vậy, ba mô hình đề xuất tạo thành ba lựa chọn phù hợp với các yêu cầu triển khai khác nhau: ASTRA-Net cho các hệ thống ưu tiên tốc độ, SpecDiff cho các kịch bản ưu tiên chất lượng phân đoạn, và ASTA-Net cho sự cân bằng giữa độ chính xác và hiệu quả xử lý.

Mục Lục

TÓM TẮT	iii
1 TỔNG QUAN	1
1.1 GIỚI THIỆU	1
1.2 MỤC TIÊU	5
1.3 PHƯƠNG PHÁP NGHIÊN CỨU	7
1.4 GIỚI HẠN NGHIÊN CỨU	12
1.5 BỐ CỤC	13
2 CƠ SỞ LÝ THUYẾT	14
2.1 LÝ THUYẾT VỀ TÍN HIỆU 5G NR–LTE–ASR	14
2.1.1 Mô hình tín hiệu thu trong môi trường đồng tồn tại	14
2.1.2 Tổng quan về tín hiệu LTE	16
2.1.3 Tổng quan về tín hiệu 5G NR	18
2.1.4 Tổng quan về tín hiệu radar ASR	20
2.2 LÝ THUYẾT VỀ PHÂN TÍCH THỜI GIAN–TẦN SỐ	23
2.2.1 Hạn chế của phân tích miền thời gian và miền tần số	24
2.2.2 Biến đổi Fourier thời gian ngắn	24
2.2.3 Ảnh phổ của tín hiệu vô tuyến	25
2.2.4 So sánh tổng quan giữa các kỹ thuật phân tích thời gian–tần số	26
2.3 TỔNG QUAN VỀ LÝ THUYẾT HỌC SÂU	28
2.3.1 Khái niệm cơ bản về học sâu	28
2.3.2 Mạng nơ-ron tích chập	29
2.3.3 Mạng nơ-ron tích chập tách biệt theo chiều sâu	30
2.4 PHÂN ĐOẠN NGŨ NGHĨA TRONG THỊ GIÁC MÁY TÍNH	32
2.4.1 Khái niệm phân đoạn ngữ nghĩa	32
2.5 TỔNG QUAN VỀ CÁC MẠNG HỌC SÂU TRONG PHÂN ĐOẠN NGŨ NGHĨA HÌNH ẢNH	33
2.5.1 U-Net++	33
2.5.2 DeepLabV3+	35
2.5.3 SegFormer	36
2.5.4 So sánh tổng quan giữa các kiến trúc mạng phân đoạn ngữ nghĩa	38

3	THIẾT KẾ MÔ HÌNH MẠNG HỌC SÂU CHO PHÂN ĐOẠN ẢNH PHỔ	40
3.1	TỔNG QUAN BÀI TOÁN VÀ HỆ THỐNG CẢM NHẬN PHỔ THÔNG MINH	40
3.2	YÊU CẦU THIẾT KẾ MÔ HÌNH ĐỀ XUẤT CHO PHÂN ĐOẠN ẢNH PHỔ	41
3.3	ĐỊNH HƯỚNG THIẾT KẾ CÁC MÔ HÌNH ĐỀ XUẤT	43
3.4	MÔ HÌNH ƯU TIÊN TỐC ĐỘ Suy Luận - ASTRA-Net	44
3.4.1	Đường dẫn nhận thức động (Dynamic Perception Path - DP)	45
3.4.2	Đường dẫn phổ-thời gian (Spectro-Temporal Path - ST)	48
3.4.3	Đầu ra phân đoạn của ASTRA-Net	50
3.4.4	Hàm mất mát huấn luyện	51
3.5	MÔ HÌNH TỐI ƯU HIỆU SUẤT - SpecDiff	51
3.5.1	Cơ sở khuếch tán trong không gian tiềm ẩn	52
3.5.2	Ánh xạ không gian tiềm ẩn và tái tạo mặt nạ phân đoạn	53
3.5.3	Mạng dự đoán nhiễu có điều kiện	54
3.5.4	Hàm mất mát huấn luyện	57
3.6	MÔ HÌNH CÂN BẰNG HIỆU SUẤT - ASTA-Net	58
3.6.1	Bộ mã hóa Transformer với chú ý tự cộng	59
3.6.2	Đường tổng hợp mẫu tín hiệu	61
3.6.3	Đường tinh chỉnh không gian	62
3.6.4	Hợp nhất cộng hưởng đa luồng	63
3.6.5	Hàm mất mát huấn luyện	64
3.6.6	Tóm tắt vai trò của ASTA-Net	65
3.7	CÀI ĐẶT MÔ PHỎNG	65
3.7.1	Tạo bộ dữ liệu tín hiệu mô phỏng	65
3.7.2	Cấu hình huấn luyện	66
3.7.3	Phương pháp và tiêu chí đánh giá	66
4	KẾT QUẢ VÀ THẢO LUẬN	68
4.1	Phân tích nghiên cứu cắt bỏ của các mô hình đề xuất	68
4.1.1	Phân tích nghiên cứu cắt bỏ của ASTRA-Net	68
4.1.2	Phân tích nghiên cứu cắt bỏ của SpecDiff	70
4.1.3	Phân tích nghiên cứu cắt bỏ và các siêu tham số trong ASTA-Net	72
4.2	Phân tích lỗi phân đoạn bằng ma trận nhầm lẫn	77
4.3	Hiệu năng phân đoạn dưới các điều kiện kênh truyền	79
4.3.1	Sự bền vững của mô hình trong môi trường nhiễu	79
4.3.2	Ảnh hưởng đồng thời của dịch Doppler và SNR đến độ chính xác phân đoạn	81
4.3.3	Chi tiết số liệu hiệu năng dưới tác động của nhiễu SNR và Doppler	82
4.4	Ảnh hưởng của kích thước ảnh phổ đối với hiệu suất mô hình	83
4.4.1	Chi tiết số liệu hiệu năng và tốc độ suy luận theo độ phân giải	84
4.5	So sánh các mô hình đề xuất với các mô hình phân đoạn tiên tiến	84

5 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	89
5.1 KẾT LUẬN	89
5.2 HƯỚNG PHÁT TRIỂN	91
CÔNG BỐ KHOA HỌC	99

Danh sách hình

2.1	Kiến trúc tổng quan của mạng LTE [1].	16
2.2	Kiến trúc tổng quan của hệ thống 5G NR [2].	18
2.3	Kiến trúc tổng quan của hệ thống radar giám sát hàng không ASR.	21
2.4	Minh họa quá trình biến đổi Fourier thời gian ngắn để tạo biểu diễn thời gian–tần số.	25
2.5	Cấu trúc cơ bản của mạng nơ-ron sâu gồm lớp đầu vào, các lớp ẩn và lớp đầu ra.	29
2.6	Minh họa quá trình trích xuất đặc trưng bằng các bộ lọc trong mạng CNN.	29
2.7	Minh họa tích chập theo chiều sâu và tích chập điểm.	31
2.8	Ví dụ về bài toán phân đoạn ngữ nghĩa.	32
2.9	Kiến trúc tổng quan của U-Net và U-Net++.	34
2.10	Kiến trúc tổng quan của mạng DeepLabV3+.	35
2.11	Kiến trúc tổng quan của mạng SegFormer.	37
3.1	Tổng quan về hệ thống cảm nhận phổ thông minh.	41
3.2	Một số ảnh phổ từ bộ dữ liệu	42
3.3	Kiến trúc tổng quan của mô hình ASTRA-Net.	44
3.4	Cấu trúc của khối chọn lọc phổ động (Dynamic Selective Spectrum Layer - DSSL).	45
3.5	Cơ chế tính điểm chú ý trong khối DSSL.	46
3.6	Cấu trúc của bộ chất lọc phổ thích nghi (Adaptive Spectrum Distiller - ASD).	47
3.7	Các khối xử lý trong đường dẫn phổ–thời gian.	48
3.8	Kiến trúc tổng quan của mô hình SpecDiff.	52
3.9	Minh họa tiến trình khử nhiễu ngược trong mô hình khuếch tán.	53
3.10	Ánh xạ không gian tiềm ẩn và tái tạo mặt nạ phân đoạn trong SpecDiff.	55
3.11	Mạng dự đoán nhiễu với đường dẫn đặc trưng điều kiện trong SpecDiff.	56
3.12	Kiến trúc tổng quan của mô hình ASTA-Net.	59
3.13	Mối liên kết giữa bộ mã hóa Transformer và khối tự chú ý cộng (ASA) trong ASTA-Net.	60
3.14	Đường tổng hợp mẫu tín hiệu (PS path) và mô-đun ngữ cảnh cục bộ (LCM) trong ASTA-Net.	61
3.15	Cấu trúc đường tinh chỉnh không gian (SR path) và mô-đun tinh chỉnh không gian (SRM) trong ASTA-Net.	62
3.16	Kiến trúc tổng quan của cộng hưởng đa luồng trong ASTA-Net.	63
4.1	Phân tích độ nhảy của các siêu tham số trong ASTA-Net.	75

4.2	So sánh ảnh hưởng của các hàm mất mát phụ trong ASTA-Net theo các mức SNR.	76
4.3	Ma trận nhầm lẫn của ASTRA-Net, ASTA-Net và SpecDiff.	78
4.4	So sánh mAcc và mIoU của ASTRA-Net, ASTA-Net và SpecDiff theo các mức SNR khác nhau.	80
4.5	So sánh mAcc và mIoU của ASTRA-Net, ASTA-Net và SpecDiff theo các mức SNR tại các mức dịch Doppler khác nhau.	81
4.6	Ảnh hưởng của kích thước ảnh phổ đến mAcc và mIoU của ASTRA-Net, ASTA-Net và SpecDiff.	83
4.7	Qualitative comparison between SpecDiff segmentation results and the corresponding ground truths at different SNR levels: (a) -10 dB, (b) 0 dB, (c) 10 dB, (d) 20 dB and (e) 30 dB.	87

Danh sách bảng

2.1	Tóm tắt một số kỹ thuật phân tích tín hiệu trong miền thời gian–tần số.	27
3.1	Các tham số sinh dữ liệu và cấu hình dạng sóng mô phỏng.	66
4.1	Bảng nghiên cứu cắt bỏ thành phần của ASTRA-Net.	69
4.2	Bảng nghiên cứu cắt bỏ thành phần của SpecDiff.	71
4.3	Bảng nghiên cứu cắt bỏ thành phần của ASTA-Net.	73
4.4	Phân tích độ nhạy của siêu tham số.	77
4.5	Phân tích ablation của các hàm mất mát phụ.	77
4.6	Đánh giá hiệu suất của các mô hình theo môi trường nhiễu	82
4.7	Phân tích ảnh hưởng của độ phân giải hình ảnh đến hiệu suất của các mô hình (Hình 4.6)	84
4.8	Performance Comparison with State of the Art Semantic Segmentation Models . .	85

Danh sách các từ viết tắt

Các từ viết tắt	Định nghĩa
5G	Fifth-Generation
NR	New Radio
6G	Sixth-Generation
AM	Attention Mechanism
ASR	Air Surveillance Radar
ASTA-Net	Mạng hợp nhất chú ý không gian–thời gian thích nghi
ASTRA-Net	Mạng chú ý không gian–thời gian nhẹ thích nghi
CNN	Convolutional Neural Network
CR	Cognitive Radio
CWT	Continuous Wavelet Transform
DL	Deep Learning
FLOPs	Floating-Point Operations
I/Q	In-Phase and Quadrature
LSTM-CNN	Long Short-Term Memory - Convolutional Neural Network
mAcc	Mean Accuracy
mIoU	Mean Intersection Over Union
Mix-FFN	Mixed Feed-Forward Network
PU	Primary User
SNR	Signal-to-Noise Ratio
SpecDiff	Mô hình khuếch tán phân đoạn ảnh phổ
SS	Spectrum Sensing
STFT	Short-Time Fourier Transform
SU	Secondary User
UE	User Equipment
VAE	Variational Autoencoder
WVD	Wigner-Ville Distribution

Chương 1

TỔNG QUAN

1.1 GIỚI THIỆU

Trong những năm gần đây, sự phát triển nhanh chóng của các hệ thống thông tin không dây đã làm gia tăng đáng kể nhu cầu sử dụng tài nguyên phổ vô tuyến. Sự mở rộng của mạng thông tin di động thế hệ thứ năm (fifth-generation, 5G), định hướng mạng thông tin di động thế hệ thứ sáu (sixth-generation, 6G), Internet vạn vật, truyền thông xe tự hành và các hệ thống tích hợp cảm nhận–truyền thông khiến môi trường phổ trở nên đông đúc hơn so với các thế hệ mạng trước đây [3]. Bên cạnh chức năng truyền dữ liệu, các hệ thống 6G còn hướng đến khả năng cảm nhận môi trường, định vị và hỗ trợ các tác vụ trí tuệ nhân tạo tại biên [4]. Vì vậy, phổ tần không chỉ là tài nguyên phục vụ truyền thông, mà còn là không gian quan sát quan trọng cho các ứng dụng cảm nhận vô tuyến thông minh [5]. Trong bối cảnh đó, cảm nhận phổ (spectrum sensing, SS) giữ vai trò nền tảng trong việc theo dõi trạng thái chiếm dụng phổ và hỗ trợ khai thác phổ linh hoạt. Các khảo sát gần đây về vô tuyến nhận thức (cognitive radio, CR) cho thấy học máy và học sâu đang trở thành các công cụ quan trọng để nâng cao khả năng nhận biết trạng thái phổ trong các mạng không dây hiện đại [6]. Khác với các hệ thống phổ cố định, môi trường phổ động yêu cầu thiết bị phải nhận biết được tín hiệu đang xuất hiện, vùng phổ đang bị chiếm dụng và mức độ tin cậy của thông tin quan sát [7]. Điều này đặc biệt quan trọng đối với truy cập phổ động (dynamic spectrum access, DSA), nơi người dùng thứ cấp (secondary user, SU) chỉ có thể khai thác phổ khi không gây can nhiễu có hại đến người dùng đang được ưu tiên (primary user, PU) [8]. Một đặc điểm nổi bật của các mạng vô tuyến thế hệ mới là sự đồng tồn tại giữa hệ thống truyền thông và radar. Các nghiên cứu về cảm nhận và truyền thông tích hợp cho thấy việc chia sẻ tài nguyên giữa radar và truyền thông là một hướng phát triển quan trọng trong các hệ thống 5G và 6G nâng cấp [9]. Tuy nhiên, sự chia sẻ này cũng làm cho môi trường vô tuyến trở nên phức tạp hơn vì nhiều dạng tín hiệu dị thể có thể cùng xuất hiện trong một vùng quan sát [10]. Các

mô hình đồng tồn tại radar–truyền thông cho thấy tín hiệu truyền thông và radar có thể gây can nhiễu lẫn nhau nếu hệ thống không có khả năng nhận biết chính xác trạng thái phổ [11]. Do đó, cảm nhận phổ trong bối cảnh hiện đại không chỉ cần phát hiện sự tồn tại của tín hiệu, mà còn cần phân biệt được nhiều lớp tín hiệu khác nhau trong miền thời gian–tần số.

Trong phạm vi của khóa luận này, bài toán được đặt trong kịch bản có sự cùng tồn tại giữa tín hiệu vô tuyến mới thế hệ thứ năm (fifth-generation new radio, 5G NR), tiến hóa dài hạn (long-term evolution, LTE), radar giám sát hàng không (air surveillance radar, ASR) và nhiễu nền. Các tín hiệu 5G NR và LTE thường có cấu trúc đa sóng mang, phân bố năng lượng trên nhiều thành phần tần số và có thể chiếm dụng vùng phổ rộng. Trong khi đó, tín hiệu ASR thường có dạng xung, xuất hiện gián đoạn theo thời gian và tạo nên các vùng năng lượng có hình thái khác biệt trên ảnh phổ. Các khảo sát về tín hiệu tích hợp cảm nhận–truyền thông hướng đến 5G-Advanced và 6G cũng chỉ ra rằng đặc tính thời gian–tần số của tín hiệu truyền thông và radar ngày càng đa dạng hơn, khiến việc nhận dạng trong môi trường phổ chia sẻ trở nên khó khăn hơn [12]. Trong môi trường vô tuyến đông đúc, các phương pháp phát hiện và phân loại tín hiệu radar–truyền thông bằng mô hình học sâu cũng đã được nghiên cứu nhằm xử lý sự chồng lấn giữa nhiều loại tín hiệu [13]. Một số nghiên cứu gần đây còn khai thác các cơ chế chú ý ba chiều hoặc đặc trưng thời gian–tần số để cải thiện nhận dạng dạng sóng trong hệ thống radar–truyền thông tích hợp [14]. Những kết quả này cho thấy việc phân biệt tín hiệu dị thể trong miền phổ là một bài toán có ý nghĩa thực tiễn rõ rệt [15].

Các phương pháp cảm nhận phổ truyền thống thường dựa trên phát hiện năng lượng, bộ lọc phù hợp hoặc đặc trưng chu kỳ. Những phương pháp này có ưu điểm là đơn giản và dễ triển khai khi thông tin về tín hiệu hoặc nhiễu được giả định rõ ràng. Tuy nhiên, trong các môi trường phổ động, nhiễu nền thay đổi hoặc tín hiệu bị suy giảm, các giả định này thường khó được đảm bảo. Các nghiên cứu cảm nhận phổ dựa trên học sâu đã chỉ ra rằng cách tiếp cận dựa trên dữ liệu có thể giảm sự phụ thuộc vào đặc trưng thủ công và tăng khả năng thích nghi với các điều kiện kênh phức tạp [16]. Đặc biệt, khi tín hiệu hoạt động ở mức tỷ số tín hiệu trên nhiễu (signal-to-noise ratio, SNR) rất thấp, các mô hình khai thác tương quan thời gian–không gian như mạng tích chập hồi tiếp (long short-term memory, LSTM) có thể hỗ trợ cải thiện khả năng phát hiện phổ [17]. Các hướng tiếp cận dựa trên tự tương quan và học đặc trưng sâu cũng được nghiên cứu nhằm nâng cao độ bền trong các mạng vô tuyến nhận thức [18]. Bên cạnh các mô hình học có giám sát, các phương pháp ít phụ thuộc nhãn dữ liệu cũng ngày càng được quan tâm trong cảm nhận phổ. Phân cụm sâu đã được sử dụng để nhận dạng công nghệ truy cập vô tuyến mà không cần nhãn đầy đủ, qua đó giảm gánh nặng gán nhãn trong các môi trường phổ phức tạp [19]. Các mô hình cảm nhận phổ hợp tác dựa trên mạng kết hợp bộ nhớ dài–ngắn hạn và tích chập (LSTM-CNN) cũng cho thấy khả năng khai thác đồng thời đặc trưng tín hiệu và quan hệ theo chuỗi giữa nhiều quan sát [20]. Gần đây, kiến trúc biến đổi (Transformer) và cơ chế chú ý (attention mechanism) được sử dụng trong phát hiện phổ băng rộng nhằm học quan hệ giữa các vùng phổ ở phạm vi xa

hơn [21]. Tuy vậy, phần lớn các hướng tiếp cận này vẫn chủ yếu đưa ra quyết định ở mức toàn cục, chẳng hạn như phát hiện trạng thái kênh, phân loại dạng tín hiệu hoặc nhận dạng công nghệ truy cập vô tuyến. Do đó, chúng chưa mô tả đầy đủ hình dạng, biên và vùng chiếm dụng chi tiết của từng tín hiệu trong miền thời gian–tần số.

Để khai thác tốt hơn cấu trúc không gian của tín hiệu, nhiều nghiên cứu chuyển tín hiệu vô tuyến sang dạng ảnh phổ hai chiều. Biến đổi Fourier thời gian ngắn (short-time Fourier transform, STFT) là một kỹ thuật phổ biến để biểu diễn tín hiệu không dừng trong miền thời gian–tần số [22]. Trên ảnh phổ, trục thời gian và trục tần số cho phép quan sát sự thay đổi năng lượng của tín hiệu theo từng vùng cục bộ, từ đó tạo điều kiện cho các mô hình thị giác máy tính học đặc trưng phổ hiệu quả hơn [23]. Cách biểu diễn này đặc biệt phù hợp với các tín hiệu có cấu trúc khác nhau như 5G NR, LTE và ASR, vì mỗi loại tín hiệu có thể tạo ra các mẫu hình thái riêng trong ảnh phổ. Tuy nhiên, việc chuyển tín hiệu sang ảnh phổ chỉ là bước biểu diễn dữ liệu; đóng góp chính của nghiên cứu vẫn nằm ở việc thiết kế mô hình học sâu có khả năng khai thác hiệu quả biểu diễn này. Trong giai đoạn đầu, nhiều phương pháp thị giác máy tính tiếp cận ảnh phổ thông qua bài toán phát hiện vùng tín hiệu. Các mô hình phát hiện có thể xác định vùng tín hiệu bằng hộp giới hạn, qua đó chuyển bài toán từ phân loại toàn cục sang định vị vùng phổ [24]. Các mô hình dựa trên kiến trúc bạn chỉ nhìn một lần (YOLO) cũng được sử dụng để phát hiện và phân loại đồng thời tín hiệu truyền thông và radar trong môi trường vô tuyến đông đúc [13]. Một hướng khác thực hiện đồng thời phân đoạn và phân loại phổ nhằm kết hợp thông tin vị trí và nhận tín hiệu trong phổ rộng [25]. Mặc dù các phương pháp này giúp định vị tín hiệu tốt hơn so với phân loại toàn ảnh, hộp giới hạn vẫn chưa thể mô tả chính xác biên dạng thật của vùng phổ. Trong thực tế, vùng tín hiệu có thể bị méo, phân mảnh hoặc không có dạng hình chữ nhật do nhiễu, fading, dịch Doppler và sự chồng lấn giữa nhiều nguồn phát.

Từ hạn chế của phát hiện bằng hộp giới hạn (bounding box), phân đoạn ngữ nghĩa (semantic segmentation) ảnh phổ trở thành một hướng tiếp cận phù hợp hơn cho cảm nhận phổ hiện đại. Thay vì dự đoán nhãn cho toàn ảnh hoặc cho một hộp vùng, phân đoạn ngữ nghĩa gán nhãn cho từng điểm ảnh trong ảnh phổ. Cách tiếp cận này cho phép mô hình tạo mặt nạ phân đoạn thể hiện chi tiết vùng chiếm dụng phổ của từng lớp tín hiệu. Trong thị giác máy tính, phân đoạn ảnh bằng học sâu đã được khảo sát rộng rãi và chứng minh hiệu quả trong nhiều bài toán cần dự đoán ở cấp điểm ảnh [26]. SegFormer cho thấy khả năng kết hợp đặc trưng đa mức với bộ giải mã nhẹ, phù hợp với các bài toán cần cân bằng hiệu năng và chi phí [27]. Mask2Former tiếp tục mở rộng ý tưởng dự đoán mặt nạ bằng cơ chế chú ý có mặt nạ, cho thấy hướng phân đoạn dựa trên mặt nạ có thể xử lý nhiều dạng bài toán phân đoạn khác nhau [28]. Những mô hình này cung cấp cơ sở quan trọng để áp dụng tư duy phân đoạn ngữ nghĩa vào ảnh phổ. Ngoài SegFormer và Mask2Former, nhiều mô hình thị giác hiện đại cũng đóng vai trò nền tảng cho việc thiết kế kiến trúc phân đoạn ảnh phổ. MaskFormer cho thấy phân đoạn có thể được nhìn nhận như bài toán dự đoán tập mặt nạ thay vì chỉ phân loại từng điểm ảnh độc lập [29]. Swin Transformer khai thác cơ chế tự chú ý

theo cửa sổ dịch chuyển để giảm chi phí tính toán khi xử lý ảnh có độ phân giải cao [30]. SETR tiếp cận phân đoạn ảnh bằng Transformer thuần, qua đó nhấn mạnh khả năng học quan hệ toàn cục trong ảnh [31]. Segmenter tiếp tục khai thác bộ mã hóa Transformer cho phân đoạn ngữ nghĩa với cơ chế phân đoạn dựa trên biểu diễn nhúng [32]. SegNeXt sử dụng thiết kế chú ý tích chập để tăng hiệu quả phân đoạn trong khi vẫn duy trì chi phí hợp lý [33]. Các khảo sát gần đây về Transformer thị giác và Transformer thị giác hiệu quả cũng cho thấy xu hướng thiết kế mô hình thị giác hiện đại đang tập trung mạnh vào việc cân bằng giữa khả năng biểu diễn và chi phí tính toán [34]. Đây là cơ sở quan trọng cho các mô hình ảnh phổ hướng đến thiết bị biên hoặc các hệ thống có tài nguyên hạn chế [35].

Đối với cảm nhận phổ, các mô hình phân đoạn ảnh phổ chuyên biệt đã bắt đầu xuất hiện trong những năm gần đây. Mô hình cảm nhận phổ sâu dựa trên phân đoạn ngữ nghĩa cho tín hiệu đồng kênh cho thấy việc dự đoán mặt nạ ở cấp điểm ảnh có thể hỗ trợ mô tả vùng phổ chồng lấn chính xác hơn so với phát hiện toàn cục [36]. SRNet khai thác mạng phân đoạn ngữ nghĩa sâu cho cảm nhận phổ trong truyền thông không dây, nhấn mạnh vai trò của việc học đặc trưng trên ảnh phổ [37]. DPSEgNet sử dụng kiến trúc đa tỷ lệ hai đường nhằm kết hợp thông tin ngữ cảnh và chi tiết không gian trong ảnh phổ [38]. RPNNet tập trung vào việc bảo toàn độ phân giải nhằm giữ lại các chi tiết nhỏ và vùng biên quan trọng trong ảnh phổ 5G NR-LTE [39]. D2SNet kết hợp khử nhiễu và phân đoạn để tăng độ bền của mô hình trong môi trường phổ nhiễu [40]. Những kết quả này cho thấy phân đoạn ảnh phổ là một hướng nghiên cứu đang phát triển nhanh và có liên hệ trực tiếp với nhu cầu cảm nhận phổ thông minh. Song song với các mô hình truyền thẳng, các cơ chế huấn luyện và tối ưu mô hình cũng được quan tâm nhằm tăng độ bền và giảm chi phí triển khai. Huấn luyện đối nghịch đã được sử dụng để cải thiện khả năng nhận dạng tín hiệu 5G NR-LTE trong các điều kiện nhiễu và biến dạng [41]. Các kỹ thuật giảm kích thước mô hình như tái sử dụng lớp tích chập cũng được khai thác nhằm giảm tài nguyên lưu trữ mà vẫn duy trì hiệu năng phân đoạn [42]. Những hướng này cho thấy bài toán cảm nhận phổ không chỉ yêu cầu độ chính xác cao, mà còn cần xem xét số tham số, chi phí tính toán và khả năng triển khai trên các nền tảng có tài nguyên hạn chế. Do đó, một mô hình phân đoạn ảnh phổ hiệu quả cần cân bằng giữa chất lượng mặt nạ, độ trễ suy luận và mức độ phức tạp của kiến trúc.

Gần đây, các mô hình tạo sinh (generative model) cũng mở ra một hướng tiếp cận mới cho bài toán phân đoạn. Mô hình khuếch tán xác suất khử nhiễu cho thấy khả năng mô hình hóa quá trình sinh dữ liệu thông qua chuỗi khử nhiễu có điều kiện [43]. Mô hình sinh dựa trên trường điểm số mở rộng cách nhìn này bằng cách mô tả quá trình sinh dữ liệu thông qua phương trình vi phân ngẫu nhiên và trường điểm số [44]. Mô hình khuếch tán trong không gian tiềm ẩn giảm chi phí tính toán bằng cách thực hiện quá trình khuếch tán (diffusion process) trong không gian tiềm ẩn (latent space) thay vì trực tiếp trên ảnh độ phân giải cao [45]. Các khảo sát gần đây về mô hình khuếch tán trong thị giác máy tính cho thấy mô hình khuếch tán không chỉ phù hợp với sinh ảnh, mà còn có thể hỗ trợ các tác vụ phục hồi, phân đoạn và dự đoán cấu trúc [46]. Khớp dòng

tiếp tục mở rộng họ mô hình tạo sinh bằng cách học trường vận tốc liên tục giữa phân phối đơn giản và phân phối dữ liệu [47]. Trong thị giác máy tính, DiffusionDet cũng cho thấy quá trình khử nhiễu có thể được dùng để tinh chỉnh dự đoán có cấu trúc [48]. Đối với phân đoạn ảnh phổ, mô hình tạo sinh có ý nghĩa đặc biệt vì mặt nạ phân đoạn không chỉ là nhãn rời rạc, mà còn mang cấu trúc không gian rõ ràng. Trong môi trường nhiễu, các vùng tín hiệu yếu hoặc biên phổ mờ có thể bị dự đoán sai nếu mô hình chỉ dựa trên ánh xạ truyền thẳng từ ảnh phổ sang nhãn. Mô hình khuếch tán trong không gian tiềm ẩn đã được khai thác cho cảm nhận phổ trong môi trường đồng tồn tại radar và truyền thông, qua đó tận dụng khả năng khử nhiễu và phục hồi cấu trúc của mô hình tạo sinh [49]. Hướng này phù hợp với bài toán phân đoạn phổ vì mô hình có thể học cách tái tạo mặt nạ có cấu trúc, thay vì chỉ dự đoán từng điểm ảnh một cách độc lập. Tuy nhiên, các mô hình tạo sinh thường có chi phí suy luận cao hơn mô hình truyền thẳng, do đó cần được đánh giá đồng thời về chất lượng phân đoạn và độ trễ xử lý.

Từ các phân tích trên, có thể thấy rằng bài toán phân đoạn ảnh phổ trong cảm nhận phổ hiện đại vẫn còn nhiều thách thức. Mô hình cần phân biệt các tín hiệu dị thể như 5G NR, LTE và ASR trong điều kiện có nhiễu, chồng lấn và biến dạng kênh. Mô hình cũng cần tạo ra mặt nạ phân đoạn có biên chính xác, đồng thời kiểm soát số tham số và thời gian suy luận để phù hợp với các hệ thống thực tế. Trên cơ sở đó, khóa luận này tập trung nghiên cứu ba hướng mô hình học sâu cho phân đoạn ảnh phổ. Thứ nhất, ASTRA-Net được xem xét như một kiến trúc gọn nhẹ và hiệu quả tính toán nhằm phục vụ các kịch bản cần suy luận nhanh [50]. Thứ hai, SpecDiff được nghiên cứu như một hướng tiếp cận dựa trên mô hình tạo sinh nhằm cải thiện khả năng phục hồi cấu trúc mặt nạ phân đoạn trong môi trường đồng tồn tại radar–truyền thông [49]. Thứ ba, ASTA-Net được nghiên cứu theo hướng cân bằng giữa hiệu năng phân đoạn và chi phí tính toán, khai thác đồng thời đặc trưng ngữ cảnh, cấu trúc mẫu và chi tiết không gian của ảnh phổ. Với ba hướng tiếp cận này, khóa luận hướng đến việc đánh giá toàn diện khả năng ứng dụng của học sâu trong phân đoạn tín hiệu 5G NR, LTE, ASR và nhiễu trên ảnh phổ.

1.2 MỤC TIÊU

Mục tiêu chính của khóa luận là nghiên cứu và đánh giá các mô hình học sâu cho bài toán phân đoạn ảnh phổ, nhằm nhận diện chính xác các vùng phổ tương ứng với tín hiệu 5G NR, LTE, ASR và nhiễu trong môi trường phổ có nhiều thành phần chồng lấn (overlapping signals). Thông qua việc biểu diễn tín hiệu vô tuyến dưới dạng ảnh phổ thời gian–tần số và áp dụng phân đoạn ngữ nghĩa ở cấp điểm ảnh, khóa luận hướng đến việc xác định chi tiết vùng chiếm dụng phổ của từng loại tín hiệu, từ đó hỗ trợ quá trình cảm nhận phổ thông minh trong các hệ thống thông tin không dây hiện đại. Khác với các hướng tiếp cận chỉ phát hiện sự tồn tại của tín hiệu hoặc phân loại toàn bộ ảnh phổ, khóa luận tập trung vào việc tạo ra mặt nạ phân đoạn thể hiện rõ vị trí,

hình dạng và ranh giới của từng lớp tín hiệu trong miền thời gian–tần số. Đây là yêu cầu quan trọng trong các môi trường phổ phức tạp, nơi tín hiệu truyền thông và radar có thể cùng xuất hiện, bị ảnh hưởng bởi nhiễu nền, fading, dịch Doppler hoặc sự chồng lấn giữa nhiều nguồn phát. Bên cạnh độ chính xác phân đoạn, khóa luận cũng xem xét các yếu tố liên quan đến khả năng triển khai như số lượng tham số, FLOPs và thời gian suy luận. Để đạt được mục tiêu tổng quát trên, khóa luận tập trung vào các mục tiêu cụ thể sau:

- **Xây dựng bài toán phân đoạn ảnh phổ cho cảm nhận phổ thông minh.** Khóa luận chuyển đổi bài toán nhận dạng tín hiệu từ mức phát hiện toàn cục sang phân đoạn ngữ nghĩa chi tiết theo từng vùng thời gian - tần số. Việc gán nhãn từng điểm ảnh theo các lớp 5G NR, LTE, ASR và nhiễu giúp mô hình không chỉ xác định sự hiện diện của tín hiệu, mà còn mô tả chính xác ranh giới, vùng phổ bị chiếm dụng và mức độ chồng lấn giữa các lớp.
- **Nghiên cứu ASTRA-Net theo hướng mô hình gọn nhẹ và tốc độ cao.** Khóa luận đánh giá kiến trúc ASTRA-Net [50] với định hướng giảm thiểu độ phức tạp tính toán và thời gian suy luận. Mô hình tập trung khai thác các đặc trưng thời gian - tần số thiết yếu trong khi vẫn duy trì số lượng tham số và FLOPs ở mức thấp, phù hợp cho các kịch bản yêu cầu xử lý nhanh hoặc triển khai trên nền tảng hạn chế tài nguyên.
- **Nghiên cứu SpecDiff theo hướng mô hình tạo sinh cho phân đoạn ảnh phổ.** Khóa luận nghiên cứu SpecDiff [49] như một hướng tiếp cận dựa trên mô hình tạo sinh nhằm cải thiện chất lượng mặt nạ phân đoạn. Thay vì chỉ ánh xạ trực tiếp ảnh phổ sang nhãn phân đoạn, SpecDiff khai thác quá trình tinh chỉnh và khôi phục cấu trúc mặt nạ trong không gian tiềm ẩn. Mục tiêu của hướng này là khảo sát khả năng sử dụng mô hình khuếch tán để hỗ trợ phân đoạn trong các trường hợp tín hiệu bị nhiễu, vùng biên không rõ hoặc các lớp tín hiệu bị chồng lấn trong miền thời gian–tần số. Đây là hướng nghiên cứu nhằm ưu tiên chất lượng phân đoạn và khả năng tái tạo cấu trúc vùng tín hiệu.
- **Nghiên cứu ASTA-Net theo hướng cân bằng giữa hiệu năng và chi phí tính toán.** Khóa luận nghiên cứu ASTA-Net như một kiến trúc phân đoạn ảnh phổ có khả năng khai thác đồng thời đặc trưng ngữ cảnh, cấu trúc mẫu và chi tiết không gian. Mô hình được định hướng theo kiến trúc nhiều nhánh, trong đó nhánh mã hóa ngữ cảnh sử dụng cơ chế tự chú ý cộng tính để học quan hệ toàn cục với độ phức tạp thấp hơn so với cơ chế tự chú ý tiêu chuẩn. Bên cạnh đó, nhánh tổng hợp mẫu hỗ trợ học phân bố đặc trưng của từng lớp tín hiệu, trong khi nhánh tinh chỉnh không gian giúp bảo toàn các chi tiết biên và biến đổi cục bộ trong ảnh phổ. Các đặc trưng từ các nhánh được kết hợp thông qua cơ chế hợp nhất hiệp đồng nhằm tạo ra mặt nạ phân đoạn có chất lượng tốt hơn.
- **Nghiên cứu cơ chế tối ưu và hàm mất mát cho phân đoạn ảnh phổ.** Quá trình huấn luyện được cải thiện bằng cách kết hợp hàm mất mát entropy chéo (nhằm tối ưu phân loại cấp điểm ảnh) và hàm mất mát gom cụm đặc trưng trên nhánh tổng hợp mẫu của ASTA-Net.

Cách tiếp cận này không chỉ giúp mô hình học ranh giới tín hiệu tốt hơn mà còn tăng tính nhất quán, cải thiện khả năng phân biệt giữa các lớp tín hiệu có hình thái tương đồng.

- **Đánh giá toàn diện các mô hình trong nhiều điều kiện thực nghiệm.** Khóa luận đánh giá các mô hình dựa trên các chỉ số phân đoạn như độ chính xác trung bình (mAcc), chỉ số giao trên hợp trung bình (mIoU) và ma trận nhầm lẫn (confusion matrix), đồng thời xem xét các tiêu chí liên quan đến khả năng triển khai như số tham số, FLOPs và thời gian suy luận. Ngoài ra, các mô hình được phân tích dưới nhiều điều kiện khác nhau, bao gồm các mức SNR, dịch Doppler và kích thước ảnh phổ. Mục tiêu của hướng đánh giá này là làm rõ ưu điểm, hạn chế và mức độ phù hợp của từng mô hình trong các kịch bản triển khai khác nhau.

Thông qua các mục tiêu trên, khóa luận hướng đến việc xây dựng và đánh giá một hệ thống phân đoạn ảnh phổ có khả năng kết hợp giữa độ chính xác nhận diện và hiệu quả tính toán. ASTRA-Net đại diện cho hướng mô hình gọn nhẹ và suy luận nhanh, SpecDiff đại diện cho hướng mô hình tạo sinh nhằm cải thiện chất lượng mặt nạ phân đoạn, trong khi ASTA-Net đại diện cho hướng cân bằng giữa hiệu năng và chi phí xử lý. Nhìn chung, ba hướng tiếp cận này tạo nền tảng để phân tích toàn diện khả năng ứng dụng của học sâu trong cảm nhận phổ thông minh, đặc biệt đối với các môi trường vô tuyến phức tạp có sự đồng tồn tại giữa 5G NR, LTE, ASR và nhiều môi trường.

1.3 PHƯƠNG PHÁP NGHIÊN CỨU

Để hoàn thành các mục tiêu đã đề ra, khóa luận triển khai một quy trình nghiên cứu gồm các bước chính: xây dựng bộ dữ liệu ảnh phổ, phân tích và chuẩn hóa dữ liệu, thiết kế các mô hình phân đoạn ảnh phổ, huấn luyện và tối ưu mô hình, sau đó đánh giá kết quả bằng các chỉ số định lượng, phân tích trực quan và so sánh với các kiến trúc liên quan. Quy trình nghiên cứu được tổ chức nhằm đảm bảo bài toán cảm nhận phổ được tiếp cận một cách có hệ thống, từ khâu tạo lập tín hiệu, biểu diễn tín hiệu dưới dạng ảnh phổ, xây dựng mặt nạ phân đoạn, đến huấn luyện và đánh giá mô hình học sâu.

Trong khóa luận này, trọng tâm của phương pháp nghiên cứu không nằm ở việc đề xuất một phép biến đổi tín hiệu mới, mà nằm ở việc thiết kế và đánh giá các mô hình học sâu cho phân đoạn ảnh phổ. Vì vậy, biểu diễn ảnh phổ được sử dụng như đầu vào thống nhất cho các mô hình, trong khi các kiến trúc ASTRA-Net, SpecDiff và ASTA-Net được nghiên cứu theo ba định hướng khác nhau: tối ưu tốc độ, cải thiện chất lượng mặt nạ bằng mô hình tạo sinh và cân bằng giữa hiệu năng với chi phí tính toán. Các giai đoạn chính của phương pháp nghiên cứu được trình bày như sau.

Tạo lập bộ dữ liệu ảnh phổ

Dữ liệu là yếu tố nền tảng trong quá trình xây dựng và đánh giá các mô hình học sâu cho bài toán phân đoạn ảnh phổ. Trong khóa luận này, bộ dữ liệu được xây dựng dựa trên bốn lớp chính gồm 5G NR, LTE, ASR và nhiễu. Việc lựa chọn các lớp tín hiệu này nhằm mô phỏng môi trường phổ có sự đồng tồn tại giữa tín hiệu truyền thông di động và radar, trong đó các dạng tín hiệu có thể khác nhau về cấu trúc phổ, thời lượng xuất hiện, mức năng lượng và hình thái trong miền thời gian–tần số.

Các tín hiệu được tạo lập trong nhiều điều kiện khác nhau nhằm phản ánh sự đa dạng của môi trường vô tuyến. Các tham số như băng thông, tần số trung tâm, thời lượng tín hiệu, mức nhiễu, tỷ số tín hiệu trên nhiễu và kịch bản chồng lấn giữa nhiều nguồn phát được thay đổi để tạo ra các mẫu ảnh phổ có mức độ phức tạp khác nhau. Bên cạnh đó, một số yếu tố kênh truyền như fading, dịch Doppler và nhiễu nền cũng được xem xét nhằm đánh giá khả năng hoạt động của mô hình trong các điều kiện không lý tưởng. Sau khi tín hiệu được tạo lập trong miền thời gian, STFT được sử dụng để chuyển đổi tín hiệu một chiều thành ảnh phổ hai chiều. Ảnh phổ biểu diễn sự phân bố năng lượng của tín hiệu theo thời gian và tần số, nhờ đó cung cấp đầu vào phù hợp cho bài toán phân đoạn ngữ nghĩa. Đối với mỗi ảnh phổ, mặt nạ phân đoạn tương ứng được xây dựng để xác định vùng thuộc từng lớp tín hiệu. Mặt nạ này đóng vai trò là nhãn huấn luyện, cho phép mô hình học cách gán nhãn từng điểm ảnh theo các lớp 5G NR, LTE, ASR và nhiễu.

Việc tạo lập bộ dữ liệu được thực hiện nhằm bảo đảm hai yêu cầu chính. Thứ nhất, dữ liệu phải thể hiện được sự khác biệt hình thái giữa các lớp tín hiệu, chẳng hạn như vùng phổ rộng của tín hiệu truyền thông và dạng xung gián đoạn của tín hiệu radar. Thứ hai, dữ liệu phải bao gồm các kịch bản khó như tín hiệu yếu, nhiễu mạnh, vùng biên không rõ và các vùng phổ bị chồng lấn. Những yếu tố này giúp quá trình đánh giá mô hình phản ánh tốt hơn các thách thức của bài toán cảm nhận phổ thông minh.

Phân tích và chuẩn hóa dữ liệu ảnh phổ

Sau khi tạo lập bộ dữ liệu, khóa luận tiến hành phân tích và chuẩn hóa dữ liệu nhằm đảm bảo ảnh phổ và mặt nạ nhãn có thể được sử dụng hiệu quả trong quá trình huấn luyện mô hình. Việc phân tích dữ liệu tập trung vào chất lượng của ảnh phổ, sự rõ ràng của vùng tín hiệu, mức độ chồng lấn giữa các lớp và sự tương ứng giữa ảnh đầu vào với mặt nạ phân đoạn. Đây là bước quan trọng nhằm hạn chế sai lệch dữ liệu trước khi đưa vào các mô hình học sâu. Quá trình phân tích và chuẩn hóa dữ liệu bao gồm các nội dung chính sau:

- Kiểm tra độ phân giải, cường độ và chất lượng trực quan của các ảnh phổ được tạo từ tín hiệu đầu vào.

- Xác minh sự tương ứng giữa ảnh phổ và mặt nạ phân đoạn của các lớp 5G NR, LTE, ASR và nhiễu.
- Đánh giá sự đa dạng của dữ liệu theo các mức nhiễu, mức SNR, dịch Doppler và các kịch bản chồng lấn tín hiệu.
- Chuẩn hóa kích thước ảnh phổ, giá trị cường độ và định dạng nhãn để phù hợp với yêu cầu đầu vào của các mô hình phân đoạn.
- Chia dữ liệu thành các tập huấn luyện, kiểm định và kiểm tra nhằm phục vụ quá trình huấn luyện, điều chỉnh mô hình và đánh giá khách quan.

Việc sử dụng nhất quán một bộ dữ liệu đã qua phân tích và chuẩn hóa không chỉ bảo đảm tính công bằng trong quá trình so sánh thực nghiệm giữa nhiều hướng mô hình khác nhau, mà còn giúp giảm thiểu ảnh hưởng của các sai khác không mong muốn như chênh lệch cường độ, kích thước ảnh hay định dạng nhãn. Điều này đặc biệt quan trọng đối với bài toán phân đoạn ảnh phổ, nơi các lỗi nhỏ ở vùng biên hoặc vùng tín hiệu yếu có thể tác động lớn đến chất lượng mặt nạ dự đoán; do đó, khâu chuẩn hóa đóng vai trò then chốt trong việc duy trì quá trình huấn luyện ổn định và nâng cao độ tin cậy của toàn bộ kết quả đánh giá.

Thiết kế và xây dựng mô hình phân đoạn ảnh phổ

Trên cơ sở bộ dữ liệu ảnh phổ đã được chuẩn bị, khóa luận nghiên cứu các kiến trúc phân đoạn ảnh phổ theo hướng phân đoạn ngữ nghĩa. Trong đó, ảnh phổ được sử dụng làm đầu vào, còn mặt nạ phân đoạn tương ứng được sử dụng làm đầu ra. Mục tiêu của mô hình là gán nhãn cho từng điểm ảnh trong ảnh phổ, qua đó xác định vùng chiếm dụng phổ của từng lớp tín hiệu, gồm 5G NR, LTE, ASR và nhiễu. Cách tiếp cận này cho phép hệ thống không chỉ nhận biết loại tín hiệu xuất hiện, mà còn mô tả được vị trí, hình dạng và ranh giới của vùng tín hiệu trong miền thời gian–tần số. Khóa luận tập trung vào ba hướng thiết kế mô hình với các mục tiêu khác nhau.

Hướng thứ nhất là ASTRA-Net, được nghiên cứu như một kiến trúc phân đoạn ảnh phổ gọn nhẹ, ưu tiên tốc độ suy luận và chi phí tính toán thấp. Mô hình này hướng đến việc khai thác hiệu quả các đặc trưng thời gian–tần số của ảnh phổ trong khi vẫn kiểm soát số lượng tham số và độ trễ xử lý. Do đó, ASTRA-Net phù hợp với các kịch bản cần xử lý nhanh hoặc triển khai trên các nền tảng có tài nguyên hạn chế.

Hướng thứ hai là SpecDiff, được nghiên cứu như một mô hình phân đoạn ảnh phổ dựa trên cơ chế tạo sinh. Khác với các mô hình truyền thống chỉ ánh xạ trực tiếp ảnh phổ sang mặt nạ nhãn, SpecDiff khai thác biểu diễn trong không gian tiềm ẩn và quá trình tinh chỉnh mặt nạ để cải thiện chất lượng phân đoạn. Hướng tiếp cận này đặc biệt phù hợp với các trường hợp vùng tín hiệu bị nhiễu che phủ, biên phổ không rõ hoặc nhiều lớp tín hiệu bị chồng lấn. Mục tiêu của

SpecDiff là nâng cao khả năng khôi phục cấu trúc vùng tín hiệu và tạo ra mặt nạ phân đoạn có tính nhất quán không gian tốt hơn.

Hướng thứ ba là ASTA-Net, được nghiên cứu như một kiến trúc cân bằng giữa hiệu năng phân đoạn và chi phí tính toán. ASTA-Net được định hướng theo cấu trúc nhiều nhánh nhằm khai thác đồng thời các nhóm đặc trưng khác nhau trên ảnh phổ. Nhánh mã hóa ngữ cảnh sử dụng cơ chế tự chú ý cộng tính để học quan hệ toàn cục giữa các vùng tín hiệu với độ phức tạp thấp hơn so với cơ chế tự chú ý tiêu chuẩn. Nhánh tổng hợp mẫu tập trung khai thác phân bố và cấu trúc đặc trưng của từng lớp tín hiệu, trong khi nhánh tinh chỉnh không gian hỗ trợ bảo toàn chi tiết biên và các biến đổi cục bộ. Các đặc trưng từ các nhánh được kết hợp thông qua cơ chế hợp nhất hiệp đồng, giúp mô hình tạo ra mặt nạ phân đoạn dựa trên sự kết hợp giữa thông tin ngữ cảnh, cấu trúc mẫu và chi tiết không gian.

Huấn luyện và tối ưu mô hình

Sau khi xây dựng kiến trúc mô hình, khóa luận tiến hành huấn luyện trên tập dữ liệu ảnh phổ đã được chuẩn bị. Quá trình huấn luyện được thực hiện trên tập huấn luyện, trong khi tập kiểm định được sử dụng để theo dõi khả năng hội tụ, điều chỉnh siêu tham số và hạn chế hiện tượng quá khớp. Các thiết lập như kích thước lô dữ liệu, số chu kỳ huấn luyện, tốc độ học, thuật toán tối ưu và cấu hình suy luận được lựa chọn phù hợp với điều kiện thực nghiệm và đặc điểm của từng kiến trúc.

Đối với ASTRA-Net, quá trình huấn luyện tập trung vào việc tối ưu hóa khả năng dự đoán mặt nạ phân đoạn với chi phí tính toán thấp. Mô hình được huấn luyện để học các đặc trưng phân biệt giữa các vùng 5G NR, LTE, ASR và nhiễu trên ảnh phổ. Trong quá trình tối ưu, mô hình cần duy trì khả năng nhận diện các vùng tín hiệu có cấu trúc nhỏ, biên không rõ hoặc bị ảnh hưởng bởi nhiễu, đồng thời vẫn giữ được tốc độ suy luận nhanh. Vì vậy, việc huấn luyện ASTRA-Net không chỉ hướng đến độ chính xác phân đoạn, mà còn phục vụ mục tiêu xây dựng một kiến trúc gọn nhẹ, phù hợp với các hệ thống cần xử lý gần thời gian thực.

Đối với SpecDiff, quá trình huấn luyện tập trung vào khả năng tái tạo và tinh chỉnh mặt nạ phân đoạn trong không gian tiềm ẩn. Mô hình học cách khai thác đặc trưng điều kiện từ ảnh phổ đầu vào để hỗ trợ quá trình khôi phục cấu trúc mặt nạ phân đoạn. Cách huấn luyện này giúp mô hình học được quan hệ giữa ảnh phổ và mặt nạ nhãn ở mức cấu trúc, thay vì chỉ dự đoán từng điểm ảnh một cách độc lập. Nhờ đó, SpecDiff có khả năng cải thiện chất lượng mặt nạ trong các trường hợp tín hiệu yếu, vùng biên bị mờ hoặc các vùng phổ bị chồng lấn phức tạp. Tuy nhiên, do là mô hình theo hướng tạo sinh, SpecDiff cũng cần được đánh giá đồng thời về chất lượng phân đoạn và chi phí suy luận.

Đối với ASTA-Net, khóa luận nghiên cứu cơ chế tối ưu dựa trên hàm mất mát kết hợp.

Hàm mất mát entropy chéo được sử dụng để tối ưu quá trình phân loại từng điểm ảnh trong mặt nạ phân đoạn. Bên cạnh đó, hàm mất mát gom cụm đặc trưng được sử dụng trên nhánh tổng hợp mẫu nhằm khuyến khích các đặc trưng cùng lớp tiến gần nhau hơn trong không gian biểu diễn. Cơ chế này giúp mô hình không chỉ học nhận phân đoạn ở cấp điểm ảnh, mà còn tăng tính nhất quán của đặc trưng theo từng lớp tín hiệu. Điều này đặc biệt quan trọng đối với ảnh phổ có nhiều vùng tín hiệu chồng lấn hoặc có hình thái gần giống nhau.

Đánh giá và so sánh thực nghiệm

Sau quá trình huấn luyện, các mô hình được đánh giá trên tập kiểm tra độc lập nhằm kiểm tra khả năng tổng quát hóa trên những ảnh phổ chưa được sử dụng trong huấn luyện. Hiệu quả phân đoạn được đo bằng các chỉ số định lượng như độ chính xác trung bình (mean accuracy, mAcc), giao trên hợp trung bình (mean intersection over union, mIoU) và ma trận nhầm lẫn. Các chỉ số này cho phép đánh giá khả năng nhận diện từng lớp tín hiệu, mức độ chồng khớp giữa mặt nạ dự đoán và mặt nạ nhãn thực, cũng như xu hướng nhầm lẫn giữa các lớp 5G NR, LTE, ASR và nhiễu.

Bên cạnh các chỉ số về độ chính xác, khóa luận cũng xem xét các tiêu chí liên quan đến khả năng triển khai như số lượng tham số, FLOPs, thời gian suy luận và độ trễ xử lý. Các tiêu chí này đặc biệt quan trọng khi mô hình hướng đến các hệ thống có tài nguyên hạn chế như thiết bị biên, hệ thống nhúng hoặc thiết bị IoT. Ngoài ra, kết quả phân đoạn cũng được phân tích trực quan bằng cách so sánh ảnh phổ đầu vào, mặt nạ nhãn thực và mặt nạ dự đoán. Phân tích trực quan giúp đánh giá khả năng bám biên, nhận diện tín hiệu yếu, xử lý vùng chồng lấn và duy trì cấu trúc của vùng tín hiệu trong điều kiện nhiễu. Để đánh giá độ bền của mô hình trong các điều kiện kênh truyền khác nhau, khóa luận tiến hành phân tích hiệu năng theo nhiều mức SNR và nhiều mức dịch Doppler. Các thí nghiệm theo SNR giúp làm rõ khả năng phân đoạn khi tín hiệu bị nhiễu nền che phủ ở các mức độ khác nhau. Trong khi đó, các thí nghiệm theo dịch Doppler cho phép đánh giá ảnh hưởng của sự dịch chuyển tần số do chuyển động tương đối giữa nguồn phát, máy thu hoặc vật phản xạ. Ngoài ra, khóa luận cũng khảo sát ảnh hưởng của kích thước ảnh phổ nhằm phân tích sự đánh đổi giữa độ chi tiết của biểu diễn thời gian–tần số và chi phí tính toán.

Để làm rõ vị trí của các mô hình nghiên cứu trong bối cảnh các phương pháp hiện có, khóa luận tiến hành so sánh với một số kiến trúc phân đoạn liên quan như Twins, SegFormer, SegNeXt, DeepLabV3+, DPSEgNet, PRMNet, SRNet, UNet++ và UPerNet. Các mô hình được đánh giá dựa trên cùng bộ dữ liệu hoặc cùng điều kiện thực nghiệm nhằm đảm bảo tính công bằng trong so sánh. Kết quả thu được là cơ sở để phân tích ưu điểm, hạn chế và khả năng ứng dụng của từng hướng tiếp cận đối với bài toán phân đoạn ảnh phổ. Trong đó, ASTRA-Net được xem xét ở khía cạnh tốc độ và độ gọn nhẹ, SpecDiff được xem xét ở khía cạnh chất lượng mặt nạ phân đoạn, còn ASTA-Net được xem xét ở khía cạnh cân bằng giữa hiệu năng và chi phí tính toán.

1.4 GIỚI HẠN NGHIÊN CỨU

Để đảm bảo phạm vi nghiên cứu phù hợp với thời gian, dữ liệu và điều kiện thực nghiệm hiện có, khóa luận được giới hạn trong một số khía cạnh chính. Các giới hạn này giúp xác định rõ phạm vi áp dụng của kết quả nghiên cứu và tránh mở rộng kết luận vượt quá những nội dung đã được thực hiện.

- **Giới hạn về dữ liệu đầu vào:** Dữ liệu sử dụng trong khóa luận chủ yếu được xây dựng thông qua quá trình mô phỏng hoặc xử lý tín hiệu trong môi trường có kiểm soát. Cách tiếp cận này cho phép chủ động thiết lập các tham số tín hiệu, mức SNR, điều kiện nhiễu và mặt nạ phân đoạn tương ứng cho từng lớp. Tuy nhiên, khóa luận chưa sử dụng dữ liệu thu trực tiếp từ thiết bị phần cứng vô tuyến hoặc thiết bị đo phổ thực tế. Do đó, bộ dữ liệu chưa phản ánh đầy đủ các yếu tố bất định của môi trường vô tuyến thực, chẳng hạn như sai lệch phần cứng, nhiễu ngoài mô hình, can nhiễu không xác định hoặc sự thay đổi nhanh của kênh truyền.
- **Giới hạn về loại tín hiệu nghiên cứu:** Khóa luận chỉ tập trung vào bốn lớp chính gồm 5G NR, LTE, ASR và nhiễu. Đây là các lớp tín hiệu được sử dụng để mô phỏng kịch bản đồng tồn tại giữa hệ thống truyền thông di động và radar trong môi trường chia sẻ phổ. Khóa luận chưa xét đến các loại tín hiệu khác như Wi-Fi, Bluetooth, LoRa, NB-IoT, tín hiệu vệ tinh, tín hiệu thiết bị bay không người lái hoặc các dạng radar khác. Vì vậy, kết quả nghiên cứu chỉ được diễn giải trong phạm vi các lớp tín hiệu đã được đưa vào dữ liệu.
- **Giới hạn về phương pháp biểu diễn tín hiệu:** Trong phạm vi khóa luận, tín hiệu được chuyển đổi sang ảnh phổ hai chiều bằng biến đổi Fourier thời gian ngắn. Biểu diễn này phù hợp với bài toán phân đoạn ngữ nghĩa vì cho phép quan sát sự phân bố năng lượng của tín hiệu theo cả thời gian và tần số. Tuy nhiên, khóa luận chưa thực hiện so sánh hệ thống giữa biểu diễn ảnh phổ này với các phương pháp biểu diễn khác như biến đổi wavelet, phân bố Wigner–Ville hoặc học trực tiếp từ tín hiệu đồng pha và vuông góc (in-phase and quadrature, I/Q). Do đó, kết quả nghiên cứu chủ yếu phản ánh hiệu quả của các mô hình trên biểu diễn ảnh phổ được sử dụng trong phạm vi thí nghiệm.
- **Giới hạn về điều kiện kênh truyền:** Các thí nghiệm trong khóa luận xem xét một số điều kiện nhiễu, mức SNR và mức dịch Doppler nhất định nhằm đánh giá độ bền của mô hình trong các kịch bản phổ phức tạp. Tuy nhiên, các điều kiện này chưa bao quát đầy đủ toàn bộ hiện tượng có thể xuất hiện trong môi trường vô tuyến thực tế, chẳng hạn như fading mạnh, sai lệch đồng bộ, phản xạ đa đường phức tạp, méo phi tuyến phần cứng hoặc can nhiễu không xác định. Vì vậy, khả năng tổng quát hóa của mô hình trong môi trường thực tế cần được tiếp tục kiểm chứng bằng dữ liệu thu nhận từ phần cứng.

- **Giới hạn về mô hình học sâu:** Trọng tâm của khóa luận là nghiên cứu ba mô hình phân đoạn ảnh phổ gồm ASTRA-Net, SpecDiff và ASTA-Net. Mỗi mô hình được xem xét theo một định hướng riêng: ASTRA-Net ưu tiên tốc độ và tính gọn nhẹ, SpecDiff ưu tiên chất lượng mặt nạ phân đoạn thông qua cơ chế tạo sinh, còn ASTA-Net hướng đến sự cân bằng giữa hiệu năng và chi phí tính toán. Các mô hình khác như Twins, SegFormer, SegNeXt, DeepLabV3+, DPSEgNet, PRMNet, SRNet, UNet++ và UPerNet được sử dụng làm phương pháp đối sánh trong phạm vi thực nghiệm. Khóa luận chưa thực hiện khảo sát toàn diện tất cả các kiến trúc phân đoạn hiện có và chưa tối ưu lại toàn bộ mô hình đối sánh theo nhiều cấu hình khác nhau.
- **Giới hạn về đánh giá và triển khai thực tế:** Hiệu quả của mô hình được đánh giá chủ yếu thông qua các chỉ số thường dùng trong phân đoạn ngữ nghĩa như mAcc, mIoU, ma trận nhầm lẫn, số lượng tham số, FLOPs và thời gian suy luận. Các đánh giá này phản ánh chất lượng phân đoạn và độ phức tạp mô hình trong điều kiện thực nghiệm phần mềm. Khóa luận chưa đánh giá mức tiêu thụ năng lượng, độ ổn định khi chạy liên tục, khả năng chịu lỗi trên phần cứng chuyên dụng hoặc hiệu suất khi tích hợp vào một hệ thống cảm nhận phổ hoàn chỉnh. Mô hình cũng chưa được triển khai trực tiếp trên các nền tảng phần cứng như vi tuyến định nghĩa bằng phần mềm, FPGA, NVIDIA Jetson, Raspberry Pi hoặc vi điều khiển chuyên dụng.

Kết quả nghiên cứu chỉ được diễn giải trong điều kiện dữ liệu mô phỏng, tập lớp tín hiệu đã xác định, biểu diễn ảnh phổ, các mô hình học sâu và chỉ số đánh giá đã sử dụng. Những nội dung như dữ liệu thu thực tế, mở rộng thêm loại tín hiệu, so sánh nhiều biểu diễn thời gian–tần số, đánh giá tiêu thụ năng lượng và triển khai phần cứng không nằm trong phạm vi thực hiện của khóa luận này.

1.5 BỔ CỤC

Luận văn được cấu trúc thành 5 chương:

- **Chương 1: Tổng quan.**
- **Chương 2: Cơ sở lý thuyết.**
- **Chương 3: Thiết kế mô hình mạng học sâu cho phân đoạn ảnh phổ.**
- **Chương 4: Kết quả và thảo luận.**
- **Chương 5: Kết luận và hướng phát triển.**

Chương 2

CƠ SỞ LÝ THUYẾT

2.1 LÝ THUYẾT VỀ TÍN HIỆU 5G NR–LTE–ASR

Trong các hệ thống cảm nhận phổ hiện đại, việc nhận diện chính xác từng loại tín hiệu trong môi trường vô tuyến đóng vai trò quan trọng đối với quá trình quản lý, chia sẻ và khai thác tài nguyên phổ tần. Khác với các bài toán phát hiện phổ truyền thống, vốn chủ yếu xác định một kênh tần số có đang được sử dụng hay không, bài toán phân đoạn ảnh phổ yêu cầu hệ thống xác định chi tiết vùng thời gian–tần số tương ứng với từng lớp tín hiệu. Điều này đặc biệt cần thiết trong các môi trường có sự đồng tồn tại giữa tín hiệu truyền thông di động và tín hiệu radar, chẳng hạn như LTE, 5G NR và ASR. Các tín hiệu này có bản chất vật lý và hình thái phổ khác nhau: LTE và 5G NR là các tín hiệu truyền thông di động dựa trên cơ chế đa sóng mang, thường chiếm dụng vùng phổ tương đối rộng và có thể kéo dài theo thời gian; trong khi đó, ASR là tín hiệu radar dạng xung, thường xuất hiện ngắt quãng và có đặc trưng cục bộ rõ rệt trong miền thời gian–tần số. Do đó, trước khi trình bày các phương pháp phân tích thời gian–tần số và mô hình học sâu, cần làm rõ mô hình truyền nhận cũng như đặc trưng phổ của từng nhóm tín hiệu.

2.1.1 Mô hình tín hiệu thu trong môi trường đồng tồn tại

Trong môi trường vô tuyến thực tế, tín hiệu được phát từ một hoặc nhiều nguồn phát, lan truyền qua kênh truyền và được thu nhận tại máy thu. Quá trình lan truyền này không diễn ra trong điều kiện lý tưởng mà chịu ảnh hưởng bởi nhiều yếu tố như suy hao công suất, phản xạ, tán xạ, fading đa đường, dịch Doppler và nhiễu nền. Khi nhiều hệ thống cùng hoạt động trong một vùng phổ, tín hiệu thu được tại máy thu có thể được xem là sự tổng hợp của nhiều nguồn tín hiệu

khác nhau sau khi đi qua các kênh truyền tương ứng. Một mô hình tổng quát của tín hiệu thu trong môi trường đồng tồn tại có thể được biểu diễn như sau:

$$y(t) = \sum_{u=1}^U x_u(t) * h_u(t) + n(t), \quad (2.1)$$


trong đó $y(t)$ là tín hiệu thu được tại máy thu, U là số nguồn tín hiệu đang hoạt động, $x_u(t)$ là tín hiệu phát của nguồn thứ u , có thể tương ứng với LTE, 5G NR hoặc ASR, $h_u(t)$ là đáp ứng xung của kênh truyền ứng với nguồn tín hiệu đó, $n(t)$ là nhiễu cộng trong môi trường vô tuyến, và ký hiệu $*$ biểu thị phép tích chập trong miền thời gian. Mô hình này cho thấy tín hiệu thu được không chỉ phụ thuộc vào dạng sóng phát ban đầu, mà còn bị biến đổi bởi kênh truyền và nhiễu trong quá trình lan truyền. Các yếu tố ảnh hưởng chính đến hình thái tín hiệu thu được có thể được tóm tắt như sau:

- Fading đa đường: tín hiệu có thể đến máy thu qua nhiều đường truyền khác nhau do phản xạ từ tòa nhà, mặt đất, phương tiện hoặc các vật thể xung quanh. Các thành phần tín hiệu này có độ trễ, pha và biên độ khác nhau, khi chồng lấn có thể làm biến dạng tín hiệu và gây fading chọn lọc theo tần số.
- Dịch Doppler: khi có chuyển động tương đối giữa nguồn phát, máy thu hoặc vật phản xạ, tần số quan sát được của tín hiệu có thể bị dịch chuyển. Hiện tượng này đặc biệt đáng chú ý trong các kịch bản radar hoặc môi trường có mục tiêu di chuyển nhanh, làm thay đổi vị trí và hình thái của tín hiệu trên ảnh phổ.
- SNR thấp: nhiễu nền là thành phần không thể tránh khỏi trong hệ thống vô tuyến. Khi SNR thấp, năng lượng tín hiệu có thể bị che khuất bởi nhiễu, làm cho biên tín hiệu trở nên mờ, vùng tín hiệu bị phân mảnh hoặc bị nhầm lẫn với nền nhiễu.
- Sự chồng lấn phổ: trong môi trường chia sẻ phổ, các tín hiệu LTE, 5G NR và ASR có thể cùng xuất hiện trong một khoảng thời gian hoặc vùng tần số nhất định. Sự chồng lấn này làm tăng độ phức tạp của bài toán phân đoạn vì mô hình cần phân biệt từng lớp tín hiệu ở mức điểm ảnh thay vì chỉ xác định sự có mặt của tín hiệu.

Từ các phân tích trên có thể thấy rằng tín hiệu thu được trong môi trường đồng tồn tại thường mang tính không dừng, bị biến đổi bởi kênh truyền và có thể bị che khuất bởi nhiễu hoặc can nhiễu. Do đó, việc quan sát tín hiệu trong miền thời gian đơn thuần thường chưa đủ để nhận diện chính xác từng loại tín hiệu. Điều này đặt ra nhu cầu sử dụng biểu diễn thời gian–tần số, trong đó sự phân bố năng lượng của tín hiệu theo thời gian và tần số được thể hiện dưới dạng ảnh phổ, tạo cơ sở cho bài toán phân đoạn ngữ nghĩa ở các phần sau.

2.1.2 Tổng quan về tín hiệu LTE

LTE là một công nghệ truyền thông di động thế hệ thứ tư, được phát triển nhằm cải thiện tốc độ truyền dữ liệu, giảm độ trễ và nâng cao hiệu quả sử dụng phổ tần so với các thế hệ mạng trước đó như 3G và HSPA. LTE được thiết kế để hỗ trợ truyền dữ liệu gói tốc độ cao, đáp ứng nhu cầu ngày càng tăng của các dịch vụ di động như truy cập Internet, truyền video, thoại qua IP và các ứng dụng đa phương tiện. Một trong những đặc điểm quan trọng của LTE là khả năng hỗ trợ băng thông linh hoạt, cho phép hệ thống thích ứng với nhiều điều kiện triển khai khác nhau. Nhờ đó, LTE không chỉ đóng vai trò là nền tảng quan trọng của mạng di động thế hệ thứ tư, mà còn tạo tiền đề cho sự phát triển của các công nghệ truyền thông sau này như LTE-Advanced và 5G NR.



Hình 2.1: Kiến trúc tổng quan của mạng LTE [1].

Kiến trúc tổng quan của mạng LTE được thể hiện ở Hình 2.1. Về cơ bản, mạng LTE bao gồm thiết bị người dùng (user equipment, UE), mạng truy nhập vô tuyến E-UTRAN (evolved UMTS terrestrial radio access network), trạm gốc evolved NodeB và lõi mạng gói phát triển EPC (evolved packet core). Trong đó, E-UTRAN chịu trách nhiệm kết nối vô tuyến giữa UE và mạng lõi thông qua các trạm evolved NodeB. EPC đảm nhiệm các chức năng điều khiển, quản lý thuê bao, định tuyến dữ liệu và kết nối với các mạng dữ liệu gói bên ngoài. Trong kiến trúc này, các luồng báo hiệu được sử dụng để điều khiển kết nối, quản lý di động và xác thực người dùng, trong khi luồng dữ liệu người dùng được truyền qua các cổng mạng để kết nối đến mạng dữ liệu gói. Các thành phần chính trong kiến trúc LTE có thể được mô tả như sau:

- UE (User Equipment): Là thiết bị người dùng đầu cuối, chẳng hạn như điện thoại di động, máy tính bảng, thiết bị IoT hoặc các thiết bị thu phát vô tuyến. UE thực hiện truyền nhận dữ liệu và trao đổi các thông điệp báo hiệu với mạng LTE thông qua trạm gốc evolved NodeB.
- Evolved NodeB: Là trạm gốc của mạng LTE, đảm nhiệm chức năng truyền nhận tín hiệu vô tuyến với UE. Evolved NodeB thực hiện xử lý lớp vật lý, điều chế, mã hóa kênh, lập lịch tài nguyên vô tuyến, điều khiển truy nhập và chuyển tiếp dữ liệu giữa UE và EPC.
- E-UTRAN (Evolved UMTS Terrestrial Radio Access Network): Là mạng truy nhập vô tuyến

của LTE, bao gồm các trạm evolved NodeB. E-UTRAN chịu trách nhiệm quản lý giao diện vô tuyến, truyền nhận dữ liệu giữa UE và mạng lõi, đồng thời hỗ trợ các chức năng như lập lịch, quản lý tài nguyên vô tuyến và chuyển giao khi UE di chuyển giữa các vùng phủ sóng.

- EPC (Evolved Packet Core): Là lõi mạng gói của LTE, có nhiệm vụ xử lý báo hiệu, quản lý di động, quản lý thuê bao và định tuyến dữ liệu người dùng đến các mạng dữ liệu bên ngoài. EPC được thiết kế theo hướng truyền dữ liệu gói hoàn toàn, giúp LTE hỗ trợ hiệu quả các dịch vụ dựa trên IP.
- MME (Mobility Management Entity): Là thực thể quản lý di động trong EPC, chịu trách nhiệm xử lý các thủ tục báo hiệu điều khiển. MME thực hiện các chức năng như xác thực người dùng, quản lý trạng thái kết nối, quản lý di động, thiết lập phiên truyền dữ liệu và phối hợp với HSS để kiểm tra thông tin thuê bao.
- HSS (Home Subscriber Server): Là cơ sở dữ liệu trung tâm lưu trữ thông tin thuê bao của người dùng. HSS chứa các thông tin liên quan đến danh tính thuê bao, quyền truy cập dịch vụ, thông tin xác thực và các tham số hỗ trợ quá trình quản lý kết nối trong mạng LTE.
- S-GW (Serving Gateway): Là cổng phục vụ trong EPC, có nhiệm vụ chuyển tiếp dữ liệu người dùng giữa E-UTRAN và P-GW. S-GW cũng đóng vai trò là điểm neo dữ liệu khi UE di chuyển giữa các trạm gốc, giúp duy trì phiên truyền dữ liệu trong quá trình chuyển giao.
- P-GW (Packet Data Network Gateway): Là cổng kết nối giữa EPC và các mạng dữ liệu gói bên ngoài. P-GW thực hiện cấp phát địa chỉ IP cho UE, lọc gói dữ liệu, định tuyến lưu lượng và kết nối người dùng đến Internet hoặc các mạng dịch vụ khác.
- Packet Data Network: Là mạng dữ liệu bên ngoài mà người dùng truy cập thông qua hệ thống LTE, chẳng hạn như Internet, máy chủ dịch vụ hoặc các mạng dữ liệu chuyên dụng.


Trong công nghệ LTE, tín hiệu được tổ chức dựa trên cơ chế đa sóng mang, trong đó đường xuống sử dụng ghép kênh phân chia theo tần số trực giao. LTE hỗ trợ nhiều mức băng thông khác nhau, thường từ 1.4 MHz đến 20 MHz, cho phép hệ thống thích ứng với tài nguyên phổ được cấp phát. Băng thông quyết định phạm vi tần số mà tín hiệu LTE chiếm dụng; khi băng thông lớn hơn, vùng năng lượng quan sát được trên ảnh phổ cũng rộng hơn. Bên cạnh đó, LTE có thể hoạt động ở hai chế độ song công chính là FDD và TDD. Trong FDD, đường lên và đường xuống sử dụng hai dải tần riêng biệt, trong khi TDD chia sẻ cùng một dải tần nhưng phân tách theo thời gian. Các tham số như băng thông, chế độ song công, cấu hình tài nguyên, sơ đồ điều chế và điều kiện kênh truyền đều ảnh hưởng đến cách tín hiệu LTE phân bố trong miền thời gian–tần số.

Nhìn chung, LTE là một hệ thống truyền thông di động có cấu trúc tương đối ổn định, trong đó tín hiệu thường chiếm một dải tần xác định và có xu hướng duy trì tính liên tục theo thời gian. Khi được biểu diễn trên ảnh phổ, LTE thường tạo thành vùng năng lượng tương đối đều và

liên tục hơn so với các tín hiệu dạng xung như radar ASR. Tuy nhiên, trong điều kiện SNR thấp, fading hoặc khi chồng lấn với 5G NR, biên của vùng tín hiệu LTE có thể bị mờ, đứt gãy hoặc bị che khuất bởi nhiễu. Vì vậy, việc phân đoạn chính xác tín hiệu LTE đòi hỏi mô hình phải khai thác đồng thời đặc trưng năng lượng, độ liên tục theo thời gian, phạm vi chiếm dụng tần số và ngữ cảnh lân cận để phân biệt LTE với 5G NR, ASR và nhiễu nền.

2.1.3 Tổng quan về tín hiệu 5G NR

Công nghệ 5G NR là chuẩn giao diện vô tuyến của mạng thông tin di động thế hệ thứ năm, được phát triển nhằm đáp ứng nhu cầu ngày càng cao về tốc độ truyền dữ liệu, độ trễ thấp, độ tin cậy và khả năng kết nối số lượng lớn thiết bị. So với các thế hệ mạng trước đó, 5G NR không chỉ cải thiện tốc độ truyền tải mà còn hỗ trợ nhiều kịch bản ứng dụng khác nhau như băng rộng di động nâng cao, truyền thông độ trễ thấp, truyền thông máy số lượng lớn, xe tự hành, thực tế ảo và các hệ thống công nghiệp thông minh. Bên cạnh đó, 5G NR còn được thiết kế với khả năng cấu hình linh hoạt theo từng dải tần và từng loại dịch vụ, nhờ các tham số như băng thông, khoảng cách sóng mang con, cấu trúc khung và khối tín hiệu đồng bộ. Chính sự linh hoạt này làm cho tín hiệu 5G NR có đặc trưng phổ đa dạng hơn so với các chuẩn truyền thông di động trước đó.



Hình 2.2: Kiến trúc tổng quan của hệ thống 5G NR [2].

Kiến trúc tổng quan của hệ thống 5G NR được thể hiện ở Hình 2.2. Hệ thống bao gồm thiết bị người dùng (user equipment, UE), trạm gốc thế hệ mới (next-generation NodeB, gNB),

chồng giao thức mặt phẳng người dùng, chồng giao thức mặt phẳng điều khiển, chức năng mặt phẳng người dùng (user plane function, UPF), chức năng quản lý truy nhập và di động (access and mobility management function, AMF), cùng mạng bên ngoài. Một đặc điểm quan trọng của kiến trúc 5G NR là sự tách biệt giữa mặt phẳng người dùng và mặt phẳng điều khiển. Mặt phẳng người dùng chịu trách nhiệm truyền tải dữ liệu người dùng, trong khi mặt phẳng điều khiển đảm nhiệm các thông điệp báo hiệu phục vụ quản lý truy nhập, thiết lập kết nối, điều phối tài nguyên vô tuyến và quản lý di động. Các thành phần chính trong kiến trúc 5G NR có thể được mô tả như sau:

- UE (User Equipment): Là thiết bị người dùng đầu cuối, chẳng hạn như điện thoại di động, máy tính bảng, thiết bị IoT hoặc các thiết bị thu phát vô tuyến. UE thực hiện trao đổi dữ liệu người dùng và các thông điệp báo hiệu với mạng thông qua gNB.
- gNB (Next-generation NodeB): Là trạm gốc của mạng 5G NR, đảm nhiệm chức năng truyền nhận tín hiệu vô tuyến với UE. gNB thực hiện xử lý lớp vật lý, quản lý tài nguyên vô tuyến, lập lịch truyền dẫn và chuyển tiếp dữ liệu hoặc thông điệp điều khiển giữa UE và mạng lõi.
- SDAP (Service Data Adaptation Protocol): Là lớp giao thức thuộc mặt phẳng người dùng, có nhiệm vụ ánh xạ các luồng chất lượng dịch vụ (QoS flows) vào các kênh mang dữ liệu vô tuyến phù hợp. Lớp này giúp mạng 5G NR hỗ trợ nhiều loại dịch vụ khác nhau với yêu cầu về độ trễ, độ tin cậy và tốc độ dữ liệu khác nhau.
- PDCP (Packet Data Convergence Protocol): Là lớp giao thức xuất hiện trong cả mặt phẳng người dùng và mặt phẳng điều khiển. Trong mặt phẳng người dùng, PDCP thực hiện các chức năng như nén tiêu đề, mã hóa bảo mật, sắp xếp lại gói và xử lý trùng lặp gói dữ liệu. Trong mặt phẳng điều khiển, PDCP hỗ trợ bảo vệ và truyền tải các thông điệp báo hiệu giữa UE và gNB.
- RRC (Radio Resource Control): Là lớp giao thức thuộc mặt phẳng điều khiển, chịu trách nhiệm quản lý kết nối vô tuyến giữa UE và gNB. RRC thực hiện các chức năng như thiết lập, duy trì, cấu hình lại và giải phóng kết nối vô tuyến, đồng thời hỗ trợ quản lý tài nguyên vô tuyến và trạng thái kết nối của UE.
- NAS (Non-Access Stratum): Là lớp báo hiệu giữa UE và mạng lõi 5G, được truyền qua gNB nhưng không kết thúc tại gNB. NAS phục vụ các thủ tục như đăng ký mạng, xác thực, quản lý truy nhập, quản lý di động và quản lý phiên kết nối dữ liệu.
- Lower Layers: Các lớp thấp hơn bao gồm RLC (radio link control) hỗ trợ phân mảnh, ghép lại, sắp xếp và kiểm soát truyền lại dữ liệu giữa các lớp giao thức, MAC và lớp vật lý, MAC (medium access control) đảm nhiệm việc lập lịch truyền dẫn, ghép kênh dữ liệu, quản lý truy nhập tài nguyên vô tuyến và ánh xạ dữ liệu xuống các kênh truyền phù hợp, và lớp vật lý thực hiện các chức năng truyền dẫn tín hiệu.

- UPF (User Plane Function): Là chức năng mặt phẳng người dùng trong mạng lõi 5G, chịu trách nhiệm định tuyến và chuyển tiếp dữ liệu người dùng giữa mạng truy nhập vô tuyến và mạng bên ngoài. UPF đóng vai trò quan trọng trong việc kết nối người dùng với Internet hoặc các mạng dữ liệu khác.
- AMF (Access and Mobility Management Function): Là chức năng quản lý truy nhập và di động trong mạng lõi 5G. AMF xử lý các thủ tục báo hiệu như đăng ký mạng, xác thực, quản lý truy nhập và quản lý di động của UE.
- External Network: Là mạng bên ngoài mà người dùng truy cập thông qua hệ thống 5G NR, chẳng hạn như Internet, máy chủ dịch vụ hoặc các mạng dữ liệu chuyên dụng.


Trong công nghệ 5G NR, tín hiệu được thiết kế linh hoạt thông qua nhiều tham số kỹ thuật quan trọng, trong đó có băng thông, khoảng cách sóng mang con (subcarrier spacing, SCS), cấu trúc khung và khối tín hiệu đồng bộ (synchronization signal block, SSB). Băng thông quyết định phạm vi tần số mà tín hiệu chiếm dụng; khi băng thông càng lớn, khả năng truyền tải dữ liệu càng cao nhưng vùng phổ quan sát được trên ảnh phổ cũng mở rộng hơn. SCS là một thành phần quan trọng trong hệ numerology của 5G NR, ảnh hưởng đến cách các sóng mang con được bố trí trong miền tần số và làm thay đổi mật độ năng lượng của tín hiệu. Bên cạnh đó, cấu trúc khung linh hoạt cho phép 5G NR điều chỉnh cách phân bổ tài nguyên theo thời gian để phù hợp với các yêu cầu dịch vụ khác nhau, từ đó làm thay đổi mức độ liên tục của tín hiệu trong miền thời gian. Ngoài ra, SSB hỗ trợ quá trình đồng bộ và truy nhập ban đầu giữa UE và mạng, đồng thời có thể tạo ra các mẫu tín hiệu đặc trưng trong miền thời gian–tần số. Vì vậy, sự thay đổi của các tham số trên làm cho hình thái phổ của 5G NR trở nên đa dạng và đặt ra yêu cầu mô hình phân đoạn phải học được các đặc trưng phổ có tính khái quát.

Nhìn chung, 5G NR là một hệ thống truyền thông có cấu trúc linh hoạt, trong đó sự thay đổi của băng thông, SCS, cấu trúc khung và các thành phần đồng bộ làm cho hình thái phổ của tín hiệu trở nên đa dạng. Khi được biểu diễn trên ảnh phổ, 5G NR thường tạo thành vùng năng lượng có băng thông tương đối rộng, nhưng mức độ liên tục, mật độ năng lượng và biên phổ có thể thay đổi theo cấu hình hệ thống, công suất phát và điều kiện kênh truyền. Trong điều kiện SNR thấp hoặc khi chồng lấn với LTE và ASR, ranh giới giữa 5G NR với các lớp tín hiệu khác có thể trở nên không rõ ràng. Vì vậy, việc nhận diện và phân đoạn chính xác tín hiệu 5G NR đòi hỏi mô hình phải học được các đặc trưng phổ có tính khái quát, đồng thời đủ khả năng phân biệt 5G NR với các tín hiệu truyền thông và radar cùng tồn tại trong môi trường phổ.

2.1.4 Tổng quan về tín hiệu radar ASR

ASR là radar giám sát hàng không, được sử dụng nhằm phát hiện, giám sát và theo dõi mục tiêu bay trong khu vực quan sát, đặc biệt là vùng không phận xung quanh sân bay. Khác với

LTE và 5G NR là các hệ thống truyền thông di động phục vụ truyền dữ liệu giữa thiết bị người dùng và mạng, ASR hoạt động dựa trên nguyên lý phát xung điện từ ra môi trường và thu nhận tín hiệu phản xạ từ mục tiêu. Thông qua thời gian trễ, cường độ phản xạ, hướng quét và sự thay đổi tần số do hiệu ứng Doppler, hệ thống radar có thể suy ra các thông tin quan trọng như khoảng cách, hướng, vận tốc tương đối và quỹ đạo di chuyển của mục tiêu. Do đó, tín hiệu ASR có đặc trưng khác biệt rõ rệt so với tín hiệu truyền thông di động, đặc biệt ở tính chất phát xung, thời gian xuất hiện ngắn và mức năng lượng có thể tập trung trong một khoảng thời gian nhất định.



Hình 2.3: Kiến trúc tổng quan của hệ thống radar giám sát hàng không ASR.

Kiến trúc tổng quan của hệ thống ASR được thể hiện ở Hình 2.3. Về cơ bản, hệ thống bao gồm khối điều khiển trung tâm, khối tạo dạng sóng, bộ khuếch đại công suất, bộ chuyển mạch phát-thu, ăng-ten, bộ thu RF và các khối xử lý tín hiệu phía sau. Trong quá trình hoạt động, khối tạo dạng sóng sinh tín hiệu radar theo cấu hình được thiết lập. Tín hiệu này sau đó được khuếch đại công suất và đưa đến ăng-ten thông qua bộ chuyển mạch phát-thu để phát ra môi trường. Khi tín hiệu gặp mục tiêu, một phần năng lượng được phản xạ trở lại ăng-ten. Tín hiệu phản xạ được đưa qua bộ thu RF, sau đó tiếp tục được xử lý bởi các khối nén xung, loại bỏ nhiễu nền, phát hiện và bám mục tiêu trước khi chuyển thông tin đến hệ thống kiểm soát không lưu. Các thành phần chính trong kiến trúc ASR có thể được mô tả như sau:

- **Control Unit:** Là khối điều khiển trung tâm của hệ thống radar, có nhiệm vụ điều phối quá trình phát, thu và xử lý tín hiệu. Khối này thiết lập các tham số hoạt động như dạng sóng phát, chu kỳ phát xung, thời điểm chuyển đổi giữa chế độ phát và thu, cũng như điều khiển các khối xử lý phía sau.
- **Waveform Generation:** Là khối tạo dạng sóng radar, có nhiệm vụ sinh tín hiệu phát theo cấu hình mong muốn. Dạng sóng radar có thể được thiết kế với các đặc trưng như độ rộng xung, băng thông, tần số sóng mang và chu kỳ lặp xung, từ đó ảnh hưởng trực tiếp đến khả năng phân giải và phát hiện mục tiêu.
- **Power Amplifier:** Là bộ khuếch đại công suất, có chức năng tăng công suất của tín hiệu radar trước khi phát ra môi trường. Công suất phát càng lớn thì khả năng phát hiện mục tiêu ở khoảng cách xa càng được cải thiện, tuy nhiên đồng thời cũng làm tăng mức năng lượng của

tín hiệu trên phổ quan sát.

- T/R Switch (Transmit/Receive Switch): Là bộ chuyển mạch phát-thu, có nhiệm vụ chuyển đổi đường tín hiệu giữa chế độ phát và chế độ thu. Khi radar phát xung, T/R Switch kết nối bộ phát với ăng-ten; khi radar thu tín hiệu phản xạ, khối này chuyển ăng-ten sang bộ thu RF để tiếp nhận tín hiệu phản hồi từ mục tiêu.
- Antenna: Là ăng-ten dùng để phát tín hiệu radar ra không gian và thu tín hiệu phản xạ từ mục tiêu. Trong hệ thống ASR, ăng-ten thường thực hiện quét theo phương vị để bao phủ một vùng không gian rộng, giúp radar phát hiện và theo dõi nhiều mục tiêu trong khu vực giám sát.
- Target Radar Cross Section: Là đặc trưng phản xạ radar của mục tiêu, thường được gọi là tiết diện phản xạ radar (radar cross section, RCS). RCS cho biết mức độ mục tiêu phản xạ năng lượng radar trở lại phía máy thu. Mục tiêu có RCS lớn thường tạo tín hiệu phản xạ mạnh hơn, trong khi mục tiêu có RCS nhỏ có thể khó phát hiện hơn trong môi trường nhiễu.
- RF Receiver: Là bộ thu tần số vô tuyến, có nhiệm vụ tiếp nhận tín hiệu phản xạ từ ăng-ten, khuếch đại, lọc và chuyển đổi tín hiệu về dạng phù hợp cho các bước xử lý tiếp theo. Chất lượng của bộ thu RF ảnh hưởng trực tiếp đến khả năng phát hiện các tín hiệu phản xạ yếu.
- Pulse Compression: Là khối nén xung, được sử dụng nhằm cải thiện độ phân giải khoảng cách trong khi vẫn duy trì năng lượng phát đủ lớn. Kỹ thuật này cho phép radar phát xung có độ dài tương đối lớn nhưng sau xử lý vẫn đạt được khả năng phân biệt mục tiêu tốt hơn theo khoảng cách.
- Clutter Rejection: Là khối loại bỏ clutter, tức các thành phần phản xạ không mong muốn từ mặt đất, công trình, thời tiết hoặc các vật thể tĩnh trong môi trường. Việc loại bỏ clutter giúp tăng khả năng phát hiện mục tiêu thật, đặc biệt trong các khu vực có nhiều phản xạ nền.
- Detection Tracking: Là khối phát hiện và bám mục tiêu. Sau khi tín hiệu đã được xử lý và loại bỏ nhiễu nền, khối này xác định sự tồn tại của mục tiêu, ước lượng vị trí và theo dõi sự thay đổi của mục tiêu theo thời gian.
- ATC (Air Traffic Control): Là hệ thống kiểm soát không lưu sử dụng thông tin từ radar để giám sát, quản lý và hỗ trợ điều phối hoạt động bay. Dữ liệu từ khối phát hiện và bám mục tiêu được chuyển đến ATC nhằm phục vụ quá trình theo dõi và đảm bảo an toàn hàng không.

Các tham số của tín hiệu: Trong hệ thống ASR, tín hiệu radar được đặc trưng bởi nhiều tham số quan trọng như tần số sóng mang, công suất phát, độ rộng xung, băng thông tín hiệu, chu kỳ lặp xung và tốc độ quét của ăng-ten. Độ rộng xung và băng thông ảnh hưởng đến khả

năng phân giải khoảng cách, trong khi chu kỳ lặp xung quyết định mật độ xuất hiện của các xung radar theo thời gian. Công suất phát và đặc tính phản xạ của mục tiêu ảnh hưởng đến cường độ tín hiệu thu được, còn chuyển động tương đối giữa radar và mục tiêu có thể gây ra dịch Doppler. Các yếu tố này làm cho tín hiệu ASR có hình thái phổ khác biệt so với LTE và 5G NR.

Nhìn chung, ASR là hệ thống radar hoạt động theo cơ chế phát xung và thu tín hiệu phản xạ, nên tín hiệu của nó thường không xuất hiện liên tục theo thời gian như các tín hiệu truyền thông di động. Khi được biểu diễn trên ảnh phổ, ASR thường tạo thành các vệt năng lượng ngắn, rời rạc hoặc có cường độ cao trong một khoảng thời gian nhất định. Trong điều kiện SNR thấp, các xung ASR yếu có thể bị che khuất bởi nhiễu nền; ngược lại, một số thành phần nhiễu cục bộ có năng lượng cao cũng có thể bị nhận nhầm thành tín hiệu radar. Khi ASR cùng tồn tại với LTE và 5G NR, các xung radar có thể chồng lấn với vùng phổ rộng của tín hiệu truyền thông, làm cho ranh giới phân đoạn trở nên phức tạp. Vì vậy, mô hình phân đoạn cần có khả năng nhận diện đồng thời các vùng phổ liên tục của LTE và 5G NR cũng như các cấu trúc xung ngắn, rời rạc của tín hiệu ASR.

2.2 LÝ THUYẾT VỀ PHÂN TÍCH THỜI GIAN–TẦN SỐ

Sau khi truyền qua môi trường vô tuyến, tín hiệu thu được thường chịu ảnh hưởng bởi nhiễu, fading, dịch Doppler và sự chồng lấn giữa nhiều nguồn phát khác nhau. Trong bài toán nhận diện tín hiệu 5G NR, LTE và ASR, việc chỉ quan sát tín hiệu trong một miền riêng lẻ thường không đủ để mô tả đầy đủ đặc trưng của tín hiệu. Miền thời gian cho biết sự thay đổi biên độ theo thời gian, nhưng không thể hiện rõ thành phần tần số mà tín hiệu chiếm dụng. Ngược lại, miền tần số cho biết tín hiệu có năng lượng tập trung ở những dải tần nào, nhưng không thể hiện được thời điểm các thành phần tần số đó xuất hiện hoặc biến mất. Vì vậy, phân tích thời gian–tần số đóng vai trò quan trọng trong việc biểu diễn đồng thời sự biến thiên của tín hiệu theo cả thời gian và tần số.

Trong các hệ thống vô tuyến hiện đại, đặc biệt là môi trường có sự đồng tồn tại giữa tín hiệu truyền thông và radar, đặc trưng tín hiệu thường thay đổi theo thời gian. LTE có xu hướng tạo vùng năng lượng tương đối liên tục trên một dải tần nhất định, 5G NR có mức chiếm dụng phổ linh hoạt hơn do thay đổi băng thông và cấu hình truyền dẫn, trong khi ASR thường xuất hiện dưới dạng các xung ngắn và rời rạc. Do đó, biểu diễn thời gian–tần số giúp quan sát rõ hơn hình thái phổ của từng loại tín hiệu, tạo cơ sở cho việc chuyển bài toán nhận diện tín hiệu vô tuyến thành bài toán phân đoạn trên ảnh phổ.

2.2.1 Hạn chế của phân tích miền thời gian và miền tần số

Phân tích trong miền thời gian biểu diễn tín hiệu dưới dạng sự biến thiên biên độ theo thời gian. Cách biểu diễn này hữu ích trong việc quan sát trực tiếp các sự kiện tức thời, chẳng hạn như sự xuất hiện của xung radar, sự thay đổi mức năng lượng hoặc thời điểm bắt đầu và kết thúc của một đoạn tín hiệu. Tuy nhiên, miền thời gian không cho biết rõ tín hiệu đang chiếm dụng thành phần tần số nào. Vì vậy, đối với các tín hiệu truyền thông có cấu trúc đa sóng mang như LTE và 5G NR, việc chỉ dựa vào dạng sóng thời gian sẽ gây khó khăn trong việc phân biệt đặc trưng phổ của từng loại tín hiệu.

Ngược lại, phân tích trong miền tần số cho phép xác định các thành phần phổ tần cấu thành tín hiệu thông qua biến đổi Fourier. Biểu diễn này cho biết tín hiệu có năng lượng tập trung ở những dải tần nào, từ đó hỗ trợ đánh giá phạm vi chiếm dụng phổ. Tuy nhiên, phổ Fourier truyền thống thường được tính trên toàn bộ tín hiệu nên không thể hiện được sự thay đổi của tín hiệu theo thời gian. Đối với các tín hiệu không dừng, chẳng hạn như tín hiệu radar ASR dạng xung hoặc tín hiệu truyền thông có tài nguyên thay đổi theo thời gian, việc chỉ sử dụng miền tần số có thể làm mất thông tin về thời điểm xuất hiện của từng thành phần phổ. Do đó, cần sử dụng phân tích thời gian–tần số để kết hợp ưu điểm của cả hai miền biểu diễn.

2.2.2 Biến đổi Fourier thời gian ngắn


STFT là một kỹ thuật phân tích thời gian–tần số được sử dụng rộng rãi trong xử lý tín hiệu. Ý tưởng chính của STFT là chia tín hiệu thành nhiều đoạn ngắn bằng một hàm cửa sổ, sau đó áp dụng biến đổi Fourier cho từng đoạn. Nhờ đó, STFT cho phép quan sát thành phần tần số của tín hiệu tại từng khoảng thời gian cục bộ, thay vì chỉ thu được một phổ tổng thể cho toàn bộ tín hiệu. Cách biểu diễn này đặc biệt phù hợp với các tín hiệu vô tuyến không dừng, trong đó đặc trưng phổ có thể thay đổi theo thời gian.

Với tín hiệu rời rạc $x[n]$, STFT được thực hiện bằng cách lấy từng đoạn tín hiệu cục bộ thông qua một hàm cửa sổ, sau đó áp dụng biến đổi Fourier cho đoạn tín hiệu đó. Gọi m là chỉ số khung thời gian, k là chỉ số tần số, $\mathcal{M}$ là bước dịch cửa sổ và $\mathcal{K}$ là số điểm FFT, biểu diễn STFT rời rạc có thể được viết như sau:

$$\mathcal{X}[m, k] = \sum_{\ell=0}^{L-1} x[\ell + m\mathcal{M}] g[\ell] e^{-j\frac{2\pi k\ell}{\mathcal{K}}}, \quad (2.2)$$

trong đó $\mathcal{X}[m, k]$ biểu diễn hệ số thời gian–tần số tại khung thời gian thứ m và bin tần số thứ k , $x[\ell + m\mathcal{M}]$ là đoạn tín hiệu được lấy tại vị trí cửa sổ hiện tại, $g[\ell]$ là hàm cửa sổ có độ dài L , $\mathcal{M}$

là khoảng dịch giữa hai cửa sổ liên tiếp và K là độ dài của phép biến đổi Fourier rời rạc. Thành phần mũ phức $e^{-j\frac{2\pi k\ell}{K}}$ đóng vai trò phân tích đoạn tín hiệu theo các thành phần tần số rời rạc. Hình 2.4 minh họa quá trình chia tín hiệu thành các khung ngắn, nhân với hàm cửa sổ và thực hiện biến đổi Fourier cho từng khung.



Hình 2.4: Minh họa quá trình biến đổi Fourier thời gian ngắn để tạo biểu diễn thời gian–tần số.

Trong STFT, hàm cửa sổ quyết định cách tín hiệu được quan sát trong từng khoảng thời gian ngắn, do đó ảnh hưởng trực tiếp đến sự đánh đổi giữa độ phân giải thời gian và độ phân giải tần số. Khi cửa sổ có độ dài nhỏ, STFT có khả năng định vị tốt hơn các thay đổi nhanh theo thời gian, nhưng độ phân giải tần số bị giảm. Ngược lại, cửa sổ dài giúp phân biệt các thành phần tần số tốt hơn, nhưng làm mờ thông tin về thời điểm xuất hiện của tín hiệu. Một lựa chọn phổ biến là cửa sổ Hann, được định nghĩa bởi:

$$g[\ell] = \frac{1}{2} \left(1 - \cos \left(\frac{2\pi\ell}{L-1} \right) \right), \quad 0 \leq \ell \leq L-1, \quad (2.3)$$

cửa sổ Hann giúp làm giảm rò rỉ phổ ở biên cửa sổ, từ đó tạo ra biểu diễn thời gian–tần số ổn định hơn khi phân tích các tín hiệu vô tuyến không dừng.

2.2.3 Ảnh phổ của tín hiệu vô tuyến

Kết quả của STFT là một ma trận phức biểu diễn sự phân bố của tín hiệu trên mặt phẳng thời gian–tần số. Để sử dụng trong các bài toán học sâu, ma trận này thường được chuyển thành ảnh phổ bằng cách lấy biên độ hoặc công suất của hệ số STFT. Ảnh phổ cho phép biểu diễn trực quan mức năng lượng của tín hiệu tại từng vị trí thời gian và tần số. Trong biểu diễn này, trục

thời gian thể hiện sự thay đổi của tín hiệu theo thời gian, trục tần số thể hiện phạm vi phổ mà tín hiệu chiếm dụng, còn cường độ điểm ảnh thể hiện mức năng lượng tương ứng. Ảnh phổ có thể được biểu diễn thông qua công suất của hệ số STFT như sau:

$$S(t, f) = |\mathbf{V}(t, f)|^2, \quad (2.4)$$

trong đó $S(t, f)$ là giá trị năng lượng của tín hiệu tại vị trí thời gian t và tần số f . Đối với bài toán phân đoạn phổ tín hiệu, ảnh phổ đóng vai trò như một ảnh đầu vào hai chiều, trong đó mỗi điểm ảnh tương ứng với một vị trí thời gian–tần số cần được gán nhãn. Các lớp nhãn có thể bao gồm 5G NR, LTE, ASR và nhiễu nền. Biểu diễn này giúp làm rõ sự khác biệt hình thái giữa các loại tín hiệu: LTE thường tạo vùng phổ tương đối liên tục theo thời gian, 5G NR có vùng chiếm dụng phổ linh hoạt hơn do thay đổi cấu hình truyền dẫn, còn ASR thường xuất hiện dưới dạng các vệt năng lượng ngắn và rời rạc. Vì vậy, ảnh phổ là biểu diễn phù hợp để làm cơ sở cho các mô hình phân đoạn học sâu trong nhận diện tín hiệu vô tuyến.

2.2.4 So sánh tổng quan giữa các kỹ thuật phân tích thời gian–tần số

Trong xử lý tín hiệu, nhiều kỹ thuật có thể được sử dụng để biểu diễn tín hiệu trong miền thời gian–tần số. Trong đó, ba phương pháp thường gặp là STFT, biến đổi wavelet liên tục (continuous wavelet transform, CWT) và phân bố Wigner–Ville (Wigner–Ville distribution, WVD). Các phương pháp này đều nhằm mô tả sự thay đổi của tín hiệu theo thời gian và tần số, nhưng khác nhau về nguyên lý xử lý, độ phân giải và khả năng diễn giải. Bảng 2.1 trình bày tóm tắt nguyên lý, biểu thức toán học và đặc điểm chính của ba kỹ thuật này.

Việc lựa chọn kỹ thuật phân tích thời gian–tần số phụ thuộc vào đặc tính của tín hiệu và mục tiêu xử lý. Mỗi phương pháp có ưu điểm và hạn chế riêng, do đó cần xem xét mức độ phù hợp của chúng đối với bài toán biểu diễn tín hiệu vô tuyến trong môi trường có nhiều thành phần chồng lấn.

STFT:

- **Ưu điểm:** STFT có nguyên lý đơn giản, dễ triển khai và có thể tính toán hiệu quả thông qua FFT. Kết quả của STFT là ảnh phổ có cấu trúc trực quan, trong đó trục thời gian và trục tần số được biểu diễn rõ ràng. Điều này giúp STFT phù hợp với các bài toán cần chuyển tín hiệu một chiều thành ảnh hai chiều, đặc biệt là các bài toán nhận diện hoặc phân đoạn tín hiệu vô tuyến bằng học sâu.
- **Nhược điểm:** Hạn chế chính của STFT là độ phân giải thời gian và tần số phụ thuộc vào độ dài cửa sổ cố định. Nếu cửa sổ quá ngắn, biểu diễn có khả năng định vị tốt theo thời gian

Bảng 2.1: Tóm tắt một số kỹ thuật phân tích tín hiệu trong miền thời gian–tần số.

Phương pháp	Nguyên lý	Biểu thức toán học	Đặc điểm chính
STFT	Chia tín hiệu thành các đoạn ngắn bằng hàm cửa sổ, sau đó áp dụng biến đổi Fourier cho từng đoạn để thu được phổ cục bộ.	$\mathfrak{X}[m, k] = \sum_{\ell=0}^{L-1} x[\ell + mH] g[\ell] e^{-j2\pi k\ell/K}$ Trong đó: $x[n]$: tín hiệu rời rạc $g[\ell]$: hàm cửa sổ m: chỉ số khung thời gian k: chỉ số tần số H: bước dịch cửa sổ K: số điểm FFT	Tạo biểu diễn thời gian–tần số trực quan. Độ phân giải phụ thuộc vào độ dài cửa sổ.
CWT	Phân tích tín hiệu bằng cách so khớp với các phiên bản dịch chuyển và co giãn của một wavelet mẹ.	$\mathcal{W}_x(a, b) = \frac{1}{\sqrt{ a }} \int_{-\infty}^{\infty} x(t) \psi^*\left(\frac{t-b}{a}\right) dt$ Trong đó: $x(t)$: tín hiệu cần phân tích $\psi(t)$: wavelet mẹ $\psi^*(t)$: liên hợp phức của wavelet a: hệ số tỉ lệ b: vị trí dịch thời gian	Có khả năng phân tích đa độ phân giải. Kết quả phụ thuộc vào lựa chọn wavelet mẹ.
WVD	Biểu diễn tín hiệu thông qua hàm tự tương quan tức thời, sau đó biến đổi Fourier theo biến trễ để thu được phân bố thời gian–tần số.	$\mathcal{D}_x(t, \nu) = \int_{-\infty}^{\infty} x\left(t + \frac{\lambda}{2}\right) x^*\left(t - \frac{\lambda}{2}\right) e^{-j2\pi\nu\lambda} d\lambda$ Trong đó: $x(t)$: tín hiệu đầu vào $x^*(t)$: liên hợp phức của tín hiệu t: thời gian ν: tần số λ: biến trễ	Có độ tập trung thời gian–tần số cao, nhưng dễ xuất hiện thành phần chéo khi tín hiệu có nhiều thành phần.

nhưng độ phân giải tần số giảm. Ngược lại, nếu cửa sổ quá dài, các thành phần tần số được phân biệt tốt hơn nhưng thông tin về thời điểm xuất hiện của tín hiệu có thể bị làm mờ.

CWT:

- Ưu điểm: CWT có khả năng phân tích đa độ phân giải nhờ thay đổi thang của wavelet mẹ. Phương pháp này có thể đạt độ phân giải thời gian tốt đối với các thành phần tần số cao và độ phân giải tần số tốt đối với các thành phần tần số thấp. Vì vậy, CWT phù hợp với các tín hiệu có đặc trưng biến thiên theo nhiều thang thời gian khác nhau.
- Nhược điểm: CWT thường có chi phí tính toán cao hơn STFT do phải xét nhiều hệ số tỉ lệ và vị trí dịch. Ngoài ra, kết quả phân tích phụ thuộc đáng kể vào việc lựa chọn wavelet mẹ. Nếu wavelet được chọn không phù hợp với đặc trưng tín hiệu, biểu diễn thu được có thể không phản ánh rõ các thành phần cần quan sát.

WVD:

- Ưu điểm: WVD có khả năng tạo biểu diễn thời gian–tần số với độ tập trung cao, giúp quan sát rõ sự phân bố năng lượng của tín hiệu trong trường hợp tín hiệu đơn thành phần hoặc

có cấu trúc đơn giản. Nhờ đặc điểm này, WVD có thể cung cấp thông tin chi tiết về sự biến thiên đồng thời theo thời gian và tần số.

- **Nhược điểm:** Hạn chế lớn của WVD là sự xuất hiện của các thành phần chéo khi tín hiệu có nhiều thành phần hoặc khi nhiều nguồn tín hiệu chồng lấn. Các thành phần chéo này có thể tạo ra vùng năng lượng giả trên mặt phẳng thời gian–tần số, làm cho biểu diễn khó diễn giải và không thuận lợi trong các môi trường phổ phức tạp.

2.3 TỔNG QUAN VỀ LÝ THUYẾT HỌC SÂU


2.3.1 Khái niệm cơ bản về học sâu

Học sâu (deep learning, DL) là một nhánh quan trọng của học máy, được xây dựng dựa trên các mạng nơ-ron nhân tạo có nhiều lớp xử lý liên tiếp [51]. Thay vì yêu cầu con người tự thiết kế đặc trưng đầu vào, học sâu cho phép mô hình tự động học các biểu diễn phù hợp trực tiếp từ dữ liệu thông qua quá trình huấn luyện. Nhờ khả năng này, học sâu đã trở thành nền tảng của nhiều hệ thống thông minh hiện đại trong các lĩnh vực như thị giác máy tính, xử lý ngôn ngữ tự nhiên, nhận dạng tiếng nói và phân tích dữ liệu.

Một mạng nơ-ron sâu thường bao gồm lớp đầu vào, các lớp ẩn và lớp đầu ra. Lớp đầu vào có nhiệm vụ tiếp nhận dữ liệu ban đầu. Các lớp ẩn thực hiện quá trình xử lý và biến đổi dữ liệu qua nhiều mức độ khác nhau. Ở các lớp đầu, mô hình thường học những đặc trưng đơn giản và mang tính cục bộ. Khi đi qua nhiều lớp hơn, các đặc trưng này dần được kết hợp để tạo thành những biểu diễn có tính trừu tượng cao hơn. Lớp đầu ra sử dụng các biểu diễn đã học được để tạo ra kết quả dự đoán phù hợp với từng bài toán cụ thể.

Quá trình huấn luyện của mạng nơ-ron sâu thường bắt đầu bằng bước lan truyền tiến, trong đó dữ liệu được truyền từ lớp đầu vào qua các lớp ẩn đến lớp đầu ra để tạo ra dự đoán [52]. Kết quả dự đoán này được so sánh với nhãn thực tế thông qua một hàm mất mát nhằm đánh giá mức độ sai lệch của mô hình. Sau đó, thuật toán lan truyền ngược được sử dụng để đưa thông tin sai số quay trở lại các lớp trước, từ đó cập nhật các trọng số trong mạng. Quá trình này được lặp lại nhiều lần để mô hình dần cải thiện khả năng dự đoán.


Hình 2.5 minh họa cấu trúc tổng quát của một mạng nơ-ron sâu. Các nút trong hình biểu diễn các đơn vị xử lý, còn các đường nối thể hiện sự truyền thông tin giữa các lớp. Dữ liệu được đưa vào mạng thông qua lớp đầu vào, sau đó được xử lý qua nhiều lớp ẩn trước khi tạo ra kết quả tại lớp đầu ra. Số lượng lớp ẩn và số lượng nút trong mỗi lớp có thể thay đổi tùy thuộc vào độ phức tạp của bài toán và khả năng tính toán của hệ thống.



Hình 2.5: Cấu trúc cơ bản của mạng nơ-ron sâu gồm lớp đầu vào, các lớp ẩn và lớp đầu ra.

Trong thị giác máy tính, học sâu được ứng dụng rộng rãi cho nhiều nhiệm vụ như phân loại ảnh, phát hiện đối tượng, nhận dạng khuôn mặt và phân đoạn ngữ nghĩa. Các mô hình học sâu có khả năng học đặc trưng trực tiếp từ dữ liệu ảnh, giúp giảm sự phụ thuộc vào các bước xử lý thủ công. Đây là cơ sở quan trọng cho sự phát triển của nhiều kiến trúc xử lý ảnh hiện đại, trong đó mạng nơ-ron tích chập là một trong những kiến trúc tiêu biểu và được sử dụng phổ biến nhất.

2.3.2 Mạng nơ-ron tích chập



Hình 2.6: Minh họa quá trình trích xuất đặc trưng bằng các bộ lọc trong mạng CNN.

Mạng nơ-ron tích chập (convolutional neural network, CNN) là một kiến trúc học sâu được sử dụng rộng rãi trong xử lý ảnh [53]. CNN được thiết kế để khai thác cấu trúc không gian của dữ liệu thông qua các lớp tích chập. Khác với mạng nơ-ron kết nối đầy đủ, CNN không xử lý ảnh như một vector một chiều mà giữ lại quan hệ lân cận giữa các điểm ảnh. Điều này giúp mô hình học được các đặc trưng cục bộ một cách hiệu quả, đồng thời giảm đáng kể số lượng tham số cần huấn luyện.

Thành phần quan trọng nhất của CNN là lớp tích chập. Trong lớp này, các bộ lọc nhỏ được

trượt trên ảnh đầu vào để tạo ra các bản đồ đặc trưng. Mỗi bộ lọc có thể học một dạng đặc trưng khác nhau, chẳng hạn như cạnh, đường biên, vùng chuyển mức sáng hoặc các mẫu kết cấu cục bộ. Khi nhiều bộ lọc được sử dụng đồng thời, mô hình có thể thu được nhiều bản đồ đặc trưng khác nhau, giúp biểu diễn ảnh đầu vào dưới nhiều khía cạnh.

Một đặc điểm nổi bật của CNN là cơ chế chia sẻ trọng số. Cùng một bộ lọc được áp dụng trên nhiều vị trí khác nhau của ảnh, cho phép mô hình phát hiện cùng một loại đặc trưng tại nhiều vùng khác nhau. Cơ chế này giúp CNN giảm số lượng tham số so với các mạng kết nối đầy đủ và cải thiện khả năng tổng quát khi xử lý dữ liệu ảnh. Nhờ đó, CNN trở thành lựa chọn phù hợp cho các bài toán cần trích xuất đặc trưng không gian.

CNN thường được xây dựng bằng cách xếp chồng nhiều lớp xử lý. Các tầng đầu thường học những đặc trưng đơn giản như cạnh, góc hoặc texture. Các tầng sâu hơn kết hợp các đặc trưng này để hình thành những biểu diễn phức tạp hơn, có khả năng phản ánh cấu trúc và ngữ nghĩa của ảnh. Nhờ khả năng học đặc trưng theo nhiều cấp độ, CNN được sử dụng rộng rãi trong các bài toán như phân loại ảnh, phát hiện đối tượng và phân đoạn ngữ nghĩa.


Hình 2.6 minh họa quá trình trích xuất đặc trưng trong mạng CNN. Ảnh đầu vào gồm nhiều kênh được xử lý bởi một tập các bộ lọc tích chập. Mỗi bộ lọc tạo ra một bản đồ đặc trưng tương ứng, trong đó thể hiện một loại thông tin được học từ dữ liệu đầu vào. Các bản đồ đặc trưng này tiếp tục được truyền qua các lớp sau để tạo ra những biểu diễn có mức độ trừu tượng cao hơn.

Bên cạnh lớp tích chập, CNN thường kết hợp thêm các thành phần như hàm kích hoạt, lớp chuẩn hóa và lớp giảm kích thước. Hàm kích hoạt giúp mô hình học các quan hệ phi tuyến, lớp chuẩn hóa hỗ trợ ổn định quá trình huấn luyện, còn các thao tác giảm kích thước giúp giảm chi phí tính toán và mở rộng vùng quan sát của mô hình. Trong các bài toán phân đoạn ngữ nghĩa, CNN thường đóng vai trò là bộ trích xuất đặc trưng, sau đó kết hợp với các cơ chế khôi phục độ phân giải để tạo ra bản đồ dự đoán ở cấp điểm ảnh.

2.3.3 Mạng nơ-ron tích chập tách biệt theo chiều sâu

Mạng nơ-ron tích chập tách biệt theo chiều sâu (depthwise separable convolution) là một cải tiến quan trọng từ phép tích chập truyền thống, được thiết kế nhằm tối ưu hóa khối lượng tính toán và giảm thiểu số lượng tham số của mô hình mà vẫn duy trì được hiệu suất trích xuất đặc trưng [54]. Thay vì thực hiện việc tính toán đồng thời trên cả không gian (chiều rộng, chiều cao) và chiều sâu (số lượng kênh) như lớp tích chập chuẩn, kỹ thuật này phân tách quá trình trên thành hai bước xử lý hoàn toàn độc lập.

Như được minh họa trong Hình 2.7, giai đoạn đầu tiên là tích chập theo chiều sâu (depthwise convolution). Trong bước này, mô hình không sử dụng các bộ lọc đa kênh để gộp thông tin ngay



Hình 2.7: Minh họa tích chập theo chiều sâu và tích chập điểm: Tích chập theo chiều sâu áp dụng một bộ lọc không gian riêng cho từng kênh đầu vào, trong khi tích chập điểm sử dụng các bộ lọc 1×1 để kết hợp thông tin giữa các kênh và tạo ra số kênh đầu ra mong muốn.


lập tức. Thay vào đó, mỗi kênh của dữ liệu đầu vào sẽ được áp dụng riêng một bộ lọc không gian duy nhất. Cách tiếp cận này cho phép mạng học các đặc trưng không gian cục bộ (như biên, vân, góc cạnh) một cách độc lập cho từng kênh tín hiệu, giúp tiết kiệm đáng kể chi phí tính toán.

Giai đoạn thứ hai là tích chập điểm (pointwise convolution). Sau khi các đặc trưng không gian đã được trích xuất riêng lẻ, mô hình sử dụng các bộ lọc có kích thước 1×1 lướt qua toàn bộ bản đồ đặc trưng để thực hiện tổ hợp tuyến tính. Mặc dù bộ lọc 1×1 không mở rộng trường nhìn không gian, nó lại đóng vai trò cốt lõi trong việc dung hợp thông tin xuyên suốt các kênh (cross-channel). Thao tác này giúp mạng học được mối tương quan phức tạp giữa các đặc trưng ở các kênh khác nhau và đồng thời cho phép người dùng điều chỉnh linh hoạt số lượng kênh ở đầu ra.

Sự phân tách tinh tế này mang lại lợi thế vượt trội về mặt hiệu năng. Bằng cách bẻ gãy sự phụ thuộc toán học đồng thời giữa kích thước bộ lọc và độ sâu kênh, tích chập tách biệt theo chiều sâu có thể giảm số lượng phép toán thực thi và số lượng tham số xuống nhiều lần so với tích chập truyền thống. Nhờ đặc tính ưu việt này, kỹ thuật trên đã trở thành xương sống cho nhiều kiến trúc mạng gọn nhẹ nổi tiếng (như MobileNet hay Xception), đặc biệt phù hợp cho các bài toán thời gian thực hoặc triển khai trên các thiết bị di động, hệ thống nhúng có tài nguyên tính toán hạn chế.

2.4 PHÂN ĐOẠN NGỮ NGHĨA TRONG THỊ GIÁC MÁY TÍNH

2.4.1 Khái niệm phân đoạn ngữ nghĩa



Hình 2.8: Ví dụ về bài toán phân đoạn ngữ nghĩa.

Phân đoạn ảnh là một nhiệm vụ quan trọng trong thị giác máy tính, nhằm chia ảnh thành các vùng có ý nghĩa để hỗ trợ quá trình nhận diện và phân tích nội dung ảnh. Tùy theo mức độ chi tiết của đầu ra, các bài toán xử lý ảnh liên quan đến nhận diện vùng và đối tượng có thể được phân biệt như sau:

- **Phân đoạn ngữ nghĩa (semantic segmentation):** Mỗi điểm ảnh trong ảnh được gán một nhãn lớp tương ứng, nhưng không phân biệt các cá thể khác nhau thuộc cùng một lớp.
- **Phân đoạn thực thể (instance segmentation):** Mở rộng từ phân đoạn ngữ nghĩa bằng cách vừa gán nhãn lớp cho từng điểm ảnh, vừa tách riêng từng cá thể khác nhau trong cùng một lớp.
- **Phát hiện đối tượng (object detection):** Xác định vị trí và lớp của đối tượng thông qua các hộp giới hạn, thay vì gán nhãn chi tiết cho từng điểm ảnh.

Trong đó, phân đoạn ngữ nghĩa cung cấp mức mô tả chi tiết hơn so với phân loại ảnh và phát hiện đối tượng, vì kết quả đầu ra thể hiện trực tiếp vùng không gian thuộc từng lớp trong ảnh. Phân đoạn ngữ nghĩa có thể được xem là bài toán gán nhãn cho từng điểm ảnh trong một ảnh đầu vào. Mục tiêu của bài toán này là tạo ra một bản đồ phân đoạn, trong đó mỗi điểm ảnh được phân loại vào một lớp ngữ nghĩa cụ thể. Nhờ vậy, mô hình không chỉ xác định được nội dung xuất hiện trong ảnh, mà còn chỉ ra chính xác vùng nào trong ảnh thuộc về từng lớp.

Khác với phát hiện đối tượng, vốn biểu diễn vị trí đối tượng bằng hộp giới hạn, phân đoạn ngữ nghĩa tạo ra mặt nạ phân đoạn bám sát hơn theo hình dạng thực tế của vùng cần nhận diện. Tuy nhiên, phân đoạn ngữ nghĩa không tách riêng các cá thể khác nhau trong cùng một lớp. Ví dụ, nếu trong ảnh có nhiều cây, tất cả các điểm ảnh thuộc lớp “cây” sẽ được gán cùng một nhãn, thay vì phân biệt từng cây lẻ như trong phân đoạn thực thể.

Hình 2.8 minh họa một ví dụ về phân đoạn ngữ nghĩa. Trong ảnh, các vùng thuộc những lớp khác nhau như bầu trời, cây, cỏ hoặc đối tượng chính sẽ được gán các nhãn khác nhau. Các điểm ảnh cùng lớp được biểu diễn bằng cùng một màu, từ đó tạo thành một bản đồ phân loại điểm ảnh cho toàn bộ ảnh. Kết quả này giúp mô hình hiểu rõ hơn cấu trúc không gian và nội dung của cảnh trong ảnh.


2.5 TỔNG QUAN VỀ CÁC MẠNG HỌC SÂU TRONG PHÂN ĐOẠN NGỮ NGHĨA HÌNH ẢNH

Phần này tập trung phân tích các mô hình mạng học sâu tiên tiến dựa trên kiến trúc mã hóa - giải mã, được thiết kế dành riêng cho bài toán phân đoạn ngữ nghĩa hình ảnh. Cụ thể, nghiên cứu sẽ khảo sát ba mô hình phát triển theo ba hướng tiếp cận khác biệt. Trước tiên, là mô hình mã hóa - giải mã dạng một nhánh, còn được biết đến với tên gọi kiến trúc U-shape, mà điển hình là DeepLabV3+[55]. Các mô hình thuộc nhóm này thường có cấu trúc đơn giản, dễ triển khai và thuận tiện cho việc tích hợp các cải tiến nhằm nâng cao độ chính xác. Thứ hai, mô hình BiSeNet [56], tiêu biểu cho kiến trúc mạng hai nhánh, trong đó bổ sung một đường dẫn không gian song song với đường dẫn ngữ cảnh để hỗ trợ việc trích xuất và bổ sung thông tin cần thiết cho giai đoạn giải mã. Cuối cùng, mô hình SegFormer [27] được phân tích, nổi bật với việc sử dụng AM, giúp cải thiện khả năng nhận dạng các đối tượng trong ảnh, từ đó làm phong phú thêm lượng thông tin được trích xuất trong giai đoạn mã hóa.

2.5.1 U-Net++

Được phát triển dựa trên nền tảng của mạng U-Net [57], U-Net++ [58] là một kiến trúc mạng nơ-ron tích chập tiên tiến chuyên dụng cho bài toán phân đoạn ảnh ngữ nghĩa. Mặc dù U-Net tiêu chuẩn đã chứng minh được hiệu quả vượt trội nhờ thiết kế đối xứng mã hóa-giải mã (encoder-decoder) kết hợp cùng các kết nối tắt (skip connections), mô hình này vẫn bộc lộ một điểm hạn chế cốt lõi trong quá trình dung hợp thông tin. Kiến trúc tổng quan của cả hai mạng được minh họa chi tiết trong Hình 2.9.

Vấn đề căn bản của U-Net nằm ở sự chênh lệch lớn về mặt ngữ nghĩa giữa hai luồng dữ liệu khi thực hiện kết nối trực tiếp. Cụ thể, các bản đồ đặc trưng được trích xuất từ những tầng mã hóa nông thường bảo toàn rất tốt các chi tiết không gian cục bộ như đường biên, góc cạnh hoặc kết cấu vật thể. Tuy nhiên, khi đối chiếu với các đặc trưng ở nhánh giải mã tương ứng — vốn đã trải qua nhiều bước giảm mẫu (downsampling) để thu thập ngữ nghĩa trừu tượng bậc cao — sự khác biệt này khiến mạng gặp khó khăn trong việc đồng bộ hóa và tối ưu hóa thông tin phân đoạn.



Hình 2.9: Kiến trúc tổng quan của U-Net và U-Net++.

Để giải quyết triệt để khoảng cách ngữ nghĩa nói trên, U-Net++ tái cấu trúc cơ chế truyền đạt thông tin bằng cách thay thế các đường kết nối thẳng thành một mạng lưới kết nối tất lồng nhau (nested skip pathways). Phương pháp này chèn thêm một loạt các khối tích chập trung gian, đóng vai trò như một cơ chế làm "mềm" sự biến đổi đặc trưng, giúp thông tin từ nhánh mã hóa được tinh chỉnh tiệm cận dần với mức độ ngữ nghĩa của nhánh giải mã trước khi tiến hành dung hợp. Các thành tố cốt lõi làm nên sức mạnh của kiến trúc U-Net++ bao gồm:


- **Nhánh mã hóa–giải mã:** Kế thừa triết lý từ U-Net, mạng sử dụng nhánh mã hóa để nén thông tin không gian và trích xuất các dải đặc trưng từ thấp đến cao. Ngược lại, nhánh giải mã đảm nhiệm vai trò nội suy và nâng mẫu (upsampling) nhằm khôi phục lại độ phân giải ban đầu, từ đó xuất ra bản đồ dự đoán ở cấp độ điểm ảnh.
- **Kết nối tất lồng nhau:** Đây là bước đột phá của U-Net++ so với phiên bản tiền nhiệm. Việc đan xen các nút chập trung gian (intermediate nodes) tạo ra một ma trận truyền tải dữ liệu dày đặc. Quá trình này đảm bảo các bản đồ đặc trưng không bị ép buộc dung hợp đột ngột, từ đó triệt tiêu sự thiếu đồng nhất về mặt ngữ nghĩa giữa các tầng mạng.
- **Hợp nhất đặc trưng đa mức:** Kiến trúc này cho phép tích hợp đồng thời những đặc trưng giàu chi tiết hình học (từ các tầng nông) với các đặc trưng chứa đựng ngữ cảnh bao quát (từ các tầng sâu). Nhờ sự dung hợp đa dạng này, mô hình cải thiện đáng kể khả năng nhận diện các vật thể có kích thước biến thiên, đồng thời giữ được độ sắc nét tại khu vực đường

biên vật thể.

- **Giám sát sâu:** Nhằm tối ưu hóa luồng lan truyền ngược và giải quyết hiện tượng triệt tiêu đạo hàm, U-Net++ tích hợp các đầu ra phụ tại nhiều nhánh giải mã khác nhau. Cơ chế này không chỉ ép các lớp ẩn phải học được những biểu diễn có tính phân biệt cao hơn, mà còn cho phép người dùng linh hoạt cắt tỉa mạng trong giai đoạn suy luận để cân bằng giữa độ chính xác và chi phí tính toán phần cứng.

2.5.2 DeepLabV3+

Được giới thiệu bởi Chen và cộng sự [55], DeepLabV3+ là một trong những hệ tư tưởng tiên phong trong lĩnh vực phân đoạn ảnh ngữ nghĩa, nổi bật với khả năng tối ưu hóa đồng thời việc trích xuất ngữ cảnh diện rộng và khôi phục độ chính xác không gian. So với phiên bản tiền nhiệm DeepLabV3 — vốn chỉ tập trung vào nhánh mã hóa (encoder) — kiến trúc này đã tạo ra bước đột phá bằng cách tích hợp thêm một module giải mã (decoder) tinh gọn nhưng hiệu quả, nhằm khắc phục triệt để hiện tượng nhòe biên giới đối tượng. Về cấu trúc vi mô, sức mạnh biểu diễn của DeepLabV3+ được cấu thành từ ba trụ cột kỹ thuật: mạng nòng cốt (backbone), phép chập giãn nở (atrous/dilated convolution) và khối gộp không gian tháp hình kim tự tháp (Atrous Spatial Pyramid Pooling - ASPP). Sự phối hợp của các thành phần này thiết lập một cơ chế mạnh mẽ để xử lý thách thức về biến thiên tỷ lệ vật thể (scale variation) mà không làm suy hao nghiêm trọng thông tin hình học sau các pha giảm mẫu. Sơ đồ khối tổng quan của DeepLabV3+ được trình bày chi tiết trong Hình 2.10.



Hình 2.10: Kiến trúc tổng quan của mạng DeepLabV3+.

Các khối chức năng định hình nên kiến trúc DeepLabV3+ được phân tích cụ thể như sau:

- **Mạng nòng cốt trích xuất đặc trưng thô:** Mô hình triển khai một mạng nơ-ron tích chập sâu làm cơ sở trích xuất đặc trưng đa cấp độ. Backbone này chịu trách nhiệm kiến tạo

một biểu diễn phân cấp: từ các thuộc tính thị giác sơ cấp (như cạnh, góc, vân bề mặt) ở các lớp nông, cho đến những đặc trưng chứa đựng ngữ nghĩa hàm súc ở các lớp sâu. Dữ liệu đầu ra từ backbone sẽ đóng vai trò làm tín hiệu dẫn hướng cho cả khối phân tích ngữ cảnh (ASPP) lẫn nhánh giải mã phía sau.


- **Phép chập giãn nở (Atrous/Dilated Convolution):** Đây là cơ chế cốt lõi tạo nên bản sắc của họ kiến trúc DeepLab. Thay vì mở rộng kích thước ma trận lọc một cách vật lý hay lạm dụng các lớp gộp gây mất mát không gian, phép chập atrous chèn thêm các "khoảng trống" vào giữa các trọng số của kernel. Kỹ thuật này cho phép mở rộng trường nhìn hiệu dụng (receptive field) một cách hàm mũ mà không làm gia tăng độ phức tạp tính toán hay làm suy giảm độ phân giải không gian của bản đồ đặc trưng.
- **Khối Atrous Spatial Pyramid Pooling (ASPP):** Nhằm đối phó với sự đa dạng về kích thước đối tượng trong cùng một khung hình, mô-đun ASPP vận hành như một bộ lọc đa phổ (multi-scale filter). Nó bao gồm một hệ thống các lớp chập atrous được bố trí song song, mỗi lớp sở hữu một hệ số giãn nở biệt lập để "quét" qua các vùng ngữ cảnh có bán kính khác nhau. Quá trình nội suy các luồng dữ liệu song song này, kết hợp cùng đặc trưng trung bình toàn cục, cung cấp cho mạng một lăng kính tổng thể, giúp phân biệt rõ ràng các vật thể bất chấp sự khác biệt về quy mô.
- **Nhánh giải mã tinh chỉnh:** Khác với DeepLabV3, DeepLabV3+ bổ sung thêm bộ giải mã nhằm cải thiện chi tiết không gian của bản đồ phân đoạn. Bộ giải mã kết hợp đặc trưng mức cao từ ASPP với đặc trưng mức thấp từ backbone. Các đặc trưng mức thấp chứa nhiều thông tin về biên và cấu trúc cục bộ, trong khi đặc trưng mức cao mang thông tin ngữ nghĩa mạnh hơn. Sự kết hợp này giúp kết quả phân đoạn vừa có ngữ cảnh tốt, vừa giữ được chi tiết ở vùng biên.

2.5.3 SegFormer

SegFormer [27] đánh dấu một bước chuyển mình quan trọng trong lĩnh vực phân đoạn ảnh ngữ nghĩa khi ứng dụng thành công nền tảng Transformer thay thế cho các mạng CNN truyền thống. Sự khác biệt cốt lõi của SegFormer nằm ở việc từ bỏ các phép chập cục bộ (local convolutions) để tận dụng cơ chế tự chú ý (self-attention). Cơ chế này thiết lập một trường nhìn toàn cục (global receptive field) ngay từ những tầng xử lý đầu tiên, cho phép mô hình định lượng và liên kết mức độ phụ thuộc dài hạn (long-range dependencies) giữa bất kỳ cặp không gian nào trong ảnh. Sơ đồ tổng quát của kiến trúc đột phá này được trình bày tại Hình 2.11.

Về mặt cấu trúc, SegFormer đoạn tuyệt với thiết kế đối xứng thường thấy để chuyển sang một hệ sinh thái gồm hai module bất đối xứng: một khối mã hóa Transformer phân cấp (Hierarchical Transformer Encoder) và một khối giải mã dựa trên đa tầng perceptron siêu nhẹ (Lightweight

All-MLP Decoder).



Hình 2.11: Kiến trúc tổng quan của mạng SegFormer.

Chức năng của từng module cấu thành được phân tích cụ thể như sau:

- Khối mã hóa Transformer phân cấp:** Để giải quyết bài toán suy hao thông tin không gian, SegFormer đề xuất một chiến lược chia nhỏ và nội suy phân cấp. Khối mã hóa này xuất ra các ma trận đặc trưng với độ phân giải đa tỷ lệ: bảo tồn chi tiết kết cấu vật lý ở các tầng nông và nén dần thành các vector ngữ nghĩa hàm súc ở các tầng sâu. Nhằm phá vỡ rào cản về độ phức tạp tính toán $\mathcal{O}(N^2)$ của cơ chế self-attention truyền thống, kiến trúc này tích hợp thuật toán tự chú ý hiệu quả kết hợp cùng mô-đun Mix-FFN. Đáng chú ý, Mix-FFN chèn các phép chập trực tiếp vào mạng feed-forward để rò rỉ thông tin vị trí, loại bỏ hoàn toàn nhu cầu sử dụng các chuỗi mã hóa vị trí cứng nhắc vốn làm giảm độ linh hoạt khi kích thước ảnh đầu vào thay đổi.
- Khối giải mã đa tầng Perceptron (All-MLP Decoder):** Sự tinh giản ở khối giải mã là một minh chứng cho sức mạnh biểu diễn vượt trội của nhánh mã hóa. Khước từ các bộ giải mã nặng nề chứa nhiều lớp chập, SegFormer chỉ sử dụng chuỗi các hàm tuyến tính (MLP layers) để trực tiếp hợp nhất dữ liệu. Quá trình này diễn ra qua ba bước: đồng nhất số lượng kênh, nội suy tất cả các bản đồ đặc trưng về cùng một độ phân giải không gian, và cuối cùng là nối dính để xuất ra mặt nạ phân đoạn. Cấu trúc All-MLP không những triệt tiêu đáng kể lượng tham số mà vẫn đảm bảo tính giao thoa hoàn hảo giữa tín hiệu ngữ nghĩa toàn cục và tín hiệu biên hình học.

Nhờ kết hợp bộ mã hóa Transformer phân cấp với bộ giải mã nhẹ, SegFormer đạt được sự cân bằng giữa khả năng học ngữ cảnh toàn cục và hiệu quả tính toán. Mô hình phù hợp với các bài toán phân đoạn cần khai thác quan hệ dài hạn giữa các vùng ảnh, đồng thời vẫn duy trì cấu

trúc giải mã đơn giản. Tuy nhiên, do dựa trên cơ chế attention, chi phí xử lý của SegFormer vẫn có thể tăng khi ảnh đầu vào có độ phân giải lớn hoặc khi số lượng token trong encoder tăng cao.

2.5.4 So sánh tổng quan giữa các kiến trúc mạng phân đoạn ngữ nghĩa

Mục này tiến hành đối chiếu toàn diện ba kiến trúc U-Net++, DeepLabV3+ và SegFormer trên ba hệ quy chiếu cốt lõi: năng lực biểu diễn không gian, độ phức tạp thuật toán và tính khả thi khi triển khai thực tiễn. Về bản chất, ba mô hình này là minh chứng cho ba trường phái tư tưởng thiết kế mạng nơ-ron khác biệt: U-Net++ tối ưu hóa luồng thông tin vi mô qua các liên kết tắt lồng nhau; DeepLabV3+ thao túng trường nhìn vĩ mô thông qua phép chụp giãn nở; trong khi SegFormer thiết lập trường chú ý toàn cục dựa trên cơ chế Transformer.

1. Năng lực biểu diễn và độ chính xác phân đoạn

- **U-Net++:** Điểm tựa sức mạnh của mô hình này nằm ở cơ chế chuyển tiếp đặc trưng tiệm cận. Thay vì ánh xạ trực tiếp, mạng lưới nút trung gian (intermediate nodes) đóng vai trò như một bộ đệm làm mềm độ lệch ngữ nghĩa giữa pha mã hóa và giải mã. Cấu trúc này trao cho mô hình sự nhạy bén đặc biệt trong việc định vị ranh giới, khôi phục các vật thể vi mô và bảo toàn hình thái phức tạp của các vùng tín hiệu yếu.
- **DeepLabV3+:** Năng lực phân đoạn của hệ thống được định hình bởi khả năng dung nạp ngữ cảnh đa tỷ lệ (multi-scale context). Mô-đun ASPP kết hợp cùng phép chụp atrous cho phép mở rộng trường nhìn hiệu dụng một cách hàm mũ mà không bào mòn độ phân giải. Song song đó, nhánh giải mã bổ trợ khôi phục sắc nét các đường bao. Cách tiếp cận này tỏ ra ưu việt khi đối phó với những khung hình có sự biến thiên dữ dội về tỷ lệ và kích thước đối tượng.
- **SegFormer:** Vượt ra khỏi giới hạn của tích chụp cục bộ, SegFormer tái định hình bài toán bằng cách thiết lập các mối phụ thuộc không gian tầm xa (long-range spatial dependencies) ngay từ bước đầu tiên. Mạng nòng cốt Transformer phân cấp không chỉ trích xuất xuất sắc đặc trưng đa mức mà còn cung cấp một lăng kính toàn cục về cấu trúc ảnh. Bộ giải mã All-MLP sau đó làm nhiệm vụ dung hợp, giúp mô hình nắm bắt sâu sắc mối liên hệ giữa các vùng tín hiệu phân tán.

2. Chi phí tính toán và độ phức tạp thuật toán

- **U-Net++:** Sự đánh đổi lớn nhất của U-Net++ là sự bùng nổ về số lượng tham số và phép toán do ma trận liên kết tắt dày đặc (dense skip pathways). Mặc dù cải thiện vượt bậc chất

lượng khôi phục không gian, kiến trúc này đòi hỏi dung lượng lưu trữ lớn và băng thông tính toán cao, tạo ra một rào cản nhất định về mặt tối ưu hóa tài nguyên.

- **DeepLabV3+:** Gánh nặng tính toán tỷ lệ thuận với độ sâu của mạng nòng cốt (như ResNet hay Xception) và số lượng nhánh song song trong khối ASPP. Đặc biệt, khi độ phân giải ảnh đầu vào tăng lên, việc duy trì các phép chập trên bề mặt không gian rộng sẽ tiêu hao đáng kể chu kỳ xử lý và bộ nhớ của phần cứng.
- **SegFormer:** Ở phương diện này, SegFormer mang đến một thiết kế bất đối xứng chiến lược: nhánh giải mã MLP cắt giảm triệt để chi phí tính toán ở phần đuôi, nhưng cơ chế self-attention ở nhánh mã hóa lại có độ phức tạp gia tăng đáng kể khi lượng token đầu vào lớn. Do đó, tính hiệu quả của mô hình phụ thuộc sát sao vào việc tinh chỉnh kích thước ảnh và thiết lập độ sâu của khối phân cấp Transformer.

3. Tính khả thi trong triển khai thực tiễn

- **U-Net++:** Là sự lựa chọn lý tưởng cho các hệ thống đòi hỏi sự khắt khe về độ chính xác điểm ảnh (pixel-level accuracy), đặc biệt trong các môi trường nhiễu làm mờ ranh giới đối tượng. Tuy nhiên, để đưa vào các hệ thống nhúng có tài nguyên hạn chế, việc áp dụng các kỹ thuật cắt tỉa nhánh (network pruning) là điều kiện mang tính bắt buộc.
- **DeepLabV3+:** Vô cùng phù hợp với các tác vụ giám sát quang cảnh rộng, nơi các loại tín hiệu có sự chênh lệch lớn về kích thước và hình thái. Mô hình đạt độ tin cậy cao nhưng đòi hỏi vi xử lý phải có bộ tăng tốc phần cứng (hardware accelerators) đủ mạnh để gánh vác khối lượng tính toán nội tại từ ASPP.
- **SegFormer:** Thể hiện sự thích ứng tuyệt vời đối với các bài toán phân đoạn hiện đại nhờ sự cân bằng giữa trường nhìn toàn cục và kiến trúc giải mã tối giản. Dẫu vậy, rào cản lớn nhất khi triển khai thực tế là giới hạn về dung lượng VRAM (Video RAM), vốn rất dễ bị quá tải nếu hệ thống phải lưu trữ các ma trận chú ý (attention matrices) của các khung ảnh độ phân giải siêu cao.

Chương 3


THIẾT KẾ MÔ HÌNH MẠNG HỌC SÂU CHO PHÂN ĐOẠN ẢNH PHỔ

3.1 TỔNG QUAN BÀI TOÁN VÀ HỆ THỐNG CẢM NHẬN PHỔ THÔNG MINH

Trong các hệ thống vô tuyến hiện đại, nhiều loại tín hiệu có thể cùng tồn tại trong một môi trường phổ, chẳng hạn như 5G NR, LTE, ASR và nhiễu nền. Khi các tín hiệu này xuất hiện đồng thời hoặc nằm gần nhau trong miền thời gian–tần số, việc chỉ phát hiện sự tồn tại của tín hiệu là chưa đủ. Hệ thống cần xác định được loại tín hiệu và vùng phổ mà tín hiệu đó chiếm dụng, từ đó hỗ trợ giám sát phổ, phát hiện can nhiễu và tối ưu hóa việc sử dụng tài nguyên tần số.

Trong nghiên cứu này, bài toán cảm nhận phổ được xây dựng dưới dạng phân đoạn ngữ nghĩa ảnh phổ. Tín hiệu vô tuyến sau khi thu nhận được chuyển đổi sang miền thời gian–tần số bằng phép biến đổi STFT. Ảnh phổ thu được đóng vai trò là đầu vào của mô hình học sâu, trong khi đầu ra là bản đồ phân đoạn, trong đó mỗi điểm ảnh được gán vào một lớp tương ứng như 5G NR, LTE, ASR hoặc Noise. Tổng quan về hệ thống cảm nhận phổ thông minh được minh họa trong Hình 3.1. Quy trình xử lý của hệ thống gồm các bước chính sau:

- **Thu nhận tín hiệu vô tuyến:** Các tín hiệu trong môi trường phổ được thu nhận từ nhiều nguồn khác nhau, bao gồm tín hiệu thông tin di động, tín hiệu radar và nhiễu nền. Ở giai đoạn này, dữ liệu vẫn ở dạng tín hiệu miền thời gian.




Hình 3.1: Tổng quan về hệ thống cảm nhận phổ thông minh.

- **Biểu diễn tín hiệu thành ảnh phổ:** Tín hiệu thu được được chuyển sang miền thời gian–tần số bằng STFT. Cách biểu diễn này cho phép quan sát sự phân bố năng lượng của tín hiệu theo cả thời gian và tần số, giúp làm rõ vùng xuất hiện của từng loại tín hiệu trên ảnh phổ.
- **Phân đoạn ảnh phổ bằng mô hình học sâu:** Ảnh phổ được đưa vào mô hình phân đoạn để dự đoán nhãn cho từng điểm ảnh. Khác với bài toán phân loại ảnh thông thường, mô hình không chỉ xác định loại tín hiệu xuất hiện mà còn tạo ra bản đồ thể hiện vùng chiếm dụng phổ của từng lớp tín hiệu.
- **Đánh giá kết quả phân đoạn:** Bản đồ phân đoạn dự đoán được so sánh với nhãn thực tế để đánh giá chất lượng mô hình. Các chỉ số như mAcc, mIoU, số tham số và thời gian suy luận được sử dụng nhằm phân tích đồng thời hiệu suất phân đoạn và chi phí tính toán.

Với cách tiếp cận này, bài toán cảm nhận phổ được chuyển thành bài toán phân tích vùng chiếm dụng phổ ở cấp điểm ảnh. Điều này giúp hệ thống cung cấp thông tin chi tiết hơn về vị trí, phạm vi và loại tín hiệu xuất hiện trong miền thời gian–tần số.

3.2 YÊU CẦU THIẾT KẾ MÔ HÌNH ĐỀ XUẤT CHO PHÂN ĐOẠN ẢNH PHỔ

Các yêu cầu thiết kế của hệ thống được xác định dựa trên đặc điểm của bài toán phân đoạn ảnh phổ và dữ liệu đầu vào. Trong nghiên cứu này, ảnh phổ là biểu diễn chính của tín hiệu vô tuyến trong miền thời gian–tần số. Mỗi ảnh phổ thể hiện sự phân bố năng lượng của tín hiệu theo thời gian và tần số, từ đó cho phép mô hình học sâu xác định vùng chiếm dụng phổ của từng lớp tín hiệu. Một số ảnh phổ từ bộ dữ liệu được minh họa trong Hình 3.2. Các mẫu trong tập huấn luyện và đánh giá gồm tín hiệu 5G NR và LTE riêng lẻ ở các mức SNR khác nhau. Trong khi đó,



Hình 3.2: Một số ảnh phổ từ bộ dữ liệu: (a) dữ liệu huấn luyện và đánh giá với các tín hiệu 5G NR và LTE riêng lẻ tại các mức SNR lần lượt là 20 dB và 10 dB, (b) dữ liệu kiểm tra với các tín hiệu tổng hợp tại các mức SNR lần lượt là -10 dB và 0 dB.

dữ liệu kiểm tra gồm các tín hiệu tổng hợp, phản ánh tình huống phức tạp hơn khi nhiều thành phần phổ cùng xuất hiện trong một ảnh. Các ví dụ này cho thấy dữ liệu đầu vào không chỉ khác nhau về loại tín hiệu mà còn thay đổi theo mức nhiễu và cấu trúc phổ.

Từ dữ liệu ảnh phổ, có thể thấy các lớp tín hiệu như 5G NR, LTE và ASR có hình thái khác nhau, trong khi Noise thường không có cấu trúc cố định. Khi SNR thấp, độ tương phản giữa tín hiệu và nhiễu giảm, khiến các vùng tín hiệu yếu dễ bị nhầm với nền nhiễu. Dịch Doppler có thể làm thay đổi vị trí hoặc hình dạng của tín hiệu trên ảnh phổ. Fading đa đường có thể làm tín hiệu bị suy giảm cục bộ, méo dạng hoặc xuất hiện các vùng năng lượng không liên tục. Ngoài ra, các tín hiệu có thể xuất hiện gần nhau hoặc chồng lấn trong miền thời gian-tần số, làm cho đường biên giữa các lớp trở nên khó phân biệt. Từ các đặc điểm trên, hệ thống phân đoạn ảnh phổ cần đáp ứng các yêu cầu thiết kế sau:

- **Yêu cầu về độ chính xác phân đoạn:** Mô hình cần xác định đúng vùng thời gian-tần số của từng lớp tín hiệu, gồm 5G NR, LTE, ASR và Noise. Yêu cầu này đặc biệt quan trọng trong các trường hợp tín hiệu yếu, biên không rõ hoặc nhiều thành phần phổ xuất hiện đồng thời.
- **Yêu cầu về khả năng hoạt động trong điều kiện nhiễu:** Mô hình cần duy trì kết quả phân đoạn ổn định khi SNR thấp, có nhiều nền, fading đa đường hoặc dịch Doppler. Trong các điều kiện này, tín hiệu có thể bị mờ, biến dạng hoặc đứt đoạn trên ảnh phổ.
- **Yêu cầu về khả năng xử lý vùng tín hiệu chồng lấn:** Hệ thống cần phân biệt được các vùng tín hiệu xuất hiện gần nhau hoặc chồng lấn trong miền thời gian-tần số. Mô hình phải giữ được chi tiết biên và hạn chế nhầm lẫn giữa các lớp có cấu trúc phổ tương tự nhau.

- **Yêu cầu về tốc độ suy luận:** Hệ thống cần xử lý ảnh phổ với độ trễ thấp để phù hợp với các kịch bản giám sát phổ gần thời gian thực. Yêu cầu này giúp hệ thống phản hồi kịp thời khi môi trường phổ thay đổi.
- **Yêu cầu về chi phí tính toán và kích thước mô hình:** Mô hình cần kiểm soát số tham số, FLOPs và bộ nhớ sử dụng. Điều này giúp tăng khả năng triển khai trên các nền tảng tính toán hạn chế như thiết bị biên, hệ thống nhúng hoặc trạm giám sát phổ.

3.3 ĐỊNH HƯỚNG THIẾT KẾ CÁC MÔ HÌNH ĐỀ XUẤT


Từ các yêu cầu thiết kế đã trình bày, bài toán phân đoạn ảnh phổ cần được xem xét dưới nhiều tiêu chí khác nhau, bao gồm độ chính xác phân đoạn, khả năng xử lý trong môi trường nhiễu, tốc độ suy luận và chi phí tính toán. Do đó, nghiên cứu này xây dựng ba hướng thiết kế mô hình nhằm đánh giá các mức đánh đổi khác nhau giữa hiệu suất phân đoạn và khả năng triển khai. Ba mô hình được khảo sát gồm ASTRA-Net, SpecDiff và ASTA-Net.

- ASTRA-Net được xây dựng theo hướng ưu tiên tốc độ suy luận và hiệu quả tính toán. Mục tiêu chính của mô hình là giảm độ phức tạp kiến trúc, rút ngắn thời gian xử lý và vẫn duy trì khả năng trích xuất đặc trưng cần thiết cho bài toán phân đoạn ảnh phổ. Định hướng này phù hợp với các kịch bản yêu cầu xử lý nhanh, độ trễ thấp hoặc triển khai trên các nền tảng có tài nguyên hạn chế.

- SpecDiff đại diện cho hướng thiết kế ưu tiên chất lượng phân đoạn. Mô hình khai thác biểu diễn tiềm ẩn và cơ chế khuếch tán để hỗ trợ quá trình tái tạo và tinh chỉnh bản đồ phân đoạn. Cách tiếp cận này hướng đến việc cải thiện khả năng phân biệt các vùng tín hiệu yếu, vùng biên không rõ hoặc các trường hợp tín hiệu bị ảnh hưởng bởi nhiễu và chồng lấn. Tuy nhiên, do sử dụng cơ chế sinh và tinh chỉnh đặc trưng, SpecDiff thường đòi hỏi chi phí tính toán cao hơn so với các mô hình ưu tiên tốc độ.

- ASTA-Net được thiết kế theo hướng cân bằng giữa hiệu suất phân đoạn và tốc độ suy luận. Mô hình kết hợp nhiều nhánh xử lý để khai thác đồng thời đặc trưng cục bộ, thông tin ngữ cảnh và cấu trúc không gian của ảnh phổ. Định hướng này giúp ASTA-Net duy trì chất lượng phân đoạn ổn định trong các điều kiện phổ phức tạp, đồng thời kiểm soát độ phức tạp tính toán ở mức phù hợp cho các kịch bản triển khai thực tế.


3.4 MÔ HÌNH ƯU TIÊN TỐC ĐỘ SUY LUẬN - ASTRA-Net



Hình 3.3: Kiến trúc tổng quan của mô hình ASTRA-Net.

ASTRA-Net được xây dựng nhằm thực hiện phân đoạn ngữ nghĩa ảnh phổ trong bài toán cảm nhận phổ thông minh. Đầu vào của mô hình là ảnh phổ biểu diễn năng lượng tín hiệu trong miền thời gian–tần số, trong khi đầu ra là bản đồ phân đoạn thể hiện vùng chiếm dụng phổ của từng lớp tín hiệu. Trong nghiên cứu này, các lớp cần phân đoạn gồm 5G NR, LTE, ASR và Noise. Khác với các mô hình phân đoạn ảnh thông thường, ASTRA-Net được thiết kế chuyên biệt cho ảnh phổ, trong đó đặc trưng tín hiệu không chỉ thay đổi theo không gian ảnh mà còn phụ thuộc vào quan hệ giữa trục thời gian và trục tần số. Trong môi trường phổ phức tạp, các tín hiệu có thể xuất hiện với kích thước, cường độ và hình thái khác nhau. Tín hiệu ASR thường xuất hiện dưới dạng các thành phần ngắn hoặc cục bộ, trong khi tín hiệu 5G NR và LTE thường có vùng chiếm dụng phổ rộng hơn và liên tục hơn trong miền thời gian–tần số. Ngoài ra, nhiễu nền, fading đa đường và dịch Doppler có thể làm suy giảm độ tương phản, làm mờ biên tín hiệu hoặc tạo ra các vùng năng lượng không liên tục. Vì vậy, mô hình cần có khả năng khai thác đặc trưng đa tỉ lệ, giữ chi tiết cục bộ và đồng thời nắm bắt được ngữ cảnh phổ–thời gian ở phạm vi rộng.

Kiến trúc tổng quan của ASTRA-Net được minh họa trong Hình 3.3. Mô hình gồm hai đường dẫn chính: đường dẫn nhận thức động (Dynamic Perception Path - DP) và đường dẫn phổ–thời gian (Spectro-Temporal Path - ST). DP gồm khối chọn lọc phổ động (Dynamic Selective Spectrum Layer - DSSL) và bộ chất lọc phổ thích nghi (Adaptive Spectrum Distiller - ASD), có nhiệm vụ trích xuất đặc trưng phổ thích nghi và tăng cường ngữ cảnh toàn cục. ST sử dụng khối đa tập phổ cảm nhận (Perceptive Spectrum Manifold - PSM), trong đó có lớp không gian theo đường dẫn (Pathwise Spatial Layer - PSL), nhằm tinh chỉnh đặc trưng theo cấu trúc phổ–thời gian. Cuối cùng, các đặc trưng từ hai đường dẫn được hợp nhất để tạo bản đồ phân đoạn. Trong các công thức dưới đây, $\mathcal{K}_{k \times m}^s(\cdot)$ ký hiệu phép tích chập tiêu chuẩn với stride s và kích thước kernel $k \times m$. Ký hiệu $\mathcal{G}_{k \times m, r}^s(\cdot)$ biểu diễn phép tích chập theo chiều sâu với hệ số giãn r . Ký hiệu $\mathcal{A}_{k \times m}^s(\cdot)$ là phép lấy trung bình cục bộ, $\mathcal{p}_{\text{gap}}(\cdot)$ là phép lấy trung bình toàn cục, $\mathcal{p}_{\text{gap}}(\cdot)$ là phép



Hình 3.4: Cấu trúc của khối chọn lọc phổ động (Dynamic Selective Spectrum Layer - DSSL).

lấy cực đại toàn cục, $\mathcal{U}_{k \times}(\cdot)$ là phép tăng mẫu k lần, $\sigma(\cdot)$ là hàm sigmoid, $\odot$ là phép nhân theo từng phần tử và $\langle \cdot \rangle$ là phép ghép nối theo chiều kênh.

3.4.1 Đường dẫn nhận thức động (Dynamic Perception Path - DP)


Đường dẫn nhận thức động (Dynamic Perception Path - DP) được thiết kế nhằm trích xuất đặc trưng phổ ở nhiều phạm vi tiếp nhận khác nhau. Trong ảnh phổ, một tín hiệu có thể chiếm vùng hẹp theo tần số nhưng kéo dài theo thời gian, hoặc xuất hiện trong thời gian ngắn nhưng có sự thay đổi mạnh theo tần số. Các phép tích chập với vùng tiếp nhận cố định có thể gặp hạn chế khi xử lý đồng thời nhiều dạng tín hiệu như vậy. Do đó, DP sử dụng DSSL để khai thác đặc trưng phổ đa tỉ lệ và sử dụng ASD để bổ sung thông tin ngữ cảnh toàn cục.

Khối chọn lọc phổ động (Dynamic Selective Spectrum Layer - DSSL)

DSSL là khối chính trong DP, được thiết kế để tạo ra các đặc trưng phổ thích nghi theo nhiều vùng tiếp nhận. Cấu trúc của DSSL được trình bày trong Hình 3.4. Khối này gồm nhiều nhánh tích chập theo chiều sâu song song, trong đó mỗi nhánh sử dụng một hệ số giãn khác nhau. Các hệ số giãn giúp mở rộng vùng tiếp nhận của bộ lọc mà không làm tăng đáng kể số lượng tham số. Nhờ đó, DSSL có thể khai thác đồng thời các chi tiết cục bộ, vùng biên tín hiệu và các cấu trúc phổ có phạm vi rộng hơn. Đầu ra của DSSL được xác định như sau:

$$\mathbf{F}_{\text{DSSL}}^{\text{out}} = \sum_{i=1}^P \mathbf{a}_i \odot \mathcal{K}_{i \times i}^i \left(\mathcal{G}_{3 \times 3, r=2i}^i \left(\mathbf{F}_{\text{DSSL}}^{\text{in}} \right) \right), \quad (3.1)$$

trong đó $\mathbf{F}_{\text{DSSL}}^{\text{in}}$ và $\mathbf{F}_{\text{DSSL}}^{\text{out}}$ lần lượt là đặc trưng đầu vào và đầu ra của DSSL. Tham số P là số nhánh song song trong DSSL. Trọng số $\mathbf{a}_i$ thể hiện mức đóng góp của nhánh thứ i khi hợp nhất đặc trưng. Với các giá trị dilation khác nhau, mỗi nhánh có khả năng quan sát tín hiệu ở một



Hình 3.5: Cơ chế tính điểm chú ý trong khối DSSL.

phạm vi riêng, từ đó giúp mô hình thích nghi tốt hơn với các cấu trúc phổ có kích thước khác nhau.

Cơ chế tính điểm chú ý trong DSSL được minh họa trong Hình 3.5. Thay vì gán trọng số cố định cho từng nhánh tích chập, DSSL tạo trọng số dựa trên nội dung của đặc trưng đầu vào. Cơ chế này bắt đầu bằng việc tách đặc trưng thành hai thành phần: thành phần tần số không gian thấp và thành phần tần số không gian cao. Thành phần tần số không gian thấp biểu diễn các cấu trúc phổ tổng quát, trong khi thành phần tần số không gian cao giữ lại các chi tiết sắc nét như biên tín hiệu, xung radar hoặc các vùng năng lượng hẹp. Thành phần tần số không gian thấp được xác định bằng phép lấy trung bình cục bộ:

$$\mathbf{F}_{low} = \mathcal{K}_{l \times l}^i (\mathcal{A}_{3 \times 3}^i (\mathbf{F}_{DSSL}^{in})), \quad (3.2)$$

trong đó $\mathcal{A}_{3 \times 3}^i(\cdot)$ là phép lấy trung bình với kernel 3×3 và stride bằng l . Phép lấy trung bình này làm mượt đặc trưng đầu vào, từ đó nhấn mạnh các vùng phổ có cấu trúc tổng quát và giảm bớt ảnh hưởng của các dao động nhỏ. Thành phần tần số không gian cao được tính bằng phần sai khác giữa đặc trưng ban đầu và đặc trưng đã được làm mượt:


$$\mathbf{F}_{bigb} = \mathcal{K}_{l \times l}^i (\mathbf{F}_{DSSL}^{in} - \mathcal{A}_{3 \times 3}^i (\mathbf{F}_{DSSL}^{in})). \quad (3.3)$$

Thành phần $\mathbf{F}_{bigb}$ giúp mô hình giữ lại các thay đổi cục bộ trong ảnh phổ. Đây là các thông tin cần thiết để nhận diện vùng biên, tín hiệu hẹp hoặc các thành phần phổ có thời gian xuất hiện ngắn. Hai thành phần $\mathbf{F}_{bigb}$ và $\mathbf{F}_{low}$ được ghép theo chiều kênh để tạo đặc trưng điều khiển cho nhánh chú ý:

$$\mathbf{G} = \mathcal{R} (\mathbb{P}_{gap} (\mathcal{K}_{l \times l}^i (\langle \mathbf{F}_{bigb}, \mathbf{F}_{low} \rangle))), \quad (3.4)$$

trong đó $\mathbf{G}$ là tensor điểm chú ý sau khi lấy trung bình toàn cục và định dạng lại. Trọng số của nhánh thứ i được tạo bởi:

$$\mathbf{a}_i = \sigma (\mathbf{G}_i). \quad (3.5)$$



Hình 3.6: Cấu trúc của bộ chất lọc phổ thích nghi (Adaptive Spectrum Distiller - ASD).

Nhờ cơ chế này, DSSL có thể tự điều chỉnh mức đóng góp của từng nhánh tích chập. Khi ảnh phổ chứa nhiều chi tiết cục bộ, các nhánh nhảy với thành phần tần số không gian cao sẽ được nhấn mạnh. Ngược lại, khi tín hiệu có vùng chiếm dụng rộng và cấu trúc ổn định hơn, các nhánh có vùng tiếp nhận lớn có thể đóng vai trò quan trọng hơn.

Bộ chất lọc phổ thích nghi (Adaptive Spectrum Distiller - ASD)

Bên cạnh DSSL, DP còn sử dụng ASD để tăng cường ngữ cảnh phổ toàn cục. Cấu trúc của ASD được trình bày trong Hình 3.6. Trong ảnh phổ, một số vùng tín hiệu có thể bị nhiễu che khuất, suy giảm năng lượng hoặc có biên không rõ. Khi đó, việc chỉ dựa vào đặc trưng cục bộ có thể chưa đủ để đưa ra quyết định phân đoạn chính xác. ASD bổ sung ngữ cảnh toàn cục thông qua hai phép gộp khác nhau, giúp mô hình nhấn mạnh các vùng tín hiệu quan trọng.

ASD sử dụng phép lấy trung bình toàn cục và phép lấy cực đại toàn cục để trích xuất hai dạng ngữ cảnh khác nhau. Phép lấy trung bình toàn cục phản ánh xu hướng phân bố chung của đặc trưng, trong khi phép lấy cực đại toàn cục làm nổi bật các đáp ứng mạnh nhất. Đầu ra của ASD được biểu diễn như sau:

$$\mathbf{F}_{\text{ASD}}^{\text{out}} = \mathbf{F}_{\text{ASD}}^{\text{in}} \odot \mathcal{P}_{\text{gap}}(\mathbf{Y}) + \mathbf{F}_{\text{ASD}}^{\text{in}} \odot \mathcal{P}_{\text{gmp}}(\mathbf{Y}), \quad (3.6)$$


với

$$\mathbf{Y} = \mathcal{K}_{l \times l}^i(\mathbf{F}_{\text{ASD}}^{\text{in}}). \quad (3.7)$$


Trong đó, $\mathbf{F}_{\text{ASD}}^{\text{in}}$ và $\mathbf{F}_{\text{ASD}}^{\text{out}}$ lần lượt là đặc trưng đầu vào và đầu ra của ASD. Hai phép gộp toàn cục $\mathcal{P}_{\text{gap}}$ và $\mathcal{P}_{\text{gmp}}$ giúp mô hình thu nhận cả thông tin phân bố tổng thể và các đáp ứng nổi bật trên ảnh phổ. Trong DP, ảnh phổ đầu vào trước hết được đưa qua hai lớp tích chập 3×3 để tạo đặc trưng ban đầu. Đặc trưng này sau đó được xử lý bởi DSSL để tạo đặc trưng phổ sơ cấp:

$$\mathbf{Y}_{\text{ss}} = \text{DSSL}(\mathcal{K}_{3 \times 3}^2(\mathcal{K}_{3 \times 3}^2(\mathbf{X}_{\text{in}}))). \quad (3.8)$$

Trong đó, $\mathbf{X}_{\text{in}}$ là ảnh phổ đầu vào và $\mathbf{Y}_{\text{ss}}$ là đặc trưng phổ ban đầu sau khi qua các lớp tích chập



(a) Lớp không gian theo đường dẫn (Pathwise Spatial Layer - PSL).



(b) Khối đa tạp phổ cảm nhận (Perceptive Spectrum Manifold - PSM).

Hình 3.7: Các khối xử lý trong đường dẫn phổ-thời gian.

và DSSL. Quá trình xử lý tại giai đoạn thứ i của DP được mô tả như sau:

$$\mathbf{F}_{dp}^i = \begin{cases} \mathbf{A}SD(\mathbf{Y}_{ss}), & i = 1, \\ DSS\mathbf{A}(\mathbf{F}_{dp}^{i-1}), & i = \{2, 3\}. \end{cases} \quad (3.9)$$

Ở giai đoạn đầu, ASD làm giàu ngữ cảnh toàn cục cho đặc trưng $\mathbf{Y}_{ss}$. Ở các giai đoạn tiếp theo, DSSL tiếp tục tinh chỉnh đặc trưng bằng các vùng tiếp nhận thích nghi. Nhờ đó, DP đóng vai trò trích xuất đặc trưng phổ đa tỉ lệ, đồng thời bổ sung ngữ cảnh phổ toàn cục trước khi chuyển đặc trưng sang đường dẫn ST.

3.4.2 Đường dẫn phổ-thời gian (Spectro-Temporal Path - ST)

Đường dẫn phổ-thời gian (Spectro-Temporal Path - ST) được thiết kế để tinh chỉnh đặc trưng từ DP bằng cách khai thác quan hệ theo trục thời gian và tần số. Nếu DP tập trung vào đặc trưng phổ thích nghi và ngữ cảnh toàn cục, thì ST tập trung vào cấu trúc phổ-thời gian của ảnh phổ. Điều này đặc biệt quan trọng trong các trường hợp tín hiệu có biên không rõ, bị nhiễu hoặc xuất hiện gần các vùng tín hiệu khác.

Trong ST, khối đa tạp phổ cảm nhận (Perceptive Spectrum Manifold - PSM) được sử dụng để tinh chỉnh đặc trưng. Bên trong PSM có lớp không gian theo đường dẫn (Pathwise Spatial Layer - PSL), đóng vai trò trích xuất chi tiết cục bộ và ngữ cảnh không gian. Vì PSL là thành phần con trong cấu trúc PSM, hai khối này được trình bày chung trong Hình 3.7.

Lớp không gian theo đường dẫn (Pathwise Spatial Layer - PSL)

PSL được sử dụng để trích xuất đồng thời chi tiết cục bộ và ngữ cảnh không gian trong ảnh phổ (Hình 3.7a). Khối này gồm hai nhánh tích chập song song, trong đó, nhánh 3×3 tập trung vào các chi tiết cục bộ, trong khi nhánh 5×5 mở rộng phạm vi quan sát để thu nhận thêm ngữ cảnh không gian. Hai nhánh này giúp mô hình vừa giữ được thông tin biên vừa quan sát được cấu trúc lân cận của vùng tín hiệu. Đặc trưng trung gian của PSL được xác định như sau:

$$\mathbf{F}_p = \langle \mathcal{K}_{3 \times 3}^2(\mathbf{F}_{\text{PS}\mathbf{\Lambda}}^{\text{in}}), \mathcal{K}_{5 \times 5}^2(\mathbf{F}_{\text{PS}\mathbf{\Lambda}}^{\text{in}}) \rangle, \quad (3.10)$$

trong đó $\mathbf{F}_{\text{PS}\mathbf{\Lambda}}^{\text{in}}$ là đặc trưng đầu vào của PSL. Phép ghép nối hai nhánh tích chập tạo ra đặc trưng $\mathbf{F}_p$, kết hợp giữa chi tiết mức thấp và ngữ cảnh không gian. Đầu ra của PSL được tính theo:

$$\mathbf{F}_{\text{PS}\mathbf{\Lambda}}^{\text{out}} = \mathbf{F}_p + \mathcal{K}_{i \times i}^i(\mathbf{F}_p) \odot \sigma(\mathcal{K}_{i \times i}^i(\mathbf{F}_p)). \quad (3.11)$$

Trong công thức trên, thành phần cộng tắt giúp bảo toàn đặc trưng gốc và hỗ trợ quá trình lan truyền gradient. Thành phần nhân với hàm sigmoid đóng vai trò như cơ chế điều tiết đặc trưng, giúp nhấn mạnh các vùng có thông tin quan trọng. Nhờ đó, PSL hỗ trợ PSM trong việc giữ chi tiết biên, vùng tín hiệu nhỏ và các cấu trúc phổ cục bộ.

Khối đa tạp phổ cảm nhận (Perceptive Spectrum Manifold - PSM)

PSM là khối tinh chỉnh đặc trưng chính trong đường dẫn ST (Hình 3.7b). Khối này có cấu trúc encoder-decoder, trong đó encoder sử dụng PSL để trích xuất đặc trưng ở các mức khác nhau, còn decoder khôi phục và tinh chỉnh đặc trưng bằng các lớp tích chập bất đối xứng. Cách thiết kế này phù hợp với ảnh phổ vì trục thời gian và trục tần số có ý nghĩa khác nhau, do đó cần các bộ lọc có khả năng khai thác quan hệ theo từng hướng riêng biệt. Quá trình mã hóa tại giai đoạn thứ i của PSM được định nghĩa như sau:

$$\mathbf{F}_e^i = \begin{cases} \text{PS}\mathbf{\Lambda}(\mathbf{F}_{\text{PSM}}^{\text{in}}), & i = 1, \\ \text{PS}\mathbf{\Lambda}(\mathbf{F}_e^{i-1}), & i = 2. \end{cases} \quad (3.12)$$

Trong đó, $\mathbf{F}_{\text{PSM}}^{\text{in}}$ là đặc trưng đầu vào của PSM và $\mathbf{F}_e^i$ là đặc trưng mã hóa ở giai đoạn thứ i . Việc dùng PSL trong encoder giúp PSM kết hợp giữa giảm kích thước đặc trưng và bảo toàn thông tin

không gian quan trọng. Nhánh giải mã của PSM được mô tả bởi:

$$\mathbf{F}_d^j = \begin{cases} \mathcal{B}_{\mathbf{r}, \mathbf{b}}(\langle \mathbf{F}_e^i, \mathcal{U}_{2 \times}(\mathbf{F}_e^2) \rangle), & j = 1, \\ \mathcal{B}_{\mathbf{r}, \mathbf{b}}(\langle \mathbf{F}_d^{j-1}, \mathbf{F}_{\text{PSM}}^{\text{in}} \rangle), & j = 2. \end{cases} \quad (3.13)$$

Trong đó, $\mathcal{B}_{\mathbf{r}, \mathbf{b}}(\cdot)$ là khối xử lý gồm các lớp tích chập bất đối xứng 1×3 và 3×1 , còn $\mathcal{U}_{2 \times}(\cdot)$ là phép tăng mẫu hai lần. Các lớp tích chập 1×3 và 3×1 giúp mô hình học riêng các quan hệ theo từng trục của ảnh phổ. Nhờ đó, PSM có thể biểu diễn tốt hơn các biến đổi theo thời gian và tần số của tín hiệu. Đầu ra cuối cùng của PSM được tính như sau:

$$\mathbf{F}_{\text{PSM}}^{\text{out}} = \mathcal{K}_{1 \times 1}^i(\mathbf{F}_{\text{PSM}}^{\text{in}} + (\sigma(\mathbf{F}_d^2) \odot \mathbf{F}_d^2)). \quad (3.14)$$

Trong đó, $\mathbf{F}_d^2$ là đặc trưng sau giai đoạn giải mã cuối cùng. Thành phần $\sigma(\mathbf{F}_d^2) \odot \mathbf{F}_d^2$ giúp nhấn mạnh các vùng đặc trưng quan trọng trước khi kết hợp với đặc trưng đầu vào. Lớp tích chập 1×1 cuối cùng có nhiệm vụ trộn thông tin theo kênh và tạo ra đặc trưng đầu ra của PSM.

Luồng xử lý của đường dẫn ST

Dựa trên đặc trưng từ DP và PSM, quá trình xử lý của ST tại giai đoạn thứ i được xác định như sau:

$$\mathbf{F}_{\text{st}}^i = \begin{cases} \langle \mathbf{F}_{\text{dp}}^i, \text{PSM}(\mathbf{Y}_{\text{ss}}) \rangle, & i = 1, \\ \langle \mathbf{F}_{\text{dp}}^i, \text{PSM}(\mathbf{F}_{\text{st}}^{i-1}) \rangle, & i = \{2, 3\}. \end{cases} \quad (3.15)$$

Trong đó, $\mathbf{F}_{\text{st}}^i$ là đặc trưng đầu ra của ST tại giai đoạn thứ i . Công thức này cho thấy ST không hoạt động tách rời mà liên tục kết hợp đặc trưng từ DP với đặc trưng đã được tinh chỉnh bởi PSM. Nhờ vậy, mô hình có thể kết hợp thông tin phổ thích nghi với cấu trúc phổ-thời gian trong cùng một biểu diễn đặc trưng.

3.4.3 Đầu ra phân đoạn của ASTRA-Net

Sau khi DP và ST trích xuất đặc trưng, ASTRA-Net tạo đầu ra phân đoạn bằng cách kết hợp đặc trưng cuối của ST với ASD và PSM. ASD cung cấp ngữ cảnh toàn cục, trong khi PSM tiếp tục tinh chỉnh cấu trúc phổ-thời gian. Hai thành phần này được nhân với nhau trước khi tăng mẫu để tạo bản đồ phân đoạn cuối cùng. Đầu ra thống nhất của ASTRA-Net được tính như sau:

$$\mathbf{X}_{\text{out}} = \mathcal{U}_{4 \times}(\mathbf{A} \text{SD}(\mathcal{K}_{1 \times 1}^i(\mathbf{F}_{\text{st}}^3)) \odot \text{PSM}(\mathbf{F}_{\text{st}}^3)). \quad (3.16)$$

Trong đó, $\mathbf{F}_{\text{st}}^3$ là đặc trưng đầu ra của ST tại giai đoạn cuối, còn $\mathcal{U}_{4 \times}$ là phép tăng mẫu bốn lần để đưa bản đồ đặc trưng về kích thước phù hợp với bản đồ phân đoạn. Phép tích chập 1×1 được sử

dụng để điều chỉnh số kênh trước khi đặc trưng được đưa vào ASD. Kết quả sau ASD được nhân với đặc trưng tinh chỉnh bởi PSM nhằm nhấn mạnh các vùng phổ quan trọng trước khi tạo đầu ra cuối cùng. Cuối cùng, $\mathbf{X}_{\text{out}}$ được đưa qua lớp phân loại theo điểm ảnh để tạo xác suất thuộc lớp tại từng vị trí trên ảnh phổ.

Nhờ sự phối hợp giữa DP và ST, ASTRA-Net khai thác được cả đặc trưng phổ đa tỉ lệ, ngữ cảnh toàn cục và quan hệ phổ-thời gian. Trong đó, DSSL giúp mô hình thích nghi với các dạng tín hiệu có kích thước khác nhau, ASD bổ sung thông tin ngữ cảnh toàn cục, còn PSM và PSL hỗ trợ tinh chỉnh cấu trúc thời gian-tần số và giữ lại các chi tiết không gian quan trọng. Cấu trúc này giúp ASTRA-Net phù hợp với bài toán phân đoạn ảnh phổ trong các môi trường có nhiễu, tín hiệu yếu hoặc nhiều loại tín hiệu cùng tồn tại.

3.4.4 Hàm mất mát huấn luyện

Trong quá trình huấn luyện mô hình ASTRA-Net, bài toán phát hiện phổ được giải quyết dưới dạng phân loại đa lớp ở cấp độ điểm ảnh. Do đó, hàm mất mát Cross-Entropy (CE) tiêu chuẩn được sử dụng để tối ưu hóa trọng số của mạng, thông qua việc đánh giá sự sai khác giữa phân phối xác suất dự đoán và nhãn thực tế. Công thức của hàm mất mát được định nghĩa như sau:


$$\mathcal{L}_{ce} = -\frac{1}{\mathcal{M}} \sum_{i=1}^{\mathcal{M}} \sum_{k=1}^K y_{i,k} \log \left(\text{softmax}(\mathbf{X}_{\text{out}})_{i,k} \right), \quad (3.17)$$

trong đó $\mathcal{M}$ là tổng số điểm ảnh trên bản đồ đặc trưng, K là số lượng lớp tín hiệu cần phân loại, $y_{i,k}$ là nhãn one-hot của điểm ảnh i thuộc lớp k , và $\mathbf{X}_{\text{out}}$ biểu diễn bản đồ đặc trưng đầu ra của mạng trước khi đi qua hàm kích hoạt softmax.

3.5 MÔ HÌNH TỐI ƯU HIỆU SUẤT - SpecDiff

SpecDiff là mô hình phân đoạn ảnh phổ được xây dựng dựa trên nguyên lý khuếch tán trong không gian tiềm ẩn. Khác với các kiến trúc phân đoạn trực tiếp, mô hình này không chỉ học ánh xạ từ ảnh phổ sang bản đồ nhãn, mà còn sử dụng tiến trình khử nhiễu có điều kiện để tinh chỉnh biểu diễn trước khi tái tạo mặt nạ phân đoạn. Cách tiếp cận này phù hợp với bài toán cảm nhận phổ trong các môi trường có nhiễu, fading, dịch Doppler hoặc nhiễu tín hiệu cùng tồn tại trong miền thời gian-tần số.

Đầu vào của SpecDiff là ảnh phổ $\mathbf{X}_{\text{in}}$, còn đầu ra là bản đồ phân đoạn $\mathbf{X}_{\text{out}}$ tương ứng với các lớp 5G NR, LTE, ASR và Noise. Mô hình gồm ba thành phần chính: khối mã hóa-giải mã tiềm ẩn, mạng dự đoán nhiễu và đường dẫn đặc trưng điều kiện. Khối mã hóa-giải mã có nhiệm vụ



Hình 3.8: Kiến trúc tổng quan của mô hình SpecDiff.


vụ nén ảnh phổ vào không gian tiềm ẩn và tái tạo lại mặt nạ phân đoạn. Mạng dự đoán nhiễu thực hiện quá trình khử nhiễu trong không gian tiềm ẩn. Đường dẫn điều kiện cung cấp thông tin ngữ nghĩa từ ảnh phổ nhằm định hướng quá trình khử nhiễu.

Kiến trúc tổng quan của SpecDiff được minh họa trong Hình 3.8. Trong luận văn này, khối mã hóa–giải mã được mô tả như một thành phần học biểu diễn tiềm ẩn và tái tạo mặt nạ phân đoạn. Mặc dù hình minh họa có cấu trúc tương đồng với một bộ mã hóa–giải mã tiềm ẩn, phần mô tả không giả định rằng mô hình sử dụng một VAE huấn luyện sẵn độc lập. Cách trình bày này phù hợp hơn với nội dung phương pháp, trong đó trọng tâm nằm ở việc sử dụng không gian tiềm ẩn để giảm chi phí khuếch tán và tăng khả năng tinh chỉnh mặt nạ phân đoạn.

SpecDiff là mô hình phân đoạn ảnh phổ được xây dựng dựa trên nguyên lý khuếch tán trong không gian tiềm ẩn. Khác với các kiến trúc phân đoạn trực tiếp, mô hình này không chỉ học ánh xạ từ ảnh phổ sang bản đồ nhãn, mà còn sử dụng tiến trình khử nhiễu có điều kiện để tinh chỉnh biểu diễn trước khi tái tạo mặt nạ phân đoạn. Cách tiếp cận này phù hợp với bài toán cảm nhận phổ trong các môi trường có nhiễu, fading, dịch Doppler hoặc nhiễu tín hiệu cùng tồn tại trong miền thời gian–tần số.

3.5.1 Cơ sở khuếch tán trong không gian tiềm ẩn

Mô hình khuếch tán gồm hai tiến trình chính: tiến trình khuếch tán thuận và tiến trình khử nhiễu ngược. Trong tiến trình thuận, nhiễu Gaussian được thêm dần vào biểu diễn sạch qua nhiều bước thời gian. Trong tiến trình ngược, một mạng học sâu được huấn luyện để dự đoán thành phần nhiễu tại mỗi bước, từ đó từng bước khôi phục lại biểu diễn sạch. Đối với SpecDiff, hai tiến trình này được thực hiện trong không gian tiềm ẩn thay vì trên ảnh phổ gốc, giúp giảm kích thước dữ liệu cần xử lý và tăng hiệu quả suy luận. Gọi $\mathbf{F}_0$ là biểu diễn tiềm ẩn sạch và $\mathbf{F}_t$ là biểu diễn sau khi thêm nhiễu tại bước thời gian t . Tiến trình khuếch tán thuận được mô tả bởi:



Hình 3.9: Minh họa tiến trình khử nhiễu ngược trong mô hình khuếch tán.

$$q(\mathbf{F}_t | \mathbf{F}_0) = \mathcal{N}(\mathbf{F}_t; \sqrt{\bar{\alpha}_t} \mathbf{F}_0, (1 - \bar{\alpha}_t) \mathbf{I}), \quad (3.18)$$

trong đó $\bar{\alpha}_t$ là hệ số tích lũy của lịch nhiễu tại bước t , còn $\mathbf{I}$ là ma trận đơn vị. Từ phân phối trên, $\mathbf{F}_t$ có thể được viết dưới dạng:

$$\mathbf{F}_t = \sqrt{\bar{\alpha}_t} \mathbf{F}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \quad (3.19)$$

Nhiều $\mathbf{F}_t$ được tạo bằng cách kết hợp biểu diễn sạch $\mathbf{F}_0$ với nhiễu Gaussian $\boldsymbol{\epsilon}$. Khi t tăng, thành phần nhiễu tăng dần và thông tin từ biểu diễn sạch bị suy giảm. Tiến trình khử nhiễu ngược được mô hình hóa thông qua phân phối có điều kiện:

$$p_\theta(\mathbf{F}_{t-1} | \mathbf{F}_t, \mathbf{F}_c^0, t) = \mathcal{N}(\mathbf{F}_{t-1}; \boldsymbol{\mu}_\theta(\mathbf{F}_t, \mathbf{F}_c^0, t), \sigma_t^2 \mathbf{I}), \quad (3.20)$$

trong đó $\mathbf{F}_c^0$ là đặc trưng điều kiện trích xuất từ ảnh phổ, còn $\boldsymbol{\mu}_\theta$ là giá trị trung bình được ước lượng bởi mạng dự đoán nhiễu. Thay vì dự đoán trực tiếp $\mathbf{F}_0$, mạng ϵ_θ được huấn luyện để ước lượng nhiễu trong $\mathbf{F}_t$:

$$\boldsymbol{\epsilon}_\theta = \epsilon_\theta(\mathbf{F}_t, t, \mathbf{F}_c^0). \quad (3.21)$$

Tiến trình khử nhiễu ngược của mô hình khuếch tán được minh họa trong Hình 3.9. Quá trình này bắt đầu từ một biểu diễn nhiễu và từng bước khôi phục về biểu diễn sạch hơn. Trong quá trình suy luận, số bước khử nhiễu có thể được rút gọn bằng bộ giải nhanh nhằm giảm độ trễ mà vẫn duy trì chất lượng tái tạo.

3.5.2 Ánh xạ không gian tiềm ẩn và tái tạo mặt nạ phân đoạn

Việc thực hiện khuếch tán trực tiếp trên ảnh phổ có độ phân giải cao có thể làm tăng đáng kể chi phí tính toán. Vì vậy, SpecDiff trước hết ánh xạ ảnh phổ vào không gian tiềm ẩn có kích thước nhỏ hơn. Không gian này vẫn giữ các đặc trưng ngữ nghĩa cần thiết cho phân đoạn, nhưng giảm kích thước dữ liệu cần xử lý trong tiến trình khuếch tán. Sau khi quá trình khử nhiễu hoàn tất, bộ giải mã tái tạo bản đồ phân đoạn từ biểu diễn tiềm ẩn đã được tinh chỉnh.

Quá trình ánh xạ không gian tiềm ẩn và tái tạo mặt nạ được minh họa trong Hình 3.8. Khối mã hóa–giải mã trong hình được trình bày như một thành phần học biểu diễn tiềm ẩn. Bộ mã hóa

nén ảnh phổ thành các đặc trưng nhiều mức, trong khi bộ giải mã khôi phục mặt nạ phân đoạn từ biểu diễn sau khử nhiễu. Trong khối mã hóa, mô-đun chọn lọc đặc trưng (Feature Selection - FS) được sử dụng để trích xuất đặc trưng quan trọng từ ảnh phổ. Đầu ra của FS được xác định như sau:

$$\mathbf{F}_{\text{FS}}^{\text{out}} = \mathcal{C}_{1 \times 1}^i \left(\sigma \left(\mathcal{C}_{3 \times 3}^i \left(\mathcal{C}_{3 \times 3}^i \left(\mathbf{F}_{\text{FS}}^{\text{in}} \right) \right) \right) \right), \quad (3.22)$$

trong đó $\mathbf{F}_{\text{FS}}^{\text{in}}$ và $\mathbf{F}_{\text{FS}}^{\text{out}}$ lần lượt là đặc trưng đầu vào và đầu ra của FS. Ký hiệu $\mathcal{C}_{k \times m}^s(\cdot)$ biểu diễn phép tích chập với kernel $k \times m$ và stride s . Hàm sigmoid $\sigma(\cdot)$ đóng vai trò như cổng điều tiết đặc trưng, giúp mô-đun FS nhấn mạnh các vùng phổ quan trọng và giảm ảnh hưởng của nhiễu. Quá trình mã hóa tại giai đoạn thứ i được định nghĩa như sau:


$$\mathbf{F}_e^i = \begin{cases} \mathcal{M}_{2 \times 2}^2(\text{FS}(\mathbf{K}_{\text{iv}})), & i = 1, \\ \mathcal{M}_{2 \times 2}^2(\text{FS}(\mathbf{F}_e^{i-1})), & i \in \{2, 3\}, \end{cases} \quad (3.23)$$

trong đó $\mathcal{M}_{2 \times 2}^2(\cdot)$ là phép max pooling 2×2 với stride bằng 2. Qua từng giai đoạn, kích thước không gian của đặc trưng giảm dần, trong khi số kênh tăng lên để biểu diễn thông tin ngữ nghĩa ở mức cao hơn.

Ở phía giải mã, bộ decoder tương ứng được sử dụng để ánh xạ biểu diễn tiềm ẩn sau khử nhiễu về bản đồ phân đoạn ở cấp điểm ảnh. Cụ thể, đặc trưng tiềm ẩn sau khi được mạng khuếch tán tinh chỉnh sẽ được tăng mẫu dần qua các giai đoạn liên tiếp và xử lý bằng các khối FS để khôi phục độ phân giải không gian. Như vậy, khối mã hóa–giải mã đóng vai trò cầu nối giữa ảnh phổ đầu vào, không gian tiềm ẩn và mặt nạ phân đoạn đầu ra, trong đó encoder đã huấn luyện cung cấp biểu diễn tiềm ẩn ổn định cho quá trình khuếch tán, còn decoder đảm nhiệm việc tái tạo mặt nạ phân đoạn cuối cùng.

3.5.3 Mạng dự đoán nhiễu có điều kiện

Thành phần trung tâm của SpecDiff là mạng dự đoán nhiễu có điều kiện. Mạng này nhận biểu diễn nhiễu $\mathbf{F}_t$ tại bước thời gian t , đặc trưng điều kiện $\mathbf{F}_c^0$ từ encoder và dự đoán thành phần nhiễu $\epsilon_\theta(\mathbf{F}_t, t, \mathbf{F}_c^0)$. Kiến trúc của mạng dự đoán nhiễu được minh họa trong Hình 3.10. Mạng gồm ba thành phần chính: khối nén điều kiện thời gian (Time-Conditional Squeeze - TCS), đường dẫn đặc trưng điều kiện (Conditional Feature Path - CP) và bộ lọc tần số (Frequency Filter - FF).



Hình 3.11: Mạng dự đoán nhiều với đường dẫn đặc trưng điều kiện trong SpecDiff.

Trong đó, $\mathbf{F}_z^j$ là đặc trưng của đường dẫn nhiều tại giai đoạn thứ j . Việc giảm mẫu liên tiếp giúp mạng mở rộng vùng tiếp nhận và xây dựng biểu diễn đa tỉ lệ cho quá trình dự đoán nhiều.

Đường dẫn đặc trưng điều kiện (Conditional Feature Path - CP)

CP cung cấp thông tin ngữ nghĩa từ ảnh phổ cho mạng dự đoán nhiều (Hình 3.11). Nếu chỉ sử dụng $\mathbf{F}_t$, mạng có thể khó phân biệt đâu là cấu trúc tín hiệu cần giữ lại và đâu là nhiễu cần loại bỏ. Do đó, CP tích hợp đặc trưng từ encoder vào nhiều mức của mạng dự đoán nhiều, giúp quá trình khử nhiễu được định hướng bởi nội dung phổ đầu vào. Giai đoạn thứ j của CP được biểu diễn như sau:

$$\mathbf{F}_c^j = \begin{cases} \langle \mathcal{M}_{2 \times 2}^2(\mathcal{WCS}(\mathbf{F}_e^{j-1}, t)), \mathcal{C}_{i \times 1}^i(\mathbf{F}_z^j) \rangle, & j \in \{1, 2\}, \\ \mathcal{M}_{2 \times 2}^2(\mathcal{WCS}(\mathbf{F}_e^{j-1}, t)), & j = 3. \end{cases} \quad (3.29)$$

Trong đó, $\mathbf{F}_c^j$ là đặc trưng điều kiện tại giai đoạn thứ j , còn $\mathbf{F}_z^j$ là đặc trưng từ đường dẫn nhiều ở cùng mức. Phép ghép nối $\langle \cdot \rangle$ giúp kết hợp thông tin điều kiện từ encoder với trạng thái nhiều hiện tại.

Bộ lọc tần số (Frequency Filter - FF)

FF được sử dụng để tách đặc trưng thành thành phần tần số thấp và tần số cao. Thành phần tần số thấp thường biểu diễn cấu trúc ổn định của tín hiệu, trong khi thành phần tần số cao chứa các chi tiết sắc nét và có thể bao gồm cả nhiễu. Việc phân tách này giúp mạng dự đoán nhiều

khai thác tốt hơn sự khác biệt giữa cấu trúc tín hiệu cần bảo toàn và nhiễu cần loại bỏ. Đầu ra của FF được xác định như sau:

$$\mathbf{F}_{\mathcal{W}\mathcal{W}}^{out} = \mathcal{C}_{l \times l}^l (\langle \mathbf{F}_{bigb}, \mathbf{F}_{low} \rangle), \quad (3.30)$$

với

$$\mathbf{F}_{low} = \mathcal{A}_{3 \times 3}^l (\mathbf{F}_{\mathcal{W}\mathcal{W}}^{in}), \quad \mathbf{F}_{bigb} = \mathbf{F}_{\mathcal{W}\mathcal{W}}^{in} - \mathbf{F}_{low}. \quad (3.31)$$

Trong đó, $\mathcal{A}_{3 \times 3}^l(\cdot)$ là phép lấy trung bình với kernel 3×3 và stride bằng 1. Thành phần $\mathbf{F}_{low}$ giữ lại cấu trúc trơn và ổn định, trong khi $\mathbf{F}_{bigb}$ biểu diễn phần sai khác, bao gồm các chi tiết cục bộ và thành phần nhiễu.

Ở mức đặc trưng thấp nhất, SpecDiff kết hợp đặc trưng từ CP và đường dẫn nhiễu bằng một cơ chế tương tự attention. Quá trình tích hợp được mô tả như sau:

$$\mathbf{F}_{ck\star} = \mathcal{WCS}(\sigma(\mathbf{F}_{ck} \odot \mathcal{C}_{3 \times 3}^l(\mathbf{F}_\star)), t), \quad (3.32)$$

với

$$\mathbf{F}_{ck} = (\mathcal{W}\mathcal{W}(\mathbf{F}_c^3) \odot \mathcal{C}_{3 \times 3}^l(\mathbf{F}_k)) \odot (\mathcal{W}\mathcal{W}(\mathbf{F}_z^3) \odot \mathcal{C}_{3 \times 3}^l(\mathbf{F}_c)). \quad (3.33)$$

Trong đó, $\mathbf{F}_{ck}$ biểu diễn mức tương tác giữa đặc trưng điều kiện và đặc trưng nhiễu. Đặc trưng tích hợp $\mathbf{F}_{ck\star}$ chứa thông tin đã được chọn lọc từ cả đường dẫn điều kiện và đường dẫn nhiễu, đóng vai trò là đầu vào cho nhánh giải mã của mạng dự đoán nhiễu.

Sau khi thu được $\mathbf{F}_{ck\star}$, đặc trưng này được đưa vào nhánh giải mã của mạng dự đoán nhiễu. Nhánh giải mã gồm các bước tăng mẫu liên tiếp kết hợp với các khối TCS, nhằm khôi phục dần độ phân giải của biểu diễn tiềm ẩn và đồng thời duy trì điều kiện theo bước thời gian t . Quá trình này cho phép thông tin đã được tích hợp từ đường dẫn nhiễu và đường dẫn điều kiện được truyền ngược về không gian tiềm ẩn có kích thước phù hợp với bước khử nhiễu hiện tại.

Trên sơ đồ kiến trúc, đầu ra của nhánh giải mã được biểu diễn là $\mathbf{F}_{t-l}$, tức biểu diễn tiềm ẩn sau một bước khử nhiễu từ $\mathbf{F}_t$. Nói cách khác, $\mathbf{F}_{ck\star}$ đóng vai trò là đặc trưng trung gian đã hợp nhất thông tin điều kiện và nhiễu, còn nhánh giải mã chuyển đặc trưng này thành biểu diễn tiềm ẩn ở bước trước đó trong tiến trình khử nhiễu. Việc lặp lại quá trình này qua nhiều bước giúp mô hình dần loại bỏ nhiễu trong không gian tiềm ẩn trước khi decoder tái tạo bản đồ phân đoạn cuối cùng.

3.5.4 Hàm mất mát huấn luyện

Quá trình huấn luyện SpecDiff gồm hai giai đoạn. Giai đoạn 1 huấn luyện khối VAE để học không gian tiềm ẩn từ mặt nạ phân đoạn. Sau khi hội tụ, các tham số của VAE được cố định và

encoder đã huấn luyện được sử dụng để tạo biểu diễn tiềm ẩn cho giai đoạn khuếch tán. Giai đoạn 2 huấn luyện mạng khuếch tán để dự đoán nhiễu trong không gian tiềm ẩn này.

- **Giai đoạn 1:** Ở giai đoạn đầu, mạng Autoencoder biến phân (VAE) được huấn luyện để tái tạo mặt nạ phân đoạn $\tilde{\mathbf{X}}$ từ đầu vào $\mathbf{X}$. Hàm mất mát của VAE gồm mất mát tái tạo (reconstruction loss) và thành phần điều chuẩn Kullback-Leibler (KL divergence):

$$\mathcal{L}_{VAE} = \mathcal{L}_{rec} + \lambda_{KL} \mathcal{L}_{reg}, \quad (3.34)$$

trong đó λ_{KL} là hệ số cân bằng cho thành phần KL. Mất mát tái tạo được tính bằng categorical cross-entropy:

$$\mathcal{L}_{rec} = -\frac{1}{M} \sum_{i=1}^M \sum_{c=1}^C \mathbf{x}_{i,c} \log(\tilde{\mathbf{x}}_{i,c}), \quad (3.35)$$

với M là số điểm ảnh và C là số lớp phân đoạn. Thành phần điều chuẩn KL có nhiệm vụ ràng buộc phân phối tiềm ẩn tiến gần đến phân phối chuẩn:

$$\mathcal{L}_{reg} = D_{KL}(\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\sigma}^2) \parallel \mathcal{N}(\mathbf{0}, \mathbf{I})). \quad (3.36)$$


Sau khi VAE hội tụ, bộ mã hóa được trích xuất và sử dụng như một mô hình tiền huấn luyện để tạo ra biểu diễn tiềm ẩn sạch $\mathbf{F}_0$ cung cấp cho mạng khuếch tán ở các giai đoạn tiếp theo.

- **Giai đoạn 2:** Mạng dự đoán nhiễu nhận $\mathbf{F}_t$, bước thời gian t và đặc trưng điều kiện $\mathbf{F}_c^0$ để ước lượng lại nhiễu đã thêm vào. Hàm mất mát khuếch tán được định nghĩa bằng sai số bình phương giữa nhiễu thực và nhiễu dự đoán:

$$\mathcal{L}_{diff} = \mathbb{E}_{t, \mathbf{F}_0, \epsilon} \left[\|\epsilon - \epsilon_{\theta}(\mathbf{F}_t, t, \mathbf{F}_c^0)\|_2^2 \right]. \quad (3.37)$$

3.6 MÔ HÌNH CÂN BẰNG HIỆU SUẤT - ASTA-Net

ASTA-Net, viết đầy đủ là Attentive Synergic Tri-stream Additive Network, là một kiến trúc phân đoạn ảnh phổ được thiết kế nhằm cân bằng giữa độ chính xác phân đoạn và chi phí tính toán. Mô hình hướng đến bài toán nhận dạng và phân tách các vùng phổ của 5G NR, LTE, ASR và Noise trong điều kiện phổ phức tạp. Điểm chính của ASTA-Net là tách quá trình học đặc trưng thành nhiều luồng bổ sung cho nhau, thay vì phụ thuộc vào một nhánh trích xuất đặc trưng duy nhất. Về mặt kiến trúc, ASTA-Net gồm ba thành phần chính. Thành phần thứ nhất là bộ mã hóa Transformer sử dụng mô-đun chú ý tự cộng (Additive Self-Attention - ASA) để học ngữ cảnh toàn cục của ảnh phổ. Thành phần thứ hai là đường tổng hợp mẫu tín hiệu (Pattern Synthesis Path -



Hình 3.12: Kiến trúc tổng quan của mô hình ASTA-Net.

PS), có nhiệm vụ mô hình hóa phân bố đặc trưng của từng loại tín hiệu. Thành phần thứ ba là đường tinh chỉnh không gian (Spatial Refinement Path - SR), tập trung vào các chi tiết biên và cấu trúc cục bộ. Các đặc trưng từ những thành phần này được kết hợp thông qua khối hợp nhất cộng hưởng (Synergic Fusion - SF) để tạo bản đồ phân đoạn cuối cùng.

Kiến trúc tổng quan của ASTA-Net được trình bày trong Hình 3.12. Từ ảnh phổ đầu vào $\mathbf{X}_{iv}$, mô hình đồng thời học đặc trưng ngữ cảnh toàn cục, đặc trưng phân bố mẫu tín hiệu và đặc trưng không gian cục bộ. Cách tổ chức ba luồng giúp mô hình xử lý tốt hơn các trường hợp tín hiệu bị nhiễu, có vùng biên không rõ hoặc xuất hiện chồng lấn trong miền thời gian–tần số.


3.6.1 Bộ mã hóa Transformer với chú ý tự cộng

Bộ mã hóa Transformer được sử dụng để trích xuất đặc trưng ngữ cảnh toàn cục từ ảnh phổ. Trong ảnh phổ, đặc trưng của một vùng tín hiệu không chỉ phụ thuộc vào giá trị cường độ tại từng điểm ảnh mà còn phụ thuộc vào quan hệ với các vùng lân cận theo trục thời gian và tần số. Vì vậy, việc học quan hệ dài hạn là cần thiết để phân biệt các vùng tín hiệu có hình thái tương tự hoặc bị suy giảm bởi nhiễu.

Bộ mã hóa gồm nhiều giai đoạn xử lý. Ở giai đoạn đầu, phép nhúng patch chồng lấn (Overlapping Patch Embedding - OPE) được sử dụng để chuyển ảnh phổ đầu vào thành chuỗi đặc trưng. Ở các giai đoạn tiếp theo, phép gộp patch chồng lấn (Overlapping Patch Merging - OPM) được dùng để giảm kích thước không gian và tăng số kênh biểu diễn. Quá trình mã hóa tại giai đoạn thứ j được biểu diễn như sau:

$$\mathbf{X}_j = \begin{cases} \mathcal{F}_{\mathbf{W}_{PB}}^j(\mathcal{F}_{OPE}(\mathbf{X}_{iv})), & j = 1, \\ \mathcal{F}_{\mathbf{W}_{PB}}^j(\mathcal{F}_{OPM}(\mathbf{X}_{j-1})), & j \in \{2, 3, 4\}, \end{cases} \quad (3.38)$$

trong đó $\mathbf{X}_j$ là đặc trưng đầu ra tại giai đoạn thứ j , $\mathcal{F}_{OPE}(\cdot)$ là phép nhúng patch chồng lấn, $\mathcal{F}_{OPM}(\cdot)$ là phép gộp patch chồng lấn, và $\mathcal{F}_{\mathbf{W}_{PB}}^j(\cdot)$ là khối Transformer tại giai đoạn thứ j . Thành



Hình 3.13: Mối liên kết giữa bộ mã hóa Transformer và khối tự chú ý cộng (ASA) trong ASTA-Net.

phần cốt lõi trong Transformer block là mô-đun chú ý tự cộng (Additive Self-Attention - ASA), được minh họa trong Hình 3.13. Theo thiết kế của ASTA-Net, ASA được sử dụng để thay thế cơ chế multi-head self-attention thông thường. Lý do là self-attention truyền thống có thể làm phân mảnh đặc trưng khi chia không gian biểu diễn thành nhiều head khác nhau, đồng thời làm tăng nguy cơ lan truyền các thành phần nhiễu trong ảnh phổ. Ngược lại, ASA duy trì đặc trưng trên toàn bộ chiều biểu diễn, từ đó giúp bảo toàn cấu trúc tín hiệu và tạo ra một biểu diễn ngữ cảnh gọn hơn. Gọi $\mathbf{F}_{\text{ASA}}^{\text{in}} \in \mathbb{R}^{\mathcal{M} \times D}$ là đặc trưng đầu vào của ASA, trong đó $\mathcal{M}$ là số token và D là số chiều đặc trưng. Hai ma trận query $\mathbf{Q} \in \mathbb{R}^{\mathcal{M} \times D}$ và key $\mathbf{K} \in \mathbb{R}^{\mathcal{M} \times D}$ được tạo bởi các lớp tuyến tính độc lập. Thay vì tính attention đầy đủ giữa mọi cặp token, ASA trước hết xây dựng một vector truy vấn toàn cục $\mathbf{F}_{\text{CQ}} \in \mathbb{R}^{1 \times D}$. Vector này đóng vai trò như trọng số chú ý theo kênh và được tính như sau:

$$\mathbf{F}_{\text{CQ}} = \text{Softmax} \left(\frac{\sum_{i=1}^{\mathcal{M}} \alpha_i \mathbf{c}_{i1}}{\sqrt{d}} \right), \quad (3.39)$$

trong đó


$$\alpha_i = \mathbf{c}_{i1} \cdot \mathbf{w}_a, \quad (3.40)$$

với $\mathbf{c}_{i1}$ là token query thứ i và $\mathbf{w}_a \in \mathbb{R}^{1 \times D}$ là tham số truy vấn toàn cục có thể học được. Hệ số α_i biểu diễn mức tương quan giữa token thứ i và truy vấn toàn cục. Sau khi thu được $\mathbf{F}_{\text{CQ}}$, vector này được broadcast để điều tiết đặc trưng key. Đầu ra của ASA được xác định bởi:

$$\mathbf{F}_{\text{ASA}}^{\text{out}} = \phi(\mathbf{Q}) + \mathcal{P}(\mathbf{K} \odot \mathbf{F}_{\text{CQ}}), \quad (3.41)$$

trong đó $\phi(\cdot)$ là phép chuẩn hóa lớp, $\mathcal{P}(\cdot)$ là phép chiếu tuyến tính kết hợp với hàm kích hoạt GELU, và $\odot$ là phép nhân theo từng phần tử. Cơ chế cộng tắt trong equation 3.41 giúp bảo toàn dòng gradient và giữ lại thông tin từ nhánh query.

So với self-attention tiêu chuẩn có độ phức tạp bậc hai theo số token, ASA giảm độ phức tạp từ $O(\mathcal{M}^2 D)$ xuống $O(\mathcal{M} D^2)$, trong đó $\mathcal{M}$ và D lần lượt là số token và chiều đặc trưng. Nhờ đó, mô-đun này phù hợp hơn với ảnh phổ có độ phân giải cao, nơi số lượng token lớn nhưng vẫn



Hình 3.14: Đường tổng hợp mẫu tín hiệu (PS path) và mô-đun ngữ cảnh cục bộ (LCM) trong ASTA-Net.

cần giữ thông tin ngữ cảnh toàn cục để phân biệt các tín hiệu 5G NR, LTE và ASR trong điều kiện nhiễu.


3.6.2 Đường tổng hợp mẫu tín hiệu

Đường tổng hợp mẫu tín hiệu (Pattern Synthesis Path - PS) được thiết kế để mô hình hóa phân bố cấu trúc của từng loại tín hiệu trong ảnh phổ. Các tín hiệu 5G NR, LTE và ASR có đặc điểm phổ khác nhau về độ rộng băng thông, mức năng lượng, tính liên tục theo thời gian và hình thái phổ. Do đó, PS path giúp mô hình học các mẫu phân bố đặc trưng của từng lớp, thay vì chỉ dựa vào thông tin cục bộ tại từng điểm ảnh. Cấu trúc của nhánh PS được trình bày trong Hình 3.14. Nhánh này sử dụng mô-đun LCM để kết hợp đặc trưng cục bộ với ngữ cảnh rộng hơn. Mỗi LCM gồm tích chập tiêu chuẩn và tích chập giãn, cho phép mô hình đồng thời khai thác chi tiết phổ gần và cấu trúc tín hiệu ở phạm vi lớn hơn.

Gọi $\mathcal{C}_{m \times m}^s(\cdot)$ là chuỗi thao tác gồm batch normalization, GELU và tích chập $m \times m$ với stride s . Mô-đun LCM tại giai đoạn thứ i với hệ số giãn r_i được ký hiệu là $\mathcal{F}_{\text{LCM}}^{i, r_i}(\cdot)$. Đặc trưng của PS path tại giai đoạn thứ i được xác định như sau:

$$\mathbf{F}_{\text{PS}}^i = \begin{cases} \mathcal{F}_{\text{LCM}}^{i, r_i}(\mathcal{C}_{3 \times 3}^2(\mathcal{C}_{3 \times 3}^2(\mathbf{X}_{\text{in}}))) + \mathbf{F}_{\text{GC}}^i, & i = 1, \\ \mathcal{F}_{\text{LCM}}^{i, r_i}(\mathbf{F}_{\text{PS}}^{i-1}) + \mathbf{F}_{\text{GC}}^i, & i \in \{2, 3\}, \end{cases} \quad (3.42)$$

trong đó $\mathbf{F}_{\text{PS}}^i$ là đặc trưng tổng hợp mẫu tại giai đoạn thứ i , còn $\mathbf{F}_{\text{GC}}^i$ là đặc trưng ngữ cảnh toàn cục từ encoder sau khi được căn chỉnh kích thước. Việc cộng $\mathbf{F}_{\text{GC}}^i$ vào từng giai đoạn giúp PS path kết hợp thông tin toàn cục với đặc trưng mẫu cục bộ.



Hình 3.15: Cấu trúc đường tinh chỉnh không gian (SR path) và mô-đun tinh chỉnh không gian (SRM) trong ASTA-Net.

Đặc trưng cuối của PS path, ký hiệu $\mathbf{F}_{PS}^3$, được sử dụng trong khối hợp nhất cuối và đồng thời được đưa qua S-head để tạo embedding phục vụ hàm mất mát mất phụ. Cơ chế này giúp PS path học các phân bố đặc trưng ổn định hơn cho từng lớp tín hiệu.

3.6.3 Đường tinh chỉnh không gian

Đường tinh chỉnh không gian (Spatial Refinement Path - SR) tập trung vào việc cải thiện chi tiết biên và cấu trúc không gian của vùng tín hiệu. Trong ảnh phổ, ranh giới giữa tín hiệu và nhiễu thường bị làm mờ, đặc biệt trong điều kiện SNR thấp hoặc khi các tín hiệu chồng lấn. Vì vậy, bên cạnh việc học phân bố mẫu tín hiệu bằng PS path, mô hình cần một nhánh chuyên biệt để tinh chỉnh các chi tiết cục bộ và vùng chuyển tiếp. Cấu trúc của đường SR và mô-đun SRM được trình bày trong Hình 3.15. Hình này cho thấy SR path nhận đặc trưng ngữ cảnh toàn cục từ encoder để điều khiển các khối SRM theo từng giai đoạn. Bên trong SRM, đặc trưng không gian được kết hợp với embedding pha và cơ chế scale-shift nhằm tăng cường các vùng biên, vùng chuyển tiếp và chi tiết cục bộ của tín hiệu trên ảnh phổ.

Trong SRM, đặc trưng ngữ cảnh toàn cục $\mathbf{F}_{GC}^{in}$ được dùng để tạo các tham số điều tiết γ và β . Đồng thời, đặc trưng không gian đầu vào $\mathbf{F}_{SRM}^{in}$ được xử lý để tạo đặc trưng θ . Đặc trưng này được chia thành hai phần θ_1 và θ_2 , sau đó đưa qua các hàm sin và cos để tạo embedding pha:

$$\mathbf{F}_{PE} = \langle \sin(\theta_1), \cos(\theta_2) \rangle. \quad (3.43)$$

Embedding pha $\mathbf{F}_{PE}$ giúp mô hình biểu diễn các biến đổi cục bộ có tính tuần hoàn hoặc có sự thay đổi nhanh trong ảnh phổ. Đầu ra của SRM được tính như sau:

$$\mathbf{F}_{SRM}^{out} = \text{GEMU}(\gamma \odot \mathbf{F}_{PE} + \beta + \theta). \quad (3.44)$$


Trong đó, γ và β lần lượt đóng vai trò scale và shift, còn θ giữ lại thông tin không gian ban đầu.

Cơ chế điều tiết này giúp SRM tăng cường các vùng biên và làm rõ các cấu trúc cục bộ quan trọng. Quá trình xử lý của SR path tại giai đoạn thứ i được mô tả bởi:

$$\mathbf{F}_{\text{SR}}^i = \begin{cases} \mathcal{F}_{\text{SRM}}^i (\mathcal{C}_{3 \times 3}^2 (\mathcal{C}_{3 \times 3}^2 (\mathbf{X}_{\text{iv}})), \mathbf{F}_{\text{CC}}^i), & i = 1, \\ \mathcal{F}_{\text{SRM}}^i (\mathbf{F}_{\text{SR}}^{i-1}, \mathbf{F}_{\text{CC}}^i), & i \in \{2, 3\}. \end{cases} \quad (3.45)$$

Trong đó, $\mathbf{F}_{\text{SR}}^i$ là đặc trưng của SR path tại giai đoạn thứ i , còn $\mathcal{F}_{\text{SRM}}^i(\cdot)$ là SRM tương ứng. Đặc trưng cuối $\mathbf{F}_{\text{SR}}^3$ được sử dụng trong khối hợp nhất để bổ sung thông tin biên và chi tiết không gian.

3.6.4 Hợp nhất cộng hưởng đa luồng



Hình 3.16: Kiến trúc tổng quan của cộng hưởng đa luồng trong ASTA-Net.

Sau khi thu được đặc trưng từ encoder, PS path và SR path, ASTA-Net sử dụng khối hợp nhất cộng hưởng (Synergic Fusion - SF) để tổng hợp các biểu diễn này. SF có nhiệm vụ cân bằng giữa hai nguồn thông tin: đặc trưng tinh chỉnh không gian từ SR path và đặc trưng phân bố mẫu từ PS path. Cách hợp nhất này giúp mô hình vừa giữ được biên tín hiệu, vừa duy trì tính nhất quán của vùng phổ thuộc cùng một lớp. Hình 3.16 minh họa mối liên hệ giữa bộ mã hóa Transformer, ASA và khối hợp nhất cộng hưởng. Đặc trưng toàn cục từ encoder được đưa vào các nhánh PS và SR, sau đó hai nhánh này được hợp nhất bằng cơ chế cổng. Tín hiệu điều khiển của SF được xác định bởi:

$$\mathbf{H} = \mathbf{F}_{\text{SR}}^3 + \mathbf{F}_{\text{CC}}^3. \quad (3.46)$$

Từ tín hiệu điều khiển $\mathbf{H}$, mô hình tạo trọng số thông qua hàm sigmoid để điều tiết đóng góp của SR path và PS path:

$$\mathbf{F}_{\text{SF}} = \langle \mathbf{F}_{\text{SR}}^3 \odot \sigma(\mathbf{H}), \mathbf{F}_{\text{PS}}^3 \odot (1 - \sigma(\mathbf{H})) \rangle. \quad (3.47)$$

Khi $\sigma(\mathbf{H})$ có giá trị lớn, mô hình ưu tiên đặc trưng từ SR path để giữ chi tiết biên. Khi $\sigma(\mathbf{H})$ có giá trị nhỏ, đặc trưng từ PS path đóng vai trò lớn hơn trong việc tái tạo các vùng tín hiệu có cấu

trúc đồng nhất. Đầu ra phân đoạn được tạo bởi:

$$\mathbf{X}_{\text{out}} = \mathcal{C}_{3 \times 3}^l (\mathcal{U}_{4 \times} (\mathbf{F}_{S\mathbf{v}})), \quad (3.48)$$

trong đó $\mathcal{U}_{4 \times}(\cdot)$ là phép tăng mẫu bốn lần. Sau đó, $\mathbf{X}_{\text{out}}$ được đưa qua softmax để tạo xác suất lớp tại từng điểm ảnh.

3.6.5 Hàm mất mát huấn luyện

ASTA-Net được huấn luyện bằng một hàm mất mát tổng hợp bao gồm hai thành phần: cross-entropy loss cho đầu ra phân đoạn cuối cùng và aggregation loss dành riêng cho đường tổng hợp mẫu tín hiệu (PS path). Tương tự như quá trình tối ưu của ASTRA-Net, thành phần cross-entropy loss ($\mathcal{L}_{ce}$) nhằm đảm bảo độ chính xác phân đoạn ở cấp điểm ảnh và được tính toán dựa trên công thức đã trình bày tại Phương trình (3.17). Trong khi đó, aggregation loss đóng vai trò là một hàm mất mát bổ trợ (auxiliary loss), giúp các luồng đặc trưng trong PS path có tính phân biệt cao hơn giữa các lớp tín hiệu trước khi tiến hành dung hợp. Đối với aggregation loss, đặc trưng cuối của PS path $\mathbf{F}_{\text{PS}}^3$ được đưa qua S-head để tạo bản đồ embedding:

$$\mathbf{E} = \mathcal{S}_{\text{head}} (\mathbf{F}_{\text{PS}}^3). \quad (3.49)$$

Gọi $\mathbf{e}_i$ là embedding của điểm ảnh thứ i và $\mathbf{p}_k$ là prototype học được của lớp k . Hai vector này được chuẩn hóa L2:

$$\tilde{\mathbf{e}}_i = \frac{\mathbf{e}_i}{\|\mathbf{e}_i\|_2}, \quad \tilde{\mathbf{p}}_k = \frac{\mathbf{p}_k}{\|\mathbf{p}_k\|_2}. \quad (3.50)$$

Xác suất điểm ảnh i thuộc lớp k được tính dựa trên độ tương đồng cosine giữa embedding và prototype:

$$p(y_i = k \mid \mathbf{e}_i) = \frac{\exp(\tilde{\mathbf{e}}_i^T \tilde{\mathbf{p}}_k / \tau)}{\sum_{j=1}^K \exp(\tilde{\mathbf{e}}_i^T \tilde{\mathbf{p}}_j / \tau)}. \quad (3.51)$$

Trong đó, τ là hệ số điều chỉnh độ sắc nét của phân phối. Aggregation loss được xác định bởi:

$$\mathcal{L}_{ag} = -\frac{1}{N} \sum_{i=1}^N \log(p(y_i = y_i^{\text{true}} \mid \mathbf{e}_i)). \quad (3.52)$$

Hàm mất mát này khuyến khích các embedding thuộc cùng một lớp tiến gần prototype tương ứng, từ đó cải thiện tính compact của đặc trưng nội lớp và tăng khả năng phân biệt giữa các lớp tín hiệu. Hàm mất mát tổng được viết như sau:

$$\mathcal{L}_{\text{total}} = \lambda_{ce} \mathcal{L}_{ce} + \lambda_{ag} \mathcal{L}_{ag}, \quad (3.53)$$

trong đó λ_{ce} và λ_{ag} là các hệ số cân bằng giữa độ chính xác phân đoạn cuối và khả năng gom cụm đặc trưng trong PS path.

3.6.6 Tóm tắt vai trò của ASTA-Net

ASTA-Net kết hợp ba loại đặc trưng quan trọng cho phân đoạn ảnh phổ. Bộ mã hóa Transformer với ASA cung cấp ngữ cảnh toàn cục, PS path học phân bố mẫu tín hiệu, còn SR path tinh chỉnh biên và chi tiết không gian. Khối SF hợp nhất thích nghi các đặc trưng này để tạo bản đồ phân đoạn cuối cùng. Nhờ thiết kế ba luồng, ASTA-Net có khả năng cân bằng giữa mô hình hóa ngữ cảnh, tái tạo mẫu tín hiệu và bảo toàn chi tiết cục bộ trong bài toán phân đoạn phổ.

3.7 CÀI ĐẶT MÔ PHỎNG

3.7.1 Tạo bộ dữ liệu tín hiệu mô phỏng

Do hiện nay còn thiếu các bộ dữ liệu công khai có độ tin cậy cao và có nhãn phân đoạn ở cấp điểm ảnh cho các kịch bản đồng tồn tại giữa tín hiệu thông tin di động và radar, nghiên cứu này xây dựng một bộ dữ liệu mô phỏng tuân theo các cấu hình thực tế của hệ thống vô tuyến. Bộ dữ liệu gồm 120,000 ảnh phổ có kích thước 256×256 điểm ảnh, được tạo từ các tín hiệu đại diện cho 5G NR, LTE, ASR và Noise. Các tín hiệu được mô phỏng trong môi trường kênh truyền tại tần số sóng mang 2.8 GHz, có xét đến fading đa đường, dịch Doppler và nhiễu cộng Gaussian trắng (AWGN). Môi trường mô phỏng được thiết lập với số lượng vật tán xạ thay đổi từ 1 đến 30, độ trễ trễ cực đại $\tau_{\text{max}} = 20 \mu\text{s}$ và các mức SNR nằm trong khoảng từ -10 đến 30 dB. Thành phần radar được mô phỏng theo dạng radar giám sát hàng không băng S với công suất phát đỉnh 25 kW, độ rộng xung $1 \mu\text{s}$ và tần số lặp xung xấp xỉ 1050 Hz. Đối với tín hiệu 5G NR, mô phỏng sử dụng khoảng cách sóng mang con 15 hoặc 30 kHz, băng thông từ 10 đến 50 MHz và chu kỳ SSB bằng 20 ms. Trong khi đó, tín hiệu LTE được tạo dựa trên các kênh tham chiếu R.6, R.8 và R.9, với băng thông từ 5 đến 20 MHz và điều chế QPSK hoặc 64QAM. Các tham số chi tiết được trình bày trong Bảng 3.1.

Để đánh giá khả năng của mô hình trong các kịch bản chưa xuất hiện ở giai đoạn huấn luyện, bộ dữ liệu được chia theo kịch bản tín hiệu thay vì chia ngẫu nhiên theo mẫu. Cụ thể, tập huấn luyện gồm 80,000 mẫu chỉ chứa các kịch bản hai tín hiệu, gồm 5G NR–ASR hoặc LTE–ASR. Tập xác thực và kiểm tra gồm 40,000 mẫu được xây dựng từ kịch bản đồng tồn tại ba tín hiệu 5G NR–LTE–ASR. Cách chia này giúp kiểm tra khả năng của mô hình trong việc phân tách các tín hiệu chồng lấn phức tạp mà mô hình chưa trực tiếp quan sát trong quá trình huấn luyện.

Bảng 3.1: Các tham số sinh dữ liệu và cấu hình dạng sóng mô phỏng.

Cấu hình dạng sóng và môi trường mô phỏng						Ký hiệu	
Loại	Tham số	Giá trị	Loại	Tham số	Giá trị	Tham số	Ý nghĩa
ASR	f_s	61.44 MHz	LTE	Ref.	{R.6, R.8, R.9}	f_s	Tần số lấy mẫu
	$\mathcal{P}_w$	1 μ s		B	[5, 20] MHz	$\mathcal{P}_w$	Độ rộng xung
	PRF	≈ 1050 Hz		Mod.	{QPSK, 64QAM}	PRF	Tần số lặp xung
	$\mathcal{M}_p$	3		T_{subft}	[0, 40] ms	$\mathcal{M}_p$	Số xung trong mỗi burst
	P_{peak}	25 kW				P_{peak}	Công suất phát đỉnh
	G_{tx}	32.8 dB				G_{tx}	Độ lợi Anten phát
5G NR	Δf	{15, 30} kHz	Môi trường	f_c	2.8 GHz	Δf	Khoảng cách sóng mang con
	B	[10, 50] MHz		f_D	{0, 5, 70, 500} Hz	T_{SSB}	Chu kỳ khối SSB
	T_{SSB}	20 ms		SNR	{-10, 0, 10, 20, 30} dB	T_{subft}	Độ dịch thời gian ngẫu nhiên
	Mod.	QPSK		$\mathcal{M}_{\text{scat}}$	[1, 30]	f_c	Tần số sóng mang
	T_{subft}	[0, 40] ms		τ_{waa}	20 μ s	f_D	Dịch Doppler
				$\mathbf{p}_{tx}$	[0, 0, 15] ^T (Radar) [200, 0, 450] ^T (Com.)	$\mathcal{M}_{\text{scat}}$	Số lượng vật tán xạ
						τ_{waa}	Độ trễ trễ cực đại
						$\mathbf{p}_{tx}$	Tọa độ máy phát

3.7.2 Cấu hình huấn luyện

Quá trình huấn luyện mô hình mạng nơ-ron đề xuất được thực hiện với các thiết lập cụ thể như sau: thuật toán tối ưu hóa adaptive moment estimation (AdamW) được sử dụng do khả năng hội tụ nhanh và hiệu quả trong các bài toán học sâu; để giảm thiểu nguy cơ quá khớp trên tập dữ liệu huấn luyện, điều chuẩn bằng hệ số suy giảm trọng số L2 (weight decay) được áp dụng với giá trị là 10^{-4} ; các giai đoạn được huấn luyện trong 60 epoch với kích thước batch là 32, tốc độ học ban đầu được đặt là 10^{-4} ; mô hình cuối cùng được lựa chọn dựa trên hiệu suất tốt nhất (độ chính xác toàn cục cao nhất) trên tập dữ liệu kiểm định (validation set) trong suốt quá trình huấn luyện; toàn bộ quá trình huấn luyện và đánh giá được thực hiện trên nền tảng Kaggle, tận dụng tài nguyên tính toán với GPU NVIDIA T4 (T4×2).

3.7.3 Phương pháp và tiêu chí đánh giá

Năng lực phân đoạn ngữ nghĩa của kiến trúc đề xuất được định lượng thông qua hệ thống các hệ số đo lường chuẩn mực trong lĩnh vực thị giác máy tính [60]. Các phép toán đánh giá được xây dựng dựa trên ma trận nhầm lẫn, với các đại lượng cốt lõi bao gồm: True Positive ($\mathcal{TP}_i$), True Negative ($\mathcal{TN}_i$) và False Positive ($\mathcal{FP}_i$) được tính toán độc lập cho từng lớp i trong tổng số $\mathcal{K}$ lớp (với bài toán hiện tại $\mathcal{K} = 4$). Hai hệ số trung tâm được sử dụng để đối chiếu hiệu năng gồm:

- **Độ chính xác trung bình:** Hệ số này xác định tỷ lệ phân loại chính xác trên tổng thể số lượng điểm ảnh của tập dữ liệu kiểm định. Công thức toán học của mAcc được biểu diễn như sau:

$$\text{mAcc} = \frac{1}{\mathcal{K}} \sum_{i=1}^{\mathcal{K}} \frac{\mathcal{TP}_i}{\mathcal{TP}_i + \mathcal{FN}_i} \quad (3.54)$$

Mặc dù mAcc cung cấp một góc nhìn vĩ mô về khả năng nhận diện, độ tin cậy của chỉ số này thường bị suy giảm trong các kịch bản dữ liệu mất cân bằng (class imbalance). Cụ thể, một

mô hình có xu hướng thiên lệch (bias) dự đoán lớp đa số (ví dụ: nền tảng nhiễu) vẫn có thể đạt ngưỡng mAcc ấn tượng mà không phản ánh đúng thực lực phân đoạn các lớp thiểu số.

- **Chỉ số giao trên hợp trung bình:** Nhằm khắc phục điểm yếu của mAcc, mIoU được xem là hệ số tham chiếu tối quan trọng để nghiệm thu chất lượng mặt nạ phân đoạn. mIoU đánh giá mức độ tương giao không gian giữa phân vùng dự đoán và phân vùng thực tế (ground truth). Để tính toán hệ số này, thuật toán trước tiên đo lường IoU cho từng lớp cụ thể, sau đó lấy trung bình cộng trên toàn bộ K lớp học được:

$$\text{mIoU} = \frac{1}{K} \sum_{i=1}^K \frac{\text{TP}_i}{\text{TP}_i + \text{FP}_i + \text{FN}_i} \quad (3.55)$$

Nhờ cơ chế định chuẩn (normalization) độc lập cho từng lớp, mIoU đảm bảo tính công bằng trong việc đánh giá hiệu suất, đồng thời là một thước đo cực kỳ nhạy bén đối với sự sai lệch ranh giới hình học của đối tượng.

Bên cạnh các tham số tối ưu hóa chất lượng phân đoạn, khối lượng tham số mạng (learnable parameters) cũng được đưa vào hệ quy chiếu. Việc đối chiếu tham số giữa mạng lưới đề xuất và các hệ thống state-of-the-art hiện hành là cơ sở thiết yếu để minh chứng cho năng lực cân bằng giữa hiệu suất xử lý toán học và chi phí tài nguyên tính toán của mô hình.

Chương 4

KẾT QUẢ VÀ THẢO LUẬN

Chương này trình bày các kết quả mô phỏng cụ thể nhằm minh chứng cho sự cải tiến của phương pháp nhận dạng tín hiệu được đề xuất, đặc biệt là về khả năng phân đoạn và độ phức tạp của mô hình. Những cải tiến này tập trung vào khả năng phân đoạn tín hiệu và giảm thiểu độ phức tạp của mô hình mạng so với mạng cơ sở. Để đảm bảo tính thuyết phục và chứng minh hiệu quả của mô hình, các kết quả đánh giá được thực hiện thông qua ba thí nghiệm mô phỏng chính. Thứ nhất, hiệu suất phân đoạn của mô hình đề xuất được khảo sát trên tín hiệu có mức SNR khác nhau, qua đó chứng minh năng lực của mô hình trong việc nhận diện các tín hiệu cùng tồn tại trong một dải tần số. Thứ hai, một nghiên cứu loại bỏ được tiến hành để phân tích mức độ ảnh hưởng của các thành phần cải tiến trong mô hình và đưa ra nhận xét về tác động của từng mô-đun đến kết quả đầu ra. Cuối cùng, kết quả phân đoạn của mô hình đề xuất được so sánh với các mô hình phân đoạn ngữ nghĩa tiên tiến hiện nay, qua đó khẳng định tiềm năng ứng dụng thực tế của mô hình được đề xuất.

4.1 Phân tích nghiên cứu cắt bỏ của các mô hình đề xuất

4.1.1 Phân tích nghiên cứu cắt bỏ của ASTRA-Net

Để đánh giá mức đóng góp của từng mô-đun trong ASTRA-Net, nghiên cứu đã triển khai thí nghiệm cắt bỏ thành phần. Các cấu hình được xây dựng bằng cách lần lượt bỏ sung từng thành phần hoặc kết hợp nhiều thành phần vào kiến trúc nền, sau đó so sánh sự thay đổi về mAcc, mIoU, số tham số, FLOPs và thời gian suy luận. Mục tiêu của thí nghiệm này là làm rõ vai trò riêng của từng mô-đun, cũng như mức độ hỗ trợ giữa các mô-đun trong việc cải thiện hiệu suất phân đoạn ảnh phổ.

Bảng 4.1: Bảng nghiên cứu cắt bỏ thành phần của ASTRA-Net.

Method	Components			Performance		Params	FLOPs	Speed
	DSSL	ASD	PSL	mAcc (%)	mIoU (%)	(M)	(G)	(ms)
Baseline	$\times$	$\times$	$\times$	61.84	48.72	3.2	1.85	1.12
$\mathcal{M}_1$	$\checkmark$	$\times$	$\times$	64.26	50.91	3.8	2.16	1.52
	$\times$	$\checkmark$	$\times$	65.10	51.68	4.1	2.38	1.88
	$\checkmark$	$\checkmark$	$\times$	67.34	53.42	4.4	2.70	2.05
$\mathcal{M}_2$	$\times$	$\times$	$\checkmark$	63.72	50.16	4.6	2.55	1.86
	$\checkmark$	$\times$	$\checkmark$	66.85	52.94	5.6	3.12	2.05
	$\times$	$\checkmark$	$\checkmark$	67.58	53.87	6.1	3.45	2.18
ASTRA-Net	$\checkmark$	$\checkmark$	$\checkmark$	69.42	55.36	6.6	3.89	2.36

Bảng 4.1 trình bày kết quả nghiên cứu cắt bỏ thành phần của ASTRA-Net với ba mô-đun chính gồm Dynamic Selective Spectrum Layer (DSSL), Adaptive Spectrum Distiller (ASD) và Pathwise Spatial Layer (PSL). Các cấu hình trong bảng được chia thành bốn nhóm: baseline, $\mathcal{M}_1$, $\mathcal{M}_2$ và ASTRA-Net đầy đủ. Trong đó, baseline là kiến trúc nền chưa sử dụng ba mô-đun tăng cường; $\mathcal{M}_1$ được dùng để đánh giá ảnh hưởng của DSSL và ASD khi chưa có PSL; $\mathcal{M}_2$ được dùng để đánh giá vai trò của PSL và khả năng kết hợp của PSL với DSSL hoặc ASD; cuối cùng, ASTRA-Net là cấu hình đầy đủ kết hợp đồng thời cả ba thành phần. Cấu hình baseline đạt 61.84% mAcc và 48.72% mIoU với 3.2M tham số, 1.85 GFLOPs và độ trễ 1.12 ms. Kết quả này cho thấy kiến trúc nền có chi phí tính toán thấp, nhưng khả năng biểu diễn còn hạn chế do chưa có cơ chế lựa chọn đặc trưng đa tỉ lệ, chưa có khối làm giàu ngữ cảnh toàn cục và chưa có mô-đun tăng cường đặc trưng không gian. Vì vậy, baseline đóng vai trò làm mốc để đánh giá mức cải thiện khi từng thành phần của ASTRA-Net được bổ sung. Nhóm $\mathcal{M}_1$ tập trung đánh giá ảnh hưởng của DSSL và ASD trong trường hợp chưa sử dụng PSL. Khi chỉ bổ sung DSSL, mAcc tăng từ 61.84% lên 64.26% và mIoU tăng từ 48.72% lên 50.91%. Sự cải thiện này cho thấy DSSL giúp mô hình thích ứng tốt hơn với các cấu trúc tín hiệu có kích thước khác nhau trong ảnh phổ. Cụ thể, các tín hiệu dạng xung như ASR thường có cấu trúc hẹp và cục bộ, trong khi 5G NR và LTE có xu hướng tạo ra các vùng phổ rộng và liên tục hơn. Do đó, cơ chế receptive field động của DSSL giúp mô hình khai thác đồng thời các chi tiết cục bộ và các vùng phổ có phạm vi lớn hơn. Khi chỉ bổ sung ASD trong nhóm $\mathcal{M}_1$, mô hình đạt 65.10% mAcc và 51.68% mIoU, cao hơn cấu hình chỉ dùng DSSL. Kết quả này cho thấy đặc trưng ngữ cảnh toàn cục đóng vai trò quan trọng trong phân đoạn ảnh phổ. ASD giúp mô hình tổng hợp thông tin trên toàn bộ bản đồ đặc trưng, từ đó tăng khả năng nhận diện các vùng tín hiệu bị nhiễu, bị suy giảm năng lượng hoặc bị chia cắt theo miền thời gian-tần số. Khi kết hợp DSSL và ASD, mô hình đạt 67.34% mAcc và 53.42% mIoU, tương ứng mức cải thiện 5.50 điểm mAcc và 4.70 điểm mIoU so với baseline. Điều này cho thấy DSSL và ASD có tính bổ trợ: DSSL tăng khả năng khai thác đặc trưng đa tỉ lệ, trong khi ASD bổ sung thông tin ngữ cảnh toàn cục để điều tiết đặc trưng. Nhóm $\mathcal{M}_2$ được thiết kế để đánh giá vai trò của PSL. Khi chỉ sử dụng PSL, mô hình đạt 63.72% mAcc và 50.16% mIoU. Kết quả này cho thấy PSL có khả năng cải thiện hiệu suất so với baseline nhờ tăng cường đặc trưng không

gian và hỗ trợ bảo toàn các chi tiết cục bộ của vùng tín hiệu. Tuy nhiên, mức cải thiện của PSL khi đứng riêng lẻ thấp hơn so với ASD hoặc tổ hợp DSSL–ASD, cho thấy thông tin không gian cần được kết hợp với đặc trưng đa tỉ lệ hoặc ngữ cảnh toàn cục để phát huy hiệu quả tốt hơn. Khi PSL được kết hợp với DSSL trong nhóm $\mathcal{M}_2$, mô hình đạt 66.85% mAcc và 52.94% mIoU. Điều này cho thấy PSL giúp giữ lại các đặc trưng cục bộ sau khi DSSL đã lựa chọn đặc trưng ở nhiều tỉ lệ khác nhau. Khi PSL được kết hợp với ASD, hiệu suất tăng lên 67.58% mAcc và 53.87% mIoU, cao hơn cấu hình DSSL–PSL. Kết quả này cho thấy ngữ cảnh toàn cục từ ASD đặc biệt hữu ích khi kết hợp với mô-đun tăng cường không gian, vì nó giúp các chi tiết cục bộ được diễn giải trong bối cảnh phổ rộng hơn. Nói cách khác, PSL đóng vai trò giữ biên và chi tiết không gian, còn ASD giúp xác định các chi tiết đó có thuộc về vùng tín hiệu có ý nghĩa hay chỉ là nhiễu nền. Cấu hình đầy đủ ASTRA-Net kết hợp đồng thời DSSL, ASD và PSL đạt 69.42% mAcc và 55.36% mIoU, cao nhất trong toàn bộ bảng. So với baseline, cấu hình này cải thiện 7.58 điểm mAcc và 6.64 điểm mIoU. Sự cải thiện này cho thấy ba thành phần không hoạt động độc lập mà bổ trợ lẫn nhau. DSSL cung cấp khả năng thích ứng với các cấu trúc phổ đa tỉ lệ; ASD làm giàu ngữ cảnh toàn cục; còn PSL giúp bảo toàn chi tiết không gian và vùng biên. Khi được kết hợp, các mô-đun này giúp ASTRA-Net phân đoạn hiệu quả hơn các vùng tín hiệu có hình thái khác nhau trong ảnh phổ. Mặc dù cấu hình đầy đủ làm tăng số tham số lên 6.6M và FLOPs lên 3.89G, thời gian suy luận vẫn chỉ đạt 2.36 ms. Mức độ trễ này vẫn thấp so với yêu cầu của các kịch bản giám sát phổ gần thời gian thực. Do đó, kết quả nghiên cứu cắt bỏ thành phần cho thấy ASTRA-Net đạt được sự cải thiện đáng kể về hiệu suất trong khi vẫn duy trì chi phí tính toán thấp. Điều này củng cố vai trò của ASTRA-Net như một mô hình ưu tiên tốc độ, phù hợp với các hệ thống cần xử lý nhanh trên nền tảng tài nguyên hạn chế.

4.1.2 Phân tích nghiên cứu cắt bỏ của SpecDiff

Để đánh giá vai trò của các thành phần trong SpecDiff, nghiên cứu cắt bỏ thành phần được thực hiện trên ba khối chính gồm Time-Conditional Squeeze (TCS), Frequency Filter (FF) và Conditional Path (CP). Các cấu hình được chia thành bốn nhóm: baseline, $\mathcal{M}_1$, $\mathcal{M}_2$ và SpecDiff đầy đủ. Trong đó, baseline là cấu hình chưa sử dụng ba thành phần trên; $\mathcal{M}_1$ đánh giá ảnh hưởng của FF và CP khi chưa có TCS; $\mathcal{M}_2$ đánh giá vai trò của TCS và khả năng kết hợp của TCS với FF hoặc CP; cuối cùng, SpecDiff là cấu hình đầy đủ kết hợp đồng thời cả ba thành phần. Mục tiêu của thí nghiệm này là làm rõ cơ chế nào đóng góp nhiều nhất vào hiệu quả khử nhiễu trong không gian tiềm ẩn, đồng thời phân tích sự đánh đổi giữa chất lượng phân đoạn và chi phí tính toán.

Bảng 4.2 cho thấy cấu hình baseline đạt 66.70% mAcc và 52.20% mIoU với 7.2M tham số, 8.10 GFLOPs và độ trễ 5.90 ms. Đây là cấu hình nền của SpecDiff khi chưa sử dụng TCS, FF và CP. Mặc dù baseline đã khai thác biểu diễn tiềm ẩn, hiệu suất vẫn còn hạn chế do quá trình dự

Bảng 4.2: Bảng nghiên cứu cắt bỏ thành phần của SpecDiff.

Method	Components			Performance		Params	FLOPs	Speed
	TCS	FF	CP	mAcc (%)	mIoU (%)	(M)	(G)	(ms)
Baseline	$\times$	$\times$	$\times$	66.70	52.20	7.2	8.10	5.90
$\mathcal{M}_1$	$\times$	$\checkmark$	$\times$	67.58	53.24	7.8	8.72	6.42
	$\times$	$\times$	$\checkmark$	68.82	54.48	8.1	8.95	6.58
	$\times$	$\checkmark$	$\checkmark$	71.10	56.40	8.8	9.56	7.02
$\mathcal{M}_2$	$\checkmark$	$\times$	$\times$	72.54	58.20	10.5	10.84	7.46
	$\checkmark$	$\checkmark$	$\times$	73.75	59.28	11.1	11.42	8.12
	$\checkmark$	$\times$	$\checkmark$	74.36	60.20	11.4	11.68	8.30
SpecDiff	$\checkmark$	$\checkmark$	$\checkmark$	75.18	61.35	12.0	12.25	8.60

đoán nhiễu chưa được điều kiện hóa theo bước khuếch tán, chưa có cơ chế tách thành phần phổ ổn định và nhiễu, đồng thời chưa được hướng dẫn trực tiếp bởi đặc trưng điều kiện từ encoder. Nhóm $\mathcal{M}_1$ được thiết kế để đánh giá vai trò của FF và CP trong trường hợp chưa sử dụng TCS. Khi chỉ bổ sung FF, mô hình đạt 67.58% mAcc và 53.24% mIoU, tương ứng cải thiện 0.88 điểm mAcc và 1.04 điểm mIoU so với baseline. FF có nhiệm vụ tách biểu diễn tiềm ẩn thành thành phần tần số thấp và tần số cao. Thành phần tần số thấp thường biểu diễn cấu trúc tín hiệu ổn định, trong khi thành phần tần số cao chứa các chi tiết biên và nhiễu. Nhờ cơ chế này, mạng dự đoán nhiễu có thể phân biệt tốt hơn giữa cấu trúc tín hiệu thật và nhiễu cần loại bỏ. Tuy nhiên, khi FF đứng riêng lẻ, mức cải thiện còn hạn chế vì mô hình vẫn thiếu thông tin điều kiện ngữ nghĩa và thiếu khả năng thích ứng theo mức nhiễu của từng bước khuếch tán. Khi chỉ bổ sung CP trong nhóm $\mathcal{M}_1$, mô hình đạt 68.82% mAcc và 54.48% mIoU, cao hơn cấu hình chỉ sử dụng FF. Kết quả này cho thấy CP đóng vai trò quan trọng hơn FF khi xét riêng lẻ. CP đưa đặc trưng điều kiện từ encoder vào mạng dự đoán nhiễu ở nhiều mức tỉ lệ, giúp mô hình biết được thông tin ngữ cảnh của ảnh phổ gốc trong quá trình khử nhiễu. Nhờ đó, mạng không chỉ dựa vào biểu diễn tiềm ẩn nhiễu, mà còn được hướng dẫn bởi đặc trưng ngữ nghĩa liên quan đến vị trí và cấu trúc của các vùng tín hiệu. Khi kết hợp FF và CP trong nhóm $\mathcal{M}_1$, mô hình đạt 71.10% mAcc và 56.40% mIoU. So với baseline, mức cải thiện đạt 4.40 điểm mAcc và 4.20 điểm mIoU. Kết quả này cho thấy FF và CP có quan hệ bổ trợ. FF giúp làm rõ cấu trúc phổ bằng cách tách thành phần ổn định và thành phần chi tiết, trong khi CP cung cấp thông tin điều kiện từ encoder để định hướng quá trình dự đoán nhiễu. Tuy nhiên, do chưa có TCS, mô hình vẫn chưa thích ứng đầy đủ với mức nhiễu thay đổi theo từng bước khuếch tán. Nhóm $\mathcal{M}_2$ tập trung đánh giá vai trò của TCS. Khi chỉ sử dụng TCS, mô hình đạt 72.54% mAcc và 58.20% mIoU, tương ứng cải thiện 5.84 điểm mAcc và 6.00 điểm mIoU so với baseline. Đây là mức cải thiện lớn nhất trong các thành phần đơn lẻ, cho thấy TCS là mô-đun quan trọng nhất trong mạng dự đoán nhiễu của SpecDiff. Lý do là quá trình khuếch tán có bản chất phụ thuộc vào bước thời gian t : ở mỗi bước, mức nhiễu trong biểu diễn tiềm ẩn là khác nhau. TCS chuyển bước thời gian thành vector điều kiện và sử dụng cơ chế scale-shift để điều tiết feature map, nhờ đó mạng có thể thích ứng với từng mức nhiễu cụ thể

thay vì sử dụng cùng một phép biến đổi cho mọi bước khử nhiễu. Khi TCS được kết hợp với FF, mô hình đạt 73.75% mAcc và 59.28% mIoU. So với cấu hình chỉ có TCS, FF giúp cải thiện thêm 1.21 điểm mAcc và 1.08 điểm mIoU. Điều này cho thấy sau khi đã có điều kiện hóa theo bước thời gian, việc tách đặc trưng phổ thấp và cao tiếp tục hỗ trợ mạng phân biệt giữa cấu trúc tín hiệu ổn định và nhiễu cục bộ. Khi TCS được kết hợp với CP, mô hình đạt 74.36% mAcc và 60.20% mIoU, cao hơn cấu hình TCS-FF. Kết quả này cho thấy CP có tác động mạnh hơn FF khi kết hợp với TCS, vì thông tin điều kiện từ encoder giúp mạng dự đoán nhiễu tập trung vào các vùng tín hiệu có ý nghĩa thay vì xử lý biểu diễn tiềm ẩn một cách độc lập. Cấu hình đầy đủ SpecDiff, kết hợp đồng thời TCS, FF và CP, đạt kết quả cao nhất với 75.18% mAcc và 61.35% mIoU. So với baseline, mô hình cải thiện 8.48 điểm mAcc và 9.15 điểm mIoU. Sự cải thiện này cho thấy ba thành phần đóng vai trò bổ sung lẫn nhau trong quá trình khử nhiễu. TCS giúp mạng thích ứng với mức nhiễu theo từng bước khuếch tán; FF hỗ trợ phân rã cấu trúc phổ để tách tín hiệu ổn định khỏi nhiễu; còn CP cung cấp đặc trưng điều kiện nhằm định hướng quá trình phục hồi biểu diễn tiềm ẩn. Tuy nhiên, hiệu suất cao của SpecDiff đi kèm với chi phí tính toán lớn hơn. Cấu hình đầy đủ sử dụng 12.0M tham số, 12.25 GFLOPs và có thời gian suy luận 8.60 ms, cao hơn đáng kể so với baseline. Điều này phản ánh bản chất của mô hình khuếch tán: để đạt chất lượng phân đoạn cao, mô hình cần thêm các cơ chế điều kiện hóa và tinh chỉnh biểu diễn trong không gian tiềm ẩn. Do đó, nghiên cứu cắt bỏ thành phần cho thấy SpecDiff là mô hình ưu tiên hiệu năng phân đoạn. Mô hình phù hợp với các kịch bản đặt chất lượng mặt nạ lên hàng đầu, đặc biệt khi tín hiệu bị nhiễu mạnh, chồng lấn phổ hoặc có cấu trúc khó phân biệt.

4.1.3 Phân tích nghiên cứu cắt bỏ và các siêu tham số trong ASTA-Net

Phân tích nghiên cứu cắt bỏ thành phần của ASTA-Net

ASTA-Net được thiết kế theo hướng cân bằng giữa hiệu suất phân đoạn và chi phí tính toán thông qua kiến trúc ba luồng. Vì vậy, nghiên cứu cắt bỏ thành phần trong mục này tập trung vào hai khía cạnh chính: ảnh hưởng của bộ mã hóa ASA so với efficient self-attention, và mức đóng góp của ba thành phần PS, SR và SF trong việc học phân bố mẫu tín hiệu, tinh chỉnh chi tiết không gian và hợp nhất đặc trưng thích nghi. Thông qua các cấu hình trong Bảng 4.3, mục này làm rõ vì sao ASTA-Net đạt được sự cân bằng giữa độ chính xác, khả năng hoạt động trong điều kiện nhiễu và thời gian suy luận.

Bảng 4.3 trình bày kết quả nghiên cứu cắt bỏ thành phần của ASTA-Net theo hai nhóm yếu tố: loại encoder và các thành phần xử lý đặc trưng gồm Pattern Synthesis Path (PS), Spatial Refinement Path (SR) và Synergic Fusion (SF). Mỗi cấu hình thành phần được đánh giá với hai loại encoder, gồm efficient self-attention và Additive Self-Attention (ASA). Cách tổ chức này cho

Bảng 4.3: Bảng nghiên cứu cắt bỏ thành phần của ASTA-Net.

Encoder	Components PS SR SF			mAcc (%)				mIoU (%)	Params (M)	Speed (ms)
				SNR (dB)			Ovr.			
				−10	10	30				
Efficient self-attention	X	X	X	27.84	41.92	54.12	56.18	42.05	8.3	3.34
ASA	X	X	X	30.15	43.68	56.94	58.54	43.94	7.7	2.97
Efficient self-attention	✓	X	X	31.45	44.56	58.11	59.44	44.48	8.7	4.42
ASA	✓	X	X	34.22	46.31	60.45	62.56	46.48	8.1	4.06
Efficient self-attention	X	✓	X	32.90	45.42	59.58	59.98	45.64	9.0	4.67
ASA	X	✓	X	36.18	50.04	64.32	64.68	50.11	9.2	4.24
Efficient self-attention	X	X	✓	33.74	48.91	61.22	63.50	48.76	9.3	3.49
ASA	X	X	✓	35.56	49.72	62.54	64.28	49.89	8.7	3.22
Efficient self-attention	✓	✓	✓	36.08	56.45	58.91	71.74	56.78	11.6	6.15
ASA	✓	✓	✓	37.28	58.26	60.75	72.59	58.10	11.0	5.06


phép đánh giá đồng thời hai vấn đề: thứ nhất, hiệu quả của ASA so với cơ chế attention nền; thứ hai, mức đóng góp riêng và mức hỗ trợ của các nhánh PS, SR và SF trong kiến trúc ba luồng của ASTA-Net. Trước hết, xét cấu hình không sử dụng PS, SR và SF, encoder efficient self-attention đạt 56.18% mAcc tổng thể và 42.05% mIoU với 8.3M tham số và độ trễ 3.34 ms. Khi thay thế bằng ASA, mAcc tăng lên 58.54% và mIoU tăng lên 43.94%, đồng thời số tham số giảm xuống 7.7M và độ trễ giảm còn 2.97 ms. Kết quả này cho thấy ASA không chỉ cải thiện hiệu suất phân đoạn mà còn giúp giảm chi phí tính toán của encoder. Lợi ích này đến từ cơ chế chú ý tự cộng, trong đó thông tin không gian được nén thành vector truy vấn toàn cục để điều tiết đặc trưng, thay vì tính attention đầy đủ giữa mọi cặp token. Nhờ đó, ASA hạn chế sự phân mảnh đặc trưng và giảm lan truyền nhiễu trong ảnh phổ, đồng thời vẫn duy trì khả năng khai thác ngữ cảnh toàn cục. Khi bổ sung PS path, cấu hình sử dụng efficient self-attention đạt 59.44% mAcc và 44.48% mIoU, trong khi cấu hình sử dụng ASA đạt 62.56% mAcc và 46.48% mIoU. So với cấu hình ASA không có PS, SR và SF, việc bổ sung PS giúp tăng 4.02 điểm mAcc và 2.54 điểm mIoU. Điều này cho thấy PS path có vai trò quan trọng trong việc học phân bố mẫu tín hiệu. Trong ảnh phổ, các vùng tín hiệu thuộc cùng một lớp thường có sự nhất quán về phân bố năng lượng và cấu trúc thời gian-tần số. PS path khai thác đặc điểm này thông qua các mô-đun ngữ cảnh cục bộ, giúp mô hình tái tạo các vùng tín hiệu có cấu trúc đồng nhất hơn. Lợi ích của PS thể hiện rõ ở mức SNR thấp, khi mAcc tại -10 dB tăng từ 30.15% lên 34.22% trong cấu hình dùng ASA, cho thấy nhánh này hỗ trợ mô hình nhận diện tốt hơn các vùng tín hiệu bị nhiễu. Khi bổ sung SR path, cấu hình dùng ASA đạt 64.68% mAcc và 50.11% mIoU, cao hơn đáng kể so với cấu hình chỉ dùng PS. So với cấu hình ASA không có các nhánh bổ sung, SR giúp tăng 6.14 điểm mAcc và 6.17 điểm mIoU. Đây là mức cải thiện lớn nhất trong các cấu hình chỉ sử dụng một thành phần. Kết quả này phản ánh vai trò của SR path trong việc tinh chỉnh biên và tăng cường chi tiết không gian của vùng tín hiệu. Về mặt kiến trúc, SR path sử dụng Spatial Refinement Module (SRM), trong đó embedding pha được tạo từ các hàm sin và cos để mô hình hóa sự biến đổi không gian cục bộ. Cơ chế scale-shift dựa trên đặc trưng ngữ cảnh toàn cục giúp SRM điều tiết đặc trưng không gian, từ đó làm rõ các vùng chuyển tiếp giữa tín hiệu và nhiễu. Điều này đặc biệt quan trọng đối với bài toán phân đoạn

ảnh phổ, vì ranh giới giữa các lớp tín hiệu thường bị mờ trong điều kiện nhiễu hoặc chồng lấn phổ. Đối với SF, cấu hình dùng ASA đạt 64.28% mAcc và 49.89% mIoU. So với cấu hình ASA không có các thành phần bổ sung, SF giúp tăng 5.74 điểm mAcc và 5.95 điểm mIoU. Kết quả này cho thấy cơ chế hợp nhất thích nghi có vai trò quan trọng trong việc điều phối các nguồn đặc trưng khác nhau. SF sử dụng tín hiệu điều khiển để cân bằng giữa đặc trưng không gian và đặc trưng mẫu tín hiệu, nhờ đó mô hình có thể ưu tiên thông tin phù hợp tùy theo cấu trúc của ảnh phổ. Khi vùng tín hiệu có biên rõ hoặc chi tiết cục bộ quan trọng, nhánh tính chỉnh không gian có thể được nhấn mạnh; ngược lại, khi cần tái tạo các vùng tín hiệu rộng và đồng nhất, thông tin từ nhánh tổng hợp mẫu tín hiệu trở nên quan trọng hơn. Cơ chế này giúp ASTA-Net tránh phụ thuộc cứng vào một nguồn đặc trưng duy nhất. Cấu hình đầy đủ của ASTA-Net, kết hợp ASA với PS, SR và SF, đạt hiệu suất cao nhất trong bảng với 72.59% mAcc tổng thể và 58.10% mIoU. So với cấu hình đầy đủ dùng efficient self-attention, mô hình dùng ASA cải thiện mAcc từ 71.74% lên 72.59% và mIoU từ 56.78% lên 58.10%. Đồng thời, số tham số giảm từ 11.6M xuống 11.0M và độ trễ giảm từ 6.15 ms xuống 5.06 ms. Điều này cho thấy ASA không chỉ có lợi trong các cấu hình đơn lẻ, mà còn tiếp tục phát huy hiệu quả khi kết hợp với toàn bộ kiến trúc ba luồng. Xét theo các mức SNR, cấu hình đầy đủ của ASTA-Net đạt 37.28%, 58.26% và 60.75% mAcc lần lượt tại -10 , 10 và 30 dB. So với cấu hình đầy đủ dùng efficient self-attention, mô hình dùng ASA cải thiện hiệu suất ở cả ba mức SNR. Điều này cho thấy ASA, PS, SR và SF không chỉ cải thiện hiệu suất trung bình mà còn hỗ trợ mô hình duy trì khả năng phân đoạn trong nhiều điều kiện nhiễu khác nhau. Ở SNR thấp, PS giúp mô hình giữ được phân bố mẫu tín hiệu, SR hỗ trợ nhận diện vùng biên bị suy giảm, còn SF hợp nhất các đặc trưng này một cách thích nghi. Tổng hợp các kết quả trên, ASTA-Net thể hiện rõ vai trò là mô hình cân bằng giữa độ chính xác và chi phí tính toán. So với ASTRA-Net, ASTA-Net đạt hiệu suất cao hơn nhờ kiến trúc ba luồng kết hợp ngữ cảnh toàn cục, phân bố mẫu tín hiệu và tính chỉnh không gian. So với SpecDiff, ASTA-Net không cần quá trình khử nhiễu lặp trong không gian tiềm ẩn nên có thời gian suy luận thấp hơn. Với 72.59% mAcc, 58.10% mIoU, 11.0M tham số và độ trễ 5.06 ms, ASTA-Net cung cấp một điểm cân bằng hợp lý giữa hiệu năng phân đoạn và khả năng triển khai thực tế.

Phân tích siêu tham số và hàm mất mát của ASTA-Net

Bên cạnh nghiên cứu cắt bỏ các thành phần kiến trúc, ASTA-Net còn được đánh giá thông qua phân tích siêu tham số và hàm mất mát phụ. Mục tiêu của thí nghiệm này là xác định cấu hình huấn luyện phù hợp cho hàm mất mát tổng, đồng thời kiểm chứng vai trò của hàm mất mát tổng hợp (aggregation loss) trong việc cải thiện độ phân biệt đặc trưng. Cụ thể, ba siêu tham số được khảo sát gồm trọng số của hàm mất mát tổng hợp λ_{ag} , hệ số nhiệt độ τ trong không gian prototype, và trọng số của cross-entropy loss λ_{ce} .

Bảng 4.1 cho thấy hiệu suất của ASTA-Net phụ thuộc đáng kể vào lựa chọn các siêu tham




Hình 4.1: Phân tích độ nhạy của các siêu tham số trong ASTA-Net.

số trong hàm mất mát tổng. Đối với λ_{ag} , mAcc tăng dần khi trọng số này tăng từ 0.1 đến 0.5, đạt giá trị cao nhất 71.69% tại $\lambda_{ag} = 0.5$, sau đó giảm khi λ_{ag} tiếp tục tăng. Điều này cho thấy hàm mất mát tổng hợp có vai trò tích cực trong việc tăng tính compact của đặc trưng cùng lớp, nhưng nếu trọng số quá lớn, thành phần này có thể lấn át mục tiêu phân đoạn chính và làm giảm khả năng tối ưu hóa mask cuối cùng. Đối với hệ số nhiệt độ τ , giá trị tốt nhất đạt được tại $\tau = 0.3$ với 71.69% mAcc. Khi τ quá nhỏ, phân phối xác suất trong không gian prototype trở nên quá sắc nét, khiến quá trình tối ưu có thể trở nên nhạy với nhiễu và các điểm ảnh khó. Ngược lại, khi τ quá lớn, ràng buộc giữa embedding và prototype trở nên mềm hơn, làm giảm khả năng gom cụm đặc trưng cùng lớp. Do đó, $\tau = 0.3$ cung cấp mức cân bằng phù hợp giữa tính phân biệt liên lớp và độ compact nội lớp. Đối với λ_{ce} , hiệu suất cao nhất đạt 72.02% tại $\lambda_{ce} = 0.7$. Khi λ_{ce} quá thấp, thành phần giám sát pixel-level chưa đủ mạnh để tối ưu hóa bản đồ phân đoạn cuối. Ngược lại, khi λ_{ce} quá cao, mô hình có xu hướng phụ thuộc nhiều vào dự đoán điểm ảnh riêng lẻ, làm giảm tác dụng của hàm mất mát tổng hợp trong việc điều chỉnh cấu trúc đặc trưng. Vì vậy, cấu hình $\lambda_{ce} = 0.7$, $\lambda_{ag} = 0.5$ và $\tau = 0.3$ được lựa chọn như thiết lập cân bằng giữa độ chính xác phân đoạn và độ bền vững của biểu diễn đặc trưng.

Nghiên cứu cắt bỏ hàm mất mát phụ

Để đánh giá vai trò của hàm mất mát tổng hợp, nghiên cứu này so sánh bốn cấu hình huấn luyện phụ trên PS path, gồm không sử dụng loss phụ, sử dụng Dice loss, sử dụng cross-entropy



Hình 4.2: So sánh ảnh hưởng của các hàm mất mát phụ trong ASTA-Net theo các mức SNR.

loss và sử dụng hàm mất mát tổng hợp theo các mức SNR khác nhau.

Từ Bảng 4.2, có thể thấy việc bổ sung loss phụ trên PS path giúp cải thiện hiệu suất so với cấu hình không sử dụng loss phụ. Khi không có loss phụ, mô hình đạt trung bình 65.43% mAcc và 50.70% mIoU. Dice loss cải thiện mAcc trung bình lên 66.50% và mIoU lên 51.28%, cho thấy việc tối ưu độ chồng lấn vùng phân đoạn có tác động tích cực đến chất lượng mask. Tuy nhiên, Dice loss chủ yếu tập trung vào độ tương đồng vùng và chưa trực tiếp tăng tính phân biệt của đặc trưng trong không gian embedding. Khi sử dụng cross-entropy loss làm loss phụ, hiệu suất tiếp tục tăng lên 67.65% mAcc và 52.27% mIoU. Điều này cho thấy giám sát pixel-level trên PS path giúp mô hình học đặc trưng có liên hệ trực tiếp hơn với nhãn phân đoạn. Tuy nhiên, cross-entropy loss vẫn tối ưu từng điểm ảnh tương đối độc lập, nên chưa đảm bảo được sự compact của các đặc trưng cùng lớp trong không gian biểu diễn. hàm mất mát tổng hợp đạt hiệu suất tốt nhất ở tất cả các mức SNR, với mAcc trung bình 68.51% và mIoU trung bình 53.22%. Đặc biệt, ở mức SNR 30 dB, hàm mất mát tổng hợp đạt 75.12% mAcc và 60.39% mIoU, cao hơn rõ rệt so với các loss phụ còn lại. Kết quả này cho thấy hàm mất mát tổng hợp không chỉ cải thiện dự đoán điểm ảnh, mà còn giúp các đặc trưng thuộc cùng một lớp tin hiệu tiến gần nhau hơn trong không gian embedding. Nhờ đó, mô hình học được các cụm đặc trưng ổn định hơn cho 5G NR, LTE, ASR và Noise, đặc biệt trong các điều kiện có nhiễu hoặc chồng lấn tín hiệu. Kết quả trên xác nhận vai trò của hàm mất mát tổng hợp trong ASTA-Net. Loss này bổ sung cho cross-entropy loss bằng cách tăng tính compact nội lớp và khả năng phân biệt liên lớp của đặc trưng trên PS path. Vì vậy, việc sử dụng hàm mất mát tổng hợp giúp ASTA-Net cải thiện độ bền vững của biểu diễn, đồng thời nâng cao

Bảng 4.4: Phân tích độ nhạy của siêu tham số.

Method	Hyperparameters			mAcc (%)	mIoU (%)
	λ_{ag}	λ_{ce}	τ		
ASTA-Net (Fig. 4.1)	0.1	1	1	68.35	54.21
	0.2	1	1	69.43	55.18
	0.3	1	1	69.56	55.32
	0.4	1	1	70.95	56.45
	0.5	1	1	71.69	57.21
	0.6	1	1	70.55	56.12
	0.7	1	1	69.48	55.23
	0.8	1	1	69.23	54.98
	0.9	1	1	67.88	53.64
	1.0	1	1	67.56	53.10
	1	0.1	1	64.47	50.32
	1	0.2	1	66.14	51.85
	1	0.3	1	67.49	53.12
	1	0.4	1	68.39	54.02
	1	0.5	1	69.65	55.19
	1	0.6	1	70.62	56.11
	1	0.7	1	72.02	57.48
	1	0.8	1	69.80	55.34
	1	0.9	1	68.74	54.29
	1	1.0	1	67.56	53.10
	1	1	0.1	68.15	54.08
	1	1	0.2	69.19	55.02
	1	1	0.3	71.69	57.15
	1	1	0.4	69.09	54.92
	1	1	0.5	68.00	53.81
	1	1	0.6	67.56	53.44
	1	1	0.7	67.28	53.11
	1	1	0.8	66.93	52.75
	1	1	0.9	66.81	52.61
	1	1	1.0	66.30	52.14

Bảng 4.5: Phân tích ablation của các hàm mất mát phụ.

Method	SNR	Auxiliary loss			mAcc (%)	mIoU (%)
		Dice	CE	Ag		
ASTA-Net (Fig. 4.2)	-10	X	X	X	53.24	37.67
		✓	X	X	54.35	38.20
		X	✓	X	54.74	39.12
		X	X	✓	54.81	39.65
	0	X	X	X	62.17	47.56
		✓	X	X	62.28	48.54
		X	✓	X	63.50	48.55
		X	X	✓	63.76	48.94
	10	X	X	X	69.34	54.52
		✓	X	X	71.67	55.61
		X	✓	X	73.11	56.80
		X	X	✓	74.27	57.30
	20	X	X	X	70.91	56.57
		✓	X	X	71.82	56.77
		X	✓	X	73.44	57.46
		X	X	✓	74.61	59.81
	30	X	X	X	71.48	57.17
		✓	X	X	72.39	57.30
		X	✓	X	73.44	59.44
		X	X	✓	75.12	60.39


chất lượng phân đoạn trong nhiều điều kiện SNR khác nhau.

Chi tiết số liệu đánh giá siêu tham số và hàm mất mát

Để cung cấp cơ sở định lượng chi tiết cho các phân tích trực quan ở hai phần trên, Bảng 4.4 tổng hợp đầy đủ các giá trị mAcc và mIoU thu được từ các cấu hình thực nghiệm.

4.2 Phân tích lỗi phân đoạn bằng ma trận nhầm lẫn

Ma trận nhầm lẫn trong Hình 4.3 được sử dụng để phân tích chi tiết khả năng phân đoạn theo từng lớp tín hiệu, gồm ASR, 5G NR, LTE và Noise. Các phần tử trên đường chéo chính biểu diễn tỷ lệ dự đoán đúng của từng lớp, trong khi các phần tử ngoài đường chéo phản ánh xu hướng nhầm lẫn giữa các lớp. Nhìn chung, cả ba mô hình đều cho kết quả tốt nhất trên lớp ASR, cho thấy đặc trưng phổ của tín hiệu radar có tính phân biệt cao hơn so với các tín hiệu thông tin di động và nhiễu nền. Đối với ASTRA-Net, độ chính xác theo từng lớp lần lượt đạt 85.12% đối với



Hình 4.3: Ma trận nhầm lẫn của ASTRA-Net, ASTA-Net và SpecDiff.

ASR, 70.45% đối với 5G NR, 55.28% đối với LTE và 66.83% đối với Noise. Mặc dù mô hình nhận diện tương đối tốt lớp ASR, các nhầm lẫn giữa LTE, 5G NR và Noise vẫn còn đáng kể. Cụ thể, 25.25% pixel LTE bị dự đoán thành Noise, 17.84% pixel LTE bị nhầm thành 5G NR, và 27.14% pixel Noise bị nhầm thành 5G NR. Điều này cho thấy ASTRA-Net còn gặp khó khăn trong việc phân biệt các vùng phổ có năng lượng thấp, biên không rõ hoặc có cấu trúc gần giống nhiễu.

Khi chuyển sang ASTA-Net, các giá trị trên đường chéo chính đều được cải thiện so với ASTRA-Net. Cụ thể, độ chính xác của ASR tăng từ 85.12% lên 88.27%, 5G NR tăng từ 70.45% lên 73.14%, LTE tăng từ 55.28% lên 58.62%, và Noise tăng từ 66.83% lên 70.33%. Các mức cải thiện lần lượt là 3.15, 2.69, 3.34 và 3.50 điểm phần trăm. Kết quả này cho thấy ASTA-Net khai thác hiệu quả hơn các đặc trưng không gian và ngữ cảnh trong ảnh phổ, từ đó cải thiện khả năng phân biệt giữa các lớp tín hiệu. Tuy nhiên, một số nhầm lẫn vẫn còn tồn tại, đặc biệt là LTE bị nhầm thành Noise ở mức 24.52% và Noise bị nhầm thành 5G NR ở mức 25.14%. Điều này phản ánh rằng các vùng LTE có cường độ yếu hoặc bị nhiễu che phủ vẫn dễ bị mô hình hấp thụ vào lớp Noise, trong khi một số vùng nhiễu có cấu trúc cục bộ tương tự tín hiệu thông tin có thể bị nhận diện nhầm thành 5G NR.

Trong ba mô hình, SpecDiff đạt kết quả tốt nhất trên hầu hết các lớp, với độ chính xác lần


lượt là 90.43% đối với ASR, 75.61% đối với 5G NR, 62.18% đối với LTE và 72.38% đối với Noise. So với ASTA-Net, SpecDiff cải thiện thêm 2.16 điểm phần trăm ở lớp ASR, 2.47 điểm phần trăm ở lớp 5G NR, 3.56 điểm phần trăm ở lớp LTE và 2.05 điểm phần trăm ở lớp Noise. Đặc biệt, tỷ lệ LTE bị nhầm thành 5G NR giảm từ 17.84% ở ASTRA-Net xuống còn 12.54% ở SpecDiff, cho thấy khả năng phân biệt giữa các tín hiệu thông tin có cấu trúc phổ gần nhau đã được cải thiện. Tuy vậy, các nhầm lẫn giữa LTE và Noise, cũng như giữa Noise và 5G NR, vẫn chưa được loại bỏ hoàn toàn; cụ thể, LTE vẫn bị nhầm thành Noise ở mức 24.89% và Noise bị nhầm thành 5G NR ở mức 24.61%. Kết quả này cho thấy SpecDiff cải thiện rõ rệt chất lượng phân đoạn tổng thể nhờ khả năng tinh chỉnh và khôi phục cấu trúc vùng tín hiệu, nhưng bài toán phân biệt các vùng phổ yếu, không liên tục hoặc có biên mờ vẫn là một thách thức đáng kể. Nhìn chung, xu hướng từ ASTRA-Net đến ASTA-Net và SpecDiff cho thấy sự cải thiện nhất quán về khả năng phân đoạn, trong đó ASTRA-Net phù hợp với định hướng mô hình gọn nhẹ, ASTA-Net đạt sự cân bằng hơn về hiệu năng, còn SpecDiff cho khả năng phân biệt lớp tốt nhất trong ba mô hình được đánh giá.

4.3 Hiệu năng phân đoạn dưới các điều kiện kênh truyền

4.3.1 Sự bền vững của mô hình trong môi trường nhiễu

Để đánh giá khả năng bền vững của các mô hình trong môi trường nhiễu, thí nghiệm được thực hiện trên các mức SNR khác nhau, gồm -10 , 0 , 10 , 20 và 30 dB. Khi SNR thấp, thành phần nhiễu nền chiếm ưu thế so với tín hiệu hữu ích, làm cho các vùng năng lượng trong ảnh phổ trở nên kém rõ ràng, biên thời gian-tần số bị mờ và các vùng tín hiệu yếu dễ bị che lấp. Đối với bài toán phân đoạn ảnh phổ, hiện tượng này không chỉ làm giảm khả năng nhận diện đúng lớp tín hiệu, mà còn ảnh hưởng trực tiếp đến việc khôi phục hình dạng và ranh giới của vùng phổ. Vì vậy, mIoU thường thấp hơn mAcc trong môi trường nhiễu mạnh: mô hình có thể dự đoán đúng một phần lớn vùng tín hiệu chính, nhưng chỉ cần sai lệch tại biên hoặc bỏ sót các vùng năng lượng yếu thì tỷ lệ giao-hợp giữa dự đoán và nhãn thực sẽ giảm đáng kể.


Hình 4.4 cho thấy hiệu năng của cả ba mô hình đều tăng khi SNR được cải thiện. Ở mức -10 dB, các mô hình đạt kết quả thấp nhất do ảnh phổ bị nhiễu nền che phủ mạnh; mAcc của ASTRA-Net, ASTA-Net và SpecDiff lần lượt là 34.08%, 37.28% và 41.46%, trong khi mIoU tương ứng là 24.85%, 27.94% và 31.20%. Khi SNR tăng từ -10 dB lên 10 dB, cả mAcc và mIoU đều cải thiện rõ rệt, cho thấy các cấu trúc phổ đặc trưng của 5G NR, LTE và ASR trở nên dễ phân biệt hơn khi nhiễu nền giảm xuống. Tuy nhiên, từ 20 dB đến 30 dB, tốc độ cải thiện bắt đầu chậm lại; chẳng hạn, mAcc của ASTRA-Net chỉ tăng từ 56.47% lên 58.02%, ASTA-Net tăng từ 60.18%



Hình 4.4: So sánh mAcc và mIoU của ASTRA-Net, ASTA-Net và SpecDiff theo các mức SNR khác nhau.

lên 60.75%, và SpecDiff tăng từ 63.86% lên 64.41%. Điều này cho thấy ở vùng SNR cao, nhiễu không còn là yếu tố giới hạn chính, mà hiệu năng bắt đầu phụ thuộc nhiều hơn vào độ phân giải ảnh phổ, mức độ chồng lấn giữa các tín hiệu, sự tương đồng hình thái của các vùng phổ và năng lực biểu diễn của từng kiến trúc.

Xét theo từng mô hình, SpecDiff duy trì hiệu năng cao nhất trên toàn bộ dải SNR, đạt 64.41% mAcc và 56.33% mIoU tại 30 dB. Kết quả này phù hợp với định hướng thiết kế của SpecDiff, trong đó cơ chế sinh và tinh chỉnh đặc trưng hỗ trợ tốt hơn cho việc khôi phục cấu trúc vùng tín hiệu trong điều kiện nhiễu. ASTA-Net đạt hiệu năng trung gian, thể hiện khả năng cân bằng giữa trích xuất đặc trưng cục bộ, khai thác ngữ cảnh và chi phí tính toán; tại 30 dB, mô hình đạt 60.75% mAcc và 51.64% mIoU. Trong khi đó, ASTRA-Net có hiệu năng thấp hơn hai mô hình còn lại nhưng vẫn duy trì xu hướng tăng ổn định theo SNR, cho thấy mô hình phù hợp hơn với định hướng gọn nhẹ và suy luận nhanh. Nhìn chung, kết quả trong Hình 4.4 cho thấy cả ba mô hình đều có khả năng thích nghi khi điều kiện nhiễu được cải thiện, đồng thời phản ánh rõ sự đánh đổi giữa độ chính xác phân đoạn, khả năng bền vững và mức độ phức tạp của từng kiến trúc.



Hình 4.5: So sánh mAcc và mIoU của ASTRA-Net, ASTA-Net và SpecDiff theo các mức SNR tại các mức dịch Doppler khác nhau.

4.3.2 Ảnh hưởng đồng thời của dịch Doppler và SNR đến độ chính xác phân đoạn

Bên cạnh nhiễu nền, dịch Doppler cũng là một yếu tố quan trọng ảnh hưởng đến hình dạng của tín hiệu trong ảnh phổ. Dịch Doppler xuất hiện khi có chuyển động tương đối giữa nguồn phát, máy thu hoặc vật phản xạ, làm thay đổi tần số quan sát được của tín hiệu. Trong miền thời gian-tần số, hiện tượng này có thể làm vùng phổ bị lệch, giãn hoặc biến dạng so với trường hợp tĩnh. Khi kết hợp với SNR thấp, các vùng năng lượng vốn đã yếu càng dễ bị che phủ bởi nhiễu, khiến mô hình khó xác định chính xác cả lớp tín hiệu lẫn ranh giới phân đoạn. Do đó, ảnh hưởng của Doppler không chỉ thể hiện ở việc giảm mAcc, mà còn làm mIoU suy giảm mạnh hơn do lỗi biên và lỗi chồng khớp vùng dự đoán trở nên rõ rệt.

Hình 4.5 cho thấy ở các mức Doppler thấp, cụ thể 0 Hz và 5 Hz, cả ba mô hình đều cải thiện rõ khi SNR tăng. Trong trường hợp $f_D = 0$ Hz, tín hiệu không bị dịch tần nên cấu trúc phổ được

giữ ổn định hơn; vì vậy hiệu năng tăng tương đối nhanh khi SNR chuyển từ vùng thấp sang vùng trung bình. Ở mức 30 dB, ASTRA-Net đạt 62.1% mAcc và 54.1% mIoU, ASTA-Net đạt 67.4% mAcc và 58.9% mIoU, trong khi SpecDiff đạt 74.0% mAcc và 65.2% mIoU. Khi Doppler tăng nhẹ lên 5 Hz, xu hướng cải thiện theo SNR vẫn được duy trì nhưng hiệu năng giảm so với trường hợp không có Doppler, đặc biệt ở mIoU. Điều này cho thấy ngay cả dịch Doppler nhỏ cũng có thể làm biến phổ kém ổn định hơn, khiến bài toán phân đoạn cấp pixel trở nên khó hơn so với chỉ phân loại sự hiện diện của tín hiệu.

Khi Doppler tăng lên 70 Hz và 500 Hz, ảnh hưởng của biến dạng phổ trở nên rõ rệt hơn. Ở các mức SNR thấp như -10, 0 và 10 dB, hiệu năng thường tăng chậm do tín hiệu vừa bị nhiễu che phủ vừa bị dịch tần làm sai lệch hình dạng phổ. Chẳng hạn tại $f_D = 500$ Hz, mAcc của SpecDiff chỉ tăng từ 36.1% lên 41.5% khi SNR thay đổi từ -10 dB đến 10 dB, trong khi mIoU tăng từ 20.2% lên 27.0%. Tuy nhiên, khi SNR đạt 20 dB và 30 dB, các mô hình bắt đầu phục hồi đáng kể do vùng tín hiệu trở nên rõ hơn, giúp giảm tác động của nhiễu lên quá trình trích xuất đặc trưng. Trong toàn bộ các mức Doppler, SpecDiff vẫn duy trì hiệu năng cao nhất nhờ khả năng tinh chỉnh và khôi phục cấu trúc vùng tín hiệu, ASTA-Net giữ vai trò cân bằng giữa hiệu năng và độ phức tạp, còn ASTRA-Net có hiệu năng thấp hơn nhưng vẫn duy trì xu hướng tăng nhất quán theo SNR. Kết quả này cho thấy khả năng bền vững của mô hình trong môi trường thực tế cần được đánh giá đồng thời theo cả nhiễu nền và dịch Doppler, thay vì chỉ xét riêng từng yếu tố.

4.3.3 Chi tiết số liệu hiệu năng dưới tác động của nhiễu SNR và Doppler


Bảng 4.6 cung cấp chi tiết các số liệu định lượng về mAcc và mIoU cho các biểu đồ phân tích tác động của SNR và dịch Doppler đã được trình bày ở các phần trên.

Bảng 4.6: Đánh giá hiệu suất của các mô hình theo môi trường nhiễu

Method	Doppler (Hz)	SNR (dB)				
		-10	0	10	20	30
		mAcc (%) / mIoU (%)				
ASTRA-Net ASTA-Net SpecDiff	(Fig. 4.4)	34.08 / 24.85	43.96 / 34.72	55.31 / 45.18	56.47 / 47.36	58.02 / 48.22
		37.28 / 27.94	49.63 / 39.88	58.26 / 48.76	60.18 / 50.92	60.75 / 51.64
		41.46 / 31.20	55.72 / 44.36	61.08 / 52.84	63.86 / 55.67	64.41 / 56.33
(Fig. 4.5)						
ASTRA-Net	0	33.82 / 26.08	44.53 / 35.17	57.64 / 46.81	60.78 / 52.15	62.43 / 54.48
	5	33.15 / 25.29	43.58 / 34.12	56.11 / 45.34	59.47 / 50.82	61.21 / 53.37
	70	29.42 / 17.54	33.09 / 20.12	39.23 / 25.38	47.91 / 35.76	53.48 / 42.73
	500	27.84 / 15.08	30.51 / 17.18	34.12 / 20.27	44.48 / 32.14	50.18 / 39.42
ASTA-Net	0	39.12 / 29.23	50.64 / 40.51	63.13 / 51.68	66.82 / 57.77	67.88 / 59.42
	5	38.21 / 28.38	49.48 / 39.42	61.62 / 50.48	65.38 / 56.43	66.72 / 58.00
	70	33.42 / 20.18	37.53 / 23.09	43.58 / 30.54	54.71 / 42.87	60.82 / 51.78
	500	31.18 / 17.83	34.12 / 20.14	38.23 / 24.48	51.48 / 38.92	57.34 / 47.53
SpecDiff	0	44.53 / 34.58	57.18 / 45.83	69.52 / 58.12	73.84 / 64.48	74.62 / 65.87
	5	43.58 / 33.82	56.13 / 44.58	68.22 / 56.88	72.38 / 63.14	73.41 / 64.53
	70	38.48 / 24.53	42.42 / 28.18	49.13 / 34.08	61.18 / 49.32	66.43 / 57.18
	500	33.14 / 19.48	34.82 / 19.43	38.47 / 23.82	53.62 / 39.68	59.18 / 48.53

4.4 Ảnh hưởng của kích thước ảnh phổ đối với hiệu suất mô hình

Kích thước ảnh phổ có ảnh hưởng trực tiếp đến mức độ bảo toàn thông tin thời gian–tần số của tín hiệu. Với kích thước nhỏ, đặc biệt là 64×64 , các chi tiết cục bộ như biên phổ, vùng năng lượng hẹp và các cấu trúc tín hiệu yếu dễ bị nén hoặc làm mờ trong quá trình biểu diễn. Điều này làm giảm khả năng nhận biết ranh giới giữa tín hiệu và nền, từ đó ảnh hưởng đến chất lượng phân đoạn ở cấp pixel. Kết quả trong Hình 4.6 cho thấy ở kích thước 64×64 , ASTRA-Net đạt 64.23% mAcc và 47.20% mIoU, ASTA-Net đạt 65.98% mAcc và 51.29% mIoU, trong khi SpecDiff đạt 70.92% mAcc và 57.39% mIoU. Sự chênh lệch này cho thấy SpecDiff có khả năng duy trì đặc trưng phân đoạn tốt hơn trong điều kiện ảnh phổ bị giảm độ chi tiết, trong khi ASTA-Net giữ vai trò trung gian và ASTRA-Net có xu hướng bị ảnh hưởng rõ hơn bởi việc giảm kích thước đầu vào.



Hình 4.6: Ảnh hưởng của kích thước ảnh phổ đến mAcc và mIoU của ASTRA-Net, ASTA-Net và SpecDiff.

Khi kích thước ảnh phổ tăng từ 64×64 lên 128×128 và 256×256 , hiệu năng của cả ba mô hình đều được cải thiện. Đối với ASTRA-Net, mAcc tăng từ 64.23% lên 69.42%, còn mIoU tăng từ 47.20% lên 55.36% khi kích thước tăng đến 256×256 . ASTA-Net cũng cải thiện từ 65.98% lên 71.51% về mAcc và từ 51.29% lên 56.40% về mIoU. Trong cùng điều kiện, SpecDiff đạt 75.18% mAcc và 61.35% mIoU, tiếp tục duy trì kết quả cao nhất trong ba mô hình. Tại kích thước 256×256 , SpecDiff cao hơn ASTA-Net 3.67 điểm phần trăm về mAcc và 4.95 điểm phần trăm về mIoU.

mIoU; đồng thời cao hơn ASTRA-Net 5.76 điểm phần trăm về mAcc và 5.99 điểm phần trăm về mIoU. Sự cải thiện này cho thấy kích thước 256×256 cung cấp đủ độ chi tiết để các mô hình khai thác hiệu quả hơn cấu trúc vùng phổ, đặc biệt là các vùng biên và các tín hiệu có cường độ thấp.

Tuy nhiên, khi tiếp tục tăng kích thước từ 256×256 lên 512×512 , mức cải thiện trở nên hạn chế hơn, cho thấy hiệu năng bắt đầu tiến gần trạng thái bão hòa. Cụ thể, ASTRA-Net chỉ tăng từ 69.42% lên 70.22% mAcc và từ 55.36% lên 56.33% mIoU. ASTA-Net tăng từ 71.51% lên 73.34% mAcc và từ 56.40% lên 57.44% mIoU. Đối với SpecDiff, mức tăng còn nhỏ hơn ở mAcc, từ 75.18% lên 75.39%, trong khi mIoU tăng từ 61.35% lên 62.17%. Mặc dù 512×512 vẫn cho kết quả cao nhất, mức cải thiện so với 256×256 không lớn, đặc biệt khi xét đến chi phí tính toán và bộ nhớ thường tăng theo kích thước ảnh đầu vào. Do đó, trong phạm vi thí nghiệm này, kích thước 256×256 có thể được xem là lựa chọn cân bằng hơn giữa chất lượng phân đoạn và hiệu quả xử lý, trong khi 512×512 chủ yếu mang lại lợi ích bổ sung ở mức biên.

4.4.1 Chi tiết số liệu hiệu năng và tốc độ suy luận theo độ phân giải

Bảng 4.7: Phân tích ảnh hưởng của độ phân giải hình ảnh đến hiệu suất của các mô hình (Hình 4.6)

Method	Image Resolution	mAcc (%)	mIoU (%)	Speed (ms)
ASTRA-Net	64×64	64.23	47.20	1.06
	128×128	66.55	50.36	1.57
	256×256	69.42	54.36	2.36
	512×512	70.22	56.33	6.34
ASTA-Net	64×64	65.98	51.29	5.2
	128×128	67.80	53.14	11.8
	256×256	71.51	56.40	20.3
	512×512	73.34	58.44	68.4
SpecDiff	64×64	70.92	57.39	2.60
	128×128	73.02	59.23	3.97
	256×256	75.18	61.35	8.60
	512×512	75.39	62.17	29.01

Bảng 4.7 cung cấp chi tiết các số liệu định lượng cho biểu đồ phân tích ảnh hưởng của kích thước ảnh phổ ở phần trước. Đồng thời, bảng cũng bổ sung thêm thông số về thời gian suy luận để đánh giá khả năng đáp ứng thời gian thực của từng kiến trúc mô hình.

4.5 So sánh các mô hình đề xuất với các mô hình phân đoạn tiên tiến

Bảng 4.8 trình bày kết quả so sánh giữa ba mô hình đề xuất và các mô hình phân đoạn tiên tiến. Các mô hình được đánh giá trên hai nhóm tiêu chí chính: chất lượng phân đoạn, gồm mAcc và mIoU, và chi phí tính toán, gồm số tham số, FLOPs và thời gian suy luận. Trong bài toán

Bảng 4.8: Performance Comparison with State of the Art Semantic Segmentation Models

Method	Backbone	mAcc (%)	mIoU (%)	Params (M)	FLOPs (G)	Speed (ms)
Twins [61]	Twins-PCPVT-S	59.19	44.52	24.0	7.42	6.45
SegFormer [27]	MiT-B1	60.40	45.81	14.0	4.59	3.91
SegNeXt [33]	MSCAN-S	61.99	47.23	13.9	6.12	4.45
DeepLabV3+ [62]	ResNet34	63.97	48.84	22.0	9.23	12.61
DPSegNet [63]	-	65.52	50.63	7.0	8.95	7.09
PRMNet [64]	-	65.92	51.05	14.5	16.07	5.63
SRNet [65]	ResNet34	66.88	51.64	24.7	8.15	6.47
UNet++ [59]	ResNet34	67.31	51.95	26.0	18.48	14.91
UPerNet [30]	Swin-T	68.31	53.46	59.0	56.03	10.9
ASTRA-Net (ours)	-	69.42	55.36	6.0	3.89	2.36
ASTA-Net (ours)	-	72.59	58.10	11.0	6.34	5.06
SpecDiff (ours)	-	75.18	61.35	12.0	12.25	8.60

phân đoạn ảnh phổ, việc chỉ xét mAcc hoặc mIoU là chưa đủ, vì một mô hình có độ chính xác cao nhưng có số tham số lớn, FLOPs cao hoặc độ trễ lớn sẽ khó đáp ứng các yêu cầu triển khai trong hệ thống cảm biến phổ gần thời gian thực. Do đó, phần so sánh này tập trung phân tích đồng thời cả hiệu năng và độ phức tạp của từng phương pháp.

Đối với nhóm mô hình phân đoạn tổng quát, Twins đạt 59.19% mAcc và 44.52% mIoU, với 24.0M tham số, 7.42G FLOPs và thời gian suy luận 6.45 ms. Mặc dù mô hình này có khả năng học đặc trưng toàn cục, hiệu năng phân đoạn trên ảnh phổ vẫn còn thấp so với các phương pháp còn lại. Điều này cho thấy các cơ chế trích xuất đặc trưng được thiết kế cho ảnh tự nhiên chưa thật sự phù hợp với các vùng phổ có biên mờ, cấu trúc hẹp và dễ bị nhiễu hóa. SegFormer đạt 60.40% mAcc và 45.81% mIoU, sử dụng 14.0M tham số, 4.59G FLOPs và đạt độ trễ 3.91 ms. So với Twins, SegFormer có chi phí tính toán thấp hơn và tốc độ nhanh hơn, nhưng mIoU vẫn chỉ đạt dưới 46%, cho thấy mô hình còn hạn chế trong việc khôi phục chính xác vùng tín hiệu ở cấp pixel. SegNeXt đạt 61.99% mAcc và 47.23% mIoU, với 13.9M tham số, 6.12G FLOPs và 4.45 ms. Mặc dù SegNeXt cải thiện nhẹ so với SegFormer, hiệu năng vẫn còn cách xa các mô hình đề xuất, đặc biệt ở chỉ số mIoU.

DeepLabV3+ đạt 63.97% mAcc và 48.84% mIoU, với 22.0M tham số, 9.23G FLOPs và độ trễ 12.61 ms. So với SegFormer và SegNeXt, DeepLabV3+ cải thiện hiệu năng nhờ khả năng khai thác ngữ cảnh đa tỉ lệ, nhưng chi phí suy luận lại tăng đáng kể. Độ trễ 12.61 ms cho thấy mô hình này không thật sự thuận lợi cho các hệ thống cần xử lý nhanh. UNet++ đạt 67.31% mAcc và 51.95% mIoU, sử dụng 26.0M tham số, 18.48G FLOPs và có thời gian suy luận 14.91 ms. Mô hình này cho kết quả cao hơn DeepLabV3+, nhưng độ phức tạp lớn do cấu trúc kết nối dày đặc làm tăng chi phí tính toán và độ trễ. UPerNet là mô hình đối sánh có hiệu năng cao nhất trong nhóm nền, đạt 68.31% mAcc và 53.46% mIoU. Tuy nhiên, mô hình này cũng có chi phí lớn nhất trong bảng, với 59.0M tham số, 56.03G FLOPs và thời gian suy luận 10.9 ms. Điều này cho thấy


UPerNet có khả năng biểu diễn mạnh, nhưng yêu cầu tài nguyên rất lớn, chưa phù hợp với các kịch bản triển khai nhẹ hoặc yêu cầu độ trễ thấp.

Đối với các mô hình gần hơn với bài toán phân đoạn ảnh phổ, DPSegNet đạt 65.52% mAcc và 50.63% mIoU, với 7.0M tham số, 8.95G FLOPs và thời gian suy luận 7.09 ms. DPSegNet có số tham số tương đối thấp, nhưng FLOPs và độ trễ vẫn còn cao so với mức hiệu năng đạt được. PRMNet đạt 65.92% mAcc và 51.05% mIoU, sử dụng 14.5M tham số, 16.07G FLOPs và có tốc độ 5.63 ms. Mặc dù PRMNet cải thiện nhẹ so với DPSegNet, mức tăng về mAcc và mIoU không lớn, trong khi FLOPs tăng đáng kể. Điều này cho thấy việc bảo toàn đặc trưng độ phân giải cao có thể hỗ trợ phân đoạn ảnh phổ, nhưng cũng làm tăng chi phí tính toán. SRNet đạt 66.88% mAcc và 51.64% mIoU, với 24.7M tham số, 8.15G FLOPs và độ trễ 6.47 ms. So với PRMNet, SRNet có mAcc và mIoU cao hơn, nhưng lại cần nhiều tham số hơn. Nhìn chung, các mô hình chuyên biệt cho ảnh phổ đã cải thiện hiệu năng so với nhiều kiến trúc tổng quát, nhưng vẫn còn hạn chế về khả năng cân bằng giữa độ chính xác, số tham số và tốc độ suy luận.

ASTRA-Net vượt qua toàn bộ các mô hình đối sánh về sự cân bằng giữa hiệu năng và chi phí tính toán. Mô hình đạt 69.42% mAcc và 55.36% mIoU, cao hơn UPerNet với 68.31% mAcc và 53.46% mIoU. Đáng chú ý, ASTRA-Net chỉ sử dụng 6.0M tham số và 3.89G FLOPs, thấp hơn rõ rệt so với 59.0M tham số và 56.03G FLOPs của UPerNet. Về thời gian suy luận, ASTRA-Net đạt 2.36 ms, nhanh nhất trong toàn bộ bảng. So với SegFormer, mô hình vốn có độ trễ 3.91 ms, ASTRA-Net vừa nhanh hơn vừa đạt mAcc và mIoU cao hơn đáng kể. So với SRNet, ASTRA-Net cải thiện từ 66.88% lên 69.42% về mAcc và từ 51.64% lên 55.36% về mIoU, trong khi số tham số giảm từ 24.7M xuống 6.0M. Tuy nhiên, điểm hạn chế của ASTRA-Net là hiệu năng vẫn thấp hơn ASTA-Net và SpecDiff, cho thấy mô hình này ưu tiên tốc độ và tính gọn nhẹ hơn là tối đa hóa chất lượng phân đoạn.

ASTA-Net đạt 72.59% mAcc và 58.10% mIoU, cao hơn ASTRA-Net ở cả hai chỉ số. So với ASTRA-Net, mAcc tăng từ 69.42% lên 72.59%, trong khi mIoU tăng từ 55.36% lên 58.10%. Mức cải thiện này cho thấy các cơ chế khai thác ngữ cảnh, tổng hợp đặc trưng và tinh chỉnh không gian trong ASTA-Net giúp mô hình biểu diễn ảnh phổ tốt hơn. So với UPerNet, ASTA-Net cũng cho kết quả cao hơn, với 72.59% mAcc so với 68.31% và 58.10% mIoU so với 53.46%. Đồng thời, ASTA-Net chỉ cần 11.0M tham số và 6.34G FLOPs, thấp hơn nhiều so với UPerNet. Tuy nhiên, so với ASTRA-Net, ASTA-Net có chi phí lớn hơn, với số tham số tăng từ 6.0M lên 11.0M, FLOPs tăng từ 3.89G lên 6.34G và độ trễ tăng từ 2.36 ms lên 5.06 ms. Vì vậy, ASTA-Net phù hợp với các kịch bản cần hiệu năng cao hơn ASTRA-Net nhưng vẫn muốn duy trì chi phí tính toán ở mức hợp lý.

SpecDiff đạt hiệu năng tốt nhất trong toàn bộ bảng, với 75.18% mAcc và 61.35% mIoU. So với ASTA-Net, SpecDiff cải thiện từ 72.59% lên 75.18% về mAcc và từ 58.10% lên 61.35% về mIoU. So với ASTRA-Net, mức cải thiện còn rõ hơn, từ 69.42% lên 75.18% về mAcc và từ 55.36%



Hình 4.7: Qualitative comparison between SpecDiff segmentation results and the corresponding ground truths at different SNR levels: (a) -10 dB, (b) 0 dB, (c) 10 dB, (d) 20 dB and (e) 30 dB.

lên 61.35% về mIoU. Khi so với UPerNet, SpecDiff cũng cho thấy ưu thế rõ rệt, đạt 75.18% mAcc so với 68.31% và 61.35% mIoU so với 53.46% . Mặc dù vậy, SpecDiff có chi phí tính toán cao nhất trong ba mô hình đề xuất, với 12.0M tham số, 12.25G FLOPs và thời gian suy luận 8.60 ms. Độ trễ này vẫn thấp hơn UPerNet, DeepLabV3+ và UNet++, nhưng cao hơn ASTRA-Net và ASTA-Net. Do đó, SpecDiff phù hợp hơn với các kịch bản ưu tiên chất lượng phân đoạn, đặc biệt khi cần khôi phục tốt cấu trúc vùng tín hiệu và biên phổ, nhưng không phải là lựa chọn tối ưu nhất nếu yêu cầu chính là tốc độ suy luận thấp nhất.

Tổng thể, kết quả trong Bảng 4.8 cho thấy các mô hình đề xuất không chỉ đạt hiệu năng cao hơn các phương pháp đối sánh mà còn thể hiện rõ các định hướng thiết kế khác nhau. ASTRA-Net là lựa chọn gọn nhẹ nhất, với 6.0M tham số, 3.89G FLOPs và 2.36 ms, phù hợp cho các hệ thống cần tốc độ cao. ASTA-Net đạt sự cân bằng tốt hơn giữa hiệu năng và chi phí, với 72.59% mAcc, 58.10% mIoU, 11.0M tham số và 5.06 ms. SpecDiff đạt hiệu năng cao nhất với 75.18% mAcc và 61.35% mIoU, nhưng cần nhiều FLOPs và thời gian suy luận hơn. Các kết quả này cho thấy việc thiết kế mô hình chuyên biệt cho ảnh phổ có hiệu quả hơn so với việc áp dụng trực tiếp các mô hình phân đoạn tổng quát, đồng thời cung cấp ba lựa chọn phù hợp với các yêu cầu triển khai khác nhau: ASTRA-Net cho tốc độ, ASTA-Net cho cân bằng và SpecDiff cho chất lượng phân đoạn.

Hình 4.7 trực quan hóa hiệu năng phân đoạn của mô hình SpecDiff qua các mức tỷ số tín hiệu trên nhiễu (SNR) khác nhau. Trong các kịch bản có mức SNR cao (10 dB, 20 dB và 30 dB)

như được minh họa lần lượt tại Hình 4.7c, Hình 4.7d và Hình 4.7e, mô hình dự đoán ra các mặt nạ phân đoạn có độ chính xác cao, bám sát nhãn gốc với các ranh giới tín hiệu sắc nét.

Ngược lại, dưới các điều kiện vô tuyến thách thức hơn ở mức SNR thấp (-10 dB và 0 dB) tương ứng tại Hình 4.7a và Hình 4.7b, SpecDiff vẫn bảo toàn được cấu trúc tín hiệu chủ đạo, mặc dù sự mơ hồ cục bộ có thể xuất hiện tại các vùng tín hiệu mạng di động yếu. Quan sát tại Hình 4.7a, tín hiệu LTE bị nhận diện thiếu một phần do đặc tính băng thông rộng làm phân tán năng lượng, dẫn đến mật độ phổ cục bộ giảm xuống dưới ngưỡng phân biệt của mô hình.

Đối với trường hợp 0 dB (Hình 4.7b), vùng phân mảnh bị dự đoán nhầm thành 5G NR không đại diện cho một tín hiệu truyền dẫn 5G NR vật lý bổ sung, cũng không phải là hiện tượng phân tách tất định do kênh truyền gây ra. Thực chất, đây là một dự đoán dương tính giả mang tính cục bộ của mô hình khi gặp phải tình trạng mờ nhòe tín hiệu nghiêm trọng ở mức SNR thấp. Quá trình biến dạng kênh truyền và tác động của nhiễu nền đã làm giảm mức độ tương phản phổ và làm mờ ranh giới tín hiệu; hệ quả là một số điểm ảnh mang đặc điểm của LTE hoặc bị nhiễu lẫn át lại có hình thái biểu diễn tương đồng với các đặc trưng của tín hiệu 5G NR.

Chương 5

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 KẾT LUẬN

Trong bối cảnh phổ tần vô tuyến ngày càng trở nên đông đúc do sự cùng tồn tại của nhiều hệ thống thông tin và radar, bài toán cảm biến phổ thông minh đóng vai trò quan trọng trong việc nhận dạng, giám sát và quản lý tài nguyên phổ một cách hiệu quả. Đặc biệt, sự chồng lấn giữa các tín hiệu 5G NR, LTE và ASR trong miền thời gian–tần số đặt ra nhiều thách thức cho các phương pháp nhận dạng truyền thống, nhất là trong điều kiện nhiễu cao, dịch Doppler, fading đa đường và biên tín hiệu không rõ ràng. Trước yêu cầu đó, luận văn đã tiếp cận bài toán theo hướng phân đoạn ngữ nghĩa ảnh phổ, trong đó tín hiệu vô tuyến được chuyển đổi sang biểu diễn thời gian–tần số bằng STFT, sau đó được xử lý như một ảnh đầu vào để dự đoán bản đồ nhân ở cấp pixel.

Trên cơ sở bài toán đã đặt ra, luận văn đã nghiên cứu và xây dựng hệ thống phân đoạn ảnh phổ cho bốn lớp chính, gồm 5G NR, LTE, ASR và Noise. Thay vì chỉ xem cảm biến phổ như một bài toán phát hiện sự tồn tại của tín hiệu, hướng tiếp cận phân đoạn ngữ nghĩa cho phép xác định chi tiết vùng chiếm dụng phổ của từng lớp tín hiệu trong miền thời gian–tần số. Đây là điểm quan trọng vì trong các hệ thống phổ chia sẻ, việc biết chính xác tín hiệu xuất hiện ở đâu, kéo dài trong khoảng thời gian nào và chiếm dụng vùng tần số nào có ý nghĩa thực tiễn cao hơn so với chỉ nhận biết tín hiệu có tồn tại hay không.

Luận văn đã đề xuất và đánh giá ba định hướng mô hình khác nhau. ASTRA-Net được thiết kế theo hướng gọn nhẹ và tốc độ cao, phù hợp với các hệ thống cần suy luận nhanh hoặc có tài nguyên tính toán hạn chế. ASTA-Net được xây dựng nhằm đạt sự cân bằng giữa hiệu năng

phân đoạn và chi phí tính toán, thông qua việc kết hợp các cơ chế trích xuất đặc trưng, tinh chỉnh không gian và hợp nhất đặc trưng. SpecDiff khai thác hướng tiếp cận mô hình tạo sinh trong không gian tiềm ẩn nhằm cải thiện chất lượng tái tạo bản đồ phân đoạn, đặc biệt trong những trường hợp vùng tín hiệu bị nhiễu hóa hoặc có biên không rõ ràng. Ba mô hình này không chỉ khác nhau về kiến trúc mà còn phản ánh ba mục tiêu triển khai khác nhau: tốc độ, cân bằng và chất lượng phân đoạn.

Các kết quả thực nghiệm cho thấy các mô hình đề xuất đều cải thiện hiệu năng khi điều kiện tín hiệu trở nên thuận lợi hơn. Trong thí nghiệm theo SNR, cả mAcc và mIoU đều tăng rõ rệt khi SNR chuyển từ vùng thấp sang vùng trung bình, sau đó bắt đầu bão hòa ở các mức SNR cao hơn. Kết quả này phù hợp với bản chất của ảnh phổ: khi nhiễu nền giảm, vùng năng lượng của tín hiệu trở nên rõ hơn, giúp mô hình dễ xác định lớp và ranh giới phân đoạn hơn. Tuy nhiên, mIoU thường thấp hơn mAcc, cho thấy việc dự đoán đúng lớp của phần lớn pixel chưa đủ để bảo đảm vùng dự đoán có hình dạng và biên khớp hoàn toàn với nhãn thực. Điều này khẳng định rằng mIoU là một chỉ số quan trọng trong đánh giá chất lượng phân đoạn ảnh phổ.

Bên cạnh nhiễu nền, luận văn cũng phân tích ảnh hưởng đồng thời của dịch Doppler và SNR. Kết quả cho thấy khi dịch Doppler thấp, các mô hình vẫn cải thiện rõ theo SNR. Tuy nhiên, khi Doppler tăng lên, đặc biệt ở các mức 70 Hz và 500 Hz, hiệu năng tại các mức SNR thấp bị suy giảm đáng kể. Nguyên nhân là do Doppler làm biến dạng cấu trúc phổ, khiến các vùng tín hiệu bị lệch hoặc giãn trong miền thời gian–tần số. Khi hiện tượng này kết hợp với nhiễu nền, mô hình gặp khó khăn hơn trong việc xác định ranh giới chính xác của từng lớp tín hiệu. Mặc dù vậy, khi SNR đạt các mức cao hơn, các mô hình bắt đầu phục hồi hiệu năng, cho thấy khả năng tận dụng thông tin phổ rõ hơn để cải thiện phân đoạn.

Luận văn cũng khảo sát ảnh hưởng của kích thước ảnh phổ đến hiệu suất mô hình. Kết quả cho thấy ảnh phổ có kích thước nhỏ làm mất nhiều chi tiết thời gian–tần số, đặc biệt là các vùng biên và các tín hiệu có cấu trúc hẹp. Khi tăng kích thước lên 128×128 và 256×256 , hiệu năng của các mô hình được cải thiện rõ rệt do biểu diễn ảnh phổ bảo toàn tốt hơn cấu trúc của tín hiệu. Tuy nhiên, khi tăng tiếp lên 512×512 , mức cải thiện trở nên hạn chế, cho thấy hiệu năng bắt đầu bão hòa. Do đó, kích thước 256×256 có thể được xem là lựa chọn cân bằng giữa mức độ chi tiết của ảnh phổ và chi phí xử lý.

Thông qua phân tích ma trận nhầm lẫn, luận văn chỉ ra rằng lớp ASR thường được nhận diện tốt hơn do có đặc trưng phổ tương đối khác biệt so với các tín hiệu thông tin di động. Ngược lại, LTE và Noise là các lớp dễ gây nhầm lẫn hơn, đặc biệt trong các vùng tín hiệu yếu hoặc có biên không rõ ràng. Xu hướng cải thiện từ ASTRA-Net sang ASTA-Net và SpecDiff cho thấy việc tăng cường khả năng biểu diễn đặc trưng, hợp nhất ngữ cảnh và tinh chỉnh bản đồ phân đoạn có tác động tích cực đến chất lượng dự đoán. Trong đó, SpecDiff đạt kết quả tốt nhất về khả năng phân biệt lớp, ASTA-Net thể hiện sự cân bằng ổn định, còn ASTRA-Net vẫn giữ được lợi thế về

tốc độ và độ gọn nhẹ.

So sánh với các mô hình phân đoạn tiên tiến cho thấy các mô hình đề xuất đạt hiệu quả tốt hơn trong cả hiệu năng và khả năng kiểm soát chi phí tính toán. ASTRA-Net đạt kết quả cao hơn nhiều mô hình đối sánh trong khi có số tham số, FLOPs và thời gian suy luận thấp. ASTA-Net tiếp tục cải thiện mAcc và mIoU với chi phí tính toán vẫn ở mức hợp lý. SpecDiff đạt hiệu năng cao nhất, cho thấy tiềm năng của các mô hình tạo sinh trong việc khôi phục cấu trúc bản đồ phân đoạn. Nhìn chung, các kết quả đạt được cho thấy hướng thiết kế mô hình chuyên biệt cho ảnh phổ có hiệu quả hơn so với việc áp dụng trực tiếp các kiến trúc phân đoạn tổng quát từ thị giác máy tính.

Tóm lại, luận văn đã hoàn thành các mục tiêu đặt ra thông qua việc xây dựng quy trình phân đoạn ảnh phổ, thiết kế các mô hình học sâu phù hợp với bài toán cảm biến phổ và đánh giá toàn diện dưới nhiều điều kiện khác nhau. Kết quả nghiên cứu cho thấy các mô hình đề xuất có khả năng nhận dạng và phân đoạn các vùng tín hiệu 5G NR, LTE, ASR và Noise trong ảnh phổ, đồng thời cung cấp các lựa chọn triển khai linh hoạt theo từng yêu cầu cụ thể. ASTRA-Net phù hợp với các hệ thống cần tốc độ cao, ASTA-Net phù hợp với các kịch bản cần cân bằng giữa hiệu năng và chi phí, trong khi SpecDiff phù hợp với những trường hợp ưu tiên chất lượng phân đoạn. Những kết quả này góp phần khẳng định tiềm năng của học sâu và các mô hình tạo sinh trong việc hỗ trợ quản lý phổ tần thông minh cho các hệ thống vô tuyến hiện đại.

5.2 HƯỚNG PHÁT TRIỂN

Mặc dù luận văn đã đạt được các kết quả tích cực, vẫn còn nhiều hướng phát triển có thể được tiếp tục nghiên cứu nhằm nâng cao tính thực tiễn và mở rộng phạm vi ứng dụng của hệ thống. Trước hết, cần tiến hành đánh giá mô hình trên dữ liệu thu nhận từ phần cứng thực tế, chẳng hạn như các nền tảng vô tuyến định nghĩa bằng phần mềm (Software-Defined Radio – SDR). Dữ liệu mô phỏng cho phép kiểm soát tốt các tham số như SNR, Doppler và loại tín hiệu, nhưng dữ liệu thực tế thường chứa nhiều yếu tố phức tạp hơn như nhiễu phần cứng, sai lệch tần số, méo phi tuyến, mất đồng bộ và nhiễu từ môi trường. Việc kiểm chứng trên SDR sẽ giúp đánh giá khách quan hơn độ ổn định, độ trễ, mức tiêu thụ tài nguyên và khả năng triển khai của mô hình trong các hệ thống giám sát phổ thực.

Một hướng phát triển quan trọng khác là mở rộng tập lớp tín hiệu. Trong phạm vi luận văn, hệ thống tập trung vào 5G NR, LTE, ASR và Noise. Tuy nhiên, môi trường phổ tần thực tế có thể bao gồm nhiều loại tín hiệu khác như Wi-Fi, Bluetooth, LoRa, NB-IoT, tín hiệu vệ tinh, tín hiệu UAV hoặc các dạng radar khác. Việc mở rộng bộ dữ liệu và huấn luyện mô hình trên nhiều loại tín hiệu hơn sẽ giúp hệ thống tiến gần hơn đến một công cụ giám sát phổ toàn diện.

Đồng thời, khi số lớp tăng lên, bài toán phân đoạn cũng trở nên khó hơn do sự tương đồng hình thái giữa các tín hiệu và khả năng chồng lấn phổ phức tạp hơn. Vì vậy, cần nghiên cứu thêm các cơ chế học đặc trưng phân biệt lớp, học tương phản hoặc học bán giám sát để nâng cao khả năng tổng quát.

Bên cạnh việc mở rộng dữ liệu, cần tiếp tục cải thiện khả năng hoạt động của mô hình trong các điều kiện kênh truyền khắc nghiệt. Các thí nghiệm trong luận văn đã cho thấy SNR thấp và dịch Doppler cao có thể làm suy giảm đáng kể mIoU, đặc biệt ở các vùng biên hoặc vùng tín hiệu yếu. Trong tương lai, có thể tích hợp thêm các chiến lược tăng cường dữ liệu, mô phỏng kênh truyền phức tạp hơn, hoặc thiết kế các hàm mất mát nhấn mạnh vào vùng biên và các lớp khó phân đoạn. Ngoài ra, có thể nghiên cứu các cơ chế ước lượng độ bất định để mô hình không chỉ đưa ra bản đồ phân đoạn mà còn cho biết mức độ tin cậy của từng vùng dự đoán.

Một định hướng có nhiều tiềm năng là tiếp tục khai thác các mô hình tạo sinh cho bài toán phân đoạn ảnh phổ. Kết quả của SpecDiff cho thấy các mô hình tạo sinh có khả năng hỗ trợ khôi phục cấu trúc vùng tín hiệu và cải thiện chất lượng bản đồ phân đoạn. Trong tương lai, có thể nghiên cứu sâu hơn các hướng như diffusion models, rectified flow, flow matching hoặc consistency models. Các mô hình này có thể được sử dụng để tinh chỉnh bản đồ phân đoạn, khử nhiễu trong không gian tiềm ẩn hoặc sinh ra các mặt nạ phân đoạn có cấu trúc mượt và nhất quán hơn. Đặc biệt, flow matching và rectified flow là các hướng đáng chú ý vì chúng có khả năng mô hình hóa quá trình biến đổi từ nhiễu sang dữ liệu theo quỹ đạo liên tục, đồng thời có thể giảm số bước suy luận so với diffusion truyền thống. Nếu được thiết kế phù hợp, các mô hình này có thể giúp cải thiện chất lượng phân đoạn mà vẫn duy trì độ trễ ở mức chấp nhận được cho các hệ thống cảm biến phổ gần thời gian thực. Ngoài ra, việc tối ưu hóa mô hình cho triển khai trên thiết bị biên cũng là một hướng cần được xem xét. Các kỹ thuật như pruning, quantization, knowledge distillation hoặc thiết kế kiến trúc nhẹ có thể được áp dụng để giảm số tham số, giảm bộ nhớ và tăng tốc suy luận. Điều này đặc biệt quan trọng đối với các hệ thống IoT, trạm thu di động hoặc các nền tảng giám sát phổ phân tán, nơi tài nguyên tính toán bị giới hạn. Với các mô hình có hiệu năng cao nhưng chi phí lớn hơn như SpecDiff, việc kết hợp các kỹ thuật nén mô hình hoặc rút gọn quá trình suy luận sẽ giúp nâng cao khả năng triển khai thực tế.

Cuối cùng, có thể mở rộng nghiên cứu theo hướng học phân tán và học liên kết. Trong các hệ thống cảm biến phổ quy mô lớn, dữ liệu có thể được thu thập từ nhiều thiết bị hoặc nhiều vị trí địa lý khác nhau. Việc truyền toàn bộ dữ liệu phổ về một máy chủ trung tâm có thể gây tốn băng thông và phát sinh vấn đề về quyền riêng tư dữ liệu. Do đó, các phương pháp như federated learning, split learning hoặc collaborative sensing có thể được nghiên cứu để huấn luyện mô hình trên nhiều thiết bị mà không cần tập trung toàn bộ dữ liệu thô. Kết hợp học phân tán với các mô hình phân đoạn ảnh phổ và mô hình tạo sinh có thể mở ra hướng phát triển mới cho các hệ thống quản lý phổ tần thông minh, linh hoạt và có khả năng mở rộng trong tương lai.

TÀI LIỆU THAM KHẢO

- [1] 3GPP TS 36.300, “Evolved Universal Terrestrial Radio Access (E-UTRA) and Evolved Universal Terrestrial Radio Access Network (E-UTRAN); overall description; stage 2,” 3rd Generation Partnership Project; Technical Specification Group Radio Access Network, Technical Specification, 2020, release 16.
- [2] 3GPP TS 38.300, “NR; NR and NG-RAN overall description; stage-2,” 3rd Generation Partnership Project; Technical Specification Group Radio Access Network, Technical Specification, Oct. 2025, version 19.0.0, Release 19.
- [3] C. De Alwis, A. Kalla, Q.-V. Pham, P. Kumar, K. Dev, W.-J. Hwang, and M. Liyanage, “Survey on 6G frontiers: Trends, applications, requirements, technologies and future research,” *IEEE Open Journal of the Communications Society*, vol. 2, pp. 836–886, 2021.
- [4] F. Liu, Y. Cui, C. Masouros, J. Xu, T. X. Han, Y. C. Eldar, and S. Buzzi, “Integrated sensing and communications: Toward dual-functional wireless networks for 6G and beyond,” *IEEE Journal on Selected Areas in Communications*, vol. 40, no. 6, pp. 1728–1767, 2022.
- [5] Z. Liu, X. Chen, H. Wu, Z. Wang, X. Chen, D. Niyato, and K. Huang, “Integrated sensing and edge AI: Realizing intelligent perception in 6G,” *IEEE Communications Surveys & Tutorials*, 2025, early Access.
- [6] N. Abdel Khalek, D. H. Tashman, and W. Hamouda, “Advances in machine learning-driven cognitive radio for wireless networks: A survey,” *IEEE Communications Surveys & Tutorials*, vol. 26, no. 2, pp. 1201–1237, 2024.
- [7] J. Manco, I. Dayoub, A. Nafkha, M. Alibakhshikenari, and H. B. Thameur, “Spectrum sensing using software defined radio for cognitive radio networks: A survey,” *IEEE Access*, vol. 10, pp. 131 887–131 908, Dec. 2022.
- [8] N. C. Luong, X. Lu, D. T. Hoang, D. Niyato, and D. I. Kim, “Radio resource management in joint radar and communication: A comprehensive survey,” *IEEE Communications Surveys & Tutorials*, vol. 23, no. 2, pp. 780–814, 2021.
- [9] J. A. Zhang, M. L. Rahman, K. Wu, X. Huang, Y. J. Guo, S. Chen, and J. Yuan, “Enabling joint communication and radar sensing in mobile networks—a survey,” *IEEE Communications Surveys & Tutorials*, vol. 24, no. 1, pp. 306–345, 2022.

- [10] A. Liu, Z. Huang, M. Li, Y. Wan, W. Li, T. X. Han, C. Liu, R. Du, D. N. Tan, J. Lu, Y. Shen, F. Colone, and K. Chetty, "A survey on fundamental limits of integrated sensing and communication," *IEEE Communications Surveys & Tutorials*, vol. 24, no. 2, pp. 994–1034, 2022.
- [11] F. Liu, C. Masouros, A. P. Petropulu, H. Griffiths, and L. Hanzo, "Joint radar and communication design: Applications, state-of-the-art, and the road ahead," *IEEE Transactions on Communications*, vol. 68, no. 6, pp. 3834–3862, 2020.
- [12] Z. Wei, H. Qu, Y. Wang, X. Yuan, H. Wu, Y. Du, K. Han, N. Zhang, and Z. Feng, "Integrated sensing and communication signals toward 5G-A and 6G: A survey," *IEEE Internet of Things Journal*, vol. 10, no. 13, pp. 11 068–11 092, Jul. 2023.
- [13] X. Kang *et al.*, "Joint detection and classification of communication and radar signals in congested RF environments using YOLOv8," in *Proceedings of IEEE MILCOM*, Washington, DC, USA, Oct. 2024, pp. 1–6.
- [14] T.-D. Tran and T. Huynh-The, "DTANet: High-performance network with decoupled three-dimensional attention for radar-communications waveform classification," *IEEE Communications Letters*, vol. 29, no. 11, pp. 2741–2745, Nov. 2025.
- [15] T. Huynh-The, T.-D. Tran, N. C. Luong, and D. Niyato, "Temporal-frequency-aware deep networks for efficient waveform classification in integrated radar-communication (IRC) systems," *IEEE Internet of Things Journal*, vol. 13, no. 7, pp. 12 613–12 624, Apr. 2026.
- [16] S. Zheng, S. Chen, P. Qi, H. Zhou, and X. Yang, "Spectrum sensing based on deep learning classification for cognitive radios," *China Communications*, vol. 17, no. 2, pp. 138–148, 2020.
- [17] Q. Wang, B. Su, C. Wang, L. P. Qian, Y. Wu, and X. Yang, "ConvLSTM-based spectrum sensing at very low SNR," *IEEE Wireless Communications Letters*, vol. 12, no. 6, pp. 967–971, Jun. 2023.
- [18] K. Chae, J. Park, and Y. Kim, "Rethinking autocorrelation for deep spectrum sensing in cognitive radio networks," *IEEE Internet of Things Journal*, vol. 10, no. 1, pp. 31–41, 2023.
- [19] L. Milosheški, M. Mohorčič, and C. Fortuna, "Spectrum sensing with deep clustering: Label-free radio access technology recognition," *IEEE Open Journal of the Communications Society*, vol. 5, pp. 4746–4763, 2024.
- [20] L. Li *et al.*, "Cooperative spectrum sensing based on LSTM-CNN combination network in cognitive radio system," *IEEE Access*, vol. 11, pp. 87 615–87 625, Aug. 2023.
- [21] W. Zhang *et al.*, "Spectrum Transformer: An attention-based wideband spectrum detector," *IEEE Transactions on Wireless Communications*, vol. 23, no. 9, pp. 12 343–12 353, Sep. 2024.

- [22] H. Jeon, Y. Jung, S. Lee, and Y. Jung, “Area-efficient short-time fourier transform processor for time–frequency analysis of non-stationary signals,” *Applied Sciences*, vol. 10, no. 20, Oct. 2020.
- [23] L. Cai, K. Cao, Y. Wu, and Y. Zhou, “Spectrum sensing based on spectrogram-aware CNN for cognitive radio network,” *IEEE Wireless Communications Letters*, vol. 11, pp. 2135–2139, 2022.
- [24] T. Huynh-The, P.-T. Huynh, and Q.-V. Pham, “Spec-YOLO: An efficient deep network for spectrogram-based signals identification,” *IEEE Wireless Communications Letters*, vol. 14, no. 11, pp. 3550–3554, Nov. 2025.
- [25] P. Subedi, S. Shin, and M. C. Vuran, “Seek and classify: End-to-end joint spectrum segmentation and classification for multi-signal wideband spectrum sensing,” in *Proceedings of the IEEE 49th Conference on Local Computer Networks (LCN)*, Caen, France, Oct. 2024, pp. 1–9.
- [26] S. Minaee, Y. Boykov, F. Porikli, A. Plaza, N. Kehtarnavaz, and D. Terzopoulos, “Image segmentation using deep learning: A survey,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, no. 7, pp. 3523–3542, 2022.
- [27] E. Xie *et al.*, “SegFormer: Simple and efficient design for semantic segmentation with Transformers,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, Virtual Event, Dec. 2021, pp. 12 077–12 090.
- [28] B. Cheng, I. Misra, A. G. Schwing, A. Kirillov, and R. Girdhar, “Masked-attention mask Transformer for universal image segmentation,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022, pp. 1290–1299.
- [29] B. Cheng, A. G. Schwing, and A. Kirillov, “Per-pixel classification is not all you need for semantic segmentation,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, 2021, pp. 27 865–27 878.
- [30] Z. Liu *et al.*, “Swin Transformer: Hierarchical vision Transformer using shifted windows,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, Montreal, QC, Canada, Oct. 2021, pp. 10 012–10 022.
- [31] S. Zheng, J. Lu, H. Zhao, X. Zhu, Z. Luo, Y. Wang, Y. Fu, J. Feng, T. Xiang, P. H. S. Torr, and L. Zhang, “Rethinking semantic segmentation from a sequence-to-sequence perspective with Transformers,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021, pp. 6881–6890.
- [32] R. Strudel, R. Garcia, I. Laptev, and C. Schmid, “Segmenter: Transformer for semantic segmentation,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021, pp. 7262–7272.

- [33] M.-H. Guo *et al.*, “SegNeXt: Rethinking convolutional attention design for semantic segmentation,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, New Orleans, LA, USA, Nov. 2022, pp. 1140–1156.
- [34] K. Han, Y. Wang, H. Chen, X. Chen, J. Guo, Z. Liu, Y. Tang, A. Xiao, C. Xu, Y. Xu, Z. Yang, Y. Zhang, and D. Tao, “A survey on vision Transformer,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 45, no. 1, pp. 87–110, 2023.
- [35] L. Papa *et al.*, “A survey on efficient vision Transformers,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 46, no. 12, 2024.
- [36] W. Deng, X. Wang, and Z. Huang, “Semantic-segmentation-based deep spectrum sensing for cochannel signals,” *IEEE Internet of Things Journal*, vol. 11, no. 23, pp. 37 645–37 660, Dec. 2024.
- [37] T. Huynh-The, G.-V. Nguyen, T.-H. Vu, D. Benevides da Costa, and Q.-V. Pham, “SRNet: Deep semantic segmentation network for spectrum sensing in wireless communications,” *IEEE Wireless Communications Letters*, vol. 14, no. 2, pp. 355–359, Feb. 2025.
- [38] T.-T. Le, D. Benevides da Costa, and T. Huynh-The, “Efficient spectrum sensing via a multi-scale dual-path segmentation network,” *IEEE Wireless Communications Letters*, vol. 14, no. 7, pp. 2134–2138, Jul. 2025.
- [39] H.-T. Nguyen, H.-T. P. Dang, Q.-V. Pham, and T. Huynh-The, “Resolution-preserving multi-scale network for 5G-LTE spectrogram-based spectrum sensing,” *IEEE Wireless Communications Letters*, vol. 14, no. 6, pp. 1673–1677, Jun. 2025.
- [40] H.-T. Nguyen, T.-H. Vu, D. Benevides da Costa, Q.-V. Pham, and T. Huynh-The, “D2SNet: A denoising-to-segmentation network for enhanced 5G-LTE spectrum awareness,” *IEEE Wireless Communications Letters*, vol. 14, no. 12, pp. 3942–3946, Dec. 2025.
- [41] H.-T. P. Dang, H.-T. Nguyen, Q.-V. Pham, V.-C. Phan, and T. Huynh-The, “Adversarial training approach for signal identification in 5G-LTE spectrum sensing,” *IEEE Wireless Communications Letters*, vol. 15, pp. 390–394, 2026.
- [42] —, “Compact spectrum sensing with RpNet+CLRu: Reducing model size for 5G-LTE signal identification,” *IEEE Transactions on Vehicular Technology*, vol. 75, no. 4, pp. 5819–5830, Apr. 2026.
- [43] J. Ho, A. Jain, and P. Abbeel, “Denoising diffusion probabilistic models,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2020, pp. 6840–6851.
- [44] Y. Song, J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, and B. Poole, “Score-based generative modeling through stochastic differential equations,” in *Proceedings of the International Conference on Learning Representations (ICLR)*, 2021.

- [45] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, “High-resolution image synthesis with latent diffusion models,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022, pp. 10 684–10 695.
- [46] F.-A. Croitoru, V. Hondru, R. T. Ionescu, and M. Shah, “Diffusion models in vision: A survey,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2023.
- [47] Y. Lipman, R. T. Q. Chen, H. Ben-Hamu, M. Nickel, and M. Le, “Flow matching for generative modeling,” in *Proceedings of the International Conference on Learning Representations (ICLR)*, 2023.
- [48] S. Chen, P. Sun, Y. Song, and P. Luo, “DiffusionDet: Diffusion model for object detection,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023, pp. 19 830–19 843.
- [49] T. Huynh-The, P.-L. Huynh, V.-C. Phan, T.-H. Vu, and D. Benevides da Costa, “Latent diffusion for spectrum sensing of coexisting radar and communication signals,” *IEEE Wireless Communications Letters*, vol. 15, pp. 1025–1029, 2026.
- [50] P.-L. Huynh, V.-C. Phan, Q.-V. Pham, D. B. da Costa, and T. Huynh-The, “ASTRA-Net: Adaptive spectro-temporal robust architecture for spectrum sensing,” *IEEE Wireless Communications Letters*, vol. 15, pp. 1926–1930, Feb. 2026.
- [51] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *Nature*, vol. 521, no. 7553, pp. 436–444, May 2015.
- [52] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, “Learning representations by back-propagating errors,” *Nature*, vol. 323, no. 6088, pp. 533–536, Oct. 1986.
- [53] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, “Gradient-based learning applied to document recognition,” *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, Nov. 1998.
- [54] F. Chollet, “Xception: Deep learning with depthwise separable convolutions,” in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Honolulu, HI, USA, Jul. 2017, pp. 1251–1258.
- [55] L.-C. Chen, Y. Zhu, G. Papandreou, F. Schroff, and H. Adam, “Encoder-decoder with atrous separable convolution for semantic image segmentation,” in *Proceedings of the European Conference on Computer Vision (ECCV)*, Munich, Germany, Sep. 2018, pp. 833–851.
- [56] C. Yu, J. Wang, C. Peng, C. Gao, G. Yu, and N. Sang, “BiSeNet: Bilateral segmentation network for real-time semantic segmentation,” in *Proceedings of the European Conference on Computer Vision (ECCV)*, Munich, Germany, Sep. 2018, pp. 325–341.

- [57] O. Ronneberger, P. Fischer, T. Brox, J. Hornegger, W. M. Wells, and A. F. Frangi, “U-Net: Convolutional networks for biomedical image segmentation,” in *International Conference on Medical Image Computing and Computer-Assisted Intervention*, Munich, Germany, Nov. 2015, pp. 234–241.
- [58] Z. Zhou, M. M. Rahman Siddiquee, N. Tajbakhsh, and J. Liang, “UNet++: A nested U-Net architecture for medical image segmentation,” in *Proc. DLMIA and ML-CDS*, Granada, Spain, Sep. 2018, pp. 3–11.
- [59] Z. Zhou *et al.*, “UNet++: Redesigning skip connections to exploit multiscale features in image segmentation,” *IEEE Transactions on Medical Imaging*, vol. 39, no. 6, pp. 1856–1867, Jun. 2020.
- [60] G. Csurka, D. Larlus, F. Perronnin, and F. Meylan, “What is a good evaluation measure for semantic segmentation?” in *24th British Machine Vision Conference*, vol. 27, University of Bristol, 2013, pp. 10–5244.
- [61] X. Chu *et al.*, “Twins: Revisiting the design of spatial attention in vision Transformers,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, Virtual Event, Dec. 2021, pp. 9355–9366.
- [62] T. Huynh-The, Q.-V. Pham, T.-H. Vu, D. B. da Costa, and V.-P. Hoang, “Intelligent spectrum sensing with ConvNet for 5G and LTE signals identification,” in *IEEE Statistical Signal Processing Workshop*, Hanoi, Vietnam, Jul. 2023, pp. 140–144.
- [63] T.-T. Le *et al.*, “Efficient spectrum sensing via a multi-scale dual-path segmentation network,” *IEEE Wireless Communications Letters*, pp. 1–1, Apr. 2025.
- [64] H.-T. Nguyen *et al.*, “Resolution-preserving multi-scale network for 5G-LTE spectrogram-based spectrum sensing,” *IEEE Wireless Communications Letters*, vol. 14, no. 6, pp. 1673–1677, Jun. 2025.
- [65] T. Huynh-The *et al.*, “SRNet: Deep semantic segmentation network for spectrum sensing in wireless communications,” *IEEE Wireless Communications Letters*, vol. 14, no. 2, pp. 355–359, Feb. 2025.

CÔNG BỐ KHOA HỌC

Bài báo thuộc tạp chí quốc tế SCI(E)

1. Phuoc-Long Huynh, Van-Ca Phan, Quoc-Viet Pham, Daniel Benevides da Costa, and Thien Huynh-The, “ASTRA-Net: Adaptive Spectro-Temporal Robust Architecture for Spectrum Sensing,” *IEEE Wireless Communications Letters*, vol. 15, pp. 1926-1930, Feb. 2026. [SCIE, Q1 JCR, IF:5.5] [\[Link\]](#)
2. Thien Huynh-The, Phuoc-Long Huynh, Van-Ca Phan, Thai-Hoc Vu, and Daniel Benevides da Costa, “Latent Diffusion for Spectrum Sensing of Coexisting Radar and Communication Signals,” *IEEE Wireless Communications Letters*, vol. 15, pp. 1025-1029, 2026. [SCIE, Q1 JCR, IF: 5.5] [\[Link\]](#)
3. Thien Huynh-The, Phuoc-Long Huynh, Thai-Hoc Vu, Van-Ca Phan, Son Ngoc Truong, and Quoc-Viet Pham, “Attentive Synergic Tri-stream Additive Network for 5G-LTE-ASR Spectrum Identification,” *IEEE Transactions on Vehicular Technology*. [SCI, Q1 JCR, IF: 7.5] **(Revision resubmitted)**

Bài báo thuộc tạp chí trong danh mục Hội đồng Giáo sư ngành

1. Phuoc-Long Huynh *et al*, “Generative Rectified Flow for Precise Spectrum Identification in Coexisting 5G-LTE and Radar Networks,” *REV Journal on Electronics and Communications*. **(Revision resubmitted)**.